

**“PREDICTIVE MAINTENANCE” MESIN
KOMPRESOR RECIPROCATING BERBASIS
*MACHINE LEARNING***

BAB I

PENDAHULUAN

1.1 Latar Belakang

Teknologi Informasi (TI) di era digital berkembang pesat untuk memenuhi kebutuhan bisnis yang terus berubah serta munculnya teknologi baru secara berkala. Kapabilitas TI yang dinamis mencakup kemampuan untuk memperoleh, menerapkan, mengintegrasikan, dan menata ulang sumber daya TI guna mencapai tujuan bisnis (T. Li & Chan, 2019). *Artificial Intelligence* (AI) merupakan bidang luas dalam teknologi informasi yang melibatkan komputasi, pengembangan perangkat lunak, dan transmisi data. AI diterapkan untuk meningkatkan kinerja di berbagai sektor, seperti kesehatan, organisasi bisnis, industri otomotif dan manufaktur. AI berperan dalam otomatisasi tugas penting, meningkatkan akurasi, dan efisiensi operasional. Teknologi AI mencakup pengenalan suara, robotika, identifikasi biometrik, *deep learning*, dan *machine learning* (Mohammad, 2020). Meskipun AI mencakup berbagai teknologi, *machine learning* adalah salah satu pendorong utama dalam inovasi dan penerapan AI, terutama dalam situasi yang memerlukan analisis data skala besar secara cepat dan efisien (Soliman, Fatnassi, Elgammal, & Figueiredo, 2023).

Machine Learning (ML) atau pembelajaran mesin adalah bidang ilmu komputer yang fokus pada pengembangan algoritma dan teknik untuk menyelesaikan masalah kompleks yang sulit dipecahkan dengan metode pemrograman konvensional (Rebala, Ravi, & Churiwala, 2019). *Machine learning* dibagi menjadi empat kategori yaitu *supervised learning*, *unsupervised learning*, *semi-supervised learning*, dan *reinforcement learning* (Mohammad, 2020). Beberapa algoritma umum dalam *supervised learning* termasuk *Naive Bayes*, *Linear Discriminant Analysis* (LDA), *Logistic Regression*, *K-Nearest Neighbors* (KNN), *Support Vector Machine* (SVM), *Decision Tree* (DT), *Random Forest* (RF), *Adaptive Boosting* (AdaBoost), *Extreme Gradient Boosting* (XGBoost), *Stochastic Gradient Descent* (SGD), dan *Rule-based Classification*. Pada *unsupervised*

learning, algoritma yang sering digunakan untuk clustering antara lain *K-Means*, *Mean-Shift*, *Density-Based Spatial Clustering of Applications with Noise* (DBSCAN), *Gaussian Mixture Models* (GMM), dan *Agglomerative Hierarchical Clustering*. Sementara itu, algoritma umum dalam *reinforcement learning* mencakup *Q-Learning*, *Deep Q-Learning*, dan *Monte Carlo Methods* (I. H. Sarker, 2021). Teknologi *machine learning* telah menjadi populer di bidang aplikasi karena kemampuannya yang luas. Beberapa area aplikasi yang menonjol termasuk keamanan siber dan intelijen ancaman, dimana *machine learning* digunakan untuk mendeteksi ancaman kolaboratif dan mempertimbangkan indikator ancaman (Preuveneers, Joosen, & Privacy, 2021). Pada sektor kesehatan, *machine learning* mampu untuk mendeteksi dan mendiagnosis COVID-19 dengan akurasi yang tinggi melalui penggunaan berbagai jenis descriptor tekstur (Medeiros, Machado, de Freitas, da Silva, & de Souza, 2024). Selain itu, teknologi ini juga digunakan dalam pengenalan gambar, ucapan, dan pola, dengan hasil yang menjanjikan dalam mendeteksi kanker ginjal (Galić, Stojanović, & Čajić, 2024). Analisis prediktif dan pengambilan keputusan yang cerdas membuka banyak peluang untuk meningkatkan efisiensi dan produktivitas di sektor industri (Elkateb, Métwalli, Shendy, & Abu-Elanien, 2024).

Kompresor reciprocating merupakan alat mekanis penting dalam industri modern seperti kimia, kilang, transportasi gas, dan penyimpanan gas (Giampaolo, 2023). Kompresor ini memiliki kapasitas yang besar dan kemampuan memberikan tekanan gas yang tinggi, mulai dari pengkondisian udara hingga pengisian tekanan udara pada ban kendaraan (Xing, Feng, He, & Peng, 2021). Kompresor reciprocating memiliki beberapa kelebihan antara lain efisiensi tinggi, kemampuan kompresi, kemampuan perawatan, fleksibilitas, dan biaya operasional rendah (Lv, Yu, Ma, Ye, Wu, & Wang, 2021). Namun, dalam dekade terakhir tuntutan ekonomi telah memengaruhi operasional kompresor reciprocating, dimana banyak kasus memaksa kompresor bekerja pada kapasitas penuh tanpa cadangan dengan menuntut kinerja yang andal. Tantangan ini mengakibatkan kelelahan dan keausan tetap menjadi masalah yang tak terhindarkan (Cerrada, Montalvo, Zambrano, Cabrera, & Sánchez, 2022). Jenis kegagalan yang paling

umum pada kompresor reciprocating meliputi kegagalan segel piston, kegagalan bantalan, dan kegagalan katup. Kegagalan segel piston dapat menyebabkan kebocoran fluida yang dikompresi, berpotensi mengakibatkan kebakaran atau ledakan. Sementara itu, kegagalan bantalan dapat mengakibatkan getaran berlebihan yang memengaruhi komponen lainnya. Kegagalan katup juga dapat mengganggu operasi dan memicu masalah pada sistem lain (Medina, Sánchez, Cabrera, Cerrada, Estupiñan, Ao, & Vásquez, 2024). Katup yang rusak merupakan alasan paling umum untuk penghentian yang tidak terjadwal, dengan persentase sekitar 36%, diikuti oleh cincin piston sekitar 7% (Yu, Zhang, Hu, & Chen, 2022), dan bantalan dapat mencapai sekitar 16% dari semua kegagalan kompresor (Wu, Li, Zhu, Li, Zhang, Zhang, Yang, Yu, & Wang, 2023). Kerusakan mesin kompresor reciprocating memiliki dampak signifikan, termasuk kerugian ekonomi bagi perusahaan (Lv et al., 2021). Jika kompresor tidak beroperasi pada efisiensi terukurnya, hal ini dapat mengakibatkan kerugian finansial yang besar seperti yang ditunjukkan oleh penelitian Muo (2018) yang mengacu pada Wachel, dimana waktu henti bisa menghabiskan biaya hingga 100.000 USD per hari. Penelitian Shu et al. (2016) menunjukkan bahwa kerugian tahunan akibat pemadaman abnormal di Amerika Serikat saja mencapai setidaknya 2 miliar dolar AS. Selain itu, kompresor reciprocating yang sering digunakan untuk menangani gas mudah terbakar seperti hidrogen, etilena, dan gas alam, dapat menimbulkan ancaman serius bagi keselamatan manusia, seperti yang dikemukakan oleh Lv et al. (2021). Kegagalan kompresor reciprocating dapat menyebabkan waktu henti, kerugian produksi, biaya perawatan, dan potensi bahaya keselamatan, yang menekankan pentingnya strategi pemantauan dan pemeliharaan yang efektif untuk kompresor reciprocating.

Maintenance atau pemeliharaan adalah kegiatan yang bertujuan untuk memastikan kinerja dan keandalan mesin atau sistem, dengan mengurangi risiko kegagalan dan memperpanjang umur operasional (Zonta, Da Costa, da Rosa Righi, de Lima, da Trindade, & Li, 2020). Pemeliharaan terbagi menjadi tiga strategi kategori utama. Pertama adalah *Reactive Maintenance* (RM), dimana tindakan pemeliharaan dilakukan hanya setelah peralatan mengalami kerusakan

atau ketika sudah terlalu parah. Kedua adalah *Preventif Maintenance* (PM), melibatkan pemeliharaan terjadwal berdasarkan waktu yang ditetapkan atau iterasi proses, tanpa mempertimbangkan kondisi aktual dari peralatan. Ketiga adalah *Predictive Maintenance* (PdM), pemantauan kondisi peralatan secara *real-time* untuk memperkirakan kapan kegagalan akan terjadi, sehingga pemeliharaan dapat dilakukan tepat sebelum peralatan tersebut mengalami kerusakan (Ran, Zhou, Lin, Wen, & Deng, 2019). Metode pemeliharaan dan diagnosis kesalahan tradisional, seperti pemeliharaan rutin dan inspeksi manusia secara berkala, sering kali tidak mampu mendeteksi kesalahan dan mencegah kegagalan secara akurat. Metode-metode ini sangat terbatas dalam kemampuannya untuk memprediksi potensi kegagalan sebelum terjadi. Sebaliknya, sistem pemeliharaan prediktif yang menggunakan teknik seperti model rata-rata bergerak terintegrasi autoregresif dan pemodelan diagnosis dan prognosis kesalahan, dapat membantu mendeteksi kesalahan dan mencegah kegagalan. Sistem ini dapat menghemat biaya perawatan dan meningkatkan efektivitas operasional dengan memungkinkan identifikasi kesalahan dini dan pengambilan keputusan proaktif (Varghese, 2023). Pemeliharaan prediktif memiliki dua fokus utama, yaitu peningkatan efisiensi energi atau penghematan energi, dan penurunan waktu berhenti yang tidak terjadwal (Assagaf, Sukandi, Abdillah, Arifin, Ga, & Technology, 2023). Ada berbagai pendekatan teoritis dan praktis yang telah diusulkan dalam penerapan pemeliharaan prediktif. Sebagai contoh, penelitian Elkateb et al. (2024) menggunakan algoritma *machine learning*, yaitu AdaBoost untuk mengklasifikasikan penghentian mesin secara *real-time* untuk pemeliharaan prediktif di industri tekstil. Sementara itu, penelitian L. Wang, Zhu, and Zhao (2024) mengusulkan strategi pemeliharaan prediktif dinamis berbasis data dengan menggunakan metode ansambel *deep learning* untuk prediksi sisa masa manfaat. Bidang transportasi, penelitian H-Nia, Flodin, Casanueva, Asplund, and Stichel (2024) menggunakan metode *Multibody Dynamics Simulations* (MBS) untuk menghitung sisa umur roda dan rel kereta api dalam pemeliharaan prediktif. Sedangkan dalam pengembangan sistem pemeliharaan prediktif pada pompa sentrifugal limbah, penelitian Bahar, Schokry, and Alhanjouri (2023)

menggunakan metode *Seasonal Autoregressive Integrated Moving Average* (SARIMA) untuk peramalan deret waktu dan *Anomaly Detection Toolkit* (ADTK) untuk deteksi anomali. Beberapa skenario aplikasi, kebutuhan akan pemrosesan data dan aliran data yang kompleks secara *real-time* telah terbukti penting. Meskipun model *Autoregressive Integrated Moving Average* (ARIMA) juga telah digunakan untuk deteksi kesalahan dan perkiraan pemeliharaan prediktif dalam deret waktu (Fernandes, Canito, Corchado, & Marreiros, 2019; Francis & Mohan, 2019). Namun, metode ini tidak sefleksibel atau sukses seperti metode *machine learning* (Ayvaz & Alpay, 2021). Oleh karena itu, metode *machine learning* akan menjadi pilihan yang lebih efektif dalam implementasi pemeliharaan prediktif.

Berdasarkan pada kondisi mesin kompresor reciprocating, berbagai penerapan pemeliharaan prediktif maupun *machine learning*, maka peneliti akan mengusulkan mengenai “Predictive Maintenance Pada Mesin Kompresor Reciprocating Berbasis *Machine Learning*”, guna meningkatkan kinerja operasional, meminimalkan *downtime*, dan mengurangi biaya perawatan pada mesin kompresor reciprocating.

1.2 Rumusan Masalah

Berdasarkan pada latar belakang masalah penelitian yang telah diuraikan dan sesuai dengan usulan topik penelitian, maka dirumuskan masalah pokok yang harus diteliti adalah sebagai berikut:

1. Algoritma *machine learning* apa yang paling efektif untuk memprediksi kegagalan pada mesin kompresor reciprocating?
2. Bagaimana membangun model *machine learning* dari algoritma yang terpilih untuk memprediksi kegagalan pada mesin kompresor reciprocating?
3. Bagaimana membangun sistem peringatan pemeliharaan prediktif berbasis *machine learning* pada mesin kompresor reciprocating?
4. Bagaimana kinerja sistem peringatan pemeliharaan prediktif berbasis *machine learning* pada mesin kompresor reciprocating?

1.4 Tujuan Penelitian

Adapun tujuan dari penelitian ini secara umum adalah memberikan solusi untuk pemeliharaan prediktif pada mesin kompresor reciprocating menggunakan *machine learning*. Selain itu, secara khusus tujuan penelitian ini adalah sebagai berikut:

1. Membandingkan efektivitas berbagai algoritma *machine learning* untuk memprediksi kegagalan pada mesin kompresor reciprocating.
2. Menghasilkan model *machine learning* dari algoritma yang terpilih untuk memprediksi kegagalan pada mesin kompresor reciprocating.
3. Menghasilkan prototipe sistem peringatan pemeliharaan prediktif berbasis *machine learning* pada mesin kompresor reciprocating.
4. Mengevaluasi kinerja sistem peringatan pemeliharaan prediktif berbasis *machine learning* pada mesin kompresor reciprocating.

Berdasarkan Tabel 2.1, penelitian Sim et al. (2019) berhasil memanfaatkan sinyal *Acoustic Emission* (AE) untuk mendeteksi kerusakan pada katup kompresor reciprocating. Penelitian tersebut menunjukkan bahwa nilai RMS AE sangat dipengaruhi oleh kondisi katup dan kecepatan kompresor, membuktikan AE sebagai alat diagnosis yang efektif melalui analisis varians dan regresi. Penelitian Loukopoulos et al. (2019) melangkah lebih jauh dengan menggunakan kombinasi metode statistik dan *machine learning* untuk memperkirakan kapan kerusakan akan terjadi (*Remaining Useful Life/RUL*). Penelitian tersebut menunjukkan bahwa metode prognostik yang beragam, seperti metode ensemble memberikan hasil yang lebih baik dibandingkan metode tunggal yang digunakan oleh Sim et al. (2019) dalam meningkatkan akurasi prediksi RUL.

Penelitian Cabrera et al. (2020) mengusulkan metode baru untuk diagnosis kesalahan menggunakan pendekatan *Bayesian* dan pengurangan dimensi deret waktu dengan model LSTM. Hasilnya menunjukkan akurasi pengenalan kesalahan yang lebih tinggi daripada metode lain, yang memperkenalkan penggunaan optimasi *Bayesian* dalam model *deep learning* untuk meningkatkan kinerja. Penelitian Loutas et al. (2020) mengembangkan indikator kesehatan berbasis pengukuran suhu dan PCA untuk estimasi probabilistik tentang RUL. Penelitian tersebut menunjukkan bahwa model *Gradient Boosted Trees* (GBTs) dan *Non-Homogeneous Hidden Semi Markov Models* (NHHSMM) efektif dalam memprediksi RUL, dengan tingkat kepercayaan tinggi menggarisbawahi pentingnya pendekatan probabilistik berbasis data yang memperluas penggunaan metode *machine learning* yang digunakan oleh Loukopoulos et al. (2019).

Penelitian Toroghi and Sadighi (2020) menggunakan *Electrical Signature Analysis* (ESA) untuk mendeteksi kesalahan mekanis pada kompresor, yang menunjukkan bahwa sinyal arus dapat digunakan secara akurat melalui analisis transformasi Fourier (FFT). Metode tersebut menambah dimensi baru dalam deteksi kerusakan dengan metode non-invasif yang berbeda dari AE yang digunakan oleh Sim et al. (2019). Penelitian X. Li et al. (2020) mengembangkan metodologi prognostik menggunakan *Just-in-Time Learning* (JITL) berbasis *Gradient Boosting Decision Tree* (GBDT), menunjukkan bahwa pendekatan ini

mampu mengatasi non-linearitas dan memprediksi RUL dengan akurasi tinggi. Penelitian ini dapat dikatakan melanjutkan perkembangan metode prognostik dari Loukopoulos et al. (2019), memperkenalkan adaptasi langsung berdasarkan kondisi operasi yang beragam.

Penelitian Zou et al. (2020) mengembangkan model evaluasi berbasis *Analytic Hierarchy Process* (AHP) dan *Fuzzy Comprehensive Evaluation* (FCE) untuk strategi pemeliharaan optimal. Penelitian tersebut menunjukkan bahwa metode ini meningkatkan keandalan evaluasi dan memberikan panduan efektif untuk desain dan pemeliharaan kompresor, memperluas aplikasi metode prediktif yang sebelumnya difokuskan pada estimasi RUL. Penelitian Charoenchitt and Tangamchit (2021) mendeteksi kerusakan awal pada kompresor menggunakan autoencoder, menggabungkan data termodinamika dan getaran untuk meningkatkan akurasi prediksi. Pendekatan ini memperkuat penggunaan data sensor yang berbeda untuk deteksi anomali yang telah diinisiasi oleh Toroghi and Sadighi (2020) dengan ESA.

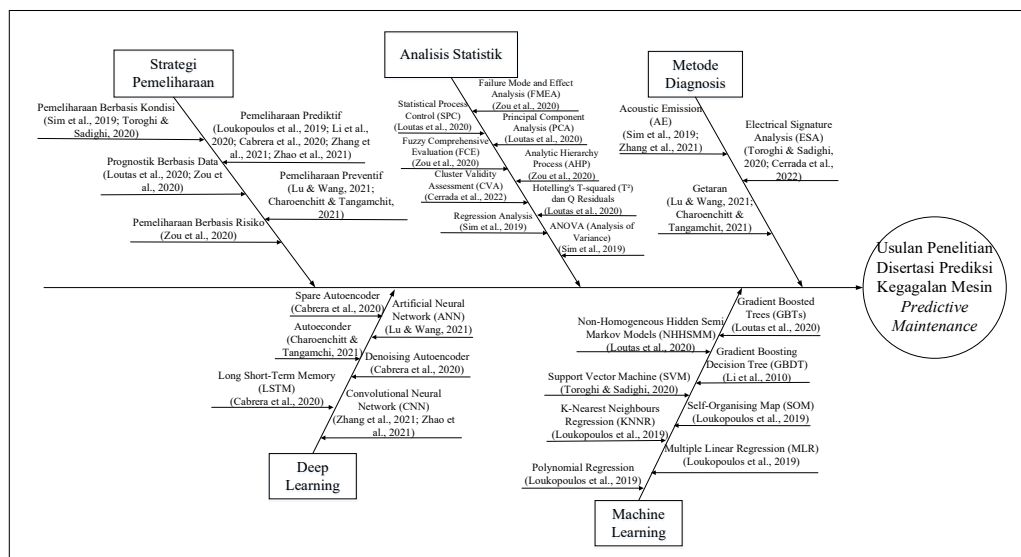
Penelitian Lu and Wang (2021) mengembangkan sistem prediksi kegagalan menggunakan dekomposisi wavelet dan *Artificial Neural Network* (ANN), menunjukkan akurasi hampir 100% dalam deteksi kegagalan. Penelitian tersebut menggabungkan analisis domain waktu dan wavelet untuk meningkatkan fitur ekstraksi dan prediksi, melanjutkan tren dalam penggunaan *machine learning* untuk diagnosis yang dimulai oleh penelitian sebelumnya. Penelitian Zhang et al. (2021) mengevaluasi penggunaan teknologi AE dengan metode *deep learning*, khususnya CNN dan LSTM untuk memprediksi karakteristik dinamis katup. Hasilnya menunjukkan akurasi tinggi dan memperluas penggunaan teknologi AE yang awalnya diusulkan oleh Sim et al. (2019), dengan tambahan kemampuan *deep learning* untuk prediksi yang lebih canggih.

Penelitian Zhao et al. (2021) mengembangkan metodologi deteksi kesalahan menggunakan CNN yang ditingkatkan dengan mekanisme perhatian, mencapai akurasi 99.4% bahkan dalam kondisi bising. Penelitian ini menunjukkan kemampuan CNN yang ditingkatkan dalam pemrosesan fitur global dan akurasi diagnosis tinggi, memperluas kemampuan prediksi *deep learning* yang digunakan

oleh Zhang et al. (2021). Penelitian Cerrada et al. (2022) mengusulkan penggunaan sinyal arus sebagai metode non-intrusif untuk diagnosis kesalahan bantalan, mencapai presisi tinggi dengan metode LAMDA. Penelitian ini menawarkan solusi yang lebih sederhana dan efisien biaya dibandingkan analisis getaran tradisional, menggabungkan pendekatan berbasis data yang telah diterapkan dalam penelitian sebelumnya.

Setiap penelitian membangun fondasi yang sebelumnya dan memperluas metode yang digunakan untuk diagnosis dan prediksi kerusakan kompresor reciprocating. Hal ini menunjukkan perkembangan dari analisis sederhana sinyal AE ke penggunaan kombinasi metode *machine learning* dan data sensor yang lebih kompleks. Sebagaimana penelitian yang akan diusulkan, pengembangan model prediksi kegagalan mesin bertujuan untuk menciptakan sistem pemeliharaan prediktif yang efektif, yang dapat membantu organisasi dalam mengoptimalkan operasi dalam meminimalkan risiko kerusakan.

Konteks analisis penelitian sebelumnya mengenai diagnosis dan prediksi kerusakan pada kompresor reciprocating, diagram *fishbone* dapat digunakan untuk menggambarkan faktor-faktor kunci yang berkontribusi terhadap pengembangan teknologi dan metodologi dalam bidang ini. Berikut diagram fishbone yang mempengaruhi penelitian usulan pengembangan prediksi kegagalan pada kompresor reciprocating yang dapat dilihat pada Gambar 2.4.



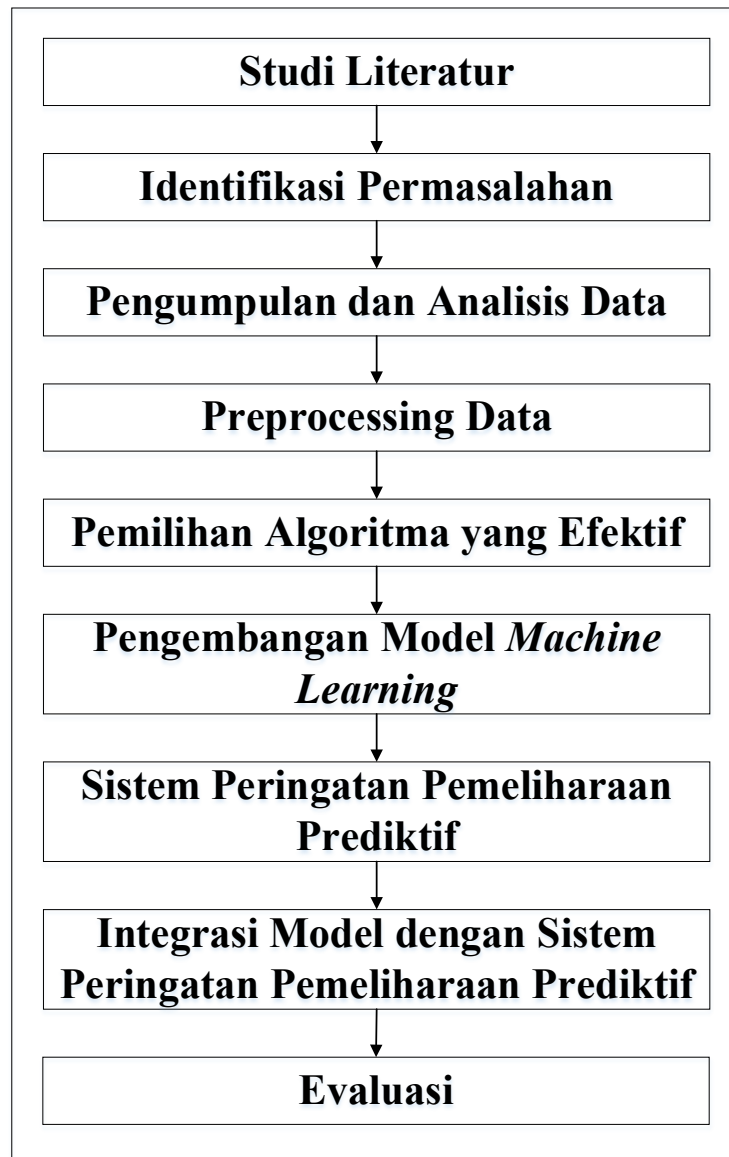
Gambar 2.4 Diagram *Fishbone* Usulan Penelitian Disertasi

BAB III

METODE PENELITIAN

3.1 Tahapan Penelitian

Tahapan penelitian merupakan serangkaian langkah-langkah yang dilakukan dalam penelitian. Gambaran mengenai tahapan penelitian ini dapat dilihat pada Gambar 3.1.



Gambar 3.1 Tahapan Penelitian

Gambar 3.1 menunjukkan tahapan penelitian sebagai dasar untuk pengembangan sistem pemeliharaan prediktif menggunakan teknik *machine*

learning. Tahapan penelitian ini terdiri dari studi literatur untuk memahami keadaan yang terfokus terhadap tentang mesin kompresor reciprocating, metode prediksi pemeliharaan mesin, *predictive maintenance*, dan *machine learning*. Identifikasi permasalahan secara spesifik yang akan diatasi oleh penelitian, termasuk mendefinisikan ruang lingkup serta tujuan dari penelitian. Pengumpulan data yang relevan dan melakukan analisis awal untuk memahami karakteristik dan pola dalam data. Preprocessing data melibatkan pembersihan data, normalisasi, dan transformasi data agar siap digunakan dalam model *machine learning*. Tahap ini bertujuan untuk mengatasi masalah data yang hilang, *outliers*, dan memastikan data berada dalam format yang sesuai. Pemilihan algoritma *machine learning* yang efektif untuk membantu mencapai akurasi yang lebih tinggi dan efisiensi dalam prediksi. Pengembangan dan melatih model *machine learning* menggunakan algoritma yang telah dipilih dengan data yang telah diproses, tahap ini melibatkan pembagian data menjadi set pelatihan dan set pengujian, serta termasuk mengatur parameter model untuk mencapai kinerja terbaik. Sistem peringatan pemeliharaan prediktif menggunakan model *machine learning* untuk memprediksi kegagalan mesin, sistem ini bertujuan untuk memberikan peringatan dini sebelum terjadinya kerusakan atau kegagalan mesin. Integrasi model dengan sistem peringatan pemeliharaan prediktif, tahap ini memastikan bahwa model dapat bekerja secara *real-time* dan memberikan peringatan yang akurat kepada pengguna. Serta tahapan terakhir adalah evaluasi kinerja sistem secara keseluruhan untuk memastikan bahwa sistem peringatan pemeliharaan prediktif berfungsi dengan baik dan mencapai tujuan yang diinginkan.

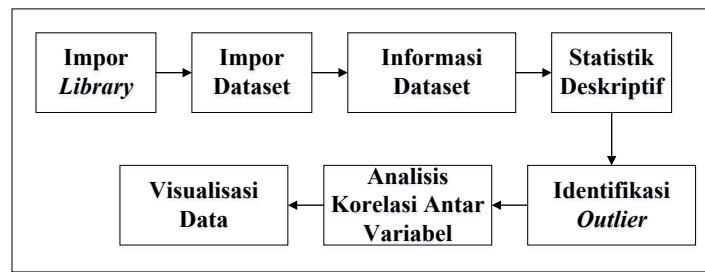
3.2 Pengumpulan dan Analisis Data

Observasi data dilakukan pada platform terpercaya yang menyediakan berbagai dataset publik yaitu *Kaggle*. Data yang digunakan yaitu dataset mesin kompresor reciprocating yang divisualisasikan oleh akun *kaggle* bernama Ahmet Okudan. Dataset tersebut berisi data operasional dari mesin kompresor reciprocating dengan total 1000 sampel. Setiap sampel dalam dataset tersebut mencakup 26 kolom yang berisi informasi dapat dilihat pada Tabel 3.1.

Tabel 3.1 Deskripsi Kolom Dataset Mesin Kompresor Reciprocating

No	Nama Kolom	Deskripsi
1.	ID	Identifikasi unik untuk setiap entri
2.	RPM	Kecepatan putaran mesin dalam rotasi per menit
3.	Motor Power	Daya motor dalam watt
4.	Torque	Torsi yang dihasilkan oleh mesin
5.	Outlet Pressure (bar)	Tekanan keluaran dalam bar
6.	Air Flow	Aliran udara yang diukur
7.	Noise (dB)	Tingkat kebisingan dalam desibel
8.	Outlet Temperature	Suhu keluaran
9.	Water Pump Outlet Pressure	Tekanan keluaran pompa air
10.	Water Inlet Temperature	Suhu air masuk
11.	Water Outlet Temperature	Suhu air keluar
12.	Water Pump Power	Daya pompa air
13.	Water Flow	Aliran air
14.	Oil Pump Power	Daya pompa oli
15.	Oil Tank Temperature	Suhu tangki oli
16.	G-Acceleration X (gaccx)	Akselerasi gravitasi pada sumbu X
17.	G-Acceleration Y (gaccy)	Akselerasi gravitasi pada sumbu Y
18.	G-Acceleration Z (gaccz)	Akselerasi gravitasi pada sumbu Z
19.	H-Acceleration X (haccx)	Akselerasi horizontal pada sumbu X
20.	H-Acceleration Y (haccy)	Akselerasi horizontal pada sumbu Y
21.	H-Acceleration Z (haccz)	Akselerasi horizontal pada sumbu Z
22.	Bearings	Kondisi bearing, misalnya "Ok"
23.	Water Pump	Kondisi pompa air, misalnya "Ok"
24.	Radiator	Kondisi radiator, misalnya "Clean"
25.	Exvalve	Kondisi katup eksvalve, misalnya "Clean"
26.	AC Motor	Kondisi motor AC, misalnya "Stable"

Analisis data penelitian ini menggunakan metode *Exploratory Data Analysis* (EDA) bertujuan untuk memberikan gambaran umum tentang data dan mengidentifikasi pola atau anomali yang mungkin tidak terlihat dengan metode lain. Penerapan metode EDA dalam dataset mesin kompresor reciprocating menggunakan *software python open access* di *notebook jupyter*, gambaran mengenai alur proses analisis data dapat dilihat pada Gambar 3.2.




Gambar 3.2 Alur Proses Analisis Data

Gambar 3.2 menggambarkan alur proses analisis data dengan tahap pertama adalah mengimpor *library* atau pustaka yang diperlukan untuk analisis data. Tahap selanjutnya adalah mengimpor dataset yang akan dianalisis. Tahap berikutnya adalah memeriksa informasi dasar tentang dataset untuk memahami struktur dan isi data. Tahap ini termasuk melihat beberapa baris pertama dataset, tipe data setiap kolom, dan jumlah data. Tahap selanjutnya statistik deskriptif untuk memahami distribusi data seperti *mean*, *median*, *mode*, *standard deviation*, dan *range*. Tahap berikutnya identifikasi *outlier* atau nilai yang jauh berbeda dari data lainnya. *Outlier* dapat mempengaruhi analisis dan model, sehingga perlu diperiksa apakah akan dihapus atau ditangani dengan cara lain. Tahap selanjutnya analisis korelasi dilakukan untuk melihat hubungan antara variabel-variabel dalam dataset. Korelasi membantu memahami bagaimana satu variabel mungkin mempengaruhi variabel lain. Tahap terakhir visualisasi data menggunakan berbagai jenis grafik seperti *histogram*, *scatter plot*, dan *box plot* untuk lebih memahami distribusi dan pola dalam data.

3.3 Preprocessing Data

Preprocessing data sangat penting untuk memastikan bahwa data yang digunakan untuk pelatihan model *machine learning* memiliki kualitas yang tinggi, relevan, dan sesuai. Alur proses data preprocessing pada penelitian ini dapat dilihat pada Gambar 3.3.

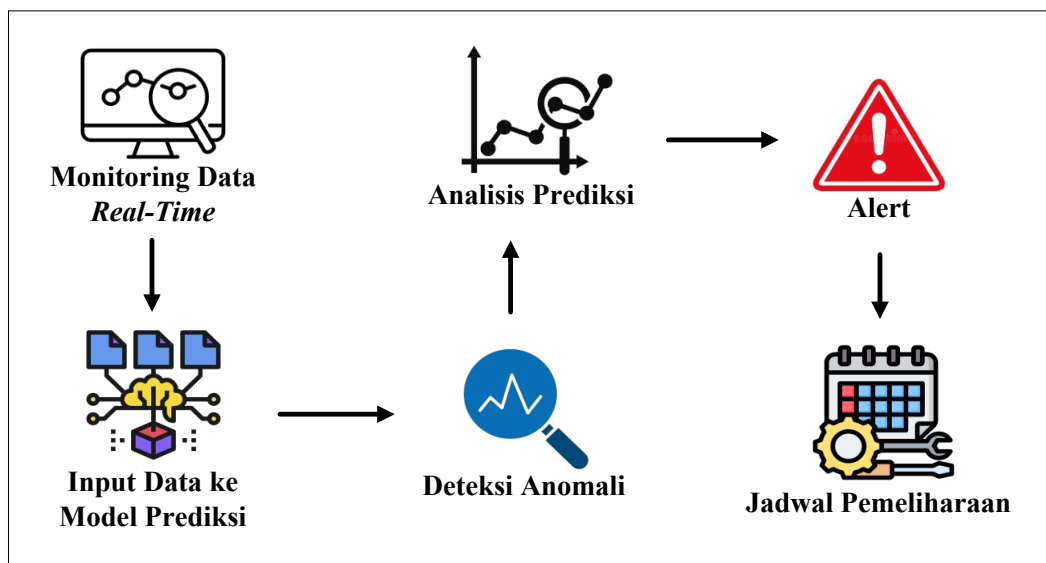


Gambar 3.3 Alur Proses Data Preprocessing

Gambar 3.3 menunjukkan alur proses data preprocessing terdiri dari tahap pertama imputasi dilakukan untuk mengganti nilai yang *outlier* dengan nilai yang lebih representative. Tahap kedua transformasi data untuk memperbaiki distribusi yang tidak normal. Tahap ketiga reduksi dimensi yaitu mengurangi jumlah fitur dalam dataset guna menangani dataset dengan banyak fitur, mengurangi kompleksitas model, dan mencegah overfitting.

3.4 Sistem Peringatan Pemeliharaan Prediktif

Sistem peringatan pemeliharaan prediktif adalah sistem yang menggunakan teknik-teknik analisis data, terutama *machine learning* untuk memantau kondisi mesin dan memprediksi kegagalan yang mungkin terjadi. Penelitian ini mengusulkan sistem untuk memberikan peringatan dini kepada operator atau tim pemeliharaan sehingga tindakan preventif dapat dilakukan sebelum kegagalan terjadi, mengurangi downtime, dan biaya pemeliharaan. Gambaran alur kerja usulan sistem peringatan pemeliharaan prediktif dapat dilihat pada Gambar 3.4.



Gambar 3.4 Alur Kerja Sistem Peringatan Pemeliharaan Prediktif

Gambar 3.4 menggambarkan alur kerja dari sistem pemeliharaan prediktif pada mesin kompresor reciprocating berbasis *machine learning*. Tahap awal adalah data operasional mesin dikumpulkan secara menerus menggunakan sensor, bertujuan memastikan data terkini tersedia untuk dianalisis guna mendeteksi

tanda-tanda awal kegagalan mesin. Tahap kedua menginput data dari pemantauan *real-time* ke dalam model prediksi pemeliharaan yang telah dilatih. Tahap ketiga mendeteksi adanya anomali atau pola yang tidak biasa agar tindakan pencegahan dapat diambil sebelum kerusakan terjadi. Tahap keempat analisis prediksi untuk memperkirakan kapan dan bagaimana kegagalan akan terjadi, sehingga pemeliharaan dapat direncanakan dengan tepat. Tahap kelima *alert* atau peringatan untuk memberikan informasi kepada tim pemeliharaan agar dapat segera mengambil tindakan. Tahap terakhir menjadwalkan tindakan pemeliharaan yang diperlukan berdasarkan peringatan untuk menghindari kegagalan mendadak dan meminimalkan downtime.