



**“PREDICTIVE MAINTENANCE” MESIN  
KOMPRESOR RECIPROCATING BERBASIS  
*MACHINE LEARNING***

**KUALIFIKASI**

Devi Resviani  
99223122

**PROGRAM DOKTOR TEKNOLOGI INFORMASI  
UNIVERSITAS GUNADARMA  
Juni 2024**

## DAFTAR ISI

	Halaman
<b>Cover .....</b>	i
<b>Daftar Isi .....</b>	ii
<b>Daftar Gambar .....</b>	iii
<b>Daftar Tabel .....</b>	iv
<b>BAB I PENDAHULUAN.....</b>	5
1.1 Latar Belakang .....	5
1.2 Rumusan Masalah .....	9
1.3 Batasan Masalah.....	10
1.4 Tujuan Penelitian.....	10
1.5 Kontribusi dan Manfaat Penelitian.....	10
<b>BAB II TELAAH PUSTAKA.....</b>	12
2.1 <i>Artificial Intelligence</i> .....	12
2.2 <i>Machine Learning</i> .....	15
2.3 <i>Predictive Maintenance</i> .....	21
2.4 Mesin Kompresor Reciprocating .....	26
2.5 Perbandingan Penelitian Terdahulu.....	29
<b>BAB III METODE PENELITIAN .....</b>	44
3.1 Tahapan Penelitian .....	44
3.2 Pengumpulan dan Analisis Data .....	45
3.3 Preprocessing Data.....	47
3.4 Sistem Peringatan Pemeliharaan Prediktif.....	48
3.3 Jadwal Penelitian.....	49
<b>DAFTAR PUSTAKA.....</b>	51

## DAFTAR GAMBAR

	<b>Halaman</b>
Gambar 2.1 Biaya Pemeliharaan vs Ketersediaan .....	23
Gambar 2.2 Peristiwa Kekritisan .....	24
Gambar 2.3 Komponen Kompresor Reciprocating.....	27
Gambar 2.4 Diagram Fishbone Usulan Penelitian Disertasi.....	43
Gambar 3.1 Tahapan Penelitian .....	44
Gambar 3.2 Alur Proses Analisis Data .....	47
Gambar 3.3 Alur Proses Data Preprocessing .....	47
Gambar 3.4 Alur Kerja Sistem Peringatan Pemeliharaan Prediktif .....	48

## DAFTAR TABEL

	<b>Halaman</b>
Tabel 2.1 Perbandingan Penelitian Terdahulu.....	30
Tabel 2.1 Perbandingan Penelitian Terdahulu Lanjutan.....	31
Tabel 2.1 Perbandingan Penelitian Terdahulu Lanjutan.....	32
Tabel 2.1 Perbandingan Penelitian Terdahulu Lanjutan.....	33
Tabel 2.1 Perbandingan Penelitian Terdahulu Lanjutan.....	34
Tabel 2.1 Perbandingan Penelitian Terdahulu Lanjutan.....	35
Tabel 2.1 Perbandingan Penelitian Terdahulu Lanjutan.....	36
Tabel 2.1 Perbandingan Penelitian Terdahulu Lanjutan.....	37
Tabel 2.1 Perbandingan Penelitian Terdahulu Lanjutan.....	38
Tabel 2.1 Perbandingan Penelitian Terdahulu Lanjutan.....	39
Tabel 2.1 Perbandingan Penelitian Terdahulu Lanjutan.....	40
Tabel 3.1 Deskripsi Kolom Dataset Mesin Kompresor Reciprocating....	46
Tabel 3.2 Jadwal Penelitian.....	49
Tabel 3.2 Jadwal Penelitian Lanjutan.....	50

# BAB I

## PENDAHULUAN

### 1.1 Latar Belakang

Teknologi Informasi (TI) di era digital berkembang pesat untuk memenuhi kebutuhan bisnis yang terus berubah serta munculnya teknologi baru secara berkala. Kapabilitas TI yang dinamis mencakup kemampuan untuk memperoleh, menerapkan, mengintegrasikan, dan menata ulang sumber daya TI guna mencapai tujuan bisnis (T. Li & Chan, 2019). *Artificial Intelligence* (AI) merupakan bidang luas dalam teknologi informasi yang melibatkan komputasi, pengembangan perangkat lunak, dan transmisi data. AI diterapkan untuk meningkatkan kinerja di berbagai sektor, seperti kesehatan, organisasi bisnis, industri otomotif dan manufaktur. AI berperan dalam otomatisasi tugas penting, meningkatkan akurasi, dan efisiensi operasional. Teknologi AI mencakup pengenalan suara, robotika, identifikasi biometrik, *deep learning*, dan *machine learning* (Mohammad, 2020). Meskipun AI mencakup berbagai teknologi, *machine learning* adalah salah satu pendorong utama dalam inovasi dan penerapan AI, terutama dalam situasi yang memerlukan analisis data skala besar secara cepat dan efisien (Soliman, Fatnassi, Elgammal, & Figueiredo, 2023).

*Machine Learning* (ML) atau pembelajaran mesin adalah bidang ilmu komputer yang fokus pada pengembangan algoritma dan teknik untuk menyelesaikan masalah kompleks yang sulit dipecahkan dengan metode pemrograman konvensional (Rebala, Ravi, & Churiwala, 2019). *Machine learning* dibagi menjadi empat kategori yaitu *supervised learning*, *unsupervised learning*, *semi-supervised learning*, dan *reinforcement learning* (Mohammad, 2020). Beberapa algoritma umum dalam *supervised learning* termasuk *Naïve Bayes*, *Linear Discriminant Analysis* (LDA), *Logistic Regression*, *K-Nearest Neighbors* (KNN), *Support Vector Machine* (SVM), *Decision Tree* (DT), *Random Forest* (RF), *Adaptive Boosting* (AdaBoost), *Extreme Gradient Boosting* (XGBoost), *Stochastic Gradient Descent* (SGD), dan *Rule-based Classification*. Pada *unsupervised*

*learning*, algoritma yang sering digunakan untuk clustering antara lain *K-Means*, *Mean-Shift*, *Density-Based Spatial Clustering of Applications with Noise* (DBSCAN), *Gaussian Mixture Models* (GMM), dan *Agglomerative Hierarchical Clustering*. Sementara itu, algoritma umum dalam *reinforcement learning* mencakup *Q-Learning*, *Deep Q-Learning*, dan *Monte Carlo Methods* (I. H. Sarker, 2021). Teknologi *machine learning* telah menjadi populer di bidang aplikasi karena kemampuannya yang luas. Beberapa area aplikasi yang menonjol termasuk keamanan siber dan intelijen ancaman, dimana *machine learning* digunakan untuk mendeteksi ancaman kolaboratif dan mempertimbangkan indikator ancaman (Preuveneers, Joosen, & Privacy, 2021). Pada sektor kesehatan, *machine learning* mampu untuk mendeteksi dan mendiagnosis COVID-19 dengan akurasi yang tinggi melalui penggunaan berbagai jenis descriptor tekstur (Medeiros, Machado, de Freitas, da Silva, & de Souza, 2024). Selain itu, teknologi ini juga digunakan dalam pengenalan gambar, ucapan, dan pola, dengan hasil yang menjanjikan dalam mendeteksi kanker ginjal (Galić, Stojanović, & Čajić, 2024). Analisis prediktif dan pengambilan keputusan yang cerdas membuka banyak peluang untuk meningkatkan efisiensi dan produktivitas di sektor industri (Elkateb, Métwalli, Shendy, & Abu-Elanien, 2024).

Kompresor reciprocating merupakan alat mekanis penting dalam industri modern seperti kimia, kilang, transportasi gas, dan penyimpanan gas (Giampaolo, 2023). Kompresor ini memiliki kapasitas yang besar dan kemampuan memberikan tekanan gas yang tinggi, mulai dari pengkondisian udara hingga pengisian tekanan udara pada ban kendaraan (Xing, Feng, He, & Peng, 2021). Kompresor reciprocating memiliki beberapa kelebihan antara lain efisiensi tinggi, kemampuan kompresi, kemampuan perawatan, fleksibilitas, dan biaya operasional rendah (Lv, Yu, Ma, Ye, Wu, & Wang, 2021). Namun, dalam dekade terakhir tuntutan ekonomi telah memengaruhi operasional kompresor reciprocating, dimana banyak kasus memaksa kompresor bekerja pada kapasitas penuh tanpa cadangan dengan menuntut kinerja yang andal. Tantangan ini mengakibatkan kelelahan dan keausan tetap menjadi masalah yang tak terhindarkan (Cerrada, Montalvo, Zambrano, Cabrera, & Sánchez, 2022). Jenis kegagalan yang paling

umum pada kompresor reciprocating meliputi kegagalan segel piston, kegagalan bantalan, dan kegagalan katup. Kegagalan segel piston dapat menyebabkan kebocoran fluida yang dikompresi, berpotensi mengakibatkan kebakaran atau ledakan. Sementara itu, kegagalan bantalan dapat mengakibatkan getaran berlebihan yang memengaruhi komponen lainnya. Kegagalan katup juga dapat mengganggu operasi dan memicu masalah pada sistem lain (Medina, Sánchez, Cabrera, Cerrada, Estupiñan, Ao, & Vásquez, 2024). Katup yang rusak merupakan alasan paling umum untuk penghentian yang tidak terjadwal, dengan persentase sekitar 36%, diikuti oleh cincin piston sekitar 7% (Yu, Zhang, Hu, & Chen, 2022), dan bantalan dapat mencapai sekitar 16% dari semua kegagalan kompresor (Wu, Li, Zhu, Li, Zhang, Zhang, Yang, Yu, & Wang, 2023). Kerusakan mesin kompresor reciprocating memiliki dampak signifikan, termasuk kerugian ekonomi bagi perusahaan (Lv et al., 2021). Jika kompresor tidak beroperasi pada efisiensi terukurnya, hal ini dapat mengakibatkan kerugian finansial yang besar seperti yang ditunjukkan oleh penelitian Muo (2018) yang mengacu pada Wachel, dimana waktu henti bisa menghabiskan biaya hingga 100.000 USD per hari. Penelitian Shu et al. (2016) menunjukkan bahwa kerugian tahunan akibat pemadaman abnormal di Amerika Serikat saja mencapai setidaknya 2 miliar dolar AS. Selain itu, kompresor reciprocating yang sering digunakan untuk menangani gas mudah terbakar seperti hidrogen, etilena, dan gas alam, dapat menimbulkan ancaman serius bagi keselamatan manusia, seperti yang dikemukakan oleh Lv et al. (2021). Kegagalan kompresor reciprocating dapat menyebabkan waktu henti, kerugian produksi, biaya perawatan, dan potensi bahaya keselamatan, yang menekankan pentingnya strategi pemantauan dan pemeliharaan yang efektif untuk kompresor reciprocating.

*Maintenance* atau pemeliharaan adalah kegiatan yang bertujuan untuk memastikan kinerja dan keandalan mesin atau sistem, dengan mengurangi risiko kegagalan dan memperpanjang umur operasional (Zonta, Da Costa, da Rosa Righi, de Lima, da Trindade, & Li, 2020). Pemeliharaan terbagi menjadi tiga strategi kategori utama. Pertama adalah *Reactive Maintenance* (RM), dimana tindakan pemeliharaan dilakukan hanya setelah peralatan mengalami kerusakan

atau ketika sudah terlalu parah. Kedua adalah *Preventif Maintenance* (PM), melibatkan pemeliharaan terjadwal berdasarkan waktu yang ditetapkan atau iterasi proses, tanpa mempertimbangkan kondisi aktual dari peralatan. Ketiga adalah *Predictive Maintenance* (PdM), pemantauan kondisi peralatan secara *real-time* untuk memperkirakan kapan kegagalan akan terjadi, sehingga pemeliharaan dapat dilakukan tepat sebelum peralatan tersebut mengalami kerusakan (Ran, Zhou, Lin, Wen, & Deng, 2019). Metode pemeliharaan dan diagnosis kesalahan tradisional, seperti pemeliharaan rutin dan inspeksi manusia secara berkala, sering kali tidak mampu mendeteksi kesalahan dan mencegah kegagalan secara akurat. Metode-metode ini sangat terbatas dalam kemampuannya untuk memprediksi potensi kegagalan sebelum terjadi. Sebaliknya, sistem pemeliharaan prediktif yang menggunakan teknik seperti model rata-rata bergerak terintegrasi autoregresif dan pemodelan diagnosis dan prognosis kesalahan, dapat membantu mendeteksi kesalahan dan mencegah kegagalan. Sistem ini dapat menghemat biaya perawatan dan meningkatkan efektivitas operasional dengan memungkinkan identifikasi kesalahan dini dan pengambilan keputusan proaktif (Varghese, 2023). Pemeliharaan prediktif memiliki dua fokus utama, yaitu peningkatan efisiensi energi atau penghematan energi, dan penurunan waktu berhenti yang tidak terjadwal (Assagaf, Sukandi, Abdillah, Arifin, Ga, & Technology, 2023). Ada berbagai pendekatan teoritis dan praktis yang telah diusulkan dalam penerapan pemeliharaan prediktif. Sebagai contoh, penelitian Elkateb et al. (2024) menggunakan algoritma *machine learning*, yaitu AdaBoost untuk mengklasifikasikan penghentian mesin secara *real-time* untuk pemeliharaan prediktif di industri tekstil. Sementara itu, penelitian L. Wang, Zhu, and Zhao (2024) mengusulkan strategi pemeliharaan prediktif dinamis berbasis data dengan menggunakan metode ansambel *deep learning* untuk prediksi sisa masa manfaat. Bidang transportasi, penelitian H-Nia, Flodin, Casanueva, Asplund, and Stichel (2024) menggunakan metode *Multibody Dynamics Simulations* (MBS) untuk menghitung sisa umur roda dan rel kereta api dalam pemeliharaan prediktif. Sedangkan dalam pengembangan sistem pemeliharaan prediktif pada pompa sentrifugal limbah, penelitian Bahar, Schokry, and Alhanjouri (2023)



menggunakan metode *Seasonal Autoregressive Integrated Moving Average* (SARIMA) untuk peramalan deret waktu dan *Anomaly Detection Toolkit* (ADTK) untuk deteksi anomali. Beberapa skenario aplikasi, kebutuhan akan pemrosesan data dan aliran data yang kompleks secara *real-time* telah terbukti penting. Meskipun model *Autoregressive Integrated Moving Average* (ARIMA) juga telah digunakan untuk deteksi kesalahan dan perkiraan pemeliharaan prediktif dalam deret waktu (Fernandes, Canito, Corchado, & Marreiros, 2019; Francis & Mohan, 2019). Namun, metode ini tidak sefleksibel atau sukses seperti metode *machine learning* (Ayvaz & Alpay, 2021). Oleh karena itu, metode *machine learning* akan menjadi pilihan yang lebih efektif dalam implementasi pemeliharaan prediktif.

Berdasarkan pada kondisi mesin kompresor reciprocating, berbagai penerapan pemeliharaan prediktif maupun *machine learning*, maka peneliti akan mengusulkan mengenai “Predictive Maintenance Pada Mesin Kompresor Reciprocating Berbasis *Machine Learning*”, guna meningkatkan kinerja operasional, meminimalkan *downtime*, dan mengurangi biaya perawatan pada mesin kompresor reciprocating.

## **1.2 Rumusan Masalah**

Berdasarkan pada latar belakang masalah penelitian yang telah diuraikan dan sesuai dengan usulan topik penelitian, maka dirumuskan masalah pokok yang harus diteliti adalah sebagai berikut:

1. Algoritma *machine learning* apa yang paling efektif untuk memprediksi kegagalan pada mesin kompresor reciprocating?
2. Bagaimana membangun model *machine learning* dari algoritma yang terpilih untuk memprediksi kegagalan pada mesin kompresor reciprocating?
3. Bagaimana membangun sistem peringatan pemeliharaan prediktif berbasis *machine learning* pada mesin kompresor reciprocating?
4. Bagaimana kinerja sistem peringatan pemeliharaan prediktif berbasis *machine learning* pada mesin kompresor reciprocating?

### 1.3 Batasan Masalah

Berdasarkan uraian rumusan masalah, maka batasan dari penelitian ini adalah sebagai berikut:

1. Penelitian ini difokuskan pada mesin kompresor jenis reciprocating. Mesin ini dipilih karena memiliki peran penting dalam berbagai industri seperti kimia, kilang, transportasi gas, dan penyimpan gas. Fokus pada jenis mesin ini memungkinkan penelitian untuk mendalami karakteristik spesifik dan tantangan pemeliharaan yang unik.
2. Penentuan metode *machine learning* didasarkan pada analisis dataset dan performa masing-masing algoritma dalam konteks pemeliharaan prediktif.
3. Dataset yang digunakan dalam penelitian ini diperoleh dari website Kaggle, yang telah divisualisasikan dan diunggah oleh akun Ahmet Okudan.

### 1.4 Tujuan Penelitian

Adapun tujuan dari penelitian ini secara umum adalah memberikan solusi untuk pemeliharaan prediktif pada mesin kompresor reciprocating menggunakan *machine learning*. Selain itu, secara khusus tujuan penelitian ini adalah sebagai berikut:

1. Membandingkan efektivitas berbagai algoritma *machine learning* untuk memprediksi kegagalan pada mesin kompresor reciprocating.
2. Menghasilkan model *machine learning* dari algoritma yang terpilih untuk memprediksi kegagalan pada mesin kompresor reciprocating.
3. Menghasilkan prototipe sistem peringatan pemeliharaan prediktif berbasis *machine learning* pada mesin kompresor reciprocating.
4. Mengevaluasi kinerja sistem peringatan pemeliharaan prediktif berbasis *machine learning* pada mesin kompresor reciprocating.

### 1.5 Kontribusi dan Manfaat Penelitian

Kontribusi penelitian ini memperluas pemahaman tentang penerapan *machine learning* dalam pemeliharaan prediktif pada mesin kompresor reciprocating, mencakup eksplorasi dan perbandingan efektivitas berbagai

algoritma *machine learning* dalam memprediksi kegagalan mesin. Hasil penelitian ini mengembangkan model prediktif dengan akurasi tinggi yang dapat diadopsi industri untuk mengurangi downtime dan meningkatkan efisiensi operasional. Selain itu, penelitian ini menghasilkan prototipe sistem peringatan pemeliharaan prediktif berbasis *machine learning* yang memberikan solusi praktis bagi perusahaan untuk meningkatkan pemeliharaan mesin dan mengurangi risiko kerusakan. Evaluasi kinerja sistem ini dalam konteks industri nyata juga memberikan wawasan penting tentang efektivitas dan efisiensinya.

Manfaat penelitian ini sangat signifikan bagi industri yang menggunakan mesin kompresor reciprocating. Melalui prediksi kegagalan lebih awal, perusahaan dapat melakukan pemeliharaan tepat waktu, meningkatkan efisiensi operasional, dan mengurangi waktu henti yang tidak terduga. Pemeliharaan prediktif berbasis *machine learning* dapat mengurangi biaya perawatan dengan mengidentifikasi potensi kegagalan lebih awal, sehingga menghindari kerusakan besar dan mahal. Deteksi kegagalan dini juga mengurangi risiko kecelakaan, meningkatkan keselamatan kerja di lingkungan industri. Implementasi pemeliharaan prediktif memungkinkan optimalisasi sumber daya dan mengurangi waktu henti produksi, sehingga dapat menyebabkan kerugian ekonomi yang signifikan.

## **BAB II**

### **TELAAH PUSTAKA**

#### **2.1    *Artificial Intelligence (AI)***

*Artificial Intelligence (AI)* atau kecerdasan buatan merujuk pada metode untuk menciptakan mesin yang dapat berpikir dan berperilaku secara cerdas. Mesin-mesin ini diatur oleh perangkat lunak yang ada di dalamnya, sehingga AI erat kaitannya dengan pengembangan program perangkat lunak cerdas untuk mengontrol fungsi-fungsi mesin. Bidang ilmu AI fokus pada penemuan teori dan metodologi agar mesin dapat memahami dunia sekitarnya dan merespons situasi seperti manusia (Joshi, 2017). Luger and Stubblefield (1993) mendefinisikan AI sebagai cabang ilmu komputer yang berhubungan dengan otomasi perilaku cerdas. Sementara Haag and Keen (1996) menyatakan bahwa AI terkait dengan menangkap, memodelkan, dan menyimpan kecerdasan manusia dalam sistem teknologi informasi. Tujuannya adalah membantu proses pengambilan keputusan yang biasanya dilakukan oleh manusia. Secara singkat, *Artificial Intelligence (AI)* adalah bidang ilmu yang berkaitan dengan pengembangan mesin cerdas melalui perangkat lunak, memungkinkan mereka membantu dalam pengambilan keputusan manusia.

Perkembangan *Artificial Intelligence (AI)* dimulai pada tahun 1970-an, dipengaruhi oleh penelitian yang bertujuan mengembangkan mesin yang mampu melakukan fungsi kognitif seperti berpikir, belajar, dan berbicara. Disiplin ilmu yang mendukung AI meliputi berbagai bidang seperti biologi, linguistik, psikologi, ilmu kognitif, ilmu saraf, matematika, filsafat, teknik, dan ilmu komputer (Benbya, Pachidi, & Jarvenpaa, 2021). Keberadaan AI memberikan sumbangan penting dalam berbagai bidang, seperti biologi dengan memberikan alat yang kuat bagi para ahli untuk menjelajahi mekanisme kompleks di berbagai tingkatan, mulai dari tingkat genetik hingga tingkat ekosistem (Hassoun, Jefferson, Shi, Stucky, Wang, Rosa Jr, & Biology, 2021). Terlebih lagi, AI memiliki keterkaitan yang erat dengan linguistik membantu dalam penanganan

dan penerapan bahasa alami yang berdampak pada interaksi cerdas, komunikasi efektif, dan pertukaran lintas budaya (Jia, 2023). Bidang klinis dan psikologis, AI membantu dalam pelatihan klinis, pengobatan, penilaian psikolog, dan pengambilan keputusan (Luxton & Practice, 2014). Ilmu kognitif juga sangat terbantu dengan adanya AI, karena memungkinkan pengembangan model komputasi yang meniru proses berpikir manusia (Jin, 2020). Lebih lanjut, integrasi ilmu saraf dan AI membawa dampak signifikan dalam bidang pengobatan, terutama dalam deteksi dan pengobatan berbagai gangguan neurodegeneratif, dengan menggunakan teknologi biosensor dan pembelajaran mesin. (Sharma, Katare, Chauhan, Rani, Mani, & Research, 2022). Pendidikan matematika, AI dapat diimplementasikan melalui berbagai pendekatan, termasuk sistem pembelajaran mesin dan perangkat teknologi digital untuk meningkatkan efektivitas pembelajaran (bin Mohamed, Hidayat, binti Suhaizi, bin Mahmud, & binti Baharuddin, 2022). Bidang filsafat, AI membantu dalam penyediaan contoh-contoh tandingan, mendorong perubahan dalam teori, dan memberikan pemahaman yang lebih dalam tentang konsep-konsep filosofis yang kompleks (Pollock, 1990). Sementara itu di bidang teknik, AI menyediakan alat bantu yang kuat untuk memecahkan masalah kompleks yang membutuhkan kecerdasan manusia, seperti sistem berbasis pengetahuan, logika fuzzy, dan algoritme genetik (Pham & Pham, 1999). Bidang ilmu komputer, AI memperluas aplikasinya ke berbagai domain, termasuk dalam deteksi dan pencegahan penipuan oleh perusahaan kartu kredit dan bank (Oana, Cosmin, & Valentin, 2017). Keseluruhan, perkembangan AI telah memberikan dampak yang signifikan di berbagai bidang, memperluas batas-batas pengetahuan manusia dan memberikan alat yang kuat untuk menjawab tantangan kompleks zaman ini.

Integrasi *Artificial Intelligence* (AI) merambah berbagai sektor, mencakup komersial, ilmu kedokteran, farmasi, proses manufaktur, hingga manajemen. Pada sektor komersial, penggunaan AI dapat meningkatkan efektivitas strategi pemasaran dan penjualan (Abbasi & Esmaili, 2024). Bidang ilmu kedokteran, AI memiliki peran kunci dalam diagnosis radiologi, endoskopi, aplikasi USG, keterampilan pembedahan, kualitas penelitian dan teknologi bedah jarak jauh

(Atmojo, Ningrum, Handayani, Widiyanto, & Darmayanti, 2024). Penelitian oleh Sonam Tiwari (2024) menunjukkan bahwa AI membantu dalam pengambilan keputusan sepanjang proses pengembangan obat, dari laboratorium hingga rumah sakit. AI juga memberikan dukungan dalam pemilihan opsi pengobatan terbaik bagi pasien dan pengumpulan informasi medis untuk pengembangan obat di masa depan pada sektor farmasi. Sikka, Sarkar, Garg, and Apparel (2024) menyoroti potensi keuntungan besar AI dalam sektor manufaktur, khususnya dalam operasi tekstil. AI membantu mengatasi masalah presisi manusia, variasi kualitas, serta menjanjikan peningkatan efisiensi dan inovasi. Pada manajemen, penelitian Nisa, Suwaidi, and Humanities (2023) menekankan bahwa AI memberikan wawasan berharga dan panduan untuk implementasi yang efektif dalam manajemen operasional. Secara keseluruhan, pengaruh *Artificial Intelligence* (AI) melibatkan peningkatan efisiensi, pengambilan keputusan yang cerdas, dan inovasi di berbagai sektor, mulai dari komersial, ilmu kedokteran, farmasi, manufaktur hingga manajemen.

*Artificial Intelligence* (AI) telah membawa dampak signifikan dalam berbagai sub-bidang, diantaranya *Speech Processing*, *Natural Language Processing*, *Planning*, *Engineering and Expert System*, *Fuzzy System*, *Models of Brain and Evolutionary*, *Machine Vision and Robotics*, serta *Machine Learning* (Chowdhary, 2020). Salah satu aplikasi *Speech Processing* terlihat dalam penelitian Aji and Aeman (2023), yang merancang alat forensik audio dengan menggunakan *auto speech recognition*. Alat ini membantu tim forensik dalam menganalisis suara secara efisien. Penerapan *Natural Language Processing* juga terlihat dalam penelitian van Genugten and Schacter (2024), yang mengembangkan pendekatan untuk menilai wawancara autobiografi secara otomatis. Hasil penelitian menunjukkan bahwa model ini memiliki kinerja baik di seluruh kumpulan data. Bidang *Planning*, Sahputra and Muzakir (2020) berhasil menciptakan game edukasi bahasa Inggris yang cepat dan akurat menggunakan *Artificial Intelligence*. Hasil penelitian menunjukkan bahwa penerapan AI pada game edukasi dapat berjalan lancar di platform desktop dan android. Penerapan *Engineering and Expert System* terlihat dalam penelitian Lumbantoruan and Niska

(2024), yang menggunakan sistem pakar untuk mendiagnosis penyakit pada hewan peliharaan. Penelitian ini menunjukkan kesesuaian yang konsisten antara penilaian ahli dan hasil sistem. Penggunaan *Fuzzy System* untuk kontrol Fuzzy ditemukan dalam penelitian Shen, Zhang, Pan, and Sun (2024), yang berhasil mengatasi masalah kontrol pelacakan jalur kendaraan otonom dengan menggabungkan sistem fuzzy dengan sistem kendali PID. *Models of Brain and Evolutionary* diterapkan dalam penelitian Isai and Nugroho (2024) untuk pencarian rute terpendek menggunakan algoritma genetika, membantu mengatasi masalah kepadatan lalu lintas di wilayah tertentu. *Machine Vision and Robotics* turut berkontribusi, seperti dalam penelitian Moru and Borro (2020) yang menentukan pengukuran roda gigi industri pada tingkat subpiksel dengan aplikasi *machine vision*. Penelitian Xiao, Pan, Tavasoli, Azimi, Bao, Farsangi, and Yang (2024) menunjukkan bahwa penggunaan robot dengan unit kendali dan penginderaan yang sesuai dapat mencapai berbagai tugas seperti navigasi otonom, pemetaan, konstruksi, dan inspeksi struktur sipil. *Machine Learning* juga menjadi fokus, seperti yang terlihat dalam penelitian Meddaoui, Hachmoud, and Hain (2024), mereka menentukan kinerja berbagai model *machine learning* yang paling efektif untuk prediksi pemeliharaan mesin turbofan. Secara keseluruhan, integrasi AI dalam berbagai sub-bidang ini memberikan kontribusi positif terhadap efisien, otomatisasi, dan peningkatan kinerja dalam berbagai aplikasi praktis, yang menunjukkan potensi besar AI dalam mengatasi tantangan dan meningkatkan kemajuan teknologi.

## **2.2     *Machine Learning***

*Machine Learning* (ML) atau pembelajaran mesin adalah bidang ilmu komputer yang berfokus pada pengembangan algoritma dan teknik untuk mengatasi permasalahan kompleks yang sulit dipecahkan menggunakan metode pemrograman konvensional (Rebala et al., 2019). Paradigma komputasi ini memungkinkan pembangunan kemampuan penyelesaian masalah melalui pembelajaran dari contoh-contoh sebelumnya, mencerminkan konsep dasar dari pembelajaran mesin sebagai proses penalaran berbasis kasus yang merujuk pada

situasi serupa yang telah terjadi sebelumnya (Jo, 2021). Definisi Mitchell (1997) menyatakan bahwa pembelajaran mesin melibatkan kemampuan komputer untuk belajar dari pengalaman terhadap tugas-tugas yang dihadapi, sehingga meningkatkan kinerja secara keseluruhan. Demikian, esensi dari *Machine Learning* adalah memberikan kemampuan pada komputer untuk melakukan penalaran dan meningkatkan kinerja berdasarkan pengalaman yang diperoleh dari tugas-tugas sebelumnya.

Jenis-jenis utama *machine learning* mencakup *Supervised Learning*, *Unsupervised Learning*, dan *Semi-supervised Learning* (Campesato, 2020). *Supervised Learning* atau pembelajaran yang diawasi memanfaatkan data berlabel untuk pelatihan, dimana terbagi menjadi dua kategori utama yaitu klasifikasi dan regresi (Najafabadi, Villanustre, Khoshgoftaar, Seliya, Wald, & Muharemagic, 2015). Klasifikasi bertujuan untuk memprediksi keluaran nilai diskrit, sementara regresi memprediksi output dari nilai kontinu (Moroch-Cayamcela, Lee, & Lim, 2019). Sisi lain, *Unsupervised Learning* atau pembelajaran tanpa pengawasan berguna dalam data mining ketika data tidak memiliki label, dengan fokus utama pada pengelompokan (Baryannis, Validi, Dani, & Antoniou, 2019). Metode umum dari pembelajaran tak terawasi termasuk *k-clustering* dan analisis komponen utama. *K-clustering* berdasarkan asumsi bahwa perbedaan antara data dapat diukur dengan jarak euclidean, sedangkan analisis komponen menggunakan transformasi orthogonal untuk menghasilkan variabel yang tidak berkorelasi (Baryannis et al., 2019). *Semi-supervised Learning* atau pembelajaran semi terawasi sebagai gabungan *supervised* dan *unsupervised learning*, melibatkan campuran data berlabel dan tidak berlabel dalam proses pembelajaran, dengan data tidak berlabel biasanya lebih berlimpah dalam praktiknya. Meskipun konsepnya ideal, pendekatan ini tidak banyak diterapkan dalam aplikasi praktis (Chollet, 2017). Data terbagi menjadi data berlabel, data tak berlabel dan data multilabel. Data berlabel merujuk pada data yang telah dikategorikan atau diklasifikasikan dengan label atau kategori yang telah ditentukan sebelumnya. Data tak berlabel, disisi lain tidak memiliki informasi spesifik tentang titik data seperti label atau kategori. Sedangkan data multilabel memungkinkan untuk



dikaitkan dengan beberapa label atau kategori, yang berguna dalam scenario dimana satu label mungkin tidak sepenuhnya menangkap kompleksitas data atau hubungan antara label yang berbeda.

*Machine Learning* memiliki berbagai aplikasi yang luas, termasuk klasifikasi, regresi, pengelompokan, prediksi, pembelajaran aturan asosiasi dan rekayasa fitur untuk pengurangan dimensi, serta metode pembelajaran mendalam (Erhan, Courville, Bengio, & Vincent, 2010; I. H. J. S. c. s. Sarker, 2021b). Banyak masalah klasifikasi yang umum terjadi, mulai dari klasifikasi biner yang hanya melibatkan dua label kelas seperti “benar dan salah” atau “ya dan tidak”, klasifikasi multikelas yang secara tradisional melibatkan lebih dari dua label kelas, hingga klasifikasi multi-label yang memungkinkan prediksi berbagai label yang tidak saling eksklusif (Han, Pei, & Tong, 2022; Pedregosa, Varoquaux, Gramfort, Michel, Thirion, Grisel, Blondel, Prettenhofer, Weiss, & Dubourg, 2011). Literatur *machine learning* dan ilmu data, telah diusulkan berbagai algoritma klasifikasi yang digunakan secara luas di berbagai bidang aplikasi. Salah satu algoritma yang umum digunakan adalah *Naïve Bayes* (NB), yang didasarkan pada teorema *Bayes* dengan asumsi independensi antara setiap pasangan fitur (John & Langley, 2013). Ada juga Analisis Diskriminan Linier (LDA), yang menggunakan kepadatan bersyarat kelas pada data untuk membuat batas keputusan linier (John & Langley, 2013; Pedregosa et al., 2011). Selain itu, *Logistic Regression* (LR) adalah model statistik berbasis probabilitas yang sering digunakan untuk masalah klasifikasi (Cessie & Houwelingen, 1992; I. H. J. S. c. s. Sarker, 2021b). Algoritma lainnya termasuk *K-Nearest Neighbors* (KNN), yang tidak membuat model internal tetapi menyimpan contoh-contoh terdekat dalam ruang n-dimensi (Pedregosa et al., 2011), serta *Support Vector Machine* (SVM) yang efektif dalam ruang dimensi tinggi dengan menggunakan fungsi kernel (Pedregosa et al., 2011). Metode lain seperti *Decision Tree* (DT) atau *Random Forest* (RF) juga populer, DT adalah metode non-parametrik yang digunakan untuk tugas klasifikasi dan regresi, sedangkan RF menggunakan ensambel paralel untuk meningkatkan akurasi prediksi dengan menggabungkan beberapa pohon keputusan (Pedregosa et al., 2011; J. R. Quinlan, 2014). Ada juga metode

ensambel seperti *Adaptive Boosting* (AdaBoost) dan *Extreme Gradient Boosting* (XGBoost) yang menggunakan pendekatan berulang untuk meningkatkan pengklasifikasi (Freund & Schapire, 1996; Pedregosa et al., 2011). Metode optimasi seperti *Stochastic Gradient Descent* (SGD) juga berhasil diterapkan pada masalah klasifikasi teks dan pemrosesan bahasa alami, meskipun sensitif terhadap penskalaan fitur dan membutuhkan berbagai hiperparameter (Han et al., 2022; Pedregosa et al., 2011; I. H. J. S. c. s. Sarker, 2021b). Selain itu, ada juga klasifikasi berbasis aturan yang menggunakan aturan *IF-THEN* untuk prediksi kelas, seperti *Zero-R*, *One-R*, dan *decision tree* (Holte, 1993; J. R. Quinlan, 2014; J. R. J. M. I. Quinlan, 1986; Witten, Frank, Hall, Pal, & Data, 2005).

Model regresi menjadi salah satu teknik yang sangat berguna dalam berbagai bidang, seperti peramalan keuangan, estimasi biaya, analisis tren, pemasaran, estimasi deret waktu, dan pemodelan respons obat (I. H. J. S. c. s. Sarker, 2021b). Regresi linier sederhana dan berganda adalah dua teknik yang sangat populer dalam pemodelan *machine learning*. Regresi linier, hubungan antara variabel dependen dan independent diasumsikan sebagai linier (Han et al., 2022). Namun, ketika hubungan tersebut tidak linier, regresi polinomial menjadi pilihan yang tepat. Regresi polinomial memungkinkan model untuk menangkap pola yang lebih kompleks dalam data (Pedregosa et al., 2011; I. H. J. S. c. s. Sarker, 2021b). Selain itu, terdapat juga teknik regresi seperti LASSO dan regresi ridge yang berguna dalam mengatasi masalah *overfitting* dan kompleksitas model. Regresi LASSO membantu dalam memilih subset prediktor yang penting, sementara regresi ridge berguna saat data memiliki *multicollinearity*, yaitu ketika prediktor saling berkorelasi (I. H. J. S. c. s. Sarker, 2021b).

Metode pengelompokan merupakan teknik pembelajaran mesin tanpa pengawasan yang berguna mengidentifikasi dan mengelompokkan titik data terkait dalam kumpulan data yang besar tanpa memperhatikan hasil yang spesifik (Han et al., 2022). Berbagai bidang aplikasi seperti keamanan siber, *e-commerce*, pemrosesan data seluler, analisis kesehatan, pemodelan pengguna, dan analisis perilaku, pengelompokan dapat digunakan (I. H. J. S. c. s. Sarker, 2021b). Ada beberapa jenis metode pengelompokan yang umum digunakan. Salah satunya

adalah metode partisi, yang mengkategorikan data ke dalam beberapa kelompok atau *cluster* berdasarkan fitur dan kesamaan dalam data. Algoritma yang paling umum dalam metode partisi adalah *K-means*, *K-Medoids*, CLARA, dan lain-lain (Kaufman & Rousseeuw, 2009; MacQueen, 1967; Park & Jun, 2009). Metode lain adalah metode berbasis kepadatan, yang menggunakan konsep bahwa sebuah *cluster* dalam ruang data adalah wilayah bersebelahan dengan kepadatan titik tinggi yang diisolasi dari *cluster* lain. Contohnya adalah algoritma DBSCAN, OPTICS, dan lain-lain (Ankerst, Breunig, Kriegel, & Sander, 1999; Ester, Kriegel, Sander, & Xu, 1996). Ada juga metode berbasis hierarki, yang berusaha membangun hierarki *cluster* dalam struktur pohon. Sebagai contoh, teknik BOTS adalah algoritma pengelompokan hierarkis yang bergerak dari bawah ke atas (Sarker, Colman, Kabir, & Han, 2018). Metode-metode lainnya termasuk metode berbasis kisi, yang cocok untuk menangani dataset yang sangat besar (Agrawal, Gehrke, Gunopulos, & Raghavan, 1998; W. Wang, Yang, & Muntz, 1997), dan metode berbasis model, yang dapat menggunakan pembelajaran statistik atau metode pembelajaran jaringan syaraf (Xu & Tian, 2015). Misalnya, GMM adalah metode pembelajaran statistik, sedangkan SOM adalah metode pembelajaran jaringan syaraf (Carpenter, Grossberg, & processing, 1987; Rasmussen, 1999; I. H. J. S. C. S. Sarker, 2021a). Pengelompokan berbasis batasan adalah pendekatan semi-pengawasan yang menggunakan batasan untuk menggabungkan pengetahuan domain. Algoritma seperti *COP K-means* dan *CMWK-Means* adalah contoh dari pengelompokan semacam ini (de Amorim, 2012; Wagstaff, Cardie, Rogers, & Schrödl, 2001). Dalam praktiknya, beberapa algoritma pengelompokan yang populer adalah *K-means clustering*, *Mean-shift clustering*, DBSCAN, dan Model campuran Gaussian (GMM) (Ester et al., 1996; MacQueen, 1967; Pedregosa et al., 2011; I. H. J. S. c. s. Sarker, 2021b). Masing-masing memiliki kelebihan dan kelemahan yang sesuai dengan karakteristik data yang dihadapi. Misalnya, meskipun DBSCAN lebih lambat dari *K-means*, DBSCAN dapat menemukan cluster dengan bentuk sembarang dan tidak memerlukan spesifikasi apriori tentang jumlah cluster dalam data (I. H. J. S. c. s. Sarker, 2021b).

*Reinforcement learning* (RL) adalah metode pembelajaran mesin yang memungkinkan agen untuk mempelajari lingkungan interaktif melalui percobaan dan pengalaman (Puterman, 2014). Pendekatan ini dapat dibedakan menjadi dua, yaitu berbasis model dan tanpa model. Contoh dari pendekatan berbasis model adalah *AlphaZero* dan *AlphaGo* (Silver, Huang, Maddison, Guez, Sifre, Van Den Driessche, Schrittwieser, Antonoglou, Panneershelvam, & Lanctot, 2016), sedangkan *Q-learning*, *Deep Q Network*, *Monte Carlo Control*, dan *State-Action-Reward-State-Action* (SARSA) adalah contoh algoritma tanpa model. RL bersama dengan pembelajaran yang diawasi dan tidak diawasi merupakan salah satu paradigma dasar dalam pembelajaran mesin. RL memiliki beragam aplikasi di dunia nyata, seperti teori permainan, analisis kontrol, manufaktur, dan logistik rantai pasokan (I. H. J. S. c. s. Sarker, 2021b). *Deep learning* adalah cabang dari pembelajaran mesin yang menggunakan jaringan syaraf tiruan (JST) untuk mempelajari representasi data (Han et al., 2022). Keunggulan utama terletak pada kinerjanya yang superior terutama ketika berurusan dengan dataset besar (Sarker, Kayes, Badsha, Alqahtani, Watters, & Ng, 2020; Xin, Kong, Liu, Chen, Li, Zhu, Gao, Hou, & Wang, 2018). Algoritma *deep learning* yang umum digunakan meliputi *Multilayer Perceptron* (MLP), *Convolutional Neural Network* (CNN, atau ConvNet), *Long Short-Term Memory Recurrent Neural Network* (LSTM-RNN) (I. H. J. S. C. S. Sarker, 2021a).

Teknologi *machine learning* telah menjadi populer di berbagai bidang aplikasi karena kemampuannya untuk belajar dari masa lalu dan membuat keputusan yang cerdas (I. H. J. S. c. s. Sarker, 2021b). Beberapa area aplikasi yang menonjol termasuk keamanan siber dan intelijen ancaman, dimana penelitian telah menunjukkan kemampuan *machine learning* dalam mendeteksi ancaman kolaboratif dan memperhitungkan indikator ancaman (Preuveneers et al., 2021). Selain itu, dalam konteks *Internet of Things* (IoT) dan kota pintar, penelitian telah membuktikan efektivitas *machine learning* dalam mendeteksi anomali dan intrusi dalam jaringan IoT (Shafiq, Tian, Sun, Du, & Guizani, 2020). Sektor perawatan kesehatan dan pandemi COVID-19, *machine learning* juga memainkan peran penting dengan kemampuannya untuk mendeteksi dan mendiagnosis

COVID-19 dengan akurasi yang meningkat melalui penggunaan berbagai jenis descriptor tekstur (Medeiros et al., 2024). Sementara dalam *e-commerce* dan rekomendasi produk, penelitian telah menunjukkan bahwa sistem pemberi rekomendasi yang dirancang dengan menggunakan *machine learning* dapat memiliki tingkat akurasi yang tinggi dan dapat diimplementasikan dalam skenario dunia nyata (Dingari, 2022). juga Analisis sentiment merupakan aplikasi terpenting dari *machine learning*, seperti yang ditunjukkan dalam penelitian tentang pengklasifikasi NLP dan ML pada dataset tweet Trump (Barzenji, 2021). Kemudian, dalam bidang pengenalan gambar, ucapan, dan pola, *machine learning* telah digunakan untuk mendeteksi kanker ginjal dengan hasil yang menjanjikan (Galić et al., 2024). Penerapan *machine learning* juga memainkan peran penting dalam mencapai berkelanjutan dengan mengatasi permasalahan individual dan meningkatkan efisiensi produksi (Bhansali, Saxena, & Bandhu, 2021). Selain itu, dalam analisis perilaku pengguna dan aplikasi ponsel pintar yang memahami konteks, pendekatan penemuan aturan menggunakan *machine learning* telah terbukti lebih memadai (Khan, Lu, Toseef, Musyafa, Amin, & Computing, 2023). Prediksi lalu lintas dan transportasi juga merupakan area dimana *machine learning* telah terbukti bermanfaat, dengan kemampuannya untuk menganalisis data besar dan meningkatkan efisiensi sistem transportasi (Meena, Sharma, & Mahrishi, 2020). Bidang genetika, komputasi lunak, dan pembelajaran mendalam, penelitian telah membantu melatih kendaraan otonom dengan tepat (Elkateb et al., 2024). Potensi *machine learning* dalam analisis prediktif dan pengambilan keputusan yang cerdas membuka banyak peluang untuk meningkatkan efisiensi dan produktivitas di berbagai sektor, seperti industri tekstil (Elkateb et al., 2024). Demikian, dapat disimpulkan bahwa penerapan *machine learning* memiliki potensi besar untuk menghadirkan solusi inovatif dan meningkatkan kualitas hidup secara keseluruhan.

### **2.3 Predictive Maintenance**

*Maintenance* atau pemeliharaan yang melibatkan pekerjaan untuk menjaga, memulihkan, atau meningkatkan setiap bagian bangunan, layanan, dan

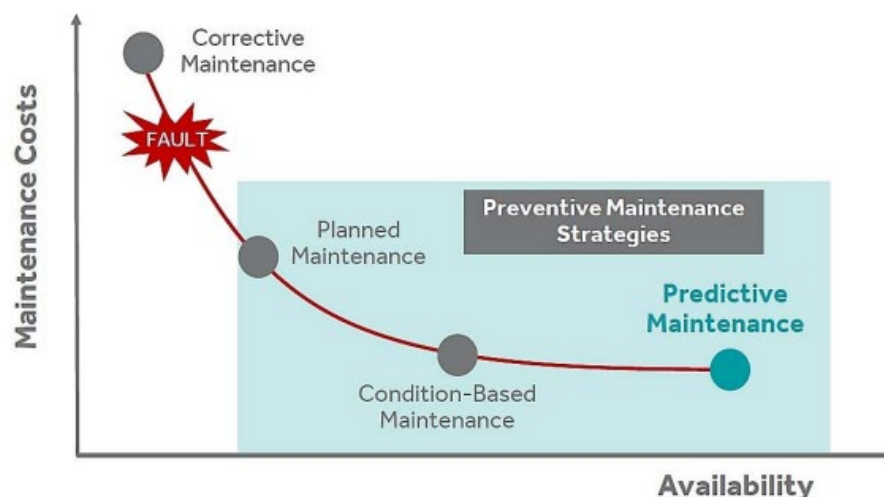
lingkungannya, serta mempertahankan utilitas dan nilai bangunan, telah didefinisikan oleh beberapa ahli. Seeley and Seeley (1976) menggambarkan pemeliharaan sebagai tugas yang bertujuan menjaga standar yang dapat diterima saat ini. Menurut Blanchard, Verma, and Peterson (1995) pemeliharaan melibatkan serangkaian kebijakan untuk mempertahankan atau mengembalikan barang dalam keadaan operasional yang efektif. Corder (1996) menyatakan bahwa pemeliharaan merupakan kombinasi tindakan untuk menjaga atau memperbaiki barang hingga mencapai kondisi yang dapat diterima. Semakin kompleksnya interaksi kegiatan produksi dalam ekosistem manufaktur, pemeliharaan menjadi sangat penting bagi industri (Sezer, Romero, Guedea, Macchi, & Emmanouilidis, 2018). Ini terbukti dengan fakta bahwa biaya pemeliharaan bisa mencapai 15%-60% dari harga pokok produksi dalam beberapa jenis industri (Mobley, 2002). Berbagai strategi pemeliharaan, seperti pemeliharaan *run-to-failure*, pemeliharaan preventif, dan pemeliharaan prediktif, telah dikembangkan untuk mengatasi berbagai tantangan dalam pemeliharaan industri dan pabrik (Motaghare, Pillai, & Ramachandran, 2018).

Pemeliharaan *run-to-failure* juga dikenal sebagai pemeliharaan korektif merupakan strategi dimana item dibiarkan beroperasi hingga mengalami kegagalan sebelum diperbaiki (Selcuk, 2017). Meskipun pilihan yang paling murah dalam jangka pendek (Patil, Jadhav, Bardiya, Davande, & Raverkar), strategi ini dapat menjadi mahal karena biaya tinggi untuk suku cadang dan tenaga kerja yang diperlukan untuk memperbaiki mesin yang rusak. Selain itu, pendekatan ini juga dapat meningkatkan biaya dan beban pada sistem lain (Motaghare et al., 2018).

Pemeliharaan preventif melibatkan pelaksanaan tugas pemeliharaan sesuai jadwal yang telah ditetapkan. Meskipun dapat membantu mengurangi kemungkinan kegagalan yang tidak terduga, strategi ini juga berpotensi menyebabkan pemeliharaan dan waktu henti yang tidak perlu (Patil et al.). Dalam prakteknya, jadwal tugas pemeliharaan preventif sering didasarkan pada grafik siklus hidup peralatan. Namun, efektivitasnya bergantung pada bagaimana

peralatan digunakan dan dipelihara selama siklus hidupnya (Motaghare et al., 2018).

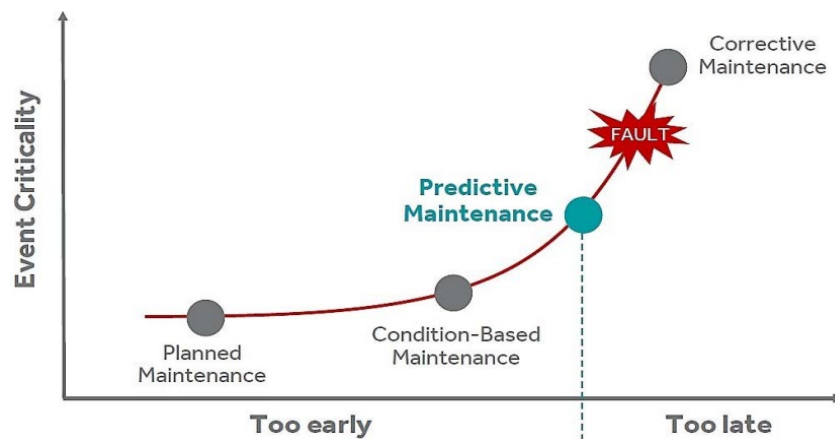
Pemeliharaan prediktif adalah pendekatan yang melibatkan pemantauan terus menerus untuk mencegah kerusakan sistem, dengan tujuan memaksimalkan interval waktu antara tugas pemeliharaan yang berurutan dan mengurangi biaya produksi secara keseluruhan (Motaghare et al., 2018). Pendekatan ini fokus pada metode proaktif untuk mengurangi biaya dan meningkatkan waktu kerja alat berat. Tujuan pemeliharaan prediktif adalah memperkirakan kapan suatu komponen atau sistem tidak lagi berfungsi dengan efektif, yang biasanya diukur melalui sisa masa pakai (RUL), indikator kesehatan, atau efektivitas peralatan (Kang, Catal, & Tekinerdogan, 2021; Papachatzakis, Papakostas, & Chrysosolouris, 2007).



**Gambar 2.1 Biaya Pemeliharaan vs Ketersediaan (Motaghare et al., 2018)**

Gambar 2.1 menunjukkan grafik yang membandingkan biaya pemeliharaan dengan ketersediaan peralatan atau mesin. biaya pemeliharaan menunjukkan bahwa semakin ke atas, biaya pemeliharaannya semakin tinggi. Bagian ketersediaan menunjukkan bahwa semakin ke kanan, ketersediaan peralatan atau mesin semakin tinggi. Grafik ini menekankan bahwa dengan menerapkan strategi pemeliharaan yang proaktif, seperti pemeliharaan prediktif dan pemeliharaan berdasarkan kondisi, perusahaan dapat mengurangi biaya pemeliharaan secara signifikan dengan meningkatkan ketersediaan peralatan. Program pemeliharaan prediktif dapat mengurangi frekuensi tugas pemeliharaan

yang tidak perlu dan meminimalkan waktu henti sistem. seperti yang digambarkan pada Gambar 2.2 sebagai berikut.



**Gambar 2.2 Peristiwa Kekritisitas (Motaghare et al., 2018)**

Gambar 2.2 menunjukkan pemeliharaan prediktif dengan memastikan bahwa sistem hanya diservis jika ada kebutuhan pemeliharaan yang sebenarnya untuk menghindari kerusakan peralatan, mengatasi kekritisitas peristiwa dengan benar. Penggunaan pemeliharaan prediktif dalam industri dapat menghasilkan pemeliharaan yang lebih baik dan waktu henti yang lebih sedikit dari sistem. Saat melakukan pemeliharaan prediktif, penting untuk mengetahui terlebih dahulu tindakan yang harus dilakukan untuk mencegah penghentian produksi dalam kondisi yang berbeda. Struktur fisik mesin dan sifat kegagalan berkorelasi dalam perkiraan untuk mempertahankan masalah yang tidak diantisipasi (Peng, Dong, & Zuo, 2010). Evaluasi model pemeliharaan prediktif merupakan kombinasi dari model matematis yang berguna untuk mengidentifikasi kapan masalah muncul dan kapan harus melakukan tindakan perawatan (Thomas, Levrat, Iung, & Cochetoux, 2009). Pemeliharaan prediktif membantu mengukur dan mencatat parameter fisik secara terus menerus untuk menganalisis dan membandingkan data untuk membuat keputusan perawatan (Sakib & Wuest, 2018).

Pendekatan multidisiplin untuk pemeliharaan prediktif menggabungkan ilmu komputer, kecerdasan buatan, dan komputasi terdistribusi (Zonta, Da Costa, da Rosa Righi, de Lima, da Trindade, Li, & Engineering, 2020). Penelitian oleh Liu, Yu, Dillon, Rahayu, and Li (2022) menitikberatkan pada pengembangan sistem terdistribusi berbantuan AI untuk pemeliharaan prediktif di pabrik, dengan



memanfaatkan pemilihan fitur dan komputasi tepi untuk mengatasi tantangan bandwidth jaringan dan waktu respons. Sejalan dengan itu, Zheng, Paiva, and Gurciullo (2020) mengusulkan kerangka kerja pemeliharaan cerdas yang mengintegrasikan teknologi AI dan IoT, termasuk pemodelan keandalan probabilistik dengan pembelajaran mendalam dan pengumpulan waktu nyata. Durbhaka and Barani (2021) juga menggali lebih dalam tentang konvergensi AI dan IoT dalam sistem pemeliharaan prediktif, terutama dalam konteks turbin angin.

Pemeliharaan prediktif memiliki aplikasi yang luas di berbagai industri, seperti perkeretaapian, otomotif, kedirgantaraan dan pertahanan untuk pesawat, serta di seluruh industri manufaktur (Arena, Collotta, Luca, Ruggieri, Termine, & Applications, 2021; Binder, Mezhuyev, & Tschandl, 2023; Cheng, Chaw, Goh, Ting, Sahrani, Ahmad, Kadir, & Ang, 2022; Scott, Verhagen, Bieber, & Marzocca, 2022; Xie, Huang, Zeng, Jiang, & Podlich, 2020). Konteks penting terkait pemeliharaan prediktif, terdapat tiga klasifikasi pendekatan yang umum digunakan untuk prediksi. Pertama, pendekatan berbasis model fisik yang menggunakan pemodelan matematis dengan memperhatikan kondisi komponen untuk memprediksi kegagalan. Kedua, pendekatan berbasis yang mengurangi kompleksitas model fisik dengan menggunakan strategi hibrida seperti sistem pakar atau logika fuzzy. Ketiga, pendekatan berbasis data yang merupakan model yang paling umum digunakan saat ini, meliputi statistik, pengenalan pola, kecerdasan buatan dan algoritma pembelajaran mesin (Zonta, Da Costa, da Rosa Righi, de Lima, da Trindade, Li, et al., 2020).

Beberapa penelitian telah mengusulkan berbagai pendekatan teoritis dan praktis dalam penerapan pemeliharaan prediktif. Sebagai contoh, L. Wang et al. (2024) mengusulkan strategi pemeliharaan prediktif dinamis berbasis data dengan menggunakan metode ansambel *deep learning* untuk prediksi sisa masa manfaat. Bidang transportasi, H-Nia et al. (2024) menggunakan metode *Multibody Dynamics Simulations* (MBS) untuk menghitung sisa umur roda dan rel kereta api dalam pemeliharaan prediktif. Sementara dalam pengembangan sistem pemeliharaan prediktif pada pompa sentrifugal limbah, Bahar, Schokry, and


Alhanjouri (2023) menggunakan metode *Seasonal Autoregressive Integrated Moving Average* (SARIMA) untuk peramalan deret waktu dan *Anomaly Detection Toolkit* (ADTK) untuk deteksi anomali. Selanjutnya, Elkateb et al. (2024) memanfaatkan algoritma *machine learning*, seperti AdaBoost untuk mengklasifikasikan penghentian mesin secara *real-time* untuk pemeliharaan prediktif di industri tekstil. Berbagai penelitian menyoroti potensi *machine learning*, menekankan keunggulan signifikan dibandingkan metode tradisional terutama dalam prediksi dan pengoptimalan pemeliharaan (Almamlook, Alshammaria, Albalawi, & Management, 2022; Dalzochio, Kunst, Pignaton, Binotto, Sanyal, Favilla, & Barbosa, 2020). (Ren, 2021) mengeksplorasi lebih lanjut potensi *machine learning* dalam peningkatan keandalan, sementara Azari, Flammini, Santini, and Caporuscio (2023) memperkenalkan pembelajaran transfer sebagai teknik untuk mengatasi tantangan dalam *machine learning* tradisional dan algoritma *deep learning*. Secara kolektif, penelitian tersebut menggarisbawahi kesepahaman yang berkembang bahwa *machine learning* memang lebih baik untuk pemeliharaan prediktif.

## **2.4 Mesin Kompresor Reciprocating**

Kompresor adalah alat mekanis yang berfungsi untuk menaikkan udara, gas, dan uap dengan memindahkannya dari satu tempat menuju ke tempat yang lain. Kompresor memiliki banyak kegunaan dan penting peranannya dalam aktivitas manusia sehari-hari. Contohnya pada mesin pengkondisian udara, mengisi tekanan udara pada ban kendaraan, serta menyalurkan gas dalam kegiatan perindustrian (Giampaolo, 2023). Ada dua jenis utama kompresor, yaitu kompresor positif dan kompresor nonpositif. Komponen positif bekerja dengan cara gas dihisap masuk ke dalam silinder dikompresikan. Sedangkan kompresor nonpositif menggunakan impeller untuk mempercepat aliran gas yang kemudian mengubah energi kinetiknya untuk menaikkan tekanan (Syamsuri, 2023). Jenis-jenis kompresor non positif meliputi kompresor sentrifugal, kompresor aksial, dan kompresor aliran campuran. Di sisi lain, kompresor positif terdiri dari berbagai macam jenis dan model, seperti kompresor baling-baling geser, kompresor cincin

air, kompresor lobus putar, kompresor sekrup heliks, dan kompresor reciprocating (Robison & Beaty, 1992).

Kompresor reciprocating merupakan jenis kompresor perpindahan positif yang paling terkenal dan paling banyak digunakan. Mereka bekerja dengan prinsip yang mirip dengan pompa sepeda lama, menggunakan piston di dalam silinder. Saat piston bergerak maju di dalam silinder, udara atau gas dipadatkan ke dalam ruang yang lebih kecil, sehingga meningkatkan tekanannya (Bloch & Hoefner, 1996). Penelitian oleh Elhaj, Gu, Ball, Albarbar, Al-Qattan, and Naid (2008) menyebutkan bahwa kerja kompresor reciprocating melibatkan tiga proses fisik yang berbeda. Pertama, proses elektromagnetik untuk menghasilkan torsi listrik. Kedua, proses mekanis untuk gerakan dinamis poros engkol, piston, dan katup. Ketiga, proses aliran fluida untuk membentuk tekanan di dalam silinder dan mengatur aliran udara melalui katup. Kompresor jenis ini banyak digunakan dalam industri proses dan transportasi atau distribusi gas. Beberapa industri yang menggunakan kompresor reciprocating termasuk kimia, petrokimia, kilang, pulp dan kertas, serta utilitas (Brown, 1997). Adapun komponen-komponen mengenai mesin kompresor reciprocating dapat dilihat pada Gambar 2.1.



**Gambar 2.3 Komponen Kompresor Reciprocating (Stewart, 2018)**

Gambar 2.3 menampilkan komponen-komponen pada mesin kompresor reciprocating. Komponen tersebut meliputi kerangka kompresor, perpanjangan kerangka, dan pemandu kepala silang, bagian jarak dua kompartemen, serta silinder kompresor berpendingin air. Kerangka kompresor meliputi *crankshaft*,

*frame lubrication oil pump*, dan *oil level sight glass*. *Crankshaft* merupakan inti dari mesin kompresor reciprocating, dengan setiap lemparan ditempa dan beban penyeimbang dipasang untuk menyeimbangkan massa bolak balik dari kepala dan piston. Pompa minyak pelumas rangka mengambil minyak dari wadah bak mesin, memompanya melalui pendingin dan filter, dan kemudian melalui pipa ke bantalan. (Bloch & Godse, 2006). Kaca penglihat tingkat minyak digunakan untuk memantau tinggi rendahnya pemberian dan pengisian minyak pelumas pada kompresor, menghindari kerusakan akibat minyak yang terlalu kotor (IDO BRIAN, 2022).

Perpanjangan kerangka dan pemandu kepala silang mencakup batang penghubung yang dilengkapi dengan baut pratorsi untuk mengencangkan tutup ke badan pada ujung engkol, serta kepala silang bergelang yang dikencangkan secara hidraulik. Bagian jarak dua kompartemen meliputi *oil scraper rings*, *partition packing*, *oil slingers*, dan *piston rod* (Bloch & Godse, 2006). Cincin pengikis minyak bertugas mengembalikan minyak pelumas yang menempel pada dinding silinder akan dikembalikan kekarter (Prakasa, 2017). Pengepakan partisi dilakukan penempatan cincin pengepakan di dalam kotak pengepakan untuk menciptakan segel, dengan cincin yang paling dekat dengan silinder yang menanggung beban tekanan utama (Xiaohan, Qingqing, Jianmei, & Xueyuan, 2016). Sling oli digunakan dalam sistem untuk mencegah oli pelumas masuk ke dalam aliran udara, yang dapat merusak mesin (Doble, 1987). Batang piston dipasang pada *crosshead* dan harus terkunci baik dengan mur pengunci atau pin untuk mencegah serangan balik (Bloch & Godse, 2006).

Silinder kompresor berpendingin air memiliki pengemasan tekanan yang mencegah kebocoran gas dan mempertahankan tekanan di dalam sistem (Yang, Jin, Du, Cui, & Yang, 2009). Kepala rangka silinder berfungsi sebagai komponen penting yang menampung silinder, memberikan dukungan untuk proses kompresi, dan menampung gas yang dikompresi sebelum diarahkan ke saluran pembuangan (Baumann, 1994; Kläy, 1975). Unloader saluran masuk tipe steker membongkar kompresor selama periode permintaan rendah dengan mengurangi atau menghentikan sepenuhnya operasi kompresor (Soedel, 2002). Saluran masuk

kompresor berfungsi sebagai titik masuknya gas atau udara yang akan dikompresi, dengan fitur seperti filter untuk menghilangkan kontaminan dari gas yang masuk serta katup atau mekanisme kontrol lainnya (Xiaohan et al., 2016). Jaket air silinder integral membantu mendinginkan silinder kompresor. Unloader saluran masuk tipe port membantu mengatur kapasitas kompresor dengan mengontrol aliran gas ke dalam silinder selama proses kompresi (Marchante-Avellaneda, Navarro-Peris, & Shrestha, 2024). Liner silinder memberikan permukaan yang halus dan tahan aus untuk piston meluncur, memastikan kompresi yang efisien, dan meminimalkan kerugian gesekan. Kepala luar silinder menahan gas yang sedang dikompresi dan memastikan penyegelan yang tepat untuk mencegah kebocoran selama siklus kompresi dan ekspansi. Mur batang piston menahan batang piston ke piston, memungkinkan gerakan bolak-balik piston. Penopang silinder mempertahankan posisi silinder dan menahan gaya yang dihasilkan selama siklus kompresi dan ekspansi. Pelepasan kompresor mengacu pada saluran keluar di mana gas terkompresi dibuang dari silinder kompresor ke saluran pembuangan atau sistem. Katup pelepasan mengontrol aliran gas terkompresi dari silinder ke saluran pembuangan. Piston padat dan piston berongga digunakan sesuai dengan ukuran dan kebutuhan kompresor untuk efisiensi serta kinerja yang optimal (Marchante-Avellaneda et al., 2024).

## **2.5 Perbandingan Penelitian Terdahulu**

Peninjauan literatur ini bertujuan untuk memahami kemajuan yang telah dicapai, tantangan yang dihadapi, serta peluang untuk pengembangan lebih lanjut. Penelitian mengenai prediksi kegagalan mesin untuk sistem pemeliharaan prediktif berbasis *machine learning* telah banyak dilakukan. Perbandingan antara penelitian-penelitian terdahulu yang terkait dengan prediksi kegagalan mesin untuk sistem pemeliharaan prediktif berbasis *machine learning* disajikan dalam Tabel 2.1.

**Tabel 2.1 Perbandingan Penelitian Terdahulu**

No	Penulis	Tujuan Penelitian	Metode	Hasil Penelitian	Kelebihan	Kekurangan	ML	WS	PdM
1	Sim, Ramli, and Saifizul (2019)	Memantau dan memprediksi kondisi kesehatan katup pada kompresor reciprocating menggunakan teknik AE	Statistik ANOVA	ANOVA menunjukkan kondisi katup maupun kecepatan kompresor memiliki efek signifikan pada nilai RMS AE yang dihitung dari peristiwa SVO, SVC, dan DVO, dengan nilai $p < 0.01$ . Nilai RMS AE dari peristiwa SVO menunjukkan korelasi linear yang tinggi dengan kecepatan untuk semua kondisi kerusakan katup, dengan nilai $R^2 > 0.7$ untuk kondisi normal, kebocoran tunggal, dan kebocoran ganda. Hasil tersebut menunjukkan bahwa sinyal Emisi Akustik (AE), khususnya nilai RMS AE dari pembukaan katup hisap (SVO), dapat memprediksi kerusakan katup pada kompresor reciprocating dengan berbagai	Pendekatan statistik yang kuat dalam mengolah data, teknik emisi akustik (AE) lebih sensitif terhadap kerusakan material dibandingkan teknik getaran hal ini memberikan kontribusi penting dalam bidang NDT untuk pemantauan kondisi mesin	Asumsi bahwa kecepatan kompresor konstan selama pengukuran mungkin tidak realistis dalam kondisi operasi sebenarnya, kurang memperhatikan pengaruh faktor lain seperti kekakuan pegas katup pada sinyal AE	x	x	x

No	Penulis	Tujuan Penelitian	Metode	Hasil Penelitian	Kelebihan	Kekurangan	ML	WS	PdM
				kecepatan, karena korelasi linear yang tinggi antara RMS AE dan kecepatan kompresor.					
2	Loukopoulos, Zolkiewski, Bennett, Sampath, Pilidis, Li, and Mba (2019)	Meminimalkan waktu henti dan biaya pemeliharaan dalam meningkatkan ketersediaan serta keselamatan	Multiple Linear Regression (MLR), Polynomial Regression (PR), Self-Organising Map (SOM), K-Nearest Neighbours Regression (KNNR), dan metode ensemble	Pada kasus kegagalan 8, metode ensemble memberikan hasil terbaik dengan NMSE 0.96, MAPER 16.14, CRA 0.84, dan MAD 9.35. Regresi Polinomial (PR) juga menunjukkan kinerja baik dengan NMSE 0.96, MAPER 14.17, CRA 0.86, dan MAD 11.3. Metode Self-Organising Map 1 (SOM1) memiliki kinerja terburuk dengan NMSE 0.35, MAPER 40.45, CRA 0.60, dan MAD 41.85. Pada Kasus Kegagalan 11, metode ensemble tetap terbaik dengan NMSE 0.92, MAPER 25.17, CRA 0.75, dan MAD 15.21. Regresi Polinomial (PR) dan Regresi Linear Berganda	Pendekatan multi metode prognostik yang memberikan hasil lebih baik dibandingkan metode tunggal	Metode prognostik sangat bergantung pada ketersediaan dan kualitas data historis, Beberapa metode menunjukkan variasi kinerja yang signifikan, seperti SOM1 yang memiliki akurasi rendah dan variasi tinggi	✓	x	✓

No	Penulis	Tujuan Penelitian	Metode	Hasil Penelitian	Kelebihan	Kekurangan	ML	WS	PdM
				(MLR) menunjukkan kinerja yang cukup baik, sementara SOM1 memiliki kinerja terburuk dengan NMSE -0.39, MAPER 51.88, CRA 0.48, dan MAD 62.05. Hasil ini menunjukkan bahwa metode ensemble umumnya memberikan kinerja terbaik di sebagian besar metrik, diikuti oleh PR, sedangkan SOM1 memiliki kinerja terendah dan variasi tertinggi.					
3	Cabrera, Guamán, Zhang, Cerrada, Sánchez, Cevallos, Long, and Li (2020)	Diagnosis kesalahan pada kompresor reciprocating menggunakan pendekatan Bayesian dan pengurangan dimensi deret waktu untuk membangun model berbasis Long Short Term Memory	Bayesian, LSTM, Random Forest, Classification Tree, K-Nearest Neighbors, Denoising Autoencoder, dan Sparse Autoencoder	del LSTM dengan optimasi bayesian mencapai akurasi pengenalan kesalahan sebesar 93%, mengungguli metode lain seperti Random Forest, Classification Tree, K-Nearest Neighbors dengan nilai masing-masing 57,4%; 59,0%; dan 41,0%; serta model Deep Learning lainnya seperti	Kontribusi signifikan dalam bidang diagnosis kerusakan mesin dengan memperkenalkan pendekatan baru berbasis LSTM dan optimasi Bayesian	Ketergantungan pada data spesifik, kompleksitas implementasi, potensi kehilangan informasi waktu yang relevan	✓	x	x



No	Penulis	Tujuan Penelitian	Metode	Hasil Penelitian	Kelebihan	Kekurangan	ML	WS	PdM
		(LSTM)		Denoising Autoencoder sebesar 84,0% dan Sparse Autoencoder 90,5%.					
4	Loutas, Eleftheroglou, Georgoulas, Loukopoulos, Mba, and Bennett (2020)	Mengembangkan indikator kesehatan berbasis pengukuran suhu dan analisis komponen utama (PCA) untuk membuat estimasi probabilistik tentang sisa masa pakai (RUL) kompresor reciprocating	Model matematis probabilistik Gradient Boosted Trees (GBTs) dan Non-Homogeneous Hidden Semi Markov Models (NHHSMM)	Kedua model tersebut dapat memperkirakan RUL rata-rata dengan batas kepercayaan 95%, dengan NHHSMM menunjukkan sedikit keunggulan atas beberapa metrik dibandingkan GBTs.	Menunjukkan efektivitas dari metodologi prognostik berbasis data dalam memprediksi RUL kompresor reciprocating, yang sangat bermanfaat untuk perencanaan pemeliharaan dengan memberikan kuantifikasi ketidakpastian	Adanya keterbatasan pada jenis data yang digunakan yang hanya berupa data suhu, dan kompleksitas dalam implementasi yang memerlukan pemahaman mendalam tentang teknik statistik dan machine learning	✓	✓	✓
5	Toroghi and Sadighi (2020)	Mendeteksi kesalahan pada kompresor udara reciprocating dengan menggunakan Electrical Signature Analysis (ESA)	Support Vector Machine (SVM)	Setiap kondisi kesalahan diuji sebanyak 10 kali, sementara kondisi kompresor sehat diuji sebanyak 30 kali. Data sinyal diakuisisi dengan frekuensi sampel 8 kHz dan difilter menggunakan filter analog	Pendekatan inovatif yaitu ESA yang mengurangi kebutuhan sensor yang mahal dan kompleksitas instalasi, menyajikan model matematika yang	Kekhususan terhadap jenis kompresor tertentu dan kompleksitas model yang membutuhkan keahlian teknis tinggi, serta kebutuhan akan data berkualitas tinggi	✓	✓	✓

No	Penulis	Tujuan Penelitian	Metode	Hasil Penelitian	Kelebihan	Kekurangan	ML	WS	PdM
				Chebyshev I dengan frekuensi sudut 3,7 kHz sebelum ekstraksi fitur dilakukan. Metode Support Vector Machine (SVM) linier yang menunjukkan akurasi yang paling tinggi sebesar 98%. Penggunaan ESA dalam kombinasi dengan algoritma machine learning seperti SVM sangat efektif untuk pemantauan kondisi dan deteksi kesalahan pada kompresor udara.	komprehensif, serta tidak hanya teori dan simulasi tetapi memvalidasi efektivitas metode ESA	yang mungkin membatasi aplikasinya di lingkungan industri nyata			
6	X. Li, Mba, and Loukopoulos (2020)	Mengembangkan metodologi prediksi untuk kegagalan katup pada kompresor reciprocating dengan menggunakan pendekatan Just-in-Time Learning (JITL) berbasis data	Just-in-Time Learning (JITL) dan Gradient Boosting Decision Tree (GBDT)	Rata-rata nilai SCORE untuk metode JITL-GBDT adalah 24.44, sedangkan untuk metode GBDT adalah 281.5. Hasil tersebut menunjukkan JITL-GBDT mampu memprediksi RUL dengan akurasi lebih tinggi dibandingkan model GBDT	Pendekatan adaptif dan efisiensi komputasi karena hanya menggunakan data historis yang relevan	Membutuhkan penanganan yang cermat dalam implementasi dan pemeliharaan, termasuk penyesuaian parameter secara berkala, ketergantungan pada data berkualitas tinggi, dan proses seleksi fitur	✓	✓	✓

No	Penulis	Tujuan Penelitian	Metode	Hasil Penelitian	Kelebihan	Kekurangan	ML	WS	PdM
				konvensional, terutama dalam menghadapi pola degradasi yang bervariasi.		serta tuning parameter yang mungkin rumit dan memakan waktu			
7	Zou, Xiang, Zou, Liu, Xu, Zou, and Chen (2020)	Menilai kemampuan unit kompresor dalam memenuhi persyaratan keselamatan, serta memprediksi perkembangan kerusakan	Analytic Hierarchy Process (AHP), Fuzzy Comprehensive Evaluation (FCE), dan Failure Mode and Effects Analysis (FMEA)	Simulasi kegagalan piston ring pada titik waktu seperti 1478, 3820, dan 5230 jam, dan model Weibull, ketersediaan piston ring menurun signifikan setelah 4400 jam, mengindikasikan risiko kegagalan tinggi. Evaluasi keandalan dilakukan dengan metode kuadrat dan simulasi Monte Carlo, yang membantu menentukan siklus pemeliharaan optimal. Strategi pemeliharaan dikembangkan menggunakan metode AHP-FCE, berdasarkan analisis kegagalan dan penilaian ahli, menetapkan prioritas pemeliharaan tinggi, sedang, dan rendah. Hasil ini	Pemodelan multi level dengan AHP-FCE, hasil yang objektif dan efektif dengan menerapkan metode matematika sampling acak, analisis numerik untuk data kesalahan	Metode yang digunakan memiliki keterbatasan seperti faktor subjektif manusia dan potensi kesalahan perhitungan	x	x	✓

No	Penulis	Tujuan Penelitian	Metode	Hasil Penelitian	Kelebihan	Kekurangan	ML	WS	PdM
				memberikan panduan efektif untuk meningkatkan keandalan dan efisiensi operasional kompresor.					
8	Charoenchitt and Tangamchit (2021)	Mendeteksi kerusakan awal pada kompresor reciprocating menggunakan autoencoder	Autoencoder	Dataset pertama yang terdiri dari 79 fitur, kesalahan rekonstruksi rata-rata untuk operasi normal adalah 3.93 dengan standar deviasi 0.68, meningkat menjadi 4.74 (SD 0.39) dua bulan sebelum kegagalan, 5.15 (SD 0.39) satu bulan sebelum kegagalan, dan 5.11 (SD 0.34) lima belas hari sebelum kegagalan. Dataset kedua yang mencakup 12 fitur tambahan, kesalahan rekonstruksi rata-rata untuk operasi normal adalah 2.69 (SD 0.44), meningkat menjadi 3.47 (SD 0.73) dua bulan sebelum kegagalan, 3.78 (SD 0.84) satu bulan sebelum	Menawarkan pendekatan yang inovatif dan metodologi yang kuat untuk deteksi anomali pada kompresor reciprocating	Dalam data kegagalan dan kompleksitas implementasi menjadi tantangan yang perlu diatasi untuk penerapan yang lebih luas di industri	✓	✓	✓

No	Penulis	Tujuan Penelitian	Metode	Hasil Penelitian	Kelebihan	Kekurangan	ML	WS	PdM
				kegagalan, dan 4.41 (SD 0.57) lima belas hari sebelum kegagalan. Berdasarkan hasil tersebut model mampu membedakan antara operasi normal dan abnormal dengan margin yang signifikan, memungkinkan prediksi kerusakan hingga dua bulan sebelum terjadi. Pendekatan ini juga mengatasi masalah kualitas data yang buruk dan dapat berfungsi sebagai indikator peringatan dini untuk pemeliharaan mesin.					
9	Lu and Wang (2021)	Mendeteksi mode kegagalan pada tahap awal dan menyediakan rekomendasi pemeliharaan yang tepat	Dekomposisi wavelet, Artificial Neural Network (ANN), dan Support Vector Machine (SVM)	Model ANN menghasilkan akurasi lebih tinggi sebesar 100%, dibandingkan SVM sebesar 99,5%. Waktu pelatihan ANN jauh lebih cepat dibandingkan SVM, yang mengakibatkan lebih efisien untuk diagnosis mesin	Pendekatan multi fitur dengan menggunakan analisis domain waktu dan fitur wavelet untuk mengekstraksi fitur dari getaran	Analisis hanya dilakukan pada getaran sumbu x dan y, yang mungkin tidak mencakup semua jenis anomali yang bisa terjadi pada kompresor	✓	✓	✓

No	Penulis	Tujuan Penelitian	Metode	Hasil Penelitian	Kelebihan	Kekurangan	ML	WS	PdM
10	Zhang, Yang, Zhang, and Wang (2021)	Mengevaluasi penggunaan teknologi Emisi Akustik (AE) untuk pengukuran non-destruktif gerakan katup kompresor reciprocating	Deep learning khususnya jaringan saraf tiruan (Convolutional Neural Network/CNN) dan Long Short-Term Memory (LSTM) untuk memprediksi karakteristik dinamis katup	CNN mencapai akurasi prediksi 94,49%, sedangkan LSTM mencapai 96,14%, dengan CNN lebih cepat dalam prediksi.	Teknik deep learning dapat secara efektif mendiagnosis dan memprediksi kegagalan katup kompresor, menggabungkan kecepatan prediksi tinggi dan pendekatan non-invasif	Tantangan seperti kompleksitas implementasi dan ketergantungan pada kualitas data yang tinggi menuntut sumber daya komputasi yang besar dan investasi awal yang signifikan	x	✓	✓
11	Zhao, Liu, Zhang, Sun, Wang, and Wei (2021)	Mengembangkan sebuah metodologi baru untuk mendeteksi kesalahan pada kompresor reciprocating menggunakan Convolutional Neural Network (CNN) yang ditingkatkan dengan mekanisme perhatian	CNN digunakan mengoptimalkan pengolahan sinyal getaran dengan mengubah data mentah menjadi format dua dimensi	Metode yang diusulkan mencapai akurasi diagnosis sebesar 99,4%, dan bahkan dalam kondisi kebisingan yang kuat, metode ini tetap mempertahankan akurasi sebesar 90,2%. Selain itu, metode yang diusulkan menunjukkan ketahanan terhadap kebisingan yang lebih baik dibandingkan dengan metode lainnya yang diuji,	Metode yang dikembangkan unggul dalam akurasi dan kemampuan anti-kebisingan dibandingkan metode lain	Pendekatan yang memerlukan sumber daya komputasi yang signifikan, sangat bergantung pada kualitas data yang tinggi, dan kompleksitas implementasinya dapat menjadi pembatas dalam aplikasi skala besar atau pada perangkat dengan kapasitas terbatas	x	✓	✓

No	Penulis	Tujuan Penelitian	Metode	Hasil Penelitian	Kelebihan	Kekurangan	ML	WS	PdM
				seperti CNN dengan akurasi 98,4%, LSTM-CNN dengan akurasi 97,3%, dan A-CNN dengan akurasi 98,1%. Ketika diuji di bawah kondisi SNR yang berbeda, metode ini tetap mempertahankan akurasi yang tinggi: tanpa kebisingan 99,4%, SNR 50 dB 99,3%, SNR 20 dB 98,9%, SNR 10 dB 95,2%, dan SNR 5 dB 90,2%. Hal ini menunjukkan kemampuan luar biasa dalam pengenalan kesalahan dan ketahanan terhadap kebisingan.					
12	Cerrada et al. (2022)	Mengusulkan penggunaan sinyal arus sebagai metode non-intrusif untuk diagnosis kesalahan pada bantalan kompresor reciprocating, sebagai	Cluster Validity Assessment (CVA) dan Learning Methodology for Multivariable Data Analyses (LAMDA)	Presisi klasifikasi sebesar 97,5% pada fase pelatihan dan 90% pada fase pengujian. Seleksi fitur dioptimalkan melalui validasi klaster, yang memungkinkan model ini mengklasifikasikan tiga jenis kegagalan dengan presisi	Penggunaan metode non-invasif yang lebih sederhana dan murah dibandingkan analisis getaran tradisional, serta efisiensi biaya karena sinyal arus lebih mudah diukur	Ketergantungan yang tinggi pada kualitas data, kompleksitas implementasi yang memerlukan sumber daya komputasi besar dan keahlian data sains, serta tantangan dalam	✓	✓	✓

No	Penulis	Tujuan Penelitian	Metode	Hasil Penelitian	Kelebihan	Kekurangan	ML	WS	PdM
		alternatif dari sinyal getaran yang biasa digunakan		tinggi. Hasil ini mengindikasikan bahwa penggunaan sinyal arus sebagai alternatif non-intrusif terhadap analisis getaran memberikan hasil yang menjanjikan dalam diagnosis kesalahan mekanis pada mesin.		menyesuaikan model untuk jenis kompresor atau kondisi operasional yang berbeda			
13	Penelitian Usulan, 2024	Mengembangkan model prediksi kegagalan untuk pemeliharaan prediktif pada mesin kompresor reciprocating menggunakan machine learning	Regresi dan Machine Learning	-	-	-	✓	✓	✓



Berdasarkan Tabel 2.1, penelitian Sim et al. (2019) berhasil memanfaatkan sinyal *Acoustic Emission* (AE) untuk mendeteksi kerusakan pada katup kompresor reciprocating. Penelitian tersebut menunjukkan bahwa nilai RMS AE sangat dipengaruhi oleh kondisi katup dan kecepatan kompresor, membuktikan AE sebagai alat diagnosis yang efektif melalui analisis varians dan regresi. Penelitian Loukopoulos et al. (2019) melangkah lebih jauh dengan menggunakan kombinasi metode statistik dan *machine learning* untuk memperkirakan kapan kerusakan akan terjadi (*Remaining Useful Life/RUL*). Penelitian tersebut menunjukkan bahwa metode prognostik yang beragam, seperti metode ensemble memberikan hasil yang lebih baik dibandingkan metode tunggal yang digunakan oleh Sim et al. (2019) dalam meningkatkan akurasi prediksi RUL.

Penelitian Cabrera et al. (2020) mengusulkan metode baru untuk diagnosis kesalahan menggunakan pendekatan *Bayesian* dan pengurangan dimensi deret waktu dengan model LSTM. Hasilnya menunjukkan akurasi pengenalan kesalahan yang lebih tinggi daripada metode lain, yang memperkenalkan penggunaan optimasi *Bayesian* dalam model *deep learning* untuk meningkatkan kinerja. Penelitian Loutas et al. (2020) mengembangkan indikator kesehatan berbasis pengukuran suhu dan PCA untuk estimasi probabilistik tentang RUL. Penelitian tersebut menunjukkan bahwa model *Gradient Boosted Trees* (GBTs) dan *Non-Homogeneous Hidden Semi Markov Models* (NHHSMM) efektif dalam memprediksi RUL, dengan tingkat kepercayaan tinggi menggarisbawahi pentingnya pendekatan probabilistik berbasis data yang memperluas penggunaan metode *machine learning* yang digunakan oleh Loukopoulos et al. (2019).

Penelitian Toroghi and Sadighi (2020) menggunakan *Electrical Signature Analysis* (ESA) untuk mendeteksi kesalahan mekanis pada kompresor, yang menunjukkan bahwa sinyal arus dapat digunakan secara akurat melalui analisis transformasi Fourier (FFT). Metode tersebut menambah dimensi baru dalam deteksi kerusakan dengan metode non-invasif yang berbeda dari AE yang digunakan oleh Sim et al. (2019). Penelitian X. Li et al. (2020) mengembangkan metodologi prognostik menggunakan *Just-in-Time Learning* (JITL) berbasis *Gradient Boosting Decision Tree* (GBDT), menunjukkan bahwa pendekatan ini

mampu mengatasi non-linearitas dan memprediksi RUL dengan akurasi tinggi. Penelitian ini dapat dikatakan melanjutkan perkembangan metode prognostik dari Loukopoulos et al. (2019), memperkenalkan adaptasi langsung berdasarkan kondisi operasi yang beragam.

Penelitian Zou et al. (2020) mengembangkan model evaluasi berbasis *Analytic Hierarchy Process* (AHP) dan *Fuzzy Comprehensive Evaluation* (FCE) untuk strategi pemeliharaan optimal. Penelitian tersebut menunjukkan bahwa metode ini meningkatkan keandalan evaluasi dan memberikan panduan efektif untuk desain dan pemeliharaan kompresor, memperluas aplikasi metode prediktif yang sebelumnya difokuskan pada estimasi RUL. Penelitian Charoenchitt and Tangamchit (2021) mendeteksi kerusakan awal pada kompresor menggunakan autoencoder, menggabungkan data termodinamika dan getaran untuk meningkatkan akurasi prediksi. Pendekatan ini memperkuat penggunaan data sensor yang berbeda untuk deteksi anomali yang telah diinisiasi oleh Toroghi and Sadighi (2020) dengan ESA.

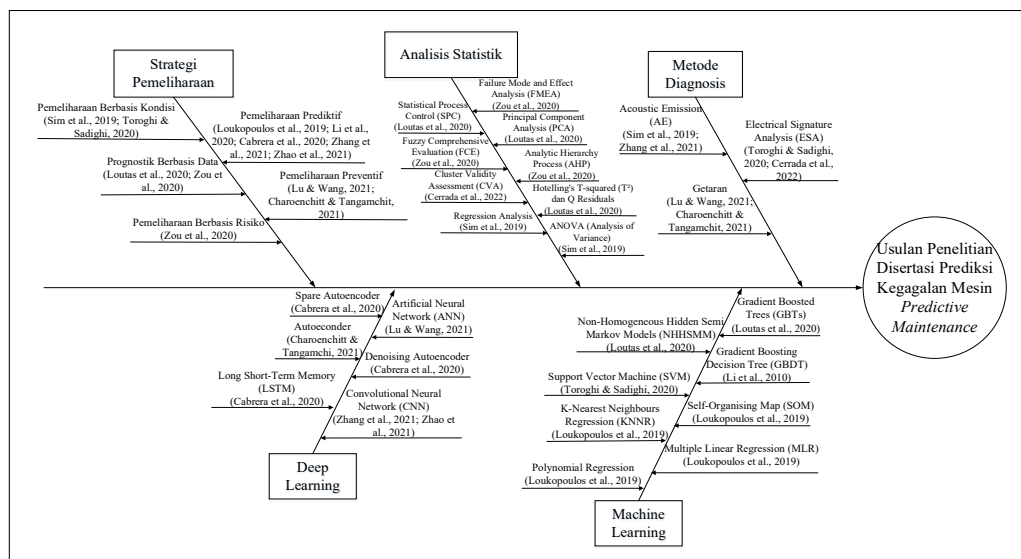
Penelitian Lu and Wang (2021) mengembangkan sistem prediksi kegagalan menggunakan dekomposisi wavelet dan *Artificial Neural Network* (ANN), menunjukkan akurasi hampir 100% dalam deteksi kegagalan. Penelitian tersebut menggabungkan analisis domain waktu dan wavelet untuk meningkatkan fitur ekstraksi dan prediksi, melanjutkan tren dalam penggunaan *machine learning* untuk diagnosis yang dimulai oleh penelitian sebelumnya. Penelitian Zhang et al. (2021) mengevaluasi penggunaan teknologi AE dengan metode *deep learning*, khususnya CNN dan LSTM untuk memprediksi karakteristik dinamis katup. Hasilnya menunjukkan akurasi tinggi dan memperluas penggunaan teknologi AE yang awalnya diusulkan oleh Sim et al. (2019), dengan tambahan kemampuan *deep learning* untuk prediksi yang lebih canggih.

Penelitian Zhao et al. (2021) mengembangkan metodologi deteksi kesalahan menggunakan CNN yang ditingkatkan dengan mekanisme perhatian, mencapai akurasi 99.4% bahkan dalam kondisi bising. Penelitian ini menunjukkan kemampuan CNN yang ditingkatkan dalam pemrosesan fitur global dan akurasi diagnosis tinggi, memperluas kemampuan prediksi *deep learning* yang digunakan

oleh Zhang et al. (2021). Penelitian Cerrada et al. (2022) mengusulkan penggunaan sinyal arus sebagai metode non-intrusif untuk diagnosis kesalahan bantalan, mencapai presisi tinggi dengan metode LAMDA. Penelitian ini menawarkan solusi yang lebih sederhana dan efisien biaya dibandingkan analisis getaran tradisional, menggabungkan pendekatan berbasis data yang telah diterapkan dalam penelitian sebelumnya.

Setiap penelitian membangun fondasi yang sebelumnya dan memperluas metode yang digunakan untuk diagnosis dan prediksi kerusakan kompresor reciprocating. Hal ini menunjukkan perkembangan dari analisis sederhana sinyal AE ke penggunaan kombinasi metode *machine learning* dan data sensor yang lebih kompleks. Sebagaimana penelitian yang akan diusulkan, pengembangan model prediksi kegagalan mesin bertujuan untuk menciptakan sistem pemeliharaan prediktif yang efektif, yang dapat membantu organisasi dalam mengoptimalkan operasi dalam meminimalkan risiko kerusakan.

Konteks analisis penelitian sebelumnya mengenai diagnosis dan prediksi kerusakan pada kompresor reciprocating, diagram *fishbone* dapat digunakan untuk menggambarkan faktor-faktor kunci yang berkontribusi terhadap pengembangan teknologi dan metodologi dalam bidang ini. Berikut diagram fishbone yang mempengaruhi penelitian usulan pengembangan prediksi kegagalan pada kompresor reciprocating yang dapat dilihat pada Gambar 2.4.



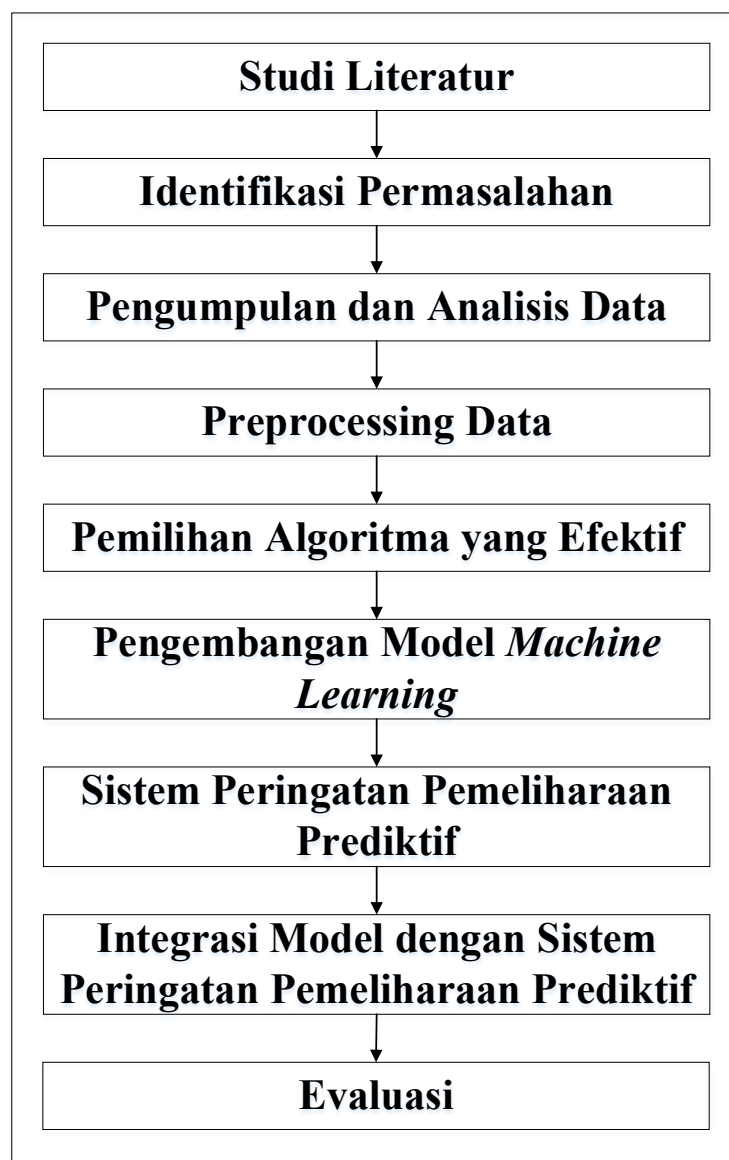
**Gambar 2.4 Diagram Fishbone Usulan Penelitian Disertasi**

## BAB III

### METODE PENELITIAN

#### 3.1 Tahapan Penelitian

Tahapan penelitian merupakan serangkaian langkah-langkah yang dilakukan dalam penelitian. Gambaran mengenai tahapan penelitian ini dapat dilihat pada Gambar 3.1.



**Gambar 3.1 Tahapan Penelitian**

Gambar 3.1 menunjukkan tahapan penelitian sebagai dasar untuk pengembangan sistem pemeliharaan prediktif menggunakan teknik *machine*

*learning*. Tahapan penelitian ini terdiri dari studi literatur untuk memahami keadaan yang terfokus terhadap tentang mesin kompresor reciprocating, metode prediksi pemeliharaan mesin, *predictive maintenance*, dan *machine learning*. Identifikasi permasalahan secara spesifik yang akan diatasi oleh penelitian, termasuk mendefinisikan ruang lingkup serta tujuan dari penelitian. Pengumpulan data yang relevan dan melakukan analisis awal untuk memahami karakteristik dan pola dalam data. Preprocessing data melibatkan pembersihan data, normalisasi, dan transformasi data agar siap digunakan dalam model *machine learning*. Tahap ini bertujuan untuk mengatasi masalah data yang hilang, *outliers*, dan memastikan data berada dalam format yang sesuai. Pemilihan algoritma *machine learning* yang efektif untuk membantu mencapai akurasi yang lebih tinggi dan efisiensi dalam prediksi. Pengembangan dan melatih model *machine learning* menggunakan algoritma yang telah dipilih dengan data yang telah diproses, tahap ini melibatkan pembagian data menjadi set pelatihan dan set pengujian, serta termasuk mengatur parameter model untuk mencapai kinerja terbaik. Sistem peringatan pemeliharaan prediktif menggunakan model *machine learning* untuk memprediksi kegagalan mesin, sistem ini bertujuan untuk memberikan peringatan dini sebelum terjadinya kerusakan atau kegagalan mesin. Integrasi model dengan sistem peringatan pemeliharaan prediktif, tahap ini memastikan bahwa model dapat bekerja secara *real-time* dan memberikan peringatan yang akurat kepada pengguna. Serta tahapan terakhir adalah evaluasi kinerja sistem secara keseluruhan untuk memastikan bahwa sistem peringatan pemeliharaan prediktif berfungsi dengan baik dan mencapai tujuan yang diinginkan.

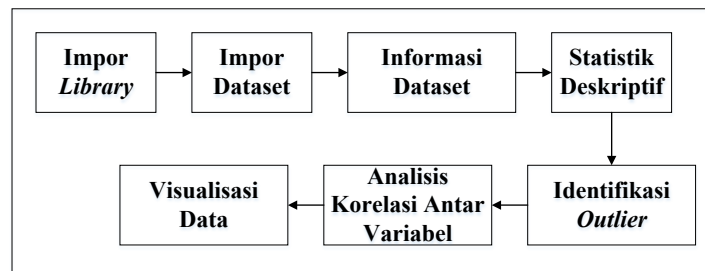
### **3.2 Pengumpulan dan Analisis Data**

Observasi data dilakukan pada platform terpercaya yang menyediakan berbagai dataset publik yaitu *Kaggle*. Data yang digunakan yaitu dataset mesin kompresor reciprocating yang divisualisasikan oleh akun *kaggle* bernama Ahmet Okudan. Dataset tersebut berisi data operasional dari mesin kompresor reciprocating dengan total 1000 sampel. Setiap sampel dalam dataset tersebut mencakup 26 kolom yang berisi informasi dapat dilihat pada Tabel 3.1.

**Tabel 3.1 Deskripsi Kolom Dataset Mesin Kompresor Reciprocating**

No	Nama Kolom	Deskripsi
1.	ID	Identifikasi unik untuk setiap entri
2.	RPM	Kecepatan putaran mesin dalam rotasi per menit
3.	Motor Power	Daya motor dalam watt
4.	Torque	Torsi yang dihasilkan oleh mesin
5.	Outlet Pressure (bar)	Tekanan keluaran dalam bar
6.	Air Flow	Aliran udara yang diukur
7.	Noise (dB)	Tingkat kebisingan dalam desibel
8.	Outlet Temperature	Suhu keluaran
9.	Water Pump Outlet Pressure	Tekanan keluaran pompa air
10.	Water Inlet Temperature	Suhu air masuk
11.	Water Outlet Temperature	Suhu air keluar
12.	Water Pump Power	Daya pompa air
13.	Water Flow	Aliran air
14.	Oil Pump Power	Daya pompa oli
15.	Oil Tank Temperature	Suhu tangki oli
16.	G-Acceleration X (gaccx)	Akselerasi gravitasi pada sumbu X
17.	G-Acceleration Y (gaccy)	Akselerasi gravitasi pada sumbu Y
18.	G-Acceleration Z (gaccz)	Akselerasi gravitasi pada sumbu Z
19.	H-Acceleration X (haccx)	Akselerasi horizontal pada sumbu X
20.	H-Acceleration Y (haccy)	Akselerasi horizontal pada sumbu Y
21.	H-Acceleration Z (haccz)	Akselerasi horizontal pada sumbu Z
22.	Bearings	Kondisi bearing, misalnya "Ok"
23.	Water Pump	Kondisi pompa air, misalnya "Ok"
24.	Radiator	Kondisi radiator, misalnya "Clean"
25.	Exvalve	Kondisi katup eksvalve, misalnya "Clean"
26.	AC Motor	Kondisi motor AC, misalnya "Stable"

Analisis data penelitian ini menggunakan metode *Exploratory Data Analysis* (EDA) bertujuan untuk memberikan gambaran umum tentang data dan mengidentifikasi pola atau anomali yang mungkin tidak terlihat dengan metode lain. Penerapan metode EDA dalam dataset mesin kompresor reciprocating menggunakan *software python open access* di *notebook jupyter*, gambaran mengenai alur proses analisis data dapat dilihat pada Gambar 3.2.




**Gambar 3.2 Alur Proses Analisis Data**

Gambar 3.2 menggambarkan alur proses analisis data dengan tahap pertama adalah mengimpor *library* atau pustaka yang diperlukan untuk analisis data. Tahap selanjutnya adalah mengimpor dataset yang akan dianalisis. Tahap berikutnya adalah memeriksa informasi dasar tentang dataset untuk memahami struktur dan isi data. Tahap ini termasuk melihat beberapa baris pertama dataset, tipe data setiap kolom, dan jumlah data. Tahap selanjutnya statistik deskriptif untuk memahami distribusi data seperti *mean*, *median*, *mode*, *standard deviation*, dan *range*. Tahap berikutnya identifikasi *outlier* atau nilai yang jauh berbeda dari data lainnya. *Outlier* dapat mempengaruhi analisis dan model, sehingga perlu diperiksa apakah akan dihapus atau ditangani dengan cara lain. Tahap selanjutnya analisis korelasi dilakukan untuk melihat hubungan antara variabel-variabel dalam dataset. Korelasi membantu memahami bagaimana satu variabel mungkin mempengaruhi variabel lain. Tahap terakhir visualisasi data menggunakan berbagai jenis grafik seperti *histogram*, *scatter plot*, dan *box plot* untuk lebih memahami distribusi dan pola dalam data.

### 3.3 Preprocessing Data

Preprocessing data sangat penting untuk memastikan bahwa data yang digunakan untuk pelatihan model *machine learning* memiliki kualitas yang tinggi, relevan, dan sesuai. Alur proses data preprocessing pada penelitian ini dapat dilihat pada Gambar 3.3.

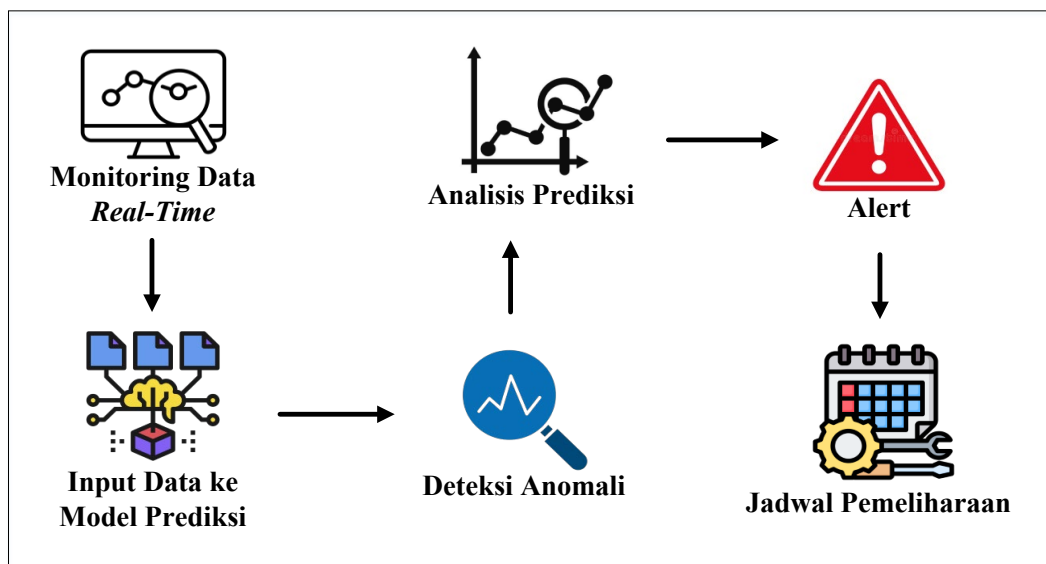


**Gambar 3.3 Alur Proses Data Preprocessing**

Gambar 3.3 menunjukkan alur proses data preprocessing terdiri dari tahap pertama imputasi dilakukan untuk mengganti nilai yang *outlier* dengan nilai yang lebih representative. Tahap kedua transformasi data untuk memperbaiki distribusi yang tidak normal. Tahap ketiga reduksi dimensi yaitu mengurangi jumlah fitur dalam dataset guna menangani dataset dengan banyak fitur, mengurangi kompleksitas model, dan mencegah overfitting.

### 3.4 Sistem Peringatan Pemeliharaan Prediktif

Sistem peringatan pemeliharaan prediktif adalah sistem yang menggunakan teknik-teknik analisis data, terutama *machine learning* untuk memantau kondisi mesin dan memprediksi kegagalan yang mungkin terjadi. Penelitian ini mengusulkan sistem untuk memberikan peringatan dini kepada operator atau tim pemeliharaan sehingga tindakan preventif dapat dilakukan sebelum kegagalan terjadi, mengurangi downtime, dan biaya pemeliharaan. Gambaran alur kerja usulan sistem peringatan pemeliharaan prediktif dapat dilihat pada Gambar 3.4.



**Gambar 3.4 Alur Kerja Sistem Peringatan Pemeliharaan Prediktif**

Gambar 3.4 menggambarkan alur kerja dari sistem pemeliharaan prediktif pada mesin kompresor reciprocating berbasis *machine learning*. Tahap awal adalah data operasional mesin dikumpulkan secara menerus menggunakan sensor, bertujuan memastikan data terkini tersedia untuk dianalisis guna mendeteksi



tanda-tanda awal kegagalan mesin. Tahap kedua menginput data dari pemantauan *real-time* ke dalam model prediksi pemeliharaan yang telah dilatih. Tahap ketiga mendeteksi adanya anomali atau pola yang tidak biasa agar tindakan pencegahan dapat diambil sebelum kerusakan terjadi. Tahap keempat analisis prediksi untuk memperkirakan kapan dan bagaimana kegagalan akan terjadi, sehingga pemeliharaan dapat direncanakan dengan tepat. Tahap kelima *alert* atau peringatan untuk memberikan informasi kepada tim pemeliharaan agar dapat segera mengambil tindakan. Tahap terakhir menjadwalkan tindakan pemeliharaan yang diperlukan berdasarkan peringatan untuk menghindari kegagalan mendadak dan meminimalkan downtime.

### 3.5 Jadwal Penelitian

Jadwal penelitian sebagai panduan untuk mengelola waktu dan sumber daya secara efektif. Jadwal ini mencakup semua aktivitas yang perlu dilakukan, mulai dari perencanaan awal hingga pelaporan akhir. Kegiatan penelitian direncanakan selesai pada tahun 2026 seperti pada Tabel 3.2.

**Tabel 3.2 Jadwal Penelitian**

No	Persiapan	Kegiatan	Tahun/Bulan											
			2023		2024									
			11	12	1	2	3	4	5	6	7	8	9	10
1	Mencari tema penelitian	Studi Literatur												
	Mencari jurnal sesuai tema													
2	Menganalisis sumber-sumber yang diperoleh	Identifikasi Permasalahan												
3	Menentukan metode pengumpulan data	Pengumpulan dan Analisis Data												
	Mengidentifikasi sumber data													
	Menentukan metode analisis data													
4	Memiliki hasil data dari analisis	Preprocessing Data												
5	Menyusun Bab I-III	Ujian Kualifikasi												
6	Memiliki hasil data dari preprocessing	Pemilihan Algoritma yang Efektif												
7	Memiliki algoritma yang telah dipilih	Pengembangan Model Machine Learning												
8	Menentukan metode dan alat yang berhubungan dengan sistem terhadap mesin	Membangun Prototipe Sistem Peringatan Pemeliharaan Prediktif												
9	Memiliki model yang telah dikembangkan	Integrasi Model Machine Learning dengan Sistem Peringatan Pemeliharaan Prediktif												
	Memiliki gambaran alur kerja sistem peringatan pemeliharaan prediktif													

**Tabel 3.3 Jadwal Penelitian Lanjutan**

No	Persiapan	Kegiatan	Tahun/Bulan																	
			2025												2026					
			1	2	3	4	5	6	7	8	9	10	11	12	1	2	3	4	5	6
10	Memiliki hasil dari integrasi model dengan sistem	Evaluasi																		
11	Menyusun Bab IV-V dan memperbaiki yang disarankan pada uji kualifikasi	Evaluasi progress pertama																		
12	Mencari seminar yang relevan dengan topik	Paper Seminar atau Jurnal Internasional																		
	Mengajukan makalah																			
13	Memperbaiki yang disarankan pada evaluasi progress pertama	Evaluasi progress kedua																		
14	Mengukur sejauh mana kegiatan penelitian yang telah dilaksanakan	Evaluasi RKP																		
15	Mencari seminar yang relevan dengan topik	Paper Kedua Jurnal Internasional																		
	Mengajukan makalah																			
16	Memperbaiki yang disarankan pada evaluasi RKP	Sidang Disertasi Tertutup																		
17	Memperbaiki yang disarankan pada sidang tertutup	Sidang Disertasi Terbuka																		

## DAFTAR PUSTAKA

- Abbasi, R., & Esmaili, M. (2024). Identifying the Applications of Artificial Intelligence in Online Marketing. In *Smart and Sustainable Interactive Marketing* (pp. 32-54): IGI Global.
- Agrawal, R., Gehrke, J., Gunopulos, D., & Raghavan, P. (1998). *Automatic subspace clustering of high dimensional data for data mining applications*. Paper presented at the Proceedings of the 1998 ACM SIGMOD international conference on Management of data.
- Aji, M. P., & Aeman, U. G. J. J. M. P. (2023). Aplikasi Speech Recognition untuk audio forensik. *17*(1), 61-73.
- Almamlook, R., Alshammara, N., Albalawi, O. J. P. o. t. I. C. o. I. E., & Management, O. (2022). Machine Learning for Predictive Maintenance in the Manufacturing Sector.
- Ankerst, M., Breunig, M. M., Kriegel, H.-P., & Sander, J. J. A. S. r. (1999). OPTICS: Ordering points to identify the clustering structure. *28*(2), 49-60.
- Arena, F., Collotta, M., Luca, L., Ruggieri, M., Termine, F. J. M., & Applications, C. (2021). Predictive Maintenance in the Automotive Sector: A Literature Review.
- Assagaf, I., Sukandi, A., Abdillah, A. A., Arifin, S., Ga, J. L. J. R. i. E. S., & Technology. (2023). Machine Predictive Maintenance by Using Support Vector Machines. *1*(01), 31-35.
- Atmojo, J. T., Ningrum, A. N., Handayani, R. T., Widiyanto, A., & Darmayanti, A. T. J. J. I. P. J. I. S. K. (2024). Artificial Intelligence dalam Praktik Kesehatan. *14*(3), 1081-1088.
- Ayvaz, S., & Alpay, K. J. E. S. w. A. (2021). Predictive maintenance system for production lines in manufacturing: A machine learning approach using IoT data in real-time. *173*, 114598.
- Azari, M. S., Flammini, F., Santini, S., & Caporuscio, M. J. I. A. (2023). A Systematic Literature Review on Transfer Learning for Predictive Maintenance in Industry 4.0. *11*, 12887-12910.
- Baryannis, G., Validi, S., Dani, S., & Antoniou, G. J. I. J. o. P. R. (2019). Supply chain risk management and artificial intelligence: state of the art and future research directions. *57*(7), 2179-2202.
- Barzenji, H. (2021). Sentiment analysis of Twitter texts using Machine learning algorithms. *%J Academic Platform-Journal of Engineering*, *9*(3), 460-471.
- Baumann, H. (1994). Design Features of A Small Oilfree, Reciprocating, High Pressure Compressor.
- Benbya, H., Pachidi, S., & Jarvenpaa, S. J. J. o. t. A. f. I. S. (2021). Special issue editorial: Artificial intelligence in organizations: Implications for information systems research. *22*(2), 10.
- Bhansali, A., Saxena, S., & Bandhu, K. C. J. M. L. f. S. D. (2021). Machine learning for sustainable agriculture. *9*, 129.
- bin Mohamed, M. Z., Hidayat, R., binti Suhaizi, N. N., bin Mahmud, M. K. H., & binti Baharuddin, S. N. J. I. E. J. o. M. E. (2022). Artificial intelligence in mathematics education: A systematic literature review. *17*(3), em0694.
- Binder, M., Mezhyuev, V., & Tschandl, M. J. I. E. M. R. (2023). Predictive Maintenance for Railway Domain: A Systematic Literature Review. *51*, 120-140.

- Blanchard, B. S., Verma, D., & Peterson, E. L. (1995). *Maintainability: A key to effective serviceability and maintenance management* (Vol. 13): John Wiley & Sons.
- Bloch, H. P., & Godse, A. (2006). *Compressors and modern process applications*: John Wiley & Sons.
- Bloch, H. P., & Hoefner, J. J. (1996). *Reciprocating compressors:: operation and maintenance*: Elsevier.
- Brown, R. N. (1997). *Compressors: Selection and sizing*: Gulf Professional Publishing.
- Cabrera, D., Guamán, A., Zhang, S., Cerrada, M., Sánchez, R.-V., Cevallos, J., . . . Li, C. (2020). Bayesian approach and time series dimensionality reduction to LSTM-based model-building for fault diagnosis of a reciprocating compressor. *Neurocomputing*, 380, 51-66. doi:<https://doi.org/10.1016/j.neucom.2019.11.006>
- Campeato, O. (2020). *Artificial Intelligence, Machine Learning, and Deep Learning*: Mercury Learning and Information.
- Carpenter, G. A., Grossberg, S. J. C. v., graphics,, & processing, i. (1987). A massively parallel architecture for a self-organizing neural pattern recognition machine. 37(1), 54-115.
- Cerrada, M., Montalvo, D., Zambrano, X., Cabrera, D., & Sánchez, R. V. (2022). Fault diagnosis in reciprocating compressor bearings: an approach using LAMDA applied on current signals. *IFAC-PapersOnLine*, 55(19), 199-204. doi:<https://doi.org/10.1016/j.ifacol.2022.09.207>
- Cessie, S. I., & Houwelingen, J. V. J. J. o. t. R. S. S. C. A. S. (1992). Ridge estimators in logistic regression. 41(1), 191-201.
- Charoenchitt, C., & Tangamchit, P. (2021, 20-22 Jan. 2021). *Anomaly Detection of a Reciprocating Compressor using Autoencoders*. Paper presented at the 2021 Second International Symposium on Instrumentation, Control, Artificial Intelligence, and Robotics (ICA-SYMP).
- Cheng, X., Chaw, J. K., Goh, K. M., Ting, T. T., Sahrani, S., Ahmad, M. N., . . . Ang, M. C. J. S. (2022). Systematic Literature Review on Visual Analytics of Predictive Maintenance in the Manufacturing Industry. 22.
- Chollet, F. (2017). *Xception: Deep learning with depthwise separable convolutions*. Paper presented at the Proceedings of the IEEE conference on computer vision and pattern recognition.
- Chowdhary, K. (2020). *Fundamentals of artificial intelligence*: Springer.
- Corder, A. (1996). Teknik manajemen pemeliharaan.
- Dalzochio, J., Kunst, R., Pignaton, E., Binotto, A. P. D., Sanyal, S., Favilla, J., & Barbosa, J. L. V. J. C. I. (2020). Machine learning and reasoning for predictive maintenance in Industry 4.0: Current status and challenges. 123, 103298.
- de Amorim, R. C. (2012). *Constrained clustering with minkowski weighted k-means*. Paper presented at the 2012 IEEE 13th International Symposium on Computational Intelligence and Informatics (CINTI).
- Dingari, M. (2022). *Product recommendation using machine learning*. California State University, Northridge,
- Doble, I. (1987). *Supercharging with an axial compressor* (0148-7191). Retrieved from
- Durbhaka, G. K. J. T. J. o. C., & Education, M. (2021). Convergence Of Artificial Intelligence And Internet Of Things In Predictive Maintenance Systems – A Review.

- Elhaj, M., Gu, F., Ball, A. D., Albarbar, A., Al-Qattan, M., & Naid, A. (2008). Numerical simulation and experimental study of a two-stage reciprocating compressor for condition monitoring. *Mechanical Systems and Signal Processing*, 22(2), 374-389. doi:<https://doi.org/10.1016/j.ymssp.2007.08.003>
- Elkateb, S., Métwalli, A., Shendy, A., & Abu-Elanien, A. E. J. A. E. J. (2024). Machine learning and IoT-Based predictive maintenance approach for industrial applications. 88, 298-309.
- Erhan, D., Courville, A., Bengio, Y., & Vincent, P. (2010). *Why Does Unsupervised Pre-training Help Deep Learning?* Paper presented at the Proceedings of the Thirteenth International Conference on Artificial Intelligence and Statistics, Proceedings of Machine Learning Research. <https://proceedings.mlr.press/v9/erhan10a.html>
- Ester, M., Kriegel, H.-P., Sander, J., & Xu, X. (1996). *A density-based algorithm for discovering clusters in large spatial databases with noise*. Paper presented at the kdd.
- Fernandes, M., Canito, A., Corchado, J. M., & Marreiros, G. (2019). *Fault detection mechanism of a predictive maintenance system based on autoregressive integrated moving average models*. Paper presented at the International Symposium on Distributed Computing and Artificial Intelligence.
- Francis, F., & Mohan, M. (2019). *Arima model based real time trend analysis for predictive maintenance*. Paper presented at the 2019 3rd International conference on Electronics, Communication and Aerospace Technology (ICECA).
- Freund, Y., & Schapire, R. E. (1996). *Experiments with a new boosting algorithm*. Paper presented at the icml.
- Galić, D., Stojanović, Z., & Čajić, E. J. T. v. (2024). Application of Neural Networks and Machine Learning in Image Recognition. 31(1), 316-323.
- Giampaolo, T. (2023). *Compressor handbook: principles and practice*: CRC Press.
- H-Nia, S., Flodin, J., Casanueva, C., Asplund, M., & Stichel, S. J. V. S. D. (2024). Predictive maintenance in railway systems: MBS-based wheel and rail life prediction exemplified for the Swedish Iron-Ore line. 62(1), 3-20.
- Haag, S., & Keen, P. (1996). *Information Technology: Tomorrow's Advantage Today*: ERIC.
- Han, J., Pei, J., & Tong, H. (2022). *Data mining: concepts and techniques*: Morgan kaufmann.
- Hassoun, S., Jefferson, F., Shi, X., Stucky, B., Wang, J., Rosa Jr, E. J. I., & Biology, C. (2021). Artificial intelligence for biology. 61(6), 2267-2275.
- Holte, R. C. J. M. I. (1993). Very simple classification rules perform well on most commonly used datasets. 11, 63-90.
- IDO BRIAN, L. (2022). *PENGOPERASIAN DAN PERAWATAN KOMPRESOR UDARA DUA TINGKAT DI KAPAL MV. TANTO NUSANTARA*. Politeknik Transportasi Sungai, Danau, Dan Penyeberangan Palembang,
- Isai, A., & Nugroho, A. J. J. I. M. I. d. K. (2024). Pencarian Rute Terpendek menggunakan Algoritma Genetika (Studi Kasus: Pengoptimalan Mobilitas Kota Salatiga Terhadap Kota-Kota Tetangga). 5(1), 681-692.
- Jia, Y. J. L. N. o. L., & Literature. (2023). Research on the Development Trends of Linguistics in the Age of Artificial Intelligence. 6(12), 1-8.

- Jin, C. (2020). *Relevance Between Artificial Intelligence and Cognitive Science*. Paper presented at the Proceedings of the 1st International Symposium on Artificial Intelligence in Medical Sciences.
- Jo, T. (2021). *Machine Learning Foundations: Supervised, Unsupervised, and Advanced Learning*: Springer International Publishing.
- John, G. H., & Langley, P. J. a. p. a. (2013). Estimating continuous distributions in Bayesian classifiers.
- Joshi, P. (2017). *Artificial intelligence with python*: Packt Publishing Ltd.
- Kang, Z., Catal, C., & Tekinerdogan, B. J. S. (2021). Remaining useful life (RUL) prediction of equipment in production lines using artificial neural networks. *21*(3), 932.
- Kaufman, L., & Rousseeuw, P. J. (2009). *Finding groups in data: an introduction to cluster analysis*: John Wiley & Sons.
- Khan, M. F., Lu, L., Toseef, M., Musyafa, A., Amin, A. J. J. o. A. I., & Computing, H. (2023). NotifyMiner: rule based user behavioral machine learning approach for context wise personalized notification services. *14*(10), 13301-13317.
- Kläy, H. J. C. (1975). Reciprocating compressors with labyrinth pistons for helium. *15*(10), 569-571.
- Li, T., & Chan, Y. E. (2019). Dynamic information technology capability: Concept definition and framework development. *The Journal of Strategic Information Systems*, *28*(4), 101575. doi:<https://doi.org/10.1016/j.jsis.2019.101575>
- Li, X., Mba, D., & Loukopoulos, P. (2020, 23-25 Oct. 2020). *A Just-In-Time-Learning Based Data-driven Method for Valve Failure Prognostics*. Paper presented at the 2020 11th International Conference on Prognostics and System Health Management (PHM-2020 Jinan).
- Liu, Y., Yu, W., Dillon, T. S., Rahayu, W., & Li, M. J. I. T. o. I. I. (2022). Empowering IoT Predictive Maintenance Solutions With AI: A Distributed System for Manufacturing Plant-Wide Monitoring. *18*, 1345-1354.
- Loukopoulos, P., Zolkiewski, G., Bennett, I., Sampath, S., Pilidis, P., Li, X., & Mba, D. (2019). Abrupt fault remaining useful life estimation using measurements from a reciprocating compressor valve failure. *Mechanical Systems and Signal Processing*, *121*, 359-372. doi:<https://doi.org/10.1016/j.ymssp.2018.09.033>
- Loutas, T., Eleftheroglou, N., Georgoulas, G., Loukopoulos, P., Mba, D., & Bennett, I. (2020). Valve Failure Prognostics in Reciprocating Compressors Utilizing Temperature Measurements, PCA-Based Data Fusion, and Probabilistic Algorithms. *IEEE Transactions on Industrial Electronics*, *67*(6), 5022-5029. doi:10.1109/TIE.2019.2926048
- Lu, Y. J., & Wang, C. H. (2021). Integration of wavelet decomposition and artificial neural network for failure prognosis of reciprocating compressors. *%J Process Safety Progress*, *40*(3), 105-115.
- Luger, G. F., & Stubblefield, W. A. (1993). *Artificial Intelligence: Structures and Strategies for Complex Problem Solving*: The Benjamin/Cummings.
- Lumbantoruan, A. R., & Niska, D. Y. J. J. P. I. d. T. K. (2024). Design Of Expert System For Diagnosing Diseases In Pet Dogs Based On Web Using The Forward Chaining Method. *16*(1), 1217-1228.
- Luxton, D. D. J. P. P. R., & Practice. (2014). Artificial intelligence in psychological practice: Current and future applications and implications. *45*(5), 332.

- Lv, Q., Yu, X., Ma, H., Ye, J., Wu, W., & Wang, X. (2021). Applications of machine learning to reciprocating compressor fault diagnosis: A review. *9*(6), 909.
- MacQueen, J. (1967). *Some methods for classification and analysis of multivariate observations*. Paper presented at the Proceedings of the fifth Berkeley symposium on mathematical statistics and probability.
- Marchante-Avellaneda, J., Navarro-Peris, E., & Shrestha, S. S. J. A. T. E. (2024). Comparison and selection of experimental designs for the characterization of scroll and reciprocating compressors: Adjustment of polynomial models with compact experimental samples. *241*, 122341.
- Meddaoui, A., Hachmoud, A., & Hain, M. (2024). Advanced ML for Predictive Maintenance: Case Study on Remaining Useful Life Prediction and Reliability Enhancement.
- Medeiros, E. P., Machado, M. R., de Freitas, E. D. G., da Silva, D. S., & de Souza, R. W. R. J. E. S. w. A. (2024). Applications of machine learning algorithms to support COVID-19 diagnosis using X-rays data information. *238*, 122029.
- Medina, R., Sánchez, R.-V., Cabrera, D., Cerrada, M., Estupiñan, E., Ao, W., & Vásquez, R. E. J. S. (2024). Scale-Fractal Detrended Fluctuation Analysis for Fault Diagnosis of a Centrifugal Pump and a Reciprocating Compressor. *24*(2), 461.
- Meena, G., Sharma, D., & Mahrishi, M. (2020). *Traffic prediction for intelligent transportation system using machine learning*. Paper presented at the 2020 3rd International Conference on Emerging Technologies in Computer Engineering: Machine Learning and Internet of Things (ICETCE).
- Mitchell, T. M. (1997). Machine learning. In: McGraw-hill.
- Mobley, R. K. (2002). *An introduction to predictive maintenance*: Elsevier.
- Mohammad, S. M. J. S. E. J. (2020). Artificial Intelligence in Information Technology.
- Morocho-Cayamcela, M. E., Lee, H., & Lim, W. J. I. a. (2019). Machine learning for 5G/B5G mobile and wireless communications: Potential, limitations, and future directions. *7*, 137184-137206.
- Moru, D. K., & Borro, D. J. T. I. J. o. A. M. T. (2020). A machine vision algorithm for quality control inspection of gears. *106*, 105-123.
- Motaghare, O., Pillai, A. S., & Ramachandran, K. I. (2018, 13-15 Dec. 2018). *Predictive Maintenance Architecture*. Paper presented at the 2018 IEEE International Conference on Computational Intelligence and Computing Research (ICICIC).
- Najafabadi, M. M., Villanustre, F., Khoshgoftaar, T. M., Seliya, N., Wald, R., & Muharemagic, E. (2015). Deep learning applications and challenges in big data analytics. *Journal of Big Data*, *2*(1), 1. doi:10.1186/s40537-014-0007-7
- Nisa, N. A. A., Suwaidi, R. A. J. I. J. o. S. S., & Humanities. (2023). Analisis Potensi Dampak Artificial Intelligence (AI) terhadap Efisiensi Manajemen Operasional: Tinjauan Literatur. *3*(2), 93-97.
- Oana, O., Cosmin, T., & Valentin, N. C. J. O. U. A., Economic Sciences Series. (2017). Artificial Intelligence-a new field of computer science which any business should consider. *17*(1), 356-360.
- Papachatzakis, P., Papakostas, N., & Chryssolouris, G. (2007). *Condition based operational risk assessment an innovative approach to improve fleet and aircraft operability: Maintenance planning*. Paper presented at the 1st European Air and Space Conference, Berlin, Germany.

- Park, H.-S., & Jun, C.-H. J. E. s. w. a. (2009). A simple and fast algorithm for K-medoids clustering. *36*(2), 3336-3341.
- Patil, C. R., Jadhav, S. K., Bardiya, A. L., Davande, A. P., & Raverkar, M. P. Machine Learning-Based Predictive Maintenance of Industrial Machines.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., . . . Dubourg, V. J. t. J. o. m. L. r. (2011). Scikit-learn: Machine learning in Python. *12*, 2825-2830.
- Peng, Y., Dong, M., & Zuo, M. J. J. T. I. J. o. A. M. T. (2010). Current status of machine prognostics in condition-based maintenance: a review. *50*, 297-313.
- Pham, D., & Pham, P. (1999). Artificial intelligence in engineering. %J *International Journal of Machine Tools Manufacture*, *39*(6), 937-949.
- Pollock, J. J. P. P. (1990). Philosophy and artificial intelligence. *4*, 461-498.
- Prakasa, P. J. S. T. (2017). PERAWATAN DAN PERBAIKAN SISTEM PELUMASAN MESIN HONDA ACCORD TAHUN 1979.
- Preuveneers, D., Joosen, W. J. J. o. C., & Privacy. (2021). Sharing machine learning models as indicators of compromise for cyber threat intelligence. *1*(1), 140-163.
- Puterman, M. L. (2014). *Markov decision processes: discrete stochastic dynamic programming*: John Wiley & Sons.
- Quinlan, J. R. (2014). *C4. 5: programs for machine learning*: Elsevier.
- Quinlan, J. R. J. M. I. (1986). Induction of decision trees. *1*, 81-106.
- Ran, Y., Zhou, X., Lin, P., Wen, Y., & Deng, R. (2019). A survey of predictive maintenance: Systems, purposes and approaches. %J *arXiv preprint arXiv:07383*.
- Rasmussen, C. J. A. i. n. i. p. s. (1999). The infinite Gaussian mixture model. *12*.
- Rebala, G., Ravi, A., & Churiwala, S. (2019). *An introduction to machine learning*: Springer.
- Ren, Y. (2021). *Optimizing Predictive Maintenance With Machine Learning for Reliability Improvement*.
- Robison, D. H., & Beaty, P. J. (1992). *Compressor types, classifications, and applications*. Paper presented at the Proceedings of the 21st Turbomachinery Symposium.
- Sahputra, R. J., & Muzakir, A. J. J. P. S. I. d. I. (2020). Penerapan AI Melalui Pendekatan Heuristik Semilaritas Pada Game Edukasi Anak Usia Dini. *1*(4), 209-219.
- Sakib, N., & Wuest, T. J. P. c. (2018). Challenges and opportunities of condition-based predictive maintenance: a review. *78*, 267-272.
- Sarker, I. H. (2021). Machine learning: Algorithms, real-world applications and research directions. *2*(3), 160.
- Sarker, I. H., Colman, A., Kabir, M. A., & Han, J. J. T. C. J. (2018). Individualized time-series segmentation for mining mobile phone user behavior. *61*(3), 349-368.
- Sarker, I. H., Kayes, A., Badsha, S., Alqahtani, H., Watters, P., & Ng, A. J. J. o. B. d. (2020). Cybersecurity data science: an overview from machine learning perspective. *7*, 1-29.
- Sarker, I. H. J. S. C. S. (2021a). Deep cybersecurity: a comprehensive overview from neural network and deep learning perspective. *2*(3), 154.
- Sarker, I. H. J. S. c. s. (2021b). Machine learning: Algorithms, real-world applications and research directions. *2*(3), 160.
- Scott, M. J., Verhagen, W. J., Bieber, M. T., & Marzocca, P. J. S. (2022). A Systematic Literature Review of Predictive Maintenance for Defence Fixed-Wing Aircraft Sustainment and Operations. *22*(18), 7070.



- Seeley, I. H., & Seeley, I. H. J. B. M. (1976). Building Control. 249-269.
- Selcuk, S. J. P. o. t. I. o. M. E., Part B: Journal of Engineering Manufacture. (2017). Predictive maintenance, its implementation and latest trends. 231(9), 1670-1679.
- Sezer, E., Romero, D., Guedea, F., Macchi, M., & Emmanouilidis, C. (2018, 17-20 June 2018). *An Industry 4.0-Enabled Low Cost Predictive Maintenance Approach for SMEs*. Paper presented at the 2018 IEEE International Conference on Engineering, Technology and Innovation (ICE/ITMC).
- Shafiq, M., Tian, Z., Sun, Y., Du, X., & Guizani, M. J. F. G. C. S. (2020). Selection of effective machine learning algorithm and Bot-IoT attacks traffic identification for internet of things in smart city. 107, 433-442.
- Sharma, M., Katare, D. P., Chauhan, R., Rani, S., Mani, R. J. J. A. I., & Research, C. D. f. B. (2022). Artificial intelligence: the future of neuroscience. 8, 97.
- Shen, H., Zhang, F., Pan, X., & Sun, X. (2024). The fuzzy system based on vague partitions and its application to path tracking control for autonomous vehicles. *Journal of Intelligent & Fuzzy Systems, Preprint*, 1-24. doi:10.3233/JIFS-232903
- Sikka, M. P., Sarkar, A., Garg, S. J. R. J. o. T., & Apparel. (2024). Artificial intelligence (AI) in textile industry operational modernization. 28(1), 67-83.
- Silver, D., Huang, A., Maddison, C. J., Guez, A., Sifre, L., Van Den Driessche, G., . . . Lanctot, M. J. n. (2016). Mastering the game of Go with deep neural networks and tree search. 529(7587), 484-489.
- Sim, H.-Y., Ramli, R., & Saifizul, A. (2019). Reciprocating compressor valve damage estimation under varying speeds through the acoustic emission technique. *International Journal of Structural Integrity*, 10(5), 621-633. doi:10.1108/IJSI-03-2019-0024
- Soliman, M., Fatnassi, T., Elgammal, I., & Figueiredo, R. J. B. D. C. C. (2023). Exploring the Major Trends and Emerging Themes of Artificial Intelligence in the Scientific Leading Journals amidst the COVID-19 Era. 7, 12.
- Sonam Tiwari, D. A. P. (2024). A REVIEW ON DRUG DISCOVERY AND DEVELOPMENT ASSOCIATED WITH ARTIFICIAL INTELLIGENCE. *EPRA International Journal of Research and Development (IJRD)*, 9(1), 141-147.
- Stewart, M. (2018). *Surface production operations: volume IV: pumps and compressors*: Gulf Professional Publishing.
- Syamsuri, H. J. J. M. G. (2023). PERANCANGAN SIMULATOR KOMPRESOR TORAK UNTUK MEDIA PEMBELAJARAN. 2(1), 26-34.
- Thomas, É., Levrat, É., lung, B., & Cochetoux, P. J. I. p. v. (2009). Opportune maintenance and predictive maintenance decision support. 42(4), 1603-1608.
- Toroghi, A., & Sadighi, A. (2020). *Smart fault detection of reciprocating air compressors based on electrical signature analysis*. Paper presented at the 2020 6th Iranian Conference on Signal Processing and Intelligent, Tahrán/Iran.
- van Genugten, R. D. I., & Schacter, D. L. (2024). Automated scoring of the autobiographical interview with natural language processing. *Behavior Research Methods*. doi:10.3758/s13428-023-02145-x
- Wagstaff, K., Cardie, C., Rogers, S., & Schrödl, S. (2001). *Constrained k-means clustering with background knowledge*. Paper presented at the Icml.
- Wang, L., Zhu, Z., & Zhao, X. (2024). Dynamic predictive maintenance strategy for system remaining useful life prediction via deep learning ensemble method. *Reliability*

- Engineering & System Safety*, 245, 110012. doi:<https://doi.org/10.1016/j.ress.2024.110012>
- Wang, W., Yang, J., & Muntz, R. (1997). *STING: A statistical information grid approach to spatial data mining*. Paper presented at the Vldb.
- Witten, I. H., Frank, E., Hall, M. A., Pal, C. J., & Data, M. (2005). *Practical machine learning tools and techniques*. Paper presented at the Data mining.
- Wu, W., Li, C., Zhu, Z., Li, X., Zhang, Y., Zhang, J., . . . Wang, B. (2023). A new method for reciprocating compressor fault diagnosis based on indicator diagram feature extraction. %J *Proceedings of the Institution of Mechanical Engineers, Part A: Journal of Power Energy*, 237(6), 1337-1347.
- Xiao, Y., Pan, X., Tavasoli, S., Azimi, M., Bao, Y., Farsangi, E. N., & Yang, T. T. (2024). Autonomous inspection and construction of civil infrastructure using robots. In *Automation in Construction toward Resilience* (pp. 1-26): CRC Press.
- Xiaohan, J., Qingqing, Z., Jianmei, F., & Xueyuan, P. J. M. P. i. E. (2016). Numerical Simulation and Experimental Study on Temperature Distribution of Self-Lubricating Packing Rings in Reciprocating Compressors. 2016.
- Xie, J., Huang, J., Zeng, C., Jiang, S.-H., & Podlich, N. C. J. G. (2020). Systematic Literature Review on Data-Driven Models for Predictive Maintenance of Railway Track: Implications in Geotechnical Engineering.
- Xin, Y., Kong, L., Liu, Z., Chen, Y., Li, Y., Zhu, H., . . . Wang, C. J. I. a. (2018). Machine learning and deep learning methods for cybersecurity. 6, 35365-35381.
- Xing, L., Feng, J., He, Z., & Peng, X. (2021). Analysis and development of a roots-type air compressor with fixed internal compression for fuel cell system. *Proceedings of the Institution of Mechanical Engineers, Part A: Journal of Power and Energy*, 236(1), 51-60. doi:10.1177/09576509211030031
- Xu, D., & Tian, Y. J. A. o. D. S. (2015). A comprehensive survey of clustering algorithms. 2, 165-193.
- Yang, X.-b., Jin, X.-q., Du, Z.-m., Cui, T.-s., & Yang, S.-k. J. J. o. S. J. U. (2009). Experimental study on frictional and sealing performances of packing rings in an oil-free gas compressor. 14, 725-731.
- Yu, Z., Zhang, B., Hu, G., & Chen, Z. J. S. P. (2022). Early fault diagnosis model design of reciprocating compressor valve based on multiclass support vector machine and decision tree. 2022.
- Zhang, Y., Yang, G., Zhang, D., & Wang, T. (2021). Investigation on recognition method of acoustic emission signal of the compressor valve based on the deep learning method. *Energy Reports*, 7, 62-71. doi:<https://doi.org/10.1016/j.egy.2021.10.053>
- Zhao, D., Liu, S., Zhang, H., Sun, X., Wang, L., & Wei, Y. (2021). Intelligent Fault Diagnosis of Reciprocating Compressor Based on Attention Mechanism Assisted Convolutional Neural Network Via Vibration Signal Rearrangement. *Arabian Journal for Science and Engineering*, 46(8), 7827-7840. doi:10.1007/s13369-021-05515-9
- Zheng, H., Paiva, A. R. C., & Gurciullo, C. S. J. A. (2020). Advancing from Predictive Maintenance to Intelligent Maintenance with AI and IIoT. *abs/2009.00351*.
- Zonta, T., Da Costa, C. A., da Rosa Righi, R., de Lima, M. J., da Trindade, E. S., & Li, G. P. (2020). Predictive maintenance in the Industry 4.0: A systematic literature review. %J *Computers Industrial Engineering*, 150, 106889.

- Zonta, T., Da Costa, C. A., da Rosa Righi, R., de Lima, M. J., da Trindade, E. S., Li, G. P. J. C., & Engineering, I. (2020). Predictive maintenance in the Industry 4.0: A systematic literature review. *150*, 106889.
- Zou, B., Xiang, Y., Zou, R., Liu, H., Xu, C., Zou, Y., & Chen, S. (2020, 9-13 Nov. 2020). *Improved RCM method by AHP-FCE for the maintenance strategy of reciprocating compressor unit*. Paper presented at the 2020 15th IEEE Conference on Industrial Electronics and Applications (ICIEA).