

Pengembangan Metode Prediksi Stunting Berbasis *Generative Adversarial Networks*

I Komang Sugi Martha

10 Agustus 2022



**PENGEMBANGAN METODE PREDIKSI
STUNTING BERBASIS *GENERATIVE
ADVERSARIAL NETWORKS***

**I KOMANG SUGIARTHA
NPM: 99217007**

**PROGRAM DOKTOR TEKNOLOGI INFORMASI
UNIVERSITAS GUNADARMA
2022**



PENGEMBANGAN METODE PREDIKSI STUNTING BERBASIS GENERATIVE *ADVERSARIAL NETWORKS*

DISERTASI

Untuk memenuhi salah satu syarat guna memperoleh gelar Doktor
Teknologi Informasi
di bawah pimpinan Rektor Universitas Gunadarma
Profesor Doktor E. S. Margianti, SE, MM

Dipertahankan dalam Sidang Terbuka Senat Universitas Gunadarma
Pada Hari - Tanggal - Jam - WIB - selesai

**I KOMANG SUGIARTHA
NPM: 99217007**

**PROGRAM DOKTOR TEKNOLOGI INFORMASI
UNIVERSITAS GUNADARMA
2022**

Pernyataan orisinalitas dan publikasi

Saya yang bertanda tangan di bawah ini:

Nama : I Komang Sugiarktha
NPM : 99217007
Judul disertasi : PENGEMBANGAN METODE PREDIKSI
STUNTING BERBASIS *GENERATIVE
ADVERSARIAL NETWORKS*
Tanggal Sidang : xxx
Tanggal Lulus :

menyatakan bahwa tulisan di atas merupakan hasil karya saya sendiri dan dapat dipublikasikan sepenuhnya oleh Universitas Gunadarma. Segala kutipan dalam bentuk apapun telah mengikuti kaidah dan etika yang berlaku. Semua hak cipta dari logo serta produk yang disebut dalam buku ini adalah milik masing-masing pemegang haknya, kecuali disebutkan lain. Mengenai isi dan tulisan merupakan tanggung jawab Penulis, bukan Universitas Gunadarma.

Demikianlah pernyataan ini dibuat dengan sebenarnya dan dengan penuh kesadaran.

Jakarta, - Juli 2022

(I Komang Sugiarktha)

**PENGEMBANGAN METODE PREDIKSI
STUNTING BERBASIS GENERATIVE
*ADVERSARIAL NETWORKS***

DISERTASI

**I KOMANG SUGIARTHA
NPM: 99217007**

Telah disetujui oleh:

Profesor Doktor Ing. Adang Suhendra, SSi, SKom, MSc
Promotor

Dr. rer. nat. I Made Wiryana, SSi, SKom, MSc
Ko-Promotor

Ko-Promotor

Lembar Pengesahan

Judul disertasi : **PENGEMBANGAN METODE PREDIKSI STUNTING BERBASIS *GENERATIVE ADVERSARIAL NETWORKS***
Nama mahasiswa : **I Komang Sugiarktha**
Nomor Pokok Mahasiswa : **99217007**

Menyetujui:

Komisi Pembimbing

Promotor Profesor Doktor Ing. Adang Suhendra, SSi, SKom, MSc
Ko Promotor Dr. rer. nat. I Made Wiryana, SSi, SKom, MSc
Ko Promotor -

Komite Penguji

Ketua Profesor Doktor Ing. Adang Suhendra (Promotor)
Anggota - (Penguji Luar)
Profesor Doktor E.S. Margianti, SE., MM (Penguji Dalam)
Profesor Doktor Suryadi Harmanto, SSi., MMSI (Penguji Dalam)
Profesor Insinyur Busono Soerowirdjo, PhD (Penguji Dalam)
Profesor Doktor Sarifuddin Madenda (Penguji Dalam)
Profesor Doktor Eri Prasetyo Wibowo (Penguji Dalam)
- (Penguji Dalam)
- (Ko-Promotor)
- (Ko-Promotor)

Abstrak

I Komang Sugiarta. 99217007

PENGEMBANGAN METODE PREDIKSI STUNTING BERBASIS *GENERATIVE ADVERSARIAL NETWORKS*.

Disertasi, Program Doktor Teknologi Informasi, Universitas Gunadarma, 2022.

Kata Kunci: prediksi,stunting,GAN,machine learning

(-+ -+ lampiran)

Tulis abstrak di sini

Daftar Pustaka (xxx-xxx)

Abstract

I Komang Sugiarta. 99217007
XXXXXXXXXXXX.

Dissertation, Doctoral Programme of Information Technology, Gunadarma University, 2022.

Keyword: prediksi,stunting,GAN,machine learning
(-+ -+ appendix)

Tulis abstrak di sini

References (xxx-xxx)

Kata Pengantar

Penulisan disertasi ini merupakan syarat untuk memperoleh gelar Doktor dalam bidang Teknologi Informasi di Universitas Gunadarma, dengan demikian selesailah studi program Doktor (Strata Tiga) yang penulis jalani di Program Pascasarjana Universitas Gunadarma. Penulis sepenuhnya menyadari bahwa ini merupakan sebagai suatu awalan bagi proses pengembangan, dan pengabdian ilmu yang telah dicapai dalam kehidupan akademik dan masyarakat yang terus menerus ditingkatkan dari kuantitas dan kualitasnya.

Tanpa bantuan moral dan material dari berbagai pihak selama tahap penyelesaian disertasi ini, penulis tidak akan dapat menyelesaikan dengan baik. Untuk itu dengan kerendahan hati penulis dengan tulus mengucapkan terima kasih kepada:

1. Yayasan Pendidikan Gunadarma yang telah memberikan kesempatan berarti kepada penulis untuk melanjutkan studi di Program Doktor Teknologi Informasi Universitas Gunadarma
2. Ibu Prof. Dr. E.S. Margianti, SE., MM., Rektor Universitas Gunadarma yang telah memberikan kesempatan dan kepercayaan kepada penulis untuk melanjutkan studi ini dengan segala fasilitas yang disediakan, dukungan dan semangat serta kemudahan yang diberikan, sehingga proses perkuliahan, penelitian, dan penulisan disertasi dapat berjalan dengan baik.
3. Bapak Prof. Dr. Bambang Suryawan selaku Koordinator Program Pascasarjana Universitas Gunadarma, yang telah memberi saran, dorongan dan motivasi kepada penulis untuk menyelesaikan penelitian dan penulisan disertasi ini.
4. Bapak Prof. Ir. Busono Soerowirdjo, PhD., Direktur Program Pasca

Sarjana Doktor Universitas Gunadarma, yang telah memberikan bimbingan dan masukan sehingga memperkaya disertasi ini.

5. Bapak Prof. Dr. Sarifuddin Madenda dan Prof. Dr. Eri Prasetyo Wibowo, Ketua dan Sekretaris Program Doktor Teknologi Informasi Universitas Gunadarma, yang telah memberikan arahan, motivasi, masukan koreksi dan saran dalam penulisan disertasi ini.
6. Bapak Prof. Dr. Ing. Adang Suhendra, SSi, SKom, MSc selaku Promotor, atas bimbingan, tenaga, dan waktu, juga semangat, arahan dan panduan yang sangat berharga untuk kepada penulis untuk dapat meneliti dan menulis sesuai dengan kaidah-kaidah ilmiah yang baik, dan benar.
7. Bapak Dr. xxx selaku Ko-Promotor yang tidak berhentinya memotivasi, memberi semangat, yang senantiasa meluangkan waktu untuk memberikan ide, panduan, data, metode dan teknik serta memberikan koreksi yang membangun bagi penyelesaian disertasi ini.
8. Bapak Dr. xxx selaku Ko-Promotor yang tidak berhentinya memotivasi, senantiasa meluangkan waktu untuk memberikan ilmu, ide, panduan, data, metode dan teknik serta memberikan koreksi yang membangun bagi penyelesaian disertasi ini.
9. Bapak Prof. xxxx, sebagai penguji luar yang telah berkenan menguji disertasi ini dan memberikan koreksi serta saran yang bermanfaat kepada penulis untuk penyempurnaan disertasi ini.
10. Bapak Prof. Suryadi Harmanto, SSi, MMSI dan Ibu Dr. Detty Purnamasari, sebagai penguji dalam yang telah memberikan motivasi dan masukan pada penulisan disertasi ini menjadi lebih baik.
11. Bapak Alm. Prof. Dr. Djati Kerami dan Bapak Alm. Prof. Dr. Yuvara Sukra, MSc., yang telah mengajarkan kejujuran dan kebenaran di dalam penelitian.
12. Tim Pengembangan DGX, yang telah membantu dalam penggunaan mesin DGX.

13. Rekan-rekan Program Doktor Teknologi Informasi, khususnya seluruh angkatan 19B yang selalu memberi semangat untuk menyelesaikan studi.
14. Teman-teman di sekretariat Program Doktor Teknologi Informasi Universitas Gunadarma, Ibu Dr. Diny Wahyuni SKom., MMSI., Ibu Dr. Reni Diah yang turut membantu dalam administrasi penyelesaian disertasi ini.
15. Rekan-rekan di mares, Ibu Dr. Ida Astuti, Dr. Winda Widya Aristya, Diah Tri Budi Lestari dan Fikri Fadlillah yang telah memberikan dukungan dan membantu kelancaran dalam penyelesaian disertasi ini.
16. Rekan-rekan di Kampus F1, Dr. Ernianthi H, Dr. Andreas Hadiyono, Nurul, Koko, Evan, Fina, Elina, Dr. Syamsi yang telah membantu kelancaran dalam penyelesaian disertasi ini.
17. Orang tua tercinta, Ni Ketut Rustini yang telah memberikan doa, semangat serta kasih sayang yang tiada terkira.
18. Teruntuk istriku tercinta Kadek Dwy Triesna Febyana, sebagai penyeorang dan penghapus kelelahan sekaligus motivasi terbesar bagi penyelesaian penulisan studi ini.
19. Rekan-rekan di IBC yang telah banyak membantu penulis dalam penyelesaian disertasi ini.
20. Rekan-rekan dan sahabat di Universitas Gunadarma yang tidak dapat disebutkan satu-persatu.

Semoga Tuhan Yang Maha Esa membalas semua keikhlasan, perhatian dan bantuan Bapak, Ibu, dan Saudara yang telah diberikan kepada penulis dengan balasan yang berlipat ganda.

Kritik dan saran dari pembaca, penulis harapkan untuk perbaikan di masa yang akan datang.

Jakarta, xxxx 2022

Penulis

(I Komang Sugiarkha)

Daftar Isi

Abstrak	iii
Abstract	iv
Kata Pengantar	v
1 Pendahuluan	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	6
1.3 Batasan Masalah	6
1.4 Tujuan Penelitian	6
1.5 Kontribusi Penelitian	6
2 Telaah Pustaka	8
2.1 <i>Artificial Intelligence</i> (AI)	8
2.2 <i>Machine Learning</i> (ML)	9
2.2.1 <i>Supervised Learning</i>	11
2.2.2 <i>Unsupervised Learning</i>	13
2.2.3 <i>Reinforcement Learning</i>	14
2.3 Generative Adversarial Networks (GANs)	15
2.4 <i>Deep Learning</i>	17
2.5 Data Mining	18
2.5.1 Tahap-Tahap Data mining	19
2.6 <i>Natural Language Processing</i> (NLP)	21
2.6.1 <i>Text Mining</i>	22
2.6.2 Pra-Proses Teks (<i>Text Preprocessing</i>)	23
2.6.3 Clustering	24
2.6.4 K-Means	24

2.7 Prediksi	25
2.8 Situasi Balita Pendek (Stunting)	26
2.8.1 Diagnosis Stunting	27
2.8.2 Faktor Risiko Stunting	27
2.8.3 Dampak Stunting	29
2.9 Program Indonesia Sehat dengan Pendekatan Keluarga (PIS-PK)	30
2.10 Penelitian Terkait	32
3 Metode Penelitian	36
3.1 Tahapan Penelitian	36
3.2 Faktor Indikator Penyebab Stunting	37
3.3 Pengembangan Model	41
3.3.1 Akuisisi Data	43
3.3.2 <i>Preprocessing</i>	43
3.3.3 Proses Pengembangan Model Prediksi Stunting	44
3.4 Pengujian	47
4 Hasil dan Pembahasan	48
4.1 Implementasi Penelitian	48
4.2 Pembangunan Model	49
4.2.1 Akuisisi Data	49
4.2.2 Proses Preprocessing	51
5 Kesimpulan dan Saran	52
5.1 Kesimpulan	52
5.2 Saran	52
Daftar Pustaka	52
LAMPIRAN	59
RIWAYAT HIDUP	60

Daftar Tabel

2.1 Rangkuman Hasil Penelitian Terkait	34
2.2 Rangkuman Hasil Penelitian Terkait	35
3.1 Hubungan Indikator Stunting	39
3.2 Hubungan Indikator Stunting	40
4.1 Jumlah Data Stunting	49
4.2 Jumlah Data Indikator PIS-PK	50

Daftar Gambar

2.1	Skema <i>Artifical Intelligence</i> dan <i>Machine Learning</i> (Karthikeyan and Priyakumar, 2022)	11
2.2	Ilustrasi <i>supervised learning</i>	13
2.3	Ilustrasi <i>unsupervised learning</i>	14
2.4	Ilustrasi Reinforcement learning	15
2.5	Konsep Generative Adversarial Networks (GANs)	16
2.6	Ilustrasi Model <i>Feature Learning</i>	18
2.7	Tahap–tahap Data Mining (Han and Kamber, 2006)	19
2.8	Penjabaran Visi & Misi Presiden Menjadi Program Indonesia Sehat	31
3.1	Metodologi Penelitian	37
3.2	Pengembangan Model	42
3.3	Tahapan Akuisisi Data	43
3.4	<i>Preprocessing</i>	44
3.5	Tahapan <i>Preprocessing</i>	44
3.6	Proses Pengembangan Model Prediksi Stunting	45
3.7	Arsitektur <i>Generative Adversarial Networks</i>	46
4.1	Data Jumlah Stunting	50
4.2	Data Indikator PIS-PK	51

Daftar Algoritma

Bab 1

Pendahuluan

1.1 Latar Belakang

Salah satu cabang dari bidang *Artificial Intelligence* (kecerdasan buatan) yang berkembang pesat saat ini yaitu *Machine Learning* (Pembelajaran Mesin). Pembelajaran mesin menempati peringkat ketiga untuk kategori perkembangan tercepat hak paten yang disetujui. Tujuh perusahaan raksasa seperti IBM, Microsoft, Google, LinkedIn, Facebook, Intel, dan Fujitsu tercatat memiliki paten baru terbanyak di bidang tersebut. Semakin meningkatnya animo pada bidang ini, pembelajaran mesin kemudian menjadi salah satu topik yang sering diangkat dalam riset atau penelitian (Jordan and Mitchell, 2015).

Kemampuan belajar yang menjadi dominan ditentukan oleh kemampuan perangkat lunak atau algoritma. Implementasi kemampuan belajar dapat dicapai dengan berbagai teknik, baik menggunakan kaidah (*rule*), menggunakan statistika, maupun menggunakan pendekatan fisiologi yaitu sistem saraf manusia atau disebut dengan ANN (*Artificial Neural Network*) atau jaringan saraf tiruan (Russell, 2010). *Machine Learning* dapat berfungsi untuk beradaptasi dengan suatu keadaan yang baru, serta untuk mendeteksi dan memperkirakan suatu pola. Sebagai upaya ilmiah, *Machine Learning* tumbuh dari studi pengenalan pola dan teori pembelajaran komputasi pada *Artificial Intelligence* (AI). *Machine Learning* sangat erat kaitannya dengan statistik komputasi dan juga berfokus pada pembuatan prediksi melalui penggunaan komputer.

Beberapa algoritma dari *machine learning* menggunakan data yang ti-

dak sedikit, hal ini membuat suatu tantangan bagi *machine learning engineer* untuk dapat mengolah dan memperoleh hasil yang maksimal dari suatu model *machine learning*. Beberapa algoritma dari *machine learning*, seperti *Neural Networks*, *Convolutional Neural Networks*, *Recurrent Neural Networks*, *Support Vector Machine*, *K-Nearest Neighbors*, *K-Means*, *Principal Component Analysis*, *Deep Q Networks*, *Deep Deterministic Policy Gradient*, dan *Generative Adversarial Networks*. Banyaknya algoritma yang ada pada *machine learning*, baik itu baru maupun lama memungkinkan dalam pemecahan hampir semua masalah yang ada di era Revolusi Industri 4.0 (Praramadhan and Saputra, 2021).

Generative Adversarial Networks (GANs) adalah salah satu dari algoritma *Unsupervised Learning* yang ada pada *machine learning* sejak tahun 2014, dimana algoritma ini menggunakan 2 *neural networks* atau jaringan syaraf buatan yang terdiri atas *Generator* dan *Diskriminasi*. Dengan adanya struktur seperti itu dapat menghasilkan suatu data sintesis baru yang menyerupai bentuk asli pada inputnya. Keberhasilan algoritma *Generative Adversarial Networks* (GAN) banyak diterapkan di berbagai bidang, seperti prediksi pasar saham, optimasi portofolio, pemrosesan informasi keuangan dan strategi eksekusi perdagangan, karena model GAN menghasilkan data yang tampak realistik dengan model generator dan diskriminasi (Husein et al., 2019).

Penelitian dengan pengembangan algoritma *Generative Adversarial Networks* banyak dikembangkan seperti yang diusulkan oleh Saxena and Cao (2019), mengusulkan model berbasis *generative adversarial network* baru (bernama, D-GAN) untuk prediksi *Spatial-Temporal* (ST) yang lebih akurat dengan secara implisit mempelajari representasi fitur ST dengan cara yang tidak diawasi. Lei et al. (2019) juga memperkenalkan model *non-linier* baru GCN-GAN untuk mengatasi tugas prediksi tautan temporal yang menantang dari bobot jaringan dinamis. Model yang diusulkan memanfaatkan manfaat dari *graph convolutional network* (GCN), *long short-term memory* (LSTM) serta *generative adversarial network* (GAN).

Zhang et al. (2019) juga mengusulkan arsitektur baru dari *Generative Adversarial Network* (GAN) dengan *Multi-Layer Perceptron* (MLP) sebagai *diskriminasi* dan *Long Short-Term Memory* (LSTM) sebagai *generator* untuk peramalan harga penutupan saham. *Generator* dibangun dengan LSTM untuk menambang distribusi data saham dari data pasar saham yang diberikan dan menghasilkan data dalam distribusi yang sama, sedangkan *diskrimina-*

tor yang dirancang oleh MLP bertujuan untuk membedakan data saham real dan data yang dihasilkan.

Penelitian lain mengenai pengembangan *Multi-Model Generative Adversarial Network Hybrid Prediction Algorithm* (MMGAN-HPA) untuk prediksi harga pasar saham yang dilakukan oleh Polamuri et al. (2021) dan model *Time Series Generative Adversarial Networks* untuk memprediksi penjualan harian obat di rumah sakit yang dilakukan oleh Husein et al. (2019). Pada penerapan dan pengembangan algoritma GAN untuk melakukan prediksi data, dapat dilihat bahwa model berbasis GAN memberikan solusi yang baik untuk analisis data stunting.

Saat ini stunting menjadi permasalahan yang sangat perlu diperhatikan. Indonesia memiliki tingkat prevalensi stunting tinggi. Menurut data Riset Kesehatan Dasar (Riskesdas) tahun 2018 angka prevalensi stunting tercatat 8,7 juta (30,7%) bayi berumur dibawah lima tahun (balita) mengalami stunting (Umiyah and Hamidiyah, 2021). Kendala pelaksanaan penurunan stunting disebabkan belum tersedianya strategi komprehensif. Stunting berhubungan dengan status gizi seorang anak yang stagnan, terkait dengan pola hidup bersih dan sehat, ada pernikahan dini, kondisi geografis dan akses ke layanan kesehatan yang sulit, dan potensi kerawanan pangan. Kerentanan (*vulnerability*) menunjukkan kondisi-kondisi, faktor-faktor atau proses-proses fisik, sosial, ekonomi, dan lingkungan yang meningkatkan kecenderungan (*susceptibility*) sebuah komunitas terhadap dampak bahaya (Mitra, 2015).

Stunting merupakan salah satu kasus malnutrisi kronis yang prevalensinya terus meningkat dari tahun ke tahun di Indonesia (Aulia et al., 2021). Stunting digambarkan status gizi dengan tinggi badan menurut umur yang kurang dari standar pertumbuhan balita normal, yaitu kurang dari -2.0 standar deviasi. Faktor yang mempengaruhi stunting pada balita adalah berat badan lahir < 2.500 gram, MPASI, faktor pendidikan ibu rendah, pendapatan rumah tangga, faktor sanitasi yang tidak baik (Romadoniyah et al., 2022).

Berdasarkan data WHO tahun 2016, di wilayah Asia Tenggara prevalensi balita stunting mencapai 33,8%. Pada tahun 2011, Indonesia berada di peringkat lima dari 81 negara dengan jumlah anak stunting terbesar di dunia yang mencapai 7.547.000 anak. Indonesia dilaporkan memiliki jumlah anak stunting yang lebih besar daripada beberapa negara Afrika, seperti Ethiopia, Republik Demokratik Congo, Kenya, Uganda, dan Sudan. Selama tahun

2007-2011, Indonesia dilaporkan memiliki anak-anak dengan berat badan sedang, berat badan rendah, dan berat badan berlebih yang masing-masing mencapai 13%, 18% dan 14%. Pada tahun 2012, angka kematian anak di bawah lima tahun di Indonesia mencapai 152.000(RI, 2016).

Prevalensi balita stunting di Indonesia masih fluktuatif sejak tahun 2007-2017. Prevalensi balita stunting di Indonesia pada tahun 2007 adalah 36,8%, tahun 2010 sebesar 35,6%, tahun 2013 sebesar 37,2%, dan tahun 2017 sebesar 29,6%.^{2,5} Menurut WHO, prevalensi balita pendek menjadi masalah kesehatan masyarakat jika prevalensinya 20% atau lebih. Karenanya persentase balita pendek di Indonesia masih tinggi dan merupakan masalah kesehatan yang harus ditanggulangi. Dibandingkan beberapa negara tetangga, prevalensi balita pendek di Indonesia juga tertinggi dibandingkan Myanmar (35%), Vietnam (23%), Malaysia (17%), Thailand (16%), dan Singapura (4%) (RI, 2016).

Masyarakat Indonesia sering menganggap tubuh pendek atau tinggi adalah keturunan. Persepsi yang salah di masyarakat perlu mendapat perhatian serius dari masyarakat, pemerintah, dan otoritas terkait. Temuan studi membuktikan bahwa faktor keturunan hanya memberikan kontribusi 15%. Sedangkan yang terbesar adalah faktor yang berkaitan dengan gizi, hormon pertumbuhan dan terjadinya penyakit infeksi berulang. Variabel lain dalam pertumbuhan stunting adalah asap rokok dan polusi udara yang berpengaruh terhadap pertumbuhan stunting. Masalah gizi ini bersifat kronis, dan akan berdampak pada fungsi kognitif yaitu tingkat kecerdasan yang rendah dan berdampak pada kualitas sumber daya manusia. Temuan Riskesdas menunjukkan bahwa kasus stunting relatif stagnan sekitar 36,8% (2007) dan mencapai 37,2% (2013) dari 33 provinsi di Indonesia. Lebih dari setengahnya memiliki tingkat prevalensi lebih dari rata-rata nasional.

Penurunan angka stunting anak merupakan yang pertama dari 6 tujuan dalam Target Gizi Global di tahun 2025 dan indikator utama dalam Tujuan Pembangunan Berkelanjutan kedua dari *Zero Hunger*. Salah satu upaya yang telah dilakukan oleh pemerintah melalui Kementerian Kesehatan (Kemenkes) dalam penanggulangan stunting pada balita adalah dengan Pusat Kesehatan Masyarakat (Puskesmas) dan Pos Pelayanan Terpadu (Posyandu) melalui Gerakan 1000 Hari Pertama Kehidupan (HPK). Beberapa program penanggulangan stunting yang telah dilakukan diantaranya adalah Pemberian Makanan Tambahan (PMT) yang diberikan pada balita dan ibu hamil,

Pemberian Tablet Tambah Darah (TTD) yang diberikan pada remaja putri dan ibu hamil, Peningkatan cakupan imunisasi dasar lengkap dengan sasan bayi dan balita, Pemberian vitamin A pada balita, dan Pemberian zinc pada kasus diare terutama pada ibu hamil dan balita (Saputri, 2019).

Tujuan Pembangunan Berkelanjutan (*Sustainable Development Goal*) 2.2 mengusulkan penghentian stunting pada anak di bawah usia lima tahun pada tahun 2025. Di Meksiko, kemajuan dalam pengurangan stunting telah melambat di abad ke-21. Salah satu tantangan dalam menanggulangi stunting adalah dengan terkonsentrasi di daerah-daerah tertentu, namun belum ada data yang merinci lokasi dan faktor penyebab stunting. Dengan menerapkan estimator Bayesian hierarkis menggunakan data dari survei perwakilan nasional (ENSANUT 2012, dalam bahasa Spanyol) dan sampel Perumahan Nasional dan Sensus Penduduk 2010 dapat menghasilkan perkiraan area kecil pertama terjadinya stunting (Nájera, 2019).

Menurut Aheto and Dagne (2014) angka stunting pada anak di bawah 5 tahun adalah salah satu indikator kesehatan terpenting secara global. Di tingkat nasional, malnutrisi menyumbang sekitar 40% dari kematian balita di Ghana. Pemetaan risiko penyakit memberikan peluang untuk surveilans penyakit dan intervensi yang ditargetkan. Dengan menggunakan data dari Survei Demografi dan Kesehatan Ghana 2014, Aheto and Dagne (2014) bertujuan untuk memperkirakan dan memetakan prevalensi pengerdilan di bawah 5 tahun di Ghana, dengan tujuan mengidentifikasi masyarakat yang berisiko lebih tinggi di mana intervensi dan penelitian lebih lanjut dapat ditargetkan dalam mencegah terjadinya stunting.

Berdasarkan latar belakang di atas maka pada penelitian ini dikembangkan metode *Machine Learning* berbasis *Generative Adversarial Networks* untuk perancangan model prediksi stunting yang dapat digunakan untuk mendekati terjadinya stunting pada suatu wilayah di Indonesia. Data yang digunakan adalah data hasil survei Program Indonesia Sehat dengan Pendekatan Keluarga (PIS-PK) yang ada di Kementerian Kesehatan. Data yang ada di PIS-PK terdiri dari 12 indikator untuk menentukan status keluarga sehat, pra sehat dan tidak sehat. Melihat masalah ini maka dibutuhkan pendekatan yang dapat memprediksi tingkat stunting pada suatu daerah berdasarkan indikator PIS-PK. Penelitian ini berfokus pada penerapan metode *machine learning* berbasis *Generative Adversarial Networks* untuk memprediksi stunting.

1.2 Rumusan Masalah

Berdasarkan latar belakang di atas, maka perlu dirumuskan masalah-masalah penelitian yang harus dicari solusinya, yaitu:

1. Bagaimana membangun model prediksi terjadinya stunting pada suatu wilayah berbasis *Generative Adversarial Networks*?
2. Bagaimana mengembangkan metode *machine learning* berbasis *Generative Adversarial Networks* dalam melakukan prediksi terjadinya stunting pada suatu wilayah di Indonesia?

1.3 Batasan Masalah

Batasan masalah pada penelitian ini yaitu:

- Data yang digunakan berupa data teks yang berasal dari data survey Program Indonesia Sehat - Pendekatan Keluarga (PIS-PK).
- Rentang waktu data yang digunakan mulai dari tahun 2020-2021.
- Data stunting yang digunakan berasal dari Kementerian Kesehatan (Kemenkes).

1.4 Tujuan Penelitian

Tujuan dari penelitian ini adalah:

1. Membangun model prediksi terjadinya stunting pada suatu wilayah di Indonesia berbasis *Generative Adversarial Networks*.
2. Mengembangkan metode *machine learning* berbasis *Generative Adversarial Networks* dalam melakukan prediksi terjadinya stunting pada suatu wilayah di Indonesia.

1.5 Kontribusi Penelitian

Penelitian ini memberikan kontribusi ilmiah sebagai berikut:

1. Menghasilkan pengembangan model prediksi terjadinya stunting pada suatu wilayah di Indonesia berbasis *Generative Adversarial Networks*.
2. Menghasilkan metode *machine learning* berbasis *Generative Adversarial Networks* dalam melakukan prediksi terjadinya stunting pada suatu wilayah di Indonesia.

Selain kontribusi ilmiah penelitian ini juga memberikan kontribusi praktis bagi Kementerian Kesehatan Republik Indonesia sebagai berikut:

1. Perangkat lunak yang dihasilkan dapat dimanfaatkan Kementerian Kesehatan dalam mencegah terjadinya stunting pada suatu wilayah di Indonesia.

Bab 2

Telaah Pustaka

2.1 *Artificial Intelligence (AI)*

Artificial Intelligence (AI) merupakan sumber daya baru sebagai representasi dari pengetahuan yang berhubungan erat dengan teknologi berbasis komputer dan menekankan pada kemampuan komputer untuk meniru manusia dalam melakukan pembelajaran dan mengatasi masalah (Ng, 2016). Pada *Artificial Intelligence*, manusia cukup menginformasikan kepada komputer permasalahan yang sedang terjadi dengan melakukan rekayasa dan representasi simbol selanjutnya komputer ditanamkan kemampuan inferensi. Hal ini berbeda dengan komputer konvensional dimana manusia harus memerintahkan komputer untuk menyelesaikan permasalahan yang terjadi dengan suatu algoritma selanjutnya komputer dan program akan diberikan data (Heryadi and Irwansyah, 2020).

Pada (Russell and Norvig, 1995) mengelompokkan definisi AI ke dalam 4 kategori, yang salah satunya adalah *acting rationally: the rational agent approach*. Artinya membuat inferensi yang logis merupakan bagian dari suatu *rational agent*. Hal ini disebabkan satu-satunya cara untuk melakukan aksi secara rasional adalah dengan menalar secara logis. Dengan melihat secara logis, maka bisa dapat disimpulkan bahwa aksi yang diberikan akan mencapai tujuan atau tidak. Jika mencapai tujuan, maka *agent* dapat melakukan aksi berdasarkan kesimpulan tersebut.

Ahmad (2017) menyatakan ada beberapa teknologi yang mengadopsi dasar AI dan sangat erat kaitannya dengan pemanfaatan teknologi berbasis komputerisasi dan mesin serta terdapat tiga metode yang dikembangkan

dari teknik AI yaitu:

- **Fuzzy Logic (FL)** adalah suatu teknik yang digunakan dalam mengatasi pemberian keputusan yang tidak pasti 0 atau 1 (Ahmad, 2017). Teknik ini diterapkan salah satunya pada alat penghisap debu (Robandi, 2021).
- **Evolutionary Computing (EC)** adalah metode dengan menerapkan skema evolusi yang melibatkan banyak individu yang diuji untuk dilakukan seleksi terbaik dalam membangkitkan generasi berikutnya. Algoritma genetika merupakan salah satu contoh implementasi dari metode ini (Ahmad, 2017).
- **Machine Learning (ML)** adalah suatu pendekatan yang digunakan untuk menirukan perilaku manusia yang memiliki ciri adanya proses pembelajaran dan pelatihan. Klasifikasi dan prediksi merupakan aplikasi utama dari ML. Beberapa metode ML yang banyak digunakan diantaranya *Decision Support System* (DSS), *Support Vector Machine* (SVM) dan *Neural Network* (NN) (Ahmad, 2017).

2.2 **Machine Learning (ML)**

Menurut (Samuel, 1959), *Machine learning* atau disebut pembelajaran mesin merupakan bidang studi komputer yang memberikan kemampuan kepada mesin komputer untuk belajar tanpa harus secara eksplisit. Terdapat beberapa kategori dari *machine learning*, yaitu:

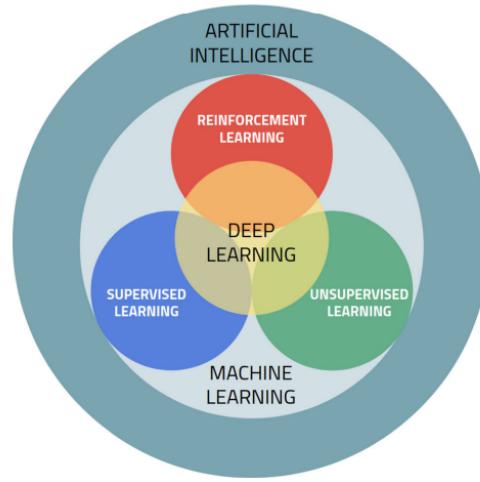
- Berdasarkan bagaimana cara pelatihan dengan menggunakan supervisi (pelabelan) dari manusia atau tanpa supervisi manusia. Terdiri dari empat kategori yaitu *supervised*, *unsupervised*, *semisupervised*, dan *reinforcement learning*.
- Berdasarkan bagaimana cara pembelajaran. Terdiri dari dua kategori , yaitu: *online learning* dan *batch learning*.
- Berdasarkan bagaimana cara perbandingan data. Terdiri dari dua kategori, yaitu: *instance based* dan *model-based learning*.

Umumnya machine learning dikategorikan berdasarkan jenis pelatihan yaitu berdasarkan pelabelan supervisi manusia atau tanpa supervisi manusia.

1. **Supervised Learning**, pada metode ini data yang di input ke dalam suatu algoritma mencakup kategori yang diinginkan atau sering disebut diberikan pelabelan. Metode klasifikasi umumnya menggunakan jenis pelatihan supervisi atau memprediksi nilai dari sebuah angka. Sebagai contoh adalah penentuan harga mobil berdasarkan fitur dari mobil tersebut misalnya jarak tempuh, umur, merk, dan lainnya yang dikenal dengan *predictors*. Beberapa algoritma yang menggunakan *supervised learning* adalah *K-Nearest Neighbors*, *Linear Regression*, *Logistic Regression*, *Support Vector Machines (SVMs)*, *Decision Trees and Random Forests*, dan *Neural networks*.
2. **Unsupervised Learning**, pada metode ini data yang akan diinput ke dalam suatu algoritma tidak melalui kategorisasi atau pelabelan dari manusia, karena seluruh kategorisasi akan dilakukan berdasarkan data yang dimasukan dan akan terbentuk berdasarkan ciri yang bersesuaian. Terdapat beberapa algoritma unsupervised learning di antaranya:
 - (a) *Clustering*, seperti: *k-Means*, *Hierarchical Cluster Analysis (HCA)* dan *Expectation Maximization*
 - (b) *Association rule learning*, seperti: *Apriori* dan *Eclat*
 - (c) Reduksi Dimensi dan Visualisasi, seperti: *Principal Component Analysis (PCA)* , *Kernel PCA* , *Locally-Linear Embedding (LLE)* dan *t-distributed Stochastic Neighbor Embedding (t-SNE)*.
3. **Semisupervised Learning**, pada metode ini jenis pelatihan yang digunakan adalah gabungan metode *supervised* dan *unsupervised learning*, sehingga terdapat data yang telah diketahui kategorisasi atau dilabelkan, dan data yang belum dilabelkan. Salah satu algoritma yang menggunakan metode ini adalah *Deep Belief Networks (DBNs)* dengan komponen yang dikenal dengan *Restricted Boltzmann Machines (RBMs)*. Metode RBM akan dilatih menggunakan data *unsupervised*, kemudian sistem tersebut akan dioptimalisasi menggunakan teknik *supervised*.
4. **Reinforcement Learning**, pada metode ini dikenal istilah *agent* yang harus mempertimbangkan lingkungan dalam sistem pembelajaran. Sistem akan memilih, melakukan tindakan dan mengukur akibat (*rewards*) agar terhindar akibat yang negatif (*penalties*), sehingga diperlukan

suatu strategi yang dikenal dengan *policy* untuk mendapatkan dampak yang positif.

Berdasarkan penjelasan diatas bahwa *machine learning* terbagi menjadi tiga kategori; *Supervised Learning*, *Unsupervised Learning*, *Reinforcement Learning* berkaitan dengan *artificial intelligence* (Karthikeyan and Priyakumar, 2022), berikut dijelaskan dalam Gambar 2.1



Gambar 2.1: Skema *Artifical Intelligence* dan *Machine Learning* (Karthikeyan and Priyakumar, 2022)

Sumber:

2.2.1 *Supervised Learning*

Supervised learning adalah membangkitkan suatu fungsi yang memetakan input (dengan sejumlah atribut) ke output (label kelas) berdasarkan data ber-label yang diberikan. Kualitas hasil pembelajaran sangat bergantung pada validasi label pada data latih. *Supervised* digunakan untuk meyelesaikan masalah klasifikasi maupun regresi. Beberapa model yang termasuk dalam *supervised* adalah: *deep neural network* (DNN), *convolutional neural network* (CNN), *recurrent neural network* (RNN) dan lainnya sebagainya (Suyanto et al., 2019).

Supervised learning adalah proses belajar yang membutuhkan guru. Yang dimaksud guru di sini adalah sesuatu yang memiliki pengetahuan tentang lingkungan. Guru bisa direpresentasikan sebagai sekumpulan sampel-sampel input-output. Pembangunan pengetahuan dilakukan oleh guru dengan memberikan respon yang diinginkan kepada *supervised*. Respon yang

diinginkan tersebut mempresentasikan aksi optimum yang dilakukan oleh *supervised*. Parameter-parameter jaringan berubah-ubah berdasarkan vektor latih dan sinyal kesalahan (sinyal kesalahan adalah perbedaan antara keluaran supervised dan respon yang diinginkan). Proses perubahan ini dilakukan secara berulang-ulang, selangkah demi selangkah, dengan tujuan agar *supervised* bisa memiliki kemampuan yang mirip dengan gurunya. Dengan kata lain *supervised* dilatih untuk dapat memetakan sekumpulan sampel input-output dengan akurasi yang tinggi (Suyanto et al., 2019).

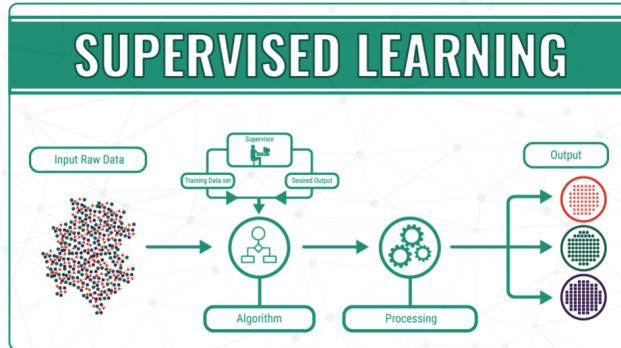
Sebagian besar praktik *machine learning* mengandalkan algoritma *supervised learning*. Algoritmanya dinamakan seperti ini karena *training dataset* (sekumpulan data untuk training) akan memandu dan mengajari komputer agar menghasilkan *outcome* sesuai harapan. Metode semacam ini mirip dengan seorang guru sedang mengajari anak-anak berhitung (Primartha, 2018).

Supervised learning menggunakan training data yang sudah diberi label untuk mempelari *mapping function*, dari *input* variabel (x) ke *output* variabel (y).

$$y = f(x) \quad (2.1)$$

Beberapa algoritma yang termasuk dalam *supervised* antara lain:

- *Decision tree*
- *Naïve Bayes Classifier*
- *Artificial neural networks*
- *Linear Regression*



Gambar 2.2: Ilustrasi *supervised learning*
Sumber:

2.2.2 *Unsupervised Learning*

Unsupervised learning adalah memodelkan sekumpulan input secara otomatis tanpa ada panduan (berupa output yang diinginkan). Artinya data-data yang dipelajari hanya berupa input tanpa label kelas. *Unsupervised* biasanya digunakan untuk masalah klasterisasi: diberikan sebuah himpunan data masukan, kelompokkan data tersebut ke dalam sejumlah klaster berdasarkan kriteria tertentu. Misalnya tingkat kemiripan dalam suatu kelas (Suyanto et al., 2019).

Unsupevised learning adalah proses belajar yang tidak membutuhkan guru untuk memantau pross belajar. Dengan kata lain, tidak ada sekumpulan sampel input-output atau fungsi tertentu untuk dipelajari oleh jaringan (Suyanto et al., 2019).

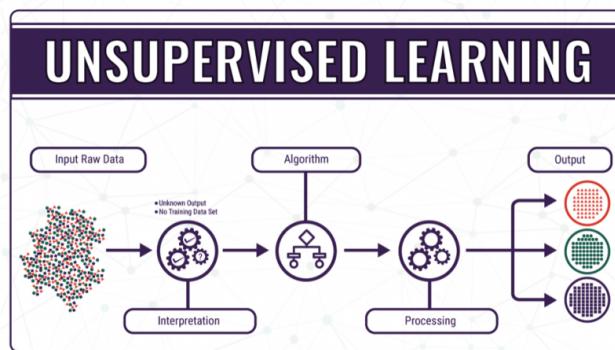
Pada *unsupervised learning* persoalan diproses hanya mengandalkan data yang belum dilatih sebelumnya. *Unsupervised* menggunakan *unlabeled training dataset* untuk memodelkan struktur dari data. Sehingga *unsupervised learning* bersifat lebih subjektif dibandingkan *supervised learning* (Primartha, 2018).

Unsupervised learning bermanfaat untuk kasus-kasus dimana kita ingin menemukan relasi implisit dari *unlabeled* dataset yang disediakan. Jadi pada *unsupervised learning* kita tidak memprediksi masa depan. Sebab input variabel (X) tidak memiliki relasi dengan output variabel (Y).

$$f(X) \quad (2.2)$$

Beberapa algoritma yang termasuk dalam unsupervised antara lain:

- *K-Means, Hierarchical Clustering*
- *Fuzzy C-Means*
- *Density-Based Spatial Clustering of Applications with Noise* (DBSCAN)
- *Self-Organizing Map*



Gambar 2.3: Ilustrasi *unsupervised learning*
Sumber:

2.2.3 Reinforcement Learning

Reinforcement learning (RL) adalah suatu metode *learning* yang dipengaruhi oleh *feedback* dari lingkungan dengan teknik *learning* yang *iterative* (berulang-ulang) dan *adaptive* (menyesuaikan). *Reinforcement learning* dipercaya mendekati cara manusia belajar (Primartha, 2018).

Reinforcement learning adalah mempelajari suatu kebijakan bagaimana melakukan aksi berdasarkan hasil pengamatan terhadap lingkungan yang ada. Setiap aksi menghasilkan akibat bagi lingkungan tersebut, dan lingkungan memberikan umpan balik untuk memandu *reinforcement learning* (Suyanto et al., 2019).

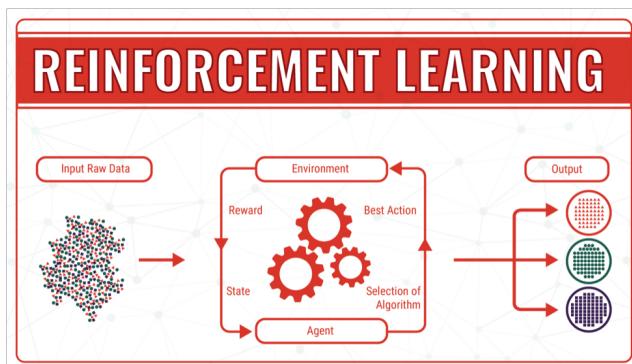
Reinforcement learning diinspirasi oleh kebiasaan makhluk hidup dalam belajar dan bertindak, khususnya manusia. Pada *Reinforcement learning* tidak ada *training dataset*. Data-data yang diperoleh berdasarkan pengalaman. Algoritma *Reinforcement learning* mengijinkan *agent* untuk memutuskan aksi selanjutnya berdasarkan kondisi saat ini. Representasi *Reinforcement*

learning mirip dengan *supervised learning*. Yang membedakan adalah pada *Reinforcement learning* inputnya tidak hanya x , namun x dan y .

$$y = f(x) \text{ given } z \quad (2.3)$$

Algoritma *Reinforcement learning* tidak memiliki tujuan eksplisit, sebagaimana gantinya algoritma dipaksa untuk belajar menemukan nilai optimal melalui kegiatan *trial* dan *error*. Salah satu contoh penerapan *Reinforcement learning* adalah pada bidang *robotic*. Beberapa algoritma yang dikelompokkan dalam *Reinforcement learning* antara lain:

- Genetic Algorith (GA)
- Dynamic Programming (DP)
- Generalized Policy Iteration (GPI)
- Monte Carlo



Gambar 2.4: Ilustrasi Reinforcement learning

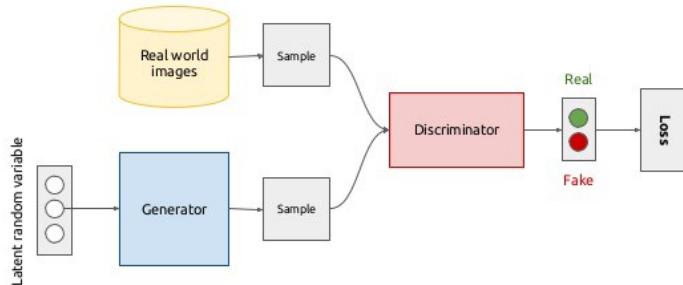
Sumber:

2.3 Generative Adversarial Networks (GANs)

Generative Adversarial Networks (GAN's) diperkenalkan pertama kali oleh Ian J. Goodfellow bersama tujuh orang lainnya pada tahun 2014 melalui Jurnal mereka yang berjudul Generative Adversarial Nets (Goodfellow et al., 2014). Penggunaan Generative Adversarial Networks (GAN's) sangat berbeda dengan Algoritma Deep Learning lainnya, dimana Algoritma lainnya memanfaatkan penuh terhadap dataset yang ada dimana dataset tersebut

dilatih untuk memaksimalkan hasil akurasi dari setiap pengujian yang dilakukan, semakin banyak dataset yang dimiliki maka semakin baik hasil yang didapatkan. Generative Adversarial Networks (GAN's) memiliki pendekatan yang berbeda dengan dengan algoritma lainnya, algoritma ini menggunakan dua jaringan syaraf buatan (neural network) untuk menyelesaikan permasalahan yang ada. Kedua jaringan syaraf buatan tersebut adalah Generator yang berfungsi untuk mengambil sampel data dari dataset, dan Diskriminator yang berfungsi untuk mengklasifikasikan bahwa sampel data itu bernilai asli atau palsu (Volkhonskiy et al., 2016), (Metz et al., 2016), (Goodfellow et al., 2014). Dengan adanya kedua neural network tersebut, maka akan dihasilkan suatu data yang baru yang sangat menyerupai data inputannya.

Generative adversarial networks (conceptual)



5

Gambar 2.5: Konsep Generative Adversarial Networks (GANs)
Sumber:

Struktur Generative Adversarial Networks (GANs) yang terdapat pada 2.5 menunjukkan bahwa fungsi dipisahkan menjadi Generator dan Diskriminasi. Untuk mempermudah penjelasan disini Generator diinisialisasikan dengan fungsi G dan Diskriminasi dengan fungsi D , dengan X sebagai data asli yang ada di dalam Dataset, terakhir terdapat Z sebagai variabel acak. Setiap hasil dari G akan diwakili $G(z)$ sebagai sampel baru hasil dari Generator. Data X akan dimasukkan ke dalam Diskriminasi D untuk memberikan label terhadap $G(z)$. jika Diskriminasi D menghasilkan label 1(True) berarti $G(z)$ dianggap mirip dengan X . Jika Diskriminasi D menghasilkan label 0(False) berarti $G(z)$ dianggap tidak mirip dengan X . Untuk hasil dari Generator G sangat baik, Diskriminasi D harus mengklasifikasikan $G(z)$ dengan label 0.

tujuan G adalah untuk membuat kinerja data yang dihasilkan $G(z)$ pada D ($D(G(z))$) konsisten dengan kinerja Real Samples X pada D .

2.4 *Deep Learning*

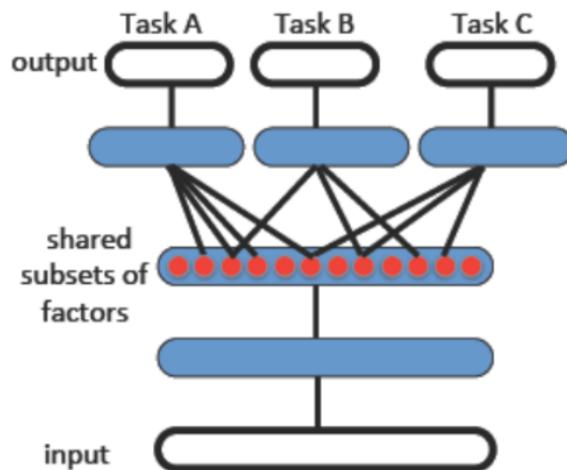
Deep Learning telah muncul sebagai area baru penelitian mesin sejak tahun 2006 (Hinton et al. (2006); Bengio (2009); Arel et al. (2010)). *Deep Learning* (atau terkadang disebut *feature learning*) adalah seperangkat algoritma pembelajaran mesin yang mencoba mempelajari model masukan berlapis ganda (*multi layer*), umumnya jaringan syaraf tiruan. *Deep Neural Network* terdiri dari beberapa tingkatan operasi non linier. Sebelum tahun 2006, mencari ruang parameter arsitektur dalam adalah tugas yang tidak penting, tapi baru-baru ini algoritma *deep learning* telah diusulkan untuk menyelesaikan masalah dengan sukses (Bengio, 2009).

Deep learning muncul sebagai area baru penelitian pembelajaran mesin dengan mencoba meniru otak manusia, yang mampu melakukan pengolahan dan pembelajaran dari data masukan yang kompleks dan pemecahannya untuk bermacam tugas rumit dengan baik. *Deep learning* telah berhasil diaplikasikan ke beberapa bidang seperti gambar, suara, teks dan gerak. Teknik yang dikembangkan dari penelitian *deep learning* telah berdampak pada penelitian proses bahasa alami atau *Natural Language Processing* yang dikenal dengan NLP (Du and Shanker, 2009).

Keuntungan lain dari *deep learning* adalah *transfer learning*. *Transfer learning* adalah kemampuan pembelajaran algoritma untuk mengeksplorasi kesamaan antara tugas belajar yang berbeda agar bisa dibagi ke dalam kekuatan statistik, dan transfer pengetahuan tugas yang berbeda. Fitur algoritma pembelajaran memiliki sebuah keuntungan untuk sebuah tugas karena mereka belajar fitur yang menangkap faktor yang mendasari, subset dari fitur yang mungkin relevan untuk tugas tertentu, seperti yang diilustrasikan pada Gambar 2.6. Hipotesis ini nampaknya dikonfirmasi oleh sejumlah hasil empiris yang menunjukkan kelebihan *feature learning* atau algoritma *deep learning* dalam domain adaptasi dan multi task (Bengio, 2009).

Gambar 2.6 adalah ilustrasi model *feature learning* yang menemukan faktor penjelas (lapisan tersembunyi di tengah warna merah). Fitur bersama dipelajari tanpa pengawasan atau dengan pengawasan, karena himpunan

bagian ini tumpang tindih, pembagian kekuatan statistik memungkinkan keuntungan dalam generalisasi.



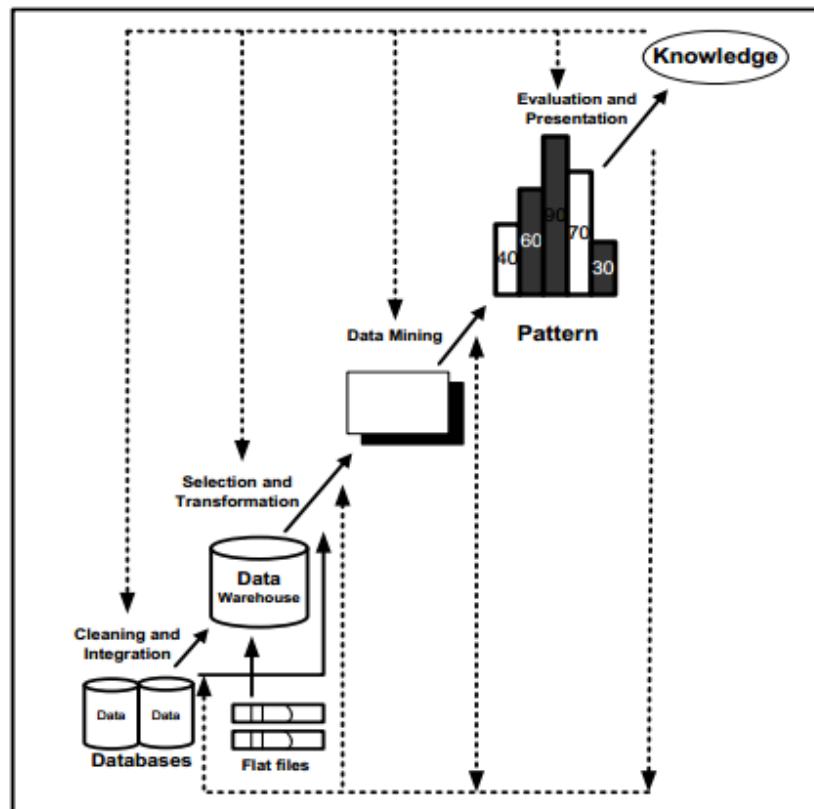
Gambar 2.6: Ilustrasi Model *Feature Learning*
Sumber:

2.5 Data Mining

Data mining adalah kegiatan menemukan pola yang menarik dari data dalam jumlah besar, data dapat disimpan dalam *database*, *data warehouse*, atau penyimpanan informasi lainnya. Data mining berkaitan dengan bidang ilmu-ilmu lain, seperti *database system*, *data warehousing*, statistik, *machine learning*, *information retrieval*, dan komputasi tingkat tinggi. Selain itu, *data mining* didukung oleh ilmu lain seperti *neural network*, pengenalan pola, *spatial data analysis*, *image database*, *signal processing* (Han and Kamber, 2006). Data mining didefinisikan sebagai proses menemukan pola-pola dalam data, proses ini otomatis atau seringnya semiotomatis, pola yang ditemukan harus penuh arti dan pola tersebut memberikan keuntungan, biasanya keuntungan secara ekonomi serta data yang dibutuhkan dalam jumlah besar (Witten et al., 2005). Karakteristik data mining yaitu data mining berhubungan dengan penemuan sesuatu yang tersembunyi dan pola data tertentu yang tidak diketahui sebelumnya. Data mining biasa menggunakan data yang sangat besar dan biasanya data yang besar digunakan untuk membuat hasil lebih dipercaya serta data mining berguna untuk membuat keputusan yang kritis terutama dalam strategi (Glick et al., 2004).

2.5.1 Tahap-Tahap Data mining

Sebagai suatu rangkaian proses, data mining dapat dibagi menjadi beberapa tahap yang diilustrasikan di Gambar 2.7. Tahap-tahap tersebut bersifat interaktif, pemakai terlibat langsung atau dengan perantaraan *knowledge base*.



Gambar 2.7: Tahap-tahap Data Mining (Han and Kamber, 2006)

Tahap-tahap data mining (Han and Kamber, 2006) ada 7 yaitu:

1. **Pembersihan data (data cleaning).** Pembersihan data merupakan proses menghilangkan noise dan data yang tidak konsisten atau data tidak relevan. Pada umumnya data yang diperoleh, baik dari database suatu perusahaan maupun hasil eksperimen, memiliki isian-isian yang tidak sempurna seperti data yang hilang, data yang tidak valid atau juga hanya sekedar salah ketik. Selain itu, ada juga atribut-atribut data yang tidak relevan dengan hipotesa data mining yang dimiliki. Data-data yang tidak relevan itu juga lebih baik dibuang. Pembersihan data

juga akan mempengaruhi performasi dari teknik data mining karena data yang ditangani akan berkurang jumlah dan kompleksitasnya.

2. **Integrasi data (*data integration*)**. Integrasi data merupakan penggabungan data dari berbagai database ke dalam satu database baru. Tidak jarang data yang diperlukan untuk data mining tidak hanya berasal dari satu database tetapi juga berasal dari beberapa database atau file teks. Integrasi data dilakukan pada atribut-atribut yang mengidentifikasi entitas-entitas yang unik seperti atribut nama, jenis produk, nomor pelanggan dan lainnya. Integrasi data perlu dilakukan secara cermat karena kesalahan pada integrasi data bisa menghasilkan hasil yang menyimpang dan bahkan menyesatkan pengambilan aksi nantinya. Sebagai contoh bila integrasi data berdasarkan jenis produk ternyata menggabungkan produk dari kategori yang berbeda maka akan didapatkan korelasi antar produk yang sebenarnya tidak ada.
3. **Seleksi data (*data selection*)**. Data yang ada pada database sering kali tidak semuanya dipakai, oleh karena itu hanya data yang sesuai untuk dianalisis yang akan diambil dari database. Sebagai contoh, sebuah kasus yang meneliti faktor kecenderungan orang membeli dalam kasus market basket analysis, tidak perlu mengambil nama pelanggan, cukup dengan id pelanggan saja.
4. **Transformasi data (*data transformation*)**. Data diubah atau digabung ke dalam format yang sesuai untuk diproses dalam data mining. Beberapa metode data mining membutuhkan format data yang khusus sebelum bisa diaplikasikan. Sebagai contoh beberapa metode standar seperti analisis asosiasi dan clustering hanya bisa menerima input data kategorikal. Karenanya data berupa angka numerik yang berlanjut perlu dibagi-bagi menjadi beberapa interval. Proses ini sering disebut transformasi data.
5. **Proses mining**, merupakan suatu proses utama saat metode diterapkan untuk menemukan pengetahuan berharga dan tersembunyi dari data.
6. **Evaluasi pola (*pattern evaluation*)**, untuk mengidentifikasi pola-pola menarik kedalam knowledge based yang ditemukan. Dalam tahap ini

hasil dari teknik data mining berupa pola-pola yang khas maupun model prediksi dievaluasi untuk menilai apakah hipotesa yang ada memang tercapai. Bila ternyata hasil yang diperoleh tidak sesuai hipotesa ada beberapa alternatif yang dapat diambil seperti menjadikannya umpan balik untuk memperbaiki proses data mining, mencoba metode data mining lain yang lebih sesuai, atau menerima hasil ini sebagai suatu hasil yang di luar dugaan yang mungkin bermanfaat.

7. **Presentasi pengetahuan (*knowledge presentation*)**, merupakan visualisasi dan penyajian pengetahuan mengenai metode yang digunakan untuk memperoleh pengetahuan yang diperoleh pengguna. Tahap terakhir dari proses data mining adalah bagaimana memformulasikan keputusan atau aksi dari hasil analisis yang didapat. Ada kalanya hal ini harus melibatkan orang-orang yang tidak memahami data mining. Karenanya presentasi hasil data mining dalam bentuk pengetahuan yang bisa dipahami semua orang adalah satu tahapan yang diperlukan dalam proses data mining. Dalam presentasi ini, visualisasi juga bisa membantu mengkomunikasikan hasil data mining

2.6 *Natural Language Processing (NLP)*

Natural Language Processing (NLP) adalah penerapan ilmu komputer, untuk mengkaji interaksi antara komputer dengan bahasa (alami) manusia. NLP berupaya memecahkan masalah untuk memahami bahasa alami manusia dan mengubah bahasa tersebut menjadi representasi formal yang dapat dimengerti dan diproses oleh komputer (Pustejovsky and Stubbs, 2012). Terdapat tujuh tingkatan dalam *Natural Language Processing* dalam melakukan analisis dan pemaknaan suatu input bahasa natural (Liddy and Liddy, 2001), yaitu:

- **Phonology**, berkaitan dengan interpretasi bunyi pada speech dalam suatu kata.
- **Morphology**, berkaitan dengan interpretasi makna dari suatu kata (berhubungan dengan prefiks dan suffiks).
- **Lexical**, berkaitan dengan interpretasi makna dari masing-masing kata yang dianalisis secara individual.

- **Syntactic**, berkaitan dengan analisis kata dalam sebuah kalimat dengan tujuan untuk menemukan struktur gramatikal.
- **Semantic**, berkaitan dengan interpretasi makna kata yang terbentuk akibat interaksi makna dalam kata pada suatu kalimat.
- **Discourse**, berkaitan dengan analisis makna sebuah teks yang terdiri dari beberapa kalimat.
- **Pragmatic**, berkaitan dengan analisis pada pemilihan penggunaan kata menggunakan konteks yang ada dalam teks.

NLP menyediakan teori dan implementasi untuk diaplikasikan dalam berbagai bidang. Faktanya segala bidang yang berhubungan dengan pengolahan teks merupakan kandidat untuk NLP. Beberapa bidang pengaplikasian yang memanfaatkan NLP diantaranya adalah *Information Retrieval*, *Information Extraction*, *Question Answering*, *Summarization*, *Machine Translation*, *Sentiment Analysis* dan *Dialogue System* (Liddy and Liddy, 2001).

2.6.1 *Text Mining*

Text Analytics atau yang dikenal dengan istilah *Text Mining* merupakan teknologi *Artificial Intelligence* (AI) yang melakukan ekstraksi pola yang menghasilkan informasi dan pengetahuan yang berguna yang berasal dari sumber data. Penambangan teks memiliki tujuan dan menggunakan proses yang sama dengan penambangan data, namun memiliki masukan yang berbeda. Masukan untuk penambangan teks yaitu berupa data yang tidak terstruktur maupun data terstruktur (Feldman et al., 2007).

Dua tahap penerapan struktur data teks yakni diawali dengan menerapkan struktur terhadap sumber data yang berupa teks selanjutnya dilakukan ekstraksi dari informasi dan *knowledge* yang relevan dari data teks terstruktur dengan menggunakan metode dan teknik yang sama dengan penambangan data. *Feature selection* dan *text preprocessing* merupakan tahapan-tahapan secara umum yang digunakan pada *text mining* (Feldman et al., 2007).

Adrifina, Putri, and Wicaksana, (2008) memanfaatkan *text mining* dalam pemilihan jenis berita secara otomatis menggunakan pendekatan kata kunci. Pada proses *text mining* database vektor mempengaruhi tingkat akurasi.

Text mining bermanfaat dalam memudahkan pencarian data dan dapat dimanfaatkan dalam peringkasan teks berita secara otomatis, sehingga waktu yang digunakan dalam membaca berita lebih singkat (Maryana, Kurniawati dan Agusten, 2018).

2.6.2 Pra-Proses Teks (*Text Preprocessing*)

Text preprocessing merupakan tahapan untuk mempersiapkan teks sebelum dijadikan data sebagai masukan yang akan diproses pada tahap selanjutnya. Hasil pengolahan *text preprocessing* dapat dieksplorasi lebih lanjut untuk analisis sentimen (Ariestya, Astuti, dan Wiryana, 2018). Beberapa tahapan *text preprocessing* yang umum digunakan adalah:

1. **Tahap *Case Folding***; yakni tahapan yang digunakan untuk mengubah semua huruf kapital menjadi huruf kecil dan untuk menghilangkan karakter atau tanda baca tertentu (Ariestya et al., 2018).
2. **Tahap *Tokenizing***; merupakan tahapan dimana kalimat dipotong berdasarkan kata penyusun (Ariestya et al., 2018).
3. **Tahap *Stopword Removal***; adalah suatu proses untuk menghilangkan kata-kata yang tidak deskriptif. *Stoplist* (kata-kata yang berada dalam daftar *stopwords* yang akan dihapus) harus dibuat sebelum melakukan tahap ini. Pustaka sastrawi merupakan daftar *stoplist* bahasa Indonesia yang dapat digunakan pada tahap *stopwords* (Rosid, Fitran, Astutik, Mulloh dan Gozali, 2020). Beberapa contoh kata *stoplist* pada pustaka sastrawi yakni; 'mereka', 'sudah', 'saya', 'terhadap', 'secara', 'agar', 'lain', 'anda', 'begitu', 'mengapa', 'kenapa', 'yaitu', 'yakni', 'daripada', 'itulah', 'lagi', 'maka', 'tentang', 'demi', 'dimana'. Tingkat akurasi terbukti meningkat dengan memanfaatkan tahap *stopword removal* (Darujati and Gumelar, 2012).
4. **Tahap *Stemming***; Mencari akar kata atau kata dasar dengan cara menghilangkan imbuhan (*prefix/suffix*) merupakan tujuan dari proses tahap *stemming*. Algoritma Nazief dan Adriani merupakan salah satu algoritma yang umum digunakan dalam tahap ini untuk teks berbahasa Indonesia (Cendana and Permana, 2019). Teknik *stemming* diperbaiki

menggunakan incorbiz pada kalimat non formal berbahasa Indonesia (Rianto, Mutiara, Wibowo, dan Santosa, 2021). Hasil yang diperoleh menunjukkan tingkat kesalahan lebih kecil sehingga akurasi yang dihasilkan dalam prediksi sangat baik (Rianto et al., 2020).

2.6.3 Clustering

Menurut **Tan (2006)**, clustering adalah proses pembagian satu himpunan objek dapat ke dalam bagian yang disebut dengan cluster, yang memiliki karakteristik yang sama antar satu objek dengan objek lainnya dan berbeda dengan cluster yang lain. Partisi dilakukan secara otomatis dengan algoritma clustering, sehingga metode ini bermanfaat untuk menemukan kelompok yang tidak dikenal. Dalam clustering dikenal empat tipe data, yaitu:

1. Variabel berskala interval
2. Variabel biner
3. Variabel nominal, ordinal, dan rasio
4. Variabel dengan tipe lainnya

Syarat menggunakan clustering menurut **Han dan Kamer (2012)** adalah mampu menangani data dalam jumlah besar, algoritma klasterisasi dapat diimplementasikan pada berbagai macam bentuk data, menemukan cluster yang tidak terduga, mampu menangani data yang rusak, sensitifitas pada perubahan input, dan hasilnya dapat diimplementasikan dan berguna.

2.6.4 K-Means

Dalam machine-learning dan K-Means merupakan metode analisis kelompok yang mengarah pada pembagian N obyek pengamatan ke dalam K kelompok (cluster), dimana setiap obyek dimiliki oleh sebuah kelompok dengan mean (rata-rata) dan metode ini mencoba untuk menemukan pusat dari kelompok (*centroid*) dalam data sebanyak iterasi perbaikan yang dilakukan. Metode ini berusaha membagi data kedalam kelompok sehingga data yang berkarakteristik sama dimasukkan ke dalam satu kelompok sementara data yang berkarakteristik berbeda dimasukkan dalam kelompok yang lain. Adapun tujuan dari clustering/pengelompokan data ini adalah meminimalkan fungsi

obyektif yang diset dalam proses pengelompokan, yang pada umumnya berusaha meminimalkan variasi didalam suatu kelompok dan memaksimalkan variasi antar kelompok. Clustering menggunakan metode K-Means secara umum dilakukan dengan algoritma sebagai berikut:

1. Tentukan jumlah cluster
2. Alokasikan data ke dalam kelompok secara acak
3. Hitung pusat cluster (*centroid*) menggunakan mean utk masing-masing kelompok
4. Alokasikan masing-masing data ke centroid terdekat
5. Kembali ke langkah 3, jika masih ada data yang berpindah cluster atau jika nilai centroid diatas nilai ambang, atau jika nilai pada fungsi obyektif yang digunakan masih diatas ambang.

2.7 Prediksi

Prediksi numerik adalah langkah yang dilakukan dalam memprediksi nilai yang kontinyu (atau berurutan) untuk nilai yang diberikan. Menurut Han and Kamber (2006) sejauh ini pendekatan yang paling banyak digunakan untuk prediksi numerik (yang kemudian disebut dengan prediksi saja) adalah regresi, sebuah metodologi statistik yang dikembangkan oleh Sir Frances Galton, seorang ahli matematika yang juga merupakan sepupu dari Charles Darwin. Pada kenyataannya, banyak tulisan yang menggunakan istilah “regresi” dan “prediksi numerik” sebagai sinonim. Namun, seperti yang sudah diketahui bahwa beberapa teknik klasifikasi (seperti *backpropagation*, *support vector machines*, dan *knearest-neighbour classifier*) dapat diadaptasi untuk prediksi. Maka untuk lebih jelasnya, dalam bahasan kali ini digunakan teknik regresi sebagai sarana prediksi.

Analisis regresi dapat digunakan untuk memodelkan hubungan antara satu atau lebih variabel independen atau prediktor dan sebuah variabel dependen atau respon (yang bernilai kontinyu). Dalam konteks *data mining*, variabel prediktor adalah atribut yang berkepentingan mendeskripsikan basis data (yakni yang menyusun vektor atribut). Secara umum, nilai dari variabel prediktor adalah diketahui. Variabel respon adalah apa yang akan

diprediksikan. Ketika diberikan sebuah baris data yang dideskripsikan oleh variabel prediktor, maka akan diprediksikan nilai yang bersesuaian dengan variabel respon.

Analisis regresi adalah pilihan yang bagus manakala semua nilai dari variabel prediktor bernilai kontinyu juga. Banyak permasalahan dapat dipecahkan oleh Regresi Linier, dan akan lebih banyak lagi dapat dikerjakan dengan mengaplikasikan transformasi kepada variabel-variabel yang bersesuaian sehingga masalah non-linier dapat diubah menjadi masalah linier.

2.8 Situasi Balita Pendek (*Stunting*)

Kejadian balita pendek atau biasa disebut dengan stunting merupakan salah satu masalah gizi yang dialami oleh balita di dunia saat ini. Stunting (kerdil) adalah kondisi dimana balita memiliki panjang atau tinggi badan yang kurang jika dibandingkan dengan umur. Kondisi ini diukur dengan panjang atau tinggi badan yang lebih dari minus dua standar deviasi median standar pertumbuhan anak dari WHO. Balita stunting termasuk masalah gizi kronik yang disebabkan oleh banyak faktor seperti kondisi sosial ekonomi, gizi ibu saat hamil, kesakitan pada bayi, dan kurangnya asupan gizi pada bayi. Balita stunting di masa yang akan datang akan mengalami kesulitan dalam mencapai perkembangan fisik dan kognitif yang optimal.

Stunting didefinisikan sebagai keadaan dimana status gizi pada anak menurut TB/U dengan hasil nilai Z Score = <-2 SD, hal ini menunjukkan keadaan tubuh yang pendek atau sangat pendek hasil dari gagal pertumbuhan. Stunting pada anak juga menjadi salah satu faktor risiko terjadinya kematian, masalah perkembangan motorik yang rendah, kemampuan berbahasa yang rendah, dan adanya ketidakseimbangan fungsional (Anwar et al., 2014).

Stunting menjadi masalah gagal tumbuh yang dialami oleh bayi di bawah lima tahun yang mengalami kurang gizi semenjak di dalam kandungan hingga awal bayi lahir, stunting sendiri akan mulai nampak ketika bayi berusia dua tahun (Kemiskinan, 2017). Sesuai dengan yang dikemukakan oleh Schmidt (2014) bahwa stunting ini merupakan masalah kurang gizi dengan periode yang cukup lama sehingga muncul gangguan pertumbuhan tinggi badan pada anak yang lebih rendah atau pendek (kerdil) dari standar usia-

nya (Schmidt, 2014).

2.8.1 Diagnosis Stunting

Stunting sendiri akan mulai nampak ketika bayi berusia dua tahun (Kemiskinan, 2017). Stunting didefinisikan sebagai keadaan dimana status gizi pada anak menurut TB/U mempunyai hasil Zscore $-3,0 \text{ SD s/d } -2,0 \text{ SD}$ (pendek) dan $Zscore < -3,0 \text{ SD}$ (sangat pendek). Hasil pengukuran Skor Simpang Baku (Z-score) didapatkan dengan mengurangi Nilai Individual Subjek (NIS) dengan Nilai Median Baku Rujukan (NMBR) pada umur yang bersangkutan, setelah itu hasilnya akan dibagi dengan Nilai Simpang Baku Rujuk (NSBR). Jika tinggi badan lebih kecil dari nilai median, maka NSBR didapatkan dengan cara mengurangi median dengan -1 SD . Jika tinggi badan lebih besar dari pada median, maka NSBR didapatkan dengan cara mengurangi $+1 \text{ SD}$ dengan median, berikut ini rumus yang bisa digunakan :

$$Z - Score = (NIS - NMBR)/NSBR \quad (2.4)$$

Sumber : (Kemiskinan, 2017)

Keterangan :

NIS : Nilai Individual Subjek (Tinggi badan anak)

NMBR: Nilai Median Baku Rujukan

NSBR : Nilai Simpang Baku Rujuk

2.8.2 Faktor Risiko Stunting

Beberapa faktor yang menyebabkan terjadinya stunting diantaranya:

- Status Gizi. Status Gizi merupakan sebuah penilaian keadaan gizi yang diukur oleh seseorang pada satu waktu dengan mengumpulkan data (Arisman, 2010).
- Kebersihan Lingkungan. Sanitasi yang baik akan mempengaruhi tumbuh kembang seorang anak. Sanitasi dan keamanan pangan dapat meningkatkan risiko terjadinya penyakit infeksi (RI, 2018).
- Makanan Pendamping ASI. Masalah kebutuhan gizi yang semakin tinggi akan dialami bayi mulai dari umur enam bulan membuat seorang

bayi mulai mengenal Makanan Pendamping ASI (MP-ASI) yang mana pemberian MP-ASI untuk menunjang pertambahan sumber zat gizi disamping pemberian ASI hingga usia dua tahun. Makanan pendamping harus diberikan dengan jumlah yang cukup, sehingga baik jumlah, frekuensi, dan menu bervariasi bisa memenuhi kebutuhan anak (Kementerian Kesehatan, 2011).

- ASI Eksklusif. Air Susu Ibu (ASI) merupakan air susu yang dihasilkan seorang ibu setelah melahirkan. ASI Eksklusif adalah pemberian ASI yang diberikan sejak bayi dilahirkan hingga usia bayi 6 bulan tanpa memberikan makanan atau minuman lainnya seperti susu formula, air putih, air jeruk kecuali vitamin dan obat (RI, 2016). ASI mengandung enzim pencerna susu sehingga organ pencernaan pada bayi sangat mudah untuk mencerna dan menyerap ASI, kata lain organ pencernaan bayi belum memiliki enzim yang cukup untuk mencerna makanan lain selain ASI.
- Berat Badan Lahir. Berat badan lahir adalah pengukuran berat badan yang setelah dilahirkan (RI, 2016).
- Berat Bayi Lahir Rendah. Berat bayi lahir rendah memiliki hubungan yang bermakna dengan kejadian stunting. Dikatakan Berat Badan Lahir Rendah (BBLR) jika berat < 2500 gram. Berat Badan Lahir Rendah (BBLR) merupakan faktor risiko yang paling dominan terhadap kejadian stunting pada anak baduta. Karakteristik bayi saat lahir (BBLR atau BBL normal) merupakan hal yang menentukan pertumbuhan anak. Anak dengan riwayat BBLR mengalami pertumbuhan linear yang lebih lambat dibandingkan Anak dengan riwayat BBL normal (Rahayu et al., 2015).
- Pendidikan Orang Tua. Tingkat pendidikan orang tua yang rendah juga mampu meningkatkan risiko terjadinya malnutrisi pada anak. Tingkat pendidikan orang tua merupakan salah satu penyebab terjadinya stunting hal ini dikarenakan pendidikan yang tinggi dianggap mampu untuk membuat keputusan dalam meningkatkan gizi dan kesehatan anak-anak. Pengetahuan yang tinggi juga mempengaruhi orang tua dalam menentukan pemenuhan gizi keluarga dan pola pengasuhan anak,

dimana pola asuh yang tidak tepat akan meningkatkan risiko kejadian stunting (Adriani and Wirjatmadi, 2012).

- Pendapatan Orang Tua. Tingkat pendapatan keluarga memiliki hubungan yang bermakna dengan kejadian stunting. Hal ini dikarenakan keluarga dengan pendapatan yang rendah akan mempengaruhi dalam penyediakan pangan untuk keluarga. Daya beli keluarga tergantung dengan pendapatan keluarga, dengan adanya pendapatan yang tinggi maka kemungkinan terpenuhinya kebutuhan makan bagi keluarga (Adriani and Wirjatmadi, 2012).
- Penyakit Infeksi Diare Diare merupakan keadaan dimana seseorang BAB dengan konsistensi yang lembek atau bahkan dapat berupa air saja dengan frekuensi yang sering bisa tiga atau lebih dalam satu hari. Penyakit infeksi diare ini sering diderita oleh anak, seorang anak yang mengalami diare secara terus menerus akan berisiko untuk mengalami dehidrasi atau kehilangan cairan sehingga penyakit infeksi tersebut dapat membuat anak kehilangan nafsu makan dan akan membuat penyerapan nutrisi menjadi terganggu (Kemenkes, 2011).
- Pola Pemberian Makan. Pola asuh yang baik dalam mencegah terjadinya stunting dapat dilihat dari praktik pemberian makan. Pola pemberian makan yang baik ini dapat berdampak pada tumbuh kembang dan kecerdasan anak sejak bayi. Pola asuh pemberian makan yang sesuai dengan anjuran (RI, 2016), yaitu pola makan pemberian makan yang baik kepada anak adalah dengan memberikan makanan yang memenuhi kebutuhan zat gizi anaknya setiap hari, seperti sumber energi yang terdapat pada nasi, umbi – umbian dan sebagainya.

2.8.3 Dampak Stunting

Dampak stunting dibagi menjadi dua, yakni ada dampak jangka panjang dan juga ada jangka pendek. Jangka pendek kejadian stunting yaitu terganggunya perkembangan otak, pertumbuhan fisik, kecerdasan, dan gangguan metabolisme pada tubuh. Sedangkan untuk jangka panjangnya yaitu mudah sakit, munculnya penyakit diabetes, penyakit jantung dan pembuluh darah, kegemukan, kanker, stroke, disabilitas pada usia tua, dan kualitas kerja yang kurang baik sehingga membuat produktivitas menjadi rendah (RI, 2016).

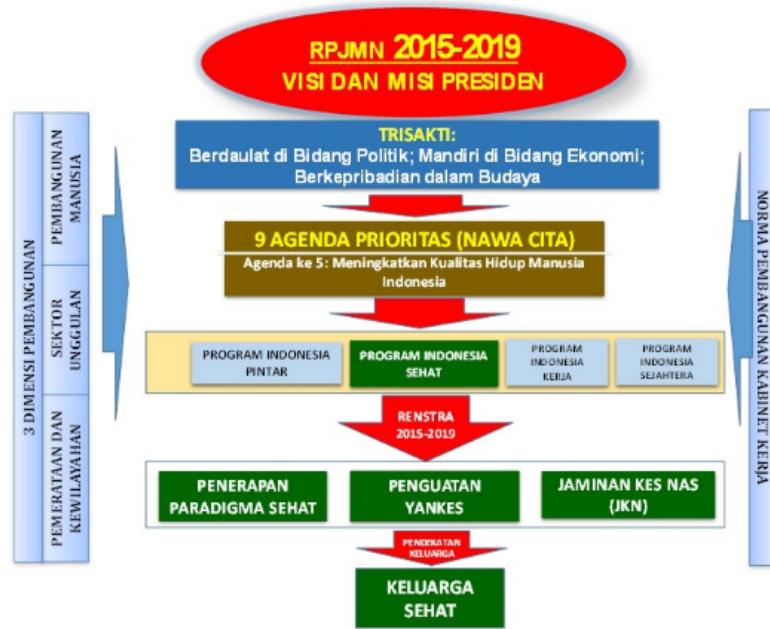
Kejadian stunting menjadi salah satu masalah yang terbilang serius jika dikaitan dengan adanya angka kesakitan dan kematian yang besar, kejadian obesitas, buruknya perkembangan kognitif, dan tingkat produktivitas pendapatan yang rendah. Berbagai permasalahan ini sangat mudah ditemukan di negara – negara berkembang seperti Indnesia (UNICEF., 2007).

Stunting pada anak yang harus disadari yaitu rusaknya fungsi kognitif sehingga anak dengan stunting mengalami permasalahan dalam mencapai pertumbuhan dan perkembangan secara optimal. Stunting pada anak ini juga menjadi faktor risiko terhadap kematian, perkembangan motorik yang rendah, kemampuan berbahasa yang rendah, dan ketidakseimbangan fungsional (Anwar et al., 2014).

2.9 Program Indonesia Sehat dengan Pendekatan Keluarga (PIS-PK)

Program PIS-PK atau yang lebih dikenal dengan Program Keluarga Sehat adalah salah satu program puskesmas yang menggunakan pendekatan keluarga untuk meningkatkan jangkauan sasaran. Program ini juga bertujuan untuk mendekatkan/meningkatkan akses pelayanan kesehatan di wilayah kerjanya dengan langsung mendatangi keluarga. Pendekatan keluarga merupakan strategi atau pendekatan pelayanan terintegrasi antara upaya kesehatan perorangan (UKP) dan upaya kesehatan masyarakat (UKM) yang didasari oleh data dan informasi profil kesehatan keluarga melalui kunjungan rumah.

Program Indonesia Sehat merupakan salah satu program dari Agenda ke-5 Nawa Cita seperti pada Gambar 2.8, yaitu Meningkatkan Kualitas Hidup Manusia Indonesia. Program ini didukung oleh program sektoral lainnya yaitu Program Indonesia Pintar, Program Indonesia Kerja, dan Program Indonesia Sejahtera. Program Indonesia Sehat selanjutnya menjadi program utama Pembangunan Kesehatan yang kemudian direncanakan pencapaiannya melalui Rencana Strategis Kementerian Kesehatan Tahun 2015-2019, yang ditetapkan melalui Keputusan Menteri Kesehatan R.I. Nomor HK.02.02/Menkes/52/2015.



Gambar 2.8: Penjabaran Visi & Misi Presiden Menjadi Program Indonesia Sehat

Sumber:

Sasaran dari Program Indonesia Sehat adalah meningkatnya derajat kesehatan dan status gizi masyarakat melalui upaya kesehatan dan pemberdayaan masyarakat yang didukung dengan perlindungan finansial dan pemera-taan pelayanan kesehatan. Sasaran ini sesuai dengan sasaran pokok RPJMN 2015-2019, yaitu:

1. Meningkatnya status kesehatan dan gizi ibu dan anak
2. Meningkatnya pengendalian penyakit
3. Meningkatnya akses dan mutu pelayanan kesehatan dasar dan rujukan terutama di daerah terpencil, tertinggal dan perbatasan
4. Meningkatnya cakupan pelayanan kesehatan universal melalui Kartu Indonesia Sehat dan kualitas pengelolaan SJSN kesehatan,
5. Terpenuhinya kebutuhan tenaga kesehatan, obat dan vaksin
6. Meningkatnya responsivitas sistem kesehatan.

Dalam rangka pelaksanaaan Program Indonesia Sehat telah disepakati adanya dua belas indikator utama untuk penanda status kesehatan sebuah keluarga (Indonesia, 2016). Kedua belas indikator utama tersebut adalah sebagai berikut:

1. Keluarga mengikuti program Keluarga Berencana (KB)
2. Ibu melakukan persalinan di fasilitas kesehatan
3. Bayi mendapat imunisasi dasar lengkap
4. Bayi mendapat air susu ibu (ASI) eksklusif
5. Balita mendapatkan pematauan pertumbuhan
6. Penderita tuberkulosis paru mendapatkan pengobatan sesuai standar
7. Penderita hipertensi melakukan pengobatan secara teratur
8. Penderita gangguan jiwa mendapatkan pengobatan dan tidak ditelan-tarkan
9. Anggota keluarga tidak ada yang merokok
10. Keluarga sudah menjadi anggota Jaminan Kesehatan Nasional (JKN)
11. Keluarga mempunyai akses sarana air bersih
12. Keluarga mempunyai akses atau menggunakan jamban sehat

Berdasarkan indikator tersebut, dilakukan penghitungan Indeks Keluarga Sehat (IKS) dari setiap keluarga, sedangkan keadaan masing-masing indikator mencerminkan kondisi PHBS dari keluarga yang bersangkutan (Indonesia, 2016).

2.10 Penelitian Terkait

Penelitian terkait yang membahas model prediksi berbasis *Generative Adversarial Networks* (GAN) diantaranya Saxena and Cao (2019) mengusulkan model berbasis *generative adversarial network* baru (bernama, D-GAN) untuk prediksi *Spation-Temporal* (ST) yang lebih akurat dengan secara implisit

mempelajari representasi fitur ST dengan cara yang tidak diawasi. Lei et al. (2019) memperkenalkan model *non-linier* baru GCN-GAN untuk mengatasi tugas prediksi tautan temporal yang menantang dari bobot jaringan dinamis. Model yang diusulkan memanfaatkan manfaat dari *graph convolutional network* (GCN), *long short-term memory* (LSTM) serta *generative adversarial network* (GAN).

Selain itu Zhang et al. (2019) juga mengusulkan arsitektur baru dari *Generative Adversarial Network* (GAN) dengan *Multi-Layer Perceptron* (MLP) sebagai *diskriminator* dan *Long Short-Term Memory* (LSTM) sebagai *generator* untuk peramalan harga penutupan saham. *Generator* dibangun dengan LSTM untuk menambang distribusi data saham dari data pasar saham yang diberikan dan menghasilkan data dalam distribusi yang sama, sedangkan *diskriminator* yang dirancang oleh MLP bertujuan untuk membedakan data saham real dan data yang dihasilkan.

Lain halnya penelitian yang dilakukan oleh Polamuri et al. (2021) membentuk model *Hybrid* penggabungan MM-HPA dan GAN-HPA untuk meningkatkan proses prediksi di pasar saham, Soleymani and Paquet (2022) melakukan pendekatan yang didasarkan pada persamaan stokastik, integral jalur Feynman-Dirac, *deep Bayesian networks*, dan *temporal generative adversarial neural networks* (t-GAN) untuk prediksi harga saham jangka panjang dan Husein et al. (2019) mengembangkan model prediksi berbasis *Generative Adversarial Networks* (GAN) untuk melakukan prediksi penjualan obat di Rumah Sakit.

Tabel 2.2 tertera ringkasan penelitian terkait topik bahasan dan metode yang digunakan pada model prediksi berbasis *Generative Adversarial Networks* (GAN).

Tabel 2.1: Rangkuman Hasil Penelitian Terkait

No.	Nama Peneliti, Tahun	Topik	Kelebihan	Kekurangan
1	Divya Saxena, Jiannong Cao (2019)	Mengusulkan model berbasis <i>generative adversarial network</i> baru (bernama, D-GAN) untuk prediksi <i>Spation-Temporal</i> (ST).	D-GAN berhasil menangani korelasi ST dan elemen stokastik yang ada dalam data ST.	Kedepannya perlu menggunakan mekanisme atensi untuk meningkatkan performa model D-GAN yang dikembangkan.
2	Kai Lei, Meng Qin, Bo Bai, Gong Zhang, Min Yang (2019)	Memperkenalkan model non-linier baru GCN-GAN untuk mengatasi tugas prediksi tautan temporal.	Manfaatkan <i>graph convolutional network</i> (GCN), <i>long short-term memory</i> (LSTM) serta <i>generative adversarial network</i> didalam prediksi tautan temporal.	Belum dapat mengatasi masalah prediksi tautan temporal dengan kumpulan simpul yang tidak tetap.
3	Kang Zhang, Guoqiang Zhong, Junyu Dong, Shengke Wang, Yong Wang (2019)	Mengusulkan arsitektur baru dari <i>Generative Adversarial Network</i> (GAN) dengan <i>Multi-Layer Perceptron</i> (MLP) sebagai diskriminator dan <i>Long Short-Term Memory</i> (LSTM) sebagai <i>generator</i> untuk peramalan harga penutupan saham.	<i>Generator</i> dibangun dengan LSTM untuk menambang distribusi data saham, sedangkan <i>diskriminator</i> yang dirancang oleh MLP bertujuan untuk membedakan data saham real dan data yang dihasilkan.	Mengeksplorasi cara mengekstrak faktor keuangan yang lebih penting dan berpengaruh dari pasar saham dan mengoptimalkan model untuk mempelajari distribusi data secara lebih akurat.

Tabel 2.2: Rangkuman Hasil Penelitian Terkait

No.	Nama Peneliti, Tahun	Topik	Kelebihan	Kekurangan
4	Amir Mahmud Husein, Muhammad Arsyal, Sutrisno Sinaga, Hendra Syahputa (2019)	Mengembangkan model prediksi berbasis <i>Generative Adversarial Networks</i> (GAN) untuk melakukan prediksi penjualan obat dengan tujuan meminimalisir terjadinya kekurangan dan kelebihan stok obat di Rumah Sakit.	Menggunakan <i>framework GAN</i> dalam melakukan eksplorasi peramalan jumlah penjualan obat selama satu minggu ke depan.	Perlu mencari cara mengekstraksi faktor yang lebih penting dan berpengaruh dari perencanaan kebutuhan obat dan mengoptimalkan model.
5	Subba Rao Polamuri, Dr. Kudipudi Srinivas, Dr. A. Krishna Mohan (2021)	Membentuk model <i>Hybrid</i> penggabungan MM-HPA dan GAN-HPA yang dikenal sebagai MMGAN-HPA untuk meningkatkan proses prediksi di pasar saham.	Model MMGAN-HPA menunjukkan peningkatan dari GAN-HPA dalam prediksi harga saham.	Membutuhkan metode LSTM dan CNN yang digunakan sebagai model generator dan diskriminator.
6	Farzan Soleymani, Eric Paquet (2022)	Penelitian ini didasarkan pada persamaan stokastik, integral jalur Feynman-Dirac, <i>Deep Bayesian Networks</i> , dan <i>Temporal Generative Adversarial Neural Networks</i> (t-GAN) untuk prediksi harga saham jangka panjang.	Mengusulkan kerangka kerja baru yang disebut QuantumPath untuk prediksi keuangan jangka panjang.	Pengambilan sampel distribusi data dengan t-GAN menggabungkan mekanisme memori jangka pendek dan memori jangka panjang.

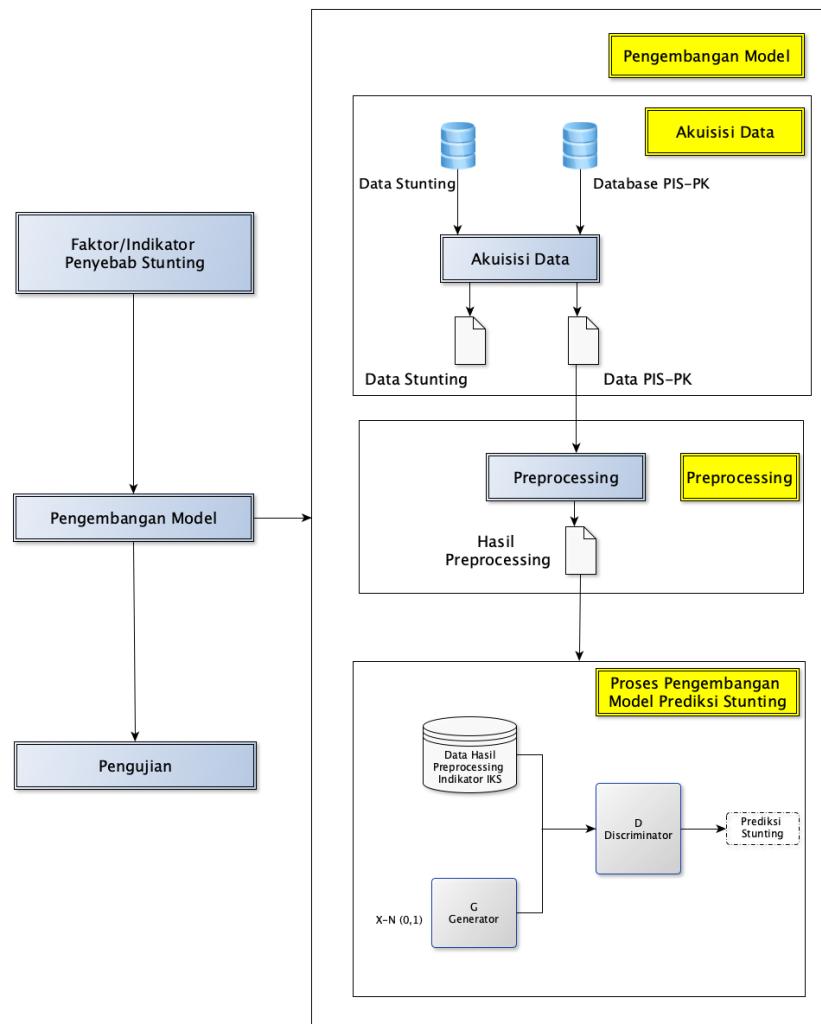
Bab 3

Metode Penelitian

3.1 Tahapan Penelitian

Penelitian ini memiliki fokus pengembangan model dalam melakukan prediksi terjadinya stunting pada suatu wilayah berbasis *Generative Adversarial Networks*. Gambar 3.1 adalah tahapan penelitian dalam membangun model prediksi terjadinya stunting pada suatu wilayah berbasis *Generative Adversarial Networks*.

1. Faktor indikator penyebab stunting menjelaskan tentang faktor-faktor yang menyebabkan terjadinya stunting pada balita.
2. Pengembangan model pada penelitian ini dibagi menjadi beberapa tahapan, antara lain:
 - (a) Akusisi Data memperoleh informasi yang dibutuhkan dalam rangka mencapai tujuan penelitian.
 - (b) *Preprocessing* merupakan tahap pemrosesan data dari langkah akusisi data.
 - (c) Proses Pengembangan Model Prediksi Stunting berbasis *Generative Adversarial Networks* untuk memprediksi keadaan stunting pada suatu wilayah.
3. Pengujian adalah tahap terakhir dari rangkaian cara kerja *machine learning*. Yaitu perbandingan kinerja pemodelan yang telah divalidasi sebelumnya kemudian dengan data uji, lalu mengaplikasikan data *train* dengan menciptakan prediksi berdasarkan data baru.



Gambar 3.1: Metodologi Penelitian

3.2 Faktor Indikator Penyebab Stunting

Faktor-faktor yang mempengaruhi terjadinya stunting pada balita terdiri dari beberapa faktor, diantaranya:

- Hasil penelitian yang dilakukan oleh Umiyah and Hamidiyah (2021) menunjukkan bahwa ada hubungan antara berat badan lahir dengan kejadian stunting dengan nilai Pvalue = 0,009 ($P \leq 0,05$). Sedangkan sebaliknya untuk usia (Pvalue 0,095), jenis kelamin (Pvalue

0,512), dan panjang badan lahir (Pvalue 0,334) tidak ada hubungan dengan kejadian stunting.

- Hasil penelitian yang dilakukan oleh Apriluana and Fikawati (2018)menunjukkan faktor status gizi dengan berat badan lahir < 2.500 gram memiliki pengaruh secara bermakna terhadap kejadian stunting pada anak dan memiliki risiko mengalami stunting sebesar 3,82 kali. Faktor pendidikan ibu rendah memiliki pengaruh secara bermakna terhadap kejadian stunting pada anak dan memiliki risiko mengalami stunting sebanyak 1,67 kali. Faktor pendapatan rumah tangga yang rendah diidentifikasi sebagai predictor signifikan untuk stunting pada balita sebesar 2,1 kali. Faktor sanitasi yang tidak baik memiliki pengaruh yang signifikan terhadap kejadian stunting pada balita dan memiliki risiko mengalami stunting hingga sebesar 5,0 kali.
- Hasil penelitian yang dilakukan oleh Romadonyah et al. (2022)menunjukkan faktor yang mempengaruhi stunting pada balita adalah berat badan lahir < 2.500 gram, MPASI, faktor pendidikan ibu rendah, pendapatan rumah tangga, faktor sanitasi yang tidak baik.
- Hasil penelitian yang dilakukan oleh Ariati (2019)menunjukkan prevalensi stunting sebesar 32,5 % dan balita Normal 67,5%. Analisis uji statistik menunjukkan adanya hubungan bermakna antara faktor prenatal (usia ibu saat hamil, status gizi ibu saat hamil), faktor pasca-natal (ASI Eksklusif, riwayat imunisasi, penyakit infeksi), Karakteristik keluarga (pendidikan ibu, pekerjaan ayah dan status sosial ekonomi) dengan kejadian stunting.
- Hasil penelitian yang dilakukan oleh Al-Rahmad et al. (2013)diperoleh kejadian stunting pada balita disebabkan rendahnya pendapatan keluarga ($p=0,026$; $OR=3,1$), pemberian ASI tidak eksklusif ($p=0,002$; $OR=4,2$), pemberian MP-ASI kurang baik ($p=0,007$; $OR=3,4$), serta imunisasi tidak lengkap ($p=0,040$; $OR=3,5$).

Dari hasil penelitian tersebut, penulis melakukan keterhubungan antara faktor-faktor penyebab stunting dengan indikator PIS-PK. Hubungan faktor stunting dengan indikator PIS-PK dapat dilihat pada Tabel 3.1.

Tabel 3.1: Hubungan Indikator Stunting

No	Judul	Penulis	Indikator	PIS-PK
1	Karakteristik Anak Dengan Kejadian Stunting	Umiyah and Hamidiyah (2021)	1. Berat Badan Lahir	1. Indikator 5
2	Analisis Faktor-Faktor Risiko terhadap Kejadian Stunting pada Balita (0-59 Bulan) di Negara Berkembang dan Asia Tenggara	Apriluana and Fikawati (2018)	1. Berat Badan Lahir Rendah 2. Pendidikan Ibu 3. Pendapatan Rumah Tangga 4. Sanitasi Kurang Baik	1. Indikator 5 2. - 3. - 4. Indikator 11
3	Literatur Review : Faktor – Faktor yang Mempengaruhi Kejadian Stunting pada Balita di Negara Berkembang	Romadoniyah et al. (2022)	1. Berat badan lahir 2. MPASI 3. Pendidikan ibu rendah 4. Pendapatan rumah tangga 5. Sanitasi yang tidak baik	1. Indikator 5 2. Indikator 4 3. - 4. - 5. Indikator 11

Tabel 3.2: Hubungan Indikator Stunting

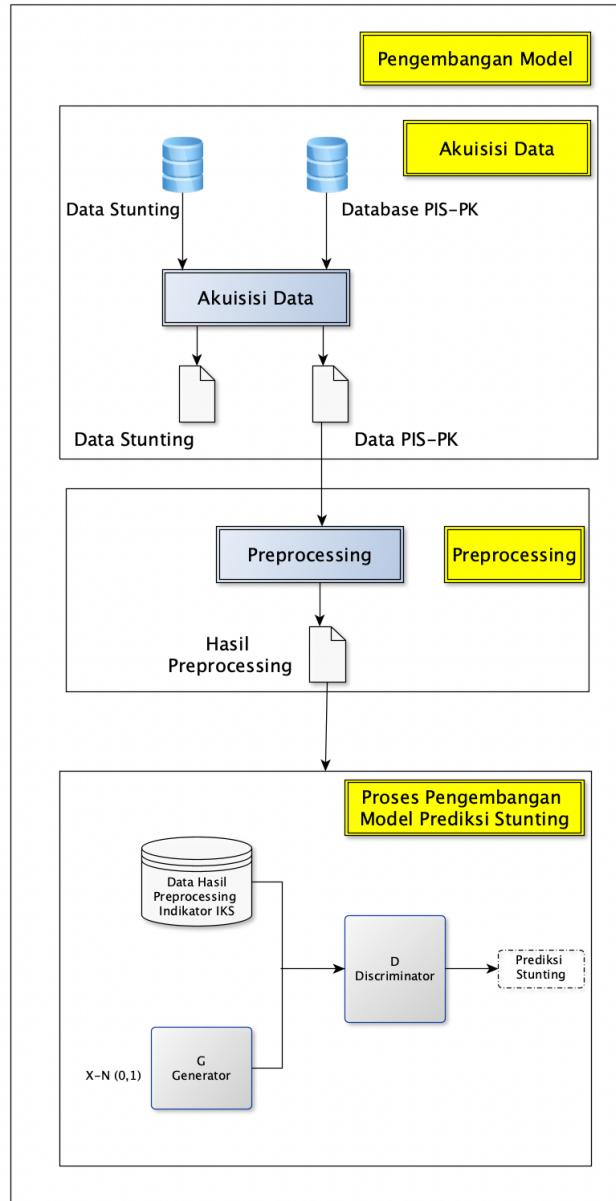
No	Judul	Penulis	Indikator	PIS-PK
4	Faktor-Faktor Resiko Penyebab Terjadinya Stunting pada Balita Usia 23-59 Bulan	Ariati (2019)	1. Usia ibu saat hamil 2. Status gizi ibu saat hamil 3. ASI Eksklusif 4. Riwayat imunisasi 5. Penyakit infeksi 6. Pendidikan ibu 7. Pekerjaan ayah 8. Status sosial ekonomi	1. - 2. - 3. Indikator 4 4. Indikator 3 5. - 6. - 7. - 8. -
5	Kajian stunting pada anak balita ditinjau dari pemberian ASI eksklusif, MP-ASI, status imunisasi dan karakteristik keluarga di Kota Banda Aceh	Al-Rahmad et al. (2013)	1. Pendapatan keluarga 2. ASI tidak eksklusif 3. MP-ASI kurang baik 4. Imunisasi tidak lengkap	1. - 2. Indikator 4 3. Indikator 4 4. Indikator 3

Dari hasil keterhubungan faktor penyebab stunting dengan indikator PIS-PK, indikator yang digunakan ada 4 indikator. Indikator tersebut diantaranya:

1. Indikator 3 (Bayi mendapat imunisasi dasar lengkap)
2. Indikator 4 (Bayi mendapat air susu ibu (ASI) eksklusif)
3. Indikator 5 (Balita mendapatkan pematauan pertumbuhan)
4. Indikator 11 (Keluarga mempunyai akses sarana air bersih)

3.3 Pengembangan Model

Beberapa tahap yang dilakukan dalam pengembangan model stunting diantaranya akuisisi data, preprocessing dan proses pengembangan model. Gambar menunjukkan proses pengembangan model yang dilakukan dalam penelitian.

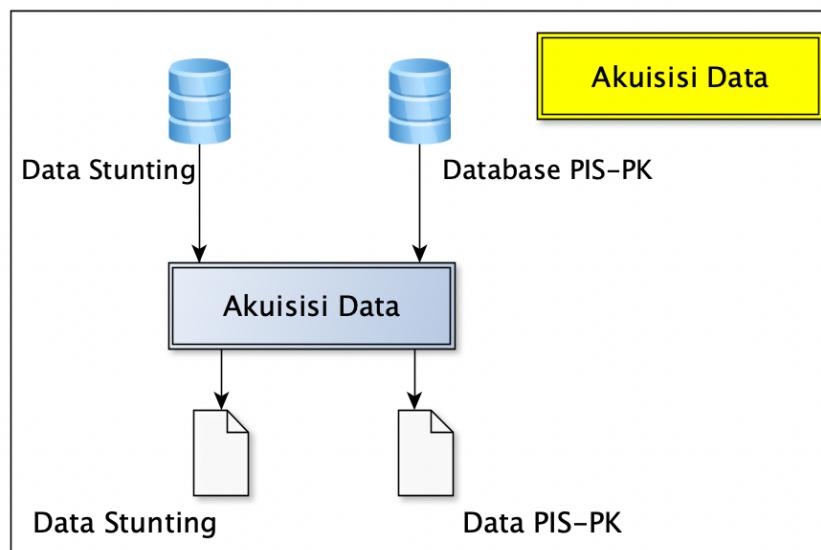


Gambar 3.2: Pengembangan Model

1. Akusisi Data memperoleh informasi yang dibutuhkan dalam rangka mencapai tujuan penelitian.
2. Preprocessing merupakan tahap pemrosesan data dari langkah akusisi data.
3. Proses Pengembangan Model Prediksi Stunting berbasis *Generative Adversarial Networks* untuk memprediksi keadaan stunting pada suatu wilayah.

3.3.1 Akuisisi Data

Tahap pertama dari pengembangan model terjadinya stunting adalah akuisisi data seperti pada Gambar 3.3. Akuisisi data adalah tahap pengumpulan data yang dibutuhkan dalam penelitian. Dalam penelitian ini data dikumpulkan dari data stunting dan data PIS-PK.

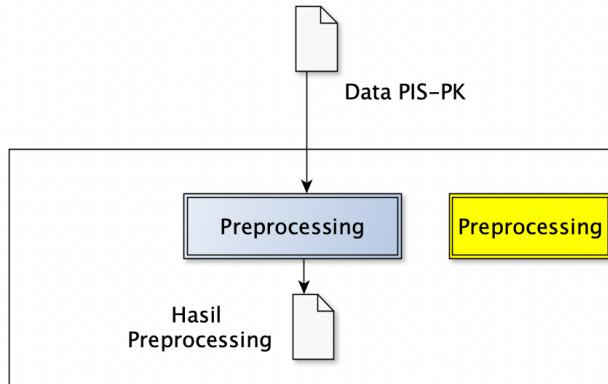


Gambar 3.3: Tahapan Akuisisi Data

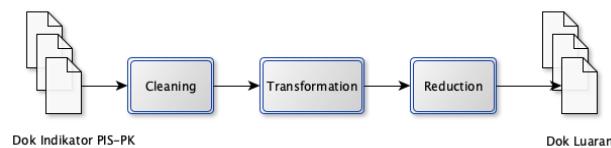
Pada Gambar 3.3 merupakan tahapan yang dilakukan dalam melakukan akuisisi data stunting dan data indikator PIS-PK.

3.3.2 Preprocessing

Tahap *preprocessing* berfungsi untuk membersihkan data sehingga dapat menghindari penggunaan data yang bermasalah dan tidak konsisten (Surjandari et al., 2018). Proses ini digambarkan pada Gambar 3.4.

Gambar 3.4: *Preprocessing*

Tahap *preprocessing* yang digunakan penelitian ini meliputi tahap pembersihan data, transformasi data dan data *reduction*. Tahapan tersebut digambarakan pada Gambar 3.5.

Gambar 3.5: Tahapan *Preprocessing*

Cleaning. Untuk membuat data layak digunakan untuk penelitian, dilakukan tahapan pembersihan data (*cleaning*).

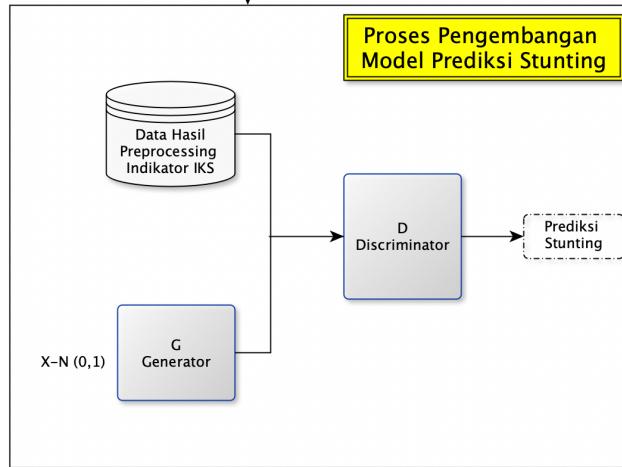
Transformation. Untuk mengubah data dalam bentuk yang sesuai dalam proses penelitian.

Reduction. Untuk meningkatkan efisiensi penyimpanan serta analisis data.

3.3.3 Proses Pengembangan Model Prediksi Stunting

Pada tahap ini menjelaskan metode yang diusulkan menggunakan pendekatan kerangka *Generative Adversarial Networks* (GAN) untuk prediksi terjadinya stunting pada suatu wilayah. GAN diperkenalkan oleh Goodfellow et al. (2014) sebagai kerangka model *deep learning* untuk menangkap distribusi data pelatihan dengan menghasilkan data baru dari distribusi yang sama menggunakan model *generator* dan *diskriminators*. Arsitektur GAN mempelajari fitur tanpa pengawasan dengan proses pembelajaran yang kompetitif.

GAN akan menghasilkan lebih banyak ruang fitur yang dapat dimanfaatkan, sehingga mengurangi potensi kelebihan fitur selama pelatihan. Berikut ini adalah gambaran arsitektur model GAN yang diusulkan pada Gambar 3.6.



Gambar 3.6: Proses Pengembangan Model Prediksi Stunting

Gambar 3.6 Metode arsitektur yang diusulkan Model G (*Generator*) dilatih untuk menghasilkan data yang terlihat seperti data persebaran data indeks keluarga sehat di setiap wilayah, sedangkan model D (*Discriminator*) dilatih untuk membedakan antara data dari *Generator* dan data nyata. Kesalahan dari D digunakan untuk melatih G untuk mengalahkan D. Persaingan antara G dan D memaksa D untuk membedakan secara acak dari variabilitas nyata, secara formal GAN menyelesaikan permainan min-max dengan persamaan berikut:

$$\max_D V(D) = E_{\chi \sim P_{data}(\chi)} [\log D(\chi)] + E_{z \sim P_z(z)} [\log(1 - D(G(z)))] \quad (3.1)$$

Diskriminat mengeluarkan nilai $D(x)$ yang menunjukkan kemungkinan bahwa x adalah data nyata dengan tujuan memaksimalkan peluang untuk mengenali data nyata sebagai data nyata yang dihasilkan sebagai data palsu. Untuk mengukur kerugian model GAN menggunakan *cross-entropy*, $p \log (q)$, untuk data real $p = 1$. Di sisi *generator*, fungsi tujuan menggunakan model untuk menghasilkan D setinggi mungkin (x) nilai untuk membalikkan perbedaan.

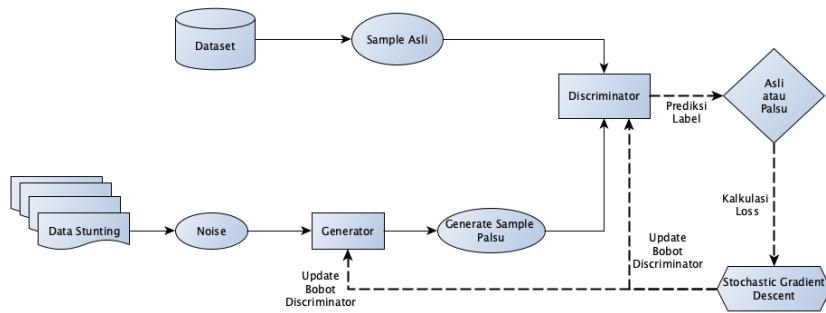
$$\frac{\min}{G} V(G) = E_{z \sim P_z(z)} [\log(1 - D(G(z)))] \quad (3.2)$$

Seperi yang dijelaskan dalam makalah Goodfellow et al. (2014), D dan G memainkan permainan min-max di mana D mencoba memaksimalkan probabilitas dengan benar mengklasifikasikan *real* dan *false* ($\log D(x)$), dan G mencoba meminimalkan probabilitas bahwa D akan memprediksi output yang salah ($\log(1 - D(G(x)))$).

$$\frac{\min}{G} \frac{\max}{D} V(D, G) = E_{x \sim P_{\text{data}}(x)} [\log D(x)] + E_{z \sim P_z(z)} [\log(1 - D(G(z)))] \quad (3.3)$$

Dimana P_{data} adalah distribusi data pelatihan nyata dari ke x , dan P_z adalah distribusi z vektor *noise* yang diambil. G adalah pemetaan dari z ke ruang x , sedangkan D memetakan input x ke nilai skalar yang mewakili x probabilistik menjadi sampel nyata.

Generative Adversarial Networks (GAN) asli yang diusulkan oleh Goodfellow et al. (2014) menampilkan sebuah generator dan diskriminasi; generator G dilatih untuk menghasilkan sampel palsu yang dapat menipu pembeda D , sedangkan yang terakhir dilatih untuk membedakan antara sampel asli dan palsu. Seperti yang ditunjukkan pada Gambar 3.7, generator menggunakan data stunting untuk membuat sampel palsu. Diskriminasi membandingkan sampel asli dengan palsu sampel. Akhirnya kerugian diskriminasi dihitung dan digunakan untuk memperbaharui diskriminasi dan generator.



Gambar 3.7: Arsitektur *Generative Adversarial Networks*

Diberikan noise dari noise z dari data stunting $p(z)$, dan a sampel x dari distribusi data nyata $p_{\text{data}}(x)$. Diskriminasi keluarannya adalah $D(x)$ untuk sampel asli dan $D(G(x))$ untuk sampel palsu. Diskriminasi secara ber-

samaan berusaha meningkatkan kemampuannya untuk mengenali sampel nyata dengan memaksimalkan $\log D(x)$ ke 1, dan sampel palsu dengan memaksimalkan $\log(1 - D(G(z)))$ ke 0. Generator menghindari pembangkitan sampel yang mudah dikenali oleh diskriminator dengan meminimalkan $\log(1 - D(G(z)))$. Permainan min-max yang dimainkan antara generator dan diskriminator diwakili pada (Persamaan (3.3)).

Proses pelatihan GAN pertama-tama akan menghitung kerugian dan perbarui diskriminator (Persamaan (3.4)). Kemudian hitung dan perbarui generator (Persamaan (3.5)).

$$\nabla_{\Theta_d} \frac{1}{m} \sum_{i=1}^m [\log D(x^{(i)}) + \log(1 - D(G(z^{(i)})))] \quad (3.4)$$

$$\nabla_{\Theta_g} \frac{1}{m} \sum_{i=1}^m \log(1 - D(G(z^{(i)}))) \quad (3.5)$$

Diskriminator diperbarui dengan menaikkan gradien stokastiknya ∇_{Θ_d} , sedangkan generator diperbarui dengan menurunkan gradien stokastiknya ∇_{Θ_g} . salah ukuran batch yang digunakan untuk pelatihan ini adalah sampelnya indeks.

3.4 Pengujian

Tujuan dari penelitian ini adalah membangun model prediksi berbasis *Generative Adversarial Networks* untuk memprediksi terjadinya stunting pada suatu wilayah yang dibutuhkan untuk mencegah terjadinya stunting dan mengoptimalkan perencanaan program pemerintah dalam penurunan terjadinya stunting. Data dipisahkan menjadi dua bagian untuk model pelatihan dan pengujian. Data yang digunakan adalah data dari tahun 2020-2022 untuk data stunting dan rentang waktu tahun 2019-2021 untuk data indikator PIS-PK.

Bab 4

Hasil dan Pembahasan

4.1 Implementasi Penelitian

Implementasi tahapan proses yang dikembangkan dalam penelitian ini terdiri dari dua tahap, yaitu:

1. **Tahap Pembangunan Model.** Tahap ini merupakan tahap terdiri dari urutan proses, dimana dokumen hasil akuisisi data diolah selanjutnya ditentukan parameter untuk menghasilkan data set untuk selanjutnya dilakukan pelatihan sehingga menghasilkan suatu model.
2. **Tahap Pengujian.** Tahap ini merupakan implementasi dari hasil tahap pengembangan model.

Perangkat lunak yang digunakan dalam implementasi dari tahapan yang dilakukan sebagai berikut:

- Sistem operasi yang digunakan yaitu MacOS Monterey.
- Bahasa pemrograman yang digunakan adalah Python 3.9.7 (<https://www.python.org/>).
- Aplikasi Jupyter Notebook digunakan untuk mengolah data di python.

4.2 Pembangunan Model

Tahap pembangunan model merupakan tahapan dari strategi dalam membangun model, yang terdiri dari beberapa tahap, yaitu akuisisi data, *preprocessing* dan pengembangan model.

4.2.1 Akuisisi Data

Akuisisi data merupakan tahapan awal dari pengumpulan data sebelum dilakukan pemrosesan data lebih lanjut. Tahap akuisisi data ini mengubah bentuk file dari database menjadi .csv. Data yang digunakan dalam penelitian ini adalah data stunting dan data indikator PIS-PK. Kumpulan data stunting dan data indikator PIS-PK diperoleh dari Kementerian Kesehatan.

Tabel 4.1 menunjukkan jumlah data stunting yang akan digunakan dalam penelitian.

Tabel 4.1: Jumlah Data Stunting

No.	Tahun	Jumlah
1	2022	16.321
2	2021	170.854
3	2020	39.441

Gambar 4.1 merupakan bentuk data stunting di masing-masing daerah yang di dapat dari Kementerian Kesehatan. Data ini terdiri dari data provinsi, kabupaten, kecamatan, jumlah balita stunting, dan lain-lain.

	A	B	C	D	E	F	G	H	I	K	L	M	N	O	P	Q	R	S
	kode	date	index	year	lat	long	id	lat_semaran	balita	mtl_balita_dilaku	mtl_balita_dilaku	mtl_balita_dilaku	mtl_balita_dilaku	mtl_balita_wanting	global_tahun	mtl_underweight	mtl_tulera_ditrima	mtl_menangat_tan
1	1560931	5513_0_0_2022-11-01	2022-11-01	5513	5513	5513	5513	5513	5	5	5	5	5	5	5	5	5	5
2	156446	10108_0_0_2022-04-01	2022-04-01	10108	10108	10108	10108	10108	5	5	5	5	5	5	5	5	5	5
3	156446	10108_0_0_2022-04-01	2022-04-01	10108	10108	10108	10108	10108	5	5	5	5	5	5	5	5	5	5
4	226828	3009_0_0_2022-04-01	2022-04-01	3009	3009	3009	3009	3009	5	5	5	5	5	5	5	5	5	5
5	226828	3009_0_0_2022-04-01	2022-04-01	3009	3009	3009	3009	3009	5	5	5	5	5	5	5	5	5	5
6	226829	3009_0_0_2022-04-01	2022-04-01	3009	3009	3009	3009	3009	5	5	5	5	5	5	5	5	5	5
7	226830	3009_0_0_2022-04-01	2022-04-01	3009	3009	3009	3009	3009	5	5	5	5	5	5	5	5	5	5
8	226830	3009_0_0_2022-04-01	2022-04-01	3009	3009	3009	3009	3009	5	5	5	5	5	5	5	5	5	5
9	226860	3009_0_0_2022-04-01	2022-04-01	3009	3009	3009	3009	3009	5	5	5	5	5	5	5	5	5	5
10	226860	3009_0_0_2022-04-01	2022-04-01	3009	3009	3009	3009	3009	5	5	5	5	5	5	5	5	5	5
11	226864	10498_0_0_2022-04-01	2022-04-01	10498	10498	10498	10498	10498	5	5	5	5	5	5	5	5	5	5
12	226864	10498_0_0_2022-04-01	2022-04-01	10498	10498	10498	10498	10498	5	5	5	5	5	5	5	5	5	5
13	226866	10498_0_0_2022-04-01	2022-04-01	10498	10498	10498	10498	10498	5	5	5	5	5	5	5	5	5	5
14	226867	10498_0_0_2022-04-01	2022-04-01	10498	10498	10498	10498	10498	5	5	5	5	5	5	5	5	5	5
15	226867	10498_0_0_2022-04-01	2022-04-01	10498	10498	10498	10498	10498	5	5	5	5	5	5	5	5	5	5
16	226869	7482_0_0_2022-03-01	2022-03-01	7482	7482	7482	7482	7482	5	5	5	5	5	5	5	5	5	5
17	226872	9912_0_0_2022-03-01	2022-03-01	9912	9912	9912	9912	9912	5	5	5	5	5	5	5	5	5	5
18	226872	9912_0_0_2022-03-01	2022-03-01	9912	9912	9912	9912	9912	5	5	5	5	5	5	5	5	5	5
19	226879	9429_0_0_2022-03-01	2022-03-01	9429	9429	9429	9429	9429	5	5	5	5	5	5	5	5	5	5
20	226880	9429_0_0_2022-03-01	2022-03-01	9429	9429	9429	9429	9429	5	5	5	5	5	5	5	5	5	5
21	226881	9705_0_0_2022-03-01	2022-03-01	9705	9705	9705	9705	9705	5	5	5	5	5	5	5	5	5	5
22	226881	10484_0_0_2022-03-01	2022-03-01	10484	10484	10484	10484	10484	5	5	5	5	5	5	5	5	5	5
23	226882	10484_0_0_2022-03-01	2022-03-01	10484	10484	10484	10484	10484	5	5	5	5	5	5	5	5	5	5
24	226887	10498_0_0_2022-03-01	2022-03-01	10498	10498	10498	10498	10498	5	5	5	5	5	5	5	5	5	5
25	226888	9711_0_0_2022-03-01	2022-03-01	9711	9711	9711	9711	9711	5	5	5	5	5	5	5	5	5	5
26	226888	9711_0_0_2022-03-01	2022-03-01	9711	9711	9711	9711	9711	5	5	5	5	5	5	5	5	5	5
27	226890	9955_0_0_2022-03-01	2022-03-01	9955	9955	9955	9955	9955	5	5	5	5	5	5	5	5	5	5
28	226890	9955_0_0_2022-03-01	2022-03-01	9955	9955	9955	9955	9955	5	5	5	5	5	5	5	5	5	5
29	226892	7647_0_0_2022-03-01	2022-03-01	7647	7647	7647	7647	7647	5	5	5	5	5	5	5	5	5	5
30	226893	6021_0_0_2022-03-01	2022-03-01	6021	6021	6021	6021	6021	5	5	5	5	5	5	5	5	5	5
31	226895	9711_0_0_2022-03-01	2022-03-01	9711	9711	9711	9711	9711	5	5	5	5	5	5	5	5	5	5
32	226895	3931_0_0_2022-03-01	2022-03-01	3931	3931	3931	3931	3931	5	5	5	5	5	5	5	5	5	5
33	226896	10484_0_0_2022-03-01	2022-03-01	10484	10484	10484	10484	10484	5	5	5	5	5	5	5	5	5	5
34	226896	10484_0_0_2022-03-01	2022-03-01	10484	10484	10484	10484	10484	5	5	5	5	5	5	5	5	5	5
35	226902	7811_0_0_2022-03-01	2022-03-01	7811	7811	7811	7811	7811	5	5	5	5	5	5	5	5	5	5
36	226902	6021_0_0_2022-03-01	2022-03-01	6021	6021	6021	6021	6021	5	5	5	5	5	5	5	5	5	5
37	226914	9711_0_0_2022-03-01	2022-03-01	9711	9711	9711	9711	9711	5	5	5	5	5	5	5	5	5	5
38	226916	10604_0_0_2022-03-01	2022-03-01	10604	10604	10604	10604	10604	5	5	5	5	5	5	5	5	5	5
39	226916	10604_0_0_2022-03-01	2022-03-01	10604	10604	10604	10604	10604	5	5	5	5	5	5	5	5	5	5
40	226919	10794_0_0_2022-03-01	2022-03-01	10794	10794	10794	10794	10794	5	5	5	5	5	5	5	5	5	5
41	226919	10794_0_0_2022-03-01	2022-03-01	10794	10794	10794	10794	10794	5	5	5	5	5	5	5	5	5	5
42	226919	10794_0_0_2022-03-01	2022-03-01	10794	10794	10794	10794	10794	5	5	5	5	5	5	5	5	5	5
43	226919	7429_0_0_2022-03-01	2022-03-01	7429	7429	7429	7429	7429	5	5	5	5	5	5	5	5	5	5
44	226926	2489_0_0_2022-03-01	2022-03-01	2489	2489	2489	2489	2489	5	5	5	5	5	5	5	5	5	5
45	226926	2489_0_0_2022-03-01	2022-03-01	2489	2489	2489	2489	2489	5	5	5	5	5	5	5	5	5	5
46	226926	2489_0_0_2022-03-01	2022-03-01	2489	2489	2489	2489	2489	5	5	5	5	5	5	5	5	5	5

Gambar 4.1: Data Jumlah Stunting

Data stunting tersebut akan digunakan sebagai data training.

Sedangkan data indikator PIS-PK akan digunakan sebagai data input dalam penelitian ini. Tabel 4.2 menunjukkan jumlah indikator PIS-PK yang akan digunakan sebagai data input dalam penelitian.

Tabel 4.2: Jumlah Data Indikator PIS-PK

No.	Tahun	Jumlah
1	2021	355
2	2020	704
3	2019	9.224

Gambar 4.2 ini merupakan bentuk raw data dari data indikator PIS-PK.

	A	B	C	D	E	F	G	H	I	J	K	U	V	W	X	Y	Z	AA	AB	AC	AD	AE	AF	AG
1	SUR0010	TANGSEL SURVEI	NAMAKK	NO KK	ALAMAT	PROVINSI	KABUPATEN	KECAMATAN	KELURAHAN	RT	RW	JUMLAH KELUARGA	JUMLAH ANAK KELUARGA	JUMLAH ANAK JENIS SUMBER	JENIS SUMBER									
2	2d54b4e0	-2018-05-22	PARIO		DUSUN KARANGENGGOK	JAWA TIMUR	PACTAN	DONORDIO	SUKOINDO	5	2	6	6	4	1	0	Y	Y	Y	Y	Y	Y	Y	T
3	2d54b4e0	-2018-05-22	PARIO		DUSUN KARANGENGGOK	JAWA TIMUR	PACTAN	DONORDIO	SUKOINDO	5	2	6	6	4	2	1	0	Y	Y	Y	Y	Y	Y	T
4	2d54b4e0	-2018-05-22	PARIO		DUSUN KARANGENGGOK	JAWA TIMUR	PACTAN	DONORDIO	SUKOINDO	5	2	6	6	4	2	1	0	Y	Y	Y	Y	Y	Y	T
5	2d54b4e0	-2018-05-22	PARIO		DUSUN KARANGENGGOK	JAWA TIMUR	PACTAN	DONORDIO	SUKOINDO	5	2	6	6	4	2	1	0	Y	Y	Y	Y	Y	Y	T
6	1d40101e	-2018-05-25	MSKHM		PERHUTI	JAWA TIMUR	PACTAN	DONORDIO	CEMENG	16	1	1	3	0	0	0	0	Y	Y	Y	Y	Y	Y	T
7	2d54b4e0	-2018-05-22	PARIO		DUSUN KARANGENGGOK	JAWA TIMUR	PACTAN	DONORDIO	SUKOINDO	5	2	6	6	4	2	1	0	Y	Y	Y	Y	Y	Y	T
8	2d54b4e0	-2018-05-22	PARIO		DUSUN KARANGENGGOK	JAWA TIMUR	PACTAN	DONORDIO	SUKOINDO	5	2	6	6	4	2	1	0	Y	Y	Y	Y	Y	Y	T
9	2d54b4e0	-2018-05-22	WANDI		BELAH	JAWA TIMUR	PACTAN	DONORDIO	BELAH	2	5	6	6	4	2	1	0	Y	Y	Y	Y	Y	Y	T
10	2d54b4e0	-2018-05-13	WANDI		BELAH	JAWA TIMUR	PACTAN	DONORDIO	BELAH	2	5	6	6	4	3	1	0	Y	Y	Y	Y	Y	Y	T
11	2d54b4e0	-2018-05-12	ARIF HARYADI		BELAH	JAWA TIMUR	PACTAN	DONORDIO	BELAH	2	2	3	3	2	2	0	1	Y	Y	Y	Y	Y	Y	T
12	2d54b4e0	-2018-05-12	ARIF HARYADI		BELAH	JAWA TIMUR	PACTAN	DONORDIO	BELAH	2	2	3	3	2	2	0	1	Y	Y	Y	Y	Y	Y	T
13	d8c19872	-2018-05-04	SEMAN		ILOK	JAWA TIMUR	PACTAN	DONORDIO	CEMING	11	2	3	3	3	3	0	0	Y	Y	Y	Y	Y	Y	T
14	edc2f4e4	-2018-05-13	ISMAIDI		BELAH	JAWA TIMUR	PACTAN	DONORDIO	BELAH	2	2	3	3	3	2	0	0	Y	Y	Y	Y	Y	Y	T
15	3d001140	-2018-05-13	SEMAN		BELAH	JAWA TIMUR	PACTAN	DONORDIO	BELAH	11	2	3	3	3	3	0	0	Y	Y	Y	Y	Y	Y	T
16	4d0d0ef0	-2018-05-11	SUSYONO		TEKIN	JAWA TIMUR	PACTAN	DONORDIO	CEMING	12	1	3	3	3	3	0	0	Y	Y	Y	Y	Y	Y	T
17	4d0d0ef0	-2018-05-11	SUSYONO		TEKIN	JAWA TIMUR	PACTAN	DONORDIO	CEMING	12	1	3	3	3	3	0	0	Y	Y	Y	Y	Y	Y	T
18	4d0d0ef0	-2018-05-11	SUSYONO		TEKIN	JAWA TIMUR	PACTAN	DONORDIO	CEMING	12	1	3	3	3	3	0	0	Y	Y	Y	Y	Y	Y	T
19	2d54b4e0	-2018-05-13	WANDI		BELAH	JAWA TIMUR	PACTAN	DONORDIO	BELAH	2	5	6	4	4	3	1	0	Y	Y	Y	Y	Y	Y	T
20	2d54b4e0	-2018-05-13	WANDI		BELAH	JAWA TIMUR	PACTAN	DONORDIO	BELAH	2	5	6	4	4	3	1	0	Y	Y	Y	Y	Y	Y	T
21	2d54b4e0	-2018-05-12	ARIF HARYADI		BELAH	JAWA TIMUR	PACTAN	DONORDIO	BELAH	2	2	3	3	2	2	0	1	Y	Y	Y	Y	Y	Y	T
22	2d54b4e0	-2018-05-12	ARIF HARYADI		BELAH	JAWA TIMUR	PACTAN	DONORDIO	BELAH	2	2	3	3	2	2	0	1	Y	Y	Y	Y	Y	Y	T
23	2d54b4e0	-2018-05-12	ARIF HARYADI		BELAH	JAWA TIMUR	PACTAN	DONORDIO	BELAH	2	2	3	3	2	2	0	1	Y	Y	Y	Y	Y	Y	T
24	2d54b4e0	-2018-05-13	WANDI		BELAH	JAWA TIMUR	PACTAN	DONORDIO	BELAH	2	5	4	4	3	3	1	0	Y	Y	Y	Y	Y	Y	T
25	b17474e0	-2018-05-05	TUKINO		DSM GEDANGAN	JAWA TIMUR	PACTAN	DONORDIO	SUKOINDO	8	2	5	5	4	5	0	0	Y	Y	Y	Y	Y	Y	T
26	b17474e0	-2018-05-05	TUKINO		DSM GEDANGAN	JAWA TIMUR	PACTAN	DONORDIO	SUKOINDO	8	2	5	5	4	5	0	0	Y	Y	Y	Y	Y	Y	T
27	ba3803f2	-2018-04-09	HARYADI		KRAJAN LOR	JAWA TIMUR	PACTAN	DONORDIO	SEMAR	1	1	3	3	2	2	1	0	Y	Y	Y	Y	Y	Y	T
28	4d0d0ef0	-2018-05-10	KRAJAN LOR		DSM GEDANGAN	JAWA TIMUR	PACTAN	DONORDIO	SEMAR	1	1	3	3	2	2	1	0	Y	Y	Y	Y	Y	Y	T
29	83081133	-2018-05-09	SANI		SURUH	JAWA TIMUR	PACTAN	DONORDIO	CEMING	9	3	2	2	2	2	0	0	Y	Y	Y	Y	Y	Y	T
30	3d001140	-2018-05-19	SUKRMO		LEAHANG	JAWA TIMUR	PACTAN	DONORDIO	BELAH	5	2	3	3	2	2	0	1	0	Y	Y	Y	Y	Y	T
31	3d001140	-2018-05-19	SUKRMO		LEAHANG	JAWA TIMUR	PACTAN	DONORDIO	BELAH	5	2	3	3	2	2	0	1	0	Y	Y	Y	Y	Y	T
32	b17474e0	-2018-05-05	TUKINO		DSM GEDANGAN	JAWA TIMUR	PACTAN	DONORDIO	SUKOINDO	8	2	5	5	4	5	0	0	Y	Y	Y	Y	Y	Y	T
33	ba3803f2	-2018-04-09	HARYADI		KRAJAN LOR	JAWA TIMUR	PACTAN	DONORDIO	SEMAR	1	1	3	3	2	2	1	0	Y	Y	Y	Y	Y	Y	T
34	4d0d0ef0	-2018-05-02	ED SUPRANO		GOLO	JAWA TIMUR	PACTAN	DONORDIO	SEMAR	9	3	2	2	2	2	0	0	Y	Y	Y	Y	Y	Y	T
35	046412b6	-2018-05-15	MISYAN		TUNGSAU	JAWA TIMUR	PACTAN	DONORDIO	BELAH	3	2	2	2	2	2	0	0	Y	Y	Y	Y	Y	Y	T
36	65138446	-2018-05-02	KRAJAN KUL		JAWA TIMUR	PACTAN	DONORDIO	SEMAR	3	1	2	2	2	2	0	0	Y	Y	Y	Y	Y	Y	T	
37	3d001140	-2018-05-02	KRAJAN KUL		JAWA TIMUR	PACTAN	DONORDIO	SEMAR	9	1	4	3	3	3	0	0	Y	Y	Y	Y	Y	Y	T	
38	dfb729fe	-2018-05-02	ED SUPRANO		GOLO	JAWA TIMUR	PACTAN	DONORDIO	SEMAR	9	1	4	3	3	3	0	0	Y	Y	Y	Y	Y	Y	T
39	3d001140	-2018-05-02	ED SUPRANO		GOLO	JAWA TIMUR	PACTAN	DONORDIO	SEMAR	9	1	4	3	3	3	0	0	Y	Y	Y	Y	Y	Y	T
40	b17474e0	-2018-05-05	TUKINO		DSM GEDANGAN	JAWA TIMUR	PACTAN	DONORDIO	SUKOINDO	8	2	5	5	4	5	0	0	Y	Y	Y	Y	Y	Y	T
41	83081133	-2018-05-09	SANI		SURUH	JAWA TIMUR	PACTAN	DONORDIO	CEMING	9	3	2	2	2	2	0	0	Y	Y	Y	Y	Y	Y	T
42	3d001140	-2018-05-09	SAPRIAN		TUNGSAU	JAWA TIMUR	PACTAN	DONORDIO	SEMAR	3	2	2	2	2	2	0	0	Y	Y	Y	Y	Y	Y	T
43	ba3803f2	-2018-04-09	HARYADI		KRAJAN LOR	JAWA TIMUR	PACTAN	DONORDIO	SEMAR	1	1	3	3	2	2	1	0	Y	Y	Y	Y	Y	Y	T
44	dfb729fe	-2018-05-02	ED SUPRANO		GOLO	JAWA TIMUR	PACTAN	DONORDIO	SEMAR	9	1	3	3	2	2	1	0	Y	Y	Y	Y	Y	Y	T

Gambar 4.2: Data Indikator PIS-PK

Data indikator PIS-PK di ambil dari *database* yang telah di sediakan, kemudian data di konvert kedalam bentuk raw data dalam bentuk file .csv.

4.2.2 Proses Preprocessing

Data indikator PIS-PK yang telah diperoleh dari tahap sebelumnya, terbagi menjadi beberapa kelompok data, yakni data tanggal survei, nama kk, alamat, provinsi, kabupaten/kota, kecamatan, kelurahan, rt, rw dan 12 indikator PIS-PK. Selanjutnya dari masing-masing kelompok data tersebut akan dilakukan tahap selanjutnya untuk memilih data-data yang akan digunakan.

Bab 5

Kesimpulan dan Saran

5.1 Kesimpulan

5.2 Saran

Daftar Pustaka

- Adriani, M. and Wirjatmadi, B. (2012). Pengantar gizi kesehatan masyarakat.
- Adrifina, A., Putri, J. U., and Wicaksana, I. (2008). Pemilahan artikel berita dengan text mining. In *Proceeding, Seminar Ilmiah Nasional Komputer dan Sistem Intelijen (KOMMIT 2008)*. Gunadarma University.
- Aheto, J. M. K. and Dagne, G. A. (2014). Geostatistical analysis, web-based mapping and environmental determinants of under-five chronic malnutrition (stunting): Evidence from the 2014 ghana demographic and health survey. *Web-Based Mapping and Environmental Determinants of Under-Five Chronic Malnutrition (Stunting): Evidence from the*.
- Ahmad, A. (2017). Mengenal artificial intelligence, machine learning, neural network, dan deep learning. *J. Teknol. Indones.*, no. October, page 3.
- Al-Rahmad, A. H., Miko, A., and Hadi, A. (2013). Kajian stunting pada anak balita ditinjau dari pemberian asi eksklusif, mp-asi, status imunisasi dan karakteristik keluarga di kota banda aceh. *J Kesehatan Ilmiah Nasuwakes*, 6(2):169–184.
- Anwar, F., Khomsan, A., Mauludyani, A. V., and Ekawidyani, K. R. (2014). Masalah dan solusi stunting akibat kurang gizi di wilayah perdesaan.
- Apriluana, G. and Fikawati, S. (2018). Analisis faktor-faktor risiko terhadap kejadian stunting pada balita (0-59 bulan) di negara berkembang dan asia tenggara. *Media Penelitian dan Pengembangan Kesehatan*, 28(4):247–256.
- Arel, I., Rose, D. C., and Karnowski, T. P. (2010). Deep machine learning-a new frontier in artificial intelligence research [research frontier]. *IEEE computational intelligence magazine*, 5(4):13–18.

- Ariati, L. I. P. (2019). Faktor-faktor resiko penyebab terjadinya stunting pada balita usia 23-59 bulan. *Oksitosin: Jurnal Ilmiah Kebidanan*, 6(1):28–37.
- Ariestya, W. W., Astuti, I., and Wiryan, I. M. (2018). Preprocessing for crawler of short message social media. In *2018 Third International Conference on Informatics and Computing (ICIC)*, pages 1–6. IEEE.
- Arisman, M. (2010). Gizi dalam daur kehidupan: Buku ajar ilmu gizi, edisi 2. Jakarta: EGC.
- Aulia, A., Puspitasari, D. I., Huzaimah, N., Wardita, Y., and Sandi, A. P. (2021). Stunting dan faktor ibu. *Journal Of Health Science (Jurnal Ilmu Kesehatan)*, 6(1):27–31.
- Bengio, Y. (2009). Learning deep architectures for ai. *Found Trends Mach Learn.* 2(1): 1-127.
- Cendana, M. and Permana, S. D. H. (2019). Pra-pemrosesan teks pada grup whatsapp untuk pemodelan topik. *Jurnal Mantik Penusa*, 3(3).
- Darujati, C. and Gumelar, A. B. (2012). Pemanfaatan teknik supervised untuk klasifikasi teks bahasa indonesia. *Jurnal Bandung Text Mining*, 16(1):5–1.
- Du, T. and Shanker, V. (2009). Deep learning for natural language processing. *Eecis. Udel. Edu*, pages 1–7.
- Feldman, R., Sanger, J., et al. (2007). *The text mining handbook: advanced approaches in analyzing unstructured data*. Cambridge university press.
- Glick, M., Klon, A. E., Acklin, P., and Davies, J. W. (2004). Enrichment of extremely noisy high-throughput screening data using a naive bayes classifier. *Journal of biomolecular screening*, 9(1):32–36.
- Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., Courville, A., and Bengio, Y. (2014). Generative adversarial nets. *Advances in neural information processing systems*, 27.
- Han, J. and Kamber, M. (2006). Data mining: Concepts and techniques, 2nd editionmorgan kaufmann publishers. *San Francisco, CA, USA*.
- Heryadi, Y. and Irwansyah, E. (2020). *Deep Learning: Aplikasinya di Bidang Geospasial*. AWI Technology Press.

- Hinton, G. E., Osindero, S., and Teh, Y.-W. (2006). A fast learning algorithm for deep belief nets. *Neural computation*, 18(7):1527–1554.
- Husein, A. M., Arsyal, M., Sinaga, S., and Syahputa, H. (2019). Generative adversarial networks time series models to forecast medicine daily sales in hospital. *Sinkron: jurnal dan penelitian teknik informatika*, 3(2):112–118.
- Indonesia, K. K. R. (2016). Peraturan menteri kesehatan republik indonesia nomor 39 tahun 2016. *Kementerian Kesehatan*.
- Jordan, M. I. and Mitchell, T. M. (2015). Machine learning: Trends, perspectives, and prospects. *Science*, 349(6245):255–260.
- Karthikeyan, A. and Priyakumar, U. (2022). Artificial intelligence: machine learning for chemical sciences. *Journal of Chemical Sciences*, 134(1):1–20.
- Kemenkes, R. (2011). Kementerian kesehatan ri. *Bul. Jendela, Data dan Inf. Kesehat. Epidemiol. Malar. di Indones. Jakarta Bhakti Husada*.
- Kemiskinan, T. N. P. P. (2017). 100 kabupaten. *Kota Prioritas Untuk Intervensi Anak Kerdil (Stunting)*.
- Lei, K., Qin, M., Bai, B., Zhang, G., and Yang, M. (2019). Gcn-gan: A non-linear temporal link prediction model for weighted dynamic networks. In *IEEE INFOCOM 2019-IEEE Conference on Computer Communications*, pages 388–396. IEEE.
- Liddy, E. D. and Liddy, J. H. (2001). An nlp approach for improving access to statistical information for the masses.
- Maryana, F., Kurniawati, A., and Agusten, D. (2018). Term frequency method for automated text summarization application of indonesian news article. In *2018 Third International Conference on Informatics and Computing (ICIC)*, pages 1–7. IEEE.
- Metz, L., Poole, B., Pfau, D., and Sohl-Dickstein, J. (2016). Unrolled generative adversarial networks. *arXiv preprint arXiv:1611.02163*.
- Mitra, M. (2015). Permasalahan anak pendek (stunting) dan intervensi untuk mencegah terjadinya stunting (suatu kajian kepustakaan). *Jurnal Kesehatan Komunitas*, 2(6):254–261.

- Nájera, H. E. C. (2019). Small-area estimates of stunting. mexico 2010: Based on a hierarchical bayesian estimator. *Spatial and Spatio-temporal Epidemiology*, 29:1–11.
- Ng, A. (2016). What artificial intelligence can and can't do right now. *Harvard Business Review*, 9(11).
- Polamuri, S. R., Srinivas, K., and Mohan, A. K. (2021). Multi-model generative adversarial network hybrid prediction algorithm (mmgan-hpa) for stock market prices prediction. *Journal of King Saud University-Computer and Information Sciences*.
- Praramadhan, A. A. and Saputra, G. E. (2021). Cycle generative adversarial networks algorithm with style transfer for image generation. *arXiv preprint arXiv:2101.03921*.
- Primartha, R. (2018). Belajar machine learning; teori dan praktik.
- Pustejovsky, J. and Stubbs, A. (2012). *Natural Language Annotation for Machine Learning: A guide to corpus-building for applications*. " O'Reilly Media, Inc.".
- Rahayu, A., Yulidasari, F., Putri, A. O., and Rahman, F. (2015). Riwayat berat badan lahir dengan kejadian stunting pada anak usia bawah dua tahun. *Kesmas: Jurnal Kesehatan Masyarakat Nasional (National Public Health Journal)*, 10(2):67–73.
- RI, K. (2016). Situasi balita pendek. *Infodatin Pusat Data dan Informasi Kemenkes RI*.
- RI, K. (2018). Kementerian kesehatan republik indonesia. kementerian kesehatan ri. sekretariat r jenderal. rencana strategis kementerian kesehatan tahun rencana strategis kementerian kesehatan tahun.
- Rianto, R., Mutiara, A. B., Wibowo, E. P., and Santosa, P. I. (2020). Improving the accuracy of text classification using stemming method, a case of informal indonesian conversation.
- Rianto Mutiara, A., Wibowo, E., and Santosa, P. (2021). Improving stemming techniques for non-formal indonesian sentences using incorbiz. icic express letter.

- Robandi, I. (2021). *ARTIFICIAL INTELLIGENCE: Mengupas Rekayasa Kecerdasan Tiruan*. Penerbit Andi.
- Romadoniyah, R., Rejeki, D. S. S., and Pramatama, S. (2022). Literatur review: Faktor-faktor yang mempengaruhi kejadian stunting pada balita di negara berkembang. *Jurnal Pendidikan Tambusai*, 6(2):11647–11656.
- Rosid, M. A., Fitriani, A. S., Astutik, I. R. I., Mulloh, N. I., and Gozali, H. A. (2020). Improving text preprocessing for student complaint document classification using sastrawi. In *IOP Conference Series: Materials Science and Engineering*, volume 874, page 012017. IOP Publishing.
- Russell, S. and Norvig, P. (1995). *Prentice Hall series in artificial intelligence*. Prentice Hall Englewood Cliffs, NJ:.
- Russell, S. J. (2010). *Artificial intelligence a modern approach*. Pearson Education, Inc.
- Samuel, A. L. (1959). Some studies in machine learning using the game of checkers. *IBM Journal of research and development*, 3(3):210–229.
- Saputri, R. A. (2019). Upaya pemerintah daerah dalam penanggulangan stunting di provinsi kepulauan bangka belitung. *Jdp (Jurnal Dinamika Pemerintahan)*, 2(2):152–168.
- Saxena, D. and Cao, J. (2019). D-gan: Deep generative adversarial nets for spatio-temporal prediction. *arXiv preprint arXiv:1907.08556*.
- Schmidt, C. W. (2014). Beyond malnutrition: the role of sanitation in stunted growth.
- Soleymani, F. and Paquet, E. (2022). Long-term financial predictions based on feynman-dirac path integrals, deep bayesian networks and temporal generative adversarial networks. *Machine Learning with Applications*, 7:100255.
- Surjandari, I., Rosyidah, A., Zulkarnain, Z., and Laoh, E. (2018). Mining web log data for news topic modeling using latent dirichlet allocation. In *2018 5th International Conference on Information Science and Control Engineering (ICISCE)*, pages 331–335. IEEE.

- Suyanto, K., Ramadhani, N., and Mandala, S. (2019). Deeplearning moder-nisasi machine learning untuk big data. *Bandung-Indonesia: Informatika Bandung*.
- Umiyah, A. and Hamidiyah, A. (2021). Karakteristik anak dengan kejadian stunting. *Oksitosin: Jurnal Ilmiah Kebidanan*, 8(1):66–72.
- UNICEF. (2007). *A World Fit for Us: The Children's Statement from the UN Special Session on Children: Five Years on*. UNICEF.
- Volkhonskiy, D., Borisenko, B., and Burnaev, E. (2016). Generative adversarial networks for image steganography.
- Witten, I. H., Frank, E., Hall, M. A., Pal, C. J., and DATA, M. (2005). Practical machine learning tools and techniques. In *DATA MINING*, volume 2, page 4.
- Zhang, K., Zhong, G., Dong, J., Wang, S., and Wang, Y. (2019). Stock market prediction based on generative adversarial network. *Procedia computer science*, 147:400–406.

LAMPIRAN

TERMINOLOGI

No	Kata	Arti
1.		
2.		
3.		
4.		
5.		
6.		
7.		
8.		

RIWAYAT HIDUP



IDENTITAS DIRI

Nama Lengkap	I Komang Sugiarktha
Tempat Tanggal Lahir	Pagesangan, 26 Maret 1992
Jenis Kelamin	Laki-laki
Pekerjaan	Dosen
NIP	
Jabatan Struktural	Staff Incubator Business Center Universitas Gunadarma
Alamat	Jl. Haji Namat No.14 Akses UI, Kelapa Dua, Depok
Alamat E-mail	sugiarktha26@gmail.com

RIWAYAT PENDIDIKAN

Tahun	Jenjang	Jurusan
2016	S2	Magister Manajemen Sistem Informasi, Universitas Gunadarma
2014	S1	Sistem Informasi, Universitas Gunadarma
2010	SMA	SMK Negeri 3 Mataram
2007	SMP	SMP Negeri 11 Mataram
2004	SD	SD Negeri 35 Mataram

RIWAYAT PEKERJAAN

Tahun	Pekerjaan
2016 - Sekarang	Dosen, Universitas Gunadarma
2020 - Sekarang	Senior Programmer SIASN, Badan Kepegawaian Negara
2019 - Sekarang	Senior Mobile Programmer Aplikasi Keluarga Sehat, Kementerian Kesehatan
2019 - Sekarang	Team Pengembang Materi dan Pengajar VSGA Digital Talent Scholarship, Kominfo
2014 - 2016	Freelance Developer
2011 - 2014	IT Support, PT Media Global Indonesia