



OPTIMASI DESAIN PRODUK MELALUI PENGENALAN
FAKTOR EMOSIONAL DENGAN PENDEKATAN
KANSEI ENGINEERING DAN *GENERATIVE AI*

PROPOSAL KUALIFIKASI

ARIFIA NOOR RIWANTI
99223118

PROGRAM DOKTOR TEKNOLOGI INFORMASI
UNIVERSITAS GUNADARMA
2024

Daftar Isi

Daftar isi	i
1 Pendahuluan	
1.1 Latar Belakang Penelitian	1
1.2 Rumusan Masalah Penelitian	7
1.3 Batasan Penelitian	7
1.4 Tujuan Penelitian	8
1.5 Kontribusi dan Manfaat.....	8
2 Tinjauan Pustaka	
2.1 Teknologi Informasi (TI)	10
2.1.1 Peran Teknologi Informasi (TI)	10
2.2 Konsep Dasar <i>Artificial Intelligence</i> (AI).....	11
2.2.1 Pemanfaatan AI dalam Bidang Industri	12
2.3 <i>Machine Learning</i> (ML)	13
2.3.1 Algoritma pada <i>Machine Learning</i> (ML).....	14
2.4 <i>Deep Learning</i> (DL)	15
2.4.1 <i>Convolutional Neural Networks</i> (CNN)	16
2.5 <i>Generative Adversarial Network</i> (GAN).....	17
2.5.1 <i>Training</i> GAN	18
2.5.2 Aplikasi GAN.....	19
2.5.3 Jenis-Jenis GAN	20
2.6 <i>Text Mining</i>	20
2.6.1 Klasifikasi Teks	21
2.6.2 Ekstraksi Fitur dan Pembobotan.....	22

2.7	Citra.....	23
2.7.1	Citra Digital.....	24
2.7.2	Jenis-Jenis Citra.....	25
2.7.3	Pengolahan Citra Digital.....	28
2.8	Produk	29
2.8.1	Proses Pengembangan Produk.....	30
2.8.2	Kebutuhan Pelanggan (<i>Customer Needs</i>).....	31
2.9	<i>Kansei Engineering</i> (KE)	31
2.9.1	Tipe <i>Kansei Engineering</i>	32
2.9.2	Metodologi <i>Kansei Engineering</i>	33
2.10	Penelitian Terdahulu	34
2.11	<i>Roadmap</i> Penelitian	42
3	Metodologi	
3.1	Data Ulasan Produk.....	45
3.2	<i>Pre-Processing</i>	46
3.2.1	Pembersihan Data.....	46
3.2.2	Tokenisasi	47
3.2.3	<i>Part of Speech Tagging</i>	47
3.2.4	Lemmatisasi.....	49
3.2.5	Penghapusan <i>Stop Words</i>	49
3.3	Ekstraksi Teks	49
3.3.1	<i>Term Frequency-Inverse Document Frequency</i> (TF-IDF).....	50
3.3.2	Pengumpulan Kata <i>Kansei</i>	51

3.4	Reduksi Kata <i>Kansei</i>	51
	3.4.1 <i>Principal Component Analysis</i>	51
3.5	<i>Dataset</i> Gambar Produk	52
	3.5.1 Pengumpulan Gambar Produk.....	52
	3.5.2 <i>Pre-Processing</i> Gambar Produk.....	52
3.6	Pelabelan Data Gambar Produk	54
	3.6.1 Kuesioner <i>Semantic Differential 2</i>	54
	3.6.2 Pengenalan Gambar Produk	54
3.7	Proses Pembuatan Desain.....	56
	3.7.1 Arsitektur Dasar GAN.....	56
	3.7.2 Pelatihan Model GAN	60
	3.7.3 Evaluasi Model GAN	61
3.8	Verifikasi Desain.....	61

Daftar Pustaka

BAB 1

PENDAHULUAN

1.1 Latar Belakang Penelitian

Teknologi Informasi (TI) telah menjadi jalan dalam meningkatkan efisiensi di berbagai bidang industri. Dalam sektor manufaktur, TI memainkan peran penting dalam otomatisasi proses produksi (T. Yang, Yi, Lu, Johansson, & Chai, 2021), kontrol kualitas (Kaniappan Chinnathai & Alkan, 2023), manajemen rantai pasok (Tanveer, Kremantzis, Roussinos, et al., 2023), perawatan prediktif (Ciancio, Homri, Dantan, Siadat, & Convain, 2022) hingga perancangan produk (Huang, 2022). Sistem otomasi canggih yang didukung oleh TI memungkinkan suatu proses berjalan secara efisien. Membahas lebih dalam mengenai desain produk, TI membuka jalan untuk inovasi dengan hadirnya kecerdasan buatan. Hal tersebut mengoptimalkan waktu proses insinyur dan desainer untuk menciptakan konsep produk serta purwarupa virtual sebelum memasuki tahap produksi (Li, Su, Zhang, & Bai, 2021).

Kecerdasan buatan atau *Artificial Intelligence* (AI) telah mendorong terobosan di berbagai sektor industri. Perkembangan dalam *Machine Learning* (ML) memungkinkan mesin belajar dari data yang besar, sehingga menjadi dasar pengembangan sistem cerdas. ML yang dikenal saat ini terdiri dari supervised learning, unsupervised learning, dan reinforcement learning. *Supervised learning* melibatkan pengajaran model menggunakan data yang telah diberi label, sedangkan *unsupervised learning* melibatkan pembelajaran dari data tanpa label (Hasti, Tibshirani, & Friedman, 2009). Berbeda dengan *supervised* dan *unsupervised learning*, *reinforcement learning* memanfaatkan konsep pemberian imbalan atau hukuman dalam pengambilan keputusan mengambil keputusan, sehingga kinerja model dapat diperbaiki seiring berjalannya waktu (Richard S. Sutton, 2015). Cabang lanjutan dari ML adalah *Deep Learning* (DL) yang menggunakan *Neural Networks* (NN) dalam memodelkan dan memproses data. *Neural Networks*, terutama *Convolutional Neural Networks* (CNN) banyak digunakan dalam

pengolahan citra (Rahman, Winarko, & Mustofa, 2022), sementara pengolahan teks dengan *Natural Language Processing* (NLP) telah banyak dikembangkan untuk pemahaman bahasa manusia yang memungkinkan sistem untuk belajar dari fitur kompleks dan abstrak (Hosgurmah, Petli, & Jalihal, 2022). Dalam industri kesehatan, DL telah banyak diaplikasikan untuk diagnosis medis dan identifikasi pola genetik (Zhang, Wang, Cai, et al., 2023). Dalam bidang manufaktur, DL banyak digunakan dalam sistem pendukung keputusan berbasis data (Simeone, Caggiano, Deng, & Boun, 2020; Zhu, Ji, Zhang, & Sun, 2020). Pengaplikasian DL lainnya yaitu mencakup desain produk inovatif dengan kemampuannya untuk menciptakan variasi model dan mengenali tren desain (Wu & Zhang, 2022).

Desain produk inovatif yang mampu memenuhi permintaan pasar yang terus berkembang menjadi perhatian utama produsen saat ini. Produk yang dibuat hanya berdasarkan inspirasi dari desainer seringkali belum memenuhi keinginan dan kebutuhan konsumen (Nagamachi, 1995). Bagi seorang perancang produk penting untuk menerjemahkan persepsi konsumen dengan tepat. Rekayasa Kansei atau *Kansei engineering* (KE) yang juga dikenal sebagai rekayasa afektif, muncul sebagai metode desain berorientasi konsumen yang bertujuan menerjemahkan perasaan dan kesan konsumen terhadap produk ke dalam elemen desain. Istilah "*Kansei*" berasal dari Jepang di mana merujuk pada ekspresi emosional yang dipicu oleh stimulus dari sebuah produk (Nagamachi, 1995). Ekspresi emosional yang diidentifikasi dalam Kansei engineering disebut sebagai atribut Kansei (W. M. Wang, Wang, Li, Tian, & Tsui, 2019). Atribut Kansei digunakan untuk membantu desainer menciptakan produk yang sesuai dengan preferensi emosional konsumen. KE terbukti efektif dalam mengidentifikasi dan menerjemahkan preferensi konsumen serta telah memberikan kontribusi besar dalam pembuatan produk terkenal seperti Mazda dengan mobil sport bernama "Miyata" (Nagamachi, 1995), *Shampoo by Milbon*, desain rumah, dapur dan toilet (Nagamachi, 2008), Fuji film, kosmetik seperti Shiseido hingga desain bra wanita dengan nama "*Good-up Bra*" by *Wacoal* (Nagamachi, 2002).

Pendekatan KE tradisional untuk mendapatkan kata kansei umumnya dilakukan melalui metode seperti survei, wawancara dan diskusi kelompok

terhadap produk tertentu, namun memiliki keterbatasan pada jumlah data, membutuhkan banyak waktu dan sukarelawan (Liu, Wu, Chen, & Hu, 2023). Pengumpulan data dalam jumlah besar dapat menjadi solusi di era *big data* saat ini. Salah satu sumber data yang biasa digunakan untuk menangkap kebutuhan pasar adalah ulasan pelanggan pada situs belanja daring. Ulasan pelanggan mampu menggambarkan emosi pengguna secara akurat karena dibuat setelah pembelian atau pemakaian produk (W. M. Wang et al., 2019). Berbeda dengan pendekatan tradisional yang biasanya melibatkan uji coba sampel, di mana belum ada keputusan pembelian atau rasa kepemilikan.

Fokus pada desain visual produk memungkinkan adanya inovasi tanpa terhalang oleh keterbatasan bahan yang mungkin tidak tersedia atau dapat dikustomisasi sesuai target pasar karena bergantung pada daya beli pengguna. Dalam fase perancangan dan pengembangan produk, salah satu prioritas utama terletak pada pengembangan desain visual dan model produk yang inovatif dan menarik (Huang, 2022). Penelitian Chan, Kwong, Wongthongtham, et al., (2020) menunjukkan bahwa desain yang menarik dan relevan dengan tren terkini sering kali diutamakan karena konsumen cenderung menilai produk dari penampilan luarnya seperti tekstur atau motif, bentuk, warna, dan gaya produk yang dapat membangkitkan perasaan positif. Desain yang menarik secara visual merupakan faktor pertama yang dapat memicu keinginan pembelian. Penelitian Crollic, Zheng, Hoegg, & Alba (2019) juga menjelaskan bahwa estetika dan tampilan dari suatu produk bahkan mampu membuat penilaian konsumen menjadi bias terhadap fungsionalitas dan bahan. Material dan bahan dapat menjadi pertimbangan setelah desain dari produk telah dikonsepkan dengan jelas atau dapat ditentukan beriringan pada tahap awal pengembangan produk (Tomičić-Pupek, Srpak, Havaš, & Srpak, 2020), sehingga memungkinkan adanya penyesuaian di mana desain visual awal dapat dimodifikasi dengan variasi material yang ada. Variasi material dapat disesuaikan atau diubah pada tahap berikutnya, sejalan dengan ketersediaan, kekuatan, ketahanan, biaya, dan teknologi produksi yang tersedia berdasarkan sektor industri terkait (Maidin, Sapuan, Mohammad Taha, & Zuhri, 2024). Hal ini

menunjukkan bahwa proses desain visual produk dan pemilihan material mungkin terjadi bersamaan namun dengan umpan balik dari masing-masing ranah.

Penelitian ini berangkat dari keinginan mendukung program pemerintah dalam mengurangi penggunaan plastik sekali pakai dan mendukung upaya global dalam mengurangi limbah plastik. Selaras dengan Peraturan Presiden No. 97 Tahun 2017 Tentang Kebijakan Dan Strategi Nasional Pengelolaan Sampah, yang menetapkan langkah-langkah yang harus diambil dalam mengurangi sampah plastik, termasuk plastik sekali pakai, serta Peraturan Gubernur DKI Jakarta No. 142 Tahun 2019 Tentang Kewajiban Penggunaan Kantong Belanja Ramah Lingkungan yang menegaskan penggunaan alternatif selain kantong plastik sekali pakai sebagai bentuk upaya mendukung keberlanjutan lingkungan. Kebijakan-kebijakan tersebut dapat membuka peluang bagi usaha mikro, kecil, dan menengah (UMKM) lokal untuk berinovasi dalam memproduksi tas belanja versi lokal.

Bagi masyarakat, kesadaran membawa tas belanja tidak cukup jika hanya diatur melalui peraturan pemerintah. Kesadaran diri diperlukan agar kontrol perilaku yang dirasakan (*Perceived Behavioral Control*) yaitu berhubungan dengan keyakinan seseorang tentang kemampuannya untuk melakukan tindakan tertentu (Muposhi, Mpinganjira, & Wait, 2021; B. Wang & Li, 2022) dapat memiliki pengaruh terhadap niat membawa tas belanja yang dapat digunakan kembali. Desain yang sesuai dengan preferensi pengguna akan meningkatkan daya tarik dan pengalaman emosional dalam menggunakan tas belanja. Masyarakat akan lebih cenderung menggunakan tas belanja secara rutin sebagai kebiasaan sehari-hari ketika telah menyadari manfaat nyata yang diberikan, sehingga akan tercapai pengurangan kantong plastik sekali pakai dan kebiasaan masyarakat yang lebih ramah lingkungan dan berkelanjutan.

Pemanfaatan AI, khususnya melalui *text mining* dan *Natural Language Processing* (NLP) dapat meningkatkan kemampuan KE. *Text mining* mampu mengekstraksi informasi berharga dari teks yang tidak terstruktur, seperti ulasan produk daring. Integrasi *text mining* dan KE dalam menangkap data emosional pengguna melalui ulasan online telah dieksplorasi oleh beberapa peneliti. Du, Zhang, Cai, & Park (2024) dalam penelitiannya membuktikan bahwa kata *kansei*

dapat diperoleh secara objektif melalui *text mining* pada ulasan produk. Sebelumnya, Liu et al. (2023) mengusulkan metode TF-EPA untuk ekstraksi pasangan kata kansei dan mengembangkan model jaringan syaraf untuk pemetaan parameter produk dan nilai evaluasi *kansei*. Masih berkaitan dengan ekstraksi kata, penelitian Z. Li, Tian, Wang, dan Wang (2020) juga memperkenalkan pendekatan *opinion mining* untuk ekstraksi respon afektif dari ulasan pelanggan *e-commerce*.

Arsitektur DL yang sering digunakan dalam pengolahan citra yaitu *Generative AI*. Berdasarkan konteks perancangan produk, tipe *Generative AI* yaitu *Generative Adversarial Network* (GAN) dapat digunakan untuk menghasilkan variasi desain otomatis dan membantu tim desain untuk menjelajahi opsi desain dengan lebih cepat dan efisien (Kaji, Takenouchi, & Tokumaru, 2020). Hal ini memungkinkan eksplorasi konsep-konsep baru dan membuka peluang untuk menciptakan produk-produk yang tidak hanya fungsional tetapi juga estetis. Arsitektur GAN pertama kali muncul dan diperkenalkan oleh Goodfellow pada tahun 2014. GAN merupakan arsitektur *deep learning* yang memungkinkan pembelajaran model untuk menghasilkan data baru yang realistis dengan cara mempertandingkan dua jaringan *neural*, yaitu generator dan diskriminator (Goodfellow, 2014). Pemanfaatan GAN dalam pembuatan gambar terbukti efektif dalam berbagai bidang, terutama dalam industri kreatif dan desain. GAN mampu menghasilkan pola kerajinan keramik (S. S. C. Chen, Cui, Tan, et al., 2020), menciptakan desain fashion (L. Chen, Fang, & Chen, 2021), dan motif batik inovatif dengan variasi yang beragam (Khalida, 2022).

Pemanfaatan integrasi GAN dan KE menawarkan peluang untuk mengembangkan kreativitas desain sesuai dengan preferensi konsumen. Li et al. (2021) mengusulkan kerangka kerja generasi konsep produk berbasis *deep learning* dan *Kansei Engineering* (PCGA-DLKE) dengan studi kasus bor tangan dan helm sepeda. Arsitektur GAN yang digunakan yaitu PD-GAN merupakan modifikasi dari ResNet dan DCGAN. Kelebihan penelitian ini yaitu mampu mengembangkan arsitektur ResNet-18 menjadi PAR-ResNet sebagai pengenalan preferensi afektif. Hasilnya menunjukkan bahwa PAR-ResNet memiliki akurasi yang lebih tinggi yaitu sebesar 87.10% jika dibandingkan dengan Alex-Net, VGG-11 dan VGG-16.

Kekurangan penelitian terletak pada proses augmentasi data yang masih dilakukan secara manual dengan perangkat lunak desain seperti Photoshop. Penelitian Wu & Zhang (2022) menggunakan arsitektur ResNet-50 untuk percobaan pengenalan gambar payung kertas minyak klasik. Hasilnya menunjukkan bahwa tingkat efektifitas dan akurasi dari pengenalan gambar produk sebesar 94.3%. Generasi desain payung kertas minyak menggunakan DCGAN. Kelebihan penelitian ini yaitu dengan memanfaatkan DCGAN terbukti bahwa desain payung yang dihasilkan bermakna untuk produksi berdasarkan verifikasi desainer produk terhadap hasil generasi gambar. Kekurangan penelitian terletak pada kurangnya kemampuan jaringan di mana ukuran gambar asli sekitar 600×600 piksel, sedangkan model menghasilkan gambar sebesar 64×64 piksel dalam menghasilkan gambar, sehingga banyak detail gambar yang tidak dapat terlihat. Penelitian T. Wang, Ma, & Yang (2023) menggunakan arsitektur ResNet-34 untuk percobaan pengenalan gambar desain pola anyaman dengan tingkat akurasi pengenalan pola sebesar 95.92%. Kelebihan penelitian ini yaitu mengkombinasikan pelatihan DCGAN dengan desain pola desain dari desainer profesional, sehingga mendapatkan hasil yang lebih jelas dan detail. Kekurangan penelitian ini diantaranya penggunaan dataset yang masih tergolong berskala kecil. C. Yang, Zhou, Zhu, Yu, & Wu (2021) menggunakan model generasi gambar pintar dengan kombinasi DCGAN dan Conditional GAN untuk menghasilkan gambar desain sepatu. Arsitektur VGGNet-16 digunakan dalam pengenalan gambar dengan tingkat akurasi rata-rata sebesar 79%. Kelebihan penelitian ini yaitu menggunakan dataset yang cukup besar, UT Zappos 50K yang berisi 50,025 gambar sepatu dari berbagai merek. Kekurangan penelitian terletak pada ketergantungan pada label secara manual dan masih terdapat sejumlah kecil gambar yang tidak berhasil dibentuk.

Penelitian terdahulu menunjukkan beberapa kekurangan dalam pembuatan gambar desain, terutama dalam kualitas dan resolusi gambar yang dihasilkan. Gambar dengan resolusi rendah sering kali tidak mampu menyampaikan informasi visual yang diperlukan untuk mendukung proses desain yang efektif. Kekurangan ini menghambat kemampuan perancang produk dalam memperoleh ide atau

inspirasi yang berharga dari hasil pembuatan gambar tersebut. Penelitian lebih lanjut diperlukan untuk mengatasi masalah ini dengan fokus pada peningkatan kualitas dan resolusi gambar yang dihasilkan oleh GAN.

Penelitian ini mengembangkan pendekatan KE dengan *text mining* untuk mengekstraksi informasi emosional dari teks ulasan produk. *Generative AI* yaitu GAN juga digunakan untuk optimasi proses perancangan produk, sehingga mampu menghasilkan variasi desain visual tas belanja yang berkualitas berdasarkan atribut *kansei*. Fokus penelitian ini adalah pada pengembangan desain visual tas belanja yang mencakup model, warna, motif, dan elemen terkait lainnya. Teknologi KE dan GAN memberikan manfaat besar bagi perancang produk dalam memberikan ide dan inspirasi desain. Teknologi ini juga mendukung UMKM lokal untuk mengetahui tren pasar terbaru dan mempercepat proses perancangan produk. UMKM dengan ini diharapkan dapat meningkatkan efisiensi produksi, dan responsivitas terhadap permintaan pasar, sehingga mampu bersaing dengan industri besar.

1.2 Rumusan Masalah Penelitian

Berdasarkan uraian pada latar belakang penelitian, maka dapat diidentifikasi rumusan masalah sebagai berikut:

1. Bagaimana menentukan atribut *Kansei* yang relevan dengan preferensi konsumen untuk desain tas belanja?
2. Bagaimana mengembangkan metode *Kansei Engineering* untuk optimasi desain produk tas belanja berbasis AI?
3. Bagaimana membangun sebuah algoritma integrasi *Kansei Engineering* dengan *Generative AI* untuk menghasilkan desain tas belanja yang sesuai dengan preferensi pengguna?

1.3 Batasan Penelitian

Beberapa batasan dalam penelitian ini adalah:

1. Menggunakan data ulasan produk tas belanja yang tersedia di *e-commerce* Tokopedia. Data diperoleh melalui teknik scraping, yang memungkinkan

pengumpulan informasi ulasan produk secara otomatis dari situs belanja daring tersebut.

2. Menggunakan citra berwarna 2D tas belanja yang dikumpulkan melalui teknik *scraping* dari berbagai *website*.
3. Fokus penelitian pada pengembangan desain visual tas belanja menggunakan arsitektur GAN sebagai rekomendasi ide bagi perancang produk.

1.4 Tujuan Penelitian

Berikut ini merupakan tujuan penelitian yang akan ingin dicapai dari penelitian ini.

1. Menghasilkan jenis atribut *Kansei* yang relevan dengan preferensi dan respon emosional konsumen untuk desain tas belanja.
2. Menghasilkan metode *Kansei* berbasis AI untuk optimasi proses desain tas belanja.
3. Menghasilkan algoritma *Kansei engineering Generative AI* yang dapat mengoptimalkan desain tas belanja sesuai dengan preferensi pengguna.

1.5 Kontribusi dan Manfaat

1. Penelitian ini memberikan kontribusi dari sisi keilmuan mengembangkan metode dan algoritma *Kansei Engineering Generative AI* untuk mengoptimalkan perancangan desain visual tas belanja sesuai dengan preferensi pengguna.
2. Kontribusi dari sisi teknologi dengan mengembangkan sistem desain produk yang inovatif melalui *Kansei Engineering Generative AI* sebagai alat bantu yang efektif dalam industri desain produk.
3. Penelitian ini juga menghadirkan berbagai manfaat bagi beberapa pihak. Pertama, menghadirkan ide dan inspirasi desain bagi perancang produk. Kedua, bagi produsen atau UMKM di mana penelitian ini membantu dalam memahami kebutuhan pasar dengan lebih baik dan mengoptimalkan proses perancangan model tas belanja. Terakhir bagi masyarakat, penelitian ini menawarkan pilihan desain tas belanja yang beragam, yang diharapkan dapat

mendorong perilaku ramah lingkungan dan mengurangi ketergantungan pada tas plastik sekali pakai.

BAB 2

TINJAUAN PUSTAKA

2.1. Teknologi Informasi (TI)

Teknologi informasi (TI) terdiri dari dua kata penyusun yaitu teknologi dan informasi dengan definisi sebagai ide, rancang bangun, berpikir inovatif dan kebahasaan, namun teknologi juga dapat dikatakan sebagai alat untuk memproses dan menyimpan informasi, sedangkan informasi memiliki kaitan erat dengan data, di mana data pada dasarnya adalah suatu fakta, kejadian berita, fenomena, dan hal sejenisnya yang dapat diproses sehingga menghasilkan informasi (Darmawan, 2012).

TI merujuk pada pemanfaatan sistem komputer dan perangkat lunak untuk mengelola dan memproses informasi serta memfasilitasi kolaborasi inovatif, sehingga memungkinkan integrasi data, analisis, dan komunikasi yang efisien antar tim (Y. Li, Wang, Li, & Zhao, 2007). Pemanfaatan TI juga memungkinkan terjadinya integrasi pengetahuan lintas perusahaan yang membantu memodelkan proses inovasi kolaboratif. Proses inovasi dapat dijadikan referensi umum dan bertransformasi dengan mulus ke fase rekayasa. TI membantu memastikan keterlibatan efektif semua pemangku kepentingan dari awal hingga akhir proses (Mollahassani, Gries, Forte, & Göbel, 2022).

2.1.1 Peran Teknologi Informasi

Peran TI di era industri 4.0 merupakan hal yang tidak dapat dipisahkan dalam segala aspek kehidupan seperti dalam bidang pendidikan, masyarakat, manajemen bisnis, pemerintahan dan industri. Bidang pendidikan telah memanfaatkan berbagai macam teknologi seperti penggunaan komputer serta pembelajaran dan ujian daring yang didorong pula dengan kemunculan COVID-19. Peran dalam bidang manajemen dan bisnis salah satunya yaitu dalam penggunaan sistem informasi manajemen yang mana telah dimanfaatkan dalam perusahaan perdagangan barang maupun jasa. Bidang kesehatan juga tidak terlepas dari pemanfaatan TI yaitu kecerdasan buatan telah digunakan dalam mendiagnosa penyakit, penentuan obat

serta menganalisis keadaan organ tubuh manusia. Kepolisian sebagai garda terdepan dalam melindungi masyarakat telah menggunakan berbagai TI seperti pembaca sidik jari, SIM *Smart*, surat tilang elektronik, robot penjinak bom dan masih banyak lagi. Bidang pemerintahan juga telah banyak menggunakan TI dengan sebutan *E-government* yaitu penggunaan teknologi untuk menghubungkan pemerintah dengan pihak lain dengan tujuan untuk peningkatan kualitas layanan masyarakat (Taufik, Sudarsono, Budiyantara, Sudaryana, & Muryono, 2016).

TI juga memainkan peran kunci dalam bidang industri dan manufaktur. Adanya integrasi mendalam antara kecerdasan buatan dan *Internet of Things* (IOT) melalui industri proses mampu mengarahkan teknologi pada penciptaan sistem manufaktur cerdas (T. Yang, Yi, Lu, Johansson, & Chai, 2021). TI mendukung kerja sama antara manusia dan mesin serta sistem kontrol otonom, meningkatkan pengambilan keputusan dan efisiensi operasional dengan analisis informasi secara *real-time* (Vieira, Pinto-Varela, & Barbosa-Póvoa, 2019).

2.2 Konsep Dasar Artificial Intelligence (AI)

Artificial Intelligence (AI) terinspirasi dari hasil penelitian ilmu kedokteran dan biologi. AI muncul karena keinginan peneliti dalam mengembangkan program komputer yang dapat meniru kemampuan kognitif manusia. AI memanfaatkan komputer untuk mensimulasikan aktivitas yang dapat dilakukan oleh otak manusia seperti kesadaran, pembelajaran, perencanaan dan pemecahan masalah kompleks yang sebelumnya hanya bisa diselesaikan oleh ahli (D. Li & Du, 2017).

Menurut Russel & Norvig (2016) AI merupakan mesin atau komputer yang meniru kemampuan berfikir manusia seperti melakukan pembelajaran dan penyelesaian masalah. Istilah AI sendiri pertama kali diusulkan oleh John McCarthy dalam sebuah konferensi *Computer Science* yang diselenggarakan di Dartmouth College pada tahun 1956. AI dalam dua puluh tahun terakhir berkembang sangat pesat menjadi beberapa cabang ilmu yang lebih spesifik diantaranya *Machine Learning* (ML) dan *Deep learning* (DL) (Heryadi & Wayono, 2021).

2.2.1 Pemanfaatan AI dalam bidang Industri

Industri berbasis platform digital telah menjadi kebutuhan di era ekonomi masa kini. Perusahaan kini telah memanfaatkan teknologi AI serta digitalisasi dalam segala aspek manajemen dan produksi. Beberapa pemanfaatan AI yang biasa dipakai oleh perusahaan adalah sebagai berikut (Pasaribu & Widjaja, 2022):


1. Pengenalan pola dalam perilaku transaksi pelanggan bank dan mendeteksi pemalsuan tanda tangan.
2. Prediksi perubahan data dalam jangka pendek maupun panjang.
3. Pengklasifikasian untuk memilah kumpulan entitas dalam suatu kerumunan.
4. Pengenalan konfigurasi dengan menyatukan kumpulan noda untuk menjadi gambaran agar dapat mendapatkan sebuah kesimpulan.
5. Perekam dan pencatat teks suara pelanggan pada call center serta pemberian analisis lebih lanjut.
6. Pengenalan input dari konsumen seperti umpan balik pembeli yang harus ditanggapi dengan tepat sehingga mampu memenuhi minat belanja konsumen.
7. Berinteraksi dengan bahasa alami seperti pemberian input pada aplikasi perangkat lunak untuk pemberian keterangan dan laporan.
8. Menciptakan bahasa alami dengan menyediakan ringkasan dari dokumen yang telah terpilih.

Manufaktur cerdas merupakan bentuk dari pemanfaatan AI dalam pengambilan keputusan untuk seluruh proses manufaktur dan produksi dengan dilakukannya optimasi dan kontrol secara otonom. Tujuan dibentuknya manufaktur cerdas adalah untuk meningkatkan efisiensi ke tingkat yang lebih tinggi. Perusahaan terus mengembangkan algoritma serta sistem AI untuk pengenalan, prediksi serta pengambilan keputusan dalam kondisi operasi dengan pemanfaatan *big data* yang tersedia di perusahaan. Sistem AI pada akhirnya akan berfungsi sebagai pelengkap yang mampu meningkatkan kemampuan pekerja dalam melakukan proses produksi (T. Yang et al., 2021). Peran AI bukanlah sebagai pengganti manusia melainkan saling melengkapi meningkatkan kualitas hasil akhir (*output*) dalam suatu perusahaan. Seperti proses kreatif dalam perancangan produk,

di mana AI berperan untuk mengatasi keterbatasan manusia dan meningkatkan kreativitas (Figoli, Rampino, & Mattioli, 2022).

2.3. *Machine Learning* (ML)

Pencetus pertama definisi *Machine Learning* (ML) adalah Arthur Samuel yaitu seorang peneliti IBM. ML didefinisikan sebagai suatu bidang studi cabang dari AI yang memberikan mesin atau komputer kemampuan untuk belajar dari data tanpa diprogram secara eksplisit. Konsep belajar pada ML merujuk pada kemampuan sistem untuk meningkatkan kinerjanya seiring waktu dengan banyaknya pengalaman yang diberikan (Samuel, 1962).



Gambar 2. 1 Perbedaan pemrograman klasik dengan ML
Sumber: (Chollet, 2018)

François Chollet, seorang ilmuwan komputer dan pengembang perangkat lunak, menciptakan dan mengelola Keras, sebuah API pemrograman untuk *deep learning* yang banyak digunakan dalam bidang ML. Chollet (2018) mengemukakan bahwa terdapat perbedaan mendasar antara pendekatan pemrograman tradisional dan ML. Pemrograman konvensional mengacu pada logika programmer dan bersifat statis, sedangkan ML melibatkan sistem untuk belajar dari data berdasarkan pola yang telah ditentukan melalui data latih sehingga bersifat dinamis terhadap perubahan.

2.3.1 Algoritma pada *Machine Learning* (ML)

Chollet (2018) menggolongkan algoritma ML ke dalam empat cabang yaitu sebagai berikut:

1. *Supervised Learning* (Pembelajaran Terawasi)

Supervised learning merupakan metode pembelajaran di mana model mesin belajar dari data latih yang telah diberi label. Data pelatihan memiliki label atau output yang sesuai. Tujuan model adalah untuk mempelajari hubungan antara input dan output sehingga dapat melakukan prediksi atau klasifikasi pada data baru yang belum dilihat sebelumnya.

2. *Unsupervised Learning* (Pembelajaran Tak Terawasi)

Unsupervised learning merupakan metode pembelajaran di mana model mesin diberikan data pelatihan tanpa bantuan label. Tujuan utama adalah untuk menemukan pola atau struktur dalam data tanpa petunjuk eksternal. Jenis pembelajaran ini sering digunakan untuk tugas seperti pengelompokan (*clustering*) dan reduksi dimensi.

3. *Self-Supervised Learning* (Pembelajaran Terawasi)

Self-supervised learning adalah bentuk khusus dari *supervised learning* yang tidak melibatkan label manusia. Label dihasilkan dari data input menggunakan algoritma heuristik. *Autoencoder* merupakan salah satu contoh di mana target dihasilkan dari input tanpa modifikasi. Perbedaan antara *supervised*, *self-supervised*, dan *unsupervised learning* dapat kabur, dan *self-supervised learning* dapat diinterpretasikan ulang sebagai *supervised* atau *unsupervised learning*, tergantung pada fokus pada mekanisme pembelajaran atau konteks penerapannya.

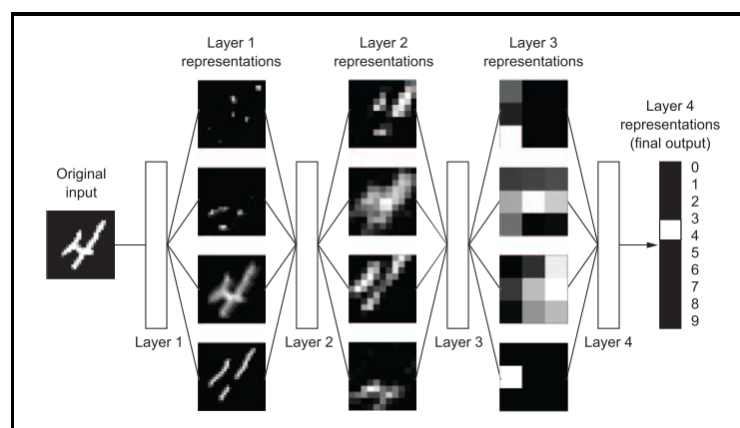
4. *Reinforcement Learning* (Pembelajaran Penguatan)

Reinforcement learning merupakan metode pembelajaran di mana model mesin belajar melalui interaksi dengan lingkungan. Agen membuat keputusan dan menerima umpan balik dari lingkungan dalam bentuk *reward* atau hukuman. Tujuan agen adalah untuk belajar strategi atau kebijakan yang mengoptimalkan akumulasi *reward* seiring waktu.

2.4 Deep learning (DL)

Deep learning (DL) muncul dari pengembangan jaringan saraf tiruan sekitar tahun 1950, namun mulai mendapat perhatian di pertengahan 1980 ketika algoritma *backpropagation* (BP) ditemukan dan diterapkan untuk melatih jaringan saraf besar. Yann LeCun merupakan pionir dalam bidang DL di mana pada tahun 1989 berhasil menggabungkan jaringan saraf konvolusi dengan BP, menghasilkan LeNet yang digunakan oleh Layanan Pos Amerika Serikat untuk klasifikasi tulisan tangan pada kode pos (Chollet, 2018). Menurut LeCun, jaringan saraf ini dirancang untuk meniru cara otak manusia memproses informasi. Keunggulan DL yaitu mampu menangani data besar dan beragam membuatnya efektif dalam berbagai aplikasi seperti pengenalan gambar, pemrosesan bahasa alami, dan pengenalan suara (LeCun, Bengio, & Hinton, 2015).

Menurut Chollet (2018) DL adalah pendekatan dalam bidang kecerdasan buatan yang menekankan pembentukan representasi hierarkis yang semakin kompleks dari data. Sama seperti LeCun, Chollet menyoroti bahwa DL memungkinkan model jaringan saraf dengan banyak lapisan secara otomatis memahami dan mempelajari fitur-fitur yang diperlukan untuk penyelesaian tugas tertentu. Keunikan DL terletak pada kemampuannya untuk melakukan pembelajaran otomatis, mengatasi kesulitan dalam representasi data yang sulit dijelaskan oleh aturan manusia atau metode tradisional. Gambar 2.2 merupakan representasi mendalam dari model.



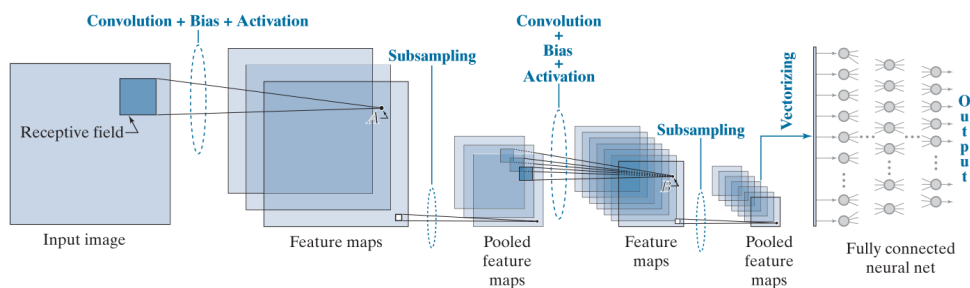
Gambar 2.2 Representasi mendalam model klasifikasi digit
Sumber: (Chollet, 2018)

Model jaringan saraf terdiri atas neuron sebagai unit pemrosesan informasi dasar dan layer adalah kelompok neuron yang terorganisir dalam satu lapisan. Terdapat tiga jenis lapisan utama dalam jaringan saraf (Heryadi & Wayono, 2021).

1. Input Layer (Lapisan Masukan) adalah layer yang menerima data awal atau input ke dalam jaringan.
2. Hidden Layer (Lapisan Tersembunyi) adalah lapisan diantara input layer dan output layer. Komputasi yang terjadi pada layer ini semakin abstrak dan konfigurasi lapisan bergantung pada kompleksitas tugas dan arsitektur jaringan.
3. Output Layer (Lapisan Keluaran) adalah lapisan yang memberikan hasil prediksi atau output dari jaringan neural.

2.4.1 *Convolutional Neural Network (CNN)*

Convolutional Neural Networks (CNN) merupakan jaringan saraf tiruan yang dirancang untuk memproses data yang memiliki struktur *grid*, seperti gambar. CNN menjadi model yang dominan dalam berbagai aplikasi pengenalan gambar, mulai dari pengenalan objek hingga deteksi wajah dan klasifikasi citra medis. CNN diperkenalkan oleh Yann LeCun pada tahun 1989 di Bell Labs (Chollet, 2018). Gambar 2.2 menunjukkan arsitektur CNN.



Gambar 2.3 Arsitektur CNN
Sumber: (Gonzalez & Woods, 2018)

Lapisan konvolusi dalam arsitektur CNN digunakan untuk ekstraksi fitur dari gambar yang diberikan sebagai input. Filter atau kernel digunakan pada gambar untuk mendeteksi fitur-fitur seperti tepi, sudut, dan tekstur. Filter ini bergerak

melintasi gambar dengan proses yang disebut sebagai konvolusi dan menghasilkan peta fitur (*feature map*) yang menunjukkan lokasi terdeteksinya fitur dalam gambar.

Lapisan pooling berfungsi untuk mengurangi dimensi peta fitur yang dihasilkan oleh lapisan konvolusi dengan tetap menjaga informasi penting yang ada. Dua teknik *pooling* yang umum digunakan adalah *max pooling* dan *average pooling*. *Max pooling* memilih nilai maksimum dari setiap area *sub-sampling*, sedangkan *average pooling* menghitung rata-rata dari nilai-nilai dalam area tersebut. Pooling ini membantu mengurangi jumlah parameter yang diperlukan dalam jaringan dan mencegah terjadinya overfitting.

Setelah melalui beberapa lapisan konvolusi dan *pooling*, peta fitur yang telah terbentuk akan diteruskan ke lapisan *fully connected*. Fitur akan diratakan menjadi vektor satu dimensi yang kemudian dihubungkan dengan kumpulan *neuron* di lapisan *fully connected*. Fungsi dari neuron adalah untuk mengintegrasikan fitur-fitur yang telah diekstraksi dan membuat keputusan akhir, sebagai contoh dalam bentuk klasifikasi atau deteksi.

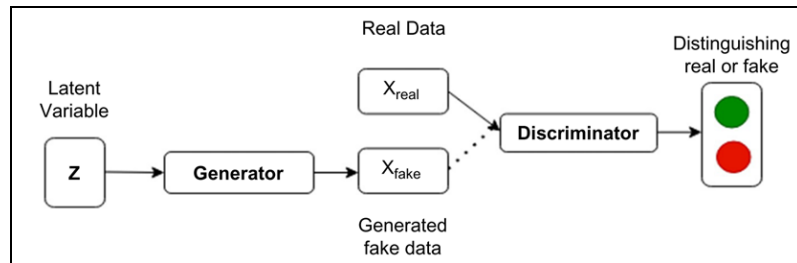
Fungsi aktivasi seperti ReLU (Rectified Linear Unit) juga penting digunakan untuk memperkenalkan non-linearitas ke dalam model. Tujuan fungsi aktivasi adalah agar CNN mampu mempelajari hubungan yang lebih kompleks antara fitur-fitur yang diekstraksi. Batch normalization juga biasa digunakan untuk meningkatkan kecepatan pelatihan dan menjaga stabilitas jaringan.

2.5 Generative Adversarial Network (GAN)

Arsitektur *Generative Adversarial Network* (GAN) pertama kali muncul dan diperkenalkan oleh Goodfellow pada tahun 2014. GAN merupakan arsitektur DL yang memungkinkan pembelajaran model untuk menghasilkan data baru yang realistis dengan cara mempertandingkan dua jaringan neural, yaitu generator dan diskriminator (Goodfellow et al., 2014).

GAN adalah teknik dalam ML yang beroperasi dengan dua model yang dilatih secara bersamaan seperti pada Gambar 2.3. Model pertama disebut generator dan model kedua diskriminator. Konsep "*Adversarial*" menandakan adanya kompetisi antara generator dan diskriminator, dimana keduanya terus berusaha untuk

mengalahkan satu sama lain. Istilah "jaringan" merujuk pada model pembelajaran mesin, dengan generator dan diskriminator biasanya diimplementasikan sebagai jaringan saraf. (Solanki, Nayyar, & Naved, 2021).

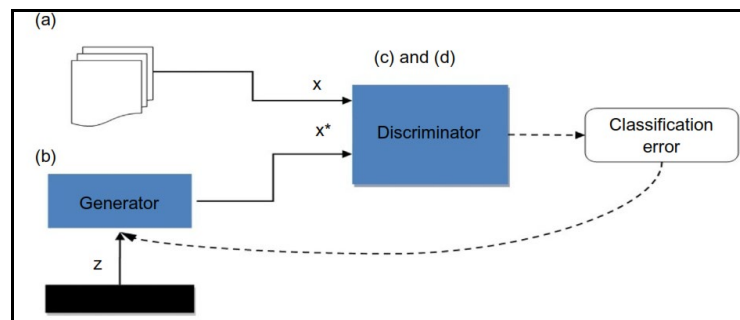


Gambar 2.4Arsitektur dasar GAN

Sumber: (Solanki et al., 2021)

2.5.1 Training GAN

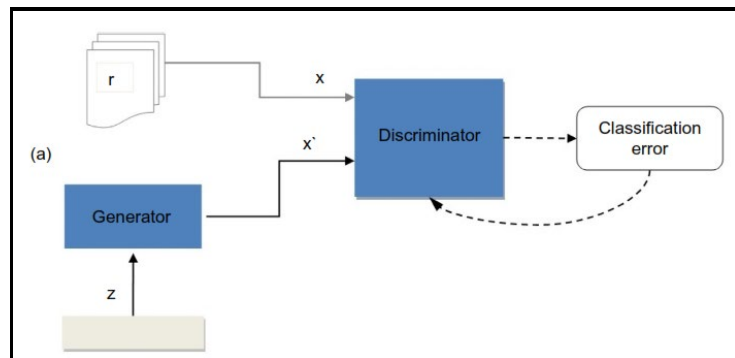
Gambar 2.3 merupakan diskriminator yang bertugas untuk membedakan antara data asli dan data palsu yang dihasilkan oleh generator. Pelatihan diskriminator melibatkan proses di mana model belajar untuk membedakan antara gambar nyata dan gambar palsu yang dihasilkan oleh generator. Diskriminator menerima dua jenis input selama pelatihan yaitu gambar asli dari dataset dan gambar yang dihasilkan oleh generator (Kailash Ahirwar, 2019)..



Gambar 2.5 Pelatihan diskriminator

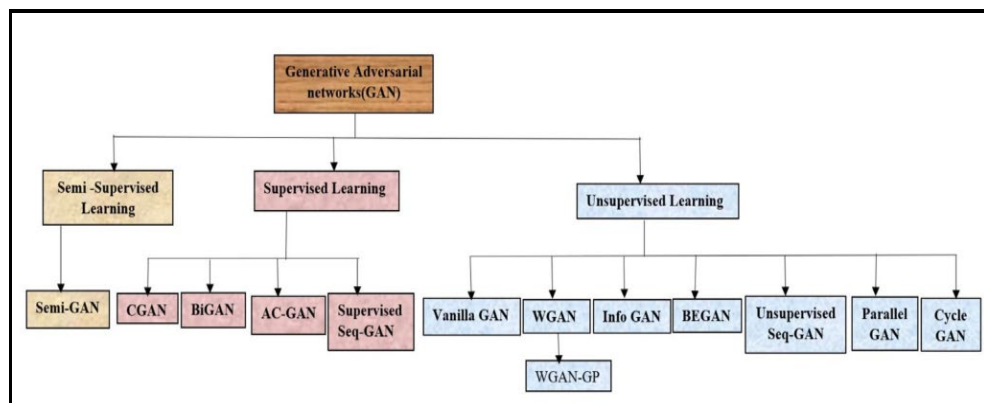
Sumber: (Solanki et al., 2021)

Gambar 2.4 merupakan pelatihan generator yang bertugas untuk menghasilkan data palsu yang sebisa mungkin mirip dengan data nyata. Kedua jaringan ini dilatih secara bersamaan. Proses ini berlanjut hingga diskriminator tidak lagi dapat membedakan dengan akurat antara data nyata dan data buatan generator (Kailash Ahirwar, 2019).



Gambar 2. 6 Pelatihan generator
Sumber: (Solanki et al., 2021)

GAN merupakan sebuah kelas algoritma dalam ML yang dapat dikategorikan berdasarkan jenis pembelajaran yang digunakan yaitu *semi-supervised*, *supervised*, atau *unsupervised*. Gambar 2.5 membagi variasi GAN berdasarkan pembelajaran yang digunakan.



Gambar 2.7 Klasifikasi model GAN
Sumber: (Solanki et al., 2021)

2.5.2 Aplikasi GAN

GAN memiliki berbagai aplikasi menarik dan praktis di berbagai industri. GAN dalam *image generation* dapat menghasilkan gambar realistis setelah dilatih pada sampel gambar, seperti menghasilkan gambar anjing baru dari ribuan contoh gambar anjing. Aplikasi ini juga digunakan dalam pemasaran, pembuatan logo, hiburan, dan media sosial. *Text-to-image synthesis* memungkinkan GANs untuk membuat gambar dari deskripsi teks, yang bermanfaat dalam industri film dan

komik untuk menghasilkan adegan atau cerita otomatis. *Face aging* digunakan dalam industri hiburan dan pengawasan, memungkinkan verifikasi wajah yang lebih tahan lama dengan menghasilkan gambar wajah pada berbagai usia. *Image-to-image translation* digunakan untuk mengonversi gambar seperti siang ke malam, sketsa menjadi lukisan, atau gambar bergaya tertentu seperti karya Picasso atau Van Gogh, hingga konversi gambar satelit dan udara. *Video synthesis* memungkinkan pembuatan konten video dengan cepat, meningkatkan produktivitas pembuat film dan hobiis. *High-resolution image generation* membantu menghasilkan gambar resolusi tinggi dari kamera beresolusi rendah, berguna untuk situs web. GAN juga dapat melengkapi bagian gambar yang hilang, memulihkan bagian yang rusak dengan cara yang sangat realistis (Kailash Ahirwar, 2019).

2.5.3 Jenis-Jenis GAN

Banyak penelitian yang terus mengembangkan dan meningkatkan kinerja GAN. Beberapa jenis GAN yang telah ditingkatkan yaitu Cycle GAN, ProGAN (Progressive GAN) dan Style GAN telah diusulkan untuk meningkatkan kualitas gambar yang dihasilkan (Kobayashi & Thongpramoon, 2022). Model lainnya yaitu Conditional GAN (C-GAN) atau biasa disebut model GAN bersyarat karena generator dan diskriminator akan dikondisikan dengan beberapa informasi tambahan seperti label kelas atau dari modalitas lain (Mirza & Osindero, 2014). Li et al., (2021) dalam penelitiannya menggunakan varian dari Vanilla GAN yaitu Product Development-GAN (PD-GAN) untuk menciptakan desain produk baru yang memenuhi kebutuhan afektif pengguna dan pelanggan. Model GAN lainnya yaitu *deep convolutional generative adversarial network* (DCGAN) yang merupakan titik penting dalam pengembangan model GAN karena menentukan struktur pelatihan yang stabil untuk memfasilitasi implementasi teknik (Chen, Fang, & Chen, 2021).

2.6. Text Mining

Text mining adalah proses analisis dokumen atau kumpulan dokumen yang kaya secara semantik untuk memahami konten dan makna informasi yang

terkandung di dalamnya. Proses ini meningkatkan kemampuan manusia dalam memproses kuantitas informasi yang besar dan memiliki nilai komersial tinggi. Penelitian di bidang *text mining* bertujuan untuk mengekstrak pola atau pengetahuan yang sebelumnya tidak diketahui, dapat dipahami, berpotensi berguna, dan praktis dari kumpulan data teks. *Text mining* menggunakan algoritma komputasi untuk membaca dan menganalisis informasi teksual, membantu mengidentifikasi pola dan hubungan yang ada dalam sejumlah besar teks. Teknologi ini menggunakan pemrosesan bahasa alami untuk mentransformasi teks bebas dalam dokumen atau database menjadi data terstruktur yang normal, cocok untuk analisis atau untuk menggerakkan algoritme pembelajaran mesin. Text mining dapat diterapkan dalam berbagai domain seperti layanan pelanggan, deteksi penipuan, iklan kontekstual, perawatan kesehatan, dan lainnya. *Text mining* seringkali memanfaatkan teknik-teknik seperti ekstraksi kategori, klusterisasi teks, ekstraksi aturan asosiasi, dan analisis tren sesuai dengan aplikasi yang diinginkan (Bhonde, Paikrao, & Rahane, 2010).

2.6.1 Klasifikasi Teks

Klasifikasi teks bertujuan untuk memproses dan menganalisis data teks secara efektif, menghasilkan wawasan yang berguna dan prediksi yang akurat dari teks. Penggunaan kerangka kerja klasifikasi teks secara umum melibatkan empat langkah penting (Yousef & ALali, 2022).

1. Pra-proses (Preprocessing)

Tahap ini melibatkan pembersihan dan penyiapan data teks untuk analisis, termasuk menghilangkan tanda baca yang tidak perlu, mengonversi teks menjadi huruf kecil, menghilangkan kata-kata yang sering muncul (stop words), dan melakukan stemming atau lemmatization. Tujuannya adalah untuk mengurangi kebisingan dalam data dan menyederhanakan representasi teks sehingga lebih mudah dianalisis.

2. Ekstraksi Fitur (Feature Extraction)

Selanjutnya adalah mengubah teks menjadi format yang dapat digunakan oleh algoritma ML. Ini melibatkan ekstraksi fitur atau atribut dari teks. Teknik

umum termasuk *Bag of Words*, TF-IDF (*Term Frequency-Inverse Document Frequency*), dan *embedding* kata.

3. Pemilihan Fitur (*Feature Selection*)

Langkah ini bertujuan untuk mengidentifikasi dan memilih fitur yang paling relevan atau berkontribusi paling banyak terhadap tugas klasifikasi. Pemilihan fitur mengurangi dimensi dari ruang fitur dan meningkatkan efisiensi dan efektivitas model pembelajaran mesin. Teknik pemilihan fitur termasuk analisis statistik, metode berbasis model, dan pengurangan dimensi.

4. Klasifikasi

Data yang telah diproses dimasukkan ke dalam algoritma klasifikasi. Model ML dilatih dengan data terstruktur untuk mengklasifikasikan teks ke dalam kategori atau label yang ditentukan. Beberapa algoritma klasifikasi populer meliputi *Naive Bayes*, *Support Vector Machines* (SVM), dan jaringan saraf biasa digunakan. Setelah model terlatih, maka selanjutnya dapat digunakan untuk memprediksi kategori dari data teks baru.

2.6.2 Ekstraksi Fitur dan Pembobotan

TF-IDF adalah salah satu metode *text mining* yang digunakan untuk mengekstraksi dan membobot kata-kata atau "terms" pada kata-kata penting dari sebuah dokumen (Ghiffari, 2018). TF-IDF merupakan singkatan dari *term frequency-inverse document frequency*, yaitu metode statistik yang dimaksudkan untuk mencerminkan seberapa penting sebuah kata dalam suatu dokumen dalam suatu koleksi teks (Djatna & Kurniati, 2015). Data yang telah dikumpulkan selanjutnya diproses dengan *transform cases*, *tokenize* dan *filter stopwords* kemudian melalui tahap *feature extraction* dengan menghitung frekuensi kemunculan kata dalam setiap dokumen sebagai Term Frequency (TF), kemudian menghitung nilai IDF untuk setiap kata (Dadgar, Araghi, & Farahani, 2016). Wawasan mengenai kata-kata yang memiliki bobot tinggi dianggap menggambarkan preferensi dan perasaan konsumen. Metode ini memberikan nilai pentingnya kata-kata berdasarkan seberapa sering kata-kata tersebut muncul di

beberapa kuesioner. Salah satu varian yang umum digunakan dalam penelitian adalah sebagai berikut:

$$wd = w \times \log \frac{D}{wD} \quad (2.1)$$

Keterangan:

wd = Bobot TF-IDF

w = Frekuensi kata dalam dokumen

D = Jumlah dokumen dalam koleksi teks.

2.7. Citra

Citra dari sudut pandang visual atau fisis merepresentasikan berbagai informasi yang memungkinkan mata untuk melakukan analisis dan interpretasi sesuai dengan keperluan tertentu. Informasi yang terkandung dalam sebuah citra bisa dibedakan menjadi dua jenis, yaitu informasi dasar dan abstrak. Informasi dasar merupakan jenis informasi yang bisa diproses secara langsung tanpa perlunya pengetahuan tambahan yang spesifik. Sebagai contoh, informasi dasar meliputi elemen-elemen seperti warna, bentuk, dan tekstur. Di sisi lain, informasi abstrak merujuk pada jenis informasi yang memerlukan tambahan pengetahuan khusus untuk dapat diproses. Contoh dari informasi abstrak adalah gambaran tentang suatu kejadian atau konteks pada waktu citra diambil, yang tidak dapat langsung dipahami tanpa pengetahuan atau informasi tambahan (Madenda, 2015).

Citra dari sudut pandang matematis dapat dijelaskan sebagai fungsi dua dimensi $f(x, y)$ yang terdiri dari koordinat spasial (x, y) dan nilai intensitas warna f pada koordinat tersebut. Citra yang nilainya bersifat kontinu dikenal sebagai citra analog, sedangkan citra dengan nilai yang diskrit dikategorikan sebagai citra digital. Sebagai contoh, citra digital dapat ditemukan dalam memori komputer atau CD-ROM. Citra digital umumnya berbentuk dua dimensi dan direpresentasikan sebagai matriks dengan jumlah elemen yang terbatas (Madenda, 2015).

2.7.1 Citra Digital

Sebuah citra digital merupakan representasi dua dimensi dari informasi visual, yang dibangun dari sejumlah piksel terbatas. Masing-masing piksel ini dikaitkan dengan posisi tertentu di dalam gambar dan mempunyai tingkat intensitas atau keabuan yang unik. Gambar digital dibuat dari nilai-nilai diskrit, dengan koordinat x dan y merepresentasikan posisi ruang, dan nilai intensitas gambar yang terbatas dan diskrit. Rentang gambar digital ini dapat meliputi berbagai bagian dari spektrum elektromagnetik, termasuk dari gelombang gamma hingga radio, dan dapat diciptakan oleh berbagai alat seperti USG, mikroskop elektron, dan gambar yang dibuat dengan komputer. Secara umum, gambar digital terdiri dari susunan terstruktur dari piksel-piksel yang bersama-sama membentuk gambaran visual dari suatu objek atau pemandangan (Gonzalez & Woods, 2008).

Citra digital secara umum dapat diartikan sebagai representasi dari piksel-piksel dalam ruang dua dimensi, di mana piksel-piksel ini diatur dalam matriks berukuran N baris dan M kolom seperti pada persamaan 2.1 dan setiap elemen matriksnya dikenal sebagai piksel (*picture element, image element, atau pel*) (Madenda, 2015).

$$F = [f(x, y)] = \begin{bmatrix} f(0,0) & f(0,1) & \dots & f(0,M) \\ f(1,0) & f(1,1) & \dots & f(1,M) \\ \vdots & \vdots & \dots & \vdots \\ f(N,0) & f(N,1) & \dots & f(N,M) \end{bmatrix} \quad (2.2)$$

Resolusi dalam citra digital didefinisikan sebagai jumlah maksimum pasangan garis dalam satuan panjang tertentu, seperti 100 pasangan garis per milimeter. Alternatifnya, resolusi bisa diukur dalam jumlah titik per unit panjang, yang umum digunakan dalam dunia percetakan dan penerbitan, misalnya dalam satuan titik per inci (dpi). Piksel, atau elemen gambar, merupakan unit terkecil dalam gambar digital. Piksel merupakan representasi digital dari titik pada gambar grafis dan sering kali disebut sebagai 'pel' (Gonzalez & Woods, 2008).

2.7.2 Jenis-jenis Citra

Menurut Gonzalez & Woods (2008) citra dapat dibedakan menjadi tiga jenis yaitu citra berwarna, *grayscale* dan biner, sedangkan menurut (Burger & Burge (2016) citra dibagi menjadi empat jenis yaitu citra berwarna, *grayscale*, biner dan citra khusus. Jenis-jenis citra ini penting dalam pemrosesan citra berwarna, karena akan menjadi fondasi untuk berbagai teknik pengolahan citra, termasuk segmentasi, pemfilteran, dan visualisasi.

Citra berwarna sering kali direpresentasikan menggunakan model warna RGB, di mana setiap piksel mengandung tiga saluran warna yaitu merah, hijau, dan biru. Model RGB memungkinkan representasi beragam dengan mengkombinasikan tiga warna primer dalam proporsi yang berbeda-beda (Gonzalez & Woods, 2008). Secara umum, setiap komponen warna dalam gambar berwarna membutuhkan 8 bit. Untuk mengkodifikasi ketiga komponen warnanya, sebuah piksel pada gambar tersebut memerlukan total 24 bit. Kisaran nilai untuk masing-masing komponen warna berada di antara 0 hingga 255 (Burger & Burge, 2016). Gambar 2.7 merupakan contoh citra berwarna.




Gambar 2.8 Citra berwarna RGB.
Sumber: (Burger & Burge, 2016)

Model warna lainnya yaitu model CMY atau CMYK adalah model warna subtraktif yang banyak digunakan dalam percetakan. Model ini terdiri dari *Cyan*, *Magenta*, *Yellow*, dan *Key* (hitam). Model CMYK bekerja dengan menyerap cahaya, bukan memancarkannya. Warna cyan yang mengenai permukaan kemudian

diberi cahaya putih, maka warnah merah yang dipantulkan tidak ada atau dapat dikatakan bahwa *cyan* menghapus cahaya merah dari pantulan cahaya putih. Konversi dari RGB ke CMYK dan sebaliknya merupakan bagian penting dari proses desain dan produksi grafis dinyatakan pada persamaan 2.3 (Sari & Pramunendar, 2017).

$$\begin{bmatrix} C \\ M \\ Y \end{bmatrix} = \begin{bmatrix} 255 \\ 255 \\ 255 \end{bmatrix} - \begin{bmatrix} R \\ G \\ B \end{bmatrix} \quad (2.3)$$

Selain itu terdapat pula model HIS atau HSV seperti pada Gambar 2.8 dirancang untuk lebih dekat dengan cara manusia mempersepsikan warna. Tingkat rona (*Hue*) merepresentasikan warna itu sendiri, saturasi (*Saturation*) menggambarkan kejenuhan warna, dan kecerahan (*Intensity* atau *Value*) menggambarkan sensasi warna (Sari & Pramunendar, 2017).

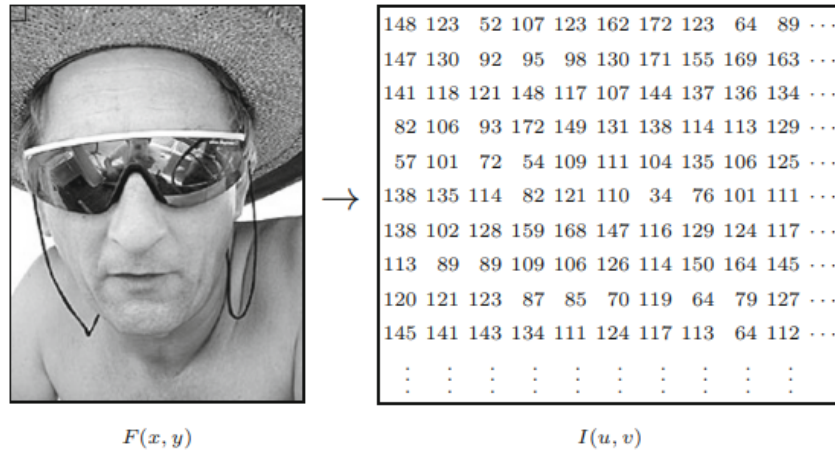


Gambar 2. 9 Distribusi warna pada HSV
Sumber: (Burger & Burge, 2016)

Model lainnya yaitu Model CIELAB dirancang untuk menjadi model warna yang universal dengan tujuan menciptakan ruang warna yang perseptual uniform. Model ini memisahkan informasi luminansi dari informasi warna, dengan L* untuk kecerahan, a* untuk posisi antara merah/magenta dan hijau, dan b* untuk posisi antara kuning dan biru (Gonzalez & Woods, 2008).

Citra *grayscale* atau citra monokrom di mana setiap piksel direpresentasikan oleh sebuah nilai intensitas tunggal. Perbedaan citra berwarna dengan grayscale ditunjukkan pada Gambar 2.7. Nilai ini biasanya berada dalam rentang 0 (hitam) hingga 255 (putih) untuk citra 8-bit. Citra skala abu-abu dalam konteks RGB dapat

diperoleh dengan mengekstraksi komponen intensitas, memisahkan informasi tentang rona dan saturasi dari intensitasnya (Gonzalez & Woods, 2008).



Gambar 2.10 Transformasi citra *grayscale* ke citra diskrit

Sumber: (Burger & Burge, 2016)

Citra biner juga termasuk citra monokrom dengan setiap pikselnya hanya memiliki dua kemungkinan warna yaitu hitam (0) atau putih (1) seperti pada Gambar 2.10. Citra jenis ini sering digunakan untuk segmentasi atau ambang batas, dan biasanya diperoleh dari citra *greyscale* melalui proses ambang batas. Piksel dengan nilai di atas ambang batas tertentu ditetapkan menjadi putih, sementara yang di bawahnya menjadi hitam (Gonzalez & Woods, 2008).



Gambar 2.11 Citra biner sederhana

Sumber: (Gonzalez & Woods, 2008)

Citra biner ditemukan dalam banyak tempat, umumnya digunakan dalam representasi grafik linier, arsip dokumen, encoding transmisi faksimili, sebagai

masker seleksi dalam pengeditan gambar dan video serta dalam dunia percetakan elektronik (Burger & Burge, 2016).

2.7.3 Pengolahan Citra Digital

Pemrosesan citra digital melibatkan tahapan akuisisi, penyempurnaan, dan pengenalan citra, serta proses dasar lainnya. Bidang ini memiliki berbagai aplikasi praktis, termasuk di bidang astronomi, biologi, kedokteran nuklir, hukum, pertahanan, dan industri. Fokus utamanya adalah pada peningkatan kualitas gambar untuk analisis manusia serta pemrosesan gambar untuk kebutuhan penyimpanan, transmisi, dan interpretasi oleh mesin. Pengolahan citra mencakup pemahaman tentang sistem visual manusia, cara pembentukan gambar di mata, adaptasi dan diskriminasi kecerahan, sensor pengambilan gambar, proses sampling dan kuantisasi, serta representasi digital gambar (Gonzalez & Woods, 2008). Terdapat beberapa teknik yang umum digunakan dalam pengolahan citra diantaranya:

1. Morfologi Matematika

Metode ini menggunakan prinsip-prinsip teori himpunan untuk menganalisis dan memodifikasi objek dalam gambar. Operasi yang termasuk dalam morfologi matematika antara lain dilatasi, erosi, pembukaan, dan penutupan, yang digunakan untuk mengubah bentuk dan struktur objek dalam gambar.

2. Segmentasi

Proses ini membagi gambar menjadi segmen-segmen yang berbeda untuk mempermudah analisis atau untuk mengubah representasi gambar menjadi lebih signifikan dan lebih mudah dipahami.

3. Pemfilteran

Metode ini bertujuan untuk menonjolkan atau mengurangi aspek tertentu dari gambar. Ini termasuk berbagai teknik seperti mengurangi *noise*, mempertajam tepi, dan menghaluskan gambar.

4. Thresholding

Teknik ini mengubah gambar menjadi format biner berdasarkan nilai ambang batas yang ditentukan. Ini sering digunakan untuk proses segmentasi dan ekstraksi fitur penting dari gambar.

5. **Skeletonisasi dan Penipisan**

Teknik ini digunakan untuk menyederhanakan bentuk dalam gambar ke bentuk kerangka atau bentuk yang lebih tipis, yang berguna dalam ekstraksi fitur dan pengenalan pola.

6. **Pemangkasan**


Metode ini bertujuan untuk menghilangkan elemen yang tidak diinginkan atau tidak relevan dari gambar, khususnya dalam konteks teknik skeletonisasi dan penjarangan.

2.8. Produk

Menurut Kotler & Armstrong (2018) produk disoroti sebagai sebuah barang atau jasa yang ditawarkan oleh suatu perusahaan untuk dijual kepada konsumen. Produk dalam konteks tersebut dirancang untuk memenuhi kebutuhan dan keinginan konsumen. Karl T. Ulrich & Eppinger (2012) mendefinisikan produk sebagai sesuatu yang dihasilkan melalui proses pengembangan yang dijual oleh suatu perusahaan untuk memenuhi kebutuhan pelanggan.

2.8.1. Proses Pengembangan Produk

Proses merupakan tahapan transformasi input menjadi sebuah output. Proses pengembangan produk adalah tahapan aktivitas yang harus dilakukan suatu perusahaan untuk menyusun, merancang, dan mengiklankan suatu produk. Gambar 2.6 merupakan fase proses pengembangan generik (Ulrich & Eppinger, 2012).



Gambar 2. 12 Fase Pengembangan Produk

Sumber: (Ulrich & Eppinger, 2012)

Tahap pertama mencakup kegiatan perencanaan atau sering disebut sebagai “*Phase Zero*” karena mendahului persetujuan proyek dan proses pengembangan produk aktual. Tahap kedua atau Fase 1 yaitu pengembangan konsep dengan menjelaskan target pasar yang diidentifikasi, alternatif yang dihasilkan dan

dievaluasi. Tahap ketiga atau Fase 2 yaitu perancangan tingkat sistem mencakup definisi arsitektur produk, dekomposisi produk, perancangan awal komponen kunci, dan alokasi tanggung jawab desain. Tahap keempat atau Fase 3 yaitu perancangan rinci mencakup spesifikasi lengkap geometri, bahan, dan toleransi bagi semua bagian unik dan penentuan bagian standar yang dibeli dari pemasok. Hasil akhirnya berupa dokumen kontrol setiap bagian dan peralatannya, spesifikasi untuk bagian yang dibeli, serta rencana proses pembuatan dan perakitan produk. Tahap kelima atau Fase 4 merupakan fase pengujian dan penyempurnaan dengan melibatkan konstruksi serta evaluasi pra-produksi produk. Tahap terakhir atau Fase 5 adalah peningkatan produksi melibatkan pembuatan produk menggunakan sistem produksi yang dimaksudkan. Transisi ke produksi berkelanjutan dilakukan secara bertahap, dengan peluncuran produk dan tinjauan pasca peluncuran untuk evaluasi komersial dan teknis.

2.8.2 Kebutuhan Pelanggan (*Customer Needs*)

Salah satu konsep dasar pemasaran adalah memahami kebutuhan dan keinginan manusia dan kebutuhan yang mencakup aspek fisik dan sosial dan keinginan dibentuk oleh budaya dan kepribadian individu. Perusahaan perlu mempelajari kebutuhan, keinginan, dan tuntutan pelanggan melalui penelitian dan analisis data. Daya beli dan keinginan pelanggan yang cepat berubah menjadi tuntutan, sehingga perusahaan perlu menyediakan produk dan layanan yang dapat memberikan nilai dan kepuasan tertinggi (Kotler & Armstrong, 2018).

Istilah “kualitas” mendefinisikan kebutuhan pelanggan dalam konteks desain produk. Seorang desainer atau perancang produk harus sadar bahwa produk yang dirancang bukan untuk mereka sendiri melainkan untuk orang lain. Perlu dipastikan bahwa spesifikasi harus diperhatikan dengan baik dan tidak terpengaruh oleh ambisi maupun pandangan pribadi. Sebagai contoh mobil mewah bukan tergolong produk berkualitas apabila target pasar adalah konsumen yang mengantar keluarga dengan anak kecil ke sekolah setiap pagi (Morris, 2009).

Identifikasi kebutuhan pelanggan bertujuan memahami dan mengkomunikasikan kebutuhan pelanggan kepada tim pengembangan. Hasilnya

berupa pernyataan kebutuhan pelanggan yang dirinci, diorganisir hierarkis, dan diberi bobot kepentingan. Terdapat lima langkah dalam proses identifikasi kebutuhan pelanggan (Ulrich & Eppinger, 2012).

1. Memperoleh informasi awal berupa data mentah dari pelanggan.
2. Menerjemahkan informasi awal untuk memahami kebutuhan pelanggan.
3. Menyusun kebutuhan ke dalam struktur hierari.
4. Menentukan tingkat kepentingan relatif dari setiap kebutuhan.
5. Refleksikan hasil dan proses yang telah dijalankan.

Desain produk memiliki pengaruh signifikan pada keputusan pembelian konsumen. Perubahan sikap konsumen terjadi pada konsumsi dan fungsi produk yang semakin beragam, sehingga penampilan produk menjadi faktor kunci dalam keputusan pembelian. Karakteristik dan faktor emosional konsumen memainkan peran penting dalam penilaian terhadap desain produk. Produsen perlu mempertimbangkan kebutuhan dan preferensi konsumen, untuk membuat keputusan yang lebih tepat dalam mengembangkan desain penampilan produk yang memenuhi kebutuhan dan harapan konsumen (Dou, Li, Nan, Wang, & Zhou, 2021).

2.9. *Kansei Engineering* (KE)

KE merupakan teknologi yang berorientasi pada konsumen untuk menerjemahkan perasaan atau respon emosi manusia ke dalam desain suatu produk (Ishihara, Ishihara, Nagamachi, & Matsubara, 1997). Teknologi ini disebut berorientasi pada konsumen karena perasaan dan citra akan hadir dalam pikiran seorang konsumen ketika ingin membeli suatu produk atau jasa. Hasil gambaran dari pikiran konsumen akhirnya menjadi masukan dalam metode KE (Nagamachi, 2002).

Kansei berasal dari kata *kan* dan *sei* dalam bahasa Jepang. Kata *kan* mencakup sensitivitas, responsivitas, perasaan, citra, dan emosi, sedangkan "*sei*" berarti manusia, sehingga dapat disimpulkan bahwa *Kansei* mencerminkan sensibilitas manusia terhadap objek dan bagaimana hal itu mempengaruhi keputusan sesuai dengan kebutuhan dan kepuasannya (Ushada, Suryandono, & Khuriyati, 2016).

KE dicetuskan oleh Mitsuo Namagachi pada tahun 1970 sebagai suatu teknologi yang dapat menerjemahkan perasaan manusia menjadi spesifikasi rancangan. Metodologi ini telah berperan dalam menciptakan lebih dari 50 produk yang sukses secara global seperti Toyota, Nissan, Mazda, Isuzu, Komatsu, GM, Ford, Sharp, Wacoal, Mizuno, Milbon, Panasonic Electric Works, Nestle, P&G, and Johnson & Johnson. Penggunaan data *Kansei* membuat perusahaan dapat merancang produk yang sesuai dengan preferensi pelanggan (Nagamachi & Lokman, 2015).

2.9.1 Tipe *Kansei Engineering*

Nagamachi mengelompokkan KE menurut alat dan masalah yang harus diselesaikan menjadi beberapa tipe. Berikut ini tipe-tipe *Kansei Engineering* (Ishihara, Nagamachi, Schütte, & Eklund, 2008).

1. *Kansei Engineering Type-I: Category Classification*

Strategi produk dan segmen pasar pada *Kansei type-I* diidentifikasi serta dikembangkan ke dalam struktur pohon untuk mengenali kebutuhan afektif pelanggan. Kebutuhan afektif atau *Kansei* tersebut kemudian dihubungkan secara manual dengan properti-produk.

2. *Kansei Engineering Type-II: Kansei Engineering System (KES)*

Tipe *Kansei* ini menggunakan bantuan sistem komputer yang berisi database *Kansei*. Alat statistik matematika digunakan untuk membangun koneksi antara *Kansei* dan properti produk.

3. *Kansei Engineering Type-III: Hybrid Kansei Engineering System*

Hampir serupa dengan *Kansei type II* tetapi, tipe ini juga memprediksi *Kansei* dari suatu produk sebagai contoh dengan menggunakan prototype atau mockup.

4. *Kansei Engineering Type-IV: Kansei Engineering Modeling*

Tipe *Kansei* ini fokus pada implementasi model prediksi matematika dengan validasi yang lebih kuat dibandingkan tipe II dan III.

5. *Kansei Engineering Type-V: Virtual Kansei Engineering*

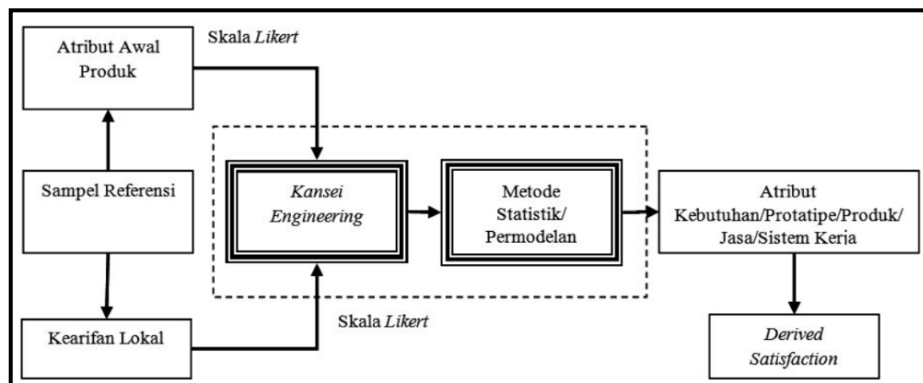
Tipe *Kansei* ini menggunakan *virtual reality* (VR), untuk menempatkan pemaparan suatu produk nyata ke dalam lingkungan *virtual 3D* atau VR.

6. *Kansei Engineering Type-V: Collaborative Kansei Engineering Designing*

Tipe *Kansei* ini didukung oleh sistem internet. Prinsip kerja *Kansei* tipe ini mendukung kerja kelompok dan rekayasa secara bersamaan, melalui cara ini tahap pengembangan dapat dipersingkat dan disederhanakan.

2.9.2 Metodologi *Kansei Engineering*

Tahapan umum dalam KE terdapat pada Gambar 2.7 yaitu dimulai dari pengumpulan sampel referensi, kemudian menentukan atribut awal produk dan menentukan kearifan lokal. Selanjutnya atribut dan kearifan lokal diberi nilai dengan skala likert dan masuk ke tahap *Kansei Engineering*. Langkah berikutnya yaitu pemodelan dengan metode statistika. Teknik statistik seperti analisis faktor dan regresi banyak digunakan dalam menentukan faktor-faktor yang mempengaruhi kepuasan pelanggan (Ushada et al., 2016).



Gambar 2.13 Metodologi *Kansei Engineering*
Sumber: (Ushada et al., 2016)

Hasil akhir yaitu berupa kepuasan yang diturunkan (*derived satisfaction*). Hal ini mencerminkan seberapa baik atribut produk yang dikembangkan amemenuhi emosi dan persepsi pelanggan yang diidentifikasi melalui penilaian *Kansei*. Proses ini menekankan pentingnya menciptakan produk yang tidak hanya fungsional tetapi juga menyentuh aspek emosional konsumen, yang sering kali merupakan faktor penentu dalam keberhasilan produk di pasar (Ushada et al., 2016).


2.10 Penelitian Terdahulu

Penelitian terdahulu telah mengembangkan *Kansei Engineering* (KE) dan *Generative Adversarial Network* (GAN) untuk optimasi proses desain dengan menciptakan gambar produk yang sesuai dengan preferensi konsumen. Kajian mengenai optimisasi proses desain menggunakan *Kansei Engineering* dan GAN akan diuraikan sebagai berikut.

(X. Li, Su, Zhang, & Bai, 2021) *Product innovation concept generation based on Deep Learning And Kansei Engineering*

Penelitian ini bertujuan mengatasi tantangan dalam menciptakan gambar konsep produk baru yang sesuai dengan preferensi afektif pengguna yang merupakan sebuah aspek penting dalam desain industri. Penelitian ini akan menciptakan sketsa konsep awal dengan memperkenalkan *Product Concept Generation Approach Framework Based on Deep Learning and Kansei Engineering* (PCGA-DLKE) untuk mendukung desainer industri. Pendekatan ini membantu dalam menghasilkan gambar konsep yang inovatif sesuai dengan emosi serta preferensi pengguna. Proses penelitian meliputi pengumpulan data, pra-pemrosesan, identifikasi preferensi afektif pengguna, pengembangan model generatif untuk pembuatan gambar konseptual, dan penerapan jaringan transfer gaya produk.

Peneliti mengembangkan model pengenalan afektif yang mengintegrasikan *Kansei Engineering* dengan deep convolutional neural networks yaitu ResNet-18 yang dimodifikasi menjadi *product affective recognition residual network* (PAR-ResNet) seperti pada Gambar 2.13. Peneliti mengajukan model desain produk generatif, PD-GAN berbasis DCGAN dan residual blocks untuk generasi gambar produk baru. Pendekatan ini diperkuat dengan pelatihan jaringan transfer gaya neural cepat (*Fast neural style transfer network*) yang telah ditingkatkan, disesuaikan dengan preferensi gaya pengguna.

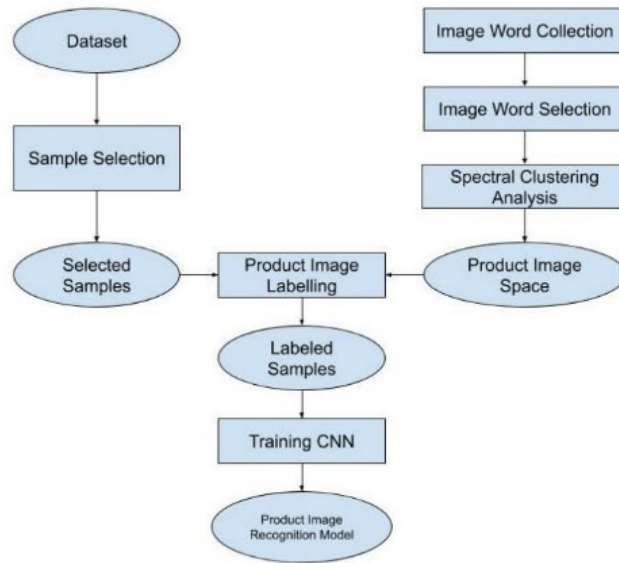


Gambar 2.14 Model pengenalan gambar produk dengan KE dan PAR-ResNet (X. Li et al., 2021)

Evaluasi pendekatan ini, diilustrasikan melalui studi kasus desain bor dan helm sepeda. Hasilnya menunjukkan peningkatan signifikan dalam inovasi konsep produk baru. Hasil ini menandakan bahwa pendekatan yang diusulkan mampu menyediakan dukungan yang lebih efektif bagi desainer produk dalam menciptakan desain yang sesuai dengan preferensi pengguna.

(C. Yang, Zhou, Zhu, Yu, & Wu, 2021) *Emotionally intelligent fashion design using CNN and GAN*

Penelitian ini mengembangkan metode desain emosional pintar untuk menghubungkan kebutuhan emosional konsumen dengan desain barang fashion. Peneliti membagi metode ini menjadi dua aspek utama yaitu model pengenalan gambar produk dengan arsitektur CNN yaitu *Visual Geomertry Group Network* (VGGNet) dan model generasi desain dengan integrasi arsitektur DCGAN dan Conditional GAN untuk menghasilkan desain yang inovatif. Kerangka model pengenalan gambar produk berdasarkan jaringan saraf konvolusional ditunjukkan pada Gambar 2.2.

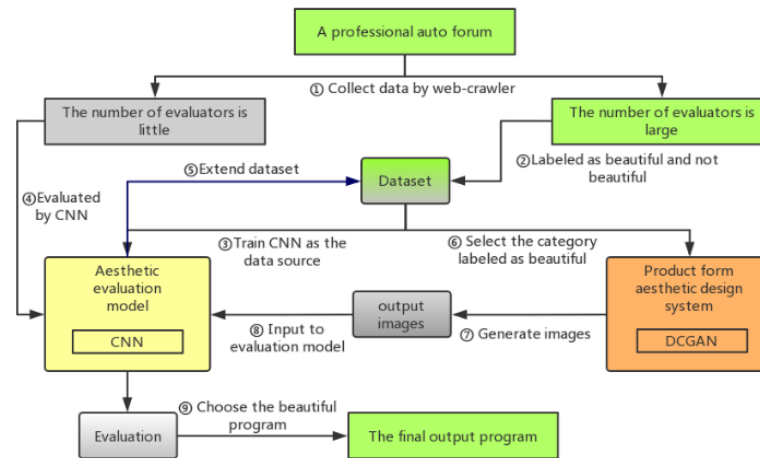


Gambar 2.15 Kerangka kerja model pengenalan gambar produk
(C. Yang et al., 2021)

Sepatu dipilih sebagai objek penelitian karena kemampuannya merefleksikan preferensi estetika dan emosional pengguna, di mana bentuk sepatu sering kali memberikan kesan pertama dan mengandung nilai emosional yang mendalam. Penelitian ini membuktikan bahwa metode yang diusulkan untuk menghasilkan desain sepatu terbukti kelayakannya, berdasarkan partisipasi pengguna dalam proses evaluasi.

(Zhou, Liu, Zhang, & Ouyang, 2021) *Evaluation and design method for product form aesthetics based on Deep Learning*

Penelitian mengusulkan metode berupa evaluasi estetika dan desain produk berbasis Deep learning. Tahap awal, melibatkan penggunaan web-crawler untuk mengumpulkan gambar tampak depan mobil beserta peringkat penampilannya. Tahap selanjutnya membuat sebuah kumpulan data dengan label berupa peringkat intuitif dan sederhana dari pengguna. *Deep Convolutional Neural Network* (DCNN) kemudian dirancang sebagai dasar untuk klasifikasi. Peneliti menyederhanakan masalah dengan mendefinisikan penelitian ini sebagai tugas klasifikasi biner yaitu mengelompokkan gambar yang tergolong estetis atau tidak estetis. Gambar 2.15 menunjukkan keseluruhan alur penelitian.

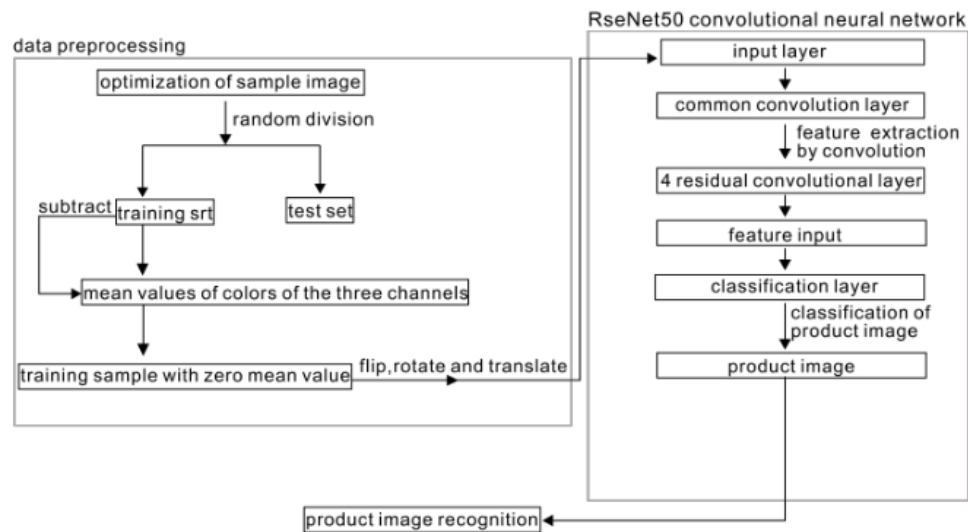


Gambar 2.16 Alur penelitian metode evaluasi dan desain estetika produk (Zhou, Liu, Zhang, & Ouyang, 2021)

Penelitian ini mengembangkan model evaluasi estetika MeiduNet yang merupakan modifikasi jaringan VGG. Model yang disulkan memiliki kinerja yang baik untuk tugas klasifikasi biner. DCGAN digunakan untuk membuat sketsa tampak depan mobil dan hasilnya menunjukkan bahwa metode yang diusulkan mampu memberikan dukungan teknis bagi desainer untuk penciptaan desain bentuk produk yang cerdas.

(Wu & Zhang, 2022) *Image style recognition and intelligent design of oiled paper bamboo umbrella based on deep learning*

Penelitian ini berfokus pada pengembangan desain cerdas untuk produk budaya kreatif dalam konteks computer aided design (CAD), dengan tujuan mengatasi masalah akurasi pengenalan yang rendah dan kebutuhan ekstraksi fitur manual dari model pengenalan gambar produk awal. Usulan pengenalan gambar produk ditunjukkan pada Gambar 2.16.




Gambar 2.17 Pengenalan gambar produk berbasis ResNet50
(Wu & Zhang, 2022)

Peneliti membangun model pengenalan gambar untuk produk budaya kreatif pada payung kertas minyak klasik menggunakan Residual Network 50 (ResNet-50). Percobaan generasi motif payung menggunakan DCGAN, di mana generator maupun diskriminator menggunakan deep neural network dengan input gaussian noise. Penelitian ini menunjukkan hasil generator mampu membentuk rangkaian payung kertas minyak melalui DCGAN. Gambar yang dihasilkan dinilai layak dan efektif dan model ini mampu menghasilkan desain payung kertas minyak klasik yang dapat memberikan inspirasi bagi desainer produk.

(Wang, Ma, & Yang, 2023) *Creativity and Sustainable Design of Wickerwork Handicraft Patterns Based on Artificial Intelligence*

Penelitian ini bertujuan untuk melindungi warisan tradisi lokal kerajinan tangan dan mengembangkannya menjadi industri kerajinan yang berperan dalam mempertahankan stabilitas sosial. Peneliti mengembangkan metode desain inovatif untuk pola anyaman serta berusaha mendorong pembangunan berkelanjutan dalam budaya kerajinan anyaman. *Deep learning* digunakan dalam penelitian ini seperti pada Gambar 2.17 untuk memahami dengan akurat persepsi emosional terhadap pola anyaman dan secara kreatif menghasilkan skema desain pola yang sesuai dengan preferensi emosional pengguna.



Gambar 2.18 Metode pengembangan pola anyaman berbasis deep Learning (Wang et al., 2023)

Model ResNet-34 digunakan dalam pengenalan gambar pola anyaman dengan hasil eksperimen menunjukkan efektivitas sebesar 94.36%. Model generasi desain otomatis untuk pola anyaman menggunakan DCGAN. Hasil generasi gambar kemudian digunakan sebagai sumber inspirasi bagi desainer untuk inovasi dalam menciptakan pola anyaman.

(Kobayashi & Kume, 2023) *Design Generation Using Stable Diffusion and Questionnaire Survey*

Penelitian ini bertujuan untuk mengembangkan sebuah metode baru untuk generasi desain produk dengan menggunakan teknik generasi gambar berbasis *Stable Diffusion* dan dikombinasikan dengan survei kuesioner. Metode ini menggunakan kata-kata *Kansei* sebagai *prompt* untuk menilai karakteristik yang diinginkan. Survei kuesioner dilakukan untuk mengidentifikasi preferensi pelanggan dan kesan yang diinginkan pelanggan terhadap produk.

Penelitian dimulai dari generasi gambar produk dengan kesan spesifik menggunakan *Stable Diffusion* berdasarkan prompt yang berisi kata-kata *Kansei*. Tahap selanjutnya verifikasi kesan pelanggan terhadap produk melalui survei

kuesioner. Selanjutnya, evaluasi preferensi pelanggan terhadap produk melalui survei kuesioner. Tahap terakhir penyesuaian (*fine-tuning*) dan generasi gambar produk.

Usulan metode diterapkan peneliti pada desain kursi untuk memverifikasi metode *Stable Diffusion* dalam menghasilkan desain. Peneliti memilih kursi dengan alasan menawarkan variasi desain yang luas serta erat kaitannya dengan emosi dan kesan pengguna. Hasilnya menunjukkan bahwa metode yang diusulkan efektif dalam menciptakan desain produk yang tidak hanya memenuhi ekspektasi fungsional tetapi juga memiliki nilai estetika dan emosional yang tinggi bagi pengguna.

(Khalida, 2022) *Pemanfaatan Word Embedding sebagai Pemandu GAN untuk Pembangkit Pola Batik*

Penelitian ini bertujuan untuk menghasilkan motif batik yang sesuai dengan deskripsi teks yang diberikan oleh perancang dan memperluas variasi motif batik yang dapat dihasilkan dengan memanfaatkan algoritma GAN yang dipadukan dengan model *word embedding*.

Pengembangan algoritma *encoding* menggunakan kombinasi *Word2Vec* dan *GloVe* bertujuan untuk mengonversi deskripsi teks menjadi format yang dapat dipahami oleh GAN. Generasi citra dilakukan dengan arsitektur DCGAN dan penambahan fungsi dari GAN CLS dan GAN INT untuk menangani input teks. Teknik mosaik juga diterapkan pada gambar yang dihasilkan untuk meningkatkan variasi dan estetika motif batik yang dihasilkan oleh GAN. Penelitian ini tidak membahas konsep *Kansei* yang berkaitan dengan aspek emosional, melainkan menggunakan deskripsi teks yang mengacu pada "*Ensiklopedia The Heritage Of Batik*".

Pengembangan algoritma kombinasi *word embedding Word2Vec* dan *GloVe* yang menghasilkan gambar motif batik dengan skor FID terbaik yaitu 78 dan nilai akurasi tertinggi sebesar 89%. Penelitian yang dilakukan berhasil menciptakan purwa-rupa perangkat lunak yang mampu menghasilkan motif batik lebih bervariasi dan mampu menghindari masalah mode collapse dalam penggunaan GAN.

Tabel 2.1. Ringkasan Kajian Penelitian

Peneliti, Tahun	Subjek Penelitian	Metode Penelitian	Kata <i>Kansei</i> / Kata afektif	Kelebihan	Kekurangan
(X. Li et al., 2021)	Generasi citra produk	Pengenalan Preferensi Afektif : PAR-ResNet Generasi citra: PD-GAN Objek: Bor dan Helm sepeda	Ergonomis – Tidak nyaman, ringkas – rumit, kuat – tidak berdaya, Praktis – Tidak Praktis, Praktis – Besar dan Menarik – Tidak Estetis	Pengembangan arsitektur ResNet-18 menjadi PAR-ResNet memiliki akurasi yang lebih tinggi jika dibandingkan dengan Alex-Net, VGG-11 dan VGG-16	Kekurangan penelitian terletak pada proses augmentasi data yang masih dilakukan secara manual dengan perangkat lunak desain.
(C. Yang et al., 2021)		Pengenalan gambar produk : VGGNet-16 Generasi citra: DCGAN dan Conditional GAN Objek: Sepatu	Pria-Wanita, Modern-Retro, Santai-Formal, Cantik-Biasa	Model CGAN mampu menghasilkan desain sepatu dengan perbedaan gaya.	Terdapat beberapa kegagalan dalam pembentukan citra sepatu seperti beberapa bagian terpisah dari badan sepatu dan terlalu banyak noise pada gambar
(Zhou et al., 2021)		Pengenalan gambar produk: MeiduNet Generasi citra: DCGAN Objek: Tampak depan mobil	Estetik dan tidak estetik	Pengembangan arsitektur CNN berbasis VGGNet yang dinamakan MeiduNet memiliki tingkat akurasi yang tinggi jika dibandingkan dengan SlimNet dan AlexNet.	Resolusi gambar yang dihasilkan kecil 64*64 sehingga gambar tidak jelas.

Tabel 2.1. Ringkasan Kajian Penelitian (Lanjutan)

Peneliti, Tahun	Subjek Penelitian	Metode Penelitian	Kata <i>Kansei</i> / Kata afektif	Kelebihan	Kekurangan
(Kobayashi & Kume, 2023)	Generasi citra produk	Generasi citra: Stable Diffusion Input teks ke model: Kata afektif Objek: Kursi	Bulat-persegi, sejuk-imut, mewah-sederhana, dan lembut-keras	Metode yang diusulkan menghasilkan gambar produk yang disukai pengguna serta menggunakan pendekatan yang responsif dengan umpan balik langsung dari pelanggan	Belum memanfaatkan fitur penyesuaian bobot kata dalam prompt <i>Stable Diffusion</i>
(Wu & Zhang, 2022)	Generasi citra motif/pola	Pengenalan gambar produk: ResNet-50 Generasi citra: DCGAN Objek: Motif payung kertas minyak klasik	Klasik dan modern	DCGAN terbukti menghasilkan desain payung yang bermakna untuk produksi berdasarkan verifikasi desainer produk terhadap hasil generasi gambar.	Kurangnya kemampuan jaringan di mana ukuran gambar asli sekitar 600×600 piksel, sedangkan model menghasilkan gambar sebesar 64×64 piksel, sehingga banyak detail gambar yang tidak dapat terlihat.
(Wang et al., 2023)		Pengenalan gambar produk: ResNet-34 Generasi citra: DCGAN Objek: Pola kerajinan anyaman	Kesenangan, kenyamanan, estetika, tradisional dan modern	ResNet mencapai akurasi pengenalan yang tinggi jika dibandingkan dengan VGGNet dan CaffeNet	Pola anyaman rumit membuat DCGAN tidak dapat menampilkan detail spesifik dan ukuran jaringan hanya dapat menghasilkan gambar kasar $64 * 64$, sehingga detail tidak terlihat dan buram.

Tabel 2.1. Ringkasan Kajian Penelitian (Lanjutan)

Peneliti, Tahun	Subjek Penelitian	Metode Penelitian	Kata <i>Kansei</i>/ Kata afektif	Kelebihan	Kekurangan
(Khalida, 2022)	Generasi citra motif/pola	Word embedding: Word2Vec dan GloVe Generasi citra: DCGAN	-	Arsitektur jaringan saraf GAN yang dikembangkan mampu menghindari terjadinya mode collapse. Evaluasi skor FID yang didapat yaitu 78 dan akurasi sebesar 89%.	Terbatasnya dataset jenis batik yang digunakan dan resolusi gambar masih perlu ditingkatkan melalui modifikasi arsitektur GAN.

2.11 Roadmap Penelitian

Penelitian terdahulu terkait *Kansei Engineering* dan *Generative Adversarial Network* (GAN) untuk optimasi proses desain secara garis besar memiliki tahapan yang sama yaitu pengenalan preferensi afektif dan generasi citra dengan menggunakan GAN.

Pengenalan preferensi afektif yang dilakukan (X. Li et al., 2021) menggunakan pendekatan KE dan modifikasi arsitektur Residual Network (ResNet-18) yaitu PAR-ResNet. Pelabelan didasari kata *Kansei* ergonomis – tidak nyaman, ringkas – rumit, kuat – tidak berdaya, praktis – tidak praktis, praktis – besar dan menarik – tidak estetik. Modifikasi kecil terletak pada tambahan deformation layer sebelum linear layer terakhir yang bernama flatter layer. Tingkat akurasi PAR-ResNet menunjukkan angka 87.10% yang mana memiliki akurasi yang lebih tinggi jika dibandingkan dengan Alex-Net yaitu sebesar 64.83%, VGG-11 sebesar 54.13% dan VGG-16 sebesar 77.22%. Pengenalan citra produk yang dilakukan (C. Yang et al., 2021) menggunakan pendekatan KE dan arsitektur VGGNet-16 yang menunjukkan tingkat akurasi sebesar 79% dengan pelabelan menggunakan kata *Kansei* pria-wanita, modern-retro, santai-formal, cantik-biasa. Penelitian (Zhou et al., 2021) menggunakan pendekatan evaluasi estetika dan arsitektur CNN yaitu MeiduNet yang dirancang berdasarkan jaringan VGG dengan tingkat akurasi yang lebih besar yaitu 98.9% , jika dibandingkan dengan AlexNet dengan tingkat akurasi 93%. Perbedaan terletak pada penelitian (Kobayashi & Kume, 2023) yang membuat gambar produk dengan survey questioner melalui petunjuk (prompt) berupa kata *Kansei* sebagai input ke *stable diffusion*. Kata *Kansei* yang digunakan yaitu bulat-persegi, sejuk-imut, mewah-sederhana, dan lembut-keras. Terdapat kekurangan dalam penelitian yaitu tidak dijelaskannya proses identifikasi atau diperolehnya kata *Kansei*.

Penelitian generasi citra motif atau pola yang dilakukan (Wu & Zhang, 2022) menggunakan modifikasi arsitektur *Residual Network* (ResNet-50) untuk percobaan pengenalan gambar motif payung kertas minyak klasik. Pengenalan gambar produk didasarkan kepada klasifikasi payung klasik dan modern. Hasilnya menunjukkan tingkat akurasi pengenalan gambar produk sebesar 94.30%. Masih

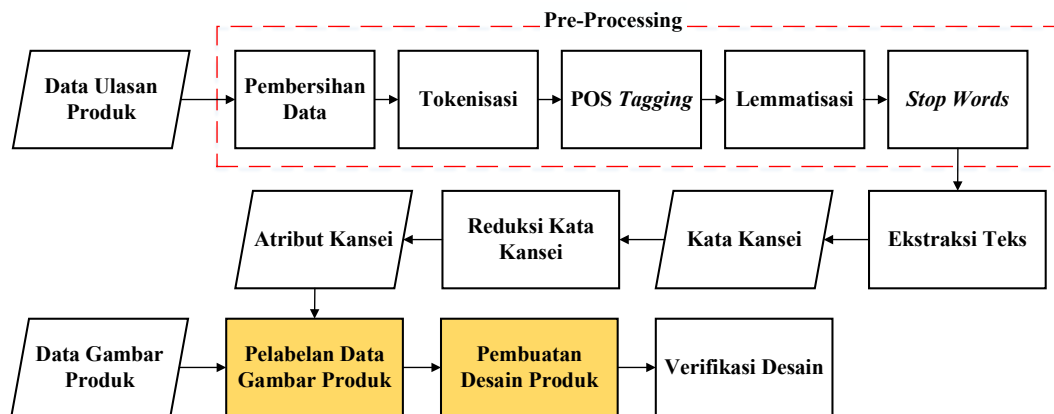
dengan penelitian generasi citra motif atau pola, penelitian (Wang, Ma, & Yang, 2023) menggunakan arsitektur ResNet-34 untuk percobaan pengenalan gambar desain pola anyaman. Pengenalan gambar produk didasarkan kepada atribut *Kansei* kesenangan, kenyamanan, estetika, tradisional dan modern. Hasil menunjukkan tingkat akurasi pengenalan pola sebesar 95.92%.

Tahap generasi citra berdasarkan penelitian (Wu & Zhang, 2022; Wang, Ma, & Yang, 2023; Zhou, Liu, Zhang, & Ouyang, 2021) menggunakan DCGAN untuk menghasilkan citra produk. DCGAN dipilih karena arsitektur jaringan yang tidak terlalu kompleks dan kemampuannya yang kuat dalam mempelajari representasi fitur tingkat tinggi dalam data, yang membuatnya sangat efektif untuk tugas-tugas yang melibatkan gambar. Generasi citra pada penelitian (C. Yang et al., 2021) memiliki perbedaan yaitu mengkombinasikan penggunaan CGAN dengan DCGAN, sementara penelitian (X. Li, Su, Zhang, & Bai, 2021) menggunakan model PD-GAN yaitu model berbasis DCGAN dan *residual blocks*. Penelitian lainnya dilakukan oleh (Khalida, 2022) dengan menggabungkan model *word embedding*, yaitu *Word2Vec* dan *GloVe* dalam menciptakan motif batik berdasarkan deskripsi teks. Sebagian besar penelitian terdahulu menggunakan DCGAN karena stabilitas yang baik dan memungkinkan untuk dilakukan modifikasi, sedangkan secara garis besar kekurangan dari penelitian terdahulu yaitu terletak pada hasil generasi citra yang buram dan belum detail.

BAB 3

METODOLOGI

Penelitian ini menggunakan pendekatan *text mining* sebagai efisiensi metode *Kansei Engineering* (KE) dan *Generative Adversarial Networks* (GAN) untuk mengoptimalkan desain produk berdasarkan preferensi afektif yang diekstraksi dari ulasan pelanggan. Metode yang digunakan melibatkan beberapa tahapan utama yang dijelaskan dalam diagram alur penelitian pada Gambar 3.1.



Gambar 3.1 Alur penelitian

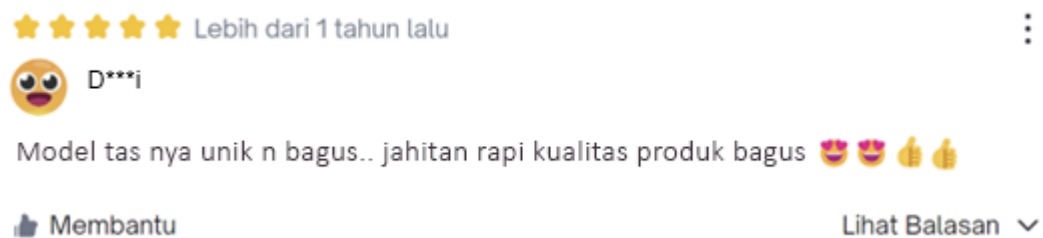
Proses dimulai dengan pembersihan data ulasan produk, meliputi pembersihan data, penghapusan *stopwords*, *part of speech* (POS) *tagging*, dan lemmatisasi untuk mendapatkan teks yang bersih. Ekstraksi teks dengan n-gram dan TF-IDF digunakan untuk menilai pentingnya kata dalam ulasan, menghasilkan kata *Kansei* yang mencerminkan emosi atau perasaan pengguna. Kata *Kansei* yang telah terkumpul selanjutnya direduksi untuk mendapatkan atribut *Kansei*.

Bagian berwarna kuning pada diagram menyoroti fokus penelitian pada pelabelan data gambar produk dan pembuatan desain produk. Pelabelan data gambar produk melibatkan pemberian label pada gambar berdasarkan atribut *Kansei* yang diidentifikasi untuk mencocokkan preferensi afektif dalam pembuatan desain visual menggunakan GAN. GAN kemudian digunakan untuk menghasilkan desain produk baru berdasarkan label afektif. Langkah terakhir

adalah verifikasi desain untuk memastikan bahwa desain yang dibentuk memenuhi kriteria preferensi afektif yang telah diidentifikasi sebelumnya.

3.1 Data Ulasan Produk

Pengumpulan data ulasan produk dilakukan pada *e-commerce* Tokopedia.com seperti pada Gambar 3.2 untuk memastikan bahwa penilaian berasal dari pelanggan yang telah membeli produk secara langsung. Tokopedia dipilih sebagai sumber data karena jumlah pengguna yang besar di Indonesia dan kemampuannya menyediakan berbagai macam produk dengan ulasan dari pengguna, selain itu faktor aksesibilitas data juga menjadi pertimbangan. Kata kunci “Tas belanja” digunakan untuk pencarian karena relevansinya dengan produk yang akan dianalisis.



Gambar 3.2 Ulasan pelanggan


Produk yang dipilih yaitu produk dengan dari toko Sovlo, Hawman dan Kamalika Artprints. Toko-toko tersebut dipilih karena reputasi baik, fokus pada penjualan produk tas dan fashion serta memiliki banyak jenis tas yang ditawarkan, sehingga dapat dipastikan bahwa data yang dianalisis cukup representatif. Desain visual tas yang dijual sangat relevan dengan penelitian yang akan meneliti mengenai aspek visual. Metode *scraping* digunakan untuk pengambilan data ulasan digunakan dalam penelitian ini karena memungkinkan pengumpulan data dalam jumlah besar dengan efisien. Data yang terkumpul selanjutnya akan disimpan dalam format CSV dan dianalisis menggunakan metode *text mining* untuk mengekstrak wawasan mengenai persepsi konsumen terhadap berbagai desain tas belanja.

3.2. Pre-processing Text

Tahap *pre-processing* atau pra-pemrosesan teks dalam *text mining* digunakan untuk menganalisis ulasan produk dengan fokus pada identifikasi kata sifat (*adjective*) yang paling sering muncul. Tahap pra-pemrosesan teks dilakukan untuk membersihkan dan mengubah data menjadi yang lebih terstruktur.

3.2.1 Pembersihan Data

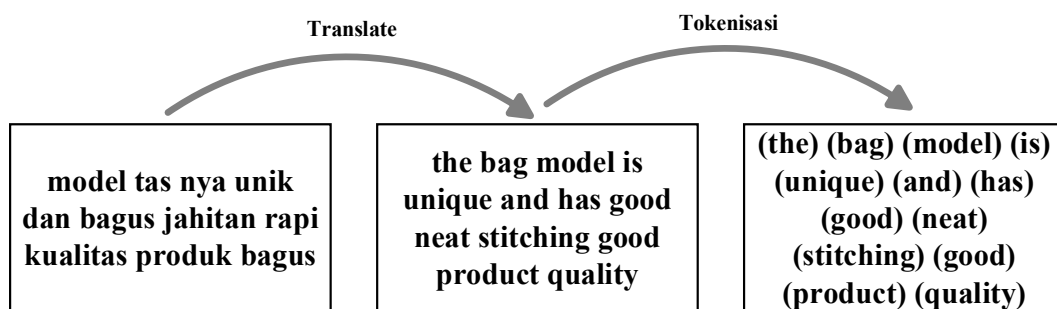
Pembersihan data melibatkan beberapa proses diantaranya *remove regex*, *case folding* dan *clean emoticon*, serta *remove slang word*. Proses pertama adalah *remove regex* untuk menghapus elemen yang tidak memberikan nilai tambah untuk analisis teks seperti tanda baca, *uniform resource locator* (url), *hashtag*, karakter, angka yang tidak berkontribusi pada makna suatu frasa atau kalimat karena akan menambah noise pada data. Tahap berikutnya adalah *case folding* untuk mengubah semua huruf dalam teks menjadi huruf kecil, sementara *clean emoticon* adalah proses penghapusan atau filter emotikon dari teks untuk membersihkan data. Langkah terakhir dalam pembersihan data adalah *remove slang word* untuk menghapus atau mengganti kata-kata slang atau kata gaul atau tidak formal dari teks untuk meningkatkan kejelasan dan formalitas dalam analisis data. Gambar 3.3 menunjukkan hasil pembersihan data dari setiap tahapan.



Gambar 3.3 Pembersihan data

3.2.2 Tokenisasi

Tokenisasi adalah proses memecah teks menjadi unit-unit yang lebih kecil, atau token. Tokenisasi kata digunakan untuk membagi teks menjadi array token. Hasil pemecahan teks ditunjukkan pada Gambar 3.4. Sebelum menuju proses tokenisasi teks diterjemahkan ke dalam bahasa Inggris sebelum tahap *Part of speech* (POS) tagging karena alat dan model *natural language processing* (NLP) yang banyak tersedia serta terlatih secara ekstensif pada data bahasa Inggris, sehingga dapat meningkatkan akurasi dan efektivitas analisis.



Gambar 3.4 Tokenisasi

3.2.3 *Part of Speech Tagging*

Part of speech (POS) tagging adalah proses penentuan kelas kata atau kategori gramatikal di mana setiap kata dalam teks diberi label sesuai dengan kelas anotasi Penn Treebank seperti yang ditunjukkan pada Tabel 3.1.

Tabel 3.1 Anotasi Penn Treebank

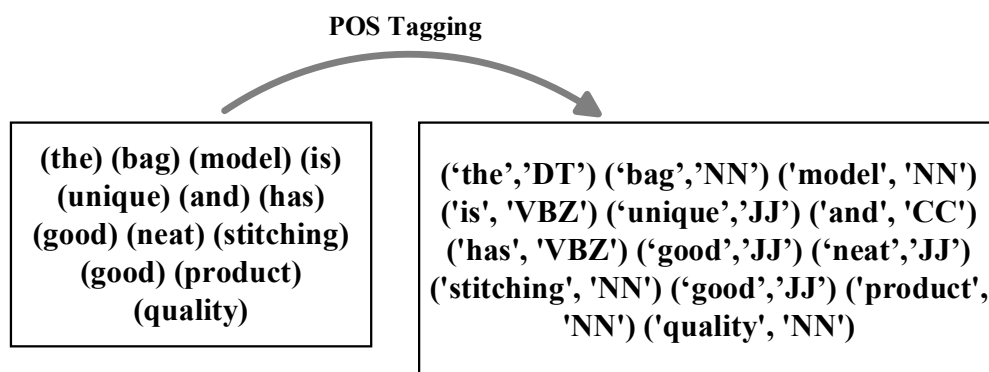
Tag	Arti
DT	Determiner
NN	Noun, singular or mass
NNS	Noun, plural
VB	Verb, base form
VBD	Verb, past tense
VBG	Verb, gerund or present participle
JJ	Adjective
RB	Adverb

Tabel 3.1 Anotasi Penn Treebank (Lanjutan)

Tag	Arti
CC	Coordinating conjunction
PRP	Personal pronoun
IN	Preposition or subordinating conjunction
UH	Interjection
CD	Cardinal number
MD	Modal

Sumber: (Marcus, Marcinkiewicz and Santorini, 1993)

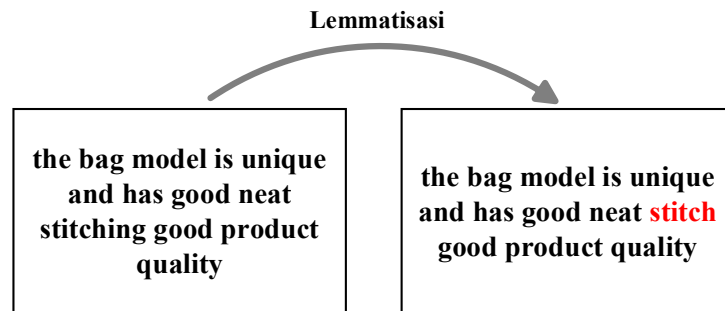
Model algoritma yang digunakan untuk melakukan POS tagging adalah *Averaged Perceptron Tagger* yang tersedia di pustaka *Natural Language Toolkit* (NLTK). Fokus utama pada penelitian ini adalah mengidentifikasi kata sifat (*adjective*) sebagai kata *Kansei* yang mewakili perasaan konsumen. Menurut (Schutte *et al.*, 2024) kata sifat penting untuk menghubungkan persepsi subjektif pengguna dengan karakteristik produk yang dapat diukur. Kata sifat memungkinkan peneliti untuk mendapatkan gambaran bagaimana pengguna melihat dan merasakan suatu produk. Gambar 3. menunjukkan hasil pelabelan dari proses POS tagging.



Gambar 3.5 POS *tagging*

3.2.4 Lemmatisasi

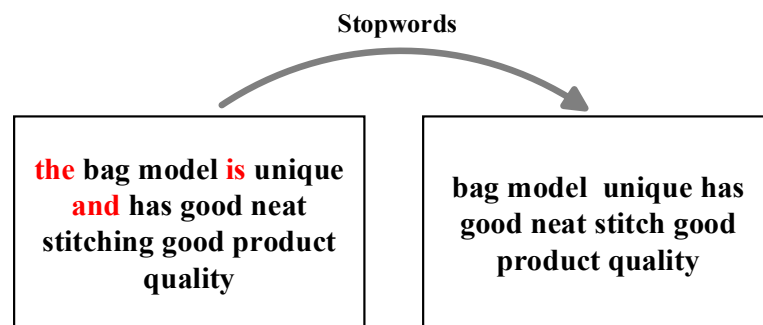
Lemmatisasi adalah proses pengurangan kata ke bentuk dasar. Lemmatisasi bekerja dengan mengembalikan kata ke bentuk dasar atau lemma, yang merupakan kata valid, dengan mempertimbangkan konteks gramatikalnya, seperti pada Gambar 3.6 mengubah “stitching” menjadi “stitch”.



Gambar 3.6 Lemmatisasi

3.2.5 Penghapusan *Stop Words*

Stop words adalah kata-kata yang sangat umum dalam sebuah bahasa tetapi dalam pencarian kata *Kansei* dimana kata yang diperlukan merupakan kata sifat, pada akhirnya *stop words* tidak memiliki makna yang signifikan. Stopwords yang sering muncul dalam kalimat diantaranya “and”, “is”, “the” dan masih banyak lagi. Penghapusan *stop words* dilakukan pada tahap akhir *pre-processing text* agar tidak memengaruhi pelabelan kata pada tahap POS tagging. Proses ini dilakukan agar fokus pada kata-kata yang berbobot serta memastikan bahwa analisis teks mampu memberikan informasi penting mengenai persepsi terhadap produk tas belanja. Gambar 3.7 merupakan hasil penghapusan *stopwords*.



Gambar 3.7 Penghapusan *stop words*

3.3 Ekstraksi Teks

Ekstraksi teks digunakan untuk mengidentifikasi kata-kata penting dari sebuah teks berdasarkan seberapa sering kata tersebut muncul dalam dokumen tertentu dibandingkan dengan kemunculannya di seluruh kumpulan dokumen dengan *Term Frequency-Inverse Document Frequency* TF-IDF

3.3.1 *Term Frequency-Inverse Document Frequency* (TF-IDF)

Term Frequency-Inverse Document Frequency (TF-IDF) digunakan untuk mengevaluasi tingkat kepentingan kata yang telah diidentifikasi melalui proses *preprocessing*. Cara kerja TF-IDF memadukan dua konsep yaitu *Term Frequency* (TF) dan *Inverse Document Frequency* (IDF). *Term Frequency* mengukur seberapa sering sebuah kata muncul dalam dokumen. Berdasarkan persamaan 3.1, jika sebuah kata muncul lebih sering dalam dokumen, maka nilai TF akan semakin tinggi, menandakan pentingnya kata tersebut dalam dokumen. Tahap ini memberikan bobot lebih pada kata yang muncul lebih sering dalam sebuah dokumen tertentu. TF dihitung dengan rumus:

$$TF(t, d) = \frac{\text{Frekuensi kata } t \text{ dalam dokumen } d}{\text{Total kata dalam dokumen } d} \quad (3.1)$$

Selanjutnya menghitung *Inverse Document Frequency* untuk mengukur seberapa penting sebuah kata dalam kumpulan dokumen IDF memberikan bobot lebih pada kata yang jarang muncul di seluruh dokumen, karena kata yang lebih unik cenderung lebih informatif. Berdasarkan persamaan 3.2 penambahan 1 pada bagian penyebut digunakan untuk menghindari pembagian dengan nol dan logaritma digunakan untuk memastikan bahwa kata yang muncul di hampir semua dokumen tidak mendapatkan bobot negatif. IDF dihitung dengan rumus:

$$IDF(t) = \log \frac{\text{Total dokumen}}{\text{Jumlah dokumen yang mengandung kata } t + 1} \quad 3.2$$

Setelah menghitung TF dan IDF, skor TF-IDF untuk kata (t) dalam dokumen (d) dihitung dengan mengalikan kedua nilai tersebut:

$$TF - IDF(t, d) = TF(t, d) \times IDF(t) \quad 3.3$$

Skor TF-IDF tertinggi menunjukkan kata atau frasa yang penting. Kata sifat yang sering muncul dalam ulasan pelanggan disebut kata *Kansei* atau kata afektif karena dianggap mampu menangkap gambaran produk yang dimiliki oleh sebagian besar konsumen.

3.3.2 Pengumpulan Kata *Kansei*

Elemen desain yang menjadi pertimbangan diantaranya pola (*patterns*), bentuk atau model (*shapes*), dan warna (*colors*). Penelitian Li (2013) menyoroti bahwa elemen tersebut dapat menarik perhatian konsumen dan mempengaruhi keputusan pembelian tas belanja. Elemen desain tersebut digunakan untuk menilai kata *Kansei* yaitu kata sifat yang menggambarkan reaksi emosional dan persepsi konsumen terhadap elemen visual tersebut. Kata sifat yang berkaitan dengan fungsionalitas, bahan produk dan selain elemen visual produk dieliminasi.

3.4. Reduksi Kata *Kansei*

Menurut (Schütte, 2005) kata *Kansei* yang didapat dari persepsi pengguna sering memiliki makna yang tumpang tindih, di mana satu kata dapat mencerminkan beberapa emosi atau persepsi yang saling berhubungan. Reduksi kata *Kansei* diperlukan dalam hal ini untuk menyederhanakan dan memfokuskan analisis dengan mempertahankan variabel atau komponen yang paling penting agar proses desain menjadi lebih efisien dan efektif.

3.3.3 *Principal Component Analysis*

Principal Component Analysis (PCA) digunakan untuk memastikan bahwa kata-kata *Kansei* yang dipilih benar-benar merepresentasikan dimensi emosional yang relevan. Proses ini memungkinkan untuk mengurangi dimensi data dengan tetap mempertahankan informasi penting, sehingga memudahkan interpretasi dan visualisasi. Hasil dari PCA memberikan informasi tentang jumlah komponen yang signifikan dan item yang memiliki beban tinggi pada masing-masing komponen.

Hasil PCA yang akan dianalisis berupa nilai *eigen value* dan *loading factor* untuk menentukan atribut *Kansei* yang paling berpengaruh. Nilai *eigen* digunakan untuk menentukan berapa banyak informasi atau varians dalam data asli yang ditangkap oleh masing-masing komponen utama. Nilai *eigen* lebih dari satu dianggap sebagai faktor utama karena mampu menjelaskan sebagian besar variabilitas dalam data. *Loading factor* menunjukkan seberapa besar suatu variabel terkait dengan komponen tertentu. Menurut (Hair *et al.*, 2010) nilai *cut-off* yang biasa digunakan dalam penentuan variabel terkait yaitu lebih besar dari 0,3 namun nilai *cut-off* tetap dapat disesuaikan dengan konteks penelitian.

3.4 Dataset Gambar Produk

3.4.1 Pengumpulan Gambar Produk

Tahap pertama yaitu pengumpulan sampel gambar produk yang beragam dengan mencakup berbagai elemen desain visual produk untuk memastikan bahwa model yang akan dilatih memiliki kemampuan menghasilkan gambar yang baik. Pengumpulan gambar sampel produk dilakukan dengan teknik *web scrapping* pada situs belanja daring yang relevan dan *website* penjualan tas belanja lainnya. Pengumpulan data ini harus mencakup lebih dari 10.000 sampel produk untuk memastikan keberagaman dan representasi yang memadai dari berbagai jenis dan model tas belanja yang tersedia di pasar. Kata kunci yang digunakan dalam pencarian produk merupakan jenis tas belanja yang banyak dijual di e-commerce diantaranya "Tas lipat parasut", "Tas belanja roda", "Tas kanvas", "Tas anyaman", "Tas karung goni", "Tas belanja kaus", "Tas kantong kertas", "Tas polypropylene", "Tas jaring", "Tas daur ulang plastik".



Gambar 3.8 Contoh *dataset* gambar tas belanja

3.4.2 *Pre-Processing* Gambar Produk

Tahap pengolahan awal gambar adalah tahap penting dalam analisis citra digital. Tujuan utamanya untuk meningkatkan kualitas gambar atau untuk mempersiapkan gambar sebelum dilakukan proses analisis lebih lanjut. Tahap pertama adalah penghapusan duplikasi, di mana gambar-gambar yang identik diidentifikasi dan dihapus untuk menghindari bias dan redundansi dalam *dataset*. Selanjutnya gambar dikonversi ke format seperti JPEG atau PNG untuk memastikan kompatibilitas dan efisiensi penyimpanan. Ukuran gambar diseragamkan ke dalam ukuran standar 256x256 piksel atau 128x128 piksel, untuk konsistensi dalam pelatihan model machine learning. Fitur *batch processing* pada Adobe Photoshop digunakan untuk pengubahan ukuran dan format, serta peningkatan kualitas gambar. Selanjutnya, tahap augmentasi data, di mana variasi tambahan dibuat dari gambar yang ada untuk meningkatkan jumlah dan keragaman data meliputi rotasi, flipping, zooming, pemotongan, dan perubahan kecerahan atau kontras.

3.5 Pelabelan Data Gambar Produk

Pelabelan data produk dengan pengenalan gambar produk atau pengenalan preferensi afektif bertujuan untuk memetakan emosi atau persepsi yang diekspresikan melalui atribut *Kansei* menjadi label yang sesuai untuk gambar produk. Proses ini memungkinkan otomatisasi pelabelan data besar secara efisien.

3.5.1 Kuesioner Semantic Differential 2


Tahap awal pelabelan yaitu penyebaran kuesioner SD kepada responden. Target responden terdiri dari tiga kelompok utama yaitu ahli desain produk, mahasiswa dengan jurusan desain produk atau teknik industri, dan konsumen yang memiliki pengalaman langsung dengan produk tas belanja. Kuesioner disusun dengan skala bipolar dengan atribut *Kansei* positif dan negatif seperti pada contoh Tabel 3.6.

Tabel 3.6 Contoh atribut *Kansei* positif dan negatif

Kata <i>Kansei</i> Positif	Kata <i>Kansei</i> Negatif
Beautiful	Ugly
Cool	Dull
Luxurious	Simple
Super	Mediocre
Unique	Common

Sebanyak 10% dari keseluruhan *dataset* sampel gambar dilabeli secara manual dengan menilai pasangan atribut *Kansei*. Gambar 3.9 merupakan bentuk umum kuesioner SD untuk pelabelan gambar.

Produk 1



-2 -1 0 1 2

Atribut Kansei 1 (Negatif) ○ ○ ○ ○ ○

Atribut Kansei 2 (Negatif) ○ ○ ○ ○ ○

⋮

Atribut Kansei n (Negatif Atribut)

Atribut Kansei 1 (Positif) ○ ○ ○ ○ ○

Atribut Kansei 2 (Positif) ○ ○ ○ ○ ○

⋮

Atribut Kansei n (Positif)

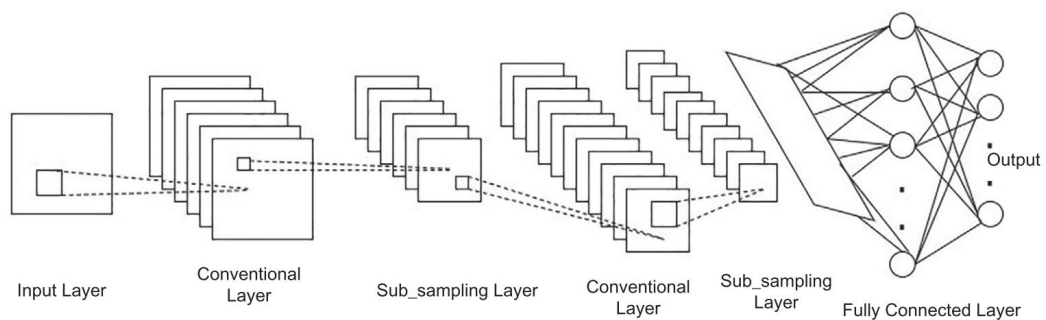
Gambar 3.9 Kuesioner SD 2 Pelabelan Gambar

3.5.2 Pengenalan Gambar Produk

Proses pengenalan gambar produk merupakan langkah penting pengembangan sistem pengenalan gambar dengan melibatkan pemberian label atau anotasi berdasarkan atribut *Kansei* pada gambar dalam kumpulan *dataset* untuk menyediakan informasi yang diperlukan, sehingga model pembelajaran mesin dapat belajar dan mengklasifikasikan gambar dengan akurat.

Langkah awal yang perlu dilakukan yaitu membangun model CNN yang terdiri dari beberapa lapisan konvolusi, *pooling*, dan *fully connected*. Arsitektur CNN yang telah digunakan dalam penelitian sebelumnya yaitu ResNet-18 (Li *et al.*, 2021), VGGNet-16 (Yang *et al.*, 2021), modifikasi VGGNet (Zhou *et al.*, 2021), ResNet-50 (Wu and Zhang, 2022) dan ResNet-34 (Wang, Ma and Yang, 2023) yang telah terbukti mampu menangkap fitur penting dari gambar.

Model pengenalan gambar dibangun dengan arsitektur *Convolutional Neural Networks* (CNN), sebuah metode *deep learning* yang efektif dalam pengenalan dan klasifikasi gambar. CNN dilatih menggunakan *dataset* gambar produk yang telah dilabeli secara manual dengan atribut *Kansei*. Model ini belajar dan dilatih untuk mengidentifikasi fitur-fitur penting dalam gambar yang terkait dengan preferensi afektif pengguna.



Gambar 3.10 Model Dasar CNN

Model CNN pada Gambar 3.10 terdiri dari beberapa lapisan yang bekerja bersama untuk melakukan tugas pengenalan gambar. Pertama, lapisan input menerima data mentah, seperti gambar dengan berbagai saluran warna. Data ini kemudian melewati lapisan konvolusi pertama yang menerapkan filter atau kernel untuk mendeteksi fitur dasar seperti tepi, sudut, dan tekstur, menghasilkan peta

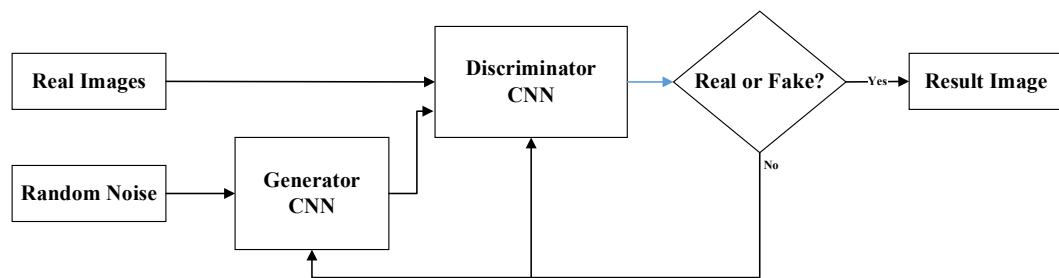
fitur. Lapisan *sub-sampling* atau *pooling* mengurangi dimensi peta fitur dengan metode seperti *max pooling* atau *average pooling*, yang membantu mengurangi jumlah komputasi dan mencegah *overfitting*. Peta fitur yang telah direduksi arsi kemudian memasuki lapisan konvolusi kedua, yang mendeteksi fitur yang lebih kompleks dari data yang telah disederhanakan. Lapisan ini diikuti oleh lapisan *sub-sampling* untuk mereduksi dimensi dan menyederhanakan fitur yang telah diekstraksi. Setelah melalui perulangan proses konvolusi dan *pooling*, hasil diteruskan ke lapisan *fully connected*.

Setelah pelatihan, model ini dapat digunakan untuk menganalisis gambar baru dan memberikan prediksi label berdasarkan pola yang telah dipelajarinya. Model yang dibangun nantinya mampu mengklasifikasikan gambar baru sesuai dengan label atribut *Kansei*.

3.7 Proses Pembuatan Desain


3.7.1 Arsitektur Dasar GAN

Setelah *dataset* gambar produk dilabeli dengan atribut *Kansei*, langkah selanjutnya adalah membangun model *Generative Adversarial Network* (GAN). Penelitian ini menggunakan *Deep Convolutional Generative Adversarial Networks* (DCGAN) yaitu varian GAN yang menggunakan arsitektur *convolutional neural networks* (CNN) untuk menghasilkan gambar. Penelitian ini menggunakan DCGAN karena kemampuannya yang unggul dalam stabilitas pelatihan, efisiensi generasi gambar karena jaringan relatif sederhana jika dibandingkan dengan model GAN lainnya dan memiliki kemampuan generasi gambar yang cukup baik, terbukti dalam penelitian (Li *et al.*, 2021), (Wu and Zhang, 2022) dan (Wang, Ma and Yang, 2023) yang mampu menghasilkan gambar sesuai dengan preferensi konsumen. DCGAN terdiri dari dua komponen utama generator dan diskriminator seperti pada Gambar 3.11.




Gambar 3.11 Arsitektur dasar DCGAN

Gambar 3.12 menunjukkan jaringan generator dimulai dengan input berupa vektor z berukuran 100 yang melalui proses proyeksi dan pemodelan ulang menjadi tensor $4 \times 4 \times 1024$. Tensor kemudian diolah melalui empat lapisan konvolusi transpos atau disebut juga sebagai dekonvolusi yang masing-masing bertujuan untuk memperluas dimensi spasial dari gambar sambil mengurangi kedalaman jumlah saluran atau fitur tensor. Lapisan pertama konvolusi memperluas ukuran dari 4×4 menjadi 8×8 dan mengurangi kedalaman dari 1024 menjadi 512. Proses serupa terjadi pada lapisan berikutnya, dengan lapisan kedua yang mengubah ukuran menjadi 16×16 dan kedalaman menjadi 256, lapisan ketiga menjadi 32×32 dan kedalaman 128, dan lapisan keempat menjadi 64×64 dengan kedalaman berkurang menjadi 64. Jaringan ini menggunakan *stride* 2 pada setiap lapisan konvolusi transpos, artinya kernel filter berpindah dua piksel untuk setiap operasi. Tujuan akhir dari jaringan ini adalah untuk menghasilkan *generated picture* di ujung jaringan menciptakan data baru yang mendekati dengan data latih yang digunakan untuk melatih jaringan.



Gambar 3.12 Struktur jaringan generator

Gambar 3.13 menunjukkan jaringan diskriminator melalui proses yang terbalik. Jaringan ini dimulai dengan gambar input berukuran 64x64x3. Setelah melalui beberapa lapisan konvolusi (conv), ukuran gambar secara bertahap dikurangi sementara jumlah filter bertambah. Lapisan pertama (conv1) menghasilkan output berukuran 32x32x128, lapisan kedua (conv2) menghasilkan 16x16x256, lapisan ketiga (conv3) menghasilkan 8x8x512, dan lapisan keempat (conv4) menghasilkan 4x4x1024. Setelah lapisan konvolusi, output melalui proses *flatten* menjadi vektor satu dimensi dan kemudian melewati lapisan *fully connected* (FC) yang menghasilkan probabilitas untuk kelas target.



Gambar 3.13 Struktur jaringan discriminator

3.7.2 Pelatihan Model GAN

Proses pelatihan model DCGAN dimulai dengan generator menerima input berupa vektor acak. Vektor ini kemudian diubah oleh generator melalui serangkaian lapisan dekonvolusi menjadi gambar yang realistis dan sesuai dengan atribut *Kansei*. Diskriminator menerima dua jenis input gambar asli dengan label atribut *Kansei* dan gambar palsu yang dihasilkan oleh generator. Diskriminator melalui lapisan konvolusi memproses gambar dan memberikan probabilitas apakah gambar tersebut asli atau palsu.

Hyperparameter merupakan konfigurasi yang ditetapkan sebelum proses pelatihan dimulai berdasarkan eksperimen dan penyesuaian untuk menemukan kombinasi optimal yang menghasilkan performa terbaik. Beberapa *hyperparameter* umum yang perlu diperhatikan dalam pelatihan GAN adalah laju

pembelajaran (*learning rate*), ukuran batch, jumlah *epoch*, *optimizer* untuk generator dan diskriminator, jumlah lapisan, jumlah unit dalam lapisan *dense*, fungsi aktivasi, dan fungsi *loss*.

Loss function atau fungsi *loss* merupakan hal penting dalam mengukur perbedaan antara prediksi model dan nilai sebenarnya. *Loss function* pada diskriminator bertujuan untuk membedakan antara gambar nyata dan gambar yang dihasilkan oleh generator. Nilai *loss* yang rendah menunjukkan bahwa diskriminator berhasil membedakan antara gambar nyata dan palsu dengan baik. *Loss function* pada generator berupaya menipu diskriminator agar menganggap gambar palsu sebagai nyata. Nilai *loss* yang rendah menunjukkan bahwa generator berhasil menipu diskriminator dengan baik, sehingga menghasilkan gambar yang terlihat nyata. Pelatihan dapat dihentikan ketika *loss function* pada generator maupun diskriminator mencapai konvergensi, yang berarti perubahan nilai *loss* antar epoch menjadi sangat kecil dan stabil.

3.7.3 Evaluasi Model GAN

Evaluasi kualitas gambar perlu dilakukan setelah proses pelatihan model GAN. Evaluasi metrik memainkan peran penting dalam menentukan seberapa baik model GAN bekerja dalam menghasilkan gambar yang realistis dan berkualitas tinggi. Hasil kualitas gambar diukur dengan *Frechet Inception Distance* (FID). Nilai FID rendah artinya generator telah menghasilkan gambar berkualitas tinggi, sebaliknya, jika nilai FID tinggi maka menunjukkan bahwa gambar yang dihasilkan memiliki kualitas yang lebih rendah.

3.8 Verifikasi Desain

Verifikasi desain dan atribut *Kansei* dilakukan dengan survey kuesioner untuk pengumpulan dan analisis umpan balik dari pengguna potensial mengenai hasil desain produk yang telah dibuat. Proses ini sangat penting dalam tahap pengembangan desain untuk memastikan bahwa desain yang telah dikembangkan memenuhi preferensi pengguna.

DAFTAR PUSTAKA

- Bhonde, S. B., Paikrao, R. L., & Rahane, K. U. (2010). Text association analysis and ambiguity in text mining. *AIP Conference Proceedings*, 1324, 204–206. <https://doi.org/10.1063/1.3526195>
- Burger, W., & Burge, M. J. (2016). *Digital Image Processing: An Algorithmic Introduction Using Java Second Edition*. In Springer (Vol. 24, Issue 11). <http://digital-library.theiet.org/content/journals/10.1049/ep.1978.0474%5Cnhttp://link.springer.com/10.1007/978-1-4471-6684-9>
- Chan, K. Y., Kwong, C. K., Wongthongtham, P., Jiang, H., Fung, C. K. Y., Abu-Salih, B., Liu, Z., Wong, T. C., & Jain, P. (2020). Affective design using machine learning: a survey and its prospect of conjoining big data. *International Journal of Computer Integrated Manufacturing*, 33(7), 645–669. <https://doi.org/10.1080/0951192X.2018.1526412>
- Chollet, F. (2018). *Deep learning with Python*. In *Machine Learning and Deep Learning in Real-Time Applications*. Manning Publications Co. <https://doi.org/10.4018/978-1-7998-3095-5.ch003>
- Ciancio, V., Homri, L., Dantan, J. Y., Siadat, A., & Convain, P. (2022). Development of a flexible predictive maintenance system in the context of Industry 4.0. *IFAC-PapersOnLine*, 55(10), 1576–1581. <https://doi.org/10.1016/j.ifacol.2022.09.615>
- Crolic, C., Zheng, Y., Hoegg, J., & Alba, J. W. (2019). The influence of product aesthetics on consumer inference making. *Journal of the Association for Consumer Research*, 4(4), 398–408. <https://doi.org/10.1086/705033>
- Dadgar, S. M. H., Araghi, M. S., & Farahani, M. M. (2016). A novel text mining approach based on TF-IDF and support vector machine for news classification. *Proceedings of 2nd IEEE International Conference on Engineering and Technology, ICETECH 2016, March*, 112–116. <https://doi.org/10.1109/ICETECH.2016.7569223>
- Darmawan, D. (2012). *Pendidikan Teknologi Informasi dan Komunikasi*. PT. Remaja Rosdakarya Offset. ipusnas
- Djatna, T., & Kurniati, W. D. (2015). A System Analysis and Design for Packaging Design of Powder Shaped Fresheners Based on Kansei Engineering. *Procedia Manufacturing*, 4(iess 2015), 115–123. <https://doi.org/10.1016/j.promfg.2015.11.021>
- Dou, R., Li, W., Nan, G., Wang, X., & Zhou, Y. (2021). How can manufacturers make decisions on product appearance design? A research on optimal design based on customers' emotional satisfaction. *Journal of Management Science and Engineering*, 6(2), 177–196. <https://doi.org/10.1016/j.jmse.2021.02.010>
- Du, Y., Zhang, M., Cai, M., & Park, K. (2024). Construction of Product Appearance Kansei Evaluation Model Based on Online Reviews and FAHP: A Case Study of Household Portable Air Conditioners. *Sustainability*, 16(8), 3132. <https://doi.org/10.3390/su16083132>

- Figoli, F. A., Rampino, L., & Mattioli, F. (2022). Artificial intelligence in the design process. FrancoAngeli. <http://bit.ly/francoangeli-oa>
- Ghiffari, M. A. (2018). Kansei Engineering Modelling for Packaging Design Chocolate Bar. SEAS (Sustainable Environment Agricultural Science), 2(1), 10. <https://doi.org/10.22225/seas.2.1.539.10-17>
- Gonzalez, R. C., & Woods, R. E. (2008). Digital Image Processing (third). Pearson Education.
- Goodfellow, I. J., Jean Pouget-Abadie, Mirza, M., Xu, B., & Warde-Farley, D. (2014). Generative Adversarial Nets. Advances in Neural Information Processing Systems, 3063–3071. <https://doi.org/10.1109/ICCVW.2019.00369>
- Hair, J. *et al.* (2010) *Multivariate Data Analysis.pdf*, Australia : Cengage.
- Hasti, T., Tibshirani, R., & Friedman, J. (2009). The Elements of Statistical Learning: Data Mining, Inference, and Prediction, Second Edition (2nd ed.). Springer. <https://doi.org/https://doi.org/10.1007/978-0-387-84858-7>
- Heryadi, Y., & Wayono, T. (2021). Dasar-Dasar Deep Learning dan Implementasinya. Gava Media.
- Hosgurmath, S., Petli, V., & Jalihal, V. K. (2022). An omicron variant tweeter sentiment analysis using NLP technique. Global Transitions Proceedings, 3(1), 215–219. <https://doi.org/10.1016/j.gltp.2022.03.025>
- Huang, S. (2022a). Product Innovation Design Method Based on BP Neural Network. Advances in Multimedia, 2022. <https://doi.org/10.1155/2022/6830892>
- Huang, S. (2022b). Product Innovation Design Method Based on BP Neural Network. In Advances in Multimedia (Vol. 2022). <https://doi.org/10.1155/2022/6830892>
- Ishihara, S., Ishihara, K., Nagamachi, M., & Matsubara, Y. (1997). An analysis of Kansei structure on shoes using self-organizing neural networks. International Journal of Industrial Ergonomics, 19(2), 93–104. [https://doi.org/10.1016/S0169-8141\(96\)00006-6](https://doi.org/10.1016/S0169-8141(96)00006-6)
- Ishihara, S., Nagamachi, M., Schütte, S., & Eklund, J. (2008). 20-Affective Meaning : the Kansei Engineering Approach. In H. N. J. Schifferstein & P. Hekkert (Eds.), Product Experience (pp. 477–496). Elsevier. <https://doi.org/https://doi.org/10.1016/B978-0-08-045089-6.X5001-1>
- Kailash Ahirwar. (2019). Generative Adversarial Networks Projects. Packkt Publishing Ltd.
- Kaji, N., Takenouchi, H., & Tokumaru, M. (2020). Performance Evaluation of T-Shirt Image Generation System Considering User's Preference. International Journal of Affective Engineering, 19(4), 283–291. <https://doi.org/10.5057/ijae.ijae-d-20-00004>
- Kaniappan Chinnathai, M., & Alkan, B. (2023). A digital life-cycle management framework for sustainable smart manufacturing in energy intensive industries. Journal of Cleaner Production, 419(July), 138259. <https://doi.org/10.1016/j.jclepro.2023.138259>

- Kobayashi, M., & Kume, K. (2023). Design Generation Using Stable Diffusion and Questionnaire Survey. 21(5), 226–231. <https://doi.org/10.14733/cadconfp.2023.226-231>
- Kotler, P., & Armstrong, G. (2018). Principles of Marketing, Seventeenth Edition. In Pearson (Seventh Ed). Pearson Education.
- Lecun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. *Nature*, 521(7553), 436–444. <https://doi.org/10.1038/nature14539>
- Li, D., & Du, Y. (2017). Artificial intelligence with uncertainty, second edition. In Artificial Intelligence with Uncertainty, Second Edition. <https://doi.org/10.1201/9781315366951>
- Li, X., Su, J., Zhang, Z., & Bai, R. (2021). Product innovation concept generation based on deep learning and Kansei engineering. *Journal of Engineering Design*, 32(10), 559–589. <https://doi.org/10.1080/09544828.2021.1928023>
- Li, Y., Wang, J., Li, X., & Zhao, W. (2007). Design creativity in product innovation. *International Journal of Advanced Manufacturing Technology*, 33(3–4), 213–222. <https://doi.org/10.1007/s00170-006-0457-y>
- Liu, Z., Wu, J., Chen, Q., & Hu, T. (2023). An improved Kansei engineering method based on the mining of online product reviews. *Alexandria Engineering Journal*, 65, 797–808. <https://doi.org/10.1016/j.aej.2022.09.044>
- Madenda, S. (2015). Pengolahan Citra dan Video Digital. Erlangga.
- Maidin, N. A., Sapuan, S. M., Mohammad Taha, M., & Zuhri, M. Y. M. (2024). Material selection and conceptual design in natural fibre composites. 9(1), 35–45. <https://doi.org/doi:10.1515/psr-2022-0073>
- Marcus, M.P., Marcinkiewicz, M.A. and Santorini, B. (1993) ‘Building a large annotated corpus of English: the Penn Treebank’, *Corpus Linguistics: Readings in a Widening Discipline*, 19(2), pp. 242–257.
- Mollahassani, D., Gries, J., Forte, S., & Göbel, J. C. (2022). Supporting Collaborative Innovation Processes in Smart Product Value Creation Networks. *Procedia CIRP*, 109(March), 349–355. <https://doi.org/10.1016/j.procir.2022.05.261>
- Morris, R. (2009). The Fundamentals of Product Design. In The Fundamentals of Product Design. AVA Book Production Pte. Ltd. <https://doi.org/10.5040/9781474221634>
- Mugobo, V. V., & Ntuli, H. (2022). Consumer Preference for Attributes of Single-Use and Multi-Use Plastic Shopping Bags in Cape Town: A Choice Experiment Approach. *Sustainability (Switzerland)*, 14(17). <https://doi.org/10.3390/su141710887>
- Muposhi, A., Mpinganjira, M., & Wait, M. (2021). Factors influencing the use of non-plastic reusable shopping bags: A cognitive-normative-habitual approach. *Australian Journal of Environmental Education*, 37(3), 306–325. <https://doi.org/10.1017/ae.2021.9>
- Nagamachi, M. (1995). Kansei engineering: A new consumer-oriented technology for product development. *International Journal of Industrial Ergonomics*, 15(1995), 3–11. <https://doi.org/10.1201/9780203010457>

- Nagamachi, M. (2002). Kansei Engineering as a Powerful Consumer-Oriented Technology for Product Development. *Applied Ergonomics*, 33, 289–294. [https://doi.org/https://doi.org/10.1016/S0003-6870\(02\)00019-4](https://doi.org/https://doi.org/10.1016/S0003-6870(02)00019-4)
- Nagamachi, M. (2002). Kansei Engineering as a Powerful Consumer-Oriented Technology for Product Development. *Applied Ergonomics*, 33, 289–294. [https://doi.org/https://doi.org/10.1016/S0003-6870\(02\)00019-4](https://doi.org/https://doi.org/10.1016/S0003-6870(02)00019-4)
- Nagamachi, M. (2008). Perspectives and the new trend of Kansei/affective engineering. *The TQM Journal*, 20(4), 290–298. <https://doi.org/10.1108/17542730810881285>
- Nagamachi, M., & Lokman, A. M. (2015). Kansei Innovation. In *Kansei Innovation*. CRC Press (Taylor & Francis Group). <https://doi.org/10.1201/b18054>
- Pasaribu, M., & Widjaja, A. (2022). *Artificial Intelligence: Perspektif Manajemen Strategis*. PT. Gramedia.
- Peraturan Gubernur DKI Jakarta No. 142 Tahun 2019 tentang Kewajiban Penggunaan Kantong Belanja Ramah Lingkungan., (2019). <https://example.com/pergubdki142-2019>
- Peraturan Presiden No. 97 Tahun 2017 tentang Kebijakan dan Strategi Nasional Pengelolaan Sampah, (2017). <https://example.com/perpres97-2017>
- Rahman, A., Winarko, E., & Mustofa, K. (2022). Product image retrieval using category-aware siamese convolutional neural network feature. *Journal of King Saud University - Computer and Information Sciences*, 34(6), 2680–2687. <https://doi.org/10.1016/j.jksuci.2022.03.005>
- Richard S. Sutton, A. G. B. (2015). Reinforcement learning: An Introduction. In *Decision Theory Models for Applications in Artificial Intelligence: Concepts and Solutions* (2nd ed.). MIT Press Cambridge. <https://doi.org/10.4018/978-1-60960-165-2.ch004>
- Russel, S. J., & Norvig, P. (2016). *Kecerdasan Buatan: Pendekatan Modern* (Third Edit). Pearson Education.
- Samuel, A. L. (1962). Artificial Intelligence: A Frontier of Automation. *The Annals of the American Academy of Political and Social Science*, 340(1), 10–20. <https://doi.org/10.1177/000271626234000103>
- Sari, Y., & Pramunendar, R. A. (2017). *Pengolahan Citra dalam Soft Computing* (1st ed.). CV Jejak.
- Simeone, A., Caggiano, A., Deng, B., & Boun, L. (2020). A deep learning based-decision support tool for solution recommendation in cloud manufacturing platforms. *Procedia CIRP*, 86, 68–73. <https://doi.org/10.1016/j.procir.2020.01.019>
- Solanki, A., Nayyar, A., & Naved, M. (2021). *Generative Adversarial Networks for Image-to-Image Translation*. Academic Press.
- Schütte, S. (2005) *Engineering Emotional Values in Product Design, Engineering*. Linköping.
- Schutte, S. et al. (2024) ‘Kansei for the Digital Era’, *International Journal of Affective Engineering*, 23(1), pp. 1–18. <https://doi.org/10.5057/ijae.ijae-d-23-00003>.

- Tanveer, U., Kremantzis, M. D., Roussinos, N., Ishaq, S., Kyrgiakos, L. S., & Vlontzos, G. (2023). A fuzzy TOPSIS model for selecting digital technologies in circular supply chains. *Supply Chain Analytics*, 4(2023), 1–16. <https://doi.org/10.1016/j.sca.2023.100038>
- Taufik, A., Sudarsono, B. G., Budiyantera, A., Sudaryana, I. K., & Muryono, T. T. (2016). *Pengantar Teknologi Informasi*. Pena Persada.
- Tomičić-Pupek, K., Srpak, I., Havaš, L., & Srpak, D. (2020). Algorithm for customizing the material selection process for application in power engineering. *Energies*, 13(23). <https://doi.org/10.3390/en13236458>
- Ulrich, K. T., & Eppinger, S. D. (2012). *Product design and development*. In McGraw-Hill Education (Sixth Edit). McGraw-Hill Education. https://doi.org/10.2166/9781789061840_0019
- Ushada, M., Suryandono, A., & Khuriyati, N. (2016). *Kansei Engineering untuk Agroindustri*. Gadjah Mada University Press.
- Vieira, M., Pinto-Varela, T., & Barbosa-Póvoa, A. P. (2019). A model-based decision support framework for the optimisation of production planning in the biopharmaceutical industry. *Computers and Industrial Engineering*, 129(January), 354–367. <https://doi.org/10.1016/j.cie.2019.01.045>
- Wang, B., & Li, Y. (2022). Consumers' Intention to Bring a Reusable Bag for Shopping in China: Extending the Theory of Planned Behavior. *International Journal of Environmental Research and Public Health*, 19(6). <https://doi.org/10.3390/ijerph19063638>
- Wang, T., Ma, Z., & Yang, L. (2023). Creativity and Sustainable Design of Wickerwork Handicraft Patterns Based on Artificial Intelligence. *Sustainability*, 15(2), 1574. <https://doi.org/10.3390/su15021574>
- Wang, W. M., Wang, J. W., Li, Z., Tian, Z. G., & Tsui, E. (2019). Multiple affective attribute classification of online customer product reviews: A heuristic deep learning method for supporting Kansei engineering. *Engineering Applications of Artificial Intelligence*, 85(May), 33–45. <https://doi.org/10.1016/j.engappai.2019.05.015>
- Wu, Y., & Zhang, H. (2022). Image style recognition and intelligent design of oiled paper bamboo umbrella based on deep learning. *Computer-Aided Design and Applications*, 19(1), 76–90. <https://doi.org/10.14733/CADAPS.2022.76-90>
- Wu, Y., & Zhang, H. (2022). Image style recognition and intelligent design of oiled paper bamboo umbrella based on deep learning. *Computer-Aided Design and Applications*, 19(1), 76–90. <https://doi.org/10.14733/CADAPS.2022.76-90>
- Yang, C., Zhou, Y., Zhu, B., Yu, C., & Wu, L. (2021). Emotionally intelligent fashion design using CNN and GAN. *Computer-Aided Design and Applications*, 18(5), 900–913. <https://doi.org/10.14733/cadaps.2021.900-913>
- Yang, C., Zhou, Y., Zhu, B., Yu, C., & Wu, L. (2021). Emotionally intelligent fashion design using CNN and GAN. *Computer-Aided Design and Applications*, 18(5), 900–913. <https://doi.org/10.14733/cadaps.2021.900-913>

- Yang, T., Yi, X., Lu, S., Johansson, K. H., & Chai, T. (2021). Intelligent Manufacturing for the Process Industry Driven by Industrial Artificial Intelligence. *Engineering*, 7(9), 1224–1230. <https://doi.org/10.1016/j.eng.2021.04.023>
- Yousef, M., & ALali, A. (2022). Analysis and Evaluation of Two Feature Selection Algorithms in Improving the Performance of the Sentiment Analysis Model of Arabic Tweets. *International Journal of Advanced Computer Science and Applications*, 13(6), 705–711. <https://doi.org/10.14569/IJACSA.2022.0130683>
- Zhang, M., Wang, C., Cai, L., Zhao, J., Xu, Y., Xing, J., Sun, J., & Zhang, Y. (2023). Developing a weakly supervised deep learning framework for breast cancer diagnosis with HR status based on mammography images. *Computational and Structural Biotechnology Journal*, 22, 17–26. <https://doi.org/10.1016/j.csbj.2023.08.012>
- Zhou, A., Liu, H., Zhang, S., & Ouyang, J. (2021). Evaluation and design method for product form aesthetics based on deep learning. *IEEE Access*, 9, 108992–109003. <https://doi.org/10.1109/ACCESS.2021.3101619>
- Zhu, M., Ji, Y., Zhang, Z., & Sun, Y. (2020). A data-driven decision-making framework for online control of vertical roller mill. *Computers and Industrial Engineering*, 143(March), 106441. <https://doi.org/10.1016/j.cie.2020.106441>