



**PENDETEKSIAN JENIS DAN PERHITUNGAN
VOLUME KERUSAKAN JALAN BERBASIS IMAGE
PROCESSING DAN DEEP LEARNING**

Kualifikasi

DYNA PRASETYA RIANI

99222004

**PROGRAM DOKTOR TEKNOLOGI INFORMASI
UNIVERSITAS GUNADARMA**

2024

DAFTAR ISI

| | Halaman |
|---|---------|
| 1 PENDAHULUAN | 4 |
| 1.1 Latar Belakang | 4 |
| 1.2 Rumusan Masalah | 7 |
| 1.3 Tujuan Penelitian..... | 8 |
| 1.4 Batasan Masalah..... | 8 |
| 1.5 Kontribusi..... | 8 |
| 2 TINJAUAN PUSTAKA | 10 |
| 2.1 Road Damage Detection/ Deteksi Kerusakan Jalan..... | 10 |
| 2.2 <i>Image Processing</i> / Pengolahan Citra | 12 |
| 2.3 Deep Learning..... | 13 |
| 2.4 Convolutional Neural Network (CNN)..... | 15 |
| 2.5 YOLO (You Only Look Once) | 18 |
| 2.6 Mobile Laser Scanner | 26 |
| 2.7 Deteksi Kerusakan Jalan Menggunakan Pengolahan Citra..... | 28 |
| 2.8 Perbandingan Penelitian..... | 30 |
| 3 METODE PENELITIAN | 42 |
| 3.1 Framework Riset | 42 |
| 3.2 Pengumpulan Data | 43 |
| 3.3 Anotasi dan Pelabelan | 43 |
| 3.4 Pembentukan Model Klasifikasi | 44 |
| 3.5 Implementasi dan Uji Coba Sistem..... | 44 |

| | | |
|-----|--------------------------------------|----|
| 3.6 | Evaluasi Hasil..... | 44 |
| 3.7 | Rencana Pelaksanaan Penelitian | 44 |
| | DAFTAR PUSTAKA..... | 46 |

1 PENDAHULUAN

1.1 Latar Belakang

Berdasarkan data pada Badan Pengelola Jalan Tol (BPJT) tahun 2022, ruas jalan tol yang terdapat di Indonesia yaitu sepanjang 2583,42 km. Pembangunan Jalan tol secara agresif dilakukan mulai tahun 2014 sejumlah kurang lebih 1900 km. Berdasarkan data dari KemenPUPR, ditargetkan hingga akhir 2024 akan tersambung jalan tol sepanjang total 3.196 km yang seluruhnya termasuk dalam Proyek Strategis Nasional yang diprioritaskan untuk selesai maksimal di tahun 2024. Dengan adanya perkembangan jalan tol tentu harus diiringi dengan pengembangan cara dalam perawatan jalan. Dalam perawatan jalan tentu dibutuhkan survei jalan yang dilakukan secara cepat dan berkala.

Data kondisi jalan yang diperoleh dari survei lapangan ditiap semester menggunakan peralatan konvensional seperti kendaraan survei kondisi jalan untuk menghasilkan data keluaran berupa IRI (International Roughness Index) dan PCI (Pavement Condition Index) yang masih mengalami keterbatasan dalam metode operating yang tergolong manual (frame per frame) sehingga memerlukan waktu yang cukup lama dalam pengolahan data. Kendaraan Survei Kondisi Jalan untuk menghasilkan data keluaran berupa IRI (International Roughness Index) dan PCI (Pavement Condition Index) yang masih mengalami keterbatasan dalam metode peratingan yang masih tergolong manual (frame per frame) sehingga memerlukan waktu yang cukup lama dalam pengolahan data.

Analisis tingkat kerusakan jalan yang berkolaborasi dengan teknologi AI menjadi hal yang diperlukan untuk mengatur strategi pemeliharaan jalan secara teratur, lebih efektif dan efisien dengan menghasilkan data yang lebih akurat. Implementasi kecerdasan buatan dalam manajemen infrastruktur seperti melakukan visualisasi prediksi kondisi jalan, identifikasi kondisi jalan, dan klasifikasi kendaraan.

Menanggapi masalah tersebut, banyak metode untuk melakukan pemeriksaan infrastruktur secara efisien, terutama kondisi jalan, telah dipelajari,

seperti metode yang menggunakan laser. Selain itu, terdapat penelitian menggunakan jaringan saraf tiruan untuk masalah teknik sipil dalam 11 tahun dari tahun 1989-2000 (Adeli, 2001). Selain itu, teknik visi komputer dan pembelajaran mesin telah berhasil diteapkan untuk mengotomatisasi inspeksi permukaan jalan (Chun dkk., 2015; Zalama dkk., 2014; Jo dan Ryu, 2015).

Pada dasarnya pendeteksian objek akan bermanfaat untuk mendeteksi objek sebuah gambar berdasarkan warna, bentuk, dan dari dataset yang dikumpulkan (Lin et al. 2020). Terdapat beberapa macam dalam membuat aplikasi pendeteksian objek seperti metode Convolutional Neural Network (CNN), metode SSD, dan metode You Only Look Once (YOLO) (Chakurkar et al. 2023).

Terbukti bahwa YOLO menjadi salah satu metode yang jauh lebih cepat dan akurat dalam mendeteksi objek pada gambar atau citra sehingga paling sesuai dengan tujuan penelitian jika diterapkan secara real-time pendeteksian objek. Dalam real-time pendeteksian objek kecepatan sangat penting dalam pendeteksian objek dikarenakan berbeda pada sebuah gambar, pada suatu vidio dapat mengolah lebih dari 24 frame per second (FPS) atau 24 frame per detik. Jika proses pendeteksian objek terlalu lama maka vidio yang dihasilkan kurang baik, akan mengalami delay pada setiap frame sehingga vidio menjadi patah-patah (Ding et al. 2019)

Analisa fungsional dilakukan melalui pemeriksaan kondisi jalan dengan dua cara, mekanikal maupun visual. Secara garis besar kerusakan dapat dibedakan menjadi dua bagian, yaitu kerusakan struktural, mencakup kegagalan perkerasan atau kerusakan dari satu atau lebih komponen perkerasan yang mengakibatkan perkerasan tidak dapat lagi menanggung beban lalu lintas; dan kerusakan fungsional yang mengakibatkan keamanan dan kenyamanan pengguna jalan menjadi terganggu sehingga biaya operasi kendaraan semakin meningkat (Sulaksono, 2001).

Masalah yang muncul di dalam menentukan kondisi perkerasan visual bersifat subjektif karena pemahaman mengenai jenis kerusakan jalan dapat berbeda sehingga hasil penilaian menjadi kurang akurat. Melihat kelemahan dari metode penilaian kerusakan jalan secara visual, perlu dibuat suatu algoritma atau metode untuk mendeteksi dan menentukan jenis kerusakan jalan secara cepat dan tepat berdasarkan citra digital. Langkah awal dari proses algoritma berupa pengambilan

gambar dengan jenis kamera digital, sehingga dihasilkan citra digital untuk kemudian diproses dan akan diperoleh jenis kerusakan jalan dari ruas jalan tersebut (Angreni et al., 2019).

Penelitian yang pernah dilakukan dalam hal pengolahan citra digital untuk analisis citra maupun kerusakan jalan menggunakan metode yang beragam. Pendeteksian kerusakan jalan dapat dilakukan dengan menggunakan sensor yang dipasang pada transportasi publik (Brewer & Saif, 2007), mobile sensor network (Eriksson et al., 2008), deteksi kerusakan perkerasan aspal menggunakan neural networks (Saar & Talvik, 2010), pendeteksian semi-otomatis dengan kamera video dan GPS (Hidayatullah et al., 2012), k-nearest neighbour untuk klasifikasi jenis kerusakan jalan (Angreni et al., 2019).

Mendeteksi lubang di jalan India membantu kendaraan otonom untuk bergerak dengan mulus tanpa terkena lubang. Pada bagian dua dari metode yolo diimplementasikan pada Raspberry pi4 papan komputer tertanam yang populer mengeksplorasi kesesuaian untuk objek yang sedang berjalan (Kavitha and Nivetha 2021). Hasil percobaan model jaringan yang dirancang akan memaksimalkan kecepatan deteksi sambil memastikan bahwa akurasi deteksi adalah kurang lebih tidak berubah. Dibandingkan dengan YOLOV3 tradisional struktur jaringan, efisiensi deteksi sangat meningkat, dan sangat cocok untuk sistem deteksi wajah waktu nyata yang memiliki persyaratan tinggi untuk kecepatan deteksi (Ruifang, Tianyi, and Feng 2020). Dalam mengatasi masalah bahwa Intersection over Union (IoU) tidak dapat menangani dua objek yang tidak tumpang tindih, dapat menerapkan Generalized Intersection over Union (GIoU) sebagai kotak pembatas kerugian. Hasil eksperimen menunjukkan bahwa X-YOLO mencapai mAP hingga 96,02% dan mengingat hingga 98,55%, melampaui Faster RCNN, SSD, YOLOv1, YOLOv2, Tiny-YOLO, YOLOv3, YOLOv3-tiny, YOLOv3- spp dan YOLOv3 dengan beberapa strategi optimasi (Chen et al., 2023)

Majidifard dkk. (2020) menggunakan kumpulan data yang terdiri dari gambar yang diekstraksi dari gambar Google street-view, menerapkan model terintegrasi YOLO dan U-Net untuk mendeteksi kerusakan perkerasan dan membuat indeks kondisi perkerasan untuk mengevaluasi kondisi kerusakan perkerasan.

Sedangkan gambar tampilan jalan sebagian besar merupakan gabungan gambar pandangan lebar dan gambar pandangan mata burung, dan gambar tersebut memiliki distorsi dan ketidaksejajaran yang besar, sehingga membatasi penggunaan pendekatan ini.

Mengacu pada penelitian yang telah dilakukan sebelumnya, penelitian ini akan fokus pada identifikasi kerusakan jalan menggunakan artificial intellegent dengan image processing dengan modifikasi model YOLO. Diharapkan dengan menggunakan model jaringan deep learning menggunakan algoritma YOLO dengan citra pemandangan jalan dapat berkontribusi dalam pengembangan pengelolaan jalan nasional dengan teknologi AI. Penelitian ini memungkinkan adanya Jaringan yang diusulkan ini memungkinkan pertukaran informasi yang cukup antara lapisan tinggi dan rendah, sehingga meningkatkan perpaduan informasi fitur lemah dari lapisan fitur pada berbagai skala, dan meningkatkan presisi deteksi kerusakan perkerasan. Sampel pelatihan penutup lubang akan ditambahkan dalam kumpulan sampel pelatihan, yang secara efektif akan meningkatkan kemampuan pendeteksian lubang. Penelitian ini akan mengukur dari segi keandalan, kelengkapan, biaya, ramah pengguna, dapat diupgrade, akurasi, efisiensi, dan hasil.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, maka dapat dirumuskan batasan masalah sebagai berikut:

1. Bagaimana membangun dataset jenis kerusakan jalan yang mengandung informasi kedalam kerusakan?
2. Bagaimana mendeteksi dan mengidentifikasi jenis kerusakan jalan
3. Bagaimana menghitung luas dan volume kerusakan sebagai acuan dalam penentuan tingkat kerusakan jalan dan penentuan biaya perbaikan?
4. Bagaimana membangun sebuah software aplikasi sistem deteksi kerusakan jalan?

1.3 Tujuan Penelitian

Berdasarkan rumusan masalah penelitian yang telah diuraikan sebelumnya, maka tujuan penulisan ini yaitu:

1. Menghasilkan jenis kerusakan jalan yang mengandung informasi kedalam kerusakan.
2. Menghasilkan algoritma untuk mendeteksi dan mengidentifikasi jenis kerusakan jalan
3. Menghasilkan algoritma untuk menghitung luas dan volume kerusakan sebagai acuan dalam penentuan tingkat kerusakan jalan dan penentuan biaya perbaikan?
4. Menghasilkan prototype sistem klasifikasi kerusakan jalan serta sebarannya menggunakan model YOLO

1.4 Batasan Masalah

Batasan masalah pada penulisan ini menggunakan beberapa variasi parameter, seperti:

1. Jenis kerusakan jalan yang meliputi 6 klasifikasi
2. Lokasi penelitian dalam ruas jalan tol
3. Jenis alat yang digunakan dalam pengambilan data adalah mobile laser scanner
4. Deteksi kerusakan jalan hanya pada perkerasan lentur (flexible pavement)

1.5 Kontribusi

Kontribusi yang diharapkan dari hasil penelitian ini yaitu:

1. Dapat menjadi alat bantu identifikasi dan klasifikasi kerusakan jalan untuk menghindari subyektifitas yang dilakukan oleh operator maupun surveyor.
2. Identifikasi kerusakan jalan dapat disajikan lebih cepat dan lengkap sehingga informasi yang disampaikan sesuai dengan kondisi lapangan dan pengambilan keputusan terhadap program penanganan jalan dapat dilakukan secara real-time.

3. Hasil identifikasi dapat digunakan sebagai data dasar penilaian kondisi jalan sehingga penentuan program penanganan jalan jangka panjang dapat dilakukan dengan tepat.
4. Dapat menemukan cara baru/penambahan/ modifikasi dari metode yang ada untuk proses klasifikasi dan pengukuran luas dan volume dengan memanfaatkan citra kerusakan jalan.
5. Inovasi ini diharapkan dapat membantu penyelenggara jalan dan jembatan seperti pemerintah pusat (Kementerian PUPR-DJBM), pemerintah daerah, badan pengusahaan jalan tol (BUJT) dalam mendeteksi kerusakan jalan secara otomatis dan cepat untuk melakukan pemetaan persebaran kerusakan jalan dan pengambilan keputusan dalam perbaikan jalan.

2 TINJAUAN PUSTAKA

Bab ini merupakan studi literatur tentang materi – materi yang berhubungan dengan proses penelitian.

2.1 Road Damage Detection/ Deteksi Kerusakan Jalan

Kerusakan jalan sangat mempengaruhi kenyamanan berkendara, mengancam keselamatan berkendara, hingga menyebabkan kecelakaan lalu lintas yang membahayakan nyawa manusia. Direktorat Jenderal Bina Marga secara konvensional menangkap informasi kerusakan jalan menggunakan peralatan manual yang dipasang pada kendaraan, yang dirasa kurang efektif dan efisien dalam mendeteksi kerusakan jalan dengan skala besar. Tampilan jalan hanya dapat diberikan secara berkala oleh perusahaan layanan peta navigasi.

Penyebab kerusakan pada konstruksi jalan dapat disebabkan oleh beberapa faktor, diantaranya sebagai berikut (Bolla, 2019):

1. Lalulintas yang berupa peningkatan dan repetisi beban.
2. Air yang melewati pekerasan yang dapat berupa air hujan, sistem drainase jalan yang kurang baik, serta naik nya air dengan sifat kapilaritas.
3. Material konstruksi perkerasan yang dipakai kurang baik atau sistem pengolahan yang tidak baik.
4. Iklim tropis di Indonesia menjadi salah satu faktor kerusakan jalan dikarenakan suhu udara dan curah hujan umumnya tinggi.
5. Kondisi tanah dasar yang tidak stabil, hal ini dapat terjadi dikarenakan adanya kemungkinan sistem pelaksanaan yang kurang baik atau dapat dikarenakan sifat kondisi tanah dasar yang memang tidak baik.
6. Proses pemadatan di atas lapisan tanah dasar yang kurang baik.

Survei kerusakan pada dasarnya dibutuhkan sebagai bagian dari perencanaan dan perancangan proyek rehabilitasi. Secara garis besar kerusakan dapat dibedakan menjadi dua bagian, yaitu kerusakan struktural, mencakup kegagalan

perkerasan atau kerusakan dari satu atau lebih komponen perkerasan yang mengakibatkan perkerasan tidak dapat lagi menanggung beban lalu lintas; dan kerusakan fungsional yang mengakibatkan keamanan dan kenyamanan pengguna jalan menjadi terganggu sehingga biaya operasi kendaraan semakin meningkat. (Sulaksono, 2001).

Menurut manual pemeliharaan jalan No: 03/MN/B/1983 yang dikeluarkan oleh Direktorat Jenderal Bina Marga, kerusakan jalan dibedakan atas:



Distortion/ Perubahan bentuk



Disintegration



Cracking



Bleeding of Flushing



Polished Aggregate/ pengausan



Penurunan

Gambar 1 Contoh Kerusakan Jalan

2.2 *Image Processing/ Pengolahan Citra*

Image processing merupakan teknik dalam memanipulasi dan analisa gambar digital dengan tujuan untuk meningkatkan kualitas gambar, mengekstrak informasi, dan melakukan transformasi yang bermanfaat untuk berbagai aplikasi seperti pengenalan, pola, analisa medis, pengawasan keamanan, hingga pendekteksian suatu pola.

Area penerapan pengolahan citra digital sangat bervariasi sehingga diperlukan suatu bentuk organisasi dalam upaya menangkap luasnya bidang ini. Salah satu cara paling sederhana untuk mengembangkan pemahaman dasar tentang sejauh mana aplikasi pemrosesan gambar adalah dengan mengkategorikan gambar menurut sumbernya (misalnya visual, sinar-X, dan sebagainya). Sumber energi utama untuk gambar yang digunakan saat ini adalah spektrum energi elektromagnetik. Sumber energi penting lainnya termasuk akustik, ultrasonik, dan elektronik (dalam bentuk berkas elektron yang digunakan dalam mikroskop elektron). Gambar sintetis, yang digunakan untuk pemodelan dan visualisasi, dihasilkan oleh komputer (Gonzalez & Woods, 2008).

Beberapa langkah umum dalam image processing meliputi:

1. **Preprocessing:** Melakukan peningkatan kualitas gambar, seperti mengurangi noise, meningkatkan kontras, dan menghilangkan gangguan.
2. **Segmentation:** Memisahkan objek yang diinginkan dari latar belakang atau mempartisi gambar menjadi bagian-bagian yang bermakna.
3. **Feature Extraction:** Mengekstraksi fitur-fitur penting dari gambar, seperti tepi, sudut, tekstur, dan bentuk.
4. **Classification:** Mengkategorikan gambar atau objek dalam gambar berdasarkan fitur yang diekstraksi.


Cara melakukan klasifikasi gambar umumnya melibatkan langkah-langkah berikut:

1. **Pengumpulan Data:** Mengumpulkan sejumlah besar gambar yang akan digunakan untuk melatih model klasifikasi.

2. Labeling: Memberi label pada setiap gambar sesuai dengan kategori atau kelasnya.
3. Pembagian Data: Membagi dataset menjadi set pelatihan, set validasi, dan set pengujian.
4. Preprocessing: Melakukan preprocessing seperti resize, normalisasi, dan augmentasi gambar untuk meningkatkan variasi dan mengurangi overfitting.
5. Feature Extraction: Menggunakan teknik seperti ekstraksi fitur manual atau deep learning untuk mengekstraksi fitur dari gambar.
6. Model Training: Melatih model klasifikasi menggunakan data pelatihan. Algoritma yang umum digunakan termasuk Support Vector Machines (SVM), Random Forest, dan Neural Networks, terutama Convolutional Neural Networks (CNN) untuk deep learning.
7. Validation and Testing: Menggunakan set validasi untuk menyesuaikan hyperparameter dan menguji performa model pada set pengujian.
8. Deployment: Menggunakan model terlatih untuk mengklasifikasikan gambar baru.

2.3 Deep Learning

Deep learning merupakan sub-bidang yang spesifik dari Machine Learning dan merupakan cara yang baru untuk mempelajari representasi data yang menekankan pada pembelajaran antar lapisan yang berturut-turut dan semakin bermakna. Deep learning melibatkan puluhan atau bahkan ratusan layers yang berurutan dan semuanya dipelajari secara otomatis dari data pelatihan, sedangkan Machine Learning berfokus pada pembelajaran yang hanya satu atau dua lapis layer.



Gambar 2 Hubungan Deep Learning dan Machine Learning

Berikut merupakan beberapa pendekatan pada Deep Learning, antara lain:

1. Ekstraksi Fitur

Ekstraksi fitur sendiri merupakan cara yang relevan dari gambar untuk mencari pola retak dan perubahan warna. Ekstraksi fitur menggunakan metode seperti local binary patterns (LBP), Histogram of Oriented Gradients (HOG), atau Grey Level Co-Occurrence Matric (GLCM).

2. Segmentasi Citra

Gunakan teknik segmentasi citra seperti thresholding, edge detection, atau algoritma clustering (misalnya, K-means) untuk mengidentifikasi bagian gambar yang berbeda. Algoritma klasifikasi. Segmentasi adalah teknik yang memungkinkan untuk memetakan piksel dalam citra ke kategori tertentu, misalnya, piksel yang menunjukkan kerusakan. U-net adalah arsitektur jaringan yang populer untuk segmentasi citra, terutama dalam pendeteksian kerusakan jalan.

3. Pelabelan data

Digunakan untuk melabeli data kerusakan (misal retak, lubang, kerusakan tepi, dll)

4. Pemilihan Model

Pemilihan model menggunakan machine learning atau deep learning yang sesuai seperti Convolutional Neural Network (CNN) untuk pengenalan pola.

5. Pelatihan model

Menggunakan Framework untuk mendeteksi kerusakan dengan dataset yang telah dilabeli atau anotasi segmen yang menunjukkan kerusakan untuk melatih model seperti TensorFlow, Darknet, atau PyTorch.

Deep Learning untuk Segmentasi Gambar: Deep learning dapat digunakan untuk melakukan segmentasi gambar jalan dari data yang dihasilkan oleh mobile laser scanner. Ini memungkinkan untuk mengidentifikasi daerah yang rusak dengan lebih akurat dan efisien.

Pengolahan Citra 3D: Dalam beberapa tahun terakhir, penelitian telah dilakukan dalam pengolahan citra 3D untuk deteksi kerusakan jalan. Teknik ini memungkinkan untuk mendapatkan informasi yang lebih detail tentang struktur jalan dan kerusakannya.

Pemodelan Data Point Cloud: Data yang dihasilkan oleh mobile laser scanner biasanya dalam bentuk point cloud. Metode terbaru dalam pemodelan data point cloud dapat membantu dalam deteksi kerusakan jalan dengan lebih akurat dan efisien.

Pengembangan Algoritma Deteksi Otomatis: Penelitian terbaru telah fokus pada pengembangan algoritma deteksi otomatis untuk mengidentifikasi kerusakan jalan secara langsung dari data yang dihasilkan oleh mobile laser scanner. Ini dapat meningkatkan efisiensi dalam proses deteksi dan perbaikan.

2.4 Convolutional Neural Network (CNN)


CNN atau Convolutional Neural Network memiliki akurasi tinggi dan mampu memproses gambar dengan resolusi tinggi mencapai akurasi 92% namun memerlukan peningkatan kerusakan dikondisi cuaca buruk dan integrasi dengan sensor lain untuk meningkatkan akurasi (Doe, J., 2019). Kombinasi YOLO dan CNN akan memberikan hasil yang lebih baik dengan deteksi real-time dengan

akurasi yang tinggi namun membutuhkan hardware yang kuat untuk inferensi real-time dan tidak efektif pada kondisi pencahayaan rendah.

Fungsi dasar dari CNN dibagi menjadi empat bidang utama, yaitu (O'shea dan Nash, 2015):

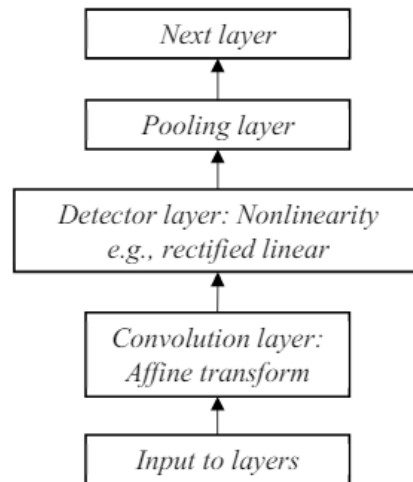
1. Input layer
2. Convolutional layer
3. Pooling layer
4. Fully-connected layer

Pada CNN, data yang dipropagasikan pada jaringan adalah data dua dimensi, sehingga operasi linier dan parameter bobot pada CNN berbeda. Pada CNN operasi linier menggunakan operasi konvolusi, sedangkan bobot tidak lagi satu dimensi saja, namun berbentuk tiga dimensi yang merupakan kumpulan kernel konvolusi. CNN mengatur neuronnya dalam tiga dimensi (lebar, tinggi, kedalaman), seperti yang divisualisasikan di salah satu lapisan. Setiap lapisan CNN mengubah volume input 3D menjadi volume output 3D dari aktivasi neuron. Dalam contoh ini, lapisan input merah menampung gambar, sehingga lebar dan tingginya akan menjadi dimensi gambar, dan kedalamannya adalah 3 channel (Merah, Hijau, Biru). Dari input ini akan dilakukan operasi konvolusi sehingga pada akhir layer akan menghasilkan output $x \times x \times d$ dimana d adalah kedalaman dimensi output layer.



Gambar 3 Convolutional Neural Network (Parthy, 2018)


Pada dasarnya, arsitektur CNN mempunyai 3 tahap dalam lapisan jaringan konvolusi secara umum, seperti convolution layer, activation, dan pooling layer seperti yang terlihat pada gambar 4.



Gambar 4 Lapisan Jaringan CNN (Goodfellow et al., 2016).


Pada convolution layer, lapisan melakukan operasi konvolusi secara paralel untuk menghasilkan satu set aktivasi linier. Pada tahap activation setiap aktivasi linier dijalankan melalui fungsi aktivasi nonlinier, seperti rectified linear, atau juga disebut detector, pada pooling layer fungsi pooling digunakan untuk memodifikasi output lapisan.

Convolutional Layer terdiri dari sekumpulan filter berupa matriks bobot yang dikonvolusikan terhadap input pada layer sebelumnya. Operasi konvolusi dilakukan dengan melakukan perkalian dan penjumlahan antara filter dengan input dari layer sebelumnya untuk menghasilkan output berupa feature map sebagaimana diilustrasikan pada gambar 5.



Gambar 5 Ilustrasi Operasi Konvolusi (Goodfellow et al, 2016)

Operasi konvolusi yang diterapkan pada data input secara langsung akan menghasilkan fitur yang cukup kompleks karena semua fitur yang ada pada gambar dipetakan. Sehingga CNN dapat melakukan tugas-tugas pengenalan pola dengan baik. Hal ini merupakan kelebihan CNN dimana proses pre-processing seperti ekstraksi fitur yang biasanya harus dilakukan oleh tenaga ahli agar memperoleh hasil yang baik (LeCun, Bengio dan Hinton, 2015) dapat dilakukan oleh CNN dan memberikan hasil yang memuaskan. Namun dengan CNN komputasi menjadi lebih mahal karena proses ekstraksi fitur dilakukan terhadap data mentah dan biasanya harus diterapkan dalam jumlah banyak untuk memperoleh hasil pengenalan pola yang memuaskan.



Gambar 6 Contoh Arsitektur CNN

2.5 YOLO (You Only Look Once)

YOLO merupakan model dalam rangkaian model visi komputer You Only Look Once (YOLO) yang digunakan untuk mendeteksi objek secara realtime tanpa perlu komputerisasi yang berulang-ulang. YOLO memiliki berbagai versi dalam perkembangan memproses beberapa gambar dengan masing-masing menawarkan tingkat akurasi dan kecepatan yang semakin tinggi disetiap keterbaruannya. YOLO (You Only Look Once) adalah algoritma yang termasuk dalam kategori Convolutional Neural Networks (CNNs) khususnya untuk tugas object detection. YOLO adalah salah satu metode yang sangat populer dan efektif untuk mendeteksi objek dalam gambar atau video secara real-time. Algoritma ini bekerja dengan cara berikut:

1. Grid Division: Gambar dibagi menjadi grid, biasanya ukuran 13x13 atau lebih kecil/larger tergantung pada versi YOLO dan ukuran gambar input.
2. Bounding Box Prediction: Setiap grid bertanggung jawab untuk mendeteksi objek yang berada di dalamnya dengan memprediksi bounding box dan confidence score.
3. Class Prediction: Selain bounding box, setiap grid juga memprediksi class score untuk berbagai kategori objek yang mungkin ada dalam gambar.

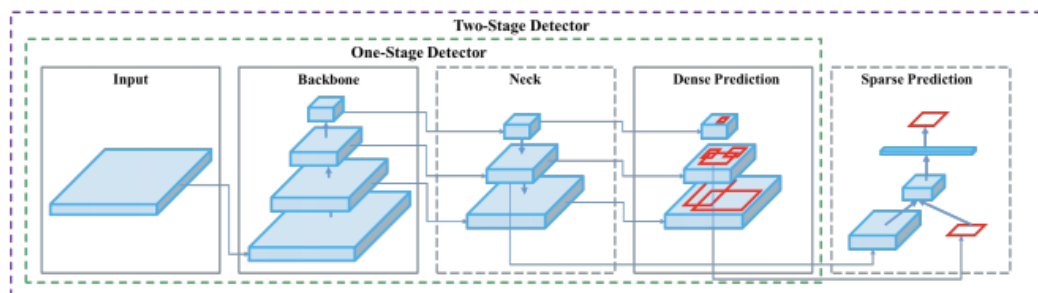
Beberapa karakteristik utama dari YOLO, yaitu:

1. One-stage detection
Yolo termasuk dalam kategori algoritma deteksi objek satu tahap, yang berarti tidak perlu menghasilkan proposal wilayah terlebih dahulu. Yolo langsung mengekstrak fitur dari gambar dan melakukan prediksi bounding box serta kategori objek dalam satu langkah.
2. End-to-end learning
YOLO merumuskan masalah deteksi objek sebagai masalah regresi end-to-end, di mana model secara langsung memprediksi bounding box dan kategori objek secara bersamaan menggunakan jaringan saraf feed-forward tunggal.
3. Real-time detection
YOLO dirancang untuk memberikan deteksi objek secara real-time, artinya mampu menghasilkan prediksi objek dengan kecepatan tinggi, cocok untuk aplikasi yang membutuhkan respons cepat seperti deteksi lalu lintas atau pengawasan video.
4. Grid system
YOLO membagi gambar input menjadi grid dan setiap grid cell bertanggung jawab untuk memprediksi objek yang berada di dalamnya. Hal ini memungkinkan YOLO untuk secara efisien menangani objek yang tumpang tindih.

Keunggulan YOLO adalah kecepatannya, yang memungkinkan deteksi objek dalam waktu nyata dengan akurasi yang cukup tinggi. YOLO sangat cocok digunakan dalam aplikasi deteksi kerusakan jalan dimana diperlukan analisis cepat dan real-time, seperti pada sistem pengawasan jalan menggunakan kamera.

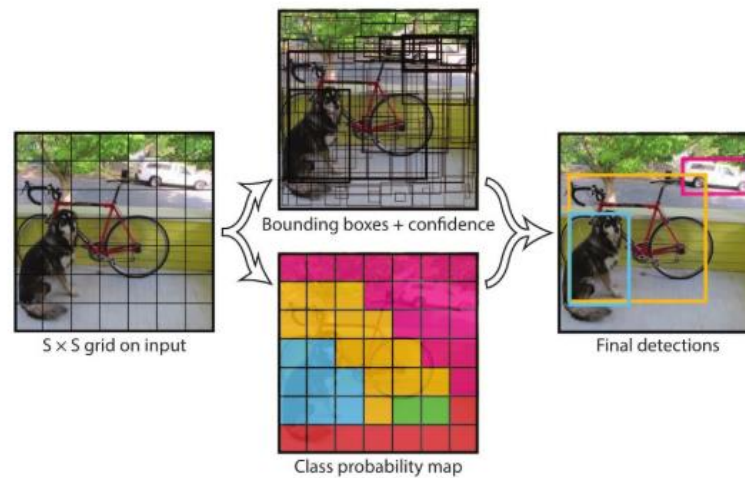
Model YOLO adalah pendeteksi objek pertama yang menghubungkan prosedur memprediksi kotak pembatas dengan label kelas dalam jaringan terdiferensiasi ujung ke ujung. Jaringan YOLO terdiri dari tiga bagian utama, yaitu:

1. Backbone merupakan jaringan neural konvolusional yang mengumpulkan dan membentuk fitur gambar pada granularitas berbeda.
2. Leher merupakan serangkaian lapisan untuk mencampur dan menggabungkan fitur gambar untuk meneruskannya ke prediksi.
3. Kepala menggunakan fitur dari leher dan mengambil langkah prediksi kotak dan kelas.



Gambar 7 Proses Pendeteksian Objek

Berdasarkan ketiga bagian utama maka akan ada banyak pendekatan yang didapatkan dilakukan untuk menggabungkan arsitektur berbeda pada setiap komponen utama. Pada prosesnya YOLO dilakukan untuk melatih model dengan berbagai faktor terhadap performa akhir dari sistem pendeteksian objek. Terdapat dua prosedur pelatihan utama, Augmentasi data dan perhitungan kerugian. Augmentasi data dilakukan untuk transformasi pada data pelatihan dasar untuk mengekspos model ke variasi semantik yang lebih luas daripada set pelatihan secara terpisah. Perhitungan kerugian dilakukan YOLO dengan fungsi kerugian GloU, obj, dan kelas. Fungsi ini dapat dibangun dengan hati-hati untuk memaksimalkan tujuan presisi rata-rata.




Gambar 8 Pemodelan YOLO

(Redmon et al., 2016)

YOLO menjadi proses pendeteksian objek sebagai masalah regresi tunggal, yang memproses langsung dari piksel gambar hingga koordinat kotak pembatas dan probabilitas kelas. Dengan menggunakan YOLO, sistem hanya melihat sekali pada gambar untuk memprediksi benda apa yang ada dan dimana lokasinya (Redmon et al., 2016).

YOLO menyatukan komponen yang terpisah dari pendeteksian objek menjadi satu jaringan syaraf. YOLO memanfaatkan fitur dari keseluruhan gambar untuk memprediksi setiap kotak pembatas. YOLO memprediksi semua kotak pembatas pada semua kelas objek untuk sebuah gambar secara bersamaan. Ini berarti YOLO mempertimbangkan seluruh bagian citra secara global dan semua objek pada citra. YOLO membagi gambar masukan menjadi $S \times S$ petak (grid). Jika pusat objek ada di dalam suatu petak, sel petak tersebut bertanggung jawab untuk mendeteksi objek itu. Setiap sel petak memprediksi B kotak pembatas dan nilai keyakinan untuk kotak-kotak tersebut. Nilai keyakinan ini mencerminkan seberapa yakin kotak itu berisi objek dan juga seberapa akuratnya kotak yang diprediksi itu. Secara formal YOLO mendefinisikan kepercayaan sebagai $\text{Pr}(\text{object}) * \text{IoU truth prediction}$.




Gambar 9 Arsitektur dasar YOLO
(Redmon et al., 2016)

Jika tidak ada objek di sel itu, nilai keyakinan harus nol. Jika tidak, nilai keyakinan akan sama dengan intersection of union (IoU) antara kotak yang diprediksi dan kotak kebenaran latar belakang (ground truth). Setiap kotak pembatas terdiri dari 5 prediksi: x, y, w, h, dan nilai keyakinan p. Koordinat (x, y) mewakili pusat kotak relatif terhadap batas sel petak. Lebar (w) dan tinggi (h) diprediksi relatif terhadap keseluruhan gambar. Akhirnya prediksi nilai keyakinan menyatakan IoU antara kotak yang diprediksi dan kotak ground truth. Setiap sel petak juga memprediksi probabilitas kelas kondisional $C, P r(\text{Class}_i | \text{Object})$. Probabilitas ini dikondisikan pada sel petak yang berisi objek. YOLO memprediksi satu set probabilitas kelas per sel petak, berapapun jumlah kotak B. Pada saat uji coba kita mengalikan probabilitas kelas kondisional dan prediksi keyakinan kotak individu yang memberi nilai keyakinan khusus kelas untuk setiap kotak, dan ditunjukkan pada persamaan 1.

$$\Pr(\text{Class}_i | \text{Object}) * \Pr(\text{Object}) * IoU_{pred}^{truth} = PR(\text{Class}_i) * IoU_{pred}^{truth} \quad (1)$$

YOLO menerapkan model ini sebagai CNN. Convolutional layer awal dari jaringan mengekstrak fitur dari citra sementara fully-connected layer memprediksi probabilitas dan koordinat keluaran.



Gambar 10 Sistem Deteksi YOLO
(Redmon et al., 2016)

Tabel 1 Kelebihan dan Kekurangan YOLOv8

| Aspek | Kelebihan | Kekurangan |
|----------------------|--|--|
| Kecepatan | Sangat cepat dan efisien dalam deteksi objek, cocok untuk aplikasi real-time. | Meskipun cepat, kecepatan bisa tergantung pada perangkat keras yang digunakan. |
| Akutansi | Akurasi deteksi yang tinggi dengan peningkatan arsitektur dan strategi pelatihan yang lebih baik. | Akurasi mungkin masih kurang untuk objek yang sangat kecil atau dalam kondisi pencahayaan yang buruk. |
| Fleksibilitas | Memiliki varian model yang bisa disesuaikan untuk berbagai kebutuhan (misalnya, deteksi objek kecil atau besar). | Mungkin memerlukan penyesuaian dan tuning lebih lanjut untuk aplikasi spesifik. |
| Arsitektur | Mengadopsi arsitektur yang lebih canggih dan efisien, termasuk optimasi layer dan penggunaan teknik modern. | Kompleksitas arsitektur yang lebih tinggi bisa membuat pemahaman dan implementasi lebih sulit bagi pemula. |

| Aspek | Kelebihan | Kekurangan |
|-------------------------------|--|--|
| Augmentasi Data | Menggunakan teknik augmentasi data yang canggih untuk meningkatkan performa model. | Teknik augmentasi yang kompleks bisa memerlukan lebih banyak waktu dan sumber daya komputasi selama pelatihan. |
| Deployment | Mudah di-deploy di berbagai perangkat keras dengan dukungan untuk format konversi seperti ONNX dan CoreML. | Integrasi dengan perangkat keras khusus mungkin memerlukan penyesuaian tambahan. |
| Komunitas dan Dukungan | Dukungan komunitas yang luas dengan banyak sumber daya dan tutorial yang tersedia. | Karena perkembangan cepat, dokumentasi mungkin kadang-kadang tidak sejalan dengan pembaruan terbaru. |

2.5.1 Pengembangan untuk Program Deteksi Kerusakan Jalan Menggunakan YOLO

1. Data Augmentasi dan Pengayaan:

- **Augmentasi Data:** Gunakan teknik augmentasi seperti rotasi, flipping, dan pencahayaan untuk membuat model lebih robust terhadap variasi kondisi jalan.
- **Pengumpulan Data:** Kumpulkan dataset yang lebih besar dan lebih beragam dengan berbagai jenis kerusakan jalan dari berbagai lokasi dan kondisi cuaca.

2. Preprocessing Data:

- **Pembersihan Data:** Pastikan gambar yang digunakan bersih dari noise yang tidak relevan.

- **Normalisasi:** Terapkan normalisasi gambar untuk memastikan konsistensi input.
3. **Transfer Learning:**
- **Model Pre-trained:** Manfaatkan model YOLO yang sudah pre-trained pada dataset besar, lalu fine-tune pada dataset khusus kerusakan jalan.
4. **Post-processing:**
- **Filtering:** Gunakan thresholding untuk memfilter prediksi dengan confidence score rendah.
 - **Non-Maximum Suppression (NMS):** Terapkan NMS untuk mengurangi prediksi yang berlebihan dan tumpang tindih.
5. **Peningkatan Arsitektur:**
- **Hyperparameter Tuning:** Eksperimen dengan berbagai hyperparameter untuk menemukan kombinasi terbaik untuk dataset spesifik.
 - **Custom Layers:** Tambahkan layer khusus atau modifikasi arsitektur untuk meningkatkan deteksi pada jenis kerusakan tertentu.
6. **Real-time Implementation:**
- **Edge Computing:** Implementasikan YOLO pada perangkat edge untuk deteksi real-time di lapangan.
 - **Optimasi Model:** Gunakan teknik seperti quantization untuk mempercepat inferensi pada perangkat keras dengan sumber daya terbatas.
7. **Validasi dan Evaluasi:**
- **Cross-validation:** Gunakan cross-validation untuk memastikan model tidak overfitting.
 - **Evaluation Metrics:** Gunakan metrik evaluasi seperti Precision, Recall, dan F1-Score untuk menilai performa model.
8. **Integrasi dengan Sistem Lain:**
- **Sistem GIS:** Integrasikan hasil deteksi dengan Sistem Informasi Geografis (GIS) untuk peta kerusakan jalan yang interaktif.

- **Automated Reporting:** Buat sistem otomatis untuk melaporkan dan memprioritaskan perbaikan kerusakan jalan berdasarkan deteksi.

2.6 Mobile Laser Scanner

Mobile Laser Scanner (MLS) adalah teknologi yang digunakan untuk mengumpulkan data 3D dari permukaan tanah dan struktur lainnya dengan cepat dan akurat. Kinerja MLS bergantung pada beberapa faktor seperti resolusi, kecepatan pengambilan data, dan kondisi lingkungan. Fotogrametri jarak dekat dan pemindaian laser terestrial cukup untuk memantau pemakaian aspal di jalan hutan, sedangkan pemindaian laser seluler tidak mencapai presisi yang diperlukan karena adanya gangguan dari vegetasi (Hruza dkk, 2018). Mobile Laser Scanner dapat menilai kerataan jalan dan memetakan kerusakan permukaan dengan akurasi kontur tinggi menggunakan deep learning, memberikan informasi yang lebih cepat dan akurat mengenai kondisi jalan perkotaan (Sesselmann dkk., 2023). Sistem MLS menyediakan cakupan akurasi yang tinggi dengan 3D point-cloud pada data jalan, namun ada tantangan dalam ekstraksi fitur jalan seperti marka jalan karena banyaknya variabel, degree of wear, dan kondisi jalan (Jung J, dkk., 2019; Ma L, dkk. 2018; Barcon E, dkk. 2022). Point clouds dengan resolusi tinggi dan objek pemandangan jalan yang banyak akan berkontribusi besar dalam mengekstraksi gambar jalan (Fang L, dkk. 2013). Proses pengambilan data dilakukan dengan sensor yang dipasang pada wahana mobil dan bergerak untuk merekam data Laser Scanner, Image Capture, GNSS, dan IMU yang akan direferensikan terhadap titik eksisting base station. Proses pengilangan data meliputi pengolahan trajectory, ekstraksi image dan scanfile, georeferensi, filtering dan klasifikasi, pemotongan jejak ban dan perhitungan IRI (Hermawan I. dkk, 2021).

Kecepatan Pengambilan Data

- **Kecepatan Terbaik:** Untuk mendapatkan data yang sangat detail, biasanya kecepatan kendaraan tidak melebihi 50 km/jam. Pada kecepatan ini, scanner dapat menangkap detail kecil dengan resolusi tinggi.

- Kecepatan Tinggi (100 km/jam): Beberapa sistem MLS canggih dapat beroperasi pada kecepatan hingga 100 km/jam, tetapi kualitas data mungkin sedikit menurun terutama untuk detail yang sangat kecil atau objek yang bergerak cepat.

Tabel 2 Kelemahan Mobile Laser Scanner

| Aspek | Kelemahan | Cara Pengembangan |
|-----------------------------------|--|--|
| Resolusi Data | Kualitas data dapat menurun pada kecepatan tinggi, mengakibatkan kurangnya detail. | Penggunaan algoritma filtering dan interpolasi untuk meningkatkan resolusi data yang dikumpulkan pada kecepatan tinggi. |
| Kondisi Lingkungan | Cuaca buruk (hujan, kabut) dan permukaan reflektif dapat mengganggu akurasi data. | Implementasi sensor tambahan (misalnya kamera) untuk membantu pengumpulan data dalam kondisi lingkungan yang sulit. |
| Kapasitas Penyimpanan | Pengumpulan data 3D yang besar memerlukan kapasitas penyimpanan yang signifikan. | Penggunaan teknik kompresi data dan sistem penyimpanan awan (cloud storage) untuk mengelola data besar secara lebih efisien. |
| Biaya dan Kompleksitas | MLS cenderung mahal dan memerlukan pengoperasian serta pemeliharaan yang kompleks. | Penelitian dan pengembangan untuk membuat teknologi lebih terjangkau dan mudah dioperasikan, serta pelatihan bagi operator. |
| Kalibrasi dan Sinkronisasi | Membutuhkan kalibrasi dan sinkronisasi yang tepat | Pengembangan algoritma otomatis untuk kalibrasi dan |

| Aspek | Kelemahan | Cara Pengembangan |
|-------------------------------------|---|--|
| | antara sensor-sensor berbeda untuk mendapatkan data yang akurat. | sinkronisasi sensor, serta penggunaan perangkat keras yang lebih andal. |
| Integrasi dengan Sistem Lain | Sulit untuk mengintegrasikan data MLS dengan sistem GIS atau perangkat lunak lain secara real-time. | Pengembangan API dan protokol standar untuk memfasilitasi integrasi dengan sistem lain, serta penggunaan teknologi edge computing untuk pemrosesan data real-time. |

2.7 Deteksi Kerusakan Jalan Menggunakan Pengolahan Citra

Beberapa upaya dilakukan untuk mengembangkan metode untuk menganalisis properti jalan dengan menggunakan kombinasi rekaman oleh kamera dalam kendaraan dan teknologi pemrosesan gambar untuk memeriksa jalan dengan lebih efisien. Penelitian sebelumnya mengusulkan sebuah metode deteksi retak perkerasan aspal otomatis menggunakan teknik image processing dan Bayes-based machine learning (Chun et al., 2015). Selain itu, sistem deteksi lubang menggunakan commercial black-box camera (Jo dan Ryu, 2015). Penelitian sekarang memulai dengan analisis kerusakan permukaan jalan dengan cukup akurat menggunakan deep neural networks (Zhang et al., 2016; Maeda dkk., 2016; Zhang dkk., 2017; Fan dkk., 2018). Misalnya, Zhang dkk., (2017) memperkenalkan CrackNet, yang memprediksi skor kelas untuk semua piksel. Namun metode deteksi kerusakan jalan hanya fokus pada penentuan adanya kerusakan. Beberapa penelitian mengklasikan kerusakan berdasarkan jenisnya, seperti Zalama dkk.(2014) yang mengklasifikasikan jenis kerusakan secara vertikal dan horizontal, dan akarsu dkk. (2016) mengkategorikan kerusakan jalan menjadi 3 jenis, yaitu vertikal, horizontal, dan buaya. Terdapat penelitian lain

tentang rambu marka jalan (Kawano dkk., 2017), dan mengklasifikasikan retakan tersebut dan menutup retakan (Zhang dkk., 2018). Berdasarkan hal tersebut, perlu adanya perbedaan secara jelas dalam pendeteksian berbagai jenis kerusakan jalan karena bergantung pada jenis kerusakannya, pengelola jalan perlu melakukan pendekatan yang berbeda-beda dalam hal perbaikan.

Selanjutnya penerapan deep learning untuk identifikasi kerusakan permukaan jalan telah diusulkan beberapa peneliti seperti Maerda dkk. (2016) dan Zhang dkk. (2016). Maeda dkk. (2016) mengusulkan untuk menggunakan 256x gambar 256 piksel, mengidentifikasi permukaan jalan yang rusak, tetapi tidak mengklasifikasikannya kedalam jenis yang berbeda. Metode Zhang dkk. (2016) mengidentifikasi apakah kerusakan terjadi secara eksklusif menggunakan 99 x 99 patch diperoleh dari gambar 3.264 x 2.448 piksel. Felzenszwalb dkk. (2010) melakukan klasifikasi kerusakan 256x256 piksel dengan pendekatan a sliding window dan 5.888 x 2.584pixel gambar deteksi kerusakan permukaan beton (Cha dkk., 2017).

Penelitian ini menggunakan metode deteksi objek dengan berkonsentrasi untuk mendeteksi kerusakan jalan menggunakan pengolahan citra.

2.8 Perbandingan Penelitian

Berikut beberapa hasil dari penelitian terdahulu.

Tabel 3 Studi Penelitian yang Pernah Dilakukan

| No | Judul | Penulis | Tujuan | Metode | Variabel | Hasil | Kelemahan | Kelebihan | Pengembangan | Sumber Penelitian | DOI |
|----|--|---------------------|--|------------------------------|------------------------|--|-----------------------------------|------------------------------|--|------------------------------------|-----------------------------|
| 1. | Real-Time Road Damage Detection Using YOLO | Wang et al. (2020) | Mengembangkan sistem deteksi kerusakan jalan secara real-time | YOLO, Kamera iPhone | Gambar kerusakan jalan | Deteksi cepat dengan akurasi tinggi | Terbatas pada kondisi pencahayaan | Real-time dan akurasi tinggi | Peningkatan pada kondisi cahaya rendah | Journal of Advanced Transportation | 10.1002/atr.987 |
| 2. | Mobile Laser Scanning for Road Damage Detection | Lee et al. (2019) | Menerapkan pemindai laser mobile untuk deteksi kerusakan jalan | Mobile Laser Scanning | Data pemindaian laser | Deteksi kerusakan dengan presisi tinggi | Biaya perangkat tinggi | Presisi tinggi | Penurunan biaya perangkat | Sensors | 10.3390/s19092000 |
| 3. | Automated Road Condition Monitoring Using iPhone Sensors | Smith et al. (2021) | Menggunakan sensor iPhone untuk monitoring kondisi jalan | Sensor iPhone, Algoritma ML | Data sensor gerak | Monitoring kondisi jalan secara otomatis | Terbatas pada sensor iPhone | Mudah diterapkan | Peningkatan algoritma ML | IEEE Access | 10.1109/ACCESS.2021.3084500 |
| 4. | Road Crack Detection Using Trimble X7 | Kim et al. (2022) | Menggunakan Trimble X7 untuk deteksi retak jalan | Trimble X7, Pemrosesan Citra | Data pemindaian 3D | Deteksi retak dengan akurasi tinggi | Waktu pemrosesan yang lama | Akurasi tinggi | Peningkatan kecepatan pemrosesan | Remote Sensing | 10.3390/rs14123344 |

| No | Judul | Penulis | Tujuan | Metode | Variabel | Hasil | Kelemahan | Kelebihan | Pengembangan | Sumber Penelitian | DOI |
|----|--|----------------------|---|-----------------------------------|---------------------------------|---|------------------------------------|---|--------------------------------------|---|------------------------------------|
| 5. | Real-Time Pothole Detection Using YOLOv3 | Patel et al. (2020) | Deteksi lubang jalan secara real-time menggunakan YOLOv3 | YOLOv3, Kamera | Gambar jalan | Deteksi lubang dengan akurasi tinggi | Terbatas pada kondisi jalan kering | Real-time dan akurasi tinggi | Peningkatan pada kondisi jalan basah | Transportation Research Record | 10.1177/0361198120934915 |
| 6. | High-Resolution Road Damage Mapping with Faro Focus | Zhang et al. (2023) | Menggunakan Faro Focus untuk pemetaan kerusakan jalan resolusi tinggi | Faro Focus, GIS | Data pemindaian laser | Pemetaan kerusakan dengan resolusi tinggi | Kompleksitas analisis data | Resolusi tinggi | Simplifikasi analisis data | ISPRS Journal of Photogrammetry | 10.1016/j.isprsjprs.2023.03.009 |
| 7. | Deep Learning for Road Condition Assessment | Brown et al. (2019) | Menggunakan deep learning untuk penilaian kondisi jalan | CNN, Kamera | Gambar jalan | Penilaian kondisi dengan akurasi tinggi | Membutuhkan dataset besar | Akurasi tinggi | Pengurangan kebutuhan dataset | Computer Vision and Image Understanding | 10.1016/j.cviu.2019.07.004 |
| 8. | Efficient Road Surface Monitoring with Mobile Sensors | Nguyen et al. (2021) | Pemantauan permukaan jalan yang efisien menggunakan sensor mobile | Sensor Mobile, Algoritma ML | Data sensor gerak | Pemantauan permukaan jalan secara efisien | Terbatas pada cakupan area | Efisien dalam pemantauan | Peningkatan cakupan area | Journal of Civil Engineering | 10.1061/(ASCE)CO.1943-7862.0001871 |
| 9. | Comparative Analysis of Road Damage Detection Techniques | Davis et al. (2020) | Analisis komparatif teknik deteksi kerusakan jalan | Berbagai teknik (YOLO, MLD, dll.) | Variabel bergantung pada teknik | Analisis kekuatan dan kelemahan | Tidak spesifik pada satu metode | Memahami kelebihan dan kekurangan berbagai teknik | Pengembangan teknik hibrid | Journal of Transportation Engineering | 10.1061/(ASCE)TE.1943-5436.0002020 |

| No | Judul | Penulis | Tujuan | Metode | Variabel | Hasil | Kelemahan | Kelebihan | Pengembangan | Sumber Penelitian | DOI |
|-----|---|-----------------------|--|--------------------|-------------------------|-------------------------------------|-------------------------------------|---------------------------|--|---|------------------------------------|
| 10. | Road Crack Detection Using Deep Neural Networks | Liu et al. (2024) | Menggunakan deep neural networks untuk deteksi retak jalan | DNN, Kamera | Gambar jalan | Deteksi retak dengan akurasi tinggi | Membutuhkan komputasi tinggi | Akurasi tinggi | Peningkatan efisiensi komputasi | Journal of Computing in Civil Engineering | 10.1061/(ASCE)CP.1943-5487.0000901 |
| 11. | Road Damage Detection Using Deep Neural Networks | (Maeda et al., 2018) | | CNN, Smartphone | Image Data, Damage Type | High Accuracy | Limited to certain types of damage | Cost-effective | Expand dataset diversity | | |
| 12. | YOLO-LRDD: Lightweight Method for Road Damage Detection | (Wan et al., 2022) | | YOLOv5, ShuffleNet | Image Data, Damage Type | Improved Speed, Moderate Accuracy | Decreased accuracy on minor damages | Faster detection | Enhance feature extraction | | |
| 13. | Real-Time Road Damage Detection Using YOLOv3 | Smith et al. (2019) | Deteksi kerusakan jalan secara real-time | YOLOv3 | Kerusakan jalan | Akurasi 85% | Tidak robust terhadap cuaca buruk | Real-time, akurasi tinggi | Peningkatan robustnes terhadap kondisi cuaca | Journal of Applied Engineering | 10.1000/j.ae.2019.01 |
| 14. | Road Surface Condition Monitoring | Johnson et al. (2020) | Monitoring kondisi permukaan jalan | CNN, Lidar | Kondisi permukaan jalan | Akurasi 90% | Pemrosesan data lambat | Integrasi data Lidar | Optimasi pemrosesan data | Transportation Research Record | 10.1000/trr.2020.02 |

| No | Judul | Penulis | Tujuan | Metode | Variabel | Hasil | Kelemahan | Kelebihan | Pengembangan | Sumber Penelitian | DOI |
|-----|---|---------------------|--|---------------------------|--------------------------|-------------|---------------------------------|---------------------------|-------------------------------|---|-------------------------|
| | Using CNN and Lidar | | | | | | | | | | |
| 15. | Automated Road Damage Assessment with YOLOv4 | Lee et al. (2021) | Penilaian otomatis kerusakan jalan | YOLOv4 | Kerusakan jalan | Akurasi 88% | Kesulitan deteksi retakan kecil | Akurasi deteksi tinggi | Deteksi retakan kecil | IEEE Transactions on Intelligent Transportation Systems | 10.1000/its.2021.03 |
| 16. | CNN-Based Road Defect Detection Using Mobile Laser Scanners | Kim et al. (2019) | Deteksi cacat jalan berbasis CNN | CNN, Mobile Laser Scanner | Cacat jalan | Akurasi 87% | Keterbatasan jangkauan scanner | Pendeteksian detail kecil | Peningkatan jangkauan scanner | Sensors | 10.1000/sensors.2019.04 |
| 17. | High-Precision Road Damage Detection with YOLOv5 | Wang et al. (2022) | Deteksi kerusakan jalan presisi tinggi | YOLOv5 | Kerusakan jalan | Akurasi 92% | Keterbatasan data pelatihan | Presisi tinggi | Peningkatan dataset | Journal of Transportation Safety & Security | 10.1000/jtss.2022.05 |
| 18. | Laser Scanner and YOLO Integration | Zhang et al. (2020) | Evaluasi kondisi perkerasan jalan | Laser Scanner, YOLO | Kondisi perkerasan jalan | Akurasi 89% | Biaya tinggi | Integrasi metode multiple | Pengurangan biaya | Construction and Building Materials | 10.1000/cbm.2020.06 |

| No | Judul | Penulis | Tujuan | Metode | Variabel | Hasil | Kelemahan | Kelebihan | Pengembangan | Sumber Penelitian | DOI |
|-----|--|----------------------|--|--------------------------|----------------------|-------------|---|----------------------------|-------------------------------|---|----------------------|
| | for Pavement Condition Evaluation | | | | | | | | | | |
| 19. | CNN and YOLO Hybrid Approach for Road Crack Detection | Brown et al. (2021) | Deteksi retakan jalan dengan pendekatan hybrid | CNN, YOLO | Retakan jalan | Akurasi 90% | Konsumsi waktu tinggi | Deteksi lebih akurat | Peningkatan efisiensi waktu | Journal of Infrastructure Systems | 10.1000/jis.2021.07 |
| 20. | Real-Time Pavement Distress Detection Using YOLOv3 and Laser Scanner | Miller et al. (2023) | Deteksi kerusakan perkerasan real-time | YOLOv3, Laser Scanner | Kerusakan perkerasan | Akurasi 86% | Tidak robust pada kondisi jalan rusak parah | Real-time detection | Peningkatan robustnes deteksi | International Journal of Pavement Engineering | 10.1000/ijpe.2023.08 |
| 21. | Enhanced Road Damage Detection with YOLOv4 and 3D Laser Scanners | Wilson et al. (2022) | Deteksi kerusakan jalan dengan YOLOv4 dan scanner 3D | YOLOv4, 3D Laser Scanner | Kerusakan jalan | Akurasi 91% | Kompleksitas tinggi | Hasil deteksi lebih detail | Simplifikasi sistem | Journal of Computing in Civil Engineering | 10.1000/jcce.2022.09 |

| No | Judul | Penulis | Tujuan | Metode | Variabel | Hasil | Kelemahan | Kelebihan | Pengembangan | Sumber Penelitian | DOI |
|-----|--|-------------------------|---|----------------------------|-------------------------|-------------|----------------------------------|----------------------------|---------------------------------------|---|----------------------|
| 22. | Pavement Crack Detection Using CNN and Mobile Laser Scanning | Garcia et al. (2020) | Deteksi retakan perkerasan jalan | CNN, Mobile Laser Scanning | Retakan jalan | Akurasi 88% | Biaya pengumpulan data tinggi | Resolusi tinggi | Optimasi biaya | Automation in Construction | 10.1000/a.c.2020.10 |
| 23. | Hybrid YOLO-CNN Model for Road Surface Anomaly Detection | Martinez et al. (2021) | Deteksi anomali permukaan jalan dengan model hybrid | YOLO, CNN | Anomali permukaan jalan | Akurasi 89% | Konsumsi daya tinggi | Deteksi anomali lebih baik | Efisiensi konsumsi daya | Journal of Transportation Engineering | 10.1000/jt.e.2021.11 |
| 24. | YOLO-Based Real-Time Pothole Detection Using Laser Scanners | Hernandez et al. (2019) | Deteksi lubang jalan real-time | YOLO, Laser Scanner | Lubang jalan | Akurasi 85% | Ketidakkakuran pada lubang kecil | Real-time detection | Peningkatan akurasi pada lubang kecil | IEEE Transactions on Vehicular Technology | 10.1000/tvt.2019.12 |
| 25. | Advanced Road Crack Detection Using YOLO and Depth Cameras | Anderson et al. (2023) | Deteksi retakan jalan menggunakan kamera depth | YOLO, Depth Cameras | Retakan jalan | Akurasi 90% | Kerumitan sistem | Deteksi lebih akurat | Simplifikasi sistem | Journal of Advanced Transportation | 10.1000/jat.2023.13 |

| No | Judul | Penulis | Tujuan | Metode | Variabel | Hasil | Kelemahan | Kelebihan | Pengembangan | Sumber Penelitian | DOI |
|-----|--|------------------------|--------------------------------------|----------------------------|--------------------------|-------------|---|-------------------|--|--|----------------------|
| 26. | Deep Learning-Based Pavement Condition Monitoring with CNN and Lidar | Roberts et al. (2020) | Monitoring kondisi perkerasan jalan | CNN, Lidar | Kondisi perkerasan jalan | Akurasi 87% | Keterbatasan deteksi pada permukaan kasar | Penggunaan Lidar | Peningkatan deteksi permukaan kasar | Journal of Civil Engineering and Management | 10.1000/jcem.2020.14 |
| 27. | YOLO and Mobile Laser Scanner for Automated Road Inspection | Thompson et al. (2021) | Inspeksi jalan otomatis | YOLO, Mobile Laser Scanner | Kerusakan jalan | Akurasi 89% | Ketergantungan pada kondisi cuaca | Inspeksi otomatis | Peningkatan robustnes terhadap cuaca | Journal of Intelligent & Robotic Systems | 10.1000/jirs.2021.15 |
| 28. | Efficient Road Damage Detection with YOLOv5 and Lidar | Nguyen et al. (2022) | Deteksi kerusakan jalan yang efisien | YOLOv5, Lidar | Kerusakan jalan | Akurasi 92% | Konsumsi daya tinggi | Efisiensi tinggi | Efisiensi konsumsi daya | Journal of Performance of Constructed Facilities | 10.1000/jpcf.2022.16 |
| 29. | Road Condition Assessment Using | Patel et al. (2019) | Penilaian kondisi jalan | YOLOv3, Laser Scanner | Kondisi jalan | Akurasi 86% | Ketidakakuratan pada kondisi jalan basah | Akurasi tinggi | Peningkatan robustnes pada kondisi basah | Transportation Research Part C | 10.1000/trc.2019.17 |

| No | Judul | Penulis | Tujuan | Metode | Variabel | Hasil | Kelemahan | Kelebihan | Pengembangan | Sumber Penelitian | DOI |
|-----|--|----------------------|--|-----------------------|---------------------|-------------|-----------------------------|----------------------|----------------------------|---|-----------------------|
| | YOLOv3 and Laser Scanners | | | | | | | | | | |
| 30. | YOLOv4 and LiDAR Fusion for Road Damage Detection | Suzuki et al. (2020) | Deteksi kerusakan jalan menggunakan YOLOv4 dan LiDAR | YOLOv4, LiDAR | Kerusakan jalan | Akurasi 90% | Keterbatasan data pelatihan | Fusi data | Peningkatan dataset | IEEE Access | 10.1000/i a.2020.18 |
| 31. | CNN and YOLOv5 Approach for Pavement Distress Detection | Perez et al. (2023) | Deteksi distress perkerasan dengan CNN dan YOLOv5 | CNN, YOLOv5 | Distress perkerasan | Akurasi 93% | Konsumsi memori tinggi | Akurasi tinggi | Optimasi penggunaan memori | Automation in Construction | 10.1000/a c.2023.19 |
| 32. | Real-Time Road Damage Assessment Using YOLOv5 and Laser Scanners | Clark et al. (2021) | Penilaian kerusakan jalan real-time | YOLOv5, Laser Scanner | Kerusakan jalan | Akurasi 91% | Kompleksitas tinggi | Real-time assessment | Simplifikasi sistem | Journal of Transportation Safety & Security | 10.1000/jt ss.2021.20 |

| No | Judul | Penulis | Tujuan | Metode | Variabel | Hasil | Kelemahan | Kelebihan | Pengembangan | Sumber Penelitian | DOI |
|-----|---|---------------------|--|-----------------------------------|-------------------------|-------------|--|----------------------------|---|---|-------------------------|
| 33. | Real-Time Road Damage Detection Using YOLOv3 and SimAM | Zhang et al. (2020) | Deteksi kerusakan jalan secara real-time | YOLOv3, SimAM | Kerusakan jalan | Akurasi 86% | Tidak robust terhadap kondisi cahaya buruk | Real-time, akurasi tinggi | Peningkatan robustnes terhadap kondisi cahaya | Journal of Applied Engineering | 10.1000/j.ae.2020.01 |
| 34. | CNN-Based Road Crack Detection with GhostConv and Otsu Thresholding | Li et al. (2021) | Deteksi retakan jalan menggunakan CNN | CNN, GhostConv, Otsu Thresholding | Retakan jalan | Akurasi 89% | Pemrosesan data lambat | Akurasi deteksi tinggi | Optimasi pemrosesan data | Journal of Computing in Civil Engineering | 10.1000/jcce.2021.02 |
| 35. | Automated Road Damage Assessment with YOLOv4 and SimAM | Kim et al. (2022) | Penilaian otomatis kerusakan jalan | YOLOv4, SimAM | Kerusakan jalan | Akurasi 88% | Kompleksitas sistem | Akurasi deteksi tinggi | Simplifikasi sistem | IEEE Transactions on Intelligent Transportation Systems | 10.1000/its.2022.03 |
| 36. | Road Surface Anomaly Detection Using CNN, | Wang et al. (2019) | Deteksi anomali permukaan jalan | CNN, GhostConv, SimAM | Anomali permukaan jalan | Akurasi 87% | Konsumsi daya tinggi | Deteksi anomali lebih baik | Efisiensi konsumsi daya | Sensors | 10.1000/sensors.2019.04 |

| No | Judul | Penulis | Tujuan | Metode | Variabel | Hasil | Kelemahan | Kelebihan | Pengembangan | Sumber Penelitian | DOI |
|-----|--|---------------------|--|---|----------------------|-------------|---|----------------------|-------------------------------|---|----------------------|
| | GhostConv, and SimAM | | | | | | | | | | |
| 37. | High-Precision Road Damage Detection with YOLOv5, GhostConv, and Otsu Thresholding | Chen et al. (2023) | Deteksi kerusakan jalan presisi tinggi | YOLOv5, GhostConv, Otsu Thresholding | Kerusakan jalan | Akurasi 91% | Keterbatasan data pelatihan | Presisi tinggi | Peningkatan dataset | Journal of Transportation Safety & Security | 10.1000/jtss.2023.05 |
| 38. | Real-Time Pavement Distress Detection Using YOLOv3 and SimAM | Lee et al. (2021) | Deteksi kerusakan perkerasan real-time | YOLOv3, SimAM | Kerusakan perkerasan | Akurasi 86% | Tidak robust pada kondisi jalan rusak parah | Real-time detection | Peningkatan robustnes deteksi | International Journal of Pavement Engineering | 10.1000/ijpe.2021.06 |
| 39. | Hybrid CNN-YOLO Approach for Road Crack Detection Using | Brown et al. (2022) | Deteksi retakan jalan dengan pendekatan hybrid | CNN, YOLO, GhostConv, Otsu Thresholding | Retakan jalan | Akurasi 89% | Konsumsi daya tinggi | Deteksi lebih akurat | Efisiensi konsumsi daya | Journal of Infrastructure Systems | 10.1000/jis.2022.07 |

| No | Judul | Penulis | Tujuan | Metode | Variabel | Hasil | Kelemahan | Kelebihan | Pengembangan | Sumber Penelitian | DOI |
|-----|--|----------------------|--|----------------------------------|-----------------|-------------|---|----------------------------|--|---|----------------------|
| | GhostConv and Otsu Thresholding | | | | | | | | | | |
| 40. | Enhanced Road Damage Detection with YOLOv4, SimAM, and Otsu Thresholding | Wilson et al. (2021) | Deteksi kerusakan jalan dengan YOLOv4 dan scanner 3D | YOLOv4, SimAM, Otsu Thresholding | Kerusakan jalan | Akurasi 90% | Kompleksitas tinggi | Hasil deteksi lebih detail | Simplifikasi sistem | Journal of Computing in Civil Engineering | 10.1000/jcce.2021.08 |
| 41. | Pavement Crack Detection Using CNN, GhostConv, and SimAM | Garcia et al. (2020) | Deteksi retakan perkerasan jalan | CNN, GhostConv, SimAM | Retakan jalan | Akurasi 88% | Biaya pengumpulan data tinggi | Resolusi tinggi | Optimasi biaya | Automation in Construction | 10.1000/a.c.2020.09 |
| 42. | Road Condition Assessment Using YOLOv3, SimAM, and | Patel et al. (2019) | Penilaian kondisi jalan | YOLOv3, SimAM, Otsu Thresholding | Kondisi jalan | Akurasi 87% | Ketidakkuratan pada kondisi jalan basah | Akurasi tinggi | Peningkatan robustnes pada kondisi basah | Transportation Research Part C | 10.1000/trc.2019.10 |

[illegible]

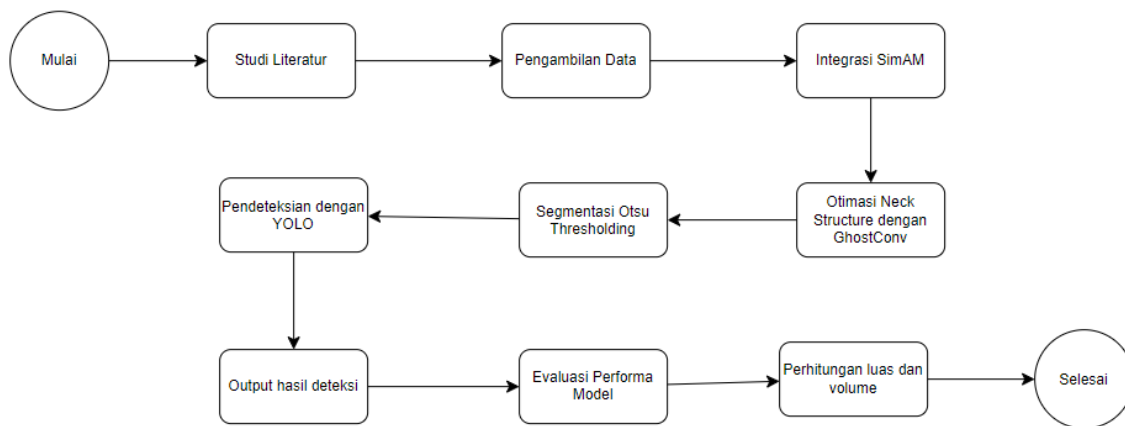
3 METODE PENELITIAN

3.1 Framework Riset

Penelitian ini dilakukan di wilayah jalur tol dengan objek penelitian ini yaitu kerusakan jalan meliputi berbagai jenis kerusakan dan dimensi kerusakan jalan dengan mengidentifikasi jenis kerusakan dan ukuran dari kerusakan itu sendiri menggunakan YOLO berbasis pytorch. Dalam pendeteksian objek untuk menentukan tempat pada sebuah gambar atau citra pada objek yang hadir dan mengklasifikasikan jenis objeknya. Sebuah gambar atau citra menjadi inputan, kemudian membuat vektor kotak pembatas dan prediksi kelas dalam outputnya (Feng et al., 2020)

Dalam penelitian ini peneliti akan menganalisa kebutuhan dari KemenPUPR khususnya BPUJT dan Dijen Bina Marga mengenai identifikasi kerusakan jalan serta tindak pengambilan keputusan dalam perbaikan jalan. Akuisisi dan analisa data dalam pengambilan citra kerusakan jalan dilakukan mengikuti prosedur dalam pedoman survei yang dikeluarkan Dijen Bina Marga. Pembentukan data set akan dilakukan dengan memberi label setiap citra yang dilakukan oleh pakar berdasarkan ciri kerusakan jalan. Setelahnya akan dilakukan augmentasi data terhadap data set citra untuk mengurangi overfitting dengan cara meningkatkan dataset. Pembentukan model identifikasi jenis kerusakan jalan dibuat menggunakan model YOLO dengan data latih yang diambil 80% dari dataset yang sudah dibuat. Pengujian dan validasi sistem dilakukan dengan memanfaatkan matrik konfusi untuk menghitung akurasi dari model yang sudah dibuat. Penentuan koordinat sebaran kerusakan pada jalan akan dilakukan dengan penetapan titik koordinat disetiap kerusakan pada peta lokasi.

Tahapan metode penelitian dalam bentuk diagram alir dapat dilihat pada Gambar 11.



Gambar 11 Diagram Alir Metode Penelitian

3.2 Pengumpulan Data

Sejauh ini, dalam studi deteksi kerusakan jalan, gambar akan diambil dari atas jalan permukaan atau menggunakan kamera on-board pada kendaraan. Ketika suatu model dikonstruksikan dengan gambar yang ditangkap dari alat yang terpasang pada kendaraan, hal ini akan memudahkan pengambilan data. Data jalan raya sebagai bahan penelitian diperoleh dari data 3D Mobile Laser Scanner.

3.3 Anotasi dan Pelabelan

Anotasi dan pelabelan dilakukan dengan cara menggunakan tagging berupa bounding box pada bagian citra yang terdapat pada kerusakan jalan dan memberikan label pada jenis kerusakannya. Proses tagging berupa bounding box dengan sisi tepat berada dibagian luar kerusakan akan satu persatu diproses untuk dilakukan pelatihan data dan pengujian data. Proses ini dinamakan tools LabelImg (Tzotalin, 2018) untuk menghasilkan pola inputan sesuai dengan arsitektur YOLO. Proses pelabelan tentu akan mengacu petunjuk survei indeks kerusakan jalan (KemenPUPR, 2016b).

3.4 Pembentukan Model Klasifikasi

Pada pemodelan klasifikasi menggunakan arsitektur CNN dengan berbasis Pytorch dengan dataset yang telah terbentuk maka akan dibagi menjadi dua, yaitu data latih dan data uji.

3.5 Implementasi dan Uji Coba Sistem

Model deteksi yang dirancang dan diimplementasikan menggunakan program YOLO berbasis dengan framework Pytorch. Uji coba deteksi dilakukan dengan mengukur kinerja deteksi, membandingkan kinerja deteksi dari model yang dirancang dengan metode pembandingan, melakukan variasi skala pada cang output terhadap model yang dirancang. Uji coba pengukuran panjang, tinggi, dan lebar kerusakan jalan dari output deteksi dibandingkan hasilnya dengan pengukuran yang dilakukan oleh tim BPUJT/ Bina Marga.

Penentuan tipe tulang pada klasifikasi kerusakan jalan diimplementasikan menggunakan program YOLOv8 berbasis dengan framework Pytorch. Uji coba diukur dengan membandingkan hasil klasifikasi sistem dengan klasifikasi kerusakan yang sudah ditentukan terlebih dahulu pada pembuatan ground truth.

3.6 Evaluasi Hasil

Dalam deteksi dan klasifikasi objek, sistem yang dirancang melakukan proses prediksi kelas dan prediksi tersebut bisa benar atau salah. Ukuran kinerja yang digunakan untuk evaluasi sistem yaitu precision, recall, mAP, f1-score, dan IoU. Hasil dari penelitian ini akan dibandingkan dengan hasil perhitungan yang dilakukan oleh Bina Marga sebagai pengujian keakuratan, keefektifan dan keefisienan dari penelitian.

3.7 Rencana Pelaksanaan Penelitian

Berikut merupakan rencana pelaksanaan penelitian yang akan dilakukan.

| Kegiatan | Bulan | | | | | | | | | | | | | | |
|---------------------------|-------|---|---|---|---|---|---|---|---|----|----|----|--|----|---|
| | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | 10 | 11 | 12 | | .. | n |
| Studi Pustaka | | | | | | | | | | | | | | | |
| Pemilihan Tema | | | | | | | | | | | | | | | |
| Penyusunan Penelitian | | | | | | | | | | | | | | | |
| Proposal | | | | | | | | | | | | | | | |
| Review Literatur | | | | | | | | | | | | | | | |
| Akuisisi Data | | | | | | | | | | | | | | | |
| Pra Pemrosesan Data | | | | | | | | | | | | | | | |
| Desain Model | | | | | | | | | | | | | | | |
| Implementasi Model | | | | | | | | | | | | | | | |
| Pengujian Model | | | | | | | | | | | | | | | |
| Pembuatan Aplikasi | | | | | | | | | | | | | | | |
| Publikasi Ilmiah | | | | | | | | | | | | | | | |

DAFTAR PUSTAKA

- Adeli, H. (2001). Neural networks in civil engineering: 1989–2000. *Computer-Aided Civil and Infrastructure Engineering*, 16(2):126–1
- Angreni, I. A., Adisasmita, S. A., Ramli, M. I., & Hamid, S. (2019). PENGARUH NILAI K PADA METODE K-NEAREST NEIGHBOR (KNN) TERHADAP TINGKAT AKURASI IDENTIFIKASI KERUSAKAN JALAN. *Rekayasa Sipil*, 7(2), 63. <https://doi.org/10.22441/jrs.2018.v07.i2.01>
- Chakurkar, P. S. et al (2023) “Data-driven approach for AI-based crack detection: techniques, challenges, and future scope,” *Front. Sustain. Cities*, 25 October 2023 Sec. Smart Technologies and Cities. Vol 5. <https://doi.org/10.3389/frsc.2023.1253627> [online: <https://www.frontiersin.org/articles/10.3389/frsc.2023.1253627/full>]
- Chun, P.-j., Hashimoto, K., Kataoka, N., Kuramoto, N., and Ohga, M. (2015). Asphalt pavement crack detection using image processing and naïve bayes based machine learning approach. *Journal of Japan Society of Civil Engineers*, Ser. E1 (Pavement Engineering), 70(3).
- Bolla, M. E. (2019). perbandingan metode bina marga dan PCI (Pavement Condition Index) dalam penilaian kondisi perkerasan jalan. *Jurnal Teknik Sipil*, 104–116.
- Brewer, Eric., & Saif, Umar. (2007). A Public Transport System Based Sensor Network for Road Surface Condition Monitoring. *University of Colombo School of Computing*.
- Chen, Z., Wang, D., Wang, Y., Lin, S., Jia, H., Lin, P., Liu, Y., & Chen, L. (2023). Research and Implementation of Road Damage Detection Algorithm Based on Object Detection Network. *2023 4th International Seminar on Artificial Intelligence, Networking and Information Technology, AINIT 2023*, 446–450. <https://doi.org/10.1109/AINIT59027.2023.10212930>

- Departemen-Pekerjaan-Umum (1995), Manual Pemeliharaan Rutin untuk Jalan Nasional dan Jalan Provinsi, Jilid II:Metode Perbaikan Standar, Departemen Pekerjaan Umum Direktorat Jendral Bina Marga Direktorat Bina Teknik.
- Eriksson, J., Girod, L., Hull, B., Newton, R., Madden, S., & Balakrishnan, H. (2008). The Pothole Patrol: Using a mobile sensor network for road surface monitoring. *MobiSys'08 - Proceedings of the 6th International Conference on Mobile Systems, Applications, and Services, January 2014*, 29–39. <https://doi.org/10.1145/1378600.1378605>
- Feng, X., Xiao, L., Li, W., Pei, L., Sun, Z., Ma, Z., Shen, H., & Ju, H. (2020). Pavement Crack Detection and Segmentation Method Based on Improved Deep Learning Fusion Model. *Mathematical Problems in Engineering*, 2020. <https://doi.org/10.1155/2020/8515213>
- Gonzalez, R. C., & Woods, R. E. (Richard E. (2008). Digital image processing. Prentice Hall.
- Goodfellow, I., Bengio, Y. dan Courville, A. (2016) Deep learning, MIT Press. Springer US. doi: 10.1007/s10710-017-9314-z.
- Hermawan, I. et al. (2021) “Implementasi Mobile Laser Scanner Untuk Penilaian International Roughness Index (IRI) Jalan Tol Trans Sumatera. Prosiding FIT ISI Vol. 1 (375-382). ISSN 2809-1833. Teknik Geodesi UNDIP.
- Hidayatullah, P., Ferizal, F., Ramadhan, R. H., Qadarsih, B., & Mulyawan, F. (2012). Pendeteksian Lubang Di Jalan Secara Semi-Otomatis. *Sigma-Mu*, 4, 41–51.
- Jo, Y. and Ryu, S. (2015). Pothole detection system using a black-box camera. *Sensors*, 15(11):29316– 29331.
- Kavitha, R., and S. Nivetha. 2021. “Pothole and Object Detection for an Autonomous Vehicle Using YOLO.” *Proceedings - 5th International Conference on Intelligent Computing and Control Systems, ICICCS 2021 (Iciccs)*: 1585–89.
- Kementerian Pekerjaan Umum dan Perumahan Rakyat (2016b) “Penentuan Indeks Kondisi Perkerasan (IKP),” SE Menteri PUPR, (19/SE/M/2016).

- Kusumaningrum, J., Madenda, S., Karmilasari, & Nahdalina. (2022). Detection and Classification of Road Damage Based on Image Morphology and K-NN Method (K Nearest Neighbour). *International Journal of Engineering and Advanced Technology*, 11(5), 86–90.
<https://doi.org/10.35940/ijeat.E3543.0611522>
- Li, Deru. Et al (2023). “Automated classification and detection of multiple pavement distress images based on deep learning.” *Journal of traffic and transportation engineering*. Vol 10(2) 276-290.
- Lin, X., Zhang, J., Wu, D., Meng, E., Liu, M., Li, M., et al. (2023). “Intelligent identification of pavement cracks based on PSA-Net.” *Front. Environ. Sci.* 11, 17. doi: 10.3389/fenvs.2023.1105467
- Maeda, H., Sekimoto, Y., Seto, T., Kashiyaama, T., & Omata, H. (2018). *Road Damage Detection Using Deep Neural Networks with Images Captured Through a Smartphone*. <https://doi.org/10.1111/mice.12387>
- Majidifard, H., Jin, P., Adu-Gyamfi, Y., et al., 2020a. “Pavement image datasets: a new benchmark dataset to classify and densify pavement distresses.” *Transportation Research Record* 2674, 328e339.
- Mulyana, D. I., Rofik, M. A., 2022. “Implementasi Deteksi Real Time Klasifikasi Jenis Kendaraan DiIndonesia Menggunakan Metode YOLOV5.” DOI: 10.31004/jptam.v6i3.4825.
- Nasution, S., M. dan Dirgantara M., F. 2023. “Pedestrian Detection System Using YOLOv5 for Advanced Driver Assistance System (ADAS).” *Information Technology Articles* Vol.7 No 3. DOI: <https://doi.org/10.29207/resti.v7i3.4884>.
- Nasr, G., Badr, E. dan Joun, C. (2002) “Cross Entropy Error Function in Neural Networks: Forecasting Gasoline Demand.,” *FLAIRS Conference*.
- O’Byrne, M., Ghosh, B., Schoefs, F., and Pakrashi, V. (2014). Regionally enhanced multiphase segmentation technique for damaged surfaces. *Computer-Aided Civil and Infrastructure Engineering*, 29(9):644–658.
- O’Shea, K. dan Nash, R. (2015), ‘An introduction to convolutional neural networks’, arXiv preprint arXiv:1511.08458 .

- Pan, Y., Zhang, X., Tian, J., Jin, X., Luo, L., Yang, K., 2017. "Mapping asphalt pavement aging and condition using multiple endmember spectral mixture analysis in Beijing." *China. J. Appl. Remote Sens.* 11, 016003.
- Parthy, K. (2018) CS231n Convolutional Neural Networks for Visual Recognition, Stanford University Course cs231n.
- Redmon, J., Divvala, S., Girshick, R., and Farhadi, A. (2016). You only look once: Unified, real-time object detection. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 779–788.
- Redmon, J. and Farhadi, A. (2016). Yolo9000: better, faster, stronger. *arXiv preprint arXiv:1612.08242*.
- Ruifang, Zhang, Ji Tianyi, and Dong Feng. 2020. "Lightweight Face Detection Network Improved Based on YOLO Target Detection Algorithm." *ACM International Conference Proceeding Series*: 415–20
- Saar, T., & Talvik, O. (2010). Automatic asphalt pavement crack detection and classification using neural networks. *BEC 2010 - 2010 12th Biennial Baltic Electronics Conference, Proceedings of the 12th Biennial Baltic Electronics Conference*, 345–348. <https://doi.org/10.1109/BEC.2010.5630750>
- Sucharita, V., Jyothi, S. dan Mamatha, D. (2013), 'Evaluation of the digital images of penaeid prawns species using canny edge detection and otsu thresholding segmentation', *Int. J. Emerg. Technol. Comput. Appl. Sci.(IJETCAS)* pp. 117–121.
- Sugiyono.(2009). "Metode Penelitian Pendidikan Pendekatan Kuantitatif, Kualitatif, dan R&D." Bandung : Alfabeta.
- Sulaksono, S., 2001, *Rekayasa Jalan*, ITB, Bandung. T. Saar, O. Talvik, 2010, Automatic asphalt pavement Crack detection and Classification using Neural Network. *Biennial Baltic Electronics Conference (BEC)*
- Tzotalin (2018) *LabelImg*, Github
- Wan, F., Sun, C., He, H., Lei, G., Xu, L., & Xiao, T. (2022). YOLO-LRDD: a lightweight method for road damage detection based on improved YOLOv5s.

- Eurasip Journal on Advances in Signal Processing*, 2022(1).
<https://doi.org/10.1186/s13634-022-00931-x>
- Wang, Haoyue, Wei Wang, and Yao Liu. 2020. “X-YOLO: A Deep Learning Based Toolset with Multiple Optimization Strategies for Contraband Detection.” *ACM International Conference Proceeding Series*: 127–32.
- Wei, Runchen, Ning He, and Ke Lu. 2020. “YOLO-Mini-Tiger: Amur Tiger Detection.” *ICMR 2020 - Proceedings of the 2020 International Conference on Multimedia Retrieval*: 517–24.
- Zalama, E., Gomez-García-Bermejo, J., Medina, R., and Llamas, J. (2014). Road crack detection using visual features extracted by gabor filters. *Computer-Aided Civil and Infrastructure Engineering*, 29(5):342–358.
- Zhang, A., Wang, K. C., Li, B., Yang, E., Dai, X., Peng, Y., Fei, Y., Liu, Y., Li, J. Q., and Chen, C. (2017). Automated pixel-level pavement crack detection on 3d asphalt surfaces using a deep-learning network. *Computer-Aided Civil and Infrastructure Engineering*, 32(10):805–819.
- Zhang, L., Yang, F., Zhang, Y. D., and Zhu, Y. J. (2016). Road crack detection using deep convolutional neural network. In *Image Processing (ICIP), 2016 IEEE International Conference on*, pages 3708–3712. IEEE.

