



PENGEMBANGAN METODE IDENTIFIKASI
PERGERAKAN ANOMALI PADA KERUMUNAN
BERBASIS GENERATIF

Ike Putri Kusumawijaya

99216004

PROGRAM DOKTOR TEKNOLOGI INFORMASI
UNIVERSITAS GUNADARMA
2022

ABSTRAK

Mendeteksi perilaku anomali dengan cepat dan otomatis di lingkungan yang ramai sangat penting untuk meningkatkan keselamatan, mencegah risiko, dan menjamin respon yang cepat. Deteksi anomali dalam sistem pengawasan sangat penting untuk memastikan keselamatan, keamanan, dan dalam beberapa kasus termasuk dalam pencegahan kemungkinan bencana. Deteksi anomali bermaksud untuk menemukan anomali dalam waktu cepat secara otomatis. Sistem pemantauan cerdas menjadi penting untuk manajemen kerumunan yang efektif. Tujuan dari penelitian ini adalah mengembangkan metode untuk identifikasi pergerakan anomali pada kerumunan berbasis generatif menggunakan *Generative Adversarial Network* (GAN) dan menggunakan pemrosesan video secara *real-time*. Konsep penelitian berawal dari kamera pengawas yang membandingkan masukkan dari *train GAN* yang disimpan di dalam server dengan video yang diambil dari kamera secara *real time*, hasil dari perbandingan video tersebut akan menghasilkan *behaviour analysis* atau pola gerakan anomali pada kerumunan sehingga outputnya akan menjadi suatu dataset untuk identifikasi gerakan anomali pada kerumunan.

DAFTAR ISI

Halaman Judul	i
Abstrak	ii
Daftar Isi	iii
1. PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Batasan Masalah	2
1.3 Tujuan Penelitian	3
1.4 Kontribusi Penelitian	3
2. TINJAUAN PUSTAKA	2
2.1 Perilaku Kolektif	2
2.2 Analisis Kerumunan	2
2.3 Model Kerumunan Terinspirasi dari Fisika	8
2.3.1 <i>Social Force Models</i>	8
2.3.2 <i>Flow Field Models</i>	10
2.3.3 <i>Crowd Energy Models</i>	11
2.3.4 <i>Substantial Derivative</i>	12
2.4 Representasi Gerak	12
2.5 Konsep dan Jenis Anomali	15
2.6 Deteksi Anomali Kerumunan	16
2.6.1 Kriteria Deteksi Anomali	19
2.6.2 Deteksi Anomali Menggunakan Metode <i>Handcrafted</i>	20
2.6.3 Deteksi Anomali Menggunakan <i>Neural Networks</i>	22
2.6.4 Deteksi Anomali Menggunakan <i>Generative Adversarial Networks</i>	24
2.7 <i>Generative Modeling</i>	26
2.8 <i>Machine Learning</i>	28
2.8.1 <i>Deep Learning</i>	30
2.8.2 <i>Support Vector Machine</i>	31

2.8.3 <i>Generative Adversarial Networks</i>	32
2.9 Rangkuman Hasil Penelitian Terkait	35
3. METODOLOGI PENELITIAN	48
3.1 Sistem Struktur Anomali pada Kerumunan	48
3.2 Kerangka Penelitian Perilaku Anomali pada Kerumunan	49
3.3 Tahap Pelatihan dan Pengujian Menggunakan GAN	50
DAFTAR PUSTAKA	53

1. PENDAHULUAN

1.1 Latar Belakang

Dengan bertambahnya populasi dan keragaman aktivitas manusia, adegan keramaian menjadi lebih sering terjadi di dunia nyata daripada sebelumnya. Komposisi penonton yang heterogen dalam hal warna kulit, usia, bahasa, dan budaya menghadirkan beberapa masalah administratif bagi penyelenggara lokal yang berfokus pada memastikan manajemen acara yang efisien. Otoritas administratif lebih peduli untuk memahami mekanisme kerumunan yang menjelaskan apa yang dapat membahayakan kerumunan besar. Hal tersebut membawa tantangan besar bagi manajemen publik, keamanan atau keselamatan.

Aktivitas perubahan individu dalam kerumunan dapat terjadi karena beberapa hal, biasanya dipicu oleh kejadian tidak normal seperti kebakaran, suara keras yang berbahaya, pelepasan gas, atau adanya tindakan mengancam seperti tauran, perampokan atau tindakan criminal lainnya. Perilaku ini menimbulkan keributan atau *chaos* yang dihasilkan dapat mengarah pada tindakan yang sama mengancamnya dengan insiden itu sendiri (Grant dan Flynn, 2017). Untuk mengidentifikasi/menafsirkan insiden keributan tersebut secara manual hampir tidak mungkin (Cao et al., 2009; Joshi et al., 2019), dikarenakan jumlah kamera pengawas yang berada didalam satu area melebihi jumlah personel dan monitor, sehingga potensi kesalahan seperti personel yang mengabaikan insiden atau melewatkan insiden ini dapat terjadi dalam hal ini

Tempat-tempat umum menggunakan semakin banyak kamera pengintai, misalnya, sistem transportasi umum, rumah sakit, pusat perbelanjaan, taman, dll. Kamera keamanan yang sangat besar membuat sejumlah besar video dan aplikasi potensial mencakup deteksi objek, pelacakan, pengambilan gambar, dan sebagainya. Dengan meluasnya penggunaan teknik pengawasan video, evaluasi manual dari sejumlah besar data video kerumunan yang dikumpulkan dari kamera pengawasan menjadi rumit, memakan waktu, dan tidak efektif dalam kasus kerumunan besar. Hal ini membutuhkan tenaga kerja dan perhatian terus menerus untuk memutuskan apakah tindakan yang

diambil adalah normal atau tidak normal. Oleh karena itu, fungsi deteksi anomali otomatis diperlukan untuk sistem pengawasan dalam mengidentifikasi dan mendeteksi anomali secara akurat di tempat kejadian.

Mendeteksi perilaku abnormal dengan cepat dan otomatis di lingkungan yang ramai sangat penting untuk meningkatkan keselamatan, mencegah risiko, dan menjamin respon yang cepat. Deteksi anomali dalam sistem pengawasan sangat penting untuk memastikan keselamatan, keamanan, dan dalam beberapa kasus termasuk dalam pencegahan kemungkinan bencana. Deteksi anomali bermaksud untuk menemukan anomali dalam waktu cepat secara otomatis. Sistem pemantauan cerdas menjadi penting untuk manajemen kerumunan yang efektif. *Computer vision*, analisis video, dan deteksi anomali pada kerumunan secara otomatis telah menjadi topik penelitian yang populer dan karena adegan yang rumit dan ketidakpastian anomali, deteksi anomali ini masih menantang.

Untuk masalah *unsupervised* dan *semi-supervised*, *generative adversarial network* (GAN) menjadi metode yang representatif di bidang kecerdasan buatan. Dalam jaringan tradisional, vektor berdimensi tinggi perlu ditransfer ke vektor laten agar menyerupai data sumber. Banyak pendekatan yang telah meningkatkan masalah dari tahap pelatihan. GAN menunjukkan kinerja yang lebih baik dibandingkan dengan metode tradisional. GAN adalah *semi-supervised learning* dari representasi fitur yang kaya untuk distribusi data arbitrer. Metode ini sangat cocok digunakan untuk deteksi anomali. Jaringan double-encoder memungkinkan model untuk menghasilkan gambar ke representasi yang mendasarinya dalam tahap pelatihan. GAN mempelajari kejadian reguler dengan meminimalkan jarak antara frame video yang berdekatan dan vektor laten (Han et al., 2020).

1.2 Batasan Masalah

Penelitian ini merupakan pengembangan bidang analisis kerumunan dengan menggunakan metode *Generative adversarial network (GAN)*, metode ini digunakan untuk meningkatkan kinerja deteksi pergerakan manusia dalam kerumunan di tempat umum/publik. Adapun batasan masalah dari penelitian ini adalah sebagai berikut :

1. Video diambil dengan menggunakan kamera pengawas di tempat ramai.
2. Video yang digunakan seluruhnya merupakan sampel digital dengan kuantisasi 28 yang artinya setiap piksel memiliki rentang nilai $[0, 255]$.
3. Penelitian ini membahas bagaimana *Generative Adversarial Networks* dalam mendeteksi pergerakan anomali pada kerumunan.

1.3 Tujuan Penelitian

Tujuan dari penelitian ini adalah mengembangkan metode untuk mengidentifikasi pergerakan anomali pada kerumunan berbasis generatif menggunakan *Generative Adversarial Network* (GAN) dan menggunakan pemrosesan video secara *real time*. Pengembangan penelitian GAN dengan menggunakan representasi video secara *real-time* memungkinkan dapat diimplementasikan secara langsung di tempat publik.

Penelitian ini juga bertujuan untuk melakukan deteksi pergerakan pada kerumunan dalam tingkat kepadatan yang berbeda, sehingga dapat mengklasifikasi pergerakan kerumunan yang bersifat anomali maupun normal.

1.4 Kontribusi Penelitian

Penelitian ini diharapkan dapat memberikan kontribusi sebagai berikut :

1. Penelitian ini menyajikan pendekatan baru untuk deteksi pergerakan anomali pada kerumunan dengan menerapkan video sebagai representasi gerak menggunakan algoritma GAN.
2. Penelitian ini dapat mengklasifikasi kumpulan data pergerakan anomali dengan beragam nilai kepadatan orang.
3. Penelitian ini menghasilkan kumpulan data pergerakan pada kerumunan dengan beragam nilai kepadatan dari berdensitas tinggi hingga rendah dengan berlabel keterangan normal dan anomali. Kumpulan data yang terkumpul menjadi dataset untuk dikembangkan oleh peneliti selanjutnya.

2. TINJAUAN PUSTAKA

2.1 Perilaku Kolektif


Presentasi hierarkis kerumunan memungkinkan 'kerumunan' untuk diberi peringkat di tingkat teratas dengan kumpulan beberapa grup di bawahnya. Terletak di bawah setiap kelompok adalah kumpulan individu. Individu dianggap sebagai level terbawah. Terutama adegan yang ramai dapat dikategorikan sebagai terstruktur atau tidak terstruktur (Rodriguez et al., 2009). Dalam kerumunan yang terstruktur, gerakan kerumunan biasanya dalam arah yang sama. Varians dalam arah gerak biasanya tidak berubah. Selain itu, orang banyak menunjukkan perilaku keseluruhan tunggal dari waktu ke waktu. Contohnya adalah cuplikan dari penonton di konser rock, penonton menghadap ke panggung dan kemungkinan besar bergoyang bersama atau melompat-lompat secara bersamaan. Sedangkan *unstructured crowds* (Sjarif et al., 2011), suasananya sangat riuh (penuh dengan aktivitas, kegembiraan, atau kebingungan). Gerakan kerumunan itu acak dan individu-individu dalam kerumunan itu bergerak ke berbagai arah pada saat tertentu. Selain itu, adegan tersebut menyajikan banyak perilaku orang banyak. Contohnya adalah kerumunan penumpang di stasiun kereta api. Individu di kerumunan akan menunjukkan perilaku yang berbeda seperti berlari ke peron, mengantri untuk membeli tiket, duduk di bangku, atau berdiri di sekitar melihat layar.

2.2 Analisis Kerumunan

Analisis kerumunan merupakan tahap mengidentifikasi setiap orang dalam satu kejadian bersama dengan posisi yang berbeda. Dalam proses identifikasi terdapat proses segmentasi yang diterapkan untuk menghitung jumlah orang dalam kerumunan. Berbagai macam proses metode segmentasi untuk menganalisis kerumunan, seperti metode identifikasi seluruh kontur tubuh (kepala, bahu, lengan, dan kaki), atau secara efisien membetuk tubuh bentuk manusia (kepala dan bahu). Permasalahan yang muncul dengan penerapan metode ini adalah penanganan oklusi dan menangani kerumunan dengan beragam jenis kepadatan. Beberapa sub-area yang harus dipertimbangkan saat

menggunakan pendekatan langsung termasuk metode berbasis model dan metode pengelompokan berbasis lintasan untuk analisis kerumunan (Saleh et al., 2015).

Acara berskala besar, ramai, dan menarik orang dari berbagai lokasi dengan latar belakang budaya yang beragam dapat menghasilkan tantangan manajemen, kontrol, dan komunikasi yang signifikan karena keragamannya. Pertemuan besar ini berpotensi berbahaya bagi publik. Banyak karakteristik fisik yang menggambarkan perilaku kerumunan, termasuk arah gerak, kecepatan, energi, dan gaya interaksi. Bidang analisis kerumunan mencakup tiga konsep atau level umum (Aldayri & Albattah, 2022) : manajemen kerumunan, pemantauan kerumunan, dan kontrol kerumunan.

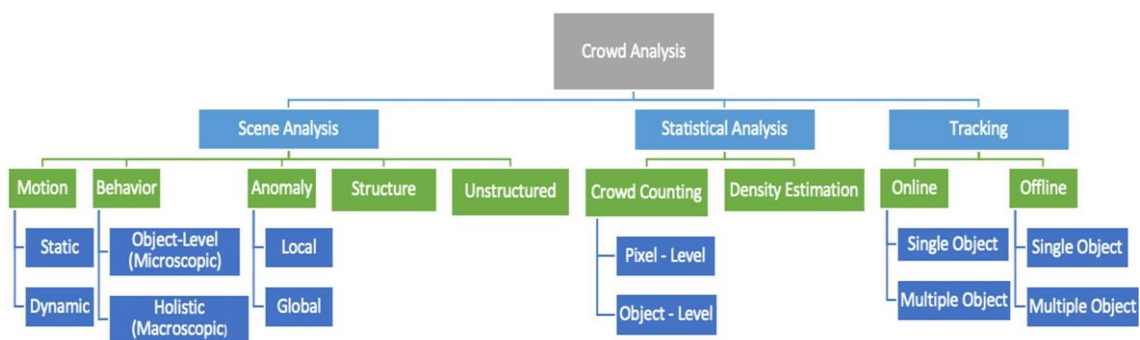


Gambar 2.1 Konsep Analisis Kerumunan (Aldayri & Albattah, 2022)

Manajemen kerumunan (***crowd management***) didefinisikan sebagai penggunaan teknik untuk merencanakan dan mengelola acara pengumpulan massa sebelum, selama, dan setelah acara. Hal ini dilakukan untuk memastikan keselamatan orang, perencanaan dan pengelolaan acara yang baik, memprediksi dan mencegah masalah yang tidak terduga, dan menyiapkan rencana awal untuk keadaan darurat. Pemantauan kerumunan (***crowd monitoring***) memberikan kesempatan untuk memperkirakan dinamika kerumunan, mendeteksi dan memprediksi kemungkinan risiko, melacak, mendukung simulasi virtual perilaku kerumunan, dan mengembangkan sistem otomatis. Secara global, lembaga keamanan dan manajemen acara mulai menyadari pentingnya pemantauan kerumunan, mengingat meningkatnya kekhawatiran tentang keselamatan

publik. Kontrol kerumunan (*crowd controlling*) adalah praktik keamanan publik dan tindakan yang diambil selama situasi untuk mencegah perilaku anomali seperti perkelahian, kerusakan, atau kerumunan massa terjadi.

Analisis adegan kerumunan otomatis melibatkan penghitungan, pelacakan, dan pengidentifikasian perilaku kerumunan besar individu yang menempati ruang fisik yang sama. Perkiraan jumlah orang di suatu daerah dikenal dengan istilah *crowdcounting*. Aspek penting dari keselamatan kerumunan adalah pengenalan aksi kerumunan, yang mengenali tindakan yang berbeda dari individu atau kelompok individu. Kemampuan untuk melacak objek dalam urutan video yang ramai sangat penting untuk menafsirkan adegan visual.



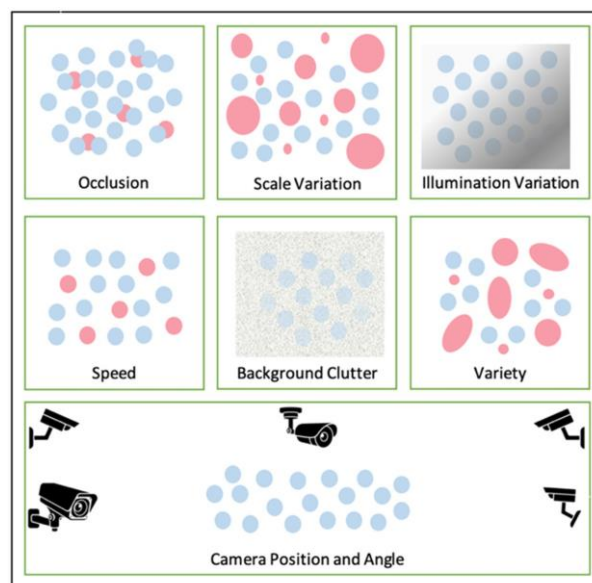
Gambar 2.2 Taksonomi pada Analisis Kerumunan (Aldayri & Albattah, 2022)

- **Scene Analysis:** Analisis video otomatis dan dapat mendeteksi serta menganalisis peristiwa temporal dan spasial. Kegunaannya dalam menemukan anomali secara *real-time*, memantau keramaian, mendeteksi pejalan kaki, dan melacak kendaraan. Membuat analisis adegan video menjadi topik penelitian yang aktif. CCTV yang tersebar di area publik yang ramai memudahkan proses analisis gerakan, pemahaman perilaku, deteksi anomali, dan penentuan jenis kerumunan, apakah terstruktur atau tidak terstruktur.
- **Statistical Analysis:** Estimasi kepadatan massa dan penghitungan massa adalah contoh analisis statistik, yang melibatkan analisis pola dan tren dalam data kuantitatif. Jumlah orang per meter dapat digunakan untuk menghitung kepadatan

massa. Sedangkan *crowdcounting* adalah metode menghitung berapa banyak orang yang hadir dalam suatu ruang. Estimasi ini efektif dalam mengendalikan arus keramaian di area tertentu dan menghindari kepadatan, kecelakaan, dan injak-injak.

- **Tracking:** Pelacakan objek adalah proses penentuan lokasi objek bergerak dari waktu ke waktu. Sebuah objek dapat dilacak secara *online* atau *offline*, dan satu objek atau beberapa objek dapat dilacak secara bersamaan. Perubahan fitur dari waktu ke waktu dapat digunakan untuk melacak anomali yang terdeteksi oleh deteksi objek.

Beberapa entitas bergerak dalam video tidak tampak jelas bagi pengamat dalam beberapa keadaan. Ada beragam jenis tantangan, seperti yang diilustrasikan pada Gambar 2.3.



Gambar 2.3 Tantangan pada Analisis Adegan Kerumunan (Aldayri & Albattah, 2022)

- **Occlusion:** terjadi ketika dua atau lebih objek datang terlalu dekat bersama-sama dan tampaknya bergabung, yang menyebabkan sistem kehilangan jejak objek yang dapat dilacak atau melacak objek yang salah karena tumpang tindih.

- **Scale Variation:** terjadi ketika ada berbagai ukuran objek yang dilacak, yang menyebabkan sistem pelacakan kehilangan pelacakan yang tepat.
- **Illumination Variation:** mengacu pada variasi kuantitas cahaya asal yang dicerminkan pada gambar dan dapat disebabkan oleh perubahan pencahayaan, bayangan, atau kebisingan.
- **Speed:** sementara objek dalam adegan sering bergerak dengan kecepatan yang berbeda, prediktor harus mengenali objek dalam video bergerak secara akurat dengan menjadi cepat selama prediksi.
- **Background Clutter:** mengacu pada keberadaan sejumlah besar objek dalam gambar yang menyulitkan detektor untuk mengenali objek individual karena pengaturannya yang tidak seragam. Ada kemungkinan objek yang perlu diidentifikasi akan menyatu dengan latar belakang, sehingga sulit untuk dideteksi.
- **Variety:** terjadi ketika suatu benda memiliki lebih dari satu bentuk dan ukuran.
- **Camera Position and Angle:** mungkin ada ketidakkonsistenan dalam perspektif karena sudut dan posisi kamera yang berbeda, serta gerakan kamera yang miring dan naik turun.

2.3 Model Kerumunan Terinspirasi dari Fisika

Beberapa model yang terinspirasi dari fisika telah dikembangkan pada masa lalu untuk mendeteksi anomali pada kerumunan dan dapat dibagi menjadi *Social Force Model*, *Flow Field Model*, *Crowd Energy Model*, dan pendekatan yang terinspirasi dari fisika lainnya seperti *Substantial Derivative* yang dipinjam dari dinamika fluida untuk memodelkan dinamika massa (Bour et al., 2019).

2.3.1 Social Force Models

Social Force Model (SFM), awalnya diperkenalkan oleh Helbing et al. adalah metode mani historis untuk pemodelan perilaku orang banyak menurut seperangkat aturan fisik yang telah ditentukan sebelumnya. Lebih khusus, SFM bertujuan untuk mewakili kekuatan interaksi antara individu dalam kerumunan menggunakan kekuatan

tolak dan menarik yang terbukti menjadi fitur yang signifikan untuk menganalisis perilaku orang banyak. Termotivasi oleh keberhasilan SFM untuk mereproduksi pola pergerakan massa, 15 tahun kemudian Mehran et al. mengadopsi skema SFM dan partikel adveksi untuk mendeteksi dan melokalisasi perilaku abnormal dalam video kerumunan. Untuk tujuan ini, dianggap seluruh kerumunan sebagai kumpulan partikel bergerak yang gaya interaksinya dihitung menggunakan SFM. Kemudian memetakan gaya interaksi ke dalam bidang gambar untuk mendapatkan aliran gaya setiap partikel dalam bingkai video. Peta kekuatan ini digunakan sebagai dasar untuk mengekstraksi fitur yang, bersama dengan pengambilan sampel jalur *spatiotemporal* acak dan strategi *bag-of-words*, digunakan untuk menetapkan label normal atau abnormal untuk setiap frame.

Beberapa teknik berbasis SFM telah diusulkan untuk mendeteksi anomali terletak pada skenario kerumunan. Raghavendra dkk. menerapkan metode *particle swarm optimization* (PSO) untuk mengoptimalkan gaya interaksi partikel, yang dihitung dengan SFM, sehingga populasi partikel melayang menuju gerakan utama dalam urutan video. Perpindahan tersebut didorong oleh fungsi fitness PSO, yang bertujuan untuk meminimalkan gaya interaksi, sehingga dapat memodelkan perilaku kerumunan yang paling tersebar dan tipikal.

Pendekatan ini mendeteksi dan melokalisasi anomali dengan memeriksa apakah beberapa partikel tidak sesuai dengan distribusi gerakan yang diperkirakan. Metode yang diusulkan dalam bukunya bertujuan untuk secara *spatiotemporal* menemukan ketidakstabilan perilaku kerumunan menggunakan model kekuatan sosial berbasis medan kecepatan baru. Berbeda dengan SFM tradisional yang mendefinisikan kekuatan interaksi sebagai variabel dependen posisi geometris relatif partikel, metode ini dapat memberikan prediksi interaksi yang lebih baik menggunakan probabilitas tumbukan dalam kerumunan dinamis.

Menganalisis ketidakstabilan *spatiotemporal* dapat membantu mendeteksi potensi kelainan dalam video kerumunan dan menemukan daerah di mana kelainan dapat terjadi. Meskipun penampilan menarik dari model berbasis SFM, studi psikologi sosial baru-baru ini berpendapat bahwa terlalu disederhanakan untuk menangkap perilaku orang banyak yang kompleks, selain sangat dipengaruhi oleh kekuatan generalisasi yang buruk, yang

berarti bahwa model dikalibrasi pada serangkaian pengamatan empiris mungkin sering gagal untuk menangani serangkaian pengamatan yang berbeda (Bour et al., 2019)..

Beberapa pendekatan telah diusulkan untuk mengatasi masalah ini, heuristik perilaku dapat dianggap sebagai contoh yang paling menonjol. Secara khusus, tidak seperti model berbasis SFM yang bertujuan untuk menggambarkan gerakan kerumunan yang kompleks dengan mengkalibrasi serangkaian gaya pada pengamatan empiris, kelas pendekatan ini mendefinisikan seperangkat heuristik perilaku yang dirumuskan menggunakan konsep seperti kecepatan dan percepatan yang dipinjam dari mekanika Newton. Heuristik perilaku baru-baru ini telah berhasil digunakan untuk mendeteksi kelainan dalam kerumunan dari urutan video yang menunjukkan keunggulannya atas model SFM.

2.3.2 Flow Field Models

Tujuan dari *flow field model* adalah untuk menangkap pola reguler kerumunan dan menemukan bagaimana pola tersebut berubah dari waktu ke waktu. Dalam metode jenis ini, gerakan yang menyimpang dari pola reguler dianggap sebagai anomali. Penerapan pemodelan aliran medan pertama kali diusulkan oleh Ali et al. untuk segmentasi arus kerumunan kepadatan tinggi dan deteksi ketidakstabilan aliran. Selain itu memperluas kerangka kerja ke deteksi anomaly dengan melakukan *finite time Lyapunov exponent* (FTLE) yang batasnya bervariasi sesuai dengan perubahan perilaku aliran dinamis. *Lagrangian coherent structures* baru (LCS) muncul di bidang FTLE, tepatnya di lokasi di mana perubahan terjadi. Ketidakstabilan kerumunan diukur dengan perubahan jumlah segmen aliran dari waktu ke waktu. Ketidakstabilan yang terdeteksi dapat berpotensi digunakan untuk melokalisasi anomali pada setiap frame. Karya ini, bagaimanapun, terbatas pada adegan terstruktur, di mana batas-batas segmen kerumunan ditentukan dengan jelas. Wu et al. mengusulkan pendekatan invarian kacau untuk pemodelan aliran dan deteksi anomali untuk skenario kerumunan terstruktur dan tidak terstruktur.

Lintasan partikel yang dihitung dengan adveksi partikel dikelompokkan untuk mendapatkan lintasan yang mewakili aliran massa. Selanjutnya, dinamika kacau semua

lintasan representatif diekstraksi dan dikuantifikasi menggunakan fitur invarian kacau. Akhirnya, model probabilitas dipelajari dari fitur-fitur ini untuk mengklasifikasikan video kueri suatu adegan sebagai normal atau abnormal (Bour et al., 2019).

2.3.3 Crowd Energy Models

Berfokus pada simulasi bagaimana perpindahan gerakan massa dari situasi normal ke abnormal (dan sebaliknya) menggunakan konsep energi fisika yang berbeda seperti energi potensial, energi kinetik, entropi, dan tekanan. Xiong et al. mengusulkan model energi baru untuk mendeteksi pertemuan pejalan kaki yang tidak normal dan berlari dalam video kerumunan. Model ini didasarkan pada energi potensial dan energi kinetik. Sebuah istilah yang disebut *crowd distribution index* (CDI) didefinisikan untuk mewakili dispersi, yang nantinya dapat menentukan energi kinetik. Akhirnya, aktivitas abnormal dideteksi melalui analisis ambang batas. Cui et al. mengusulkan untuk mengeksplorasi hubungan antara keadaan perilaku subjek saat ini dan tindakannya.

Fungsi potensial energi interaksi diperkenalkan untuk mewakili keadaan perilaku subjek saat ini, dan kecepatan digunakan sebagai tindakannya, dan bagaimana keadaan saat ini berubah dari waktu ke waktu dalam bentuk energi potensial. Support Vector Machines digunakan untuk menemukan kejadian abnormal. Yang dkk. mengusulkan *histogram of oriented pressure* (HOP) untuk mendeteksi anomali dalam adegan kerumunan, di mana SFM dan *local binary pattern* (LBP) diadopsi untuk menghitung tekanan. *Cross-histogram* digunakan untuk menghasilkan vektor fitur daripada menggabungkan histogram magnitudo dan histogram arah secara paralel, dan mesin vektor pendukung dan filter median diadopsi untuk mendeteksi anomali. Ren dkk. mendeteksi perilaku kerumunan abnormal menggunakan entropi perilaku. Ide kuncinya adalah untuk menganalisis perubahan *scene behavior entropy* (SBE) dari waktu ke waktu, dan melokalisasi perilaku abnormal sesuai dengan distribusi entropi perilaku piksel di ruang gambar. Eksperimen mengungkapkan bahwa *SBE frame* akan naik ketika terjadi lari, dispersi, berkumpul, atau berjalan regresif.

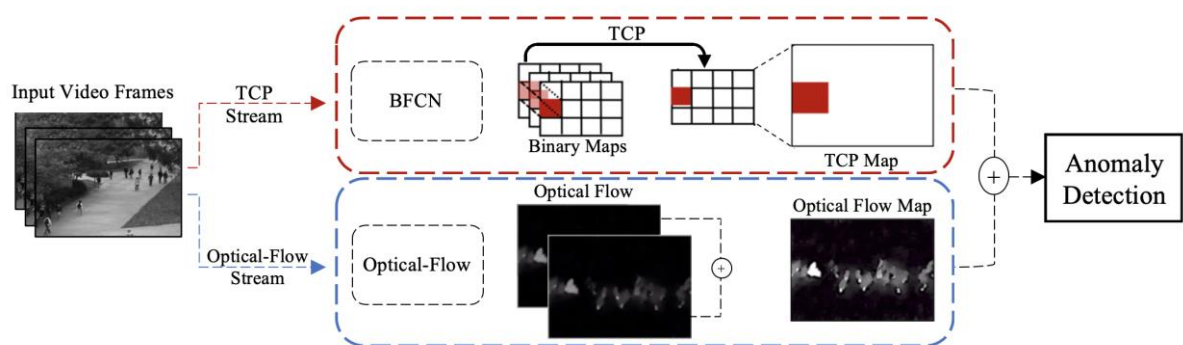
2.3.4 Substantial Derivative

Turunan substansial merupakan konsep penting dalam mekanika fluida yang menggambarkan perubahan unsur-unsur fluida berdasarkan sifat-sifat fisiknya seperti komponen temperatur, densitas, dan kecepatan dari fluida yang mengalir sepanjang lintasannya. Tidak seperti pendekatan di atas yang hanya menggunakan pola gerak temporal sebagai sumber informasi utama, pendekatan ini memiliki kemampuan besar untuk mencakup informasi spasial dan temporal perubahan gerak dalam satu kerangka. Metode yang mengeksplorasi sifat *spatiotemporal* turunan *substansial* untuk mendeteksi perilaku kekerasan dalam berbagai skenario kerumunan (Bour et al., 2019).

2.4 Representasi Gerak

Penelitian yang dilakukan oleh Javed et al. (2008) berpendapat representasi gerak pada massa bahwa pejalan kaki pada kerumunan yang normal sering menggunakan jalur yang sama saat berjalan; penelitian menggunakan fenomena ini untuk membentuk hubungan antara sifat pejalan dengan representasi gerak pada kerumunan.

Javed dkk. (2008) juga menyatakan bahwa objek yang memiliki representasi bergerak normal dari satu kamera ke kamera lain dalam video sering kali menampilkan penampakan perubahan dengan kecepatan yang tetap, jika sebaliknya maka terdapat kerumunan yang bersifat anomali.



Gambar 2.4 Representasi Gerak ((Ravanbakhsh et al., 2016)

Representasi gerakan kerumunan adalah fitur kerumunan khusus yang diekstraksi untuk tujuan menganalisis perilaku kerumunan. Metode analisis perilaku kerumunan

mengekstrak berbagai jenis representasi gerak untuk mendeteksi dan/atau mengidentifikasi perilaku kerumunan. Metode penting dan baru dalam bidang ini diselidiki di bawah ini.

Kerangka penting yang diusulkan oleh Ali dan Shah (2007) diterapkan pada kerumunan kepadatan tinggi untuk tujuan deteksi segmentasi dan ketidakstabilan aliran. Struktur Dinamika Partikel Lagrangian digunakan untuk adveksi partikel berdasarkan medan aliran yang dihasilkan oleh kerumunan yang bergerak. Kerumunan yang bergerak ditangani sebagai sistem dinamis aperiodik. Adveksi adalah proses materi bergerak sepanjang atau menjadi adveksi oleh aliran. Aliran ini dapat dimodelkan menggunakan medan kecepatan dengan menentukan kecepatan pada posisi dan waktu tertentu. Segmen aliran digunakan sebagai indikasi pola gerakan yang muncul. Direpresentasikan struktur segmentasi aliran berdasarkan sistem dinamik non-linier, dinamika fluida, dan teori turbulensi untuk menemukan segmen aliran tersebut. Lintasan yang diekstraksi dari adveksi partikel akan menyoroti fitur aliran penting yang memiliki korelasi langsung dengan objek fisik dalam sebuah adegan.

Adapun deteksi ketidakstabilan aliran, menganggap setiap perubahan segmen aliran tidak normal. Hubungan antara segmen aliran dari waktu ke waktu dibuat dan terjadinya segmen aliran baru menunjukkan abnormalitas aliran normal. Pengujian pendekatan diterapkan pada video adegan kerumunan/trek kepadatan tinggi yang diambil dari situs web rekaman stok seperti Getty-Images, Photo-Search dan Video Google. Selain itu, cuplikan video dari National Dokumenter geografis bernama '*Inside Mecca*' digunakan untuk eksperimen lebih lanjut. Meskipun hasil kuantitatif tidak didokumentasikan, hasil kualitatif untuk segmentasi aliran dan deteksi ketidakstabilan aliran dicatat saat diuji menggunakan rekaman yang disebutkan di atas.

(Wang et al., 2007) mengusulkan kerangka kerja pembelajaran tanpa pengawasan yang menggunakan ekstraksi data dari materi visual untuk memahami tindakan dalam adegan yang ramai. Model Bayesian digunakan untuk menghubungkan data visual tingkat rendah, tindakan sederhana “atomik”, dan koneksi multi-agen. Tindakan atom dimodelkan menggunakan data visual tingkat rendah yang diekstraksi. Selanjutnya, koneksi multi-agen dimodelkan menggunakan aksi atom. Kerangka kerja ini tidak

melacak manusia tetapi menggunakan gerakan lokal untuk fitur. Performa sistem menurun karena partisi rekaman yang diperpanjang menjadi klip yang lebih pendek dan lebih mudah dikelola. Penelitian ini tidak mencatat metrik evaluasi kuantitatif apa pun, tetapi pengujian diterapkan pada kumpulan data adegan *trac* berdurasi 1,5 jam, dan hasilnya didokumentasikan sebagai angka.

Cheriyadat dan Radke (2008) menjelaskan metode untuk mengidentifikasi gerakan dominan dalam kerumunan. Aliran optik digunakan pada algoritma untuk melacak fitur objek tingkat rendah. Detektor digunakan oleh Shi-Tomasi-Kanade (Shi dan Tomasi, 1994) dan Rosten-Drummond (Tomasi dan Detection, 1991) untuk mengekstrak fitur tingkat rendah. Kemudian, implementasi yang ditingkatkan dari algoritma aliran optik Kanade-Lucas-Tomasi (Lucas dan Kanade, 1981) digunakan untuk melacak fitur-fitur ini. Akibatnya, trek titik fitur diekstraksi, tetapi panjangnya dan dianggap tidak dapat diandalkan yang mengarah pada kebutuhan untuk metode pengelompokan. Urutan umum terpanjang digunakan sebagai metrik jarak untuk membandingkan trek titik fitur. Lintasan yang memiliki arah yang sama dan dianggap berdekatan secara spasial dikelompokkan menjadi satu dengan hasil gerakan dominan yang halus. Metrik kuantitatif tidak diterapkan, tetapi eksperimen diterapkan pada empat urutan rekaman video yang berbeda: Urutan platform, Urutan kampus, urutan Eskalator, dan urutan Bandara yang diambil dari dataset benchmark PETS 2007 (Ferryman dan Tweed, 2007). Dalam format video, dokumen, titik fitur, titik trek, dan gerakan dominan untuk setiap urutan video dalam penelitiannya (Cheriyadat dan Radke, 2008).

Curl and Divergence of motion Trajectories descriptor (CDT) untuk analisis perilaku disajikan oleh Wu et al. (2017). Deskriptor ditemukan menggunakan *curl* dan *divergence* sepanjang jalur tangensial dan radial yang menunjukkan gerakan lintasan dan bidang konjugasi masing-masing. Penggunaan CDT untuk menggambarkan urutan gerak kolektif, metode ini digunakan untuk mempertimbangkan karakteristik lokal dan struktur global dari medan vektor gerak. Untuk mengklasifikasikan perilaku orang banyak, diawali dengan mengekstrak bidang sub-gerak dari bidang vektor gerak menggunakan adveksi partikel.

Metode ini dapat digunakan untuk pola gerakan yang tumpang tindih dan dapat

membedakan, kemudian menggunakan penggabungan maks-min dan gerakan padat untuk mengutip vektor fitur kohesif dari data gerakan yang kaya. Untuk eksperimen, deskriptor CDT terbatas pada lima perilaku yang mengidentifikasi; jalur, lengkungan searah jarum jam, kemacetan dan kepala air mancur. Metode yang diusulkan dibandingkan dengan empat metode lainnya dan diuji pada kumpulan data UCF (Idrees et al., 2013) dan CUHK (Shao et al., 2014, 2017). Disajikan secara menyeluruh adalah hasil dari berbagai pengaturan pengujian. Hasil kuantitatif seperti ROC, tingkat positif-benar dan positif-palsu, dan grafik eksperimental menunjukkan hasil yang menguntungkan dari teknik ini.

2.5 Konsep dan Jenis Anomali

Kata anomali berasal dari kata Yunani “*anomolia*”, yang menunjukkan pola yang tidak teratur atau tidak rata. Dalam komunitas data mining dan statistik, anomali juga dikenal dengan istilah *abnormal*, *deviants*, dan *outliers*. Hal ini dapat didefinisikan sebagai pola yang tidak biasa yang tidak sesuai dengan perilaku atau tempat yang diharapkan. Untuk data tekstual, anomali dapat dideteksi dengan memplot data; titik data yang lebih besar atau lebih kecil dari data lain disebut sebagai anomali atau outlier yang tidak konsisten dengan data lain. Di sisi lain, untuk data video atau gambar, anomali dapat diidentifikasi dengan menganalisis dan memahami perilaku atau pola objek di area tersebut; objek yang berperilaku berbeda dari pola yang diharapkan adalah objek anomali.

Deteksi anomali mengacu pada deteksi dan lokalisasi pola atau perilaku apa pun yang tidak sesuai dengan harapan. Seseorang mungkin menunjukkan perilaku abnormal di depan umum sendiri atau sebagai bagian dari kelompok. Ribuan jemaah haji berkumpul serentak di area haji yang merupakan ilustrasi tempat padat penduduk. Berbagai aktivitas abnormal dapat terjadi, seperti kemacetan, berjalan melawan jalur pejalan kaki, berdiri di tempat yang tidak diperuntukkan bagi berdiri dan menghalangi pergerakan jemaah haji, duduk di tempat selain yang diperuntukkan untuk duduk, dan berlari dan berebut di pintu gerbang dan kereta api dan stasiun. Apalagi kekerasan merupakan representasi dari perilaku abnormal yaitu kekuatan fisik yang mempengaruhi lingkungan dan orang-orang di sekitarnya. Hal ini dapat dideteksi melalui sistem

pengawasan cerdas yang membantu untuk mengontrol keamanan lingkungan dan membatasi pelanggaran dan kecelakaan lainnya.

Pada dasarnya, istilah anomali mengacu pada segala sesuatu yang tidak biasa, tidak teratur, atau tidak seperti biasanya dan berbeda dari peristiwa normal. Sebuah anomali dapat dipecah menjadi tiga jenis (Aldayri & Albattah, 2022): *point anomalies*, *extended anomalies*, dan *collective anomalies*.

- ***Point anomalies***: Terjadi ketika satu entitas individu telah mengamati perilaku tidak teratur dari sisa data.
- ***Extended Anomalies***: Sebuah contoh yang dapat dianggap anomali dalam beberapa keadaan tertentu disebut anomali kontekstual yang juga disebut anomali kondisional. Ketika suatu nilai data memiliki perilaku yang tidak teratur dibandingkan dengan data lainnya dalam konteks tertentu tetapi tidak dalam semua keadaan. Jika ada sesuatu yang anomali dalam beberapa konteks tertentu, maka itu dapat diklasifikasikan sebagai anomali kontekstual.
- ***Collective Anomalies***: Mewakili kumpulan entitas terkait sebagai kelompok berkorelasi yang telah mengamati anomali terhadap data yang tersisa disebut anomali kolektif.

2.6 Deteksi Anomali Kerumunan

Memantau keamanan publik sering kali melibatkan deteksi perilaku abnormal dalam video pengawasan orang banyak. Deteksi anomali dalam adegan ramai mengacu pada deteksi ketidakteraturan, kelainan, atau menemukan pola yang tidak selaras dengan perilaku normal dalam gambar atau data urutan video. Deteksi anomali digambarkan sebagai pola pengidentifikasian yang sangat berbeda dari yang lain. Deteksi anomali mengacu pada identifikasi gerakan kerumunan, di mana perilaku abnormal di lokasi ramai biasanya muncul sebagai keributan orang banyak.

Deteksi anomali bertujuan untuk mengidentifikasi dan mengkategorikan anomali pada dataset yang diberikan. Deteksi anomali dapat diklasifikasikan menjadi tiga kategori: terawasi, tidak terawasi, dan semi terawasi. Kumpulan data yang memiliki data

dan label dapat digunakan untuk deteksi anomali terawasi. Label menentukan jenis peristiwa, apakah itu "normal" atau "tidak normal". Kumpulan data tidak berlabel digunakan untuk metode deteksi anomali tanpa pengawasan. Metode tanpa pengawasan menganggap bahwa sebagian besar peristiwa dalam kumpulan data adalah normal dan sebaliknya dianggap anomali. Dalam situasi di mana kumpulan data belum sepenuhnya berlabel atau tidak berlabel yang berarti bahwa beberapa data diberi label dan beberapa tidak berlabel maka teknik deteksi anomali semi-diawasi digunakan. Prosedur deteksi anomali menilai pola dalam data normal yang tersedia, mengilustrasikannya, dan kemudian memodelkannya untuk mengungkap pola baru dalam data baru. Sistem pengawasan, deteksi intrusi, deteksi penipuan, dan pemantauan kesehatan hanyalah beberapa domain di mana deteksi anomali memiliki aplikasi.

Anomali dalam kerumunan adalah pola atipikal yang tidak sesuai dengan normalitas yang dipelajari (Singh et al., 2020). Deteksi anomali juga biasanya dianggap sebagai masalah deteksi *outlier* di mana kelainan akan menjadi peristiwa probabilitas rendah mengenai model perilaku normal yang dipelajari (Mahadevan et al., 2010). Deteksi anomali kerumunan diterapkan untuk mendeteksi adegan anomali atau non-tipikal dalam rekaman kerumunan. Aplikasi ini sangat penting dalam pencegahan bencana kerumunan di bidang-bidang seperti pengawasan video. Ada dua metode utama yang digunakan dalam deteksi anomali kerumunan, yaitu metode *handcrafted* dan metode *machine learning*:

- ***Handcrafted methods:***

Metode ini memerlukan ekstraksi fitur gerak dan/atau tampilan seperti aliran optik dan tracklet. Secara tradisional, untuk merekonstruksi adegan normal dengan kesalahan rekonstruksi kecil menggunakan kamus yang diajarkan. Fitur yang cocok dengan adegan anomali akan memiliki kesalahan rekonstruksi yang besar. Masalah dengan metode ini adalah bahwa metode ini memerlukan penggabungan beberapa pengetahuan apriori selama pelatihan. Penggabungan ini bisa menjadi rumit dalam kasus adegan pengawasan video yang kompleks.

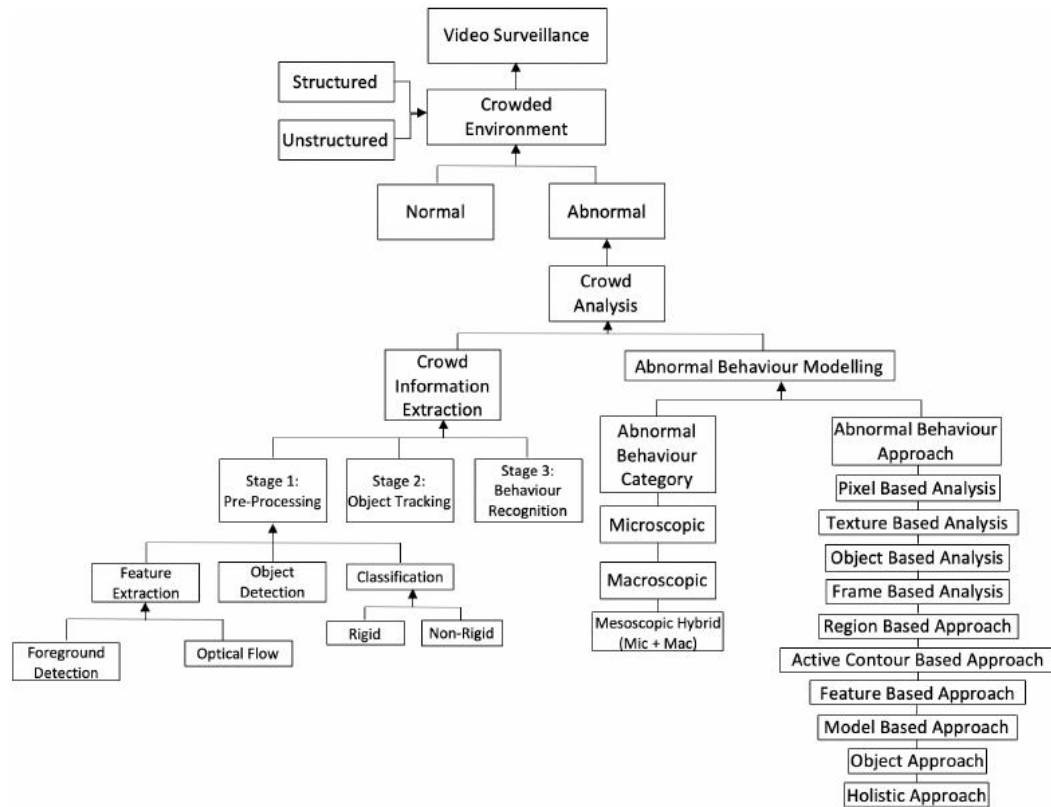
- **Machine Learning:**

Beberapa metode *supervised* dan *unsupervised* adalah *convolutional neural network* (Sabokrou et al., 2018), *convolutional auto-encoder* (Fan et al., 2020), *stacked denoising auto-encoder* (Vu et al., 2019), *spatio-temporal auto-encoder* (Fradi et al., 2017), dan *long short-term memory* (Majumder et al., 2018). Metode tanpa pengawasan cenderung melakukan lebih baik daripada yang diawasi karena kelangkaan anotasi dan ukuran data pelatihan yang kecil. Metode ini biasanya menggabungkan fitur tingkat rendah seperti garis, kurva dan tepi, atau fitur tingkat tinggi seperti objek dan bentuk. Masalah dengan hanya menggunakan deteksi fitur tingkat rendah adalah:

- Biasanya menyebabkan daerah terfragmentasi dan terputus; dan
- Peka terhadap *noise* dan sangat dipengaruhi oleh perubahan lingkungan.

Metode *deep machine learning* yang menggabungkan *generative adversarial networks* (GAN) dalam kerangka yang digunakan telah menyajikan hasil akurasi yang melampaui *model deep learning* lainnya. *Convolutional generative adversarial networks* (CGAN) dilatih untuk menerjemahkan antara sepasang *frame* dan fitur *optical flow* yang sesuai dengan menggunakan terjemahan gambar-ke-gambar (Isola et al., 2017). CGAN kemudian digunakan untuk menghasilkan *frame* atau *optical flow* berdasarkan input. CGAN sebelumnya telah digabungkan dengan CNN, *autoencoder*, dan *autoencoder denoising* untuk deteksi anomali kerumunan.

Ringkasan keseluruhan secara umum untuk metode *computer vision* pada analisis perilaku kerumunan dan deteksi anomali kerumunan dalam pemantauan video diilustrasikan pada Gambar 2.5.



Gambar 2.5 Kerangka Kerja Deteksi Perilaku Abnormal Kerumunan dalam Pemantauan Video (Sjarif et al., 2012)

2.6.1 Kriteria Deteksi Anomali

Ada dua kriteria standar yang digunakan untuk mempertimbangkan anomali (perilaku apa pun yang keluar dari kenormalan yang ditetapkan) dalam sebuah gambar yaitu berdasarkan *frame-level* dan *pixel-level* deteksi anomali (Li et al., 2014). Kriteria ketiga adalah *dual-pixel level* (Sabokrou et al., 2015), yang juga mempertimbangkan kendala *pixel-level*. Batasan ini digunakan untuk menghitung *true-positive rate* (TPR) dan *false-positive rate* (FPR). Berikut dijelaskan masing-masing kendala:

- **Frame-level detection:** Kriteria deteksi ini tidak mempertimbangkan lokalisasi anomali dalam *frame*. Sebaliknya, jika ada piksel dalam *frame* yang terdeteksi tidak normal, seluruh *frame* dianggap tidak normal. Jika *ground truth data* bertepatan dengan deteksi *frame* maka *true-positive* dihitung ke dalam TPR.

Untuk menghitung kurva ROC. Metode deteksi ini diterapkan beberapa kali dengan menggunakan ambang batas yang berbeda (Mahadevan et al., 2010; Li et al., 2014; Ravanbakhsh et al., 2017)

- ***Pixel-level detection***: Kriteria deteksi ini mempertimbangkan pentingnya lokalisasi abnormalitas dalam bingkai. Persyaratannya adalah; setidaknya 40% dari *ground truth pixel* anomali ditutupi oleh piksel yang terdeteksi. Kelemahan deteksi ini adalah “Lucky Guess” jika bagian dari wilayah yang terdeteksi tumpang tindih dengan data *ground-truth* maka wilayah yang terdeteksi salah tidak dipertimbangkan. Kriteria tambahan (*dual pixel-level*), digunakan untuk menyelesaikan masalah ini. (Mahadevan et al., 2010; Li et al., 2014; Ravanbakhsh et al., 2017)
- ***Dual pixel-level detection***: Kriteria pendeteksian baru ini menerapkan batasan deteksi tingkat piksel dan mengharuskan setidaknya $\beta\%$ piksel yang terdeteksi dicakup oleh *anomaly ground truth pixels*. (Sabokrou et al., 2015; Vu et al., 2019)

2.6.2 Deteksi anomali menggunakan metode *Handcrafted*

Andrade dkk. (2006) memodelkan perilaku normal kerumunan menggunakan metode ekstraksi fitur tanpa pengawasan. Metode ekstraksi cocok dengan HMM (*Hidden Markov Model*) untuk semua fragmen footage kemudian pengelompokan spektral diterapkan menggunakan matriks kesamaan yang dihitung. Menggunakan fragmen berkerumun dapat ditemukan jumlah model yang sesuai untuk mengkarakterisasi pola gerak normal dengan melatih satu set HMM baru. Rekaman baru dibandingkan dengan model perilaku normal menggunakan ambang deteksi untuk mendeteksi perilaku kerumunan yang tidak normal. Dua set data simulasi digunakan untuk eksperimen, satu dengan aliran massa normal dan yang lainnya dengan rekaman jalan keluar yang padat.

Social Force Model (SFM) digunakan oleh Mehran et al. (2009) untuk deteksi dan lokalisasi perilaku orang banyak yang tidak normal. Untuk mencapai hal tersebut maka digunakan adveksi partikel yang didasarkan pada *space-time average* dari *optical flow*. Metode ini menganggap partikel yang bergerak sesuai dengan individu. SFM digunakan untuk memperkirakan kekuatan interaksi. Pendekatan *bag of words* menggunakan *vector*

field, pemetaan kekuatan interaksi ke *frame* gambar untuk memodelkan perilaku "normal" orang banyak. Kumpulan data UMN (University of Minnesota, 2006) dan kumpulan data web dari cuplikan yang dikumpulkan dari Getty Images, dan ThoughtEquity.com digunakan dalam eksperimen. Hasil dari pengujian dataset UMN dengan area 0,96 di bawah ROC. Hal ini merupakan peningkatan dibandingkan dengan *pure optical flow* untuk mendeteksi metode perilaku kerumunan yang tidak normal yang menunjukkan hasil area 0,84 di bawah ROC.

Berdasarkan *social force model* yang khas, Yang et al. (2012) menyajikan *local pressure model* yang mempertimbangkan karakteristik lokal kerumunan. Metode ini dapat mendeteksi anomali dalam kerumunan menggunakan kecepatan lokal dan karakteristik kepadatan lokal. Metode yang digunakan, dimulai dengan penempatan grid partikel untuk menghitung karakteristik lokal secara efisien. *Pressure model* digunakan untuk mengekstrak *local pressure* menggunakan karakteristik ini. Akibatnya, vektor fitur diekstraksi untuk frame footage dengan pemanfaatan *Histogram of Oriented Pressure* (HOP). Untuk deteksi kelainan, *Support Vector Machine* (SVM) digunakan untuk klasifikasi, dan filter median diimplementasikan pada hasil klasifikasi untuk perbaikan lebih lanjut. Filter median adalah metode penyaringan digital non-linear yang biasanya digunakan untuk menghilangkan *noise* dari sinyal atau gambar. Algoritma biasanya berjalan melalui gambar dan mengganti setiap entri dengan median dari entri tetangga. Eksperimen diterapkan pada dataset UMN (University of Minnesota, 2006), dan nilai area under curve (AUC) sebesar 0,9784 tercatat sebagai nilai yang lebih baik dibandingkan dengan metode SFM (Mehran et al., 2009).

El-Etriby dkk. (2017) menguji kerangka kerja inovatif yang memanfaatkan model diskriminatif seperti *Conditional Random Field* (CRFs), *Hidden Conditional Random Field* (HCRFs) dan *Latent dynamic Conditional Random Fields* (LDCRFs) untuk mendeteksi perilaku kerumunan. Menginisialisasi metode dengan menerapkan segmentasi bingkai untuk mengekstrak *region of interest* (ROI). Untuk mengekstrak bidang aliran, pemangkasan aliran optik diterapkan berdasarkan ambang batas yang telah ditentukan dari panjang Euclidean dari vektornya. Kombinasi *Moving Dierence Image* (MDI), *Gaussian Mixture Model* (GMM), *K-means clustering*, dan *Adaptive Median*

digunakan untuk mencapai hal tersebut. Pendakian gradien digunakan pada model diskriminatif yang sebelumnya dicatat dengan ukuran jendela bervariasi dari 0-8 untuk memodelkan urutan pola blok aliran. Anomali terdeteksi dari rasio statistik blok aliran anomali dan total blok aliran. Eksperimen metode diterapkan pada dataset PETS2009 (Ferryman dan Shahrokni, 2009), dan hasil rasio pengenalan adalah 96,2%, 97,1%, 98,1% untuk CRF, HCRF, dan LDCRF.

2.6.3 Deteksi Anomali Menggunakan *Neural Networks*

Mahadevan dkk. (2010) memanfaatkan ekstraksi fitur video lokal untuk mendeteksi anomali dalam kerumunan. Dengan menggunakan ekstraksi fitur global seperti *Markov Random Field* (MRF) atau *Latent Dirichlet Allocation* (LDA), penelitian ini menggunakan tiga properti lokal untuk representasi video. Yang pertama adalah dinamika dan tampilan pola kerumunan menggunakan campuran *dynamic textures* (DTs), yang kedua adalah kelainan temporal yang diekstraksi menggunakan *Gaussian Mixture Model* (GMM). Yang terakhir adalah kelainan spasial yang diekstraksi menggunakan metode *saliency detection*. Representasi ini digunakan untuk memodelkan perilaku normal orang banyak, outlier yang terdeteksi di bawah model ini dianggap sebagai kelainan. Penelitian telah menunjukkan bahwa tekstur dinamis lebih pas daripada *optical flow* dalam proses deteksi anomali kerumunan. Metode ini secara komputasi berat.

Majumder dkk. (2018) menggunakan *recurrent neural network* (RNN) untuk mengekstraksi anomali dari gerakan. Kerangka kerja ini menggunakan dua LSTM (*long short-term memory*) yang ditumpuk sebagai encoder-decoder untuk mendefinisikan perilaku normal. Digambarkan anomali sebagai setiap gerakan yang tidak mengikuti pola normal. Seperti gerakan tiba-tiba dan gerakan yang lebih lambat, lebih cepat, atau dalam arah yang berbeda dengan pemandangan yang diamati. Algoritma Farnebäck (2003) diterapkan untuk mengekstrak besaran aliran optik padat untuk setiap adegan. Dalam proses pelatihan, tiga jaringan LSTM dilatih pada skala yang berbeda. Urutan dibentuk dari penumpukan aliran optik dan diumpunkan ke RNN yang ditumpuk untuk memprediksi *future flow*. Beberapa kumpulan data digunakan untuk pengujian dan hasil kualitatifnya dibandingkan dengan algoritma pendeteksian anomali lainnya. Hasil

kuantitatif didokumentasikan dari pengujian pada dataset UMN (University of Minnesota, 2006) dan menghasilkan nilai AUC 99%.

Serupa dengan Majumder et al. (2018) metode yang diterapkan oleh Qiu et al. (2018) menggunakan *Convolutional Neural Network* dengan menambahkan LSTM untuk mendeteksi objek anomali. Kerangka kerja ini menggabungkan teknik berbasis lintasan dan gerak dengan mengekstraksi objek menggunakan CNN dan memasukkan data tersebut ke LSTM. CNN yang diterapkan didasarkan pada detektor *You Only Look Once* (YOLO) (Redmon dan Farhadi, 2018) yang menampilkan kotak pembatas objek yang terdeteksi. Karena representasi objek sederhana, metode ini secara komputasi murah dan cepat. Model LSTM yang diterapkan tidak hanya mempertimbangkan data spasial dan/atau temporal dari setiap objek tetapi juga mencakup data korelasi tentang tetangga objek. Posisi, kecepatan, percepatan, dan arah adalah semua karakteristik yang digunakan untuk menafsirkan kenormalan menggunakan ambang batas. Metode ekstraksi objek CNN dilatih di ImageNet (Deng et al., 2009), dan LSTM menggunakan dataset OTB-30 (Wu et al., 2013) untuk pelatihan/pengujian. Plot keberhasilan komparatif menunjukkan kinerja yang lebih baik daripada teknik pelacakan standar. Hasil eksperimen didokumentasikan sebagai *one pass evaluation* (OPE) sebesar 0,467, *temporal robustness evaluation* (TRE) sebesar 0,559 dan *spatial robustness evaluation* (SRE) sebesar 0,544.

Fan dkk. (2020) menggunakan metode *partially semi-supervised deep learning* untuk mendeteksi anomali menggunakan sampel normal. Aliran dinamis, penggabungan beberapa bingkai aliran optik sekuensial diproduksi menggunakan Ranking SVM untuk mempertimbangkan data temporal jangka panjang. Aliran dinamis yang dihasilkan dimasukkan ke dalam dua aliran *Gaussian Mixture Fully Convolutional Variational Auto-encoder* (GMFC-VAE). Gambar RGB dari data sampel normal juga dimasukkan ke dalam GMFC-VAE. GMFC-VAE menggunakan representasi fitur: gambar RGB (isyarat penampilan) dan aliran dinamis (isyarat gerak) untuk mendeteksi anomali. Encoder-decoder didasarkan pada *Fully Convolutional Network* (FCN) yang tidak menyertakan lapisan yang terhubung penuh. Lokasi spasial masing-masing dari gambar input dan peta fitur output disimpan. Skor anomali diberikan berdasarkan metode energi sampel untuk menguji sampel. Kumpulan data UCSD (Chan et al., 2008) dan Avenue (Lu et al., 2013)

digunakan untuk eksperimen, dan evaluasi didasarkan pada kriteria tingkat bingkai dan tingkat piksel. *Area Under Curve* (AUC), *Equal Error Rate* (EER), *True Positive Rate* (TPR), dan *False Positive Rate* (FPR) semuanya digunakan untuk mengevaluasi sistem. Mengenai deteksi tingkat bingkai, sistem yang diusulkan mengungguli sistem seperti (Mehran et al., 2009).

2.6.4 Deteksi Anomali Menggunakan *Generative Adversarial Networks*

Generative Adversarial Networks (GAN) biasanya digunakan untuk menghasilkan data palsu yang dapat ditafsirkan sebagai data nyata, kerangka kerja telah digunakan dalam aplikasi seperti klasifikasi gambar, pembuatan gambar, dan klasifikasi gambar. Baru-baru ini kerangka kerja telah digunakan untuk deteksi anomali kerumunan.

Ravanbakhsh dkk. (2017) telah memanfaatkan kerangka kerja untuk tujuan deteksi anomaly. Jaringan generatif digunakan untuk memodelkan data normal. Dengan kurangnya ketersediaan dataset abnormal, generator memiliki keuntungan dilatih hanya pada data normal. Data abnormal kemudian dideteksi dengan mengukur jarak antara data yang dihasilkan dan yang dipelajari. Dengan menggunakan kerangka yang disajikan oleh Isola et al. (2017) untuk mempelajari translasi antara aliran maka akan dihitung menggunakan (Brox et al., 2004), dan bingkai input yang sesuai. Ketika pengujian jaringan tidak akan dapat menghasilkan adegan abnormal karena dilatih pada rekaman normal dan perbedaan lokal digunakan untuk mendeteksi anomali. Dalam pengaturan eksperimental, pengujian diterapkan pada kumpulan data UCSD dan UMN. Hasil kuantitatif didokumentasikan sehubungan dengan deteksi/lokalisasi abnormalitas *frame-level* dan *pixel-level*. Dibandingkan dengan metode yang diusulkan oleh Ravanbakhsh et al. (2016) dan Xu dkk. (2017), metode ini telah menunjukkan nilai AUC dan EER yang lebih baik. Kerugian dari arsitektur ini adalah ketergantungan pada CNN, yang telah dilatih sebelumnya pada ImageNet, untuk mengumpulkan data semantik dalam jumlah yang memadai.

Ravanbakhsh dkk. (2019) menyajikan kelanjutan dari pekerjaan yang telah dibahas sebelumnya. Tidak seperti Ravanbakhsh et al. (2017), jaringan diskriminatif digunakan untuk mendeteksi anomali selama pengujian, sedangkan pekerjaan

sebelumnya menggunakan kesalahan rekonstruksi jaringan generatif untuk mendeteksi anomali. Pengaturan pengujian yang sama diterapkan menggunakan kumpulan data yang sama. Hasil AUC yang dihasilkan saat menguji arsitektur ini pada dataset UMN adalah 0,99. Hasil ini sangat mirip dengan hasil 0,99 dari pekerjaan sebelumnya pada dataset yang sama. Sementara pekerjaan sebelumnya bergantung pada CNN yang telah dilatih sebelumnya untuk data semantik dan strategi fusi untuk mempertimbangkan kesalahan rekonstruksi tingkat piksel dan berbasis semantik, pekerjaan terakhir tampaknya tidak lebih cepat sehubungan dengan waktu pelatihan. Diklaim bahwa waktu pengujian berkurang karena penggunaan diskriminator permusuhan untuk deteksi.

Pendekatan baru untuk deteksi anomali disajikan oleh Liu et al. (2018) di mana penelitian tersebut menggunakan *future frame prediction* untuk tujuan mendeteksi perilaku anomali. Ide dasar dari pendekatan ini adalah untuk memanfaatkan penyimpangan antara frame video kebenaran dasar dan frame masa depan yang diprediksi sesuai untuk menemukan adegan yang tidak teratur. Jaringan menghasilkan bingkai prediksi dari U-Net dan memanfaatkan kendala yang berbeda untuk mencapai prediksi bingkai kualitas yang lebih tinggi. Beberapa kendala yang digunakan adalah *adversarial training loss* (Isola et al., 2017) untuk melatih model dengan lebih baik dalam menghasilkan kualitas gambar yang lebih baik. Kendala kedua yang digunakan adalah kendala spasial berdasarkan intensitas dan *gradient loss*. Pada akhirnya *optical flow loss* yang dihitung menggunakan *FlowNet* jaringan yang telah dilatih sebelumnya (Dosovitskiy et al., 2015) digunakan sebagai batasan gerak. Komplikasi dari metode ini adalah *FlowNet* dianggap mahal untuk ekstraksi aliran optik dan jaringan tingkat positif palsu. Jaringan dilatih dan diuji pada beberapa kumpulan data: Avenue, UCSD, dan ShanghaiTech.

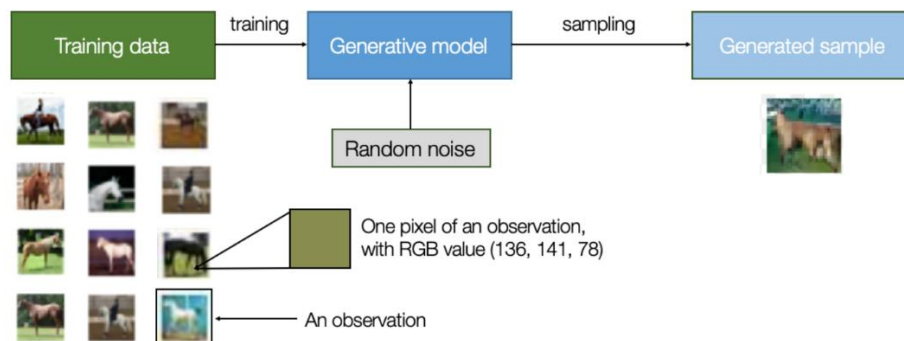
Vu et al. (2019) menghadirkan MLAD (*MultiLevel Anomaly Detector*), sebuah jaringan berdasarkan sistem deteksi anomali oleh Ravanbakhsh et al. (2017) dengan tambahan *Denoising Autoencoder* (DAEs). DAE adalah jaringan saraf yang dilatih untuk merekonstruksi data dari data input yang sengaja dirusak (noise diperkenalkan). Sistem representasi bertingkat menggunakan fitur tingkat rendah dan tingkat abstrak untuk mendeteksi anomali. Awalnya, jaringan dilatih dengan menghitung bingkai aliran optik

yang sesuai dengan bingkai input. Dua DAE dilatih secara terpisah pada frame video input dan aliran optik terhitung yang cocok. DAE terlatih kemudian mengekstrak fitur tingkat tinggi untuk input dan bingkai aliran optik. Fitur yang dihasilkan (level tinggi dan gerakan) dimasukkan ke dalam *Conditional Generative Adversarial Networks* (CGAN) (Isola et al., 2017) untuk melatih jaringan. Untuk pengujian, aliran optik dihitung, fitur tingkat tinggi dihasilkan menggunakan DAE yang telah dilatih sebelumnya dan CGAN yang terlatih menghasilkan berbagai peta kesalahan. Peta deteksi biner disimpulkan dari peta kesalahan dan disusun untuk menghasilkan hasil deteksi.

Penelitian yang lebih baru dilakukan oleh Pourreza et al. (2021a) mempertimbangkan masalah deteksi ketidakteraturan sebagai metode klasifikasi biner. Dengan menggunakan GAN Wasserstein dilakukan proses pelatihan jaringan generatif dengan cara yang khas di mana generator dilatih pada sampel normal (perilaku normal). Namun, saat melatih generator pada data normal, data normal yang gagal dihasilkan oleh generator dianggap sebagai data abnormal. Data abnormal dan data normal yang dihasilkan kemudian digunakan untuk melatih pengklasifikasi biner untuk mendeteksi sampel tidak beraturan. Metode ini digunakan untuk mendeteksi anomali video dan gambar *outlier*. Proses pengujian kerangka kerja ini pada UCSD Ped-2 untuk deteksi anomali video tingkat bingkai dan menghasilkan hasil EER sebesar 11%.

2.7 Generative Modeling

Pemodelan generatif adalah bentuk pembelajaran mesin tanpa pengawasan dimana model belajar untuk menemukan pola dalam data input. Dengan menggunakan pengetahuan ini, model dapat menghasilkan data baru sendiri, yang dapat dihubungkan dengan dataset pelatihan asli (Karras et al, 2018). Model tanpa pengawasan yang merangkum distribusi variabel input mungkin dapat digunakan untuk membuat atau menghasilkan contoh baru dalam distribusi input. jenis model ini disebut sebagai model generatif.



Gambar 2.6 Contoh Proses Pemodelan Generatif (Karras et al., 2018)

Misalkan terdapat dataset yang berisi gambar kuda. Kemudian akan dibangun model yang dapat menghasilkan citra baru kuda yang belum pernah ada tetapi masih terlihat nyata karena model tersebut telah mempelajari aturan umum yang mengatur penampilan kuda. Hal ini adalah jenis masalah yang dapat diselesaikan dengan menggunakan pemodelan generatif. Ringkasan dari proses pemodelan generatif yang khas ditunjukkan pada Gambar 2.6.

Langkah pertama yaitu memerlukan kumpulan data yang terdiri dari banyak contoh entitas yang coba dibuat. Hal ini dikenal sebagai data pelatihan, dan salah satu titik data tersebut disebut observasi. Setiap pengamatan terdiri dari banyak fitur—untuk masalah pembuatan citra, fitur biasanya berupa nilai piksel individual. Tujuannya adalah untuk membangun model yang dapat menghasilkan set fitur baru yang terlihat seolah-olah telah dibuat menggunakan aturan yang sama seperti data asli. Secara konseptual, untuk pembuatan gambar ini adalah tugas yang sangat sulit, mengingat banyaknya cara nilai piksel individual dapat ditetapkan dan jumlah pengaturan yang relatif kecil yang membentuk gambar entitas yang dicoba untuk disimulasikan.

Model generatif juga harus probabilistik daripada deterministik. Jika model yang dikerjakan hanyalah perhitungan tetap, seperti mengambil nilai rata-rata setiap piksel dalam dataset, itu tidak generatif karena model menghasilkan output yang sama setiap saat. Model harus menyertakan elemen stokastik (acak) yang mempengaruhi sampel individu yang dihasilkan oleh model.

Dapat dibayangkan bahwa ada beberapa distribusi probabilistik yang tidak diketahui yang menjelaskan mengapa beberapa gambar mungkin ditemukan dalam

dataset pelatihan dan gambar lainnya tidak. Tugas dari model generative adalah untuk membangun model yang meniru distribusi ini sedekat mungkin dan kemudian mengambil sampel darinya untuk menghasilkan pengamatan baru yang berbeda yang terlihat seolah-olah dapat dimasukkan dalam set pelatihan asli.

Salah satu contoh dari model generatif adalah Naive Bayes yang merupakan contoh model generatif yang lebih sering digunakan sebagai model diskriminatif. Misalnya, Naive Bayes bekerja dengan meringkas distribusi probabilitas setiap variabel input dan kelas output. Ketika prediksi dibuat, probabilitas untuk setiap hasil yang mungkin dihitung untuk setiap variabel, probabilitas independen digabungkan, dan hasil yang paling mungkin diprediksi. Digunakan secara terbalik, distribusi probabilitas untuk setiap variabel dapat dijadikan sampel untuk menghasilkan nilai fitur baru yang masuk akal (independen). Contoh lain dari model generatif termasuk Alokasi Dirichlet Laten, atau LDA, dan Model Campuran Gaussian, atau GMM.

Metode *deep learning* dapat digunakan sebagai model generatif. Dua contoh populer termasuk *Restricted Boltzmann Machine* (RBM) dan *Deep Belief Network* (DBN). Dua contoh modern algoritma pemodelan generatif pembelajaran mendalam termasuk *Variational Autoencoder* (VAE) dan *Generative Adversarial Network* (GAN).

2.8 Machine learning

Machine learning dilakukan melalui 2 fase, yaitu fase training dan fase application. Fasetraining adalah proses pemodelan dari algoritma yang digunakan akan dipelajari oleh sistem melalui training data, sedangkan fase application adalah proses pemodelan yang telah dipelajari sistem melalui fase training akan digunakan untuk menghasilkan sebuah keputusan tertentu, dengan menggunakan testing data.

Machine learning dapat dilakukan dengan dua cara, yaitu supervised learning dan unsupervised learning. Unsupervised learning adalah pemrosesan sample data dilakukan tanpa mewajibkan hasil akhir memiliki bentuk yang sesuai dengan bentuk tertentu, dengan menggunakan beberapa sample data sekaligus. Penerapan unsupervised learning dapat ditemukan pada proses visualisasi, atau eksplorasi data. Supervised learning adalah pemrosesan sample data x akan diproses sedemikian rupa, sehingga

menghasilkan output yang sesuai dengan hasil akhir y. Supervised learning dapat diterapkan pada proses klasifikasi (Hairani, 2018)

Machine learning merupakan serangkaian teknik yang dapat membantu dalam menangani dan memprediksi data yang sangat besar dengan cara mempresentasikan data-data tersebut dengan algoritma pembelajaran, Istilah *machine learning* pertama kali didefinisikan oleh Arthur Samuel pada tahun 1959. Menurut Arthur Samuel, *machine learning* adalah suatu bidang ilmu komputer yang memberikan kemampuan pembelajaran kepada komputer untuk mengetahui sesuatu tanpa pemrograman yang jelas.

Menurut (Mohri et.al, 2012) *machine learning* dapat didefinisikan sebagai metode komputasi berdasarkan pengalaman untuk meningkatkan performa atau membuat prediksi yang akurat. Definisi pengalaman disini ialah informasi sebelumnya yang telah tersedia dan bisa dijadikan data pembelajar. Dalam pembelajaran *machine learning*, terdapat skenario-skenario seperti :

- ***Supervised Learning***

Penggunaan skenario supervised learning, pembelajaran menggunakan masukan data pembelajaran yang telah diberi label. Setelah itu membuat prediksi dari data yang telah diberi label.

- ***Unsupervised Learning***

Penggunaan skenario unsupervised learning, pembelajaran menggunakan masukan data pembelajaran yang tidak diberi label. Setelah itu mencoba untuk mengelompokan data berdasarkan karakteristik-karakteristik yang ditemui.

- ***Reinforcement learning***

Pada skenario reinforcement learning fase pembelajaran dan tes saling dicampur. Untuk mengumpulkan informasi pembelajar secara aktif dengan berinteraksi ke lingkungan sehingga untuk mendapatkan balasan untuk setiap aksi dari pembelajar.

2.8.1 Deep Learning

Deep Learning merupakan salah satu bidang dari *machine learning* yang memanfaatkan jaringan syaraf tiruan untuk implementasi permasalahan dengan dataset yang besar. Teknik deep learning memberikan arsitektur yang sangat kuat untuk supervised learning. Dengan menambahkan lebih banyak lapisan maka model pembelajaran tersebut bisa mewakili data citra berlabel dengan lebih baik. Pada *machine learning* terdapat teknik untuk menggunakan ekstraksi fitur dari data pelatihan dan algoritma pembelajaran khusus untuk mengklasifikasi citra maupun untuk mengenali suara. Namun, metode ini masih memiliki beberapa kekurangan baik dalam hal kecepatan dan akurasi.

Aplikasi konsep jaringan syaraf tiruan yang dalam (banyak lapisan) dapat ditanggihkan pada algoritma *machine learning* yang sudah ada sehingga komputer sekarang bisa belajar dengan kecepatan, akurasi, dan skala yang besar. Prinsip ini terus berkembang hingga deep learning semakin sering digunakan pada komunitas riset dan industri untuk membantu memecahkan banyak masalah data besar seperti Computer Vision, Speech recognition, dan Natural Language Processing. Feature Engineering adalah salah satu fitur utama dari deep learning untuk mengekstrak pola yang berguna dari data yang akan memudahkan model untuk membedakan kelas. Feature Engineering juga merupakan teknik yang paling penting untuk mencapai hasil yang baik pada tugas prediksi. Namun, sulit untuk dipelajari dan dikuasai karena kumpulan data dan jenis data yang berbeda memerlukan pendekatan teknik yang berbeda juga.

Dalam deep learning, metode CNN (Convolutional Neural Network) sangatlah bagus dalam menemukan fitur yang baik pada citra ke lapisan berikutnya untuk membentuk hipotesis nonlinier yang dapat meningkatkan kekompleksitasan sebuah model. Model yang kompleks tentunya akan membutuhkan waktu pelatihan yang lama sehingga di dunia deep learning penggunaan GPU sudah sangatlah umum (Danukusumo, 2017).

2.8.2 Support Vector Machine

Support Vector Machine (SVM) dikembangkan oleh Boser, Guyon, dan Vapnik, pertama kali diperkenalkan pada tahun 1992 di *Annual Workshop on Computational Learning Theory*. Konsep dasar metode *SVM* sebenarnya merupakan gabungan atau kombinasi dari teori-teori komputasi yang telah ada pada tahun sebelumnya, seperti *marginhyperplane* (Dyda dan Hart, 1973; Cover, 1965; Vapnik, 1964), kernel diperkenalkan oleh Aronszajn tahun 1950, *Lagrange Multiplier* yang ditemukan oleh Joseph Louis Lagrange pada tahun 1766, dan demikian juga dengan konsep-konsep pendukung lain.

Menurut (Fachrurrazi, 2011) *SVM* merupakan suatu teknik untuk melakukan prediksi, baik prediksi dalam kasus regresi maupun klasifikasi. Teknik *SVM* digunakan untuk mendapatkan fungsi pemisah (*hyperplane*) yang optimal untuk memisahkan observasi yang memiliki nilai variabel target yang berbeda (William, 2011). *Hyperplane* ini dapat berupa *line* pada *two dimension* dan dapat berupa *flat plane* pada *multiple dimension*. Menurut (Nugroho, 2003), karakteristik *SVM* secara umum dirangkum sebagai berikut:

- Secara prinsip *SVM* adalah *linear classifier*
- *Pattern recognition* dilakukan dengan mentransformasikan data pada ruang input (*input space*) ke ruang yang berdimensi lebih tinggi (*feature space*), dan optimisasi dilakukan pada ruang vector yang baru tersebut. Hal ini membedakan *SVM* dari solusi *pattern recognition* pada umumnya, yang melakukan optimisasi parameter pada hasil transformasi yang berdimensi lebih rendah daripada dimensi input space.
- Menerapkan strategi *Structural Risk Minimization (SRM)*.
- Prinsip kerja *SVM* pada dasarnya hanya mampu menangani klasifikasi dua kelas, namun telah dikembangkan untuk klasifikasi lebih dari dua kelas dengan adanya *pattern recognition*.

Metode *Support Vector Machine* memiliki beberapa keuntungan yaitu:

- **Generalisasi**
Generalisasi didefinisikan sebagai kemampuan suatu metode untuk mengklasifikasi suatu pattern atau pola, yang tidak termasuk data yang digunakan

dalam fase pembelajaran metode itu.

- ***Curse of dimensionality***

Curse of dimensionality didefinisikan sebagai masalah yang dihadapi suatu metode pattern recognition dalam mengestimasi parameter dikarenakan jumlah sampel data yang relatif lebih sedikit dibandingkan dengan dimensional ruang vektor tersebut.

- ***Feasibility***

SVM dapat diimplementasikan relatif lebih mudah, karena proses penentuan *support vector* dapat dirumuskan dalam *Quadratic Programming (QP) problem* (Nugroho, 2003).

Adapun kerugian dari metode *Support Vector Machine* adalah sebagai berikut:

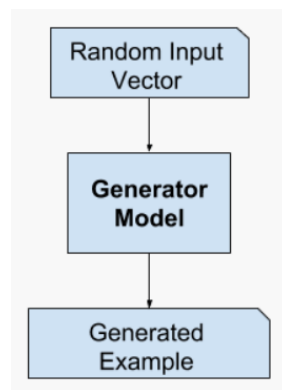
- Sulit dipakai pada problem berskala besar. Dalam hal ini dimaksudkan dengan jumlah sampel yang diolah
- *SVM* secara teoritik dikembangkan untuk problem klasifikasi dengan dua kelas. Namun dewasa ini *SVM* telah dimodifikasi agar dapat menyelesaikan masalah dengan lebih dari dua kelas (Nugroho, 2003).

2.8.3 Generative Adversarial Networks

Pada tahun 2014, Goodfellow dkk. memperkenalkan kerangka kerja untuk memperkirakan model generatif berdasarkan proses permusuhan. Kerangka kerja ini terdiri dari dua model berbasis jaringan saraf dalam: model generatif *G* dan model diskriminator *D*. Model *G* mempelajari distribusi data pelatihan dan menggunakannya untuk menghasilkan sampel baru. Model *D* menentukan apakah sampel berasal dari data pelatihan atau dihasilkan oleh model generatif.

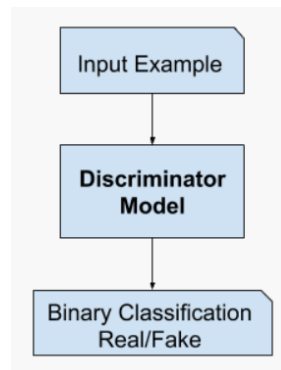
Model generator mengambil vektor acak dengan panjang tetap sebagai input dan menghasilkan sampel dalam domain. Vektor diambil secara acak dari distribusi Gaussian, dan vektor tersebut digunakan untuk menyemai proses generatif. Setelah pelatihan, titik-titik dalam ruang vektor multidimensi ini akan sesuai dengan titik-titik dalam domain masalah, membentuk representasi terkompresi dari distribusi data.

Ruang vektor ini disebut sebagai ruang laten, atau ruang vektor yang terdiri dari variabel-variabel laten. Variabel laten, atau variabel tersembunyi, adalah variabel-variabel yang penting untuk domain tetapi tidak dapat diamati secara langsung. Artinya, ruang laten menyediakan kompresi atau konsep tingkat tinggi dari data mentah yang diamati seperti distribusi data input. Dalam kasus GAN, model generator menerapkan makna pada titik-titik dalam ruang laten yang dipilih, sehingga titik-titik baru yang ditarik dari ruang laten dapat diberikan ke model generator sebagai masukan dan digunakan untuk menghasilkan contoh keluaran baru dan berbeda. Setelah pelatihan, model generator disimpan dan digunakan untuk menghasilkan sampel baru.



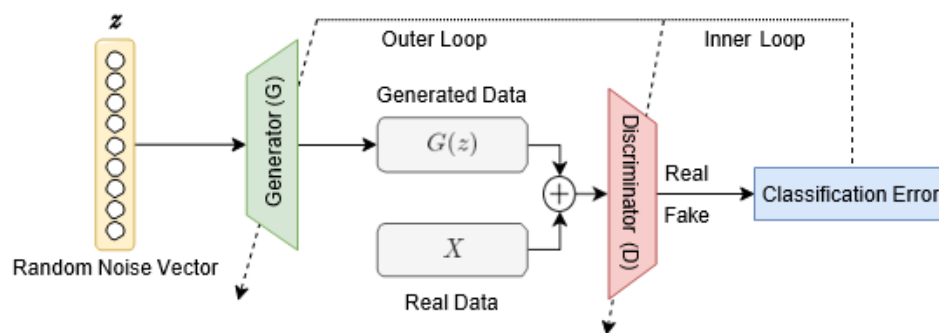
Gambar 2.7 Contoh Model Generator

Model diskriminator mengambil contoh dari domain sebagai input (nyata atau dihasilkan) dan memprediksi label kelas biner nyata atau palsu (dihasilkan). Contoh nyata berasal dari dataset pelatihan. Contoh yang dihasilkan adalah keluaran oleh model generator. Diskriminator adalah model klasifikasi yang normal (dan dipahami dengan baik). Setelah proses pelatihan, model diskriminator dibuang karena tertarik pada generator. Terkadang, generator dapat digunakan kembali karena telah belajar mengekstrak fitur secara efektif dari contoh dalam domain masalah. Beberapa atau semua lapisan ekstraksi fitur dapat digunakan dalam aplikasi pembelajaran transfer menggunakan data input yang sama atau serupa.



Gambar 2.8 Contoh Model Diskriminator

Kekuatan GAN berasal dari proses permusuhan, di mana kedua model bersaing satu sama lain untuk meningkatkan akurasi dalam tugas yang ditentukan. Diagram pada Gambar 2.9 menggambarkan blok dari *Generative Adversarial Network* (GAN) :



Gambar 2.9 Diagram blok Generative Adversarial Network (Sabuhi et al, 2021)

- *Real Data* (X), atau set data pelatihan, berisi contoh yang harus dipelajari oleh generator G , biasanya dalam bentuk batch.
- *Random Noise Vector* (z) adalah input mentah ke generator. Ini adalah vektor angka acak yang digunakan generator untuk menghasilkan contoh palsu.
- *Generator Model* (G) dilatih untuk mempelajari distribusi data masukan. Model ini menggunakan input (z) untuk menghasilkan contoh palsu ($G(z)$) yang tidak dapat dibedakan dari data sebenarnya.
- *Discriminator Model* (D) mencoba membedakan data yang dihasilkan oleh

generator dari data yang sebenarnya. Masukan untuk model ini adalah data nyata (X) dan data yang dihasilkan ($G(z)$). Output dari model ini adalah keputusan biner untuk setiap instance data, yaitu real/fake.

- *Iterative Training*: GAN dilatih menggunakan kesalahan klasifikasi diskriminator. Kesalahan digunakan untuk menyetel parameter (bobot dan bias) dari diskriminator, dan kemudian parameter generator. *Backpropagation* umumnya digunakan sebagai algoritma pelatihan. Pelatihan berulang ini terdiri dari dua *loop*:
 - *Inner loop*: di mana parameter diskriminator disetel untuk memaksimalkan akurasi klasifikasi dalam memprediksi label yang benar untuk data nyata dan data yang dihasilkan.
 - *Outer loop*: di mana parameter generator disetel untuk menghasilkan data yang memiliki peluang minimal untuk dibedakan dari data nyata oleh diskriminator.

Adversarial training dari model generator dan model diskriminator adalah masalah zero-sum game: ketika satu model menjadi lebih baik, yang lain menjadi lebih buruk dalam proporsi yang sama. Untuk semua permainan zero-sum, ada titik di mana tak satu pun dari pemain dapat memperbaiki situasi. Titik ini disebut sebagai keseimbangan Nash. Tujuan GAN adalah untuk mencapai keseimbangan ini, karena data palsu yang dihasilkan oleh model generator tidak dapat dibedakan dari data nyata oleh model diskriminator. Keluaran dari diskriminator tersebut kemudian merupakan tebakan acak apakah data masukan tersebut asli atau palsu (Sabuhi et al, 2021).

2.9 Rangkuman Hasil Penelitian Terkait

Rangkuman beberapa hasil penelitian terkait deteksi anomali pada kerumunan dapat dilihat pada tabel 3.1 sebagai berikut :

Tabel 3.1. Rangkuman Hasil Penelitian Terkait

No	Peneliti, Tahun, dan Judul	Metode	Hasil
1	Ernesto L.	<i>Multiple</i>	Penelitian ini menghasilkan teknik

No	Peneliti, Tahun, dan Judul	Metode	Hasil
	Andrade, Scott Blunsden, dan Robert B. Fisher. 2006. <i>"Modelling Crowd Scenes for Event Detection"</i>	<i>Observation Hidden Markov Model</i>	otomatis untuk mendeteksi kejadian abnormal di kerumunan menggunakan proyeksi vektor eigen di sub-ruang yang direntang oleh adegan kerumunan normal sebagai fitur input, teknik yang diusulkan menerapkan pengelompokan spektral untuk secara otomatis mengidentifikasi jumlah segmen gerak yang berbeda dalam urutan. Fitur dalam segmen gerakan berkerumun digunakan untuk melatih <i>Multiple Observation Hidden Markov Model</i> yang berbeda untuk urutan normal, kemudian dapat menyusun kumpulan model untuk video simulasi pelatihan. Eksperimen menunjukkan bahwa kumpulan model efektif dalam mendeteksi situasi darurat yang disimulasikan dengan cepat dalam kerumunan yang padat. Penyelidikan hubungan antara jumlah vektor eigen dan variasi kemungkinan model menunjukkan bahwa semua konfigurasi menunjukkan penurunan yang signifikan relatif terhadap kasus normal dan mampu mendeteksi keadaan darurat dengan benar.

No	Peneliti, Tahun, dan Judul	Metode	Hasil
2	Ramin Mehran, Alexis Oyama, dan Mubarak Shah. 2009. <i>"Abnormal Crowd Behavior Detection using Social Force Model"</i>	<i>Social Force Model</i>	Penelitian ini berhasil menggunakan <i>social force model</i> untuk mendeteksi perilaku abnormal dalam adegan kerumunan. Metode tersebut digunakan untuk menangkap dinamika perilaku kerumunan berdasarkan kekuatan interaksi individu tanpa perlu melacak objek secara individual atau melakukan segmentasi. Hasil dari metode tersebut menunjukkan bahwa metode ini efektif dalam mendeteksi dan melokalisasi perilaku abnormal di kerumunan. Eksperimen menunjukkan bahwa metode yang diusulkan berhasil menangkap dinamika perilaku kerumunan dan mengungguli pendekatan serupa berdasarkan <i>pure optical flow</i> .
3	Vijay Mahadevan, Weixin Li, Viral Bhalodia, dan Nuno Vasconcelos. 2010. <i>"Anomaly Detection in</i>	<i>Mixture of Dynamic Textures, Gaussian Mixture Model, Saliency Detection</i>	Penelitian ini berhasil menunjukkan bahwa deteksi anomali berbasis <i>Mixture of Dynamic Texture (MDT)</i> mengungguli semua pendekatan lainnya. Perbedaan kinerja lebih menonjol dalam tugas pelokalan anomali yang menunjukkan bahwa pendekatan yang lainnya mungkin berhasil memiliki

No	Peneliti, Tahun, dan Judul	Metode	Hasil
	<i>Crowded Scenes"</i>		tingkat deteksi yang baik dalam tugas deteksi anomali karena hit yang beruntung. Penelitian telah menunjukkan bahwa tekstur dinamis lebih pas daripada aliran optik dalam proses deteksi anomali kerumunan.
4	Hua Yang, Yihua Cao, Shuang Wu, Weiyao Lin, Shibao Zheng, dan Zhenghua Yu. 2012. <i>"Abnormal crowd behavior detection based on local pressure model"</i>	<i>Histogram of Oriented Pressure, Social Force Model, SVM</i>	Penelitian ini berhasil menggunakan metode <i>Histogram of Oriented Pressure</i> (HOP) yang efisien untuk mendeteksi anomali kerumunan. <i>Social force model</i> dan <i>local binary pattern</i> diadopsi untuk menghitung tekanan. Arah tekanan dimasukkan ke dalam statistik untuk meningkatkan akurasi. Histogram silang digunakan untuk menghasilkan vektor fitur daripada menggabungkan histogram magnitudo dan histogram arah secara paralel. SVM diadopsi karena efisiensi dan efektivitasnya yang tinggi. Anomali transien tak terduga dihilangkan menggunakan <i>median filtering</i> . Hasil eksperimen menunjukkan bahwa awal dan akhir anomali dapat dideteksi dengan benar.

No	Peneliti, Tahun, dan Judul	Metode	Hasil
5	<p>Mahdyar Ravanbakhsh, Moin Nabi, Enver Sangineto, Lucio Marcenaro, Carlo Regazzoni, dan Nicu Sebe. 2017.</p> <p><i>"Abnormal Event Detection in Videos Using Generative Adversarial Nets"</i></p>	<i>Generative Adversarial Nets</i>	<p>Penelitian ini berhasil membahas masalah deteksi kelainan dalam video kerumunan dengan menggunakan metode <i>generative deep learning</i> berdasarkan dua <i>conditional GAN</i>. GAN tersebut dilatih hanya menggunakan data normal sehingga tidak dapat menghasilkan kejadian abnormal. Pada waktu pengujian, perbedaan lokal antara gambar nyata dan gambar yang dihasilkan digunakan untuk mendeteksi kemungkinan kelainan. Hasil eksperimen pada kumpulan data standar menunjukkan bahwa metode ini berhasil unggul dengan protokol evaluasi <i>frame-level</i> dan <i>pixel-level</i>.</p>
6	<p>Peng Qiu, Sumi Kim, Jeong-Hyu Lee, and Jaeho Choi. 2018.</p> <p><i>"Anomaly Detection in a Crowd Using a Cascade of Deep Learning Networks"</i></p>	<i>Convolutional Neural Network, Long Short-term Memory</i>	<p>Penelitian ini berhasil mendeteksi objek anomali menggunakan LSTM sebagai encoder decoder dan sebagai model prediksi untuk memperkirakan tracklet masa depan setiap objek. Sebelum melakukan deteksi abnormal, dilakukan proses ekstrak fitur menggunakan CNN dan deteksi kotak pembatas objek individual. Tidak seperti pendekatan berbasis pengklasifikasi, metode deteksi</p>

No	Peneliti, Tahun, dan Judul	Metode	Hasil
			ini dianggap sebagai kelas masalah regresi probabilitas setiap objek dengan kotak pembatasnya. Jaringan koheren di LSTM digunakan untuk menangkap perilaku spatiotemporal objek individu yang dibandingkan dengan objek bergerak lainnya untuk membedakan gerakan atau ukuran abnormal dari yang normal.
7	Avishek Majumder, R. Venkatesh Babu, dan Anirban Chakraborty. 2018. "Anomaly from Motion: Unsupervised Extraction of Visual Irregularity via Motion Prediction"	<i>Recurrent Neural Network, Long Short-term Memory</i>	Penelitian ini berhasil menggunakan representasi gerakan yang sangat jarang untuk memprediksi keteraturan dalam gerakan. Tiga jaringan kecil digunakan pada skala yang berbeda karena tidak tersedianya data pelatihan yang besar. Penelitian ini berhasil menunjukkan bagaimana model multiskala membantu meningkatkan hasil deteksi peristiwa anomali. Karena datanya jarang maka dapat meregresi prediksi masa depan daripada merekonstruksi. Dalam kasus data yang padat, kebanyakan model regresi biasanya gagal dan konvergen ke rata-rata data masukan.

No	Peneliti, Tahun, dan Judul	Metode	Hasil
8	Wen Liu, Weixin Luo, Dongze Lian, dan Shenghua Gao. 2018. <i>"Future Frame Prediction for Anomaly Detection – A New Baseline"</i>	<i>Future Frame Prediction</i>	<p>Penelitian ini berhasil menggunakan jaringan <i>future frame prediction</i> untuk deteksi anomali. U-Net digunakan sebagai jaringan prediksi dasar untuk menghasilkan <i>future frame prediction</i> yang lebih realistis, selain <i>adversarial training</i> dan kendala dalam penampilan, dilakukan juga proses untuk menghilangkan ruang temporal untuk memastikan aliran optik dari bingkai yang diprediksi konsisten dengan kebenaran dasar. Dengan cara ini dapat menjamin untuk menghasilkan peristiwa normal baik dari segi penampilan dan gerak, dan peristiwa dengan perbedaan yang lebih besar antara prediksi dan kebenaran dasar akan diklasifikasikan sebagai anomali. Eksperimen ekstensif pada tiga kumpulan data menunjukkan metode ini mengungguli metode yang ada dengan selisih yang besar, yang membuktikan efektivitas metode untuk deteksi anomali.</p>

No	Peneliti, Tahun, dan Judul	Metode	Hasil
9	Hung Vu, Tu Dinh Nguyen, Trung Le, Wei Luo, dan Dinh Phung. 2019. <i>"Robust Anomaly Detection in Videos Using Multilevel Representations"</i>	<i>MultiLevel Anomaly Detector</i>	Penelitian ini menghasilkan <i>multilevel anomaly detector</i> . Dengan menemukan objek yang tidak biasa pada representasi tingkat tinggi selain pada data tingkat rendah dan menggabungkan hasil deteksi ini, detektor tersebut dapat melokalisasi wilayah anomali dengan akurasi tinggi dan deteksi palsu yang rendah. Eksperimen pada kumpulan data publik menunjukkan bahwa metode ini dapat mengungguli detektor tingkat tunggal dan sistem canggih lainnya yang ada pada kumpulan data UCSD Ped 2 dan Avenue, dan kompetitif pada kumpulan data UCSD Ped 1. Kebenaran dasar UCSD Ped 1 juga dikoreksi dan dipublikasikan ke komunitas riset.

No	Peneliti, Tahun, dan Judul	Metode	Hasil
10	Mahdyar Ravanbakhsh dan Enver Sangineto. 2019. <i>"Training Adversarial Discriminators for Cross- channel Abnormal Event Detection in Crowds"</i>	<i>Generative Adversarial Nets</i>	Penelitian ini berhasil menggunakan pendekatan berbasis GAN untuk deteksi kelainan. Informasi pengawasan timbal balik dari generator dan jaringan diskriminator digunakan untuk mengatasi kurangnya <i>supervised training data</i> dari skenario deteksi kelainan tipikal. Strategi ini memungkinkan untuk melatih <i>end-to-end anomaly detectors</i> hanya menggunakan rangkaian video pelatihan yang relatif kecil dan diawasi dengan lemah. Pendekatan yang diusulkan secara tajam mengungguli metode sebelumnya. Hasil perbandingan pendekatan yang diusulkan dengan baseline berbasis rekonstruksi yang kuat dan tugas encoding/decoding saluran yang sama, menunjukkan bahwa akurasi keseluruhan dan keunggulan komputasi dari metode yang diusulkan.

No	Peneliti, Tahun, dan Judul	Metode	Hasil
11	Tarik Alafif, Bander Alzahrani, Yong Cao, Reem Alotaibi, Ahmed Barnawi, dan Min Chen. 2020. <i>"Generative adversarial network based abnormal behavior detection in massive crowd videos: a Hajj case study"</i>	<i>Optical Flow, Generative Adversarial Networks</i>	<p>Penelitian ini menghasilkan kumpulan data perilaku abnormal pada peserta haji yang berisi berbagai perilaku abnormal dalam video kerumunan besar. Perilaku abnormal dapat berpotensi berbahaya bagi arus kerumunan skala besar.</p> <p><i>Optical flow</i> berdasarkan GAN dengan bantuan pembelajaran transfer untuk mendeteksi kelainan perilaku dalam adegan kerumunan besar. U-Net dan Flownet digunakan dalam kerangka kerja untuk menghasilkan dan membedakan perilaku normal dan abnormal individu dalam kerumunan besar. Model ini telah mampu mendeteksi perilaku abnormal dari dataset kerumunan skala besar peserta haji tetapi akurasi masih perlu ditingkatkan.</p>

No	Peneliti, Tahun, dan Judul	Metode	Hasil
12	Yaxiang Fan, Gongjian Wen, Deren Li, Shaohua Qiu, Martin D. Levine, dan Fei Xiao. 2020. "Video anomaly detection and localization via Gaussian Mixture Fully Convolutional Variational Autoencoder"	<i>Gaussian Mixture Fully Convolutional Variational Auto-encoder</i>	Penelitian ini berhasil menggunakan metodologi <i>supervised deep learning</i> yang efektif untuk mendeteksi dan menemukan peristiwa anomali dalam video pengawasan. Pendekatannya dibangun di atas kerangka kerja jaringan dua aliran yang masing-masing menggunakan <i>RGB frames</i> dan <i>dynamic flows</i> . Pada tahap pelatihan, patch gambar sampel normal untuk setiap aliran diekstraksi sebagai input untuk melatih <i>Gaussian Mixture Fully Convolutional Variational Autoencoder (GMFC-VAE)</i> yang mempelajari <i>Gaussian Mixture Model (GMM)</i> . Pada tahap pengujian, probabilitas bersyarat dari setiap komponen <i>Gaussian Mixture</i> dari patch uji diperoleh dengan menggunakan GMFC-VAE untuk setiap aliran.

No	Peneliti, Tahun, dan Judul	Metode	Hasil
13	Karishma Pawar dan Vahida Attar. 2021. <i>"Application of Deep Learning for Crowd Anomaly Detection from Surveillance Videos"</i>	<i>Convolutional Autoencoder, Sequence to Sequence Long Short-term Memory Autoencoder</i>	Penelitian ini berhasil menggunakan pendekatan <i>unsupervised learning</i> berdasarkan <i>deep learning</i> dan paradigma pembelajaran untuk mendeteksi anomali global dari video pengawasan kerumunan. Hasil yang didapatkan adalah signifikan dalam hal EER sebesar 15% dan AUC sebesar 87%. Selain itu, model yang diusulkan membutuhkan waktu 0,04 detik untuk memproses setiap frame pada "mediocre GPU" dan oleh karena itu, memenuhi syarat untuk diterapkan secara real-time pemrosesan video pengawasan untuk deteksi anomali.
14	Abid Mehmood. 2021. <i>"Efficient Anomaly Detection in Crowd Videos Using Pre- Trained 2D Convolutional Neural Networks"</i>	<i>Pre-Trained 2D Convolutional Neural Networks</i>	Penelitian ini berhasil menggunakan CNN dua aliran untuk mendeteksi perilaku abnormal dalam adegan kerumunan. Pendekatan ini mengadopsi bentuk modifikasi dari CNN 2D yang telah dilatih sebelumnya untuk aliran spasial dan temporal. <i>RGB image frames</i> dan the <i>SG3Is (stacked grayscale 3-channel images)</i> digunakan untuk menyelaraskan masing-masing aliran spasial dan temporal. Penggunaan SG3Is


No	Peneliti, Tahun, dan Judul	Metode	Hasil
			untuk mewakili fitur gerak memungkinkan untuk menghindari penggunaan alternatif komputasi yang mahal untuk aliran temporal, seperti <i>optical flow</i> atau <i>dynamic images</i> .
15	Masoud Pourreza, Bahram Mohammadi, Mostafa Khaki, dan Samir Bouindour. 2021. " <i>G2D: Generate to Detect Anomaly</i> "	<i>Binary Classification, Generative Adversarial Networks</i>	Penelitian ini berhasil menggunakan <i>general purpose framework</i> untuk deteksi ketidakteraturan. Dua jaringan yaitu <i>unsupervisedly</i> dan <i>adversarially</i> dilatih pada sampel normal yang bertujuan untuk menghasilkan data yang tidak teratur. Setelah itu, <i>deep neural network</i> digunakan sebagai pengklasifikasi biner mempelajari anomali yang dihasilkan secara bersamaan bersama dengan instance normal yang tersedia. G2D dapat secara akurat mendeteksi ketidakteraturan tetapi tidak menyadari data kelas abnormal.

3. METODOLOGI PENELITIAN

Penelitian ini melakukan pengembangan metode untuk deteksi pergerakan anomali pada kerumunan menggunakan Algoritma *Generative Adversarial Network*. Metodologi yang digunakan adalah sebagai berikut.

1. Studi literature. Pada tahap ini dilakukan studi terhadap beberapa artikel dan buku yang menguraikan mengenai pemrosesan video, deteksi pergerakan anomali pada kerumunan dan Algoritma *Generative Adversarial Network*
2. Merancang algoritma *Generative Adversarial Network* secara *Real time* untuk mengklasifikasi antara pergerakan normal dan anomali pada kerumunan
3. Menguji keunggulan *Generative Adversarial Network* secara *Real time* dengan algoritma sebelumnya

3.1 Sistem Struktur Anomali pada Kerumunan




Gambar 3.1 Sistem Deteksi Anomali pada Kerumunan (Yang et al., 2012)

Pada gambar 3.1 merupakan konsep awal sistem struktur pada kerumunan, untuk mendeteksi adanya kerumunan yang bersifat anomaly. Konsep ini berawal dari model dari kerumunan atau dapat dikatakan *social force model* yaitu sebuah model kerumunan yang memfokuskan pada karakteristik lokal orang jika terdapat tekanan dalam kerumunan, atau kerumunan yang memiliki kepadatan yang tinggi. Model ini dimulai dengan penempatan frame video untuk menghitung karakteristik lokal secara efisien dan mendapatkan nilai *local pressure model* atau *local model*. Model ini berfungsi untuk mengekstrak

karakteristik tekanan lokal untuk mengetahui pola atau sifat perilaku dari kerumunan sesuai karakteristik penduduk/masyarakat. Pola ini menggunakan vektor fitur diekstraksi untuk frame video dengan pemanfaatan *Histogram of Oriented Pressure* (HOP), dan untuk pola anomali akan terlihat menggunakan *Support Vector Machine* (SVM).

Untuk klasifikasi, dan filter median diimplementasikan pada hasil klasifikasi. Filter median adalah metode penyaringan digital non-linear yang biasanya digunakan untuk menghilangkan noise dari sinyal atau gambar pada video. Penelitian ini menggunakan model sistem anomali untuk mengetahui pola pergerakan pada kerumunan khususnya pada objek peneliti atau masyarakat di Indonesia. Sehingga mendapat kebaharuan menjadi dataset untuk membedakan pola pergerakan pada kerumunan anomali ataupun normal pada penduduk Indonesia.

3.2 Kerangka Penelitian Perilaku Anomali pada Kerumunan



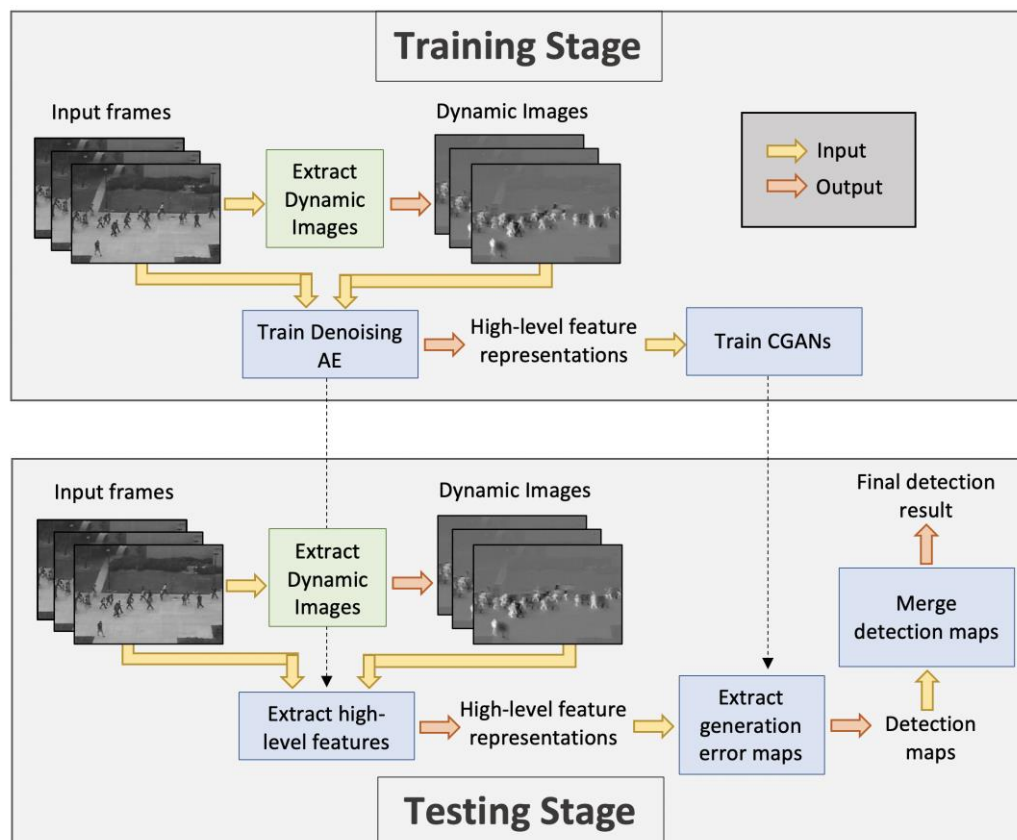
Gambar 3.2 Kerangka Penelitian Perilaku Anomali pada kerumunan. (El-Etriby et al., 2017)

Pada gambar 3.2 merupakan kerangka penelitian yang diadaptasi dari penelitian El-Etriby et al., tahun 2017. Pada penelitian ini, sumber kerumunan berasal dari video atau kamera pengawas, proses selanjutnya melalui *segmentation video*, yaitu proses yang dilakukan pada gambar 3.1 berfungsi untuk menemukan pola yang terjadi pada kerumunan. Pada proses segmentasi juga akan dianalisis pola yang memiliki kerumunan normal dan tidak normal/anomali, pola ini dijadikan *formation block* berfungsi untuk mendapatkan karakteristik yang didapat dari kerumunan, karakteristik yang diambil adalah nilai kepadatan kerumunan, tekanan pada kerumunan, serta pergerakan kerumunan yang terjadi, hasil dari karakteristik ini menjadi *point of interest* atau hal

utama dalam pengambilan pola, sehingga dari nilai ini akan diketahui analisis perilaku yang terekam dalam video.

3.3 Tahap Pelatihan dan Pengujian Menggunakan GAN

Sistem *training* atau pelatihan dan *testing* atau pengujian menggunakan algoritma *Generative Adversarial Network*, terdapat pada gambar 3.3



Gambar 3.3 Kerangka Proses Klasifikasi Penelitian . (El-Etriby et al., 2017)

Kerangka proses di atas dibagi menjadi dua tahap utama yaitu pelatihan jaringan dan pengujian jaringan untuk deteksi anomali.

Tahap 1: Tahap pelatihan mengikuti langkah-langkah di bawah ini:

1. Ekstraksi representasi *dynamic images* untuk setiap frame input (perilaku normal).
2. Melatih dua *Denoising Autoencoder* (DAE) yang berbeda, satu untuk frame input dan yang lainnya untuk *dynamic images*.

3. Ekstraksi *high-level features* dari frame input dan *dynamic images* dari *Denoising Autoencoder* (DAE) yang telah dilatih sebelumnya sesuai dengan tipe datanya.
4. Pelatihan dua *Conditional Generative Adversarial Networks* (CGAN) tentang *high-level features* yang diekstraksi dari frame input dan *dynamic images*.

Tahap 2: Tahap pengujian mengikuti langkah-langkah di bawah ini:

1. Ekstraksi representasi *dynamic images* untuk setiap masukan frame pengujian.
2. Perhitungan *high-level features* untuk frame input dan representasi *dynamic images* yang sesuai.
3. Perhitungan *generation error maps* menggunakan *pre-trained Conditional Generative Adversarial Networks* (CGAN) untuk menghitung *binary detection maps* untuk setiap tingkat representasional.
4. Hasil deteksi akhir ditentukan berdasarkan penggabungan peta deteksi yang diekstraksi.

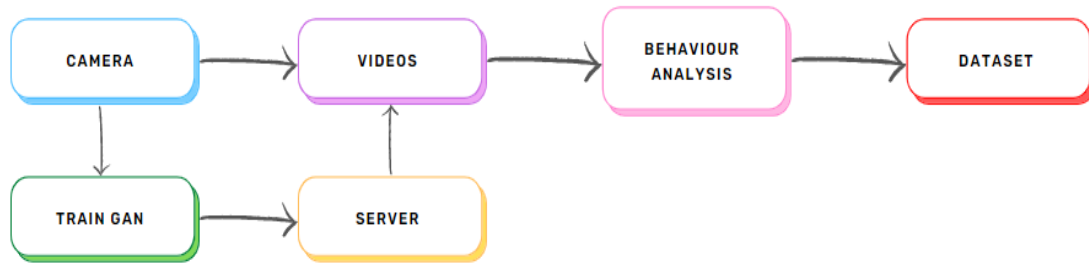
Pada gambar 3.3 algoritma *Generative adversarial network* menggunakan *dynamic image* atau analisa urutan video yang dijadikan gambar. Pada gambar tersebut frame yang sudah dijadikan gambar dilakukan proses *training*. Pengembangan dari proses *training* dan *testing* ini adalah dengan menggunakan input video seperti pada gambar 3.4



Gambar 3.4 Konsep Masukkan video

Pada gambar 3.4 konsep masukkan video dilakukan melalui kamera pengawas yang terhubung kepada router untuk dapat melakukan *streaming* atau analisis secara *real-time/online*. Hasil proses training dan testing disimpan dalam server, sehingga saat kamera menangkap video maka akan membandingkan dengan server yang sudah terisi

oleh konsep atau pola dari normal dan anomali. Sehingga penelitian yang akan diteliti memiliki konsep sebagai berikut :



Gambar 3.5 Konsep Penelitian

Pada gambar 3.5 konsep penelitian berawal dari kamera pengawas yang membandingkan masukkan dari *train GAN* yang disimpan di dalam server dengan video yang diambil dari kamera secara *real time*, hasil dari perbandingan video tersebut akan menghasilkan *behaviour analysis* atau pola gerakan anomali pada kerumunan sehingga outputnya akan menjadi suatu dataset untuk identifikasi gerakan anomali pada kerumunan.

DAFTAR PUSTAKA

1. Alafif, T., Alzahrani, B., Cao, Y., Alotaibi, R., Barnawi, A., & Chen, M. (2020). Generative adversarial network based abnormal behavior detection in massive crowd videos: a Hajj case study. *Journal of Ambient Intelligence and Humanized Computing*. doi: /10.1007/s12652-021-03323-5.
2. Aldayri, A., & Albattah, W. (2022). Taxonomy of Anomaly Detection Techniques in Crowd Scenes. *Sensors* 2022, 22, 60-80. doi: 10.3390/s22166080.
3. Andrade, E.L., Blunsden, S., & Fisher, R.B. (2006). Modelling crowd scenes for event detection, *18th International Conference on Pattern Recognition (ICPR'06)*, 175–178. doi:10.1109/ICPR.2006.806.
4. Bour, P., Cribelier, E., & Argyriou, V. (2019). Crowd behavior analysis from fixed and moving cameras. *Multimodal Behavior Analysis in the Wild*, 289–322. doi:10.1016/b978-0-12-814601-9.00023-7
5. Fan, Y., Wen, G., Li, D., Qiu, S., Levine, M.D., & Xiao, F. (2020). Video anomaly detection and localization via gaussian mixture fully convolutional variational autoencoder. *Computer Vision and Image Understanding*, 195, 102920. doi: 10.1016/j.cviu.2020.102920.
6. Javed, O., Shafique, K., Rasheed, Z., & Shah, M. (2008). Modeling inter-camera space-time and appearance relationships for tracking across non-overlapping views. *Computer Vision and Image Understanding*, 109, 146–162. doi: 10.1016/j.cviu.2007.01.003.
7. Liu, W., Luo, W., Lian, D., & Gao, S. (2018). Future frame prediction for anomaly detection—a new baseline. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 6536–6545.
8. Mahadevan, V., Li, W., Bhalodia, V., & Vasconcelos, N. (2010). Anomaly detection in crowded scenes, in: 2010 IEEE Computer Society

- Conference on Computer Vision and Pattern Recognition (CVPR), pp. 1975–1981. doi:10.1109/CVPR.2010.5539872.
9. Majumder, A., Babu, R.V., & Chakraborty, A. (2018). Anomaly from motion: Unsupervised extraction of visual irregularity via motion prediction, in: Rameshan, R., Arora, C., Dutta Roy, S. (Eds.), *Computer Vision, Pattern Recognition, Image Processing, and Graphics* (pp. 66-77). Springer Singapore, Singapore.
 10. Mehmood., A. (2021). Efficient Anomaly Detection in Crowd Videos Using Pre-Trained 2D Convolutional Neural Networks. *IEEE Access*, Vol.9, 138283-138295 . doi: 10.1109/ACCESS.2021.3118009.
 11. Mehran, R., Oyama, A., & Shah, M. (2009). Abnormal crowd behavior detection using social force model. *2009 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 935–942. doi: 10.1109/CVPR.2009.5206641.
 12. Pawar, K., & Attar, V. (2021). Application of Deep Learning for Crowd Anomaly Detection from Surveillance Videos. *Proceeding in 2021 11th International Conference on Cloud Computing, Data Science & Engineering (Confluence)*. doi: 10.1109/Confluence51648.2021.9377055.
 13. Pourreza, M., Mohammadi, B., Khaki, M., Bouindour, S., Snoussi, H., & Sabokrou, M. (2021). G2D: Generate to detect anomaly. *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision*, 2003–2012.
 14. Qiu, P., Kim, S., Lee, J., & Choi, J. (2018). Anomaly detection in a crowd using a cascade of deep learning networks, in: Bhateja, V., Nguyen, B.L., Nguyen, N.G., Satapathy, S.C., Le, D.N. (Eds.), *Information Systems Design and Intelligent Applications* (pp. 596-607). Springer Singapore, Singapore.
 15. Ravanbakhsh, M., Nabi, M., Sangineto, E., Marcenaro, L., Regazzoni, C., & Sebe, N. (2017). Abnormal event detection in videos using generative

- adversarial nets. *2017 IEEE International Conference on Image Processing (ICIP)*, 1577–1581.
16. Ravanbakhsh, M., Sangineto, E., Nabi, M., & Sebe, N. (2019). Training adversarial discriminators for cross-channel abnormal event detection in crowds. *2019 IEEE Winter Conference on Applications of Computer Vision (WACV)*. 1896–1904.
 17. Sabuhi, M., Zhou, M., Bezemer, C., & Musilek, P. (2021). Applications of Generative Adversarial Networks in Anomaly Detection: A Systematic Literature Review. *IEEE Access*, vol. 9, 161003-161029. doi: 10.1109/ACCESS.2021.3131949.
 18. Sjarif, N. N. A. and Shamsuddin, S.M.H., Hashim, S.Z.M., & Yuhani, S.S. (2011). Crowd analysis and its applications. *ICSECS (1)*, 687–697.
 19. Sjarif, N., Shamsuddin, S., & Hashim, S. (2012). Detection of abnormal behaviors in crowd scene: a review. *International Journal of Advances in Soft Computing and its Applications* 4, 1–33.
 20. Vu, H., Nguyen, T., Le, T., Luo, W., Phung, D., 2019. Robust anomaly detection in videos using multilevel representations. *Proceedings of The Thirty-Third AAAI conference on Artificial Intelligence, Association for the Advancement of Artificial Intelligence (AAAI)*, 5216–5223. doi:10.1609/aaai.v33i01.
 21. Yang, H., Cao, Y., Wu, S., Lin, W., Zheng, S., & Yu, Z. (2012). Abnormal crowd behavior detection based on local pressure model, *Proceedings of The 2012 Asia Pacific Signal and Information Processing Association Annual Summit and Conference*, 1–4.