



**Model Kecerdasan Artifisial Untuk
Mengklasifikasikan Kesuburan Tanaman Dengan
Menggunakan Data Unsur Hara (N) Dan Data
Citra Daun**

DISERTASI

IMAM BIL QISTHI
99223125

**PROGRAM DOKTOR TEKNOLOGI INFORMASI
UNIVERSITAS GUNADARMA
2024**

DAFTAR ISI

COVER	i
DAFTAR ISI	ii
I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Batasan Masalah	3
1.3 Tujuan Penelitian	4
1.4 Kontribusi dan Manfaat Penelitian	4
II TELAAH PUSTAKA	5
2.1 Kajian Penelitian	5
2.2 Kecerdasan Artifisial (AI)	10
2.2.1 Machine Learning	11
2.2.2 Deep Learning	11
2.3 Pengolahan Citra	11
2.3.1 Definisi Citra	11
2.3.2 Citra Digital	12
2.3.3 Jenis Citra	13
2.3.3.1 Citra Berwarna	13
2.3.3.2 Citra Gray Level	14
2.3.4 Ruang Warna	14
2.3.4.1 Warna RGB	15
2.3.4.2 Warna HSV	15
2.3.5 Ekstraksi Fitur Citra	16
2.3.5.1 Ekstraksi Fitur Warna Histogram	17
2.4 Unsur Penyusun Tanaman	18
2.4.1 Peran Nitrogen Pada Tumbuhan	19
2.4.2 Defesiensi Nitrogen	19
III METODE PENELITIAN	20
3.1 Tahapan Penelitian	20
3.1.1 Pengumpulan Data	20
3.1.2 Pemahaman Citra	22
3.1.3 Pra-pemrosesan data	23

3.1.3.1	Segmentasi Citra	24
3.1.3.2	Normalisasi Ukuran Data Citra	27
3.1.3.3	Ekstraksi Fitur Warna Citra	28
3.1.4	Pembentukan dataset	30
3.1.5	Pemisahan dataset	31
3.1.6	Pemodelan	31
3.1.7	Deployment Model	32
3.2	Rencana Kegiatan	33
	DAFTAR PUSTAKA	35

BAB I

PENDAHULUAN

1.1 Latar Belakang

Sistem pertanian sangat bergantung pada kecukupan air, sinar matahari dan asupan nutrisi pada tanaman. Setiap tanaman memiliki kebutuhan nutrisi yang berbeda (Wulandhari, Gunawan, Qurania, Harsani, Triastinurmiatiningsih, Tarawan & Hermawan 2019). Berdasarkan buku (Allen V. Barker 2015) menyebutkan bahwa tanaman biasanya terdiri dari berbagai unsur seperti Karbon (C), Hidrogen(H), Oksigen(O) dan Nitrogen (N). Unsur-unsur tersebut merupakan unsur utama pada tanaman atau dapat disebut dengan *makronutrien*. Sumber lain menyebutkan bahwa (Vince Ordog 2011) Karbon (C), Hidrogen(H), dan Oksigen (O) tidak dapat dianggap sebagai nutrisi mineral karena mereka diperoleh dari air dan karbondioksida. Sedangkan Nitrogen merupakan nutrisi mineral karena dapat diperoleh dari tanah. Nitrogen (N) memiliki peran yang penting dalam tanaman, yaitu sebagai elemen esensial yang artinya jika terjadi ketiadaan elemen dapat menyebabkan beberapa kelainan pertumbuhan dan perkembangan reproduksi pada tanaman. Defisiensi nutrisi Nitrogen (N) merupakan kondisi dimana sebuah tanaman mengalami kekurangan unsur Nitrogen(N) yang merupakan elemen esensial dari tanah. Salah satu ciri yang terlihat sebuah tanaman mengalami defisiensi nutrisi Nitrogen(N) adalah terjadi klorosis (menguning) pada daun yang lebih tua didekat pangkal tanaman, untuk daun yang lebih muda tidak menunjukkan gejala ini karena daun lebih muda Nitrogen(N) dimobilisasi dari daun yang lebih tua.

Pengolahan citra adalah serangkaian teknik dan metode yang digunakan untuk memanipulasi dan menganalisis citra (gambar) dengan tujuan untuk meningkatkan kualitas informasi yang terkandung dalam citra sehingga dapat diinterpretasikan secara tepat oleh mata manusia dan membantu presepsi mesin dalam melakukan tugas otonom berdasarkan pada informasi fitur-fitur yang terkandung dalam citra. Informasi pada citra dibagi menjadi informasi dasar seperti color, bentuk, dan tekstur, informasi dasar ini dapat diolah secara langsung tanpa bantuan tambahan pengetahuan khusus dan informasi abstrak yang tidak dapat diolah secara langsung dengan ban-

tuan tambahan pengetahuan khusus. Contoh Informasi yang bersifat abstrak adalah ekspresi wajah dalam sebuah citra yang dapat menggambarkan situasi perasaan seseorang (keadaan sedih, senang, marah dan lainnya) (Madenda 2015). Contoh lain adalah kondisi tumbuhan dalam sebuah citra yang dapat menggambarkan keadaan nutrisi tercukupi atau nutrisi mengalami defisiensi. Kedua contoh ini tidak dapat diolah oleh komputer kecuali menggabungkan informasi dasar dengan tambahan pengetahuan khusus.

Kecerdasa artifisial(AI) merupakan sekumpulan algoritma dan model matematika untuk memproses data dan membuat prediksi atau keputusan berdasarkan data tersebut (Mitchell 1997). Pengertian AI sumber lain adalah bidang ilmu komputer yang memiliki fokus pada pengembangan sistem atau mesin yang dapat melakukan tugas-tugas yang biasanya membutuhkan kecerdasan manusia, meliputi tugas pengenalan suara, pengenalan gambar, pemahaman bahasa alami, pengambilan keputusan, dan pemecahan masalah (Russell & Norvig 2016).

Banyak penelitian yang memanfaatkan pengolahan citra dan kecerdasan artifisial untuk mengenali kondisi yang terjadi pada tanaman. Secara garis besar penelitian-penelitian yang ada memanfaatkan pengolahan citra untuk mempertajam informasi dan mengolahnya menggunakan kecerdasan artifisial. Pada penelitian (Sethy, Barpanda, Rath & Behera 2020), menggunakan beberapa teknik pengolahan citra ekstraksi fitur pada citra daun padi seperti *Gray Level Co-occurrence Matrix* (GLCM), *Histogram of Oriented Gradients* (HOG), dan *Local Binary Pattern* (LBP). *Support Vector Machine* (SVM) dan *Convolutional Neural Network* (CNN) sebagai model untuk mengenali berdasarkan dari hasil ekstraksi fitur GLCM, HOG, dan LBP. Pada penelitian (Khenilyn P. Lewis 2020), menggunakan beberapa teknik pengolahan citra seperti konversi ruang warna citra dan normalisasi ukuran citra. CNN digunakan untuk mengekstraksi fitur citra dan digunakan untuk mengenali fitur citra. Pada penelitian (Asad Ali & Khan 2022), menggunakan beberapa teknik pengolahan citra untuk melakukan augmentasi pada data dan teknik ekstraksi fitur pada citra menggunakan *pixel based texture*. CNN sebagai model untuk mengenali berdasarkan hasil ekstraksi fitur. Pada penelitian (Mohamed Farag Taha 2022), menggunakan beberapa teknik pengolahan citra untuk melakukan augmentasi dan segmentasi data. CNN sebagai model untuk mengekstraksi fitur citra dan digunakan untuk mengenali fitur citra. Pada penelitian (Mateo et al. 2022), menggunakan teknik pengolahan citra untuk ekstraksi fitur pada citra daun bawang menggunakan *Canny edge*, CNN sebagai model

untuk mengenali berdasarkan hasil ekstraksi fitur. Pada penelitian (Navarro, Mateo & Manlises 2023), menggunakan CNN sebagai model untuk mengekstraksi fitur citra dan digunakan untuk mengenali fitur citra.. Pada penelitian (Gómez-Flores et al. 2024), menggunakan teknik pengolahan citra untuk melakukan segmentasi (*Region of Interest*) dan augmentasi. CNN sebagai model untuk mengekstraksi fitur citra dan digunakan untuk mengenali fitur citra.

Berdasarkan penelitian yang telah dilakukan sebelumnya, terdapat potensi yang dapat dikembangkan lebih lanjut yaitu dengan menambahkan parameter input lain seperti nilai kandungan Nitrogen(N) pada tanah yang dapat dideteksi dari tanah dengan sensor mengingat dalam penelitian yang telah dilakukan sebelumnya hanya menggunakan parameter input citra saja, dan diharapkan dengan menambahkan parameter input data nitrogen (N) ini dapat membantu menambah informasi dasar yang didapatkan dari data citra untuk mengetahui kondisi kesehatan yang terjadi pada tanaman. Penelitian ini, akan dilakukan ekstraksi fitur warna Histogram untuk mengetahui jumlah piksel kuning pada citra daun yang menandakan tanaman mengalami gejala klorosis akibat kekurangan nutrisi, akan dilakukan analisis juga korelasi antara warna daun dengan kandungan NPK (N) dalam tanah menggunakan teknologi kecerdasan artifisial sehingga hasilnya dapat menjadi indikator awal tanaman kekurangan atau kelebihan nutrisi. Sehingga sistem yang efektif untuk mendeteksi status kesehatan tanaman melalui warna daun dan kandungan NPK (N) dalam tanah dapat tercipta dan dapat memberikan rekomendasi pemupukan yang lebih efisien dalam penggunaan pupuk, mengurangi biaya, dan meningkatkan hasil panen serta kualitas tanaman.

1.2 Batasan Masalah

Berdasarkan pada uraian latar belakang yang telah dituliskan dan dijelaskan sebelumnya, maka batasan penelitian ini dapat diuraikan sebagai berikut.

1. Dataset yang menggunakan data citra dari tanaman cabai yang sehat ataupun mengalami kekurangan nutrisi dan data nitrogen yang diperoleh dari tanah yang dideteksi menggunakan sensor.
2. Dataset citra akan diproses menggunakan ekstraksi fitur warna untuk memperoleh informasi kondisi tanaman dari citra daun.

1.3 Tujuan Penelitian

1. Mengembangkan sistem deteksi warna daun yang terintergasi dengan sensor NPK untuk memonitor status kesehatan tanaman.
2. Melakukan analisis korelasi warna daun dan kandungan NPK (N) dalam tanah.
3. Mengoptimalkan penggunaan pupuk berdasarkan data deteksi warna daun dan sensor NPK untuk meningkatkan produktivitas dan kualitas tanaman

1.4 Kontribusi dan Manfaat Penelitian

Penelitian ini bermanfaat dalam bidang keilmuan dan bidang pertanian, karena penelitian ini tidak hanya menangani data berupa citra tetapi menangani juga data berupa nilai NPK (N) yang diperoleh dari sensor. Kemudian korelasi yang kuat antara perubahan warna daun dan variasi kandungan NPK(N) dapat digunakan sebagai indikator awal kekurangan nutrisi atau kelebihan nutrisi. Sehingga sistem yang efektif untuk mendeteksi status kesehatan tanaman melalui warna daun dan kandungan NPK (N) dalam tanah dapat tercipta dan dapat memberikan rekomendasi pemupukan yang lebih efisien dalam penggunaan pupuk, mengurangi biaya, dan meningkatkan hasil panen serta kualitas tanaman.

BAB II

TELAAH PUSTAKA

2.1 Kajian Penelitian

Beberapa penelitian terkait dengan deteksi defesiensi Nitrogen (N) pada berbagai jenis tanaman yang telah dilakukan pada penelitian terdahulu. Kajian tersebut dijelaskan sebagai berikut:

Identification of Plant Nutrient Deficiencies Using Convolutional Neural Networks (Watchareeruetai, Noinongyao, Wattanapaiboon-suk, Khantiviriya & Duangsrisai 2018).

Penelitian ini menghadirkan pendekatan inovatif untuk mendeteksi defesiensi Nitrogen (N) pada tanaman *black gram* menggunakan pendekatan metode analisis citra dan kecerdasan artifisial, yang diharapkan dengan pendekatan ini memiliki kinerja yang lebih baik dari pada manual oleh manusia. Data yang digunakan pada penelitian ini adalah data citra tanaman *black gram* yang dikumpulkan secara mandiri. Data citra tersebut memiliki 6 kondisi yaitu Sehat, defesiensi kalsium, defesiensi iron, defesiensi magnesium, defesiensi nitrogen, dan defesiensi potassium. Kondisi tersebut dapat disebut sebagai blok kondisi. *Convolutional Neural Network* (CNN) digunakan untuk melakukan ekstraksi fitur dan memprediksi probabilitas gejala kekurangan nutrisi dalam blok kondisi tertentu. CNN akan dilatih dalam mode *one versus all* dan fokus dalam satu jenis solusi, misalnya untuk defesiensi kalsium model CNN akan dilatih dengan 2 label: sehat dan defesiensi kalsium. Penelitian ini menawarkan pendekatan yang lebih efisien dari pada sebelumnya yaitu pendekatan manual oleh manusia, hal ini dibuktikan bahwa pendekatan kecerdasan buatan dan citra analisis menghasilkan nilai overall presisi, recall dan F-measure masing-masing sebesar 43.02%, 52.13%, dan 47.14%, mengungguli jauh pendekatan manusia dengan nilai masing-masing 27.37%, 26.46%, dan 20.85%. Future work penelitian ini yang mungkin dapat dikembangkan adalah mendeteksi defesiensi nutrisi pada tanaman dengan menambahkan parameter lain, misalnya data nitrogen atau data unsur lain yang dikumpulkan melalui sensor, sehingga model akan semakin baik.

Penelitian yang sudah dilakukan oleh peneliti terdahulu terangkum dalam Tabel 2.1 berikut.

Tabel 2.1: Tabel Penelitian Terdahulu

No	Penelitian	Data	Metode	Hasil
1	Classification of Nutrient Deficiency in Black Gram Using Deep Convolutional Neural Networks (Kadipa Aung Myo Han 2019)	Penelitian ini menggunakan data dari penelitian sebelumnya dengan resolusi yang diubah menjadi 149x149 piksel dan dilakukan augmentasi melalui flip horizontal dan flip vertikal untuk menambah jumlah data. Data yang telah diproses kemudian digunakan untuk melatih model CNN.	Penelitian ini menggunakan arsitektur CNN seperti <i>AlexNet</i> , <i>VGG16</i> , <i>Inception</i> , <i>Xception</i> , <i>ResNet50</i> , <i>MobileNet</i> , dan <i>MobileNetV2</i> yang akan dicari terbaik performanya	Penelitian ini berhasil mengimplementasikan arsitektur <i>ResNet50</i> menggunakan dataset dari penelitian sebelumnya, dan arsitektur ini terbukti menghasilkan kinerja yang lebih baik dibandingkan penelitian sebelumnya yang berbasis blok CNN.
2	Plant Nutrient Deficiency Detection Using Deep Convolutional Neural Network (Wulandhari, Gunawan, Qurania, Harsani, Triastinur-miatiningsih, Tarawan & Hermawan 2019)	Penelitian ini menggunakan 234 data citra tanaman okra, yang dikategorikan menjadi dua kelas (sehat dan kekurangan nutrisi) dan diubah ukurannya menjadi 229 x 229 piksel, data augmentation menggunakan rotasi, pergeseran, zoom, dan flip horizontal.	Penelitian ini menggunakan metode Convolutional Neural Network work	Penelitian ini menghasilkan akurasi 96% untuk training dan 86% untuk testing. Penelitian masa depan dapat menambahkan parameter unsur hara untuk meningkatkan akurasi prediksi.

Tabel Penelitian Terdahulu dianjutkan ke halaman berikutnya

Tabel 2.1 – Lanjutan dari halaman sebelumnya.

No	Penelitian	Data	Metode	Hasil
3	Nitrogen Deficiency Prediction of Rice Crop Based on Convolutional Neural Network (Sethy, Barpanda, Rath & Behera 2020)	Data penelitian ini dikumpulkan dengan mengikuti instruksi Leaf Colour Chart (LCC) dari International Rice Research Institute (IRRI). Sebanyak 5790 citra daun padi berukuran 227x227 piksel terkumpul.	Menggunakan beberapa arsitektur CNN yang telah diganti output layer dengan SVM dan algoritma machine learning (SVM) dengan ekstraksi fitur citra tradisional (HOG, GLCM, dan LBP)	Penelitian ini menunjukkan bahwa model ResNet50 yang dimodifikasi output layer-nya dengan SVM memiliki akurasi tertinggi dibanding model lain dan metode ekstraksi fitur citra tradisional yang digabung dengan SVM. Penelitian di masa depan dapat mengimplementasikan model ini pada perangkat mobile untuk memberikan manfaat yang luas bagi petani.
4	Classification And Detection Of Nutritional Deficiencies In Coffeefee Plants Using Image Processing And Convolutional Neural Network (CNN) (Khenilyn P. Lewis 2020)	Data citra daun kopi yang berhasil dikumpulkan secara mandiri sebanyak 1000 citra daun kopi yang memiliki gejala defisiensi nutrisi seperti Boron, Kalsium, Besi, Nitrogen, Fosfor, Kalium, Magnesium dan Seng yang diverifikasi oleh ahli pertanian dan ahli tanah.	Pendekatan yang digunakan adalah pendekatan <i>processing</i> dan kecerdasan artifisial (CNN) untuk melakukan klasifikasi defisiensi nutrisi pada tanaman kopi.	Penelitian ini berhasil memperoleh akurasi yang baik dan model diimplementasikan ke dalam alat prototipe. Kekurangan penelitian ini adalah tidak menghilangkan background, yang dapat mempengaruhi hasil model CNN. Future work akan fokus pada pemrosesan citra, serta menambahkan input seperti jumlah unsur hara.

Tabel Penelitian Terdahulu dilanjutkan ke halaman berikutnya

Tabel 2.1 – Lanjutan dari halaman sebelumnya.

No	Penelitian	Data	Metode	Hasil
5	Palm leaf nutrient deficiency detection using convolutional neural network (CNN). (Ibrahim, Hasan, Sabri, Airin Fariza Abu Samah, Rahimi Samah & Rusland 2022)	Penelitian ini menggunakan data citra yang memiliki ciri sehat dan defisiensi unsur hara seperti Nitrogen, Kalsium, Magnesium, Boron, Seng, dan Mangan. Ciri sehat atau defisiensi dijadikan label atau kategori untuk penelitian ini.	Penelitian nakan pendekatan kecerdasan artifisial dengan arsitektur CNN bernama <i>Restnet-50</i>	Penelitian ini berhasil mengimplementasikan model CNN untuk mendeteksi defisiensi unsur hara pada daun kelapa sawit dengan akurasi rata-rata 94.29% per label. Kekurangannya adalah kurangnya penjelasan tentang pemrosesan data. Future work akan lebih baik jika menjelaskan secara detail cara pengumpulan, pemrosesan data, termasuk penanganan data yang sedikit.
6	Detection of Deficiency of Nutrients in Grape Leaves Using Deep Network (Asad Ali & Khan (2022))	Penelitian ini menggunakan dataset citra daun anggur yang diambil secara mandiri sebanyak 880 daun anggur diantaranya 210, 240, 220, dan 210 daun yang dipengaruhi oleh defisiensi nutrisi yaitu Kalsium, Magnesium, Fosfor, dan Nitrogen.	Pendekatan yang digunakan pada penelitian ini adalah <i>image processing</i> dan kecerdasan artifisial CNN dengan ekstraksi fitur dengan ekstraksi fitur <i>Pixel-based features</i>	Performa model ini lebih rendah dibandingkan CNN dengan ekstraksi fitur multi dimensi. Kekurangannya adalah ketidakseimbangan jumlah data di masing-masing kelas. Kelebihannya, metode augmentation yang digunakan meningkatkan jumlah data, sehingga model dapat mempelajari lebih banyak fitur.

Tabel Penelitian Terdahulu dilanjutkan ke halaman berikutnya

Tabel 2.1 – Lanjutan dari halaman sebelumnya.

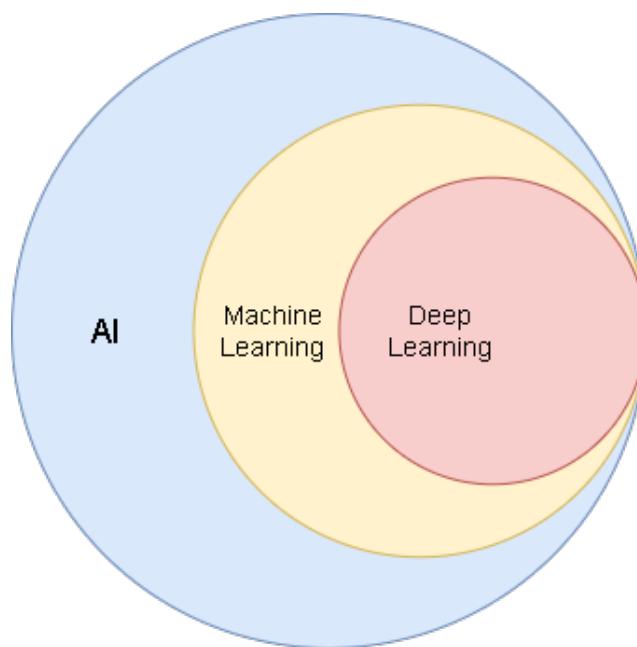
No	Penelitian	Data	Metode	Hasil
7	Using Deep Convolutional Neural Network for Image-Based Diagnosis of Nutrient Deficiencies in Plants Grown in Aquaponics (Mohamed Farag Taha 2022)	Penelitian menggunakan data citra RGB sebanyak 3000 data citra, terdiri dari 2400 data selada aquaponik dan 600 data selada hidroponik. Data dikelompokkan menjadi 4 kelas: defisiensi nitrogen (N), defisiensi fosfor (P), defisiensi kalium (K), dan defisiensi penuh (FN).	Pendekatan yang digunakan pada penelitian ini adalah <i>image processing</i> dan <i>Deep Convolutional Neural Networks</i> (DCNN) seperti <i>ResNet18</i> , <i>Inceptionv3</i> ungul terhadap beberapa metode machine learning seperti SVM, KNN, dan DT.	Penelitian ini berhasil melakukan diagnosis status nutrisi pada tanaman selada baik aquaponik atau hidroponik dengan membandingkan kinerja dari DCNN dan machine learning, dimana kinerja metode DCNN seperti ResNet18, dan Inceptionv3 unggul terhadap beberapa metode machine learning seperti SVM, KNN, dan DT.
8	Identification of Macro-Nutrient Deficiency in Onion Leaves (Allium cepa L.) Using Convolutional Neural Network (CNN) (Mateo, Navarro & Manlises 2022)	Dataset yang digunakan pada penelitian ini adalah 1000 citra daun bawang. Dataset dibagi menjadi 4 kelas yaitu kelas defisiensi nutrisi Nitrogen, defisiensi Kalium, defisiensi Fosfor dan Sehat (nutrisi cukup). Dataset dibagi dengan rasio 70:20:10 untuk data pelatihan, validasi, dan pengujian,	Pendekatan penelitian ini adalah jaringan syaraf tiruan dengan arsitektur VGG-16 dan <i>Canny edge</i> untuk mengekstraksi fitur pada data citra daun kemudian model akan diimplementasikan ke alat prototipe	Penelitian ini berhasil mengimplementasikan arsitektur jaringan syaraf tiruan VGG-16 dengan akurasi keseluruhan 83% dan model diintegrasikan ke perangkat hardware yang dapat menangkap, menyimpan, mengklasifikasi gambar, dan menampilkan hasilnya di monitor. Future work mencakup augmentasi data, penerapan pada jenis daun lain.

2.2 Kecerdasan Artifisial (AI)

Artificial Intelligence atau kecerdasan artifisial merupakan sekumpulan algoritma dan model matematika untuk memproses data dan membuat prediksi atau keputusan berdasarkan data tersebut (Mitchell 1997). Pengertian AI menurut sumber lain adalah bidang ilmu komputer yang memiliki fokus pada pengembangan sistem atau mesin yang dapat melakukan tugas-tugas yang biasanya membutuhkan kecerdasan manusia, meliputi tugas pengenalan suara, pengenalan gambar, pemahaman bahasa alami, pengambilan keputusan, dan pemecahan masalah (Russell & Norvig 2016). Menurut (Goodfellow, Bengio & Courville 2016) AI dapat dibagi menjadi 2 kategori utama:

1. AI Umum (General AI) AI yang memiliki kemampuan untuk memahami, belajar, dan menerapkan pengetahuan dan keterampilan dalam berbagai domain sehingga mirip dengan manusia.
2. AI Sempit (Narrow AI) AI yang dirancang dan dilatih untuk melakukan tugas tertentu, seperti asistan virtual, atau sistem rekomendasi.

Menurut (Alzubaidi, Zhang, Humaidi, Al-Dujaili, Duan, Al-Shamma, Santamaría, Fadhel, Al-Amidie & Farhan 2021) AI terdiri dari beberapa lapisan, mulai dari AI yang bersifat sederhana hingga lapisan AI paling kompleks yaitu *Deep Learning*. Seperti yang ditampilkan pada Gambar 2.1.



Gambar 2.1: Bidang AI (Alzubaidi et al. 2021)

Berdasarkan Gambar 2.1, AI dapat dikatakan kecerdasan yang paling sederhana. Salah satu implementasi AI adalah *Rule-Based Expert System*, dimana menggunakan serangkaian aturan logika untuk menentukan hasil atau memberikan saran berdasarkan input yang diberikan. Aturan ini biasanya berupa pernyataan if-else yang mengandung kondisi dan tindakan yang harus dilakukan jika kondisi tersebut terpenuhi (Sasikumar et al. 2007). Lapisan yang lebih dalam dan lebih kompleks dibandingkan dengan AI yang bersifat sederhana adalah *Machine Learning*. Contoh implementasi dari *Machine Learning* (ML) misalnya sentimen analisis untuk mengklasifikasikan sentimen positif atau negatif dengan menggunakan algoritma *Decision Tree* atau *Support Vector Machine*. Dimana *Decision Tree* atau *Support Vector Machine* akan mempelajari pola-pola pada data sentimen. Lapisan yang lebih dalam dibandingkan dengan ML yaitu lapisan *Deep Learning* (DL). Lapisan ini mempelajari data yang lebih kompleks dari pada lapisan ML dan mempelajari fitur pada data secara otomatis (Russell & Norvig 2016, Goodfellow et al. 2016).

2.2.1 Machine Learning

Machine learning (ML) merupakan salah satu cabang dari AI, ML merupakan sebuah proses komputasi data yang berulang untuk melakukan tugas tertentu, komputasi yang berulang adalah proses pembelajaran yang dilakukan oleh mesin untuk menjadi lebih baik dalam melakukan tugas yang diberikan. Performa dari model ML dipengaruhi dari kualitas data yang digunakan, apakah data memiliki noise atau seberapa kompleks data yang digunakan.

2.2.2 Deep Learning

Deep Learning (DL) merupakan bagian yang lebih dalam dari ML yang memiliki tujuan untuk mengatasi masalah-masalah yang ada pada ML salah satunya ketergantungan pada kualitas data yang digunakan, DL mampu mengatasi noise dan data yang lebih kompleks.

2.3 Pengolahan Citra

2.3.1 Definisi Citra

Secara visual, citra merupakan representasi dari informasi yang terkandung di dalamnya sehingga mata manusia dapat menganalisis dan menginterpretasikan

informasi yang didapat sesuai dengan tujuan yang diharapkan. Informasi pada citra dibagi menjadi 2 yaitu informasi dasar (*low level image analysis*) dan informasi abstrak. Informasi dasar dapat diolah secara langsung tanpa membutuhkan bantuan tambahan dengan pengetahuan khusus seperti warna(*color*), bentuk(*shape*), dan tekstur (*texture*). Informasi abstrak tidak dapat diolah secara langsung tanpa membutuhkan bantuan dengan pengetahuan khusus seperti ekspresi wajah di dalam sebuah citra yang menggambarkan situasi perasaan seseorang (keadaan sedih, senang, marah, dan lainnya). Informasi abstrak ini tidak dapat dianalisis dan dikenali oleh komputer kecuali menggabungkan informasi dasar dengan tambahan pengetahuan khusus (Madenda 2015).

Secara matematis, citra dapat difinisikan sebagai fungsi dua dimensi $f(x, y)$, di mana x dan y adalah koordinat spasial (*plane*) dan f adalah nilai intensitas warna atau tingkat keabuan citra pada koordinat tersebut x dan y . Ketika nilai f , x , dan y bersifat diskrit yang memiliki nilai terbatas sehingga dapat disebut sebagai citra digital seperti yang tersimpan dalam memori komputer dan CD-ROM. Jika nilai f , x , dan y bersifat kontinu yang memiliki nilai terbatas maka citra disebut sebagai citra analog, seperti yang ditampilkan pada layar Televisi, komputer dan foto cetak (Gonzalez & Woods 2009, Madenda 2015).

2.3.2 Citra Digital

Citra digital umumnya dua dimensi (2D) yang dinyatakan dalam bentuk matriks dengan jumlah elemen berhingga. Setiap elemen matriks pada citra memiliki posisi koordinat x dan y tertentu dan juga memiliki nilai. Secara umum, citra digital merupakan representasi piksel-piksel dalam ruang 2D yang dinyatakan dalam matriks berukuran N baris dan M kolom seperti pada persamaan 2.1. Setiap elemen matriks citra disebut piksel (*picture element, image element, atau pel*). Nilai setiap piksel f pada koordinat x dan y merepresentasikan intensitas warna dan dapat dikodekan dalam 24 bit untuk citra berwarna (tiga komponen warna *Red*, *Green*, dan *Blue*), 8 bit untuk citra *gray-level* atau 1 bit untuk citra biner.

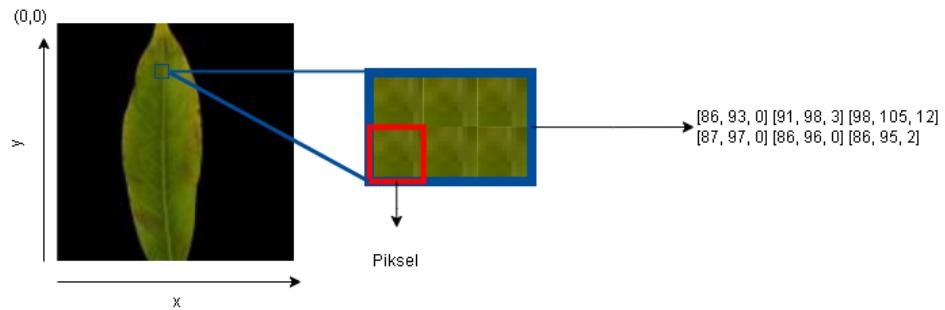
$$\begin{bmatrix} f(0,0) & f(1,0) & f(2,0) & \cdots & f(x,0) \\ f(0,1) & f(1,1) & f(2,1) & \cdots & f(x,1) \\ f(0,2) & f(1,2) & f(2,2) & \cdots & f(x,2) \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ f(0,y) & f(1,y) & f(2,y) & \cdots & f(x,y) \end{bmatrix} \quad (2.1)$$

2.3.3 Jenis Citra

2.3.3.1 Citra Berwarna

Citra berwarna dapat disebut dengan *true color image*. Citra ini secara visual memiliki kandungan informasi warna, di mana warna ini direpresentasikan dalam nilai-nilai piksel yang mengandung *luminance*, *hue*, dan *chrominance/saturation*. *Luminance* merupakan ukuran tingkat kecerahan suatu warna, sehingga jika menaikkan dan menurunkan nilai *luminance* dapat menjadikan warna pada citra menjadi lebih cerah atau lebih gelap. *Hue* merupakan salah satu sifat utama selain *luminance* yang direpresentasikan dalam nilai derajat (0-360 derajat). *Chrominance/saturation* merepresentasikan tinggi rendahnya kandungan cahaya putih dalam suatu warna. Demakin rendah nilai *chrominance* (mendekati nol) maka warna tersebut semakin pucat (memutih) hingga menjadi warna putih/abu-abu dan sebaliknya, jika nilai *chrominance* semakin tinggi maka warna tersebut semakin mendekati *saturation (pure color)*(Gonzalez & Woods 2009, Madenda 2015).

Secara matematis, citra berwarna direpresentasikan dalam matrix 3 dimensi (3D) $f(n, m, k)$. Di mana $n = \{1, 2, 3, \dots, N\}$, N adalah banyaknya baris, dan $m = \{1, 2, 3, \dots, M\}$, M adalah banyaknya kolom, sehingga N dan M merepresentasikan koordinat piksel. Sedangkan $k = \{1, 2, 3\}$ merepresentasikan komponen warna merah ($1 = R$), hijau ($2 = G$), dan biru ($3 = B$). Fungsi inilah yang digunakan untuk proses analisis citra digital berwarna (Gonzalez & Woods 2009, Madenda 2015). Gambar 2.2 merupakan contoh citra daun yang memiliki warna dalam bentuk RGB.



Gambar 2.2: Citra Berwarna

2.3.3.2 Citra Gray Level

Citra gray level merupakan citra yang nilai pikselnya hanya memiliki nilai *luminance*, berbeda dengan citra berwarna yang dikodekan dalam 24 bit pada umumnya citra ini dikodekan dalam 8 bit yang artinya memiliki skala kabuan yang bervariasi dari nilai 0 hingga 255 ($2^8 - 1$). Nilai 0 merepresentasikan hitam, nilai diantara 0 hingga 255 merepresentasikan keabuan yang bervariasi dari hitam hingga cerah menuju putih, dan Nilai 255 merepresentasikan warna putih (Madenda 2015).

Citra gray dapat diperoleh melalui konversi ruang warna RGB ke ruang warna lain seperti YC_bC_r atau HSV dengan mengambil komponen *Y* pada citra YC_bC_r dan komponen *V* pada citra HSV (Ahmad et al. 2018). Persamaan 2.2 dan Persamaan 2.3 adalah persamaan untuk melakukan konversi citra cray dari citra berwarna.

$$Y = b_r R + b_g G + b_b B \quad (2.2)$$

$$V = \max(R, G, B) \quad (2.3)$$

2.3.4 Ruang Warna

Tujuan Ruang warna (*Color Space* atau *Color Model*) adalah untuk memfasilitasi spesifikasi warna dengan cara standar. Pada hakikatnya, ruang warna adalah spesifikasi dari sistem koordinat dan subruang dalam sistem tersebut yang sedemikian rupa sehingga tiap warna dalam model diwakili oleh satu titik yang terdapat dalam subruang tersebut.

Sebagian ruang warna yang digunakan saat ini, berorientasi pada perangkat keras (seperti monitor warna dan printer) atau pada aplikasi , di mana

manipulasi warna menjadi tujuannya (seperti pembuatan grafik warna untuk animasi). Ruang warna dalam pemrosesan citra digital, paling sering digunakan adalah ruang warna RGB dan HSV yang sangat berkaitan dengan cara manusia menggambarkan dan menginterpretasikan warna (Gonzalez & Woods 2009).

2.3.4.1 Warna RGB

Ruang warna RGB (*Red, Green, Blue*) merupakan ruang warna standar yang didasarkan pada hasil akuisisi frekuensi warna oleh sensor elektronik. Bentuk keluaran dari sensor ini berupa sinyal analog, kemudian intensitas amplitudonya didigitalisasi dan dikodekan dalam 8 bit untuk setiap warnanya, sehingga dari warna dasar ini dapat terbentuk 2^{24} atau 16.777.216 warna lainnya (Madenda 2015).

2.3.4.2 Warna HSV

Ruang warna HSV mengacu pada nilai *hue*, *saturation*, *value* yang identik juga dengan luminance, yang warna hsv memiliki ide yang sama dengan ruang warna HSL yaitu merepresentasikan warna dalam koordinat silindris 3D. Ruang warna HSV seing disebut juga dengan *hexcone model*. Berikut adalah langkah-langkah dan Persamaan konversi warna dari ruang RGB ke HSV

1. Normalisasi Nilai RGB Semua nilai RGB perlu dinormalisasi ke rentang 0 hingga 1 dengan membaginya dengan 255.

$$r = \frac{R}{255} \quad (2.4)$$

$$g = \frac{G}{255} \quad (2.5)$$

$$b = \frac{B}{255} \quad (2.6)$$

2. Hitung Nilai Maksimum dan Minimum:

$$\max = \max(R, G, B) \quad (2.7)$$

$$\min = \min(R, G, B) \quad (2.8)$$

$$\delta = c_{\max} - c_{\min} \quad (2.9)$$

3. Hitung Nilai Hue:

Hue (H) dinyatakan dalam derajat dalam rentang [0, 360] derajat atau dalam [0, 1] jika menggunakan skala 0-1.

- Jika $\delta = 0$, maka $H = 0$
- Jika $c_{\max} = r$, maka

$$H = 60^\circ \times \left(\frac{g - b}{\delta} \mod 6 \right) \quad (2.10)$$

- Jika $c_{\max} = g$, maka

$$H = 60^\circ \times \left(\frac{b - r}{\delta} + 2 \right) \quad (2.11)$$

- Jika $c_{\max} = b$, maka

$$H = 60^\circ \times \left(\frac{r - g}{\delta} + 4 \right) \quad (2.12)$$

4. Hitung Nilai Saturation:

Saturation (S) adalah perbandingan antara jangkauan warna dan tingkat kecerahan maksimum:

$$S = \begin{cases} 0 & \text{jika } c_{\max} = 0 \\ \frac{\delta}{c_{\max}} & \text{jika } c_{\max} \neq 0 \end{cases} \quad (2.13)$$

Jika $c_{\max} = b$, maka

$$H = 60 \times \left(\frac{r - g}{\delta} + 4 \right) \quad (2.14)$$

5. Hitung Nilai Value:

Value (V) adalah nilai terbesar dari RGB komponen:

$$V = c_{\max} \quad (2.15)$$

2.3.5 Ekstraksi Fitur Citra

Ekstraksi fitur dalam konteks pengolahan data atau pembelajaran mesin mengacu pada proses mengidentifikasi dan mengekstrak informasi yang relevan atau representatif dari data mentah. Tujuan utamanya adalah untuk menyederhanakan representasi data yang kompleks, tetapi tetap mempertahankan infor-

masi yang penting untuk analisis lebih lanjut atau untuk pembuatan prediksi (Bishop 2006, Li et al. 2020).

2.3.5.1 Ekstraksi Fitur Warna Histogram

Histogram citra dapat didefinisikan sebagai banyaknya jumlah piksel dalam sebuah citra yang memiliki intensitas yang sama tanpa memperhitungkan di mana posisi piksel itu berada. Artinya, histogram tidak menggambarkan informasi posisi spasial setiap piksel atau setiap objek dalam citra, tetapi lebih pada gambaran informasi statistik misalnya distribusi intensitas atau distribusi warna citranya. Histogram citra dapat direpresentasikan dalam bentuk grafik (kurva) satu dimensi atau 3 dimensi (Madenda 2015, Gonzalez & Woods 2009).

Secara matematis, histogram citra untuk citra grayscale dihitung dengan menggunakan Persamaan 2.16 berikut:

$$H(I) = \text{card}\{(x, y) \mid I(x, y) = I\} \quad (2.16)$$

Persamaan 2.16 akan mendefinisikan histogram dari sebuah citra I dengan menghitung jumlah piksel yang memiliki nilai intensitas tertentu di mana:

- $H(I)$ adalah histogram dari citra I .
- card menunjukkan kardinalitas, atau jumlah elemen dalam himpunan.
- (x, y) adalah pasangan koordinat dalam citra.
- $I(x, y)$ adalah nilai intensitas piksel pada posisi (x, y) .

Histogram untuk citra grayscale dengan nilai piksel dalam rentang $[0, L - 1]$, histogram h dapat didefinisikan sebagai fungsi yang menghitung jumlah piksel untuk setiap nilai intensitas i :

$$h(i) = \sum_{x=0}^{M-1} \sum_{y=0}^{N-1} 1(f(x, y) = i) \quad (2.17)$$

Di mana:

- $h(i)$ adalah frekuensi nilai intensitas i .
- M dan N adalah dimensi citra (lebar dan tinggi).
- $f(x, y)$ adalah nilai intensitas piksel pada koordinat (x, y) . Ketika kita menghitung histogram untuk citra grayscale, kita hanya memperhatikan nilai intensitas keabuan tersebut atau satu saluran warna.

- $1(\cdot)$ adalah fungsi indikator yang bernilai 1 jika kondisi di dalamnya benar, dan 0 jika salah.

Histogram untuk citra dalam ruang warna HSV, kita perlu memperbaiki setiap komponen warna (Hue, Saturation, dan Value) secara terpisah. Setiap komponen akan memiliki histogramnya sendiri. Berikut adalah bagaimana kita dapat menuliskan persamaan untuk setiap komponen menggunakan Persamaan

Histogram untuk Komponen Hue (H):

$$h_H(i) = \sum_{x=0}^{M-1} \sum_{y=0}^{N-1} 1(H(x, y) = i) \quad (2.18)$$

Histogram untuk Komponen Saturation (S):

$$h_S(i) = \sum_{x=0}^{M-1} \sum_{y=0}^{N-1} 1(S(x, y) = i) \quad (2.19)$$

Histogram untuk Komponen Value (V):

$$h_V(i) = \sum_{x=0}^{M-1} \sum_{y=0}^{N-1} 1(V(x, y) = i) \quad (2.20)$$

2.4 Unsur Penyusun Tanaman

Berdasarkan buku (Allen V. Barker 2015) menyebutkan bahwa tanaman biasanya terdiri dari berbagai unsur seperti Karbon (C), Hidrogen (H), Oksigen (O), dan Nitrogen (N). Unsur-unsur tersebut merupakan unsur utama atau makronutrien yang sangat penting dan dibutuhkan oleh tanaman dalam jumlah yang besar. Unsur-unsur tersebut memiliki peranan yang penting untuk tanaman. Pertama, unsur Karbon (C), Hidrogen (H), Oksigen (O) yang digunakan untuk proses fotosintesis pada tanaman untuk mengubah energi matahari menjadi kimia dalam bentuk glukosa. Kedua, pembentukan makromolekul organik(karbohidrat, protein, lemak) dalam tanaman memerlukan unsur Karbon (C), Hidrogen (H), Oksigen (O) sebagai komponen utama dan unsur Nitrogen (N) diperlukan untuk sintesis protein dan asam nukleat. Ketiga, pertumbuhan dan perkembangan kekurangan nitrogen dapat menyebabkan fenomena klorosis(menguningnya daun) karena kurangnya klorofil, sehingga pertumbuhan tanaman menjadi terhambat. Buku lain (Vince Ordog 2011)

menyebutkan bahwa Karbon (C), Hidrogen (H), dan Oksigen (O) tidak dapat dianggap sebagai nutrisi mineral karena mereka diperoleh dari air dan karbondioksida.

2.4.1 Peran Nitrogen Pada Tumbuhan

Peran nitrogen pada tumbuhan adalah sebagai elemen esensial bagi tanaman artinya jika terjadi ketiadaan elemen dalam hal ini Nitrogen (N) dapat menyebabkan beberapa kelainan pada pertumbuhan, perkembangan hingga reproduksi pada tanaman (Vince Ordog 2011).

2.4.2 Defesiensi Nitrogen

Defesiensi Nitrogen (DN) merupakan kondisi dimana sebuah tanaman mengalami kekurangan unsur Nitrogen(N) yang berasal dari tanah (Vince Ordog 2011). Unsur tersebut merupakan elemen esensial bagi tanaman yang dapat mempengaruhi pertumbuhan, perkembangan, hingga reproduksi pada tanaman. Berikut adalah Ciri-ciri dan efek yang umum ditemukan pada sebuah tanaman yang mengalami defesiensi Nitrogen (N):

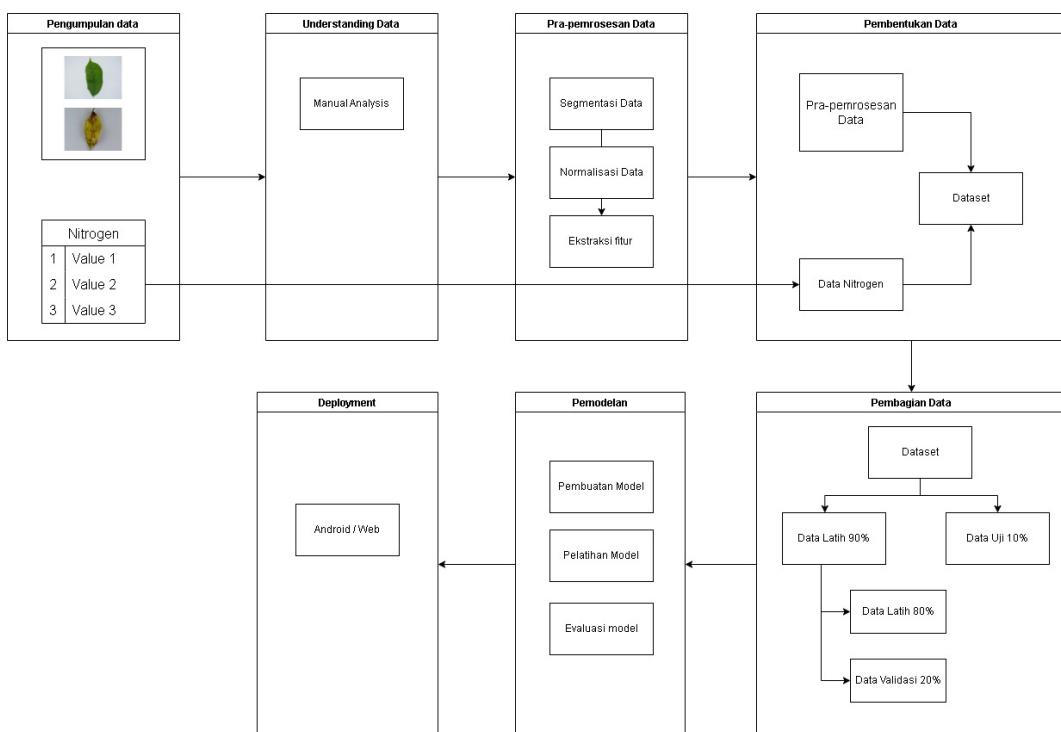
1. Beberapa bagian daun pada tanaman menguning (klorosis) terjadi karena kekurangan Nitrogen (N) yang menjadi komponen sel tanaman. Fenomena ini terjadi pada sebagian besar spesies, terutama pada daun yang lebih tua didekat dengan pangkal tanaman, untuk daun yang lebih muda tidak menunjukkan gejala ini karena pada daun yang lebih muda Nitrogen (N) dapat dimobilisasi dari daun yang lebih tua seperti padi (Vince Ordog 2011, Sethy, Barpanda, Rath & Behera 2020).
2. Beberapa bagian tanaman (daun, tangkai dan batang) berwarna ungu atau bisa disebut akumulasi pigmen. fenomena ini terjadi karena Karbohidrat dialihkan untuk berbagai proses metabolisme (nitrogen dan sintesis antosianin) yang menyebabkan akumulasi pigmen pada tanaman, namun terjadi hanya pada spesies tertentu seperti tomat dan varietas jagung (Vince Ordog 2011).
3. Keterlambatan pertumbuhan (kerdil) terjadi ketika tanaman kekurangan Nitrogen (N). Ukuran seluruh bagian pada tanaman seperti akar, batang, daun, tunas berukuran kecil, sehingga pertumbuhan terlambat.

BAB III

METODE PENELITIAN

3.1 Tahapan Penelitian

Tahapan Penelitian bertujuan untuk menggambarkan secara umum bagaimana tahapan yang dilakukan dalam penelitian sehingga menjadi lebih terstruktur. Tahapan penelitian digambarkan pada Gambar 3.1



Gambar 3.1: Tahapan Penelitian

3.1.1 Pengumpulan Data

Data pada penelitian ini berupa data citra daun cabai dan data jumlah nitrogen yang dikumpulkan secara mandiri. Tanaman cabai akan ditanam di Ladang dengan pengkondisian pupuk tunggal N sehingga akan terlihat perbedaan antara tanaman cabai yang tercukupi atau tidak tercukupi nutrisi NPK(N). Data citra akan dikumpulkan menggunakan kamera dan data citra daun yang digunakan pada penelitian ini memperhatikan potensi noise yang mungkin

terdapat pada gambar saat pengumpulan seperti bayangan sehingga pencahayaan akan diusahakan konsisten, kemudian jarak antara objek dengan kamera jaraknya selalu sama sehingga dapat konsisten skala ukuran objek pada gambarnya, kemudian angle pada kamera saat pengambilan data citra juga dibuat konsisten, dan yang terakhir ketika melakukan pengambilan data citra tanaman sebaiknya mengambil daun yang tua dan dekat dengan pangkal hal ini karena menurut (Vince Ordog 2011) daun muda akan selalu tercukupi nutrisi Nitrogennya karena akan dimobilisasi dari daun yang lebih tua. Berikut adalah gambar dari ladang yang telah disurvei sebelumnya untuk ditanami tanaman cabai sebagai lokasi pengambilan data akan ditampilkan pada Gambar 3.2



Gambar 3.2: Lokasi Pengambilan Data

Data jumlah nitrogen akan dikumpulkan menggunakan sensor NPK dan data jumlah nitrogen akan dikumpulkan secara bersamaan, artinya ketika pengambilan citra daun akan dilakukan pencatatan data nitrogen yang terdeteksi oleh sensor unsur hara. Berikut adalah tampilan dari sensor unsur hara NPK(N) yang akan digunakan untuk mengukur kadar Nitrogen dalam tanah, akan ditampilkan pada Gambar 3.3



Gambar 3.3: Alat Sensor NPK(N)

3.1.2 Pemahaman Citra

Tahapan penelitian ini bertujuan untuk memahami lebih jauh data citra daun yang menjadi objek penelitian ini seperti mempelajari kondisi daun yang memiliki kondisi kekurangan atau tercukupi unsur Nitrogen(N) seperti apa. Selain itu, tahap ini bertujuan untuk mengetahui informasi apa saja yang dapat dikumpulkan dari data citra daun, meliputi bagaimana melakukan ekstraksi, penanganan noise, dan sebagainya. Data yang digunakan pada tahapan ini sementara menggunakan data sekunder, yang berasal dari kaggle (Do 2019) dan dataset mendeley (Victor A Tuesta Montezza 2023). Kondisi data citra ditampilkan pada Gambar 3.4

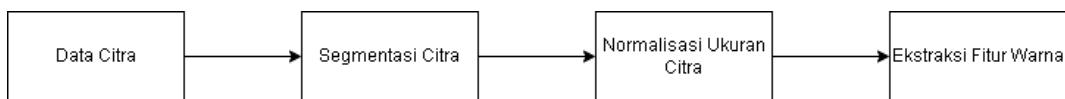


Gambar 3.4: Citra Daun Nutrisi(N) Cukup (subur) Dan Kekurangan Nutrisi (N)

Pada Gambar 3.4 dapat diperhatikan ketika melihat data citra daun, dikatakan nutrisi tercukupi ketika daunnya seluruhnya hijau dan dikatakan nutrisi Nitrogen(N) tidak tercukupi ketika daunnya sebagian kuning atau seluruh kuning. Hal ini merupakan kinerja mata manusia dalam membedakan atau mencirikan suatu nutrisinya tercukupi atau tidak dari warnanya, jika tanaman menguning maka tanaman dianggap kekurangan nutrisi Nitrogen(N) atau jika tanaman hijau keseluruhan dianggap tercukupi nutrisi Nitrogen(N), sehingga dapat menggunakan metode ekstraksi fitur warna seperti histogram untuk melihat berapa banyak warna kuning yang mencirikan kesuburan tanaman dari daun. hal ini juga dikuatkan dengan buku yang ditulis oleh (Vince Ordog 2011). Pada Gambar 3.2 dapat diperhatikan bahwa data citra memiliki potensi noise yaitu bayangan dan background dari citra itu sendiri ketika dilakukan pengambilan, sehingga dapat dilakukan segmentasi pada data citra. Atas dasar dari hasil tahapan ini tahapan selanjutnya yaitu tahapan Pra-pemrosesan data dapat ditentukan.

3.1.3 Pra-pemrosesan data

Tahap pra-pemrosesan data bertujuan untuk memastikan dataset citra yang diperoleh pada tahap pengumpulan data memiliki kualitas yang baik dan konsisten sehingga dataset tersebut jika diproses hasilnya juga akan baik. Tahap ini menjadi penting dan krusial karena jika dataset citra tidak memiliki kualitas yang baik dan konsisten maka hasil yang dihasilkan juga akan demikian. Sehingga tahap ini mengandung prinsip *Garbage In Garbage Out*(GIGO). Tahap Pra-pemrosesan data ditampilkan pada Gambar 3.5

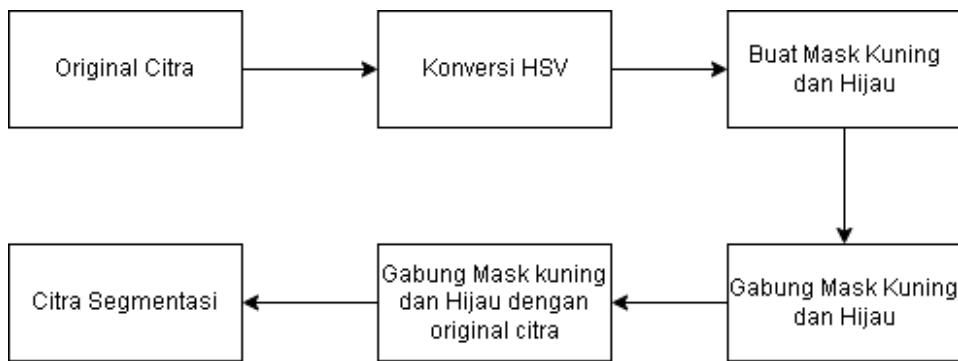


Gambar 3.5: Tahapan Pra-pemrosesan Data

Tahap Pra-pemrosesan data yang telah ditampilkan pada Gambar 3.5 ditentukan berdasarkan tahapan sebelumnya yaitu Pemahaman Data menggunakan data sekunder dan kemungkinan akan digunakan juga ketika sudah menggunakan data primer. Tahapan Pra-pemrosesan akan dijelaskan secara terperinci setiap tahapnya sebagai berikut.

3.1.3.1 Segmentasi Citra

Tahap segmentasi citra merupakan salah satu tahapan dari Pra-pemrosesan Data yang bertujuan untuk menghilangkan potensi noise seperti background pada citra atau bayangan pada citra sehingga dapat mengurangi potensi kesalahan. Tahapan Segmentasi Citra ditampilkan pada Gambar 3.6



Gambar 3.6: Tahapan Segmentasi data

Tahapan pertama pada tahap segmentasi citra adalah konversi ruang warna RGB kedalam ruang warna HSV hal ini bertujuan untuk meningkatkan keakuratan dalam proses segmentasi karena dengan warna HSV informasi mengenai warna (H), Saturasi (S) dan kecerahan (V), dipisahkan menjadi tiga komponen yang independen sehingga memudahkan segmentasi berbasis warna, karena komponen Hue memungkinkan fokus pada warna tanpa dipengaruhi oleh variasi pencahayaan atau intensitas, yang sering kali menjadi masalah dalam ruang warna RGB di mana warna dan kecerahan bercampur.

Pseudocode konversi citra warna RGB ke HSV menggunakan Persamaan 2.4 hingga Persamaan 2.15.

Algoritma 3.1 Konversi Ruang Warna RGB ke HSV

INPUT: RGB values (R, G, B)

OUTPUT: HSV values (H, S, V)

- 1: **Function** RGBtoHSV(R, G, B)
 - 2: **1. Normalisasi Nilai RGB:**
 - 3: $r \leftarrow R/255$
 - 4: $g \leftarrow G/255$
 - 5: $b \leftarrow B/255$
-

Algoritma 3.2 Konversi Ruang Warna RGB ke HSV (Lanjutan)

1: **2. Hitung Nilai Maksimum dan Minimum:**

2: $c_{\max} \leftarrow \max(r, g, b)$

3: $c_{\min} \leftarrow \min(r, g, b)$

4: $\delta \leftarrow c_{\max} - c_{\min}$

5:

6: **3. Hitung Nilai Hue (H):**

7: **IF** $\delta = 0$ **THEN**

8: $H \leftarrow 0$

9: **ELSE**

10: **IF** $c_{\max} = r$ **THEN**

11: $H \leftarrow 60 \times ((g - b) / \delta \bmod 6)$

12: **ELSE IF** $c_{\max} = g$ **THEN**

13: $H \leftarrow 60 \times ((b - r) / \delta + 2)$

14: **ELSE IF** $c_{\max} = b$ **THEN**

15: $H \leftarrow 60 \times ((r - g) / \delta + 4)$

16: **END IF**

17: **END IF**

18: **IF** $H < 0$ **THEN**

19: $H \leftarrow H + 360$

20: **END IF**

21:

22: **4. Hitung Nilai Saturation (S):**

23: **IF** $c_{\max} = 0$ **THEN**

24: $S \leftarrow 0$

25: **ELSE**

26: $S \leftarrow \delta / c_{\max}$

27: **END IF**

28:

29: **5. Hitung Nilai Value (V):**

30: $V \leftarrow c_{\max}$

31:

32: **return** (H, S, V)

Setelah citra dikonversi dari ruang warna RGB ke dalam ruang warna HSV, langkah selanjutnya adalah menggunakan citra dalam ruang warna HSV tersebut sebagai input untuk proses segmentasi berikutnya. Proses ini

melibatkan tahap thresholding citra HSV yang dilakukan dengan menerapkan masking biner dan operasi bitwise. Dalam tahap thresholding, nilai-nilai warna dalam komponen Hue, Saturation, dan Value dianalisis untuk menentukan rentang warna tertentu yang ingin disegmentasi.

Teknik masking biner digunakan untuk menciptakan sebuah masker yang menyorot bagian-bagian citra yang sesuai dengan kriteria warna yang telah ditentukan. Masker biner ini kemudian dioperasikan dengan citra asli menggunakan operasi bitwise, seperti AND atau OR, untuk menghasilkan citra yang hanya menampilkan objek atau area dengan warna yang diinginkan.

Proses ini sangat efektif dalam segmentasi objek berdasarkan warna tertentu dalam suatu citra, karena memungkinkan isolasi objek secara presisi dan akurat meskipun terdapat variasi pencahayaan atau kompleksitas warna lainnya. Dengan demikian, thresholding berbasis ruang warna HSV yang digabungkan dengan masking biner dan operasi bitwise menjadi metode yang sangat efisien untuk deteksi dan pemrosesan objek warna dalam berbagai aplikasi pengolahan citra.

Algoritma 3.3 Thresholding Warna Ruang HSV

INPUT: Image I HSV

OUTPUT: Image $result$ with only green and yellow regions

```

1: Input HSV image:
2:  $I_{HSV}(x, y) \leftarrow (H, S, V)$ 
3:
4: Define the color ranges for green and yellow in HSV space:
5:  $lower\_green \leftarrow [25, 40, 40]$ ,  $upper\_green \leftarrow [85, 255, 255]$ 
6:  $lower\_yellow \leftarrow [15, 40, 40]$ ,  $upper\_yellow \leftarrow [35, 255, 255]$ 
7:
8: Create binary masks for green and yellow:
9: for each pixel  $(x, y)$  in  $I_{HSV}$  do
10:   IF  $lower\_green \leq I_{HSV}(x, y) \leq upper\_green$  THEN
11:      $mask\_green(x, y) \leftarrow 1$ 
12:   ELSE
13:      $mask\_green(x, y) \leftarrow 0$ 
14:   END IF
15:   IF  $lower\_yellow \leq I_{HSV}(x, y) \leq upper\_yellow$  THEN
16:      $mask\_yellow(x, y) \leftarrow 1$ 
17:   ELSE
18:      $mask\_yellow(x, y) \leftarrow 0$ 
19:   END IF
20: END for

```

Algoritma 3.4 Thresholding Warna Ruang HSV (Lanjutan)

```

1: Combine the green and yellow masks using bitwise OR:
2: for each pixel  $(x, y)$  do
3:    $mask(x, y) \leftarrow mask\_green(x, y) \vee mask\_yellow(x, y)$ 
4: END for
5:
6: Apply the combined mask to the original image:
7: for each pixel  $(x, y)$  do
8:   IF  $mask(x, y) == 1$  THEN
9:      $result(x, y) \leftarrow I(x, y)$ 
10:    ELSE
11:       $result(x, y) \leftarrow 0$ 
12:    END IF
13: END for
14: return  $result$ 

```

Pseudocode ini menggambarkan langkah-langkah penting dalam segmentasi citra berbasis warna menggunakan ruang warna HSV, yang mencakup pembuatan masker biner berdasarkan thresholding, serta penerapan operasi bitwise untuk mendapatkan hasil segmentasi yang diinginkan. Contoh hasil dari tahap segementasi citra menggunakan dataset sekunder ditampilkan pada Gambar 3.7



Gambar 3.7: Contoh Hasil Segementasi Data: (A) Citra Original; (B) Citra Hasil Segmentasi

3.1.3.2 Normalisasi Ukuran Data Citra

Tahap normalisasi ukuran data citra merupakan salah satu langkah penting dalam proses pra-pemrosesan data, yang dirancang untuk meningkatkan

efisiensi baik dalam hal penyimpanan maupun pemrosesan citra digital. Dengan melakukan normalisasi ukuran, ukuran file citra dapat dikurangi secara signifikan, sehingga tidak hanya menghemat ruang penyimpanan tetapi juga memungkinkan pengelolaan data yang lebih mudah, terutama ketika berurusan dengan dataset berukuran besar. Selain itu, dengan mengurangi ukuran citra, beban komputasi yang diperlukan untuk memproses setiap gambar menjadi lebih ringan, yang pada akhirnya mempercepat keseluruhan proses pemrosesan citra, termasuk analisis, pengenalan pola, dan pelatihan model *machine learning* atau *deep learning*.

Algoritma 3.5 Normalisasi Ukuran Data Citra

INPUT: Path folder *input_folder* yang berisi gambar-gambar

OUTPUT: Gambar-gambar yang diubah ukurannya menjadi *new_size* dan disimpan dalam folder *output_folder*

- 1: **Impor** library yang diperlukan
 - 2: **Inisialisasi** path folder input dan output
 - 3: **Tentukan** ukuran baru untuk resize gambar
 - 4: **Buat** folder output jika belum ada
 - 5: **Loop** melalui setiap file dalam *input_folder*
 - 6: **for** setiap nama file di *os.listdir(input_folder)* **do**
 - 7: **IF** nama file **berakhir dengan** (.jpg, .jpeg, .png, .bmp, .gif, .JPG)
 THEN
 - 8: **Konstruksi** path lengkap ke file gambar
 - 9: **Buka** gambar menggunakan modul Image dari PIL
 - 10: **Ubah ukuran** gambar menjadi *new_size*
 - 11: **Konstruksi** path lengkap untuk menyimpan gambar yang diubah ukurannya di *output_folder*
 - 12: **Simpan** gambar yang diubah ukurannya
 - 13: **END IF**
 - 14: **END for**
 - 15: **Cetak** pesan yang menandakan selesai
-

3.1.3.3 Ekstraksi Fitur Warna Citra

Tahap Ekstraksi Fitur Warna ini bertujuan untuk mengumpulkan informasi warna yang ada pada citra daun. Seperti yang sudah diketahui bahwa tanaman yang memiliki gejala kekurangan nutrisi nitrogen(N) memiliki ciri klorosis atau terdapat warna kuning pada daun. Atas dasar ini dapat dilakukan ekstraksi fitur pada citra yang bertujuan untuk mengetahui berapa banyak piksel kuning pada sebuah gambar. Metode ekstraksi fitur warna pada citra menggunakan

histogram yang dinormalisasi. Tahapan ini digambarkan pada Gambar 3.8



Gambar 3.8: Tahapan Ekstraksi Fitur Warna

Berdasarkan tahapan ekstraksi fitur yang ditampilkan Gambar 3.8, diperlukan melakukan konversi warna HSV karena citra yang sudah berhasil tersegmentasi disimpan dalam ruang warna RGB. konversi warna RGB ke HSV menggunakan Persamaan 2.4 hingga Persamaan 2.15 . Pseudocode konversi citra warna RBG ke HSV sama dengan Pseudocode 3.1. Setelah melakukan konversi tahap selanjutnya adalah melakukan ekstraksi fitur warna pada citra dengan menggunakan histogram. ekstraksi fitur histogram dapat menggunakan Persamaan 2.16 hingga Persamaan 2.20. Pseudocode ekstraksi fitur histogram pada citra.

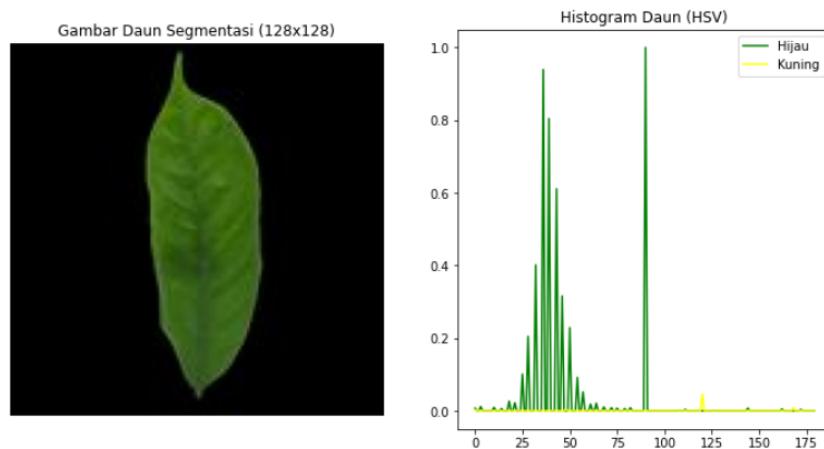
Algoritma 3.6 Hitung dan Tampilkan Histogram Ter-normalisasi

INPUT: Gambar daun dalam format RGB

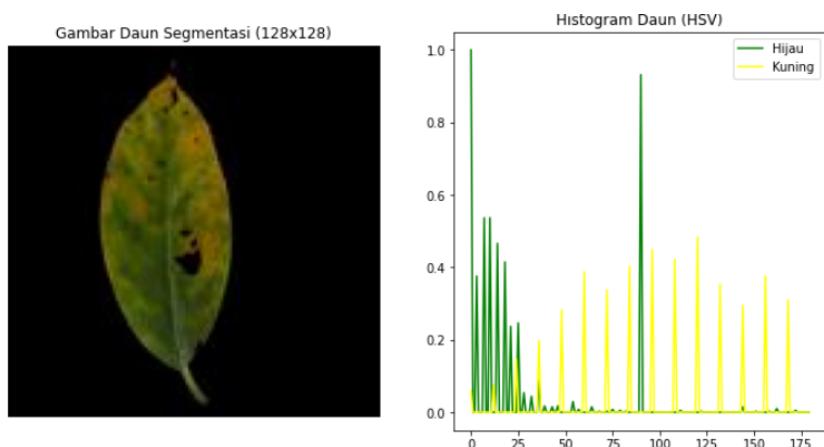
OUTPUT: Plot histogram ter-normalisasi untuk warna hijau dan kuning

- 1: **Konversi gambar dari RGB ke HSV**
 - 2: $hsv_im \leftarrow$ Konversi citra daun dari RGB ke HSV
 - 3:
 - 4: **Rentang nilai hue untuk warna hijau dan kuning**
 - 5: $hr_g \leftarrow [35, 85]$, $hr_y \leftarrow [20, 35]$. # Range nilai hue hijau dan kuning
 - 6:
 - 7: **Hitung histogram untuk hue hijau dan kuning**
 - 8: $hist_hg \leftarrow$ Hitung histogram hue untuk rentang hr_g pada hsv_im
 - 9: $hist_hy \leftarrow$ Hitung histogram hue untuk rentang hr_y pada hsv_im
 - 10:
 - 11: **Normalisasi histogram**
 - 12: $max \leftarrow$ Nilai maksimum dari $hist_hg$
 - 13: $n_hg, n_hy \leftarrow$ List kosong
 - 14: **for** $i \leftarrow 0$ **to** 179 **do**
 - 15: $n_hg.append(hist_hg[i] / max)$, $n_hy.append(hist_hy[i] / max)$
 - 16: **END for**
 - 17:
 - 18: **Tampilkan Histogram**
-

Contoh hasil dari tahap ekstrasi fitur warna menggunakan histogram yang dinormalisasi untuk menghitung total piksel hijau dan kuning.



Gambar 3.9: Contoh Hasil Ekstraksi Fitur Warna Untuk Citra Daun Yang Kecukupan Nutrisi



Gambar 3.10: Contoh Hasil Ekstraksi Fitur Warna Untuk Citra Daun Yang Kekurangan Nutrisi

Gambar 3.9 merupakan histogram dari citra daun yang memiliki nutrisi Nitrogen(N) yang tercukupi, dapat diperhatikan bahwa nilai dari histogramnya akan dominan hijau. Gambar 3.10 merupakan histogram dari citra daun yang memiliki kekurangan nutrisi Nitrogen(N), dapat diperhatikan bahwa nilai dari histogramnya akan dominan kuning.

3.1.4 Pembentukan dataset

Tahap ini bertujuan untuk mengintegrasikan hasil dari proses ekstraksi fitur yang telah dilaksanakan pada tahap pra-pemrosesan data dengan data terkait

kandungan nitrogen yang telah diperoleh melalui sensor khusus. Data nitrogen ini, yang dikumpulkan melalui sensor, memberikan nilai tambah yang signifikan terhadap validitas dan relevansi dataset yang dihasilkan. Dengan demikian, penggabungan ini menghasilkan dataset yang lebih komprehensif, yang tidak hanya memadai untuk keperluan analisis lebih lanjut tetapi juga potensial untuk digunakan dalam pengembangan model yang lebih presisi. Tahap ini juga memastikan bahwa setiap variabel atau elemen data dari kedua sumber tersebut dapat dianalisis secara bersamaan dan terpadu, sehingga memberikan wawasan yang lebih mendalam mengenai korelasi dan hubungan antara fitur-fitur yang telah diekstraksi dengan kandungan nitrogen yang terukur, yang pada akhirnya dapat meningkatkan akurasi dan validitas penelitian secara keseluruhan.

3.1.5 Pemisahan dataset

Tahap ini berfokus pada pembagian dataset yang telah dikompilasi pada tahap sebelumnya menjadi tiga subset yang esensial: data latih, data validasi, dan data uji. Proses pembagian ini sangat penting untuk memastikan bahwa model yang akan dikembangkan pada tahap selanjutnya dapat dioptimalkan dan dievaluasi dengan benar. Data latih digunakan untuk melatih model, memastikan bahwa model mampu belajar dari pola-pola dalam dataset. Data validasi berfungsi sebagai pengukur kinerja model selama proses pelatihan, memungkinkan peneliti untuk menyesuaikan hyperparameter dan mencegah overfitting. Sementara itu, data uji digunakan untuk melakukan evaluasi akhir terhadap model yang telah dilatih dan divalidasi, guna mengukur seberapa baik model tersebut dapat menggeneralisasi terhadap data yang tidak pernah dilihat sebelumnya. Dengan membagi dataset ke dalam tiga bagian ini, peneliti dapat memperoleh pemahaman yang lebih jelas mengenai kinerja model dalam kondisi yang berbeda, sekaligus meningkatkan kepercayaan diri terhadap keandalan model dalam aplikasi dunia nyata. Pembagian ini juga memastikan bahwa seluruh proses pemodelan dilakukan dengan metodologi yang ketat dan terstruktur, sehingga hasil yang diperoleh valid dan dapat diandalkan untuk studi lanjutan atau penerapan praktis.

3.1.6 Pemodelan

Tahap ini bertujuan untuk mengembangkan, melatih, dan mengevaluasi model sebagai indikator awal kekurangan atau kelebihan nutrisi menggunakan

dataset yang sebelumnya telah dibagi menjadi data latih, data validasi, dan data uji. Pada tahap ini, model yang akan digunakan dapat berupa model pembelajaran mesin (*Machine Learning*, ML) atau pembelajaran mendalam (*Deep Learning*, DL), tergantung pada kompleksitas dan kebutuhan analisis. Proses ini dimulai dengan pembuatan model yang sesuai dengan karakteristik data, di mana data latih digunakan untuk membangun dan mengoptimalkan model, sehingga dapat mengenali pola-pola yang relevan dalam dataset. Selanjutnya, data validasi digunakan untuk melakukan penyesuaian parameter model selama pelatihan, guna menghindari masalah *overfitting* dan memastikan bahwa model memiliki kemampuan generalisasi yang baik. Akhirnya, model dievaluasi menggunakan data uji untuk menilai kinerjanya secara objektif, berdasarkan metrik evaluasi yang tepat, seperti akurasi, presisi, recall, dan *F1-score*. Tahap ini krusial dalam memastikan bahwa model yang dihasilkan memiliki keandalan dan akurasi yang tinggi, sehingga dapat digunakan secara efektif dalam sistem. Penggunaan teknik ML atau DL juga memungkinkan model untuk menangkap hubungan kompleks dalam data, yang mungkin tidak dapat ditangani dengan pendekatan konvensional, sehingga meningkatkan kualitas hasil klasifikasi secara keseluruhan.

3.1.7 Deployment Model

Tahap deployment model berfokus pada implementasi model yang telah dikembangkan, dilatih, dan dievaluasi ke dalam lingkungan produksi untuk digunakan secara nyata. Pada tahap ini, model yang telah mencapai tingkat akurasi dan keandalan yang memadai di lingkungan pengujian akan diintegrasikan ke dalam sistem atau aplikasi yang akan memanfaatkan kemampuannya dalam pengambilan keputusan atau analisis dalam hal ini menjadi indikator awal kekurangan atau kelebihan nutrisi kemudian dapat digunakan untuk mengoptimalkan penggunaan pupuk.

Selama tahap deployment, perhatian khusus diberikan pada aspek-aspek seperti performa model dalam skenario nyata, skalabilitas untuk menangani volume data yang besar, dan integrasi dengan sistem lainnya. Selain itu, diperlukan pemantauan terus-menerus untuk memastikan bahwa model beroperasi dengan baik dan tetap akurat seiring dengan perubahan dalam data atau kondisi operasional. Pada umumnya, tahapan ini juga melibatkan pembuatan antarmuka pengguna yang memudahkan interaksi dengan model, serta mekanisme untuk memperbarui model jika diperlukan berdasarkan umpan balik atau data baru yang tersedia. Deployment yang sukses memastikan bahwa

model tidak hanya efektif dalam teori, tetapi juga dapat memberikan manfaat praktis dalam aplikasi nyata, mendukung pengambilan keputusan yang lebih baik, dan memberikan solusi yang efisien untuk masalah yang dihadapi.

3.2 Rencana Kegiatan

Rencana kegiatan berfungsi untuk memetakan jadwal dan tahapan-tahapan yang harus dilalui dalam penelitian. Rencana kegiatan ini penting untuk memastikan bahwa penelitian berjalan sesuai rencana dan dapat diselesaikan tepat waktu. Berikut merupakan rencana kegiatan pada penelitian ini.

Tabel 3.1: Jadwal Kegiatan Penelitian - SEMESTER 1

SEMESTER 1						
AKTIVITAS	1	2	3	4	5	6
Studi Literatur	x	x	x	x	x	x
Pembuatan Proposal				x	x	x

Tabel 3.2: Jadwal Kegiatan Penelitian - SEMESTER 2

SEMESTER 2						
AKTIVITAS	1	2	3	4	5	6
Studi Literatur	x	x	x	x	x	x
Pengumpulan Dataset (Sekunder)			x			
Pemahaman Dataset (Sekunder)				x		
Pra-Pemrosesan Dataset (Sekunder)					x	x

Tabel 3.3: Jadwal Kegiatan Penelitian - SEMESTER 3

SEMESTER 3						
AKTIVITAS	1	2	3	4	5	6
Studi Literatur	x	x	x	x	x	x
Pengumpulan Dataset (Primer)	x	x	x			
Pemahaman Data				x		
Pra-Pemrosesan data					x	x

Tabel 3.4: Jadwal Kegiatan Penelitian - SEMESTER 4

SEMESTER 4						
AKTIVITAS	1	2	3	4	5	6
Studi Literatur	x	x	x	x	x	x
Pengabungan data	x					
Pelatihan, Pengujian Model		x	x			
Tuning Model				x		
Deployment model					x	x

Tabel 3.5: Jadwal Kegiatan Penelitian - SEMESTER 5

SEMESTER 5						
AKTIVITAS	1	2	3	4	5	6
Menuliskan hasil penelitian (BAB 4 & BAB 5)	x	x				
Pembuatan Jurnal Pertama & Submit Jurnal			x			
Perbaikan Jurnal Pertama (jika ada)				x		
Pembuatan Jurnal Kedua & Submit Jurnal					x	
Perbaikan Jurnal Kedua (jika ada)						x

DAFTAR PUSTAKA

- Abayomi-Alli, O. O., Damaševičius, R., Misra, S. & MaskeliÅ«nas, R. (2021), ‘Cassava disease recognition from low-quality images using enhanced data augmentation model and deep learning’, *Expert Systems* **38**(7), 1–21.
- Ahmad, I., Moon, I. & Shin, S. J. (2018), Color to grayscale algorithms effect on edge detection A comparative study, in ‘2018 International Conference on Electronics, Information, and Communication (ICEIC)’, IEEE, pp. 1–4.
URL: <http://ieeexplore.ieee.org/document/8330719/>
- Allen V. Barker, D. J. P. (2015), *Handbook of Plant Nutrition*, CRC Press, Boca Raton.
- Alzubaidi, L., Zhang, J., Humaidi, A. J., Al-Dujaili, A., Duan, Y., Al-Shamma, O., Santamaría, J., Fadhel, M. A., Al-Amidie, M. & Farhan, L. (2021), ‘Review of deep learning: concepts, CNN architectures, challenges, applications, future directions’, *Journal of Big Data* **8**(1), 53.
URL: <https://journalofbigdata.springeropen.com/articles/10.1186/s40537-021-00444-8>
- Asad Ali, Sikandar Ali, M. H. M. M. S. M. A. S. & Khan, M. (2022), ‘Detection of Deficiency of Nutrients in Grape Leaves Using Deep Network’, *Mathematical Problems in Engineering* **2022**.
- Bishop, C. M. (2006), *Pattern Recognition and Machine Learning*, Springer.
- Chowdhury, M. E., Hossain, M. Z. & Rahman, M. S. (2020), ‘Recent advances in texture feature extraction methods for content based image retrieval: A comprehensive review’, *Journal of Imaging* **6**(11), 124.
- Do, H. M. (2019), ‘Rice diseases image dataset’. Akses pada 12 Juni 2024.
URL: <https://www.kaggle.com/datasets/minhhuy2810/rice-diseases-image-dataset>
- Dong, Z., Li, C. & Huang, D.-S. (2011), ‘Local maximal patterns for texture classification’, *Pattern Recognition Letters* **32**(14), 1773–1781.
- Fitzgibbon, A. W., Pilu, M. & Fisher, R. B. (1999), ‘Direct least-squares fitting of ellipses’, *IEEE Transactions on Pattern Analysis and Machine Intelligence* **21**(5), 476–480.

- Gómez-Flores, W., Garza-Saldaña, J. J. & Varela-Fuentes, S. E. (2024), ‘CitrusUAT: A dataset of orange Citrus sinensis leaves for abnormality detection using image analysis techniques’, *Data in Brief* **52**.
- Gonzalez, R. C. & Woods, R. E. (2009), *Digital Image Fundamentals*, 4 edn, Pearson Education Limited, Edinburg Gate.
- Goodfellow, I., Bengio, Y. & Courville, A. (2016), *Deep learning*, MIT press.
- Haralick, R. M., Shanmugam, K. & Dinstein, I. (1973), ‘Textural features for image classification’, *IEEE Transactions on Systems, Man, and Cybernetics* **3**(6), 610–621.
- Ibrahim, S., Hasan, N., Sabri, N., Airin Fariza Abu Samah, K., Rahimi Rusland, M., Samah, A. & Rusland, R. (2022), ‘Palm leaf nutrient deficiency detection using convolutional neural network (CNN)’, *Int. J. Nonlinear Anal. Appl* **13**(August 2021), 2008–6822.
URL: <http://dx.doi.org/10.22075/ijnaa.2022.5836>
- Kadipa Aung Myo Han, U. W. (2019), ‘Classification of nutrient deficiency in black gram using deep convolutional neural networks’, *JCSSE 2019 - 16th International Joint Conference on Computer Science and Software Engineering: Knowledge Evolution Towards Singularity of Man-Machine Intelligence* pp. 277–282.
- Khenilyn P. Lewis, J. D. E. (2020), ‘Classification and detection of nutritional deficiencies in coffee plants using image processing and convolutional neural network (Cnn)’, *International Journal of Scientific and Technology Research* **9**(4), 2076–2081.
- Li, S., Li, Z., Yu, Q. & Deng, S. (2020), ‘A review of feature extraction techniques in medical image processing’, *Healthcare* **8**(2), 128.
- Lin, J., Li, Y., Chen, J. & Liu, Z. (2020), ‘Shape extraction and analysis for machine vision: A review’, *Sensors* **20**(24), 7241.
- Madenda, S. (2015), *Pengolahan Citra dan Video Digital*, 1 edn, Erlangga, Jakarta.
- Mateo, K. C. H., Navarro, L. K. B. & Manlises, C. O. (2022), Identification of Macro-Nutrient Deficiency in Onion Leaves (*Allium cepa* L.) Using Convolutional Neural Network (CNN), in ‘2022 5th International Seminar

- on Research of Information Technology and Intelligent Systems (ISRITI)', IEEE, pp. 419–424.
- URL:** <https://ieeexplore.ieee.org/document/10052884/>
- Mitchell, T. M. (1997), ‘Does machine learning really work?’, *AI magazine* **18**(3), 11–11.
- Mohamed Farag Taha, Alwaseela Abdalla, G. E. M. G. L. Z. N. Z. N. L. Z. N. A. H. S. A.-R. Y. H. Z. Q. (2022), ‘Using Deep Convolutional Neural Network for Image-Based Diagnosis of Nutrient Deficiencies in Plants Grown in Aquaponics’, *Chemosensors* **10**(2), 1–23.
- Navarro, L. K. B., Mateo, K. C. H. & Manlises, C. O. (2023), CNN Models for Identification of Macro-Nutrient Deficiency in Onion Leaves (*Allium cepa* L.), in ‘2023 IEEE 5th Eurasia Conference on IOT, Communication and Engineering (ECICE)’, IEEE, pp. 396–400.
- URL:** <https://ieeexplore.ieee.org/document/10383126/>
- Ojala, T., Pietikainen, M. & Maenpaa, T. (2002), ‘Multiresolution grayscale and rotation invariant texture classification with local binary patterns’, *IEEE Transactions on Pattern Analysis and Machine Intelligence* **24**(7), 971–987.
- Russell, S. J. & Norvig, P. (2016), *Artificial intelligence: a modern approach*, Pearson.
- Sasikumar, M., Ramani, S., Anjaneyulu, K. & Chandrasekar, R. (2007), ‘A Practical Introduction to Rule Based’, (April 2015).
- Sethy, P. K., Barpanda, N. K., Rath, A. K. & Behera, S. K. (2020), ‘Nitrogen Deficiency Prediction of Rice Crop Based on Convolutional Neural Network’, *Journal of Ambient Intelligence and Humanized Computing* **11**(11), 5703–5711.
- URL:** <https://doi.org/10.1007/s12652-020-01938-8>
- Victor A Tuesta Monteza, Heber I Mejia Cabrera, J. A. D. (2023), ‘Coleaf dataset’. Akses pada 12 Juni 2024.
- URL:** <https://data.mendeley.com/datasets;brfgw46wzb/2>
- Vince Ordog, M. Z. (2011), *Plant Physiology*, Taylor and Francis Groups, Asia.

- Watchareeruetai, U., Noinongyao, P., Wattanapaiboonsuk, C., Khantiviriya, P. & Duangsrisai, S. (2018), 'Identification of Plant Nutrient Deficiencies Using Convolutional Neural Networks', *iEECON 2018 - 6th International Electrical Engineering Congress* pp. 1–4.
- Wulandhari, L. A., Gunawan, A. A. S., Qurania, A., Harsani, P., Triastinurmiatiningsih, Tarawan, F. & Hermawan, R. F. (2019), 'Plant nutrient deficiency detection using deep convolutional neural network', *ICIC Express Letters* **13**(10), 971–977.
- Zhang, Y., Zhu, W., Ju, X. & Zhang, Y. (2021), 'Recent advances in texture feature extraction and classification techniques in medical image analysis', *Frontiers in Medicine* **8**, 627204.