



**Pengembangan Model Klasifikasi Ulkus Kornea
Citra Fluorescein pada Penderita Keratitis untuk
Pencegahan Kebutaan Dini**

UJI KLASIFIKASI

INDAH SINTHYA PERMATA SARI
99223126

PROGRAM DOKTOR TEKNOLOGI INFORMASI UNIVERSITAS
GUNADARMA
Juni 2024

Daftar Isi

BAB 1.....	1
PENDAHULUAN.....	1
1.1 Latar Belakang Penelitian.....	1
1.2 Rumusan dan Batasan Masalah.....	7
1.3 Tujuan Penelitian.....	7
1.4 Kontribusi dan Manfaat Penelitian.....	8
BAB 2.....	9
TELAAH PUSTAKA.....	9
2.1 Artificial Intelligence.....	9
2.2 Deep Learning.....	10
2.3 Convolutional Neural Network.....	10
2.3.1 Lapisan Lapisan dalam CNN.....	11
2.4 Resnet V2 50.....	15
2.5 Pengolahan Citra.....	16
2.5.1 Citra Sebagai Himpunan Data 2D.....	17
2.5.2 Ketentuan Citra.....	17
2.5.3 Komponen Sistem Pengolahan Citra.....	19
2.5.4 Garis Besar Teknik Pengolahan Citra.....	20
2.6 Jenis Citra.....	21
2.6.1 Citra Berwarna.....	21
2.6.2 Citra Keabuan.....	23
2.6.3 Citra biner.....	23
2.7 Bidang Aplikasi Pengolahan Citra.....	24
2.7.1 Bidang Kesehatan.....	24
2.8 Citra Medis.....	25
2.9 Kornea.....	27
2.9.1 Inervasi Kornea.....	29
2.10 Pemeriksaan Kornea.....	29
2.10.1 Tes Fluorescein.....	29
2.10.2 Slit-Lamp Biomicroscopy.....	30

2.10.11 Scanning.....	31
2.11 Keratitis.....	31
2.11.1 Keratitis Bakterial.....	32
2.11.2 Keratitis Herpes Zoster.....	32
2.11.3 Keratitis Herpes Simpleks.....	33
2.11.4 Keratitis Fungal.....	33
2.11.5 Keratitis Amoeba.....	34
2.12 Kajian Penelitian.....	34
BAB 3.....	49
METODE PENELITIAN.....	49
3.1 Alur Penelitian.....	49
3.2 Pengumpulan Dataset Citra Mata Fluorescein.....	50
3.3 Preparation Dataset.....	50
3.4 Augmentasi Data.....	52
3.5 Pembentukan dan Pelatihan Model.....	54
3.6 Evaluasi Model.....	55
3.7 Hasil Klasifikasi.....	55
3.8 Time Table.....	55

BAB 1

PENDAHULUAN

1.1 Latar Belakang Penelitian

Kemajuan besar dalam perkembangan teknologi kecerdasan buatan telah ditandai oleh serangkaian pencapaian yang signifikan dalam kemajuan teknologi saat ini. Dalam penggunaan komputer cerdas, *Artificial Intelligence* (Kecerdasan Buatan) dianggap sebagai bidang ilmu komputer yang sangat penting. Penggunaan model matematika dan algoritma, komputer dan sistem lainnya memungkinkan untuk belajar dari data, mengenali pola dan membuat keputusan yang cerdas. Beberapa konsep penting yang dijelaskan dalam bidang ini meliputi *Machine Learning* (Pembelajaran Mesin), *Artificial Neural Network* (Jaringan Saraf Tiruan) dan pemrosesan bahasa alami (Emi Sita E dan Afrizal Zein., 2023).

Machine Learning sebagai salah satu cabang ilmu komputer *Artificial Intelligence*, difokuskan pada penggunaan data dan algoritma untuk ditiru dalam cara belajar manusia dan peningkatan akurasi bertahap. Dikenal sebagai *Deep Learning* (Pembelajaran Mendalam) atau *Artificial Neural Network*. Digunakan secara luas dalam berbagai bidang seperti pengenalan citra, pemrosesan bahasa alami dan pengenalan suara. *Deep Learning* yang merupakan salah satu cabang utama dari bidang *Artificial Intelligence*. Kemajuan besar dalam berbagai aplikasi seperti pengenalan suara, pengenalan wajah, mobil otonom dan kesehatan medis, telah dihasilkan oleh kemampuan ini untuk belajar representasikan data tingkat tinggi. (Emi Sita E et al., 2023).

Artificial Intelligence dapat menjadi salah satu solusi untuk verifikasi diagnosis secara otomatis dengan akurasi tinggi yaitu dengan mengembangkan suatu sistem identifikasi dalam bentuk perangkat lunak untuk mengidentifikasi keratitis kornea berdasarkan penyebabnya. Solusi ini berupa sistem yang dihasilkan melalui *Machine Learning* dengan mengimplementasikan penggunaan *Deep Learning* sebagai alat bantu *skrining* (Qasmieh et al., 2022). *Deep Learning* dalam

bidang kesehatan khususnya dalam bidang kesehatan mata telah memanfaatkan teknologi dalam menganalisis dan mengolah data mulai dari menganalisis gambar medis guna untuk mendeteksi penyakit terutama dalam skrining mata dengan lebih cepat dan akurat. Penerapan teknologi *Deep Learning* telah memfasilitasi pengembangan sistem untuk menganalisis citra mata dengan detail untuk mendeteksi berbagai komponen mata salah satunya kornea.

Kornea dianggap sebagai komponen penting dalam menjaga kualitas penglihatan yang baik. Kornea merupakan selaput bening pada mata yang tembus cahaya dan menutup bola mata di bagian depan. Gangguan pada kornea seperti kerusakan atau kekeruhan yang dapat menyebabkan penurunan penglihatan atau kebutaan jika tidak ditangani dengan tepat, seringkali disebabkan oleh infeksi, cedera fisik atau kondisi medis tertentu. Gejala yang berbeda pada masing-masing lapis kornea dapat disebabkan oleh inflamasi. Kebutuhan yang disebabkan oleh kekeruhan kornea diakui sebagai penyebab kelima tertinggi dengan kontribusi sekitar 3.2% dari total kasus di seluruh dunia. Organisasi kesehatan dunia (WHO) baru-baru ini melaporkan bahwa sekitar 6 juta orang di seluruh dunia terpengaruh oleh kebutaan yang berkaitan dengan kornea, termasuk 2 juta orang yang terpengaruh oleh trakoma. Diperkirakan bahwa 1.5 hingga 2.0 juta kasus kehilangan penglihatan pada mata (kebutaan unilateral) setiap tahunnya disebabkan oleh kondisi tertentu. Hal ini menunjukkan perlu adanya upaya yang lebih besar dan terkoordinasi dalam bidang kesehatan masyarakat untuk dilakukan dalam mencegah, mendeteksi dini dan mengobati kekeruhan kornea (Darren shu et al., 2021).

Penyakit keratitis memiliki beberapa jenis. Keratitis Bakteri terjadi ketika bakteri menginfeksi kornea, penyebab umum termasuk bakteri seperti *staphylococcus aureus* dan *pseudomonas aeruginosa*. Pengobatannya melibatkan penggunaan antibiotik tetes mata. Keratitis Virus jenis ini paling umum disebabkan oleh virus herpes simplex. Pengobatan meliputi antiviral seperti acyclovir. Keratitis Jamur terjadi setelah cedera mata. Penyebab umum disebabkan oleh jamur *Fusarium* dan *Aspergillus*. Pengobatan keratitis jamur menggunakan anti jamur. Keratitis *Acanthamoeba* adalah ameba yang bisa menginfeksi mata. Keratitis Foto-

oksidasi disebabkan oleh kerusakan pada kornea akibat paparan sinar ultraviolet atau refleksi sinar matahari yang intens, seperti yang bisa terjadi saat berada di pantai atau salju tanpaacamata pelindung yang memadai. Keratitis Neurotropik disebabkan ketika terjadi kerusakan saraf kornea, biasanya akibat infeksi virus herpes sebelumnya atau trauma (Radjamin, R.K. Tamin et al., 1998).

Penelitian menggunakan citra *fluorescein* dalam mendeteksi dan mendiagnosis keratitis melalui perkembangan teknik pewarnaan. Uji *fluorescein* merupakan pengujian untuk mengetahui adanya kerusakan epitel kornea akibat erosi, keratitis epitelial dan ulkus kornea. Kertas zat warna *fluorescein* ditempelkan pada fornix inferior selama 20 detik dan pasien diminta untuk berkedip atau menutup mata. Kemudian *fluorescein* dibilas dengan garam fisiologik. Bila terdapat defek (Kelainan) epitel kornea, maka akan terlihat warna hijau. Teknik pewarnaan *fluorescein* sering digunakan bersamaan dengan mikroskopi lampu celah oleh banyak ahli oftalmologi untuk mendiagnosis dan menganalisis keratitis. Keratitis merupakan inflamasi yang terjadi pada kornea dibagi menjadi keratitis infeksi dan noninfeksi berdasarkan etiologinya. Penyebab keratitis infeksi meliputi bakteri, virus, jamur dan protozoa. Beberapa patogen diketahui sebagai penyebab keratitis infeksi (Dina Lestari., 2017).

Teknologi informasi dapat menjadi salah satu solusi yaitu dengan mengembangkan program khusus sebagai alat bantu diagnosis berbasis teknologi informasi. Solusi ini berupa model yang dihasilkan melalui *Machine Learning* sebagai alat bantu skrining, sehingga dapat mengidentifikasi dan mendiagnosis gangguan penglihatan mata akibat keratitis melalui citra yang diambil. Beberapa penelitian terdahulu telah dilakukan terkait pengembangan klasifikasi dan identifikasi keratitis dengan citra *fluorescein*. Penelitian Amit Kumar menggunakan tiga model pembelajaran mendalam dikembangkan untuk mendiagnosis keratitis infeksi menggunakan gambar lampu celah, dan tingkat akurasi yang tinggi dicapai oleh model tersebut. Dengan akurasi 99.3%, model pertama berhasil membedakan antara mata yang sehat dan yang terinfeksi (Amit kumar G., 2021). Penelitian Ayumi ini menentukan probabilitas patogen penyebab pada keratitis

infeksius menggunakan algoritma pembelajaran mendalam difokuskan dan akurasi tinggi di berbagai patogen dicapai (Ayumi et al., 2021).

Penelitian Jan Gross menggunakan algoritma dan ssGSEA untuk menganalisis data, bertujuan untuk CIBERSORT mengembangkan model berbasis pembelajaran mendalam yang mampu mengidentifikasi keratitis bakteri dan jamur menggunakan citra lampu celah. Hasil akurasi yang didapat sebesar 92.73% (Jan Gross et al., 2021). Penelitian Yesheng Xu ini mengidentifikasi dan menganalisis gen yang diekspresikan secara diferensial (DEGs) terkait dengan ferroptosis dalam keratitis *Fusarium* menggunakan teknik bioinformatika dan validasi eksperimental seperti qPCR. Tujuannya adalah untuk memahami mekanisme molekuler penyakit dan menemukan target terapeutik baru. Hasilnya menyediakan wawasan baru tentang peran ferroptosis dalam keratitis *Fusarium* menawarkan potensi strategi pengobatan baru berdasarkan fungsi biologis dan jalur genetik yang terlibat (Yesheng Xu et al., 2021). Penelitian Hiam ini mengembangkan metode otomatis untuk mendiagnosis dan mengklasifikasikan keratitis dengan menggunakan teknik pembelajaran dalam dengan memanfaatkan ekstraksi fitur manual dan otomatis serta berbagai teknik reduksi dimensi, studi ini berhasil mencapai akurasi tinggi dalam mengidentifikasi berbagai pola ulserasi kornea.

Hasilnya menunjukkan efektivitas pendekatan pembelajaran dalam untuk meningkatkan diagnosis dan klasifikasi keratitis. Memberikan kontribusi signifikan pada peningkatan perawatan medis dan kesehatan masyarakat, terutama di daerah terpencil (Hiam a et al., 2022). Penelitian Zijung ini mengembangkan model diagnostik berbasis Pembelajaran Mendalam, KeratitisNet untuk diagnosis dini keratitis infeksius (IK) menggunakan gambar slit-lamp (lampu celah). Model ini merupakan kombinasi dari ResNext101_32x16d dan DenseNet169, berhasil mencapai akurasi tertinggi 77.08% dalam klasifikasi keratitis infeksius termasuk keratitis bakteri, jamur, herpes simplex, dan *Acanthamoeba*. KeratitisNet menunjukkan kinerja yang signifikan lebih baik dalam diagnosis keratitis infeksius dibandingkan dengan dokter mata manusia khususnya dalam membedakan antara berbagai tipe keratitis dengan akurasi dan AUC yang tinggi. Studi ini menekankan potensi penerapan teknologi pembelajaran mendalam pada oftalmologi untuk meningkatkan diagnosis

dan klasifikasi penyakit mata yang kompleks seperti keratitis infeksius (Zijung z et al, 2022).

Penelitian Ming-tse ini menggunakan studi kohort *longitudinal* yang menggunakan CNN (*Convolutional Neural Network*) untuk mengidentifikasi pola dalam data besar dan memprediksi hasil kesehatan. Memanfaatkan CNN dapat menganalisis data citra medis dan variabel terkait kesehatan sepanjang waktu, meningkatkan pemahaman tentang faktor resiko dan mengembangkan intervensi yang lebih tepat (Ming-tse et al., 2023). Penelitian Mohammad menggunakan kecerdasan buatan untuk mendiagnosis keratitis infeksius dan membedakan subtype jamur, dengan akurasi tinggi dalam mengidentifikasi keratitis bakteri dan jamur (Mohammad s et al., 2023). Penelitian Shaodan menyelidiki diagnosis otomatis keratitis infeksius berdasarkan analisis gambar lampu celah, mengevaluasi berbagai model *Deep Learning* untuk akurasi klasifikasi (Shaodan hu et al., 2023). Penelitian Yeo kyoung mengembangkan sistem klasifikasi berbasis pembelajaran mendalam untuk keratitis bakteri dan jamur menggunakan gambar segmen anterior, meningkatkan akurasi diagnostik dengan *Lesion Guiding* dan *Mask Adjusting Modules* (Yeo kyoung et al., 2023).

Pada beberapa kasus keratitis kornea, kesalahan verifikasi diagnosis penyebab mengakibatkan kesalahan dalam pemberian obat yang dapat berujung pada kebutaan permanen. Pada beberapa Penelitian terdahulu, sistem yang dibentuk hanya mengacu pada satu jenis penyebab infeksi, misalnya bakteri (Ghosh AK et al., 2021), virus dengan satu jenis virus yaitu Herpes Simpleks Virus (Koyama A et al., 2021) dan pada beberapa penelitian terdahulu (Ghosh AK et al., 2021) (Koyama A et al., 2021) terlihat akurasi identifikasi yang tidak mencapai *excellent identification*. Pada penelitian (Ghosh AK et al., 2021) (Koyama A et al., 2021) tidak melakukan evaluasi proses pelatihan dengan cara menganalisis akurasi dan *loss* pada model *deep learning* sehingga akurasi identifikasi keratitis memiliki *loss* hampir mencapai 30%. Akurasi dan *loss* menjadi penting untuk dianalisis, untuk mengetahui perkembangan dari sistem selama proses pelatihan dan mengetahui sistem telah mampu membaca pola dari data.

Penelitian (Xu Y et al., 2021) membagi area lesi keratitis kedalam beberapa area dengan mengikuti bentuk kornea seperti cincin melingkar juga dapat mengakibatkan sistem mengalami kesalahan identifikasi mengingat terdapat berbagai macam bentuk tepi, variasi warna dan karakteristik dari keratitis, bukan hanya berbentuk bulat (Cabrera-Aguas M., 2023). Keratitis dengan Ulkus berbentuk cakram dengan tepi berwarna kuning keabu-abuan seperti pada infeksi keratitis bakteri (Ghosh AK et al., 2021). Karakteristik Lesi terlihat agak kering, berbatas seperti garis tegas *irregular* dengan bercak putih keabu-abuan, dan terdapat penyebaran pada keratitis Jamur. Karakteristik keratitis dengan penyebab virus dapat berbentuk (Cabrera-Aguas M et al., 2022) : Keratitis epitelial punggata (keratitis jenis herpes zoster) bentuk bintik-bintik mengumpul di satu lokasi pada kornea, Ulkus epitelial mikro dendritik dengan bentuk tepi *irregular*, Keratitis numularis dengan bentuk bulat kecil lebih besar dari diameter pada keratitis epitelial punggata yang berkelompok dan Keratitis disciform dengan bentuk bulat besar hampir menutupi area kornea. Penentuan area lesi keratitis yang tidak didasarkan pada morfologi dasar keratitis pada penyebabnya (Bakteri, Jamur atau Virus) dapat menyebabkan hilangnya informasi dari objek yang dideteksi, sehingga hasil pembentukan sistem identifikasi dapat mengakibatkan *loss* yang cukup tinggi. Pembentukan sistem klasifikasi ulkus kornea pada penderita keratitis membutuhkan pelatihan arsitektur sistem klasifikasi ulkus kornea pada penderita keratitis dengan beberapa parameter yang berperan penting sebagai faktor sistem agar dapat mencapai nilai bobot yang optimal. Pada penelitian terdahulu, optimasi parameter hanya dilakukan menggunakan nilai bobot tertentu sesuai dengan dataset masukan, sehingga pada beberapa hasil pengujian untuk citra mata dengan keratitis sulit dilakukan identifikasi berdasarkan penyebab. Pada penelitian ini diusulkan penggunaan lokalisasi berbasis gradien untuk mendeteksi variasi tepi keratitis berdasarkan penyebabnya (Virus, Bakteri, dan Jamur) dan *Deep Learning*. Secara waktu, tentunya hal ini akan mempercepat proses pelatihan terhadap dataset dan memberikan akurasi ketepatan identifikasi keratitis kornea. Kebaruan dilakukan juga pada pembentukan arsitektur sistem identifikasi, dengan optimasi perubahan nilai *learning rate* secara dinamis berbasis *Cosine Learning Rate Decay*

menggunakan CNN yang mengimplementasikan pembobotan ulang pada fungsi *loss*. Hasil penelitian ini diharapkan untuk dapat memberikan pengobatan yang tepat sesuai dengan penyebab keratitis kornea untuk menghindarkan kebutaan dini.

1.2 Rumusan dan Batasan Masalah

Rumusan masalah dalam penelitian ini adalah:

1. Bagaimana mengembangkan sebuah model identifikasi keratitis kornea berbasis CNN yang dapat secara akurat membedakan penyebab infeksi keratitis (bakteri, virus dan jamur).
2. Bagaimana membangun sebuah sistem identifikasi keratitis kornea yang disebabkan oleh infeksi bakteri, virus dan jamur sehingga dapat membantu pihak medis melakukan pengobatan secara efisien.

Batasan masalah dalam penelitian ini:

1. Pada penelitian ini data yang digunakan terdiri dari 712 citra fluoresein. Bersifat sekunder yang diperoleh dari dataset publik. Bersumber: <https://doi.org/10.6084/m9.figshare.11371803.v2>.
2. Penelitian ini hanya menggunakan data citra kornea yang telah diidentifikasi dengan infeksi bakteri, virus dan jamur.

1.3 Tujuan Penelitian

Berdasarkan permasalahan yang diuraikan penelitian ini bertujuan:

1. Menghasilkan sebuah model CNN untuk mengidentifikasi dan mengklasifikasikan penyakit keratitis berdasarkan penyebabnya (bakteri, virus dan jamur).
2. Menghasilkan sistem klasifikasi ulkus kornea pada penderita keratitis yang terintegrasi dengan model CNN yang dikembangkan untuk membantu tenaga medis dalam mengenali keratitis bakteri, virus dan jamur. Sistem ini diharapkan dapat memfasilitasi proses diagnosis yang lebih cepat dan tepat, sehingga

memungkinkan penerapan pengobatan yang lebih efisien berdasarkan jenis infeksi pasien.

1.4 Kontribusi dan Manfaat Penelitian

a. Keilmuan

1. Memperkaya literatur keilmuan dengan pengetahuan baru mengenai aplikasi pembelajaran mesin dalam diagnosis keratitis, menawarkan perspektif baru dalam pemahaman kondisi kornea dan pengaruhnya terhadap kesehatan mata.
2. Menyediakan dasar bagi penelitian lebih lanjut dalam penggunaan teknologi canggih untuk diagnosa penyakit mata dan mendorong inovasi berkelanjutan dalam bidang oftalmologi.

b. Inovasi dan Teknologi

Kontribusi dalam pengembangan teknologi pembelajaran mesin yang lebih akurat dan efisien dalam mendiagnosis keratitis sehingga meningkatkan kemampuan prediksi dan klasifikasi penyakit mata.

c. Manfaat

Diharapkan penelitian ini dapat membantu dalam deteksi awal dan diagnosa dini untuk mencegah kebutaan dini akibat keratitis sehingga dapat meningkatkan kualitas hidup pasien.

BAB 2

TELAAH PUSTAKA

2.1 Artificial Intelligence

Kecerdasan Buatan atau *Artificial Intelligence* (AI) adalah teknik yang digunakan untuk meniru kecerdasan yang dimiliki oleh makhluk hidup maupun benda mati untuk menyelesaikan sebuah persoalan. Untuk melakukan hal ini, setidaknya ada tiga metode yang dikembangkan (Abu Ahmad 2017).

1. *Fuzzy Logic* (FL). Teknik ini digunakan oleh mesin untuk mengadaptasi bagaimana makhluk hidup menyesuaikan kondisi dengan memberikan keputusan yang tidak kaku 0 atau 1. Sehingga dimunculkan sistem logika *fuzzy* yang tidak kaku. Penerapan logika *fuzzy* ini salah satunya adalah untuk sistem pengereman kereta api di Jepang.
2. *Evolutionary Computing* (EC). Pendekatan ini menggunakan skema evolusi yang menggunakan jumlah individu yang banyak dan memberikan sebuah ujian untuk menyeleksi individu terbaik untuk membangkitkan generasi selanjutnya. Seleksi tersebut digunakan untuk mencari solusi dari suatu permasalahan. Contoh dari pendekatan ini adalah Algoritma Genetika yang menggunakan ide mutasi dan kawin silang, *Particle Swarm Optimization* (PSO) yang meniru kumpulan binatang seperti burung dan ikan dalam mencari mangsa, *Simulated Annealing* yang menirukan bagaimana logam ditempa, dan masih banyak lagi.
3. *Machine Learning* (ML) atau pembelajaran mesin merupakan teknik yang paling populer karena banyak digunakan untuk menggantikan atau menirukan perilaku manusia untuk menyelesaikan masalah. Sesuai namanya ML mencoba menirukan bagaimana proses manusia atau makhluk cerdas belajar dan menggeneralisasi.

2.2 Deep Learning


Deep Learning adalah bagian dari *Artificial Intelligence* dan *machine learning* yang merupakan pengembangan dari *neural network multiple layer* untuk memberikan ketepatan tugas seperti deteksi objek, pengenalan suara, terjemahan bahasa dan lain-lain. *Deep Learning* berbeda dari teknik *machine learning* yang tradisional, karena *deep learning* secara otomatis melakukan representasi dari data seperti gambar, video atau text tanpa memperkenalkan aturan kode atau pengetahuan domain manusia (Pumsirirat, 2018). *Deep learning* adalah seperangkat algoritma dalam *machine learning* yang berusaha belajar dalam berbagai level, sesuai dengan tingkat abstraksi yang berbeda, ini biasanya menggunakan jaringan syaraf tiruan, tingkat dalam model statistik yang dipelajari ini sesuai dengan tingkat konsep yang berbeda, di mana konsep tingkat yang lebih tinggi ditentukan dari tingkat yang lebih rendah, dan konsep tingkat yang lebih rendah dapat membantu untuk mendefinisikan banyak konsep tingkat yang lebih tinggi. *Deep Learning* adalah jaringan sarafnya dilatih dengan cara penurunan gradien secara sederhana, pada saat kita menambahkan lapisan jaringan yang semakin banyak, maka sebaliknya penurunan dari gradien semakin berkurang sehingga dapat mempengaruhi nilai outputnya (Abdul Raup et al, 2022).

2.3 Convolutional Neural Network

Jaringan saraf konvolusi atau *Convolutional Neural Network* (CNN) adalah jenis model dalam pembelajaran mendalam yang dikembangkan untuk mengolah data yang berpola grid, seperti gambar. Model ini dirancang secara otomatis dan adaptif mempelajari hierarki fitur spasial, mulai dari tingkat paling dasar hingga pola yang lebih kompleks (Yamashita, Nishio, Do & Togashi, 2018). CNN terdiri dari neuron yang bobot dan biasanya dapat dipelajari. Dalam lapisan-lapisan CNN, neuron disusun dalam beberapa dimensi yaitu saluran (*channels*), lebar (*width*), tinggi (*height*), dan jumlah filter untuk kasus dua dimensi yang paling sederhana. Oleh serangkaian lapisan, aktivasi atau output dari lapisan sebelumnya

ditransformasikan melalui fungsi diferensial lain dalam jaringan saraf konvolusi (Teuwena & Moriakov, 2019).

Dalam CNN, peranan penting dimainkan oleh lapisan konvolusi dan lapisan penggabungan dalam mengekstraksi fitur dari data masukan. Fitur-fitur penting dari data, seperti tepi, sudut, atau tekstur, diekstraksi menggunakan filter oleh lapisan konvolusi, sedangkan lapisan penggabungan berfungsi untuk mereduksi dimensi spasial dari fitur-fitur yang telah diekstraksi, dengan demikian mempertahankan informasi yang relevan dan mengurangi *overfitting*. Lapisan yang terhubung sepenuhnya bertugas memetakan fitur yang telah diekstraksi ke dalam keluaran akhir, seperti dalam tahap klasifikasi. Informasi fitur yang ada diserap secara menyeluruh oleh keterhubungan penuh antara setiap neuron di lapisan ini dengan semua neuron di lapisan sebelumnya, sehingga prediksi atau klasifikasi yang akurat dapat dihasilkan sesuai dengan tujuan dari model CNN (Yamashita et al., 2018).



Gambar 2.1 Arsitektur dan proses pelatihan CNN (Yamashita et al., 2018)

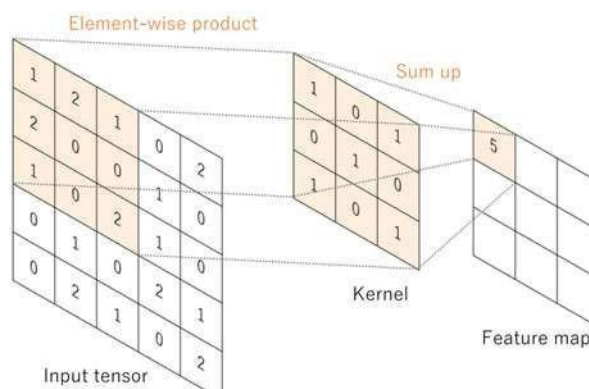
2.3.1 Lapisan Lapisan dalam CNN

Arsitektur CNN terdiri dari beberapa lapisan yang berperan penting dalam pengolahan informasi. Setiap lapisan dalam CNN dijelaskan secara rinci di bawah ini.

1. Lapisan Konvolusi

Konvolusi adalah jenis operasi yang meliputi operasi linier dan nonlinier, termasuk operasi konvolusi dan fungsi aktivasi. Lapisan konvolusi, yang merupakan elemen kunci dalam struktur CNN, digunakan untuk mengekstraksi fitur penting dari gambar, seperti tepi, sudut, atau tekstur. Dalam operasi konvolusi, kernel yang merupakan matriks kecil, digeser secara bertahap ke seluruh area

gambar. Perkalian antara elemen-elemen kernel dengan nilai-nilai yang sesuai pada gambar dilakukan di setiap posisi. Oleh operasi konvolusi, data input yang berupa array angka, yang dikenal sebagai tensor, diproses. Pada setiap titik tensor input, dihitung perkalian antara setiap elemen dalam kernel dan nilai pada titik yang sama dalam tensor input, dan kemudian hasilnya dijumlahkan untuk mendapatkan nilai pada tensor output yang disebut sebagai peta fitur, seperti yang diilustrasikan pada Gambar 2.2. Peta fitur, yang merupakan hasil dari operasi konvolusi, merupakan representasi dari fitur-fitur relevan dalam data input. Peta fitur ini mengandung informasi tentang pola-pola penting seperti tepi, sudut, atau tekstur di dalam gambar. Dua parameter utama yang mempengaruhi operasi konvolusi adalah ukuran kernel dan jumlah kernel. Kernel biasanya memiliki ukuran 3×3 , namun terkadang bisa 5×5 atau 7×7 . Jumlah kernel, yang bisa bervariasi, menentukan kedalaman peta fitur yang dihasilkan.

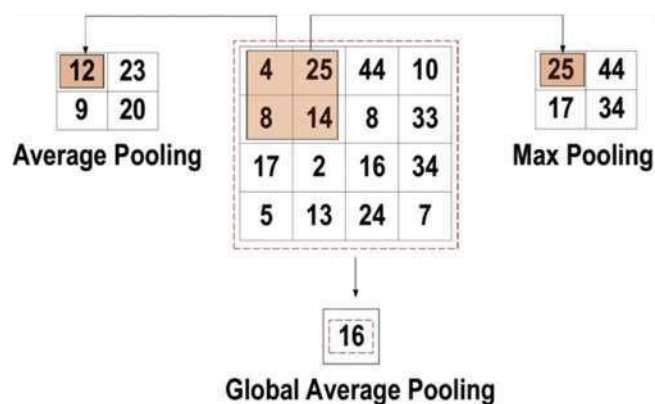


Gambar 2.2 Operasi Konvolusi

2. Lapisan Pengumpulan

Lapisan Pengumpulan ditugaskan untuk melakukan subsampling dari peta fitur yang telah dihasilkan melalui operasi konvolusi sebelumnya. Tujuan dari pendekatan ini adalah untuk mengurangi ukuran peta fitur yang besar menjadi lebih kecil, sambil mempertahankan sebagian besar informasi atau fitur dominan pada setiap langkah pengumpulan. Berbagai metode pengumpulan telah tersedia, seperti pengumpulan pohon (tree pooling), pengumpulan berpintu (gated pooling), pengumpulan rata-rata (average pooling), pengumpulan minimum (min pooling), pengumpulan maksimum (max pooling), pengumpulan rata-rata global (global average pooling) (GAP), dan pengumpulan maksimum global (global max).

pooling), yang masing-masing memiliki karakteristik khusus dan diaplikasikan berdasarkan kebutuhan aplikasi dan tujuan pengolahan data yang diinginkan. Pengumpulan maksimum sering digunakan untuk mengekstraksi fitur yang paling dominan dari suatu area, sementara pengumpulan rata-rata diaplikasikan untuk meratakan nilai-nilai piksel dalam area tersebut. Pengumpulan global (GAP) merupakan metode yang kerap digunakan untuk merangkum fitur dari seluruh peta fitur. Dikenal dan sering diaplikasikan adalah metode pooling maksimum (max), minimum (min), dan rata-rata global (GAP).



Gambar 2.3 Operasi Pengumpulan

3. Fungsi Aktivasi

Fungsi aktivasi dalam CNN adalah mekanisme matematis non-linear yang digunakan untuk menentukan apakah neuron dalam jaringan tersebut harus "aktif" atau tidak, berdasarkan masukan yang diterima. Mekanisme ini serupa dengan fungsi saklar yang mengaktifkan neuron ketika masukan mencapai ambang batas tertentu, menghasilkan keluaran. Di setiap neuron dalam arsitektur CNN, fungsi aktivasi ditugaskan untuk mengidentifikasi keberadaan fitur spesifik dalam masukan. Sebagai contoh, sinyal yang lebih tinggi akan dihasilkan oleh fungsi aktivasi jika sudut tertentu, yang terhadapnya neuron sensitif, terdeteksi dalam gambar.

Setelah lapisan dengan bobot yang dapat dipelajari, seperti lapisan terhubung penuh (FC) dan lapisan konvolusi, fungsi aktivasi non-linear diterapkan. Penerapan fungsi aktivasi non-linear ini memungkinkan pemetaan dari masukan ke keluaran menjadi lebih kompleks dan tidak linear, menunjukkan bahwa jaringan dapat

mengerti hubungan antara fitur-fitur masukan yang lebih kompleks dibandingkan hanya dengan fungsi linear sederhana. Berbagai jenis fungsi aktivasi yang umum digunakan dalam CNN dan jaringan saraf mendalam lainnya termasuk dalam kategori ini.

- Fungsi aktivasi sigmoid dikarakterisasi oleh kemampuannya untuk menerima input dari seluruh rentang bilangan riil, termasuk nilai negatif dan positif. Selama transformasi dilakukan menggunakan fungsi sigmoid, nilai-nilai input tersebut dikonversi menjadi output yang dibatasi antara 0 dan 1. Bentuk kurva dari fungsi sigmoid mirip dengan huruf 'S' dan dapat dinyatakan secara matematis melalui persamaan 2.1.

$$f(x)^{sigm} = \frac{1}{1+e^{-x}} \quad (2.1)$$

- Fungsi aktivasi tangen hiperbolik (tanh) dikenali karena kemiripannya dengan fungsi sigmoid dalam menerima input yang berupa bilangan riil. Perbedaan utamanya terletak pada kisaran output fungsi tanh, yang dibatasi antara -1 dan 1. Representasi matematis dari fungsi tangen hiperbolik dapat diungkapkan melalui persamaan 2.2.

$$f(x)^{tanh} = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (2.2)$$

- Rectified Linear Unit (ReLU) diidentifikasi sebagai fungsi yang paling sering digunakan dalam CNN. Dalam fungsi ini, semua nilai input diubah menjadi bilangan positif. Salah satu keuntungan utama dari ReLU dibandingkan dengan fungsi aktivasi lain adalah beban komputasinya yang lebih rendah. Dalam bentuk matematis, ReLU dapat direpresentasikan oleh persamaan 2.3.

$$f(x)_{ReLU} = \max(0, x) \quad (2.3)$$

- Fungsi aktivasi Leaky ReLU dibedakan dari ReLU standar yang tidak memperhitungkan input negatif. Pada Leaky ReLU, input negatif diperkenankan dengan cara dikalikan dengan gradien kecil m . Hal ini

dimaksudkan untuk mengatasi masalah "Dying ReLU," di mana neuron bisa terkunci pada nilai nol selama pelatihan. Persamaan 2.4 dapat dilihat sebagai representasi matematis dari fungsi Leaky ReLU.

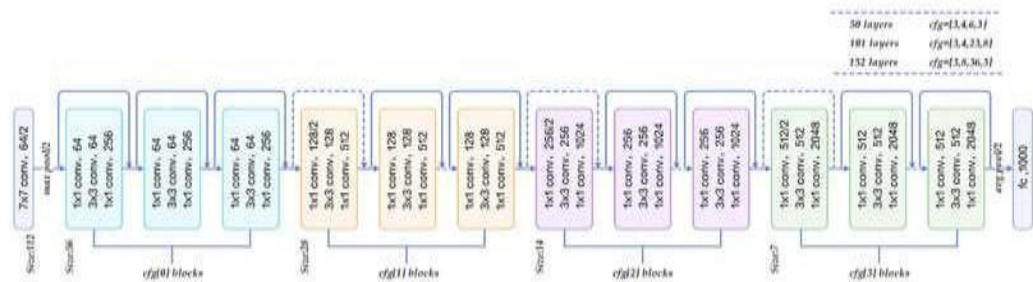
$$f(x)_{LeakyReLU} = \begin{cases} x, & \text{if } x > 0 \\ mx, & \text{if } x \leq 0 \end{cases} \quad (2.4)$$

4. Lapisan Terhubung Penuh

Lapisan *Fully Connected* (FC Layer) biasanya ditempatkan pada posisi akhir dalam arsitektur CNN dan bertugas untuk melakukan klasifikasi. Operasi FC mirip dengan jaringan saraf maju konvensional, di mana input untuk setiap neuron diperoleh dari semua output lapisan sebelumnya. Input untuk FC biasanya diperoleh dari lapisan pooling atau lapisan konvolusi terakhir dalam CNN. Penyelarasan dimensi data dilakukan dengan meratakan atau mengubah matriks output menjadi vektor satu dimensi, proses yang sering disebut sebagai "*flattening*". Output dari FC Layer kemudian diinterpretasikan sebagai hasil klasifikasi akhir dari CNN (Purwono et al., 2022).

2.4 Resnet V2 50

Residual Network (ResNet) merupakan salah satu arsitektur dari CNN. Konsep *residual learning* diperkenalkan dalam model ini melalui penambahan *shortcut connections* yang melompati satu atau lebih lapisan konvolusi. ResNet-50, yang merupakan salah satu varian dari ResNet, terdiri dari 50 lapisan. ResNet-50 mengandung 5 tahapan konvolusi utama. Di dalam setiap tahapan konvolusi pada ResNet, terdapat beberapa blok residual. Dalam setiap blok residual, terdapat tiga lapisan konvolusi (1x1, 3x3, 1x1) yang seringkali disebut sebagai lapisan bottleneck. Contoh dari blok ResNet-50 dapat dilihat pada gambar di bawah ini.



Gambar 2.4. Blok Resnet50

2.5 Pengolahan Citra

Arti pengolahan menurut kamus besar Bahasa Indonesia (KBBI) adalah suatu cara atau proses mengolah sesuatu supaya menjadi lain atau menjadi lebih sempurna. Sedangkan citra menurut KBBI berarti rupa atau gambar, dalam hal ini adalah gambar yang diperoleh menggunakan sistem visual. Secara keseluruhan pengolahan citra berarti suatu cara mengolah suatu citra menjadi citra lain yang lebih sempurna atau yang diinginkan. Dengan kata lain, pengolahan citra adalah suatu proses dengan masukan citra dan menghasilkan keluaran berupa citra seperti yang dikehendaki. Citra menurut kamus Webster berarti representasi, kemiripan atau imitasi dari suatu objek. Sebagai contoh foto sebuah apel mewakili identitas buah apel tersebut di depan sebuah kamera. Citra dapat berupa hasil fotografi, lukisan, atau gambaran serta corat-coret yang terjadi di kertas, kanvas, dan di layar monitor. Dapat dikatakan juga citra merupakan sebaran variasi gelap-terang, redup-cerah dan warna-warni di suatu bidang datar. Formalitas pengungkapan dengan angka angka yang merepresentasikan variasi intensitas kecerahan atau/dan warna pada arah mendatar dan tegak. Pada Gambar 1.3 diperlihatkan contoh-contoh citra yang telah menjadi objek pengolahan citra yang menarik (Sri Ratna S et al, 2016).


2.5.1 Citra Sebagai Himpunan Data 2D

Data Citra ditangkap oleh mata sebagai gambar. Meskipun Mata dapat melihat langsung objek atau pemandangan tanpa alat, rekaman yang terjadi di dalam otak bersifat Relatif dan Subjektif. Dikatakan relatif karena hanya dapat mengingat bagian-bagian yang lebih terang dan lebih gelap sedangkan sifat subjektif Karena dilatarbelakangi pengalaman dan harapan yang berbeda dari orang ke orang lain. Maka diperlukan alat untuk menangkap dan menyimpan Citra secara objektif, yaitu yang dapat disajikan berdasar suatu sistem ukuran yang baku. Sebelum ada kamera sebagai penangkap citra dan film untuk merekamnya, “citra” dibuat oleh pengikutnya dengan menggambar di “media datar”. Tanda petik dimaksud untuk lebih menonjolkan sifat subjektif dengan saran yang masih primitif, seperti yang dilakukan di awal sejarah manusia. Dengan kamera aspek subjektif dapat diminimumkan dan medium rekaman praktis datar sempurna. Dengan demikian objektivitas data citra dapat dikukuhkan melalui suatu proses pembakuan atau standarisasi yang telah disepakati bersama. Secara rinci data citra terdapat pada masing-masing unsur citra, yang dengan Kamera Analog berupa piksel yang tidak teratur dalam posisi dan beragam dalam ukuran. Pada film dengan angka ASA tinggi, ukuran piksel rerata tinggi dan sebaliknya pada ASA rendah piksel berukuran kecil-kecil. Sifat visual yang jelas ASA tinggi lebih peka tetapi terlihat kasar, sedang ASA rendah kurang peka tetapi tampil halus sehingga lebih kaya detail (Sri Ratna S et al, 2016).

2.5.2 Ketentuan Citra


Bila variabel x untuk posisi pada arah horizontal dan y untuk vertical, citra disajikan sebagai $f(x, y)$. Penyesuaian dengan proses pengolahan di komputer, versi diskrit citra adalah $f(m, n)$, dengan m dan n menjadi nomor urut posisi, yang secara umum $m = 0, 1, 2, \dots, M-1$ dan $n = 0, 1, 2, \dots, N-1$. Dengan demikian ada sebanyak $M \times N$ posisi diskret, yang menjadi ukuran ketelitian data citra. Di setiap posisi (m, n) terletak detail yang selanjutnya disebut unsur gambar atau picture element yang disingkat menjadi pel, pixel atau piksel. Representasi citra digital diperlihatkan

pada Gambar 2.1. Terdapat perbedaan cara menyatakan posisi titik antara koordinat pada citra dengan koordinat grafik (kartesian). Gambar 2.2 memperlihatkan perbedaan letak titik (0,0) antara koordinat pada citra dengan koordinat kartesian.



Gambar 2.5 Representasi Citra Digital (Sumber: Sri Ratna S et al, 2016)


Meskipun besar M dan N dapat sembarang, lazim juga $M = N$ sebagai format bujur-sangkar atau square. Untuk kesederhanaan komputasi, khususnya yang melibatkan Alihragam atau Transform, besar M dan N merupakan angka 2 (dua) pangkat bilangan bulat, yaitu: 2, 4, 8, 16, 32, 64, dst. Bila citra asli berukuran $M \times N$ sembarang, untuk kepraktisannya dapat dilakukan pembagian atau pemotongan, atau cropping dalam ukuran yang lebih kecil, agar lebih praktis untuk diolah atau/dan sesuai fokus tujuan pengolahan (Gambar 2.3). Komputer mengolah data citra secara digital, maka citra yang semula bersifat analog, yaitu dapat bernilai kecerahan sembarang sesuai sifat asli objek, diubah menjadi data terkuantisasi, yaitu hanya pada nilai-nilai bulat tertentu (diskrit). Standar umum adalah sebanyak 256 aras (level) intensitas, dengan sandi atau kode biner sebanyak 8 digit (bit) atau 1 byte. Untuk ketelitian dapat lebih banyak dari 256 aras, dan sebaliknya dapat pula lebih sedikit bila telah mencukupi. Pengertian ketelitian dan mencukupi berhubungan dengan kuantitas dan kualitas informasi yang diharapkan dari hasil Pengolahan. Untuk ini perlu ada pemahaman mengenai makna Informasi secara kualitatif.



(a) Koordinat pada Citra

(b) Koordinat Kartesian

Gambar 2.6 Perbedaan Letak Titik Asal (0,0) pada Koordinat Citra dengan Koordinat Kartesian (Sumber: Sri Ratna S et al, 2016)



Gambar 2.7 Gambaran Formal Ukuran Citra Asli dan Pembagian Ke dalam Bagian-Bagian yang Lebih Kecil (Sumber: Sulistiyanti, 2011)

2.5.3 Komponen Sistem Pengolahan Citra

Peralatan fotografi merupakan sarana pendigitalan citra yang telah lama dikenal dan paling banyak dipakai. Dalam satu dekade terakhir keberadaan Kamera Digital makin dominan, termasuk yang telah menyatu di HP atau telepon seluler. Dengan demikian akses data citra ke sarana pengolahan makin mudah. Kamera digital merupakan salah satu komponen dalam sistem pengolahan citra. Kamera digital termasuk ke dalam sensor citra, didalamnya terdapat sensor yang menghasilkan keluaran listrik yang sebanding dengan intensitas cahaya dan terdapat pula digitizer yang mengubah keluaran elektrik menjadi data digital. Citra digital dapat diperoleh tidak hanya menggunakan alat yang menggunakan sensor penangkap intensitas cahaya saja tetapi citra dapat juga diperoleh menggunakan sensor lainnya. Selain Kamera Digital yang telah digunakan secara umum, telah banyak pula digunakan system-sistem pencitraan yang lain seperti Sinar Gamma, Sinar-X,

Ultraviolet, Inframerah, Gelombang-Mikro, Bidang Frekuensi Radio, Ultrasonik, dan lain-lain. Pengambilan citra Sinar-X juga telah berbentuk digital, dan bahkan telah dilengkapi pula dengan fasilitas peningkatan mutu citra untuk kemudahan perolehan informasi yang diharapkan. Bahkan citra hasil pencitraan ultrasonic telah berbentuk citra 4D dengan tingkat keakuratan yang tinggi (Sri Ratna S et al, 2016).

2.5.4 Garis Besar Teknik Pengolahan Citra

Hasil Perolehan Citra, disamping langsung disimpan di sarana pengolahan, juga dapat langsung diolah-awal (preprocessing) untuk penyesuaian dengan langkah pengolahan selanjutnya. Tahap penyimpanan juga dapat terkait dengan format data yang pas dan efisien untuk kekhususan pengolahan-awal tersebut. Pengolah-awal ini dapat sekedar melakukan cropping atau pengambilan sebagian citra dan atau penapisan (filtering) untuk “membersihkan” yang dinilai tidak mengandung informasi. Poin terpenting dalam pengolahan citra adalah manipulasi dan analisis sebuah citra dilakukan dengan bantuan komputer. Secara garis besar pengolahan citra dikelompokkan menjadi 2 jenis kegiatan: (a) Memperbaiki kualitas citra agar lebih mudah diinterpretasikan. (b) Mengolah informasi pada citra untuk keperluan yang diinginkan biasanya untuk mengenali pola suatu objek. Secara umum tahapan pengolahan citra digital meliputi akuisisi citra, peningkatan kualitas citra, segmentasi citra, representasi dan uraian, pengenalan dan interpretasi (Sri Ratna S et al, 2016).

1. Tahap pertama dalam pengolahan citra adalah akuisisi citra. Akuisisi citra berfungsi untuk mengambil, mengumpulkan serta menyiapkan data citra menggunakan alat perekaman citra dan memprosesnya sehingga menghasilkan data yang dikehendaki. Alat perekam citra yang dapat digunakan antara lain kamera video, kamera konvensional, kamera digital, *scanner* dan lain-lain. Jika citra yang dihasilkan masih dalam bentuk analog maka perlu didigitalkan menggunakan digitizer.
2. Tahap peningkatan citra dikenal juga sebagai tahap pre-processing. Dalam tahap ini dilakukan peningkatan kecerahan, pengubahan kontras, menghilangkan noise, transformasi geometri, dan penentuan bagian citra yang

dibutuhkan untuk diolah lebih lanjut. Tujuan tahap ini adalah untuk meningkatkan kemungkinan keberhasilan dalam proses pengolahan citra tahap berikutnya.

3. Tahap pemulihan citra berbeda dengan tahap peningkatan citra. Tahap peningkatan citra lebih bersifat subjektif artinya lebih dipengaruhi oleh kehendak manusia sedangkan tahap pemulihan citra bersifat objektif yang cenderung didasarkan pada model probabilitas atau matematis dari degradasi citra. Artinya pemulihan citra bertujuan untuk mengembalikan citra ke citra aslinya.
4. Tahap segmentasi citra merupakan tahap lanjut dalam pengolahan citra. Tujuan tahap ini adalah untuk membagi citra menjadi bagian-bagian pokok yang mengandung informasi penting, contoh aplikasinya adalah untuk memisahkan antara objek dengan latar belakang. Segmentasi citra secara otomatis merupakan tugas yang paling sulit dalam pengolahan citra digital. Keakuratan proses segmentasi citra akan mempengaruhi keberhasilan dalam tugas pengenalan objek.
5. Tahap representasi dan deskripsi mengikuti keluaran dari tahap segmentasi yang biasanya berupa data citra mentah yang merupakan salah satu batas suatu wilayah. Data citra ini berupa runtunan titik-titik koordinat kurva tertutup dengan deskripsi luasan dan parameternya. Proses selanjutnya adalah deteksi ciri dan ekstraksi ciri yang hasilnya dapat digunakan untuk proses akhir dari pengolahan citra yaitu analisis citra.

2.6 Jenis Citra

Citra dapat diklasifikasikan berdasarkan karakteristik kontennya atau atribut visualnya menjadi citra berwarna, citra keabuan, dan citra biner.

2.6.1 Citra Berwarna

Secara visual, informasi warna dalam citra direpresentasikan dalam bentuk piksel yang memiliki komponen luminansi, hue, dan chrominance atau saturasi. Luminansi, yang mengacu pada kecerahan warna, dapat diatur agar warna menjadi

lebih terang atau lebih gelap. Hue, sifat utama dari warna, diukur dalam derajat (0° - 360°). Misalnya, nilai hue untuk merah adalah 0° atau 360° , sedangkan hijau diukur pada 120° , dan kuning, yang merupakan kombinasi dari merah dan hijau, memiliki hue 60° , demikian pula dengan warna lainnya. Chrominance atau saturasi menggambarkan tingkat kejenuhan warna. Semakin tinggi nilai chrominance, semakin tinggi kejenuhan atau kemurnian warna. Sebagai contoh, warna biru dengan saturasi 100% dihasilkan dari kombinasi tiga warna dasar: merah (*Red*), hijau (*Green*), dan biru (*Blue*).



Gambar 2.8 Citra berwarna dengan ukuran 300 x 500 piksel (Madenda, 2015).

Dalam Gambar 2.8, sebuah citra berwarna dengan ukuran piksel 300 x 500 digambarkan, memiliki 300 baris (N) dan 500 kolom (M). Fungsi matriks tiga dimensi $f(n,m,k)$ secara matematis dapat merepresentasikan citra berwarna tersebut, di mana n merupakan indeks untuk baris, m untuk kolom yang merepresentasikan posisi koordinat piksel, dan k sebagai indeks yang menggambarkan komponen warna, termasuk merah (*Red*), hijau (*Green*), dan biru (*Blue*). Pendekatan ini memungkinkan setiap elemen matriks untuk menggambarkan intensitas warna pada lokasi piksel tertentu dalam citra. Aplikasi dalam pemrosesan citra berwarna dapat diterapkan menggunakan berbagai ruang warna. Ruang warna RGB, yang umum digunakan untuk tampilan di layar monitor, merupakan salah satu dari beberapa pilihan ruang warna yang tersedia. Ruang warna lainnya seperti CMYK sering digunakan untuk dokumen yang akan dicetak dengan printer berwarna. YCbCr sering kali diterapkan dalam aplikasi kompresi

citra. Untuk proses segmentasi warna, beberapa ruang warna yang umumnya digunakan termasuk HSV, HSL, Lab, dan HCL.

2.6.2 Citra Keabuan

Citra gray-level, yang juga disebut citra skala keabuan, terdiri dari nilai piksel yang merepresentasikan nilai luminance dan dikodekan dalam 8 bit. Rentang nilai piksel ini berada dari 0 hingga 255 ($2^8 - 1$), di mana nilai 0 merepresentasikan warna hitam dan nilai 255 merepresentasikan warna putih. Nilai-nilai yang berada di antara kedua ekstrem tersebut menggambarkan berbagai tingkat keabuan yang bervariasi hingga mencapai tingkat kecerahan warna putih. Citra skala keabuan dapat dihasilkan dari transformasi ruang warna RGB ke ruang warna lain seperti HSV, HSL, Lab, YCbCr, atau HCL. Komponen Y, V, atau L dari ruang warna tersebut sering digunakan untuk mendeskripsikan citra skala keabuan. Misalnya, sebuah citra skala keabuan yang memiliki 256 tingkat kecerahan dan ditunjukkan dalam Gambar 2.9, dihasilkan dari transformasi RGB yang ditunjukkan dalam Gambar 2.8 menggunakan YCbCr.



Gambar 2.9 Citra gray-level dengan ukuran 300 x 500 piksel (Madenda, 2015).

2.6.3 Citra biner

Citra biner adalah jenis citra keabuan yang hanya terdiri dari dua tingkat kecerahan: hitam dengan nilai 0 dan putih dengan nilai 1, dengan setiap pikselnya

dikodekan menggunakan 1 bit. Dalam proses pengolahan citra biner, penerapan nilai ambang (threshold) digunakan. Piksel dengan nilai di bawah nilai ambang akan diubah menjadi 0 (hitam), sedangkan piksel dengan nilai yang melebihi ambang akan diubah menjadi 1 (putih). Sebagai contoh, citra biner yang ditampilkan dalam Gambar 2.10 adalah hasil dari citra keabuan yang ditunjukkan dalam Gambar 2.9, dengan nilai ambang yang digunakan adalah 75.



Gambar 2.10: Citra biner dengan ukuran 300 x 500 piksel (Madenda, 2015).

2.7 Bidang Aplikasi Pengolahan Citra

2.7.1 Bidang Kesehatan

Pemanfaatan pengolahan citra di bidang kesehatan sangat membantu dokter dalam mendiagnosa penyakit pasiennya. Pada bidang ini citra diperoleh tidak hanya dari pencitraan panjang gelombang sinar tampak saja tetapi juga pencitraan dengan panjang gelombang yang lebih pendek atau lebih panjang. Hal ini memungkinkan organ dalam manusia dicitrakan lebih nyata. Kemajuan penting pengolahan citra digital dalam bidang ini diawali dengan ditemukannya Tomografi terkomputerisasi (Computerized Tomography/CT). Peralatan ini diciptakan pada tahun 1972 oleh Godfrey Hounsfield dari Inggris dan Allan Cormack dari Amerika. Peralatan ini menjadi alat pencitraan medis yang penting yang digunakan untuk melengkapi pencitraan sinar X dan ultrasonography medis. Pengolahan citra digital pada bidang ini dapat digunakan untuk identifikasi penyakit dalam, identifikasi kelainan tulang, deteksi kanker, dan rekonstruksi citra janin serta lainnya (Sri Ratna S et al, 2016).

2.8 Citra Medis

Teknik dan proses pembuatan pengolahan citra yang memvisualisasikan dan mempresentasikan bagian organ tubuh beserta fungsinya untuk keperluan klinis merupakan penjelasan dari citra medis (medical imaging) dengan tujuan mendiagnosis dan mengungkapkan jenis penyakit atau juga sebagai studi tentang anatomi dan fisiologi pada ilmu kedokteran, antara lain:

1. Mamografi

Mamografi atau breasts imaging adalah alat radiologi yang khusus digunakan untuk pencitraan menggunakan sistem sinar-X dosis rendah dalam pemeriksaan jaringan payudara. Pemeriksaan mammografi (mammogram) digunakan sebagai alat screening, baik untuk mendeteksi kanker payudara dini pada wanita yang tidak mengalami gejala maupun untuk mendeteksi dan mendiagnosis penyakit payudara pada wanita yang mengalami gejala seperti sakit dan benjolan. Ini memungkinkan deteksi dan klasifikasi terhadap kista, fibroadenoma (benjolan payudara non-kanker) dan kanker. Diagnostik mamografi juga dapat dilakukan setelah screening mamografi abnormal, dalam rangka untuk mengevaluasi perluasan area yang telah dinyatakan abnormal. Namun, perlu dipahami bahwa teknologi pencitraan ini bukan untuk mencegah kanker melainkan untuk membantu pendeteksian dini adanya kanker sebelum terjadi penyebaran. Deteksi dini perubahan jaringan payudara melalui mamografi dapat memainkan peran penting dalam mengurangi kematian akibat kanker payudara tersebut. Pengolahan citra digital dapat berperan dalam melakukan analisis untuk mendeteksi secara otomatis adanya area kanker pada citra mammografi dan menghitung luasan dari area tersebut. Ini dapat memudahkan dokter untuk memantau kecepatan pertumbuhan dan penyebaran kanker.

2. *Magnetic Resonance Imaging* (MRI)

Merupakan perangkat tes medis yang digunakan para dokter dalam mendiagnosa atau mengobati seorang pasien. Perangkat ini bekerja menggunakan medan magnet dengan bantuan komputer dan tidak menggunakan radiasi ionisasi (sinar-X). Perangkat ini bekerja membuat citra terperinci dari organ-organ dan

hampir semua struktur tubuh. Hasil pencitraan ini diolah menggunakan teknologi komputer dan tersimpan di media penyimpanan CD. Detail gambar hasil MRI memungkinkan dokter untuk lebih teliti mengevaluasi berbagai bagian tubuh lainnya. Teknologi MRI telah digunakan secara meluas karena kemampuannya untuk menggambarkan dengan jelas otak dan syaraf-syaraf kecil yang membentuk sumsum tulang belakang. Pada citra MRI ini, contoh peran pengolahan citra digital adalah kemampuan untuk melakukan analisis yang mendeteksi secara otomatis adanya area penyumbatan pembuluh darah, area pendarahan otak atau adanya tumor pada otak serta menentukan posisinya, luasnya dan volumenya. Sehingga, ini dapat membantu dan memudahkan bagi para dokter untuk mengambil keputusan dan tindakan secara cepat dan lebih akurat.

3. Ultrasound Imaging

Perangkat yang bekerja menggunakan gelombang suara frekuensi tinggi untuk menghasilkan gambar dari bagian dalam tubuh dikenal dengan ultrasound scanning atau ultrasonografi (USG). Perangkat ini merupakan alat bantu medis bagi para dokter mendiagnosis dan melakukan pengobatan medis dengan menghasilkan citra gambar. Secara real time perangkat ini merekam citra struktur dan pergerakan organ tubuh seperti aliran darah. Perangkat ini semakin berkembang dan saat ini sudah dapat menampilkan citra dalam bentuk citra tiga dimensi bahkan sudah empat dimensi seperti bentuk video.

4. Nuclear Medicine Imaging

Citra medis nuklir merupakan perangkat pencitraan dengan menggunakan material radioaktif untuk mendiagnosa atau mengobati penyakit seperti kanker, jantung dan lain-lain. Prosedur pencitraannya adalah noninvasif. Proses pemindaian perangkat ini dikenal dengan radiofarmasi atau radiotracer. Proses pemberian radiofarmaka ini menggunakan beberapa cara seperti disuntik dalam pembuluh darah, melalui gas yang dihirup pernapasan atau ditelan. Akumulasi radioaktif dengan organ tubuh menghasilkan energi sinar gamma dimana

kemudian pancaran sinar terdeteksi perangkat kamera gamma. Komputer membantu mengukur radioaktif tersebut menghasilkan citra dari struktur jaringan organ pasien. Perangkat ini bekerja seperti MRI dimana citra yang dihasilkan dapat membantu menganalisa kondisi gangguan organ tubuh pasien sampai dapat mendeteksi adanya kerusakan atau kanker.

5. Bone Density Scan

Teknologi pencitraan bekerja menganalisa kandungan mineral tulang yang membantu para dokter mendiagnosis osteoporosis atau kondisi kesehatan pada tulang. Penyakit yang membuat kepadatan tulang pasien menjadi berkurang mengakibatkan nyeri tulang sampai kondisi patah tulang. Penyakit ini sering tidak terdeteksi secara awal karena tidak terdapat gejala sampai menimbulkan terjadinya patah tulang. Perangkat ini mendeteksi secara dini kondisi tulang pasien yang dipindai dalam bentuk citra gambar. Perangkat ini dapat mendeteksi sampai tingkat kepadatan dan kekeroposan tulang pasien.

2.9 Kornea

Kornea adalah selaput bening mata, bagian selaput mata yang tembus cahaya dan merupakan lapisan jaringan yang menutup bola mata sebelah depan. Kornea ini disisipkan ke dalam sklera pada limbus, lekukan melingkar pada sambungan ini disebut sulcus sclera. Kornea merupakan jaringan yang avascular. Kornea menutupi hampir seperenam dari permukaan bola mata. Kornea berbentuk melengkung di permukaan anterior dan mendatar di daerah perifer. Kornea terdiri dari 5 lapisan terdapat pada Gambar 2.4, yaitu lapisan epitel dan basal lamina, lapisan bowman, stroma dan membran descement dan lapisan endotel (Dr. Titiek Ernawati, dr., Sp.M et al, 2023).

1. Epitel dan Basal Lamina

Berbentuk epitel skuamosa lipofilik yang tidak berkeratin. Bagian ini merupakan bagian paling anterior dari kornea. Bagian ini menempel pada lamina basal hemidesmosom. Pada bagian atas dari lapisan sel basal, terdapat sel berbentuk seperti sayap dan polygonal.

2. Lapisan Bowman

Lapisan ini merupakan lapisan keras yang terdiri dari kolagen yang tersebar acak. Lapisan ini dapat berubah menjadi jaringan parut dan tidak bisa dipulihkan kembali apabila cedera.

3. Lapisan Stroma


Lapisan ini terdiri dari keratosit, *ground substance*, dan lamella kolagen (kolagen I, III, IV, V, VI, XII dan XIV) merupakan lapisan paling tebal di kornea yaitu sekitar 90 persen dari ketebalan kornea.

4. Membran Descemet

Membrane descemet terdiri dari banyak kolagen tipe IV, membrane ini memiliki ketebalan 3-4 um dan meningkat pada orang dewasa menjadi 10-12 um.

5. Lapisan Endotel

Lapisan endotel terdiri dari satu lapisan berbentuk heksagonal. Sel endotel yang muda biasanya memiliki inti yang besar dan mitokondria yang banyak. Sel ini dapat melakukan transport aktif dan menyebabkan terjadinya transfer air dari stroma kornea dan sebagai pemeliharaan dari stroma.




Gambar 2.11 Gambaran histologi lima lapis pada kornea mata (sumber: Dr. Titiek Ernawati, dr., Sp.M et al, 2023).

Pada E: epitel skuamosa kornea; panah: lapisan tipis membrane Bowman; Co: serabut kolagen pada stroma; F: fibroblast tipis; En: epitel skuamosa menuju kuboid pada endothelium.

2.9.1 Inervasi Kornea

Kornea diinervasi oleh cabang dari *nervus ophthalmica* yang membentuk pleksus di sekitar tepi kornea atau melewati sclera dan memasuki stroma kornea. Sebelum memasuki kornea, demielinisasi dari nervus yang bermielin menuju ke matriks kornea dan membentuk pleksus sub-epitelial. Nervus kornea ini juga berperan dalam memberikan rangsangan aferen pada saat mata berkedip dan reflex lakrimal mata.




Gambar 2.12 Gambaran skematis epitel kornea yang menggambarkan adhesi dari sel dan basal lamina. (sumber: Dr. Titiek Ernawati, dr., Sp.M et al, 2023).

2.10 Pemeriksaan Kornea


2.10.1 Tes Fluorescein

Fluorescein pada kornea adalah tes yang menggunakan pewarna oranye (fluorescein) dan cahaya biru untuk mendeteksi benda asing di mata. Tes ini juga dapat mendeteksi kerusakan pada epitel kornea, permukaan luar mata. Zat warna *fluorescein* akan berubah hijau pada media alkali. Zat warna *fluorescein* bila menempel pada epitel kornea yang defek akan memberikan warna hijau karena jaringan epitel yang rusak bersifat lebih basa, terdapat pada Gambar 2.7. Tes ini berguna dalam mengidentifikasi goresan dangkal atau masalah lain dengan permukaan kornea. Hal ini juga dapat membantu mengungkapkan benda asing pada permukaan mata. Hal

ini digunakan setelah kontak yang diresepkan untuk menentukan apakah ada iritasi pada permukaan kornea. Mengetahui abnormalitas produksi air mata (mata kering), kornea abrasi (goresan pada permukaan kornea), benda asing tubuh (*corpus allienum*), seperti bulu mata atau debu, infeksi, cedera atau trauma, mata kering parah yang berhubungan dengan arthritis (keratoconjunctivitis sicca) (Sumber: dr. Susy Fatmariyanti, Sp. M, 2014).



Gambar 2.13 Fluoresin Cair berupa *eye drop* dan Fluoresin Kertas (Sumber: dr. Susy Fatmariyanti, Sp. M, 2014)



(a) Cahaya Biru

(b) Cahaya Biasa

Gambar 2.14 Keratitis Epitelial pada Kornea dengan Fluoresin Test (Sumber: dr. Susy Fatmariyanti, Sp. M, 2014)

2.10.2 Slit-Lamp Biomicroscopy

Slit-Lamp Biomicroscopy merupakan alat dasar bagi dokter mata. Penguasaan pemeriksaan slit-lamp sangat penting dalam mengkategorikan patologi kornea dan merumuskan rencana diagnostic dan terapeutik. Pemeriksaan slit-lamp harus dilakukan secara urut, dimulai dengan pemeriksaan kelopak mata (margin, kelenjar

meibom dan bulu mata), konjungtiva, sclera, kornea bilik mata depan, iris, pupil dan lensa.

2.10.11 Scanning

1. Ultrasound biomicroscopy

Ultrasound biomicroscopy frekuensi (UBM) tinggi memberikan gambaran in vivo resolusi tinggi pada segmen anterior, jaringan yang divisualisasikan meliputi kornea, permukaan dan posterior iris, badan siliaris, zonula zinnia dan kapsul anterior lensa. UBM sangat membantu dalam penilaian patologi tubuh siliaris, termasuk kista dan tumor. Hal ini juga sangat berguna dalam evaluasi berbagai anomaly sudut, termasuk resesi sudut, blok pupil, plateaus iris, malignant glaucoma dan cyclodialysis cleft. Keuntungan utamanya adalah kemampuannya untuk memvisualisasikan struktur di belakang iris, sebagian besar kemampuan lainnya dalam memvisualisasikan segmen anterior telah digunakan dengan anterior segment optical coherence tomography (OCT).

2. Anterior Segment Optical Coherence Tomography (OCT)

Optical Coherence Tomography (OCT) merupakan teknologi non invasive yang memproduksi gambar 2 dimensi, resolusi tinggi, definisi tinggi dari jaringan ocular. Gambar tersebut mirip dengan gambar ultrasonographic, namun gambar dari OCT berdasarkan dari emisi dan refleksi dari cahaya (*Low Coherence Interferometry*) OCT dapat menggambarkan lapisan kornea, bilik mata depan dan iris dengan sangat baik.

2.11 Keratitis

Keratitis adalah infeksi pada kornea yang biasanya diklasifikasikan menurut lapisan kornea yang terkena yaitu keratitis superfisialis apabila mengenai lapisan epitel atau bowman dan keratitis profunda atau interstisialis (atau disebut juga keratitis parenkimatososa) yang mengenai lapisan stroma. Keratitis superfisialis apabila mengenai lapisan epitel atau bowman dan keratitis profunda atau interstisial (keratitis parenkimatososa) yang mengenai lapisan stroma.


2.11.1 Keratitis Bakterial

Etiologi: staphylococcus, streptococcus, pseudomonas dan enterobacteriaceae.

Faktor resiko: pemakaian lensa kontak, disfungsi air mata, riwayat penggunaan obat tetes mata yang terkontaminasi, benda asing pada mata.

Gejala: iritasi, fotofobia, mata berair, penurunan fungsi penglihatan, edema mata, hiperemis konjungtiva, secret mukopurulen.

Tatalaksana: antibiotic topical



Gambar 2.15 Keratitis Bakterial (Sumber: Medical Science Channel)


2.11.2 Keratitis Herpes Zoster

Manifestasi infeksi **varicella zoster** → zoster ophthalmic.

Gejala: Iritasi, fotofobia, mata berair, penurunan fungsi penglihatan, unilateral sesuai dermatome tubuh yang terkena.

Gambaran khas → **Lesi pseudodendritik.**

Terapi: antivirus topikal (idoxuridine, trifluridine, vidarabine, acyclovir), debridement epitelial, antivirus oral (berat) → 5 x 800 mg selama 7 hari.




Gambar 2.16 Keratitis Herpes Zoster- Lesi Pseudodendritik (Sumber: Medical Science Channel)

2.11.3 Keratitis Herpes Simpleks

Etiologi HSV 1 >> HSV 2 (riwayat lepuh-lepuh, infeksi herpes).

Gambaran khas → **Lesi dendritik, ulkus geografik (kronik).**

Terapi: antivirus topikal (idoxuridine, trifluridine, vidarabine, acyclovir),
debridement epitelial antivirus oral (berat) → 5 x 400 mg selama 7 hari.



(a) Lesi Dendritik (b) Ulkus Geografik

Gambar 2.17 Keratitis Herpes Simpleks (Sumber: Medical Science Channel)

2.11.4 Keratitis Fungal

Memiliki riwayat **trauma dengan tumbuhan** (terkena ranting pohon, dll),
sekret purulen.

Pemeriksaan: lesi hipopion, dan **lesi satelit.**

Tatalaksana: antifungal topical



Gambar 2.18 Keratitis Fungal (Sumber: Medical Science Channel)

2.11.5 Keratitis Amoeba

Pasien memiliki **riwayat berenang** dan penggunaan lensa kontak tidak higienis.

Pemeriksaan: ulkus indolen, cincin stroma.

Tatalaksana: Amoebisida



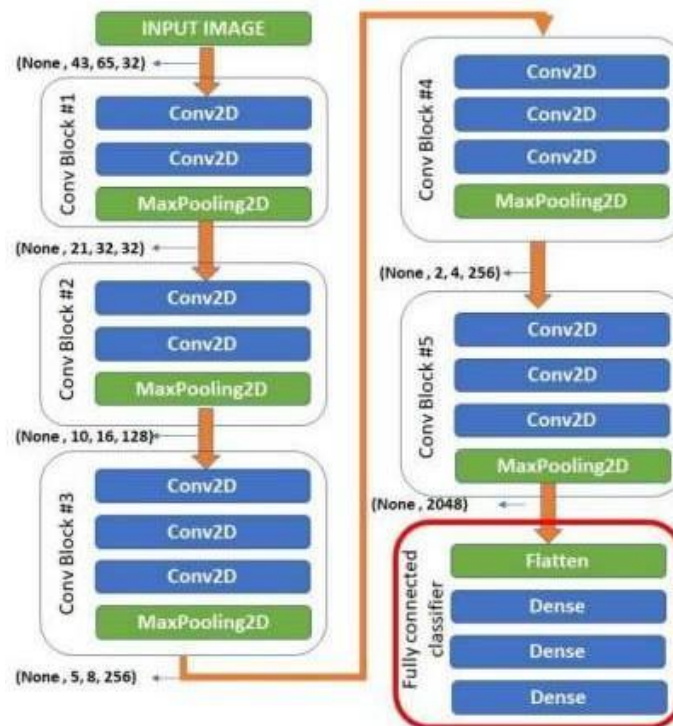
Gambar 2.19 Keratitis Amoeba (Sumber: Medical Science Channel)

2.12 Kajian Penelitian

Penelitian sebelumnya telah melakukan sejumlah penelitian yang berkaitan dengan klasifikasi dan deteksi ulkus kornea pada penyakit keratitis. Berikut adalah ringkasan dari penelitian tersebut tentang klasifikasi dan identifikasi ulkus kornea pada penyakit keratitis.

(Amit Kumar G, 2021) *Microbial Keratitis Classification Using Convolutional Neural Network and Transfer Learning*

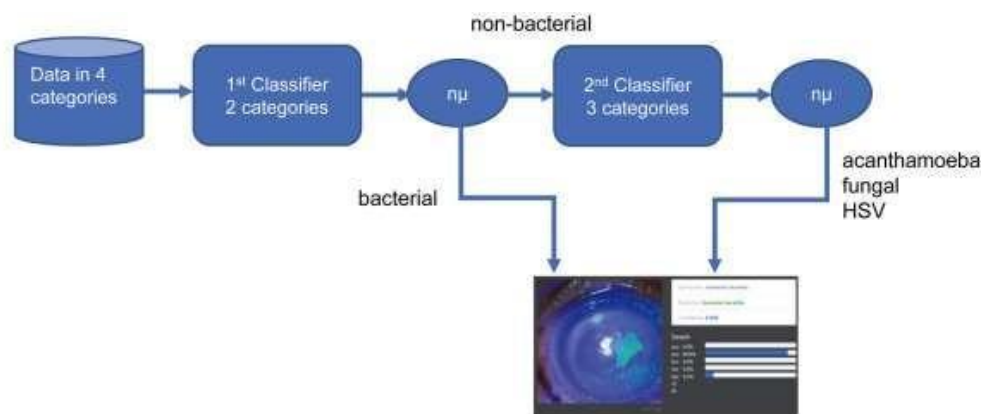
Penelitian ini mengembangkan tiga model *Deep Learning* untuk mendiagnosis keratitis infeksi berdasarkan citra slit-lamp (Ghosh & Thammasudjarit, n.d. 2021). Model pertama dibuat untuk membedakan mata sehat dengan pasien infeksi keratitis. Model ini mencapai akurasi 99.3% dan AUC 1,0. Model kedua dibuat untuk membedakan antara keratitis bakteri dan keratitis jamur. Model ini mencapai akurasi sekitar 84% dan AUC 0,96. Model ketiga bertujuan membedakan antara 2 subtype utama spesies jamur penyebab keratitis yaitu ragi (*Candida* spp.) dan filamentous (*Aspergillus* spp. dan *Fusarium* spp.). Model ini memiliki akurasi 77,5% dan AUC 0,99. Ketiga model ini menunjukkan performa yang luar biasa dalam diagnosis infeksi keratitis, khususnya dalam identifikasi dan diagnosis dini potensi kasus keratitis jamur yang sangat penting untuk memulai pengobatan secara cepat dan tepat. Model arsitektur yang digunakan untuk mengolah citra terdapat pada gambar 2.13.



Gambar 2.20 Model Arsitektur dari CNN (Ghosh & Thammasudjarit, n.d. 2021)

(Ayumi K, Dai M, Yuji N, 2021) *Determination of probability of causative pathogen in infectious keratitis using deep learning algorithm of slit-lamp images*


Penelitian dalam mengembangkan algoritma *Deep Learning Hybrid* yang menentukan probabilitas kategori patogen penyebab infeksi keratitis infeksius dengan akurasi tinggi hanya dengan menganalisis citra slit-lamp. Keratitis infeksius adalah penyebab utama kebutaan (Koyama et al., 2021). Pemeriksaan slit-lamp adalah standar untuk mendiagnosis dan mengidentifikasi patogen penyebab infeksi keratitis dikarenakan akurasi identifikasi patogen oleh oftalmolog bersertifikasi masih rendah. Untuk mengatasi masalah ini, peneliti mengadaptasi arsitektur pembelajaran mesin yang digunakan untuk pengenalan wajah dan menerapkannya untuk infeksi keratitis. Total 4.306 citra slit-lamp termasuk 312 citra dari publikasi internet tentang keratitis yang disebabkan oleh bakteri, jamur, amuba (parasit) dan herpes simpleks virus (HSV). Algoritma yang dibuat memiliki akurasi diagnosis keseluruhan yang tinggi. Pada akurasi area *under the curve* untuk amuba (parasit) sebesar 97.9%. akurasi pada bakteri sebesar 90.7%, akurasi pada jamur sebesar 95.0% dan HSV akurasi sebesar 92.3% berdasarkan validasi *group k-fold*. Algoritma ini juga terbukti kuat bahkan untuk citra dengan resolusi rendah dari internet. Arsitektur Algoritma ResNet 50 seperti pada gambar 2.14



Gambar 2.21. Gambar Arsitektur Algoritma ResNet 50 (Koyama et al., 2021)

(Jan Gross, Johannes B, Hermann B, 2021) *High-Performance Detection of Corneal Ulceration Using Image Classification with Convolutional Neural Networks*

Penelitian ini untuk melakukan deteksi ulkus kornea berdasarkan citra *fluorescein staining* menggunakan model *Convolutional Neural Network* (CNN). Ulkus kornea merupakan gejala paling umum penyakit kornea dengan tingkat kebutaan yang tinggi. Keterlambatan diagnosis dan pengobatan yang tidak tepat dapat menyebabkan kerusakan penglihatan yang tidak dapat dipulihkan atau bahkan kebutaan. Penelitian ini mengembangkan model klasifikasi berbasis CNN untuk mengidentifikasi pola ulkus kornea yang berbeda (Gross et al., 2021). Pengumpulan data dilakukan dengan menggunakan fotografi celah lampu setelah melakukan staining fluorescein pada permukaan okular 712 pasien. Data di-label oleh 3 ahli oftalmologi. Model CNN dibangun menggunakan transfer learning dengan arsitektur VGG16. Data kemudian dibagi menjadi data latih dan uji dengan rasio 80:20. Hasil penelitian menunjukkan model mampu membedakan pola ulkus dini dan lanjut dengan akurasi 92,73%. Model juga terbukti kuat terhadap pantulan cahaya dan mampu mengekstraksi fitur yang bermakna secara otomatis. Penelitian ini berkontribusi terhadap penelitian sistem informasi di bidang kesehatan dengan mengidentifikasi ulkus kornea secara dini sehingga intervensi pencegahan dapat dilakukan dan mengurangi tingkat keparahan penyakit. *Preventive Model Approach* seperti pada gambar 2.15.




Gambar 2.22. Preventive Model Approach (Gross et al., 2021).

(Yesheng Xu, Ming Kong, 2021) *Deep Sequential Feature Learning in Clinical Image Classification of Infectious Keratitis*

Penelitian ini menggunakan model *deep learning* berbasis *sequential feature learning* untuk melakukan diagnosis *end-to-end* penyakit infeksi keratitis (Xu et al., 2021). Dataset yang dikumpulkan dari tahun 1998 hingga 2018 berisikan 115.408

gambar klinis dari 10.609 pasien dengan 89 kategori penyakit keratitis, menjadi dasar pengembangan sistem. Penelitian ini berfokus pada pembagian gambar klinis pasien yang menderita infeksi keratitis, jamur, bakteri dan virus herpes. Penelitian ini membandingkan performa dari beberapa model *Deep Learning*, yaitu *Image-Level Feature Learning* yang menerapkan *Transfer Learning* pada arsitektur CNN seperti VGG-16, *GoogLeNet* dan *DenseNet*, *Patch-Level Feature Learning* yang mempelajari fitur dari *Patching/Cropping* area lesi pada citra serta *Sequential-level Feature Learning* yang mempelajari fitur secara berurutan dari pusat ke pinggir area lesi. Hasil percobaan menunjukkan bahwa model *Sequential Feature Learning* memiliki akurasi tertinggi yaitu 78.73%. performa sistem dibandingkan dengan 421 oftalmolog yang diminta untuk mendiagnosis 120 gambar klinis. Rata-rata akurasi oftalmolog hanya 49,29% jauh lebih rendah dari sistem *Deep Learning* yang diusulkan. Hal ini menunjukkan bahwa sistem AI dapat membantu diagnosis penyakit infeksi keratitis dengan lebih akurat, tetapi evaluasi lebih lanjut dengan skala yang lebih besar masih diperlukan sebelum sistem dapat diterapkan dalam praktik klinis. Diagram Alur dari Sistem Pengolahan Dataset Citra terdapat pada gambar 2.16.



Gambar 2.23. Diagram Alur dari Sistem Pengolahan Dataset Citra (Xu et al., 2021)

(Hiam A, Yazan A, Mohammed Alsalatie, 2022) *Intelligent Diagnosis and Classification of Keratitis*

Pendekatan pembelajaran mesin dalam mendiagnosa dan mengklasifikasikan ulkus kornea untuk membedakan pola ulkus kornea yang berbeda, termasuk pola umum, pola spesifikasi (jenis grading) dan tingkat keparahan (grade grading). Pentingnya

mendeteksi ulkus kornea secara dini dapat meningkatkan perawatan yang lebih baik dan terarah (Alquran et al., 2022). Penelitian ini melakukan augmentasi data untuk memperbesar dataset dengan cara manipulasi data yang ada. Selanjutnya menggunakan dua metode untuk mengklasifikasikan citra kornea dengan ekstraksi fitur manual dan otomatis. 60 fitur tekstur dan warna diekstraksi secara manual. Dalam ekstraksi fitur otomatis menggunakan CNN Resnet 101 untuk mengekstraksi 1000 fitur secara otomatis dari data. Setelah fitur diekstraksi, melakukan teknik reduksi dimensi seperti *Principal Component Analysis* (PCA) dan *Elimination by Local Feature Selection* (ELFS) digunakan untuk memilih fitur-fitur terbaik. Menggunakan algoritma SVM (*Support Vector Machine*) untuk melakukan klasifikasi data berdasarkan fitur-fitur yang diekstraksi sebelumnya untuk membedakan antara pola ulkus yang berbeda. Hasil tingkatan akurasi yang didapat dengan menggunakan 30 fitur manual yang paling signifikan diekstraksi menggunakan FCFS, model dapat membedakan ulkus bersisik dan berbentuk titik dengan akurasi sebesar 91,1%. Sedangkan untuk membedakan ulkus campuran titik-bersisik (*Point-scale ulcers*) dan ulkus bersisik (*Scale Ulcers*) mendapatkan akurasi 95,6%. Hasil akurasi menggunakan 1000 fitur otomatis menggunakan model ResNet 101 menghasilkan 88,3% untuk membedakan ulkus bersisik dan berbentuk titik dan hasil akurasi ulkus campuran titik-bersisik dan ulkus bersisik sebesar 93,9%. Sistem keseluruhan berhasil mengklasifikasikan pola umum ulkus, ke dalam tiga kelas dengan hasil akurasi terbaik sebesar 92,2% menggunakan SVM.

(Zijung Z, Haoyu W, Shigeng W, 2022) *Deep Learning-Based Classification of Infectious Keratitis on Slit-Lamp Images*

Penelitian ini membahas tentang pengembangan model diagnosis bantuan berbasis *Deep Learning* untuk diagnosis infeksi keratitis dini. Infeksi keratitis adalah kondisi mata yang disebabkan oleh mikroorganisme dan dapat mengancam penglihatan. Metode berbasis kultur yang selama ini menjadi standar untuk mendiagnosis infeksi keratitis memiliki keterbatasan seperti biopsi yang sulit, pelaporan yang tertunda dan tingkat positif yang rendah. Oleh karena itu, para oftalmolog seringkali

membuat diagnosis klinis berdasarkan karakteristik segmen anterior pasien, namun oftalmolog masih kesulitan dalam membedakan infeksi keratitis (Zhang et al., 2022). Penelitian ini bertujuan untuk membangun model diagnosis berbasis *deep learning* untuk mendiagnosis dini infeksi keratitis. Sebanyak 4.830 citra slit-lamp dikumpulkan dari pasien yang didiagnosa infeksi keratitis antara juni 2010 hingga mei 2021. Data tersebut mencakup 1.490 bakteri keratitis (30.8%), 1.670 jamur

keratitis (34.6%), 600 herpes simpleks keratitis (12.4%) dan 1.070 amoeba keratitis (22.2%). Data acak dibagi menjadi set pelatihan dan pengujian dengan rasio 9:1. Sembilan jaringan klasifikasi citra yang berbeda diimplementasikan dan dibandingkan. Teknik perpaduan model digunakan untuk menggabungkan keunggulan model tunggal. Performa model gabungan dinilai dengan validasi silang 10-lipat, kurva karakteristik operator penerima (ROC), matriks kekeliruan, visualisasi pemetaan aktivasi kelas gradient (Grad-CAM), dan penanaman stokastik terdistribusi-t (t-SNE). Keratitis Net, gabungan dari ResNext101_32x16d dan DenseNet169, mencapai akurasi tertinggi 77,08%. Akurasi Keratitis Net untuk mendiagnosa bakteri keratitis, jamur keratitis, amoeba (parasit) keratitis dan herpes simpleks keratitis berturut-turut adalah 70,27%, 77,71%, 83,81% dan 79,31%. Keratitis Net paling bingung dalam membedakan bakteri keratitis dan jamur keratitis. Tiga spesialis kornea berpengalaman diundang untuk bersaing dengan Keratitis Net. Akurasi model signifikan lebih tinggi daripada oftalmolog manusia ($p < 0,001$). Keratitis Net menunjukkan kinerja yang baik pada diagnosis klinis infeksi keratitis dan klasifikasi. *Deep Learning* dapat memberikan metode diagnosis bantuan untuk membantu klinisi menduga infeksi keratitis menggunakan manifestasi kornea yang berbeda.

(Ming-Tse K, Benny Wei-Yun H, 2023) *Monitoring the Progression of Clinically Suspected Microbial Keratitis Using Convolutional Neural Networks*

Penelitian ini membahas sebuah studi kohort longitudinal multisenter yang bertujuan untuk menentukan apakah metode berbasis *convolutional neural network* (CNN) berdasarkan fitur ekstraksi dan identifikasi dapat diterapkan untuk

memantau perkembangan keratitis pada pasien dengan dugaan microbial keratitis (MK) (Kuo et al., 2023). Studi ini menggunakan citra mata eksternal serial dari 468 pasien dengan keratitis yang dicurigai mikroba di 5 cabang Rumah Sakit Peringatan Chang Gung dari Agustus 2000 hingga Agustus 2020. Data terutama dianalisis dari 1 Januari hingga 25 Maret 2022. Model CNN yang dikembangkan dievaluasi dengan menggunakan F1 score dan akurasi. *Area under the receiver operating characteristic curve* (AUROC) digunakan untuk mengukur ketepatan dan recall. Model dilatih menggunakan 1456 pasang gambar dari 468 pasien. Model berbasis Efficient Net b3 yang dilatih penuh menunjukkan F1 score 90,2% (membaik) dan 82,1% (memburuk), akurasi 87,3%, dan AUROC 94,2% untuk 505 pasang gambar uji membaik dan 272 pasang gambar uji memburuk dari 452 pasien.

(Mohammad S, Kosar E, Amir R, 2023) *From the diagnosis of infectious keratitis to discriminating fungal subtypes; a deep learning-based study*

Penelitian ini membahas penggunaan kecerdasan buatan untuk mendiagnosis infeksi keratitis berdasarkan foto slit-lamp (Soleimani et al., 2023). tujuan penelitian ini untuk mengembangkan tiga model *Deep Learning* untuk mendiagnosis model 1, lalu membedakan keratitis bakteri dan keratitis jamur pada model 2, selanjutnya membedakan tipe jamur filamen dan khamir dari keratitis jamur pada model 3. Data yang digunakan adalah 9329 foto slit-lamp dari 977 pasien yang terdiri dari mata sehat, keratitis bakteri, dan keratitis jamur (filamen dan khamir). Dua jaringan syaraf konvolusional dirancang untuk melatih ketiga model tersebut. Model 1 mampu mendiagnosis infeksi keratitis dengan akurasi 99.3%, model 2 membedakan keratitis bakteri dan jamur dengan akurasi 84%, dan model 3 membedakan tipe jamur dengan akurasi 77,5%.

(Shaodan Hu, Yiming Sun, Jinhao L, 2023) *Automatic Diagnosis of Infectious Keratitis Based on Slit Lamp Images Analysis*

Penelitian ini membahas tentang diagnosis otomatis untuk infeksi keratitis menggunakan teknologi *Deep Learning* berbasis gambar dari mikroskop celah (*Slit-lamp*) Tujuannya adalah untuk mengklasifikasikan secara otomatis antara kornea normal dan berbagai jenis infeksi keratitis seperti keratitis bakteri (BK),

keratitis jamur (FK) dan keratitis virus (VK) (Hu et al., 2023). Peneliti membangun database yang terdiri dari 2757 gambar mikroskop celah dari 744 pasien, termasuk kornea normal dan infeksi keratitis. Enam model DL yang berbeda dievaluasi untuk klasifikasi infeksi keratitis yang terdiri dari ResNet 34, DenseNet121, ViT-Base, VGG16, Inception V4, dan EfficientNetV2-M. EfficientNet V2-M menunjukkan performa terbaik dengan akurasi 0,735, recall 0,680, dan spesifisitas 0,904. Hal ini juga lebih baik daripada dua oftalmolog. AUC model EfficientNetV2-M mencapai 0,85, dibandingkan oftalmolog pada 0,76 dan 0,77. Heatmap yang dihasilkan model menunjukkan daerah lesi pada kornea yang sangat berkorelasi dengan identifikasi infeksi keratitis. Hasil ini menunjukkan potensi sistem *Deep Learning* yang dibangun untuk membantu oftalmolog dalam skrining dan diagnosis infeksi keratitis.

(Yeo Kyoung Won, Hyebin Lee, Youngjun Kim, 2023) *Deep learning-based classification system of bacterial keratitis and fungal keratitis using anterior segment images*

Penelitian yang dilakukan oleh (Won et al., 2023) membahas tentang pengembangan dan validasi kerangka kerja *Deep Learning* untuk mendiagnosis infeksi keratitis. Penelitian ini berhasil mengembangkan dan memvalidasi sistem diagnostik otomatis berbasis *Deep Learning* untuk mendiagnosis keratitis bakteri dan jamur dengan menggunakan citra segmen anterior mata. Penelitian ini menggunakan 2 metode untuk meningkatkan akurasi diagnosis. Metode *Lesion Guiding Module* (LGM) dan metode *Mask Adjusting Module* (MAM). Hasil dari penelitian ini menunjukkan bahwa modul yang digunakan memiliki hasil yang signifikan dalam meningkatkan kinerja diagnostic keratitis bakteri dan jamur pada dataset citra segmen anterior yang berbeda. Penelitian ini menggunakan dataset dari Samsung Medical Center (SMC) dengan data citra segmen anterior sebanyak 684 citra dari 107 pasien penderita keratitis bakteri dan jamur melalui kultur pengikisan kornea. ResNet 50 diatur sebagai pengklasifikasi dasar dan algoritma kemudian divalidasi secara eksternal menggunakan 98 citra dari pencarian citra google dan buku teks oftalmologi. Hasil penelitian ini menunjukkan bahwa hasil akurasi diagnostic dari metode LGM dan MAM menunjukkan peningkatan yang signifikan

dibanding dengan model ResNet50. Akurasi meningkat dari 81.1% menjadi 87.8% dengan menggunakan dataset Samsung Medical Center (SMC). selain itu dalam menggunakan dataset terbuka hasil model tersebut menunjukkan peningkatan kinerja diagnostic dari ResNet50 64.2% setelah menerapkan LGM dan MAM akurasi menjadi 71.4%.

Penelitian yang sudah dilakukan peneliti terdahulu terangkum dalam Tabel 2.1 dibawah ini.

Tabel 2.1. Ringkasan Kajian Penelitian

Peneliti, Tahun	Subjek Penelitian	Metode Penelitian	Kelebihan	Kekurangan
Amit Kumar, 2021	Deteksi dan Klasifikasi	<i>Transfer Learning</i> dari VGGNet	Model 1 memiliki akurasi sebesar 99.3%. Model 2 memiliki akurasi sebesar 84%. Model 3 memiliki akurasi sebesar 77.5%	Jumlah data latih relative kecil hanya 250 citra dan tidak membandingkan dengan metode lain.
Ayumi K dan Dai Miyazaki, 2021		Arsitektur Algoritma ResNet50	Akurasi diagnosis tinggi untuk semua patogen penyebab infeksi keratitis dan dapat mendeteksi citra dengan resolusi rendah dari internet.	Jumlah kasus terbatas, mungkin tidak berlaku untuk spesies patogen yang berbeda secara epidemiologis dan hanya mengklasifikasikan 4 kategori utama patogen penyebab infeksi keratitis
Jan Gross, Johanness B, 2021		CNN untuk klasifikasi gambar. <i>Transfer Learning</i> digunakan dengan VGG16 sebagai model CNN yang sudah dilatih sebelumnya.	Akurasi klasifikasi sangat baik sebesar 92.73%. Model cukup kuat terhadap pantulan cahaya pada gambar mata dan metode otomatis, efisien dan akurat.	Jumlah data latih relative kecil. Belum diuji dengan dataset dari sumber yang lebih beragam. Belum diimplementasikan pada perangkat di lingkungan medis.

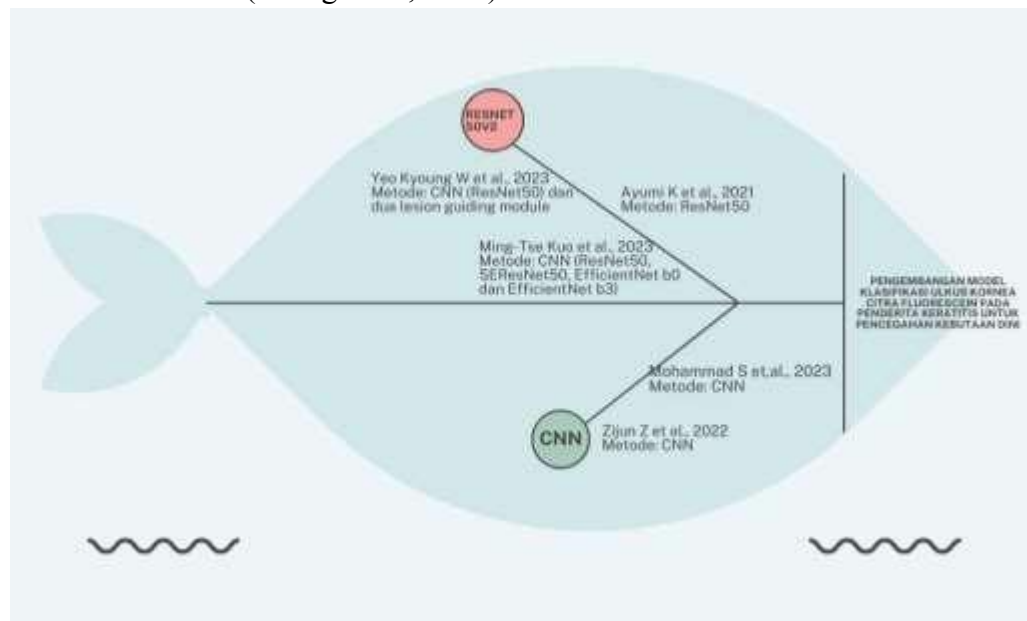
Peneliti, Tahun	Subjek Penelitian	Metode Penelitian	Kelebihan	Kekurangan
Yesheng Xu dan Ming Kong, 2021	Klasifikasi	Model <i>Sequential-level</i> , membandingkan metode <i>Image-lavel Feature Learning</i> dengan <i>Patch-level Feature Learning</i>	Akurasi diagnosis sebesar 80% lebih tinggi dibanding rata-rata akurasi dokter mata 49.27%	Dataset yang digunakan relative kecil dan hanya mencakup 4 kategori penyakit infeksi keratitis dan belum diuji pada skala besar untuk aplikasi klinis.
Hiam Alquran dan Yazan A, 2022	Deteksi dan Klasifikasi	Model CNN ResNet 101 dan SVM	Menggunakan teknik fluorescein staining untuk mendeteksi ulkus kornea dan akurasi sebesar 92.2%	Dataset terbatas dalam jumlah dan variasi yang dibutuhkan dataset yang lebih besar dan bervariasi untuk membangun model yang lebih baik. Citra yang digunakan kualitasnya kurang baik. Tidak mempertimbangkan penyebab infeksi keratitis yang berbeda yang memerlukan perawatan berbeda.
Zijun Z dan Haoyu W, 2022		<i>CNN</i>	Jumlah data besar sekitar 4.830 citra dan	Jumlah kasus tiap jenis keratitis tidak seimbang

Peneliti, Tahun	Subjek Penelitian	Metode Penelitian	Kelebihan	Kekurangan
			membandingkan dengan diagnosis dokter spesialis	dan data hanya dari satu rumah sakit spesialis.
Ming-Tse Kuo dan Benny Wei 2023		Model <i>CNN (ResNet 50, SEResNet50, Efficient Net b0 dan Efficient Net b3)</i>	Model terlatih menunjukkan performa yang baik dengan akurasi sebesar 87.3%, AUROC 94.2% dalam memantau perkembangan keratitis	Tidak ada konfirmasi mikrobiologis pada semua kasus CSMK dan kualitas gambar dapat mempengaruhi performa model.
Mohammad S dan Kosar E, 2023		Model CNN	Akurasi tinggi untuk mendiagnosis k=infeksi keratitis sebesar 99.3% pada model 1. Dapat membedakan jamur dan ragi pada keratitis jamur dengan akurasi sebesar 77.5%	Kualitas gambar rendah pada beberapa kasus dan tidak mengontrol kondisi pengembalian gambar slit-lamp
Shaodan Hu dan Yimin Sun, 2023	Diagnosis dan Klasifikasi	<i>(VGG16, ResNet 34, Inception V4, DenseNet121, ViT-Base dan EffecientNetV2-M)</i>	Melakukan klasifikasi yang lebih kompleks yaitu membedakan keratitis bakteri, keratitis jamur, keratitis virus dan normal kornea. Membandingkan kinerja 6 model <i>Deep Learning</i> yang berbeda dan 2 dokter mata.	Jumlah data yang digunakan relative terbatas dibandingkan penelitian serupa lainnya. Jumlah kasus bakterial keratitis lebih sedikit dibandingkan jenis infeksi lainnya dan model yang dikembangkan hanya dievaluasi

Peneliti, Tahun	Subjek Penelitian	Metode Penelitian	Kelebihan	Kekurangan
				menggunakan dataset internal
Yeo Kyoung W dan Hyebin Lee, 2023		<i>CNN (ResNet50)</i> dan dua <i>lesion guiding module</i> dan <i>slit beam mask adjusting module</i>	Akurasi diagnosis lebih tinggi dibanding hanya dengan ResNet 50 yakni 87.8% dengan 81.1% dan tervalidasi pada dataset terbuka eksternal dan mampu mendeteksi lokasi lesi dengan akurat.	Dataset masih terbatas ukuran dan variasi. Membutuhkan anotasi ahli untuk pelatihan dan baru bisa bedakan keratitis bakteri dan jamur.

2.9 Roadmap Penelitian

Penelitian dalam mengembangkan model diagnosis dan klasifikasi berhasil mengklasifikasikan pola umum ulkus, ke dalam tiga kelas dengan hasil akurasi terbaik sebesar 92,2% menggunakan SVM. Dilakukan oleh (Alquran, et al., 2022). Penelitian ini menggunakan model Convolutional Neural Network (CNN) untuk melakukan deteksi ulkus kornea berdasarkan gambar fluorescein staining. Hasil penelitian menunjukkan bahwa model dapat membedakan pola ulkus dini dan lanjut dengan akurasi 92,73%. Selain itu, model terbukti kuat terhadap pantulan cahaya dan dapat secara otomatis mengekstrak fitur penting. Studi ini dilakukan oleh (Gross et al., 2021). Penelitian selanjutnya tentang diagnosis otomatis infeksi keratitis menggunakan teknologi Deep Learning berbasis gambar dari mikroskop celah (Slit-lamp). Tujuannya adalah untuk mengklasifikasikan secara otomatis antara kornea normal dan berbagai jenis infeksi keratitis, seperti keratitis bakteri (BK), keratitis jamur (FK), dan keratitis virus (VK). Hasil menunjukkan bahwa mereka memiliki kinerja terbaik dengan akurasi 0,735, recall 0,680, dan spesifisitas 0,904. Lebih baik lagi daripada dua oftalmolog. Model EffecientNetV2-M memiliki AUC 0,85, sedangkan untuk oftalmologi mencapai 0,76 dan 0,77, masing-masing (Hu et al., 2023). Penelitian selanjutnya menyelidiki pengembangan model diagnosis bantuan berbasis Deep Learning untuk diagnosis infeksi keratitis dini. Untuk mendiagnosis bakteri keratitis, jamur keratitis, amoeba (parasit) keratitis, dan herpes simpleks keratitis, akurasi Keratitis Net adalah 70,27%, 77,71%, 83,81%, dan 79,31%, masing-masing. Akurasi ini paling sulit untuk membedakan antara bakteri keratitis dan jamur keratitis. Tiga ahli kornea terkenal diundang untuk berkompetisi dalam Keratitis Net. Dengan $p < 0,001$, akurasi model signifikan lebih tinggi daripada oftalmolog manusia. Keratitis Net berhasil dalam diagnosis klinis dan klasifikasi infeksi keratitis. Studi ini dilakukan oleh (Zhang et al., 2022).



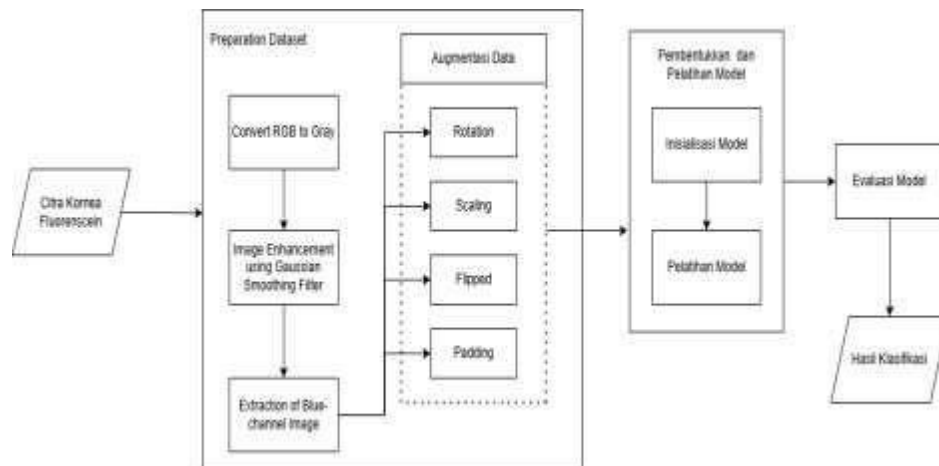
Gambar 2.24. Fishbone Penelitian

BAB 3

METODE PENELITIAN

3.1 Alur Penelitian

Dalam disertasi ini diusulkan metode klasifikasi ulkus kornea pada penderita keratitis menggunakan citra *fluorescein*. Secara garis besar, metode yang diusulkan diperlihatkan oleh bagan pada gambar 3.1.



Gambar 3.1 Bagan Umum Metode Penelitian

Pada Gambar 3.1 menggambarkan peta penelitian yang terbagi menjadi beberapa tahap utama seperti persiapan dataset, augmentasi data, pembentukan dan pelatihan model, evaluasi model dan hasil klasifikasi. Interpretasi hasil klasifikasi oleh model dalam mengidentifikasi dan mengklasifikasikan ulkus kornea untuk dapat memberikan pengobatan yang tepat sesuai dengan penyebab keratitis kornea untuk mencegah kebutaan dini merupakan kebaruan dari disertasi ini.

3.2 Pengumpulan Dataset Citra Mata Fluorescein

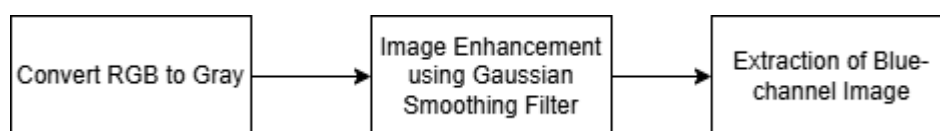
Pengumpulan citra mata fluorescein bersifat sekunder yang merupakan dataset publik berasal dari The-SUSTech-SYSU-Dataset. Terdiri dari 712 citra pewarnaan fluorescein yang dikumpulkan dari pasien dengan berbagai derajat ulkus kornea di Pusat Oftalmologi Zhongshan di Universitas Sun Yat-sen. Gambar 3.2 menunjukkan salah satu contoh citra mata fluorescein pada keratitis bakteri, virus dan jamur yang digunakan dalam penelitian ini.



Gambar 3.2 Citra Fluorescein dari database The-SUSTech-SYSU

3.3 Preparation Dataset

Proses awal melibatkan pengolahan citra kornea fluorescein dimulai dengan konversi citra dari format RGB (*Red, Green, Blue*) ke skala abu-abu lalu melakukan peningkatan kualitas gambar menggunakan filter *Gaussian Smoothing*, dan ekstraksi gambar saluran biru (*Blue Chanel*). Proses ini bertujuan untuk menyederhanakan analisis citra selanjutnya dan meningkatkan efektivitas metode segmentasi yang akan diaplikasikan. Seperti pada Gambar 3.3.



Gambar 3.3 RGB Image Processing

Pada Gambar 3.3 RGB Image Preprocessing *Convert RGB to Gray*: Konversi gambar RGB menjadi gambar skala abu-abu untuk mengurangi kompleksitas

perhitungan selanjutnya dan meningkatkan efektivitas pemrosesan citra. Setelah konversi, citra ditingkatkan kualitasnya menggunakan filter *Gaussian Smoothing* untuk mengurangi noise dan memperhalus gambar. Langkah terakhir dalam persiapan dataset adalah ekstraksi citra saluran biru *Extraction of Blue-channel Image*: Ekstraksi *Blue-channel* dari gambar RGB yang diolah. Tujuan dari ekstraksi *Blue-channel* adalah untuk memfokuskan analisis pada informasi yang lebih relevan yang sering terkandung dalam *Blue-channel*, seperti peningkatan kontras atau detail khusus yang tidak sama terlihat pada *Color-channel* lainnya. Proses ini sangat berguna dalam konteks medis atau aplikasi teknis di mana detail tertentu lebih terlihat dalam *Blue-channel*. Proses *RGB Image Processing* pada dataset dilakukan menggunakan algoritma 3.1.

Algoritma 3.1 Pra-pemrosesan Citra RGB

Input:

RGBImage: Citra dalam format RGB.

Output:

BlueChannellImage: Citra yang hanya berisi saluran biru dari citra RGB asli.

Proses:


1. Konversi RGB ke Skala Abu-abu:
 - Inisialisasi gambar baru GrayImage dengan dimensi yang sama dengan RGBImage.
 - Untuk setiap piksel dalam RGBImage:
 - Ekstrak nilai Merah, Hijau, dan Biru.
 - Hitung nilai keabuan menggunakan formula luminansi:

$$\text{GrayValue} = 0.299 * \text{Red} + 0.587 * \text{Green} + 0.114 * \text{Blue}.$$
 - Tetapkan GrayValue ke piksel yang sesuai di GrayImage.
 - Kembalikan GrayImage.
2. Peningkatan Citra Menggunakan Filter Gaussian:
 - Definisikan kernel Gaussian (misalnya matriks 5x5 atau 3x3 dengan bobot yang telah ditentukan untuk pemulusan).
 - Inisialisasi gambar baru EnhancedImage dengan dimensi yang sama dengan GrayImage.

- Terapkan filter Gaussian pada setiap piksel `GrayImage` dengan menggunakan operasi konvolusi:
 - Untuk setiap piksel di `GrayImage`, gunakan kernel Gaussian pada piksel tersebut dan tetangganya untuk menghitung nilai piksel baru.
 - Tetapkan nilai piksel baru ke `EnhancedImage` pada lokasi yang sama.
- Kembalikan `EnhancedImage`.
- Ekstraksi Saluran Biru dari Citra RGB Asli:
 - Inisialisasi gambar baru '`BlueChannellImage`' dengan dimensi yang sama dengan '`RGBImage`'.
 - Untuk setiap piksel dalam `RGBImage`:
 - Ekstrak nilai biru dari piksel.
 - Tetapkan nilai biru ke piksel yang sesuai di `BlueChannellImage`.
 - Kembalikan '`BlueChannellImage`'.

3.4 Augmentasi Data

Pada tahapan ini untuk meningkatkan performa model *Deep Learning* memerlukan augmentasi data untuk memperkaya dataset dengan berbagai versi dari gambar asli sehingga lebih baik dalam mengenali pola dalam kondisi yang berbeda-beda dan mengurangi kemungkinan *overfitting* pada data yang terlalu homogen. Augmentasi data yang dilakukan pada penelitian ini terdapat pada Gambar 3.4.



Gambar 3.4 Tahapan Proses Augmentasi Data

Gambar 3.4 merupakan proses augmentasi data untuk citra yang mencakup beberapa teknik seperti *rotation* (rotasi) proses ini melibatkan memutar gambar pada berbagai sudut. Rotasi dapat membantu model pembelajaran mesin untuk mengenali objek dalam gambar yang tidak selalu berorientasi dalam cara yang sama sehingga meningkatkan kemampuan model untuk generalisasi. *Scaling* (Penskalaan) melibatkan mengubah ukuran gambar, baik memperbesar maupun memperkecil. Teknik ini penting untuk melatih model agar mengenali objek pada berbagai ukuran dan proporsi dalam gambar. *Flipped* (Pembalikkan) melibatkan membalik gambar secara horizontal atau vertikal. Ini membantu model untuk tidak bias terhadap orientasi tertentu dari objek yang dipelajari. *Padding* (Penambahan Tepi) adalah proses menambahkan tepi pada gambar, yang umumnya berisi piksel transparan atau berwarna tertentu. Teknik ini digunakan untuk mengubah dimensi spasial gambar tanpa mengubah informasi konten yang signifikan. *Padding* juga membantu dalam situasi dimana teknik seperti konvolusi dapat mengurangi dimensi gambar asli. Algoritma di bawah merupakan gambaran proses umum augmentasi data citra yang meningkatkan kemampuan model.

Algoritma 3.2 Augmentasi Data untuk Pemrosesan Citra
Input: <code>InputImage</code> : Citra asli dalam format digital.
Output: <code>AugmentedImages</code> : Kumpulan citra yang telah di-augmentasi.
Proses: <ol style="list-style-type: none"> Rotasi: <ul style="list-style-type: none"> Fungsi <code>RotateImage</code> menerima <code>InputImage</code> dan sebuah parameter sudut rotasi.

- Untuk setiap sudut yang ditentukan (misal 90°, 180°, 270°), citra diputar sesuai dengan sudut tersebut.
- Citra yang telah diputar ditambahkan ke dalam kumpulan `AugmentedImages`.

- **Scaling:**

- Fungsi `ScaleImage` menerima `InputImage` dan parameter skala.
- Citra diubah ukurannya berdasarkan skala yang diberikan (misal skala 0.5 untuk perkecil, skala 2 untuk perbesar).
- Citra yang telah di-scale ditambahkan ke dalam kumpulan `AugmentedImages`.

- **Flipped:**

- Fungsi `FlipImage` menerima `InputImage` dan arah pembalikan (horizontal atau vertikal).
- Citra dibalik sesuai dengan arah yang ditentukan.
- Citra yang telah dibalik ditambahkan ke dalam kumpulan `AugmentedImages`.

- **Padding:**

- Fungsi `PadImage` menerima `InputImage` dan jumlah piksel padding.
- Padding ditambahkan ke sekeliling citra untuk memperbesar dimensi citra tanpa mengubah konten inti.
- Citra yang telah diberi padding ditambahkan ke dalam kumpulan `AugmentedImages`.

3.5 Pembentukan dan Pelatihan Model

Langkah pertama dalam proses pembentukan model adalah inisialisasi model dengan menentukan arsitektur yang sesuai untuk citra kornea *fluorescein*. Sebelum memulai inisialisasi dan pelatihan model data yang telah diproses melalui tahap preparation dataset dan augmentasi data menjadi input penting. Data yang telah di preproses ini akan digunakan untuk melatih model *deep learning* dengan arsitektur CNN setelah itu menentukan nilai-nilai seperti *learning rate*, jumlah *epoch* dan *batch size* yang akan digunakan selama proses pelatihan. Proses pelatihan yakni pemberian *Feed Data* merupakan citra yang telah diolah dan di augmentasi diinput ke dalam model dalam *batch*. Penyesuaian Bobot yakni model menggunakan data tersebut untuk secara bertahap menyesuaikan bobot internalnya guna meminimalkan kesalahan prediksi yang diukur melalui fungsi *loss* seperti *cross-entropy loss* untuk tugas klasifikasi. Validasi Model setelah setiap *epoch*,

Nama Kegiatan	Bulan											
	1	2	3	4	5	6	7	8	9	10	11	12
SEMESTER 1												
Studi Literatur												
Pembuatan Proposalan												
Pengumpulan Dataset (Sekunder)												
SEMESTER 2												
Pembentukan Dataset												
Pembentukkan Model												
Pelatihan dan Pengujian Model												
Penyusunan Penulisan												
SEMESTER 3												

DAFTAR PUSTAKA

- 53rd Hawaii International Conference on System Sciences (HICCS)*, online, January 5-8, 2021. (2021). University of Hawai'i at Manoa.
- Alquran, H., Al-Issa, Y., Alsalatie, M., Mustafa, W. A., Qasmieh, I. A., & Zyout, A. (2022). Intelligent Diagnosis and Classification of Keratitis. *Diagnostics*, 12(6). <https://doi.org/10.3390/diagnostics12061344>
- Deng, L., Lyu, J., Huang, H., Deng, Y., Yuan, J., & Tang, X. (2020). The SUSTech-SYSU dataset for automatically segmenting and classifying corneal ulcers. *Scientific Data*, 7(1). <https://doi.org/10.1038/s41597-020-0360-7>
- DEPARTEMEN ILMU KESEHATAN MATA. (n.d.).
- Ghosh, A. K., & Thammasudjarit, R. (n.d.). *Microbial Keratitis Classification Using Convolutional Neural Network and Transfer Learning*. <https://www.researchgate.net/publication/355093951>
- Hania, A. A. (2017). *Mengenai Artificial Intelligence, Machine Learning, Neural Network, dan Deep Learning*. <https://www.researchgate.net/publication/320395378>
- Hardianto, D., Fitriani Kamal, D., Fauzan Dava, M., Himayani, R., Ristyaning Ayu, P., & Diagnosis dan Tatalaksana Keratitis Bakterial, P. (n.d.). *Penegakan Diagnosis dan Tatalaksana Keratitis Bakterial*.
- Hu, S., Sun, Y., Li, J., Xu, P., Xu, M., Zhou, Y., Wang, Y., Wang, S., & Ye, J. (2023). Automatic Diagnosis of Infectious Keratitis Based on Slit Lamp Images Analysis. *Journal of Personalized Medicine*, 13(3). <https://doi.org/10.3390/jpm13030519>
- Kepustakaan, S. (n.d.). DEPARTEMEN ILMU KESEHATAN MATA FAKULTAS KEDOKTERAN UNIVERSITAS PADJADJARAN PUSAT MATA NASIONAL RUMAH SAKIT MATA CICENDO BANDUNG.
- KERATITIS. (n.d.).
- Koyama, A., Miyazaki, D., Nakagawa, Y., Ayatsuka, Y., Miyake, H., Ehara, F., Sasaki, S. ichi, Shimizu, Y., & Inoue, Y. (2021). Determination of probability of causative pathogen in infectious keratitis using deep learning algorithm of slit-lamp images. *Scientific Reports*, 11(1). <https://doi.org/10.1038/s41598-021-02138-w>
- Kuo, M. T., Hsu, B. W. Y., Lin, Y. S., Fang, P. C., Yu, H. J., Hsiao, Y. T., & Tseng, V. S. (2023). Monitoring the Progression of Clinically Suspected Microbial Keratitis Using Convolutional Neural Networks. *Translational Vision Science and Technology*, 12(11). <https://doi.org/10.1167/tvst.12.11.1>
- Machine Learning. (n.d.).
- Raup, A., Ridwan, W., Khoeriyah, Y., Yuliati Zaqiah, Q., & Islam Negeri Sunan Gunung Djati Bandung, U. (n.d.). *Deep Learning dan Penerapannya dalam Pembelajaran*. <http://jiip.stkipyapisdampu.ac.id>
- Soleimani, M., Esmaili, K., Rahdar, A., Aminizadeh, M., Cheraqpour, K., Tabatabaei, S. A., Mirshahi, R., Bibak, Z., Mohammadi, S. F., Koganti, R., Yousefi, S., & Djalilian, A. R. (2023). From the diagnosis of infectious keratitis to discriminating fungal subtypes; a deep learning-based study. *Scientific Reports*, 13(1). <https://doi.org/10.1038/s41598-023-49635-8>
- Won, Y. K., Lee, H., Kim, Y., Han, G., Chung, T. Y., Ro, Y. M., & Lim, D. H. (2023). Deep learning-based classification system of bacterial keratitis and fungal keratitis

- using anterior segment images. *Frontiers in Medicine*, 10. <https://doi.org/10.3389/fmed.2023.1162124>
- World report on vision Executive Summary*. (n.d.).
- Xu, Y., Kong, M., Xie, W., Duan, R., Fang, Z., Lin, Y., Zhu, Q., Tang, S., Wu, F., & Yao, Y. F. (2021). Deep Sequential Feature Learning in Clinical Image Classification of Infectious Keratitis. *Engineering*, 7(7), 1002–1010. <https://doi.org/10.1016/j.eng.2020.04.012>
- Zhang, Z., Wang, H., Wang, S., Wei, Z., Zhang, Y., Wang, Z., Chen, K., Ou, Z., & Liang, Q. (2022). Deep learning-based classification of infectious keratitis on slit-lamp images. *Therapeutic Advances in Chronic Disease*, 13. <https://doi.org/10.1177/20406223221136071>