



**Pengembangan Sistem Deteksi Kondisi Kesehatan Tulang
Lutut Menggunakan Ekstraksi Fitur Tekstur GLRLM,
Ekstraksi Fitur Warna Histogram dan Model Artificial
Neural Network (ANN)**

KUALIFIKASI

Oleh

Nurfadjri Akbar Rizqi Basuki

NIM: 99223130

**PROGRAM DOKTOR TEKNOLOGI INFORMASI
UNIVERSITAS GUNADARMA
AGUSTUS 2024**

DAFTAR ISI

COVER.....	i
DAFTAR ISI	ii
DAFTAR TABEL	v
DAFTAR GAMBAR.....	vi
BAB 1 PENDAHULUAN.....	1
1.1 Latar Belakang Masalah	1
1.2 Identifikasi Masalah	6
1.3 Batasan Masalah	6
1.4 Tujuan Penelitian.....	6
1.5 Kegunaan Penelitian.....	7
BAB 2 TELAAH PUSTAKA	8
2.1 Artificial Intelligence (AI).....	8
2.1.1 Machine Learning.....	9
2.1.2 Deep Learning	12
2.1.3 Klasifikasi.....	16
2.2 Tulang.....	17
2.2.1 Kondisi Kesehatan Tulang	18
2.2.1.1 Kondisi Tulang Normal	18
2.2.1.2 Kondisi Tulang Osteopenia	20
2.2.1.3 Kondisi Tulang Osteoporosis	22
2.3 Computer Vision	23
2.4 Citra Digital	24
2.5 Object Detection.....	25
2.6 Citra X-Ray	26
2.7 Thresholding.....	26
2.8 Operasi Morfologi	28
2.9 Ekstraksi Fitur Citra Digital	32
2.9.1 Grey Level Run Length Matrix (GLRLM)	32

2.9.1 Histogram	39
2.10 Artificial Neural Network (ANN)	40
2.10.1 Arsitektur Artificial Neural Network	41
2.10.2 ANN Backpropagation	42
2.10.3 Fungsi Aktivasi.....	44
2.11 Confusion Matrix.....	48
2.12 Flowchart.....	51
2.13 Prototype.....	53
2.14 GUI Python Tkinter	55
2.14.1 Widget Tkinter.....	55
2.15 Penelitian Terdahulu.....	55
BAB 3 METODE PENELITIAN	63
3.1 Pengumpulan Data Citra X-Ray Tulang Lutut.....	65
3.2 Pra-Pemrosesan Data Citra.....	66
3.2.1 Proses Resize Data	67
3.2.2 Proses Augmentasi Data.....	70
3.2.3 Proses Grayscale.....	73
3.2.4 Proses Normalisasi Data.....	76
3.2.5 Segmentasi.....	79
3.2.5.1 Proses Thresholding	80
3.2.5.2 Proses Operasi Morfologi.....	83
3.2.6 Ekstraksi Fitur	87
3.2.6.1 Ekstraksi Fitur Tekstur GLRLM.....	87
3.2.6.2 Ekstraksi Fitur Warna Histogram	90
3.3 Pembuatan dan Pelatihan Model	93
3.4 Evaluasi Model.....	96
BAB 4 HASIL PENELITIAN DAN PEMBAHASAN.....	98
4.1 Hasil Akuisisi Citra X-Ray Tulang Lutut.....	98
4.2 Hasil Segmentasi Citra X-Ray Tulang Lutut.....	100
4.3 Hasil Ekstraksi Fitur	104
4.3.1 Hasil Ekstraksi Fitur Tekstur GLRLM.....	105

4.3.2 Hasil Ekstraksi Fitur Warna Histogram	107
4.4 Hasil Pelatihan Model	109
4.5 Hasil Pengujian Model	112
4.6 Prototype Sistem Deteksi Kondisi Kesehatan Tulang Lutut	118
DAFTAR PUSTAKA.....	125

DAFTAR TABEL

Tabel 2.1	Simbol Flowchart	51
Tabel 2.2	Widget Tkinter	55
Tabel 2.3	Penelitian Terdahulu	59
Tabel 4.1	Hasil Akuisisi Citra X-Ray Tulang Lutut	98
Tabel 4.2	Citra Hasil Proses Thresholding.....	100
Tabel 4.3	Citra Hasil Proses Operasi Morfologi	102
Tabel 4.4	Hasil Ekstraksi Fitur Tekstur GLRLM	105
Tabel 4.5	Hasil Ekstraksi Fitur Warna Histogram	108
Tabel 4.6	Hasil Pelatihan Model ANN	110
Tabel 4.7	Uji Coba Model ANN	112

DAFTAR GAMBAR

Gambar 2.1	Artificial Intelligence, Machine Learning dan Deep	8
Gambar 2.2	Struktur Neural Network	13
Gambar 2.3	Fungsi Aktivasi ReLU	14
Gambar 2.4	(a) Neural Network Standar, (b) Neural Network	15
Gambar 2.5	Kondisi Tulang Normal	20
Gambar 2.6	Kondisi Tulang Osteopenia	21
Gambar 2.7	Kondisi Tulang Osteoporosis	23
Gambar 2.8	Citra X-Ray.....	26
Gambar 2.9	Citra Asli.....	27
Gambar 2.10	Citra Biner	28
Gambar 2.11	Sebelum Operasi Dilasi	29
Gambar 2.12	Sesudah Operasi Dilasi.....	29
Gambar 2.13	Sebelum Operasi Erosi	30
Gambar 2.14	Sesudah Operasi Erosi	30
Gambar 2.15	Sebelum Operasi Opening	31
Gambar 2.16	Sesudah Operasi Opening.....	31
Gambar 2.17	Sebelum Operasi Closing	32
Gambar 2.18	Sesudah Operasi Closing	32
Gambar 2.19	Orientasi Sudut Arah	33
Gambar 2.20	Matriks Contoh Nilai Piksel Citra	33
Gambar 2.21	Matriks GLRLM contoh nilai piksel citra a) 0°	34
Gambar 2.22	Jaringan Saraf Manusia dan ANN	41
Gambar 2.23	Multilayer ANN.....	42
Gambar 2.24	Algoritma Backpropagation	43
Gambar 2.25	Struktur ANN	45
Gambar 2.26	Fungsi Aktivasi Linier	45
Gambar 2.27	Fungsi Aktivasi Sigmoid	46
Gambar 2.28	Fungsi Aktivasi ReLU	47

Gambar 2.29 Fungsi Aktivasi Softmax	47
Gambar 2.30 Confusion Matrix.....	48
Gambar 3.1 Tahapan Penelitian	64
Gambar 3.2 Citra X-Ray Tulang Lutut.....	66
Gambar 3.3 Flowchart Pra-Pemrosesan Data Citra.....	67
Gambar 3.4 Flowchart Proses Resize Data	68
Gambar 3.5 Transformasi Proses Resize Data	70
Gambar 3.6 Flowchart Proses Augmentasi Data.....	71
Gambar 3.7 Transformasi Proses Augmentasi Data.....	73
Gambar 3.8 Flowchart Proses Grayscale.....	74
Gambar 3.9 Transformasi Proses Grayscale	76
Gambar 3.10 Flowchart Proses Normalisasi Data.....	77
Gambar 3.11 Transformasi Proses Normalisasi Data.....	79
Gambar 3.12 Proses Segmentasi Citra X-Ray Tulang Lutut.....	80
Gambar 3.13 Flowchart Proses Thresholding	81
Gambar 3.14 Transformasi Citra Biner X-Ray Tulang Lutut	83
Gambar 3.15 Flowchart Proses Operasi Morfologi.....	84
Gambar 3.16 Transformasi Citra Biner Operasi Morfologi X-Ray	86
Gambar 3.17 Flowchart Ekstraksi Fitur Tekstur GLRLM.....	89
Gambar 3.18 Flowchart Ekstraksi Fitur Warna Histogram	92
Gambar 3.19 Arsitektur Model ANN	95
Gambar 3.20 Flowchart Pembuatan dan Pelatihan Model	96
Gambar 4.1 Hasil Grafik Ekstraksi Fitur Histogram.....	108
Gambar 4.2 Grafik Akurasi dan Loss	111
Gambar 4.3 Confusion Matrix.....	111
Gambar 4.4 Tampilan Menu Utama	119
Gambar 4.5 Tampilan Menu Panduan Sistem Deteksi Kondisi	120
Gambar 4.6 Tampilan Menu Koleksi Kondisi Kesehatan Tulang	121
Gambar 4.7 Tampilan Menu Tentang Sistem Deteksi Kondisi.....	122
Gambar 4.8 Tampilan Menu Tentang Saya.....	122
Gambar 4.9 Tampilan Menu Proses Deteksi	123

Gambar 4.10 Tampilan Hasil Deteksi Kondisi Kesehatan Tulang.....	124
--	-----

BAB 1

PENDAHULUAN

1.1 Latar Belakang Masalah

Perkembangan kecerdasan buatan atau Artificial Intelligence (AI) dalam beberapa tahun terakhir telah memberikan manfaat besar di sektor kesehatan, termasuk dalam otomatisasi proses deteksi kondisi kesehatan tulang lutut yang sebelumnya dilakukan secara manual. Berbagai aplikasi AI kini mampu mendiagnosis kondisi tulang lutut dengan lebih efisien, memungkinkan tenaga medis untuk fokus pada tugas-tugas yang lebih esensial. Selain itu, AI mampu menangani analisis yang kompleks di beberapa bidang sehingga memberikan kontribusi signifikan dalam deteksi dini kondisi kesehatan tulang lutut dan proses diagnosis (Ali et al., 2023; Ella Hassanien et al., 2021; Hee Lee & Yoon, 2021).

Sistem kesehatan berbasis AI terus berkembang, menawarkan kemampuan untuk menyelesaikan tugas dengan kecepatan, keandalan dan ketekunan yang sulit dicapai oleh manusia, sering kali dengan biaya yang lebih rendah. Pengembang sistem informasi (SI) yang berhasil merancang sistem AI yang efektif membantu mengatasi berbagai tantangan dalam digitalisasi layanan kesehatan (Ahmed et al., 2020). Implementasi AI telah terbukti dapat meningkatkan kualitas perawatan pasien sambil secara signifikan mengurangi biaya kesehatan (Wolff et al., 2020). Penerapan AI juga menunjukkan potensi besar dalam deteksi dini dan manajemen kondisi kesehatan tulang lutut, seperti osteoporosis (Smets et al., 2021). Teknologi AI membantu mengidentifikasi risiko fraktur pada pasien dengan lebih akurat dan memberikan rekomendasi intervensi yang tepat (Fasihi et al., 2022).

Penyakit tulang lutut seperti osteoporosis sering menyebabkan kecacatan, terutama pada orang tua (Clynes et al., 2020). Kondisi tulang lutut seperti osteoporosis terjadi akibat hilangnya mineral pada tulang dan kerusakan struktur mikro tulang. Selain pemeriksaan dokter, deteksi osteoporosis menggunakan sinar-X tetap menjadi metode penting dalam membantu dokter menentukan keberadaan

dan perkembangan penyakit tulang lutut seperti osteoporosis (Withers et al., 2021). Peneliti telah mengembangkan teknik analisis citra tulang berbasis komputer untuk membantu diagnosis (Hussain et al., 2022). Tantangan utama dalam klasifikasi adalah gambar tulang penderita osteoporosis sering kali mirip dengan gambar tulang sehat, membuat proses klasifikasi menjadi sulit (Fathi Kazerooni et al., 2020). Meski demikian, penelitian di bidang analisis citra tulang berbasis komputer menunjukkan hasil yang menjanjikan. Gambar tulang yang sakit dan sehat dapat dibedakan menggunakan pendekatan pembelajaran mesin yang mengandalkan analisis tekstur gambar dan warna gambar (Motahhir & Bossoufi, 2021; Yousfi et al., 2020). Pendekatan berbasis pembelajaran mesin menyediakan data yang beragam untuk membedakan dan mengklasifikasikan gambar dengan sukses. Dalam pemeriksaan osteoporosis, ukuran dan kepadatan garis tekstur adalah faktor penting (Zaworski et al., 2021).

Penelitian yang dilakukan oleh Kavita Avinash Patil, K. V. Mahendra Prashanth dan A. Ramalingaiah pada tahun 2021 memanfaatkan ekstraksi fitur tekstur dari citra radiografi tulang belakang menggunakan filter Laplacian of Gaussian dan klasifikasi KNN untuk mendiagnosis osteoporosis. Metode Laplacian of Gaussian dan klasifikasi KNN mencapai tingkat akurasi klasifikasi yang tinggi, sebesar 97,22%, dengan dimensi fitur tekstur yang lebih rendah. Pengurangan dimensi fitur tekstur, kuantisasi dan pengkodean skala dengan pengali bobot berperan penting dalam meningkatkan akurasi diagnosis osteoporosis pada citra radiografi tulang belakang (Patil et al., 2021).

Penelitian yang dilakukan oleh Zhihao Xue, Jiayu Huo, Xiaojiang Sun, Xuzhou Sun, Songtao Ai, Lichi Zhang dan Chenglei Liu pada tahun 2022 memanfaatkan fitur radiomik dari citra CT tulang belakang lumbal untuk membedakan osteoporosis dari kepadatan tulang normal. Para peneliti menghasilkan model prediktif yang sangat baik dengan menggunakan fitur radiomik untuk mengidentifikasi osteoporosis dari citra CT tulang belakang lumbal. Model klasifikasi berbasis random forest (RF) menunjukkan kinerja terbaik dengan AUC sebesar 0,994 (interval kepercayaan 95%: 0,979–1,00) untuk membedakan

kepadatan tulang normal dari osteoporosis. Hasil penelitian menunjukkan bahwa citra CT tulang belakang lumbal dapat digunakan secara efektif untuk mengidentifikasi osteoporosis dan sebagai alat skrining osteoporosis oportunistik (Xue et al., 2022).

Penelitian yang dilakukan oleh Juan Du, Junying Wang, Xinghui Gai, Yan Sui, Kang Liu dan Dewu Yang pada tahun 2022 menggunakan analisis citra sinar-X cerdas untuk menilai risiko fraktur osteoporotik leher femur pada populasi lanjut usia. Tujuannya adalah meningkatkan efisiensi dan akurasi penyaringan penyakit pada populasi lanjut usia. Hasil penelitian menunjukkan bahwa model penilaian risiko fraktur osteoporotik leher femur pada populasi lanjut usia layak untuk diuji. Model jaringan saraf tiruan mencapai akurasi yang tinggi (95,83%) dan tingkat ingat sempurna (100,00%), sementara model prediksi mesin vektor dukungan memiliki spesifisitas yang tinggi (62,50%). Dengan memanfaatkan pembelajaran mesin untuk membuat model penilaian risiko fraktur osteoporotik leher femur, penelitian yang dilakukan dapat mendukung keputusan klinis dalam penilaian risiko fraktur pada populasi lanjut usia dan membantu klinik dalam memberikan intervensi yang ditargetkan bagi kelompok risiko tinggi, sehingga mengurangi risiko fraktur (Du et al., 2023).

Penelitian terkait deteksi osteoporosis telah menunjukkan kemajuan signifikan, namun terdapat celah penting yang dapat diisi dengan mengembangkan pendekatan berdasarkan ukuran dan kepadatan garis tekstur. Salah satu metode yang dapat digunakan adalah GLRLM (Gray-Level Run Length Matrix) untuk ekstraksi fitur tekstur dan Histogram untuk ekstraksi fitur warna, serta model ANN (Artificial Neural Network) untuk deteksi kondisi kesehatan tulang lutut normal, osteopenia dan osteoporosis (Dash & Senapati, 2021). Metode GLRLM, Histogram dan ANN menawarkan potensi untuk meningkatkan deteksi kondisi kesehatan tulang lutut.

Metode GLRLM merupakan teknik analisis tekstur yang mengekstrak informasi penting dari citra X-ray tulang lutut, sehingga membantu dalam mendeteksi osteoporosis (Koyuncu & Barstuğan, 2021). Osteoporosis adalah

kondisi yang ditandai dengan penurunan kepadatan tulang, dapat menyebabkan perubahan mikrostruktur tulang yang terlihat pada citra X-ray. GLRLM bekerja dengan menghitung distribusi panjang run piksel dengan nilai intensitas yang sama, di mana run didefinisikan sebagai urutan piksel yang berdekatan dengan nilai intensitas yang sama. Metode GLRLM menghasilkan matriks yang berisi informasi tentang frekuensi kemunculan run dengan panjang dan tingkat intensitas tertentu. Fitur-fitur yang dihasilkan dari GLRLM seperti panjang run rata-rata, jumlah run dan entropi, memberikan informasi berharga tentang pola tekstur dan perubahan mikrostruktur tulang. Penurunan kepadatan tulang dan perubahan struktur trabekula yang merupakan ciri khas osteoporosis dapat diidentifikasi dengan menganalisis perubahan pola run piksel dalam citra X-ray.

Sementara itu, metode Histogram digunakan untuk menghitung distribusi intensitas piksel dalam gambar (Barbosa et al., 2021). Pada citra X-ray tulang lutut, distribusi intensitas piksel menunjukkan variasi kecerahan yang terkait dengan kepadatan tulang. Tulang yang lebih padat akan menghasilkan gambar yang lebih terang dengan piksel yang lebih banyak di area intensitas tinggi, sedangkan tulang yang kurang padat akan menghasilkan gambar yang lebih gelap dengan piksel yang lebih banyak di area intensitas rendah. Analisis variasi kecerahan yang diperoleh dari histogram dapat memberikan informasi penting tentang kondisi kesehatan tulang. Pergeseran kurva histogram ke kiri, yang menunjukkan peningkatan piksel di area intensitas rendah, dapat mengindikasikan penurunan kepadatan tulang dan berpotensi osteoporosis.

Metode analisis tekstur GLRLM dimanfaatkan untuk mengekstraksi fitur-fitur penting dari citra X-ray tulang lutut, termasuk Short Run Emphasis (SRE), Long Run Emphasis (LRE), Gray Level Non Uniformity (GLNU), Run Length Non Uniformity (RLNU), Run Percentage (RP), Low Gray Level Run Emphasis (LGRE), High Gray Level Run Emphasis (HGRE), Short Run Low Gray Level Emphasis (SRLGLE), Short Run High Gray Level Emphasis (SRHGLE) dan Long Run High Gray Level Emphasis (LRHGLE). Fitur histogram digunakan untuk merepresentasikan distribusi intensitas piksel dari 0 hingga 255 dalam citra X-ray

tulang lutut. Fitur-fitur GLRLM dan histogram kemudian diintegrasikan dan dianalisis menggunakan model ANN, yang merupakan metode pembelajaran mesin mendalam (Abdolrasol et al., 2021). Kemampuan ANN dalam mengenali pola kompleks dalam citra medis menjadikannya alat yang tepat untuk mendeteksi kondisi kesehatan tulang lutut dengan tingkat akurasi yang tinggi. Integrasi GLRLM, histogram dan ANN dalam sistem deteksi kondisi kesehatan tulang lutut memungkinkan analisis tekstur yang lebih komprehensif dan mendalam, sehingga meningkatkan kemampuan dalam mengidentifikasi perubahan mikrostruktur tulang yang terkait dengan osteoporosis.

Dengan demikian, untuk memanfaatkan celah yang ada berdasarkan ukuran dan kepadatan garis tekstur pada penelitian yang sudah dilakukan sebelumnya, penelitian ini menggabungkan dua metode ekstraksi fitur, yaitu GLRLM dan Histogram, untuk mendeteksi osteoporosis secara lebih akurat. GLRLM digunakan untuk mengekstrak fitur tekstur dari citra X-ray tulang lutut, sedangkan Histogram digunakan untuk mengekstrak fitur warna. Fitur-fitur GLRLM dan histogram kemudian diintegrasikan dan dianalisis menggunakan model ANN, yang merupakan metode pembelajaran mesin mendalam. Integrasi GLRLM, Histogram dan ANN dalam penelitian ini memiliki beberapa keunggulan. Pertama, analisis tekstur yang lebih komprehensif; GLRLM mampu menangkap pola tekstur yang kompleks dalam citra X-ray, sehingga memberikan informasi yang lebih kaya tentang perubahan mikrostruktur tulang yang terkait dengan osteoporosis. Kedua, ekstraksi fitur warna yang akurat; Histogram memungkinkan ekstraksi fitur warna yang tepat dari citra X-ray, yang dapat membantu dalam mendeteksi perubahan warna tulang yang terkait dengan osteoporosis. Ketiga, kemampuan deteksi yang tinggi; model ANN yang digunakan mampu mengenali pola kompleks dalam data fitur, sehingga meningkatkan akurasi deteksi osteoporosis. Pendekatan yang mengintegrasikan GLRLM dan Histogram untuk ekstraksi fitur dari citra X-ray tulang lutut, serta menerapkan model ANN untuk analisis mendalam, diharapkan dapat memberikan solusi yang lebih canggih dan efektif dalam mendeteksi risiko serta mendiagnosis osteoporosis. Penelitian ini dapat memberikan manfaat yang

signifikan bagi pengobatan dan pencegahan penyakit pada kondisi kesehatan tulang, khususnya osteoporosis, serta meningkatkan kualitas hidup pasien.

1.2 Identifikasi Masalah

Berdasarkan latar belakang yang telah dijelaskan, identifikasi masalah dalam penelitian ini adalah:

1. Bagaimana mengembangkan algoritma ekstraksi fitur tekstur menggunakan metode GLRLM dan algoritma ekstraksi fitur warna menggunakan metode Histogram untuk mendeteksi kondisi kesehatan tulang lutut?
2. Bagaimana mengembangkan model ANN untuk mendeteksi kondisi kesehatan tulang lutut setelah melakukan ekstraksi fitur menggunakan GLRLM dan Histogram?
3. Bagaimana mengembangkan sistem deteksi kondisi kesehatan tulang lutut secara real-time?

1.3 Batasan Masalah

Batasan masalah dalam penelitian ini adalah sebagai berikut:

1. Penelitian difokuskan pada deteksi kondisi kesehatan tulang lutut.
2. Data yang digunakan berupa gambar sinar-X (X-ray) tulang lutut.
3. Analisis berfokus pada ekstraksi fitur tekstur menggunakan GLRLM, ekstraksi fitur warna menggunakan Histogram dan penerapan model ANN.
4. Jumlah total data dalam dataset adalah 1.136 gambar sinar-X tulang lutut yang telah di augmentasi menjadi 3.203 gambar.

1.4 Tujuan Penelitian

Tujuan dari penelitian ini adalah:

1. Mengembangkan algoritma ekstraksi fitur tekstur menggunakan metode GLRLM dan algoritma ekstraksi fitur warna menggunakan metode Histogram untuk mendeteksi kondisi kesehatan tulang lutut.

2. Mengembangkan model ANN untuk mendeteksi kondisi kesehatan tulang lutut setelah melakukan ekstraksi fitur menggunakan GLRLM dan Histogram.
3. Mengembangkan sistem deteksi kondisi kesehatan tulang lutut secara real-time.

1.5 Kegunaan Penelitian

Manfaat penelitian ini adalah sebagai berikut:


1. Kontribusi Ilmiah: Penelitian ini memberikan kontribusi penting dalam bidang kedokteran dengan memanfaatkan kecerdasan buatan dan teknik deep learning untuk mendeteksi osteoporosis dari citra X-ray tulang. Dengan demikian, penelitian ini membuka pintu untuk penemuan fitur-fitur baru atau kombinasi fitur yang lebih efektif dalam mendeteksi kondisi ini, yang pada akhirnya dapat meningkatkan akurasi diagnosis dan perawatan.
2. Kemajuan Teknologi: Penggunaan teknologi AI dan deep learning menandai kemajuan signifikan dalam bidang pengolahan citra medis. Dengan menerapkan algoritma-algoritma canggih, penelitian ini memungkinkan analisis citra X-ray yang lebih cepat dan akurat dibandingkan metode manual tradisional, tidak hanya mempercepat proses diagnosis, tetapi juga membuka jalan untuk pengembangan sistem otomatisasi yang dapat membantu dokter dalam mengambil keputusan yang lebih tepat.
3. Implikasi Praktis: Penelitian ini memiliki implikasi praktis yang besar dalam pelayanan kesehatan. Dengan menggunakan pendekatan berbasis AI, penelitian ini dapat membantu dokter dalam mendeteksi osteoporosis secara lebih efisien dan tepat waktu, yang pada akhirnya dapat meningkatkan prognosis dan perawatan pasien. Selain itu, dengan teknologi yang semakin canggih, implementasi sistem pendeteksian otomatis dapat dilakukan secara luas di berbagai fasilitas kesehatan, bahkan di daerah yang memiliki akses terbatas terhadap spesialis medis penelitian ini dapat meningkatkan aksesibilitas layanan kesehatan dan mengurangi beban kerja profesional medis.

BAB 2

TELAAH PUSTAKA

2.1 Artificial Intelligence (AI)

Kecerdasan Buatan (AI) merujuk pada sistem buatan yang dirancang untuk mengumpulkan pengetahuan dan informasi, serta memprosesnya menjadi kecerdasan yang dapat dimanfaatkan. AI juga dapat dianggap sebagai setiap metode komputasi yang mampu melakukan tugas-tugas yang sebelumnya hanya dilakukan oleh manusia. Pembelajaran Mesin adalah bentuk AI di mana komputer belajar dari data yang ada tanpa pemrograman yang spesifik. Pembelajaran Mendalam adalah jenis khusus dari Pembelajaran Mesin yang menggunakan arsitektur tertentu, seperti jaringan saraf dan mampu meningkatkan kinerja dengan bertambahnya data. Pembelajaran Mendalam sangat bergantung pada kemampuannya untuk secara otomatis mengenali fitur-fitur penting. Dalam pengembangan AI, pengetahuan diperoleh melalui proses Pembelajaran Mesin. Pembelajaran Mesin memiliki dua teknik utama: Pembelajaran Terawasi dan Pembelajaran Tak Terawasi. Pembelajaran Mendalam merupakan bagian dari Pembelajaran Terawasi (C. Zhang & Lu, 2021). Seperti pada Gambar 2.1.



Gambar 2.1 Artificial Intelligence, Machine Learning dan Deep Learning

2.1.1 Machine Learning

Pembelajaran Mesin (Machine Learning) adalah serangkaian teknik yang digunakan untuk memproses data dan membuat prediksi menggunakan algoritma pembelajaran. Dengan bantuan Pembelajaran Mesin, komputer dapat secara otomatis mempelajari dari data yang diberikan. Menurut (Janiesch et al., 2021), tujuan dari pembelajaran mesin adalah menciptakan perangkat lunak yang mampu belajar dari pengalaman sebelumnya. Program komputer yang mampu belajar dari pengalaman sebelumnya dapat meningkatkan kinerjanya seiring dengan pertumbuhan jumlah data yang dapat diakses, memungkinkan mereka untuk mengenali pola dan menghasilkan kecerdasan buatan untuk data masukan yang baru. Karena mesin mencoba menemukan pola dari data yang tersedia, pembelajaran mesin juga sering disebut sebagai pembelajaran induktif.

1. Komponen Machine Learning

Menurut (Bhavsar et al., 2021) komponen-komponen dalam Machine Learning terdiri dari beberapa bagian yang mencakup:

a Pembelajaran

Tahap pembelajaran menjelaskan bahwa algoritma digunakan sebagai fondasi utama dalam metode pembelajaran mesin. Pemilihan algoritma bergantung pada jenis permasalahan yang akan dipecahkan, karena setiap algoritma cocok untuk menangani permasalahan tertentu.

b Kumpulan Data

Kumpulan data merupakan data mentah yang menjadi fokus penelitian. Data mentah bisa berlabel atau tidak berlabel. Penting untuk memiliki jumlah sampel data yang memadai agar proses pembelajaran dapat memahami struktur masalah secara efektif.

c Representasi Data

Representasi data adalah proses menggambarkan atau mewakili data berdasarkan fitur-fitur yang dipilih untuk digunakan

dalam proses pembelajaran. Sebagai contoh, dalam klasifikasi gambar, gambar direpresentasikan sebagai larik nilai-nilai, di mana setiap sel dalam larik berisi nilai warna dari satu piksel. Pemilihan representasi data yang tepat akan sangat memengaruhi hasil akhir pembelajaran dan dapat membantu mencapai hasil yang lebih optimal.

d Tujuan atau Sasaran

Bagian tujuan atau sasaran menjelaskan pentingnya pembelajaran dari data untuk menyelesaikan masalah. Tujuannya adalah membantu menetapkan strategi pembelajaran dan representasi data yang sesuai. Dengan pemahaman dan ekstraksi informasi dari data, kita dapat membuat keputusan berdasarkan metode pembelajaran yang sesuai dan menetapkan hasil yang diharapkan dari analisis data.

e Target

Target menunjukkan apa yang dipelajari dan hasil akhir yang diinginkan. Target dapat berupa klasifikasi data tanpa label, pola-pola tertentu dalam representasi data, prediksi masa depan atau respons terhadap stimulus atau strategi tertentu. Dalam pembelajaran mesin, menetapkan target yang jelas sangat penting karena akan memandu penggunaan metode pembelajaran yang tepat dan menentukan hasil yang diharapkan dari analisis data.

2. Tipe Machine Learning

Menurut (Sarker, 2021) Machine Learning dibagi menjadi 3 tipe berdasarkan cara pembelajarannya, yaitu:

a Supervised Learning

Secara umum, Supervised Learning melibatkan proses pembelajaran dari data yang telah diberi label. Untuk melatih model, pembelajaran terawasi membutuhkan data berlabel sebagai panduan untuk memahami pola dan membangun representasi yang tepat.

Misalnya, dengan memberikan data berlabel tentang gambar dan kelas objek yang sesuai, kita dapat melatih model untuk mengenali objek dalam gambar. Dengan cara memberikan data berlabel tentang gambar dan kelas objek yang sesuai, model dapat belajar dan mengidentifikasi pola yang diperlukan untuk mencapai tujuan klasifikasi yang diinginkan.

b Unsupervised Learning

Unsupervised Learning melibatkan pemodelan data tanpa memerlukan label. Teknik unsupervised learning dapat menemukan pola dan struktur dalam data tanpa bantuan label. Dalam pembelajaran tanpa pengawasan, terdapat dua metode yang umum digunakan, yaitu pengelompokan dan pengurangan dimensi. Melalui pengelompokan, data dapat dikelompokkan berdasarkan kesamaan karakteristik tanpa label sebelumnya. Sementara itu, pengurangan dimensi bertujuan untuk mengurangi jumlah fitur dalam data sambil mempertahankan informasi penting, memudahkan analisis dan visualisasi data yang kompleks.

c Reinforcement Learning

Reinforcement Learning adalah metode pembelajaran mesin yang melatih model dengan mengamati bagaimana lingkungan merespons tindakan yang dilakukan. Jenis pembelajaran Reinforcement Learning melibatkan interaksi dengan lingkungan untuk mempelajari rangkaian aktivitas yang memberikan imbalan optimal. Dalam pembelajaran penguatan, model belajar dari pengalaman dan berusaha mengambil tindakan yang sesuai dengan keadaan lingkungan saat itu, dengan tujuan mencapai hasil yang diinginkan dan mengoptimalkan total imbalan yang diperoleh.

2.1.2 Deep Learning


Deep Learning, yang juga dikenal sebagai pembelajaran mendalam, adalah teknik komputasi yang memungkinkan penggunaan pemrosesan bertingkat untuk membentuk model yang dapat mempelajari representasi data dengan berbagai tingkat abstraksi. Algoritma backpropagation digunakan untuk menemukan struktur kompleks dari kumpulan data besar melalui pembelajaran mendalam. Algoritma backpropagation mengatur bagaimana mesin mengubah parameter internal yang digunakan untuk menghitung representasi di setiap lapisan, berdasarkan representasi di lapisan sebelumnya (Aboul Ella Hassanien et al., 2020).

1. Neural Network

Istilah "neural network" pertama kali digunakan untuk mencari representasi matematis dari pemrosesan informasi dalam sistem biologis. Jaringan saraf terdiri dari beberapa node yang menyerupai neuron dalam organisme hidup. Setiap node melakukan perhitungan dengan menjumlahkan bobot input dan memprosesnya melalui lapisan tersembunyi, kemudian menghasilkan output melalui fungsi aktivasi dengan bobot tertentu. Jaringan saraf awalnya sederhana, hanya memiliki satu lapisan masukan dan satu lapisan keluaran, disebut jaringan saraf lapisan tunggal. Namun, dengan menambahkan lapisan tersembunyi, jaringan saraf multi-lapisan dapat dibentuk. Oleh karena itu, Gambar 2.2 menggambarkan jaringan saraf berlapis-lapis yang terdiri dari lapisan input, tersembunyi dan output.

Nilai masukan neuron (x) dikalikan dengan bobot (w) dan kemudian ditambahkan bias (b) untuk mendapatkan hasil penjumlahan linear, (i) adalah indeks yang menunjukkan elemen ke- (i) dari total (n) elemen input yang ada. Jumlah total elemen input dilambangkan dengan (n). Hasil perhitungan kemudian diproses melalui fungsi aktivasi (g) untuk menghasilkan keluaran neuron (y). Proses perhitungan dijelaskan dalam Persamaan (2.1).

$$y = g \left(\sum_{i=1}^n x_i w_i + b \right) \quad (2.1)$$



Gambar 2.2 Struktur Neural Network

2. Fungsi Aktivasi

Fungsi aktivasi adalah fungsi yang menentukan aktivasi atau non-aktivasi neuron dalam jaringan saraf. Berikut adalah beberapa contoh fungsi aktivasi:

a Softmax

Fungsi softmax adalah fungsi eksponensial yang mengubah vektor nilai riil berdimensi-D menjadi vektor probabilitas berdimensi-D dalam rentang $[0, 1]$. Regresi logistik, jaringan saraf tiruan dan pembelajaran penguatan menggunakan fungsi softmax sebagai aplikasi pembelajaran mesin. Fungsi softmax memungkinkan perhitungan probabilitas untuk semua label di output. Rumus untuk Softmax diberikan oleh Persamaan (2.2), di mana probabilitas ($S(y_i)$) untuk kelas tertentu (y_i) diambil dari neuron di lapisan klasifikasi akhir. Nilainya dihitung menggunakan fungsi eksponensial (e) dan dinormalisasi dengan membaginya dengan jumlah semua nilai eksponensial $\sum_j e^{y_i}$, (i) menunjukkan indeks kelas tertentu yang probabilitasnya sedang dihitung,


sedangkan (j) adalah indeks yang digunakan untuk menjumlahkan semua kelas. Hasilnya adalah vektor nilai probabilitas yang berkisar dari 0 hingga 1. Jika semua nilai probabilitas dijumlahkan, hasilnya adalah 1.

$$S(y_i) = \frac{e^{y_i}}{\sum_j e^{y_i}} \quad (2.2)$$

b Rectified Linear Unit (ReLU)

ReLU secara signifikan meningkatkan kinerja model dan mengurangi jumlah perhitungan yang diperlukan selama pelatihan. Fungsi relu dihitung dengan menggunakan rumus $f(z) = \max(0, z)$, yang berarti jika nilai keluaran (z) positif, fungsi akan menghasilkan nilai yang sama dengan z, tetapi jika z negatif, fungsi akan menghasilkan nilai 0.

ReLU digunakan karena ketika nilai z negatif, ReLU menghasilkan nilai 0, membuat neuron pada lapisan yang menggunakan aktivasi relu tidak aktif atau "non-activated". Dengan demikian, ReLU membantu meningkatkan efisiensi perhitungan dan mengurangi risiko vanishing gradient, yaitu ketika gradient menjadi sangat kecil sehingga menghambat pembelajaran dalam model. Hasil dari fungsi ReLU dapat dilihat pada Gambar 2.3.




Gambar 2.3 Fungsi Aktivasi ReLU

3. Dropout

Salah satu cara untuk mengatasi overfitting dalam model adalah dengan menggunakan metode dropout. Dalam pendekatan teknik dropout, beberapa neuron dalam jaringan secara acak "dijatuhkan" atau dihapus selama proses pelatihan. Setiap iterasi pelatihan, neuron yang dipilih untuk "dijatuhkan" mengalami perubahan status. Teknik dropout membantu mengurangi risiko overfitting dan meningkatkan generalisasi model.

Dropout mengacu pada penghapusan sementara neuron dalam jaringan saraf, baik yang tersembunyi maupun terlihat. Penghapusan sementara neuron dalam jaringan saraf terjadi ketika unit atau neuron, bersama dengan semua koneksi masukan dan keluarannya, dihapus dari jaringan, seperti yang ditunjukkan pada Gambar 2.4. Penghapusan sementara neuron dalam jaringan saraf membuat model menjadi kurang bergantung pada neuron tertentu, sehingga lebih mudah disesuaikan dan digeneralisasi. Proses penghapusan unit dilakukan secara acak dalam setiap iterasi pelatihan.



Gambar 2.4 (a) Neural Networks Standar, (b) Neural Networks dengan DropOut

4. Fungsi Loss

Fungsi loss digunakan untuk mengevaluasi kinerja suatu algoritma dalam memodelkan data yang diberikan. Fungsi loss mengukur perbedaan antara hasil prediksi dari algoritma dengan nilai sebenarnya dari data. Jika terdapat perbedaan besar antara prediksi dan nilai sebenarnya, fungsi loss akan memberikan nilai yang tinggi. Selama proses pelatihan, dengan menggunakan berbagai teknik optimisasi, fungsi loss berusaha untuk mengurangi kesalahan dalam prediksi dan secara bertahap meminimalkan perbedaan antara hasil prediksi dan data aktual.

5. Backpropagation

Backpropagation merupakan algoritma yang digunakan untuk mencari nilai minimum dari fungsi loss dengan menyesuaikan bobot dalam jaringan saraf menggunakan teknik yang dikenal dengan delta rule atau gradient descent. Tujuannya adalah untuk mengurangi bobot dan memecahkan masalah pembelajaran dengan mengurangi fungsi loss. Algoritma backpropagation terdiri dari empat tahap utama:

- a Feedforward: Melakukan proses forward pass melalui jaringan saraf untuk mendapatkan prediksi model berdasarkan bobot saat feedforward.
- b Komputasi Loss: Menghitung kerugian atau kesalahan antara prediksi model dan data aktual yang diberikan.
- c Backpropagation: Menghitung gradien fungsi loss terhadap setiap bobot dalam jaringan menggunakan aturan delta atau metode penurunan gradien.
- d Pembaruan Bobot: Menyesuaikan bobot dengan mengurangi gradien bobot saat pembaruan bobot untuk meminimalkan fungsi loss, sehingga memungkinkan model untuk belajar dan meningkatkan kinerjanya.

2.1.3 Klasifikasi

Salah satu jenis analisis data yang dikenal sebagai klasifikasi bertujuan untuk menggambarkan, mengkategorikan atau mengelompokkan data ke dalam kelas tertentu. Dalam klasifikasi, model atau klasifier dibangun untuk meramalkan

label kelas atau kategori untuk data, seperti memprediksi apakah cuaca akan hujan atau cerah. Label kelas biasanya direpresentasikan oleh nilai diskrit, di mana urutan antar nilai tidak memiliki makna. Proses klasifikasi terdiri dari dua langkah. Langkah pertama adalah proses pembelajaran, di mana model klasifikasi dibangun atau dilatih menggunakan data pelatihan. Langkah kedua adalah proses klasifikasi aktual, di mana model yang telah dibangun digunakan untuk meramalkan label atau kategori data (Shao et al., 2021).

2.2 Tulang

Tulang adalah jaringan hidup. Sebagai jaringan ikat, tulang terdiri dari sel dan matriks organik ekstraseluler yang diproduksi oleh sel. Sel-sel tulang yang memproduksi matriks organik dikenal sebagai osteoblas ("pembentuk tulang"). Matriks organik terdiri dari serat kolagen dalam gel setengah padat. Matriks organik memiliki konsistensi seperti karet dan berfungsi untuk menentukan kekuatan tarik tulang (kemampuan tulang menahan patahan akibat tegangan). Kekerasan tulang berasal dari pengendapan kristal kalsium fosfat dalam matriks. Kristal anorganik memberikan tulang kekuatan kompresi (kemampuan tulang mempertahankan bentuk saat ditekan atau diperas). Jika tulang seluruhnya terdiri dari kristal anorganik, maka akan menjadi rapuh seperti kapur. Tulang memiliki kekuatan struktural yang mendekati beton bertulang, namun lebih rapuh dan jauh lebih ringan, karena merupakan campuran perancah organik yang diperkeras oleh kristal anorganik.

Sebagai komponen utama kerangka tubuh orang dewasa, jaringan tulang mendukung struktur tubuh, melindungi organ-organ vital seperti yang ada di dalam tengkorak dan rongga dada, serta menampung sumsum tulang yang menjadi tempat pembentukan sel-sel darah. Tulang juga berperan sebagai penyimpanan kalsium, fosfat dan ion lainnya, yang dapat dilepaskan atau disimpan secara terkendali untuk menjaga konsentrasi ion-ion penting dalam cairan tubuh.

Tulang membentuk sistem pengungkit yang meningkatkan kekuatan yang dihasilkan selama kontraksi otot rangka dan mengubahnya menjadi gerakan tubuh.

Jaringan bermineral memberikan fungsi mekanis dan metabolik pada kerangka. Kondisi kesehatan tulang bervariasi dari keadaan normal hingga kondisi yang lebih serius seperti osteopenia dan osteoporosis.

2.2.1 Kondisi Kesehatan Tulang

Kesehatan tulang merupakan aspek penting dari kesejahteraan fisik yang memengaruhi kemampuan seseorang untuk bergerak, beraktivitas dan melindungi organ vital. Tulang yang sehat tidak hanya memberikan struktur dan dukungan bagi tubuh, tetapi juga memainkan peran penting dalam penyimpanan mineral, produksi sel darah dan fungsi metabolik lainnya. Namun, kesehatan tulang dapat berubah seiring waktu, dipengaruhi oleh berbagai faktor termasuk usia, nutrisi, aktivitas fisik dan kondisi medis. Secara umum, kondisi kesehatan tulang dapat dibagi menjadi tiga kategori utama: normal, osteopenia dan osteoporosis (Sebro & Ashok, 2021).

2.2.1.1 Kondisi Tulang Normal

Tulang dalam kondisi normal memiliki struktur dan fungsi yang optimal, memungkinkan tubuh untuk bergerak dengan bebas, mendukung berat badan dan melindungi organ-organ vital seperti otak, jantung dan paru-paru. Pada kondisi tulang normal, tulang memiliki kepadatan mineral yang memadai dan matriks tulang yang seimbang antara komponen organik dan anorganik. Matriks organik, yang sebagian besar terdiri dari serat kolagen, memberikan fleksibilitas dan kekuatan tarik, sementara komponen anorganik, terutama kristal kalsium fosfat, memberikan kekerasan dan kekuatan kompresi (Xue et al., 2022a).

Sel-sel tulang utama yang berperan dalam menjaga kesehatan tulang meliputi osteoblas, osteoklas dan osteosit. Osteoblas adalah sel-sel yang membentuk tulang baru dengan menghasilkan matriks organik dan memfasilitasi mineralisasi. Osteoklas, sebaliknya, bertanggung jawab untuk resorpsi tulang, yaitu proses di mana tulang lama dipecah untuk memberi ruang bagi pembentukan tulang

baru. Osteosit adalah osteoblas yang telah terperangkap dalam matriks yang mereka hasilkan dan berfungsi untuk memelihara jaringan tulang.

Sistem hormonal tubuh juga memainkan peran penting dalam menjaga kesehatan tulang. Hormon paratiroid (PTH), kalsitonin dan vitamin D adalah beberapa contoh utama yang mengatur kadar kalsium dalam darah dan tulang. PTH meningkatkan kadar kalsium dalam darah dengan merangsang resorpsi tulang oleh osteoklas, sementara kalsitonin menurunkan kadar kalsium darah dengan menghambat aktivitas osteoklas. Vitamin D meningkatkan penyerapan kalsium di usus dan membantu mineralisasi tulang.

Gaya hidup sehat adalah kunci untuk mempertahankan kondisi tulang yang normal. Diet yang kaya kalsium dan vitamin D, seperti produk susu, ikan berlemak dan sayuran hijau, sangat penting untuk pembentukan dan pemeliharaan tulang yang kuat. Aktivitas fisik, terutama latihan beban seperti berjalan, berlari dan angkat beban, merangsang pembentukan tulang dan meningkatkan kepadatan tulang. Hindari kebiasaan yang dapat merusak tulang seperti merokok dan konsumsi alkohol berlebihan, karena kedua factor kebiasaan yang dapat merusak tulang dapat mengganggu keseimbangan pembentukan dan resorpsi tulang.

Secara keseluruhan, tulang yang sehat dalam kondisi normal adalah hasil dari interaksi yang kompleks antara nutrisi, aktivitas fisik dan regulasi hormonal. Mempertahankan gaya hidup yang mendukung semua faktor adalah penting untuk menjaga tulang tetap kuat dan fungsional sepanjang hidup. Kondisi tulang normal dapat dilihat pada Gambar 2.5.



Gambar 2.5 Kondisi Tulang Normal

2.2.1.2 Kondisi Tulang Osteopenia

Osteopenia merupakan kondisi pra-osteoporosis yang ditandai dengan penurunan kepadatan tulang yang lebih rendah dari normal, meskipun belum mencapai tingkat serius seperti pada osteoporosis. Pada osteopenia, tulang mengalami kehilangan massa mineral dan matriks tulang mulai menunjukkan tanda-tanda melemah. Osteopenia membuat tulang menjadi lebih rentan terhadap patah, meskipun risiko osteopenia belum sebesar pada osteoporosis (Han et al., 2022).

Penyebab utama osteopenia adalah ketidakseimbangan antara pembentukan dan resorpsi tulang. Proses pembentukan tulang oleh osteoblas tidak mencukupi untuk menggantikan tulang yang hilang melalui resorpsi oleh osteoklas. Faktor risiko utama termasuk penuaan, karena pada usia lanjut proses pembentukan tulang alami mulai menurun. Selain itu, kurangnya asupan kalsium dan vitamin D dalam diet, serta kurangnya aktivitas fisik, juga berkontribusi pada peningkatan risiko osteopenia.

Gejala osteopenia sering kali tidak terdeteksi atau tidak menimbulkan gejala klinis yang spesifik. Pada beberapa kasus, gejala awal mungkin terjadi ketika tulang mulai menjadi lebih rapuh dan terjadi patah tulang yang tidak diharapkan. Tes densitometri tulang (DXA scan) adalah metode pemeriksaan yang umum digunakan untuk mendeteksi osteopenia. Hasil dari tes densitometri tulang (DXA scan)

digambarkan dalam T-score, yang membandingkan kepadatan tulang pasien dengan kepadatan tulang rata-rata pada orang dewasa muda sehat.

Pencegahan dan pengelolaan osteopenia sering melibatkan perubahan gaya hidup dan terapi farmakologis jika diperlukan. Diet yang kaya akan kalsium dan vitamin D sangat penting untuk menjaga kepadatan tulang yang optimal. Suplemen kalsium dan vitamin D sering direkomendasikan oleh dokter untuk memenuhi kebutuhan harian yang diperlukan. Latihan berat seperti berjalan kaki, jogging dan latihan beban membantu merangsang pertumbuhan tulang dan memperlambat penurunan kepadatan tulang.

Penting juga untuk menghindari faktor risiko seperti merokok dan konsumsi alkohol berlebihan, yang dapat mempercepat kehilangan kepadatan tulang. Monitoring secara teratur dengan pemeriksaan kepadatan tulang dianjurkan untuk menilai progresi kondisi dan efektivitas perawatan yang dilakukan.

Osteopenia merupakan peringatan dini untuk memulai tindakan preventif yang tepat guna mencegah kemajuan menjadi osteoporosis yang lebih serius. Dengan pengelolaan yang tepat, banyak individu dapat memperlambat atau bahkan membalikkan penurunan kepadatan tulang, mempertahankan kesehatan tulang yang optimal dan mengurangi risiko patah tulang di masa depan. Kondisi tulang osteopenia dapat dilihat pada Gambar 2.6.



Gambar 2.6 Kondisi Tulang Osteopenia

2.2.1.3 Kondisi Tulang Osteoporosis

Osteoporosis adalah kondisi serius yang ditandai dengan penurunan kepadatan tulang secara signifikan dan struktur tulang yang rapuh. Pada osteoporosis, tulang mengalami kerapuhan yang meningkatkan risiko patah bahkan dengan trauma ringan atau aktivitas sehari-hari. Penurunan kepadatan tulang terjadi karena ketidakseimbangan antara pembentukan tulang oleh osteoblas dan resorpsi tulang oleh osteoklas, di mana proses resorpsi lebih dominan (Sadeghi et al., 2021).

Faktor risiko utama untuk osteoporosis termasuk usia lanjut, terutama pada wanita setelah menopause ketika penurunan hormon estrogen mengurangi kemampuan tubuh untuk mempertahankan kepadatan tulang. Selain itu, faktor genetik juga memainkan peran penting dalam kecenderungan seseorang terhadap osteoporosis. Gaya hidup yang tidak sehat seperti kurangnya aktivitas fisik, merokok, konsumsi alkohol berlebihan dan diet rendah kalsium juga dapat meningkatkan risiko osteoporosis.

Gejala osteoporosis sering tidak terlihat hingga terjadi patah tulang, terutama pada tulang pinggul, tulang belakang atau pergelangan tangan. Patah tulang yang paling umum adalah fraktur vertebrae (tulang belakang), yang dapat menyebabkan nyeri punggung, kehilangan tinggi tubuh, serta deformitas postur seperti kifosis (punggung bungkuk).

Diagnosis osteoporosis dapat ditegakkan melalui pemeriksaan densitometri tulang (DXA scan), yang mengukur kepadatan mineral tulang dan membandingkannya dengan nilai rata-rata orang dewasa muda yang sehat (T-score). Nilai T-score yang lebih rendah dari -2.5 menunjukkan osteoporosis.

Pengelolaan osteoporosis melibatkan pendekatan yang holistik, termasuk perubahan gaya hidup dan terapi farmakologis. Diet yang kaya kalsium dan vitamin D penting untuk mendukung kesehatan tulang. Suplemen kalsium dan vitamin D sering diresepkan untuk memenuhi kebutuhan harian yang diperlukan. Latihan berat, seperti berjalan kaki, jogging dan latihan beban, juga membantu mempertahankan kekuatan dan kepadatan tulang.

Obat-obatan untuk osteoporosis termasuk bisfosfonat, hormon terapi atau terapi pengganti estrogen (untuk wanita pascamenopause), serta obat-obatan yang mempengaruhi metabolisme tulang. Tujuan pengobatan adalah untuk memperlambat penurunan kepadatan tulang, mengurangi risiko patah tulang dan meningkatkan kualitas hidup pasien.

Pencegahan osteoporosis dimulai sejak dini dengan gaya hidup sehat yang mencakup diet seimbang, aktivitas fisik teratur dan menghindari faktor risiko yang dapat merusak tulang. Monitoring secara teratur dengan pemeriksaan densitometri tulang juga penting untuk mengevaluasi efektivitas perawatan dan memantau progresi kondisi. Dengan pengelolaan yang tepat, banyak individu dapat mengelola osteoporosis dengan baik, memperlambat penurunan kepadatan tulang dan mengurangi risiko komplikasi serius seperti fraktur tulang. Kondisi tulang osteoporosis dapat dilihat pada Gambar 2.7.



Gambar 2.7 Kondisi Tulang Osteoporosis

2.3 Computer Vision

Computer Vision merujuk pada proses analisis gambar yang mencakup langkah-langkah seperti akuisisi gambar, pemrosesan, klasifikasi, interpretasi, serta pemahaman keseluruhan, yang kemudian diikuti oleh pengambilan keputusan dan identifikasi objek dalam gambar. Esensi dari teknologi computer vision adalah meniru kemampuan visual manusia dalam perangkat elektronik, memungkinkan

perangkat elektronik memahami dan mengartikan makna dari gambar yang dimasukkan (Szeliski, 2022).

2.4 Citra Digital

Dalam mendefinisikan citra, beberapa penjelasan penting meliputi:

1. Citra digital merupakan representasi dua dimensi yang terdiri dari kumpulan piksel atau titik berwarna dari dunia visual. Bidang citra digital mencakup berbagai disiplin ilmu seperti seni, penglihatan manusia, astronomi, Teknik dan lainnya.
2. Citra digital dapat dianggap sebagai array dua dimensi yang terdiri dari nilai-nilai yang mewakili atribut piksel dalam citra.
3. Gambar digital diinterpretasikan sebagai sinyal dua dimensi yang diskrit dan secara matematis direpresentasikan sebagai fungsi dari variabel dua dimensi.

Dengan demikian, citra digital adalah representasi dua dimensi yang terdiri dari piksel-piksel, di mana setiap piksel direpresentasikan oleh angka-angka yang menggambarkan intensitas atau warna pada titik. Citra digital biasanya direpresentasikan dalam bentuk matriks dua dimensi $f(x,y)$ dengan M kolom dan N baris. Setiap titik dalam matriks mewakili suatu piksel dengan koordinat (x,y) dan nilai $f(x,y)$ menunjukkan intensitas piksel pada titik. Oleh karena itu, sebuah gambar dapat diungkapkan dalam bentuk matriks Persamaan (2.3) sebagai berikut:

$$f(x,y) = \begin{bmatrix} f(0,0) & f(0,1) & \dots & f(0,M-1) \\ f(1,0) & f(1,1) & \ddots & f(1,M-1) \\ \vdots & \vdots & \ddots & \vdots \\ f(N-1,0) & f(N-1,1) & \dots & f(N-1,M-1) \end{bmatrix} \quad (2.3)$$

Berdasarkan Persamaan (2.4), citra digital atau bayangan $f(x, y)$ dapat diasumsikan dalam bentuk fungsi matematika berikut:

$$\begin{aligned}
0 &\leq x \leq M - 1 \\
0 &\leq y \leq N - 1 \\
0 &\leq f(x, y) \leq G - 1
\end{aligned} \tag{2.4}$$

Dalam konteks citra digital, beberapa variabel yang didefinisikan adalah sebagai berikut: M mewakili jumlah baris dalam array gambar, N adalah jumlah kolom dalam array gambar dan G merupakan skala abu-abu dari gambar. Ketika memeriksa sebuah citra digital, kita melihat bahwa citra digital terbentuk dari titik-titik persegi kecil yang disebut sebagai elemen gambar, piksel atau pel. Oleh karena itu, jumlah piksel per satuan panjang memengaruhi resolusi gambar. Semakin tinggi jumlah piksel dalam citra, resolusi gambar akan lebih tinggi, menciptakan tampilan gambar digital yang lebih halus dan tajam. Resolusi yang lebih tinggi memungkinkan citra digital menampilkan detail yang lebih halus dan akurat, sedangkan resolusi yang lebih rendah mungkin mengakibatkan hilangnya beberapa detail dalam gambar. Dengan demikian, jumlah piksel per unit area menjadi faktor kunci dalam menentukan kualitas visual dari citra digital (Aaron & Chew, 2021).

2.5 Object Detection

Object Detection adalah proses mengidentifikasi objek semantik dari kelas tertentu dalam gambar dan video digital, seperti manusia, pesawat terbang atau burung. Pendekatan umum dalam deteksi objek adalah dengan memproses data menggunakan klasifikasi fitur berbasis Convolutional Neural Network (CNN). Object detection merupakan bidang penelitian utama dalam computer vision. Algoritma deteksi objek dapat dibagi menjadi dua kategori, yaitu metode tradisional dan metode deep learning. Dalam metode deep learning, algoritma deteksi objek terbagi menjadi dua kelompok, yaitu algoritma proposal wilayah seperti RCNN, SPP-net, Fast-RCNN dan Faster-RCNN, serta algoritma regresi objek seperti SSD dan YOLO (Amit et al., 2020).

2.6 Citra X-Ray

Citra X-Ray adalah hasil pemeriksaan menggunakan paparan radiasi sinar X dalam jumlah kecil pada tubuh untuk menghasilkan gambar bagian dalam tubuh manusia. Hasil pemeriksaan menggunakan paparan radiasi sinar X membantu dokter dalam mendiagnosis keluhan pasien. Oleh karena itu, pembacaan hasil pemeriksaan harus dilakukan dengan cermat untuk menghindari kesalahan (Ou et al., 2021). Beberapa contoh citra X-Ray dengan kondisi normal, osteopenia dan osteoporosis dapat dilihat pada Gambar 2.8.



Gambar 2.8 Citra X-Ray

2.7 Thresholding

Thresholding adalah teknik yang digunakan untuk mengubah citra grayscale menjadi citra hitam-putih berdasarkan nilai ambang yang telah ditentukan. Terdapat dua metode thresholding, yaitu global thresholding dan local thresholding. Pada global thresholding, nilai ambang ditetapkan satu kali untuk seluruh citra. Semua piksel dalam citra akan dikonversi menjadi hitam atau putih berdasarkan nilai ambang. Metode thresholding biasanya digunakan untuk memisahkan tulisan hitam pada kertas putih. Sebaliknya, pada local thresholding, nilai ambang ditentukan secara lokal untuk setiap piksel berdasarkan nilai piksel tetangganya. Lokal thresholding berarti nilai ambang dapat berbeda untuk setiap piksel dalam citra. Perbedaan utama antara kedua jenis thresholding adalah cara penentuan nilai ambang: global thresholding menggunakan satu nilai ambang untuk seluruh citra,

sedangkan local thresholding menggunakan nilai ambang yang bervariasi untuk setiap piksel (Zhao et al., 2021). Proses sebelum dan sesudah thresholding dapat dilihat pada Gambar 2.9 dan Gambar 2.10.

1. Ciri-ciri Global Thresholding:
 - a Tidak memperhatikan hubungan spasial antarpiksel.
 - b Sensitif terhadap pencahayaan yang tidak merata.
 - c Efektif hanya dalam kondisi ideal (misalnya, latar belakang berwarna putih dan objek berwarna hitam).
 - d Bergantung pada pemilihan nilai ambang yang tepat.
2. Ciri-ciri Local Thresholding:
 - a Memperhatikan hubungan spasial antarpiksel.
 - b Mampu beradaptasi dengan pencahayaan yang tidak merata.
 - c Dapat digunakan baik dalam kondisi ideal maupun tidak.
 - d Bergantung pada beberapa nilai ambang sesuai dengan tingkat keabuan

Citra Sebelum Thresholding



Gambar 2.9 Citra Asli

Citra Sesudah Thresholding (Biner)



Gambar 2.10 Citra Biner

2.8 Operasi Morfologi

Operasi morfologi adalah teknik dalam pengolahan citra digital yang menggunakan bentuk objek sebagai panduan dalam proses pengolahan. Nilai setiap piksel dalam citra digital diperoleh dengan mempertimbangkan piksel-piksel di sekitarnya. Jumlah piksel yang ditambahkan atau dikurangi tergantung pada ukuran dan bentuk elemen penstrukturan yang digunakan dalam memproses citra. Elemen penstrukturan adalah himpunan kecil yang digunakan untuk menganalisis citra berdasarkan karakteristiknya. Elemen penstrukturan memiliki ukuran yang lebih kecil dibandingkan dengan citra yang akan diproses (Rani et al., 2021).

Dalam operasi morfologi, terdapat beberapa jenis operasi, antara lain:

1. Operasi Dilasi

Dilasi adalah teknik yang digunakan untuk memperbesar segmen objek pada citra biner. Caranya adalah dengan menambahkan lapisan di sekitar objek atau mengubah piksel latar belakang (0) yang berdekatan dengan piksel objek (1) menjadi piksel objek (1). Proses operasi dilasi sebelum dan sesudah operasi dilasi dilakukan dapat dilihat pada Gambar 2.11. dan Gambar 2.12 (Said & Jambek, 2021).

Citra Sebelum Dilasi



Gambar 2.11 Sebelum Operasi Dilasi

Citra Sesudah Dilasi



Gambar 2.12 Sesudah Operasi Dilasi

2. Operasi Erosi

Erosi atau pengikisan, adalah kebalikan dari dilasi. Teknik erosi bertujuan untuk memperkecil atau mengikis tepi objek dengan mengubah piksel objek (1) yang berdekatan dengan piksel latar belakang (0) menjadi piksel latar belakang (0). Proses operasi erosi sebelum dan sesudah operasi erosi dilakukan dapat dilihat pada Gambar 2.13. dan Gambar 2.14 (Said & Jambek, 2021).

Citra Sebelum Erosi



Gambar 2.13 Sebelum Operasi Erosi

Citra Sesudah Erosi



Gambar 2.14 Sesudah Operasi Erosi

3. Operasi Opening

Opening adalah proses yang terdiri dari erosi yang diikuti dengan dilasi. Proses opening dimulai dengan melakukan erosi pada citra, kemudian hasilnya dilatasi. Opening biasanya digunakan untuk menghilangkan objek-objek kecil dan tipis serta dapat membuat tepi citra lebih halus. Proses operasi opening sebelum dan sesudah operasi opening dilakukan dapat dilihat pada Gambar 2.15. dan Gambar 2.16 (Saeed et al., 2021).

Citra Sebelum Opening



Gambar 2.15 Sebelum Operasi Opening

Citra Sesudah Opening



Gambar 2.16 Sesudah Operasi Opening

4. Operasi Closing

Closing adalah kebalikan dari opening. Proses closing dimulai dengan dilasi pada citra, kemudian dilanjutkan dengan erosi. Tujuan dari closing adalah untuk mengisi lubang-lubang kecil pada objek dan menggabungkan objek-objek yang berdekatan. Proses operasi closing sebelum dan sesudah operasi closing dilakukan dapat dilihat pada Gambar 2.17. dan Gambar 2.18 (Nogueira et al., 2021).

Citra Sebelum Closing



Gambar 2.17 Sebelum Operasi Closing

Citra Sesudah Closing



Gambar 2.18 Sesudah Operasi Closing


2.9 Ekstraksi Fitur Citra Digital

Proses ekstraksi fitur mengambil informasi dari objek dalam gambar, memungkinkan identifikasi atau pembeda gambar satu dengan lainnya. Ekstraksi fitur menghasilkan parameter yang mendeskripsikan objek dalam gambar (Li et al., 2021).

2.9.1 Grey Level Run Length Matrix (GLRLM)

Grey Level Run Length Matrix (GLRLM) merupakan metode untuk mengekstraksi tekstur yang menghasilkan ciri statistik dan atribut tekstur dengan mengestimasi piksel-piksel yang memiliki tingkat keabuan yang sama. GLRLM

termasuk dalam ekstraksi fitur tingkat tinggi. Hasil ekstraksi dengan GLRLM lebih baik dibandingkan dengan metode GLCM. Perbedaan utamanya terletak pada penggunaan matriks; GLRLM menggunakan matriks run length. Run length adalah jumlah piksel berurutan dalam satu arah yang memiliki tingkat keabuan yang sama. Matriks GLRLM adalah matriks dua dimensi dengan elemen $q(i, j|\theta)$, di mana i adalah tingkat keabuan setiap piksel, j adalah nilai run length dan θ adalah orientasi arah pergeseran yang dinyatakan dalam derajat. GLRLM memiliki orientasi sudut yang sama dengan GLCM, yaitu 0° , 45° , 90° dan 135° (Dash et al., 2021). Lebih detailnya dapat dilihat pada Gambar 2.19.



Gambar 2.19 Orientasi Sudut Arah

Untuk menentukan matriks run length, amati jumlah piksel yang muncul sepanjang nilai j pada tingkat keabuan i dalam suatu sudut orientasi tertentu. Proses untuk menentukan matriks run length digambarkan dalam Gambar 2.20.

1	1	2	2	5
1	1	2	2	2
1	3	3	3	3
3	5	5	4	4
3	3	4	4	4

Gambar 2.20 Matriks Contoh Nilai Piksel Citra

Pada sudut orientasi 0° , kita dapat menentukan jumlah piksel bernilai 1 dengan run length 1 yang muncul sebanyak 1 kali. Nilai yang di dapat kemudian dimasukkan ke dalam matriks run length pada baris yang sesuai dengan tingkat keabuan 1 dan kolom yang sesuai dengan run length 1. Langkah memasukkan nilai ke dalam matriks run length diulangi untuk setiap tingkat keabuan hingga mencapai tingkat keabuan terbesar dalam citra. Hasil matriks run length untuk setiap sudut orientasi dapat dilihat pada Gambar 2.21.

Gray Level	Run Length					0° $g(i)$
	1	2	3	4	5	
1	1	2	0	0	0	3
2	0	1	1	0	0	2
3	1	1	0	1	0	3
4	0	1	1	0	0	2
5	1	1	0	0	0	2
$r(j)$	3	6	2	1	0	$S=12$

a) 0°

Gray Level	Run Length					45° $g(i)$
	1	2	3	4	5	
1	1	2	0	0	0	3
2	3	1	0	0	0	4
3	5	1	0	0	0	6
4	1	2	0	0	0	3
5	3	0	0	0	0	3
$r(j)$	13	6	0	0	0	$S=19$

b) 45°

Gray Level	Run Length					90° $g(i)$
	1	2	3	4	5	
1	0	1	1	0	0	2
2	1	2	0	0	0	3
3	5	1	0	0	0	6
4	1	2	0	0	0	3
5	3	0	0	0	0	3
$r(j)$	10	6	1	0	0	$S=17$

c) 90°

Gray Level	Run Length					135° $g(i)$
	1	2	3	4	5	
1	3	1	0	0	0	4
2	1	2	0	0	0	3
3	5	1	0	0	0	6
4	3	1	0	0	0	4
5	3	0	0	0	0	3
$r(j)$	15	5	0	0	0	$S=20$

d) 135°

Gambar 2.21 Matriks GLRLM contoh nilai piksel citra a) 0° , b) 45° , c) 90° dan d) 135°

GLRLM memiliki beberapa fitur untuk analisis parameter tekstur. Fitur-fitur GLRLM meliputi Short Run Emphasis (SRE), Long Run Emphasis (LRE), Gray Level Non-Uniformity (GLNU), Run Length Non-Uniformity (RLNU), Run Percentage, Low Gray Level Run Emphasis (LGRE), High Gray Level Run Emphasis (HGRE), Short Low Gray Level Emphasis (SLGRE), Short Run High Gray Level Emphasis (SRHGE), Long Run Low Gray Level Emphasis (LRLGE) dan Long Run High Gray Level Emphasis (LRHGE). Persamaan untuk menentukan nilai-nilai fitur GLRLM adalah sebagai berikut:

1. Short Run Emphasis (SRE)

Short Run Emphasis (SRE) digunakan untuk mengukur seberapa sering run pendek muncul dalam sebuah citra. SRE mencerminkan seberapa banyak tekstur dalam citra yang terdiri dari run pendek dalam arah tertentu. Nilai tinggi dari SRE diharapkan muncul pada citra dengan tekstur kasar karena banyaknya variasi piksel tetangga yang memiliki intensitas yang sama. Jika teksturnya semakin kasar, nilai SRE cenderung semakin tinggi. Persamaan untuk menghitung SRE dapat dilihat pada persamaan (2.5) berikut:

$$SRE = \frac{1}{S} \sum_{i=1}^{N_g} \sum_{j=1}^{N_r} \frac{P(i,j)}{j^2} \quad (2.5)$$

2. Long Run Emphasis (LRE)

Long Run Emphasis (LRE) digunakan untuk mengukur seberapa sering run panjang muncul dalam sebuah citra. LRE mencerminkan seberapa banyak tekstur dalam citra yang terdiri dari run panjang dalam arah tertentu. Nilai tinggi dari LRE diharapkan muncul pada citra dengan tekstur halus karena keberadaan run yang panjang, yang berarti bahwa banyak piksel tetangga memiliki intensitas yang sama dan run tersebut berlanjut dengan panjang yang lebih besar. Jika teksturnya semakin halus, nilai LRE cenderung semakin tinggi. Persamaan untuk menghitung LRE dapat dilihat pada persamaan (2.6) berikut:

$$LRE = \frac{1}{S} \sum_{i=1}^{N_g} \sum_{j=1}^{N_r} P(i,j) \cdot j^2 \quad (2.6)$$

3. Gray Level Non-Uniformity (GLNU)

Gray Level Non-Uniformity (GLNU) digunakan untuk mengukur keseragaman tingkat keabuan dalam citra. GLNU mencerminkan distribusi tingkat keabuan dalam citra, di mana nilai GLNU yang lebih rendah menunjukkan distribusi yang lebih seragam. Nilai GLNU yang lebih tinggi

menunjukkan bahwa beberapa tingkat keabuan mendominasi citra, yang dapat terjadi pada citra dengan area besar yang memiliki intensitas seragam. Persamaan untuk menghitung GLNU dapat dilihat pada persamaan (2.7) berikut:

$$GLNU = \frac{1}{S} \sum_{i=1}^{N_g} \left(\sum_{j=1}^{N_r} P(i, j) \right)^2 \quad (2.7)$$

4. Run Length Non-Uniformity (RLNU)

Run Length Non-Uniformity (RLNU) digunakan untuk mengukur keseragaman panjang run dalam citra. RLNU mencerminkan distribusi panjang run dalam citra, di mana nilai RLNU yang lebih rendah menunjukkan distribusi panjang run yang lebih seragam. Nilai RLNU yang lebih tinggi menunjukkan bahwa beberapa panjang run mendominasi citra, yang dapat terjadi pada citra dengan area besar yang memiliki run panjang. Persamaan untuk menghitung RLNU dapat dilihat pada persamaan (2.8) berikut:

$$RLNU = \frac{1}{S} \sum_{j=1}^{N_r} \left(\sum_{i=1}^{N_g} P(i, j) \right)^2 \quad (2.8)$$

5. Run Percentage (RP)

Run Percentage (RP) digunakan untuk mengukur proporsi run dalam citra dibandingkan dengan jumlah total piksel dalam citra. RP mencerminkan seberapa banyak run yang ada dalam citra dalam arah tertentu. Nilai tinggi dari RP menunjukkan bahwa citra memiliki banyak run pendek atau panjang dalam berbagai arah. Persamaan untuk menghitung RP dapat dilihat pada persamaan (2.9) berikut:

$$RP = \frac{S}{N_g \cdot N_r} \quad (2.9)$$

6. Low Gray Level Run Emphasis (LGRE)

Low Gray Level Run Emphasis (LGRE) digunakan untuk mengukur seberapa sering run dengan tingkat keabuan rendah muncul dalam citra. LGRE mencerminkan seberapa banyak tekstur dalam citra yang terdiri dari run dengan tingkat keabuan rendah dalam arah tertentu. Nilai tinggi dari LGRE diharapkan muncul pada citra dengan banyak area yang memiliki tingkat keabuan rendah. Persamaan untuk menghitung LGRE dapat dilihat pada persamaan (2.10) berikut:

$$LGRE = \frac{1}{S} \sum_{i=1}^{N_g} \sum_{j=1}^{N_r} \frac{P(i,j)}{j^2} \quad (2.10)$$

7. High Gray Level Run Emphasis (HGRE)

High Gray Level Run Emphasis (HGRE) digunakan untuk mengukur seberapa sering run dengan tingkat keabuan tinggi muncul dalam citra. HGRE mencerminkan seberapa banyak tekstur dalam citra yang terdiri dari run dengan tingkat keabuan tinggi dalam arah tertentu. Nilai tinggi dari HGRE diharapkan muncul pada citra dengan banyak area yang memiliki tingkat keabuan tinggi. Persamaan untuk menghitung HGRE dapat dilihat pada persamaan (2.11) berikut:

$$HGRE = \frac{1}{S} \sum_{i=1}^{N_g} \sum_{j=1}^{N_r} P(i,j) \cdot i^2 \quad (2.11)$$

8. Short Low Gray Level Emphasis (SLGRE)

Short Low Gray Level Emphasis (SLGRE) digunakan untuk mengukur seberapa sering run pendek dengan tingkat keabuan rendah muncul dalam citra. SLGRE mencerminkan seberapa banyak tekstur dalam citra yang terdiri dari run pendek dengan tingkat keabuan rendah dalam arah tertentu. Nilai tinggi dari SLGRE diharapkan muncul pada citra dengan banyak variasi piksel tetangga yang memiliki intensitas rendah. Persamaan untuk menghitung SLGRE dapat dilihat pada persamaan (2.12) berikut:

$$SLGRE = \frac{1}{S} \sum_{i=1}^{N_g} \sum_{j=1}^{N_r} \frac{P(i,j)}{i^2 \cdot j^2} \quad (2.12)$$

9. Short Run High Gray Level Emphasis (SRHGE)

Short Run High Gray Level Emphasis (SRHGE) digunakan untuk mengukur seberapa sering run pendek dengan tingkat keabuan tinggi muncul dalam citra. SRHGE mencerminkan seberapa banyak tekstur dalam citra yang terdiri dari run pendek dengan tingkat keabuan tinggi dalam arah tertentu. Nilai tinggi dari SRHGE diharapkan muncul pada citra dengan banyak variasi piksel tetangga yang memiliki intensitas tinggi. Persamaan untuk menghitung SRHGE dapat dilihat pada persamaan (2.13) berikut:

$$SRHGE = \frac{1}{S} \sum_{i=1}^{N_g} \sum_{j=1}^{N_r} \frac{P(i,j) \cdot i^2}{j^2} \quad (2.13)$$

10. Long Run Low Gray Level Emphasis (LRLGE)

Long Run Low Gray Level Emphasis (LRLGE) digunakan untuk mengukur seberapa sering run panjang dengan tingkat keabuan rendah muncul dalam citra. LRLGE mencerminkan seberapa banyak tekstur dalam citra yang terdiri dari run panjang dengan tingkat keabuan rendah dalam arah tertentu. Nilai tinggi dari LRLGE diharapkan muncul pada citra dengan run panjang yang memiliki intensitas rendah. Persamaan untuk menghitung LRLGE dapat dilihat pada persamaan (2.14) berikut:

$$LRLGE = \frac{1}{S} \sum_{i=1}^{N_g} \sum_{j=1}^{N_r} \frac{P(i,j) \cdot j^2}{i^2} \quad (2.14)$$

11. Long Run High Gray Level Emphasis (LRHGE)

Long Run High Gray Level Emphasis (LRHGE) digunakan untuk mengukur seberapa sering run panjang dengan tingkat keabuan tinggi muncul dalam citra. LRHGE mencerminkan seberapa banyak tekstur dalam citra yang terdiri dari run panjang dengan tingkat keabuan tinggi dalam arah tertentu. Nilai tinggi dari LRHGE diharapkan muncul pada citra dengan run

panjang yang memiliki intensitas tinggi. Persamaan untuk menghitung LRHGE dapat dilihat pada persamaan (2.15) berikut:

$$LRHGE = \frac{1}{S} \sum_{i=1}^{N_g} \sum_{j=1}^{N_r} P(i, j) \cdot i^2 j^2 \quad (2.15)$$

Keterangan:

- $P(i, j)$: Matriks GLRLM (Gray Level Run Length Matrix) yang berisi jumlah run dengan tingkat keabuan i dan panjang run j .
- i = Tingkat keabuan (gray level) dari run dalam citra.
- j = Panjang run (run length), yaitu jumlah piksel dengan tingkat keabuan yang sama dalam arah tertentu.
- $\Sigma_{i,j}$: Menunjukkan penjumlahan untuk semua nilai i dan j dalam matriks GLRLM.
- N_g, N_r : jumlah total elemen dalam GLRLM.

2.9.2 Histogram

Sebuah gambar terdiri dari banyak sekali piksel dan setiap piksel memiliki atribut intensitas warna yang terdiri dari nilai-nilai Red, Green dan Blue (RGB). Agar lebih efisien dalam analisis, gambar bisa diubah menjadi gambar keabuan, di mana setiap piksel hanya memiliki satu nilai warna yang merepresentasikan tingkat keabuan. Dengan demikian, kompleksitas gambar dapat dikurangi, memungkinkan fokus pada distribusi intensitas keabuan.

Histogram merupakan representasi grafis dari distribusi intensitas keabuan di seluruh gambar. Histogram membagi rentang nilai intensitas keabuan ke dalam sejumlah bin, di mana masing-masing bin mewakili rentang nilai tertentu. Melalui histogram, kita bisa melihat seberapa sering nilai keabuan tertentu muncul dalam gambar, yang memberikan gambaran tentang sebaran warna di seluruh gambar.

Proses ekstraksi ciri warna dimulai dengan mengonversi gambar warna menjadi gambar keabuan. Kemudian, nilai keabuan dari setiap piksel dikelompokkan ke dalam beberapa kelompok atau bin. Biasanya, terdapat 8

kelompok yang digunakan untuk membagi rentang nilai keabuan. Selanjutnya, jumlah piksel dalam setiap kelompok dinormalisasi dengan membaginya dengan hasil perkalian panjang dan lebar gambar. Langkah ekstraksi ciri warna dilakukan untuk memastikan bahwa ekstraksi ciri dapat dilakukan secara relatif, tanpa terpengaruh oleh ukuran gambar yang berbeda-beda. Dengan cara menganalisis distribusi intensitas keabuan dalam gambar, kita dapat menganalisis distribusi intensitas keabuan dengan lebih efektif untuk mengidentifikasi pola atau fitur yang mungkin penting dalam gambar (Vijayan et al., 2023). Persamaan untuk menghitung histogram dapat dilihat pada persamaan (2.16) berikut:


$$H(i) = \frac{1}{N} \sum_{x,y} \delta(I(x,y) - i) \quad (2.16)$$

Keterangan:

- $H(i)$: frekuensi piksel dengan nilai intensitas i .
- N = jumlah total piksel dalam gambar.
- $I(x,y)$ = nilai intensitas pada piksel (x,y) .
- δ : fungsi delta Kronecker yang bernilai 1 jika $I(x,y) = i$ dan 0 jika tidak.

2.10 Artificial Neural Network (ANN)

Artificial Neural Network (ANN) adalah sistem cerdas yang digunakan untuk memproses informasi, dikembangkan dari model matematika yang umum. Prinsip kerja ANN terinspirasi dari cara kerja jaringan saraf manusia (Dastres & Soori, 2021). Para ilmuwan menciptakan algoritma matematis yang meniru pola kerja neuron saraf manusia, sehingga dikenal dengan nama Jaringan Saraf Tiruan (JST) dalam Bahasa Indonesia. Gambar 2.22 memperlihatkan persamaan arsitektur ANN dengan sistem jaringan saraf manusia .



Gambar 2.22 Jaringan Saraf Manusia (A) dan Jaringan ANN (B)

Label A pada Gambar 2.22 (A) menunjukkan struktur sel neuron dalam tubuh manusia. Sel neuron berfungsi sebagai pengantar informasi dari satu sel ke sel lainnya dengan urutan sebagai berikut:

1. Dendrit berfungsi menerima rangsangan atau informasi.
2. Badan sel menerima dan mengakumulasi rangsangan dari dendrit, memproses informasi rangsangan, lalu meneruskannya ke akson.
3. Akson meneruskan rangsangan yang telah diproses oleh badan sel ke neuron lain.

Label B pada Gambar 2.22 (B) menggambarkan struktur ANN (Artificial Neural Network) yang terdiri dari tiga bagian: input layer (x), hidden layer ($f(x)$) dan output layer (y). Informasi diterima oleh input layer menggunakan bobot tertentu. Bobot kemudian dikumpulkan dan diakumulasi oleh hidden layer. Hasil akumulasi dibandingkan dengan threshold yang telah ditentukan untuk menghasilkan nilai aktivasi. Informasi yang memenuhi syarat akan dilanjutkan ke output layer.

2.10.1 Arsitektur Artificial Neural Network


Pada Artificial Neural Network, neuron diasumsikan dapat dikelompokkan dalam beberapa layer seperti yang telah dijelaskan sebelumnya. Berdasarkan jumlah hidden layer yang digunakan, struktur ANN dibagi menjadi dua jenis: jaringan lapis tunggal (single layer network) dan jaringan lapis jamak (multilayer network) (Madhiarasan & Louzazni, 2022).

1. Jaringan Lapis Tunggal (Single Layer Network)

Jaringan lapis tunggal terdiri dari satu layer bobot yang saling terhubung. Dalam jaringan lapis tunggal, informasi yang masuk akan langsung diproses menjadi sinyal keluaran tanpa melalui hidden layer terlebih dahulu. Label B pada Gambar 2.22 (B) adalah contoh dari ANN single layer.

2. Jaringan Lapis Jamak (Multilayer Network)

ANN tipe multilayer network memiliki lebih dari satu layer yang disebut hidden layer. Semua layer yang terletak di antara input layer dan output layer disebut hidden layer dan jumlahnya bisa lebih dari satu. ANN lapis jamak menggunakan fungsi aktivasi nonlinear yang dapat menyelesaikan berbagai tipe permasalahan yang lebih rumit dan kompleks. Arsitektur multilayer network dapat dilihat pada Gambar 2.23.

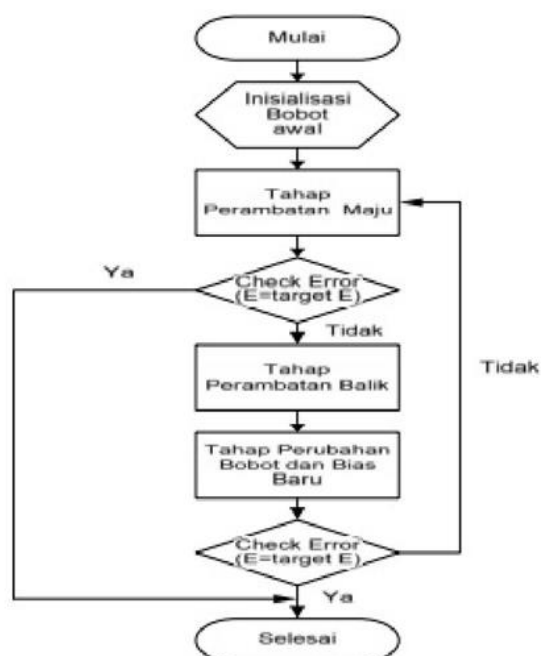


Gambar 2.23 Multilayer ANN

2.10.2 ANN Backpropagation

Backpropagation adalah algoritma pembelajaran dalam Artificial Neural Network yang banyak digunakan untuk menyelesaikan masalah-masalah rumit. Algoritma backpropagation telah ada sejak tahun 1970-an, tetapi baru dikenal luas setelah diperkenalkan oleh David Rumelhart, Geoffrey Hinton dan Ronald Williams dalam makalah mereka pada tahun 1986. Algoritma backpropagation melibatkan dua tahap perhitungan: perhitungan maju dan perhitungan mundur. Pada tahap perhitungan maju, error antara output ANN dengan target yang diinginkan dihitung. Selanjutnya, pada tahap perhitungan mundur, error yang telah dihitung digunakan untuk memperbaiki bobot pada semua neuron dalam jaringan.

Ada tiga fase utama dalam alur kerja backpropagation: feed forward, backpropagation error dan perubahan nilai bobot. Pada fase feed forward, informasi masuk dan diproses maju melalui jaringan untuk menghasilkan output. Kemudian, pada fase backpropagation error, error antara output yang dihasilkan dan target dihitung dan disebarkan mundur melalui jaringan. Akhirnya, pada fase perubahan nilai bobot, bobot diperbarui berdasarkan error yang telah dihitung untuk mengurangi kesalahan pada iterasi berikutnya. Gambar 2.24 menjelaskan alur kerja dari algoritma backpropagation secara lebih rinci (Anam et al., 2021).



Gambar 2.24 Algoritma Backpropagation

1. Feedforward

Pada tahap feedforward, proses berjalan maju seperti penggunaan Artificial Neural Network biasanya. Semua nilai input dan variabel pada input layer dikirimkan ke hidden layer. Nilai input dan variabel pada input layer diterima oleh sejumlah node yang ditentukan di hidden layer, kemudian dihitung menggunakan fungsi aktivasi. Hasil perhitungan dari

masing-masing node di hidden layer diberikan bobot dan dikirimkan ke output layer. Di output layer, perhitungan kembali dilakukan menggunakan fungsi aktivasi tertentu untuk menghasilkan nilai output berdasarkan pola masukan.

2. Backpropagation Error

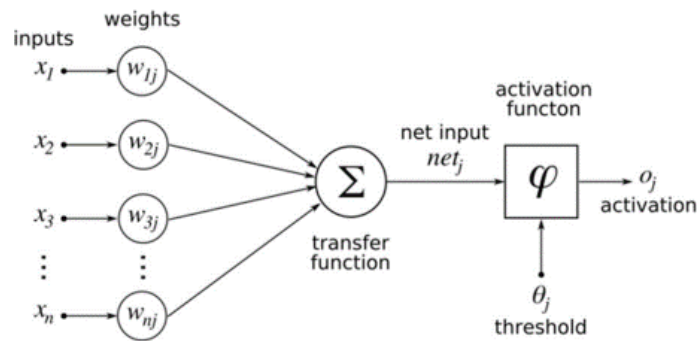
Tahap backpropagation error dilakukan setelah neural network menghasilkan output dari perhitungan input pada proses feedforward. Nilai yang diperoleh oleh masing-masing node output dibandingkan dengan nilai output yang diinginkan menggunakan fungsi loss, untuk menghitung nilai error pada setiap node. Selanjutnya, nilai error dipropagasikan ke belakang, dimulai dari output layer. Proses backpropagation error memastikan semua node di output maupun hidden layer memberikan gambaran nilai error terhadap nilai output yang diinginkan.

3. Perubahan Nilai Bobot

Setelah nilai error diperoleh, nilai error digunakan untuk menghitung gradien dari fungsi loss dengan memperhatikan bobot dari jaringan. Gradien dari fungsi loss kemudian digunakan untuk menemukan nilai optimal yang digunakan untuk memperbarui bobot jaringan.

2.10.3 Fungsi Aktivasi


Fungsi aktivasi adalah fungsi yang digunakan untuk mengolah informasi yang diterima sebagai input (Apicella et al., 2021). Gambar 2.25 memberikan ilustrasi tentang fungsi aktivasi dalam struktur ANN.



Gambar 2.25 Struktur ANN

Pada Gambar 2.25 fungsi transfer mengubah sejumlah input ($x_1, x_2, x_3 \dots x_n$) yang memiliki bobot ($w_{1j}, w_{2j}, \dots w_{nj}$) dan bias menjadi nilai input (net_j) bagi fungsi aktivasi. Fungsi aktivasi kemudian memproses nilai input, membandingkannya dengan threshold yang telah ditentukan dan mengubahnya menjadi output (o_j). Beberapa fungsi aktivasi yang umum digunakan dalam ANN adalah:

1. Fungsi Aktivasi Linier




Gambar 2.26 Fungsi Aktivasi Linier

Gambar 2.26 menunjukkan fungsi aktivasi linier yang menghasilkan output yang sama dengan inputnya. Rumus fungsi aktivasi linier dapat dilihat pada Persamaan (2.17), $f(x)$ adalah fungsi aktivasi linier yang diterapkan pada nilai input (x). Fungsi aktivasi linier tidak melakukan

transformasi apa pun pada nilai inputnya, sehingga output yang dihasilkan sama persis dengan nilai input.

$$f(x) = x \quad (2.17)$$

2. Fungsi Aktivasi Sigmoid




Gambar 2.27 Fungsi Aktivasi Sigmoid

Gambar 2.27 menunjukkan fungsi aktivasi sigmoid yang menghasilkan output dalam rentang 0 hingga 1. Rumus fungsi aktivasi sigmoid dapat dilihat pada Persamaan (2.18), $f(x)$ adalah fungsi aktivasi sigmoid yang diterapkan pada nilai input (x). Fungsi aktivasi sigmoid menggunakan bilangan Euler (e) sebagai basis fungsi eksponensial. Hasil dari fungsi aktivasi sigmoid adalah output yang dinormalisasi dalam rentang 0 hingga 1, yang membuatnya sangat berguna dalam konteks jaringan saraf untuk memodelkan probabilitas.

$$f(x) = \frac{1}{1 + e^{-x}} \quad (2.18)$$

3. Fungsi Aktivasi ReLU (Rectified Linear Unit)




Gambar 2.28 Fungsi Aktivasi ReLU

Gambar 2.28 menunjukkan fungsi aktivasi ReLU yang menghasilkan output yang sama dengan input jika input positif dan nol jika input negatif. Rumus fungsi aktivasi ReLU dapat dilihat pada Persamaan (2.19), $f(x)$ adalah fungsi aktivasi ReLU yang diterapkan pada nilai input (x). Fungsi aktivasi ReLU menggunakan operasi $\max(0, x)$ untuk menghasilkan output, di mana hasilnya adalah nilai maksimum antara 0 dan (x). Dengan kata lain, jika nilai input (x) positif, outputnya adalah (x), jika nilai input (x) negatif atau nol, outputnya adalah 0.

$$f(x) = \max(0, x) \quad (2.19)$$

4. Fungsi Aktivasi Softmax



Gambar 2.29 Fungsi Aktivasi Softmax

Gambar 2.29 menunjukkan fungsi aktivasi Softmax yang digunakan untuk klasifikasi multi-kelas. Fungsi aktivasi softmax mengubah nilai input menjadi probabilitas, dengan total probabilitas semua kelas sama dengan 1. Rumus fungsi aktivasi softmax dapat dilihat pada Persamaan (2.20). $f(x_i)$ adalah fungsi aktivasi Softmax yang menghasilkan probabilitas untuk kelas ke-(i) dari nilai input (x_i). Fungsi eksponensial (e^{x_i}) digunakan untuk menghitung eksponen dari nilai input (x_i). Penjumlahan ($\sum_{j=1}^n e^{x_j}$) adalah jumlah dari semua nilai eksponensial dari semua kelas (j), yang berfungsi untuk menormalisasi nilai eksponensial sehingga total semua probabilitas adalah 1. Indeks (j) digunakan untuk mewakili setiap kelas dalam himpunan kelas, dengan (j) berkisar dari 1 hingga (n), di mana (n) adalah jumlah total kelas.

$$f(x_i) = \frac{e^{x_i}}{\sum_{j=1}^n e^{x_j}} \quad (2.20)$$

2.11 Confusion Matrix

Efektivitas model klasifikasi dapat dievaluasi menggunakan parameter pengukuran seperti akurasi, presisi dan recall, yang dihitung menggunakan matriks konfusi. (Pommé et al., 2022).

		Actual Value (as confirmed by experiment)	
		positives	negatives
Predicted Value (predicted by the test)	positives	TP True Positive	FP False Positive
	negatives	FN False Negative	TN True Negative

Gambar 2.30 Confusion Matrix

Berdasarkan Gambar 2.30, ada perbedaan dalam definisi pengukuran antara klasifikasi dan deteksi objek:

1. Pengukuran dalam Klasifikasi
 - a. **True Positive (TP):** Menunjukkan kejadian yang diprediksi dengan benar oleh model dan memiliki nilai aktual yang benar.
 - b. **False Positive (FP):** Menunjukkan kejadian yang salah diprediksi sebagai positif oleh model tetapi memiliki nilai aktual yang salah.
 - c. **False Negative (FN):** Merupakan kejadian yang salah diprediksi sebagai negatif oleh model tetapi seharusnya positif (misalnya, deteksi yang terlewatkan).
 - d. **True Negative (TN):** Menunjukkan kejadian yang diprediksi dengan benar sebagai negatif oleh model dan memiliki nilai negatif aktual yang benar.
2. Pengukuran dalam Deteksi Objek
 - a. **True Positive (TP):** Merupakan deteksi yang memiliki lokalisasi dan klasifikasi yang benar, di mana $\text{IOU (Intersection over Union)} \geq$ ambang batas yang ditentukan.
 - b. **False Positive (FP):** Merupakan deteksi dengan klasifikasi yang benar tetapi $\text{IOU} < \text{ambang}$ yang ditentukan atau beberapa deteksi untuk objek yang sama.
 - c. **False Negative (FN):** Merupakan objek yang tidak terdeteksi atau salah diklasifikasikan dengan $\text{IOU} \geq \text{ambang}$ batas yang ditentukan.
 - d. **True Negative (TN):** Tidak digunakan dalam evaluasi deteksi objek.

Pemahaman atas perbedaan definisi antara True Positive, False Positive, False Negative dan True Negative penting karena tugas deteksi objek memiliki karakteristik dan persyaratan yang berbeda dari tugas klasifikasi. Penggunaan IOU dalam evaluasi deteksi objek memungkinkan penilaian yang lebih akurat terhadap kinerja model dalam mendeteksi dan mengklasifikasikan objek serta mengukur keakuratan kotak pembatas yang terdeteksi.

$$\text{Accuracy} = \frac{TP + TN}{TP + FP + FN + TN} \quad (2.21)$$

Persamaan (2.21) digunakan sebagai parameter untuk mengevaluasi akurasi model dalam deteksi objek. Sementara itu, Persamaan (2.22) dapat diterapkan untuk menghitung tingkat presisi.

$$\text{Precision} = \frac{TP}{TP + FP} \quad (2.22)$$

Presisi mengukur seberapa tepat model dalam memprediksi kejadian positif (P) dalam serangkaian prediksi. Selain presisi dan akurasi, untuk mendapatkan pemahaman yang lebih rinci tentang kinerja sistem, recall atau sensitivitas sistem terhadap suatu kelas juga dapat dihitung menggunakan Persamaan (2.23).

$$\text{Recall} = \frac{TP}{TP + FN} \quad (2.23)$$

Dalam evaluasi performa model deteksi objek, selain akurasi (Accuracy), presisi (Precision) dan recall (Recall), F1-score juga merupakan metrik penting yang menggabungkan kedua aspek untuk memberikan gambaran yang lebih holistik tentang kinerja sistem. F1-score dapat dihitung menggunakan Persamaan (2.24) berikut:



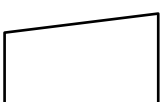
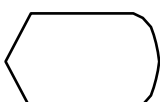
$$\text{F1 - Score} = 2 * \frac{\text{Precision} * \text{Recall}}{\text{Precision} + \text{Recall}} \quad (2.24)$$

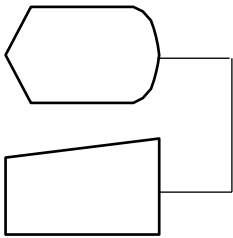

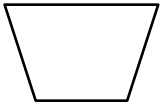
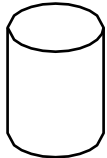

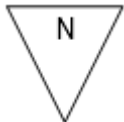


F1-score adalah rata-rata harmonis dari presisi dan recall. Metrik f1-score berguna ketika ingin mencari keseimbangan antara presisi dan recall dalam kasus-kasus di mana terdapat ketidakseimbangan antara kelas positif dan negatif atau ketika keduanya memiliki nilai penting yang sama dalam evaluasi performa model.

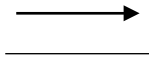
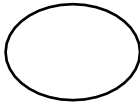
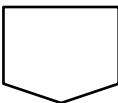
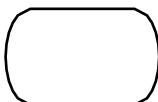
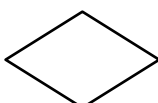
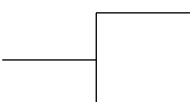
2.12 Flowchart

Flowchart, sebagai teknik grafis, digunakan untuk mengilustrasikan sistem informasi dengan cara yang sederhana dan mudah dimengerti. Biasanya, perangkat lunak seperti Microsoft PowerPoint, Microsoft Excel dan Microsoft Word digunakan untuk membuat diagram alur. Flowchart sangat berguna untuk menampilkan bagaimana sebuah perusahaan memproses transaksi dan mengelola aliran data melalui sistem mereka. Dalam flowchart, terdapat empat jenis simbol: simbol input/output, simbol pemrosesan, simbol penyimpanan dan simbol aliran. Kehadiran jenis simbol pada flowchart mempermudah pemahaman dan penjelasan mengenai informasi dan proses sistem secara visual (J. H. Zhang et al., 2023). Jenis simbol pada flowchart membuat informasi dan proses sistem lebih mudah dipahami dan dijelaskan secara visual pada Tabel 2.1.

Tabel 2.1 Simbol Flowchart

1	Simbol Input atau Output	
		Dokumen atau laporan dalam bentuk elektronik atau kertas.
		Banyak dokumen, dengan penomoran pada sudut kanan atas masing-masing dokumen.
		Alat untuk memasukkan data elektronik seperti terminal, tablet, telepon dan komputer
		Output elektronik yang digunakan untuk menampilkan data, seperti layar, monitor atau terminal.

		Alat input dan output elektronik bekerja sama untuk menunjukkan alat yang sedang digunakan.
2	Simbol Pemrosesan	
		Pemrosesan yang dilakukan oleh komputer.
		Pemrosesan manual.
3	Simbol Penyimpanan	
		Data yang disimpan dalam database
		Data disimpan dalam pita magnetis, yang merupakan alat penyimpanan backup yang populer.
		Dokumen kertas yang diarsipkan diurutkan menurut numerik "N", huruf "A" dan tanggal "D".
		Buku besar atau jurnal akuntansi berbasis kertas
4	Simbol Arus dan Lain-lain	
		Akses ke proses, dokumen dan tujuan

	Menggunakan garis komunikasi untuk mengirimkan data dari satu tempat ke tempat lain.
	Menghubungkan konektor atau arus pemrosesan, ke halaman yang sama.
	Konektor ke halaman lain.
	Awal akhir, pihak luar.
	Mengambil keputusan
	Anotasi untuk menambah catatan penjelasan atau komentar deskriptif sebagai klarifikasi.

2.13 Prototype

Prototype adalah representasi awal atau model pertama dari suatu produk atau sistem yang dirancang untuk menunjukkan fitur-fitur utama, fungsi dan interaksi yang diharapkan dari produk atau sistem yang akan dibuat. Prototype biasanya digunakan untuk mengumpulkan umpan balik awal dari pengguna, menguji konsep, serta mengidentifikasi dan mengatasi masalah potensial sebelum mengembangkan versi final yang lengkap.

1. Tujuan

Validasi Konsep: Prototype membantu untuk menguji dan memvalidasi konsep produk atau sistem sebelum memasuki tahap pengembangan yang lebih lanjut. Dengan demikian, memungkinkan untuk

mengidentifikasi kesalahan atau kekurangan dalam desain atau konsep sejak dini.

- a Umpan Balik Pengguna: Menggunakan prototype memungkinkan untuk mendapatkan umpan balik dari pengguna atau pemangku kepentingan tentang desain dan fitur yang diusulkan. Menggunakan prototype memungkinkan untuk melakukan perbaikan dan penyesuaian sebelum biaya pengembangan yang lebih besar dikeluarkan.
- b Perencanaan dan Pengembangan: Prototype membantu dalam perencanaan dan pengembangan produk atau sistem secara lebih terperinci. Prototype memungkinkan tim pengembang untuk mengidentifikasi risiko dan menciptakan strategi pengembangan yang lebih efektif.

2. Jenis Prototype

- a Prototipe Kasar (Low-Fidelity Prototype): Biasanya berupa sketsa atau mock-up sederhana yang digunakan untuk menunjukkan konsep desain secara kasar tanpa detail yang mendalam.
- b Prototipe Lengkap (High-Fidelity Prototype): Lebih mendetail dan sering kali interaktif, mirip dengan versi final produk atau sistem, digunakan untuk mengevaluasi fungsi dan interaksi yang lebih mendalam.

3. Implementasi dalam Pengembangan Perangkat Lunak

Dalam pengembangan perangkat lunak, prototipe dapat berupa model tampilan antarmuka pengguna (UI), alur kerja (workflow) atau bahkan bagian-bagian sistem yang kritis. Penggunaan prototipe membantu untuk memastikan bahwa solusi yang dihasilkan memenuhi kebutuhan pengguna dan spesifikasi yang telah ditetapkan sebelumnya.

2.14 GUI Python Tkinter

Tkinter (Tk Interface) adalah pustaka standar dalam Python yang digunakan untuk membuat antarmuka pengguna grafis (GUI) dengan menggunakan Tk GUI Toolkit. Tkinter disertakan langsung dengan Python dan berfungsi sebagai antarmuka grafis untuk TCL (Tool Command Language), yang mempermudah pengembangan program dengan GUI. Pustaka Tkinter menyediakan berbagai widget GUI, seperti tombol, bilah gulir, kotak daftar dan sebagainya, dengan perilaku default yang telah ditentukan, sehingga mempercepat proses pengembangan program berbasis GUI (MOORE, 2021).

2.14.1 Widget Tkinter

Tkinter telah menyediakan sekitar 14 widget dasar. Tabel 2.2 menampilkan kelas widget pada Tkinter.

Tabel 2.2 Widget Tkinter

Kelas Widget	Deskripsi
Button	Widget tombol yang dapat diklik.
Canvas	Wadah untuk elemen-elemen grafis.
Checkbutton	Widget untuk pilihan berbagai pilihan.
Entry	Widget entri teks satu baris.
Frame	Wadah untuk widget lainnya.
Label	Widget untuk menampilkan teks atau gambar.
Listbox	Widget untuk menampilkan daftar item.
Menu	Widget menu dropdown.
Menubutton	Tombol yang mengaktifkan menu.
Message	Widget untuk menampilkan teks multi-baris.
Radiobutton	Widget untuk pilihan tunggal.
Scale	Widget untuk memilih nilai dari skala.
Scrollbar	Widget untuk menggulirkan konten.
Text	Widget untuk pengeditan dan tampilan teks multi-baris.

2.15 Penelitian Terdahulu

Beberapa penelitian terdahulu tentang deteksi osteoporosis atau kondisi kesehatan tulang adalah sebagai berikut:

1. Penelitian yang dilakukan oleh Zhihao Xue, Jiayu Huo, Xiaojiang Sun, Xuzhou Sun, Songtao Ai, Lichi Zhang dan Chenglei Liu pada tahun 2022 berjudul "Using radiomic features of lumbar spine CT images to differentiate osteoporosis from normal bone density" menggunakan data dari 133 pasien untuk mengembangkan model prediktif dalam mendeteksi osteoporosis dari gambar CT tulang belakang lumbar. Dengan metode penggunaan fitur radiomik, dipilih fitur-fitur signifikan menggunakan regresi logistik dan matriks koefisien korelasi Pearson. Hasil penelitian menunjukkan bahwa model klasifikasi berbasis RF memiliki kinerja tertinggi, dengan AUC yang cukup tinggi untuk membedakan berbagai kondisi tulang, yaitu 0,994 untuk normal BMD dan osteoporosis, 0,866 untuk osteopenia versus osteoporosis dan 0,940 untuk normal BMD versus osteopenia (Xue et al., 2022b).
2. Penelitian yang dilakukan oleh Kavita Avinash Patil, K V Mahendra Prashanth dan Dr. A Ramalingaiah pada tahun 2021 berjudul "Texture Feature Extraction of Lumbar Spine Trabecular Bone Radiograph Image using Laplacian of Gaussian Filter with KNN Classification to Diagnose Osteoporosis" bertujuan untuk mengklasifikasikan tulang belakang lumbar normal (non-osteoporosis) dan abnormal (osteoporosis) berdasarkan mikro-arsitektur trabekular. Metode yang digunakan dalam penelitian ini mencakup diskriminasi mikro-arsitektur tulang trabekular lumbar menggunakan turunan arah orde pertama dan kedua dari filter Laplacian of Gaussian dengan deviasi standar yang berbeda untuk mendapatkan respons minimum dan maksimum. Pengurangan dimensi fitur tekstur, kuantisasi dan pengkodean skala berdekatan dengan pengali berbobot digunakan untuk mengurangi variasi intensitas fitur tekstur. Bagian kedua penelitian ini berfokus pada pengurangan fitur histogram sebagai data pelatihan untuk klasifikasi gambar tulang belakang lumbar (L1-L4) normal dan osteoporotik menggunakan pengklasifikasi K-Nearest Neighbor (KNN). Hasil pengujian dataset menunjukkan akurasi klasifikasi yang efektif sebesar 97,22% dengan pengurangan dimensi fitur tekstur (Patil et al., 2021).

3. Penelitian yang dilakukan oleh Yijie Fang, Wei Li, Xiaojun Chen, Keming Chen, Han Kang, Pengxin Yu, Rongguo Zhang, Jianwei Liao, Guobin Hong dan Shaolin Li pada tahun 2020 berjudul "Opportunistic osteoporosis screening in multi-detector CT images using deep convolutional neural networks" menggunakan metode jaringan saraf konvolusional dalam (DCNN) untuk segmentasi otomatis tubuh vertebra dan perhitungan kepadatan mineral tulang (BMD) pada gambar CT. Penelitian ini melibatkan 1449 pasien, dengan 586 kasus digunakan untuk pelatihan dan 863 kasus untuk pengujian. U-Net digunakan untuk segmentasi tubuh vertebra, sementara DenseNet-121 digunakan untuk perhitungan BMD. Hasil penelitian menunjukkan bahwa segmentasi otomatis berkorelasi baik dengan segmentasi manual untuk empat vertebra lumbar (L1–L4) dengan koefisien dice rata-rata minimum 0,823, 0,786 dan 0,782 untuk tiga set pengujian. Perhitungan BMD otomatis menunjukkan korelasi tinggi ($r > 0,98$) dan kesesuaian dengan nilai yang diperoleh dari QCT (Fang et al., 2021).
4. Penelitian yang dilakukan oleh C. Tang, W. Zhang, H. Li, L. Li, Z. Li, A. Cai, L. Wang, D. Shi dan B. Yan pada tahun 2020 berjudul "CNN-based qualitative detection of bone mineral density via diagnostic CT slices for osteoporosis screening" bertujuan untuk mendesain metode diagnostik baru untuk skrining osteoporosis dengan menggunakan CNN. Metode diagnostic untuk skrining osteoporosis dengan menggunakan CNN terdiri dari dua modul fungsional untuk mendeteksi BMD secara kualitatif dari irisan CT 2D diagnostik. Modul pertama, Mark-Segmentation-Network (MS-Net), digunakan untuk menemukan dan menyegmentasi ROI dari irisan CT 2D diagnostik. Modul kedua, BMD-Classification-Network (BMDC-Net), digunakan untuk menentukan kategori BMD berdasarkan fitur ROI. Jaringan dilatih menggunakan irisan CT 2D dari 150 pasien dan diuji pada 63 pasien. Hasil penelitian menunjukkan bahwa MS-Net memiliki presisi segmentasi yang sangat baik dengan dice index (DI), pixel accuracy (PA)

dan intersection over union (IOU) lebih dari 0,8. BMDC-Net mencapai akurasi 76,65% dan area under the receiver operating characteristic curve sebesar 0,9167 (Tang et al., 2021).

5. Penelitian yang dilakukan oleh Ryoungwoo Jang, Jae Ho Choi, Namkug Kim, Jae Suk Chang, Pil Whan Yoon dan Chul-Ho Kim pada tahun 2021 berjudul "Prediction of osteoporosis from simple hip radiography using deep learning algorithm" bertujuan untuk memprediksi osteoporosis menggunakan radiografi pinggul sederhana dengan algoritma pembelajaran mendalam. Metode penelitian ini melibatkan pengumpulan 1001 dataset DXA femur proksimal dengan gambar radiografi pinggul yang dipotong dari sisi yang sama pada pasien wanita berusia ≥ 55 tahun, dimana 504 pasien mengalami osteoporosis ($T\text{-score} \leq -2.5$) dan 497 pasien tidak mengalami osteoporosis. Dataset dibagi menjadi tiga set: 800 gambar untuk pelatihan, 100 gambar untuk validasi dan 101 gambar untuk pengujian. Model deep neural network (DNN) dikembangkan berdasarkan VGG16 yang dilengkapi dengan jaringan saraf non-lokal. Hasil penelitian menunjukkan model DNN memiliki akurasi keseluruhan sebesar 81,2%, sensitivitas 91,1% dan spesifisitas 68,9%. Nilai PPV adalah 78,5% dan NPV adalah 86,1%. Area under the ROC curve sebesar 0,867 menunjukkan kinerja yang baik untuk skrining osteoporosis menggunakan radiografi pinggul sederhana. Validasi eksternal mengonfirmasi kinerja model dengan akurasi keseluruhan sebesar 71,8% dan nilai AUC sebesar 0,700 (Jang et al., 2021).
6. Penelitian yang dilakukan oleh Insha Majeed Wani dan Sakshi Arora pada tahun 2022 berjudul "Osteoporosis diagnosis in knee X-rays by transfer learning based on convolution neural network" bertujuan untuk mendeteksi osteoporosis menggunakan pendekatan CNN pada gambar x-ray. Metode penelitian ini melibatkan penggunaan transfer learning dari CNN berbasis deep learning yaitu AlexNet, VggNet-16, ResNet dan VggNet-19 untuk mengklasifikasikan gambar x-ray sendi lutut ke dalam kelompok normal,

osteopenia dan osteoporosis. Dataset yang digunakan terdiri dari 381 gambar x-ray lutut yang divalidasi secara medis dengan T-scores dari Sistem Ultrasonik Kuantitatif. Hasil penelitian menunjukkan bahwa arsitektur AlexNet yang dilatih sebelumnya mencapai akurasi terbaik sebesar 91,1%, dengan tingkat kesalahan 0,09 dan kehilangan validasi 0,54, dibandingkan dengan akurasi 79%, tingkat kesalahan 0,21 dan kehilangan validasi 0,544 ketika jaringan yang tidak dilatih sebelumnya digunakan (Wani & Arora, 2023).

7. Penelitian yang dilakukan oleh Prakash U M, Kottilingam Kottursamy, Korhan Cengiz, Utku Kose dan Bui Thanh Hung pada tahun 2021 berjudul "4x-expert systems for early prediction of osteoporosis using multi-model algorithms" bertujuan untuk meningkatkan prediksi dan akurasi diagnosis osteoporosis melalui sistem pakar yang dirancang menggunakan berbagai algoritma pembelajaran mesin. Metode penelitian ini melibatkan penggunaan sistem pakar 4x yang menggabungkan beberapa model pembelajaran mesin untuk memperbaiki prediksi dan akurasi melalui berbagai proses komputasi. Hasil penelitian menunjukkan bahwa sistem 4x-expert memiliki kemampuan prediksi yang ekstensif dengan akurasi berkisar antara 75% hingga 97% (U M et al., 2021).

Untuk mempermudah dalam memahami isi penelitian terdahulu yang berkaitan dengan penelitian ini akan di uraikan dalam bentuk tabel, penelitian terdahulu yang berkaitan dapat dilihat pada Tabel 2.3.

Tabel 2.3 Penelitian Terdahulu

No	Nama Penulis, Tahun	Judul	Metode	Hasil Penelitian	Pembeda
1.	(Xue et al., 2022b)	Using radiomic features of lumbar spine CT images to differentiate	Random Forest (RF)	Hasil penelitian menunjukkan bahwa model klasifikasi berbasis Random Forest	Mengembangkan Sistem Deteksi kondisi Kesehatan tulang lutut menggunakan Ekstraksi Fitur

		osteoporosis from normal bone density		(RF) memiliki kinerja tertinggi. Untuk membedakan berbagai kondisi tulang, AUC yang diperoleh adalah 0,994 untuk normal BMD dan osteoporosis, 0,866 untuk osteopenia versus osteoporosis dan 0,940 untuk normal BMD versus osteopenia.	Tekstur GLRLM, Ekstraksi Fitur warna Histogram dan ANN
2.	(Patil et al., 2021)	Texture Feature Extraction of Lumbar Spine Trabecular Bone Radiograph Image using Laplacian of Gaussian Filter with KNN Classification to Diagnose Osteoporosis	Laplacian of Gaussian, Histogram, KNN	Hasil pengujian dataset menunjukkan akurasi klasifikasi yang efektif sebesar 97,22% dengan pengurangan dimensi fitur tekstur	Mengembangkan Sistem Deteksi kondisi Kesehatan tulang lutut menggunakan Ekstraksi Fitur Tekstur GLRLM, Ekstraksi Fitur Histogram dan ANN
3.	(Fang et al., 2021)	Opportunistic osteoporosis screening in multi-detector CT images using deep convolutional neural networks	DCNN, U-Net	Hasil penelitian menunjukkan bahwa segmentasi otomatis berkorelasi baik dengan segmentasi manual untuk empat vertebra lumbar (L1–L4) dengan koefisien dice	Mengembangkan Sistem Deteksi kondisi Kesehatan tulang lutut menggunakan Ekstraksi Fitur Tekstur GLRLM, Ekstraksi Fitur Histogram dan ANN

				<p>rata-rata minimum 0,823, 0,786 dan 0,782 untuk tiga set pengujian. Selain itu, perhitungan BMD otomatis menunjukkan korelasi tinggi ($r > 0,98$) dan kesesuaian dengan nilai yang diperoleh dari QCT</p>	
4.	(Tang et al., 2021)	CNN-based qualitative detection of bone mineral density via diagnostic CT slices for osteoporosis screening	Mark-Segmentation-Network (MS-Net) dan BMD-Classification-Network (BMDC-Net)	<p>Hasil penelitian menunjukkan bahwa MS-Net memiliki presisi segmentasi yang sangat baik dengan dice index (DI), pixel accuracy (PA) dan intersection over union (IOU) lebih dari 0,8. Selain itu, BMDC-Net mencapai akurasi 76,65% dan area under the receiver operating characteristic curve sebesar 0,9167</p>	Mengembangkan Sistem Deteksi kondisi Kesehatan tulang lutut menggunakan Ekstraksi Fitur Tekstur GLRLM, Ekstraksi Fitur Histogram dan ANN
5.	(Jang et al., 2021)	Prediction of osteoporosis from simple hip radiography using deep learning algorithm	DNN	<p>Hasil penelitian menunjukkan model DNN memiliki akurasi keseluruhan sebesar 81,2%, sensitivitas</p>	Mengembangkan Sistem Deteksi kondisi Kesehatan tulang lutut menggunakan Ekstraksi Fitur Tekstur GLRLM, Ekstraksi Fitur

				91,1% dan spesifisitas 68,9%	Histogram dan ANN
6.	(Wani & Arora, 2023)	Osteoporosis diagnosis in knee X-rays by transfer learning based on convolution neural network	CNN	Hasil penelitian menunjukkan bahwa arsitektur AlexNet yang dilatih sebelumnya mencapai akurasi terbaik sebesar 91,1%, dengan tingkat kesalahan 0,09 dan kehilangan validasi 0,54, dibandingkan dengan akurasi 79%, tingkat kesalahan 0,21 dan kehilangan validasi 0,544 ketika jaringan yang tidak dilatih sebelumnya digunakan.	Mengembangkan Sistem Deteksi kondisi Kesehatan tulang lutut menggunakan Ekstraksi Fitur Tekstur GLRLM, Ekstraksi Fitur Histogram dan ANN
7.	(U M et al., 2021)	4x-expert systems for early prediction of osteoporosis using multi-model algorithms	4x multi-model deep learning	Hasil penelitian menunjukkan bahwa sistem 4x-expert memiliki kemampuan prediksi yang ekstensif dengan akurasi berkisar antara 75% hingga 97%	Mengembangkan Sistem Deteksi kondisi Kesehatan tulang lutut menggunakan Ekstraksi Fitur Tekstur GLRLM, Ekstraksi Fitur Histogram dan ANN

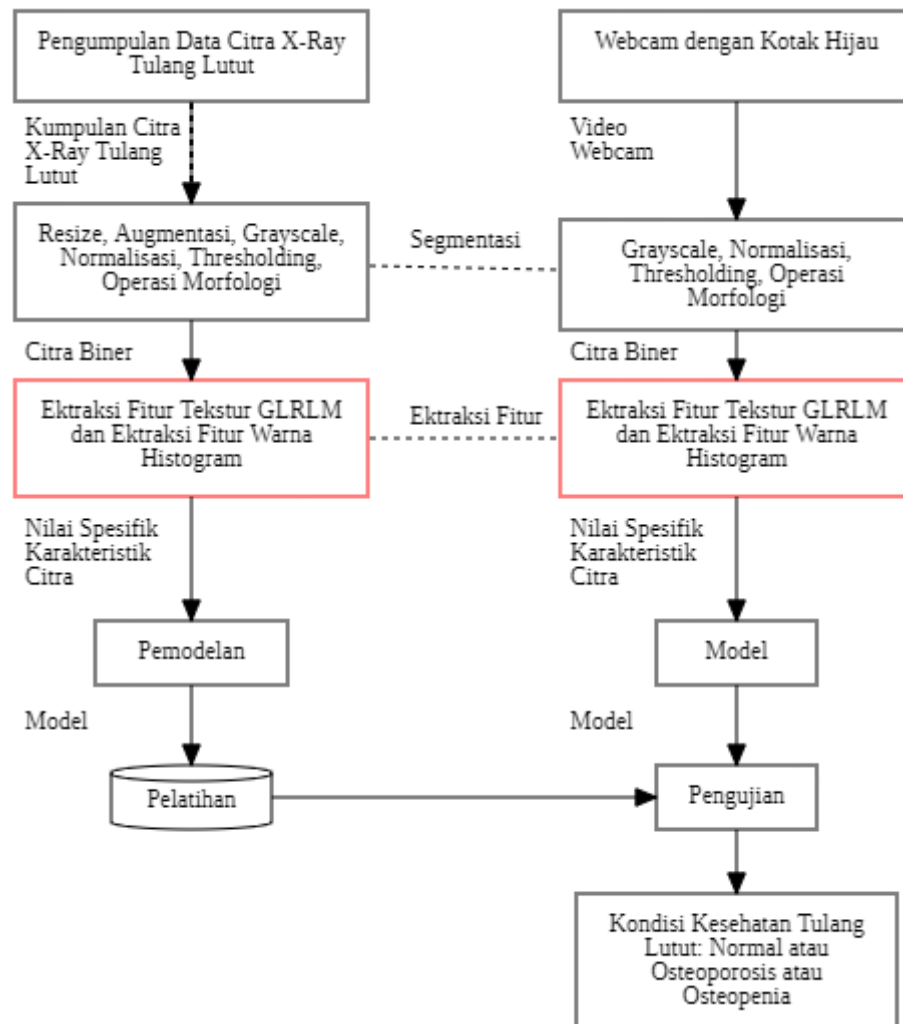
BAB 3

METODE PENELITIAN

Metode atau tahapan penelitian terkait deteksi kondisi kesehatan tulang lutut berdasarkan tekstur dan warna menggunakan model jaringan saraf tiruan dapat dilihat pada Gambar 3.1. Secara umum, penelitian ini dibagi menjadi dua bagian utama. Bagian pertama (kotak di sebelah kiri) melibatkan pembuatan model deteksi kondisi kesehatan tulang lutut, sedangkan bagian kedua (kotak di sebelah kanan) berfokus pada aplikasi pendeteksian kondisi kesehatan tulang lutut.

Bagian pertama (kotak sebelah kiri) terdiri dari beberapa tahapan: pengumpulan data citra x-ray tulang lutut, pengubahan ukuran citra (resize), augmentasi, konversi citra menjadi skala abu-abu (grayscale), normalisasi citra, thresholding, operasi morfologi, ekstraksi fitur tekstur menggunakan GLRLM, ekstraksi fitur warna menggunakan histogram warna, pemodelan dan pelatihan model. Bagian ekstraksi fitur yang ditandai dengan kotak merah merupakan kebaruan penelitian.

Bagian kedua (kotak sebelah kanan) dimulai dengan proses pengambilan citra menggunakan webcam dengan objek yang ditempatkan di dalam kotak hijau. Langkah-langkah berikutnya meliputi konversi citra menjadi skala abu-abu (grayscale), normalisasi citra, thresholding, operasi morfologi, ekstraksi fitur tekstur menggunakan GLRLM dan ekstraksi fitur warna menggunakan histogram warna. Model yang telah dilatih pada bagian pertama kemudian digunakan untuk pengujian dan klasifikasi kondisi kesehatan tulang lutut berdasarkan citra dari webcam. Dari kedua bagian tahapan penelitian ini, dihasilkan prediksi kondisi kesehatan tulang lutut normal, osteopenia atau osteoporosis.



Gambar 3.1 Tahapan Penelitian

Berdasarkan Gambar 3.1, tahapan penelitian terbagi menjadi dua bagian utama. Bagian pertama, yang terletak di sebelah kiri, dimulai dengan pengumpulan citra x-ray tulang lutut. Citra-citra x-ray tulang lutut kemudian diubah ukurannya dan dikonversi menjadi citra dalam skala abu-abu dan di normalisasi. Selanjutnya, dilakukan augmentasi untuk menciptakan variasi dalam dataset, diikuti dengan tahap thresholding untuk mengonversi citra menjadi citra biner. Operasi morfologi diterapkan untuk mengurangi noise dan memperbaiki komponen citra. Dua jenis fitur diekstraksi dari citra: fitur tekstur menggunakan Gray-Level Run Length Matrix (GLRLM) dan fitur warna menggunakan histogram warna. Setelah itu,

model dilatih menggunakan data yang telah diproses. Bagian yang diberi kotak merah menunjukkan kebaruan penelitian.

Bagian kedua, yang terletak di sebelah kanan, dimulai dengan pengambilan citra menggunakan webcam dengan objek yang ditempatkan di dalam kotak hijau. Langkah-langkah pemrosesan yang sama seperti pada bagian pertama diterapkan pada citra webcam. Citra dari webcam diubah menjadi skala abu-abu, dinormalisasi dan kemudian dilakukan thresholding untuk menghasilkan citra biner. Operasi morfologi juga diterapkan untuk mengurangi noise dan memperbaiki komponen citra. Fitur tekstur diekstraksi menggunakan GLRLM dan fitur warna diekstraksi menggunakan histogram warna. Model yang telah dilatih pada bagian pertama digunakan untuk mengklasifikasikan kondisi tulang lutut berdasarkan citra dari webcam. Evaluasi dilakukan untuk menguji kinerja model dalam memprediksi kondisi kesehatan tulang lutut, menghasilkan prediksi kondisi seperti normal, osteopenia atau osteoporosis. Keseluruhan proses tahap penelitian ini dirancang untuk mengembangkan sistem yang mampu mendiagnosis kondisi kesehatan tulang lutut menggunakan citra x-ray langsung dari webcam.

3.1 Pengumpulan Data Citra X-Ray Tulang Lutut

Penelitian ini menggunakan citra x-ray tulang lutut untuk mendeteksi kondisi kesehatan tulang lutut, yang bisa berupa normal, osteoporosis atau osteopenia. Data citra kondisi kesehatan tulang lutut diperoleh dari Kaggle dan Mendeley Data, dengan total 1.136 citra yang digunakan dalam penelitian. Gambar 3.2 menampilkan contoh citra x-ray tulang lutut yang dipakai sebagai sampel dalam penelitian ini.



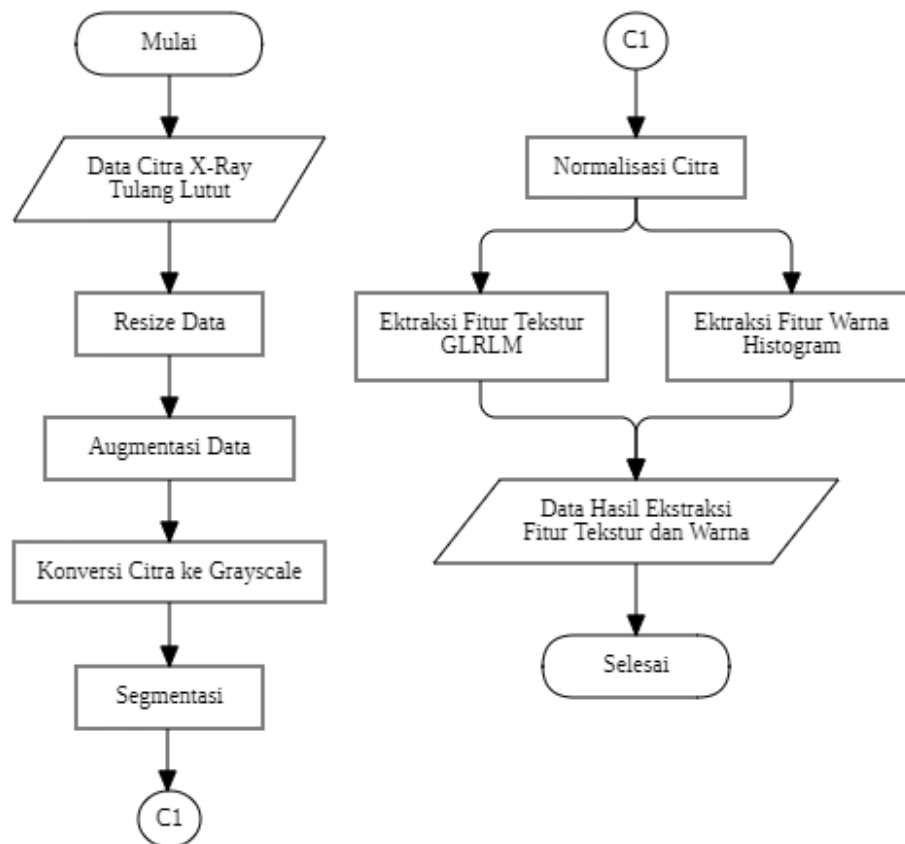
Gambar 3.2 Citra X-Ray Tulang Lutut

Pada Gambar 3.2, ditampilkan beberapa contoh citra x-ray tulang lutut yang menjadi fokus penelitian. Citra kondisi Kesehatan tulang lutut menunjukkan variasi kondisi tulang lutut, termasuk kondisi normal, osteoporosis atau osteopenia. Penggunaan dataset kondisi Kesehatan tulang lutut menjadi landasan untuk analisis dan pengembangan sistem deteksi yang dapat mengenali kondisi kesehatan tulang lutut dengan tepat.

3.2 Pra-Pemrosesan Data Citra

Pada tahap pra-pemrosesan data citra, langkah pertama adalah melakukan resize untuk menyesuaikan ukuran citra agar sesuai dengan kebutuhan analisis atau pengolahan berikutnya, seperti penghematan waktu komputasi atau konsistensi ukuran citra. Langkah selanjutnya adalah augmentasi data untuk menghasilkan variasi citra tambahan dalam kumpulan data, yang membantu meningkatkan keberagaman dan kinerja model pada tahap pelatihan. Setelah itu, citra dikonversi menjadi skala abu-abu (grayscale) untuk memudahkan proses berikutnya. Proses thresholding diterapkan untuk mengonversi citra menjadi citra biner, diikuti dengan operasi morfologi untuk mengurangi noise dan memperbaiki komponen citra. Tahap berikutnya adalah segmentasi citra sinar-X tulang lutut untuk memisahkan bagian yang relevan untuk analisis lebih lanjut. Ekstraksi fitur tekstur dilakukan menggunakan Gray-Level Run Length Matrix (GLRLM) untuk mendapatkan nilai distribusi panjang dan jumlah run (deretan) piksel dengan tingkat abu-abu tertentu dalam citra, yang memberikan informasi penting tentang tekstur citra. Selanjutnya,

dilakukan ekstraksi fitur warna menggunakan histogram untuk menghasilkan representasi distribusi nilai-nilai intensitas piksel dalam citra, yang membantu dalam menganalisis kontras dan fitur-fitur warna lainnya dalam citra sinar-X tulang lutut. Tahap pra-pemrosesan data citra dapat dilihat pada Gambar 3.3.




Gambar 3.3 Flowchart Pra-Pemrosesan Data Citra

3.2.1 Proses Resize Data

Proses resize data bertujuan untuk menyesuaikan ukuran citra agar sesuai dengan kebutuhan analisis atau pengolahan berikutnya, seperti penghematan waktu komputasi atau konsistensi dalam kumpulan data, yang membantu meningkatkan kinerja model pada tahap pelatihan. Pertama, Citra X-Ray Tulang Lutut dibuka atau dibaca dari lokasinya. Setelah itu, ukuran citra diubah menjadi 224x224 piksel menggunakan metode interpolasi untuk menjaga kualitasnya. Metode interpolasi

penting untuk memastikan citra tetap halus dan jelas setelah diubah ukurannya. Terakhir, citra yang sudah diubah ukurannya disimpan kembali di lokasi yang diinginkan. Detail tahapan proses resize data dapat dilihat pada Gambar 3.4 dan Algoritma 3.1 beserta potongan code pada Pseudocode 3.1. Hasil proses resize data dapat dilihat pada Gambar 3.5.



Gambar 3.4 Flowchart Proses Resize Data

Flowchart pada Gambar 3.4 menunjukkan tahapan-tahapan yang harus dilalui dalam proses resize data. Mulai dari pembacaan citra X-Ray, penentuan ukuran target, penerapan metode interpolasi, hingga penyimpanan kembali citra yang telah diubah ukurannya. Setiap tahapan dijelaskan secara visual untuk memudahkan pemahaman mengenai alur kerja dalam proses resize data.

Algoritma 3.1: Proses Resize Data

Input: Citra X-Ray Tulang Lutut

Output: Citra X-Ray Tulang Lutut dengan ukuran 224x224 piksel

Proses:

1. Mulai
-

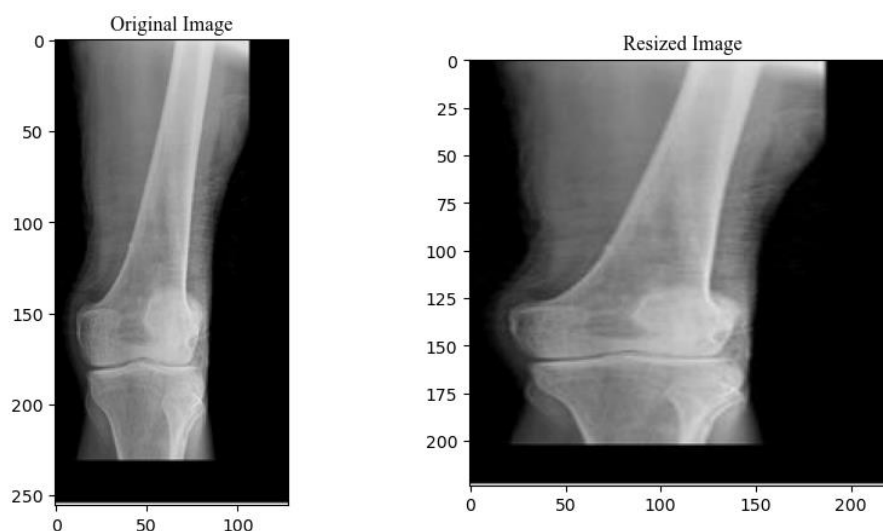
-
2. Baca citra X-Ray tulang lutut dari path input
 3. Tentukan ukuran target sebagai (224, 224) piksel
 4. Terapkan metode interpolasi untuk menjaga kualitas citra saat mengubah ukurannya
 5. Ubah ukuran citra X-Ray menjadi 224x224 piksel
 6. Simpan citra yang telah diubah ukurannya ke path output
 7. Selesai
-

Algoritma 3.1 menjelaskan langkah-langkah rinci dalam proses resize data. Mulai dari pembacaan citra X-Ray tulang lutut dari path input, menentukan ukuran target menjadi 224x224 piksel, menerapkan metode interpolasi untuk menjaga kualitas citra, mengubah ukuran citra dan menyimpan citra yang telah diubah ukurannya ke path output. Algoritma proses resize data memberikan panduan yang jelas tentang bagaimana proses resize data harus dilakukan.

Pseudocode 3.1: Proses Resize Data

```
def ubah_ukuran(input_path, output_path, size=(224, 224)):
    for img_name in os.listdir(input_path):
        img_path = os.path.join(input_path, img_name)
        with Image.open(img_path) as img:
            resized_img = img.resize(size)
            resized_img.save(os.path.join(output_path,
img_name))
```

Pseudocode 3.1 memberikan gambaran tentang implementasi teknis dari proses resize data menggunakan kode sederhana. Fungsi `resize_image` menerima path citra dan ukuran target sebagai parameter, membaca citra dalam mode grayscale menggunakan OpenCV, kemudian mengubah ukuran citra menggunakan metode `resize` dan mengembalikan citra yang telah diubah ukurannya. Pseudocode proses resize data mempermudah pemahaman tentang bagaimana langkah-langkah dalam algoritma dapat diimplementasikan dalam kode pemrograman.



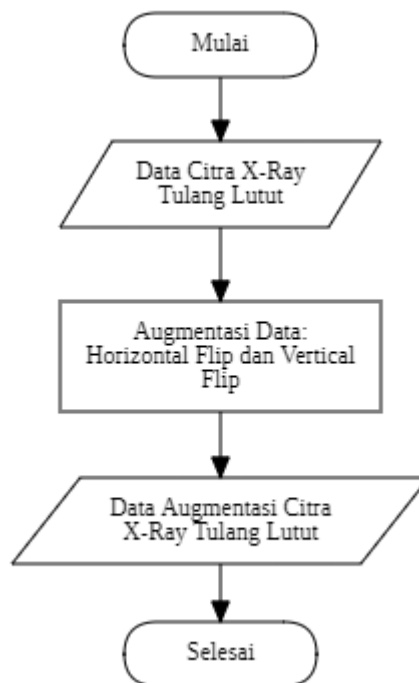
Gambar 3.5 Transformasi Proses Resize Data

Gambar 3.5 menunjukkan hasil dari proses transformasi resize data. Perbandingan antara citra asli dengan citra yang telah diubah ukurannya ditampilkan untuk memperlihatkan bahwa kualitas citra tetap terjaga meskipun ukurannya telah diubah menjadi 224x224 piksel. Proses resize data menegaskan bahwa metode interpolasi yang digunakan efektif dalam menjaga detail dan kejelasan citra setelah proses resize.

3.2.2 Proses Augmentasi Data

Proses augmentasi data adalah langkah penting dalam pengolahan data untuk meningkatkan variasi dataset yang digunakan dalam pelatihan model. Tujuan utama dari augmentasi data adalah untuk meningkatkan generalisasi model dengan memperkenalkan variasi kecil dalam data pelatihan, tanpa mempengaruhi esensi dari data itu sendiri. Pertama, Citra X-Ray Tulang Lutut dengan ukuran 224x224 dibuka atau dibaca dari lokasinya. Setelah itu, melakukan teknik augmentasi pada citra, teknik augmentasi yang digunakan adalah horizontal flip dan vertical flip, citra diperbanyak sebanyak 3x. Terakhir, citra yang sudah dilakukan proses augmentasi disimpan kembali di lokasi yang diinginkan. Setelah di augmentasi data menjadi 3.203. Detail tahapan proses augmentasi data dapat dilihat pada Gambar

3.6 dan Algoritma 3.2 beserta potongan code pada Pseudocode 3.2. Proses augmentasi data dapat dilihat pada Gambar 3.7.



Gambar 3.6 Flowchart Proses Augmentasi Data

Flowchart pada Gambar 3.6 menunjukkan tahapan-tahapan dalam proses augmentasi data. Dimulai dari pembacaan citra X-Ray, penerapan teknik augmentasi seperti horizontal flip dan vertical flip, hingga penyimpanan kembali citra yang telah di-augmentasi. Visualisasi proses augmentasi data membantu memahami alur kerja augmentasi data secara lebih mendetail dan terstruktur.

Algoritma 3.2: Proses Augmentasi Data

Input: Citra X-Ray Tulang Lutut dengan ukuran 224x224 piksel

Output: Citra X-Ray Tulang Lutut dengan augmentasi

Proses:


1. Mulai
 2. Baca Citra X-Ray Tulang Lutut dengan ukuran 224x224
 3. Terapkan teknik augmentasi (Horizontal flip dan vertical flip)
 4. Ubah ukuran citra X-Ray menjadi 224x224 piksel
 5. Simpan citra hasil augmentasi
 6. Selesai
-

Algoritma 3.2 menjelaskan langkah-langkah dalam proses augmentasi data. Proses dimulai dengan pembacaan citra X-Ray tulang lutut berukuran 224x224 piksel. Kemudian, teknik augmentasi seperti horizontal flip dan vertical flip diterapkan. Setelah itu, citra yang sudah di-augmentasi disimpan kembali ke lokasi yang diinginkan. Algoritma proses augmentasi data memberikan panduan yang jelas tentang bagaimana augmentasi data harus dilakukan untuk meningkatkan variasi dalam dataset.

Pseudocode 3.2: Proses Augmentasi Data

```
def augmentasi(input_path, output_path):
    for img_name in os.listdir(input_path):
        img_path = os.path.join(input_path, img_name)
        with Image.open(img_path) as img:
            img.save(os.path.join(output_path,
f"{img_name}") )
            img_h_flip =
img.transpose(Image.FLIP_LEFT_RIGHT)
            img_h_flip.save(os.path.join(output_path,
f"{img_name.split('.')[0]}_h_flip.{img_name.split('.')[1]}
"))
            img_v_flip =
img.transpose(Image.FLIP_TOP_BOTTOM)
            img_v_flip.save(os.path.join(output_path,
f"{img_name.split('.')[0]}_v_flip.{img_name.split('.')[1]}
"))
```

Pseudocode 3.2 memberikan gambaran tentang implementasi teknis dari proses augmentasi data. Fungsi `augment_and_visualize` menerima path citra sebagai parameter, membaca citra dalam mode grayscale menggunakan OpenCV, kemudian menerapkan teknik augmentasi seperti horizontal flip, vertical flip dan kombinasi keduanya (`hv_flip`). Pseudocode proses augmentasi data mempermudah pemahaman tentang bagaimana langkah-langkah dalam algoritma dapat diimplementasikan dalam kode pemrograman.



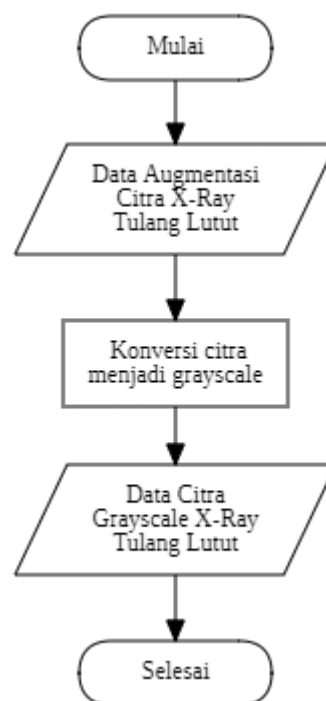
Gambar 3.7 Transformasi Proses Augmentasi Data

Gambar 3.7 menunjukkan hasil dari proses augmentasi data. Perbandingan antara citra asli dengan citra yang telah di-augmentasi ditampilkan untuk memperlihatkan variasi yang dihasilkan oleh teknik augmentasi. Proses augmentasi data menegaskan bahwa teknik augmentasi yang digunakan, seperti horizontal flip dan vertical flip, efektif dalam menciptakan variasi data yang dapat membantu meningkatkan kinerja model saat pelatihan.

3.2.3 Proses Grayscale

Proses grayscale adalah langkah lanjutan setelah augmentasi data yang bertujuan untuk mengkonversi citra berwarna menjadi citra grayscale. Tujuan utama dari proses grayscale adalah untuk menyederhanakan data dengan

mengurangi dimensi warna, yang dapat membantu dalam analisis dan pelatihan model dengan fokus pada fitur tekstur dan struktur tanpa gangguan dari informasi warna. Pertama, citra X-Ray tulang lutut yang telah melalui proses augmentasi, dengan ukuran 224x224 piksel, dibaca dari lokasi penyimpanannya. Selanjutnya, citra x-ray tulang lutut dikonversi menjadi citra grayscale dengan menggunakan metode konversi grayscale yang menjaga informasi intensitas dalam format monokrom. Terakhir, citra grayscale yang telah diproses disimpan kembali di lokasi yang diinginkan. Detail tahapan proses grayscale dapat dilihat pada Gambar 3.8 dan Algoritma 3.3 beserta potongan kode pada Pseudocode 3.3. Hasil dari proses konversi grayscale dapat dilihat pada Gambar 3.9.



Gambar 3.8 Flowchart Proses Grayscale

Flowchart pada Gambar 3.8 menunjukkan tahapan-tahapan dalam proses konversi grayscale secara visual. Flowchart proses grayscale dimulai dengan pembacaan citra X-Ray yang telah di-augmentasi, diikuti dengan konversi citra menjadi grayscale, hingga penyimpanan citra grayscale. Visualisasi proses

grayscale membantu memahami alur kerja konversi grayscale dengan jelas dan terstruktur.

Algoritma 3.3: Proses Grayscale

Input: Citra X-Ray Tulang Lutut dengan ukuran 224x224 piksel

Output: Citra X-Ray Tulang Lutut dalam format grayscale

Proses:


1. Mulai
 2. Baca Citra X-Ray Tulang Lutut dengan ukuran 224x224
 3. Konversi citra menjadi grayscale
 4. Simpan citra hasil konversi grayscale
 5. Selesai
-

Algoritma 3.3 menjelaskan langkah-langkah rinci dalam proses konversi grayscale. Proses dimulai dengan membaca citra X-Ray tulang lutut yang telah melalui proses augmentasi. Kemudian, citra dikonversi menjadi format grayscale untuk menyederhanakan informasi warna menjadi intensitas monokrom. Setelah konversi selesai, citra grayscale disimpan di lokasi yang diinginkan. Algoritma proses grayscale memberikan panduan jelas tentang bagaimana konversi grayscale dilakukan.

Pseudocode 3.3: Proses Grayscale

```
def grayscale(input_path, output_path):
    for img_name in os.listdir(input_path):
        img_path = os.path.join(input_path, img_name)
        with Image.open(img_path) as img:
            grayscale_img = img.convert("L")
            grayscale_img.save(os.path.join(output_path,
img_name))
```

Pseudocode 3.3 memberikan gambaran teknis tentang implementasi proses konversi grayscale. Fungsi grayscale menerima path citra sebagai parameter, membaca citra dari path input, mengkonversi citra ke format grayscale menggunakan metode `convert("L")` dan menyimpan citra grayscale ke path output. Pseudocode proses grayscale mempermudah pemahaman tentang bagaimana langkah-langkah dalam algoritma diterjemahkan ke dalam kode pemrograman.



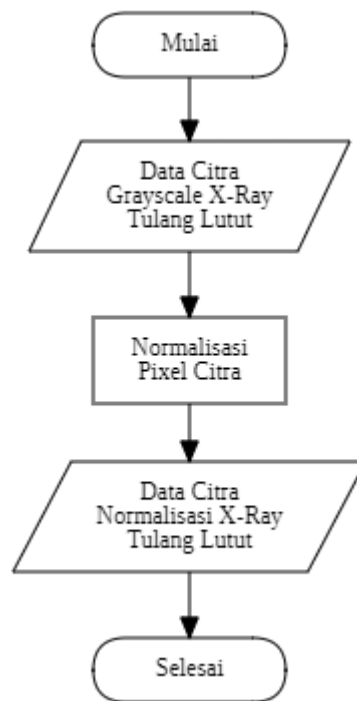
Gambar 3.9 Transformasi Proses Grayscale

Gambar 3.9 menunjukkan hasil dari proses konversi grayscale. Perbandingan antara citra asli yang telah di-augmentasi dan citra grayscale menampilkan bagaimana informasi warna diubah menjadi intensitas monokrom. Proses konversi citra x-ray tulang lutut menegaskan bahwa teknik konversi grayscale efektif dalam menyederhanakan data untuk analisis lebih lanjut dan pelatihan model.

3.2.4 Proses Normalisasi Data

Proses normalisasi data adalah langkah lanjutan setelah konversi citra menjadi grayscale, yang bertujuan untuk menskalakan nilai piksel citra ke rentang yang seragam. Normalisasi data penting untuk memastikan bahwa semua citra memiliki skala intensitas yang konsisten, yang dapat meningkatkan performa model dalam pelatihan. Pertama, citra X-Ray tulang lutut yang telah dikonversi menjadi grayscale dibaca dari lokasi penyimpanannya. Nilai piksel citra kemudian dinormalisasi dengan membagi setiap nilai piksel dengan 255.0 sehingga semua nilai piksel berada dalam rentang 0 hingga 1. Terakhir, citra yang telah dinormalisasi disimpan kembali di lokasi yang diinginkan. Detail tahapan proses normalisasi data dapat dilihat pada Gambar 3.10 dan Algoritma 3.4 beserta

potongan kode pada Pseudocode 3.4. Hasil dari proses normalisasi data dapat dilihat pada Gambar 3.11.



Gambar 3.10 Flowchart Proses Normalisasi Data

Gambar 3.10 menunjukkan tahapan-tahapan dalam proses normalisasi data secara visual. Flowchart proses normalisasi data dimulai dengan pembacaan citra grayscale, dilanjutkan dengan normalisasi nilai piksel citra, hingga penyimpanan citra yang telah dinormalisasi. Visualisasi proses normalisasi data membantu memahami alur kerja normalisasi data dengan jelas dan terstruktur.

Algoritma 3.4: Proses Normalisasi Data

Input: Citra X-Ray Tulang Lutut dalam format grayscale

Output: Citra X-Ray Tulang Lutut dengan nilai piksel yang dinormalisasi

Proses:

1. Mulai
 2. Baca Citra X-Ray Tulang Lutut grayscale
 3. Normalisasi nilai piksel dengan membagi setiap nilai piksel dengan 255.0
 4. Simpan citra hasil normalisasi
 5. Selesai
-

Algoritma 3.4 menjelaskan langkah-langkah rinci dalam proses normalisasi data. Proses dimulai dengan membaca citra grayscale dari path input. Kemudian, nilai piksel citra dinormalisasi dengan membaginya dengan 255.0 untuk membawa semua nilai piksel ke dalam rentang 0 hingga 1. Setelah normalisasi selesai, citra yang telah dinormalisasi disimpan di lokasi yang diinginkan. Algoritma proses normalisasi data memberikan panduan jelas tentang bagaimana normalisasi data dilakukan.

Pseudocode 3.4: Proses Normalisasi Data

```
def normalisasi(input_path, output_path):
    for img_name in os.listdir(input_path):
        img_path = os.path.join(input_path, img_name)
        with Image.open(img_path) as img:
            print(f"Pixel values before normalization for
{img_name}:")
            print(np.array(img))
            img_normalized = np.array(img) / 255.0
            print(f"\nPixel values after normalization for
{img_name}:")
            print(img_normalized)
            img_normalized = (img_normalized *
255).astype(np.uint8)
            img_normalized =
Image.fromarray(img_normalized)
img_normalized.save(os.path.join(output_path, img_name))
```

Pseudocode 3.4 memberikan gambaran teknis tentang implementasi proses normalisasi data. Fungsi normalisasi menerima path citra sebagai parameter, membaca citra dari path input, menormalisasi nilai piksel dengan membagi setiap nilai piksel dengan 255.0 dan menyimpan citra yang telah dinormalisasi ke path output. Pseudocode proses normalisasi data mempermudah pemahaman tentang bagaimana langkah-langkah dalam algoritma diterjemahkan ke dalam kode pemrograman.

```

Pixel values before normalization for 10.png:
[[ 0  0  0 ...  0  0  0]
 [ 0  0  0 ...  0  0  0]
 [ 0  0  0 ...  0  0  0]
 ...
 [ 0  0  0 ...  0  0  0]
 [138 138 138 ... 138 138 138]
 [255 255 255 ... 255 255 255]]

Pixel values after normalization for 10.png:
[[0.      0.      0.      ... 0.      0.      0.      ]
 [0.      0.      0.      ... 0.      0.      0.      ]
 [0.      0.      0.      ... 0.      0.      0.      ]
 ...
 [0.      0.      0.      ... 0.      0.      0.      ]
 [0.54117647 0.54117647 0.54117647 ... 0.54117647 0.54117647 0.54117647]
 [1.      1.      1.      ... 1.      1.      1.      ]]

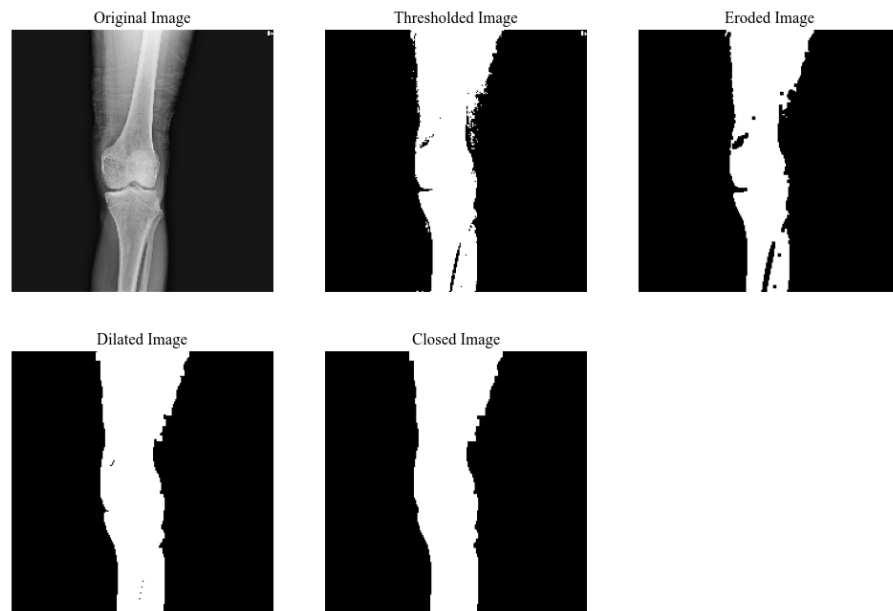
```

Gambar 3.11 Transformasi Proses Normalisasi Data

Gambar 3.11 menunjukkan hasil dari proses normalisasi data. Perbandingan antara citra grayscale asli dan citra yang telah dinormalisasi menampilkan bagaimana nilai piksel diubah menjadi rentang 0 hingga 1. Proses normalisasi citra menegaskan bahwa teknik normalisasi efektif dalam menyamakan skala intensitas citra, yang penting untuk analisis lebih lanjut dan pelatihan model.

3.2.5 Segmentasi

Tahap segmentasi bertujuan untuk mengidentifikasi wilayah penting atau Region of Interest (RoI) seperti area tulang lutut, serta memisahkannya dari latar belakang. Tahap segmentasi dijelaskan secara rinci pada Gambar 3.12. Proses pertama dimulai dengan mengonversi setiap citra menjadi citra biner dengan menggunakan metode thresholding. Penjelasan lebih rinci tentang proses thresholding diuraikan pada sub-bab 3.2.3.1. Proses terakhir melibatkan operasi morfologi pada setiap citra hasil thresholding, tujuan dari operasi morfologi adalah untuk melakukan perbaikan dan menghilangkan noise serta menghubungkan bagian-bagian objek yang terputus. Penjelasan lebih lanjut tentang proses operasi morfologi diuraikan pada sub-bab 3.2.3.2.



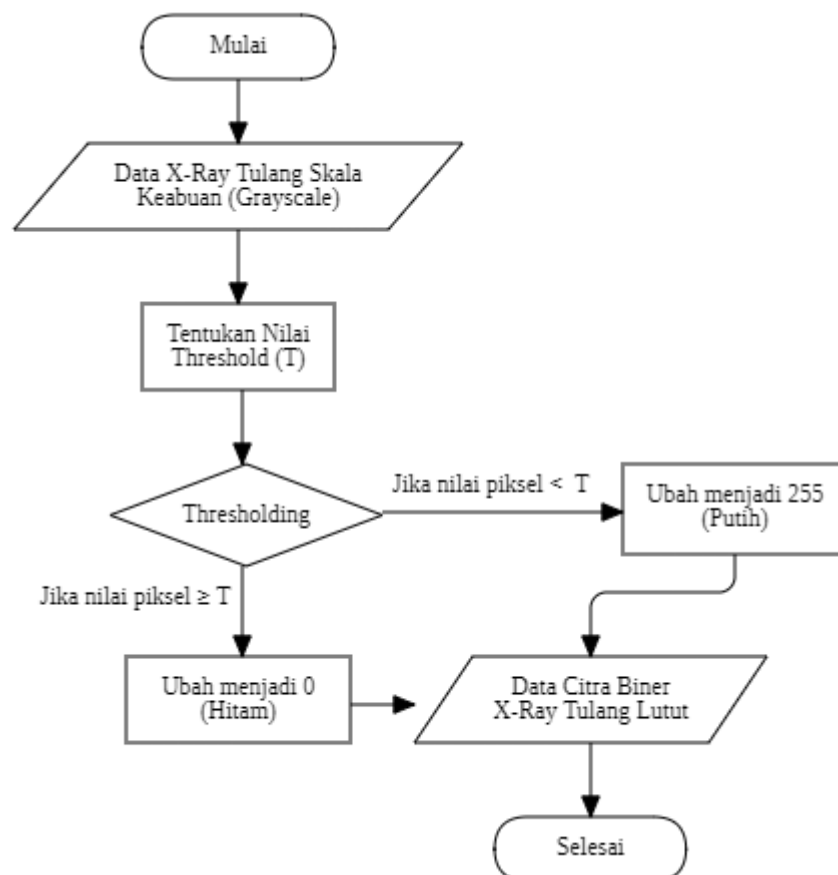
Gambar 3.12 Proses Segmentasi Citra X-Ray Tulang Lutut

Gambar 3.12 menggambarkan tahapan-tahapan dalam proses segmentasi citra X-Ray tulang lutut. Proses segmentasi citra x-ray tulang lutut dimulai dengan mengonversi citra asli menjadi citra biner menggunakan metode thresholding untuk memisahkan objek dari latar belakang. Langkah berikutnya adalah menerapkan operasi morfologi pada citra biner untuk memperbaiki kualitas citra, menghilangkan noise dan menyambungkan bagian objek yang mungkin terputus. Visualisasi proses segmentasi citra x-ray tulang lutut membantu memahami alur kerja segmentasi citra secara lebih mendalam dan sistematis, memastikan identifikasi wilayah penting dalam citra X-Ray tulang lutut dilakukan dengan tepat.

3.2.5.1 Proses Thresholding

Proses thresholding atau binerisasi adalah langkah untuk mengonversi citra dengan 256 skala keabuan menjadi citra biner dengan dua nilai skala keabuan: 0 (hitam) dan 1 (putih). Proses binerisasi penting dalam penelitian ini untuk memperkuat perbedaan intensitas antara objek tulang lutut dan latar belakang dalam citra X-ray tulang lutut. Dalam proses thresholding, citra X-ray tulang lutut

memiliki nilai intensitas 1, sementara citra latar belakang memiliki intensitas 0. Diagram alur proses binerisasi ditampilkan pada Gambar 3.13 dan Algoritma 3.5 beserta potongan code pada Pseudocode 3.5. Citra masukan adalah citra X-ray tulang lutut hasil dari proses grayscaling. Nilai threshold T yang digunakan adalah $T=100$, yang berarti semua piksel dengan nilai di bawah T dikonversi menjadi 0 (hitam), sementara piksel dengan nilai sama dengan atau lebih besar dari T dikonversi menjadi 1 (putih). Pemilihan nilai T didasarkan pada hasil pengujian yang menunjukkan bahwa nilai $T=100$ efektif untuk ekstraksi objek. Contoh hasil citra binerisasi ditunjukkan pada Gambar 3.14. Proses thresholding belum menghasilkan bentuk tulang lutut yang sempurna, karena beberapa bagian tulang mungkin terpisah dan beberapa bagian tulang lainnya memiliki lubang (holes).



Gambar 3.13 Flowchart Proses Thresholding

Gambar 3.13 menampilkan flowchart dari proses thresholding yang menggambarkan langkah-langkah untuk mengonversi citra X-ray tulang lutut menjadi citra biner. Tahapan proses thresholding dimulai dari pembacaan citra, penentuan nilai threshold, hingga penyimpanan citra biner. Visualisasi proses thresholding membantu memahami alur kerja proses thresholding secara lebih mendetail dan terstruktur.

Algoritma 3.5: Proses Thresholding

Input: Citra X-Ray Tulang Lutut

Output: Citra Biner X-Ray Tulang Lutut

Proses:

1. Mulai
 2. Baca citra X-Ray tulang lutut dari path input
 3. Tentukan Nilai Threshold
 4. Threshold \Rightarrow 0 maka berwarna Hitam
 5. Threshold < 0 maka berwarna Putih
 6. Simpan Citra Biner X-Ray Tulang Lutut
 7. Selesai
-


Algoritma 3.5 menjelaskan langkah-langkah dalam proses thresholding. Dimulai dengan pembacaan citra X-ray tulang lutut dari path input, kemudian menentukan nilai threshold. Pixel dengan nilai intensitas di bawah threshold akan dikonversi menjadi hitam (0), sementara pixel dengan nilai intensitas sama dengan atau lebih besar dari threshold akan dikonversi menjadi putih (1). Setelah itu, citra biner disimpan di path output. Algoritma proses thresholding memberikan panduan yang jelas tentang bagaimana proses thresholding harus dilakukan.

Pseudocode 3.5: Proses Thresholding

```
def process_thresholding(image_path, threshold_value,
    output_path):
    image = cv2.imread(image_path, cv2.IMREAD_GRAYSCALE)
    _, binary_image = cv2.threshold(image, threshold_value,
    255, cv2.THRESH_BINARY)
    return image, binary_image
```

Pseudocode 3.5 memberikan gambaran tentang implementasi teknis dari proses thresholding. Fungsi process_thresholding menerima path citra, nilai

threshold dan path output sebagai parameter. Fungsi `process_thresholding` membaca citra dalam mode grayscale menggunakan OpenCV, kemudian menerapkan metode threshold untuk mengonversi citra menjadi biner. Hasil citra biner kemudian dikembalikan. Pseudocode proses thresholding mempermudah pemahaman tentang bagaimana langkah-langkah dalam algoritma dapat diimplementasikan dalam kode pemrograman.



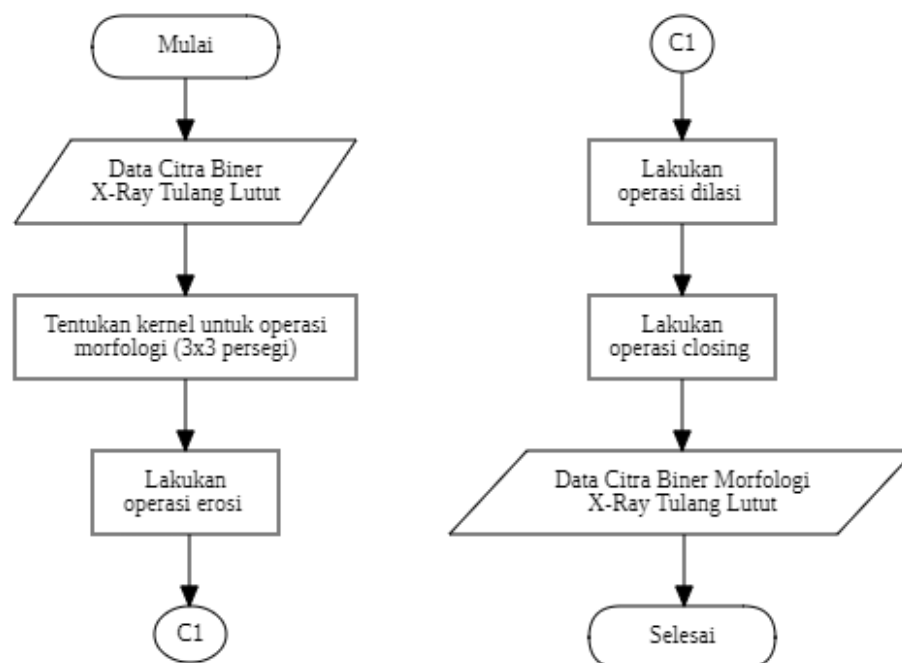
Gambar 3.14 Transformasi Citra Biner X-Ray Tulang Lutut

Gambar 3.14 menunjukkan hasil dari transformasi citra biner X-ray tulang lutut. Perbandingan antara citra asli dan citra yang telah melalui proses thresholding ditampilkan untuk memperlihatkan bagaimana proses process thresholding memperkuat perbedaan intensitas antara objek tulang lutut dan latar belakang. Hasil process thresholding membantu memastikan bahwa proses thresholding berhasil memisahkan wilayah penting dari latar belakang, meskipun belum sempurna dalam menghasilkan bentuk tulang lutut yang utuh.

3.2.5.2 Proses Operasi Morfologi

Proses morfologi bertujuan untuk menutup lubang-lubang yang ada di beberapa bagian tulang dan menyatukan kembali bagian-bagian tulang yang terpisah, sehingga dapat terbentuk tulang lutut yang utuh. Tiga operasi morfologi yang digunakan adalah erosi, dilasi dan closing. Urutan proses dan algoritma

operasi morfologi ditampilkan pada Gambar 3.15 dan Algoritma 3.6 beserta potongan code pada Pseudocode 3.6. Langkah pertama adalah operasi erosi yang bertujuan untuk mengurangi luas area objek dan menghilangkan noise kecil. Dengan menggunakan elemen struktural berbentuk persegi dengan ukuran 3x3, operasi erosi mengurangi area objek pada citra biner. Setelah erosi, operasi dilasi dilakukan untuk memperbesar area objek. Dilasi membantu menutup celah-celah antara dua objek yang berdekatan dan menyatukan bagian-bagian yang terpisah. Elemen struktural yang digunakan juga berbentuk persegi dengan ukuran 3x3 dan operasi dilasi dilakukan dua kali untuk memastikan semua bagian yang terpisah dapat menyatu. Langkah terakhir adalah operasi closing, yang merupakan kombinasi dari dilasi diikuti oleh erosi. Tujuannya adalah untuk menutup lubang-lubang kecil pada objek dan memperhalus tepi objek. Elemen struktural yang digunakan sama seperti sebelumnya, yaitu persegi dengan ukuran 3x3. Hasil akhir disimpan sebagai citra biner hasil operasi morfologi. Contoh hasil Citra Biner Operasi Morfologi X-Ray Tulang Lutut dapat dilihat pada Gambar 3.16.



Gambar 3.15 Flowchart Proses Operasi Morfologi

Gambar 3.15 menampilkan flowchart dari proses operasi morfologi yang menggambarkan langkah-langkah untuk memperbaiki citra biner hasil thresholding. Tahapan proses operasi morfologi dimulai dari pembacaan citra biner, penentuan kernel untuk operasi morfologi, hingga penyimpanan citra hasil operasi morfologi. Visualisasi proses operasi morfologi membantu memahami alur kerja proses morfologi secara lebih mendetail dan terstruktur.

Algoritma 3.6: Proses Operasi Morfologi

Input: Citra X-Ray Tulang Lutut

Output: Citra Biner Operasi Morfologi X-Ray Tulang Lutut

Proses:

1. Mulai
 2. Baca Citra Biner X-Ray Tulang Lutut dari path input
 3. Tentukan kernel untuk operasi morfologi (3x3 persegi)
 4. Lakukan operasi erosi pada citra hasil thresholding dengan kernel yang ditentukan, dilakukan sekali
 5. Lakukan operasi dilasi pada citra hasil erosi dengan kernel yang sama, dilakukan dua kali
 6. Lakukan operasi closing pada citra hasil dilasi dengan kernel yang sama
 7. Simpan Citra Biner Operasi Morfologi X-Ray Tulang Lutut
 8. Selesai
-


Algoritma 3.6 menjelaskan langkah-langkah dalam proses operasi morfologi. Dimulai dengan pembacaan citra biner X-ray tulang lutut dari path input, kemudian menentukan kernel berbentuk persegi berukuran 3x3. Operasi erosi dilakukan satu kali untuk mengurangi area objek dan menghilangkan noise kecil. Selanjutnya, operasi dilasi dilakukan dua kali untuk memperbesar area objek dan menutup celah-celah antar objek. Terakhir, operasi closing diterapkan untuk menutup lubang-lubang kecil pada objek dan memperhalus tepi objek. Algoritma proses operasi morfologi memberikan panduan yang jelas tentang bagaimana operasi morfologi harus dilakukan.

Pseudocode 3.6: Proses Operasi Morfologi

```
def morphological_operations(binary_image):
    kernel = np.ones((3, 3), np.uint8)
    erosion = cv2.erode(binary_image, kernel, iterations=1)
    dilation = cv2.dilate(erosion, kernel, iterations=2)
```

```
closing = cv2.morphologyEx(dilation, cv2.MORPH_CLOSE,
kernel)
return closing
```

Pseudocode 3.6 memberikan gambaran tentang implementasi teknis dari proses operasi morfologi. Fungsi `morphological_operations` menerima citra biner sebagai parameter. Fungsi `morphological_operations` mendefinisikan kernel berbentuk persegi berukuran 3x3, kemudian menerapkan operasi erosi, dilasi dan closing secara berurutan. Hasil akhir dari operasi morfologi kemudian dikembalikan. Pseudocode proses operasi morfologi mempermudah pemahaman tentang bagaimana langkah-langkah dalam algoritma dapat diimplementasikan dalam kode pemrograman.



Gambar 3.16 Transformasi Citra Biner Operasi Morfologi X-Ray Tulang Lutut

Gambar 3.16 menunjukkan hasil dari transformasi citra biner X-ray tulang lutut setelah operasi morfologi. Perbandingan antara citra biner hasil thresholding dan citra yang telah melalui proses morfologi ditampilkan untuk memperlihatkan bagaimana operasi morfologi menutup lubang-lubang kecil dan menyatukan bagian-bagian yang terpisah. Hasil operasi morfologi membantu memastikan bahwa operasi morfologi berhasil memperbaiki citra biner, menghasilkan bentuk tulang lutut yang lebih utuh dan jelas.

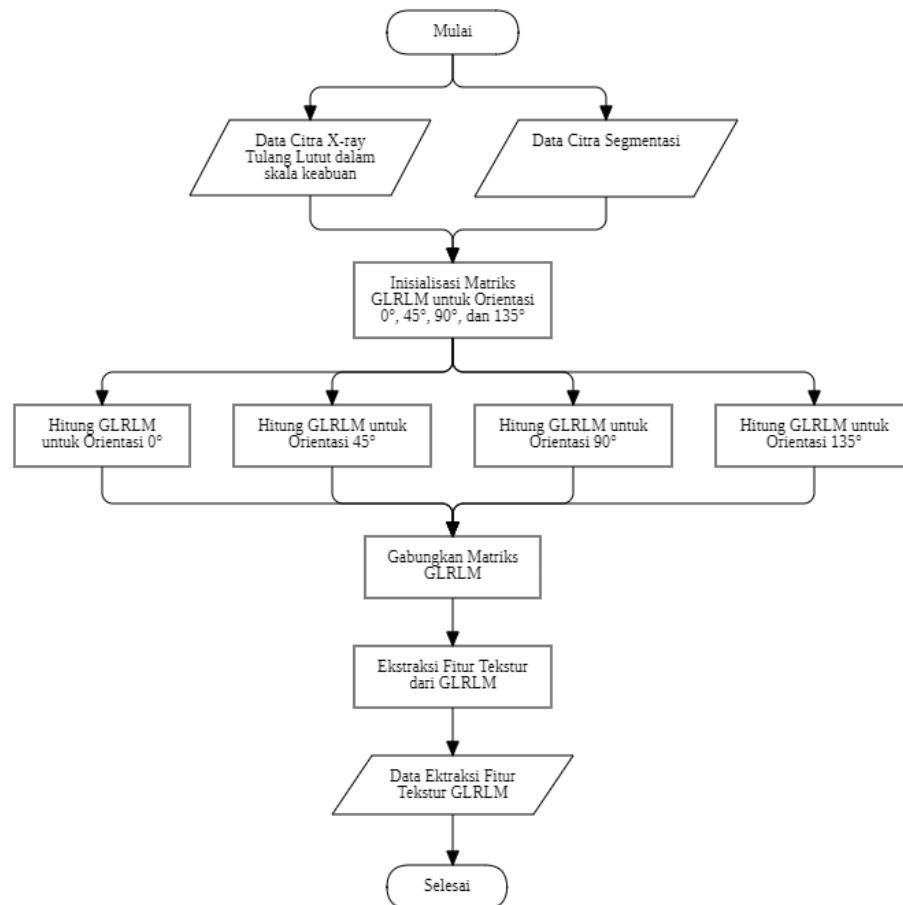
3.2.6 Ekstraksi Fitur

Pada tahap ekstraksi fitur, dilakukan ekstraksi fitur dari citra X-ray tulang lutut untuk mendapatkan informasi yang lebih bermakna yang dapat digunakan dalam analisis lebih lanjut. Fitur-fitur yang diekstraksi termasuk fitur tekstur menggunakan metode Gray-Level Run Length Matrix (GLRLM) dan fitur warna menggunakan histogram. Proses ekstraksi fitur GLRLM disesuaikan dengan area yang dihasilkan dari operasi morfologi, yang memisahkan tulang lutut dari latar belakang. Dengan demikian, ekstraksi fitur dilakukan secara khusus pada area yang telah diproses dan dipisahkan dari latar belakang melalui operasi morfologi, sehingga informasi yang diperoleh lebih akurat dan relevan untuk analisis.

3.2.6.1 Ekstraksi Fitur Tekstur GLRLM

Pada tahap ekstraksi fitur tekstur GLRLM, dilakukan ekstraksi fitur dari citra X-ray tulang lutut yang telah disesuaikan dengan area hasil operasi morfologi untuk mendapatkan informasi yang lebih bermakna dan dapat digunakan dalam analisis lebih lanjut. Proses ekstraksi fitur tekstur menggunakan metode Gray-Level Run Length Matrix (GLRLM) untuk menganalisis tekstur citra. Pertama, citra X-ray tulang lutut yang telah diproses dengan operasi morfologi dibaca dan dipersiapkan dalam bentuk grayscale. Bagian citra yang sesuai dengan area hasil operasi morfologi kemudian disiapkan untuk menentukan region of interest s(ROI) di dalam citra. Jumlah level abu-abu (gray levels) dalam citra juga ditentukan, menggunakan 256 level. Selanjutnya, dihitung matriks GLRLM untuk berbagai

orientasi: 0° , 45° , 90° dan 135° . Untuk setiap orientasi, dilakukan iterasi melalui setiap piksel dalam citra untuk menghitung panjang run pada arah yang sesuai dan menyimpan hasil hitungan ke dalam matriks GLRLM. Setelah menghitung matriks GLRLM untuk semua orientasi, hasilnya digabungkan menjadi satu matriks GLRLM 3D. Dari matriks GLRLM 3D, dilakukan ekstraksi berbagai fitur tekstur, termasuk Short Run Emphasis, Long Run Emphasis, Gray Level Non-Uniformity, Run Length Non-Uniformity, Run Percentage, Low Gray Level Run Emphasis, High Gray Level Run Emphasis, Short Low Gray Level Emphasis, Short Run High Gray Level Emphasis, Long Run Low Gray Level Emphasis dan Long Run High Gray Level Emphasis. Hasil ekstraksi fitur tekstur kemudian disimpan dan dikeluarkan dalam bentuk yang dapat digunakan untuk analisis lebih lanjut atau sebagai input ke dalam model pembelajaran mesin. Proses ekstraksi fitur tekstur GLRLM memastikan bahwa informasi yang diperoleh lebih akurat dan relevan untuk analisis. Tahapan proses ekstraksi fitur tekstur GLRLM dapat dilihat pada Gambar 3.17 dan Algoritma 3.7.



Gambar 3.17 Flowchart Ekstraksi Fitur Tekstur GLRLM

Gambar 3.17 menampilkan alur proses ekstraksi fitur tekstur menggunakan metode GLRLM. Flowchart ekstraksi fitur tekstur GLRLM memvisualisasikan setiap langkah yang diambil mulai dari pembacaan citra X-ray hingga penyimpanan hasil ekstraksi fitur tekstur. Tahapan ekstraksi fitur tekstur GLRLM memberikan gambaran yang jelas tentang bagaimana fitur tekstur diidentifikasi dan diekstraksi dari citra X-ray, memastikan bahwa informasi yang diperoleh dapat digunakan dalam analisis lebih lanjut.

Algoritma 3.7: Ekstraksi Fitur Tektur GLRLM

Input:

1. Data Citra X-ray Tulang Lutut
2. Data Citra segmentasi yang mendefinisikan wilayah minat (ROI)

Output: Ekstraksi Fitur Tekstur GLRLM

Proses:

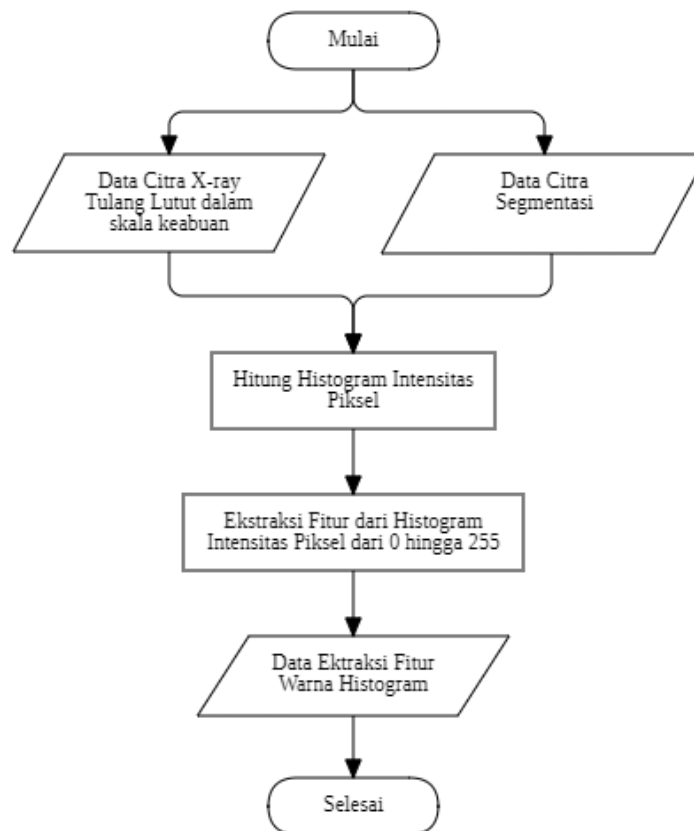
1. Mulai
 2. Baca Data Citra X-ray Tulang Lutut
 3. Baca Data Citra segmentasi
 4. Gabungkan Data Citra X-ray Tulang Lutut dengan Data Citra Segmentasi untuk mendefinisikan wilayah minat (ROI)
 5. Inisialisasi matriks nol untuk setiap orientasi: 0° , 45° , 90° dan 135° .
 6. Hitung GLRLM untuk Orientasi 0°
 7. Hitung GLRLM untuk Orientasi 45°
 8. Hitung GLRLM untuk Orientasi 90°
 9. Hitung GLRLM untuk Orientasi 135°
 10. Gabungkan Matriks GLRLM
 11. Ekstraksi Fitur Tekstur dari GLRLM (Short Run Emphasis (SRE), Long Run Emphasis (LRE), Gray Level Non-Uniformity (GLN), Run Length Non-Uniformity (RLN), Run Percentage (RP), Low Gray Level Run Emphasis (LGRE), High Gray Level Run Emphasis (HGRE), Short Run Low Gray Level Emphasis (SRLGE), Short Run High Gray Level Emphasis (SRHGE), Long Run Low Gray Level Emphasis (LRLGE) dan Long Run High Gray Level Emphasis (LRHGE))
 12. Simpan Data Ekstraksi Fitur Tekstur GLRLM
 13. Selesai
-

Algoritma 3.7 menjelaskan secara rinci langkah-langkah yang diperlukan untuk melakukan ekstraksi fitur tekstur menggunakan metode GLRLM. Dimulai dengan pembacaan citra X-ray dan citra segmentasi, kemudian menggabungkan kedua data citra x-ray dan citra segmentasi untuk mendefinisikan wilayah minat (ROI). Selanjutnya, inisialisasi matriks nol untuk setiap orientasi: 0° , 45° , 90° dan 135° . Matriks GLRLM dihitung untuk setiap orientasi secara terpisah dan hasilnya digabungkan menjadi satu matriks GLRLM 3D. Dari matriks GLRLM 3D, berbagai fitur tekstur diekstraksi dan disimpan untuk analisis lebih lanjut. Algoritma ekstraksi fitur tekstur GLRLM memberikan panduan yang sistematis dan terstruktur dalam melakukan ekstraksi fitur tekstur GLRLM, memastikan akurasi dan relevansi hasil yang diperoleh.

3.2.6.2 Ekstraksi Fitur Warna Histogram

Pada tahap ekstraksi fitur warna histogram, dilakukan ekstraksi fitur warna dari citra X-ray tulang lutut yang telah disesuaikan dengan area hasil operasi morfologi untuk mendapatkan informasi tambahan yang relevan dalam analisis

lebih lanjut. Proses ekstraksi fitur warna menggunakan metode Histogram Warna untuk menganalisis distribusi intensitas warna dalam citra. Pertama, citra X-ray tulang lutut yang telah diproses dengan operasi morfologi dipersiapkan, langkah ekstraksi fitur warna histogram akan memanfaatkan intensitas keabuan sebagai dasar untuk analisis fitur warna. Setelah itu, segmentasi yang sesuai dengan area hasil operasi morfologi diterapkan untuk menentukan region of interest (ROI) dalam citra. Penerapan segmentasi citra penting untuk memastikan bahwa hanya area yang relevan yang dianalisis, sehingga data yang dihasilkan lebih akurat dan representatif. Langkah selanjutnya adalah menghitung histogram intensitas keabuan. Histogram menggambarkan distribusi intensitas keabuan dalam ROI dan memberikan informasi tentang variasi intensitas dalam area yang dipilih. Untuk setiap pixel dalam ROI, intensitas keabuannya dihitung dan histogramnya dibuat. Proses ekstraksi fitur warna histogram memberikan gambaran mendetail tentang distribusi intensitas dalam citra. Setelah histogram intensitas keabuan dihitung, hasil histogram diratakan menjadi vektor satu dimensi sehingga dapat digunakan sebagai vektor fitur, untuk memastikan bahwa data hasil ekstraksi dapat dianalisis lebih lanjut atau digunakan sebagai input ke dalam model pembelajaran mesin. Data hasil ekstraksi fitur histogram kemudian disimpan dalam format csv. Tahapan proses ekstraksi fitur warna Histogram dapat dilihat pada Gambar 3.18 dan Algoritma 3.8.



Gambar 3.18 Flowchart Ekstraksi Fitur Warna Histogram

Gambar 3.18 menunjukkan flowchart proses ekstraksi fitur warna menggunakan metode Histogram Warna. Flowchart ekstraksi fitur warna histogram memvisualisasikan setiap langkah yang diambil mulai dari pembacaan citra X-ray hingga penyimpanan hasil ekstraksi fitur warna. Tahapan ekstraksi fitur warna histogram memberikan gambaran yang jelas tentang bagaimana distribusi intensitas warna diidentifikasi dan diekstraksi dari citra X-ray, memastikan bahwa informasi yang diperoleh dapat digunakan dalam analisis lebih lanjut.

Algoritma 3.8: Ekstraksi Fitur Warna Histogram

Input:

1. Data Citra X-ray Tulang Lutut
2. Data Citra segmentasi yang mendefinisikan wilayah minat (ROI)

Output: Ekstraksi Fitur Tekstur GLRLM

Proses:

1. Mulai
-

-
2. Baca Data Citra X-ray Tulang Lutut
 3. Baca Data Citra segmentasi
 4. Gabungkan Data Citra X-ray Tulang Lutut dengan Data Citra Segmentasi untuk mendefinisikan wilayah minat (ROI)
 5. Hitung Histogram Intensitas Piksel
 6. Ekstraksi Fitur Histogram Intensitas dari 0 hingga 225
 7. Simpan Data Ekstraksi Fitur warna Histogram
 8. Selesai
-

Algoritma 3.8 menjelaskan secara rinci langkah-langkah yang diperlukan untuk melakukan ekstraksi fitur warna menggunakan metode Histogram Warna. Dimulai dengan pembacaan citra X-ray dan citra segmentasi, kemudian menggabungkan kedua data citra X-ray dan citra segmentasi untuk mendefinisikan wilayah minat (ROI). Langkah selanjutnya adalah menghitung histogram intensitas piksel dalam ROI, yang kemudian diekstraksi menjadi fitur histogram intensitas dari 0 hingga 225. Hasil ekstraksi fitur warna histogram disimpan dalam format CSV untuk analisis lebih lanjut atau sebagai input ke dalam model pembelajaran mesin. Algoritma ekstraksi fitur warna histogram memberikan panduan yang sistematis dan terstruktur dalam melakukan ekstraksi fitur warna Histogram, memastikan akurasi dan relevansi hasil yang diperoleh.

3.3 Pembuatan dan Pelatihan Model

Pembuatan dan pelatihan model merupakan tahap penting dalam pengembangan kecerdasan buatan, di mana data diproses dan algoritma dipelajari untuk membuat model yang dapat memberikan prediksi atau hasil yang diinginkan. Model yang digunakan untuk melakukan prediksi adalah model Artificial Neural Network (ANN). Tahap pertama dalam pembuatan dan pelatihan model adalah memuat data hasil ekstraksi fitur dari file CSV, kemudian data hasil ekstraksi fitur di normalisasi tujuannya untuk meminimalkan bias, meningkatkan performa algoritma, mempercepat konvergensi.

Data hasil ekstraksi fitur kemudian diacak untuk memastikan keterwakilan yang merata dari setiap kelas. Proses pengacakan data penting untuk mencegah bias dalam pengolahan data yang mungkin timbul dari urutan data asli. Selanjutnya, data

dibagi menjadi tiga bagian utama: data pelatihan dibagi sebesar 80%, data uji dibagi sebesar 10% dan data validasi dibagi sebesar 10%. Pembagian data bertujuan untuk memberikan model kesempatan untuk belajar dari data yang berbeda-beda, serta menguji kinerja model pada data yang belum pernah dilihat sebelumnya.


Data pelatihan digunakan untuk melatih model, sementara data uji digunakan untuk mengukur performa model secara objektif. Data validasi digunakan untuk menyesuaikan parameter model dan menghindari overfitting. Selanjutnya, label diubah menjadi format array 3 dimensi untuk disesuaikan dengan kebutuhan model. Langkah selanjutnya adalah mendefinisikan arsitektur model ANN yang akan digunakan. Dalam penelitian ini, arsitektur model ANN dibangun yang terdiri dari beberapa lapisan, termasuk lapisan input, lapisan tersembunyi dan lapisan output.

Pada lapisan tersembunyi terdapat 3 lapisan, lapisan pertama terdiri dari 128 neuron dengan fungsi aktivasi ReLU (Rectified Linear Unit), lapisan kedua terdiri dari 64 neuron dengan fungsi aktivasi ReLU (Rectified Linear Unit) dan lapisan ketiga terdiri dari 3 neuron dengan fungsi aktivasi Softmax untuk keluaran yang disesuaikan dengan 3 kelas yang akan di prediksi. Detail arsitektur model dapat dilihat pada Gambar 3.19. Setelah arsitektur model ditentukan, model dikompilasi dengan pengoptimal Adam dan fungsi kerugian sparse categorical crossentropy untuk masalah klasifikasi multi-kelas.

Pengoptimal Adam dipilih karena kemampuannya yang baik dalam menangani data yang besar dan kompleks serta efisiensi dalam konvergensi. Fungsi kerugian sparse categorical crossentropy dipilih karena cocok dengan format label yang telah diubah ke dalam array 3 dimensi. Selanjutnya, model dilatih menggunakan data pelatihan. Langkah selanjutnya adalah melakukan pelatihan model ANN dengan data pelatihan. Proses pelatihan melibatkan pembaruan parameter-model berdasarkan data yang diberikan.

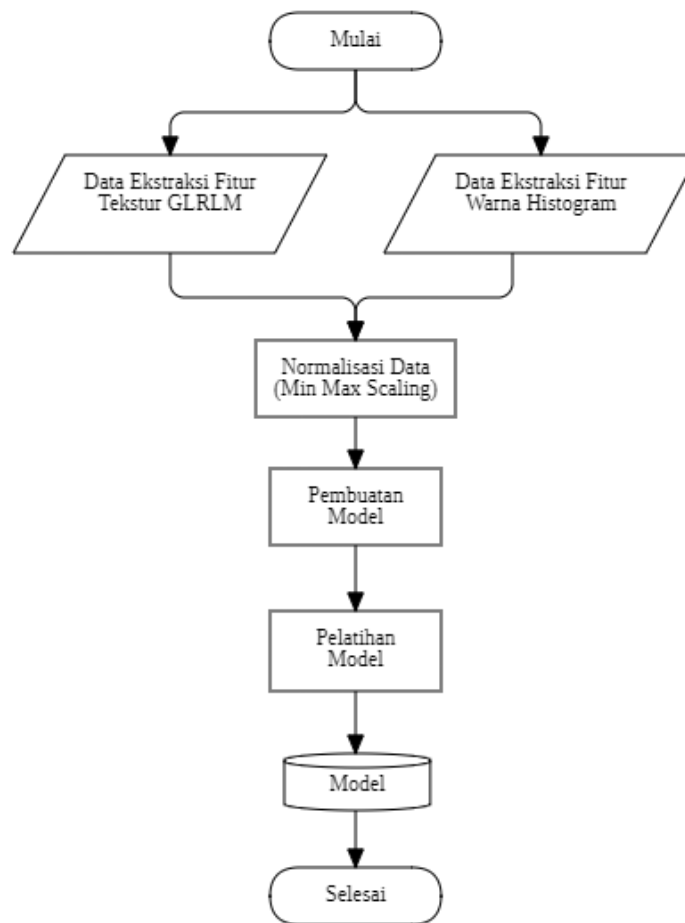
Selama pelatihan, metrik seperti akurasi dan fungsi kerugian dipantau untuk mengevaluasi kinerja model. Model juga dievaluasi pada data validasi untuk memantau kinerjanya dan menghindari overfitting. Terakhir, model yang telah

dilatih disimpan dalam format file ".h5" untuk penggunaan masa depan. Langkah penyimpanan model memungkinkan model untuk digunakan kembali tanpa perlu melalui proses pelatihan yang panjang setiap kali model dibutuhkan. Dengan demikian, tahap pembuatan dan pelatihan model menghasilkan model yang siap digunakan untuk melakukan prediksi pada data baru. Tahapan pembuatan dan pelatihan model dapat dilihat pada Gambar 3.20.



Gambar 3.19 Arsitektur Model ANN

Gambar 3.19 menggambarkan struktur model Artificial Neural Network (ANN) yang digunakan dalam penelitian ini. Model terdiri dari lapisan input, tiga lapisan tersembunyi dan lapisan output. Lapisan pertama memiliki 128 neuron dengan fungsi aktivasi ReLU, lapisan kedua memiliki 64 neuron dengan fungsi aktivasi ReLU dan lapisan ketiga memiliki 3 neuron dengan fungsi aktivasi Softmax. Struktur model ANN dirancang untuk menangani klasifikasi multi-kelas pada data yang telah diekstraksi.



Gambar 3.20 Flowchart Pembuatan dan Pelatihan Model

Gambar 3.20 memperlihatkan langkah-langkah proses pembuatan dan pelatihan model, mulai dari memuat dan menormalisasi data, pengacakan data, pembagian data menjadi data pelatihan, uji dan validasi, hingga pelatihan model dan penyimpanan model yang telah dilatih. Flowchart pembuatan dan pelatihan model memberikan gambaran visual yang jelas tentang seluruh proses yang dilakukan untuk mengembangkan model ANN yang efektif untuk prediksi.

3.4 Evaluasi Model

Model dievaluasi menggunakan data uji untuk mengukur seberapa baik performanya. Dalam evaluasi model, akurasi dan kerugian model pada data uji dicatat. Hasil evaluasi model digunakan untuk memahami sejauh mana model dapat

memprediksi dengan benar kelas dari data baru yang belum pernah dilihat sebelumnya.

Selain itu, perkembangan performa model selama proses pelatihan juga direkam dan divisualisasikan dalam grafik. Grafik proses pelatihan menunjukkan bagaimana akurasi dan kerugian model berkembang seiring berjalannya epoch. Proses perekaman dan visualisasi pelatihan model membantu untuk melihat apakah model telah mencapai konvergensi atau masih membutuhkan iterasi tambahan.

Selanjutnya, untuk memahami lebih lanjut tentang kecenderungan model dalam memprediksi kelas tertentu, confusion matrix digambarkan. Confusion matrix memberikan gambaran tentang seberapa baik model dalam mengklasifikasikan setiap kelas. Confusion matrix membantu dalam mengidentifikasi apakah ada kelas tertentu yang sering salah diklasifikasikan.

Terakhir matriks evaluasi, disajikan untuk memberikan ringkasan yang lebih rinci tentang kinerja model. Matriks evaluasi mencakup presisi, recall dan F1-score untuk setiap kelas, serta akurasi secara keseluruhan. Matriks evaluasi membantu untuk memahami secara lebih mendalam seberapa baik model dalam mengklasifikasikan setiap kelas dan di mana area yang perlu perhatian lebih lanjut. Presisi adalah rasio antara jumlah instance positif yang benar diklasifikasikan oleh model terhadap total instance yang diklasifikasikan sebagai positif oleh model. Tujuannya adalah untuk mengukur seberapa banyak dari semua prediksi positif yang sebenarnya benar. Recall adalah rasio antara jumlah instance positif yang benar diklasifikasikan oleh model terhadap total instance yang sebenarnya positif. Tujuannya adalah untuk mengukur seberapa banyak dari semua instance positif yang berhasil diidentifikasi oleh model. F1-score adalah rata-rata harmonis dari presisi dan recall. Tujuannya adalah untuk memberikan perbandingan yang seimbang antara presisi dan recall.





BAB 4

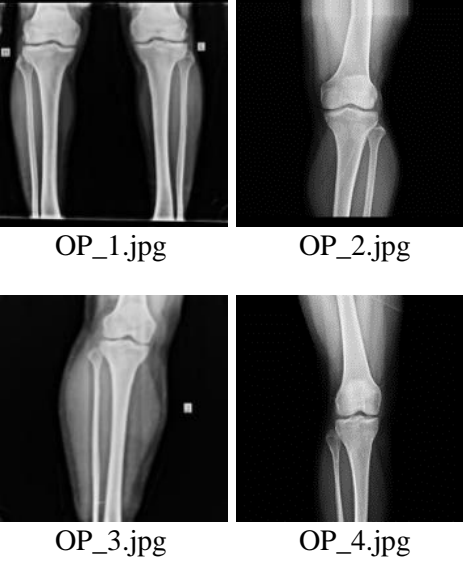
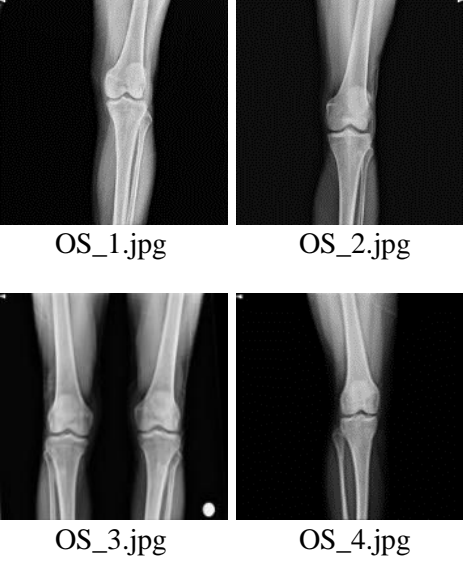
HASIL PENELITIAN DAN PEMBAHASAN

4.1 Hasil Akuisisi Citra X-Ray Tulang Lutut

Hasil akuisisi citra x-ray tulang lutut merupakan data citra x-ray yang di ambil dari website Kaggel dan Mendeley Data pada tanggal 8 Mei 2024 berjumlah 1.136. Data yang diperoleh berupa citra kondisi kesehatan tulang lutut diantaranya normal, osteopenia dan osteoporosis.

Tabel 4.1 Hasil Akuisisi Citra X-Ray Tulang Lutut

Jenis Kondisi Kesehatan Tulang Lutut	Citra X-Ray Tulang Lutut dan Nama Filenya	Jumlah Citra
Normal	<div style="display: flex; justify-content: space-around; align-items: center;"> <div style="text-align: center;">  <p>N_1.jpg</p> </div> <div style="text-align: center;">  <p>N_2.jpg</p> </div> </div> <div style="display: flex; justify-content: space-around; align-items: center;"> <div style="text-align: center;">  <p>N_3.jpg</p> </div> <div style="text-align: center;">  <p>N_4.jpg</p> </div> </div>	407







Osteopenia	 <p>OP_1.jpg OP_2.jpg</p> <p>OP_3.jpg OP_4.jpg</p>	308
Osteoporosis	 <p>OS_1.jpg OS_2.jpg</p> <p>OS_3.jpg OS_4.jpg</p>	421











Tabel 4.1 menampilkan jenis kondisi kesehatan tulang lutut kategori normal sebanyak 407 citra X-ray tulang lutut yang ditampilkan sebanyak 4 citra sebagai contoh. Selanjutnya, untuk kategori osteopenia terdapat 308 data citra X-ray tulang lutut yang juga menampilkan 4 citra sebagai contoh. Terakhir, untuk kategori osteoporosis terdapat 421 data citra X-ray tulang lutut dan 4 citra di antaranya ditampilkan sebagai contoh.


4.2 Hasil Segmentasi Citra X-Ray Tulang Lutut

Hasil segmentasi citra x-ray tulang lutut, berupa citra grayscale yang diolah untuk mendapatkan citra biner melalui proses thresholding dan operasi morfologi. Hasil dari proses thresholding dalam tahapan segmentasi untuk setiap citra tulang lutut ditampilkan pada Tabel 4.2. Hasil dari proses operasi morfologi dalam tahapan segmentasi untuk setiap citra tulang lutut ditampilkan pada Tabel 4.3. Proses operasi morfologi penting untuk mendapatkan bagian fitur tulang yang diinginkan yang nantinya akan dilakukan proses ekstraksi fitur.

Tabel 4.2 Citra Hasil Proses Thresholding









Jenis Citra X-Ray Tulang Lutut	Citra X-Ray Tulang Lutut	Citra Hasil Proses Thresholding
Normal	 N_1.jpg	
	 N_2.jpg	
	 N_3.jpg	

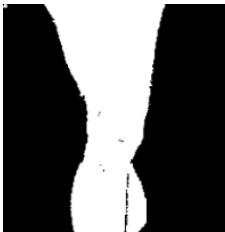
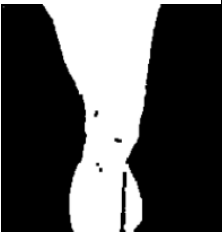
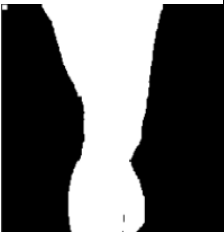

















Osteopenia	 OP_1.jpg	
	 OP_2.jpg	
	 OP_3.jpg	
Osteoporosis	 OS_1.jpg	
	 OS_2.jpg	




Tabel 4.2 menampilkan jenis kondisi kesehatan tulang lutut kategori normal citra hasil proses thresholding yang ditampilkan sebanyak 3 citra sebagai contoh. Selanjutnya, untuk kategori osteopenia citra hasil proses thresholding yang juga menampilkan 3 citra sebagai contoh. Terakhir, untuk kategori osteoporosis citra hasil proses thresholding yang ditampilkan 3 citra sebagai contoh.

Tabel 4.3 Citra Hasil Proses Operasi Morfologi

Jenis Citra X-Ray Tulang Lutut	Citra Hasil Proses Thresholding	Operasi Morfologi		
		Erosi	Dilasi	Closing
Normal				
				

				
Osteopenia				
				
				
Osteoporosis				



Tabel 4.3 menampilkan kondisi kesehatan tulang lutut dengan kategori normal, citra hasil dari proses operasi morfologi terdiri dari proses erosi untuk menghilangkan tepi yang tidak diinginkan, dilanjutkan dengan proses dilasi untuk menghubungkan area yang terpisah dan diakhiri dengan proses closing untuk mengisi lubang-lubang kecil yang ditampilkan sebanyak 3 citra sebagai contoh. Selanjutnya, untuk kategori osteopenia, citra hasil dari proses operasi morfologi juga terdiri dari proses erosi untuk menghilangkan tepi yang tidak diinginkan, dilanjutkan dengan proses dilasi untuk menghubungkan area yang terpisah dan diakhiri dengan proses closing untuk mengisi lubang-lubang kecil yang ditampilkan sebanyak 3 citra sebagai contoh. Terakhir, untuk kategori osteoporosis, citra hasil dari proses operasi morfologi terdiri dari proses erosi untuk menghilangkan tepi yang tidak diinginkan, dilanjutkan dengan proses dilasi untuk menghubungkan area yang terpisah dan diakhiri dengan proses closing untuk mengisi lubang-lubang kecil yang ditampilkan sebanyak 3 citra sebagai contoh.

4.3 Hasil Ekstraksi Fitur

Hasil Ekstraksi Fitur, bertujuan untuk mengubah data visual citra menjadi representasi numerik yang dapat diinterpretasikan oleh algoritma komputer. Fitur-

fitur tulang diekstraksi setelah proses segmentasi. Pada bagian ekstraksi fitur, perhatian utama difokuskan pada dua metode ekstraksi fitur, yaitu ekstraksi fitur tekstur menggunakan GLRLM dan ekstraksi fitur warna menggunakan Histogram.

4.3.1 Hasil Ekstraksi Fitur Tekstur GLRLM

Hasil ekstraksi fitur tekstur menggunakan GLRLM pada tahap ekstraksi fitur tekstur yang di ambil dari citra x-ray tulang lutut berdasarkan bagian hasil segmentasi terdiri dari fitur Short Run Emphasis (SRE), Long Run Emphasis (LRE), Gray Level Non Uniformity (GLNU), Run Length Non Uniformity (RLNU), Run Percentage (RP), Low Gray Level Run Emphasis (LGRE), High Gray Level Run Emphasis (HGRE), Short Run Low Gray Level Emphasis (SRLGLE), Short Run High Gray Level Emphasis (SRHGLE) dan Long Run High Gray Level Emphasis (LRHGLE), fitur-fitur GLRLM sudah dilakukan normalisasi data tujuannya untuk memudahkan analisis dan representasi data yang lebih akurat di tampilkan pada Tabel 4.4.

Tabel 4.4 Hasil Ekstraksi Fitur Tekstur GLRLM

		Jenis Kondisi Kesehatan Tulang		
		Normal	Osteopenia	Osteoporosis
Fitur-Fitur Gray-Level Run Length Matrix (GLRLM)	SRE	0.429965297	0.690020554	0.407964073
		0.586015639	0.71201756	0.48739514
		0.41283747	0.855869087	0.504039783
	LRE	0.025860126	0.006404811	0.585174222
		0.089581791	0.013980736	0.04662454
		0.015466317	0.00061135	0.57391669
	GLNU	0.669543809	0.57565301	0.381186806
		0.307794146	0.664903686	0.539980495
		0.806318726	0.191925947	0.226883935
	RLNU	0.574317942	0.688868105	0.116165337
		0.571968371	0.733973691	0.515890997
		0.585983055	0.629894464	0.12809532
	RP	0.682929616	0.701382541	0.165007182
		0.619662445	0.731628689	0.594304975
		0.70090918	0.584046096	0.154046422
	LGRE	0.107164805	0.23160915	0.016279215
		0.299128591	0.316832281	0.102867379
		0.289607353	0.165567527	0.688944823

	HGRE	0.342918484	0.320685612	0.289472181
		0.28579089	0.290419273	0.450692209
		0.166897468	0.334817846	0.247701362
	SRLGLE	0.107164805	0.23160915	0.016279215
		0.299128591	0.316832281	0.102867379
		0.289607353	0.165567527	0.688944823
	SRHGLE	0.335358239	0.327990455	0.291059746
		0.264717926	0.292200059	0.455936601
		0.157274912	0.335167237	0.241209789
	LRHGLE	0.261437676	0.257819027	0.336106362
		0.265136726	0.258335404	0.26689575
		0.269976551	0.264654166	0.257482478

Tabel 4.4 menunjukkan hasil ekstraksi fitur tekstur GLRLM untuk tiga kondisi kesehatan tulang lutut: normal, osteopenia dan osteoporosis. Untuk tulang normal, fitur Short Run Emphasis (SRE) menunjukkan prevalensi run pendek dengan nilai 0.43, 0.59 dan 0.41 secara berurutan. Fitur Long Run Emphasis (LRE) menunjukkan prevalensi run panjang yang lebih rendah dengan nilai 0.03, 0.09 dan 0.02. Fitur GLNU (Gray-Level Non-Uniformity) menunjukkan variasi homogenitas tinggi dengan nilai 0.67, 0.31 dan 0.81. Fitur RLNU (Run Length Non-Uniformity) menunjukkan variasi panjang run dengan nilai 0.57, 0.57 dan 0.59. Fitur RP (Run Percentage) menunjukkan kehadiran run yang signifikan dengan nilai 0.68, 0.62 dan 0.70. Fitur LGRE (Low Gray-Level Run Emphasis) menunjukkan prevalensi run dengan level abu-abu rendah dengan nilai 0.11, 0.30 dan 0.29. Fitur HGRE (High Gray-Level Run Emphasis) menunjukkan prevalensi run dengan level abu-abu tinggi yang bervariasi dengan nilai 0.34, 0.29 dan 0.17. Fitur SRLGLE (Short Run Low Gray-Level Emphasis) dan SRHGLE (Short Run High Gray-Level Emphasis) juga menggambarkan karakteristik serupa. Fitur LRHGLE (Long Run High Gray-Level Emphasis) menunjukkan prevalensi run panjang dengan level abu-abu tinggi.


Untuk kondisi osteopenia, nilai-nilai fitur SRE adalah 0.69, 0.71 dan 0.86, menunjukkan prevalensi run pendek yang lebih tinggi dibandingkan dengan kondisi normal. Fitur LRE menunjukkan prevalensi run panjang yang sangat rendah dengan nilai 0.01, 0.01 dan 0.001. GLNU menunjukkan variasi homogenitas dalam

distribusi level abu-abu dengan nilai 0.58, 0.66 dan 0.19. RLNU menunjukkan variasi panjang run yang lebih besar dengan nilai 0.69, 0.73 dan 0.63. Fitur RP menunjukkan kehadiran run yang tinggi dengan nilai 0.70, 0.73 dan 0.58. Fitur LGRE menunjukkan prevalensi run dengan level abu-abu rendah yang lebih tinggi dengan nilai 0.23, 0.32 dan 0.17. HGRE menunjukkan prevalensi run dengan level abu-abu tinggi yang bervariasi dengan nilai 0.32, 0.29 dan 0.33. SRLGLE dan SRHGLE juga menunjukkan pola yang serupa dengan LGRE. LRHGLE menunjukkan prevalensi run panjang dengan level abu-abu tinggi yang konsisten.

Untuk kondisi osteoporosis, fitur SRE menunjukkan prevalensi run pendek dengan nilai 0.41, 0.49 dan 0.50. Fitur LRE menunjukkan prevalensi run panjang yang lebih tinggi dengan nilai 0.59, 0.05 dan 0.57. GLNU menunjukkan variasi dalam distribusi level abu-abu dengan nilai 0.38, 0.54 dan 0.23. RLNU menunjukkan variasi panjang run yang lebih rendah dengan nilai 0.12, 0.52 dan 0.13. Fitur RP menunjukkan kehadiran run yang lebih rendah dengan nilai 0.17, 0.59 dan 0.15. Fitur LGRE menunjukkan prevalensi run dengan level abu-abu rendah yang sangat bervariasi dengan nilai 0.02, 0.10 dan 0.69. HGRE menunjukkan prevalensi run dengan level abu-abu tinggi yang bervariasi dengan nilai 0.29, 0.45 dan 0.25. SRLGLE dan SRHGLE juga menunjukkan pola yang serupa dengan LGRE. LRHGLE menunjukkan prevalensi run panjang dengan level abu-abu tinggi yang bervariasi.

4.3.2 Hasil Ekstraksi Fitur Warna Histogram

Hasil ekstraksi fitur warna menggunakan histogram pada tahap ekstraksi fitur warna didasarkan pada bagian hasil segmentasi citra X-ray tulang lutut, yang terdiri dari fitur Histogram_0 hingga Histogram_255. Setiap histogram merepresentasikan distribusi frekuensi intensitas warna dalam citra. Fitur-fitur histogram telah dinormalisasi untuk mempermudah analisis dan representasi data yang lebih akurat, seperti yang terlihat pada Tabel 4.5. Sebagai contoh hasil grafik ekstraksi fitur histogram dapat dilihat pada Gambar 4.1.



Gambar 4.1 Hasil Grafik Ekstraksi Fitur Histogram

Tabel 4.5 Hasil Ekstraksi Fitur Warna Histogram

		Jenis Kondisi Kesehatan Tulang		
		Normal	Osteopenia	Osteoporosis
Fitur-Fitur Histogram	Histogram_0	0.253550861	0.012898762	0.018316699
		0	0.178835206	0.042727278
		0.214877569	0.085970033	0.015059012
	Histogram_1	0	0	0.008053528
		0	0.151900172	0.004269643
		0.121471543	0.02519967	0.008276477
	Histogram_2	0	0	0.038129458
		0.018790879	0.158640853	0.020214639
		0.159752067	0.089480941	0.019592503
	Histogram_3	0	0	0.027855853
		0.004575954	0.07211347	0.024613341
		0.02074817	0.02421155	0
	Histogram_4	0.009505867	0	0.019639927
		0	0.043580579	0.02082453
		0.043885842	0.030726884	0
	Histogram_5	0	0	0
		0	0.061381635	0.058661161
		0.154528968	0.346221437	0.056855777
	Histogram_6	0	0	0
		0	0.115951123	0.083109072
		0.11676331	0.163504788	0
	Histogram_7	0	0	0
		0	0	0.013099213
		0.018403616	0.008590253	0
	⋮	⋮	⋮	⋮
	Histogram_255	0.003415141	0.002070362	0.001175995
		0.000579551	0.007176147	0.023691602
		0.008540306	0.003679715	0.00120855

Tabel 4.5 menampilkan hasil ekstraksi fitur histogram untuk tiga jenis kondisi kesehatan tulang lutut: normal, osteopenia dan osteoporosis, berdasarkan analisis citra X-ray. Fitur histogram memberikan gambaran tentang distribusi intensitas warna yang terdapat dalam setiap citra, yang kemudian diinterpretasikan sebagai indikator fitur visual yang dapat membedakan antara kondisi tulang yang berbeda.

Pada tulang normal, Histogram_0 menunjukkan nilai yang cukup berbeda antara kondisi normal (0.253550861), osteopenia (0.012898762) dan osteoporosis (0.018316699). Nilai histogram menandakan perbedaan dalam distribusi intensitas warna di seluruh gambar X-ray untuk setiap kondisi. Histogram-histogram lain seperti Histogram_1, Histogram_2 dan seterusnya, juga menunjukkan variasi yang mencerminkan karakteristik visual yang berbeda antara ketiga kondisi kesehatan tulang lutut.

Fitur-fitur pada histogram penting dalam konteks analisis citra medis karena dapat digunakan untuk mengidentifikasi pola-pola visual yang mungkin sulit diinterpretasikan secara manual. Dengan menggunakan ekstraksi fitur warna, dapat menghasilkan data yang lebih terstruktur dan mendalam untuk membantu dalam diagnosis dan pemantauan kondisi tulang secara lebih akurat.

4.4 Hasil Pelatihan Model


Model Artificial Neural Network (ANN) yang sudah dibuat dengan 4 kali percobaan, masing-masing dilatih dengan epoch sebanyak 50, 100, 150 dan 200, menghasilkan nilai precision untuk mengukur sejauh mana prediksi positif yang dibuat oleh model adalah benar, recall untuk mengukur sejauh mana model mampu mengidentifikasi semua instance positif yang sebenarnya, f1-score sebagai rata-rata harmonik dari precision dan recall, akurasi untuk mengukur seberapa tepat model dalam memprediksi nilai target dari seluruh data yang ada dan loss untuk menggambarkan seberapa jauh prediksi model dari nilai sebenarnya selama proses pelatihan. Nilai precision, recall, f1-score, akurasi dan loss dari 4 kali percobaan dapat dilihat pada Tabel 4.6.

Tabel 4.6 Hasil Pelatihan Model ANN

No.	Epoch	Precision	Recall	F1-Score	Akurasi	Loss
1.	50	89,14%	88,27%	88,39%	88,27%	27%
2.	100	90,23%	89,74%	89,82%	89,74%	21%
3.	150	90,03%	90,03%	90,01%	90,03%	17%
3.	200	90,46%	90,32%	90,32%	90,32%	18%


Tabel 4.6 dapat diuraikan sebagai berikut. Hasil pleatiha model ANN dari 4 kali percobaan dengan epoch 50, 100, 150 dan 200 masing-masing memiliki nilai precision, recall, F1-Score, akurasi yang sangat tinggi dan loss yang sangat rendah. Untuk mengetahui hasil model ANN yang terbaik dilihat dari nilai akurasi tertinggi, karena model ANN dengan epoch 200 memiliki nilai akurasi tertinggi maka dapat disimpulkan bahwa model ANN dengan epoch 200 adalah model ANN terbaik dengan akurasi sebesar 90,32%.

Selanjutnya dilakukan visualisasi dari hasil pelatihan model ANN terbaik dengan 200 epoch untuk memahami kinerja model dari berbagai perspektif. Nilai akurasi digunakan untuk mengetahui sejauh mana model dapat mengklasifikasikan data dengan benar selama proses pelatihan. Loss digunakan untuk mengetahui seberapa besar kesalahan prediksi model terhadap data pelatihan, yang berfungsi sebagai indikator seberapa baik model melakukan pembelajaran dari data pelatihan. Validasi akurasi digunakan untuk mengetahui kinerja model pada data validasi yang tidak dilibatkan dalam pelatihan, sehingga memberikan gambaran tentang kemampuan generalisasi model pada data baru. Validasi loss digunakan untuk mengetahui seberapa besar kesalahan prediksi model terhadap data validasi, yang dapat membantu mendeteksi masalah overfitting apabila nilai validasi loss jauh lebih tinggi daripada nilai loss pada data pelatihan. Selain itu, dilakukan juga visualisasi confusion matrix untuk mengevaluasi kinerja model secara lebih mendetail, yaitu dengan melihat berapa banyak objek yang berhasil diidentifikasi dengan benar (true positives dan true negatives) serta berapa banyak yang terlewatkan atau salah diidentifikasi (false positives dan false negatives).



Gambar 4.2 Grafik Akurasi dan Loss

Pada Gambar 4.2 grafik akurasi dan loss menunjukkan bahwa nilai akurasi dari model terbaik yaitu 200 epoch semakin naik artinya peningkatan secara keseluruhan dalam kinerja model identifikasi objek dan loss semakin menurun artinya tingkat kesalahan prediksi model terus berkurang. Selain itu, terlihat bahwa kurva akurasi dan loss cenderung berhimpitan, menandakan konsistensi dan stabilitas kinerja model dalam proses pelatihan.



Gambar 4.3 Confusion Matrix



Pada Gambar 4.3 confusion matrix menunjukkan bahwa nilai confusion matrix model terbaik yaitu 200 epoch banyak memprediksi dengan benar dan


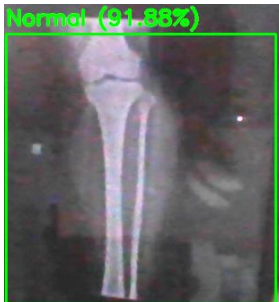



sedikit memprediksi yang salah artinya bahwa model memiliki kinerja yang baik dalam mengklasifikasikan atau mengidentifikasi objek.





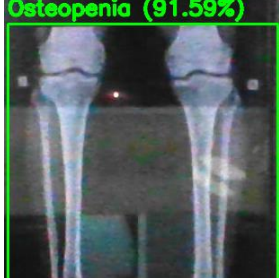
4.5 Hasil Pengujian Model


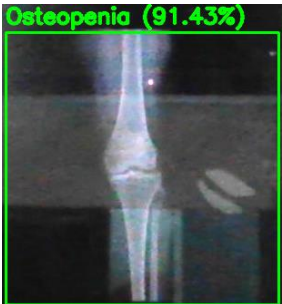
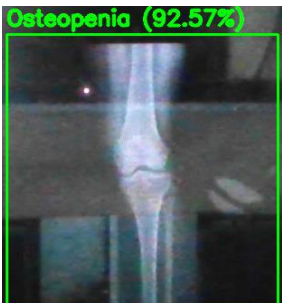

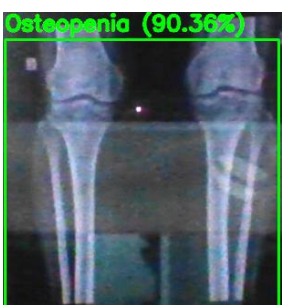
Hasil pengujian model, pengujian dilakukan untuk menguji kemampuan model ANN dalam memprediksi objek, jarak kamera dengan objek pada saat uji coba adalah 50 cm. Tujuan dari uji coba adalah untuk mengevaluasi apakah model ANN mampu mengenali dan mengklasifikasikan objek yang ada dalam gambar atau tidak. Dengan melakukan uji coba dapat mengukur sejauh mana model ANN dapat bekerja secara akurat dalam mengidentifikasi objek-objek yang muncul dalam berbagai situasi visual. Berikut hasil uji coba yang sudah dilakukan dapat dilihat pada Tabel 4.7.




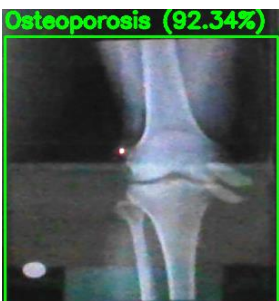

Tabel 4.7 Uji Coba Model ANN



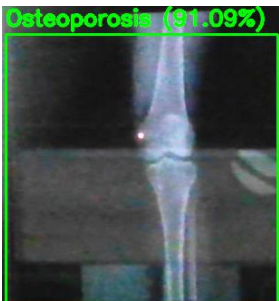
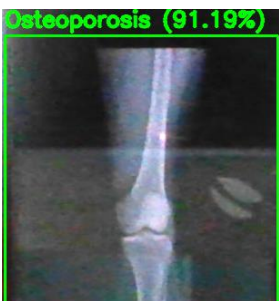

No..	Gambar	Deskripsi	Akurasi
1.		Normal	90,10%
2.		Normal	90,41%

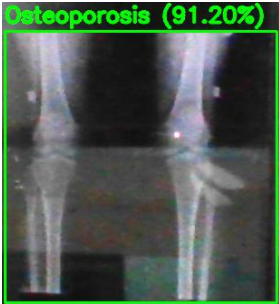
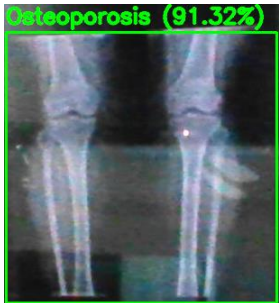
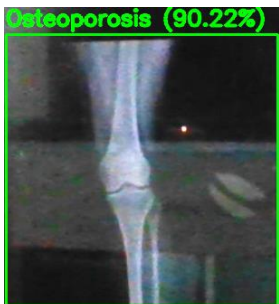
3.		Normal	90,66%
4.		Normal	91,88%
5.		Normal	93,16%
6.		Normal	91,35%
7.		Normal	91,50%

8.	<p>Normal (92.45%)</p> 	Normal	92,45%
9.	<p>Normal (91.61%)</p> 	Normal	91,61%
10.	<p>Normal (91.44%)</p> 	Normal	91,44%
11.	<p>Osteopenia (90.70%)</p> 	Osteopenia	90,70%
12.	<p>Osteopenia (91.59%)</p> 	Osteopenia	91,59%

13.		Osteopenia	91,30%
14.		Osteopenia	91,43%
15.		Osteopenia	92,57%
16.		Osteopenia	92,43%
17.		Osteopenia	90,36%

18.		Osteopenia	92,66%
19.		Osteopenia	90,46%
20.		Osteopenia	92,09%
21.		Osteoporosis	92,34%
22.		Osteoporosis	90,51%

23.		Osteoporosis	91,40%
24.		Osteoporosis	90,07%
25.		Osteoporosis	91,09%
26.		Osteoporosis	91,19%
27.		Osteoporosis	90,04%

28.		Osteoporosis	91,20%
29.		Osteoporosis	91,32%
30.		Osteoporosis	90,22%

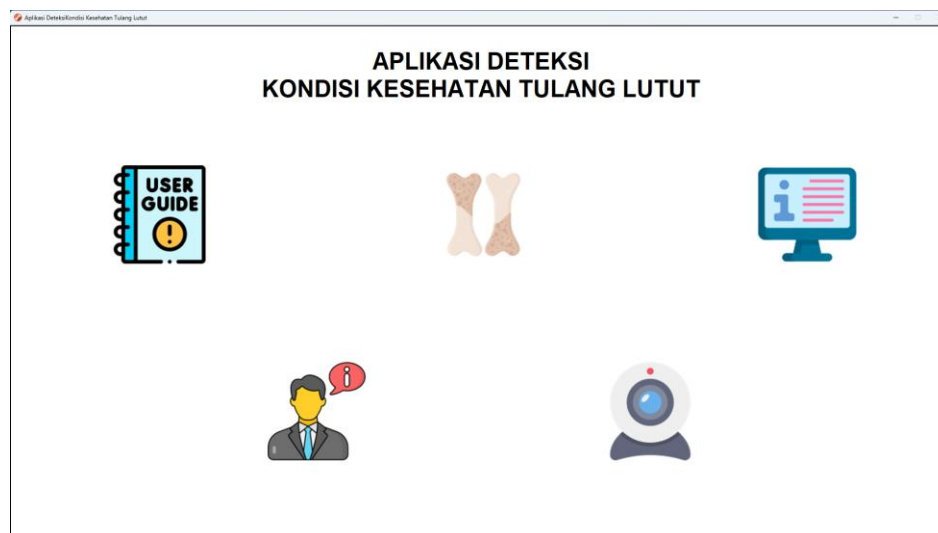
Hasil uji coba sistem deteksi kondisi Kesehatan tulang lutut dengan 30 citra X-ray kondisi Kesehatan tulang memiliki nilai akurasi yang sangat tinggi dengan rata-rata akurasi sebesar 91,40% jika dihitung dalam 30 citra kondisi Kesehatan tulang. Akurasi tertinggi mencapai 93,16% pada identifikasi kondisi Kesehatan tulang kategori Normal dan akurasi terendah mencapai 90,04% pada identifikasi jenis Osteoporosis.

4.6 Prototype Sistem Deteksi Kondisi Kesehatan Tulang Lutut

Implementasi sistem deteksi kondisi Kesehatan tulang lutut. Terdapat 6 tampilan menu diantaranya Tampilan menu utama sistem deteksi kondisi Kesehatan tulang lutut, tampilan menu panduan sistem deteksi kondisi Kesehatan

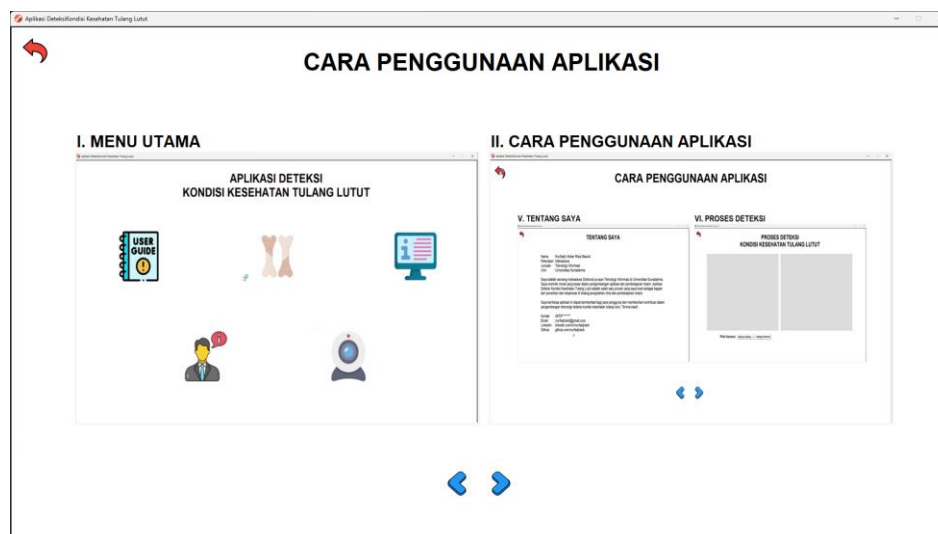
tulang lutut, tampilan menu koleksi kondisi kesehatan tulang lutut, tampilan menu tentang sistem deteksi kondisi Kesehatan tulang lutut, tampilan menu tentang saya, tampilan menu proses identifikasi dan tampilan hasil identifikasi.

Tahap awal membuka sistem deteksi kondisi Kesehatan tulang lutut, Ketika sistem deteksi kondisi Kesehatan tulang lutut dibuka yang pertama kali muncul adalah menu utama. Pada menu utama terdapat label judul menu, tombol menu panduan sistem deteksi kondisi Kesehatan tulang lutut ketika di klik maka akan menampilkan panduan sistem deteksi kondisi Kesehatan tulang lutut, tombol menu koleksi kondisi kesehatan tulang lutut ketika di klik maka akan menampilkan koleksi kondisi kesehatan tulang lutut, tombol menu tentang sistem deteksi kondisi Kesehatan tulang lutut ketika di klik maka akan menampilkan tentang sistem deteksi kondisi Kesehatan tulang lutut, tombol menu tentang saya ketika di klik maka akan menampilkan tentang pembuat sistem deteksi kondisi Kesehatan tulang lutut, tombol menu proses identifikasi ketika di klik maka akan menampilkan proses identifikasi kondisi Kesehatan tulang lutut. Tampilan menu utama dapat dilihat pada Gambar 4.4.



Gambar 4.4 Tampilan Menu Utama

Ketika menu panduan sistem deteksi kondisi Kesehatan tulang lutut pada menu utama di klik akan menampilkan informasi panduan sistem deteksi kondisi Kesehatan tulang lutut. Pada manu panduan sistem deteksi kondisi Kesehatan tulang lutut terdapat label judul menu, label sub judul langkah panduan sistem deteksi kondisi Kesehatan tulang lutut, canvas video panduan sistem deteksi kondisi Kesehatan tulang lutut, tombol prev ketika di klik akan menampilkan langkah video panduan sistem deteksi kondisi Kesehatan tulang lutut sebelumnya, tombol next ketika di klik akan menampilkan langkah video panduan sistem deteksi kondisi Kesehatan tulang lutut selanjutnya dan tombol kembali jika di klik akan kembali ke menu utama. Tampilan menu panduan sistem deteksi kondisi Kesehatan tulang lutut dapat dilihat pada Gambar 4.5.



Gambar 4.5 Tampilan Menu Panduan Sistem Deteksi Kondisi Kesehatan Tulang Lutut

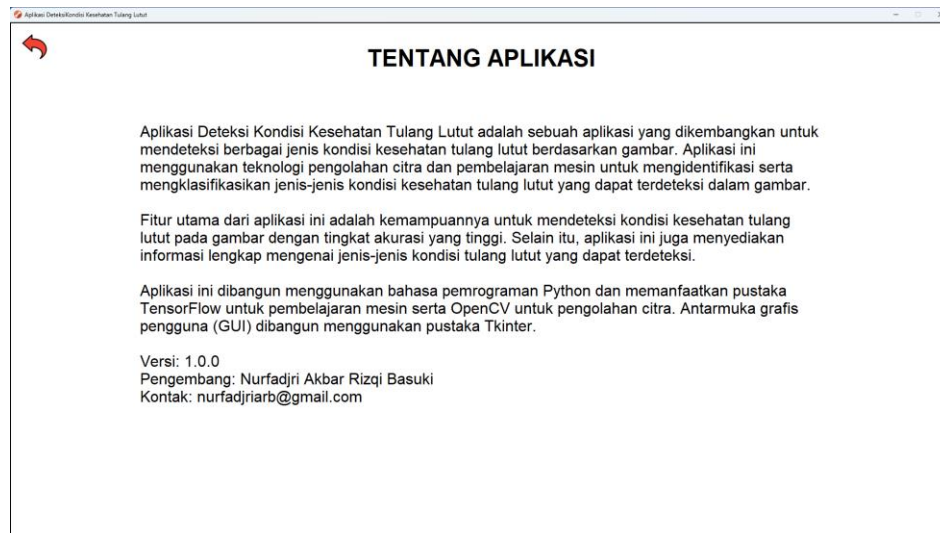
Ketika menu koleksi kondisi Kesehatan tulang lutut pada menu utama di klik akan menampilkan informasi koleksi kondisi Kesehatan tulang lutut. Pada menu koleksi kondisi Kesehatan tulang lutut terdapat label judul menu, label gambar kondisi Kesehatan tulang lutut, label deskripsi kondisi Kesehatan tulang lutut, tombol prev ketika di klik akan menampilkan data kondisi Kesehatan tulang

lutut sebelumnya, tombol next ketika di klik akan menampilkan data kondisi Kesehatan tulang lutut selanjutnya dan tombol kembali jika di klik akan kembali ke menu utama. Tampilan menu koleksi kondisi Kesehatan tulang lutut dapat dilihat pada Gambar 4.6.



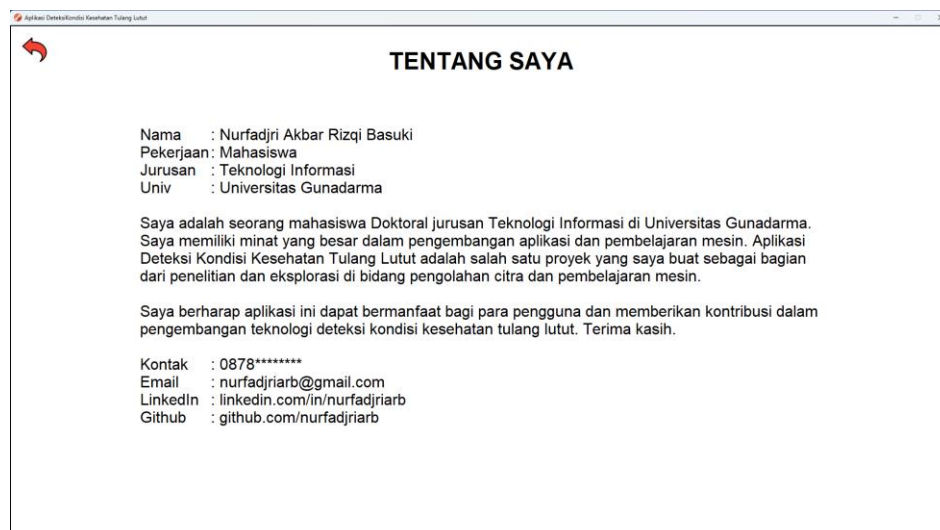
Gambar 4.6 Tampilan Menu Koleksi Kondisi Kesehatan Tulang Lutut

Ketika menu tentang sistem deteksi kondisi Kesehatan tulang lutut pada menu utama di klik akan menampilkan informasi tentang sistem deteksi kondisi Kesehatan tulang lutut. Pada menu tentang sistem deteksi kondisi Kesehatan tulang lutut terdapat label judul menu, label deskripsi tentang sistem deteksi kondisi Kesehatan tulang lutut dan tombol kembali jika di klik akan kembali ke menu utama. Tampilan menu tentang sistem deteksi kondisi Kesehatan tulang lutut dapat dilihat pada Gambar 4.7.



Gambar 4.7 Tampilan Menu Tentang Sistem Deteksi Kondisi Kesehatan Tulang Lutut

Ketika menu tentang saya pada menu utama di klik akan menampilkan informasi tentang saya. Pada menu tentang saya terdapat label judul menu, label deskripsi tentang pembuat aplikas sistem deteksi kondisi Kesehatan tulang lutut dan tombol kembali jika di klik akan kembali ke menu utama. Tampilan menu tentang saya dapat dilihat pada Gambar 4.8.



Gambar 4.8 Tampilan Menu Tentang Saya

Ketika menu proses identifikasi pada menu utama di klik akan menampilkan proses identifikasi. Pada menu proses identifikasi terdapat label judul menu, canvas video webcam, canvas screenshot, tombol pemilihan kamera jika di klik akan muncul pilihan kamera, tombol submit kamera jika di klik akan memilih kamera yang telah dipilih, tombol hasil identifikasi jika di klik akan menampilkan pop-up hasil identifikasi kondisi Kesehatan tulang lutut dan tombol kembali jika di klik akan kembali ke menu utama. Tampilan menu proses deteksi dapat dilihat pada Gambar 4.9.



Gambar 4.9 Tampilan Menu Proses Deteksi

Ketika tombol hasil identifikasi pada menu proses identifikasi kondisi Kesehatan tulang lutut di klik akan menampilkan informasi hasil identifikasi. Pada hasil identifikasi terdapat label judul, label gambar aktual untuk menampilkan citra kondisi Kesehatan tulang lutut secara aktual, label gambar prediksi untuk menampilkan citra prediksi kondisi Kesehatan tulang lutut hasil identifikasi, label nama kondisi Kesehatan tulang lutut hasil identifikasi dan label deskripsi kondisi Kesehatan tulang lutut hasil identifikasi Tampilan hasil deteksi dapat dilihat pada Gambar 4.10.



Gambar 4.10 Tampilan Hasil Deteksi Kondisi Kesehatan Tulang Lutut

DAFTAR PUSTAKA

- Aaron, J., & Chew, T. L. (2021). A guide to accurate reporting in digital image processing – Can anyone reproduce your quantitative analysis? In *Journal of Cell Science* (Vol. 134, Issue 6). Company of Biologists Ltd. <https://doi.org/10.1242/jcs.254151>
- Abdolrasol, M. G. M., Suhail Hussain, S. M., Ustun, T. S., Sarker, M. R., Hannan, M. A., Mohamed, R., Ali, J. A., Mekhilef, S., & Milad, A. (2021). Artificial neural networks based optimization techniques: A review. In *Electronics (Switzerland)* (Vol. 10, Issue 21). MDPI. <https://doi.org/10.3390/electronics10212689>
- Aboul Ella Hassanien, Roheet Bhatnagar, & Ashraf Darwish. (2020). *Advances in Intelligent Systems and Computing 1141 Advanced Machine Learning Technologies and Applications Proceedings of AMLTA 2020*. <http://www.springer.com/series/11156>
- Amit, Y., Felzenszwalb, P., & Girshick, R. (2020). Object Detection. In *Computer Vision* (pp. 1–9). Springer International Publishing. https://doi.org/10.1007/978-3-030-03243-2_660-1
- Anam, S., Maulana, M. H. A. A., Hidayat, N., Yanti, I., Fitriah, Z., & Mahanani, D. M. (2021). Predicting the Number of COVID-19 Sufferers in Malang City Using the Backpropagation Neural Network with the Fletcher-Reeves Method. *Applied Computational Intelligence and Soft Computing, 2021*. <https://doi.org/10.1155/2021/6658552>
- Apicella, A., Donnarumma, F., Isgrò, F., & Prevete, R. (2021). A survey on modern trainable activation functions. In *Neural Networks* (Vol. 138, pp. 14–32). Elsevier Ltd. <https://doi.org/10.1016/j.neunet.2021.01.026>
- Ahmed, Z., Mohamed, K., Zeeshan, S., & Dong, X. Q. (2020). Artificial intelligence with multi-functional machine learning platform development for better healthcare and precision medicine. In *Database* (Vol. 2020). Oxford University Press. <https://doi.org/10.1093/database/baaa010>
- Ali, O., Abdelbaki, W., Shrestha, A., Elbasi, E., Alryalat, M. A. A., & Dwivedi, Y. K. (2023). A systematic literature review of artificial intelligence in the healthcare sector: Benefits, challenges, methodologies, and functionalities. *Journal of Innovation and Knowledge, 8*(1). <https://doi.org/10.1016/j.jik.2023.100333>
- Barbosa, F. M. C., Magaly, A., & Canuto, P. (n.d.). *Classification of chest X-ray images using Machine Learning and Histogram of Oriented Gradients*. Bhavsar, K. A., Singla, J., Al-Otaibi, Y. D., Song, O. Y., Zikria, Y. Bin, & Bashir, A. K. (2021). Medical diagnosis using machine learning: a statistical review. In *Computers, Materials and Continua* (Vol. 67, Issue 1, pp. 107–125). Tech Science Press. <https://doi.org/10.32604/cmc.2021.014604>
- Clynes, M. A., Harvey, N. C., Curtis, E. M., Fuggle, N. R., Dennison, E. M., & Cooper, C. (2020). The epidemiology of osteoporosis. In *British Medical Bulletin* (Vol. 133, Issue 1, pp. 105–117). Oxford University Press. <https://doi.org/10.1093/bmb/ldaa005>
- Dash, S. S., Das, S., Ketan, B., & Editors, P. (2021). *Advances in Intelligent Systems and Computing 1172 Intelligent Computing and Applications Proceedings of ICICA 2019*. <http://www.springer.com/series/11156>
- Dastres, R., & Soori, M. (2021). Artificial Neural Network Systems. In *International Journal of Imaging and Robotics (IJIR)* (Vol. 2021, Issue 2). www.ceserp.com/cp-jour
- Du, J., Wang, J., Gai, X., Sui, Y., Liu, K., & Yang, D. (2023). Application of intelligent X-ray image analysis in risk assessment of osteoporotic fracture of femoral neck in the elderly.

- Mathematical Biosciences and Engineering*, 20(1), 879–893. <https://doi.org/10.3934/mbe.2023040>
- Ella Hassanien, A., Haqiq, A., Tonellato, P. J., Bellatreche, L., Goundar, S., Taher Azar, A., Sabir, E., & Bouzidi Editors, D. (2021). *Advances in Intelligent Systems and Computing* 1377. <http://www.springer.com/series/11156>
- Fang, Y., Li, W., Chen, X., Chen, K., Kang, H., Yu, P., Zhang, R., Liao, J., Hong, G., & Li, S. (2021). Opportunistic osteoporosis screening in multi-detector CT images using deep convolutional neural networks. *European Radiology*, 31(4), 1831–1842. <https://doi.org/10.1007/s00330-020-07312-8>
- Fasihi, L., Tartibian, B., Eslami, R., & Fasihi, H. (2022). Artificial intelligence used to diagnose osteoporosis from risk factors in clinical data and proposing sports protocols. *Scientific Reports*, 12(1). <https://doi.org/10.1038/s41598-022-23184-y>
- Fathi Kazerooni, A., Pozo, J. M., McCloskey, E. V., Saligheh Rad, H., & Frangi, A. F. (2020). Diffusion MRI for Assessment of Bone Quality; A Review of Findings in Healthy Aging and Osteoporosis. In *Journal of Magnetic Resonance Imaging* (Vol. 51, Issue 4, pp. 975–992). John Wiley and Sons Inc. <https://doi.org/10.1002/jmri.26973>
- Han, G., Zou, D., Liu, Z., Zhou, S., Li, W., Gong, C., Sun, Z., & Li, W. (2022). Paraspinal muscle characteristics on MRI in degenerative lumbar spine with normal bone density, osteopenia and osteoporosis: a case-control study. *BMC Musculoskeletal Disorders*, 23(1). <https://doi.org/10.1186/s12891-022-05036-y>
- Hee Lee, D., & Yoon, S. N. (2021). Application of artificial intelligence-based technologies in the healthcare industry: Opportunities and challenges. *International Journal of Environmental Research and Public Health*, 18(1), 1–18. <https://doi.org/10.3390/ijerph18010271>
- Hussain, S., Mubeen, I., Ullah, N., Shah, S. S. U. D., Khan, B. A., Zahoor, M., Ullah, R., Khan, F. A., & Sultan, M. A. (2022). Modern Diagnostic Imaging Technique Applications and Risk Factors in the Medical Field: A Review. In *BioMed Research International* (Vol. 2022). Hindawi Limited. <https://doi.org/10.1155/2022/5164970>
- Jang, R., Choi, J. H., Kim, N., Chang, J. S., Yoon, P. W., & Kim, C. H. (2021). Prediction of osteoporosis from simple hip radiography using deep learning algorithm. *Scientific Reports*, 11(1). <https://doi.org/10.1038/s41598-021-99549-6>
- Janiesch, C., Zschech, P., & Heinrich, K. (2021). Machine learning and deep learning. *Electronic Markets*. <https://doi.org/10.1007/s12525-021-00475-2/Published>
- Koyuncu, H., & Barstuğan, M. (2021). COVID-19 discrimination framework for X-ray images by considering radiomics, selective information, feature ranking, and a novel hybrid classifier. *Signal Processing: Image Communication*, 97. <https://doi.org/10.1016/j.image.2021.116359>
- Li, C., Li, X., Rahaman, M., Li, X., Sun, H., Zhang, H., Zhang, Y., Li, X., Wu, J., Yao, Y., & Grzegorzec, M. (2021). *A Comprehensive Review of Computer-aided Whole-slide Image Analysis: from Datasets to Feature Extraction, Segmentation, Classification, and Detection Approaches*. <http://arxiv.org/abs/2102.10553>
- Madhiarasan, M., & Louzazni, M. (2022). Analysis of Artificial Neural Network: Architecture, Types, and Forecasting Applications. *Journal of Electrical and Computer Engineering*, 2022. <https://doi.org/10.1155/2022/5416722>
- MOORE, A. D. (2021). *PYTHON GUI PROGRAMMING WITH TKINTER - develop responsive and powerful gui applications with... tkinter*. PACKT PUBLISHING LIMITED.
- Motahhir, S., & Bossoufi, B. (2021). *Lecture Notes in Networks and Systems 211 Digital Technologies and Applications Proceedings of ICDTA 21, Fez, Morocco*. <http://www.springer.com/series/15179>

- Nogueira, K., Chanussot, J., Mura, M. D., & Santos, J. A. D. (2021). An Introduction to Deep Morphological Networks. *IEEE Access*, 9, 114308–114324. <https://doi.org/10.1109/ACCESS.2021.3104405>
- Ou, X., Chen, X., Xu, X., Xie, L., Chen, X., Hong, Z., Bai, H., Liu, X., Chen, Q., Li, L., & Yang, H. (2021). Recent Development in X-Ray Imaging Technology: Future and Challenges. *Research*, 2021. <https://doi.org/10.34133/2021/9892152>
- Patil, K. A., Prashanth, K. V. M., & Ramalingaiah, A. (2021). Texture feature extraction of Lumbar spine trabecular bone radiograph image using Laplacian of Gaussian filter with KNN classification to diagnose osteoporosis. *Journal of Physics: Conference Series*, 2070(1). <https://doi.org/10.1088/1742-6596/2070/1/012137>
- Pommé, L.-E., Bourqui, R., Giot, R., & Auber, D. (2022). *Relative Confusion Matrix: Efficient Comparison of Decision Models*. <https://doi.org/10.1109/TV56949.2022.00025i>
- Rani, B. M. S., Majety, V. D., Pittala, C. S., Vijay, V., Sandeep, K. S., & Kiran, S. (2021). Road identification through efficient edge segmentation based on morphological operations. *Traitement Du Signal*, 38(5), 1503–1508. <https://doi.org/10.18280/ts.380526>
- Sadeghi, H., Ashraf, A., Zeynali, N., Ebrahimi, B., & A Jehu, D. (2021). Balance and functional mobility predict low bone mineral density among postmenopausal women undergoing recent menopause with osteoporosis, osteopenia, and normal bone mineral density: A cross-sectional study. *Geriatric Nursing*, 42(1), 33–36. <https://doi.org/10.1016/j.gerinurse.2020.10.020>
- Saeed, H. A., Hamad, S., & Hussain, A. T. (2021). Analysis the digital images by using morphology operators. *Indonesian Journal of Electrical Engineering and Computer Science*, 24(3), 1654–1662. <https://doi.org/10.11591/ijeecs.v24.i3.pp1654-1662>
- Said, K. A. M., & Jambek, A. B. (2021). Analysis of Image Processing Using Morphological Erosion and Dilation. *Journal of Physics: Conference Series*, 2071(1). <https://doi.org/10.1088/1742-6596/2071/1/012033>
- Sarker, I. H. (2021). Machine Learning: Algorithms, Real-World Applications and Research Directions. In *SN Computer Science* (Vol. 2, Issue 3). Springer. <https://doi.org/10.1007/s42979-021-00592-x>
- Sebro, R., & Ashok, S. S. (2021). A Statistical Approach Regarding the Diagnosis of Osteoporosis and Osteopenia From DXA: Are We Underdiagnosing Osteoporosis? *JBMR Plus*, 5(2). <https://doi.org/10.1002/jbm4.10444>
- Shao, G., Tang, L., & Zhang, H. (2021). Introducing image classification efficacies. *IEEE Access*, 9, 134809–134816. <https://doi.org/10.1109/ACCESS.2021.3116526>
- Smets, J., Shevroja, E., Hügle, T., Leslie, W. D., & Hans, D. (2021). Machine Learning Solutions for Osteoporosis—A Review. In *Journal of Bone and Mineral Research* (Vol. 36, Issue 5, pp. 833–851). John Wiley and Sons Inc. <https://doi.org/10.1002/jbmr.4292>
- Szeliski, R. (2022). *Computer Vision: Algorithms and Applications*.
- Tang, C., Zhang, W., Li, H., Li, L., Li, Z., Cai, A., Wang, L., Shi, D., & Yan, B. (2021). CNN-based qualitative detection of bone mineral density via diagnostic CT slices for osteoporosis screening. *Osteoporosis International*, 32(5), 971–979. <https://doi.org/10.1007/s00198-020-05673-w>
- U M, P., Kottursamy, K., Cengiz, K., Kose, U., & Thanh Hung, B. (2021). 4x-expert systems for early prediction of osteoporosis using multi-model algorithms. *Measurement: Journal of the International Measurement Confederation*, 180. <https://doi.org/10.1016/j.measurement.2021.109543>
- Vijayan, T., Sangeetha, M., Kumaravel, A., & Karthik, B. (2023). Feature Selection for Simple Color Histogram Filter based on Retinal Fundus Images for Diabetic Retinopathy Recognition. *IETE Journal of Research*, 69(2), 987–994. <https://doi.org/10.1080/03772063.2020.1844082>

- Wani, I. M., & Arora, S. (2023). Osteoporosis diagnosis in knee X-rays by transfer learning based on convolution neural network. *Multimedia Tools and Applications*, 82(9), 14193–14217. <https://doi.org/10.1007/s11042-022-13911-y>
- Withers, P. J., Bouman, C., Carmignato, S., Cnudde, V., Grimaldi, D., Hagen, C. K., Maire, E., Manley, M., Du Plessis, A., & Stock, S. R. (2021). X-ray computed tomography. In *Nature Reviews Methods Primers* (Vol. 1, Issue 1). Springer Nature. <https://doi.org/10.1038/s43586-021-00015-4>
- Wolff, J., Pauling, J., Keck, A., & Baumbach, J. (2020). The economic impact of artificial intelligence in health care: Systematic review. In *Journal of Medical Internet Research* (Vol. 22, Issue 2). JMIR Publications Inc. <https://doi.org/10.2196/16866>
- Xue, Z., Huo, J., Sun, X., Sun, X., Ai, S. tao, LichiZhang, & Liu, C. (2022). Using radiomic features of lumbar spine CT images to differentiate osteoporosis from normal bone density. *BMC Musculoskeletal Disorders*, 23(1). <https://doi.org/10.1186/s12891-022-05309-6>
- Yousfi, L., Houam, L., Boukrouche, A., Lespessailles, E., Ros, F., & Jennane, R. (2020). Texture Analysis and Genetic Algorithms for Osteoporosis Diagnosis. *International Journal of Pattern Recognition and Artificial Intelligence*, 34(5). <https://doi.org/10.1142/S0218001420570025>
- Zaworski, C., Cheah, J., Koff, M. F., Breighner, R., Lin, B., Harrison, J., Donnelly, E., & Stein, E. M. (2021). MRI-based Texture Analysis of Trabecular Bone for Opportunistic Screening of Skeletal Fragility. *Journal of Clinical Endocrinology and Metabolism*, 106(8), 2233–2241. <https://doi.org/10.1210/clinem/dgab342>
- Zhang, C., & Lu, Y. (2021). Study on artificial intelligence: The state of the art and future prospects. *Journal of Industrial Information Integration*, 23. <https://doi.org/10.1016/j.jii.2021.100224>
- Zhang, J. H., Meng, B., Zou, L. C., Zhu, Y., & Hwang, G. J. (2023). Progressive flowchart development scaffolding to improve university students' computational thinking and programming self-efficacy. *Interactive Learning Environments*, 31(6), 3792–3809. <https://doi.org/10.1080/10494820.2021.1943687>
- Zhao, D., Liu, L., Yu, F., Heidari, A. A., Wang, M., Oliva, D., Muhammad, K., & Chen, H. (2021). Ant colony optimization with horizontal and vertical crossover search: Fundamental visions for multi-threshold image segmentation. *Expert Systems with Applications*, 167. <https://doi.org/10.1016/j.eswa.2020.114122>