



**PENGEMBANGAN IDENTIFIKASI PENYAKIT DAN HAMA
PADA VANILI MENGGUNAKAN CNN (YOLO VERSI 8)**

PROPOSAL PENELITIAN

RADITYO HENDRATMOJO JATI N

99223131

**PROGRAM DOKTOR TEKNOLOGI INFORMASI
UNIVERSITAS GUNADARMA**

Agustus 2024

KATA PENGANTAR

Puji dan syukur Penulis panjatkan kehadiran Tuhan Yang Maha Esa yang telah memberikan rahmat dan berkat-Nya, sehingga Penulis dapat menyelesaikan Proposal Disertasi yang berjudul “Pengembangan identifikasi penyakit dan hama pada vanili menggunakan YOLO versi 8” ini tepat pada waktu yang telah ditentukan. Proposal Disertasi ini disusun untuk memenuhi salah satu syarat memperoleh gelar Doktor Teknologi Informasi (S3) pada Program Doktor, Universitas Gunadarma.

Proses penyusunan Proposal Disertasi ini tidak lepas dari berbagai pihak yang telah memberikan dukungan, bimbingan dan pengarahan yang sangat berharga. Oleh karena itu, Penulis mengucapkan terima kasih atas bantuan dari berbagai pihak dalam penyelesaian Proposal Disertasi ini kepada:

1. Yayasan Pendidikan Gunadarma yang telah memberikan beasiswa kepada Penulis untuk melanjutkan studi Program Doktor Teknologi Informasi di Universitas Gunadarma.
2. Prof. Dr. E. S. Margianti, SE., MM., dan Prof. Suryadi H.S., S.Si., MMSI., selaku Rektor dan Wakil Rektor II Universitas Gunadarma yang telah memberikan kesempatan dan kepercayaan kepada Penulis untuk melanjutkan studi Program Doktor Teknologi Informasi di Universitas Gunadarma.
3. Prof. Dr. Sarifuddin Madenda selaku Ketua Program Doktor Teknologi Informasi Universitas Gunadarma yang telah memberikan motivasi untuk menyelesaikan proposal penelitian ini.
4. Prof. Dr. Dewi Agushinta Rahayu, S.Kom, M.Sc., selaku promotor yang selalu meluangkan waktu, memberikan bimbingan dan masukan yang sangat bermanfaat bagi Penulis dalam menyelesaikan proposal penelitian ini dengan rasa tanggung jawab.

5. Kedua orang tua, yang selalu mendoakan, memberikan motivasi bagi Penulis dalam menyelesaikan proposal penelitian ini dengan rasa tanggung jawab.

Jakarta, Februari 2024

Penulis

DAFTAR ISI

	halaman
KATA PENGANTAR	i
DAFTAR ISI	iii
DAFTAR GAMBAR	v
DAFTAR TABEL	vi
DAFTAR RUMUS	vii
 1. PENDAHULUAN	
1.1 Latar Belakang	1
1.2 Rumusan Masalah	4
1.3 Tujuan Penelitian	4
1.4 Batasan Masalah	4
1.5 Kontribusi Penelitian	5
 2. KAJIAN PUSTAKA	
2.1 Deep Learning	6
2.2 Deteksi Objek	8
2.3 YOLO	8
2.4 Augmentasi Gambar	16
2.5 Matriks Evaluasi YOLO	17
2.6 Tanaman Vanili	19
2.7 Morfologi Vanili	20
2.8 Pembudidayaan Vanili	22
2.9 Penyakit dan Hama Vanili	28
2.10 Penelitian Terdahulu	31
2.11 Diagram Fishbone	34
 3. METODOLOGI PENELITIAN	
3.1 Tahapan Penelitian	36
3.2 Akuisisi Data	36
3.3 Pre-processing	37
3.4 Augmentasi Data	37

3.5	Pelatihan Model	38
3.6	Evaluasi dan Analisis Model	39
3.7	Identifikasi Penyakit Hama Vanili	40
3.8	Jadwal Penelitian	40
DAFTAR PUSTAKA		41

DAFTAR GAMBAR

	halaman
Gambar 2.1 Lapisan Konvolusi	7
Gambar 2.2 Maxpooling dan Average Pooling	7
Gambar 2.3 Arsitektur YOLO versi 1	9
Gambar 2.4 Arsitektur YOLO versi 8	11
Gambar 2.5 Modul C2f	12
Gambar 2.6 Bottleneck (T/F)	12
Gambar 2.7 Modul CBS.....	13
Gambar 2.8 Modul SPPF	14
Gambar 2.9 Arsitektur FPN-PAN	15
Gambar 2.10 Head	16
Gambar 2.11 Peta Penyebaran Tanaman Vanili	20
Gambar 2.12 Penyakit Yang Menyerang Tanaman Vanili	28
Gambar 2.13 Hama yang Menyerang Tanaman Vanili	30
Gambar 2.14 Diagram <i>Fishbone</i>	35
Gambar 3.1 Tahapan Penelitian	36
Gambar 3.2 Alur Data Diresize dan Diberikan Anotasi	37
Gambar 3.3 Alur Augmentasi Gambar	38
Gambar 3.4 Alur Pelatihan Model	38
Gambar 3.5 Alur Evaluasi dan Analisis Model	39
Gambar 3.6 Alur Identifikasi Penyakit dan Hama Vanili	40

DAFTAR TABEL

	halaman
Tabel 2.1 Penyajian Kesimpulan Prediksi.....	19
Tabel 2.2 Klasifikasi Tanaman Vanilla Planifolia	20
Tabel 2.3 Kriteria Kesesuaian Iklim Tanaman Vanili.....	23
Tabel 2.4 Penelitian Terdahulu	32
Tabel 3.1 Jadwal Kegiatan	40

BAB 1

PENDAHULUAN

1.1. Latar Belakang

Kecerdasan artifisial (*Artificial Intelligence* - AI) menawarkan kemudahan dalam mengidentifikasi suatu objek dengan bantuan mesin. Mesin belajar AI (*Machine Learning* - ML) dengan menggunakan jaringan saraf tiruan (*Artificial Neural Network* - ANN) memungkinkan mesin dapat menganalisis data yang diberikan, semakin rumit jaringan yang terhubung menyebabkan lapisan pada ANN bertambah banyak. Banyaknya lapisan memungkinkan mesin untuk mempelajari data lebih dalam (*Deep Learning* - DL). *Artificial Neural Network* pada DL memiliki beberapa model, salah satunya ialah model konvolusi (*Convolution Neural Network* - CNN). Model CNN dapat digunakan untuk mengidentifikasi penyakit dan hama tanaman pada fase antara pembibitan hingga panen secara langsung.

Pendeteksian objek menggunakan *Deep Learning* sering diimplementasikan dengan *You Only Look Once* (YOLO). YOLO merupakan salah satu algoritma DL yang menggunakan *one-stage networks* yang memungkinkan mesin untuk dapat mendeteksi suatu objek dengan cepat. YOLO kini dikenal luas sebagai pendeteksi objek secara langsung (*real time*) dikarenakan beberapa alasan: (a) menggunakan arsitektur berbobot ringan, (b) Penggabungan metode-metode fitur yang efektif, (c) sertahasil deteksi yang lebih akurat (Haitong Lou, Xuehu Duan, Junmei Guo, Haiying Liu, Jason Gu, Lingyun Bi, and Haonan Chen, 2023).

Rempah vanili (latin: *Vanilla planifolia*) merupakan tumbuhan keluarga anggrek (*Orchidaceae*) yang berasal dari Meksiko. Ekstraksi polong yang telah dikeringkan dari tumbuhan ini memberikan aroma dan rasa khas pada hasil akhir produk berasal dari kandungan *vanillin* beserta *vanillic acid* yang memberikan rasa vanili (Singletary, K. W., 2020). Kedua kandungan dari ekstrak vanili ini dimanfaatkan pada industri makanan dan minuman, serta aroma vanili sebagai campuran wewangian pada industri parfum (Agus Wahyudi, 2021). Komoditas

vanili di pasar global pada tahun 2022 mencapai harga EUR 270,40/kg untuk ekstrak vanili dan EUR 175,56/kg untuk vanili utuh (Kementerian Keuangan, 2023). Ekspor vanili dari Indonesia memenuhi 2,63% total ekspor vanili dunia, namun kenaikan harga ekspor di salah satu negara pengekspor vanili lainnya memberikan peluang kepada Indonesia untuk memenuhi permintaan vanili negara-negara pengimpor vanili (Kementrian Keuangan, 2023).

Penurunan ketersediaan komoditas vanili dalam memenuhi permintaan pasar salah satunya dipengaruhi oleh penyakit dan hama. Penyakit pada tanaman vanili di antaranya (1) penyakit busuk menyerang pada bagian batang (*Fusarium oxysporum*), sclerotium (*Sclerotium rolfsii*), daun, pucuk (*Phytophthora parasitica*), dan buah vanili; (2) penyakit antraknosa yang disebabkan oleh jamur *Colletotrichum gleosporioides* yang menyerang batang dan daun vanili (Andriana Kartikawati & Rosihan Rosman, 2018); (3) *Rust* atau karat (*Uromyces joffrini*) merupakan penyakit yang menyerang daun vanili (Daphna Havkin-Frenkel, 2018). Penyakit busuk pada batang vanili sering ditemui pada daerah penghasil utama vanili, Jawa Tengah, Bali, Sumatera Utara, Sulawesi Utara, Lampung dan NTT dengan intensitas serangan 50% – 80% (Endang Hadipoentyanti, Agus Ruhnayati, Laba Udarno, 2017). Hama pada tanaman vanili berupa bekicot dan ulat yang memakan batang, pucuk, dan buah vanili (Andriana Kartikawati & Rosihan Rosman, 2018).

Pengidentifikasian penyakit melalui daun tanaman tomat yang sehat dan yang tidak sehat menggunakan YOLO versi 3 menghasilkan tingkat akurasi sebesar 82,38% (Vijayakumar P., Amrith C., Akhash S. Shunmugam, Kritin R. dan Sanoj S., 2020), metode YOLO versi 4 dengan modifikasi menghasilkan skor F1 sebesar 93,64% dan *mean Average Precision* (mAP) sebesar 96,29 % (Arunabha M. Roy, Rikhi Bose, and Jayabrata Bhaduri, 2021), metode YOLO versi 5 dengan hasil akurasi sebesar 93% pada set data uji (Mahnoor K., Muhammad S. Sarfraz, Uzair Iqbal, Muhammad U. Aftab, Gniewko N., dan Hafiz T. Rauf, 2023). Pada tumbuhan apel pengidentifikasian penyakit *rust*, *frogeye leaf spot*, *powdery mildew*, and *scab* yang menyerang daun dengan menggunakan YOLO versi 5 dengan improvisasi yang menghasilkan *precision*, *recall*, skor F1, mAP0,5, mAP0,5:0,95 masing-

masing sebesar 84,1%, 77,3%, 80,5%, 84,3%, dan 45,9% (Huishan Li, Lei Shi, Siwen Fang and Fei Yin, 2023). Pada tumbuhan pohon karet mengidentifikasi penyakit seperti *powdery mildew* dan *anthracnose* dengan menggunakan YOLO versi 5 yang dimodifikasi menghasilkan akurasi mAP sebesar 70% (Zhaoyi Chen, Ruhui Wu, Yiyan Li, Chuyu Li, Siyu Chen, Zhineng Yuan, Shiwei Chen, and Xiangjun Zou, 2022). Identifikasi penyakit pada tanaman apel berjenis khasmiri, data yang dikumpulkan berupa daun apel yang terjangkit penyakit seperti, *leaf blight*, *spot wilt*, dan *mosaic* dengan latar abu-abu dan lingkungan asli serta daun apel dengan terserang lebih dari satu penyakit menggunakan ALAD-YOLO, YOLOv5s dengan improvisasi, mendapatkan *precision*, *recall*, mAP50, mAP50-95 model masing-masing sebesar 96,4%, 97,2%, 98,7%, dan 90,2% (Weishi Xu & Runjie Wang, 2023).

Penelitian sebelumnya dalam mengidentifikasi tiga jenis hama *Mealybugs*, *Coccidae*, *Diaspididae* dengan menggunakan metode YOLO versi 4 mendapatkan akurasi sebesar 100% pada *mealybugs*, 89% pada *coccidae*, dan 97% pada *diaspididae* (Jien W. Chen, Wan J. Lin, Hui J. Cheng, Che L. Hung, Chun Y. Lin, and Shu P. Chen, 2021), pengidentifikasian hama yang menyerang tanaman padi dan jagung, seperti DauZhong (*Cnaphalocrocis medinalis*) dan DaoMinLin (*Naranga aenescens Moore*) mengakibatkan tanaman padi hasil panen menurun, larva ErHua (*Spodoptera litura*) memakan daun tanaman jagung dimalam hari dan YuMi (*Ostrinia furnacalis*) penyebab turunnya panen jagung, DaMingShen (*Sesamia inferens*) merusak batang pada tanaman padi dan jagung, HeiBai (*Athetis lepigone*) memakan daun banyak dari variasi tanaman kebun, serta tambahan hama lainnya: YangXue (*Lymantria dispar* or *Lymantria xyliana*) menyerang pohon apel, LouGu (*Gryllotalpa orientalis*) menyerang akar tanaman sebagai penyebab kematian tanaman, dan JinGui (*Holotrichia oblita Faldermann*) menyerang buah dan daun tanaman menggunakan YOLO versi 5 yang sudah diberikan improvisasi, menghasilkan *precision* sebesar 91,9%, *recall* sebesar 82,7%, mAP50 sebesar 90,7% (Qing Dong, Lina Sun, Tianxin Han, Minqi Cai, and Ce Gao, 2024). Pengidentifikasian hama ulat bulu *thistle* (*Vanessa cardui*) yang menyerang tanaman kacang kedelai menggunakan YOLO versi 5 menghasilkan mAP sebesar

59% (Eray Önler, 2021).

Penyakit dan hama yang menjangkit tanaman vanili berdampak pada ketersediaan komoditas vanili dalam memenuhi permintaan pasar serta pendeteksian penyakit dan hama dengan segera mencegah penyebaran patogen ke seluruh bagian tanaman atau berpindah antar individu tanaman vanili. Berdasarkan analisis dan uraian mengenai pembudidayaan tanaman vanili, akan dilakukan pengembangan sistem identifikasi penyakit dan hama menggunakan *Deep Learning* dengan pendeteksian objek *one-stage*, YOLO versi 8. Sistem ini diharapkan dapat mengidentifikasi secara akurat dan responsif dan memberikan pengetahuan mengenai penyakit dan hama tanaman vanili serta juga memudahkan petani untuk dapat mengambil keputusan dalam mencegah penyebaran penyakit dan hama pada tanaman vanili.

1.2. Rumusan Masalah

Berdasarkan topik penelitian yang diajukan, rumusan masalah dari penelitian ini ialah:

1. Bagaimana mengidentifikasi penyakit dan hama pada tanaman vanili (*Vanilla planifolia*) dengan menggunakan YOLO versi 8?
2. Bagaimana mengembangkan prototipe sistem identifikasi penyakit dan hama pada tanaman vanili?

1.3. Tujuan Penelitian

Sehubungan dari rumusan masalah yang telah dipaparkan, tujuan dari penelitian ini sebagai berikut:

1. Mengidentifikasi penyakit dan hama pada tanaman vanili (*Vanilla planifolia*) dengan menggunakan YOLO versi 8.
2. Mengembangkan prototipe sistem identifikasi penyakit dan hama pada tanaman vanili.

1.4. Batasan Masalah

Penelitian identifikasi penyakit dan hama pada tanaman vanili ini memiliki

beberapa batasan:

1. Objek yang diteliti adalah tanaman vanili (*Vanilla planifolia*) pada bagian batang serta daun vanili.
2. Pengembangan sistem identifikasi dengan algoritma DL, YOLO versi 8, untuk mengidentifikasi penyakit dan hama.

1.5. Kontribusi dan Manfaat Penelitian

Hasil penelitian ini dapat memberikan kontribusi dalam bidang keilmuan berupa model identifikasi penyakit dan hama pada tanaman vanili, juga kontribusi teknologi berupa prototipe perangkat lunak untuk memberikan informasi mengenai kondisi kesehatan tanaman vanili kepada petani ataupun masyarakat awam, sehingga mereka dapat mencegah penyebaran penyakit atau hama dengan cepat dan tepat.

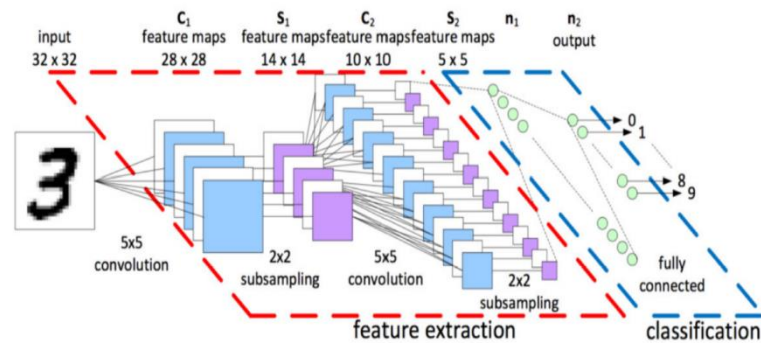
BAB 2

TELAAH PUSTAKA

2.1 Deep Learning

Deep learning (DL) sering digunakan dalam mendeteksi dan mengklasifikasi objek, salah satunya *Convolution Neural Network* (CNN). Lapisan CNN terdiri dari lapisan konvolusi, lapisan *down-sampling* (*pooling*), dan lapisan *fully connected*.

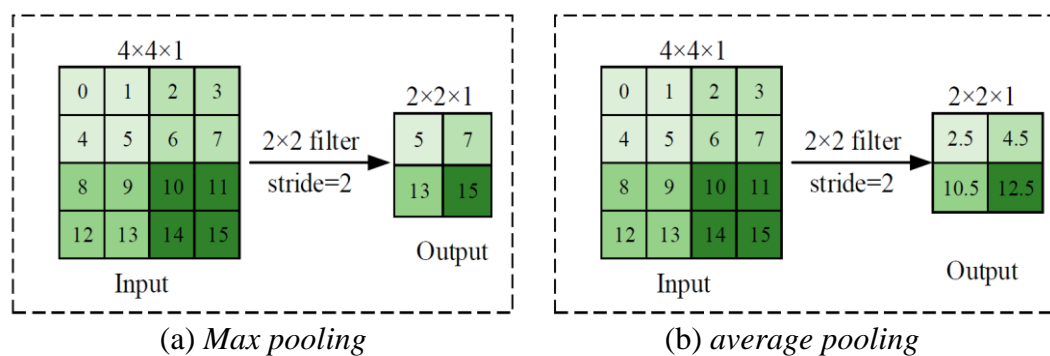
Lapisan konvolusi menggunakan informasi korelasi lokal pada suatu gambar untuk mengekstrak fitur. Proses dalam operasi konvolusi yaitu kernel, diletakkan pada sudut atas-kiri gambar, nilai piksel gambar yang berada dalam jangkauan kernel dikalikan dengan nilai kernel yang sesuai, lalu hasilnya ditotal dan ditambahkan bias di akhir. Kernel bergerak sebanyak satu piksel hingga semua lokasi yang mungkin pada gambar terfilter (Jhinzhu Lu, Lijuan Tan, and Huanyu Jiang, 2021). Pergerakan kernel dengan *stride*, ukuran kernel saat bergerak, melalui *height* dan *weight* gambar menghasilkan *activation map*, representasi 2D gambar yang menampilkan respon kernel di setiap posisi parsial gambar. Ekstraksi fitur pada CNN sering menggunakan *padding* untuk menjaga ukuran *feature map* agar tidak mengecil di setiap lapisan. Operasi ekstraksi fitur menghasilkan dua jenis *output*, pertama dimensi fitur *convoluted* berkurang jika dibandingkan dengan inputnya, kedua dimensi fitur tidak berkurang namun dipertahankan atau ditingkatkan, *padding* digunakan dalam kondisi ini (Dulari Bhatt, Chirag Patel, Hardik Talsania, Jigar Patel, Rasmika Vaghela, Sharnil Pandya, Kirit Modi, and Hemant Ghayvat, 2021). Lapisan yang terdapat pada konvolusi diilustrasikan pada gambar 2.1.



Gambar 2.1 Lapisan Konvolusi

Sumber: Bhatt D. et al., 2021

Lapisan *pooling* memilih fitur dari lapisan atas *feature map* dengan *sampling* dan membuat model *invariant* untuk translasi, rotasi, serta penskalaan secara bersamaan. Lapisan ini mengecilkan ukuran spasial fitur *convoluted*. Prosesi *pooling* yang digunakan adalah *max pooling* atau *average pooling*. *Max pooling* membagi gambar *input* menjadi beberapa area berbentuk persegi panjang berdasarkan ukuran filter dan *output* yang bernilai maksimal di setiap area, sedangkan *average pooling output* di setiap areanya bernilai rata (Jhinzhu Lu et al., 2021). *Max pooling* dan *average pooling* ditunjukkan pada gambar 2.2. *Pooling* mempersingkat waktu pelatihan dan mencegah terjadinya *overfitting*. Fungsi aktivasi menyimpulkan *output* dari *neural networks*, seperti ya atau tidak dalam mengekstraksi fitur. Fungsi aktivasi memetakan nilai *output* berkisar antara -1 dan 1 atau 0 dan 1, tergantung fungsi aktivasi apa yang digunakan (Bhatt D. et al., 2021).



Gambar 2.2 Max pooling dan Average Pooling

Sumber: Jhinzhu Lu et al., 2021

Lapisan *fully connected* terletak di lapisan paling bawah, lapisan ini menerima *input* dari *final pooling* atau lapisan *output* dari lapisan konvolusi, yang telah *flattened* sebelum diteruskan sebagai *input*. *Flattened* output membutuhkan *unrolling* semua nilai *output* yang dihasilkan setelah *pooling* terakhir atau lapisan konvolusi menjadi vektor atau matriks 3D (Bhatt D. et al., 2021).

2.2 Deteksi Objek

Perkembangan teknik *Deep Learning* dalam mendeteksi objek serta peningkatan kinerja *Graphical Process Unit* (GPU) modern memfasilitasi peneliti dalam mendesain CNN makin mendalam demi mendapatkan informasi penting dari mengekstraksi suatu gambar. Masalah yang muncul dalam pendeteksian objek terdapat pada rekognisi dan lokalisasi suatu objek, dalam pendeteksian, modul detektor dibagi menjadi dua kategori, yaitu *two-stage* dan *one-stage* (Manuel Carranza Garcia, Jesus Torres Mateo, Pedro Lara-Benitez, and Jorge Garcia-Gutierrez, 2020).

Pendeteksi objek menggunakan *two-stage* seperti CNN, mencari *arbitrary number* pada proposal objek dalam suatu gambar saat *stage* pertama, kemudian mengklasifikasikan dan melokalisasinya pada *stage* kedua. Ada juga deteksi objek dengan *one-stage*, yaitu YOLO. Pendeteksi dengan *one-stage* mengklasifikasikan serta melokalisasikan objek semantik dalam *single shot* dengan *dense sampling* (Syed Sahil Abbas Zaidi, M. Samar Ansari, Asra Aslam, Nadia Kanwal, Mamoon Asghar, and Brian Lee, 2022).

2.3 YOLO

Pertama kali *You Only Look Once* (YOLO) dipublikasikan di CVPR 2016 oleh Joseph Redmon dan kawan-kawan, YOLO mewakili sebagai pendeteksi objek dengan pendekatan *real-time end-to-end* pertama. Kemampuan YOLO dalam mendeteksi objek dengan jaringan *single pass* menjadi keunggulan dibandingkan pendeteksi objek lainnya yang menggunakan pendekatan *sliding windows* yang diikuti *classifier* untuk menjalankan ribuan kali per gambar atau menggunakan metode yang lebih rumit yang membagi langkah dalam dua tahapan. Pertama

mendeteksi *region* yang memungkinkan dengan objek (*regions proposals*), dan kemudian pada langkah kedua menjalankan *classifier* pada proposal. YOLO versi pertama ini juga hanya menggunakan regresi *output straightforward* untuk memprediksi hasil deteksi (Juan Terven, Diana-Margarita Cordova-Esparza, and Julio-Alejandro Romero-Gonzalez, 2023). Arsitektur YOLO versi 1 terdiri dari 24 lapisan konvolusi, empat *maxpooling*, dan dua lapisan *fully connected* seperti ditampilkan pada tabel di gambar 2.3.

	Type	Filters	Size/Stride	Output
	Conv	64	$7 \times 7/2$	224×224
	Max Pool		$2 \times 2/2$	112×112
	Conv	192	$3 \times 3/1$	112×112
	Max Pool		$2 \times 2/2$	56×56
1×	Conv	128	$1 \times 1/1$	56×56
	Conv	256	$3 \times 3/1$	56×56
	Conv	256	$1 \times 1/1$	56×56
	Conv	512	$3 \times 3/1$	56×56
	Max Pool		$2 \times 2/2$	28×28
4×	Conv	256	$1 \times 1/1$	28×28
	Conv	512	$3 \times 3/1$	28×28
	Conv	512	$1 \times 1/1$	28×28
	Conv	1024	$3 \times 3/1$	28×28
	Max Pool		$2 \times 2/2$	14×14
	Conv	512	$1 \times 1/1$	14×14
2×	Conv	1024	$3 \times 3/1$	14×14
	Conv	1024	$3 \times 3/1$	14×14
	Conv	1024	$3 \times 3/1$	14×14
	Conv	1024	$3 \times 3/2$	7×7
	Conv	1024	$3 \times 3/1$	7×7
	Conv	1024	$3 \times 3/1$	7×7
	FC	4096		4096
	Dropout 0.5			4096
	FC		$7 \times 7 \times 30$	$7 \times 7 \times 30$
	FC			$7 \times 7 \times 30$

Gambar 2.3 Arsitektur YOLO versi 1

Sumber: Juan Terven et al., 2023

2.3.1 Versi YOLO

Pengembangan YOLO dalam meningkatkan performa menghasilkan versi-versi pembaruan lainnya, seperti YOLOv2 (2017), YOLOv3 (2018), YOLOv4 (April 2020), YOLOv5 (beberapa bulan setelah April 2020), YOLOR (2021), YOLOX (Juli 2021), YOLOv6 (2022), YOLOv7 (2022), DAMO-YOLO (November 2022), dan YOLOv8 (Januari 2023).

YOLOv5 dirilis beberapa bulan setelah YOLOv4 di tahun 2020 oleh Glen Jocher dan CEO Ultralytics. Pada arsitektur YOLOv5 bagian *backbone* merupakan tempat berlangsungnya ekstraksi fitur gambar menggunakan CSPDarknet53 dengan Stem, *stride* pada lapisan konvolusi yang mengurangi memori dan komputasi, dan dilanjutkan dengan lapisan konvolusi yang mengekstarksi fitur gambar. Lapisan-lapisan ini membagi sama rata dimensi *feature map* melalui

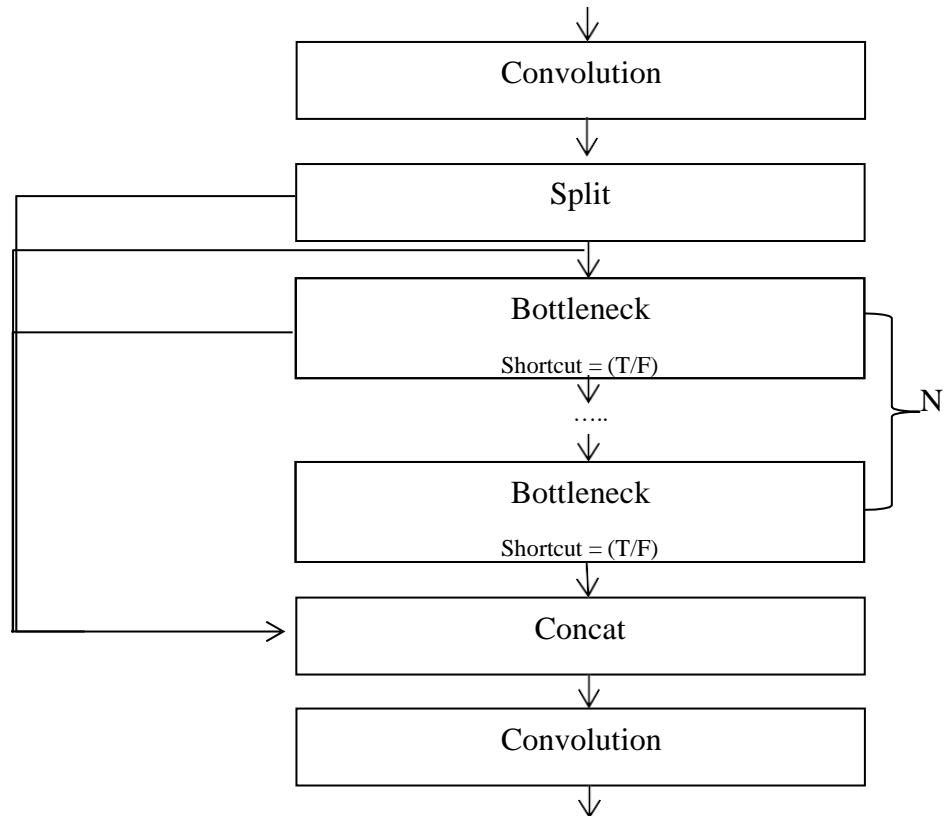
lapisan konvolusi, menambahkan perhitungan *channel* secara berurutan, dan menggabungkan *feature* dengan modul C3. Modul ini mengintegrasikan *array* lapisan konvolusi dan koneksi residual, mengoptimalkan ekstraksi fitur dan konsolidasi. *Spatial Pyramid Pooling Fast* (SPPF) dan lapisan konvolusi setelahnya memproses fitur dalam berbagai skala, lapisan SPPF mempercepat komputasi pada jaringan dengan melakukan fitur *pooling* di skala yang berbeda menjadikan *feature map* dalam ukuran yang tetap. Setiap proses konvolusi dilanjutkan dengan *batch normalization* (BN) dan aktivasi *Sigmoid Linear Unit* (SiLU). Bagian *neck* YOLOv5 menambahkan resolusi melalui modul *Upsample* dan menggabungkan *feature map* dari skala yang berbeda pada modul *concat*. Bagian *head* mengintegrasikan tiga lapisan output yang berbeda pada multi skala, modul deteksi mengantarkan fitur ke dalam target koordinat, kategorisasi, *confidence score*, yang mendukung YOLOv5 merender deteksi objek di segala skenario (Qing Dong et al., 2024; Juan Terven et al., 2023).

YOLO versi ke7 dirilis pada ArXiv Juli 2022 oleh Chien-Yao Wang, Alexey Bochkovskiy, and Hong-Yuan Mark Liao, pengembang versi YOLO yang juga mengembangkan YOLOv4 dan YOLOR sebelumnya. Lapisan aktivasi pada YOLOv7 menggunakan Swish. Arsitektur yang terdapat pada YOLO versi 7 diantaranya, menggunakan modul *Convolution*, *BatchNorm*, *SiLU* (CBS), *Extended Efficient Layer Aggregation Network* (E-ELAN), *MaxPooling* (MP), dan *Spatial Pyramid Pooling and Convolutional Spatial Pyramid Pooling* (SPPCSPC) pada bagian *backbone*. E-ELAN mengombinasikan fitur dari kelompok yang berbeda. Bagian *head* memiliki tiga kepala untuk mendeteksi objek serta hasil probabilitas kategori, *confidence*, dan prediksi bingkai koordinat dari target objek. Skala target yang dideteksi pada bagian *head* yaitu 80×80 , 40×40 , dan 20×20 masing-masing untuk target objek berukuran kecil, medium, dan besar (Yuan Zhang, Youpeng Sun, Zheng Wang, and Ying Jiang, 2023; Juan Terven et al., 2023).

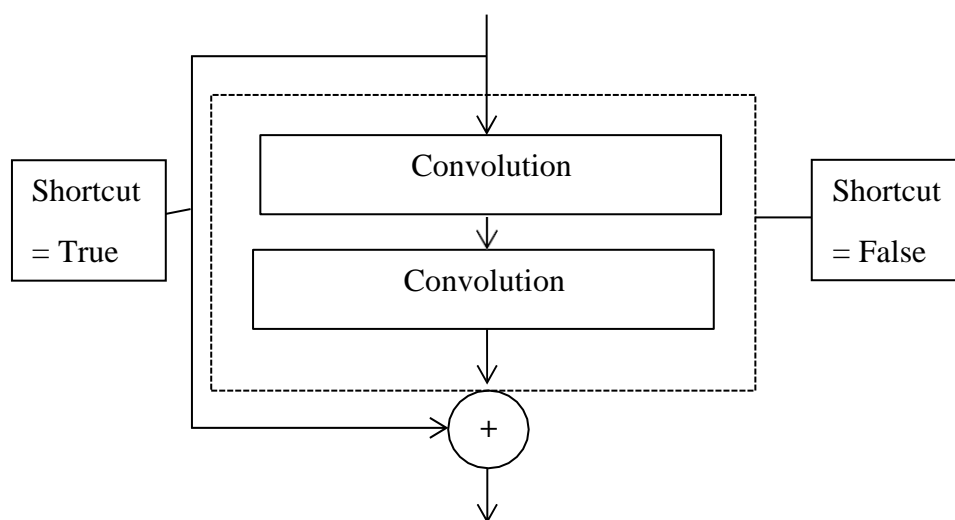
2.3.2 Arsitektur YOLO Versi 8 (YOLOv8)

Perusahaan Ultralytic meluncurkan YOLOv8 pada Januari 2023. Gambar 2.4 menggambarkan arsitektur YOLO versi 8. Arsitektur YOLO dengan deteksi *one-*

Bottleneck yang bernilai *True* memiliki jalan pintas (*shortcut*) dan nilai *False* mengharuskan informasi masuk melewati proses konvolusi. Gambar 2.5 serta Gambar 2.6 masing-masing menunjukkan alur dari modul C2f dan *bottleneck*.



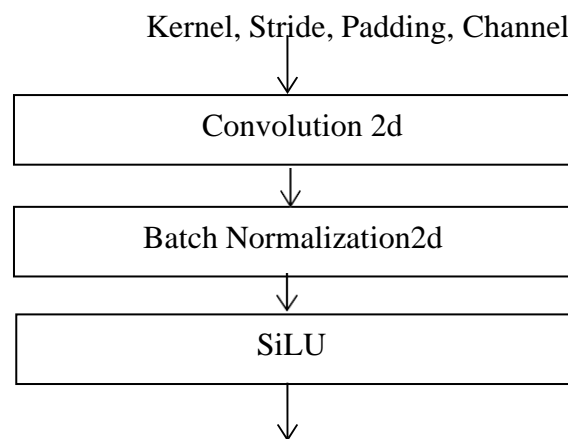
Gambar 2.5 Modul C2f



Gambar 2.6 Bottleneck (T/F)

a. Convolution, BatchNorm, SiLu (CBS)

Pada arsitektur YOLO versi 8, *Convolution* (Konvolusi), *Batch Normalization* (*BatchNorm*), dan SiLU (CBS) melakukan operasi konvolusi pada informasi masukan (*input*), kemudian *batch normalization* untuk menambahkan mAP sebesar 2% (Peiyuan Jiang, Daji Ergu, Fangyao Liu, Ying Cai, and Bo Ma, 2021), dan mengaktifkan alir informasi dengan *Sigmoid Linear Unit* (SiLU) untuk menghasilkan *output*. Gambar 2.7 menunjukkan alur CBS. Pada lapisan konvolusi pertama kali mengekstrak fitur dari sebuah gambar, lapisan ini memiliki kernel (*k*) yang berukuran 3×3 dengan *stride* (*s*) dan 1 *padding* (*p*). *BatchNorm* juga mempercepat pelatihan dan lebih *robust* dengan menormalisasikan data dan melakukan *re-scaling* dan *reshape* pada piksel (Sandhya & Abhishek Kashyap, 2023).

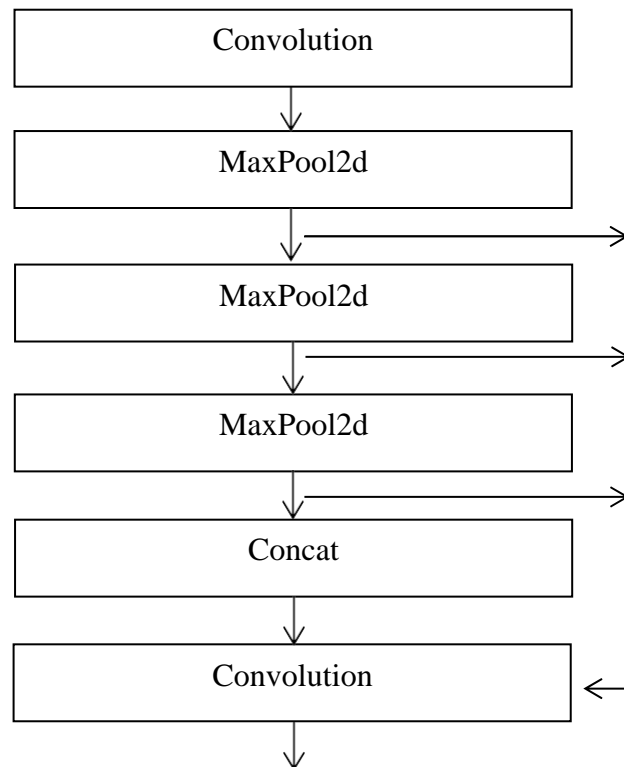


Gambar 2.7 Modul CBS

b. *Spatial Pyramid Pooling Fast*

SPPF digunakan untuk menggabungkan *feature maps input* menjadi ukuran *fixed map* untuk ukuran *ouput* yang adaptif. SPPF meringankan komputasi dan menurunkan latensi dengan koneksi sekuensial ketiga lapisan *maxpooling* berukuran 5×5 yang mengembalikan hasilnya ke lapisan konvolusi, menjamin keakurasian objek dalam skala yang bervariasi serta memastikan *lightweight* secara bersamaan (Haitong Lou et al., 2023).

Alir SPPF digambarkan pada gambar 2.8.




Gambar 2.8 Modul SPPF

2.3.2.2 Neck

Bagian *neck* YOLO versi 8 menggunakan struktur desain *Path Aggregation Network* (PAN) dan *Feature Pyramid Network* (FPN) yang menghilangkan langkah operasi konvolusi setelah langkah *up-sample* pada struktur PAN demi menjaga performa selagi mendapatkan model berbobot ringan. Rancangan FPN konvensional dalam arsitektur menggunakan pendekatan dari atas ke bawah untuk menyampaikan informasi secara *deep semantic*, namun beberapa informasi lokalisasi objek dapat hilang. Penggabungan feature map dari level yang berbeda pada rancangan FPN untuk membentuk feature pyramid dengan informasi *multi-scale* dengan menambahkan koneksi lateral antar *feature maps* di level yang berbeda demi detail informasi utilitas *high-frequency* semakin membaik dalam isi *feature* pada level rendah. Rancangan PAN meningkatkan pembelajaran informasi lokasi untuk dapat membuat peningkatan jalur dalam rancangan *top-down*, agregasi fitur dari berbagai skala pada rancangan ini menghasilkan *feature maps*

yang memiliki banyak resolusi dengan menambahkan jalan pada *encoder* dan *decoder*. Struktur hierarki piramida fitur PAN menggunakan informasi fitur di level yang berbeda yang memberikan peningkatan pada keakuratan *semantic segmentation*. PAN dan FPN membangun struktur jaringan *top-down* serta *bottom-top* untuk membuat pelengkap informasi posisi yang kurang baik dan informasi *deep semantic* melalui fusi fitur yang akan menghasilkan keberagaman dan kelengkapan fitur. Terdapat dua upsampling dan beberapa modul C2f dalam arsitektur YOLO versi 8 pada bagian *neck* yang diakhiri dengan *head* terpisah untuk menggabungkan *confidence* dan *regression box* demi mendapatkan tingkat keakuratan yang baru. Rancangan FPN dan PAN diilustrasikan pada gambar 2.9. Penggabungan fitur (*feature fusion*) dengan PAN-FPN menguatkan proses fusi dan utilitas dari informasi lapisan fitur di berbagai skala (Haitong Lou et al., 2023).



Gambar 2.9 Arsitektur FPN-PAN

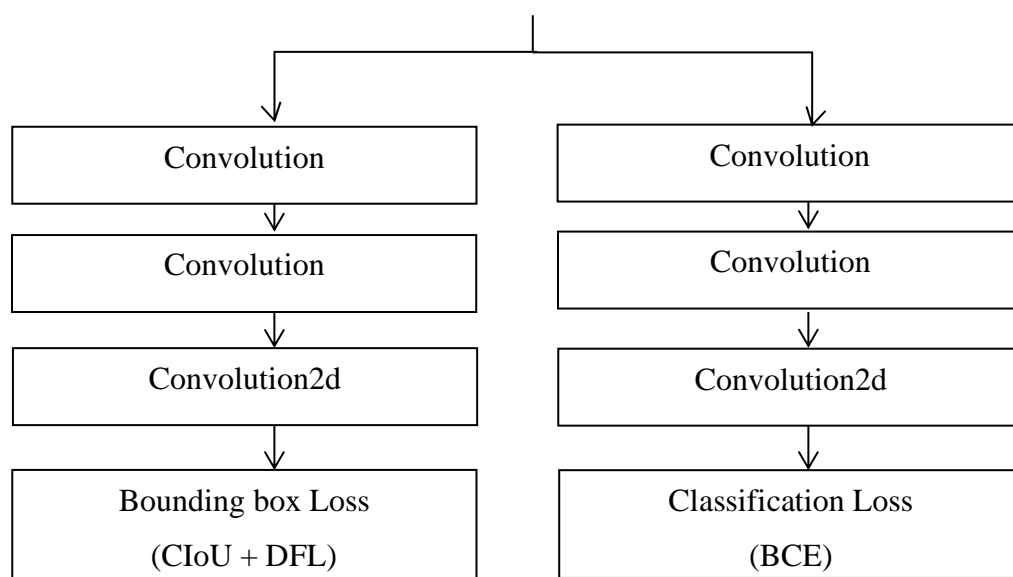
Sumber: Haitong Lou et al., 2023

Pada gambar 2.9 warna jingga menandakan pendeteksian untuk objek kecil, warna biru menandakan pendeteksian objek yang berukuran medium, dan warna ungu menandakan pendeteksian objek yang berukuran besar.

2.3.2.3 Head

Pada arsitektur YOLOv8 yang diilustrasikan pada gambar 2.4 memiliki kepala (*head*) pada tingkatan *pyramid* 3 hingga 5 yang berukuran 80×80 , 40×40 , dan 20×20 secara berurutan. Pada kepala terdapat kepala yang berfungsi untuk memprediksi regresi *bounding box* dan yang lainnya mendeteksi klasifikasi objek.

Pada kepala klasifikasi objek menggunakan fungsi *Binary Cross-Entropy Loss* (BCELoss) dan kepala prediksi regresi *bounding box* menggunakan *Complete Intersection Over Union* (CIoU) dan *Distribution Focal Loss* (DFL). Pada DFL posisi bounding box telah dimodelkan sebagai *general distribution*, jaringan langsung memfokuskan pendistribusian lokasi *bounding box* tersebut dekat dengan lokasi objek (Haitong Lou et al., 2023). Kepala YOLOv8 ditunjukkan pada gambar 2.10.



Gambar 2.10 Head

2.4 Augmentasi Gambar

Kumpulan data gambar yang akan digunakan untuk mendeteksi objek tertentu kemudian diberikan juga data gambar yang telah diaugmentasi, data gambar yang dikumpulkan dan data gambar augmentasi berguna dalam melatih model. Pembuatan model untuk dapat mendeteksi suatu objek memerlukan jumlah dan variasi data, seperti posisi, warna, atau tingkat kecerahan, yang cukup banyak untuk model dapat mempelajari data lebih dalam sehingga pengklasifikasian objek memberikan prediksi yang tepat. Pengugmentasian data menjadi salah satu cara mencegah terjadinya *overfitting* atau model kurang tepat dalam mendeteksi suatu objek (Parita Oza, Paawan Sharma, Samir Patel, Festus Adedoyin, and Alessandro Bruno, 2022). Teknik yang digunakan dalam memberikan augmentasi pada gambar

diantaranya, *flipping*, *rotation*, dan *cropping*.

Augmentasi *flipping* membalikkan gambar secara horizontal maupun vertikal, *rotation* memutar gambar dengan sudut 0–360 derajat, dan *cropping* mengambil sebagian kecil gambar dan menyesuaikan ulang ukuran gambar dan mencocokkannya dengan dimensi gambar asli (Kiran Maharana, 2022). Augmentasi lainnya seperti *blur*, *brightness*, *noise*, masing-masing berguna untuk memberikan efek *out-of-focus*, memberikan beberapa tingkat kecerahan dan dapat mengatasi perubahan penerangan pada data citra, serta juga dapat mengatasi *noise* dan meningkatkan kemampuan dalam menangani data citra baru atau beberapa skenario (Nasser Aloufi et al., 2023).

2.5 Matriks Evaluasi YOLO

Evaluasi model memberikan pengetahuan mengenai tingkat keakurasian performa model dalam melakukan pendeteksian pada dataset validasi atau dataset uji. Salah satunya estimasi pada daerah tumpang tindih (*overlapping*) antara gambar yang terdeteksi dan anotasi *bounding box* pada objek dalam citra asli (*ground truth*), matriks lain yang dilihat untuk mengevaluasi model diantaranya *Precision* (P), *Recall* (R), *Mean Average Precision* (mAP), *F1 score*, dan matriks *confusion*.

2.5.1 Precision

Precision mengukur tingkat keakuratan model saat mendeteksi objek. *Precision* merupakan perbandingan antara *True Positive* (TP) atau banyaknya objek yang terdeteksi benar dan tepat oleh model dengan keseluruhan pendeteksian objek (TP dan FP), *False Positive* (FP) atau banyaknya model mendeteksi objek yang salah namun tepat, seperti persamaan (2.1) (Carlos Santo, Marilton Aguiar, Daniel Welfer, and Bruno Belloni, 2022).

$$P = \frac{TP}{TP+FP} = \frac{\text{Object detected correctly}}{\text{All object detection}} \quad (2.1)$$

2.5.2 Recall

Recall mengukur banyaknya kekeliruan objek yang terdeteksi oleh model dan mengharuskan model untuk terbebas dari kesalahan saat mendeteksi suatu objek. *False Negative* (FN) atau banyaknya model mendeteksi objek yang salah dan tidak tepat. Nilai *recall* semakin rendah saat semakin banyaknya objek yang terdeteksi salah oleh model dan tidak tepat. Matriks ini membandingkan banyaknya objek yang terdeteksi benar dan tepat dengan seluruh objek yang dideteksi (deteksi objek yang benar dan tepat juga deteksi yang salah dan tidak tepat) seperti persamaan (2.2) (Nariman Mamdouh, 2021).

$$R = \frac{TP}{TP+FN} = \frac{TP}{All\ ground\ truth} \quad (2.2)$$

2.5.3 F1 Score

F1 score menentukan *confidence score threshold* dengan skor terbaik pada akurasi dan *recall* tertinggi. Meningkatnya jumlah objek yang terdeteksi memungkinkan terjadinya deteksi benar (TP) dan salah (FP) dengan tepat yang akan menurunkan nilai *precision*, tetapi menurunnya nilai *precision* berdampak pada nilai *recall* yang naik atau memungkinkan deteksi objek yang salah dan tidak tepat (FN). Skor F1 menyeimbangkan *precision* dengan *recall*. Nilai skor F1 yang tinggi meningkatkan *precision* serta *recall* dan sebaliknya (Sandhya & Abhishek Kashyap, 2023). *F1 score* memiliki persamaan matematis seperti persamaan (2.3).

$$F1\ score = \frac{2 \times P \times R}{P + R} \times 100\% \quad (2.3)$$

2.5.4 Mean Average Precision

Pada dataset yang besar dan terdapat banyak kelas, metrik *Mean Average Precision* (mAP) mampu mewakili ketepatan pendeteksian di semua kelas. Menghitung mAP menggunakan persamaan (2.4), dengan N mewakili banyaknya kelas yang dievaluasi, AP_i sebagai nilai *Average Precision* (AP) pada kelas ke- i (Rafael Padilla, 2021).

$$mAP = \frac{1}{N} \sum_{i=1}^N AP_i \quad (2.4)$$

2.5.5 Matriks Confusion

Perhitungan matriks *confusion* untuk mengevaluasi akurasi pengklasifikasian. Matriks ini menyediakan contoh campuran antara kelas prediksi dan kelas aktual, setiap kolom menandakan contoh dari kelas prediksi dan setiap baris menandakan contoh dari kelas aktual. Matriks *confusion* juga menampilkan “kebingungan” saat model memprediksi, yang dapat memberikan pengetahuan mengenai kesalahan apa yang dibuat oleh *classifier* dan jenis kesalahannya (Markoulidakis, I., Rallis, I., Georgoulas, I., George Kopsiaftis, Anastasios Doulamis, and Nikolaos Doulamis, 2021). Penyajian kesimpulan prediksi dengan *multi class classification problem* seperti tabel 2.1.

Tabel 2.1 Penyajian Kesimpulan Prediksi

		<i>Predicted class</i>			
		C_1	C_2	...	C_N
<i>Actual class</i>	C_1	$C_{1,1}$	FP	...	$C_{1,N}$
	C_2	FN	TP	...	FN

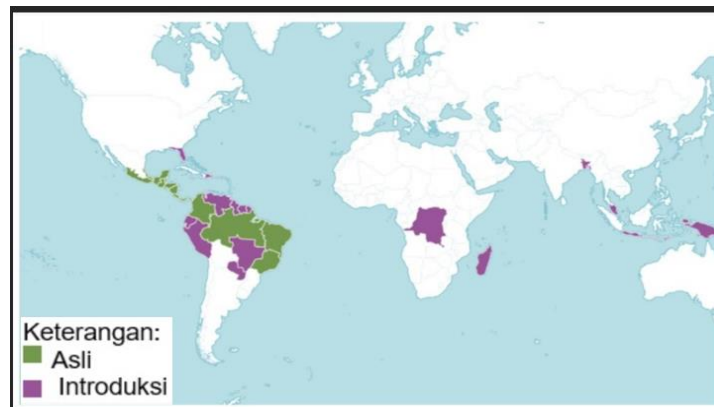
	C_N	$C_{N,1}$	FP	...	$C_{N,N}$

2.6 Tanaman Vanili

Perkebunan vanili Indonesia di tahun 2020 memiliki lahan seluas 9.291 hektar yang menghasilkan produksi mencapai 1.412 ton. Perkebunan yang sebagian besar dikelola sendiri oleh rakyat tersebar pada daerah Sumatera, Bali, Jawa Tengah, Jawa Timur, Jawa Barat, Nusa Tenggara Barat, Nusa Tenggara Timur, Sulawesi Utara, Sulawesi Tengah, Sulawesi Barat, Sulawesi Selatan, Sulawesi Tenggara dan Papua.

Vanili berasal dari benua Amerika dan pertama kali dikenalkan ke Indonesia pada tahun 1819 sebagai salah satu koleksi tanaman yang dimiliki Kebun Raya Bogor. Penyebaran tanaman vanili digambarkan pada gambar 2.11. Pada dekade 1960-an, perkembangan pesat tanaman vanili di daerah Jawa menghasilkan hasil

panen polong vanili yang dikenal dunia dengan sebutan “Java Vanilla Beans”. Vanili Indonesia mengandung lebih banyak kandungan *vanillin* sebesar 2,75% dibandingkan vanili yang ditanam di Madagaskar (2,20%), Sri Lanka (1,5%), dan Meksiko (1,75%).



Gambar 2.11 Peta Penyebaran Tanaman Vanili

Sumber: POMO, 2020

Jenis Vanili yang mayoritas ditanam di Indonesia adalah *Vanilla planifolia*. Tanaman vanili jenis ini memiliki banyak produk turunan pada masing-masing industri makanan, es krim, minuman, kosmetik, dan wewangian. Namun terdapat jenis vanili lain yang ditanam di daerah Papua, yaitu *Vanilla tahitiensis* atau dikenal juga dengan nama “Vanili Papua”. Kadar *vanillin* pada jenis ini rendah, tapi tahan terhadap serangan penyakit busuk batang. Pemanfaatan vanili tahitientis terbatas hanya untuk industri kosmetik dan wewangian.

2.7 Morfologi Vanili

Tanaman Vanili (*Vanilla planifolia*) merupakan tanaman monokotil yang berhubungan kerabat dengan tanaman anggrek. Tabel 2.1 menampilkan klasifikasi ilmiah spesies *Vanilla planifolia* (M. Fajar Ramadhan, Endang Setyorini, Nia Rachmawati, and Etty Andriati, 2019).

Tabel 2.2 Klasifikasi Tanaman *Vanilla planifolia*

Tingkatan	Nama Latin
Kingdom	<i>Plantae</i>
Divisi	<i>Magnoliophyta</i>
Kelas	<i>Liliopsida</i>
Ordo	<i>Orchidales</i>
Famili	<i>Orchidaceae</i> (Anggrek-anggrekan)
Genus	<i>Vanilla</i>
Spesies	<i>Vanilla planifolia</i>

Morfologi tanaman vanili terdiri dari:

1. Daun

Daun pada spesies *Vanilla planifolia* berbentuk pipih, bulat telur, berdaging, lanset berujung lancip, dan berwarna hijau. Ukuran daun memiliki panjang 10–25 cm dengan lebar 5–7 cm. Setiap helai daun tersusun tunggal dan terletak berselang pada masing-masing ruas. Tangkai daun tebal, pendek, dan menghadap ke atas. Tulang daun yang sejajar dapat dilihat saat usia daun menua atau mengering.

2. Batang

Batang vanili berwarna hijau yang terdapat klorofil dan stomata, memungkinkan batang vanili untuk juga dapat melakukan fotosintesis atau memasak makanan sendiri. Batang vanili dapat mencapai 100 meter, ruas pada batang memiliki panjang 5–10 cm, diameter batang 1–2 cm, berbuku-buku, berair, dan lunak. Pucuk batang yang dipotong atau patah akan membuat cabang-cabang sebagai tempat tumbuhnya bunga atau disebut juga sulur-sulur produksi.

3. Akar

Tanaman vanili merupakan tanaman yang hidupnya menempel pada tanaman lain (epifit). Seperti halnya tanaman monokotil lainnya, Vanili juga tidak memiliki akar tunggang, akar pada tanaman vanili tumbuh dari setiap buku. Akar vanili yang tumbuh ke dalam tanah memiliki bercabang-cabang dan bulu halus untuk menyerap air dan zat hara. Akar yang tumbuh di atas permukaan tanah berfungsi sebagai akar lekat.

4. Bunga

Tanaman vanili berbunga majemuk dan memiliki beberapa tandan (malai). Suatu malai pada vanili terdapat 15 hingga 20 atau lebih bunga vanili. Bunga vanili berwarna hijau kekuningan, beraroma dan ada juga yang tidak, dan bertangkai pendek. Ukuran diameter bunga vanili sebesar ± 10 cm. Dalam sekuntum bunga vanili terdapat tiga kelopak dan tiga mahkota. Mahkota bunga vanili tertutup kelopak bunga saat fase bunga kuncup, mahkota bunga terdapat corong sebagai tempat penyerbukan.

5. Buah

Pembuahan dari proses fertilisasi bunga vanili berbentuk polong (*beans*), bersudut tiga, dan bertangkai pendek. Panjang polong 10–25 cm dengan diameter 5–15 mm. Buah vanili muda berwarna hijau tanpa mengeluarkan aroma, kemudian buah vanili berubah warna menjadi kecoklatan atau kemerahan menandakan buah matang. Buah vanili matang mengandung senyawa vanillin yang memberikan aroma khas dan berisi biji-biji berwarna hitam dengan ukuran rata-rata 2 mm.

2.8 Pembudidayaan Vanili

Permintaan pasar atas komoditas rempah vanili yang semakin meningkat membuka peluang bagi petani untuk memenuhi permintaan pasar dengan membudidayakan tanaman vanili (*Vanilla planifolia*). Pembudidayaan tanaman vanili harus memperhatikan kondisi lingkungan, persiapan lahan tanam, pemilihan bibit, penanaman pohon panjat, penanaman bibit vanili, pemeliharaan, pemupukan, pengendalian penyakit dan hama, penyerbukan, hingga periode panen dan pasca panen demi menjaga kualitas dan ketersediaan rempah vanili.

2.8.1 Syarat Tumbuh

Tanaman vanili membutuhkan kondisi lingkungan yang mendukung untuk dapat tumbuh maksimal. Iklim dan lahan tempat tumbuh vanili harus diperhatikan dan dikondisikan. Tabel 2.2 menunjukkan kondisi iklim dan lahan yang ideal untuk vanili dapat tumbuh subur.

Tabel 2.3 Kriteria Kesesuaian Iklim Tanaman Vanili

Faktor	Sangat sesuai	Tidak sesuai
Ketinggian (mdpl)	300–400	> 1200
Curah hujan (mm/tahun)	1500–2000	> 3000 – < 850
Hari hujan	80–178	< 80 atau > 178
Bulan basah (> 100 mm/bulan)	7–9	> 11 atau < 3
Bulan basah (< 100 mm/bulan)	2–3	< 2 atau > 6
Suhu rata-rata harian (°C)	24–26	< 20 atau > 26
Kelembapan udara (%)	60–75	< 50 atau > 80
Radiasi matahari (%)	30–50	< 55 atau < 30
Drainase tanah	Baik	Terhambat
Tekstur tanah	Lempung berpasir	Berpasir
pH tanah	6–7	> 8 atau < 4,5
Kedalaman air tanah (cm)	> 100	< 40

Sumber: Rosman (2018)

2.8.2 Cara Bercocok Tanam

Ada beberapa rangkaian aktifitas dalam pembudidayaan tanaman vanili. Aktifitas bercocok tanam tanaman vanili harus dilakukan dan diberikan perhatian khusus supaya vanili dapat tumbuh subur dan mendapatkan hasil panen yang berkualitas.

1. Persiapan Dan Pengolahan Lahan

Penyiapan lahan dilakukan saat awal musim penghujan, lahan yang disiapkan sebagai tempat tanaman vanili bertumbuh harus terbebas dari kontaminasi penyakit busuk batang vanili. Lahan digali hingga kedalaman 30 cm dan dibiarkan terbuka agar patogen dalam tanah diseterilkan oleh sinar matahari selama \pm 2 minggu. Untuk menghindari genangan air saat musim penghujan buat saluran pembuangan air (drainase) selebar 40 cm dan kedalaman 40 cm di sekelilingkebun.

2. Pemilihan Bibit

Tanaman vanili bereproduksi secara generatif dan vegetatif. Penggunaan bibit generatif biasanya diperuntukan bagi penelitian perkembangbiakan tanaman vanili dan terdapat kesulitan dalam menanam bibit generatif (biji vanili) yang berukuran sangat kecil, memiliki kulit yang keras, serta cadangan makanan bagi bibit yang sedikit. Bibit vanili dengan cara vegetatif yang sering digunakan untuk budi daya berupa setek sulur. Setek panjang (5–7 ruas) maupun setek pendek (1 ruas) dapat menjadi bibit tanam, namun setek panjang lebih sering dipilih sebagai bibit. Untuk tujuan pembibitan, sulur yang dipilih berasal dari tanaman yang sehat, beruas rapat, berdaun lebar, serta belum pernah berbunga.

Penyemaian bibit sulur panjang dapat dilakukan dengan menanam langsung ke dalam tanah, sedangkan pada penyemaian bibit sulur pendek, setek ditanam pada media tanam yang telah dicampur dengan pupuk.

3. Penanaman Pohon Panjat

Tanaman vanili sebagai tanaman epifit membutuhkan tumbuhan lain untuk melekat. Pohon panjat atau tajar berfungsi sebagai tempat melekat dan memanjatnya tanaman vanili serta melindungi tanaman dari paparan sinar matahari penuh, tajar juga dapat berupa tiang kayu dengan tinggi 2,5 sampai 3 meter. Pohon panjat yang biasanya dipilih yaitu pohon gamal (*Gliricidia sepium*), randu (*Ceiba petandra*), turi (*Sesbania grandiflora*), atau kelor (*Moringa oleifera*). Pohon-pohon tersebut masih dapat menyediakan intensitas sinar matahari yang dibutuhkan tanaman vanili sekitar 30 – 40%.

Pemilihan pohon panjat harus memperhatikan juga aspek-aspek lain seperti jenis pohon yang berdaun rimbun, mudah dipangkas dan mampu meregenerasi untuk dapat rimbun kembali dengan cepat, tahan terhadap penyakit dan hama, bukan merupakan inang penyakit dan hama vanili, serta akar pohon menjulur lebih dalam untuk menghindari pohon mengambil air dan zat hara yang dibutuhkan tanaman vanili.

Penanaman pohon panjat didahului dengan membuat bedengan dengan lebar 1,2 meter dan panjang disesuaikan dengan keperluan serta mengarah dari

utara ke selatan supaya tanaman vanili nantinya mendapatkan cukup sinar matahari. Kemudian membuat parit sebagai drainase di antara bedengan selebar 40cm dengan kedalaman 40 cm. Selanjutnya pohon panjat ditanam di tengah bedengan yang diberi jarak tanam yang disesuaikan dengan jarak tanam vanili. Jarak antar tanam bervariasi diantaranya $1.5 \times 1.5 \text{ m}^2$, $1.5 \times 1.25 \text{ m}^2$, atau $2 \times 2 \text{ m}^2$.

4. Penanaman Bibit Vanili

Bibit vanili ditanam setelah pohon panjat sudah dapat melindungi tanaman vanili dari paparan sinar matahari. Penanaman bibit setek vanili berjarak 15–20 cmdan posisi tanam $20\text{--}30^\circ$ mengarah ke pohon panjat. Posisi tanam bertujuan untuk memudahkan sulur menempel ke pohon panjat. Untuk lubang tanam memiliki dimensi panjang 60 cm \times lebar 60 cm \times kedalaman 40 cm. Lubang tanam kemudian diberikan pupuk kandang dan ditutup dengan tanah. Penanaman setek vanili denganmenimbun 2–3 ruas pangkal bibit pada lubang tanam. Sisa ruas setek vanili diikat pada pohon panjat.

5. Pemeliharaan

Pertumbuhan sulur yang melebihi 80 cm atau telah memiliki 10 lembar daun dipangkas pucuk sulur, kemudian sulur saat mencapai 1,5–2 meter, sulur dilepas ikatannya dan dibiarkan menggantung di cabang pohon panjat pada ketinggian sulur 1,6–1,75 m.

Penyiangan rerumputan (gulma) pada area perakaran tanaman vanili secara rutin diperlukan untuk menghindari gangguan akar gulma mengambil nutrisi yangdiperlukan vanili dari dalam tanah. Penyiangan pada area luar perakaran dilakukandengan memangkas rumput hingga setinggi 3–5 cm. Penyiangan di luar perakaranberguna untuk menjaga kelembapan vanili supaya terhindar dari kekeringan.

Pemberian mulsa pada area sekitar tanaman vanili juga berfungsi untuk mengurangi penguapan pada saat musim kemarau, meningkatkan unsur hara di dalam tanah, serta memperbaiki sifat fisik-kimia tanah. Namun pada musim penghujan mulsa di sekitar tanaman vanili dikurangi demi menghindari kelembapanyang tinggi. Mulsa dapat berupa dedaunan dari

pangkas pohon panjat atau serabutkelapa.

Pemangkasan pohon panjat perlu dilakukan untuk mempertahankan jumlah intensitas sinar matahari yang diperlukan tanaman vanili serta sampah daun-daun yang dipangkas dapat dimanfaatkan sebagai mulsa, dan pemangkasan pada sulur vanili untuk merangsang pertumbuhan sulur-sulur baru dan merangsang pertumbuhan bunga. Pemangkasan sulur dilakukan dengan membuang 2–3 ruas bagian pucuk sulur.

6. Pemupukan

Pemberian pupuk secara organik berupa pupuk kandang sebanyak 10 kg untuk satu tanaman vanili per tahun. Pemberian pupuk secara kimia berupa pupuk yang mengandung campuran bahan kimia yang disesuaikan dengan kebutuhan tanaman vanili dapat tumbuh.

7. Pengendalian penyakit dan hama

Serangan penyakit menjadi ancaman utama bagi tanaman vanili untuk dapat tumbuh subur, seperti penyakit busuk batang yang sering menyerang tanaman vanili pada musim penghujan. Namun serangan hama vanili tidak begitu menjadi pengganggu pertumbuhan subur tanaman vanili, pemberian pestisida secara berkala mampu mengatasi serangan hama pada musim kemarau.

8. Penyerbukan

Bunga vanili mekar menandakan tanaman memasuki fase pembuahan, namun bunga vanili tidak dapat melakukan penyerbukan sendiri dikarenakan kepala putik dan kumpulan tepung sari (*pollinia*) terhalang oleh bibir (*labellum*). Penyerbukan secara alami dibantu oleh serangga bergenus *Melipona* (lebah tak bersengat), tapi juga dapat dibantu oleh manusia. Waktu bunga vanili mekar berlangsung dalam satu hari, jika tidak ada penyerbukan bunga akan gugur.

Penyerbukan bunga dapat dibantu dengan alat seperti lidi atau bambu sepanjang ± 10 cm yang ujungnya agak diruncingkan. Kelopak bunga dikoyak menggunakan lidi hingga tangkai putik terbuka, angkat bibir yang menghalangi hingga *pollinia* ikut terangkat, kemudian letakan *pollinia* ke kepala putik sembari memberi tekanan sedikit.

9. Panen dan pasca panen

Bunga vanili yang berhasil dibuahi melalui penyerbukan berubah menjadi buah yang berbentuk polong yang berwarna hijau. Buah vanili yang memudar warna hijaunya dan pada ujung buah mulai menguning yang menandakan buah sudah matang. Waktu buah matang pada setiap bunga dalam satu malai berbeda-beda, sehingga pemetikan buah hanya mengambil buah yang sudah matang demi menjaga mutu secara bertahap serta penuh kehati-hatian agar malai tidak patah atau rusak.

Buah matang yang telah dipetik kemudian diolah lebih lanjut sesuai standar mutu rempah vanili. Pengolahan dilakukan dengan 4 tahapan, yaitu pelayuan, pemeraman dan pengeringan, pengering-anginan, dan penyimpanan.

Tahap pelayuan polong vanili dicelup dengan wadah berlubang pada air panas selama 2 atau 3 menit, penyelupan ini bergantung pada usia polong semakin tua semakin lama. Enzim *alfaglukosidase* mulai aktif saat proses penyelupan yang nantinya akan menghasilkan senyawa vanillin. Polong yang dicelup dalam waktu singkat akan membuat enzim kurang aktif dan terlalu lama menyelupkan polong mengakibatkan enzim rusak.

Tahap pemeraman (fermentasi) polong vanili yang telah layu ditiriskan kemudian ditempatkan pada peti berdinding ganda yang disematkan serbuk gergaji atau sabut kelapa sebagai tempat pemeraman. Pemeraman memaksimalkan reaksi enzim dan merubah glukovanilin menjadi glukosa dan vanillin. Fisik polong vaniliterlihat kecoklatan, berminyak dan mengkilap.

Tahap pengeringan mengurangi kadar air yang tersimpan pada polong secara perlahan. polong ditata di atas alas yang terbuat dari bambu atau kawat, kemudian disimpan pada ruang yang bersih, kering, dan berventilasi.

Tahap penyimpanan mengoptimalkan polong menjadi lebih beraroma, polong dikumpulkan dan diikat dengan tali sebanyak 50–100 buah polong kering dalam satu ikat. Kemudian setiap ikatan dibungkus menggunakan kertas minyak dan disimpan dalam peti selama 2 hingga 3 bulan.

2.9 Penyakit Dan Hama Vanili

Pada musim penghujan tanaman vanili dapat terserang penyakit yang

menyebabkan pertumbuhan vanili terganggu dan saat musim kemarau serangan hama juga dapat mengganggu pertumbuhan jika tidak diberikan pencegahan dan penanganan. Berikut beberapa penyakit serta hama yang sering dijumpai menyerang tanaman vanili, secara detil (M. Fajar Ramadhan et al., 2019; Tatak Guntoro & M. Anis Fathoni, 2020):

1. Penyakit

Penyakit tanaman vanili menjadi perhatian utama dalam pembudidayaan tanaman vanili. Gambar 2.11 menggambarkan penyakit yang menyerang tanaman vanili diantaranya busuk batang, busuk sclerotium, lumut kerak, busuk pucuk, antraknosa.



(a) Penyakit batang busuk



(b) Karat daun



(c) Antraknosa daun

Gambar 2.12 Penyakit Yang Menyerang Tanaman Vanili

Sumber: <https://www.digrow.co.id/pengendalian-hama-dan-penyakit-tanaman-vanili/>

a. Busuk batang

Penyakit busuk batang vanili seperti gambar 2.12(a) merupakan penyakit tanaman vanili yang menjadi musuh utama dalam pembudidayaan tanaman vanili. Penyakit yang muncul saat curah hujan dan kelembapan yang tinggi ini disebabkan oleh jamur *Fusarium oxysporum*. Jamur ini bersifat *soil borne* atau penularan melalui media tanah dan *air borne* penularan melalui media udara, serta dapat membentuk *klamidospora* (spora jamur) yang memberikan kemampuan untuk bertahan hidup di dalam tanah tanpa memerlukan inang. Penyebutan busuk batang di Indonesia dikarenakan penyakit ini banyak menyerang batang tanaman vanili, sedangkan Brazil dan Madagaskar disebut penyakit busuk akar yang sering menyerang akar

tanaman.

Penyebaran jamur fusarium ini selain melalui tanah dan udara juga dapat menyebar melalui setek bakal bibit vanili, air, dan peralatan pertanian. Infeksi jamur ini memberikan resiko sebesar 7–32% saat pemilihan bibit yang disebabkan akibat luka terbuka dari sayatan ketika penyetekan bibit. Fusarium kemudian memproduksi asam fusarat yang menyebabkan tanaman layu dan busuk.

Gejala yang timbul bila tanaman vanili terjangkit penyakit ini ialah jaringan batang yang membusuk. Namun penyakit ini juga dapat membuat jaringan lain pada suatu tanaman vanili membusuk seperti pada bagian akar, pucuk, polong dan daun. Daun vanili yang terjangkit akan menguning, keriput, dan kemudian rontok. Pada polong vanili berubah warna menjadi kecoklatan hingga kehitaman.

b. Busuk Sklerotium

Penyakit busuk sklerotium (*Sclerotium rolfsii*) atau busuk pangkal menyerang pangkal batang tanaman menjadi busuk dan berwarna coklat muda.

c. Busuk Pucuk

Serangan jamur fusarium juga mengundang penyebab penyakit busuk pucuk yang disebabkan oleh *Phytophthora parasitica*. Pembusukan pada pucuk dan buah vanili berubah menjadi coklat kekuningan dan kemudian menghitam.

d. Karat daun

Ganggang *Cephaleuros henningsii* menyerang daun vanili yang tua, munculnya bercak-bercak kecil pada daun yang dapat melebar hingga 2 cm, seperti gambar 2.12(b).

e. Antraknosa

Cendawan *Colletotrichum gloesporioides* menyerang batang, daun, dan buah tanaman yang tua, timbulan bercak dengan ukuran yang bervariasi dan berwarna abu-abu yang kemudian menjadi coklat, seperti gambar 2.12(c).

2. Hama

Walaupun bukan menjadi perhatian utama, kurangnya penanganan terhadap hama dapat merusak pertumbuhan tanaman vanili. Hama yang menyerang tanaman vanili diantaranya bekicot, belalang, dan ulat. Ulat hitam yang sering ditemukan ialah *Cretonotos gangis*. Gambar 2.13 menggambarkan hama yang menyerang tanaman vanili.



(d) Hama Bekicot



(e) Hama Ulat

Gambar 2.13 Hama Yang Menyerang Tanaman Vanili

Sumber: <https://www.digrow.co.id/pengendalian-hama-dan-penyakit-tanaman-vanili/>

3. Pencegahan dan penanganan

Pentingnya perlakuan pencegahan untuk menghindari potensi terserang dan penanganan saat tanaman terserang penyakit atau hama demi meminimalisir dampak akibat serangan penyakit atau hama. Setiap penyakit dan hama memiliki perlakuan pencegahan dan penanganan yang berbeda, tergantung kepada penyakit atau hama yang dihadapi di lapangan. Langkah pencegahan dan penanganan tersebut diantaranya pencegahan penyakit busuk batang dapat dilakukan sedari pemilihan bibit, pemilihan pohon panjat, dan pengolahan tanah yang terbebas dari kontaminasi jamur *fusarium*. Peralatan pertanian saat penyetekan juga dipastikan steril. Bila terdapat tanaman vanili yang terjangkit vanili segera potong bagian yang terjangkit dan oleskan fungisida pada bekas potongan. Pada penyakit *Phytophthora parasitica* dapat dicegah dengan memangkas pohon panjat agar menjaga kelembapan yang optimal serta memangkas bagian tanaman yang terserang penyakit. Serangan penyakit karat daun oleh *Colletotrichum gloesporioides* dapat ditangani

dengan memangkas dan memusnahkan bagian tanaman yang terjangkit. Penyakit *Colletrotrichum gloesporioides* dicegah dengan memotong percabang pada pohon panjat untuk mengurangi kelembapan, mengaplikasikan fungisida atau segera memangkas bagian tanaman yang terjangkit dan memusnahkannya, serta menghambat persebaran patogen pada tanaman.

2.10 Penelitian terdahulu

Penelitian dalam pendeteksian penyakit dan hama tanaman menggunakan pendeteksian *one-stage* YOLO telah dilakukan oleh beberapa peneliti yang disajikan juga pada tabel 2.3.

Vijayakumar P., Amrith C., Akhash S. Shunmugam, Kritin R. dan Sanoj S (2020) mengidentifikasi penyakit melalui daun tanaman tomat yang sehat dan yang tidak sehat menggunakan YOLO versi 3 menghasilkan tingkat akurasi sebesar 82,38% menggunakan data gambar sebanyak 304 buah, 264 gambar digunakan sebagai data latih dan 40 gambar untuk data uji.

Metode YOLO versi 5 diteliti oleh Mahnoor K., Muhammad S. Sarfraz, Uzair Iqbal, Muhammad U. Aftab, Gniewko N., dan Hafiz T. Rauf (2023) untuk mengidentifikasi daun *money plant*, *bell paper*, dan *potato* yang sehat dan yang terserang penyakit menggunakan data gambar sebanyak 2.311 buah, 2.000 gambar untuk melatih model, 105 gambar sebagai data validasi, dan 206 gambar untuk menguji model dengan hasil akurasi sebesar 93% pada set data uji.

Penelitian mengidentifikasi penyakit pada tumbuhan apel dilakukan oleh Huishan Li, Lei Shi, Siwen Fang dan Fei Yin (2023) seperti *rust*, *frogeye leaf spot*, *powdery mildew*, and *scab* yang menyerang daun dengan menggunakan YOLO versi 5 dengan improvisasi seperti penambahan modul BiFPN (BF), *Transformer* (TR), dan *Convolutional Block Attention Module* (CBAM) yang menghasilkan *precision*, *recall*, skor F1, mAP50, mAP50:95 masing-masing sebesar 84,1%, 77,3%, 80,5%, 84,3%, dan 45,9%.

Qing Dong, Lina Sun, Tianxin Han, Minqi Cai, dan Ce Gao (2024) melakukan penelitian dengan mengidentifikasi hama yang menyerang tanaman

padi dan jagung, seperti DauZhong (*Cnaphalocrocis medinalis*), DaoMinLin (*Naranga aenescens* Moore), larva ErHua (*Spodoptera litura*), YuMi (*Ostrinia furnacalis*), DaMingShen (*Sesamia inferens*), HeiBai (*Athetis lepigone*), YangXue (*Lymantria dispar* or *Lymantria xyliana*), LouGu (*Gryllotalpa orientalis*), dan JinGui (*Holotrichia oblita* Faldermann). Data yang dikumpulkan sebanyak 6.626 gambar dan dibagi dengan komposisi 60% sebagai data latih, 20% sebagai data validasi, 20% sisanya sebagai data uji. Data juga diberikan augmentasi berupa *horizontal flipping*, *mosaic*, dan translasi kemudian data dilatih menggunakan YOLO versi 5 yang dikombinasikan dengan modul *Efficient Channel Attention* (ECA), *Content Aware Reassembly of Features* (CARAFE), *Involution*, dan *Multi-Scaling Spatial Pyramid Pooling Fast* (MTSPPF), menghasilkan *precision* sebesar 91,9%, *recall* sebesar 82,7%, mAP50 sebesar 90,7%.

Penelitian sebelumnya yang dilakukan oleh Jien W. Chen, Wan J. Lin, Hui J. Cheng, Che L. Hung, Chun Y. Lin, and Shu P. Chen (2021) dalam mengidentifikasi tiga jenis hama *Mealybugs*, *Coccidae*, *Diaspididae* dengan data gambar masing-masing sebanyak 200 buah yang kemudian keseluruhan data dibagi untuk melatih dan memvalidasi model serta menggunakan YOLO versi 4 mendapatkan akurasi sebesar 100% pada *mealybugs*, 89% pada *coccidae*, dan 97% pada *diaspididae*.

Eray Önlér (2021) meneliti pengidentifikasian hama ulat bulu *thistle* (*Vanessacardui*) yang menyerang tanaman kacang kedelai menggunakan YOLO versi 5 menghasilkan mAP sebesar 59%. Data gambar yang digunakan sebanyak 1934 untuk melatih model, 241 untuk menguji model, 241 lainnya sebagai data validasi.

Tabel 2.4 Penelitian terdahulu

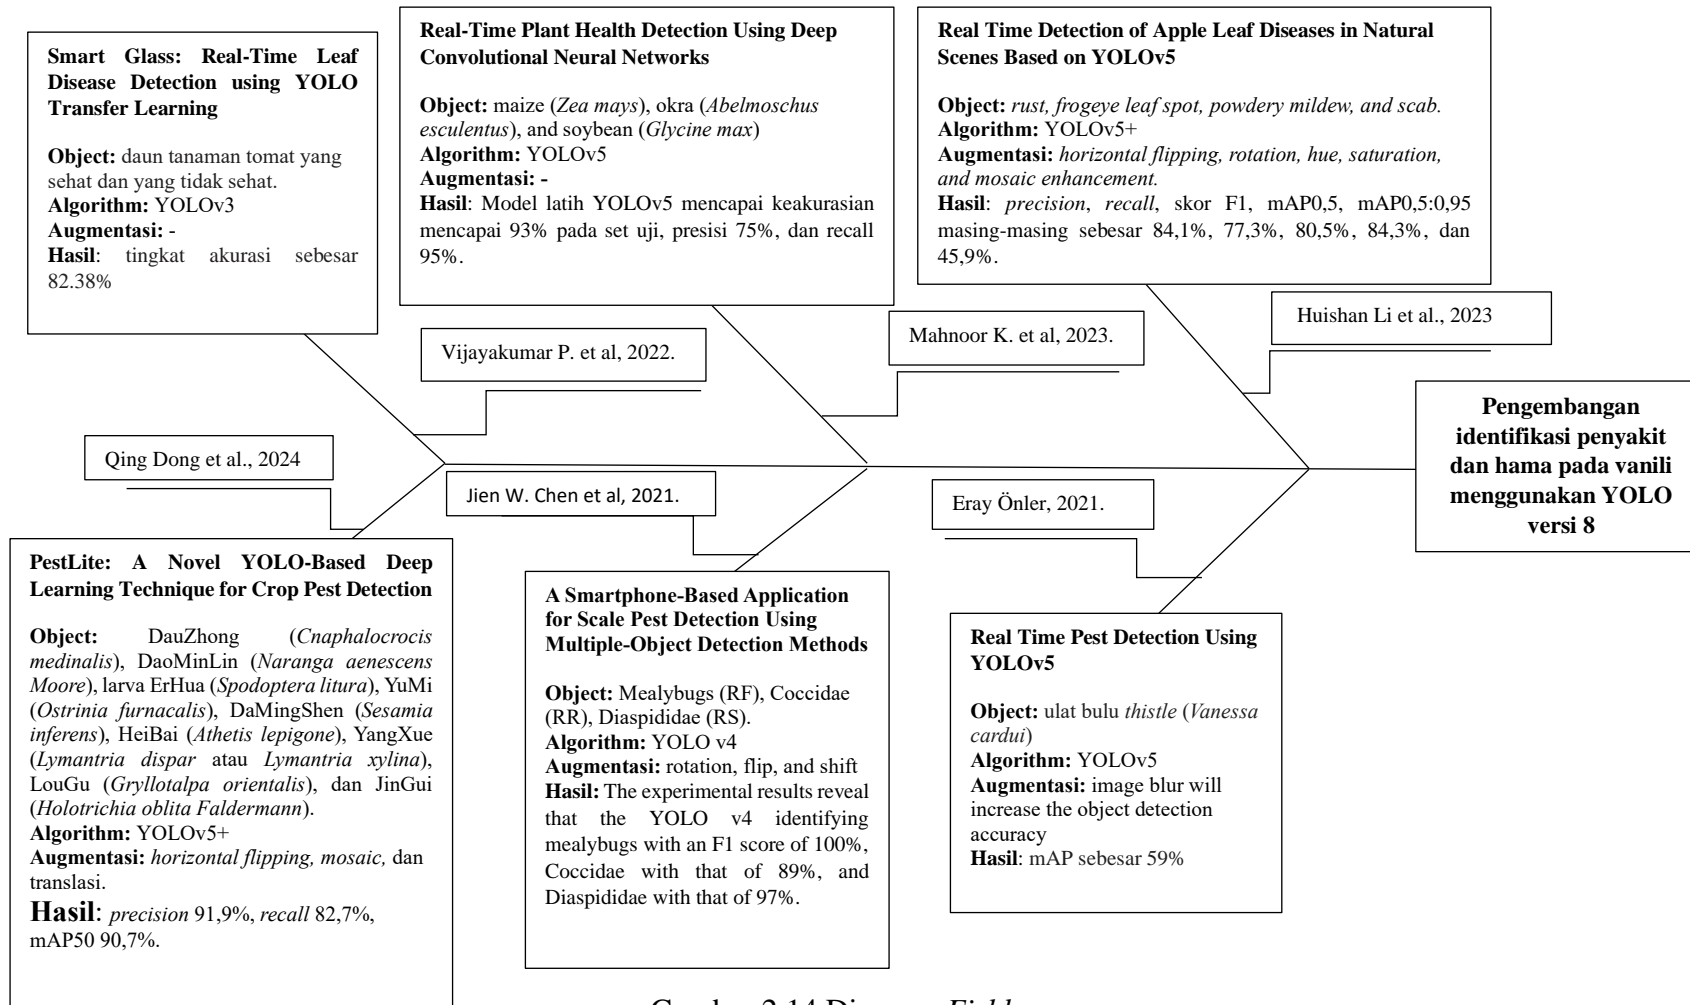
No.	Penulis, tahun	Objek	Augmentasi	Metode	Hasil
1.	Vijayakumar P. et al., 2020	Penyakit tanaman tomat	X	YOLOv3	tingkat akurasi sebesar 82,38%

No.	Penulis, tahun	Objek	Augmentasi	Metode	Hasil
2.	Mahnoor K. et al., 2023	Penyakit tanaman <i>maize</i> , <i>okra</i> , dan <i>soy bean</i>	X	YOLOv5	hasil akurasi sebesar 93% pada set data uji
3.	Huishan Li et al., 2023	Penyakit tanaman apel	<i>Horizontal flipping, rotation, hue, saturation, and mosaic enhancement.</i>	YOLOv5+	<i>precision, recall</i> , skor F1, mAP0,5, mAP0,5:0,95 masing-masing sebesar 84,1%, 77,3%, 80,5%, 84,3%, dan 45,9%.
4.	Qing Dong et al., 2024	Hama tanaman padi, jagung, dan tanaman lainnya	<i>Horizontal flipping, mosaic, dan translasi</i>	YOLOv5+	<i>precision</i> 91,9%, <i>recall</i> 82,7%, mAP50 90,7%.
5.	Jien W. Chen, et al., 2021	Hama tanaman argikultural	<i>Horizontal flipping, shift horizontal-vertical, rotasi.</i>	YOLOv4	akurasi sebesar 100% pada <i>mealybugs</i> , 89% pada <i>coccidae</i> , dan

No.	Penulis, tahun	Objek	Augmentasi	Metode	Hasil
					97% pada <i>diaspidiae</i> .
6.	Eray Önlér, 2021	Hama tanaman bunga matahari	<i>Image blur</i>	YOLOv5	mAP 59%

2.11 Diagram Fishbone

Penyajian diagram dengan bentuk tulang ikan (*fishbone*) menampilkan sebab-akibat yang telah dianalisis dan mencari hubungan antar faktor-faktor terkait. Diagram yang dikembangkan oleh Kaoru Ishikawa menempatkan akibat atau masalah yang ingin diteliti pada kepala dan faktor-faktor terkait yang kemungkinan menjadi penyebab dari masalah tersebut sebagai tulang-tulang ikan. Kemudahan yang didapatkan juga membantu mengembangkan diskusi *joint brainstorming* lebih dalam, memetakan pemikiran dari proses *brainstorming*, membantu menjabarkan akar permasalahan dari setiap faktor dengan cepat, membantu memprioritaskan penyebab yang relevan, dan lainnya. Kekurangan yang dimiliki diantaranya penyebab potensial yang tidak relevan dapat membingungkan dan permasalahan yang rumit dapat menyebabkan diagram berantakan (Usman Kasim, Nira Erdiana, and Delfira Aulia, 2021). Seperti yang diilustrasikan pada gambar 2.14.

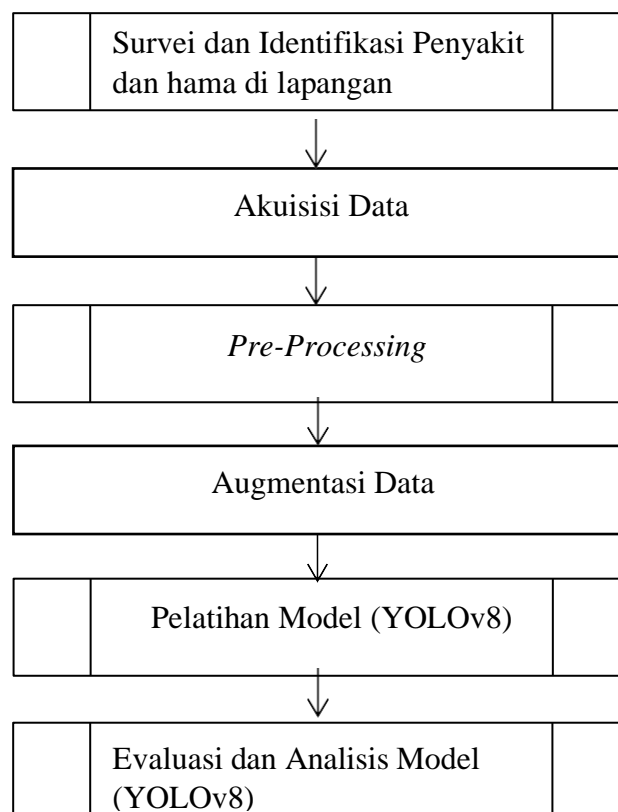
Gambar 2.14 Diagram *Fishbone*

BAB 3

METODE PENELITIAN

3.1. Tahapan Penelitian

Identifikasi penyakit dan hama vanili dengan menggunakan metode YOLO versi 8, dimulai dari akuisisi data yaitu mengumpulkan data citra penyakit dan hama vanili, *pre-processing* menyesuaikan ukuran citra, augmentasi data, melatih model dengan CNN (YOLO versi 8), mengevaluasi model, dan terakhir model dapat mengidentifikasi penyakit dan hama vanili dengan akurat. Gambar 3.1 menampilkan tahapan-tahapan yang dilakukan selama penelitian.



Gambar 3.1 Tahapan Penelitian

3.2. Survei dan identifikasi penyakit dan hama di Lapangan

Survei penyakit dan hama vanili dilakukan dengan mendatangi kebun vanili, kemudian mengobservasi tanaman vanili yang sedang terserang penyakit atau hama. Selanjutnya penyakit dan hama dipelajari untuk dapat dikelaskan dan diakuisisi menggunakan kamera ponsel sebagai dataset.

3.3. Akuisisi Data

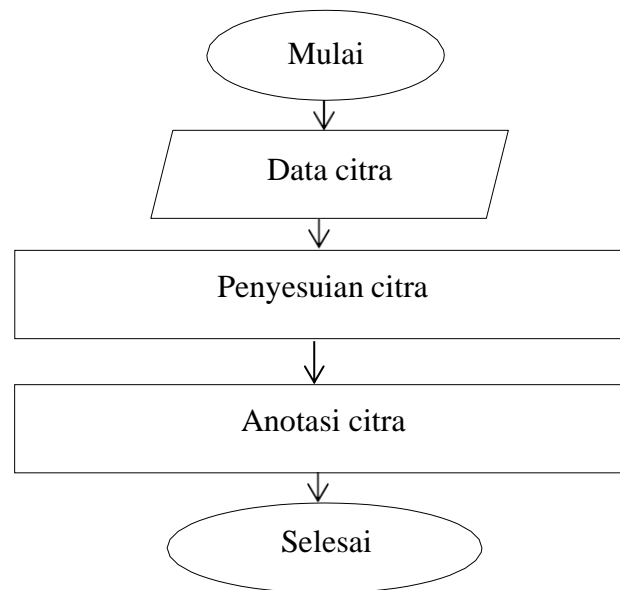
Akuisisi (pengumpulan) data dilakukan dengan mendatangi kebun vanilla dan mengambil gambar tanaman vanilla yang terjangkit penyakit busuk batang, jamur penyebab busuk batang (*Fusarium oxysporum*), dan bagian tanaman yang terserang hama bekicot secara langsung menggunakan ponsel dengan spesifikasi kamera 64 Megapiksel. Pengambilan gambar dilakukan pada waktu tertentu pagi, siang, dan sore supaya mendapatkan kondisi cahaya yang bervariasi. Gambar 3.2 merupakan contoh gambar-gambar tanaman vanili yang terjangkit penyakit busuk batang dan jamur (*Fusarium oxysporum*).



Gambar 3.2 Akuisisi data dari kebun

3.4. Pre-processing

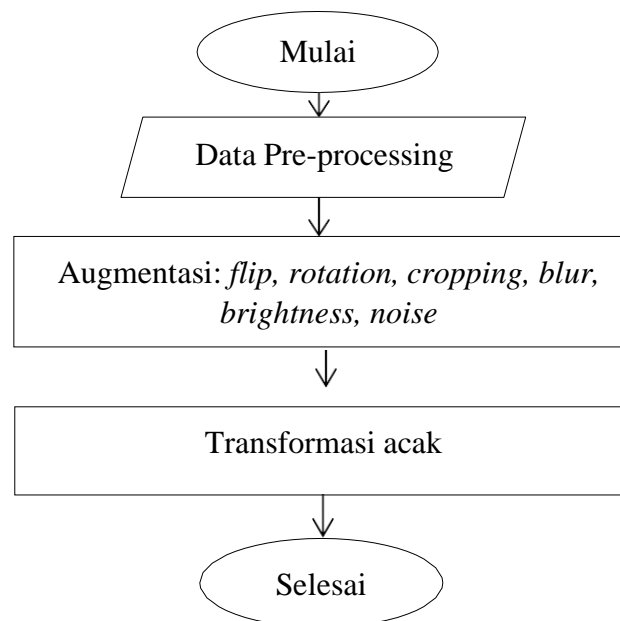
Tahap sebelum pemrosesan (*pre-processing*) membuat citra disesuaikan ukurannya menjadi lebih kecil (*resize*) 640x640. Selanjutnya data dianotasi (*annotation*) dengan membuat kotak di sekeliling objek dan diberikan label nama yang sesuai. Alur data pre-processing ditunjukkan pada gambar 3.3.



Gambar 3.3 Alur data *Diresize* dan Diberikan Anotasi

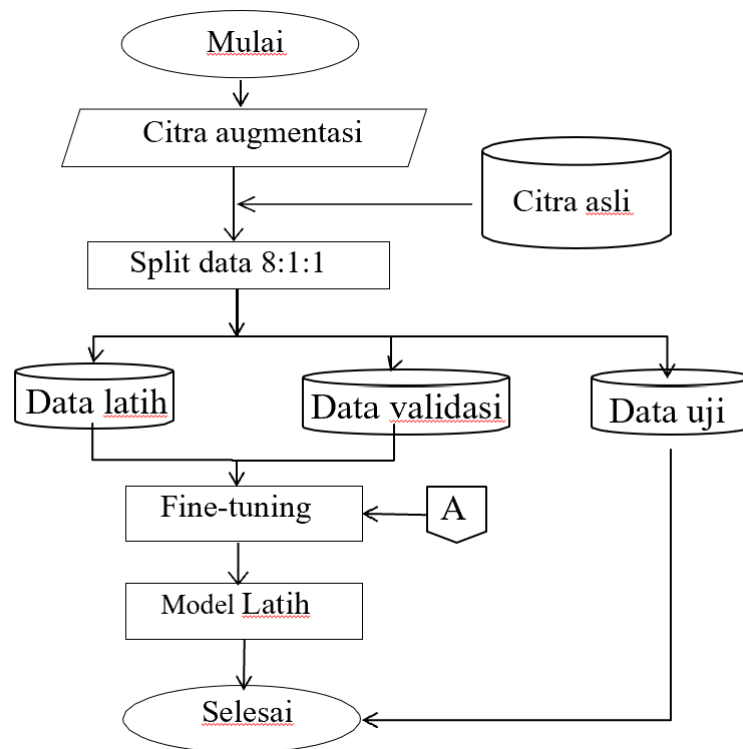
3.5. Augmentasi Data

Data citra yang telah *diresize* dan diberi label kemudian diaugmentasi. Augmentasi diperlukan untuk menghindari *overfitting* saat model melatih data. Gambar 3.4 menunjukkan augmentasi yang diberikan berupa flip horizontal, *rotation*, *cropping*, *blur*, *brightness*, *noise*, dan kemudian data ditransformasi secara acak.



Gambar 3.4 Augmentasi Gambar

3.6. Pelatihan Model

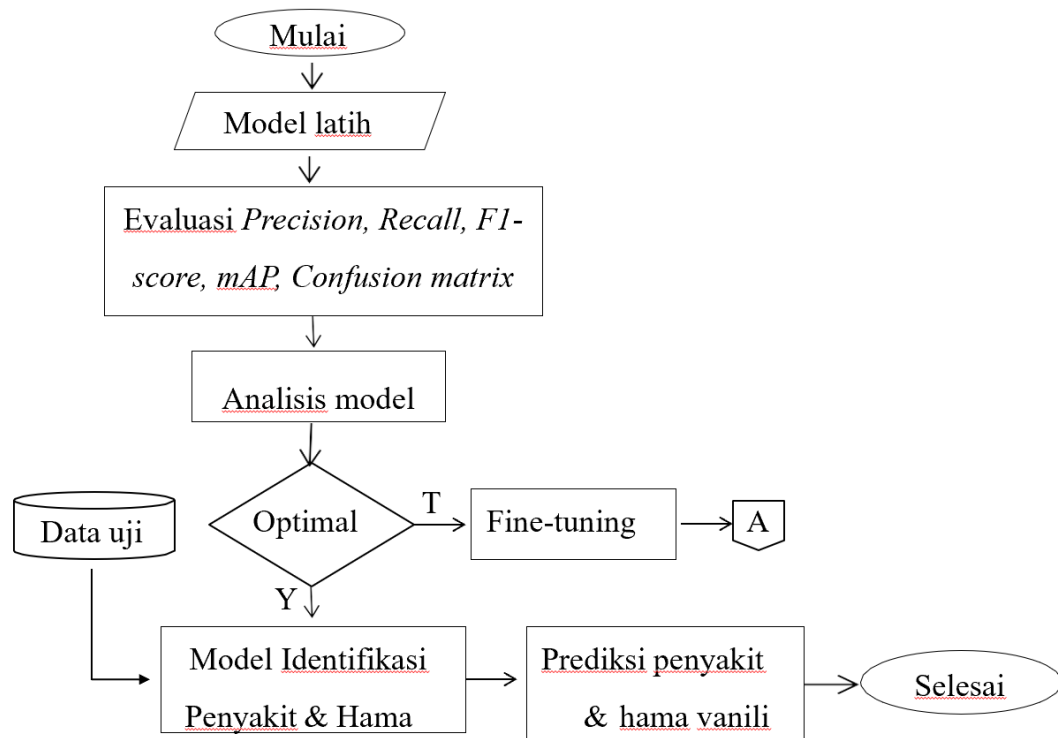


Gambar 3.5 Alur Pelatihan Model

Setelah citra diaugmentasi, kemudian citra asli dan citra augmentasi dipisahkan menjadi kelompok data latih, data uji, dan data validasi dengan komposisi 8:1:1. Selanjutnya model dilatih dengan data latih dan data validasi serta memberikan parameter berupa *epoch*, *Optimizer* dan *learning rate*. Alur pelatihan model ditunjukkan pada gambar 3.5.

3.7. Evaluasi dan Analisis Model

Evaluasi terhadap model dilakukan untuk melihat akurasi model saat mengidentifikasi penyakit dan hama vanili.



Gambar 3.6 Alur Evaluasi dan Analisis Model

Gambar 3.6 menunjukkan alur model dievaluasi dan menganalisis hasil evaluasi model, matriks yang digunakan untuk mengevaluasi model di antaranya *Precision* (P), *Recall* (R), *F1-score*, *mean Average Precision* (mAP), dan *confusion matrix*. Model yang telah dilatih kemudian dievaluasi dengan beberapa matriks yang digunakan untuk mengevaluasi model untuk menganalisis hasil evaluasi model yang optimal, model yang optimal dapat digunakan untuk memprediksi

dalam pengidentifikasian dalam pembudayaan vanilla. Model yang tidak optimal harus kembali pada fase pelatihan dan hingga hasil menjadi optimal.

3.8. Jadwal Penelitian

No	Uraian	Tahun 1		Tahun 2		Tahun 3	
		Sem1	Sem2	Sem1	Sem2	Sem1	Sem2
1	Kualifikasi						
2	Persiapan data penelitian						
3	Pengolahan penelitian						
4	<i>Progress report 1</i>						
5	<i>Progress report 2</i>						
6	Publikasi						
7	Sidang Tertutup						
8	Sidang Terbuka						

DAFTAR PUSTAKA

- Agus Wahyudi, Redy A. Permadi and Ermiati, "Technical risk control system of sustainable vanilli cultivation in Indonesia," *E3S Web of Conferences* 306, 2021.
- Andriana Kartikawati and Rosihan Rosman, "Sirkuler Informasi Teknologi Tanaman Rempah dan Obat Budidaya Vanili," Balai Penelitian Tanaman Rempah dan Obat, Bogor, 2018.
- Arunabha M. Roy, Rikhi Bose, and Jayabrata Bhaduri, "A fast accurate fine-grain object detection model based on YOLOv4 deep neural network," arXiv, 2021.
- Carlos Santos, Marilton Aguiar, Daniel Welfer, and Bruno Belloni, "A New Approach for Detecting Fundus Lesions Using Image Processing and Deep Neural Network Architecture Based on YOLO Model," MDPI, 2022
- Daphna Havkin-Frenkel, Faith C. Belanger, "Handbook of Vanilla Science and Technology," Wiley, Hoboken, NJ, USA, 2018.
- Dulari Bhatt, Chirag Patel, Hardik Talsania, Jigar Patel, Rasmika Vaghela, Sharnil Pandya, Kirit Modi, and Hemant Ghayvat, "CNN Variant for Computer Vision: History, Architecture, Application, Challenges and Future Scope," MDPI, 2021.
- Endang Hadipoentyanti, Agus Ruhnayat, Laba Udarno, "Teknologi Unggulan Vanili Budidaya dan Pascapanen Pendukung Varietas Unggul," Pusat Penelitian dan Pengembangan Perkebunan, Bogor, 2017.
- Eray Önlér, " REAL TIME PEST DETECTION USING YOLOv5," *International Journal of Agricultural and Natural Sciences*, vol. 14, no. 3, pp. 236-246, 2021.
- Haitong Lou, Xuehu Duan, Junmei Guo, Haiying Liu, Jason Gu, Lingyun Bi, and Haonan Chen, "DC-YOLOv8: Small-Size Object Detection Algorithm Based on CameraSensor," MDPI, 2023.
- Huishan Li, Lei Shi, Siwen Fang, and Fei Yin, "Real-time Detection of Apple Leaf Disease in Natural Scenes Based on YOLOv5," MDPI, 2023.
- Jhinzhu Lu, Lijuan Tan, and Huanyu Jiang, "Review on Convolution Neural Network (CNN) Applied to Plant Leaf Disease Classification," MDPI, 2021.
- Jien W. Chen, Wan J. Lin, Hui J. Cheng, Che L. Hung, Chun Y. Lin, and Shu P.

- Chen, "A Smartphone-Based Application for Scale Pest Detection Using Multiple-Object Detection Methods," *MDPI*, 2021.
- Juan Terven, Diana-Margarita Cordova-Esparza, and Julio-Alejandro Romero-Gonzalez, "A Comprehensive Review of YOLO Architecture in Computer Vision: From YOLOv1 to YOLOv8 and YOLO-NAS," *MDPI*, 2023.
- Kementrian keuangan, "Ini Potensi Ekspor Vanili Indonesia, "Si Emas Hitam" yang Menjanjikan," 16 Oktober 2023. [Online]. Available: <https://www.kemenkeu.go.id/informasi-publik/publikasi/berita-utama/Ini-Potensi-Ekspor-Vanili-Indonesia>
- Kiran Maharana, Surajit Mondal, Bhushankumar Nemade, "A review: Data pre-processing and data augmentation techniques," *Global Transitions Proceeding*, vol. 3, pp. 91-99, 2022.
- M. Fajar Ramadhan, Endang Setyorini, Nia Rachmawati, and Etty Andriati, "Ayo Berkebun Vanili," Pusat Perpustakaan dan Penyebaran Teknologi Pertanian, Bogor, 2019.
- Mahnoor K., Muhammad S. Sarfraz, Uzair Iqbal, Muhammad U. Aftab, Gniewko N., and Hafiz T. Rauf, "Real-Time Plant Health Detection Using Deep Convolutional Neural Networks," *MDPI*, 2023.
- Manuel Carranza Garcia, Jesus Torres Mateo, Pedro Lara-Benitez, and Jorge Garcia-Gutierrez, "On the Performance of One-stage and Two-stage Object Detectors in Autonomous Vehicle Using Camera Data," *MDPI*, 2020.
- Markoulidakis, I., Rallis, I., Georgoulas, I., George Kopsiaftis, Anastasios Doulamis, and Nikolaos Doulamis, "Multiclass Confusion Matrix Reduction Method and Its Application on Net Promoter Score Classification Problem," *MDPI*, 2021.
- Nariman Mamdouh & Ahmed Khattab, "YOLO-Based Deep Learning Framework for Olive Fruit Fly Detection and Counting," *IEEE*, vol. 9, pp. 84252-84262, 2021.
- Nasser Aloufi, Abdulaziz Alnori, Vijey Thayananthan, and Abdullah Basuhail, "Object Detection Performance Evaluation for Autonomous Vehicles in Sandy Weather Enviroments," *MDPI*, 2023

- Parita Oza, Paawan Sharma, Samir Patel, Festus Adedoyin, and Alessandro Bruno, "Image Augmentation Techniques for Mammogram Analysis," MDPI, 2022
- Peiyuan Jiang, Daji Ergu, Fangyao Liu, Ying Cai, and Bo Ma, "A Review of Yolo Algorithm Developments," *Procedia Computer Science*, vol. 199, pp. 1066-1073, 2021.
- Qing Dong, Lina Sun, Tianxin Han, Minqi Cai, and Ce Gao, "PestLite: A Novel YOLO-Based Deep Learning Technique for Crop Pest Detection," MDPI, vol. 14, issue 2, 2024.
- Rafael Padilla, Wesley L. Passos, Thadeu L. B. Dias, Sergio L. Netto, and Eduardo A. B. da Silva, "A Comparative Analysis of Object Detection Metrics with a Companion Open-Source Toolkit," MDPI, 2021
- Sandhya & Abhishek Kashyap, "A novel method for real-time object-based copy-move tampering localization in videos using fine-tuned YOLOv8," *Forensic Science International: Digital Investigation*, vol. 48, 2024.
- Singletary, K. W., "Vanilla: Potential Health Benefit," *Nutrition Today*, vol. 55, no. 4, pp. 186-196, 2020.
- Syed Sahil Abbas Zaidi, M. Samar Ansari, Asra Aslam, Nadia Kanwal, Mamoon Asghar, and Brian Lee, "A Survey of Modern Deep Learning based Object Detection Models," *Digital Signal Processing*, vol. 126, 2022.
- Tatak Guntoro & M. Anis Fathoni, "Teknik Terbaru Budidaya Vanili Di Pekarangan Rumah & Pot," Agromedia Pustaka, Jakarta, 2020.
- Usman Kasim, Nira Erdiana, and Delfira Aulia, "The Use of Fishbone Diagram Technique to Improve Students Writing Ability," *Proceedings of the 11th Annual International Conference (AIC) on Social Sciences*, 2021.
- Vijayakumar P., Amrith C., Akhash S. Shunmugam, Kritin R. and Sanoj S., "Smart Glass: Real-Time Leaf Disease Detection using YOLO Transfer Learning," *International Conference on Communication and Signal Processing*, 2020.
- Yusniarti, Sudarisman, Agus Budiharto, "Teknologi Unggulan Vanili Budidaya dan Pascapanen Pendukung Varietas Unggul," Pusat Penelitian dan Pengembangan Perkebunan (Puslibangbun), Bogor, 2017.
- Zhaoyi Chen, Ruhui Wu, Yiyan Li, Chuyu Li, Siyu Chen, Zhineng Yuan, Shiwei

Chen, and Xiangjun Zou, "Plant Disease Recognition Model Based on Improved YOLOv5," *MDPI*, 2022.