



**Pendekatan Hibrida Berbasis Pembelajaran
Mendalam Untuk Mendeteksi Penyakit
Tanaman Pada Citra Daun Padi**

PROPOSAL KUALIFIKASI

Zalita Nadya Utami

99223145

PROGRAM DOKTOR TEKNOLOGI INFORMASI

UNIVERSITAS GUNADARMA

2024

DAFTAR ISI

	halaman
DAFTAR ISI	2
1. PENDAHULUAN	
1.1 Latar Belakang Penelitian	4
1.2 Batasan dan Rumusan Masalah.....	9
1.3 Tujuan Penelitian	10
1.4 Kontribusi dan Manfaat Penelitian.....	11
2. TELAAH PUSTAKA	
2.1 Citra Digital	12
2.1.1 Komponen Citra Digital.....	12
2.1.2 Elemen Citra Digital	13
2.2 Pengolahan Citra Digital	13
2.3 Metode <i>Threshold</i>	14
2.4 Ekstraksi Fitur	15
2.4.1 <i>Local Binary Pattern</i>	15
2.4.2 <i>Grey Level Co-occurrence Matrix</i>	16
2.5 <i>Artificial Intelligence</i>	17
2.5.1 <i>Deep Learning</i>	18
2.6 <i>Artificial Neural Network</i>	19
2.7 <i>Convolutional Neural Network</i>	19
2.8 <i>Vision Transformer</i>	21
2.9 Pendekatan Hibrida	23
2.10 <i>Confusion Matrix</i>	24
2.11 Penyakit Daun Padi	25
2.12 Peta Jalan Penelitian.....	29
2.13 Kajian Penelitian	31

3. METODOLOGI PENELITIAN

3.1	Tahapan Penelitian	40
3.2	Akuisisi Citra Penyakit Daun Padi	41
3.3	Pre-processing Citra Daun Padi.....	42
3.4	Ekstraksi Fitur Citra Daun Padi.....	43
3.5	Pengembangan Model dan Deteksi Penyakit	43
3.6	Evaluasi dan Analisis Model	46
3.7	Estimasi Waktu Penelitian.....	47
DAFTAR PUSTAKA		49

BAB I

PENDAHULUAN

1.1 Latar Belakang Penelitian

Beras yang berasal dari tanaman padi merupakan pangan utama untuk sebagian besar penduduk dunia, khususnya Asia. Di banyak negara berkembang termasuk Indonesia, padi tidak hanya berperan sebagai makanan pokok tetapi juga menjadi komponen penting dalam perekonomian negara. Stabilitas produksi padi adalah kunci utama dalam menghadapi tantangan tersebut.

Peningkatan kebutuhan padi yang dinyatakan oleh Badan Pusat Statistik Indonesia (BPS) bahwa produksi padi pada tahun 2022 untuk konsumsi pangan penduduk Indonesia meningkat 2,29% yaitu sebesar 32,07 juta ton dibandingkan produksi padi pada tahun 2021. Namun, produktivitas padi sering terancam oleh berbagai penyakit yang menyerang seperti *bacterial leaf blight*, *brown spot*, hispa, *leaf blast*, *leaf smut*, dan tungro. Penyakit-penyakit tersebut dapat mengakibatkan penurunan drastis dalam kualitas dan kuantitas padi.

Daun padi dikenal dengan morfologinya yang unik dan berfungsi penting dalam proses fotosintesis. Umumnya, daun ini berbentuk panjang dan sempit, dengan variasi bentuk yang bisa datar atau melengkung. Panjangnya dapat berkisar antara 50-100 cm, bergantung pada varietas dan kondisi tumbuh tanaman tersebut. Warna daun juga menunjukkan variasi dari hijau muda hingga hijau gelap, yang mencerminkan varietas dan kesehatan tanaman. Strukturalnya, daun terbagi menjadi dua bagian utama yaitu pelepah, yang lebih tebal dan mengelilingi batang, serta lamina, yang merupakan bagian lebar dan pipih dari daun. Ujung daun biasanya runcing, sementara pangkalnya melingkar ketat di sekitar batang. Permukaan daun biasanya halus atau mungkin sedikit kasar dan seringkali dilapisi dengan lapisan lilin yang membantu tanaman dalam retensi air, vital untuk proses fotosintesis dan pertumbuhan tanaman. Pengelolaan penyakit pada daun padi memerlukan pemahaman mendalam tentang morfologi daun dan patogen yang

menyebabkan penyakit. Deteksi dini melalui pemantauan reguler dan penerapan strategi pengendalian yang tepat sangat krusial untuk meminimalkan kerusakan dan memastikan produktivitas yang tinggi.

Deteksi dini penyakit tanaman pada citra daun padi penting untuk penerapan strategi pengendalian pertanian yang efektif. Ciri – ciri fisik pada penyakit daun tersebut berbeda-beda seperti perubahan warna, ukuran, dan bentuk. Metode konvensional dalam mendeteksi penyakit tersebut umumnya melibatkan inspeksi visual oleh petani atau ahli agrikultur serta analisis laboratorium. Metode tersebut membutuhkan banyak waktu, tenaga, dan materi serta kemungkinan kesalahan dalam diagnosa dan hasil laboratorium yang tak jarang mengandung bias dapat menjadi fatal terutama di area lahan pertanian yang luas.

Penggunaan teknologi berbasis citra untuk mendeteksi penyakit tanaman merupakan salah satu teknologi modern yang menjanjikan di bidang pertanian. Citra yang diambil dapat dianalisis untuk mengidentifikasi tanda-tanda awal penyakit pada tanaman sehingga memungkinkan pemantauan dan tindakan pengendalian kesehatan tanaman dapat dilakukan secara lebih cepat, akurat dan sistematis. Pendekatan berbasis pembelajaran mendalam telah menunjukkan potensi yang signifikan dalam analisis citra pada berbagai bidang aplikasi.

Mengembangkan sistem pendeteksian penyakit pada daun padi dengan menggunakan pemrosesan citra dan pembelajaran mendalam memang menjanjikan, namun dihadapkan pada berbagai tantangan spesifik yang memerlukan solusi inovatif. Pertama, variabilitas data akibat kondisi pencahayaan seringkali mempengaruhi kualitas gambar, yang bisa mengurangi akurasi model. Untuk mengatasi hal ini, augmentasi citra seperti penyesuaian kecerahan dan kontras, serta penggunaan teknik normalisasi citra, dapat meningkatkan robustness model terhadap variasi pencahayaan. Kedua, morfologi daun padi yang memanjang dan sempit menyulitkan proses segmentasi yang efektif. Solusinya, penggunaan model segmentasi spesifik yang dirancang untuk menangani bentuk yang rumit sangat membantu, serta pelatihan model diferensial dengan dataset khusus daun padi untuk meningkatkan kemampuan segmentasi. Ketiga, banyak penyakit daun padi yang menunjukkan gejala serupa, membuatnya sulit dibedakan hanya dari citra visual.

Teknik seperti ekstraksi fitur lanjutan dengan *Convolutional Neural Network* (CNN) yang lebih dalam dan pembelajaran fitur multi-skala dapat memperkuat kemampuan model dalam mengidentifikasi perbedaan halus antar penyakit.

Dengan berkembangnya pembelajaran mendalam, model pembelajaran mendalam berdasarkan CNN telah banyak berhasil diaplikasikan untuk mengenali pola-pola kompleks dalam citra yang sulit diproses dengan teknik pemrosesan citra tradisional. CNN menggunakan operasi konvolusi secara otomatis yang dapat mengekstraksi fitur lokal, yang secara mendasar memecahkan masalah dari keterlibatan manusia. Namun, aplikasi teknologi ini dalam deteksi penyakit tanaman masih menghadapi tantangan seperti bidang sensorik yang lebih besar seringkali hanya dapat dicapai dengan menggunakan kernel konvolusional besar atau menumpuk beberapa kernel konvolusional kecil secara berurutan termasuk kebutuhan akan dataset yang besar, juga kurangnya kemampuan untuk menggeneralisasi hasil deteksi di berbagai kondisi lingkungan. CNN meskipun mempelajari fitur-fitur lokal secara efektif, tetapi tidak dapat memodelkan hubungan antar berbagai wilayah dalam sebuah gambar dan akan ada peningkatan *overhead* komputasi yang tidak perlu seiring dengan meningkatnya kedalaman jaringan. Karakteristik ini menentukan bahwa CNN memiliki kelemahan dalam memodelkan informasi global.

Dalam masalah ekstraksi informasi global, *Vision Transformer* (ViT) memberikan solusi yang layak. Sebagai turunan dari Transformer, ViT telah menunjukkan kinerja luar biasa pada tugas klasifikasi gambar skala besar. ViT memperkenalkan pendekatan transformatif yang memungkinkannya untuk menangkap hubungan global antar patch gambar dan mempelajari representasi secara efektif. Hal ini mengatasi tantangan distribusi dengan bobot yang sama pada fitur-fitur dalam sehingga berpotensi memastikan bahwa fitur-fitur penting mendapat perhatian yang memadai. ViT memberikan jalan yang menjanjikan untuk memajukan ekstraksi fitur otomatis dan efektif untuk mengerti konteks yang lebih luas dalam sebuah citra juga kemampuan yang melengkapi CNN dalam analisis citra untuk mencapai akurasi yang relatif lebih tinggi.

Meskipun CNN dan ViT memiliki kekuatannya masing-masing, menggabungkan CNN dan ViT dapat menawarkan solusi lebih untuk mendeteksi penyakit tanaman dengan mengintegrasikan kelebihan kedua model dalam satu *framework*. CNN efektif dalam menangkap fitur visual lokal sementara ViT berfokus pada fitur global yang membuat keduanya memiliki potensi komplementer ketika digabungkan dalam pendekatan hibrida.

Pendekatan hibrida yang mengintegrasikan CNN dan ViT menawarkan kemungkinan untuk memanfaatkan kelebihan keduanya dalam deteksi penyakit tanaman. Pendekatan ini juga berpotensi untuk mengatasi variasi dalam kualitas citra yang disebabkan oleh kondisi pencahayaan yang berbeda dan faktor lingkungan lainnya yang sering kali mempengaruhi hasil analisis citra. Pendekatan ini memungkinkan pemanfaatan kelebihan spesifik dari masing-masing metode untuk mengatasi keterbatasan yang ada ketika digunakan secara terpisah. Dengan mengintegrasikan kedua pendekatan tersebut, diharapkan dapat tercipta sebuah sistem yang dapat memberikan hasil lebih baik dalam hal akurasi dan keandalan.

Penelitian mengenai CNN, ViT dan pendekatan hibrida dari kedua algoritma ini telah banyak diaplikasikan dalam berbagai bidang visi komputer dengan pengolahan citra digital seperti pada lingkup kesehatan diantaranya dilakukan oleh Ishak Pacal untuk deteksi dini kanker payudara dengan membandingkan arsitektur CNN dan ViT menggunakan kumpulan data BUSI dengan ViT yang unggul diantara model lain yaitu akurasi yang mencapai 88,6% (PACAL, 2022). Sama hal nya dengan Ishak Pacal, penelitian yang dilakukan oleh Leamons *et al.* juga mengklasifikasikan kanker payudara menggunakan CNN dan ViT dengan hasil eksperimen tertinggi dicapai oleh ViT yaitu akurasi yang mencapai 93% (Leamons et al., 2022). Penelitian mengenai penyakit *pneumonia* berhasil dilakukan oleh Mabrouk *et al.* dengan metode *Ensemble Learning* menggunakan arsitektur CNN dan ViT, dataset yang dipakai yaitu *ImageNet*, hasil diperoleh dengan menggabungkan fitur-fitur yang diekstraksi dari ketiga model dan memperoleh akurasi sebesar 93,91% (Mabrouk et al., 2022). Penelitian mengenai deteksi penyakit retina yang dilakukan oleh Dutta *et al.* mengembangkan model

CNN berbasis pembelajaran transfer dan ViT menghasilkan pendekatan hibrida yang disebut *Conv-ViT* dengan akurasi mencapai 94% (Dutta et al., 2023).

Dalam lingkup lain seperti penelitian yang dilakukan oleh Chaudhari *et al.* mengenai pengenalan emosi wajah menggunakan ViT berhasil mencapai akurasi 88% (Chaudhari et al., 2022), juga penelitian yang dilakukan oleh Koeshidayatullah *et al.* dalam mengklasifikasikan litofasies yang merupakan langkah dasar untuk karakterisasi pengendapan dan reservoir di bawah permukaan menggunakan CNN dan ViT yang disebut sebagai *FaciesViT* menunjukkan hasil akurasi sebesar 95% (Koeshidayatullah et al., 2022).

Penelitian tentang CNN dan ViT paling banyak didominasi dalam lingkup agrikultural untuk mendeteksi penyakit tanaman diantaranya Barman *et al.* yang mengidentifikasi penyakit daun tomat dengan membandingkan ViT yang mendapat akurasi tertinggi sebesar 90,99% dan dalam penelitian ini model ViT dinamai *ViT-SmartAgri* (Barman et al., 2024). Alshammari *et al.* dengan objek penyakit daun zaitun berhasil mengembangkan pembelajaran ansambel yang menggabungkan CNN dan ViT dengan akurasi mencapai 97% (Alshammari et al., 2022). Penelitian yang dilakukan oleh Li & Li tentang identifikasi penyakit apel menggunakan model *ConvViT* mencapai hasil 96,85% (Li & Li, 2022). Han & Guo yang mengklasifikasikan penyakit daun pada tanaman lignin mencapai akurasi 85% (Han & Guo, 2024), dan Sun *et al.* yang mengusulkan model hibrida ViT untuk mengklasifikasi penyakit pada daun tebu mencapai akurasi 89,57% (Sun et al., 2023).

Berdasarkan penelitian-penelitian yang telah berhasil dilakukan sebelumnya, penelitian menggunakan algoritma CNN dan ViT banyak dilakukan untuk mendeteksi penyakit pada tanaman tetapi sebagian besar penelitian masih memiliki keterbatasan dalam hal akurasi yang belum optimal dan variasi data lain. Penelitian ini bertujuan untuk mengembangkan sebuah sistem pendeteksian penyakit tanaman menggunakan citra daun padi melalui pendekatan hibrida. Penelitian ini diperlukan untuk menggali bagaimana kombinasi CNN dan ViT bisa diaplikasikan secara efektif untuk pendeteksian dini penyakit tanaman pada citra daun padi yang diharapkan mampu untuk menangani penyakit tersebut dengan

lebih akurat dan efektif, mengembangkan teknologi pertanian presisi yang dapat mendukung upaya peningkatan produktivitas padi secara berkelanjutan, mengurangi kerugian ekonomi, meningkatkan stabilitas produksi padi dan juga ikut berkontribusi mengurangi dampak negatif terhadap lingkungan.

1.2 Batasan dan Rumusan Masalah

Pada penelitian ini, data yang akan digunakan merupakan data sekunder citra daun tanaman padi yang berasal dari situs kaggle dan data primer citra daun tanaman padi yang akan diambil langsung pada sawah yang berada di daerah kebumen dan sragen, jawa tengah. Dari seluruh sumber data citra daun, dalam penelitian ini ada 6 kelas penyakit daun padi dan 1 kelas daun padi sehat dengan total 80.126 citra daun dimana kelas sehat sebanyak 17.924 citra daun, kelas *bacterial leaf blight* sebanyak 14.942 citra daun, kelas *brown spot* sebanyak 23.291 citra daun, kelas hispa sebanyak 12.463 citra daun, kelas *leaf blast* sebanyak 779 citra daun, kelas *leaf smut* sebanyak 389 citra daun dan kelas tungro sebanyak 10.338 citra daun. Berdasarkan pada uraian latar belakang yang telah dijelaskan pada sub-bab sebelumnya, maka batasan pada penelitian ini, sebagai berikut :

1. Citra daun yang digunakan sebagai objek penelitian dibatasi pada 6 kelas penyakit daun padi, yaitu *bacterial leaf blight*, *brown spot*, hispa, *leaf blast*, *leaf smut*, tungro dan 1 kelas daun padi sehat.
2. Menguji beberapa arsitektur CNN dan beberapa model ViT secara individu maupun hibrida.
3. Mengekstraksi data dengan fitur tekstur yaitu LBP dan GLCM.

Rumusan masalah pada penelitian ini, sebagai berikut :

1. Bagaimana efektivitas dari pendekatan hibrida yang menggabungkan CNN dan ViT dibandingkan dengan pendekatan pembelajaran mendalam tunggal dalam konteks akurasi dan kecepatan?

2. Bagaimana teknik *preprocessing* citra dalam meningkatkan performa model pembelajaran mendalam pada dataset citra daun padi yang terbatas dan bervariasi?
3. Bagaimana pengaruh parameter seperti *learning rate*, *batch size*, *epoch*, resolusi gambar, *optimizer*, *activation function*, *pooling layer*, *splitting data* terhadap hasil deteksi?

1.3 Tujuan Penelitian

Berdasarkan pada rumusan masalah yang telah diuraikan, tujuan penelitian yang ingin dicapai dari penelitian ini adalah :

1. Mengembangkan sebuah model hibrida yang mengintegrasikan CNN dan ViT untuk mendeteksi penyakit pada citra daun padi. Model ini dirancang untuk menggabungkan keunggulan kedua teknik dalam pembelajaran mendalam, guna meningkatkan akurasi dan efisiensi deteksi penyakit dari citra daun padi. Serta mengevaluasi akurasi dan kecepatan model hibrida dalam mendeteksi berbagai jenis penyakit pada daun padi, serta membandingkannya dengan model pembelajaran mendalam yang berbasis tunggal.
2. Mengoptimalkan teknik *preprocessing* citra yang digunakan sebelum penerapan model pembelajaran mendalam. Hal ini meliputi pengembangan atau peningkatan metode augmentasi citra, ekstraksi fitur dan teknik lain yang relevan untuk meningkatkan kualitas data masukan sehingga dapat mendukung performa model yang optimal.
3. Mengidentifikasi dan mencari kombinasi optimal dari parameter-parameter tersebut untuk mencapai hasil deteksi yang lebih akurat dan efisien, guna membantu dalam mengoptimalkan arsitektur dan pengaturan model deteksi objek.

1.4 Kontribusi dan Manfaat Penelitian

Sebuah penelitian dapat dikatakan baik apabila memiliki manfaat dan kontribusi. Kontribusi penelitian yang akan dilakukan, sebagai berikut :

1. Dari sisi keilmuan, penelitian ini memberikan kontribusi penting dalam literatur ilmiah mengenai penggunaan teknologi pembelajaran mendalam untuk aplikasi agrikultural. Melalui pendekatan hibrida menggunakan CNN dan ViT, penelitian ini membuka jalan untuk pengembangan metode baru yang dapat mengatasi kelemahan dari teknik-teknik sebelumnya, seperti peningkatan dalam akurasi dan efisiensi deteksi penyakit tanaman dari citra.
2. Dari sisi agrikultur, penelitian ini memungkinkan penanganan penyakit padi yang lebih tepat sasaran berkat deteksi dini dan akurat mengurangi biaya juga dampak lingkungan serta membantu meningkatkan produktivitas tanaman dengan mengidentifikasi dan mengelola penyakit sebelum berdampak luas pada hasil panen.

Penelitian ini diharapkan mampu memberikan manfaat untuk masyarakat agar dapat menyediakan makanan yang lebih sehat dan aman dengan meningkatkan kontrol terhadap penyakit tanaman. Dari segi sosial dan ekonomi, efisiensi yang ditawarkan oleh teknologi baru ini dapat mengurangi kerugian finansial akibat penyakit tanaman, sekaligus mengoptimalkan penggunaan sumber daya manusia yang tidak hanya mengurangi biaya operasional bagi petani tetapi juga meningkatkan keuntungan dengan memastikan kualitas dan jumlah produksi yang lebih tinggi. Selain itu juga bermanfaat untuk lingkungan, yaitu mendukung praktik pertanian yang lebih berkelanjutan dengan mengoptimalkan penggunaan sumber daya alam dan mengurangi dampak negatif pertanian terhadap lingkungan.

BAB II

TELAAH PUSTAKA

2.1 Citra Digital

Citra digital adalah representasi visual dari objek yang ditangkap melalui sensor elektronik atau dihasilkan oleh komputer sebagai data numerik yang disimpan dalam format file digital. Citra ini terdiri dari piksel, yaitu titik-titik kecil yang memiliki nilai warna dan kecerahan tertentu. Setiap piksel pada citra digital merepresentasikan warna dan intensitas cahaya pada titik tertentu dari objek yang difoto atau digambar.

$$f(x, y) = \begin{bmatrix} f(0,0) & f(0,1) & f(0,2) & \dots & f(0,y) \\ f(1,0) & f(1,1) & f(1,2) & \dots & f(1,y) \\ f(2,0) & f(2,1) & f(2,2) & \dots & f(2,y) \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ f(x,0) & f(x,1) & f(x,2) & \dots & f(x,y) \end{bmatrix}$$

Gambar 2.1 Matriks Citra

2.1.1. Komponen Citra Digital

1. Piksel, merupakan unit dasar sebuah citra digital, ukuran dan jumlah piksel menentukan resolusi citra.
2. Resolusi, menunjukkan detail citra yang diukur dalam piksel per inci (ppi). Semakin tinggi resolusi, semakin detail gambar yang dihasilkan.
3. Format File, citra digital dapat disimpan dalam berbagai format file seperti JPEG, PNG, GIF, dan TIFF. Masing-masing memiliki karakteristik kompresi dan penggunaan yang berbeda.

2.1.2. Elemen Citra Digital

1. Warna, sebagai persepsi yang ditangkap sistem visual terhadap panjang gelombang cahaya yang dipantulkan oleh objek.
2. Bentuk, adalah properti intrinsik dari objek 3 dimensi dengan pengertian bahwa bentuk merupakan properti intrinsik utama untuk sistem visual manusia.
3. Tekstur, dicirikan sebagai distribusi spasial dari derajat keabuan di dalam sekumpulan piksel-piksel yang bertetangga. Tekstur adalah sifat-sifat atau karakteristik yang dimiliki oleh suatu daerah yang cukup besar, sehingga secara alami sifat-sifat tadi dapat berulang dalam daerah tersebut. Tekstur adalah keteraturan pola-pola tertentu yang terbentuk dari susunan piksel-piksel dalam citra digital. Informasi tekstur dapat digunakan untuk membedakan sifat-sifat permukaan suatu benda dalam citra yang berhubungan dengan kasar dan halus, juga sifatsifat spesifik dari kekasaran dan kehalusan permukaan tadi, yang sama sekali terlepas dari warna permukaan tersebut.

2.2 Pengolahan Citra Digital

Pengolahan citra digital adalah teknik yang digunakan untuk memanipulasi citra digital agar dapat digunakan lebih efektif dalam berbagai aplikasi. Teknik ini melibatkan serangkaian operasi yang dilakukan pada citra untuk memperoleh hasil yang diinginkan, baik untuk analisis, peningkatan kualitas, atau kompresi citra. Berikut adalah beberapa konsep utama dan langkah-langkah dalam pengolahan citra digital :

1. Akuisisi Citra : Proses ini melibatkan pengambilan citra menggunakan perangkat seperti kamera digital atau scanner.
2. Pra-pemrosesan : Tahap ini bertujuan untuk memperbaiki kualitas citra dengan mengurangi distorsi atau noise.

3. *Segmentasi* : Proses pemisahan atau segmentasi objek dalam citra dari latar belakangnya.
4. *Feature Extraction* : Proses mengambil ciri-ciri yang terdapat pada objek di dalam citra. Pada proses ini objek di dalam citra mungkin perlu dideteksi seluruh tepinya, lalu menghitung properti-properti objek yang berkaitan sebagai ciri. Beberapa proses ekstraksi ciri mungkin perlu mengubah citra masukan sebagai citra biner, melakukan penipisan pola, dan sebagainya.
5. *Classification* : Proses mengelompokkan objek ke dalam kelas yang sesuai.
6. *Feature Selection* : Proses memilih ciri pada suatu objek agar diperoleh ciri yang optimum, yaitu ciri yang dapat digunakan untuk membedakan suatu objek dengan objek lainnya.
7. *Learning* : Proses belajar membuat aturan klasifikasi sehingga jumlah kelas yang tumpang tindih dibuat sekecil mungkin.

2.3 Metode *Threshold*

Metode *threshold* adalah sebuah pendekatan yang digunakan dalam berbagai bidang, mulai dari ilmu komputer dan matematika hingga ilmu sosial dan manajemen, untuk mengambil keputusan atau melakukan klasifikasi berdasarkan pada suatu ambang batas tertentu yang ditentukan sebelumnya. Metode ini sangat bergantung pada penggunaan ambang batas atau nilai tertentu yang digunakan untuk memisahkan dua kelompok atau kategori yang berbeda. Metode ini tergantung pada seleksi nilai batas yang tepat, yang ditentukan berdasarkan sifat data atau masalah yang dihadapi. Nilai batas tersebut digunakan untuk memisahkan data ke dalam dua kategori atau lebih, tergantung pada kompleksitas masalah. Sebagai contoh, dalam pengenalan gambar, metode *threshold* bisa dipakai untuk memisahkan area hitam dan putih dalam sebuah citra dengan memanfaatkan nilai batas tertentu. Piksel dengan nilai di atas batas akan dianggap putih, sementara yang di bawahnya dianggap hitam. Metodenya mudah dimengerti dan diaplikasikan, dengan proses perhitungan dan penerapan batas yang relatif cepat. Metodenya juga

bisa disesuaikan dengan kebutuhan khusus dari data atau masalah yang dihadapi. Secara keseluruhan, metode *threshold* adalah pendekatan yang sederhana namun efektif untuk klasifikasi atau pengambilan keputusan berdasarkan pada nilai batas tertentu. Meskipun sederhana, metode ini bisa menjadi alat yang berharga dalam berbagai bidang dan masalah, terutama jika digunakan dengan hati-hati dan disesuaikan dengan karakteristik data yang ada.

2.4 Ekstraksi Fitur


Ekstraksi fitur adalah langkah kritis dalam pengolahan citra digital yang bertujuan untuk mengidentifikasi dan mengambil informasi penting atau karakteristik khas dari sebuah citra. Fitur-fitur ini digunakan untuk melakukan tugas seperti pengenalan pola, klasifikasi citra, dan analisis citra lebih lanjut. Fitur yang diekstrak bisa berupa warna, bentuk, tekstur, atau titik penting citra. Jenis Fitur dalam Ekstraksi Fitur, antara lain sebagai berikut :

1. **Fitur Warna** : Mencakup histogram warna, momen warna, dan statistik warna lainnya yang mencerminkan distribusi dan intensitas warna dalam citra.
2. **Fitur Bentuk** : Meliputi kontur, tepian, dan orientasi objek dalam citra. Fitur bentuk sering digunakan untuk mengidentifikasi objek dalam citra berdasarkan bentuknya.
3. **Fitur Tekstur** : Menangkap detail visual seperti kehalusan, kekasaran, atau pola berulang. Teknik ekstraksi fitur tekstur termasuk transformasi wavelet dan analisis co-occurrence matrix.

2.4.1. Local Binary Pattern

Local Binary Pattern (LBP) adalah metode deskripsi fitur yang digunakan dalam pengolahan citra untuk pengenalan pola dan deteksi objek. LBP telah menjadi salah satu teknik yang populer dalam berbagai aplikasi

pengolahan citra (Alwy et al., 2023). LBP adalah metode deskripsi fitur yang bekerja pada tingkat piksel dalam citra. Ide dasarnya adalah untuk mengekstraksi pola lokal dari piksel dengan membandingkan nilai intensitas piksel tetangga dengan nilai intensitas piksel pusat. Hasil dari ekstraksi LBP dapat dievaluasi dengan menggunakan berbagai metrik kinerja tergantung pada aplikasi tertentu, seperti akurasi pengenalan wajah atau deteksi objek. LBP adalah metode deskripsi fitur yang sederhana namun kuat dalam pengolahan citra, yang digunakan untuk mengekstraksi pola lokal dari citra untuk berbagai aplikasi seperti pengenalan pola, deteksi objek, dan analisis tekstur. Seperti ilustrasi pada



Gambar 2.2 Ekstraksi Fitur LBP


Setiap piksel dibandingkan dengan 8 nilai piksel disekelilingnya dengan mengurangi nilai piksel dengan pusat 3×3 , nilai-nilai negatif yang dihasilkan kemudian akan dikodekan dengan nilai 0, dan nilai-positif positif yang dihasilkan akan dikodekan dengan nilai 1. Setelah itu, menyusun 8 nilai biner yang menggunakan arah searah jarum jam atau sebaliknya dan merubah 8 bit biner kedalam nilai desimal untuk menggantikan nilai piksel pada pusat citra, yang dimulai dari salah bagian atas kiri.

2.4.2. *Grey Level Co-occurrence Matrix*

Grey Level Co-occurrence Matrix (GLCM) adalah metode yang digunakan dalam pengolahan citra untuk mengekstraksi informasi tekstur dari sebuah citra. Ini adalah alat analisis yang kuat untuk menggambarkan hubungan spasial antara pasangan piksel dalam citra berdasarkan tingkat

keabuan atau intensitasnya. GLCM mengukur seberapa sering pasangan piksel dengan tingkat keabuan tertentu muncul bersamaan dalam citra. Matriks GLCM adalah matriks dua dimensi yang menunjukkan frekuensi kemunculan setiap pasangan tingkat keabuan dalam citra.

GLCM digunakan untuk mengekstraksi fitur tekstur dari citra, yang penting dalam berbagai aplikasi seperti pengenalan pola, klasifikasi citra, dan deteksi objek. Hasil dari analisis GLCM dapat dievaluasi menggunakan berbagai metrik, seperti akurasi klasifikasi, ketepatan deteksi, atau kesesuaian dengan aplikasi tertentu. GLCM adalah alat yang kuat untuk mengekstraksi fitur tekstur dari citra yang digunakan dalam berbagai aplikasi pengolahan citra untuk menganalisis dan mengklasifikasikan tekstur citra dengan cermat. (Huda et al., 2022).



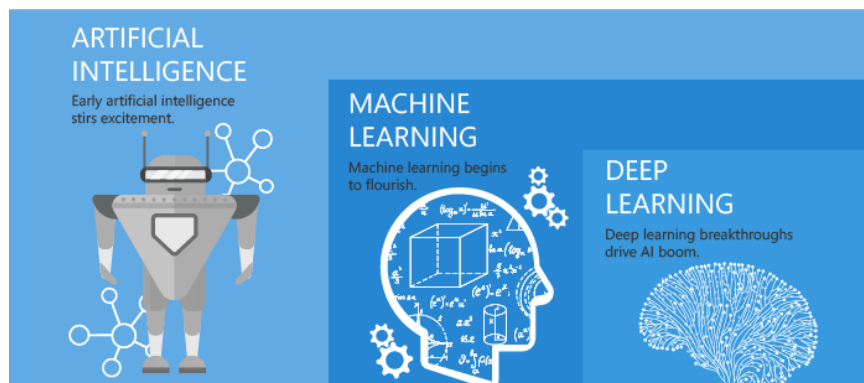
Gambar 2.3 Sudut Orientasi Arah GLCM

2.5 *Artificial Intelligence*

Artificial Intelligence (AI) adalah cabang ilmu komputer yang berfokus pada pengembangan sistem komputer yang dapat melakukan tugas yang biasanya memerlukan kecerdasan manusia. Tujuan utama dari AI adalah untuk menciptakan mesin yang dapat berpikir, belajar, dan bertindak seperti manusia, atau bahkan lebih baik dari manusia dalam beberapa kasus. AI merujuk pada kemampuan mesin untuk meniru kecerdasan manusia, seperti pemecahan masalah, pemahaman bahasa alami, pengambilan keputusan, dan belajar. Didalam AI terdapat *Machine Learning*

(ML), dimana ML dapat mempelajari data yang lebih kompleks. Lebih dalam lagi terdapat *Deep Learning* (DL) yaitu ML yang menggunakan jaringan saraf tiruan dengan banyak lapisan untuk memahami dan memproses data yang kompleks.

AI adalah bidang yang luas dan berkembang pesat dalam ilmu komputer yang berfokus pada pengembangan sistem yang mampu melakukan tugas-tugas yang sebelumnya hanya dapat dilakukan oleh manusia. AI memiliki potensi besar untuk mengubah banyak aspek kehidupan manusia dan terus menjadi fokus penelitian dan pengembangan di berbagai industri.




Gambar 2.4 Lapisan AI

2.5.1. *Deep Learning*

DL adalah subbidang dari ML yang menggunakan arsitektur jaringan saraf tiruan berlapis (deep neural networks) untuk memahami dan memproses data yang kompleks. DL telah menjadi salah satu teknik yang paling dominan dalam AI karena kemampuannya untuk menangani masalah yang sangat kompleks dan data yang besar. DL adalah bidang yang luas dan berkembang dalam ML yang menggunakan arsitektur jaringan saraf tiruan berlapis untuk memodelkan dan memproses data yang kompleks. DL telah menghasilkan kemajuan besar dalam berbagai aplikasi AI dan diperkirakan akan terus menjadi fokus penelitian dan pengembangan di masa depan.

2.6 *Artificial Neural Network*

Artificial Neural Network (ANN), atau sering disebut *Neural Network* (NN), adalah model matematika yang terinspirasi dari struktur dan fungsi jaringan saraf biologis manusia. ANN terdiri dari sejumlah besar unit pemrosesan sederhana yang disebut neuron, yang terorganisir dalam lapisan-lapisan dan terhubung melalui koneksi-koneksi yang memiliki bobot. ANN adalah model matematika yang terinspirasi dari struktur dan fungsi jaringan saraf biologis manusia, yang telah menjadi fokus utama dalam ML dan AI untuk memecahkan berbagai masalah kompleks dalam berbagai bidang.



Gambar 2.5 Arsitektur Artificial Neural Network

2.7 *Convolutional Neural Network*

CNN adalah jenis jaringan saraf tiruan yang umumnya digunakan dalam pemrosesan gambar dan penglihatan komputer. CNN sangat efektif untuk mengidentifikasi pola dalam data yang memiliki struktur spasial dan temporal, seperti gambar, video, dan data audio. Arsitektur CNN biasanya terdiri dari tiga jenis lapisan utama :

1. Lapisan Konvolusi (*Convolutional Layer*) : Lapisan ini merupakan inti dari CNN. Lapisan ini menggunakan filter atau kernel yang berpindah-pindah di atas gambar masukan, menghitung produk titik antara nilai-nilai piksel

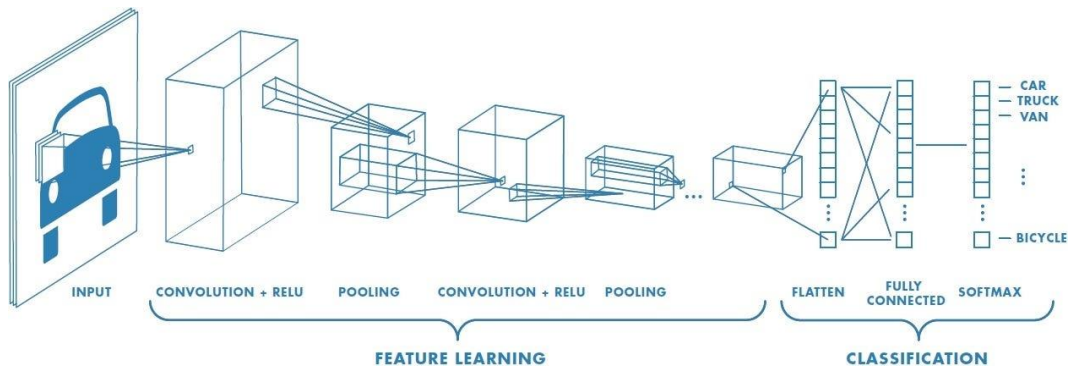
gambar dan bobot filter, dan menghasilkan peta fitur (*feature map*). Peta fitur ini menangkap informasi penting seperti tepi, sudut, dan tekstur dalam gambar.

2. Lapisan Pooling (*Pooling Layer*) : Lapisan ini bertujuan untuk mengurangi dimensi dari peta fitur yang dihasilkan oleh lapisan konvolusi. Pooling dapat berupa *max pooling* (mengambil nilai maksimal dalam suatu jendela) atau *average pooling* (menghitung rata-rata nilai dalam suatu jendela). Hal ini membantu mengurangi jumlah parameter dan komputasi dalam jaringan.
3. Lapisan Terhubung Penuh (*Fully Connected Layer*) : Setelah beberapa lapisan konvolusi dan pooling, peta fitur biasanya diubah menjadi vektor satu dimensi yang kemudian diproses oleh lapisan terhubung penuh. Lapisan ini mirip dengan lapisan yang ada pada jaringan saraf tiruan tradisional (ANN) dan digunakan untuk mengklasifikasikan gambar berdasarkan fitur yang telah diekstraksi dan didownsampling oleh lapisan sebelumnya.

CNN sering menggunakan fungsi aktivasi non-linear seperti ReLU (*Rectified Linear Unit*) setelah setiap lapisan konvolusi. Fungsi ReLU membantu menambahkan non-linearitas ke dalam model, yang memungkinkan jaringan untuk belajar lebih efektif dan mengatasi masalah linearitas.

CNN dilatih menggunakan metode backpropagation, serupa dengan jaringan saraf tiruan lainnya. Proses ini melibatkan penyesuaian bobot filter dalam lapisan konvolusi dan bobot dalam lapisan terhubung penuh berdasarkan kesalahan antara output yang dihasilkan dan label sebenarnya. Proses pelatihan bertujuan untuk meminimalkan fungsi kerugian, seperti *cross-entropy loss*, yang mengukur seberapa jauh prediksi dari nilai aktual (K. et al., 2023).

CNN telah menjadi fondasi dalam banyak aplikasi penglihatan komputer modern, seperti pengenalan wajah, deteksi objek, dan analisis citra medis, karena kemampuannya yang kuat dalam mengenali dan mengklasifikasikan gambar dengan presisi tinggi.



Gambar 2.6 Arsitektur CNN

2.8 Vision Transformer

ViT adalah model yang menerapkan prinsip-prinsip Transformer, yang awalnya dikembangkan untuk pemrosesan bahasa alami (NLP), ke dalam bidang penglihatan komputer. Diperkenalkan oleh *Google Research*, ViT menunjukkan bahwa arsitektur berbasis Transformer dapat mencapai atau bahkan melampaui performa model-model berbasis konvolusi tradisional pada berbagai tugas penglihatan komputer, seperti klasifikasi gambar, tanpa memerlukan mekanisme spesifik untuk mengolah data spasial.

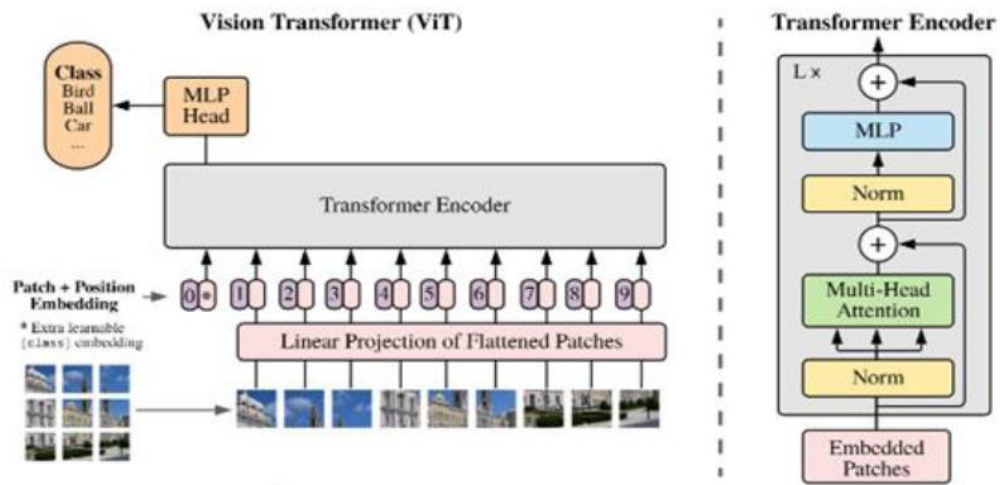
Secara fundamental, ViT memperlakukan gambar sebagai sekuen dari *patch* (bagian kecil dari gambar) dan memprosesnya dengan cara yang mirip dengan bagaimana Transformer mengolah token dalam NLP. Berikut adalah komponen utama dari ViT :

1. *Patching dan Embedding* : Gambar masukan dibagi menjadi sejumlah kecil *patch*. Misalnya, gambar berukuran 224x224 bisa dibagi menjadi 16x16 *patch*, sehingga menghasilkan 196 *patch*. Setiap *patch* diubah menjadi vektor datar dan kemudian diproses melalui lapisan embedding untuk menghasilkan representasi yang lebih kaya. Biasanya, *embedding* ini diikuti oleh penambahan posisi embedding untuk mempertahankan informasi posisi relatif antar *patch*.

2. *Encoder Transformer* : Setelah *patch* di-embed, *sequence* dari *embedded patches* diolah oleh *stack* dari *Transformer encoder layers*. Setiap layer *Transformer* terdiri dari dua sub-layer utama :
 - 1) *Multi-Head Self-Attention* (MHSA) : Layer ini memungkinkan model untuk menimbang secara adaptif berbagai bagian dari input berdasarkan informasi dari seluruh *sequence*, memungkinkan jaringan untuk belajar hubungan jarak jauh antar *patch*.
 - 2) *Feed-Forward Network* (FFN) : Setelah attention, output dari MHSA diproses oleh sebuah jaringan saraf sederhana yang diterapkan secara per-elemen pada *sequence*.
3. *Layer Normalization* dan *Residual Connections* : Setiap sub-layer dalam *Transformer encoder* dilengkapi dengan *residual connection* diikuti oleh *layer normalization*, yang membantu dalam stabilisasi pembelajaran dan memungkinkan training model yang dalam.
4. *Classification Head* : Setelah melewati semua *encoder layers*, hanya representasi dari token klasifikasi ('[CLS]') yang biasanya digunakan untuk tugas-tugas klasifikasi. Representasi ini diproses oleh satu atau beberapa lapisan terhubung penuh untuk menghasilkan prediksi akhir.

Berbeda dengan CNN yang menggunakan filter lokal dan pooling untuk memproses gambar, ViT menggunakan self-attention global yang memungkinkan model untuk menangkap hubungan antar patch dari seluruh gambar, potensial untuk menangkap dependensi yang lebih luas dan lebih kompleks dalam data.

ViT menandai langkah penting dalam penelitian penglihatan komputer dengan memperluas penerapan Transformer ke luar domain NLP. Dengan kemampuan untuk memodelkan interaksi kompleks antar bagian dari gambar, ViT menawarkan alternatif yang kuat dan sering kali lebih efisien untuk arsitektur CNN dalam berbagai tugas penglihatan komputer (Abdullah et al., 2024).



Gambar 2.7 Arsitektur ViT

2.9 Pendekatan Hibrida

Pendekatan hibrida dalam konteks pengolahan data dan kecerdasan buatan mengacu pada penggunaan kombinasi teknik, algoritma, atau model dari berbagai paradigma atau disiplin untuk menghasilkan solusi yang lebih baik atau lebih efektif daripada menggunakan salah satu pendekatan saja (Alshammari et al., 2022).

Pendekatan hibrida mencoba memanfaatkan kekuatan berbagai paradigma atau metode, seperti ML, DL, atau logika berbasis aturan. Tujuannya untuk meningkatkan kinerja, keakuratan, atau efisiensi solusi dengan mengintegrasikan berbagai teknik atau algoritma yang berbeda. Pendekatan hibrid memungkinkan fleksibilitas dalam merancang solusi yang disesuaikan dengan kebutuhan spesifik dari masalah yang dihadapi. Jenis pendekatan hibrida, antara lain :

1. Kombinasi Model: Menggabungkan beberapa model dari berbagai paradigma, seperti menggabungkan model ML dengan logika berbasis aturan.
2. Kombinasi Algoritma: Menggabungkan beberapa algoritma dari paradigma yang sama atau berbeda, seperti menggabungkan algoritma pengklasifikasi dari ML dengan algoritma optimasi heuristik.

3. Kombinasi Teknik: Menggabungkan beberapa teknik pengolahan data atau praproses, seperti menggabungkan teknik ekstraksi fitur dari DL dengan teknik pemrosesan sinyal klasik.

Pendekatan hibrida memanfaatkan keunggulan dari berbagai pendekatan untuk meningkatkan kinerja atau efektivitas solusi. Dapat disesuaikan dengan berbagai jenis masalah atau kebutuhan spesifik, karena dapat mengintegrasikan berbagai teknik atau algoritma dan dapat menghasilkan solusi yang lebih baik daripada menggunakan satu pendekatan saja, terutama dalam masalah yang kompleks atau tidak terstruktur.

Pendekatan hibrida adalah pendekatan yang kuat dan fleksibel dalam kecerdasan buatan dan pengolahan data, yang memanfaatkan kekuatan berbagai paradigma, teknik, atau algoritma untuk menghasilkan solusi yang lebih baik atau lebih efektif dalam menangani masalah yang kompleks atau tidak terstruktur.

2.10 *Confusion Matrix*

Confusion matrix adalah sebuah tabel yang sering digunakan untuk menggambarkan kinerja model klasifikasi pada set data tes dimana nilai-nilai sebenarnya diketahui. Ini sangat penting dalam bidang ML untuk menganalisis seberapa baik model dapat memprediksi kategori atau kelas dari data. Elemen – elemen dalam *confusion matrix*, diantaranya : *True Positives* (TP) adalah jumlah kasus dimana model secara benar memprediksi kelas positif sebagai positif, *True Negatives* (TN) adalah jumlah kasus dimana model secara benar memprediksi kelas negatif sebagai negatif, *False Positives* (FP) adalah jumlah kasus dimana model salah memprediksi kelas negatif sebagai positif, *False Negatives* (FN) adalah jumlah kasus dimana model salah memprediksi kelas positif sebagai negatif. *Confusion matrix* membantu dalam menganalisis kekuatan dan kelemahan model klasifikasi, memungkinkan peneliti dan pengembang untuk membuat penyesuaian pada model untuk meningkatkan kinerjanya.

2.11 Penyakit Daun Padi

Penyakit daun padi adalah masalah umum dalam pertanian padi yang bisa mempengaruhi hasil panen secara signifikan. Penyakit ini dapat disebabkan oleh berbagai agen patogen seperti jamur, bakteri, virus, dan terkadang oleh kekurangan nutrisi atau kondisi abiotik. Berikut adalah penjelasan rinci mengenai beberapa penyakit daun padi yang paling umum, penyebabnya, gejala yang ditimbulkan, serta metode pengendalian dan pencegahannya:

1. Hawar Daun Bakteri (*Bacterial Leaf Blight*)

- Penyebab : Bakteri *Xanthomonas oryzae* pv. *oryzae*
- Gejala : Daun padi menguning dan mati mulai dari ujungnya. Infeksi parah menyebabkan kerusakan luas pada daun, yang secara signifikan dapat mengurangi hasil panen.
- Pengendalian : Penggunaan varietas padi yang resisten terhadap penyakit, praktik budidaya yang baik seperti rotasi tanaman, serta penggunaan fungisida dan bakterisida yang tepat.



Gambar 2.5 *Bacterial Leaf Blight*

2. Hawar Daun (*Leaf Blast*)

- Penyebab : Jamur *Magnaporthe oryzae*
- Gejala : Gejala awal termasuk bercak-bercak bulat kecil yang berwarna abu-abu atau putih dengan tepi coklat pada daun. Bercak tersebut dapat membesar dan menyebabkan daun mati.
- Pengendalian : Penerapan fungisida, penggunaan varietas tahan, dan menghindari kelembaban yang berlebihan di lapangan yang dapat memfasilitasi penyebaran jamur.



Gambar 2.6 *Leaf Blast*

3. Penyakit Bergaris Coklat (*Brown Spot*)

- Penyebab : Jamur *Helminthosporium oryzae* atau *Cochliobolus miyabeanus*
- Gejala : Bercak kecil berwarna coklat kemerahan pada daun yang dapat menyebar dan menyebabkan daun mengering. Infeksi berat dapat mempengaruhi kualitas biji.
- Pengendalian : Pemupukan yang seimbang, terutama menghindari kekurangan silika dan potasium, serta penggunaan fungisida yang tepat.



Gambar 2.7 *Brown Spot*

4. Penyakit Tungro

- Penyebab : Virus Tungro yang tersebar melalui serangga vektor seperti wereng hijau (*Nephotettix spp*)
- Gejala : Daun menjadi kuning dan pertumbuhan tanaman terhambat. Daun muda bisa berwarna merah muda dan terdistorsi.
- Pengendalian: Pengendalian wereng hijau dengan insektisida, menggunakan varietas tahan, dan menghindari penanaman yang terlalu rapat.



Gambar 2.8 Tungro

5. Penyakit Hispa

- Penyebab : bakteri *Xanthomonas oryzae* pv. *oryzicola*.
- Gejala : Gejala awal biasanya terlihat sebagai garis-garis atau bintik-bintik berwarna gelap pada daun padi, ubang-lubang kecil yang berwarna kuning atau coklat mungkin juga muncul di tengah-tengah daun, Daun padi yang terinfeksi dapat mengalami kebengkokan atau melengkung ke atas atau ke bawah.
- Pengendalian : Menjaga kebersihan lahan, mengelola gulma, dan meminimalkan cedera mekanis pada tanaman dapat membantu mencegah infeksi bakteri.



Gambar 2.9 Hispa

6. Penyakit Lempeng (*Leaf Smut*)

- Penyebab : Jamur *Ustilaginoidea virens*
- Gejala : Pembentukan struktur spora besar berwarna hijau kekuningan pada bunga padi, yang kemudian menjadi hitam dan berdebu.
- Pengendalian : Penggunaan fungisida dan praktek budidaya yang tepat untuk mengurangi kelembaban.



Gambar 2.10 *Leaf Smut*

Pengelolaan penyakit pada tanaman padi memerlukan pendekatan terpadu, melibatkan baik praktek budidaya yang baik, pemilihan varietas yang tepat, dan penggunaan produk perlindungan tanaman untuk mencegah kerugian hasil dan memastikan stabilitas produksi pangan.

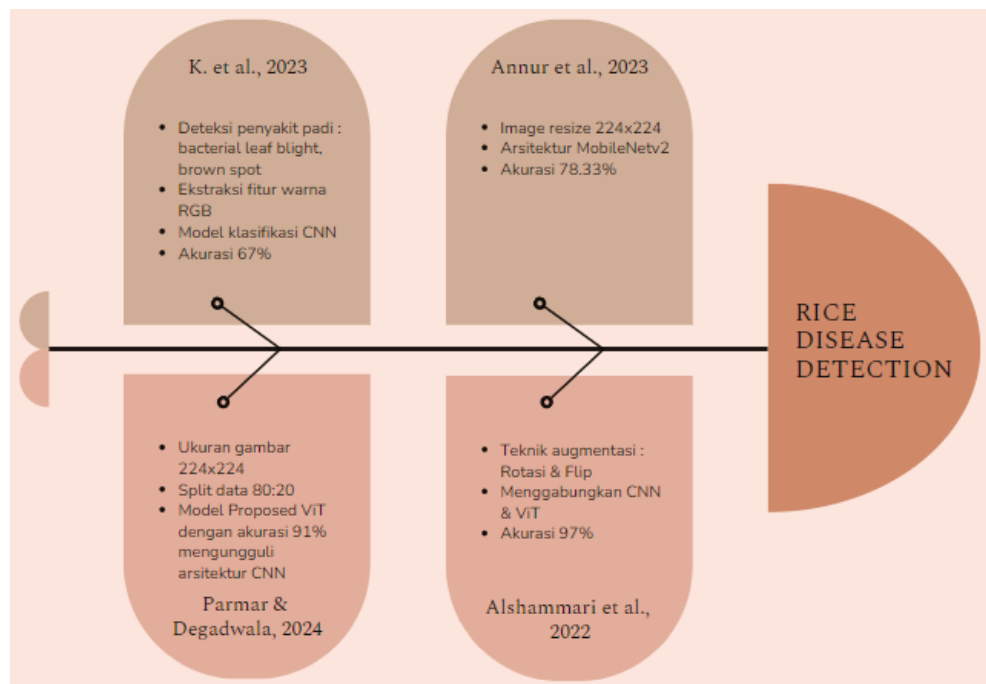
2.12 Peta Jalan Penelitian

Peta Jalan penelitian yang terkait dengan topik penelitian yang sudah dilakukan oleh peneliti dalam periode tahun 2022-2024. Pada tahun 2022, untuk penelitian mengenai LBP, (Rachmad et al., 2022) berhasil membuat model untuk klasifikasi penyakit daun jagung menggunakan ekstraksi fitur LBP. Penelitian mengenai Hibrida CNN ViT oleh (Alshammari et al., 2022) untuk mendeteksi penyakit zaitun menggunakan CNN dan digabungkan dengan ViT, masih dengan tahun yang sama (Rajaraman et al., 2022) mendeteksi penyakit tuberculosis dengan menggabungkan arsitektur CNN dengan ViTB16, ViTB32, ViTL16 dan ViTL32. Penelitian mengenai GLCM yang dilakukan oleh (Huda et al., 2022) untuk mendeteksi penyakit daun padi menggunakan ekstraksi fitur GLCM.

Periode penelitian pada tahun 2023 antara lain mengenai LBP yang dilakukan oleh (Alwy et al., 2023) untuk mengklasifikasi penyakit pada padi menggunakan ekstraksi fitur LBP dan GLCM. Penelitian mengenai CNN yang dilakukan oleh (P. K. et al., 2023) untuk mendeteksi penyakit tanaman padi

menggunakan algoritma CNN. Hibrida CNN dan ViT juga dilakukan di tahun yang sama oleh (Dutta et al., 2023) untuk mendeteksi penyakit retina menggunakan CNN dan ViT. (Annur et al., 2023) melakukan penelitian mengenai tingkat keparahan penyakit tanaman padi. Penelitiann mengenai ViT banyak dilakukan ditahun yang sama diantaranya adalah penelitian yang dilakukan oleh (Sun et al., 2023) berupa identifikasi penyakit daun tebu menggunakan ViT. Penelitian yang dilakukan oleh (Agusta & Kaswidjanti, 2023) untuk mengidentifikasi penyakit pada daun tomat GLCM digunakan untuk ekstraksi fitur tekstur.

Penelitian mengenai penyakit daun padi yang terbaru pada tahun 2024 dilakukan oleh (Sunandar & Sutopo, 2024) menggunakan ANN. Penelitian terbaru mengenai tingkat keparahan penyakit padi dilakukan oleh (Lamba et al., 2023) menggunakan CNN sebagai ekstraksinya dan untuk mengklasifikasi tingkat keparahan penyakit blas pada padi. Penelitian mengenai GLCM dilakukan oleh (Nancy & Kiran, 2024) untuk mendeteksi penyakit daun timun menggunakan GLCM sebagai ekstraksi fitur. Penelitian terbaru mengenai ViT dilakukan oleh (Barman et al., 2024) untuk penyakit tanaman pada daun tomat.



Gambar 2.12 Fishbone Rice Disease Detection

2.13 Kajian Penelitian

Beberapa penelitian terkait deteksi penyakit tanaman telah dilakukan peneliti terdahulu. kajian penelitian mengenai deteksi penyakit tanaman dengan objek citra daun padi dijelaskan berikut.

(Alshammari, Gasmi, Ltaifa, Krichen, Ammar & Mahmood, 2022) *Olive Disease Classification Based on Vision Transformer and CNN Models*

Penelitian ini mengusulkan model DL hibrida untuk klasifikasi penyakit daun zaitun. Metode penelitian meliputi augmentasi data dengan *median noise filtering*, ekstraksi fitur menggunakan kombinasi model CNN dan ViT, serta penerapan lapisan pooling dan *dropout* untuk mencegah *overfitting* sebelum klasifikasi menggunakan fungsi *softmax*. Dataset terdiri dari 3.400 gambar daun zaitun yang dikategorikan sebagai sehat, terinfeksi *Aculus olearius*, dan terinfeksi *olive peacock spot*, dengan evaluasi kinerja menggunakan metrik seperti akurasi, presisi, *recall*, dan *F1-score*. Hasil penelitian menunjukkan model ViT mencapai akurasi 96% untuk klasifikasi biner dan 95% untuk klasifikasi multikelas, sementara model hibrida ViT + VGG-16 mencapai akurasi tertinggi 97% dan 96% untuk masing-masing klasifikasi. Kelebihan penelitian ini adalah penggunaan teknik augmentasi data yang efektif, kombinasi model CNN dan ViT yang meningkatkan akurasi, dan metode regularisasi untuk mengurangi *overfitting*. Kekurangan spesifik mencakup kompleksitas model hibrida, kebutuhan data pelatihan besar, sumber daya komputasi tinggi, dan potensi *overfitting* jika augmentasi data tidak memadai. Kekurangan dari gap penelitian termasuk kurangnya penelitian tentang dampak kualitas gambar buruk, keterbatasan studi kasus pada daun zaitun, dan tidak adanya analisis mendalam tentang kesalahan klasifikasi. *Future work* mencakup penerapan model pada jenis tanaman lain, pengumpulan lebih banyak gambar penyakit daun zaitun, penggunaan teknik

augmentasi data canggih seperti GANs, dan pengembangan model interpretabilitas untuk ViT. Penelitian ini menunjukkan bahwa model DL hibrida yang diusulkan memberikan hasil yang sangat baik dan dapat dikembangkan lebih lanjut untuk aplikasi nyata dalam deteksi penyakit tanaman (Alshammari et al., 2022).

(Huda, Setiaji & Hidayat, 2022) IMPLEMENTASI GRAY LEVEL COOCCURRENCE MATRIX (GLCM) UNTUK KLASIFIKASI PENYAKIT DAUN PADI

Penelitian ini menggunakan metode GLCM dan klasifikasi *K-Nearest Neighbor* (KNN) untuk mengklasifikasikan penyakit daun padi, seperti *bacterial leaf blight*, *leaf smut*, dan *brown spot*. Data yang digunakan adalah 240 gambar dari UCI Machine Learning Repository, dengan 210 gambar untuk data latih dan 30 gambar untuk data uji. Proses ekstraksi fitur menggunakan GLCM untuk memperoleh nilai-nilai *contrast*, *correlation*, *energy*, dan *homogeneity*, kemudian klasifikasi dilakukan dengan KNN. Hasil penelitian menunjukkan bahwa pengujian pertama dengan perbandingan data training dan data uji sebesar 88:12 menghasilkan akurasi 93,3%, sementara pengujian kedua dengan perbandingan 50:50 menghasilkan akurasi 66,6%. Kelebihan metode ini adalah akurasi yang tinggi pada pengujian pertama dan kemampuannya dalam mengidentifikasi ciri tekstur daun padi. Namun, kelemahan terletak pada penurunan akurasi saat perbandingan data latih dan data uji berubah serta kebutuhan perangkat lunak khusus yang belum ramah bagi petani. Penelitian ini masih memiliki gap dalam penerapan yang mudah di lapangan dan disarankan untuk *future work* mengembangkan API berbasis Android atau Web untuk mempermudah penggunaannya oleh petani (Huda et al., 2022).

(Alwy, Wahid, Ag & Fakhri, 2023) Klasifikasi Penyakit Pada Padi Dengan Ekstraksi Fitur LBP dan GLCM

Penelitian ini mengusulkan klasifikasi penyakit pada padi dengan menggunakan ekstraksi fitur LBP dan GLCM. Metode yang digunakan meliputi empat tahapan utama: akuisisi citra, preprocessing, segmentasi, ekstraksi fitur, dan klasifikasi. Pada tahap akuisisi citra, dataset yang digunakan berjumlah 120 citra daun padi yang terdiri dari tiga jenis penyakit: *Brown Spot*, *Hispa*, dan *Leaf Blast*. Pada tahap segmentasi, nilai warna pada ruang biru dikonversi menjadi nilai biner dan dilakukan operasi morfologi untuk menghilangkan noise menggunakan metode *area open*. Ekstraksi fitur dilakukan dengan menggunakan LBP dan GLCM, yang melibatkan parameter seperti *contrast*, *correlation*, *energy*, dan *homogeneity*. Pada tahap klasifikasi, digunakan algoritma *Decision Tree* yang menghasilkan tingkat akurasi sebesar 90%. Kelebihan dari penelitian ini adalah kemampuannya untuk mendeteksi penyakit pada padi dengan akurasi yang tinggi dan penggunaan metode yang efisien dalam ekstraksi fitur dan klasifikasi. Namun, kekurangannya terletak pada kesalahan klasifikasi yang masih terjadi pada beberapa citra uji, terutama karena kesamaan pola atau karakteristik antara penyakit yang berbeda. Penelitian ini mengidentifikasi gap penelitian dalam hal peningkatan akurasi klasifikasi dan pengurangan kesalahan segmentasi. *Future work* yang diusulkan mencakup pengembangan metode yang lebih canggih untuk segmentasi dan ekstraksi fitur serta peningkatan jumlah dataset untuk pelatihan model agar hasil klasifikasi lebih akurat dan andal (Alwy et al., 2023).

Penelitian yang berhasil dilakukan oleh peneliti terdahulu terangkum pada Tabel 2.1.

Tabel 2.1 Kajian Penelitian Terdahulu

Subjek Penelitian	Peneliti, Tahun	Metode Penelitian	Kelebihan, Kekurangan, Gap Penelitian, <i>Future Work</i>
Pengembangan Model	Alshammari, Gasmi, Ltaifa, Krichen, Ammar & Mahmood, 2022	<ol style="list-style-type: none"> 1. Penerapan <i>median noise filtering</i> untuk meningkatkan kualitas gambar setelah proses augmentasi data. 2. Teknik augmentasi data meliputi rotasi, pemotongan, dan <i>flipping</i> gambar. 3. Menggabungkan model CNN dengan ViT untuk ekstraksi fitur. 4. CNN digunakan untuk menangkap representasi spasial, sementara ViT digunakan untuk memahami ketergantungan global dalam gambar. 5. Menggunakan model DL seperti <i>AlexNet</i>, VGG-16, VGG-19, dan ViT untuk klasifikasi gambar daun zaitun. 6. Penggunaan lapisan <i>pooling</i> dan <i>dropout</i> untuk menghindari <i>overfitting</i> sebelum menerapkan 	<p>Kelebihan :</p> <ol style="list-style-type: none"> 1. Kombinasi model CNN dan ViT meningkatkan akurasi klasifikasi. 2. Model hibrida menunjukkan kinerja superior dibandingkan model individual. <p>Kekurangan :</p> <p>Fokus hanya pada penyakit daun zaitun, tidak diuji pada jenis tanaman lain.</p> <p>Gap Penelitian :</p> <ol style="list-style-type: none"> 1. Kurangnya penelitian tentang dampak kualitas gambar yang sangat buruk pada performa model. 2. Keterbatasan studi kasus yang hanya fokus pada daun zaitun. 3. Tidak adanya analisis mendalam tentang kesalahan klasifikasi model

		<p>fungsi <i>softmax</i> untuk klasifikasi.</p> <p>7. Menggunakan <i>k-fold cross-validation</i> untuk menghindari masalah distribusi data yang tidak seimbang.</p> <p>8. Mengukur kinerja model dengan metrik standar seperti akurasi, presisi, <i>recall</i>, dan <i>F1-score</i>.</p>	<p>Future Work :</p> <ol style="list-style-type: none"> 1. Menerapkan model pada jenis tanaman lain untuk menguji generalisasi. 2. Menggunakan teknik augmentasi data yang lebih canggih seperti <i>Generative Adversarial Networks</i> (GANs). 3. Mengeksplorasi optimasi hyperparameter yang lebih baik.
Ekstraksi Fitur	Huda, Setiaji & Hidayat, 2022	<ol style="list-style-type: none"> 1. Mengumpulkan 240 gambar dari <i>UCI Machine Learning Repository</i> terdiri dari 3 jenis penyakit padi: <i>bacterial leaf blight</i> (70 gambar), <i>brown spot</i> (70 gambar), dan <i>leaf smut</i> (70 gambar), serta 30 gambar campuran untuk uji. 2. Mengubah gambar asli menjadi <i>grayscale</i> untuk ekstraksi fitur. 3. Menggunakan GLCM untuk mengekstraksi fitur tekstur berupa <i>contrast</i>, <i>correlation</i>, <i>energy</i>, dan <i>homogeneity</i>. 4. Menggunakan algoritma KNN untuk mengelompokkan jenis 	<p>Kelebihan :</p> <p>Penggunaan empat sudut berbeda (0°, 45°, 90°, dan 135°) untuk ekstraksi fitur.</p> <p>Kekurangan :</p> <ol style="list-style-type: none"> 1. Akurasi menurun signifikan pada skenario 50:50 (66.6%). 2. Dataset yang digunakan mungkin tidak mencakup variasi penyakit yang lebih luas. 3. Tidak ada penggunaan validasi silang untuk memastikan keandalan hasil. 4. Hanya tiga jenis penyakit yang diuji.

		<p>penyakit berdasarkan fitur yang diekstrak.</p> <p>5. Melakukan pengujian dengan dua skenario: Pertama: 210 gambar untuk pelatihan dan 30 gambar untuk pengujian (88:12). Kedua: 30 gambar untuk pelatihan dan 30 gambar untuk pengujian (50:50).</p>	<p>5. Hanya menggunakan fitur tekstur tanpa mempertimbangkan fitur lain seperti warna atau bentuk.</p> <p>6. Tidak ada perbandingan dengan metode klasifikasi lain untuk menilai keefektifan GLCM dan KNN.</p> <p>Gap Penelitian :</p> <p>1. Penelitian ini menggunakan dataset terbatas yang mungkin tidak mencerminkan variasi penyakit yang lebih luas di lapangan.</p> <p>2. Hanya menggunakan fitur tekstur, belum menggunakan fitur lain seperti warna atau bentuk untuk meningkatkan akurasi.</p> <p>Future Work :</p> <p>1. Menggunakan dataset yang lebih besar dan beragam untuk meningkatkan generalisasi model.</p> <p>2. Menerapkan teknik validasi silang untuk memastikan keandalan hasil.</p>
--	--	---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------	-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------

			<p>3. Menambahkan fitur lain seperti warna dan bentuk untuk meningkatkan akurasi dan keandalan klasifikasi.</p> <p>4. Melakukan perbandingan dengan metode klasifikasi lain untuk menilai keefektifan metode yang digunakan.</p>
	Alwy, Wahid, Ag & Fakhri, 2023	<p>1. Pengumpulan data menggunakan 120 citra daun padi yang diambil dari dataset di kaggle.com, terdiri dari tiga jenis penyakit: <i>Brown Spot</i>, <i>Hispa</i>, dan <i>Leaf Blast</i>.</p> <p>2. Konversi citra menjadi nilai biner, transformasi nilai citra warna menjadi biner.</p> <p>3. Menggunakan metode <i>Otsu thresholding</i> untuk membedakan objek dari latar belakang berdasarkan perbedaan intensitas warna.</p> <p>4. Menggunakan erosi dan area <i>open</i> untuk menghilangkan objek kecil dan menyempurnakan hasil segmentasi.</p>	<p>Kelebihan :</p> <p>1. Penggunaan LBP dan GLCM terbukti efektif dalam ekstraksi fitur tekstur citra.</p> <p>2. Algoritma <i>Decision Tree</i> memberikan hasil klasifikasi yang baik dengan akurasi tinggi.</p> <p>3. Metode segmentasi yang digunakan berhasil memisahkan objek dari latar belakang dengan baik</p> <p>Kekurangan :</p> <p>1. Proses erosi dapat menyebabkan objek citra terkikis berlebihan.</p> <p>2. Beberapa objek kecil masih tersisa setelah proses area <i>open</i>.</p> <p>3. Dataset yang digunakan hanya dari</p>

		<p>5. Menggunakan metode LBP untuk ekstraksi fitur tekstur dari citra.</p> <p>6. Ekstraksi fitur tekstur lainnya menggunakan GLCM dengan empat fitur utama: <i>Energy</i>, <i>Contrast</i>, <i>Homogeneity</i>, dan <i>Correlation</i>.</p> <p>7. Menggunakan algoritma <i>Decision Tree</i> untuk klasifikasi penyakit berdasarkan fitur yang diekstrak</p>	<p>satu sumber (kaggle.com), yang mungkin tidak mewakili variasi penyakit pada padi secara luas.</p> <p>4. Proses inversi dapat menambah kompleksitas dan potensi kesalahan dalam segmentasi.</p> <p>5. Hanya menggunakan 30 citra uji, yang mungkin tidak cukup untuk menguji keandalan sistem secara umum.</p> <p>6. Penelitian hanya fokus pada tiga jenis penyakit, tidak mencakup semua jenis penyakit padi.</p> <p>7. Tidak disebutkan berapa lama waktu pemrosesan yang dibutuhkan untuk setiap tahap.</p> <p>Gap Penelitian :</p> <p>1. Tidak ada analisis tentang efisiensi algoritma yang digunakan dalam hal waktu dan sumber daya komputasi.</p> <p>2. Penelitian ini tidak membandingkan</p>
--	--	--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------	------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------

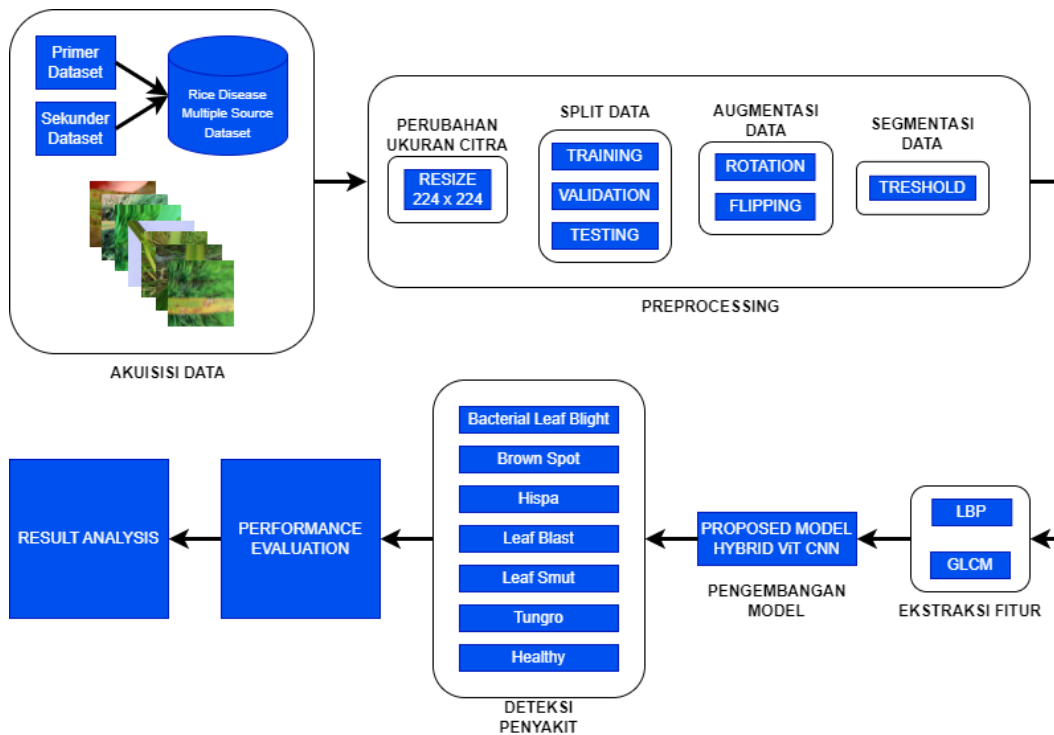
			<p>secara langsung dengan metode klasifikasi lain</p> <p>3. Tidak ada kajian tentang bagaimana ukuran dataset mempengaruhi kinerja sistem.</p> <p><i>Future Work :</i></p> <p>1. Menguji sistem dengan dataset yang lebih besar dan beragam untuk meningkatkan generalisasi.</p> <p>2. Mengembangkan metode segmentasi yang lebih adaptif untuk berbagai kondisi pencahayaan dan latar belakang.</p> <p>3. Menerapkan teknik klasifikasi lain seperti SVM atau Random Forest untuk membandingkan hasil.</p> <p>4. Mengintegrasikan fitur lain seperti bentuk dan warna selain tekstur untuk meningkatkan akurasi klasifikasi.</p>
--	--	--	------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------

BAB III

METODOLOGI PENELITIAN

3.1 Tahapan Penelitian

Dalam pengembangan model untuk deteksi penyakit tanaman pada citra daun padi diusulkan metode pengolahan citra yang tahapan – tahapannya ditunjukkan pada Gambar 3.1.



Gambar 3.1 Alur Penelitian

Tahapan pertama adalah akuisisi data berupa pengumpulan dataset citra daun padi yang terdiri dari data primer dan data sekunder. Data yang diperoleh berbeda – beda ukurannya, untuk menyelaraskannya maka dilakukan beberapa tahap preprocessing, yaitu mengubah ukuran resolusi data menjadi 224 x 224 lalu data dibagi menjadi 3 yaitu data latih, data validasi, dan data uji. Untuk

memperbanyak jumlah dan variasi data dilakukan augmentasi data agar jumlah data tiap kelas tidak jauh berbeda, dengan metode rotasi atau flipping kemudian untuk mempermudah pengenalan objek, data disegmentasi dengan cara threshold yaitu memisahkan objek citra daun padi dengan latar belakang yang tidak perlu. Setelah serangkaian tahap preprocessing, data diekstraksi fitur tekstur menggunakan LBP dan GLCM. Inti dari penelitian ini merupakan pengembangan model hibrida yang menggabungkan output CNN dengan ViT yang kemudian akan mendeteksi citra daun tersebut berpenyakit atau tidak. Setelah itu, hasil akan dievaluasi berupa akurasi, presisi, recall juga f1 score dan terakhir merupakan analisis dari metode yang telah berhasil dikembangkan.

3.2 Akuisisi Citra Penyakit Daun Padi

Akuisisi citra merupakan langkah penting yang menentukan kualitas data yang digunakan untuk melatih dan menguji model. Proses akuisisi citra yang efektif harus memastikan bahwa citra yang dikumpulkan adalah representatif dari berbagai kondisi penyakit yang dapat mempengaruhi daun padi. Dataset yang dipakai untuk penelitian ditunjukkan pada Gambar 3.2



Gambar 3.2 Dataset Penyakit Daun Padi

Gambar 3.2 merupakan data primer yang dikumpulkan langsung oleh peneliti dan data sekunder yang dikumpulkan oleh peneliti sebelumnya, dimana berurutan dari kiri ke kanan antara lain : tungro, leaf smut, leaf blast, hispa, brown spot, bacterial leaf blight.

Pengambilan dataset primer akan dilakukan di sawah daerah Kebumen dan Sragen, Jawa Tengah. Dataset yang telah berhasil dikumpulkan berupa kumpulan citra penyakit daun padi dengan format JPG, terdiri dari 14.942 citra penyakit bacterial leaf blight, 23.291 citra penyakit brown spot, 12.463 citra penyakit hispa, 779 citra penyakit leaf blast, 339 citra penyakit leaf smut, 10.338 citra penyakit tungro, dan 17.924 citra daun sehat.

Proses akuisisi citra yang terstruktur dan metodis akan memberikan fondasi yang kuat untuk penelitian dalam mendeteksi penyakit pada daun padi dan memastikan data yang digunakan berkualitas tinggi dan representatif dari kondisi nyata di lapangan.


3.3 PreProcessing Citra Daun Padi

Pra-pemrosesan citra adalah langkah penting yang mempersiapkan data citra untuk analisis dan pelatihan model lebih lanjut. Proses pra-pemrosesan membantu mengurangi variasi yang tidak relevan dalam data citra dan meningkatkan fitur-fitur penting yang berkaitan dengan penyakit tanaman. Untuk data citra, preprocessing meliputi, penghapusan duplikasi, normalisasi ukuran citra untuk memastikan bahwa semua input ke model memiliki format yang seragam, membagi data menjadi data latih, data validasi, dan data uji, augmentasi data seperti rotasi dan flipping yang dilakukan untuk meningkatkan variasi data dan mengurangi resiko overfitting, segmentasi data dengan metode threshold dilakukan untuk mengisolasi daun dari latar belakang agar model fokus pada area yang berisi informasi relevan, dan pembuatan dataset berupa labeling yaitu memberi label tiap citra atau kelas sesuai dengan jenis penyakitnya. Melalui langkah-langkah pra-pemrosesan ini, citra daun padi akan dipersiapkan dengan optimal untuk proses pembelajaran mendalam dan memastikan bahwa model dapat belajar dari fitur yang paling relevan dan menghasilkan prediksi yang akurat.

3.4 Ekstraksi Fitur Citra Daun Padi

Proses ekstraksi fitur (feature extraction) adalah langkah krusial yang memungkinkan model pembelajaran mendalam untuk mempelajari karakteristik penting dari citra yang terkait dengan berbagai jenis penyakit daun padi. Fitur – fitur yang akan dicakup berupa tekstur. Fitur tekstur diekstraksi menggunakan metode seperti GLCM yang memberikan informasi tentang pola dan struktur daun juga LBP untuk mengidentifikasi area dengan tekstur yang berbeda, yang sering terjadi pada daun yang terinfeksi.

Ekstraksi fitur yang efektif memungkinkan model untuk mempelajari nuansa yang halus namun kritis dari citra daun padi yang terkena penyakit, membantu dalam peningkatan akurasi dan efisiensi model dalam mendeteksi dan mengklasifikasikan penyakit tanaman secara otomatis. Proses ekstraksi fitur yang efisien dan efektif ini akan memungkinkan model pembelajaran mendalam untuk dengan akurat mengidentifikasi dan mengklasifikasikan penyakit pada daun padi, berkontribusi pada pengelolaan penyakit tanaman yang lebih baik.




Gambar 3.3 Ekstraksi Fitur LBP Penyakit Daun Padi

3.5 Pengembangan Model dan Deteksi Penyakit

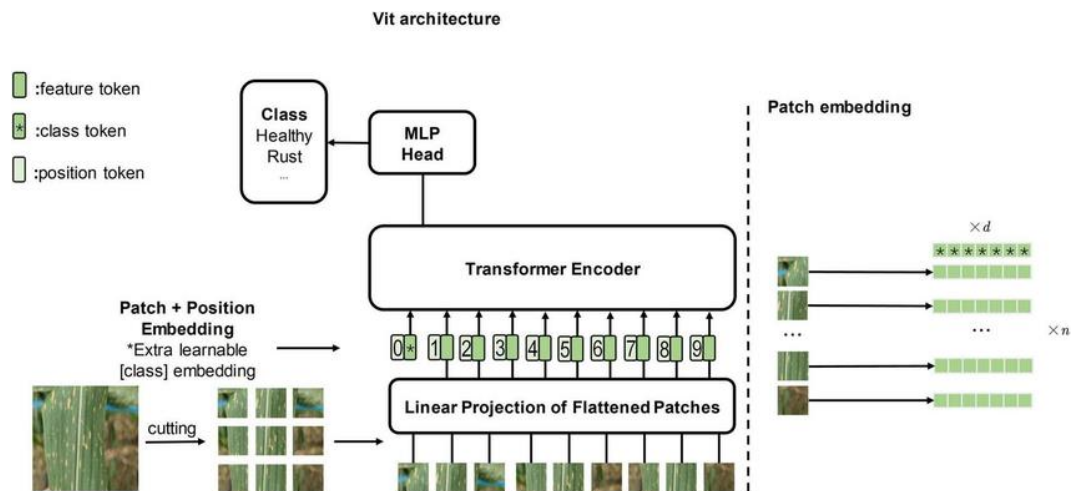
Data citra daun padi yang telah melalui preprocessing dan ekstraksi ciri kemudian digunakan untuk melatih model pembelajaran mendalam menggunakan pendekatan hibrida yaitu menggabungkan output dari CNN dan ViT. CNN digunakan untuk mengekstraksi ciri lokal dari citra, sementara ViT digunakan untuk memahami konteks global dan hubungan antar bagian citra. Outputnya

berupa deteksi citra daun padi berpenyakit atau tidak. Model dioptimalkan hyperparameter nya seperti ukuran batch, learning rate, jumlah epoch, loss function, optimizer untuk menemukan konfigurasi terbaik dalam mendeteksi penyakit pada citra daun padi. Model yang telah dioptimalkan kemudian dievaluasi untuk mengukur performa akhir dalam berbagai metrik evaluasi, seperti akurasi, presisi, recall, dan F1-score. Metrik ini memberikan gambaran menyeluruh tentang kemampuan model dalam mengklasifikasikan jenis penyakit kulit dengan tepat.



Gambar 3.4 CNN Penyakit Daun Padi

Metode Ekstraksi Fitur Hibrid menyoroti kemajuan signifikan dalam bidang pembelajaran mendalam untuk tugas visual, sebagian besar didorong oleh adopsi jaringan saraf konvolusional (CNN) dalam beberapa tahun terakhir. CNN khususnya dicatat karena bias induktif mereka terhadap ekivalensi spasial, sebuah fitur yang sangat penting untuk pembelajaran representasi visual yang serbaguna yang memfasilitasi kemudahan transfer dan meningkatkan kinerja di berbagai aplikasi. Namun, penelitian terkini menunjukkan bahwa jaringan transformator saraf, atau ViT, mencapai hasil yang setara atau bahkan lebih unggul dalam tugas klasifikasi gambar, terutama ketika berhadapan dengan dataset besar.



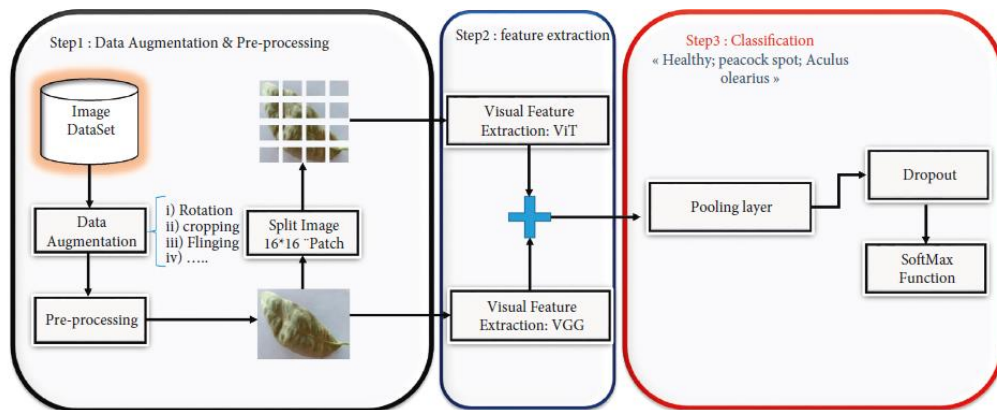
Gambar 3.5 ViT Penyakit Daun Padi

ViT beroperasi secara serupa dengan transformator yang digunakan dalam pemrosesan bahasa alami. Berbeda dengan CNN yang menggunakan lapisan konvolusional, ViT menggunakan mekanisme self-attention untuk mengumpulkan dan mengintegrasikan informasi di berbagai lokasi gambar. Metode ini berlawanan dengan pendekatan sebelumnya yang sangat bergantung pada penanaman bias induktif spesifik gambar ke dalam model.

Ketika membahas jaringan klasifikasi gambar seperti CNN, teramati bahwa jaringan ini biasanya mengirimkan representasi dengan resolusi yang berkurang secara progresif. Misalnya, jaringan seperti ResNet melibatkan beberapa tahap, masing-masing mengurangi resolusi hingga setengahnya, berujung pada peta fitur yang signifikan berkurang menjadi 1/32 dari dimensi aslinya pada setiap sumbu. Namun, ViT mempertahankan resolusi yang konsisten di seluruh lapisan. Token awal pada ViT ditetapkan pada resolusi 16x16, dan skala ini dipertahankan hingga lapisan akhir, berpotensi memungkinkan ViT untuk mempertahankan informasi posisi dalam gambar—faktor yang tidak dianggap kritis dalam banyak tugas klasifikasi tetapi berguna dalam skenario tertentu.

Lebih lanjut, variasi terbaru dari ViT, seperti pyramid ViT, menggabungkan strategi serupa dengan CNN, seperti pengurangan resolusi secara bertahap. Metode ini terbukti bermanfaat dalam mengelola persyaratan memori yang luas yang terkait dengan mekanisme self-attention dari transformator, yang meningkat secara

eksponensial dengan ukuran gambar. Dengan mengadopsi strategi pengurangan resolusi, transformator ini dapat memproses data resolusi tinggi pada lapisan awal sambil menggunakan sumber daya penyimpanan secara hemat, mirip dengan teknik yang digunakan dalam arsitektur CNN.



Gambar 3.6 Hibrida CNN ViT Penyakit Daun Padi

3.6 Evaluasi dan Analisis Model

Evaluasi terhadap model dilakukan untuk melihat akurasi model saat mengidentifikasi penyakit. Proses evaluasi dimulai dengan penerapan model pada set uji, yang terdiri dari data yang belum pernah dilihat oleh model selama fase pelatihan. Set uji ini dirancang untuk mensimulasikan kondisi dunia nyata, di mana model harus membuat prediksi tanpa bias dari data pelatihan.

Berbagai metrik evaluasi digunakan untuk mengukur kinerja model secara menyeluruh. Metrik evaluasi seperti akurasi, presisi, recall, dan F1-Score digunakan untuk mengukur performa model. Akurasi adalah metrik dasar yang menunjukkan persentase prediksi benar dari total prediksi yang dibuat oleh model. Presisi (precision) mengukur proporsi prediksi positif yang benar-benar positif, sementara recall (sensitivitas) mengukur proporsi kasus positif yang benar-benar terdeteksi oleh model. F1-score, yang merupakan harmoni rata-rata dari presisi dan recall, memberikan gambaran seimbang tentang kinerja model, terutama ketika ada

ketidakseimbangan antara kelas positif dan negatif. Analisis kesalahan (error analysis) dilakukan untuk mengidentifikasi pola kesalahan dan memahami alasan di balik prediksi yang salah. Analisis ini dapat mengungkap area di mana model perlu diperbaiki atau menunjukkan kebutuhan untuk lebih banyak data pelatihan untuk jenis penyakit tertentu. Hasilnya digunakan untuk menginformasikan iterasi lebih lanjut dari pengembangan model. Jika model menunjukkan kinerja yang memadai, langkah selanjutnya adalah mempersiapkannya untuk implementasi klinis. Namun, jika hasil evaluasi menunjukkan kekurangan, maka perlu dilakukan penyesuaian pada model, seperti penambahan data pelatihan, tuning hyperparameters, atau bahkan perubahan dalam arsitektur model.

3.7 Estimasi Waktu Penelitian

Estimasi waktu penelitian merupakan rancangan kegiatan yang dilakukan selama penelitian beserta estimasi waktu tiap kegiatan seperti yang ditunjukkan pada Tabel 3.1.

Tabel 3.1 Time Table

Kegiatan	Tahun Pertama (Semester 1)											
	1	2	3	4	5	6	7	8	9	10	11	12
Studi Literatur												
	Tahun Kedua (Semester 2 & 3)											
Pembuatan Proposal												
Pengumpulan Dataset (Sekunder)												
Pengumpulan Dataset (Primer & Sekunder)												
Pembentukan Dataset												
Pembentukan Model												
	Tahun Ketiga (Semester 4 & 5)											
Pelatihan & Pengujian Model												

Penulisan Hasil Penelitian (BAB 4)												
Penulisan Hasil Penelitian (BAB 5)												
Pembuatan Jurnal Pertama												
Submit Jurnal Pertama												
Pembuatan Jurnal Kedua												
Submit Jurnal Kedua												

Tabel 3.1 merupakan estimasi kegiatan penelitian, kegiatan studi literatur dilakukan pada tahun pertama dimana semester pertama dilaksanakan pada bulan september untuk mencari pengetahuan dan informasi untuk mendapatkan novelty dan gap dari penelitian yang akan dilakukan.

Pembuatan proposal dan pengumpulan dataset sekunder dilakukan secara beriringan di tahun kedua semester kedua selama 6 bulan sampai dilaksanakannya Ujian Kualifikasi. Pengambilan dataset primer akan dilakukan pada semester berikutnya setelah Ujian Kualifikasi yang akan dilaksanakan di daerah Sragen dan Kebumen, Jawa Tengah. Setelah pengumpulan dataset sekunder dan primer, akan dilakukan pembuatan dataset atau preprocessing citra seperti resize, augmentasi dan segmentasi data masi pada tahun dan semester yang sama.

Pembuatan model akan dilakukan setelah data selesai diproses beriringan dengan pelatihan dan pengujian model serta melakukan evaluasi kinerja model yang akan dilakukan sampai di tahun ketiga semester 4, serta penyelesaian penulisan disertasi. Pada semester 5 dan 6 di tahun ketiga, akan dilakukan penulisan jurnal pertama dan kedua sampai submit jurnal.

DAFTAR PUSTAKA

- Abdullah, W., Kim, C., & Nam, Y. (2024). A Fresh Look at Tomato Leaf Disease Recognition using Vision Transformers. 1, 105–114. <https://doi.org/10.61356/j.oia.2024.1274>
- Adhikari, S. (2024). Advancements in Agricultural Technology: Vision Transformer-Based Potato Leaf Disease Classification. *Journal of Soft Computing Paradigm*, 6(2), 169–185. <https://doi.org/10.36548/jscp.2024.2.005>
- Aggarwal, M., Khullar, V., Goyal, N., Singh, A., Tolba, A., Thompson, E. B., & Kumar, S. (2023). Pre-Trained Deep Neural Network-Based Features Selection Supported Machine Learning for Rice Leaf Disease Classification. *Agriculture*, 13(5), 936. <https://doi.org/10.3390/agriculture13050936>
- Aggarwal, S., Suchithra, M., Chandramouli, N., Sarada, M., Verma, A., Vetrithangam, D., Pant, B., & Adugna, B. A. (2022). Rice Disease Detection Using Artificial Intelligence and Machine Learning Techniques to Improve Agro-Business. *Scientific Programming*, 2022, 1–13. <https://doi.org/10.1155/2022/1757888>
- Agusta, S. W., & Kaswidjanti, W. (2023). The Implementation of Color Feature Extraction and Gray Level Co-occurrence Matrix Combination in K-Nearest Neighbor Classification Method for Tomato Leaf Disease Identification. *Telematika*, 20(2), 250. <https://doi.org/10.31315/telematika.v20i2.10009>
- Ahad, M. T., Li, Y., Song, B., & Bhuiyan, T. (2023). Comparison of CNN-based deep learning architectures for rice diseases classification. *Artificial*

Intelligence in Agriculture, 9, 22–35.
<https://doi.org/10.1016/j.aiia.2023.07.001>

Alshammari, H., Gasmi, K., Ltaifa, I. B., Krichen, M., Ammar, L. B., & Mahmood, M. A. (2022a). Olive Disease Classification Based on Vision Transformer and CNN Models. *Computational Intelligence and Neuroscience*, 2022, 1–10. <https://doi.org/10.1155/2022/3998193>

Alwy, N. a. D. P., Wahid, N. M. S. N., Ag, N. B. N. N., & Fakhri, N. M. M. (2023). Klasifikasi Penyakit Pada Padi Dengan Ekstraksi Fitur LBP dan GLCM. *Journal of Deep Learning, Computer Vision and Digital Image Processing*/Journal of Deep Learning, Computer Vision and Digital Image Processing, 1–10. <https://doi.org/10.61255/decoding.v1i1.51>

Annur, I. F., Umami, J., Annafii, M. N., Trisnaningrum, N., & Putra, O. V. (2023a). Klasifikasi Tingkat Keparahan Penyakit Leafblast Tanaman Padi Menggunakan MobileNetv2. *Fountain of Informatics Journal*, 8(1), 7–14. <https://doi.org/10.21111/fij.v8i1.9419>

Barman, U., Sarma, P., Rahman, M., Deka, V., Lahkar, S., Sharma, V., & Saikia, M. J. (2024). ViT-SmartAgri: Vision Transformer and Smartphone-Based Plant Disease Detection for Smart Agriculture. *Agronomy*, 14(2), 327. <https://doi.org/10.3390/agronomy14020327>

C, N., & S, K. (2024). Cucumber Leaf Disease Detection using GLCM Features with Random Forest Algorithm. *International Research Journal of Multidisciplinary Technovation*, 40–50. <https://doi.org/10.54392/irjmt2414>

Chaudhari, A., Bhatt, C., Krishna, A., & Mazzeo, P. L. (2022). ViTFER: Facial Emotion Recognition with Vision Transformers. *Applied System Innovation*, 5(4), 80. <https://doi.org/10.3390/asi5040080>

- Chen, H. C., Widodo, A. M., Wisnujati, A., Rahaman, M., Lin, J. C. W., Chen, L., & Weng, C. E. (2022). AlexNet Convolutional Neural Network for Disease Detection and Classification of Tomato Leaf. *Electronics*, 11(6), 951. <https://doi.org/10.3390/electronics11060951>
- Cipta, R., Khoerunisa, N., Saraswati, N. M. S., Prasetyono, N. R. N., & Alfariki, N. M. Z. (2023a). DETEKSI PENYAKIT BERCAK COKLAT, COKLAT SEMPIT DAN HAWAR MELALUI SPEKTRUM WARNA CITRA DIGITAL DAUN PADI MENGGUNAKAN METODE CONVOLUTIONAL NEURAL NETWORK. *Zonasi*, 5(2), 334–346. <https://doi.org/10.31849/zn.v5i2.13245>
- Devi, R. S. S., Kumar, V. R. V., & Sivakumar, P. (2024). InViTMixup: plant disease classification using convolutional vision transformer with Mixup augmentation. *Zhōngguó Gōngchéng Xuékān*, 47(5), 520–527. <https://doi.org/10.1080/02533839.2024.2346490>
- Dümen, S., Yılmaz, E. K., Adem, K., & Avaroglu, E. (2024). Performance of vision transformer and swin transformer models for lemon quality classification in fruit juice factories. *European Food Research & Technology*. <https://doi.org/10.1007/s00217-024-04537-5>
- Dutta, P., Sathi, K. A., Hossain, M. A., & Dewan, M. a. A. (2023). Conv-ViT: A Convolution and Vision Transformer-Based Hybrid Feature Extraction Method for Retinal Disease Detection. *Journal of Imaging*, 9(7), 140. <https://doi.org/10.3390/jimaging9070140>
- Fathoni, F. M., Putra, C. A., & Nurlaili, A. L. (2024). KLASIFIKASI PENYAKIT DAUN ANGGUR MENGGUNAKAN METODE K-NEAREST NEIGHBOR BERDASARKAN GRAY LEVEL CO-OCCURRENCE MATRIX. *Deleted Journal*, 3(1), 8–15. <https://doi.org/10.32699/biner.v3i1.6332>

- Ha, M. H., Nguyen, D. C., Do, M. T., Kim, D. T., Le, X. H., & Pham, N. T. (2024). Plant pathology identification using local-global feature level based on transformer. *Indonesian Journal of Electrical Engineering and Computer Science*, 34(3), 1582. <https://doi.org/10.11591/ijeecs.v34.i3.pp1582-1592>
- Hairah, U., Septiarini, A., Puspitasari, N., Tejawati, A., Hamdani, H., & Priyatna, S. E. (2024). Classification of tea leaf disease using convolutional neural network approach. *International Journal of Power Electronics and Drive Systems/International Journal of Electrical and Computer Engineering*, 14(3), 3287. <https://doi.org/10.11591/ijece.v14i3.pp3287-3294>
- Han, D., & Guo, C. (2024). Automatic classification of ligneous leaf diseases via hierarchical vision transformer and transfer learning. *Frontiers in Plant Science*, 14. <https://doi.org/10.3389/fpls.2023.1328952>
- Hawari, F. H., Fadillah, F., Alviandi, M. R., & Arifin, T. (2022a). KLASIFIKASI PENYAKIT TANAMAN PADI MENGGUNAKAN ALGORITMA CNN (CONVOLUTIONAL NEURAL NETWORK). *Jurnal Responsif: Riset Sains Dan Informatika*, 4(2), 184–189. <https://doi.org/10.51977/jti.v4i2.856>
- Julianto, N. A., Sunyoto, N. A., & Wibowo, N. F. W. (2022a). OPTIMASI HYPERPARAMETER CONVOLUTIONAL NEURAL NETWORK UNTUK KLASIFIKASI PENYAKIT TANAMAN PADI. *Jurnal TEKNIMEDIA*, 3(2), 98–105. <https://doi.org/10.46764/teknimedia.v3i2.77>
- Jumarlis, M., & Mirfan, N. (2022). Detecting Diseases on Clove Leaves Using GLCM and Clustering K-Means. *Jurnal RESTI (Rekayasa Sistem Dan Teknologi Informasi)*, 6(4), 624–631. <https://doi.org/10.29207/resti.v6i4.4033>
- Kalpana, P., Anandan, R., Hussien, A. G., Migdady, H., & Abualigah, L. (2024). Plant disease recognition using residual convolutional enlightened Swin

transformer networks. Scientific Reports, 14(1).
<https://doi.org/10.1038/s41598-024-56393-8>

Khoiruddin, M., Junaidi, A., & Saputra, W. A. (2022). Klasifikasi Penyakit Daun Padi Menggunakan Convolutional Neural Network. *Journal of Dinda*, 2(1), 37–45. <https://doi.org/10.20895/dinda.v2i1.341>

Koeshidayatullah, A., Al-Azani, S., Baraboshkin, E. E., & Alfarraj, M. (2022). FaciesViT: Vision transformer for an improved core lithofacies prediction. *Frontiers in Earth Science*, 10. <https://doi.org/10.3389/feart.2022.992442>

Lamba, S., Kukreja, V., Baliyan, A., Rani, S., & Ahmed, S. H. (2023a). A Novel Hybrid Severity Prediction Model for Blast Paddy Disease Using Machine Learning. *Sustainability*, 15(2), 1502. <https://doi.org/10.3390/su15021502>

Lamba, S., Kukreja, V., Rashid, J., Gadekallu, T. R., Kim, J., Baliyan, A., Gupta, D., & Saini, S. (2023). A novel fine-tuned deep-learning-based multi-class classifier for severity of paddy leaf diseases. *Frontiers in Plant Science*, 14. <https://doi.org/10.3389/fpls.2023.1234067>

Leamons, R., Cheng, H., & Shami, A. A. (2022). Vision Transformers for Medical Images Classifications. In *Lecture notes in networks and systems* (pp. 319–325). https://doi.org/10.1007/978-3-031-16075-2_22

Li, G., Wang, Y., Zhao, Q., Yuan, P., & Chang, B. (2023). PMVT: a lightweight vision transformer for plant disease identification on mobile devices. *Frontiers in Plant Science*, 14. <https://doi.org/10.3389/fpls.2023.1256773>

Li, P., Jing, R., & Shi, X. (2022). Apple Disease Recognition Based on Convolutional Neural Networks With Modified Softmax. *Frontiers in Plant Science*, 13. <https://doi.org/10.3389/fpls.2022.820146>

- Li, X., & Li, S. (2022). Transformer Help CNN See Better: A Lightweight Hybrid Apple Disease Identification Model Based on Transformers. *Agriculture*, 12(6), 884. <https://doi.org/10.3390/agriculture12060884>
- Mabrouk, A., Redondo, R. P. D., Dahou, A., Elaziz, M. A., & Kayed, M. (2022). Pneumonia Detection on Chest X-ray Images Using Ensemble of Deep Convolutional Neural Networks. *Applied Sciences*, 12(13), 6448. <https://doi.org/10.3390/app12136448>
- Narmadha, R. P., Sengottaiyan, N., & Kavitha, R. J. (2022). Deep Transfer Learning Based Rice Plant Disease Detection Model. *Intelligent Automation and Soft Computing/Intelligent Automation & Soft Computing*, 31(2), 1257–1271. <https://doi.org/10.32604/iasc.2022.020679>
- Noprisson, H. (2022a). Fine-Tuning Model Transfer Learning VGG16 Untuk Klasifikasi Citra Penyakit Tanaman Padi. *JSAI (Journal Scientific and Applied Informatics)*, 5(3), 244–249. <https://doi.org/10.36085/jsai.v5i3.3609>
- Pacal, S. (2022). Deep Learning Approaches for Classification of Breast Cancer in Ultrasound (US) Images. *Iğdır Üniversitesi Fen Bilimleri Enstitüsü Dergisi (Online)*, 12(4), 1917–1927. <https://doi.org/10.21597/jist.1183679>
- Parmar, N. M., & Degadwala, N. D. S. (2024). Deep Learning for Accurate Papaya Disease Identification Using Vision Transformers. *International Journal of Scientific Research in Computer Science, Engineering and Information Technology*, 10(2), 420–426. <https://doi.org/10.32628/cseit2410235>
- Paul, S. G., Biswas, A. A., Saha, A., Zulfiker, M. S., Ritu, N. A., Zahan, I., Rahman, M., & Islam, M. A. (2023). A real-time application-based convolutional neural network approach for tomato leaf disease classification. *Array*, 19, 100313. <https://doi.org/10.1016/j.array.2023.100313>

- PK, R., Deshmukh, V., Bhandari, S. U., Raut, R., & Kharat, R. (2023a). Rice Leaf Disease Detection Using Convolutional Neural Network. *International Journal on Recent and Innovation Trends in Computing and Communication*, 11(10s), 512–517. <https://doi.org/10.17762/ijritcc.v11i10s.7687>
- Rachmad, A., Hapsari, R. K., Setiawan, W., Indriyani, T., Rochman, E. M. S., & Satoto, B. D. (2023). Classification of Tobacco Leaf Quality Using Feature Extraction of Gray Level Co-occurrence Matrix (GLCM) and K-Nearest Neighbor (K-NN). In *Advances in intelligent systems research/Advances in Intelligent Systems Research* (pp. 30–38). https://doi.org/10.2991/978-94-6463-174-6_4
- Rachmad, A., Syarief, M., Rifka, S., Sonata, F., Setiawan, W., & Rochman, E. M. S. (2022). Corn Leaf Disease Classification Using Local Binary Patterns (LBP) Feature Extraction. *Journal of Physics. Conference Series*, 2406(1), 012020. <https://doi.org/10.1088/1742-6596/2406/1/012020>
- Rajaraman, S., Zamzmi, G., Folio, L. R., & Antani, S. (2022). Detecting Tuberculosis-Consistent Findings in Lateral Chest X-Rays Using an Ensemble of CNNs and Vision Transformers. *Frontiers in Genetics*, 13. <https://doi.org/10.3389/fgene.2022.864724>
- Saleem, M. A., Aamir, M., Ibrahim, R., Senan, N., & Alyas, T. (2022). An Optimized Convolution Neural Network Architecture for Paddy Disease Classification. *Computers, Materials & Continua/Computers, Materials & Continua* (Print), 71(3), 6053–6067. <https://doi.org/10.32604/cmc.2022.022215>
- Sampoornamma, S. (2022). RICE LEAF DISEASE CLASSIFICATION USING CNN WITH TRANSFER LEARNING. *Indian Scientific Journal of Research in Engineering and Management*, 06(05). <https://doi.org/10.55041/ijsrem16028>

- Saputra, A. D., Hindarto, D., & Santoso, H. (2023). Disease Classification on Rice Leaves using DenseNet121, DenseNet169, DenseNet201. *Sinkron*, 8(1), 48–55. <https://doi.org/10.33395/sinkron.v8i1.11906>
- Setiaji, B., & Huda, A. A. (2022). Implementasi Gray Level Co-Occurrence Matrix (GLCM) Untuk Klasifikasi Penyakit Daun Padi. *Jurnal Pseudocode*, 9(1), 33–38. <https://doi.org/10.33369/pseudocode.9.1.33-38>
- Sheila, S., Sari, I. P., Saputra, A. B., Anwar, M. K., & Pujiyanto, F. R. (2023a). Deteksi Penyakit Pada Daun Padi Berbasis Pengolahan Citra Menggunakan Metode Convolutional Neural Network (CNN). *MULTINETICS: Jurnal Multimedia Networking Informatics*, 9(1), 27–34. <https://doi.org/10.32722/multinetics.v9i1.5255>
- Sun, C., Zhou, X., Zhang, M., & Qin, A. (2023). SE-VisionTransformer: Hybrid Network for Diagnosing Sugarcane Leaf Diseases Based on Attention Mechanism. *Sensors*, 23(20), 8529. <https://doi.org/10.3390/s23208529>
- Sunandar, N., & Sutopo, J. (2024a). Utilization of Artificial Neural Network in Rice Plant Disease Classification Using Leaf Image. *Deleted Journal*, 42, 1–10. <https://doi.org/10.55529/ijrise.42.1.10>
- Tejaswini, P., Singh, P., Ramchandani, M., Rathore, Y. K., & Janghel, R. R. (2022). Rice Leaf Disease Classification Using Cnn. *IOP Conference Series. Earth and Environmental Science*, 1032(1), 012017. <https://doi.org/10.1088/1755-1315/1032/1/012017>
- Vallabhajosyula, S., Sistla, V., & Kolli, V. K. K. (2024). A Novel Hierarchical framework for Plant Leaf Disease Detection using Residual Vision Transformer. *Heliyon*, 10(9), e29912. <https://doi.org/10.1016/j.heliyon.2024.e29912>

- Xin, C., Liu, Z., Zhao, K., Miao, L., Ma, Y., Zhu, X., Zhou, Q., Wang, S., Li, L., Yang, F., Xu, S., & Chen, H. (2022). An improved transformer network for skin cancer classification. *Computers in Biology and Medicine*, 149, 105939. <https://doi.org/10.1016/j.combiomed.2022.105939>
- Yang, H., Deng, X., Shen, H., Lei, Q., Zhang, S., & Liu, N. (2023). Disease Detection and Identification of Rice Leaf Based on Improved Detection Transformer. *Agriculture*, 13(7), 1361. <https://doi.org/10.3390/agriculture13071361>
- Yao, N., Ni, F., Wu, M., Wang, H., Li, G., & Sung, W. K. (2022). Deep Learning-Based Segmentation of Peach Diseases Using Convolutional Neural Network. *Frontiers in Plant Science*, 13. <https://doi.org/10.3389/fpls.2022.876357>
- Yuan, P., Xia, Y., Tian, Y., & Xu, H. (2024a). TRiP: a transfer learning based rice disease phenotype recognition platform using SENet and microservices. *Frontiers in Plant Science*, 14. <https://doi.org/10.3389/fpls.2023.1255015>