



*Tracking Awan Cumulonimbus (Cb) Wilayah Indonesia Berbasis
Machine Learning Menggunakan Data APT Sensor Satelit NOAA*

SEMINAR BIDANG KAJIAN

Yenniwarti Rafsyam
NPM : 99219034

PROGRAM DOKTOR TEKNOLOGI INFORMASI
UNIVERSITAS GUNADARMA
Agustus 2021

Daftar Isi

HALAMAN JUDUL	i
DAFTAR ISI	i
Daftar Isi	i
Daftar Gambar	iii
DAFTAR GAMBAR	iii
Daftar Tabel	iv
DAFTAR TABEL	iv
1 Pendahuluan	1
1.1 Latar Belakang	1
1.2 Batasan dan Tujuan	3
1.2.1 Batasan Penelitian Serta Alasannya	3
1.2.2 Definisi Permasalahan dari Penelitian	4
1.2.3 Tujuan Umum dan Khusus dari Penelitian	5
1.3 Kontribusi	5
2 Tinjauan Pustaka	6
2.1 Satelit Cuaca (NOAA)	6
2.2 Sistem Akuisisi Data Citra NOAA	7
2.3 Aplikasi APT	8
2.4 Awan	8
2.4.1 Identifikasi Jenis Awan dengan Satelit	9
2.4.2 Klasifikasi Jenis Awan	9
2.5 Awan Cumulonimbus (Cb)	11

2.6	<i>Radiance</i>	12
2.7	Temperatur Kecerahan (<i>Brightness Temperature</i> = T_b)	13
2.8	Metode <i>Random Forest</i> (RF)	14
2.9	Perbandingan Tinjauan	16
3	Metodologi	19
3.1	Motivasi	19
3.2	Framework Riset	19
3.3	Pendekatan	21
3.3.1	Pemilihan Data APT	21
3.3.2	<i>Georeferencing</i> Data	23
3.3.3	Penentuan Nilai <i>Brightness Temperature</i> (T_b)	24
3.3.4	Pengembangan Model <i>Tracking</i> Awab Cb Menggunakan <i>Random Forest</i>	25
	DAFTAR PUSTAKA	27
	Bibliografi	27

Daftar Gambar

1.1	Sistem Akuisisi Data Satelit NOAA	3
2.1	Diagram Identifikasi Jenis Awan	10
2.2	Menunjukkan tahap cumulus, mature, dan sisipasi. Garis vertikal antara dasar awan dan permukaan presipitasi (hujan atau hujan es). Panah menunjukkan arus turun (textitdowndrafts) dan arus naik dalam awan. Bagian atas awan adalah di tropopause.	12
2.3	Contoh Pohon Keputusan	15
3.1	<i>Flowchart</i> Proses Penelitian untuk <i>Tracking</i> Awan Cb	20
3.2	Letak Astronomis Indonesia	22
3.3	Letak Geografis Kota Bandar Lampung	23
3.4	Metode <i>Random Forest</i> dengan Model Validasi Silang 5 Kali Lipat	26

Daftar Tabel

2.1	Satelit NOAA yang Sedang Aktif	7
2.2	Karakteristik Masing-masing Kanal APT	8
2.3	Hasil Klasifikasi Awan Melalui Citra Satelit Penginderaan Jauh	10

Bab 1

Pendahuluan

1.1 Latar Belakang

Sejak abad ke-21, perubahan iklim telah menjadi salah satu tantangan utama yang harus dihadapi manusia. Cuaca ekstrem yang disebabkan oleh perubahan iklim berpotensi menimbulkan risiko besar pada infrastruktur dan kesehatan manusia [Yuan et al., 2019].

Indonesia merupakan negara kepulauan yang berada di wilayah tropis. yang berada pada 6° LU- 11° LS dan 95° BT- 141° BT yang terletak diantara dua benua yaitu Benua Asia dan Australia dan dua samudra yaitu Samudra Hindia dan Samudra Pasifik. Indonesia juga termasuk wilayah yang banyak terkena radiasi matahari dan radiasi bumi, sehingga pola cuaca banyak dipengaruhi oleh proses konvektifnya. Awan Cumulus dan awan konvektif lain merupakan manifestasi sebuah variasi dari proses termodinamis dan dinamis baik internal maupun eksternal terhadap awan.

Awan memainkan peran penting dalam mempengaruhi dinamika kondisi iklim dan cuaca baik dalam skala lokal maupun global [Stephens, 2005], karena berbagai jenis awan memiliki perbedaan efek radiasi pada sistem permukaan-atmosfer Bumi [Liu et al., 2009]. Deteksi dan klasifikasi awan yang otomatis dan akurat berguna untuk banyak multitude hidrologi, iklim, dan aplikasi atmosfer [Vazquez et al., 2004].

Awan jenis konvektif sering dikaitkan dengan adanya cuaca buruk, terutama jenis awan Cumulonimbus (Cb). Awan Cb adalah salah satu jenis awan berbahaya yang menimbulkan cuaca ekstrem. Awan Cb, atau badai petir, adalah awan konvektif atau sistem awan yang menghasilkan curah hujan dan petir.

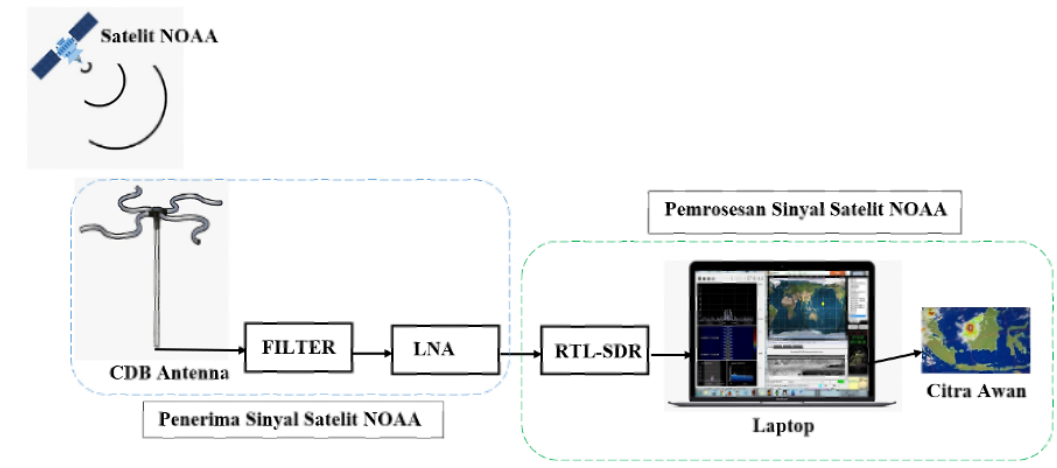
Pengamatan awan Cb bisa menjadi sumber data penting untuk asimilasi dalam prakiraan cuaca dan untuk memantau tren iklim. Selain itu, keberadaan partikel es awan Cb dapat membekukan bagian-bagian pesawat dan paling sering

menghasilkan petir yang dapat mengacaukan sistem kelistrikan dan navigasi pesawat. Pesawat yang terbang di dekat badai guntur kemungkinan akan mengalami sambaran petir, karena pesawat terbang tepat menghalangi jalannya petir. Kecenderungan untuk mengalami sambaran petir adalah apabila pesawat sedang terbang di dekat badai guntur dan di sekitar *freezing* level. Awan konvektif seperti awan Cb berasosiasi dengan ketidakstabilan atmosfer, turbulensi dan badai petir, dan dengan demikian, pemantauan awan secara terus menerus sangat penting untuk keperluan prakiraan cuaca dan kontrol lalu lintas udara [Rumi et al., 2013]. Berbagai instrumen pengukuran, yang dapat berbasis darat, terkait dengan pengamatan pesawat [Field and Furtado, 2015] atau cuaca balon, atau terintegrasi dalam satelit [Tapakis and Charalambides, 2013], dapat dimanfaatkan dalam memperoleh data yang diperlukan untuk klasifikasi awan. Informasi kondisi cuaca masih terbatas, hal tersebut salah satunya disebabkan akses data yang sulit. Untuk itu diperlukan suatu sistem teknologi yang dapat mengetahui keadaan cuaca nasional dengan tepat. Teknologi satelit merupakan kebutuhan yang tidak bisa dielakkan lagi pada saat sekarang ini dikarenakan citra satelit NOAA telah terbukti menjadi sumber penting pengamatan peristiwa cuaca dinamis. Citra satelit adalah salah satu alat paling kuat dan penting yang digunakan oleh ilmuwan untuk studi ilmu bumi dan ruang angkasa [Mahajan and Fataniya, 2019]. Citra awan satelit telah menjadi salah satu sarana penting untuk prakiraan cuaca dan analisis iklim [Roman et al., 2016], [Jaiswal and Kishtawal, 2011b], [Tang et al., 2015], khususnya untuk Peramalan dan pemantauan beberapa bencana alam, seperti angin topan, banjir, badai salju, kebakaran hutan, dan lain-lain. Deteksi dan klasifikasi awan otomatis menggunakan citra awan satelit memiliki berbagai aplikasi meteorologi seperti prakiraan cuaca dan pemantauan iklim.

Ketersediaan data citra satelit secara real time masih terbatas sehingga menjadi kendala untuk beberapa aplikasi, biasanya salah satu kekurangannya adalah bahwa sistem penerima sinyal ground sangat rumit. Namun ada satelit yang dapat menyediakan data secara gratis dan tidak rumit dan sistem penerima ekonomis biaya rendah dapat dengan mudah dibangun dan dipasang. Transmisi Gambar Otomatis (APT) dari *National Oceanic and Atmospheric* Satelit Administrasi (NOAA) adalah salah satunya. Sistem APT diperkenalkan pada tahun 1960-an dan lebih dari lima dekade telah memberikan data gambar ke stasiun pengguna dengan berbiaya relatif rendah dan bebas lisensi di sebagian besar lokasi negara di dunia. Stasiun pengguna di mana pun di dunia dapat menerima data lokal di setidaknya dua kali sehari dari setiap satelit saat melewati hampir di atas kepala stasiun pengguna tersebut (<http://usradioguy.com/noaa-apt-reception/>).

Oleh karena itu, peneliti bermaksud menerapkan data APT untuk mendetek-

si/*tracking* awan Cb. Data APT ini peneliti peroleh menggunakan sistem penerima APT/sistem penerima sinyal satelit NOAA yang sudah peneliti bangun sebelumnya, yang terdiri dari antena *cross dipole*/antena QFH, preamplifier dan perangkat lunak dekoder APT, seperti ilustrasi yang disajikan pada Gambar 1.1. Sistem APT adalah sistem penerima berbiaya rendah, konstruksi dan pemasangan bisa dilakukan sendiri dengan mudah, menyediakan data gratis dan yang andal kapan saja saat dibutuhkan.



Gambar 1.1: Sistem Akuisisi Data Satelit NOAA

1.2 Batasan dan Tujuan

1.2.1 Batasan Penelitian Serta Alasannya

Indonesia merupakan negara yang berada di wilayah khatulistiwa. Radiasi matahari sepanjang hari dan suhu permukaan laut yang cukup hangat menjadi ciri khasnya. Hal ini menyebabkan pembentukan awan secara konvektif menjadi pola utama pembentukan awan di Indonesia. Salah satu awan konvektif yang paling terkenal adalah jenis awan Cb [Fitrianti et al., 2015]. Awan Cb bisa muncul dimana saja karena pemanasan matahari atau gerak vertikal, di tanah lapang atau tempat terbuka dengan panas matahari berlebih, sehingga dalam kondisi ini tekanan rendah terjadi dan akan terjadi perpindahan sejumlah massa udara ke tempat yang bertekanan rendah tersebut. Cuaca ekstrem telah banyak diteliti dengan berbagai metode, salah satu

instrumen yang sering digunakan adalah satelit. Analisis jenis awan dengan satelit dapat dilakukan secara subjektif dan objektif. Subjektif merupakan metode yang secara langsung mengamati cuaca melalui citra satelit. Objektif merupakan metode pengolahan data satelit menjadi produk satelit dengan memanfaatkan sifat dan karakteristik dari beberapa kanal. Namun, analisis subjektif sulit dilakukan karena masih banyak kesalahan dalam interpretasinya sehingga dibutuhkan analisis objektif untuk mendeteksi jenis awan dengan akurat. Setiap daerah memiliki kondisi topografi yang berbeda. Perbedaan ini berakibat pada proses pembentukan awan di suatu daerah dengan daerah yang lainnya tidaklah sama. Misalnya pembentukan awan di laut berbeda dengan pembentukan awan di daratan [Maria and Kukuh, 2016].

Daerah studi yang akan digunakan pada penelitian ini adalah kota Bandar Lampung yang berada di wilayah Indonesia, dengan alasan belum ada penelitian yang dilakukan untuk kota bandar lampung. Data penelitian diperoleh dari data satelit NOAA 18. Lokasi Pengambilan data penelitian di daerah Pondok Rajeg, Kecamatan Cibinong Kabupaten Bogor. Dengan demikian kajian hanya dibatasi pada kegiatan sebagai berikut:

1. Data penelitian yang akan digunakan dalam pengembangan model dari tahun 2019-2021
2. Menggunakan saluran B (*Temperatur Infra Red* = TIR) dari data NOAA/APT 18 yang akan digunakan untuk pengembangan model *tracking* awan Cb.
3. Menggunakan data prediksi awan Cb dari *Meteorological Aviation Report* (METAR) dari stasiun Radin Inten II- Lampung. Data METAR ini digunakan untuk merelokasi titik-titik data dari gambar yang dipilih.
4. Model *tracking* awan Cb akan dikembangkan menggunakan bahasa pemograman *Pyhton*, menerapkan model *machine learning* dengan metode *random forest* (RF).

1.2.2 Definisi Permasalahan dari Penelitian

Awan Cb adalah sejenis awan yang mempengaruhi operasional penerbangan pesawat. Sebuah badai yang muncul dari kehadiran awan Cb adalah yang faktor utama penundaan lepas landas pesawat [Peck, 2015]. Penundaan tersebut dapat menyebabkan kerugian yang tinggi untuk operasi penerbangan. Awan Cb dapat menghasilkan *microburst* dengan turbulensi tingkat rendah, kilat, dan hujan es. Dalam fase

jelajah dan turun, di awan, turbulensi adalah faktor utama kecelakaan pesawat terbang [Mazon et al., 2018]. Awan Cb juga merupakan awan potensial menghasilkan turbulensi parah. Oleh karena itu, prediksi awan Cb merupakan suatu keharusan bagi keselamatan dan efisiensi operasi penerbangan.

Dalam penelitian [Eastman and Warren, 2014], perbandingan dari beberapa gambar menunjukkan bahwa Indonesia adalah salah satu distribusinya area dengan jumlah awan Cb yang signifikan keduanya di atas darat dan laut. Distribusi awan Cb memiliki karakteristik musiman yang dipicu oleh musim hujan. Distribusi petir yang berasal dari Cb juga paling umum di Indonesia [Christian et al., 2003]. Oleh karena itu, penelitian tentang prediksi Cb di Indonesia sangat menarik.

1.2.3 Tujuan Umum dan Khusus dari Penelitian

Tujuan dari penelitian ini adalah mengembangkan model untuk tracking awan Cb di wilayah Indonesia. Daerah studi yang dipilih adalah di kota Bandar Lampung menggunakan data NOAA / APT 18 dari penerima berbiaya rendah yang sistemnya dibuat sendiri. Sebagai *state of the art*, pada penelitian ini diusulkan *tracking* awan Cb secara *real time* sehingga bisa diakses kapan dan dimanapun oleh pengguna yang memerlukannya.

1.3 Kontribusi

Penelitian ini diharapkan dapat memberikan manfaat baik secara teoritis maupun praktis. Penelitian ini akan menganalisis parameter citra awan berdasarkan data sensor satelit NOAA pada proses *tracking* dan klasifikasi jenis awan yang akan divalidasi dengan data METAR. Penelitian akan mengeksplorasi metode pengolahan citra, dan sistem pengenalan pola yang diterapkan untuk *tracking* awan Cb. Dengan demikian, secara teoritis merupakan bentuk aplikasi dan pengembangan analisis matematis untuk identifikasi awan Cb. Secara praktis, penelitian akan memberikan manfaat untuk pengembangan/ modernisasi proses deteksi awan Cb. Keberhasilan sistem ini diharapkan mampu mengatasi permasalahan akses informasi cuaca bagi semua orang, khususnya deteksi awan Cb secara *real time* yang dapat diakses kapan dan dimanapun di wilayah Indonesia.

Bab 2

Tinjauan Pustaka

2.1 Satelit Cuaca (NOAA)

National Oceanic and Atmospheric Administration (NOAA) mengembangkan satelit cuaca yang dikelompokkan berdasarkan orbit satelitnya yaitu orbit polar dan geostasioner. Satelit NOAA dengan orbit polar dikenal dengan sistem satelit *Polar-orbiting Operational Environmental Satellites* (POES). Sistem ini menawarkan keuntungan cakupan harian secara global, dengan membuat orbit kutub hampir 14 kali per hari di ketinggian sekitar 520 mil atau 837 km di atas permukaan bumi [Irawan, 2017]. Satelit NOAA dengan orbit polar memberikan pengamatan lautan bumi, tanah, dan atmosfer, yang digunakan oleh para ilmuwan untuk mempelajari pola cuaca jangka Panjang dan untuk prakiraan cuaca. Administrasi Kelautan dan Atmosfer Nasional AS (NOAA) dan Administrasi Penerbangan dan Antariksa Nasional (NASA) bersama-sama mengembangkannya dan mengoperasikan serangkaian satelit meteorologi yang mengorbit kutub. Satelit pertama dalam seri ini mulai beroperasi pada tahun 1978 dan seri saat ini terdiri dari lima wahana antariksa: NOAA-15, NOAA-16, NOAA-17, NOAA-18, dan NOAA-19. Saat ini satelit dengan sensor AVHRR pada orbit polar yang aktif sebanyak tiga buah, yang disajikan pada 2.1. (*Advandce VHF Ground* [Dascal et al., 2012]).

Satelit cuaca NOAA ditempatkan di orbit kutub dengan kemiringan 98° kemiringan matahari mengelilingi bumi pada jarak sekitar 820 s.d 850 km. Satelit NOAA memiliki periode revolusi 102 menit. Keuntungan utama dalam menggunakan orbit kutub sinkron matahari adalah bahwa satelit NOAA melewati daerah yang sama dan sekitar waktu yang sama setiap hari, memiliki sudut iluminasi matahari optimal yang sama saat mengambil gambar bumi [Dascal et al., 2012].

Tabel 2.1: Satelit NOAA yang Sedang Aktif

Satelit	Frekuensi	Status
NOAA 15	137,6200 MHz FM	ON
NOAA 17	137,5000 MHz FM	NON AKTIF
NOAA 18	137,9125 MHz FM	ON
NOAA 19	137,1000 MHz, FM	ON

2.2 Sistem Akuisisi Data Citra NOAA

Automatic Picture Transmission (APT) dirancang untuk mentransmisikan secara langsung citra satelit ke stasiun penerimaan darat berbiaya rendah. stasiun bumi terdiri dari arah yang dapat dikontrol dan murah antena atau antena arah tetap, penerima VHF, perangkat lunak dan komputer pribadi [Eugene, 2010]. Sinyal APT ditransmisikan dari satelit yang menghasilkan gambar secara terus menerus selama sinyal transmisi diterima di stasiun bumi. Radio penerimaan sinyal APT terbatas pada "garis pandang" dari stasiun bumi dan oleh karena itu hanya dapat diterima Ketika satelit berada di atas cakrawala stasiun bumi pengguna. yang ditentukan oleh ketinggian satelit dan jalur khususnya di atas area penerimaan stasiun bumi [Eugene, 2010]. AVHRR mampu beroperasi dalam mode *real time* atau mode perekaman. Data pembacaan langsung dikirimkan ke stasiun bumi kelas transmisi gambar otomatis (APT) pada resolusi rendah (4x4 km), dimana gambar dihaluskan dengan 8-bit. Tujuan instrumen AVHRR adalah untuk menyediakan data cahaya untuk penyelidikan awan, batas air-tanah, tingkat es dan salju, permukaan es atau salju, distribusi awan siang dan malam, pancaran suhu permukaan, dan suhu permukaan laut, secara pasif diukur, menggunakan kanal inframerah dekat dan kanal radiasi spektra inframerah termal. Data AVHRR telah digunakan untuk banyak aplikasi yang beragam. Secara umum, aplikasi AVHRR/APT mencakup penggunaan meteorologis, klimatologis, dan penggunaan lahan. Kanal AVHRR APT terdiri dari kanal cahaya tampak dan kanal inframerah, yang disajikan pada Tabel 2.2.

Kanal 1, kanal cahaya tampak (*visible*) dan kanal infra merah memiliki cara deteksi awan yang berbeda. Gambar tampak dihasilkan oleh pantulan cahaya matahari pada awan. Sedangkan gambar infra merah dihasilkan oleh radiasi yang dipancarkan oleh awan [Massinai, 2005]

Tabel 2.2: Karakteristik Masing-masing Kanal APT

Kanal	Area Panjang Gelombang	Panjang Gelombang
Kanal 1	0,58 - 0,68	Visible
Kanal 2	0,325 - 1,10	Near Infrared
Kanal 3A	1,58 - 1,64	Thermal Infrared
Kanal 3B	3,55 - 3,95	Thermal Infrared
Kanal 4	10,30 - 11,30	Thermal Infrared
Kanal 5	11,50 - 12,50	Thermal Infrared

2.3 Aplikasi APT

Data APT yang diterima dari satelit NOAA dapat diterima dengan menggunakan peralatan sendiri, sehingga biaya untuk penerimaan sinyal murah. Beberapa peneliti menggunakan data APT untuk penelitian yang mereka lakukan, antara lain menggunakan kanal inframerah dekat dan inframerah termal dari data APT mendemonstrasikan pemetaan pola cuaca dan suhu permukaan laut secara *real time*. [Gjertsen, 1997] menggunakan citra APT inframerah tampak dan termal untuk mengklasifikasikan lapisan awan di atas Eropa tengah. [Torasa, 2009] menggunakan citra APT kanal B (kanal 4 =TIR) untuk estimasi curah hujan dan banyak lagi peneliti lain yang telah melakukan penelitian di bidang ini.

2.4 Awan

Awan adalah kumpulan butiran air dan kristal es yang sangat kecil atau campuran keduanya dengan konsentrasi berorde 100 per centimeter kubik dan mempunyai radius sekitar 10 mikrometer. Awan adalah kumpulan tetesan air yang sangat kecil, kristal es atau campuran keduanya, dengan alasnya di atas permukaan bumi [Sawaisarje and Ranalkar, 2012]. Awan terbentuk jika volume udara lembap mengalami pendinginan sampai di bawah temperatur titik embunnya. Dalam lapisan atmosfer di atas benua maritim Indonesia, pendinginan sangat sering disebabkan oleh ekspansi adiabatik udara yang naik melalui konveksi, orografi dan konvergensi. Jenis awan yang terbentuk disebut awan konvektif, awan orografik dan awan konvergensi. Pendinginan dapat juga disebabkan oleh proses radiatif atau percampuran udara yang berbeda temperatur dan kelembapannya [Tjasyono, 2012].

Usaha untuk memahami sifat awan dan presipitasi mempunyai sejarah yang panjang selama 70 tahun terakhir. Salah satu faktor utama yang merangsang perkembangan fisika awan adalah meningkatnya dunia penerbangan yang peka terhadap

kejadian dan pertumbuhan awan, bahkan awan cumulonimbus dianggap jalur maut dalam penerbangan.

Ahli meteorologi menggunakan gambar satelit untuk menentukan bentuk awan, ketinggian dan tipe/jenis awan. Perubahan pada sifat-sifat awan ini, bersama dengan pergerakan awan, memberikan informasi berharga kepada peramal cuaca, untuk menentukan apa yang ada terjadi, dan apa yang mungkin terjadi pada cuaca di jam dan hari ke depan. Setiap wilayah mempunyai karakteristik wilayah yang berbeda-beda yang mempengaruhi kondisi cuaca lokalnya termasuk karakteristik awannya [Saraswati, 2015].

2.4.1 Identifikasi Jenis Awan dengan Satelit

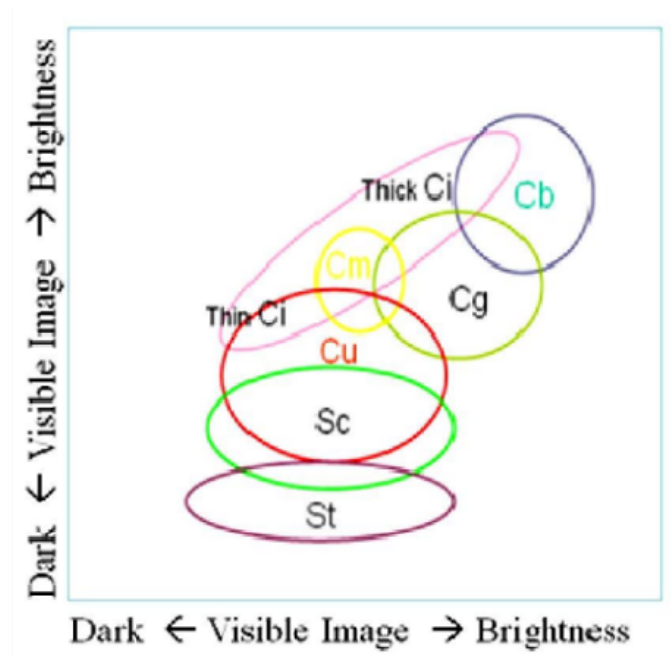
Pemetaan awan dan sistem iklim adalah tugas mendasar dalam peramalan cuaca operasional. Data satelit adalah sumber penting untuk memantau dan memprediksi sistem cuaca. Di sisi lain, tipe awan yang diidentifikasi oleh pengamatan satelit berbeda dari tipe awan yang diidentifikasi oleh permukaan bumi, karena satelit mengamati awan dari jarak yang sangat jauh di atas bumi. Jenis awan diidentifikasi oleh kecerahan pantulan matahari, dan tekstur awan seperti yang diamati dalam citra yang terlihat, dan suhu puncak awan serta tekstur seperti yang diamati pada citra inframerah. Representasi bergambar identifikasi tipe awan menggunakan citra tampak dan inframerah ditunjukkan pada Gambar 2.1.

Identifikasi jenis awan dapat dilakukan dengan menggunakan mata (visual) dan satelit. Pengamatan awan menggunakan mata (visual) adalah pengamatan yang dilakukan dari permukaan bumi, sedangkan satelit mengamati perilaku puncak awan jauh dari atas permukaan bumi. identifikasi awan dengan pengamatan visual disebut "bentuk awan", sedangkan identifikasi awan menggunakan satelit disebut "jenis awan". Jenis awan yang dikelompokkan sebagai **awan-awan stratiform** : **Ci, Cm, St** ; sedangkan kelompok **awan-awan konvektif** : **Cb, Cg, Cu** ; adapun Sc adalah bentuk peralihan keduanya yaitu memiliki karakteristik awan *stratiform* dan konvektif.

2.4.2 Klasifikasi Jenis Awan

Jenis-jenis awan dapat diidentifikasi dengan membedakan klasifikasi awan melalui citra satelit berwarna [Massinai, 2005]. Melalui citra berwarna ini, dapat langsung membedakan jenis-jenis awan, seperti yang disajikan pada Tabel 2.3

Peneliti lain [Sawaisarje and Ranalkar, 2012], mengklasifikasikan awan menjadi sepuluh bentuk atau tipe karakteristik dasar terdiri dari Cirrus (Ci), Cirrocumulus (Cc), Altostratus (As), Stratocumulus (Sc), Cumulus (Cu), Cumulonimbus (Cb), Nimbostratus (Ns), Stratiform (St), Konvektif (Cb, Cg, Cu), dan Peralihan (Sc).



Gambar 2.1: Diagram Identifikasi Jenis Awan

Tabel 2.3: Hasil Klasifikasi Awan Melalui Citra Satelit Penginderaan Jauh

Jenis Awan	Citra Awan Dari Satelit		
	Warna	Tebal/Tipis	Temperatur
Ci	Putih	Tebal	Dingin
	Kebiru-biruan	Tipis	Dingin
Cb	Putih	Tebal	Dingin
Ac	Kuning	-	Relatif Panas
	Agak Terang	Tebal	Relatif Panas
Ns	Putih	Tebal	Relatif Panas
Cs	Putih	Tebal	Relatif Panas
Cu	Hijau Bintik-bintik	Tebal	Relatif Panas
ScSt	Hijau	Tebal	Relatif Panas

mulus (Cc), Cirrostratus (Cs), Altocumulus (Ac), Altostratus (As), Nimbostratus (Ns), Stratocumulus (Sc), Stratus (St), Cumulus (Cu) dan Cumulonimbus (Cb).


2.5 Awan Cumulonimbus (Cb)

Awan cumulonimbus, atau badai petir, adalah awan konvektif atau sistem awan yang menghasilkan curah hujan dan petir. Ini sering menghasilkan hujan es yang besar, hembusan angin yang parah, tornado, dan hujan lebat. Awan Cb menghasilkan sebagian besar curah hujan di daerah tropis selama musim panas di bulan Maret, April dan Mei. Itu merupakan komponen utama badai petir, badai es, tornado, dan badai [Sawaisarje and Ranalkar, 2012].

Awan CB adalah jenis awan cumulus dengan ketebalan vertikal yang besar dan campuran kristal es dibagian atas dan tetes air di bagian bawah, karakteristik ini menyebabkan menurunkan hujan deras namun setelah periode hujan deras kemudian hujan gerimis masih bisa terjadi sangat lama. Masa hidupnya kurang lebih 2 jam. Ketinggian 2000 m - 16.000 m atau setara 6500 - 60.000 ft [Rio, 2013].

Bila ditinjau dari arah dan kecepatan aliran vertikal siklus awan Cb, maka ada tiga tahapan - tahapan pertumbuhan awan Cb yaitu : a) Tahap Pertumbuhan (*Cumulus Stage*), dalam awan terdiri dari arus naik ke atas yang kuat. Hujan belum turun, titik-titik air maupun kristal-kristal es, masih tertahan oleh arus udara yang naik ke atas puncak awan. b) Tahap Dewasa (*Mature Stage*). Titik-titik air tidak tertahan lagi oleh udara naik ke puncak awan. Hujan turun menimbulkan gaya gesek antara arus udara naik dan turun. c) Tahap Mati (*Dissipating Stage*) Tidak ada massa udara naik, massa udara yang turun meluas diseluruh awan. Kondensasi berhenti, udara yang turun melemah hingga berakhir pertumbuhan awan Cumulonimbus (Cb) [Adinda et al., 2015]. Tahapan pembentukan awan Cb seperti disajikan pada Gambar 2.2

Saat malam hari, awan Cb bisa diidentifikasi dengan bantuan petir yang terlihat di langit. Namun, terkadang sulit bagi pengamat untuk mengklasifikasikan Cb dengan landasan dari awan Cb. Awan Cb dengan atau tanpa landasan adalah sumber hujan konvektif selama musim pra-musim dan sedang berbahaya bagi sektor penerbangan [Sawaisarje and Ranalkar, 2012]. Cumulonimbus dengan landasan awan umumnya memiliki puncak awan di atas 0°C. Proses pembentukan presipitasi akan melibatkan fase es di Selain proses hujan hangat. *Downdraft* bisa jadi dimulai dengan pemuatan dan pendinginan air karena penguapan cairan awan atau air hujan dan pencairan es partikel Awan konvektif terbentuk secara vertikal gerakan yang dihasilkan dari faktor penyebab yaitu pemanasan di bagian bawah lapisan udara, pendinginan di bagian atas lapisan udara, pengangkatan atau saturasi yang berpotensi tidak stabil layer dan kombinasi semua hal di atas [Fitrianti et al., 2015].



Gambar 2.2: Menunjukkan tahap cumulus, mature, dan sisipasi. Garis vertikal antara dasar awan dan permukaan presipitasi (hujan atau hujan es). Panah menunjukkan arus turun (textitdownrafts) dan arus naik dalam awan. Bagian atas awan adalah di tropopause.

2.6 Radiance

Dalam radiometri, pancaran adalah fluks pancaran yang dipancarkan, dipantulkan, ditransmisikan, atau diterima oleh permukaan tertentu, persatuan sudut padat per satuan luas yang diproyeksikan. Satuan SI untuk pancaran adalah Watt per Steradian per meter persegi ($W Sr^{-1} m^{-2}$), [Wikipedia, 2020].

Nilai radiansi menunjukkan besarnya energi gelombang elektromagnetik per satuan luas bidang yang terpancar dari suatu obyek. Proses konversi ke nilai radiansi akan mengubah nilai-nilai digital piksel (*Digital number* = DN) (bilangan integer, untuk grey scale nilainya antara 0 sampai 255) menjadi bilangan riil dengan kisaran nilai yang berbeda pada setiap panjang gelombang atau masing-masing band. Konversi DN ke nilai radiansi pada satelit harus dihitung berdasarkan fungsi kalibrasi instrumennya [Yuliara et al., 2015]. Berikut contoh perhitungan untuk satelit landsat. Dalam hal ini besarnya radiansi diekspresikan pada persamaan 2.1.

$$I_{\lambda} = a(DN) + b \quad (2.1)$$

Dimana :

DN = Nilai piksel (*Digital Number*)

$a = \text{gain}$ dan $b = \text{offset}$

Setiap band spektral akan memiliki nilai-nilai *gain* dan *offset* yang berbeda. Satuan radiansi adalah Watts per meter persegi per steradian per mikron ($Wm^{-2}Sr^{-1}\mu m^{-1}$).

Untuk mengubah nilai DN gambar APT menjadi *radiance* (E), dapat menggunakan persamaan 2.2. (*National Aeronautics and Space Administration*, 1998). Data masukan nilai DN (C) membutuhkan nilai 10-bit (0-1023) tetapi DN dari APT gambar adalah nilai skala abu-abu 8-bit (0-255). Oleh karena itu, nilai 8-bit haruslah diubah menjadi nilai 10-bit. Persaman yang dapat digunakan adalah sebagai berikut:

$$E = C.S + I \quad (2.2)$$

Dimana :

$E = \text{Radiance}$ dalam ($mW/m^2 - Sr - cm^{-1}$)

C = Masukkan Nilai DN (0-1023)

S = Nilai kemiringan ($-0.160156 (mW/m^2 - Sr - cm^{-1})$)

I = Nilai intersep ($159.088867 (mW/m^2 - Sr - cm^{-1})$)

Radiance berguna karena menunjukkan berapa banyak daya yang dipancarkan, dipantulkan, ditransmisikan, atau diterima oleh suatu permukaan akan diterima oleh sistem optik yang melihat permukaan itu dari sudut pandang tertentu.

2.7 Temperatur Kecerahan (*Brightness Temperature* = T_b)

Brightness Temperature (disebut juga sebagai T_b) adalah ukuran pancaran radiasi gelombang mikro yang bergerak ke atas dari atas atmosfer bumi. Konversi dari jumlah radiometer ke T_b bagian atas atmosfer disebut proses kalibrasi. Beberapa langkah pemrosesan kalibrasi diperlukan untuk mendapatkan nilai T_b . *Microwave* radiometer T_b dianggap sebagai catatan data iklim fundamental dan merupakan nilai yang digunakan untuk mengukur kecepatan angin, uap air, air cair awan, curah hujan, dan suhu permukaan laut.

Brightness Temperature bukanlah suhu seperti yang biasanya dipahami. Ini mencirikan radiasi, dan tergantung pada mekanisme radiasi dapat sangat berbeda dari suhu fisik benda yang memancar (meskipun secara teoritis memungkinkan untuk membuat perangkat yang akan memanaskan oleh sumber radiasi dengan beberapa suhu kecerahan ke suhu aktual yang sama).

Nilai T_b dapat ditentukan dengan mengubah nilai *Radiance* pada persamaan 2.2 menggunakan persamaan 2.3 (*National Aeronautics and Space Administration*, 1998).

$$T_b = \frac{C_2 \cdot V}{\ln(1 + \frac{C_1 V^3}{E})} \quad (2.3)$$

Dimana: T_b = *Brightness temperature* dalam ° Kelvin

C_1 = 1,1910659 x10⁻⁵ (mW/m² – Sr – cm⁻¹)

C_2 = 1,438833 cm – K

E = Radiance dalam (mW/m² – Sr – cm⁻¹)

V = Nilai gelombang center untuk Kanal 4 AVHRR dalam cm⁻¹

Nilai gelombang center NOAA 15 = 925,4075 cm⁻¹


Nilai Gelombang center NOAA 18 = 928,1460 cm⁻¹

2.8 Metode *Random Forest* (RF)

Tahun 2001, Breiman merupakan orang yang pertama kali memperkenalkan *Random Forest* dalam teknik bagging. Pada penelitiannya, Breiman menyebutkan beberapa kelebihan dari *Random Forest* diantaranya dapat memberikan hasil akhir klasifikasi dengan baik disertai dengan tingkat *error* yang lebih rendah, mampu mengatasi jumlah data yang banyak dengan lebih baik serta merupakan sebuah algoritma yang baik untuk mengatasi *missing data* [Breiman, 2001].

Pendekatan hutan acak untuk klasifikasi membangun pohon keputusan dan kemudian menggabungkannya secara acak [Castro Franco et al., 2017]. Pendekatan hierarkis *random forest classifier* adalah teknik yang menggunakan urutan kriteria keputusan pada pola yang tidak diketahui untuk pelabelannya. Sebuah *node root*, satu set *node internal*, dan node daun (*end node*) membentuk pohon keputusan. Node akar dan tengah mewakili tahap keputusan, sedangkan node akhir mewakili klasifikasi akhir. Untuk mengimplementasikan proses klasifikasi, seperangkat aturan menetapkan jalur yang perlu diikuti. Ini dimulai pada simpul akar dan berakhir ketika item yang akan diklasifikasikan mencapai simpul daun. Node terakhir ini akan memberikan label yang sesuai ke objek yang akan diklasifikasikan.

Cara menuju ke simpul berikutnya ditentukan di setiap simpul perantara. Gambar 2.3 menampilkan penggunaan nilai reflektansi sebagai input untuk menemukan kelas hipotesisnya masing (yaitu antara "1" dan "7" untuk menghasilkan hierarki pohon keputusan. Sebagai contoh, sifat keputusan yang diambil sebagai basis dan urutan pemilihan pita spektral akan mempengaruhi hasil klasifikasi. Oleh karena itu, pencarian konfigurasi pohon yang optimal untuk digunakan dalam klasifikasi sangat diperlukan.



Gambar 2.3: Contoh Pohon Keputusan

Indeks yang paling banyak digunakan dalam induksi pohon keputusan adalah indeks penguatan informasi dan indeks Gini pengotor (*impurity Gini index*). Keduanya menggunakan perangkat lunak R. Untuk menghitung penguatan informasi, pertama-tama harus diperoleh masing-masing entropi di node yang diberikan seperti yang ditunjukkan persamaan 2.4.

$$I_E(t) = - \sum_{j=1}^m f(t, j) \log_2 f(t, j) C.S + I \quad (2.4)$$

Dimana $f(t, j)$ adalah proporsi sampel pelatihan milik kelas j , $j \in \{1, 2, \dots, m\}$, pada simpul t , dan m adalah jumlah kelas. Jika simpul t berisi N_t sampel, maka

$f(t, j)$ dihitung dengan persamaan 2.5:

$$f(t, j) = \frac{1}{N_t} \sum_{i=1}^{N_t} \Gamma(y_i, j), \Gamma(y_i, j) = \begin{cases} 1, & \text{apabila } y_1 = 1, \\ 0, & \text{lainnya} \end{cases} \quad (2.5)$$

Terakhir, untuk partisis pada atribut X , masing-masing penguatan informasi dihitung menggunakan persamaan 2.6.

$$Gain(t, X) = I_E(t) - \left(\frac{n_1}{N_t} I_E(t_X(X_1)) - \left(\frac{n_2}{N_t} I_E(t_X(X_2)) \dots - \left(\frac{n_r}{N_t} I_E(t_X(X_r)) \right. \right. \right) \quad (2.6)$$

Indeks pengotor Gini mengukur pengotor fungsi input sehubungan dengan kelas yang mencapai minimum (nol) ketika semua atribut dalam simpul jatuh ke dalam satu kelas informasi. Indeks Gini $I_G(t_X(X_i))$ terkait dengan $X \in x_1, x_2, \dots, x_r$ atribut untuk simpul t dinyatakan dalam persamaan 2.7.

$$I_G(t_X(x_i)) = 1 \sum_{j=1}^m f(t_X(x_i), j)^2 \quad (2.7)$$

Pendekatan klasifikasi berdasarkan metode *Random Forest* menggabungkan pohon klasifikasi yang dihasilkan menggunakan dataset sampel pelatihan acak salah satunya. Setiap pohon memberikan keputusan ke kelas di mana harus ditempatkan vektor input [Breiman, 2001]. Pendekatan untuk menghasilkan *Random Forest* menggabungkan metode *bagging* dan sub ruang acak. Teknik *Bagging* [Breiman, 1996], terdiri dari subset pelatihan secara acak berukuran n dari ukuran set pelatihan N ($n < N$), jika pita spektral M tersedia, subset m ($m < M$) dipilih secara acak untuk menghitung partisi terbaik pada setiap node (menggunakan Gini).

2.9 Perbandingan Tinjauan

Awan merupakan indikator utama dalam menentukan keadaan cuaca. Masing-masing jenis awan mempunyai arti yang berbeda. Adanya awan Cb dengan bentangan awan yang cukup luas pada suatu daerah dapat diasumsikan sebagai indikasi keadaan cuaca buruk karena akan turun hujan lebat. Awan stratocumulus menandakan daerah tersebut cenderung hujan gerimis. Namun, sering kali awan ini merupakan tanda bahwa cuaca yang lebih buruk akan datang. Sifat-sifat awan seperti ketinggian puncak awan, suhu, pancaran infra merah, berdampak besar pada hasil pemantauan atmosfer (peramalan fenomena meteorologi) [Feidas et al., 2000].

Karena alasan tersebut di atas, deteksi awan dalam citra penginderaan jauh merupakan langkah yang sangat penting. Penelitian yang terkait dengan awan menggunakan data citra satelit telah banyak dilakukan peneliti dengan berbagai metode yang digunakan. Teknik deteksi awan yang relevan dapat dibagi menjadi dua kelas utama: *thresholding* pendekatan yang berasal dari pengamatan fisik atau empiris, dan berbasis *Machine Learning* (ML) pendekatan yang mengandalkan penalaran statistik [Francis et al., 2019]. Beberapa penelitian untuk mengembangkan metode seperti untuk estimasi jumlah awan, tipe awan yang pernah dilakukan peneliti diantaranya dilakukan oleh [Massinai, 2005] yang menggunakan data Cuaca berdasarkan radar cuaca dan satelit MTSAT. Sementara pada receiver-nya dipergunakan jenis *image processing* menggunakan *gray level*. Penelitian lainnya dilakukan oleh [Sudiana, 2009] menggunakan data dari satelit NOAA, receiver-nya bersifat permanen sehingga tidak bisa dimobilisasi. Heidinger dkk. di [Heidinger et al., 2012] melakukan pendekatan Naive Bayesian untuk deteksi awan. Metodologi semacam ini telah diadopsi untuk deteksi awan pada data AVHRR NOAA. Penulis [Alkhatib et al., 2012b] menggunakan metode *region growing* untuk segmentasi awan debu. Para penulis [An and Shi, 2015b], untuk menyelesaikan tugas pendeteksian awan, mengusulkan pendekatan *supervised* otomatis berdasarkan skema pembelajaran skenario . Secara lebih rinci, mereka mensimulasikan semacam data struktural kubik dengan mempertimbangkan fitur gambar yang berbeda seperti warna, informasi statistik, tekstur, dan struktur. [Lin et al., 2015] mengusulkan langkah normalisasi radiometrik untuk melakukan deteksi awan pada citra satelit optik menggunakan piksel invarian. [Karlsson et al., 2015] memeriksa dua metode probabilistik untuk penyamaran awan menggunakan gambar dari satelit NOAA AVHRR. [Bai et al., 2016] melakukan deteksi awan dengan pembelajaran mesin dan fusi multi-fitur berdasarkan analisis komparatif dari fitur-fitur khas seperti spektral dan tekstur [Ardizzone et al., 2013]. Pendekatan yang diawasi menggunakan jaringan saraf diusulkan dalam [Yhann and Simpson, 1995b] untuk mendeteksi awan di atas lautan menggunakan data AVHRR. Selain metode tersebut ada dalam pembelajaran berbasis teknik [Shi et al., 2016b] di mana penulis menggunakan *Convolutional Neural Networks* (CNNs) yang terdiri dari empat lapisan convolutional dan dua lapisan terhubung sepenuhnya, yang dapat menggali fitur mendalam awan. [Francis et al., 2019] melakukan penelitian pendeteksian awan dalam citra tampak dan multispektral dari kamera satelit resolusi tinggi memperkenalkan metode CloudFCN, berdasarkan arsitektur Jaringan Konvolusi Penuh, yang dikenal sebagai U-net, yang telah menjadi pendekatan *Deep Learning* standar untuk segmentasi gambar. Hasil Penelitian salomon menunjukkan bahwa algoritma SVM memberikan klasifikasi objek awan hujan yang lebih akurat daripada metode am-

bang *Brightness temperature* IR tradisional menggunakan data citra satelit meteorologi Geostasioner-13 di atas wilayah benua colombia. [Sim et al., 2018], dalam penelitiannya mengusulkan beberapa model pendeteksian lapisan es berbasis *machine learning* dan dibandingkan dengan model teori fisik yang ada menggunakan data satelit COMS dan Himawari-8. Metode *machine learning Random Forest* (RF) dan Model *Log Linear Multinomial* (MLL) adalah versi perbaikan dari regresi logistik yang menggabungkan pendekatan jaringan syaraf tiruan untuk optimasi parameter. [Tu, 1996] digunakan untuk mengembangkan model deteksi lapisan es. Kedua model berbasis *machine learning* menghasilkan kinerja yang lebih baik (POD 68-82% dan POFD 16-18%) dibandingkan model berbasis teori fisik yang ada (POD 12-36% dan POFD 7-27%) ketika data COMS digunakan. Secara keseluruhan, model RF menghasilkan kinerja yang lebih baik daripada model MLL menggunakan validasi silang lima kali lipat. Namun, model RF menghasilkan kesalahan standar yang lebih tinggi dalam metrik kinerja daripada model MLL, yang menyiratkan kecenderungan untuk *overfitting*. Selain untuk klasifikasi awan atau deteksi awan menggunakan data satelit, metode *machine learning* juga diaplikasikan ke bidang lain, antara lain, metode *random forest*, SVM dan klasifikasi *likelihood maximum* dalam klasifikasi citra satelit yang lain yaitu untuk membedakan tanaman kapas [Valero Medina and Alzate Atehortúa, 2019]. Hasil menunjukkan, bahwa dengan menggunakan pendekatan *likelihood maximum* keberhasilan dalam mengklasifikasi tanaman kapas sebesar 68,95%, SVM sebesar 81,325%, dan dengan *Random Forest* sebesar 78,925%. Dalam penelitian ini metode SVM mempunyai tingkat keberhasilan yang lebih tinggi. Peneliti [Gumma et al., 2020] menggunakan metode *Random Forest* untuk memetakan luas lahan pertanian produksi dengan tepat dan akurat di seluruh Asia Selatan (India, Pakistan, Bangladesh, Nepal, Sri Lanka dan Bhutan) menggunakan data satelit Landsat. Dari tinjauan yang dilakukan, maka dalam penelitian ini, akan diusulkan menggunakan model *machine learning* dengan metode *Random Forest* untuk *tracking* awan Cb.

Bab 3

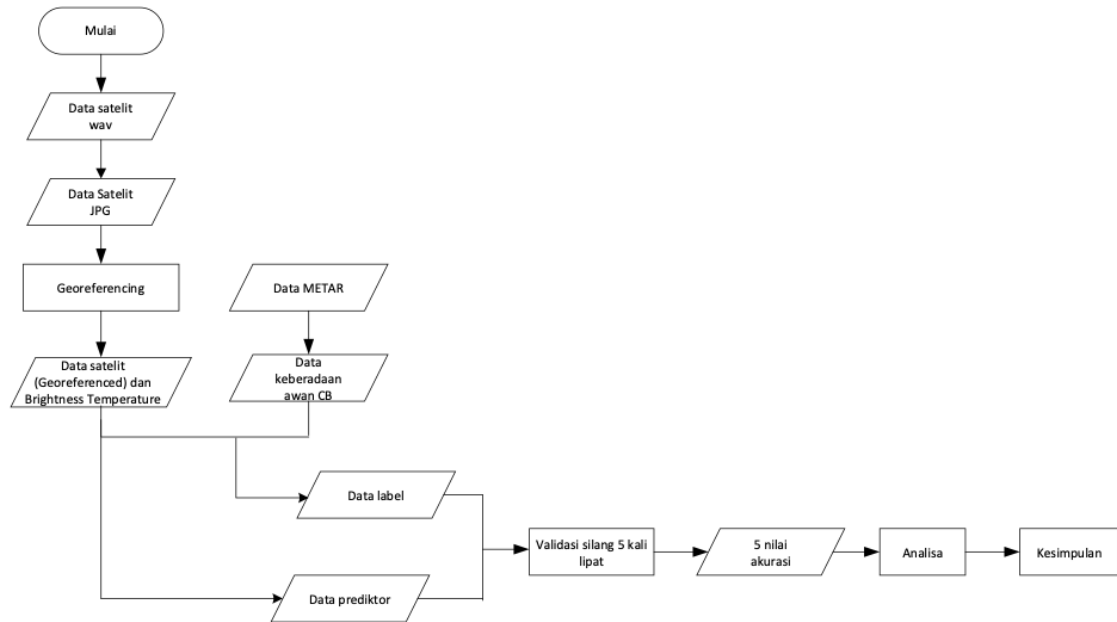
Metodologi

3.1 Motivasi

Penelitian yang akan dilakukan ini didasari dari penelitian sebelumnya, yaitu berhasil dibangun sebuah sistem penerima Transmisi Gambar Otomatis (APT) dari satelit NOAA yang disajikan pada Gambar 1.1. Sistem APT dapat menerima sinyal dengan benar saat satelit NOAA yang mengorbit melewati wilayah Indonesia, yang menghasilkan citra berupa awan. Sistem receiver APT NOAA ini yang dapat menyediakan data gratis, kapan saja dibutuhkan tersedia karena bersifat *real time* dan kemudian mengolahnya secara langsung, maka dalam hal ini ingin melakukan penelitian selanjutnya yaitu mengembangkan sebuah model untuk mendeteksi atau *tracking* awan Cb dengan menggunakan data APT NOAA dari sistem yang dibuat dan data meteorologi (METAR). Sistem ini diharapkan mampu mengatasi permasalahan akses informasi cuaca bagi semua orang. Adapun rumusan masalah dari penelitian ini adalah: Metode apa yang cocok digunakan untuk melakukan penyamaan titik koordinat dari data APT dengan titik koordinat pulau Indonesia?, Bagaimana menentukan ekstraksi ciri yang tepat untuk mengklasifikasi awan Cb?, Metode atau algoritma apa yang cocok digunakan?

3.2 Framework Riset

Perancangan penelitian merupakan tahapan yang merepresentasikan langkah-langkah tujuannya untuk memudahkan peneliti dalam melakukan penelitian. Berikut adalah tahapan penelitian yang akan dilakukan, yang dapat dilihat secara jelas pada Gambar 3.1. *flowchart* proses penelitian menunjukkan rencana atau struktur penelitian yang akan digunakan untuk memecahkan permasalahan dalam penelitian ini.



Gambar 3.1: *Flowchart* Proses Penelitian untuk *Tracking* Awan Cb

Sebagaimana dapat dilihat pada Gambar 3.1 blok diagram sistem penerima yang merupakan diagram alir sistem penerimaan data sinyal informasi yang di terima dari satelit. Sistem data akuisisi dapat secara otomatis mendeteksi dan menerima sinyal informasi satelit ketika melewati sistem. Sinyal informasi ditangkapi oleh antena *Cross Dipole* Bunga (CDB) dan QFH kemudian dipisahkan dari *carriernya* oleh radio penerima. Setelah sinyal informasi didapatkan, sound card akan bekerja untuk mengubah data analog menjadi data digital. Kemudian sinyal digital diolah dan direkam dalam bentuk file wav. Data wav yang diperoleh dari aplikasi Wxtoimg yang diubah ke bentuk citra/gambar wilayah Indonesia dengan format JPG. Ini adalah tahap pengumpulan data penelitian. Selanjutnya data penelitian diolah untuk mendapatkan data *georeferencing* dan nilai *brightness temperature* (Tb). Di mana nilai Tb ini akan digunakan sebagai data ekstraksi fitur untuk tracking awan Cb. *Feature Extraction* atau ekstraksi fitur adalah proses untuk mendapatkan ciri-ciri pembeda yang membedakan suatu objek dari objek yang lain. Ekstraksi fitur merupakan suatu pengambilan ciri (*feature*) dari suatu bentuk yang nantinya nilai yang didapatkan akan dianalisis untuk proses selanjutnya. Ekstraksi fitur bertujuan untuk mencari daerah fitur yang signifikan pada gambar tergantung pada

karakteristik intrinsik dan aplikasinya.

Kumpulan Data METAR dan satelit APT, data METAR sebagai label yaitu sumber data adanya Cb atau tidak ada Cb, sementara data satelit sebagai prediktor keberadaan Cb menggunakan model *machine learning* dengan metode *random forest* validasi silang 5 kali lipat sehingga diperoleh nilai akurasi yang tepat. Alasan pemilihan metode *random forest* ini karena untuk pengklasifikasi yang sangat efektif dan tahan terhadap *overfitting* (Oliphant et al., 2019) ; (Teluguntla et al., 2018); (Xiong et al., 2017a) ; (Rodriguez-Galiano et al., 2012). . Selanjutnya hasil yang diperoleh dianalisa dan diperoleh kesimpulan dari metode yang digunakan.

3.3 Pendekatan

3.3.1 Pemilihan Data APT

Wilayah studi penelitian ini adalah wilayah Indonesia secara umum, secara khusus area penelitian yang dipilih adalah kota Bandar Lampung. Berdasarkan letak astronomisnya Indonesia terletak diantara 6° LU- 11° LS dan 95° BT- 141° BT, seperti dapat dilihat pada Gambar 3.2 yang memiliki iklim tropis. Berdasarkan letak geografisnya Indonesia terletak diantara dua benua dan dua samudera, yaitu benua Asia dan benua Australia. Indonesia juga terletak diantara dua samudera yaitu Samudera Hindia dan Samudera Pasifik [Pustekkom kemendikbud, 2017]. Karena letak geografisnya Indonesia dipengaruhi oleh angin muson barat dan angin muson timur yang menyebabkan Indonesia memiliki dua musim yaitu musim hujan dan musim kemarau. Dari bulan November hingga Maret, angin bertiup dari arah Barat Laut membawa banyak uap air dan hujan di kawasan Indonesia; dari Mei hingga Oktober angin bertiup dari Tenggara yang bersifat kering, membawa sedikit uap air.

Indonesia selain letak yang sangat strategis juga merupakan salah satu negara terluas didunia dengan total luas negara $5.193.250 \text{ km}^2$ mencakup daratan dan lautan. Iklim Indonesia adalah tropis dengan suhu rata-rata berkisar antara 23°C sampai 28°C sepanjang tahun. Suhu rata-rata maksimal mencapai 40°C pada musim kemarau di lembah Palu, Sulawesi Tengah dan di pulau Timor, sedangkan suhu rata-rata minimum sampai di bawah 0°C di Pegunungan Jayawijaya, Papua. Curah hujan di Indonesia rata-rata 1.600 milimeter setahun, namun juga sangat bervariasi; dari lebih dari 7000 milimeter setahun sampai sekitar 500 milimeter setahun di daerah Palu dan Timor.

Kota Bandar Lampung pintu gerbang Pulau Sumatera. Sebutan ini layak untuk ibu kota Propinsi Lampung. Kota yang terletak di sebelah barat daya Pulau Sumatera ini memiliki posisi geografis yang sangat menguntungkan. Letaknya di



Gambar 3.2: Letak Astronomis Indonesia

ujung Pulau Sumatera berdekatan dengan DKI Jakarta yang menjadi pusat perekonomian negara. Secara geografis wilayah Kota Bandar Lampung berada antara $50^{\circ}20' - 50^{\circ}30' \text{ LS}$ dan $105^{\circ}28' - 105^{\circ}37' \text{ BT}$ dengan luas wilayah 192.96 km^2 dengan batas-batas sebagai berikut: Batas Utara, Kecamatan Natar, Kabupaten Lampung Selatan. Batas Selatan : Kecamatan Padang Cermin, Ketibung dan Teluk Lampung, Kabupaten Lampung Selatan. Batas Timur : Kecamatan Tanjung Bintang, Kabupaten Lampung Selatan. Batas Barat : Kecamatan Gedungtataan dan Padang Cermin Kabupaten Lampung Selatan, yang disajikan pada Gambar 3.3.

Data citra dari satelit NOAA/APT yang digunakan dalam penelitian ini diperoleh atau diterima setiap hari dari sistem yang terpasang di daerah pondok rajeg Cibinong yang berada pada titik koordinat longitude $106,8234^{\circ}\text{E}$ dan latitude $6,4583^{\circ}\text{S}$ dengan mengikuti jadwal orbit satelit NOAA 18. Data yang digunakan adalah data kanal B atau kanal 4 (*Temperature Infra Red* = TIR) dengan daerah panjang gelombang $10.3 - 11.3 \mu\text{m}$. Pada Kanal Inframerah (infra red), sistem awan dan permukaan dikenali pada kanal ini melalui radiasi thermal yang dipancarkan



Gambar 3.3: Letak Geografis Kota Bandar Lampung

oleh awan dan permukaan. Semakin dingin semakin terang (*white*) sedangkan semakin hangat semakin gelap (*black*) [M.Ryan]. Saluran 4 adalah saluran panjang gelombang inframerah dan efektif baik siang maupun malam hari. Pita TIR dari citra APT yang digunakan dalam penelitian ini menunjukkan hubungan antara kecerahan dan suhu awan yang mana mengidentifikasi area berawan. Data APT yang dipilih akan digunakan untuk mencari hubungan antara nilai *Brightness temperature* dan prediksi awan Cb yang dicatat oleh stasiun Radin Inten II Bandar Lampung. Pemilihan data APT lainnya adalah untuk validasi model. Gambar APT dengan sinyal yang jelas, diterima selama 2019 - 2021 dipilih untuk diformat ulang lebih lanjut dan kemudian diekstraksi sebagai data titik secara spasial sesuai dengan di stasiun Radin Inten II Bandar Lampung.

3.3.2 Georeferencing Data

Proses *georeferencing* ini bertujuan untuk menyamakan posisi dari koordinat citra dengan koordinat yang dijadikan acuan di Indonesia [Surahman et al., 2015]. Dalam penelitian ini yang dijadikan acuan adalah peta Indonesia dari Bakosurtanal berupa file *acuan_indopul.erv*. Proses *georeferencing* (format ulang gambar APT) yang dihasilkan diperlukan karena gambar yang dihasilkan wxtoimg dapat menampilkan data dalam bentuk gambar dengan data posisi piksel, nilai *Digital Number* (DN), dan suhu kecerahan, tetapi tidak mendukung semua fungsi yang diperlukan untuk

aplikasi. Gambar dapat diekspor ke beberapa format misalnya foto bersama (.jpg), bit mapped (.bmp), jaringan portabel grafik (.png), peta portabel (.pnm), tetapi tanpa posisi geo-referensi (lintang / bujur) dan suhu data yang diperlukan untuk bekerja dengan perangkat lunak Penginderaan Jauh dan GIS umum. Oleh karena itu, pemformatan ulang gambar APT yang diekspor diperlukan [Torasa, 2009].

Data penelitian ini data yang digunakan berupa gambar dari satelit yang di simpan dalam format file. JPG. Proses georeferencing yang dilakukan menghasilkan data geo-referensi dan suhu kecerahan secara terpisah. Data ini yang akan digunakan pada tahap selanjutnya, yaitu tahap pengolahan citra.

Langkah-langkah yang digunakan untuk proses *georeferencing* adalah sebagai berikut:

1. Tangkap data satelit NOAA dalam bentuk audio WAV.
2. Dapatkan nilai data orbit satelit yang lebih dikenal dengan data TLE1 dan TLE2 dari <http://celestrak.com/NORAD/elements/NOAA.txt> untuk data satelit NOAA yang bersangkutan. Dalam penelitian ini menggunakan data satelit NOAA 18.
3. Catat waktu awal (AOS) data ditangkap dan berapa durasi data WAV yang didapatkan
4. Dari waktu awal dan durasi data WAV, didapatkan waktu berakhir data satelit (LOS)
5. Konversi data WAV tersebut ke bentuk gambar jpg
6. Cari 4 koordinat lintang dan bujur pada 4 sudut gambar yang telah dihasilkan pada langkah 5 menggunakan tool dari <https://github.com/gut-space/noaa-tools/blob/master/noaatools/georef.py>
7. Interpolasi matrix koordinat lintang dan bujur secara linear dari 4 titik yang telah didapatkan koordinatnya menggunakan *script python*. Hasilnya adalah suatu file excel dengan kolom lintang, bujur dan *Brightness Temperature*(T_b).

3.3.3 Penentuan Nilai *Brightness Temperature* (T_b)

Selanjutnya langkah-langkah yang digunakan untuk menentukan nilai *Brightness Temperature* adalah sebagai berikut:

1. Konversi data gambar satelit (RGB) ke *greyscale* (g), menggunakan persamaan 3.1, dimana dimana R adalah untuk nilai warna merah, G untuk hijau, dan B adalah warna biru.

$$g = 0.2989R + 0.5870G + 0.1140B \quad (3.1)$$

2. Konversi nilai *greyscale* 8 bit (0-255) ke 10 bit (0-1023), yang dilambangkan dengan (g') pada persamaan 3.2,

$$g' = \frac{g}{255}1023 \quad (3.2)$$

3. Konversi nilai g' ke *radiance* (E), menggunakan persamaan 3.3

$$E = -0.160156g' + 159.088867 \quad (3.3)$$

4. Konversi nilai *radiance* ke *Brighness Temperature* (T_b), menggunakan persamaan 2.3.

3.3.4 Pengembangan Model *Tracking* Awan Cb Menggunakan *Random Forest*

Sebagaimana di lihat pada Gambar 3.1 untuk tracking awan Cb yaitu menggunakan metode *machine learning*, adapun langkah-langkah yang digunakan adalah sebagai berikut:

1. Kumpulkan data METAR dan satelit. Data METAR sebagai label yaitu sumber data adanya Cb atau tidak ada Cb. Sementara data satelit sebagai prediktor keberadaan Cb.
2. Ambil data T_b pada radius sekitar koordinat daerah METAR yang diambil sehingga terdapat 9 nilai T_b dari 9 titik dari pusat koordinat daerah METAR.
3. Model *Machine Learning* yang akan digunakan adalah *Random Forest*. Evaluasi model *machine learning* ini menggunakan validasi silang 5 kali lipat.

Pendekatan yang digunakan pada penelitian ini untuk *tracking* awan Cb adalah menggunakan model *machine learning* dengan pendekatan metode *Random Forest*, sedangkan untuk evaluasi model *machine learning* ini menggunakan validasi silang 5 kali lipat. Metode validasi silang adalah metode pergantian data latih dan data tes yang digunakan oleh model prediksi. Pada validasi silang, harus ditentukan

1	2	3	4	5
1	2	3	4	5
1	2	3	4	5
1	2	3	4	5
1	2	3	4	5

Gambar 3.4: Metode *Random Forest* dengan Model Validasi Silang 5 Kali Lipat

dulu ada berapa kali lipat yang diinginkan. Misal validasi silang yang diinginkan adalah 5x lipat, maka data akan dibagi menjadi 5 bagian seperti pada Gambar 3.4.

Pada Gambar 3.4 warna merah menunjukkan bahwa data tersebut menjadi data tes sedangkan warna putih menunjukkan kalau data tersebut adalah data latih. Data latih digunakan untuk membentuk model agar dapat memprediksi dengan baik sedangkan data tes digunakan untuk mengukur performa model prediksi yang digunakan. Pada akhirnya, akan didapatkan 5 nilai akurasi. Biasanya, 5 nilai akurasi itu akan di ambil rata-ratanya untuk mendapatkan akurasi yang sebenarnya dari model prediksi.

Bibliografi

- [Adinda et al., 2015] Adinda, D., Agung, H., Muchlisin, P., Rahma, F., and Riadi (2015). Potensi turbulensi pada peristiwa kecelakaan pesawat air asia qz850. *Jurnal Meteorologi Klimatologi dan Geofisika*, 2.
- [Alkhatib et al., 2012a] Alkhatib, M. Q., Cabrera, S. D., and Gill, T. E. (2012a). Automated detection of dust clouds and sources in noaa-avhrr satellite imagery. In *2012 IEEE Southwest Symposium on Image Analysis and Interpretation*, pages 97–100.
- [Alkhatib et al., 2012b] Alkhatib, M. Q., Cabrera, S. D., and Gill, T. E. (2012b). Automated detection of dust clouds and sources in NOAA-AVHRR satellite imagery. In *2012 IEEE Southwest Symposium on Image Analysis and Interpretation*, pages 97–100, Santa Fe, NM, USA. IEEE.
- [An and Shi, 2015a] An, Z. and Shi, Z. (2015a). Scene learning for cloud detection on remote-sensing images. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 8(8):4206–4222.
- [An and Shi, 2015b] An, Z. and Shi, Z. (2015b). Scene Learning for Cloud Detection on Remote-Sensing Images. *IEEE J. Sel. Top. Appl. Earth Observations Remote Sensing*, 8(8):4206–4222.
- [Ardizzone et al., 2013] Ardizzone, E., Bruno, A., and Mazzola, G. (2013). Scale detection via keypoint density maps in regular or near-regular textures. *Pattern Recognition Letters*, 34(16):2071–2078.
- [Bai et al., 2016] Bai, T., Li, D., Sun, K., Chen, Y., and Li, W. (2016). Cloud Detection for High-Resolution Satellite Imagery Using Machine Learning and Multi-Feature Fusion. *Remote Sensing*, 8(9):715.
- [Breiman, 1996] Breiman, L. (1996). *Bagging Predictors*. Machine Learning.

- [Breiman, 2001] Breiman, L. (2001). *Random Forest*. Machine Learning.
- [Castro Franco et al., 2017] Castro Franco, M., Garcia Ramirez, D. Y., and Jimenez Lopez, A. F. (2017). Comparison of spatial interpolation techniques to predict soil properties in the colombian piedmont eastern plains. *Tecnura*, 21(53):78–95.
- [Christian et al., 2003] Christian, H. J., Blakeslee, R. J., Boccippio, D. J., Boeck, W. L., Buechler, D. E., Driscoll, K. T., Goodman, S. J., Hall, J. M., Koshak, W. J., Mach, D. M., and Stewrt, M. F. (2003). Global frequency and distribution of lightning as observed from space by the optical transient detector. *Journal of Geophysical Research*, 108:4 1 – 4 15.
- [Dascal et al., 2012] Dascal, V., Dolea, P., Cristea, O., and Palade, T. (2012). Advanced vhf ground station for noaa weather satellite apt image reception. *ACTA TECHNICA NAPOCENSIS*, 53:1–7.
- [Eastman and Warren, 2014] Eastman, R. and Warren, S. G. (2014). Diurnal cycles of cumulus, cumulonimbus, stratus, stratocumulus, and fog from surface observations over land and ocean. *Journal of Climate*, 27(6):2386–2404.
- [Feidas et al., 2000] Feidas, H., Cartalis, C., and Cracknell, A. (2000). Use of meteosat imagery to define clouds linked with floods in greece. pages 1047–1072.
- [Field and Furtado, 2015] Field, P. and Furtado, K. (2015). How biased is aircraft cloud sampling? *Journal of Atmospheric and Oceanic Technology*, 33:151210144212009.
- [Fitrianti et al., 2015] Fitrianti, N., Fauziyah, A. R., and Fadila, R. (2015). Analisa pola hidup dan spasial awan comulonimbus menggunakan citra radar (studi kasus wilayah bima bulan januari 2015). *Meteorologi Klimatologi dan Geofisika*, 2:51–61.
- [Francis et al., 2019] Francis, A., Sidiropoulos, P., and Muller, J.-P. (2019). CloudFCN: Accurate and Robust Cloud Detection for Satellite Imagery with Deep Learning. *Remote Sensing*, 11(19):2312.
- [Gjertsen, 1997] Gjertsen, U. (1997). The seasonal variation of cloud parameters over Central Europe: a fuzzy approach for the analysis of NOAA-APT data. *Atmospheric Research*, 45(2):123–152.
- [Gumma et al., 2020] Gumma, M. K., Thenkabail, P. S., Teluguntla, P. G., Oliphant, A., Xiong, J., Giri, C., Pyala, V., Dixit, S., and Whitbread, A. M. (2020).

- Agricultural cropland extent and areas of South Asia derived using Landsat satellite 30-m time-series big-data using random forest machine learning algorithms on the Google Earth Engine cloud. *GIScience & Remote Sensing*, 57(3):302–322.
- [Heidinger et al., 2012] Heidinger, A. K., Evan, A. T., Foster, M. J., and Walther, A. (2012). A Naive Bayesian Cloud-Detection Scheme Derived from CALIPSO and Applied within PATMOS-x. *Journal of Applied Meteorology and Climatology*, 51(6):1129–1144.
- [Irawan, 2017] Irawan, R. N. (2017). JURUSAN TEKNIK ELEKTRO FAKULTAS TEKNIK UNIVERSITAS MATARAM 2017. page 103.
- [Jaiswal and Kishtawal, 2011a] Jaiswal, N. and Kishtawal, C. M. (2011a). Automatic determination of center of tropical cyclone in satellite-generated ir images. *IEEE Geoscience and Remote Sensing Letters*, 8(3):460–463.
- [Jaiswal and Kishtawal, 2011b] Jaiswal, N. and Kishtawal, C. M. (2011b). Automatic determination of center of tropical cyclone in satellite-generated ir images. *IEEE Geoscience and Remote Sensing Letters*, 8(3):460–463.
- [Karlsson et al., 2015] Karlsson, K.-G., Johansson, E., and Devasthale, A. (2015). Advancing the uncertainty characterisation of cloud masking in passive satellite imagery: Probabilistic formulations for NOAA AVHRR data. *Remote Sensing of Environment*, 158:126–139.
- [Lin et al., 2015] Lin, C.-H., Lin, B.-Y., Lee, K.-Y., and Chen, Y.-C. (2015). Radiometric normalization and cloud detection of optical satellite images using invariant pixels. *ISPRS Journal of Photogrammetry and Remote Sensing*, 106:107–117.
- [Liu et al., 2009] Liu, Y., Xia, J., Shi, C., and Hong, Y. (2009). An improved cloud classification algorithm for chinaâs fy-2c multi-channel images using artificial neural network. *Sensors (Basel, Switzerland)*, 9:5558–79.
- [Mahajan and Fataniya, 2019] Mahajan, S. and Fataniya, B. (2019). Cloud detection methodologies: variants and developmentâa review. *Complex Intelligent Systems*, 6:1–11.
- [Maria and Kukuh, 2016] Maria, O. and Kukuh, R. (2016). *Karakteristik Awan Konvektif Di Sumatra Utara Dengan Menggunakan Citra Radar Cuaca*.
- [Massinai, 2005] Massinai, M. A. (2005). Analisis liputan awan berdasarkan citra satelit penginderaan jauh. pages 209–213.

- [Mazon et al., 2018] Mazon, J., Rojas, J., Prats, X., and Miglietta, M. (2018). Influence of meteorological phenomena on worldwide aircraft accidents, 1967-2010. *Meteorological Applications*, 25:236–245.
- [Peck, 2015] Peck, L. (2015). *The Impact of Weather on Aviation Delays at O.R Tambo International Airport, South Africa*.
- [Roman et al., 2016] Roman, J., Knuteson, R., August, T., Hultberg, T., Ackerman, S., and Revercomb, H. (2016). A global assessment of nasa airs v6 and eumetsat iasi v6 precipitable water vapor using ground-based gps suominet stations: Ir pwv assessment. *Journal of Geophysical Research: Atmospheres*, 121.
- [Rumi et al., 2013] Rumi, E., Kerr, D., Coupland, J. M., Sandford, A. P., and Brettle, M. J. (2013). Automated cloud classification using a ground based infra-red camera and texture analysis techniques. page 88900J, Dresden, Germany.
- [Saraswati, 2015] Saraswati, D. (2015). Penentuan distribusi tipe awan di propinsi riau menggunakan citra satelit mtsat ir1. *Jurnal Sains dan Teknologi Modifikasi Cuaca*, 16:9–14.
- [Sawaisarje and Ranalkar, 2012] Sawaisarje, G. K. and Ranalkar, M. R. (2012). Cumulonimbus cloud with anvil over India : Synoptic cloud type observations 1970-2000. page 14.
- [Shi et al., 2016a] Shi, M., Xie, F., Zi, Y., and Yin, J. (2016a). Cloud detection of remote sensing images by deep learning. In *2016 IEEE International Geoscience and Remote Sensing Symposium (IGARSS)*, pages 701–704.
- [Shi et al., 2016b] Shi, M., Xie, F., Zi, Y., and Yin, J. (2016b). CLOUD DETECTION OF REMOTE SENSING IMAGES BY DEEP LEARNING. page 4.
- [Sim et al., 2018] Sim, S., Im, J., Park, S., Park, H., Ahn, M., and Chan, P.-w. (2018). Icing Detection over East Asia from Geostationary Satellite Data Using Machine Learning Approaches. *Remote Sensing*, 10(4):631.
- [Stephens, 2005] Stephens, G. (2005). Cloud feedbacks in the climate system: A critical review. *Journal of Climate*, 18:237–273.
- [Sudiana, 2009] Sudiana, D. (2009). *Klasifikasi Tutupan Awan Menggunakan Data Sensor Satelit NOAA/AVHRR APT*. Seminar on Intelligent Technology and Its Applications.

- [Surahman et al., 2015] Surahman, S., Iwan Santoso, A., Mustika Alam, T., and Setiyoko, A. (2015). Pemanfaatan Citra Satelit untuk Penentuan Daerah Operasi Keamanan Laut dari Illegal Fishing (Studi Kasus di Perairan Natuna). *chartdatum*, 1(2):121–132.
- [Tang et al., 2015] Tang, R., Tang, B., Wu, H., and Li, Z.-L. (2015). On the feasibility of temporally upscaling instantaneous evapotranspiration using weather forecast information. *International Journal of Remote Sensing*, 36(19-20):4918–4935.
- [Tapakis and Charalambides, 2013] Tapakis, R. and Charalambides, A. (2013). Equipment and methodologies for cloud detection and classification: A review. *Solar Energy*, 95:392–430.
- [Tjasyono, 2012] Tjasyono, B. (2012). *Mikrofisika awan dan hujan*. Ii edition. OCLC: 1084631625.
- [Torasa, 2009] Torasa, C. (2009). *NEAR-REAL TIME RAINFALL ESTIMATION USING APT DATA FROM NOAA SATELLITES AND METEOROLOGICAL DATA*. PhD thesis, Suranaree University of Technology.
- [Tu, 1996] Tu, J. V. (1996). Advantages and disadvantages of using artificial neural networks versus logistic regression for predicting medical outcomes. *Journal of Clinical Epidemiology*, 49(11):1225–1231.
- [Valero Medina and Alzate Atehorta, 2019] Valero Medina, J. A. and Alzate Atehorta, B. E. (2019). Comparison of maximum likelihood, support vector machines, and random forest techniques in satellite images classification. *Tecnura*, 23(59):13–26.
- [Vazquez et al., 2004] Vazquez, J., M. Armstrong, E., and Harris, A. (2004). The Effect of Aerosols and Clouds on the Retrieval of Infrared Sea Surface Temperatures. *Journal of Climate*, 17(20):3921–3933.
- [Wikipedia, 2020] Wikipedia (2020). Radiance.
- [Yhann and Simpson, 1995a] Yhann, S. and Simpson, J. (1995a). Application of neural networks to avhrr cloud segmentation. *IEEE Transactions on Geoscience and Remote Sensing*, 33(3):590–604.
- [Yhann and Simpson, 1995b] Yhann, S. and Simpson, J. (1995b). Application of neural networks to AVHRR cloud segmentation. *IEEE Trans. Geosci. Remote Sensing*, 33(3):590–604.

- [Yuan et al., 2019] Yuan, M., Chai, Z., and Zhao, W. (2019). *Severe Convective Weather Classification in Remote Sensing Images by Semantic Segmentation*, pages 143–156.
- [Yuliara et al., 2015] Yuliara, I. M., Si, S., Kasmawan, I. G. A., Si, S., and Si, M. (2015). KONVERSI NILAI PIKSEL CITRA SATELIT KE BESARAN FISIKA. page 16.