



Metode Klasifikasi Kematangan Buah Kelapa Sawit Dengan Menggunakan MobileNetV3 dan Teknik Attention Module

PROPOSAL KUALIFIKASI

RAGMAR FAIKAR EKA

NPM : 99223132

PROGRAM DOKTOR TEKNOLOGI INFORMASI

UNIVERSITAS GUNADARMA

2024

DAFTAR ISI

BAB 1 PENDAHULUAN	1
1.1 Latar Belakang Masalah	1
1.2 Identifikasi Masalah.....	3
1.3 Batasan Masalah	4
1.4 Tujuan Penelitian	4
1.5 Kegunaan Penelitian	4
1.6 Kontribusi Penelitian	4
BAB 2 TELAAH PUSTAKA.....	6
2.1 Pengolahan Citra.....	6
2.2 Artificial Intelligence.....	6
2.3 Machine Learning	8
2.4 Deep Learning	8
2.4.1 Deep Unsupervised Learning	9
2.4.2 Deep Semi-Supervised Learning	9
2.4.3 Deep Supervised Learning.....	10
2.4.4 Deep Reinforcement Learning.....	10
2.5 Convolutional Neural Network.....	10
2.5.1 Convolutional Layer	12
2.5.2 Pooling Layer	14
2.5.3 Activation Function	15
2.5.4 Fully Connected Layer	16
2.5.5 Loss Function	16
2.5.6 Optimizer	17
2.6 MobileNetV3	18
2.7 Convolutional Block Attention Module.....	21
2.7.1 Channel Attention Module.....	21
2.7.2 Spatial Module Attention	21
2.8 Kelapa Sawit	22
2.9 Penelitian Terdahulu	23
2.9.1 Penelitian 1	23
2.9.2 Penelitian 2	24
2.9.3 Penelitian 3	24

2.9.4 Penelitian 4	25
2.9.5 Penelitian 5	25
2.9.6 Penelitian 6	26
2.9.7 Fishbone Penelitian.....	28
BAB 3 METODE PENELITIAN.....	30
3.1 Tahapan Penelitian.....	30
3.1.1 Studi Literatur.....	31
3.1.2 Pengumpulan Data.....	31
3.1.3 Preprocessing Data	31
3.1.4 Pembuatan Model	32
3.1.5 Melatih Model	32
3.1.6 Evaluasi Model	32
3.1.7 Deploy Model.....	32
3.1.8 Pembuatan Aplikasi	32
3.1.9 Pengujian Aplikasi.....	32
3.1.10 Kesimpulan Penelitian.....	32
3.2 Jadwal Estimasi Penelitian.....	33
3.3 Kegiatan Penelitian	34
DAFTAR PUSTAKA	35

BAB 1

PENDAHULUAN

1.1 Latar Belakang Masalah

Kelapa sawit (*Elaeis guineensis*) merupakan tanaman pertanian yang penting secara global karena dapat digunakan untuk menghasilkan minyak nabati. Tanaman ini harus ditanam pada lahan yang sesuai agar tumbuh dengan baik dan tidak merugikan lingkungan sekitar. Kelapa sawit juga menjadi bahan dasar yang digunakan untuk menghasilkan beberapa jenis produk, termasuk produk makanan, seperti mie instan, mentega, selai, roti, dan kue, serta produk bukan makanan, seperti deterjen, sampo, sabun, dan biodiesel. Kelapa sawit merupakan salah satu perkebunan terbesar di Indonesia dan menjadikan Indonesia sebagai negara penghasil kelapa sawit terbesar di dunia, luas perkebunan kelapa sawit di Indonesia mempengaruhi volume produksi kelapa sawit produksi. Hal ini didukung oleh letak geografis Indonesia yang sesuai dengan kebutuhan tanaman kelapa sawit, dibandingkan dengan tanaman perkebunan lainnya kelapa sawit mempunyai keunggulan sebagai bahan baku biodiesel dan pangan. Dengan kemampuannya tersebut, minyak sawit dibutuhkan oleh berbagai jenis industri di berbagai negara. Sebagai komoditas unggulan kelapa sawit mempunyai peranan penting bagi perekonomian Indonesia. Dari tahun ke tahun ekspor minyak sawit Indonesia semakin meningkat meski sempat mengalami penurunan pada tahun 2016, selain itu hasil produksi perkebunan kelapa sawit juga mengalami peningkatan. Kelapa sawit Indonesia memiliki daya saing, menurut Ditjen Perkebunan, negara tujuan ekspor untuk kelapa sawit Indonesia adalah India, China, Pakistan, dan Eropa, bisa dikatakan Indonesia adalah negara tersebut kompetitif di pasar Asia (Daeng Ahmad Fakhrian Zuhdi et al, 2021).

Permintaan akan minyak kelapa sawit berkualitas tinggi terus meningkat. Kualitas kelapa sawit ditentukan oleh tingkat kematangan buah saat dipanen. Tingkat kematangan kelapa sawit ditentukan secara visual berdasarkan warna kulit buah. Minyak mentah buah kelapa sawit mempunyai warna gelap (ungu tua) dan berubah warna menjadi jingga ketika sudah matang (Septiarini, 2021). Negara-negara seperti Indonesia, Malaysia, dan Guatemala telah mengekspor buah kelapa sawit dalam jumlah besar ke seluruh wilayah dunia. Tingkat produksi yang sangat besar ini, serta berbagai macam produk turunan dari tanaman kelapa sawit menunjukkan bahwa kelapa sawit merupakan komoditas internasional yang sangat menonjol. Dengan permintaan yang akan terus meningkat, petani kelapa sawit akan membutuhkan sebuah metode tersebut untuk memfasilitasi produksi Tandan Buah Segar kelapa sawit yang lebih

efisien (TBS), karena salah satu permasalahan yang ada saat ini adalah penggunaan cara manual untuk penyortiran kematangan buah kelapa sawit yang dianggap memakan waktu dan tidak efisien (Suharjito et al, 2021).

Klasifikasi buah secara otomatis merupakan solusi menarik dalam budidaya dan penjualan karena dapat membantu petani buah dan supermarket untuk mengidentifikasi perbedaan buah-buahan dan statusnya dari stok atau wadah sehingga meningkatkan efisiensi produksi untuk mendapatkan keuntungan dalam bisnis. Klasifikasi berbagai macam buah atau sayur-sayuran bukan tugas yang sederhana karena terdapat beberapa kesamaan dalam bentuk, ukuran, dan warna. Biasanya, buah sayur, dan tanaman, sebelum dipanen dan dilepas ke pasar diperiksa oleh tenaga ahli atau terlatih terlebih dahulu. Beberapa faktor yang dipertimbangkan oleh para ahli dalam penilaian kualitas adalah warna dan tekstur produk. Namun, pemeriksaan dan klasifikasi secara manual dapat menimbulkan beberapa kemungkinan kesalahan yang dilakukan manusia. Untuk menghasilkan kesuksesan dalam proses klasifikasi, orang-orang yang dilatih untuk memeriksa produk diharuskan memiliki pengenalan dan analisis secara konsisten dan mungkin sulit atau membosankan ketika dilakukan secara berulang-ulang (Aaron et al, 2020). Oleh karena itu, sistem cerdas menggunakan metode *computer vision* dan *machine learning* telah dieksplorasi dalam dekade terakhir untuk dapat mengidentifikasi kecacatan pada buah, menilai kematangan, dan mengkategorisasi buah. Salah satu contoh penelitian yang dilakukan oleh Mehenag Katun et al (Mehenag Katun et al, 2020) mengajukan metode untuk mengklasifikasi jenis buah menggunakan Convolutional Neural Network (CNN). Dataset yang digunakan memiliki 1400 gambar buah dengan 7 kelas yaitu apel, pisang, jeruk, pir, mangga, nanas dan strawberry. Metode ini menghasilkan akurasi sebesar 98%.

Convolutional Neural Network (CNN) adalah salah satu metode *deep learning* yang paling umum. Dalam klasifikasi gambar tidak mudah untuk mempertahankan fitur asli gambar dalam digitalisasi karena banyaknya data untuk diolah. CNN memiliki kemampuan pembelajaran representasi yang secara otomatis dapat mengekstraksi fitur-fitur gambar dengan skala berbeda. CNN mempunyai kemampuan mengekstraksi fitur gambar yang kuat dan akurat (Chunguang Bi et al, 2023). Penggunaan CNN untuk *image recognition* dan klasifikasi tidak hanya menjadi tren di bidang pertanian, namun juga di bidang lain seperti *scene image recognition*, *remote sensing image analysis*, dan masih banyak lagi. Oleh karena itu, operasi konvolusi adalah kontributor utama bagi tugas *computer vision*, tetapi ketika struktur jaringan lebih dalam dan lebih besar seperti VGG-16, VGG-19, Alexnet, dan Xception, proses komputasi dari operasi konvolusi akan semakin tinggi. MobileNetV2 adalah *lightweight CNN*

yang berfokus pada *mobile device* yang diusulkan oleh tim Google pada tahun 2018. Dibandingkan dengan CNN biasa, MobileNetV2 dapat mengurangi parameter model dan proses perhitungan dengan sedikit penurunan akurasi. (Shiqing Dou et al, 2023). Terdapat penelitian yang dilakukan oleh Suharjito et al 2021, mereka membuat aplikasi android untuk mengklasifikasi kematangan buah Kelapa Sawit dengan MobileNetV1, aplikasi tersebut mampu membedakan kematangan Buah Kelapa Sawit dengan Tingkat kematangan kurang matang, matang, terlalu matang dan tandan kosong.

Mekanisme *Attention Module* memungkinkan *Neural Network* untuk memperhatikan informasi yang penting dalam gambar dan dapat menyembunyikan informasi yang tidak berguna, hal ini dapat meningkatkannya efisiensi untuk proses klasifikasi gambar. *Convolutional Block Attention Module* (CBAM) adalah *Lightweight Attention Module* yang terdiri dari *Channel Attention Module* (CAM) dan *Spatial Attention Module* (SAM) (Shiqing Dou et al, 2023), dimana *Channel Attention Module* mencoba menangkap ‘apa’ yang penting dalam hal yang diberikan oleh gambar, sedangkan *Spatial Module Attention* berfokus pada ‘di mana’ atau bagian mana dari gambar tersebut penting (Tej Bahdur et al, 2022). Penelitian yang dilakukan oleh Huixuan Fu, Guoqing Song dan Yuchao Wang mengusulkan model YOLOv4 dan menggabungkannya dengan CBAM untuk mendeteksi target laut. CBAM ditambahkan untuk membuat *Neural Network* lebih memperhatikan area sasaran yang berisi informasi penting, menekan informasi yang tidak relevan, dan meningkatkan akurasi. Hasil penelitian tersebut menunjukkan bahwa dengan menambahkan CBAM pada Model YOLOv4 dapat meningkatkan akurasi dibandingkan dengan model YOLOv4 biasa. Hasil penelitian tersebut meningkatkan nilai mAP50 sebesar 2,02% dan mAP75 meningkat sebesar 1,85%.

Berdasarkan pemaparan diatas, penelitian ini bertujuan untuk membuat aplikasi berbasis android untuk mengklasifikasi kematangan buah Kelapa Sawit menggunakan MobileNetV3 dan menggabungkannya dengan teknik Attention Module yaitu Convolutional Block Attention Module (CBAM). Penggabungan model Konvolusi dan *Attention Module* diharapkan dapat membantu proses dengan saling melengkapi untuk mencapai kinerja yang lebih baik dalam klasifikasi buah dengan judul penelitian “**Metode Klasifikasi Kematangan Buah Sawit Dengan Menggunakan MobileNetV3 dan Teknik Attention Module**”.

1.2 Identifikasi Masalah

1. Bagaimana cara merancang model untuk klasifikasi kematangan buah kelapa sawit?

2. Bagaimana mengetahui nilai akurasi dari klasifikasi kualitas buah kelapa sawit?
3. Bagaimana cara menggabungkan model MobileNetV3 dengan Attention Module CBAM?
4. Bagaimana cara untuk mengimplementasi model klasifikasi kematangan buah kelapa sawit ke dalam aplikasi *mobile*?

1.3 Batasan Masalah

1. Model klasifikasi kualitas buah kelapa sawit dibuat menggunakan metode CNN dengan arsitektur MobileNetV3 dan Attention Module CBAM
2. Dataset yang digunakan berupa citra buah kelapa sawit yang didapatkan dari website Roboflow

1.4 Tujuan Penelitian

1. Untuk merancang *lightweight* model klasifikasi kematangan buah kelapa sawit
2. Untuk menggabungkan model konvolusi dan teknik attention module
3. Untuk membuat aplikasi berbasis android untuk klasifikasi kematangan buah kelapa sawit

1.5 Kegunaan Penelitian

1. Mendapatkan kesimpulan mengenai penggabungan metode konvolusi MobileNetV3 dengan Attention Module CBAM
2. Mengetahui performa model MobileNetV3 dengan CBAM dalam implementasi ke dalam aplikasi Android

1.6 Kontribusi Penelitian

Penelitian ini memiliki kontribusi dalam bidang penelitian dengan mengembangkan metode klasifikasi kematangan buah kelapa sawit menggunakan penggabungan MobileNetv3 dan Convolutional Block Attention Module (CBAM).

Kontribusi selanjutnya yaitu pada bidang teknologi, hasil akhir penelitian ini membangun sebuah aplikasi *mobile* untuk klasifikasi kematangan buah kelapa sawit sehingga

diharapkan dapat memudahkan proses penyortiran atau proses panen buah kelapa sawit dengan tingkat kematangan yang pas.

BAB 2

TELAAH PUSTAKA

2.1 Pengolahan Citra

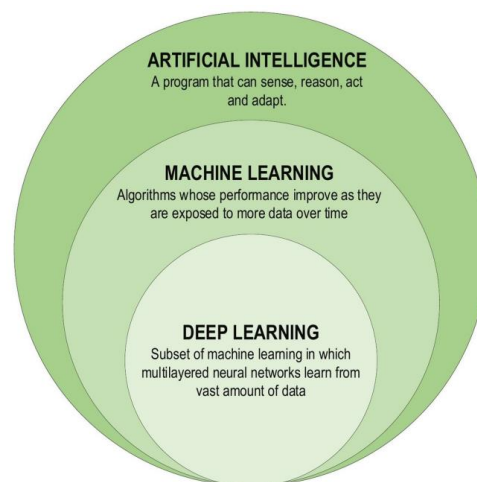
Pengolahan citra digital adalah teknik mengolah citra yang bertujuan memperbaiki kualitas citra agar mudah diinterpretasi oleh manusia atau mesin komputer yang dapat berupa foto maupun gambar bergerak. Pengolahan citra merupakan cabang ilmu dalam Artificial Intelligence yang menggunakan objek citra dalam bentuk digital untuk penyelesaian kasusnya. Metode dalam citra dapat digunakan baik perhitungan matematis pada objek secara piksel ataupun geometris. Masing-masing objek citra memiliki nilai perbedaan yang dapat diperhitungkan secara matematis, sehingga menunjukkan ciri yang berbeda antara objek satu dengan yang lain. Penciri dari perbedaan setiap objek dapat ditentukan dari warna, tekstur, ataupun bentuk. Dengan memanfaatkan informasi digital ini pengelompokkan atau clustering dapat di implementasikan terhadap objek (Juju Jumadi, Yupianti, Devi Satrika, 2021).

Pengolahan citra digital dapat diartikan sebagai teknik mengakuisisi dan memproses informasi visual menggunakan computer. Informasi yang bisa disampaikan dari sebuah citra atau gambar telah dikenal selama berabad-abad sebagai hal yang luar biasa karena “one picture is worth a thousand words” artinya dari satu citra atau gambar dapat bernilai seribu kata (Scott E Umbaugh, 2023). Bergantung dari output dari citra digital, bidang pengolahan citra digital terbagi menjadi 3 jenis yaitu Low-Level merujuk pada operasi pre-processing citra seperti *noise reduction*, *scaling*, dan sebagainya. Mid-Level merujuk pada operasi dasar pengolahan citra mengenai garis tepi atau *edge*, segmentasi, dan sebagainya. High-Level merujuk pada operasi pengolahan citra yang kompleks seperti analisis, *recognition*, dan *interpretation* dari gambar dan terkait untuk *decision-making* (Prateek Singhai, Abhishek Verma, Prabhat Kumar Srivastava, Virender Ranga, Ram Kumar, 2023).

2.2 Artificial Intelligence

Artificial Intelligence atau kecerdasan buatan adalah istilah umum untuk ilmu kecerdasan buatan yang menggunakan komputer untuk mensimulasikan perilaku cerdas manusia dan melatih komputer untuk mempelajari perilaku manusia seperti belajar, menilai, dan pengambilan keputusan. AI adalah proyek pengetahuan yang menjadikan pengetahuan sebagai objek, memperoleh pengetahuan, menganalisis dan mempelajari ekspresi metode

pengetahuan, dan menggunakan pendekatan ini untuk mencapai efek simulasi aktivitas intelektual manusia. AI adalah kompilasi ilmu komputer, logika, biologi, psikologi, filsafat, dan banyak ilmu lainnya, dan telah mencapai hasil yang luar biasa dalam aplikasi seperti pengenalan suara, pemrosesan gambar, pemrosesan bahasa alami, pembuktian teorema otomatis, dan kecerdasan robot. AI memainkan peran yang sangat diperlukan dalam pembangunan sosial telah membawa hasil revolusioner dalam meningkatkan efisiensi tenaga kerja, mengurangi biaya tenaga kerja, mengoptimalkan struktur sumber daya manusia, dan menciptakan tuntutan pekerjaan baru (Caiming Zhang, Yang Lu, 2021).



Gambar 2.1 Artificial Intelligence, Machine Learning dan Deep Learning (Laith Alzubaidi et al, 2021)

Artificial Intelligence adalah studi tentang bagaimana membuat komputer bekerja dengan kecerdasan yang di masa lalu hanya dapat dilakukan oleh manusia. Dalam beberapa tahun terakhir, AI telah berkembang pesat dan telah merubah gaya hidup masyarakat. Perkembangan AI menjadi suatu hal yang penting dalam strategi pembangunan bagi negara-negara di seluruh dunia, meningkatkan daya saing nasional dan menjaga keamanan. AI telah menjadi penelitian populer dalam ilmu pengetahuan dan teknologi, perusahaan besar seperti Google, Microsoft, dan IBM berkomitmen terhadap AI dan menerapkan AI pada lebih banyak dan berbagai bidang. AI adalah teknologi multidisiplin, yang memiliki kemampuan mengintegrasikan kognisi, Machine Learning, pengenalan emosi, interaksi manusia-komputer, penyimpanan data, dan pengambilan Keputusan (Caiming Zhang, Yang Lu, 2021).

2.3 Machine Learning

Kecerdasan buatan atau *Artificial Intelligence* khususnya *Machine Learning* telah berkembang pesat dalam beberapa tahun terakhir dalam konteks analisis data dan komputasi yang biasanya memungkinkan aplikasi berfungsi dengan cara yang cerdas. *Machine Learning* biasanya memberikan kemampuan pada sistem untuk belajar dan mengembangkan pengalaman secara otomatis tanpa diprogram secara khusus dan secara umum *machine learning* disebut sebagai teknologi terpopuler terkini di revolusi industri keempat atau Industri 4.0 (Iqbal H. Sarker, 2021). *Machine Learning* adalah bagian dari ilmu *computer science* mengenai pengenalan pola dan teori pembelajaran komputasional pada bidang kecerdasan buatan. Algoritma digunakan untuk membuat prediksi pada data. Sebelumnya bidang *machine learning* sebagian besar adalah algoritma dan teori optimasi, namun baru-baru ini *machine learning* mencakup beberapa disiplin ilmu lain yang meliputi statistik, teori informasi, teori algoritma, probabilitas dan analisis fungsional. *Machine learning* dan statistik komputasi selalu terkait erat karena keduanya merupakan spesialisasi dalam pembuatan prediksi dan optimasi matematis yang menghadirkan metode, teori, dan penerapan di lapangan. Dalam *machine learning*, instruksi program yang benar-benar statis tidak diikuti, melainkan algoritma digunakan untuk membangun model dari input yang digunakan untuk membuat prediksi atau keputusan berdasarkan data (Isonkobong Christopher Udousoro, 2020).

2.4 Deep Learning

Deep Learning adalah sekumpulan algoritma machine learning yang menggunakan banyak lapisan yang sesuai dengan level abstraksi yang berbeda untuk setiap tingkat. Ini terdiri dari lapisan input, lapisan output dan beberapa lapisan tersembunyi. Algoritma ini digunakan untuk sintesis suara, pemrosesan gambar, pengenalan tulisan tangan, deteksi objek, analitik prediksi dan pengambilan keputusan (Ayushi Chahal, Preeti Gulia, 2019). *Deep Learning* tidak lain hanyalah kumpulan *classifier* yang bekerja bersama, yang didasarkan pada regresi linier yang diikuti oleh beberapa *activation function*. Pada dasarnya, *deep learning* sama dengan pendekatan tradisional statistik regresi linier, satu-satunya perbedaan adalah pada *deep learning* terdapat banyak *neural node* dalam *deep learning* tidak seperti tradisional statistik regresi linier yang hanya mempunyai satu node. *Neural Node* ini juga dikenal sebagai *Neural Network*, dan satu node *classifier* dikenal sebagai *neural unit* atau *perception*. Hal kontras lainnya yang perlu diperhatikan bahwa dalam *deep learning* ada banyak lapisan di antara input dan outputnya. Sebuah lapisan dapat memiliki ratusan atau bahkan ribuan *neural units*.

Lapisan-lapisan yang berada di antara input dan output dikenal sebagai *hidden layers* dan node dikenal sebagai *hidden nodes* (Shi Dong, Ping Wang, Khushnood Abbas. 2021).

Teknik *Deep Learning* dibagi menjadi tiga kategori utama yaitu *Unsupervised Learning*, *Semi-Supervised Learning* dan *Supervised Learning*. *Reinforcement Learning* adalah jenis teknik *deep learning* yang sebagian besar dianggap termasuk dalam kategori teknik *semi-supervised* dan terkadang *unsupervised* (Laith Alzubaidi, Jinglan Zhang, Amjad J. Humaidi, Ayad Al-Dujaili, Ye Duan, Omran Al-Shamma, J. Santamaría, Mohammed A. Fadhel, Muthana Al-Amidie dan Laith Farhan, 2021).

2.4.1 Deep Unsupervised Learning

Teknik ini memungkinkan terlaksananya proses pembelajaran dalam keadaan tidak ada data berlabel yang tersedia atau tidak diperlukan label. Teknik jaringan *Generative*, pengurangan dimensi dan *clustering* sering kali dihitung dalam kategori *unsupervised learning*. Beberapa anggota *deep learning* telah menunjukkan kinerja yang baik dalam tugas mereduksi dimensi dan *clustering* secara non-linier seperti Restricted Boltzmann Machine (RBM), auto-encoder, dan GAN sebagai teknik yang paling baru dikembangkan. Selain itu, RNN yang mencakup pendekatan GRU dan LSTM, juga telah digunakan untuk *unsupervised learning* dalam berbagai aplikasi. Kekurangan utama dari *unsupervised learning* adalah tidak mampu memberikan informasi yang akurat mengenai penyortiran data dan komputasi yang rumit (Laith Alzubaidi et al, 2021).

2.4.2 Deep Semi-Supervised Learning

Dalam teknik ini, proses pembelajaran didasarkan pada kumpulan data semi-berlabel. Terkadang, *Generative Adversarial Network* (GAN) dan *Deep Reinforcement Learning* (DRL) digunakan dengan cara yang sama seperti Teknik ini. Selain itu, RNN yang mencakup GRU dan LSTM, juga digunakan untuk *semi-supervised learning*. Salah satu keuntungan dari teknik ini adalah meminimalkan jumlah data berlabel yang dibutuhkan. Di sisi lain salah satu kelemahannya teknik ini yaitu tidak relevannya fitur input data pelatihan yang ada dapat menghasilkan keputusan yang salah. *Text Document Classifier* adalah salah satu contoh paling populer dari penerapan *semi-supervised learning*. karena kesulitan mendapatkan yang dokumen teks berlabel dalam jumlah besar, *semi-supervised learning* sangat ideal untuk tugas klasifikasi dokumen teks (Laith Alzubaidi et al, 2021).

2.4.3 Deep Supervised Learning

Teknik ini berkaitan dengan data berlabel. Beberapa contoh *deep learning* dengan teknik *supervised learning* seperti *Recurrent Neural Network* (RNN), *Convolutional Neural Network* (CNN), dan *Deep Neural Network* (DNN). Selain itu, kategori RNN mencakup *Gated Recurrent Unit* (GRU) dan pendekatan *Long Term Short Memory* (LSTM). Keuntungan utama teknik ini adalah kemampuannya mengumpulkan data atau menghasilkan output data dari pengetahuan sebelumnya. Namun, kelemahannya teknik ini adalah batasan keputusannya kemungkinan menjadi terlalu tegang ketika set pelatihan tidak memiliki sampel yang seharusnya ada di kelas. Secara keseluruhan, teknik ini lebih sederhana dibandingkan teknik lainnya dalam cara pembelajaran dengan kinerja tinggi (Laith Alzubaidi et al, 2021).

2.4.4 Deep Reinforcement Learning

Reinforcement Learning beroperasi dengan berinteraksi dengan lingkungan, sedangkan *supervised learning* beroperasi pada data sampel yang disediakan. Teknik ini dikembangkan pada tahun 2013 oleh Google Deep Mind. Metode ini terkadang disebut sebagai *semi-supervised learning*. Berdasarkan konsep ini, beberapa teknik dikembangkan dan termasuk sebagai *supervised learning* dan *unsupervised learning*. Dibandingkan dengan teknik *traditional supervised*, untuk melakukan teknik pembelajaran ini jauh lebih sulit, karena tidak ada *straightforward loss function* yang tersedia dalam teknik *reinforcement learning*. Dalam menyelesaikan suatu tugas, pemilihan jenis *reinforcement learning* yang diperlukan yang dilakukan didasarkan pada lingkungan atau ruang lingkup permasalahannya. Misalnya, *deep reinforcement learning* adalah cara terbaik untuk mengoptimalkan masalah yang melibatkan banyak parameter. Sebaliknya, *derivative-free reinforcement learning* adalah teknik yang bekerja dengan baik untuk masalah dengan parameter yang terbatas. Beberapa penerapan *reinforcement learning* digunakan untuk perencanaan strategi bisnis dan robotika untuk otomasi industri. Kelemahan utama dari *reinforcement learning* adalah parameter yang dapat mempengaruhi kecepatan belajar (Laith Alzubaidi et al, 2021).

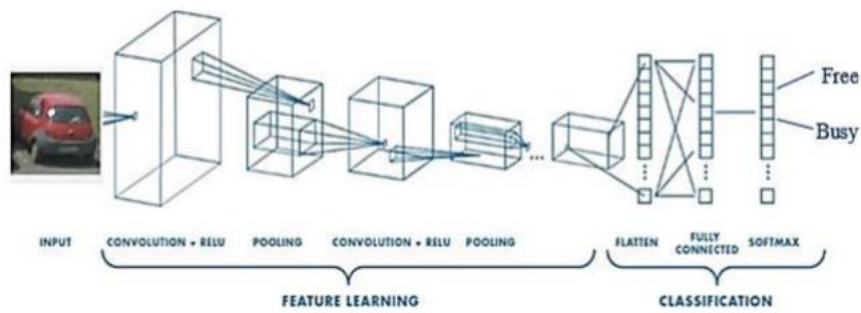
2.5 Convolutional Neural Network

Convolutional Neural Network (CNN) adalah *computer vision deep learning network* yang dapat mengenali dan mengklasifikasikan fitur gambar. Arsitektur CNN dipengaruhi oleh

organisasi dan fungsinya dari korteks visual yang dirancang menyerupai koneksi antar neuron pada otak manusia (Dulari Bhatt, Chirag Patel, Hardik Talsania, Jigar Patel, Rasmika Vaghela, Sharnil Pandya, Kirit Modi dan Hemant Ghayvat, 2021). CNN merupakan tipe jaringan syaraf tiruan yang memiliki keunggulan pada tingkat akurasi yang sangat tinggi dalam proses klasifikasi. CNN membagi proses kerjanya menjadi beberapa layer yang didalamnya terdapat tiga layer utama yaitu *Convolutional Layer*, *Pooling layer*, dan *Fully Connected Layer*. *Convolutional layer* digunakan untuk mengekstrak fitur data yang akan digunakan untuk pelatihan, kemudian *Pooling Layer* digunakan untuk membuat filter baru berdasarkan aturan yang diinginkan, dan *Fully Connected Layer* sebenarnya adalah *Multilayer Perceptron* (MLP) yang merupakan bagian dari jaringan syaraf tiruan yang terdiri dari sejumlah neuron dengan menghubungkan bobot (Novia Farhan Nissa, Angelia Janiati, Nilam Cahya, Anton, Puji Astuti, 2021).

Cara kerja CNN mirip dengan MLP, tetapi pada CNN setiap neuron disajikan dalam dua dimensi. MLP menerima input data satu dimensi dan menyebarkan data pada jaringan untuk menghasilkan output. Setiap hubungan antara neuron dalam dua lapisan yang berdekatan memiliki parameter bobot satu dimensi yang menentukan kualitas mode. Pada setiap lapisan input data, operasi linier dilakukan dengan nilai bobot yang ada, kemudian hasil komputasi ditransformasikan menggunakan operasi non linier yang disebut dengan fungsi aktivasi. Di CNN, data yang disebarkan di jaringan berupa dua dimensi, sehingga operasinya linier dan parameter bobotnya berbeda. Operasi linier pada CNN menggunakan operasi konvolusional, sedangkan bobot tidak lagi satu dimensi melainkan empat dimensi yang merupakan kumpulan konvolusional kernel (Novia et al, 2021).

Arsitektur CNN memiliki 2 bagian utama yaitu *Feature Learning* dan *Classification*. *Feature Learning* terdiri dari lapisan konvolusi, *activation function* seperti *Rectified Linear Unit* (ReLU), dan *Pooling*. Lapisan ini sering diulang atau disusun menjadi beberapa lapisan sesuai kebutuhan arsitektur yang dibuat. Bagian klasifikasi terdiri dari *Flatten*, *Fully Connected* dan *Softmax*. Komposisi pemilihan parameter dalam menyusun CNN mempengaruhi kinerja jaringan CNN yang dibangun (Sayuti Rahman, Marwan Ramli, Fitri Arnia, Rusdha Muharar, Muhammad Zen, Muhammad Ikhwan, 2021).



Gambar 2.2 Arsitektur CNN (Sayuti Rahman et al, 2021)

Dibandingkan dengan MLP, CNN menambahkan *convolutional layer* dan *pooling layer* yang sangat khas. Dalam menghadapi banyaknya piksel dan jumlah data yang lebih besar, CNN akan memiliki ukuran model yang besar namun memiliki kinerja yang lebih baik. Di satu sisi, *convolutional layer* memiliki karakteristik bidang reseptif lokal, yang akan tetap mempertahankan bentuk input sehingga korelasi antara fitur panjang dan lebar piksel gambar dapat diidentifikasi secara efektif. Di sisi lain, *convolutional layer* berulang kali menghitung kernel konvolusi yang sama dan posisi yang berbeda pada input melalui *sliding window*, yaitu menggunakan *parameter sharing* dan *sparse connection* untuk secara efektif menghindari ukuran parameter pelatihan menjadi terlalu besar. *Pooling Layer* mengurangi beban komputasi dengan mengurangi jumlah koneksi antar *convolutional layer* dan mengurangi sensitivitas berlebihan dari *convolutional layer* tersebut (Leiyu Chen, Shaobo Li, Qiang Bai, Jing Yang, Sanlong Jiang, Yanming Miao, 2021).


2.5.1 Convolutional Layer

Pada CNN dengan kedalaman tertentu, operasi konvolusi dengan menggunakan *convolutional layer* ganda dapat mengekstraksi fitur input yang berbeda. *Convolutional Layer* bagian bawah umumnya mengekstraksi fitur umum seperti tekstur, garis, dan tepi, sedangkan lapisan yang lebih tinggi mengekstrak fitur yang lebih abstrak. *Convolutional Layer* memiliki beberapa kernel konvolusi dengan parameter yang dapat dipelajari, yaitu sebuah matriks yang terdiri dari bobot yang dapat dipelajari, yang umumnya Matriks dengan bobot 3×3 , 5×5 , dan 7×7 dengan panjang dan lebar yang sama serta bilangan ganjil. Biasanya *convolutional layer* akan memasukkan *feature map*. Bobot Matriks dari kernel konvolusi sesuai dengan area lokal *connection feature map*, dan kernel konvolusi secara berurutan melakukan operasi konvolusi pada area *feature map* dengan cara bergeser. Secara umum, ukuran *input feature map* adalah H

x W x C (*height* H, *weight* W dan *channel* C), setiap kernel konvolusi adalah K x K x C, jumlah kernel konvolusi harus sama dengan jumlah *input channel* (Leiyu Chen et al, 2021). Gambar 2.3 menggambarkan proses konvolusi dari *input feature map* (5 x 5 x 3) dan kernel konvolusi (3 x 3 x 3) dapat dinyatakan sebagai :

$$feature_surface_{out} = f \left(\sum_{i=1}^3 M_i * W_i + B \right)$$

M_i mewakili permukaan fitur dari *input feature map*, W_i adalah bobot matrix dari kernel konvolusi, M adalah bias matrix, $f(\cdot)$ adalah fungsi aktivasi non-linear dan $feature_surface_{out}$ adalah output permukaan fitur.




Gambar 2.3 Skema Diagram dari proses konvolusi (Leiyu Chen et al, 2021)

Perhitungan spesifik pada *convolutional layer* adalah *cross-correlation operation* antara kernel konvolusi dan permukaan fitur. Untuk masukan dua dimensi (2-D) berukuran matriks i, ukuran konvolusi k, *strides* s dan *padding* p, ukuran permukaan fitur keluaran :

$$o = \left\lfloor \frac{i + 2p - k}{s} \right\rfloor + 1$$

Seperti yang ditunjukkan pada Gambar 2.4 diasumsikan salah satu fitur yang disebutkan di atas muncul dan *cross-correlation operation* dari kernel konvolusi, inputnya adalah permukaan fitur matriks dengan tinggi dan lebar 3, kernel konvolusi dimulai dari kiri atas dari matriks input dan bergeser pada susunan input secara berurutan dari kiri ke kanan dan atas ke bawah.




Gambar 2.4 Operasi Konvolusi (Leiyu Chen et al, 2021)

Bobot parameter kernel konvolusi diperbarui melalui *gradient backpropagation*. Ketika kernel konvolusi memproses kumpulan *input feature map* yang sama, parameternya tetap. Setiap area piksel dioperasikan dengan operasi *sliding* kernel konvolusi yang sama, yang merupakan *parameter sharing* kernel konvolusi. Mekanisme ini membuat pengoperasian menjadi sederhana dan efisien, dan dapat beroperasi pada dataset berskala besar dan sangat mengurangi jumlah parameter pelatihan dan mengurangi risiko terjadinya overfitting (Leiyu Chen et al, 2021).

2.5.2 Pooling Layer

Pooling Layer umumnya berada setelah *convolutional layer*. Alasan utama penggunaan pada pooling layer untuk melakukan proses *down-sampling* dan mereduksi input dimensi gambar untuk mengurangi jumlah koneksi pada convolutional layer, sehingga mengurangi beban komputasi jaringan.



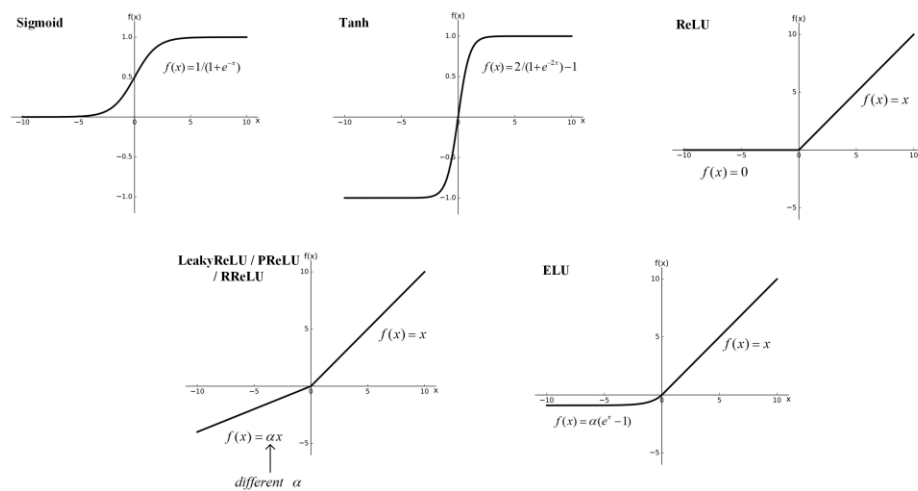
Gambar 2.5 Max Pooling dan Average Pooling (Leiyu Chen et al, 2021)

Average Pooling dan *Maximum Pooling* adalah dua metode *pooling* yang paling banyak digunakan. Walaupun terdapat max pooling dan average pooling, ada beberapa metode yang bisa lebih dari 2 metode tersebut yang secara efektif mampu mengurangi *over-fitting* dari

convolutional neural network seperti Lp Pooling, Mixed Pooling, Stochastic Pooling, Spatial Pyramid Pooling (SPP) dan Multi-scale Orderless Pooling, dll. Gambar 2.5 menunjukkan proses down-sampling dari *Max Pooling* dan *Average Pooling* (Leiyu Chen et al, 2021).

2.5.3 Activation Function

Activation Function berfungsi untuk menjadikan input dan output mempunyai hubungan fungsional, yang memperkenalkan sistem nonlinier ke dalam jaringan saraf, dan memiliki nonlinier *activation function* yang sesuai secara signifikan dapat meningkatkan kinerja jaringan.



Gambar 2.6 Operasi Pooling (Leiyu Chen et al, 2021)

Pada Gambar 2.6 menunjukkan beberapa fungsi aktivasi umum. Diantaranya, sigmoid dan Tanh disebut *saturating nonlinearities*. Dapat dilihat pada Gambar 6 dan definisi rumusnya ketika masukannya sangat besar atau sangat kecil, fungsi Sigmoid *saturates* outputnya 0 atau 1, dan fungsi Tanh *saturates* outputnya -1 atau 1 . Untuk menyelesaikan masalah yang disebabkan oleh *saturating nonlinearities*, *non-saturating nonlinier* seperti ReLU, Leaky ReLU, PReLU, RReLU dan ELU telah diusulkan. Dari segi waktu yang diperlukan untuk pelatihan penurunan gradien, fungsi sebelumnya jauh lebih lambat dibandingkan fungsi kedua, Neuron dengan nonlinier *saturates* disebut sebagai Rectified Linear Units (ReLU). Jenis *deep convolutional neural network* dengan ReLU beberapa kali lebih cepat dibandingkan dengan jaringan yang serupa dengan tanh sebagai fungsi aktivasinya (Leiyu Chen et al, 2021).

2.5.4 Fully Connected Layer

Fully Connected Layer umumnya terdapat di belakang *convolutional layer* dan *pooling layer*. *Fully Connected Layer* ini mengintegrasikan dan mengklasifikasikan informasi lokal dengan kategori diskriminasi yang diekstraksi setelah tahap konvolusi dan *pooling*, dan terakhir menampilkan informasi kategori gambar tersebut. *Fully Connected Layer* mengandung beberapa lapisan tersembunyi, yang mengekstrak fitur bertingkat tinggi dari jaringan sebelumnya menjadi bentuk yang lebih kompleks. Jumlah neuron pada ujung output merupakan jumlah kategori, dan kemudian vektor output digunakan untuk menentukan gambar termasuk dalam kategori yang mana. Dalam istilah awam, *Fully Connected Layer* bertindak sebagai *classifier* di CNN. Dalam pelatihan jaringan, output jaringan umumnya mengalami regresi softmax untuk menormalisasi probabilitas sebelum *loss function* lapisan *fully connected layer*. Parameter *fully connected layer* diperbarui menggunakan *gradient backpropagation*, ketika sebuah model yang besar dengan banyak parameter dilatih pada *dataset* yang lebih kecil, umumnya lapisan *fully connected layer* menggunakan regularisasi L2 dan dropout, tujuan penggunaannya adalah untuk menghindari terjadi overfitting pada model. Model CNN klasik pada dasarnya menggunakan dropout ReLU dan metode *dropout* dan telah mencapai kinerja klasifikasi yang baik (Leiyu Chen et al, 2021).

2.5.5 Loss Function

Penggunaan *Loss Function* yang berbeda juga mempengaruhi kinerja arsitektur CNN sesuai tugas yang diinginkan misalnya, klasifikasi gambar, pengenalan wajah, dan pengenalan objek. Beberapa *loss function* yang umum digunakan Metode klasifikasi gambar berbasis CNN dapat dilihat pada Gambar 2.7.

Loss Function	Equation	Characteristic
L1 (MAE)	$Loss(y, y^*) = \frac{1}{m} \times \sum_{i=1}^m y_i^* - y_i $	This function is widely used in regression problems. L1 Loss is called mean absolute error (MAE)
L2 (MSE)	$Loss(y, y^*) = \frac{1}{m} \times \sum_{i=1}^m (y_i^* - y_i)^2$	This function is widely used in regression problems. L2 Loss is called mean square error (MSE)
Softmax + Cross-Entropy	$Loss(y, y^*) = - \sum_i \frac{y_i}{\sum_{i=1}^m y_i} \log(y_i^*), i \in [1, m]$	This function usually employed as a substitution of the MSE in multi-class classification problems. It is also commonly used in CNN models

Gambar 2.7 *Loss Function* yang umum digunakan pada CNN (Leiyu Chen et al, 2021)

Secara keseluruhan, Softmax+Cross-Entropy telah menjadi *loss function* yang biasa digunakan pada model CNN. Ada juga banyak versi yang sudah ditingkatkan seperti center-

loss, L Softmax, A-Softmax, AM-Softmax, PEDCC-loss, dll., yang memainkan peran penting dalam berbagai tugas visual (Leiyu Chen et al, 2021).

2.5.6 Optimizer

Pelatihan jaringan *neural network* bergantung pada langkah utama dari *gradient update*, yaitu perlu menghitung gradien fungsi tujuan (*loss function*). menerapkan turunan orde pertama sehubungan dengan parameter jaringan, dan kemudian informasi gradien ditransfer ke lapisan jaringan sebelumnya dalam bentuk perhitungan parsial diferensial untuk mencapai pembaruan *learning parameter* pada setiap lapisan jaringan.

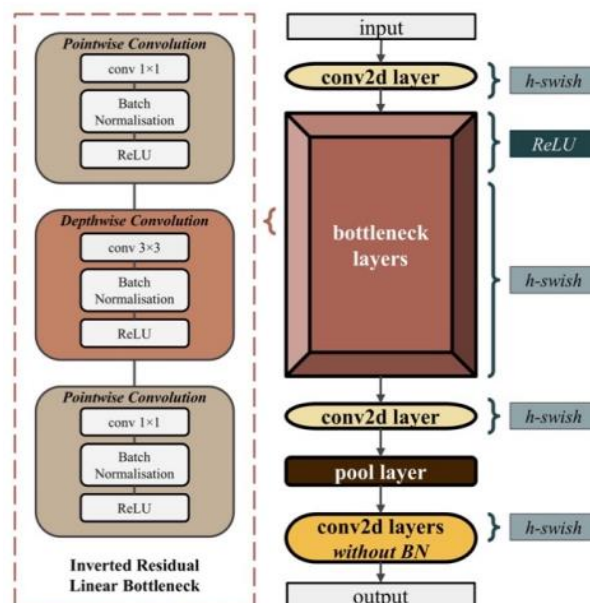
Name	Method	Characteristics
Batch Gradient Descent (BGD)	It calculates the gradient of the whole training set and subsequently uses this gradient to update the parameters.	1. For a small-sized dataset, the CNN model converges faster and creates an extra-stable gradient using BGD. 2. Generally not suitable for a large training dataset 3. It requires a substantial amount of resources.
Stochastic Gradient Descent (SGD)	It samples by arbitrarily selecting part of the training sample.	1. For a large-sized training dataset, this technique is both more memory-effective and much faster than BGD. 2. Randomness and noise are introduced due to its frequent updates. Its convergence is not stable, but the expectation is still equal to the correct gradient descent.
Mini-batch Gradient Descent	It partitions the training samples into several mini-batches, and then parameter updating is performed following gradient computation on every mini-batch.	This method combines the technical advantages of SGD and BGD, which has a steady convergence, more computational efficiency and extra memory effectiveness.
Momentum	It introduces a momentum parameter λ into SGD that accumulates historical gradient information.	When training falls into a local minimum, the gradient information with momentum can help the network escape and find the global minimum
Adaptive Moment Estimation (Adam)	It calculates an adaptive learning rate for each parameter in the model	The advantages of momentum and RMSprop are combined. It is widely used in deep learning and represents the latest trend of optimization.

Gambar 2.8 Perbedaan *Optimizer* pada CNN

Fungsi optimizer adalah menyediakan cara untuk membuat *gradient update* yang lebih masuk akal, yaitu kinerja makroskopis yang memungkinkan keseluruhan jaringan konvergen lebih cepat, nilai optimal lokal lebih kecil (*loss* yang lebih kecil), perhitungan yang minimal, dll. Gambar 2.8 merangkum beberapa optimizer yang umum digunakan termasuk metode dan karakteristiknya.

2.6 MobileNetV3

Arsitektur CNN saat ini banyak digunakan untuk menangani banyak masalah yang berbeda dan meningkatkan kinerjanya dalam hal kecepatan dan ukuran. *Convolutional Neural Network* yang efisien menerapkan *depthwise convolution structure* seperti NASNet, MobileNet, EfficientNet, MnasNet, dan ShuffleNets dianggap sebagai teknik kunci dalam banyak aplikasi computer vision karena dikenal dengan proses pelatihan yang cepat. *Depthwise Convolution Structure* adalah parameter yang diterapkan ke setiap input channel secara terpisah dari gambar yang dilatih untuk mengekstraksi informasi. Selain itu, kernel *Depthwise Convolution* dibagikan ke semua input channels, meningkatkan efisiensi model dan mengurangi proses komputasi. Namun, ukuran kernel *Depthwise Convolution* mungkin sulit dipelajari, sehingga meningkatkan kompleksitasnya proses pelatihan konvolusi mendalam. MobileNetV1 dan MobileNetV2 yang dikembangkan sebelumnya ditingkatkan dengan versi terbaru disebut MobileNetV3, diusulkan oleh (Howard et al) menggunakan *Network Architecture Search* (NAS). Teknik NAS yang digunakan yang disebut dengan algoritma NetAdapt digunakan untuk mencari ukuran kernel terbaik dan mengoptimalkan arsitektur MobileNet untuk memenuhi kebutuhan *low-resourced hardware platform* dalam hal ukuran, kinerja, dan latensi. MobileNetV3 memperkenalkan beberapa *building component* dan *block* yang terinspirasi dari versi sebelumnya, seperti yang ditunjukkan pada Gambar 2.9.



Gambar 2.9 Arsitektur MobileNetV3

Depthwise Seperable Convolution merupakan Teknik utama untuk beberapa model efisien seperti MobileNetV1 sampai V3. Tidak seperti model konvolusi tradisional yang hanya

menggunakan 1 perhitungan konvolusi untuk tiap layer, perhitungan konvolusi pada Depthwise Seperable Convolution dibagi menjadi 2 fase. Pada fase pertama, konvolusi Depthwise menggunakan single convolutional filter untuk setiap input channel. Fase kedua pointwise convolution (1x1 convolution) digunakan di semua output channel pada depthwise convolution. Hasilnya, depthwise seperable convolution meningkatkan kecepatan perhitungan dengan mengurangi jumlah komputasi namun mengurangi sedikit akurasi (Siying Qian et al, 2021).

Linear Bottleneck diperkenalkan pada MobileNetV2 untuk mengurangi dimensionality input. Linear Bottleneck mengacu pada Bottleneck Layer, yang Dimana merupakan convolutional layer dengan 1x1 filter dan digabungkan dengan linear activation function. Karena fungsi transformasi ReLU tradisional memberikan non-linearity dengan kemungkinan hilangnya informasi, MobileNetV2 memasukkan linear bottleneck layer ke dalam convolutional blocks dengan asumsi bahwa aliran fiturnya berdimensi rendah dan dapat ditangkap (Siying Qian et al, 2021).

Inverted Residual digunakan sebagai cara yang lebih aman dan efisien untuk mengekstrak semua informasi penting dari input data, bottleneck layer menggantikan lapisan ReLu, lalu terdapat juga lapisan ekspansi di awal bottleneck block. Selain itu MobileNetV2 menggunakan shortcut secara langsung diantara bottleneck untuk menyebarkan gradien dengan lebih baik ke beberapa lapisan dan mencegah hilangnya gradien dan ledakan. Inverted Residual diuji valid untuk berfungsi seperti residual block namun mengurangi memory cost secara signifikan disaat yang bersamaan (Siying Qian et al, 2021).

Selain itu, MobileNetV3 memiliki *nonlinearity* baru yang disebut *hard swish (h-swish)*, yang merupakan versi modifikasi dari fungsi sigmoid. *Nonlinearity h-swish* didefinisikan seperti pada Persamaan dibawah, yang digunakan untuk meminimalkan jumlah parameter pelatihan dan mengurangi kompleksitas dan ukuran model (Mohamed Abd Elaziz et al, 2021).

$$h - swish(x) = x \cdot \sigma(x)$$

$$\sigma(x) = \frac{ReLU6(x + 3)}{6}$$

Input	Operator type	Kernel size	#exp and	#out	stride	S E	NL
$224^2 \times 3$	conv2d	3×3	-	16	2	-	<i>h-swish</i>
$112^2 \times 16$	bottleneck	3×3	16	16	2	✓	<i>ReLU</i>
$56^2 \times 16$	bottleneck	3×3	72	24	2	-	<i>ReLU</i>
$28^2 \times 24$	bottleneck	3×3	88	24	1	-	<i>ReLU</i>
$28^2 \times 24$	bottleneck	5×5	96	40	2	✓	<i>h-swish</i>
$14^2 \times 40$	bottleneck	5×5	240	40	1	✓	<i>h-swish</i>
$14^2 \times 40$	bottleneck	5×5	240	40	1	✓	<i>h-swish</i>
$14^2 \times 40$	bottleneck	5×5	120	48	1	✓	<i>h-swish</i>
$14^2 \times 48$	bottleneck	5×5	144	48	1	✓	<i>h-swish</i>
$14^2 \times 48$	bottleneck	5×5	288	96	2	✓	<i>h-swish</i>
$7^2 \times 96$	bottleneck	5×5	576	96	1	✓	<i>h-swish</i>
$7^2 \times 96$	bottleneck	5×5	576	96	1	✓	<i>h-swish</i>
$7^2 \times 96$	conv2d	1×1	-	576	1	✓	<i>h-swish</i>
$7^2 \times 576$	pool	7×7	-	-	1	-	-
$1^2 \times 576$	conv2d (no BN)	1×1	-	1280	1	-	<i>h-swish</i>
$1^2 \times 1280$	conv2d (no BN)	1×1	-	k	1	-	-

Gambar 2.10 Spesifikasi MobileNetV3-Small

Input	Operator type	Kernel size	#exp and	#out	stride	S E	NL
$224^2 \times 3$	conv2d	-	-	16	2	-	<i>h-swish</i>
$112^2 \times 16$	bottleneck	3×3	16	16	1	-	<i>ReLU</i>
$112^2 \times 16$	bottleneck	3×3	64	24	2	-	<i>ReLU</i>
$56^2 \times 24$	bottleneck	3×3	72	24	1	-	<i>ReLU</i>
$56^2 \times 24$	bottleneck	5×5	72	40	2	✓	<i>ReLU</i>
$28^2 \times 40$	bottleneck	5×5	120	40	1	✓	<i>ReLU</i>
$28^2 \times 40$	bottleneck	5×5	120	40	1	✓	<i>ReLU</i>
$28^2 \times 40$	bottleneck	3×3	240	80	2	-	<i>h-swish</i>
$14^2 \times 80$	bottleneck	3×3	200	80	1	-	<i>h-swish</i>
$14^2 \times 80$	bottleneck	3×3	184	80	1	-	<i>h-swish</i>
$14^2 \times 80$	bottleneck	3×3	184	80	1	-	<i>h-swish</i>
$14^2 \times 80$	bottleneck	3×3	480	112	1	✓	<i>h-swish</i>
$14^2 \times 112$	bottleneck	3×3	672	112	1	✓	<i>h-swish</i>
$14^2 \times 112$	bottleneck	5×5	672	160	2	✓	<i>h-swish</i>
$7^2 \times 160$	bottleneck	5×5	960	160	1	✓	<i>h-swish</i>
$7^2 \times 160$	bottleneck	5×5	960	160	1	✓	<i>h-swish</i>
$7^2 \times 160$	conv2d	1×1	-	960	1	-	<i>h-swish</i>
$7^2 \times 960$	pool	7×7	-	-	1	-	-
$1^2 \times 960$	conv2d (no BN)	1×1	-	1280	1	-	<i>h-swish</i>
$1^2 \times 1280$	conv2d (no BN)	1×1	-	k	1	-	-

Gambar 2.11 Spesifikasi MobileNetV3-Large


Terdapat 2 jenis MobileNetV3 berdasarkan tinggi atau rendahnya target resource atau penggunaanya yaitu MobileNetV3-Small dan MobileNetV3-Large, 2 model tersebut memiliki kompleksitas arsitektur yang berbeda (Siying Qian, Yuepeng Hu, Chenran Ning, 2021). Masing-masing spesifikasi MobileNetV3-Small dan MobileNetV3-Large dapat dilihat pada Gambar 2.10 dan 2.11.

2.7 Convolutional Block Attention Module

Mekanisme *Attention Network* terinspirasi dari mekanisme otak manusia, saat mengamati gambar orang hanya memusatkan perhatiannya pada petunjuk penting daripada melihat setiap detail pada objek tersebut (Tej Bahdur et al, 2022). Mekanisme *Attention Module* memungkinkan *Neural Network* untuk memperhatikan informasi yang penting dalam gambar dan dapat menyembunyikan informasi yang tidak berguna, hal ini dapat meningkatkannya efisiensi untuk proses klasifikasi gambar. *Convolutional Block Attention Module* (CBAM) adalah *Lightweight Attention Module* yang terdiri dari *Channel Attention Module* (CAM) dan *Spatial Attention Module* (SAM) (Shiqing Dou et al, 2023), dimana *Channel Attention Module* mencoba menangkap ‘apa’ yang penting dalam hal yang diberikan oleh gambar, sedangkan *Spatial Module Attention* berfokus pada 'di mana' atau bagian mana dari gambar tersebut penting (Tej Bahdur et al, 2022).

2.7.1 Channel Attention Module

Pertama, *Channel Attention Module* mengompres fitur input dalam dimensi spasial dan melakukan *Global Max Pooling* dan *Global Average Pooling* berdasarkan lebar dan tinggi masing-masing. Dua vektor satu dimensi yang digabungkan dimasukkan ke dalam vektor *Shared Multilayer Perceptron* (shared MLP) model, dan elemen MLP yang sesuai fitur output dijumlahkan satu per satu. Kedua, melalui fungsi aktivasi sigmoid, *Inner Product Operation* dilakukan dengan *Initial Feature Map*. *Output Feature Map* adalah fitur input yang diperlukan oleh *Spatial Module Attention*, seperti yang ditunjukkan pada Gambar 2.12.




Gambar 2.12 Channel Attention Module

2.7.2 Spatial Module Attention

Fitur yang dihasilkan oleh *Channel Attention Module* berfungsi sebagai *Input Feature Map* pada modul ini. Pertama, *Max Global Pooling* dan *Global Average Pooling* dilakukan berdasarkan *channel* dan dua *feature map* yang diperoleh digabungkan dalam *Channel Based*

Dimension. Kedua, operasi konvolusi 7 x 7 dilakukan. Setelah fungsi aktivasi sigmoid, *inner product operation* dilakukan pada *output feature map* dan *feature map* diinput oleh *Spatial Module Attention* untuk mendapatkan hasil akhir fitur, seperti yang ditunjukkan pada Gambar 2.13.



Gambar 2.13 Spatial Module Attention

Pada penelitian yang dilakukan oleh Tej BahadurShahi, Chiranjibi Sitaula, Arjun Neupane dan William Guo, mereka mengkombinasikan *Convolutional Block Attention Module* (CBAM) dengan MobileNetV2 untuk mengklasifikasi jenis buah. Hasilnya, penggabungan *Attention Module* dan konvolusi dapat meningkatkan kinerja (Presisi, Recall, skor MA_F1 dan Akurasi) model. Klasifikasi jika hanya menggunakan modul konvolusi mendapatkan akurasi sebesar 92,04%, sedangkan dengan menambahkan *Attention Module* akurasinya dapat mencapai 95,75%.

2.8 Kelapa Sawit

Kelapa sawit (*Elaeis guineensis*) merupakan tanaman pertanian yang penting secara global karena dapat digunakan untuk menghasilkan minyak nabati. Tanaman ini harus ditanam pada lahan yang sesuai agar tumbuh dengan baik dan tidak merugikan lingkungan sekitar. Kelapa sawit juga menjadi bahan dasar yang digunakan untuk menghasilkan beberapa jenis produk, termasuk produk makanan, seperti mie instan, mentega, selai, roti, dan kue, serta produk bukan makanan, seperti deterjen, sampo, sabun, dan biodiesel. Oleh karena itu, permintaan akan minyak kelapa sawit berkualitas tinggi terus meningkat. Kualitas kelapa sawit ditentukan oleh tingkat kematangan buah saat dipanen. Tingkat kematangan kelapa sawit ditentukan secara visual berdasarkan warna kulit buah. Minyak mentah buah kelapa sawit mempunyai warna gelap (ungu tua) dan berubah warna menjadi jingga ketika sudah matang (Septiarini, 2021) contoh gambar buah Kelapa Sawit dapat dilihat pada Gambar 2.14.



Gambar 2.14 Buah Kelapa Sawit (Dataset)

2.9 Penelitian Terdahulu

Penelitian terdahulu berisi kumpulan paper penelitian yang sudah dilakukan untuk menjadi referensi teori, metode ataupun teknik terhadap penelitian yang akan dilakukan. Paper yang diambil merupakan paper dari jurnal internasional dengan 5 tahun terakhir. Berikut merupakan pembahasan dari tiap paper penelitian tersebut.

2.9.1 Penelitian 1

Penelitian yang dilakukan oleh Suharjito, Gregorius Natanael Elwirehardja, dan Jonathan Sebastian Prayoga dengan judul “Oil palm fresh fruit bunch ripeness classification on mobile devices using deep learning approaches” pada tahun 2021 membuat sebuah aplikasi *mobile* untuk mengklasifikasi tingkat kematangan Buah Tandan Sawit (TBS) menggunakan pendekatan *deep learning* dengan 4 model Light-Weight CNN. Dataset yang digunakan berjumlah 656 foto TBS dengan masing-masing tingkat kematangan yaitu *unripe*, *under-ripe*, *ripe*, *over-ripe*, *abnormal*, dan *empty fruit bunch (EFB)*, lalu Dataset tersebut dilakukan pemfilteran gambar dengan Gaussian blur untuk mengurangi noise gambar atau degradasi pada kualitas gambar didalam Dataset. Dalam tahap *Data Augmentaion* penelitian ini menggunakan teknik 9-Crop yang bertujuan untuk memperkaya dataset dengan memotong 1 gambar TBS menjadi 9 bagian. Terdapat 4 model yang diuji yaitu MobileNet V1, MobileNetV2, EfficientNetB0 dan NASNet. Model *Deep Learning* yang digunakan dilatih menggunakan *Transfer Learning* dan metode augmentasi data yang disebut “9 angle crop”, kedua metode ini terbukti mampu meningkatkan akurasi MobileNetV1 ketika diuji pada validasi dan uji dataset. Model tersebut selanjutnya dioptimalkan menggunakan *Quantization* pasca pelatihan, dengan *Dynamic Range Quantization* memberikan hasil terbaik untuk NASNet Mobile dan float16 *Quantization* memberikan hasil terbaik untuk MobileNetV1, MobileNetV2, dan

EfficientNetB0. Float16 *Quantized* pada model EfficientNetB0 berhasil mencapai akurasi tertinggi yaitu mencapai akurasi sebesar 0,893 pada pengujian dataset. Di sisi lain, MobileNetV1 terbukti tidak hanya merupakan CNN paling efisien yang hanya membutuhkan waktu 39 ms untuk melakukan klasifikasi gambar, tetapi juga sangat akurat, dengan skor akurasi sebesar 81%.

2.9.2 Penelitian 2

Penelitian yang dilakukan oleh Chunguang Bi, Suzhen Xu, Nan Hu, Shuo Zhang, Zhenyi Zhu dan Helong Yu dengan judul “Identification Method of Corn Leaf Disease Based on Improved Mobilenetv3 Model” pada tahun 2023 mengusulkan metode untuk identifikasi penyakit daun jagung dengan menggunakan MobileNetV3. Berdasarkan model MobileNetv3, mereka mengganti *cross-entropy loss function* dengan *bias loss function* untuk meningkatkan akurasi, lalu mengganti modul *squeeze and excitation* (SE) dengan *efficient channel attention* (ECA) untuk mengurangi parameter. Hasil pengujian menunjukkan bahwa model ini memperoleh akurasi sebesar 98.23%, dengan nilai presisi 98.26%, nilai recall 98.26%, dan F1 score mencapai 98.26%.

2.9.3 Penelitian 3

Penelitian yang dilakukan oleh Wenhao Caoa, Zhuoyu Fenga, Dongyao Zhanga dan Yisiyuan Huanga dengan judul “Facial Expression Recognition via a CBAM Embedded Network” pada tahun 2020 mengusulkan penggunaan CBAM (Convolutional Block Attention Module) ke dalam model VGG untuk mendeteksi Ekspresi Wajah. Penggunaan Neural Network biasa untuk mendeteksi ekspresi wajah manusia dapat dilakukan akan tetapi menurut eksperimen akurasinya selalu rendah hanya mencapai 70% dan sering terjadi naik turunnya tingkat akurasi tersebut. Pada penelitian ini, mereka menggabungkan CBAM. Penelitian ini memilih untuk memasukkan Convolutional Block Attention Module (CBAM) ke dalam beberapa lapisan jaringan VGG yang digunakan untuk meningkatkan akurasi dan juga stabilitas. Dataset yang digunakan memiliki 981 gambar ekspresi wajah dengan masing-masing kelas yaitu angry (135), disgust (177), fear (75), happy (207), sad (84), surprise (249) dan contempt (54). Penelitian ini membandingkan hasil akurasi dari jaringan VGG biasa dengan jaringan VGG + CBAM, hasil akurasi dari jaringan VGG biasa sebesar 91%, sedangkan hasil akurasi VGG + CBAM sebesar 96%.

2.9.4 Penelitian 4

Penelitian yang dilakukan oleh Shiqing Dou, Lin Wang, Donglin Fan, Linlin Miao, Jichi Yan dan Hongchang He dengan judul “Classification of Citrus Huanglongbing Degree Based on CBAM-MobileNetV2 and Transfer Learning” pada tahun 2023 mengusulkan metode untuk klasifikasi penyakit Jeruk Huanglongbing dengan penggabungan MobileNetV2 dan Attention Module CBAM. Dataset yang digunakan adalah citra digital daun jeruk Huanglongbing dengan, 2360 citra *early stage*, 2024 citra *middle stage* dan 1624 citra *late stage*. Penelitian menggunakan model lain untuk membandingkan hasil akurasi dengan beberapa model yaitu MobileNetV2 standar, Xception dan InceptionV3. Hasil penelitian ini menyimpulkan bahwa penggunaan CBAM pada MobileNetV2 memiliki akurasi paling tinggi yaitu 98.75% dibandingkan dengan model lainnya, lalu pemilihan metode Transfer Learning juga dapat mempengaruhi hasil akurasi model yang diuji. Metode Transfer Learning Parameter Freezing dan Parameter Fine-Tuning yang digunakan dalam penelitian ini memberikan hasil bahwa Parameter Fine Tuning mendapatkan hasil yang lebih baik dibandingkan dengan menggunakan Parameter Freezing.

2.9.5 Penelitian 5

Penelitian yang dilakukan oleh Huixuan Fu, Guoqing Song dan Yuchao Wang dengan judul “Improved YOLOv4 Marine Target Detection Combined with CBAM” pada tahun 2021 mengusulkan model YOLOv4 dan menggabungkannya dengan CBAM untuk mendeteksi target laut. Deteksi target laut dengan cara tradisional tidak dapat memenuhi persyaratan akurasi dan kecepatan sehingga penelitian ini mengusulkan untuk menggunakan kelebihan dari *Deep Learning* dalam mendeteksi target laut menggunakan YOLOv4 dan menggabungkannya dengan *Convolutional Attention Module*. Dataset target laut dikumpulkan lalu dibagi menjadi sepuluh kategori yaitu speedboat, kapal perang, kapal penumpang, kapal kargo, perahu layar, kapal tunda, dan kayak. Penelitian ini bertujuan pada masalah ketidakcukupan akurasi deteksi target laut dengan hanya menggunakan YOLOv4, sehingga *Convolutional Attention Module* ditambahkan ke jaringan YOLOv4 untuk meningkatkan bobot fitur yang berguna sekaligus menekan bobot fitur yang tidak valid untuk meningkatkan akurasi deteksi. CBAM ditambahkan untuk membuat *Neural Network* lebih memperhatikan area sasaran yang berisi informasi penting, menekan informasi yang tidak relevan, dan meningkatkan akurasi. Hasil eksperimen menunjukkan bahwa Model YOLOv4 dengan CBAM memiliki akurasi lebih tinggi

untuk mendeteksi target dibandingkan YOLOv4 biasa, mAP50 meningkat sebesar 2,02%, mAP75 meningkat sebesar 1,85%, dan kecepatan deteksi memenuhi persyaratan real-time.

2.9.6 Penelitian 6

Penelitian yang dilakukan oleh Anindita Septriani Septriani, Hamdani Hamdani, Heliza Rahmania Hatta, Khoerul Anwar dengan judul “Automatic image segmentation of oil palm fruits by applying the contour-based approach” pada tahun 2020 mengusulkan metode segmentasi dengan pendekatan *Countour* untuk mengklasifikasi buah kelapa sawit diusulkan karena buah kelapa sawit memiliki bentuk dan warna yang beragam. Metode ini mengimplementasikan algoritma Canny yang menggabungkan beberapa operasi morfologi dan rekonstruksi untuk menghilangkan *noise* pada gambar. Ada tiga macam buah kelapa sawit berdasarkan tingkat kematangannya yaitu *unripe*, *under-ripe*, dan *ripe* dengan berbagai warna, bentuk, dan latar belakang gambar. Metode ini terdiri dari tiga proses utama yaitu lokalisasi buah kelapa sawit, *pre-processing*, dan segmentasi. Proses lokalisasi bertujuan untuk membentuk sub-gambar yang berfokus untuk menyajikan area buah kelapa sawit. Sub-gambar ini disebut *Region of Interest (ROI)*. Hasil pembentukan gambar ROI akan menjadi lebih kecil dari gambar aslinya dikarenakan area non-buah (latar belakang) telah dibuang sehingga dapat mengurangi waktu pemrosesan komputasi dan bahkan mengoptimalkan hasil dari proses berikut. Tahap *pre-processing* mengkonversi gambar ROI dalam ruang warna RGB menjadi *grayscale image*. *Grayscale Image* digunakan untuk menyederhanakan proses perhitungan proses serta membuat identifikasi area buah dan latar belakang menjadi lebih mudah. Buah Kelapa Sawit mempunyai warna bermacam-macam yang bergantung dengan tingkat kematangannya serta bentuknya. Gambar buah dengan latar belakang yang kompleks memungkinkan mempunyai warna yang mirip dengan benda lain. Oleh karena itu, dalam penelitian ini mengimplementasi *contour segmentation* menggunakan Canny edge detection. Metode yang diusulkan dievaluasi menggunakan dataset yang terdiri dari 160 gambar dengan tiga macam tingkat kematangan (60 *unripe*, 50 *under-ripe*, dan 50 *ripe*). Secara keseluruhan rata-rata akurasi segmentasi mencapai 90,13% dengan tingkat *false positive* dan *false negative* sebesar 2,92% dan 5,20%.

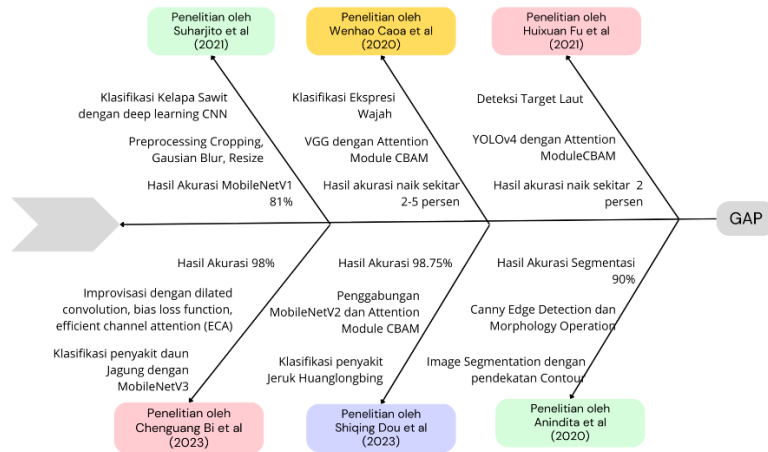
No	Penulis	Tahun	Objek	Metode	Hasil
1	Gregorius Natanael Elwirehardja, dan Jonathan Sebastian Prayoga	2021	Kelapa Sawit	Perbandingan 4 model lightweight CNN (MobileNet V1, MobileNetV2, EfficientNetB0 dan NASNet	MobileNetV1 mendapatkan hasil terbaik dengan akurasi sebesar 81%
2	Chunguang Bi, Suzhen Xu, Nan Hu, Shuo Zhang, Zhenyi Zhu dan Helong Yu	2023	Daun Jagung	Modifikasi MobileNetV3	Akurasi sebesar 98.23%, dengan nilai presisi 98.26%, nilai recall 98.26%, dan F1 score mencapai 98.26%.
3	Wenhao Caoa, Zhuoyu Fenga, Dongyao Zhanga dan Yisiyuan Huanga	2020	Ekspresi Wajah	VGG dan Convolutional Block Attention Module (CBAM)	Hasil akurasi dari jaringan VGG biasa sebesar 91%, sedangkan hasil akurasi VGG + CBAM sebesar 96%
4	Shiqing Dou, Lin Wang, Donglin Fan, Linlin Miao, Jichi Yan dan Hongchang He	2023	Daun Jeruk Huanglongbing	MobileNetV2, CBAM dan Transfer Learning lalu dibandingkan dengan MobileNetV2 standar, Xception dan InceptionV3	Hasil penelitian ini menyimpulkan bahwa penggunaan CBAM pada MobileNetV2 memiliki akurasi paling tinggi yaitu 98.75%

5	Huixuan Fu, Guoqing Song dan Yuchao Wang	2021	Target Laut	YOLOv4 dan CBAM	Hasil eksperimen menunjukkan bahwa Model YOLOv4 dengan CBAM memiliki akurasi lebih tinggi untuk mendeteksi target dibandingkan YOLOv4 biasa, mAP50 meningkat sebesar 2,02%, mAP75 meningkat sebesar 1,85%
6	Anindita Septriani Septriani, Hamdani Hamdani, Heliza Rahmania Hatta, Khoerul Anwar	2020	Kelapa Sawit	Segmentasi pendekatan Contour	Rata-rata akurasi segmentasi mencapai 90,13% dengan tingkat <i>false positive</i> dan <i>false negative</i> sebesar 2,92% dan 5,20%

Tabel 1. Penelitian Terdahulu

2.9.7 Fishbone Penelitian

Dalam melakukan penelitian, sangat penting untuk menentukan metode yang akan digunakan sesuai dengan tujuan penelitian tersebut. Pada penelitian ini penulis mengambil beberapa referensi metode dan teknik yang digunakan pada penelitian terdahulu, rangkuman penelitian tersebut disajikan dalam bentuk Fishbone Diagram pada Gambar 2.15.



Gambar 2.15 FishBone Penelitian

Berdasarkan metode dan teknik yang telah dilakukan pada penelitian terdahulu, untuk menjawab tujuan dari penelitian ini maka akan digunakan metode *deep learning* CNN dengan arsitektur MobileNetV3 dan menggabungkannya dengan *attention module* CBAM serta menggunakan pendekatan contour dalam tahap segmentasi data.

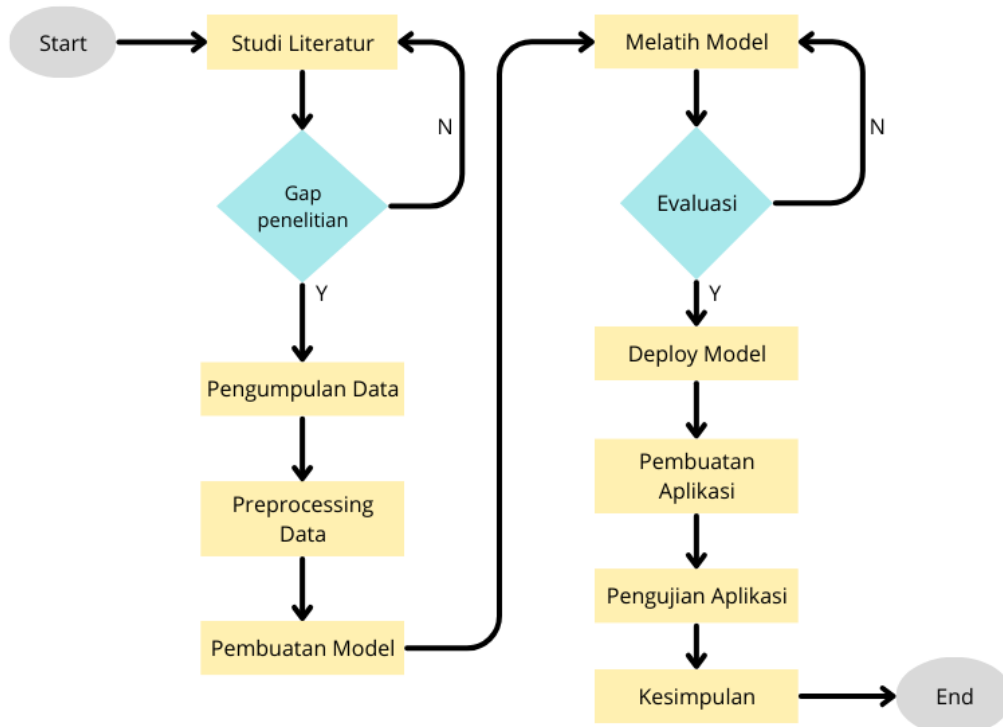
BAB 3

METODE PENELITIAN

Bab Metode Penelitian menjelaskan mengenai tahapan yang dilakukan dalam penelitian beserta menjelaskan mengenai jadwal dan estimasi waktu tahapan yang dilakukan pada penelitian ini serta menjelaskan mengenai kegiatan yang dilakukan selama penelitian. Tahapan penelitian dijelaskan dalam bentuk flowchart sehingga dapat menjelaskan proses yang dilakukan mulai dari Studi Literatur sampai dengan Kesimpulan, Jadwal dan Estimasi Penelitian digambarkan dalam bentuk Time Table untuk menjadwalkan dan melakukan estimasi waktu dari tiap tahap yang dilakukan.

3.1 Tahapan Penelitian

Terdapat beberapa tahapan yang dilakukan untuk melakukan penelitian ini, beberapa tahapan yang dilakukan dapat dilihat pada Gambar 3.1.



Gambar 3.1 Tahapan Penelitian

3.1.1 Studi Literatur

Tahap pertama yang dilakukan yaitu Studi Literature yang bertujuan untuk mencari informasi atau pengetahuan dari paper atau buku sebagai teori pendukung untuk melakukan penelitian dan mencari novelty atau gap peneltian yang sudah dilakukan. Paper dan buku yang digunakan dalam penelitian ini merupakan paper atau buku 5 tahun terakhir.

3.1.2 Pengumpulan Data

Tahap kedua yaitu pengumpulan data, data yang digunakan pada penelitian ini adalah data citra digital Kelapa Sawit dengan Tingkat kematangan Belum matang, Setengah matang, Matang, Terlalu matang dan Tandan Buah yang kosong. Data diambil dari beberapa sumber melalui website Kaggle dan Roboflow, lalu dilakukan pemilihan gambar yang sesuai untuk dijadikan sebagai dataset.



Gambar 3.2 Contoh data kelapa sawit dari masing-masing kelas

3.1.3 Preprocessing Data

Sebelum data digunakan pada model Machine Learning yang dibuat, data tersebut akan dilakukan preprocessing data agar data yang akan dilatih sesuai dengan keperluan yang dibutuhkan. Preprocessing yang dilakukan adalah *augmentasi* data, *resize*, dan Segmentasi Data. Gambar asli akan dilakukan *resize* menjadi ukuran 224x224 piksel lalu data tersebut akan di *augmentasi* untuk memperbanyak dan memvariasi data agar dan hasil *augmentasi* akan dijadikan sebagai data latih untuk model yang dibuat. *Augmentasi* yang dilakukan adalah *rotation_range*, *width_shift_range*, *height_shift_range*, *brightness_range*, *shear_range*, *zoom_range*, *horizontal_flip*, *vertical_flip*. Segmentasi dilakukan untuk memisahkan objek gambar dengan latar belakang sehingga proses klasifikasi akan lebih terfokus pada objek yang akan diproses.

3.1.4 Pembuatan Model

Tahap keempat yaitu pembuatan model machine learning menggunakan MobileNetV3 (Small/Large) dan menggabungkannya dengan attention module CBAM (Convolutional Block Attention Module).

3.1.5 Melatih Model

Tahap Kelima yaitu melatih model yang sudah dibuat menggunakan Dataset yang sudah dikumpulkan pada tahap pengumpulan data.

3.1.6 Evaluasi Model

Tahap Keenam yaitu evaluasi model, dari hasil pelatihan model akan dievaluasi atau dinilai apakah model tersebut sudah baik atau belum. Jika hasil dari evaluasi atau penilaian kinerja model kurang memuaskan maka tahap kelima akan dilakukan kembali.

3.1.7 Deploy Model

Tahap Ketujuh yaitu deploy model, model yang sudah dievaluasi dan dikatakan baik akan di deploy menjadi tflite sehingga dapat diintegrasikan ke dalam mobile device.

3.1.8 Pembuatan Aplikasi

Tahap kedelapan yaitu pembuatan aplikasi android, tahap ini dilakukan menggunakan Android Studio untuk membuat aplikasi android. Proses pembuatannya meliputi pembuatan tampilan user, memasukan tflite ke dalam aplikasi sehingga aplikasi dapat menggunakan Model Machine Learning untuk mengklasifikasi kematangan kelapa sawit menggunakan Kamera smartphone.

3.1.9 Pengujian Aplikasi

Tahap kesembilan yaitu pengujian aplikasi yang sudah dibuat, aplikasi akan diuji fungsi utamanya yaitu klasifikasi kematangan kelapa sawit.

3.1.10 Kesimpulan Penelitian

Tahap Kesepuluh yaitu menulis kesimpulan mengenai penelitian yang sudah dilakukan, kesimpulan ini mencakup kinerja model dan aplikasi yang sudah dibuat, kelebihan dan kekurangan penelitian dan penelitian selanjutnya yang akan dilakukan.

3.2 Jadwal Estimasi Penelitian

Jadwal Estimasi Penelitian menjelaskan mengenai rancangan kegiatan yang dilakukan selama penelitian beserta estimasi waktu tiap kegiatan yang dilakukan. Gambar Jadwal Estimasi Penelitian dapat dilihat pada Gambar 3.3.

Kegiatan	Tahun 1												Tahun 2											
	1	2	3	4	5	6	7	8	9	10	11	12	1	2	3	4	5	6	7	8	9	10	11	12
Studi Literatur	■	■	■	■	■																			
Pengumpulan Data		■	■	■	■	■																		
Preprocessing Data							■																	
Pembuatan Model								■	■	■	■	■												
Melatih Model									■	■	■	■	■											
Pembuatan Aplikasi											■	■	■	■	■	■								
Pengujian Aplikasi															■	■								
Kesimpulan																	■	■	■					

Gambar 3.3 Jadwal Estimasi Penelitian

Gambar diatas merupakan jadwal atau estimasi penelitian, kegiatan Studi Literatur dilakukan mulai dari bulan pertama pada tahun pertama, studi literatur dilakukan untuk mencari pengetahuan dan informasi untuk mendapatkan novelty dan gap dari penelitian yang akan dilakukan, pengumpulan data dilakukan mulai dari bulan kedua tahun pertama beriringan dengan studi literature.

Pada bulan keenam ditahun pertama dilakukan kegiatan preprocessing data, preprocessing data yang dilakukan adalah pemilihan data yang akan digunakan pada penelitian dari proses pengumpulan data, melakukan resize, augmentasi, dan segmentasi data. Pembuatan model model dilakukan pada bulan keenam beriringan dengan kegiatan pelatihan model serta melakukan evaluasi kinerja model yang sudah dilatih.

Bulan kesebelas melakukan kegiatan pembuatan aplikasi android, kegiatan yang dilakukan yaitu membuat aplikasi android menggunakan Android Studio, mendeploy model yang sudah dievaluasi menjadi format tflite lalu mengimplementasikannya ke dalam aplikasi android yang sudah dibuat. Pada bulan ketiga ditahun kedua akan dilakukan pengujian kinerja aplikasi dengan data baru lalu dilakukan evaluasi atau penilaian terhadap fungsi-fungsi aplikasi tersebut. Bulan keempat tahun kedua merupakan kegiatan terakhir yaitu menulis Kesimpulan penelitian.

3.3 Kegiatan Penelitian

Kegiatan yang dilakukan untuk melakukan penelitian dari tahun pertama sampai tahun ketiga dapat dilihat pada Tabel 2 berikut.

TAHUN PERTAMA	TAHUN KEDUA	TAHUN KETIGA
Studi Literatur	Evaluasi Model	Submit Jurnal Pertama
Pembuatan Proposal (BAB 1 sampai BAB 3)	Deploy dan Implementasi Model	Pembuatan Jurnal Kedua
Pengumpulan Dataset	Pembuatan Aplikasi	Submit Jurnal Kedua
Preprocessing Data	Menulis hasil penelitian (BAB 4)	
Pembuatan Model	Pengujian dan Evaluasi Aplikasi	
Melatih Model	Menulis hasil penelitian (BAB 4 dan BAB 5)	
	Pembuatan Jurnal Pertama	

Tabel 2. Kegiatan Penelitian

Kegiatan yang dilakukan pada tahun pertama yaitu melakukan studi literatur untuk pembuatan proposal penelitian (BAB 1 sampai BAB 3) lalu dilanjutkan dengan pengumpulan dan preprocessing data, setelah mendapatkan data kegiatan pembuatan dan pelatihan model dapat dilakukan.

Pada tahun kedua, dilakukan evaluasi model dan saat hasil evaluasi model sudah cukup baik, model akan di deploy untuk dapat diimplementasi ke dalam aplikasi yang sudah dibuat. Aplikasi akan dievaluasi dan diuji kinerjanya sehingga mendapatkan Kesimpulan dari penelitian untuk ditulis dalam BAB 4 sampai BAB 5. Pada Akhir tahun kedua, setelah mendapatkan Kesimpulan penelitian, dilakukan pembuatan jurnal pertama dan dilanjutkan pada tahun ketiga untuk pembuatan jurnal kedua.

DAFTAR PUSTAKA

- Africa ADM. Ripe Fruit Detection and Classification using Machine Learning. *International Journal of Emerging Trends in Engineering Research*. 2020 May 25;8(5):1845–9.
- Alzubaidi L, Zhang J, Humaidi AJ, Al-Dujaili A, Duan Y, Al-Shamma O, et al. Review of deep learning: concepts, CNN architectures, challenges, applications, future directions. *Journal of Big Data*. 2021 Dec 1;8(1).
- Anton A, Nissa NF, Janiati A, Cahya N, Astuti P. Application of Deep Learning Using Convolutional Neural Network (CNN) Method For Women's Skin Classification. *Scientific Journal of Informatics*. 2021 May 10;8(1):144–53.
- Ashari S, Yanris GJ, Purnama I. Oil Palm Fruit Ripeness Detection using Deep Learning. *Sinkron*. 2022 May 2;7(2):649–56.
- Bi C, Xu S, Hu N, Zhang S, Zhu Z, Yu H. Identification Method of Corn Leaf Disease Based on Improved Mobilenetv3 Model. *Agronomy*. 2023 Feb 1;13(2).
- Cao W, Feng Z, Zhang D, Huang Y. Facial Expression Recognition via a CBAM Embedded Network. In: *Procedia Computer Science*. Elsevier B.V.; 2020. p. 463–77.
- Chahal A, Gulia P. Machine learning and deep learning. *International Journal of Innovative Technology and Exploring Engineering*. 2019 Oct 1;8(12):4910–4.
- Chen L, Li S, Bai Q, Yang J, Jiang S, Miao Y. Review of image classification algorithms based on convolutional neural networks. Vol. 13, *Remote Sensing*. MDPI; 2021.
- Dong S, Wang P, Abbas K. A survey on deep learning and its applications. Vol. 40, *Computer Science Review*. Elsevier Ireland Ltd; 2021.
- Dou S, Wang L, Fan D, Miao L, Yan J, He H. Classification of Citrus Huanglongbing Degree Based on CBAM-MobileNetV2 and Transfer Learning. *Sensors*. 2023 Jun 1;23(12).
- Fu H, Song G, Wang Y. Improved yolov4 marine target detection combined with cbam. *Symmetry*. 2021 Apr 1;13(4).
- Hazarika RA, Maji AK, Sur SN, Paul BS, Kandar D. A Survey on Classification Algorithms of Brain Images in Alzheimer's Disease Based on Feature Extraction Techniques. Vol. 9, *IEEE Access*. Institute of Electrical and Electronics Engineers Inc.; 2021. p. 58503–36.

- Howard A, Sandler M, Chu G, Chen LC, Chen B, Tan M, et al. Searching for MobileNetV3. 2019 May 6; Available from: <http://arxiv.org/abs/1905.02244>
- Institute of Electrical and Electronics Engineers. 2021 IEEE 2nd International Conference on Big Data, Artificial Intelligence and Internet of Things Engineering (ICBAIE) : March 26-28, 2021, Nanchang, China.
- Jia L, Wang Y, Zang Y, Li Q, Leng H, Xiao Z, et al. MobileNetV3 with CBAM for Bamboo Stick Counting. IEEE Access. 2022;10:53963–71.
- Khatun M, Ali Nakib Aman Turzo F, Nine Pritom Sarker J. Fruits Classification using Convolutional Neural Network [Internet]. Vol. 5, GRD Journals-Global Research and Development Journal for Engineering. 2020. Available from: www.grdjournals.com
- Mutlag WK, Ali SK, Aydam ZM, Taher BH. Feature Extraction Methods: A Review. In: Journal of Physics: Conference Series. IOP Publishing Ltd; 2020.
- Prateek S, Abhishek V, Prabhat K.S, Virender R, Ram K, Image Processing and Intelligent Computing Systems, CRC Press, 2023.
- Patel J, Modi K. Indian Food Image Classification and Recognition with Transfer Learning Technique Using MobileNetV3 and Data Augmentation †. Engineering Proceedings. 2024;56(1).
- Penelitian Jurnal Agro Estate J, Rahmadhanian F, Sembiring P, Marshal Arifin Sinaga dan, Perkebunan B, Tinggi Ilmu Pertanian Agrobisnis Perkebunan S, et al. PENGARUH KEMATANGAN BUAH KELAPA SAWIT VARIETAS DXP BAH LIAS TERHADAP KADAR MINYAK SAWIT MENTAH (CPO) The Effect Of Palm Oil Fruit Maturity DxP Bah Lias Variety to the Crude Palm Oil Content.
- Phiphiphatphaisit S, Surinta O. Food Image Classification with Improved MobileNet Architecture and Data Augmentation. In: ACM International Conference Proceeding Series. Association for Computing Machinery; 2020. p. 51–6.
- Ruswanto A, Ramelan AH, Praseptiangga D, Bagus I, Partha B. Effects of Ripening Level and Processing Delay on the Characteristics of Oil Palm Fruit Bunches. 2020;10(1).
- Sayuti R, Marwan R, Fitri A, R.M, Muhammad Z, Muhammad I, Convolutional Neural Networks Untuk Visi Komputer Jaringan Saraf Konvolusional untuk Visi Komputer (Arsitektur Baru, Transfer Learning, Fine Tuning, dan Pruning), Deepublish, 2021.

- Scott E, Digital Image Processing and Analysis: Computer Vision and Image Analysis, CRC Press, 2023.
- Septiarini A, Sunyoto A, Hamdani H, Kasim AA, Utaminingrum F, Hatta HR. Machine vision for the maturity classification of oil palm fresh fruit bunches based on color and texture features. *Scientia Horticulturae*. 2021 Aug 25;286.
- Septiarini A, Hamdani H, Hatta HR, Anwar K. Automatic image segmentation of oil palm fruits by applying the contour-based approach. *Scientia Horticulturae*. 2020 Feb 5;261.
- Septiarini A, Sunyoto A, Hamdani H, Kasim AA, Utaminingrum F, Hatta HR. Machine vision for the maturity classification of oil palm fresh fruit bunches based on color and texture features. *Scientia Horticulturae*. 2021 Aug 25;286.
- Shahi TB, Sitaula C, Neupane A, Guo W. Fruit classification using attention-based MobileNetV2 for industrial applications. *PLoS ONE*. 2022 Feb 1;17(2 February).
- Suharjito, Elwirehardja GN, Prayoga JS. Oil palm fresh fruit bunch ripeness classification on mobile devices using deep learning approaches. *Computers and Electronics in Agriculture*. 2021 Sep 1;188.
- Susanto A, Wawan Cenggoro T, Pardamean B. Oil Palm Fruit Image Ripeness Classification with Computer Vision using Deep Learning and Visual Attention. Available from: https://farm3.static.flickr.com/2337/2387965665_1d4278c6
- Vaigai College of Engineering, Institute of Electrical and Electronics Engineers. Proceedings of the International Conference on Intelligent Computing and Control Systems (ICICCS 2020) : 13-15 May, 2020.
- Verma M. Artificial intelligence and its scope in different areas with special reference to the field of education [Internet]. Vol. 3, International Journal of Advanced Educational Research 5 International Journal of Advanced Educational Research. 2018. Available from: www.educationjournal.org
- Zhang C, Lu Y. Study on artificial intelligence: The state of the art and future prospects. *Journal of Industrial Information Integration*. 2021 Sep 1;23.
- Zheng M, Xu J, Shen Y, Tian C, Li J, Fei L, et al. Attention-based CNNs for Image Classification: A Survey. In: *Journal of Physics: Conference Series*. IOP Publishing Ltd; 2022.

Zhu F, Sun Y, Zhang Y, Zhang W, Qi J. An Improved MobileNetV3 Mushroom Quality Classification Model Using Images with Complex Backgrounds. *Agronomy*. 2023 Dec 1;13(12).

Zuhdi DAF, Abdullah MF, Suliswanto MSW, Wahyudi ST. The Competitiveness of Indonesian Crude Palm Oil in International Market. *Jurnal Ekonomi Pembangunan*. 2021 Jul 3;19(1):111–24.