



**Pengembangan Model Klasifikasi Anomali
Penyakit Paru Akibat COVID-19 Pada Citra
Sinar-X Paru**

SEMINAR BIDANG KAJIAN

Riezka Yunistika Fajriatifah
99223135

**PROGRAM DOKTOR TEKNOLOGI INFORMASI
UNIVERSITAS GUNADARMA
Juni 2024**

Daftar Isi

BAB 1	1
PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Batasan dan Rumusan Masalah.....	6
1.3 Tujuan Penelitian	6
1.4. Kontribusi dan Manfaat Penelitian	7
BAB 2	8
TELAAH PUSTAKA	8
2.1 <i>Artificial Intelegence</i>	8
2.2 Deep Learning.....	9
2.3 Convolutional Neural Network (CNN).....	9
2.3.1 Lapisan Lapisan dalam CNN	11
2.4 ConvNeXt	15
2.5 DenseNet.....	15
2.6 VGG19	16
2.7 ResnetV2_50	17
2.8 Xception	18
2.9 Model Stacking	18
2.10 Citra.....	20
2.11 Jenis Citra.....	22
2.11.1 Citra Berwarna	22
2.11.2 Citra Keabuan.....	23
2.11.3 Citra Biner	24
2.12 Aplikasi Pengolahan Citra.....	25
2.12.1 Citra Medis.....	25
2.13 Anatomi Paru	27
2.14 Virus Corona	29
2.14.1 Coronavirus Disease 2019 (COVID-19).....	30
2.15 Kajian Penelitian	34
2.16 Roadmap Penelitian	58

BAB 3	59
METODE PENELITIAN.....	59
3.1 Dataset COVID-19 Radiography	61
3.2 Preprocessing Dataset	62
3.3 Dataset Splitting	64
3.4 Pembuatan dan Pelatihan Model.....	66
3.4.1 Model ConvNeXt.....	66
3.4.2 Transfer Learning.....	67
3.5 Pelatihan Model	69
3.7 Evaluasi Model.....	71
3.8 Metode Stacking.....	73
3.9 Evaluasi Model Stacking	74
3.10 Inference dan Deployment	74
3.11 Time Table	74
Daftar Pustaka	76

BAB 1

PENDAHULUAN

1.1 Latar Belakang

Artificial Intelligence (Kecerdasan Buatan) merupakan cabang dari ilmu komputer yang berfokus pada pembuatan perangkat keras dan perangkat lunak yang dapat "berpikir" dan "belajar" seperti manusia (Kumar Verma & Verma, 2018). Karakteristik utama dari kecerdasan buatan adalah *knowledge* (pengetahuan). *Knowledge* seringkali direpresentasikan dalam bentuk struktur data yang dapat dimengerti dan diolah oleh sistem, seperti basis pengetahuan, grafik pengetahuan, atau model statistik (Amrizal, 2013).

Salah satu pendekatan dalam pengembangan kecerdasan buatan adalah *machine learning* (pembelajaran mesin). Pendekatan ini mencakup berbagai teknik seperti *supervised learning* (pembelajaran terawasi) dan *unsupervised learning* (pembelajaran tanpa pengawasan). Salah satu subbidang dari pembelajaran mesin adalah *deep learning* (pembelajaran mendalam). *Deep learning* menggunakan *deep neural networks* (Goodfellow, Bengio, Courville, 2016). *Deep learning* memiliki kemampuan untuk memproses, menganalisis data, dan mengekstraksi fitur secara otomatis yang berguna dalam berbagai bidang. Dalam bidang kesehatan, *deep learning* dapat digunakan untuk membantu deteksi penyakit, salah satunya saat pandemi *Coronavirus Disease 2019* (COVID-19) pada tahun 2019.

COVID-19 merupakan penyakit yang disebabkan oleh infeksi virus *Severe Acute Respiratory Syndrome Coronavirus 2* (SARS-CoV-2) (WHO, 2024). Virus ini pertama kali diidentifikasi pada 31 Desember 2019 di kota Wuhan, provinsi Hubei, Tiongkok (Rehman, Fariha, Anwar, 2021). Penyakit ini biasanya menginfeksi sistem pernafasan dan menimbulkan gejala yang mirip dengan Pneumonia. Gejala klinis infeksi COVID-19 meliputi demam, batuk kering, sesak nafas, kelelahan dan kekeruhan *ground-glass bilateral* pada *CT scan* dan sinar-X paru (Huang, Wang, Li, Ren, Zhao, Hu, 2020). Penularan COVID-19 dapat terjadi

dari manusia ke manusia melalui droplet atau penularan langsung (Lai, Shih, Ko, Tang, Hsueh, 2020). COVID-19 telah menyebar ke seluruh dunia dalam waktu yang relatif singkat dan menyebabkan pandemi global. Sejak pertama kali diidentifikasi sampai dengan 13 April 2024, tercatat total 775 juta kasus COVID-19 di seluruh dunia dengan 7 juta kasus menyebabkan kematian (Sumber: COVID - Coronavirus Statistics - Worldometer, 2024). Sampai saat ini penyebaran COVID-19 secara global masih berlangsung, terdapat lebih dari 30 ribu kasus baru setiap minggu (WHO, 2024).

Dalam menghadapi penyebaran virus yang terus berlangsung, kecepatan dan keakuratan dalam deteksi menjadi sangat penting karena virus ini mudah menular. Teknik laboratorium untuk mendeteksi COVID-19 yang menjadi standar adalah *Reverse Transcription Polymerase Chain Reaction* (RT-PCR) dan *Rapid Antigen Testing* (RAT) (Munne, Bhanothu, & Pande 2021). RT-PCR memiliki keterbatasan karena membutuhkan waktu yang lama serta peralatan dan biaya yang mahal (Rakhmina, & Herlina 2022). RAT memiliki sensitivitas yang rendah (Agustina, Fajrunni, 2020). Melihat keterbatasan tersebut, pendekatan melalui pencitraan radiologi seperti sinar-X paru dan Tomografi Komputer (CT) menjadi metode diagnostik alternatif yang umum digunakan. Menggunakan gambar radiografi seperti sinar-X paru untuk klasifikasi, memiliki kelebihan karena prosedurnya yang cepat, non-invasif, dan biaya yang relatif rendah (Zhang, Xie, Pang & Xia, 2021) dibandingkan dengan tes PCR. Selain itu, sinar-X paru lebih ekonomis daripada tes radiologi lainnya seperti CT scan dan tersedia di hampir setiap klinik (Das, Ghosh, Thunder, 2021).

Salah satu cara untuk membedakan penyakit COVID-19 dengan penyakit paru-paru lainnya adalah melalui pemeriksaan radiologi yang dilakukan dengan memeriksa kondisi organ paru-paru. Metode pemeriksaan radiologi yang umum digunakan adalah menggunakan citra sinar-x paru untuk mengetahui kondisi organ paru-paru. Paru-paru yang terkena penyakit COVID-19 memiliki ciri terdapat bintik-bintik putih yang menandakan peradangan pada bagian paru-paru disebabkan infeksi virus SARS-Cov-2. Perbedaan citra Xray (Marginean, Popescu, Vasile, Cioboata, 2022) COVID-19 dengan penyakit paru-paru umum lainnya

adalah letak bintik putih (Rousan, Elobeid, Karrar & Khader, 2020) yang menandakan infeksi dapat terjadi pada bagian atas maupun bawah paru-paru. Hal ini berbeda dengan penyakit *Viral Pneumonia* yang disebabkan oleh bakteri maupun virus yang letak peradangan berada di bagian bawah paru-paru (Balasubramaniam, Varma, Das, Lomoro, 2020). Hasil citra sinar-x COVID-19 juga memiliki perbedaan dengan penyakit *Lung Opacity* yang memiliki hasil lebih buram yang menandakan bahwa paru-paru terjadi infeksi, pendarahan, maupun edema paru.

Salah satu metode yang digunakan untuk membedakan antara paru yang terinfeksi COVID-19 dengan penyakit paru lainnya adalah dengan melakukan klasifikasi menggunakan metode *deep learning* berbasis algoritma *Convolutional Neural Network* (CNN) (Chang & Huang, 2022). Penelitian tentang klasifikasi COVID-19 menggunakan citra sinar-X paru telah banyak dilakukan. Beberapa penelitian mencoba untuk mengembangkan model deteksi COVID-19 diantaranya dilakukan oleh Nour, Comert & Polat mengembangkan model diagnosis infeksi COVID-19 menggunakan CNN untuk ekstraksi fitur. Hasil dari CNN digunakan sebagai input untuk algoritma KNN, SVM, dan *Decision Tree*, dengan *hyperparameter* yang dioptimalkan menggunakan algoritma optimasi Bayesian. Hasil terbaik diperoleh dari penggunaan algoritma SVM, dengan akurasi 98,97%, Akurasi 3 kelas sebesar 87,02%. Penelitian ini masih memiliki keterbatasan dalam mendeteksi pada kelas jamak (Nour, Comert & Polat, 2020).

Ozturk T, Talo M & Yildirim E mengembangkan DarkCovidNet. Model ini memiliki 17 lapisan konvolusi dengan struktur *end-to-end*. Akurasi untuk deteksi biner COVID-19 sebesar 98,08% dan 87,02% untuk deteksi pada kelas jamak. Penelitian ini memiliki kelemahan dalam klasifikasi kelas jamak, prediksi citra berkualitas rendah yang tidak akurat, dan kesulitan dalam mengklasifikasikan gambar dengan detail halus (Ozturk, Talo, Yildirim, 2020). Lingzhi Kong & Jinyong Cheng menggabungkan arsitektur DenseNet dan VGG16 dengan mengintegrasikan vektor fitur sebelum lapisan klasifikasi akhir. Mereka juga menerapkan mekanisme perhatian *Global Attention Block* (GAB) dan *Category Attention Block* (CAB). Model dilatih menggunakan teknik *k-fold cross-validation*

dengan membagi dataset menjadi 5 subset. Model ini mencapai akurasi 98% untuk klasifikasi biner (sehat vs. pneumonia) dan 97.3% untuk klasifikasi tiga kategori (sehat, pneumonia, dan COVID-19) (Kong & Cheng, 2022).

Sreejith & George menerapkan metode transfer learning dengan menggunakan model ResNet50V2 dan InceptionResNetV2. Proses pelatihan menggunakan optimizer adam dan dilakukan sebanyak 100 epoch. Hasil pengujian pada dataset uji menunjukkan bahwa model dengan arsitektur tersebut memiliki performa yang baik dengan nilai *accuracy* mencapai 96% untuk model ResNet50V2 dan 94% InceptionResNetV2 (Sreejith & George, 2021)

Penelitian (Liu, Mao, Wu, Feichtenhofer, Darrell, Saining Xie, 2020) mengimplementasikan model klasifikasi menggunakan CNN dengan arsitektur ConvNeXt berbasis *Residual Depth-wise Convolution* yang membuat model memiliki berbagai macam varian. Varian model yang digunakan adalah ConvNeXt base yang merupakan original arsitektur model ConvNeX (Bekhet, Alkinani, Soto, Hassaballah, 2021). Model berbasis arsitektur ConvNeXt merupakan salah satu model yang mencapai top-1 accuracy pada dataset ImageNet dengan accuracy sebesar 87.6% yang menjadikan model ini sebagai salah satu model terbaik untuk kasus klasifikasi citra (Nugroho, Puspaningrum, Munir, 2022).

Berbeda dengan beberapa penelitian diatas yang menggunakan satu model tunggal, penelitian ini mengintegrasikan berbagai model pengklasifikasi menjadi satu model menggunakan teknik *stacking*. *Integrated stacking* merupakan teknik pembelajaran *ensemble*. Metode ini menggabungkan prediksi dari berbagai model yang berbeda, sehingga dapat meningkatkan kemampuan model untuk membuat prediksi yang lebih akurat (Rajagopal, Kundapur & Hareesha, 2020). Konsep *stacking* dilakukan melalui dua tahap utama: Pertama, beberapa model dasar (atau model level-0) dilatih pada dataset yang sama. Kedua, prediksi yang dihasilkan oleh model-model dasar digunakan sebagai input untuk *meta-learner* (atau model level-1). *Meta-learner* ini kemudian dilatih untuk membuat prediksi akhir berdasarkan prediksi dari model dasar (AlMohimeed, Saleh, El-Rashidy, Saad, El-Sappagh & Mostafa, 2023).

Rajkumar, Himanshu & Marimuthu mengembangkan model WavStaCov Net-19. Model ini terdiri dari ResNet50, VGG19, Xception, dan DarkNet19, keempat arsitektur ini digabungkan dengan teknik *stacking*. Akurasi untuk klasifikasi tiga kelas adalah 96,10%, sementara untuk klasifikasi empat kelas 94,24% (Rajkumar, Himanshu & Marimuthu, 2023).

Dalam pelatihan model CNN dengan metode *transfer learning*, beberapa parameter seperti Pemilihan *learning rate* pada *optimizer* dan *batch size* berperan penting untuk mencapai bobot yang optimal. Proses pemilihan parameter tersebut dapat mempengaruhi kinerja model. He, Zhang, Xie & Muli mengimplementasikan perubahan nilai *learning rate* secara dinamis berbasis *Cosine Learning Rate Decay*. Penelitian tersebut menunjukkan bahwa penggunaan teknik *Cosine Learning Rate Decay* pada model ResNet-50-D berhasil meningkatkan akurasi top-1 pada dataset *ImageNet* dari 77.16% menjadi 77.91%. Penelitian ini juga menjelaskan mengenai penggunaan *batch size*. penggunaan *batch size* yang besar membuat model dapat mempelajari lebih banyak variasi data dalam satu *batch* pelatihan. Hal ini dapat menghasilkan nilai metrik performa yang lebih baik dibandingkan dengan penggunaan *batch size* yang kecil (He, Zhang, Xie & Muli, 2018).

Penelitian ini melakukan pembentukan model klasifikasi anomali penyakit paru akibat COVID-19 pada citra sinar-X paru menggunakan arsitektur CNN antara lain : DenseNet, VGG19, ResNetV2_50, Xception, dan ConvNext. Pengembangan pada penelitian ini dilakukan dengan menerapkan metode *stacking* dengan cara menumpuk keluaran (output) dari setiap arsitektur dengan mengambil kelebihan dari masing-masing arsitektur. Setiap arsitektur CNN tersebut dilatih secara independen untuk menghasilkan prediksi, dimana hasil prediksinya akan digunakan sebagai masukan meta-model dalam kerangka *stacking*. Meta-model merupakan model yang dilatih pada prediksi yang dihasilkan oleh model dasar. Model ini berfungsi untuk mempelajari prediksi dari model dasar (ground model) dapat digabungkan untuk menghasilkan klasifikasi akhir yang lebih akurat. Pelatihan model tunggal pada penelitian ini menerapkan pembobotan ulang pada fungsi *loss* untuk mengatasi ketidakseimbangan data pada dataset. Proses pelatihan model menggunakan metode *transfer learning* dan optimasi *Cosine Learning Rate Decay*

untuk mengubah nilai learning rate sehingga lebih cepat mencapai nilai gradient optimal pada dataset yang digunakan.

1.2 Batasan dan Rumusan Masalah

Permasalahan dalam penelitian ini adalah:

1. Bagaimana mendeteksi anomali pada citra sinar-X paru-paru yang dapat mengindikasikan adanya penyakit paru akibat infeksi COVID-19 menggunakan arsitektur CNN?
2. Bagaimana mengintegrasikan beberapa arsitektur CNN untuk mengklasifikasi penyakit paru akibat covid-19 menjadi satu model ensemble?
3. Bagaimana komparasi hasil akurasi dari model arsitektur tunggal dan model stacking dalam melakukan klasifikasi penyakit paru akibat COVID-19.

Batasan masalah dalam penelitian ini adalah:

1. Pada penelitian ini, data yang digunakan merupakan citra sinar-X paru yang berasal dari *COVID-19 Radiography Database*. Dataset dapat diakses di platform Kaggle pada url [COVID-19 Radiography Database](#).
2. Dataset Terdiri dari 3.616 citra sinar-X positif Covid-19, 10.119 citra normal, 6.012 citra *lung opacity* dan 1.345 citra pneumonia virus.
3. Semua citra dalam format file *Portable Network Graphics* (PNG) dan memiliki resolusi 299*299 piksel.
4. Setiap citra dalam dataset memiliki label tunggal.

1.3 Tujuan Penelitian

Berdasarkan permasalahan yang diuraikan, penelitian ini bertujuan :

1. Menghasilkan model CNN untuk mendeteksi anomali pada citra sinar-X paru-paru yang dapat mengindikasikan adanya penyakit paru akibat infeksi COVID-19.
2. Menghasilkan ensemble model hasil integrasi output beberapa arsitektur CNN untuk mengklasifikasi penyakit paru akibat covid-19.

3. Menghasilkan komparasi akurasi model arsitektur tunggal dan model stacking dalam melakukan klasifikasi penyakit paru akibat COVID-19.

1.4. Kontribusi dan Manfaat Penelitian

a. Keilmuan

Penelitian ini memberikan kontribusi dalam pengembangan metode baru untuk mengklasifikasikan dan mendeteksi anomali pada citra sinar-X paru yang terkait dengan infeksi COVID-19 dengan menggabungkan berbagai arsitektur pengklasifikasi menjadi satu model ensemble menggunakan metode *stacking*. Pemanfaatan model *integrated stacking* dapat meminimalkan kesalahan diagnostik dengan menggabungkan keunggulan dari berbagai model pembelajaran mesin. Menghasilkan prediksi yang lebih akurat dibandingkan dengan penggunaan model tunggal.

b. Sisi Teknologi

Penerapan model *integrated stacking* pada sistem deteksi dan klasifikasi penyakit COVID-19 dapat mengurangi beban komputasi dalam melakukan pendeteksian penyakit paru akibat COVID-19.

c. Sisi Manfaat

Penelitian ini diharapkan dapat membantu tenaga medis, khususnya radiolog dan dokter spesialis paru-paru, dalam membantu diagnosis yang cepat dan tepat, serta penatalaksanaan tindakan pengobatan pasien COVID-19 dengan lebih efektif.


BAB 2

TELAAH PUSTAKA

2.1 *Artificial Intelligence*

Artificial intelligence merupakan hasil gabungan ilmu dan rekayasa dari berbagai bidang, seperti filsafat, psikologi, dan ilmu computer (Verma, 2018). Pada tahun 1943 Warren McCulloch dan Walter Pitts mengusulkan model awal neuron buatan di mana setiap neuron didefinisikan sebagai "hidup" atau "mati," tergantung pada jumlah stimulasi dari neuron tetangga. Model ini terinspirasi dari tiga sumber, yaitu pengetahuan tentang fisiologi dasar dan fungsi neuron dalam otak, analisis formal logika proposisi yang dikembangkan oleh Russell dan Whitehead, dan teori komputasi yang ditemukan oleh Alan Turing. Model yang diusulkan menjadi dasar untuk pengembangan lebih lanjut dalam bidang artificial intelligence (Russell & Norvig, 2010).


Nama "*artificial intelligence*" diusulkan oleh John McCarthy ketika sedang menyusun sebuah seminar musim panas di Dartmouth pada tahun 1956 (Tecuci, 2012). Artificial intelligence (AI) bertujuan untuk menciptakan perangkat lunak dan perangkat keras komputer yang memiliki pemikiran seperti manusia (Lucci & Kopec, 2016). Artificial intelligence adalah bidang yang terkait dengan pengembangan dan implementasi algoritma untuk memproses data, belajar, dan menafsirkan informasi (Rahman & Saputra, 2023).



Gambar 2.1 Pendekatan dalam Artificial intelligence (Verma, 201

2.2 Deep Learning

Deep learning adalah subdomain dari pembelajaran mesin yang berfokus pada algoritma, fungsi matematika, dan jaringan saraf tiruan (Goodfellow et al., n.d.). *Deep Learning* adalah salah satu fungsi artificial intelligence yang meniru cara kerja otak manusia dalam memproses data dan menciptakan pola untuk digunakan dalam pengambilan keputusan. *Deep Learning* terdiri dari banyak jenis algoritma, beberapa yang paling sering digunakan adalah *Convolutional Neural Network* (CNN), *Multilayer Perceptrons* (MLP), dan *Recurrent Neural Network* (RNN). Keunggulan *deep learning* adalah memiliki performa terbaik dalam menyelesaikan masalah kompleks, mengurangi kebutuhan untuk rekayasa ciri, dan memiliki arsitektur yang mampu beradaptasi terhadap permasalahan baru dengan mudah. Sementara, kekurangan dari *deep learning* adalah membutuhkan banyak data, proses training yang memakan waktu, dan *overfitting*.




Gambar 2.2 Cabang ilmu artificial intelligence

2.3 Convolutional Neural Network (CNN)

Jaringan saraf konvolusi (CNN) merupakan salah satu tipe model dalam pembelajaran mendalam untuk memproses data yang memiliki pola grid, seperti gambar. Model ini dikembangkan untuk mempelajari hierarki fitur spasial, dimulai dari level yang paling dasar hingga pola yang lebih kompleks secara otomatis dan

adaptif (Yamashita, Nishio, Do & ogashi, 2018). Jaringan saraf konvolusi (CNN) terdiri dari neuron dengan bobot dan bias yang dapat dipelajari. Lapisan-lapisan CNN memiliki neuron yang disusun dalam beberapa dimensi: saluran (*channels*), lebar (*width*), tinggi (*height*), dan jumlah filter dalam kasus 2D paling sederhana. Sebuah jaringan saraf konvolusi terdiri dari serangkaian lapisan, di mana setiap lapisan mentransformasi aktivasi atau output dari lapisan sebelumnya melalui fungsi diferensial lainnya. Beberapa lapisan yang digunakan dalam CNN meliputi lapisan konvolusi, lapisan penggabungan (*pooling layer*), dan lapisan terhubung penuh (*fully connected layers*) (Teuwena & Moriakov, 2019).

Lapisan konvolusi dan lapisan penggabungan berperan dalam mengekstraksi fitur dari data input. Lapisan konvolusi menggunakan filter untuk mengekstraksi fitur-fitur penting dari data, seperti tepi, sudut, atau tekstur, sementara lapisan penggabungan membantu mereduksi dimensi spasial dari fitur-fitur yang diekstraksi, sehingga mempertahankan informasi yang relevan dan mengurangi *overfitting*. Lapisan yang terhubung sepenuhnya berperan dalam memetakan fitur yang telah diekstraksi ke dalam keluaran akhir, seperti pada tahap klasifikasi. Dengan keterhubungan penuh antar setiap neuron di lapisan ini dengan semua neuron di lapisan sebelumnya, informasi fitur yang ada dapat diserap secara menyeluruh untuk menghasilkan prediksi atau klasifikasi yang akurat sesuai dengan tujuan model CNN (Yamashita et al., 2018).



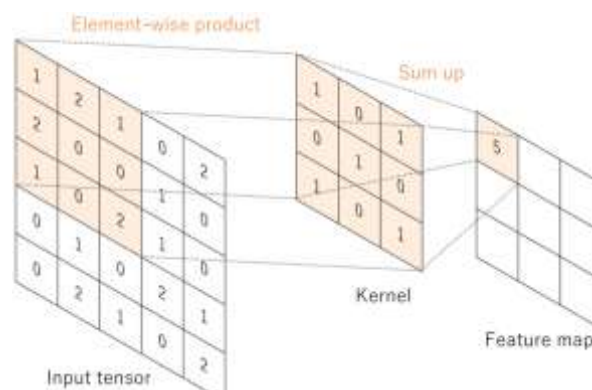
Gambar 2.3 Arsitektur dan proses pelatihan CNN (Yamashita et al., 2018)

2.3.1 Lapisan Lapisan dalam CNN

Arsitektur CNN terdiri dari beberapa lapisan yang memiliki peran penting dalam mengolah informasi. Setiap lapisan dalam CNN dijelaskan secara rinci di bawah ini.

1. Lapisan Konvolusi

Konvolusi adalah suatu jenis operasi linier dan non-linier, yang meliputi operasi konvolusi dan fungsi aktivasi. Lapisan konvolusi merupakan elemen kunci dalam struktur CNN yang dipakai untuk mengekstraksi fitur-fitur penting dari gambar, seperti tepi, sudut, atau tekstur. Dalam operasi konvolusi, setiap langkah dimulai dengan menggeser sebuah matriks kecil (kernel) ke seluruh wilayah gambar secara bertahap. Pada setiap posisi, terjadi perkalian antara elemen-elemen kernel dan nilai-nilai yang sesuai dalam gambar. Data input yang diproses oleh operasi konvolusi berupa sebuah array angka yang disebut tensor. Pada setiap titik dalam tensor input, hasil perkalian antara setiap elemen dalam kernel dan nilai pada titik yang sama dalam tensor input dihitung, kemudian hasilnya dijumlahkan untuk memperoleh nilai pada tensor output, yang dikenal sebagai peta fitur. Operasi konvolusi digambarkan pada gambar 2.4. Hasil dari operasi konvolusi adalah peta fitur, representasi dari fitur-fitur yang relevan dalam data input. Peta fitur mengandung informasi tentang pola-pola penting seperti tepi, sudut, atau tekstur dalam gambar. Dua parameter utama yang mempengaruhi operasi konvolusi adalah ukuran kernel dan jumlah kernel. Ukuran kernel biasanya 3×3 , tetapi kadang-kadang dapat berukuran 5×5 atau 7×7 . Jumlah kernel dapat bervariasi dan menentukan kedalaman peta fitur keluaran.




Gambar 2.4 Operasi Konvolusi

2. Lapisan Pengumpulan

Lapisan Pengumpulan memiliki tugas utama untuk melakukan subsampling dari peta fitur yang dihasilkan melalui operasi konvolusi sebelumnya. Pendekatan ini bertujuan untuk mengurangi ukuran peta fitur yang besar menjadi peta fitur yang lebih kecil, dengan mempertahankan sebagian besar informasi atau fitur dominan dalam setiap langkah pengumpulan. Terdapat berbagai metode pengumpulan yang tersedia, seperti pengumpulan pohon (*tree pooling*), pengumpulan berpintu (*gated pooling*), pengumpulan rata-rata (*average pooling*), pengumpulan minimum (*min pooling*), pengumpulan maksimum (*max pooling*), pengumpulan rata-rata global (*global average pooling*) (GAP), dan pengumpulan maksimum global (*global max pooling*).

Setiap metode memiliki ciri khasnya sendiri dan diterapkan sesuai dengan kebutuhan aplikasi serta tujuan pengolahan data yang diinginkan. Sebagai contoh, pengumpulan maksimum digunakan untuk mengekstraksi fitur paling dominan dari suatu wilayah, sedangkan pengumpulan rata-rata digunakan untuk meratakan nilai-nilai piksel di wilayah tersebut. Pengumpulan global (GAP) adalah metode yang sering digunakan untuk merangkum fitur dari seluruh peta fitur. Metode pooling yang paling dikenal dan sering digunakan adalah pengumpulan maksimum (max), minimum (min), dan rata-rata global (GAP).



Gambar 2.5 Operasi Pengumpulan

3. Fungsi Aktivasi

Fungsi aktivasi dalam CNN adalah sebuah mekanisme matematis *non linear* yang menentukan apakah neuron dalam jaringan tersebut harus "menyala" atau tidak berdasarkan pada masukan yang diterima. Konsep ini serupa dengan cara kerja saklar: ketika masukan mencapai suatu ambang tertentu, neuron akan diaktifkan dan menghasilkan keluaran. Dalam arsitektur CNN, setiap neuron memiliki fungsi aktivasi yang membantu menentukan keberadaan fitur spesifik dalam masukan. Misalnya, jika neuron tertentu sensitif terhadap sudut dalam sebuah gambar, fungsi aktivasinya akan memberikan sinyal yang lebih tinggi jika sudut tersebut hadir dalam gambar tersebut.

Lapisan aktivasi non-linear digunakan setelah semua lapisan dengan bobot yang dapat dipelajari, seperti lapisan terhubung penuh (FC) dan lapisan konvolusi. Dengan menerapkan fungsi aktivasi non-linear, pemetaan dari masukan ke keluaran menjadi lebih kompleks dan tidak linear. Ini menunjukkan bahwa jaringan mampu memahami hubungan antara fitur-fitur masukan yang lebih kompleks dibandingkan jika menggunakan fungsi linear sederhana. Jenis fungsi aktivasi berikut ini adalah yang paling umum digunakan dalam CNN dan jaringan saraf mendalam lainnya.

- Sigmoid: fungsi aktivasi sigmoid dapat menerima input dari seluruh rentang bilangan riil, baik negatif maupun positif. Saat proses transformasi dilakukan menggunakan fungsi sigmoid, nilai-nilai ini kemudian dikonversi menjadi output yang terbatas di antara 0 dan 1. Kurva sigmoid memiliki bentuk S dan dapat direpresentasikan secara matematis dengan persamaan 2.1.

$$f(x)_{\text{sigm}} = \frac{1}{1+e^{-x}} \quad (2.1)$$

- Tanh: Fungsi aktivasi tangen hiperbolik (tanh) mirip dengan fungsi sigmoid dalam menerima input berupa bilangan riil, yang membedakannya adalah output dari fungsi tanh dibatasi pada rentang antara -1 dan 1. Fungsi tangen hiperbolik dapat direpresentasikan oleh persamaan 2.2.

$$f(x)_{\tanh} = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (2.2)$$

- ReLU: *Rectified Linear Unit* adalah fungsi yang paling sering digunakan dalam CNN. Fungsi ini mengubah semua nilai input menjadi bilangan positif. Keuntungan utama ReLU dibandingkan dengan fungsi lainnya adalah beban komputasi yang lebih rendah. Secara matematis, ReLU direpresentasikan oleh persamaan 2.3.

$$f(x)_{ReLU} = \max(0, x) \quad (2.3)$$

- Leaky ReLU: Fungsi aktivasi leaky ReLU berbeda dengan ReLU standar yang mengabaikan input negatif, Leaky ReLU memperbolehkan adanya input negatif dengan mengalikannya dengan gradien kecil m . Ini bertujuan untuk mengatasi masalah "Dying ReLU" di mana neuron dapat terkunci pada nilai nol selama proses pelatihan. Representasi matematis dari fungsi Leaky ReLU dapat dilihat pada persamaan 2.4.

$$f(x)_{LeakyReLU} = \begin{cases} x, & \text{if } x > 0 \\ mx, & \text{if } x \leq 0 \end{cases} \quad (2.4)$$

4. Lapisan Terhubung Penuh

Fully Connected Layer (FC Layer) biasanya ditempatkan sebagai layer terakhir dalam arsitektur CNN dan berfungsi sebagai klasifikasi. FC beroperasi mirip dengan jaringan saraf maju konvensional, di mana setiap neuron menerima input dari semua output layer sebelumnya. Biasanya, input FC diperoleh dari layer pooling atau layer konvolusi terakhir dalam CNN. Proses ini melibatkan penyesuaian dimensi data dengan meratakan atau mengubah matriks output menjadi vektor satu dimensi, yang sering disebut sebagai proses "flattening". Hasil output dari FC Layer kemudian diinterpretasikan sebagai hasil klasifikasi akhir dari CNN (Purwono et al., 2022).


2.4 ConvNeXt

ConvNeXt merupakan salah satu arsitektur CNN. ConvNext dikembangkan dengan tujuan untuk untuk bersaing dengan arsitektur Vision Transformers dalam hal akurasi dan skalabilitas untuk berbagai tugas pengenalan visual. Model ini dirancang dengan mengadopsi beberapa strategi dari desain Vision Transformers, tetapi tetap mempertahankan kesederhanaan dan efisiensi dari CNN tradisional. ConvNeXt dirancang melalui proses yang sistematis dimana arsitektur ResNet standar diubah secara bertahap hingga mendekati desain Vision Transformer. Perubahan ini melibatkan beberapa komponen penting yang ditemukan membantu mengurangi kesenjangan performa antara ConvNet dan Vision Transformers. Beberapa perubahan kunci termasuk penggunaan konvolusi besar, pengaturan batch normalization ke layer normalization, dan penyesuaian dalam layer aktivasi, seperti penggantian ReLU dengan GELU.

Model ConvNeXt menunjukkan kinerja yang sangat baik dalam tugas-tugas klasifikasi, deteksi objek, dan segmentasi semantik, bahkan melampaui beberapa model Transformer dalam beberapa benchmark. Ini menegaskan bahwa arsitektur berbasis ConvNet masih sangat relevan dan efektif untuk tugas-tugas pengenalan visual meskipun popularitas yang meningkat dari model berbasis Transformer.

2.5 DenseNet

Dense Convolutional Network (DenseNet) adalah salah satu arsitektur CNN. Salah satu fitur utama dari DenseNet adalah *Dense Connectivity*. DenseNet menghubungkan setiap lapisan dengan semua lapisan lain dalam pola feed-forward. Tidak seperti arsitektur tradisional yang hanya memiliki koneksi dari satu lapisan ke lapisan berikutnya. DenseNet memiliki $\frac{L(L+1)}{2}$ untuk L lapisan. Contoh blok DenseNet dapat dilihat pada Gambar di bawah ini.




Gambar 2.6 Blok DenseNet (Huang, G., et al., 2018)

Setiap lapisan dalam blok ini mengambil semua peta fitur lapisan sebelumnya sebagai input. Setiap lapisan mendapat input dari output semua lapisan sebelumnya dalam blok yang sama. Outputnya digunakan sebagai input untuk semua lapisan berikutnya dalam arsitektur. Peta fitur dari semua lapisan sebelumnya digabungkan (concatenated) dan dijadikan masukan untuk lapisan saat ini. Lapisan H_i menerima semua output dari lapisan sebelumnya (dari x_0 sampai x_{i-1}) sebagai output.

2.6 VGG19

VGG19 adalah salah satu arsitektur CNN. VGG19 dirancang dengan 19 lapisan bobot. Lapisan tersebut terdiri dari 19 lapisan konvolusi dan 3 lapisan *fully connected layer*. Semua lapisan konvolusi menggunakan kernel dengan ukuran 3x3 dan stride 1 untuk mempertahankan resolusi gambar yang sama. Padding spatial ditambahkan untuk memastikan tidak ada informasi yang hilang di tepi gambar. *Max pooling* dilakukan melalui *window* 2x2 dengan stride 2, yang mengurangi dimensi spasial dari fitur yang diekstrak. Arsitektur ini menggunakan fungsi aktivasi *Rectified linear unit* (ReLU) untuk meningkatkan non-linearitas dan efisiensi waktu pemrosesan. Contoh blok VGG19 dapat dilihat pada Gambar di bawah ini.




Gambar 2.7 Blok VGG19

Pada penelitian ini, model VGG19 menggunakan lima blok konvolusi, dengan jumlah kernal yang meningkat dari 64 hingga 512. Peningkatan jumlah kernel ini bertujuan untuk menangkap ciri-ciri yang lebih kompleks dalam data seiring dengan semakin dalamnya jaringan memproses informasi. Tiap blok diakhiri dengan lapisan max-pooling yang mengurangi dimensi spasial peta ciri. Setelah kelima blok, sebuah lapisan global max pooling dikombinasikan dengan dua lapisan dense dan teknik dropout, diakhiri oleh lapisan output dengan empat unit untuk klasifikasi.

2.7 ResnetV2_50

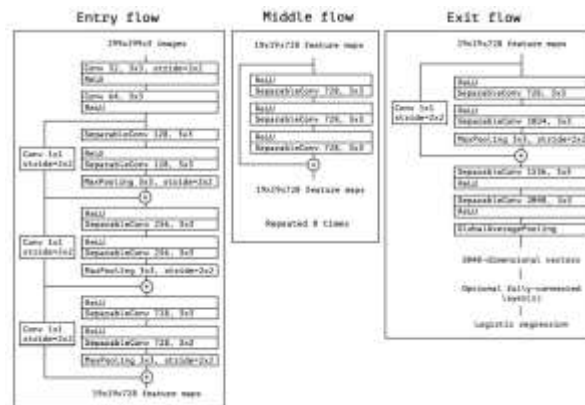
Residual Network (ResNet) adalah salah satu arsitektur dari CNN. Model ini memperkenalkan konsep *residual learning* dengan menambahkan *shortcut connections* yang melompati satu atau lebih lapisan konvolusi. ResNet-50 adalah salah satu varian dari ResNet yang terdiri dari 50 lapisan. Resnet50 memiliki 5 tahapan konvolusi utama. Setiap tahap konvolusi dalam ResNet terdiri dari beberapa blok residual. Setaip blok residual mengandung tiga lapisan konvolusi (1x1, 3x3, 1x1) yang sering disebut sebagai *bottleneck layer*. Contoh blok Resnet50 dapat dilihat pada Gambar di bawah ini.



Gambar 2.8 Blok Resnet50

2.8 Xception

Extreme Inception (Xception) adalah sebuah arsitektur CNN. Arsitektur ini merupakan pengembangan dari konsep Inception yang menggunakan konvolusi *separable depthwise*. konvolusi separable depthwise yang terdiri dari dua tahap: *depthwise convolution* (konvolusi spasial dilakukan secara independen pada setiap saluran) dan *pointwise convolution* (konvolusi 1x1 untuk menggabungkan hasilnya). Arsitektur ini memiliki 36 lapisan konvolusi yang disusun dalam 14 modul, dengan koneksi residual linier di sekitar semua modul kecuali modul pertama dan terakhir.



Gambar 2.9 Blok Xception

Gambar 3.7 menunjukkan arsitektur Xception. Data pertama kali melewati entry flow, kemudian melalui middle flow yang diulang sebanyak delapan kali, dan akhirnya melalui exit flow. Setiap lapisan konvolusi dan konvolusi separable diikuti oleh normalisasi batch. Semua lapisan konvolusi separable menggunakan depth multiplier sebesar 1, yang berarti tidak ada ekspansi kedalaman.

2.9 Model Stacking


Stacking merupakan strategi pembelajaran mesin yang menggabungkan prediksi dari dua atau lebih model pada level 0, disebut sebagai model pembelajar

dasar. Prediksi-prediksi ini kemudian dimasukkan ke dalam model pada level 1, biasanya disebut sebagai model meta untuk menghasilkan prediksi akhir. Dalam proses ini, berbagai model level 0 dilatih menggunakan kumpulan data pelatihan yang sama, kemudian hasilnya digunakan sebagai input dalam model level 1 (Brijesh Soni, 2023).

Pada level 0 dalam metode stacking, langkah pertama adalah mengalirkan data input ke sejumlah sub-model. Model stacking mempelajari sub-model ini secara bersamaan, yang menghasilkan pemetaan fitur-fitur ambigu antara data input. Proses ini merupakan bagian dari ekstraksi fitur yang dilakukan oleh model, di mana model berupaya untuk mengeksplorasi dan memahami karakteristik data yang kompleks. Setiap sub-model kemudian menghasilkan output berupa prediksi berdasarkan pemahaman mereka terhadap data input. Selanjutnya, hasil output dari setiap sub-model digabungkan menjadi fitur-fitur bertumpuk. Fitur-fitur ini merepresentasikan informasi yang beragam dan saling melengkapi dari setiap sub-model. Proses penggabungan ini meningkatkan kemampuan model untuk memahami berbagai aspek dari data yang mendasarinya. Fitur-fitur bertumpuk ini kemudian dijadikan sebagai input untuk level 1, yang dikenal sebagai meta-learner (Wong & Hasikin, 2023).

Pada tahap kedua, meta-learner belajar untuk memperbaiki prediksi yang dihasilkan oleh sub-model pada level sebelumnya. Meta-learner menggunakan fitur-fitur bertumpuk sebagai input, bersama dengan nilai ground truth yang merupakan nilai aktual dari target yang ingin diprediksi. Dengan memanfaatkan informasi dari prediksi sub-model sebelumnya dan nilai target sebenarnya, meta-learner mengoreksi atau menyesuaikan prediksi akhir. Tujuan akhir dari meta-learner adalah untuk menghasilkan prediksi yang lebih akurat dan konsisten.

Ilustrasi dari konsep stacking dapat ditemukan dalam Gambar 2.6. Dengan cara ini, ensemble bertumpuk (*stacking*) dapat menggunakan informasi dari berbagai model dasar untuk menghasilkan prediktor yang lebih tangguh dan efektif. Dibandingkan dengan menggunakan hanya satu model, pendekatan ensemble bertumpuk dapat menangkap keragaman informasi dan kompleksitas data dengan lebih baik, sehingga menghasilkan prediksi yang lebih akurat.



Gambar 2.10 Konsep model stacked (Wong et al., 2023)

2.10 Citra

Citra adalah representasi visual yang mengandung informasi dan dapat digunakan oleh semua orang sebagai sumber analisis, dengan hasil yang diinterpretasikan sesuai dengan tujuan yang diharapkan. Informasi dalam citra dapat dibagi menjadi dua jenis: informasi umum dan informasi abstrak. Informasi umum merupakan hasil pengolahan tanpa bantuan perangkat khusus, seperti warna, bentuk, dan tekstur. Sedangkan informasi abstrak merupakan hasil pengolahan dengan bantuan perangkat pengetahuan khusus, seperti ekspresi wajah yang mencerminkan perasaan seperti marah, senang, atau sedih, serta gambaran peristiwa atau situasi tertentu. Kedua jenis informasi tersebut dapat diolah menggunakan komputer, namun informasi abstrak memerlukan tambahan pengetahuan khusus.


Suatu citra, secara matematis, bisa dianggap sebagai fungsi dua dimensi $f(x, y)$, di mana x dan y adalah koordinat spasial dan f adalah nilai warna. Nilai-nilai ini bersifat terbatas atau berhingga. Citra yang ditampilkan di layar TV, monitor komputer, atau cetakan foto umumnya memiliki nilai yang kontinu dan bersifat analog. Namun, citra dengan nilai diskrit disimpan dalam bentuk citra digital, yang dapat disimpan dalam media penyimpanan seperti komputer atau CD-ROM. Citra digital biasanya berdimensi dua (2D), disajikan dalam bentuk matriks dengan elemen-elemen yang berhingga.

Pada citra digital dalam media komputer, elemen-elemen pada matriks direpresentasikan sebagai piksel. Piksel ini membentuk citra dua dimensi dalam bentuk baris dan kolom atau N dan M , seperti yang dijelaskan dalam rumus (2.5).

Piksel adalah elemen dasar dari citra digital, masing-masing merepresentasikan nilai intensitas warna di posisi x dan y . Untuk citra berwarna, nilai intensitas warna dikodekan menggunakan 24 bit dengan kombinasi komponen RGB (merah, hijau, biru), sedangkan citra keabuan menggunakan 8 bit dan citra biner menggunakan 1 bit.

$$F = [f(x, y)] = \begin{bmatrix} f(0,0) & f(0,1) & \dots & f(0,M) \\ f(N,0) & f(M,1) & \dots & f(N,M) \end{bmatrix} \quad (2.5)$$

Gambar 2.11a memberikan visualisasi representasi citra berwarna, di mana terdapat informasi warna umum pada kulit buah jeruk matang. Warna orange mewakili kulit buah jeruk, dengan buah jeruk yang memiliki bentuk bulat dan tekstur kulit yang keras. Gambar 2.11b mengilustrasikan representasi nilai-nilai elemen matriks citra (piksel) dengan tiga komponen warna dasar: merah (R), hijau (G), dan biru (B) pada kotak hitam yang ditandai dengan anak panah.



Gambar 2.11 (a) Representasi visual citra berwarna. (b) Representasi nilai nilai elemen matriks citra dengan tiga komponen warna dasar R, G dan B pada kotak hitam yang ditandai dengan anak panah (Madenda, 2015).

Representasi citra pada Gambar 2.11a diubah menjadi bentuk matriks 2D, dengan area piksel kotak hitam berukuran 5x5. Matriks piksel 5x5 ini memiliki nilai untuk pojok kiri atas, yaitu $f = (226, 94, 9)$, yang menunjukkan intensitas warna merah sebesar 226, intensitas warna hijau sebesar 94, dan intensitas warna biru sebesar 9.

2.11 Jenis Citra

Citra dapat diklasifikasikan berdasarkan karakteristik kontennya atau atribut visualnya menjadi citra berwarna, citra keabuan, dan citra biner.

2.11.1 Citra Berwarna

Secara visual, citra memiliki informasi warna yang direpresentasikan dalam bentuk piksel dengan komponen luminansi, *hue*, dan *chrominance* atau saturasi. Luminansi mengacu pada kecerahan warna yang dapat diatur untuk membuat warna menjadi lebih terang atau lebih gelap. Hue adalah sifat utama warna yang diukur dalam derajat (0° - 360°). Misalnya, merah memiliki nilai hue 0° atau 360° , hijau memiliki nilai hue 120° , kuning adalah kombinasi merah dan hijau dengan nilai hue 60° , dan seterusnya untuk warna lainnya. *chrominance* atau saturasi menjelaskan ukuran intensitas warna atau tingkat kejenuhan warna. Semakin tinggi nilai *chrominance*, semakin jenuh atau murni warna tersebut. Misalnya, warna biru memiliki saturasi 100%. Warna ini dihasilkan dari kombinasi tiga warna dasar: merah (R), hijau (G), dan biru (B).



**Gambar 2.12 Citra berwarna dengan ukuran 300 x 500 piksel
(Madenda, 2015).**

Dalam Gambar 2.12, terdapat sebuah citra berwarna dengan ukuran piksel 300 x 500, yang artinya memiliki 300 baris (N) dan 500 kolom (M). Secara matematis, fungsi matriks tiga dimensi $f(n, m, k)$ dapat merepresentasikan citra

berwarna. Dimana n adalah indeks untuk baris, m adalah indeks untuk kolom yang merepresentasikan posisi koordinat piksel, dan k adalah indeks yang menggambarkan komponen warna, seperti merah (R), hijau (G), dan biru (B). Dengan pendekatan ini, setiap elemen matriks dapat menggambarkan intensitas warna pada lokasi piksel tertentu dalam citra.

Ada beragam domain aplikasi yang dapat diterapkan dalam pemrosesan citra berwarna dengan menggunakan berbagai ruang warna. Selain ruang warna RGB yang umum digunakan untuk tampilan di layar monitor, terdapat pilihan ruang warna lain seperti CMYK, HSV, HIS, Lab, Luv, YCbCr, dan HCL. Misalnya, untuk dokumen yang akan dicetak menggunakan printer berwarna, biasanya menggunakan ruang warna CMYK. Dalam aplikasi kompresi citra, sering kali digunakan ruang warna YCbCr. Untuk proses segmentasi warna, beberapa ruang warna yang umum digunakan adalah HSV, HSL, Lab, dan HCL.

2.11.2 Citra Keabuan


Citra *gray-level*, juga dikenal sebagai citra skala keabuan, memiliki nilai piksel yang sesuai dengan nilai luminance menggunakan pengkodean 8 bit. Rentang nilai tersebut adalah dari 0 hingga 255 ($2^8 - 1$), di mana warna hitam direpresentasikan oleh nilai 0, dan warna putih oleh nilai 255. Nilai-nilai di antara keduanya menggambarkan variasi dari keabuan hingga kecerahan menuju putih. Transformasi dari ruang warna RGB ke ruang warna lainnya (HSV, HSL, Lab, YCbCr, atau HCL) dapat menghasilkan citra skala keabuan. Nilai komponen Y, V, atau L dari ruang warna tersebut menjelaskan citra skala keabuan. Sebagai contoh, citra skala keabuan dengan 256 tingkat kecerahan ditunjukkan dalam Gambar 2.9, yang merupakan hasil transformasi RGB seperti yang ditunjukkan dalam Gambar 2.8 menggunakan YCbCr.



**Gambar 2.13 Citra gray-level dengan ukuran 300 x 500 piksel
(Madenda, 2015).**

2.11.3 Citra Biner

Citra biner merupakan bagian dari citra keabuan yang hanya memiliki dua tingkat kecerahan, yaitu hitam dengan nilai 0 dan putih dengan nilai 1, di mana setiap piksel dikodekan menggunakan 1 bit. Penggunaan nilai ambang (*threshold*) diterapkan dalam proses pengolahan citra biner. Jika nilai piksel kurang dari nilai ambang, maka diubah menjadi 0 (hitam), sementara jika nilainya lebih besar dari ambang, diubah menjadi 1 (putih). Contoh citra biner dapat dilihat dalam Gambar 2.14, yang merupakan hasil dari citra keabuan seperti yang ditunjukkan dalam Gambar 2.9 dengan menggunakan nilai ambang 75.



**Gambar 2.14: Citra biner dengan ukuran 300 x 500 piksel
(Madenda, 2015).**

2.12 Aplikasi Pengolahan Citra

Citra, sebagai salah satu data multimedia yang sangat penting, telah digunakan secara luas dalam teknologi informasi. Perkembangan teknologi kamera foto dan video yang semakin canggih dan dengan harga yang relatif murah, telah membuat berbagai entitas seperti pemerintah, perusahaan, industri, rumah sakit, dan individu dapat menggunakan teknologi ini. Citra yang direkam memiliki berbagai tujuan sesuai dengan kebutuhan masing-masing pemiliknya, mulai dari penyimpanan, dokumentasi data, kebutuhan bisnis, kebutuhan ilmu pengetahuan, pembuatan album pribadi, dan lain-lain.

2.12.1 Citra Medis

Citra medis mengacu pada gambar-gambar yang dihasilkan melalui teknologi pencitraan medis, seperti Momografi, MRI (*Imaging Resonansi Magnetik*), CT (*Computed Tomography*), X-ray, dan lainnya. Tujuan utama dari citra medis adalah untuk membantu dalam diagnosis, pengobatan, dan pemantauan kondisi medis pasien. Ini dapat digunakan oleh para profesional kesehatan, seperti dokter, radiolog, dan ahli bedah, untuk memahami kondisi pasien dengan lebih baik. Citra medis juga menjadi penting dalam penelitian ilmiah dalam bidang kedokteran untuk mempelajari anatomi, fisiologi, dan perkembangan penyakit.

1. Momografi

Mamografi atau pencitraan payudara merupakan teknologi radiologi yang menggunakan sinar-X dosis rendah untuk menghasilkan gambar jaringan payudara. Mamografi digunakan sebagai alat skrining untuk deteksi dini kanker payudara pada wanita tanpa gejala, serta untuk mendiagnosis dan mengevaluasi penyakit payudara pada wanita dengan gejala seperti nyeri atau benjolan. Prosedur ini dapat mengidentifikasi dan mengklasifikasikan kista, fibroadenoma (benjolan jinak), dan kanker payudara. Setelah skrining mamografi yang tidak normal, dilakukan mamografi diagnostik untuk mengevaluasi lebih lanjut area yang menunjukkan kelainan. Penting untuk dicatat bahwa mamografi tidak digunakan untuk mencegah kanker, tetapi

untuk mendeteksinya secara dini sebelum penyebaran. Deteksi dini melalui mamografi dapat membantu mengurangi angka kematian akibat kanker payudara. Pengolahan citra digital dapat digunakan untuk secara otomatis menganalisis gambar mamografi dan mengidentifikasi area yang mencurigakan. Hal ini memfasilitasi pemantauan pertumbuhan dan penyebaran kanker oleh dokter.

2. *Magnetic Resonance Imaging (MRI)*


Magnetic Resonance Imaging (MRI) adalah alat diagnostik medis yang digunakan oleh dokter untuk mendiagnosis dan mengobati pasien. Alat ini menggunakan medan magnet dan komputer untuk membuat gambar rinci dari organ-organ dan struktur tubuh tanpa menggunakan radiasi ionisasi seperti sinar-X. Hasil pencitraan ini diproses menggunakan teknologi komputer dan disimpan dalam media penyimpanan seperti CD. Detail gambar yang dihasilkan oleh MRI dapat membantu dokter untuk melakukan evaluasi yang lebih teliti terhadap berbagai bagian tubuh. Teknologi MRI sangat berguna dalam menggambarkan dengan jelas struktur otak dan saraf kecil yang membentuk sumsum tulang belakang. Pengolahan citra digital pada citra MRI dapat digunakan untuk analisis otomatis dalam mendeteksi penyumbatan pembuluh darah, pendarahan otak, atau tumor otak, serta menentukan lokasi, ukuran, dan volume mereka. Hal ini membantu dokter dalam mengambil keputusan dan tindakan dengan cepat dan akurat.

3. Sinar-X

Sinar-X merupakan bentuk radiasi elektromagnetik, serupa dengan cahaya yang terlihat. Namun, berbeda dengan cahaya, sinar-X memiliki energi yang lebih tinggi dan dapat menembus sebagian besar benda, termasuk tubuh. Sinar-X medis digunakan untuk menghasilkan gambar jaringan dan struktur di dalam tubuh. Jika sinar-X yang melewati tubuh juga melewati detektor sinar-X di sisi lain pasien, maka akan terbentuk gambar yang mewakili "bayangan" yang terbentuk oleh objek di dalam tubuh. Salah satu jenis detektor sinar-X adalah film fotografi, tetapi ada banyak jenis detektor lain yang digunakan untuk menghasilkan gambar digital. Gambar sinar-X yang

dihasilkan dari proses ini disebut radiografi (Institute of Biomedical Imaging, 2022).

Pada radiografi, terdapat empat densitas yang berbeda, yaitu gas, lemak, air, dan mineral. Gas muncul sebagai warna hitam karena sedikit molekul yang menghalangi sinar-X. Lemak memiliki warna abu-abu gelap, sedangkan air merupakan sebagian besar dari volume tubuh yang terlihat pada radiografi. Jaringan air memiliki penampilan yang seragam dibandingkan dengan tiga densitas lainnya. Demikian pula, mineral seperti tulang atau benda asing seperti logam memiliki penampilan yang berbeda. Pengetahuan tentang empat densitas ini penting untuk interpretasi radiografi secara akurat (Hook).




Gambar 2.15 Panah kuning menunjukkan lemak di bantalan lemak jantung dan di fossa supraclavicular. Panah biru menunjukkan mineral dalam tulang-tulang rangka dan logam dari kabel EKG. Panah merah menunjukkan udara (gas) di paru-paru, yang ditandai dengan warna hitam. Panah hijau menunjukkan air dalam otot jantung (Hook).

2.13 Anatomi Paru

Paru-paru adalah organ vital dalam sistem pernapasan manusia. Paru-paru memiliki struktur yang elastis dan berpori, menyerupai spons atau karet busa. Di dalam paru-paru terdapat banyak alveoli, struktur kecil seperti kantong tempat terjadinya pertukaran gas antara udara dan darah. Fungsi utama paru-paru adalah untuk melakukan pertukaran gas, di mana oksigen dari udara yang dihirup diserap oleh alveoli dan dibawa ke seluruh tubuh melalui pembuluh darah, sementara

karbon dioksida yang dihasilkan oleh tubuh dibawa kembali ke alveoli dan dikeluarkan melalui pernapasan. Paru-paru terletak di rongga dada atau thoraks, terpisah dari rongga perut oleh diafragma. Ada dua paru-paru, kanan dan kiri, yang masing-masing berada di sisi kanan dan kiri rongga dada. Selain sebagai tempat pertukaran gas, paru-paru juga berfungsi sebagai pelindung, membantu menyaring udara dari partikel asing dan membuangnya dari tubuh melalui sistem pernapasan. Dengan peranannya yang kompleks, paru-paru memainkan peran penting dalam menjaga kesehatan dan keseimbangan gas dalam tubuh manusia (Yulia, 2020).



Gambar 2.16 Anatomi paru paru (Lampignano et al., 2018)

Gambar 2.16 menampilkan anatomi paru-paru dengan berbagai struktur yang disertakan dalam keterangan berikut:

- A. Apex paru: Bagian paling atas dari paru-paru.
- B. Lobus atas paru kanan: Bagian atas dari paru-paru kanan.
- C. Carina: Bagian terendah dari trakea, di mana terjadi percabangan ke bronkus utama.
- D. Bronchus utama paru kanan: Saluran udara utama yang masuk ke paru-paru kanan.
- E. Bronchus lobus atas paru kanan: Saluran udara yang bercabang menuju lobus atas paru kanan.
- F. Bronchus lobus tengah dan bawah paru kanan: Saluran udara yang menuju lobus tengah dan bawah paru kanan.
- G. Lobus bawah paru kanan: Bagian bawah dari paru-paru kanan.
- H. Dasar paru kanan: Bagian terbawah dari paru-paru kanan.

- I. Cardiophrenic sulcus (medial angle): Depresi pada sudut medial di antara paru-paru dan diafragma.
- J. Lobus tengah paru kanan: Bagian tengah dari paru-paru kanan.
- K. Cardiac notch: Bagian yang memanjang ke dalam dari pinggir kiri atas paru-paru kanan.
- L. Costophrenic sulcus (lateral angle): Depresi pada sudut lateral di antara paru-paru dan dinding dada.
- M. Lobus bawah paru kiri: Bagian bawah dari paru-paru kiri.
- N. Bronchus lobus bawah paru kiri: Saluran udara yang menuju lobus bawah paru kiri.
- O. Bronchus lobus atas paru kiri: Saluran udara yang menuju lobus atas paru kiri.
- P. Fissure: Pembatas antara lobus pada paru-paru.
- Q. Bronchus utama paru kiri: Saluran udara utama yang masuk ke paru-paru kiri.
- R. Hilum: Daerah di mana pembuluh darah dan saraf masuk dan keluar dari paru-paru.
- S. Lobus atas paru kiri: Bagian atas dari paru-paru kiri.
- T. Trachea: Saluran udara utama yang membawa udara dari tenggorokan ke paru-paru.

2.14 Virus Corona

Virus corona adalah sebuah kelompok virus yang memiliki potensi untuk menimbulkan berbagai penyakit pada manusia atau hewan. Beberapa jenis coronavirus telah diketahui sebagai penyebab infeksi pernapasan, mulai dari gejala ringan seperti flu hingga penyakit yang lebih serius seperti *Middle East Respiratory Syndrome* (MERS) dan *Severe Acute Respiratory Syndrome* (SARS). Salah satu varian terbaru dari virus corona, yang dikenal sebagai *Severe Acute Respiratory Syndrome Coronavirus 2* (SARS-CoV-2), telah menjadi penyebab utama penyakit Covid-19 yang menyebar secara luas di seluruh dunia. Meskipun sebagian besar kasus hanya menimbulkan gejala pernapasan ringan, seperti flu, namun beberapa

juga dapat mengakibatkan infeksi yang serius, termasuk pneumonia (Kemenkes RI, 2024)

2.14.1 Coronavirus Disease 2019 (COVID-19)

Pandemi penyakit coronavirus 2019 (Covid-19) dimulai dengan laporan mengenai jenis pneumonia yang tidak diketahui penyebabnya pada individu di pasar hewan dan makanan laut Haunan, Wuhan, Provinsi Hubei, Tiongkok, pada 31 Desember 2019 (Wu, Zhao, Yu3, Chen, Wang & Song, 2020). Pada awalnya organisasi kesehatan dunia (WHO) memberi nama virus ini dengan sebutan 2019 novel coronavirus (2019-nCoV), kemudian pada 12 Februari 2020 WHO secara resmi mengubahnya menjadi penyakit Coronavirus Disease 2019 (Covid-19), disebabkan oleh virus yang dikenal sebagai Severe Acute Respiratory Syndrome Coronavirus 2 (SARS-CoV-2) (WHO, 2024).

Covid-19 adalah penyakit menular yang dapat mempengaruhi berbagai kelompok usia. Mayoritas individu yang terinfeksi akan mengalami gejala ringan hingga sedang dan akan sembuh tanpa perlu perawatan khusus. Namun, individu dengan kondisi medis yang sudah ada sebelumnya, seperti penyakit jantung, diabetes, gangguan pernapasan kronis, serta lansia, berisiko mengalami gejala yang lebih parah (WHO, 2024). Infeksi Covid-19 bisa dimulai dari gejala ringan seperti masalah pernapasan di hidung dan tenggorokan hingga kondisi serius di paru-paru yang bisa menyebabkan kesulitan bernapas karena alveoli, atau kantong udara di paru-paru terinfeksi. Covid-19 juga bisa berdampak buruk pada jantung dan pembuluh darah, meningkatkan risiko pembekuan darah yang bisa berujung pada 3 masalah serius seperti stroke atau gagal jantung, terutama pada orang tua atau mereka dengan kondisi kesehatan tertentu seperti diabetes. Sekitar 1 dari 5 orang dengan Covid-19 mengalami masalah seperti mual dan diare karena virus mempengaruhi sistem pencernaan. Covid-19 tidak hanya masalah bagi paru-paru, virus ini bisa mempengaruhi hampir setiap bagian dari tubuh dan menyebabkan berbagai masalah kesehatan.

Penularan virus terjadi melalui droplet pernapasan yang dikeluarkan saat seseorang batuk, bersin, atau berbicara. Partikel-partikel ini dapat mengandung

virus dan menular ke orang lain melalui kontak dengan mulut, hidung, atau mata. Covid-19 menyebar dari wuhan ke sebagian besar provinsi di Tiongkok hanya dalam waktu 30 hari (Ozturk et al., 2020). Pada bulan Januari 2020, Covid-19 sudah mulai menyebar dan menginfeksi jutaan penduduk di 213 negara, termasuk Indonesia. Kasus pertama Covid-19 di Indonesia terjadi pada tanggal 02 Maret 2020, dengan 2 penderita terinfeksi yang berdomisili di Depok (Sumber: <https://Indonesia.Go.Id/>, 2024). Penyebaran wabah yang terjadi secara global di seluruh dunia semakin meningkat sehingga WHO menetapkan Covid-19 sebagai pandemi global pada 11 Maret 2020 (WHO, 2020). Berdasarkan Laporan Epidemiologis Covid-19 edisi ke-163, disajikan ulasan tentang kondisi pandemi global Covid-19 mulai dari 11 Desember 2023 sampai dengan 7 Januari 2024. Selama periode 28 hari tersebut, tercatat lebih dari 1,1 juta kasus baru di seluruh dunia setiap minggunya. Hingga kini, tercatat total 703,880,443 kasus Covid-19 di seluruh dunia, dengan 674,003,213 berhasil sembuh dan 7,003,629 kasus menyebabkan kematian (COVID - Coronavirus Statistics - Worldometer, 2024).

Derajat Penyakit Covid-19

Menurut tingkat keparahannya, Covid-19 dapat diklasifikasikan menjadi beberapa jenis, yaitu tanpa gejala, gejala ringan, sedang, berat, dan kritis (Burhan et al., n.d.).

1. Tanpa gejala: kondisi paling ringan dari Covid-19 dimana pasien tidak menunjukkan gejala apapun.
2. Ringan: gejala pada pasien dalam kategori ringan meliputi demam, batuk, kelelahan, kehilangan nafsu makan, sesak nafas, dan nyeri otot. Pada pasien yang lanjut usia atau dengan sistem kekebalan tubuh yang lemah, gejala atipikal seperti kelelahan berlebihan, penurunan kesadaran, mobilitas menurun, diare, hilangnya nafsu makan, delirium, dan tidak adanya demam juga dapat terjadi.
3. Sedang atau Moderat: pada pasien remaja atau dewasa, dapat terjadi tanda klinis pneumonia ringan tanpa tanda-tanda pneumonia berat seperti tingkat oksigen dalam darah (SpO₂) di atas 93%. Sedangkan pada anak-anak, gejala klinis pneumonia yang terjadi tidak termasuk dalam kategori berat.

4. Berat: kategori sedang/moderat terjadi ketika pasien menunjukkan tanda klinis pneumonia seperti demam, batuk, sesak napas, dan napas cepat. Selain itu, satu dari tiga kondisi berikut juga dapat terjadi: frekuensi napas lebih dari 30 kali per menit, mengalami distress pernapasan berat, atau tingkat oksigen dalam darah (SpO₂) kurang dari 93% dengan menghirup udara ruangan.
5. Kritis: kategori kritis pada pasien terjadi ketika mereka mengalami Sindrom Distres Pernapasan Akut (ARDS), sepsis, atau syok sepsis.

Penunjang Diagnostik

Penunjang diagnostik COVID-19 meliputi berbagai jenis tes dan pemeriksaan yang digunakan untuk membantu dalam diagnosis infeksi virus.


1. Teknik Laboratorium

Teknik laboratorium untuk mendeteksi Covid-19 yang paling umum dengan menggunakan metode *Reverse Transcription Polymerase Chain Reaction* (RT-PCR), *Rapid Antigen Testing* (RAT), atau tes antibodi (Munne et al., 2021). RT-PCR menggunakan spesimen pernapasan yang diperoleh dari tubuh pasien seperti swab nasofaring, orofaring, sputum atau cairan bilas bronkial. Metode ini dianggap sebagai standar dalam mendiagnosis Covid-19. Metode ini memiliki keterbatasan karena membutuhkan laboratorium khusus dengan fasilitas BSL-2, waktu pengerjaan 2 sampai 3 jam, peralatan dan biaya yang mahal, pengerjaan yang kompleks membutuhkan tenaga laboratorium ahli untuk melakukan pengambilan dan pengujian sampel serta tingginya resiko paparan terhadap tenaga medis (Rakhmina et al., 2022).

Rapid test antigen dan antibodi lebih mudah dilakukan karena tidak membutuhkan tempat dan peralatan khusus. Salah satu kelemahan dari rapid test adalah adanya kemungkinan reaktivitas silang (*cross-reactivity*) dengan jenis virus corona lainnya. Hal ini berarti rapid test dapat memberikan hasil positif palsu jika antibodi yang dihasilkan oleh tubuh merespons infeksi dari virus corona lain yang tidak terkait dengan SARS-CoV-2, seperti coronavirus yang menyebabkan flu biasa (Kesehatan Manarang et al., n.d.).

2. Pemeriksaan Radiologi

Pemeriksaan radiologis berperan penting dalam mendeteksi dan menangani pasien yang terinfeksi Covid-19. Secara klinis, infeksi virus corona pada sistem pernapasan sering kali muncul sebagai pneumonia atipikal atau organizing pneumonia dalam temuan citra medis. Meskipun foto rontgen dada kurang sensitif daripada CT scan, tetapi karena ketersediaannya, foto rontgen dada sering digunakan sebagai pendekatan pertama dalam diagnosis. Pada tahap awal penyakit, gambaran pada foto rontgen dada mungkin normal, namun akan mencapai puncaknya dalam 10-12 hari setelah munculnya gejala.



Gambar 2.17 menunjukkan tiga perubahan utama pada radiografi dada (baris atas) dan temuan yang sesuai pada CT dada (baris bawah). Di sebelah kiri, terdapat perubahan retikular difus (panah). Pada CT yang sesuai, terlihat peningkatan difus pada densitas paru-paru dan pembentukan septum interlobular yang tebal (panah). Di tengah, terlihat *ground-glass opacities* (panah). Di sebelah kanan, terdapat konsolidasi ekstensif (panah). Pada CT yang sesuai, terlihat perubahan konsolidatif yang dominan (panah). (Vancheri, Savietto, Ballati & Maggi, 2020.)

Perubahan pada foto rontgen dada (CXR) pada gambar 2.17 didefinisikan sebagai berikut:

- Perubahan retikuler, menggambarkan kumpulan opasitas linier kecil yang tak terhitung jumlahnya, yang ketika digabungkan, membentuk tampilan seperti jaring.
- Konsolidasi, menggambarkan peningkatan homogen pada atenuasi jaringan paru-paru, menyebabkan kaburnya batas-batas pembuluh darah dan dinding saluran udara.
- *ground-glass opacities* (GGO), merujuk pada area opasitas yang kabur pada paru-paru, biasanya bersifat ekstensif, di dalamnya batas-batas pembuluh darah paru-paru mungkin tidak terlihat jelas.

Distribusi perubahan dapat diklasifikasikan sebagai unilateral (hanya di satu sisi) atau bilateral (di kedua sisi).

2.15 Kajian Penelitian

Beberapa penelitian terkait klasifikasi dan deteksi anomali penyakit paru akibat infeksi COVID-19 telah dilakukan peneliti terdahulu. Kajian penelitian klasifikasi dan deteksi anomali penyakit paru akibat infeksi COVID-19 dengan objek citra sinar-x dijelaskan berikut.


(Nour, Comert & Polat, 2020) *A Novel Medical Diagnosis model for COVID-19 Infection Detection Based on Deep Features and Bayesian Optimization*

Pengembangan model diagnosis infeksi COVID-19 menggunakan pendekatan *Convolutional Neural Network* (CNN) dan pembelajaran mesin dilakukan oleh (Nour et al., 2020). Peneliti mengusulkan arsitektur CNN yang dilatih dari awal, tidak menggunakan transfer learning. Model yang diusulkan terdiri dari 5 blok dasar, dimana setiap blok terdiri dari lapisan konvolusi, ReLU, normalisasi dan *pooling*. Pada akhir model terdapat tiga lapisan terhubung penuh (*fully connected layers*) dan sebuah lapisan *softmax*. Penelitian ini menggunakan dataset publik yang berasal dari beberapa sumber, data yang digunakan berisi 2905 citra sinar-X dada *posterior-anterior* (PA) dengan 3 kelas (COVID-19 dengan 153 citra, Normal dengan 936 citra dan pneumonia viral 941 citra). Data dibagi menjadi data latih dan data uji dengan persentase 70% data uji dan 30% data latih. Sampel

pada kelas COVID-19 terlalu sedikit jika dibandingkan dengan dua kelas lainnya sehingga dilakukan augmentasi data *rotate* dan *flip* pada kelas COVID-19 untuk meningkatkan jumlah data. Setelah model CNN selesai dilatih, dilakukan ekstraksi fitur dari lapisan *fully-connected* (fc) pada arsitektur CNN. Ada 2 lapisan fc yang diekstraksi yaitu fc1 dan fc2. Fitur-fitur ini kemudian digunakan sebagai input untuk algoritma pembelajaran mesin, yaitu KNN, SVM, dan *Decision Tree*. *Hyperparameter* model pembelajaran mesin dioptimalkan menggunakan algoritma optimasi bayesian. Hasil terbaik diperoleh dari penggunaan algoritma SVM yang memiliki akurasi sebesar 98,97%, sensitivitas 89,39%, spesifisitas 99,75%, dan F-score 95,75%.

(Ozturk, Talo & Yildirim, 2020) *Automated Detection of COVID-19 Cases Using Deep Neural Networks with X-ray Images*

Penelitian dalam mengembangkan model deep learning untuk mendeteksi dan mengklasifikasikan COVID-19 secara otomatis menggunakan citra sinar-x dada dilakukan peneliti (Ozturk et al., 2020). Model yang diusulkan diberi nama DarkCovidNet, arsitektur Darknet-19 digunakan sebagai dasar dari pengembangan model ini. Dalam model yang diusulkan, terdapat 17 lapisan konvolusi. Pada setiap lapisan DarkNet, terdapat satu lapisan konvolusional yang diikuti oleh operasi BatchNorm dan LeakyReLU, setiap tiga lapisan konvolusi memiliki konfigurasi yang sama dan diulang dalam bentuk yang berurutan, model ini diakhiri dengan lapisan *Avgpool* dan *Softmax*. Model yang diusulkan sepenuhnya otomatis berdasarkan struktur *end to end*. Data yang digunakan adalah citra sinar-x dada mentah tanpa proses ekstraksi fitur apapun sejumlah 125 kasus covid-19, 500 kasus pneumonia, dan 500 kasus normal, dari keseluruhan data 80% digunakan sebagai data latih dan 20% sebagai data validasi. Model dievaluasi menggunakan *5-fold cross validation*. Hasil dari penelitian ini menunjukkan model memperoleh akurasi 98,08%, sensitivitas 95,13%, spesifisitas 95,30%, dan F1-score 96,51% untuk deteksi biner COVID-19. Sementara untuk klasifikasi 3 kelas, model memperoleh akurasi 87,02%. Hasil diagnosis model juga dievaluasi oleh radiolog untuk memastikan kinerja yang baik.



Gambar 2.18 Arsitektur model yang diusulkan (Ozturk et al., 2020).

(Mahmud, Rahman & Fattah, 2020) CovXNet: A multi-dilation convolutional neural network for automatic COVID-19 and other pneumonia detection from chest X-ray images with transferable multi-receptive feature optimization

Penelitian ini menggunakan arsitektur CNN yang disebut CovXNet. Arsitektur ini memanfaatkan konvolusi depthwise dengan berbagai tingkat dilasi untuk mengekstraksi fitur dari citra sinar-X paru. CovXNet menggabungkan konvolusi depthwise dengan dilasi variabel untuk menangkap fitur lokal dan global dari citra sinar-X. Selain itu, algoritma stacking digunakan untuk menggabungkan prediksi dari berbagai model CovXNet yang dilatih pada resolusi berbeda menggunakan meta-learner. Algoritma ini juga mengintegrasikan metode lokalisasi diskriminatif berbasis gradien untuk menyoroti area abnormal pada citra sinar-X paru. CovXNet menunjukkan performa yang baik dengan akurasi deteksi sebesar 97,4% untuk klasifikasi COVID/Normal, 96,9% untuk COVID/Pneumonia viral, 94,7% untuk COVID/Pneumonia bakteri, dan 90,2% untuk klasifikasi multikelas (COVID/Normal/Viral/Bakteri).

(V. Sreejith and Thomas George, 2021) Detection of COVID-19 from Chest X-rays Using Resnet-50

Penelitian ini menggunakan *transfer learning* dengan model ResNet-50 untuk mendeteksi COVID-19 dari gambar X-ray dada. Penelitian ini menggunakan dataset sinar-X paru COVID-19 yang tersedia secara publik. Dataset yang digunakan terdiri dari 1000 gambar. Dataset melalui tahap preprocessing dengan mengubah ukurannya menjadi 100x100 piksel dan menerapkan teknik augmentasi data seperti rotasi, zoom, dan cropping untuk meningkatkan kompleksitas. Dataset

tersebut dibagi menjadi 80% untuk pelatihan dan 20% untuk pengujian. Model ResNet-50 yang telah dilatih sebelumnya pada dataset ImageNet, dilakukan *fine tuned*. Lapisan awal model dibekukan untuk mempertahankan bobot yang telah dilatih sebelumnya, sementara lapisan terakhir dilatih untuk mengekstraksi fitur spesifik dari dataset. Penelitian ini menggunakan pelatihan mixed precision untuk mengurangi kebutuhan memori dan mempercepat proses pelatihan.

Hasil penelitian menunjukkan bahwa model ResNet-50 mencapai akurasi tinggi sebesar 96% pada data uji. Hasil dari *Confusion matrix* menunjukkan sedikit kesalahan klasifikasi, dengan 5 kasus non-COVID yang salah diprediksi sebagai COVID dan 2 kasus COVID yang salah diprediksi sebagai non-COVID.

(Teixeira, Pereira & Bertolini, 2021) *Impact of Lung Segmentation on the Diagnosis and Explanation of COVID-19 in Chest X-ray Images*

Penelitian yang dilakukan oleh (Teixeira et al., 2021) bertujuan untuk mengevaluasi dampak segmentasi paru-paru terhadap identifikasi pneumonia termasuk yang disebabkan oleh COVID-19 menggunakan citra sinar-x dada. Dataset yang digunakan terdiri dari 2678 citra sinar-x dada dengan 3 kelas target yaitu penyakit paru-paru, COVID-19, dan paru-paru normal. Penelitian dilakukan dengan membagi menjadi 3 tahap, pertama menerapkan segmentasi semantik paru-paru menggunakan pendekatan CNN dengan arsitektur U-Net. Tahap kedua adalah melakukan klasifikasi menggunakan 3 model CNN yaitu VGG16, ResNet50V2, dan InceptionV3 baik pada citra sinar-x dada utuh maupun citra hasil segmentasi paru-paru. Tahap terakhir dari penelitian ini dengan menerapkan Teknik *Explainable AI* berupa LIME dan Grad-CAM untuk menjelaskan prediksi yang dibuat oleh model klasifikasi. Hasil dari penelitian ini menunjukkan klasifikasi menggunakan gambar paru-paru yang tersegmentasi mencapai Skor F1 sebesar 0,88 untuk klasifikasi multi kelas dan 0,83 untuk identifikasi COVID-19. Dengan menggunakan gambar sinar-x dada yang tidak tersegmentasi, klasifikasi tersebut mencapai Skor F1 yang lebih tinggi masing-masing sebesar 0,92 dan 0,94. Generalisasi COVID-19, yaitu menggunakan gambar COVID-19 dari satu sumber

diagnosis yang tinggi mulai dari 89,2% hingga 98,66%. Model LBP-KNN unggul dibanding model lainnya dengan akurasi rata-rata 98,66%, sensitivitas 97,76%, spesifisitas 100%, presisi 100%, tingkat kesalahan 1,34%, dan false positif nol.

(Kong & Cheng, 2022). *Classification and detection of COVID-19 X-Ray images based on DenseNet and VGG16 feature fusion.*

Penelitian ini mengembangkan metode klasifikasi citra X-ray dada berbasis *feature fusion* dari arsitektur DenseNet dan VGG16. Metode yang digunakan meliputi tahap segmentasi menggunakan Resnet34 dan menerapkan *Global Attention Machine Block* (GAB) dan *Category Attention Block* (CAB). Segmentasi diterapkan untuk menghapus informasi latar belakang yang tidak relevan, hanya mempertahankan area bayangan dada yang relevan. GAB dan CAB diterapkan untuk mengatasi masalah *imbalance* dataset. DenseNet dan VGG16 digunakan secara terpisah untuk mengekstraksi fitur-fitur dari gambar X-ray dada. Fitur-fitur yang telah diekstraksi oleh kedua model kemudian digabungkan menggunakan teknik *feature fusion*. Penggabungan ini dapat dilakukan dengan menggabungkan vektor-vektor fitur dari kedua model. Fitur-fitur yang telah digabungkan ini kemudian digunakan untuk melakukan klasifikasi menggunakan lapisan fully connected dan lapisan softmax untuk menghasilkan prediksi akhir.

Penelitian ini menggunakan dua dataset yang tersedia secara publik. Dataset yang digunakan adalah Chest X-ray Images (Pneumonia) dan COVID-19 X-ray Image Database. Model yang dibuat menunjukkan hasil yang sangat baik dengan akurasi rata-rata 98,0% untuk klasifikasi biner (sehat dan pneumonia) dan 97,3% untuk klasifikasi tiga kategori (sehat, pneumonia umum, dan COVID-19).

(Basha, Neto & Alshathri, 2022) *Multithreshold Segmentation and Machine Learning Based Approach to Differentiate COVID-19 from Viral Pneumonia*

Segmentasi berbasis ambang batas (*threshold*) pada citra sinar-x dilakukan peneliti (Mahaboob Basha et al., 2022). Metode yang digunakan meliputi tahap pra-pemrosesan citra dengan filter median untuk mengurangi noise pada citra sinar-x dada, segmentasi otsu berbasis *multi threshold* untuk menghasilkan beberapa

masker biner, masker dengan intensitas rata-rata tertinggi akan dipilih, dan ekstraksi fitur berbasis statistik, wavelet, serta fitur tekstur *Laws texture energy*. Fitur yang diekstrak kemudian dipilih menggunakan *Random Forest* untuk memilih fitur yang paling informatif. Klasifikasi untuk membedakan antara COVID-19 dan pneumonia viral menggunakan SVM dan *Random Forest*. Hasil penelitian menunjukkan fitur intensitas dan wavelet mampu membedakan kedua patologi dengan baik. Model *Random Forest* menghasilkan performa terbaik dengan AUC 0.97 dan akurasi 0.9.

(Rajkumar, Himanshu & Marimuthu, 2023) *AI-based Wavelet and Stacked Deep Learning Architecture for COVID-19 Detection from Chest X-ray Images*


Penelitian (Rajkumar, Himanshu & Marimuthu, 2023) mengusulkan arsitektur yang disebut WavStaCovNet-19 untuk mendiagnosis COVID-19 menggunakan citra sinar-X paru. Penelitian ini menggunakan dua dataset yang tersedia secara publik: COVID-19 Image Data Collection Repository dan Chest X-ray Images (Pneumonia) Dataset. Dataset terdiri dari 5475 gambar sinar-X paru yang meliputi COVID-19, pneumonia viral, pneumonia bakteri, dan normal. Dataset tersebut dibagi menjadi subset pelatihan dan pengujian. Proses preprocessing dalam penelitian ini menggunakan teknik augmentasi data seperti rotasi, zoom, dan cropping. Citra dalam dataset diproses menggunakan transformasi *wavelet Daubechies* (DWT) dan diubah ukurannya menjadi 224x224 piksel.

Metode yang digunakan dalam penelitian ini menggunakan kombinasi transformasi wavelet dengan *stacked ensemble* dari empat model *deep learning*: ResNet50, VGG19, Xception, dan DarkNet19. Setiap model dilatih secara terpisah untuk mengekstraksi fitur unik dari citra Sinar-X. Vektor fitur yang dihasilkan dari setiap model kemudian digabungkan menjadi satu vektor fitur gabungan dan digunakan untuk melatih pengklasifikasi softmax. *Transfer learning* digunakan dengan memanfaatkan *pretrained* model dan dilakukan *fine tuned* untuk menyesuaikan dengan dataset yang digunakan. *Optimizer Adam* dan fungsi aktivasi *leaky ReLU* digunakan selama pelatihan untuk memperbaiki performa model.

Model WavStaCovNet-19 berhasil mencapai akurasi 96,10% dalam mendeteksi COVID-19 dari citra Sinar-X paru.

(Al-Zyoud, Erekat & SaraijI, 2023) *COVID-19 Chest X-ray Image Analysis by Threshold-based Segmentation*

Penelitian dalam melakukan segmentasi biner pada citra sinar-x dilakukan peneliti (Al-Zyoud et al., 2023). Penelitian ini menggunakan citra sinar-x dada *posterior-anterior* (PA) sebanyak 27 pasien terinfeksi COVID-19 dan 19 individu sehat yang diambil secara acak dari *Kaggle COVID-19 Radiography Database*. Citra kemudian diproses dengan teknik segmentasi ambang batas (*threshold*) untuk membuat citra menjadi biner hitam putih. Selanjutnya citra dibagi menjadi 4 kuadran yaitu kuadran atas kanan, atas kiri, bawah kanan dan bawah kiri. Rasio piksel putih terhadap piksel hitam dihitung untuk masing-masing kuadran untuk merepresentasikan beban viral COVID-19 pada paru-paru. Hasil penelitian menunjukkan bahwa pasien COVID-19 memiliki persentase atenuasi yang lebih tinggi secara signifikan pada kuadran bawah paru-paru dibandingkan individu sehat ($p\text{-value} < 0.00001$). Hal ini disebabkan oleh *ground glass opacity* (GGO) dan konsolidasi akibat infeksi virus. Penelitian ini juga menemukan bahwa kuadran bawah kiri memiliki jumlah piksel putih tertinggi meskipun tidak berbeda signifikan dengan kuadran bawah kanan ($p\text{-value} = 0.102792$).



Gambar 2.20 Skema Segmentasi Citra Sinar-X (Al-Zyoud et al., 2023).

(Goyal & Singh, 2023) *Detection and Classification of Lung Diseases for Pneumonia and Covid-19 Using Machine and Deep Learning Techniques*

Penelitian dalam prediksi penyakit paru-paru seperti pneumonia dan Covid-19 dari citra sinar-x menggunakan *machine* dan *deep learning* dilakukan peneliti (Goyal & Singh, 2023). Penelitian ini mengusulkan sebuah kerangka kerja yang terdiri dari beberapa langkah yaitu, akuisisi dataset, peningkatan kualitas citra, ekstraksi *region of interest* (ROI), ekstraksi fitur, normalisasi fitur, klasifikasi menggunakan metode *soft computing* dan analisis tingkat keparahan penyakit. Teknik peningkatan kualitas citra menggunakan penyesuaian nilai intensitas secara adaptif, pemfilteran median, dan pemerataan histogram. melalui proses tersebut citra sinar-X berkualitas rendah berhasil ditingkatkan dengan mempertahankan bagian tepinya dan menghilangkan bagian yang bising. Ekstraksi ROI dilakukan menggunakan segmentasi citra yang mendeteksi batas batas di sekitar citra.

Metode segmentasi yang dilakukan berdasarkan operasi morfologi erosi dan *closing*. Gambar ROI yang sudah diekstraksi selanjutnya digunakan untuk proses ekstraksi fitur. Fitur visual diekstraksi dengan deskriptor HOG, fitur tekstur diekstraksi dengan *Gray level co-occurrence matrix* (GLCM), fitur intensitas, dan fitur invarian momen geometris diekstraksi menggunakan ROI. Dari masing-masing citra ROI, diperoleh total 36 fitur yang diekstraksi yang terdiri dari 4 fitur HOG, 8 fitur Intensitas, 8 fitur momen geometris, dan 16 fitur tekstur. Setelah mendapatkan berbagai fitur yang telah diekstraksi dilakukan normalisasi *min-max* untuk membatasi fitur dalam rentang 0–1. Algoritma pembelajaran mesin ANN, SVM, KNN, dan Ensemble digunakan untuk melakukan deteksi dan klasifikasi. Algoritma deep learning yang digunakan adalah RNN dengan arsitektur LSTM (RNN-LSTM) digunakan untuk deteksi otomatis dan peningkatan akurasi penyakit paru-paru. Hasil dari penelitian ini menunjukkan metode yang diusulkan mampu meningkatkan akurasi deteksi 2-3% dan mengurangi waktu komputasi hingga 50% dibandingkan metode yang sudah ada.

(Tenali & Babu, 2023) *HQDCNet: Hybrid Quantum Dilated Convolution Neural Network for Detecting Covid-19 in the Context of Big Data Analytics*

Metode baru untuk mengidentifikasi data COVID-19 multi kelas dalam jumlah yang besar yang disebut HQDCNet (*Hybrid Quantum Dilated Convolution*

Neural Network) diusulkan oleh peneliti (Tenali & Babu, 2023). Metode yang diusulkan memanfaatkan *framework distributed computing server* berbasis Hadoop untuk mengelola dan memproses citra sinar-X dada dalam jumlah yang besar. Citra-citra tersebut kemudian disegmentasi dengan menggunakan algoritma *fuzzy empowered weighted k-means* untuk mengelompokkan bagian-bagian yang dominan dalam citra. Arsitektur yang diusulkan terdiri dari 4 lapisan utama: lapisan input, lapisan HDFS, lapisan *distributed computing server*, dan lapisan output. Pada lapisan input, citra sinar-x dada dimasukkan ke dalam sistem. Kemudian pada lapisan HDFS, citra-citra tersebut disimpan terdistribusi dengan blok berukuran tetap. Selanjutnya, beban pemrosesan didistribusikan di lapisan *distributed computing server*. Lapisan *output* berisi hasil klasifikasi covid-19. Metode yang diusulkan menunjukkan akurasi deteksi COVID-19 sebesar 99,01%, melebihi beberapa metode yang ada sebelumnya.

(Basha, Albuquerque & Chelloug, 2024) *Robust Machine Learning Technique to Classify COVID-19 Using Fusion of Texture and Vesselness of X-Ray Images*

Sebuah teknik pembelajaran mesin untuk mengklasifikasikan COVID-19 menggunakan fusion atau penggabungan fitur tekstur dan vesselness dari citra sinar-x dada dilakukan peneliti (Basha et al., 2024). Metode yang diusulkan diawali dengan mengumpulkan citra sinar-x dada normal dan berbagai patologi lain seperti COVID-19, *lung opacity*, dan viral pneumonia. Citra-citra ini kemudian melalui tahap pra-pemrosesan dengan konversi ke *grayscale* dan filter median. Selanjutnya dilakukan segmentasi multi ambang batas (*multi-threshold*) menggunakan metode Otsu untuk mendapatkan *region of interest* (ROI).

Fitur yang diekstraksi dari ROI adalah fitur tekstur menggunakan *Gray Level Co-occurrence Matrix* (GLCM) dan fitur *vesselness* menggunakan filter Frangi, Sato, dan Meijering. Kedua jenis fitur tersebut kemudian digabungkan melalui proses difusi untuk menciptakan representasi fitur yang lebih lengkap dan informatif. Algoritma pembelajaran mesin *Decision Tree* (DT) dan *Random Forest* (RF) digunakan untuk mengklasifikasikan gambar sinar-X dada ke dalam empat kategori yaitu, infeksi paru-paru umum, opasitas paru-paru, COVID-19, dan

pneumonia virus. Pendekatan ini memanfaatkan fitur yang diekstrak berdasarkan analisis tekstur dan *vesselness* dari gambar sinar-X untuk membedakan kondisi tersebut secara akurat. Hasil penelitian menunjukkan bahwa klasifikasi berbasis RF mencapai akurasi sekitar 91.8% untuk klasifikasi 4 kelas (normal, COVID-19, *lung opacity*, viral pneumonia) dan 90% untuk 3 kelas (tanpa normal). Efektivitas penggabungan fitur tekstur dan *vesselness* untuk diagnosis COVID-19 dapat dilihat dari peningkatan signifikan dalam membedakan COVID-19 dari opasitas paru-paru melalui analisis histogram, mencapai tingkat positif benar sebesar 97%.

Penelitian yang sudah dilakukan peneliti terdahulu terangkum dalam Tabel 2.1 dibawah ini.

Tabel 2.1. Ringkasan Kajian Penelitian

Peneliti, Tahun	Subjek Penelitian	Metode Penelitian	Kelebihan	Kekurangan
Nour M, Comert Z, Polat K, 2020	Pengembangan Model	<i>Convolutional Neural Network (CNN)</i> <i>Machine learning (SVM, Decision Tree, KNN).</i> <i>Bayesian Optimization</i>	- Melatih model CNN dari awal - Menggunakan pendekatan end to end - Akurasi model sebesar 98,97%	- Dataset yang tersedia belum diberi label oleh ahli - Mengandalkan arsitektur model untuk mempelajari fitur fitur yang relevan langsung dari data mentah - Belum melakukan evaluasi klinis
Ozturk T, Talo M, Yildirim E, 2020		<i>DarkCovidNet</i>	- Membuat arsitektur yang disebut dengan DarkCovidNet, model yang diusulkan memiliki jumlah layer yang lebih sedikit dibanding dengan arsitektur	- Data yang tidak seimbang membuat penurunan nilai loss yang signifikan pada awal pelatihan. -Model

Peneliti, Tahun	Subjek Penelitian	Metode Penelitian	Kelebihan	Kekurangan
			<p>darknet original.</p> <ul style="list-style-type: none"> - Akurasi untuk 2 kelas 98,08% - Akurasi 87,02% untuk 3 kelas - Model yang dihasilkan dievaluasi oleh ahli radiologi 	<p>mengklasifikasikan pasien dengan COVID-19 sebagai pneumonia</p> <ul style="list-style-type: none"> -Tingkat keberhasilan model dalam masalah klasifikasi kelas jamak relatif rendah dibandingkan dengan kelas biner -Model membuat prediksi yang salah pada citra dengan kualitas rendah - Model membuat prediksi yang salah pada pasien dengan sindrom gangguan pernapasan akut (ARDS).

Peneliti, Tahun	Subjek Penelitian	Metode Penelitian	Kelebihan	Kekurangan
				<ul style="list-style-type: none"> - Dataset COVID-19 masih terbatas - Model menemui masalah dalam mengklasifikasikan gambar dengan detail yang halus.
Rajkumar, Himanshu & Marimuthu, 2023		<i>WavStaCovNet-19</i> <i>ResNet50, VGG19, Xception, dan DarkNet19</i>	<ul style="list-style-type: none"> - Menggunakan kombinasi dari beberapa model deep learning (ResNet50, VGG19, Xception, dan DarkNet19) meningkatkan performa deteksi dan akurasi. - Model WavStaCovNet-19 mencapai akurasi 94.24% untuk klasifikasi 4 kelas 	<ul style="list-style-type: none"> - Keberhasilan model sangat bergantung pada penggunaan Discrete Wavelet Transform (DWT). - Pelatihan model WavStaCovNet-19 memerlukan sumber daya komputasi yang besar.

Peneliti, Tahun	Subjek Penelitian	Metode Penelitian	Kelebihan	Kekurangan
			(COVID-19, pneumonia bakteri, pneumonia virus, normal) dan 96.10% untuk klasifikasi 3 kelas (COVID-19, pneumonia, normal).	
Mahmud, Rahman & Fattah, 2020	Deteksi dan Klasifikasi	<i>ConvNeXt</i>	<ul style="list-style-type: none"> - Penggunaan konvolusi depthwise dengan dilasi variabel membuat model ini efisien dalam menangkap fitur lokal dan global dari gambar X-ray. - Teknik stacking algoritma dan penggunaan meta-learner meningkatkan akurasi prediksi dengan menggabungkan hasil dari 	<ul style="list-style-type: none"> - Performa model sangat bergantung pada kualitas dan jumlah data X-ray yang tersedia. Data yang berkualitas rendah dapat mempengaruhi hasil deteksi. - Arsitektur yang kompleks dan penggunaan teknik stacking memerlukan

Peneliti, Tahun	Subjek Penelitian	Metode Penelitian	Kelebihan	Kekurangan
			berbagai model CovXNet.	sumber daya komputasi yang besar - Fitur yang tumpang tindih antara COVID-19 dan pneumonia viral membuat klasifikasi menjadi lebih sulit dan dapat menyebabkan beberapa kesalahan klasifikasi.
Hasoon J, Fadel A, Hameed R, 2021		- Melakukan preprocessing citra (penghilangan noise, thresholding, operasi morfologi),	- Menghasilkan 6 model kombinasi pengklasifikasi dan operator ekstraksi fitur: LBP-KNN, HOG-KNN, Haralick-KNN, LBP-SVM, HOG-SVM, dan Haralick-SVM	- Model belum diuji dalam data yang besar untuk verifikasi lebih lanjut atas temuan penelitian

Peneliti, Tahun	Subjek Penelitian	Metode Penelitian	Kelebihan	Kekurangan
		<ul style="list-style-type: none"> - Melakukan segmentasi dengan Deteksi Region of Interest (ROI) - Ekstraksi fitur dengan (LBP, HOG, Haralick) - Klasifikasi menggunakan (KNN, SVM). - Mengkombinasikan operator ekstraksi fitur dan algoritma klasifikasi 	<ul style="list-style-type: none"> - Akurasi tinggi hingga 98,66%, sensitivitas 97,76%, spesifisitas 100% - Model LBP-KNN mengungguli model lainnya yang mencapai akurasi rata-rata 98,66%, sensitivitas 97,76%, spesifisitas 100%, presisi 100%, tingkat kesalahan 1,34%, dan nol positif palsu - Menggunakan lebih dari satu metode ekstraksi fitur dan klasifikasi. 	

Peneliti, Tahun	Subjek Penelitian	Metode Penelitian	Kelebihan	Kekurangan
V. Sreejith and Thomas George, 2021		<i>ResNet-50</i>	<ul style="list-style-type: none"> - Dengan menggunakan teknik transfer learning dan fine-tuning, pelatihan model hanya memerlukan waktu yang relatif singkat (5 menit untuk 5 epoch). - Menggunakan presisi campuran untuk mengurangi waktu pelatihan dan kebutuhan memori, memungkinkan pelatihan model yang lebih efisien. 	- Hasil penelitian sangat bergantung pada kualitas dan variasi dataset yang digunakan.

Peneliti, Tahun	Subjek Penelitian	Metode Penelitian	Kelebihan	Kekurangan
Goyal, Singh, 2023		<i>Median filtering</i> <i>ANN</i> <i>SVM</i> <i>KNN</i> <i>Ensemble</i> <i>RNN-LSTM</i>	- Meningkatkan akurasi deteksi - Mengurangi waktu komputasi	- Tidak menjelaskan cara menentukan nilai ambang untuk mendefinisikan tingkat keparahan penyakit paru-paru. Nilai ambang ditentukan secara manual berdasarkan pengamatan. - Tidak ada analisis tentang interpretasi dan kegunaan fitur yang diekstraksi.

Peneliti, Tahun	Subjek Penelitian	Metode Penelitian	Kelebihan	Kekurangan
Tenali and Babu, 2023		<i>HQDCNet: Hybrid Quantum Dilated Convolution Neural</i>	<ul style="list-style-type: none"> - Mampu menangani data citra dalam jumlah besar menggunakan <i>distributed computing server</i> berbasis Hadoop. - Akurasi deteksi COVID-19 mencapai 99,01% 	Memerlukan sumber daya komputasi yang besar untuk menjalankan model pada <i>distributed computing server</i> .
Teixeira L, Pereira R, Bertolini D, 2021	Segmentasi	<i>CNN - U-Net</i> <i>VGG16</i> <i>ResNet50V2</i> <i>InceptionV3</i>	Mengevaluasi dampak segmentasi paru-paru terhadap akurasi klasifikasi pneumonia dan COVID-19 serta menjelaskan prediksi model menggunakan teknik <i>Explainable AI</i> .	<ul style="list-style-type: none"> - Masker yang dibuat secara manual memiliki performa yang buruk jika dibandingkan dengan hasil dari penelitian lain - Penggunaan segmentasi tidak meningkatkan skor f1

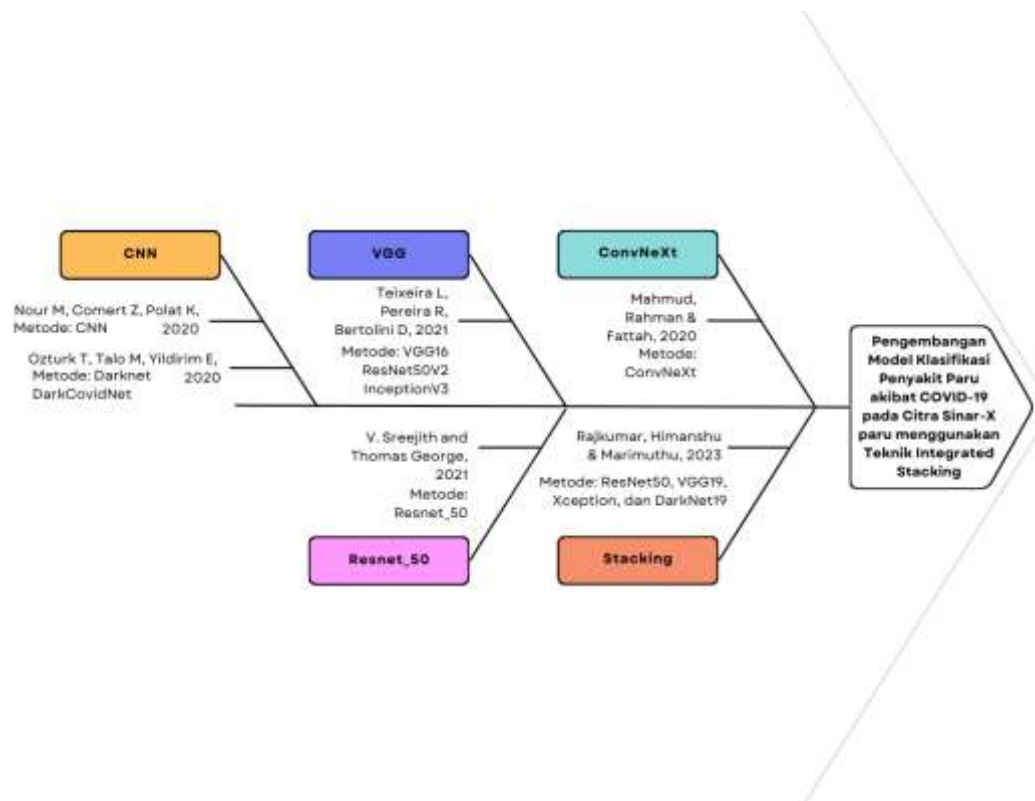
Peneliti, Tahun	Subjek Penelitian	Metode Penelitian	Kelebihan	Kekurangan
Basha, Neto, Alshathri, 2022		<i>Filter median</i> <i>Multi-threshold Otsu</i> <i>Ekstraksi fitur statistik, wavelet, dan tekstur Laws</i> <i>Random Forest</i> <i>Support Vector Machine (SVM)</i>	<ul style="list-style-type: none"> - Kombinasi fitur handcrafted statistik, wavelet, dan tekstur mampu membedakan COVID-19 dan pneumonia dengan baik - Penggunaan <i>multi-threshold</i> Otsu dapat mengidentifikasi ROI yang mungkin mengandung infeksi - Akurasi klasifikasi tertinggi mencapai 90% menggunakan <i>Random Forest</i> - Intensitas dan fitur berbasis wavelet bervariasi pada dua patologi, lebih baik 	<ul style="list-style-type: none"> - Tidak ada validasi <i>ground truth</i> untuk segmentasi ROI - Belum ada perbandingan dengan metode deep learning - Ekstraksi fitur <i>handcrafted</i> membutuhkan proses yang lama

Peneliti, Tahun	Subjek Penelitian	Metode Penelitian	Kelebihan	Kekurangan
			<p>dibedakan dengan fitur gabungan yang dilatih menggunakan pengklasifikasi SVM dan RF</p> <p>- Gambar yang telah diproses sebelumnya dan kemudian dijadikan masker tersegmentasi efektif dalam mensegmentasi wilayah infeksi.</p>	
Al-Zyoud, Erekat, SaraijI, 2023		Segmentasi biner dan thresholding	<p>Hasil penelitian: pasien COVID-19 memiliki persentase atenuasi yang lebih tinggi pada lobus bawah paru-paru.</p>	<p>- Ketergantungan pada kualitas citra</p> <p>- Kemampuan generalisasi yang terbatas</p> <p>- Metode segmentasi biner untuk menganalisis</p>

Peneliti, Tahun	Subjek Penelitian	Metode Penelitian	Kelebihan	Kekurangan
				citra mungkin tidak cukup tepat.
Basha, Albuquerque, Chelloug, 2024	Ekstraksi fitur	Fitur <i>Texture dan Vesselness</i>	<ul style="list-style-type: none"> - Mengidentifikasi <i>vesselness maps</i> - Menentukan penggabungan dua kategori yang berbeda dari fitur <i>handcrafted</i> untuk mengkategorikan patologi yang diinginkan. - Mengeksplorasi fitur-fitur <i>handcrafted</i> dari daerah-daerah dengan intensitas piksel tinggi menggunakan penggabungan GLCM dan 	<ul style="list-style-type: none"> - Ekstraksi fitur dilakukan secara manual (<i>handcrafted</i>), sehingga membutuhkan waktu - Segmentasi berlebihan bisa terjadi dengan <i>multi-thresholding</i> berdasarkan intensitas piksel

Peneliti, Tahun	Subjek Penelitian	Metode Penelitian	Kelebihan	Kekurangan
			tiga teknik vesselness. - Kombinasi fitur tekstur dan vesselness memberikan kinerja yang baik - Akurasi tertinggi 91,8% dengan Random Forest - Mampu membedakan COVID-19 dari opasitas paru dengan true positive rate 97%	

2.16 Roadmap Penelitian

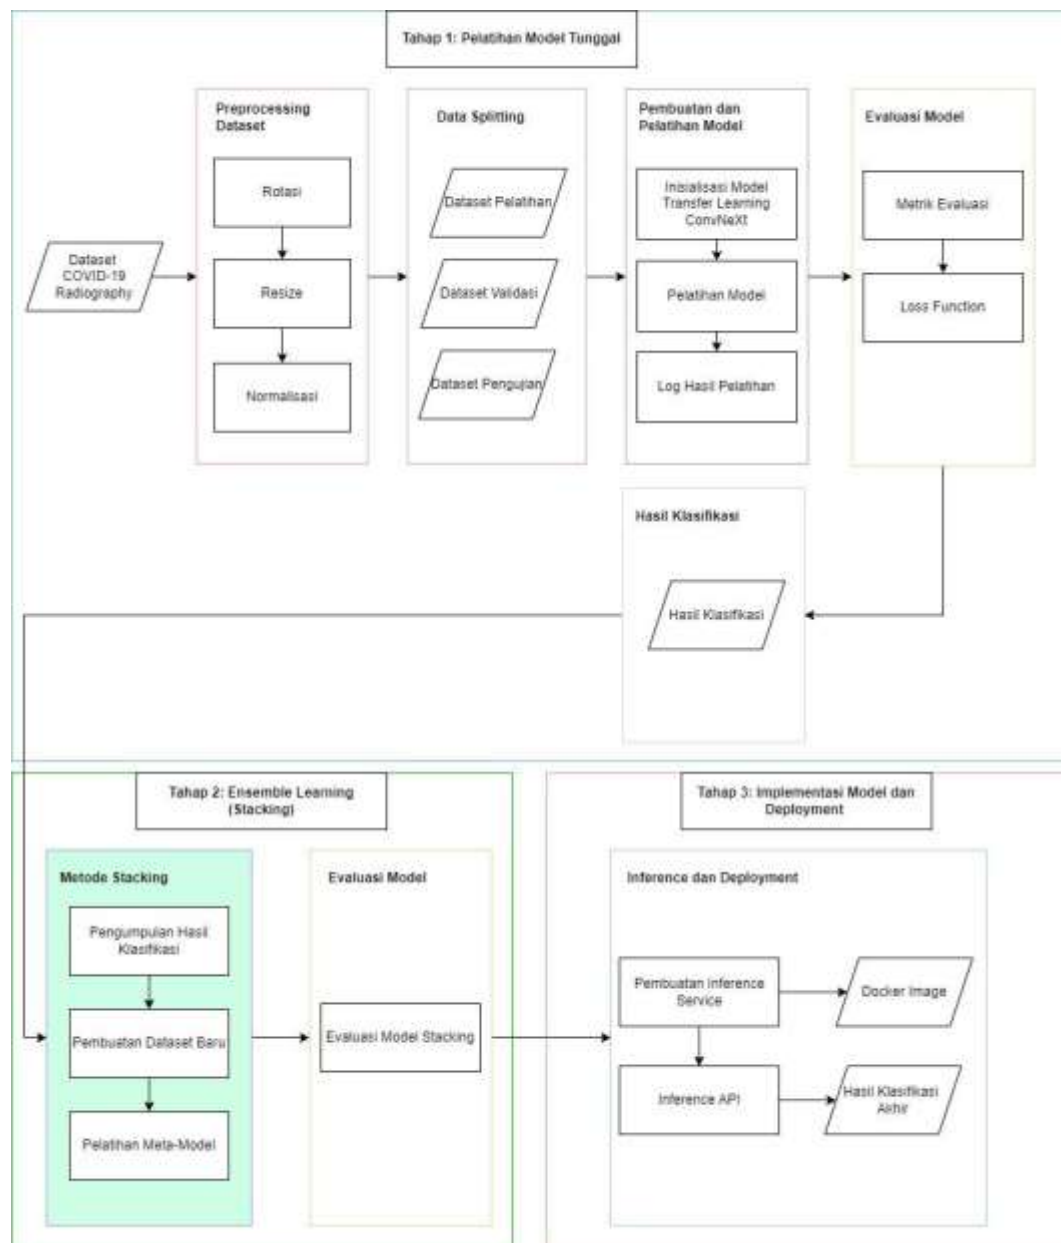


Gambar 2.21 *Fishbone* Penelitian

BAB 3

METODE PENELITIAN

Dalam disertasi ini diusulkan metode klasifikasi anomali paru akibat Covid-19 pada citra sinar-X paru yang terbagi ke dalam tiga tahap utama, seperti yang ditunjukkan pada Gambar 3.1.



Gambar 3.1 Bagan Metode Penelitian

Gambar 3,1 menggambarkan peta penelitian yang terdiri dari tiga tahap utama: pelatihan model tunggal, *ensemble learning* dengan metode *stacking* dan implementasi model. Tahap pertama terdiri dari beberapa langkah, dimulai dari *preprocessing* dataset. Pada tahap *preprocessing* dilakukan augmentasi citra untuk meningkatkan variasi data pada dataset. Tahap selanjutnya adalah *dataset splitting* dengan membagi dataset menjadi tiga subset: dataset pelatihan, dataset validasi, dan dataset pengujian. Tahapan selanjutnya adalah pembuatan dan pelatihan model.

Proses pembuatan dan pelatihan model memanfaatkan teknik *transfer learning* pada beberapa arsitektur (ConvNext, DenseNet, Vgg19, ResnetV2_50 dan Xception). Teknik *transfer learning* bertujuan untuk mempercepat proses pelatihan dengan mentransfer bobot dari model yang sudah dilatih sebelumnya. Proses pelatihan juga memanfaatkan teknik penjadwalan *learning rate*, agar model dapat mencapai nilai gradient optimal sehingga mendapatkan performa model terbaik dari proses pelatihan. Tahap berikutnya adalah mengevaluasi model yang telah dilatih menggunakan dataset uji yang tidak digunakan selama proses pelatihan. Evaluasi model dilakukan dengan mengukur performanya menggunakan *classification metric* seperti *accuracy*, *precision*, *recall*, dan *f1-score*. Hasil dari proses ini berupa beberapa model terbaik. Hasil prediksi dari beberapa model ini disimpan untuk digunakan pada tahap kedua.


Tahap kedua dalam penelitian ini adalah *ensemble learning* dengan metode *stacking*. Pada tahap ini hasil prediksi dari berbagai model tunggal yang telah dilatih sebelumnya dikumpulkan. Hasil prediksi ini mencakup probabilitas atau kelas yang diprediksi oleh masing-masing model tunggal untuk setiap sampel dalam dataset. Hasil prediksi yang dikumpulkan digunakan untuk membentuk dataset baru. Dataset baru ini terdiri dari fitur-fitur yang merupakan prediksi dari model-model tunggal sebelumnya, serta label asli dari dataset. Dataset baru ini bertujuan untuk merepresentasikan pola dan kesalahan yang dihasilkan oleh model-model tunggal. Dataset baru yang telah dibuat kemudian digunakan untuk melatih meta-model. Meta-model bertujuan untuk belajar dari kesalahan dan pola prediksi yang dihasilkan oleh model-model tunggal. Meta-model akan menggabungkan prediksi dari berbagai model tunggal untuk menghasilkan prediksi akhir yang lebih


akurat. Setelah meta-model dilatih, dilakukan evaluasi model untuk memastikan kinerjanya.

Langkah selanjutnya adalah tahap inferensi model, yang bertujuan untuk menerapkan model yang telah dilatih pada data baru agar dapat membuat prediksi. Proses inferensi ini menggunakan layanan web API (*Application Programming Interface*) berbasis web yang akan dimuat dalam sebuah gambar Docker, sehingga mempermudah proses penyebaran (*deployment*) pada perangkat dengan berbagai lingkungan yang berbeda.

3.1 Dataset COVID-19 Radiography

Dataset COVID-19 Radiography adalah kumpulan data citra sinar-X paru-paru. Dataset ini terdiri dari 21165 citra sinar-X paru yang dikategorikan menjadi 4 kelas seperti: 3616 citra sinar-X positif Covid-19, 10119 citra normal, 6012 citra *lung opacity* dan 1345 citra pneumonia virus. Gambar 3.2 menunjukkan beberapa citra sinar-X paru COVID-19, *viral pneumonia*, *lung opacity* dan normal yang disediakan oleh *database* Radiografi COVID-19. Dataset Radiograph COVID-19 dapat diakses di platform Kaggle pada url [COVID-19 Radiography Database](https://www.kaggle.com/paultimothymooney/covid19-radiography-database) .





Gambar 3.2. contoh citra sinar-X paru dari Database Radiografi COVID-19: Normal (Baris 1) COVID-19 (Baris 2), viral pneumonia (Baris 3) dan lung opacity (Baris 4).

Gambar 3.2 di atas merupakan contoh sampel citra dari dataset Radiograph COVID-19. Citra sinar-X Normal memiliki paru-paru yang bersih tanpa bintik-bintik putih, yang menandakan bahwa paru-paru tidak mengalami peradangan atau infeksi. Citra sinar-X COVID-19 memiliki ciri khas berupa bintik-bintik putih, yang menunjukkan adanya cairan dan menandakan infeksi pada paru-paru. Citra sinar-X *Lung Opacity* menunjukkan ciri khas berupa bintik-bintik putih keabuan. Pada citra sinar-X *Viral Pneumonia*, terdapat bintik-bintik putih pada bagian atas paru-paru yang menunjukkan infeksi pada saluran pernapasan atas.

3.2 Preprocessing Dataset

Sebelum digunakan dalam model *deep learning*, dataset yang telah disiapkan perlu diolah terlebih dahulu melalui tahap *preprocessing*. Tahap *preprocessing* pertama yang dilakukan adalah augmentasi citra untuk memperkaya dataset dengan berbagai variasi citra. Tahap selanjutnya adalah mengubah ukuran (*resize*) semua citra dalam dataset agar sesuai dengan kebutuhan model. Tahap

terakhir adalah normalisasi citra, dimana nilai piksel setiap citra diubah ke rentang 0 hingga 1.



Gambar 3.3 Rancangan Tahap *Preprocessing*

Gambar 3.3 memperlihatkan tahapan *preprocessing* dataset yang digunakan dalam penelitian ini. Pada tahap *preprocessing* dataset, dilakukan augmentasi citra dengan memutar citra-citra dalam dataset untuk menghasilkan variasi gambar yang terotasi. Hasil augmentasi citra ini kemudian diubah ukurannya menjadi dimensi yang sama. Selanjutnya, tipe data citra diubah ke format `torch.Tensor` agar dapat diproses oleh GPU. Tahap selanjutnya adalah normalisasi citra menggunakan nilai rata-rata dan standar deviasi dari dataset *ImageNet*, penggunaan nilai tersebut memiliki tujuan agar hasil normalisasi sama dengan proses pelatihan bobot untuk *transfer learning* model. Proses *preprocessing* pada dataset pelatihan dilakukan menggunakan algoritma 3.1.

Algoritma 3.1 Proses *Preprocessing* pada Dataset

Input:

Citra dari dataset COVID-19 Radiography

Output:

Citra yang telah dipreprocessing

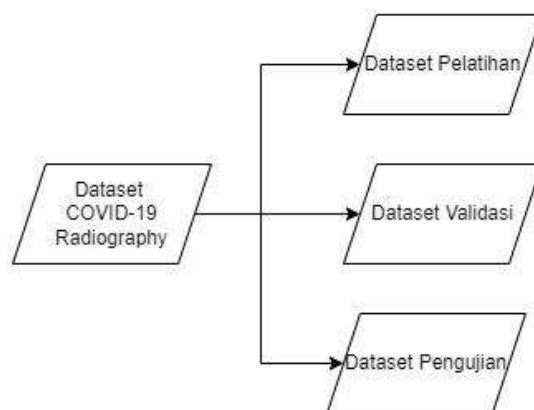
Proses:

1. Mulai.
 2. Melakukan *random rotation* pada citra menggunakan fungsi `Random Rotation()` dari PyTorch dengan parameter `rotation_range` sebesar 10.
 3. Mengubah ukuran citra menjadi 224x224 menggunakan fungsi `Resize()` dengan parameter `cfg['model']['input_size']`.
 4. Mengonversi citra menjadi tensor menggunakan fungsi `ToTensor()`.
 5. Melakukan normalisasi citra menggunakan nilai mean dan std dari dataset *ImageNet* yang diberikan, yaitu `mean=[0.485, 0.456, 0.406]` dan `std=[0.229, 0.224, 0.225]` menggunakan fungsi `Normalize()`.
 6. Selesai.
-

Algoritma 3.1 menggambarkan langkah-langkah *preprocessing* yang dilakukan pada dataset. Langkah pertama adalah melakukan augmentasi citra menggunakan *RandomRotation()* dengan parameter *rotation_range* sebesar 10 derajat. Langkah selanjutnya adalah mengubah ukuran citra dengan nilai parameter (224, 224) menggunakan fungsi *Resize()*. Setelah itu, tipe data diubah menjadi *torch.Tensor* dengan fungsi *ToTensor()* untuk persiapan pengolahan pada perangkat. Terakhir, gambar dinormalisasi dengan fungsi *Normalize()* menggunakan nilai mean dan standard deviasi dari dataset *ImageNet*, yaitu [0.485, 0.456, 0.406] dan [0.229, 0.224, 0.225].

3.3 Dataset Splitting

Dataset Splitting merupakan proses membagi dataset menjadi beberapa subset. Pada penelitian ini dataset dibagi menjadi 3 subset: yaitu dataset pelatihan, dataset validasi, dan dataset pengujian. Dataset pelatihan dan dataset validasi digunakan untuk melatih model *deep learning*. Dataset latih digunakan untuk model dalam mengekstraksi fitur-fitur dari data tersebut. Fitur-fitur yang diekstraksi kemudian divalidasi menggunakan dataset validasi. Dataset pengujian adalah subset yang digunakan untuk menguji kinerja model setelah proses pelatihan selesai. Proses pembagian dataset dapat dilihat pada gambar 3.3



Gambar 3.3. Tahapan Proses Dataset splitting

Gambar 3.3 menggambarkan tahapan *dataset splitting*. Proses pembagian dilakukan dengan membagi total dataset menjadi 80% untuk dataset pelatihan, 10% untuk dataset validasi dan 10% untuk dataset pengujian. Proses ini memastikan bahwa sebagian besar data digunakan untuk melatih model, sementara sisanya digunakan untuk memvalidasi performa model.

Langkah berikutnya adalah membagi dataset menjadi beberapa batch pelatihan. Pembagian ini dilakukan untuk mengurangi beban pelatihan yang berat dan validasi hasil pelatihan dapat dilakukan secara perbatch.

Algoritma 3.2 Proses Pemuatan Data dan Pembagian ke Batch Pelatihan, Validasi, dan Pengujian

Input:

Dataset pelatihan (train_set)
 Dataset validasi (val_set)
 Dataset uji (test_set)
 Ukuran batch untuk dataset pelatihan (train_bs)
 Ukuran batch untuk dataset uji (test_bs)

Output:

DataLoader untuk dataset pelatihan (train_dl)
 DataLoader untuk dataset validasi (val_dl)
 DataLoader untuk dataset uji (test_dl)

Proses:

1. Mulai
2. Pemuatan Data Pelatihan:
 - Atur kwargs dengan batch_size=self.train_bs, shuffle=True, num_workers=2.
 - Buat DataLoader untuk train_set dengan pin_memory=True dan kwargs.
 - Simpan DataLoader ke dalam train_dl.
3. Pemuatan Data Validasi:
 - Atur kwargs dengan batch_size=self.train_bs, shuffle=True, num_workers=2.
 - Buat DataLoader untuk val_set dengan pin_memory=True dan kwargs.
 - Simpan DataLoader ke dalam val_dl.


4. Pemuatan Data Uji:
 - Atur kwargs dengan `batch_size=test_bs`, `shuffle=True`, `num_workers=2`.
 - Buat `DataLoader` untuk `test_set` dengan `pin_memory=True` dan kwargs.
 - Simpan `DataLoader` ke dalam `test_dl`.
 5. Kembalikan `train_dl`, `val_dl`, dan `test_dl` sebagai output.
 6. Selesai.
-

Algoritma di atas mengimplementasikan proses pemuatan dataset dan pembagian data ke dalam batch pelatihan. Setiap batch memiliki jumlah citra sesuai dengan nilai batch size yang ditentukan. Proses pemuatan ini juga mencakup pengacakan dataset untuk setiap batch size, sehingga variasi citra dalam setiap batch pelatihan menjadi lebih beragam. Selain itu, pengaturan parameter `pin_memory=True` diaktifkan dengan tujuan untuk melakukan caching memory, sehingga proses pelatihan lebih cepat karena dataset hanya dimuat pada iterasi pertama dari setiap batch pelatihan.

3.4 Pembuatan dan Pelatihan Model

3.4.1 Model ConvNeXt

Model ConvNeXt adalah salah satu variasi dari arsitektur Convolutional Neural Network (CNN). Model ini mengadopsi dasar *Residual Network* dan memperkenalkan empat tahapan proses konvolusi. Salah satu fitur utama dari ConvNeXt adalah penggunaan layer *patchify* yang mengimplementasikan konvolusi 7x7 dengan stride 2, diikuti oleh layer *max-pooling*. Selain itu, arsitektur ini menggunakan fungsi aktivasi GELU pada blok ConvNeXt, yang sering digunakan dalam model berbasis transformer. Model ConvNeXt juga menerapkan *Layer Normalization* (LN), yang merupakan perbedaan signifikan dengan model berbasis CNN lainnya. Contoh blok ConvNeXt dapat dilihat pada Gambar di bawah ini.



Gambar 3.5. Blok ConvNeXt (Liu, Z., et al., 2022)

Model ConvNeXt memiliki beberapa varian ukuran, yaitu tiny, small, base, large, dan xlarge. Ukuran model ditentukan oleh jumlah blok ConvNeXt yang digunakan. Semakin besar modelnya, semakin banyak blok yang digunakan. Pada penelitian ini, model ConvNeXt yang digunakan adalah ukuran base, yang terdiri dari 4 stage dengan komponen blok ConvNeXt sebanyak [3, 3, 9, 3], dan ukuran dimensi fitur untuk setiap stage adalah [96, 192, 384, 768].

3.4.2 Transfer Learning

Transfer Learning adalah proses dimana model dilatih pada sebuah dataset baru. Proses ini memanfaatkan model yang telah dilatih sebelumnya pada dataset lain (model *pre-trained*). Proses ini diawali dengan mengubah lapisan klasifikasi atau lapisan output agar sesuai dengan jumlah kelas yang ada pada dataset baru, yaitu 4. Langkah berikutnya adalah mentransfer bobot dari lapisan ekstraksi fitur, yang bertujuan untuk menginisialisasi model berdasarkan fitur-fitur yang telah dipelajari sebelumnya pada dataset *ImageNet*. Tujuan dari *transfer learning* adalah untuk mempercepat proses pelatihan dengan memanfaatkan bobot dari model *pre-trained*. Implementasi proses *transfer learning* dapat dilihat pada Algoritma di bawah ini.

Algoritma 3.3 Proses Implementasi Transfer Learning

Input:

Pretrained (boolean): Pilihan untuk menggunakan bobot yang sudah dilatih sebelumnya dari dataset *ImageNet*.
 num_classes (int): Jumlah kelas keluaran dari model.
 x (torch.Tensor): Batch dari Tensor Input.

Output:

Probabilitas kelas setelah softmax (torch.Tensor).

Proses:

1. Mulai
 2. Inisialisasi Model
 - Inisialisasi kelas ConvNext dengan argumen pretrained dan output_class.
 - Buat model convnext_base menggunakan paket timm dengan bobot pretrained dan jumlah num_classes sesuai output_class.
 3. Metode Forward Pass
 - Terima input tensor x.
 - Proses input melalui model convnext_base.
 - Terapkan fungsi softmax pada output untuk mendapatkan probabilitas kelas.
 4. Metode Freeze Weights
 - Iterasi melalui semua parameter di feature extractor dan set requires_grad ke False untuk membekukan bobot.
 - Iterasi melalui semua parameter di classifier dan set requires_grad ke True agar dapat dilatih.
 5. Metode Unfreeze Weights
 - Iterasi melalui semua parameter di feature extractor dan set requires_grad ke True untuk membuka pembekuan bobot.
 6. Selesai
-

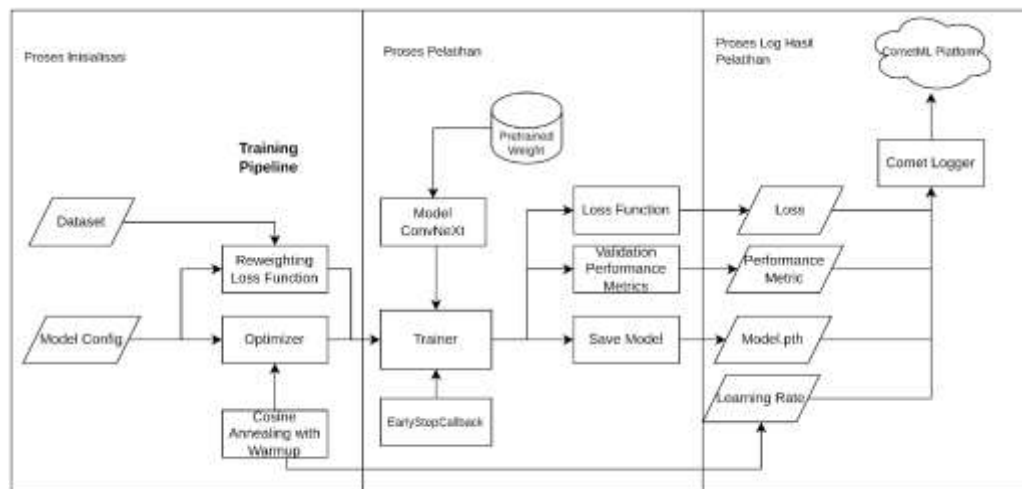
Kelas ConvNeXt pada Algoritma di atas memiliki 4 buah method yaitu init, forward, freeze, dan unfreeze. Method init adalah sebuah fungsi yang bertujuan melakukan inisiasi model sesuai dengan inputan parameter yang ada, yaitu pretrained dan num_classes. Parameter pretrained merupakan sebuah inputan boolean agar model dapat melakukan proses inisiasi dengan menggunakan bobot pra-pelatihan yang tersedia dari pytorch, sedangkan parameter num_classes merupakan parameter yang bertujuan untuk menginisiasi jumlah kelas output pada model. Method forward adalah sebuah fungsi yang menerima parameter x berupa torch.Tensor dan akan dilakukan proses forward pass pada model untuk melakukan

prediksi pada model. Method freeze memiliki tujuan untuk membekukan bobot agar tidak terbaharui pada proses backpropagation, sedangkan method unfreeze memiliki tujuan untuk memasukan parameter model dan melakukan pembaharuan bobot pada proses backpropagation. Model yang telah dibuat akan digunakan pada proses pelatihan model.

3.5 Pelatihan Model

Proses pelatihan model pada penelitian ini menerapkan teknik transfer learning yang terdiri dari dua tahap, yaitu tahap *adaptation* dan *fine tuning*. Pada tahap *adaptation*, pelatihan model hanya dilakukan pada lapisan klasifikasi dan lapisan output. Tujuan tahap ini adalah untuk menginisialisasi dan menyesuaikan bobot pada lapisan-lapisan tersebut. Tahap *adaptation* dalam proses pelatihan menggunakan nilai *learning rate* yang tinggi sehingga model dapat dengan cepat mencapai titik *optimal gradien* untuk memperoleh bobot yang tepat pada lapisan klasifikasi dan lapisan output. Tahap ini berperan penting dalam proses pengklasifikasian suatu hasil *feature extraction* menjadi suatu output prediksi.

Proses *fine tuning* adalah tahap pelatihan model secara menyeluruh yang mencakup lapisan *feature extraction* dan lapisan klasifikasi. Pada tahap *fine tuning*, nilai *learning rate* yang kecil digunakan agar bobot pra-pelatihan model tidak mengalami perubahan signifikan yang dapat mengakibatkan hasil pelatihan model kurang baik. Selain itu, penggunaan nilai *learning rate* yang kecil membantu dalam mencapai konvergensi yang stabil. Dalam penelitian ini, teknik penjadwalan *learning rate* berbasis *Cosine Learning Rate Decay* diterapkan untuk mengoptimalkan proses pelatihan baik pada tahap *adaptation* maupun *fine tuning*.



Gambar 3.8. Rancangan Alur Pelatihan

Gambar 3.8 merupakan rancangan alur pelatihan dalam penelitian ini. Alur pelatihan model terbagi menjadi 3 tahapan yakni proses inisialisasi, proses pelatihan dan proses log hasil pelatihan. Tahap pertama merupakan inisialisasi proses pelatihan berdasarkan dataset dan config yang diinput. Langkah pertama dalam inisialisasi adalah mengatur ulang bobot fungsi loss berdasarkan distribusi dataset untuk mengatasi masalah ketidakseimbangan data.

Proses perhitungan bobot menggunakan rumus total data dibagi total kelas dikali total data pada kelas tersebut. Langkah selanjutnya adalah proses mengubah bobot menjadi tensor dan memindahkan bobot ke hardware yang digunakan. Bobot yang telah dipindahkan ke hardware kemudian akan dimasukkan ke dalam fungsi *CrossEntropyLoss* untuk digunakan pada proses pelatihan model. Proses inisialisasi kedua adalah inisialisasi optimizer berdasarkan pilihan yang diinginkan.

Proses inisiasi *optimizer* yang menggunakan fungsi `get_optimizer()` merupakan fungsi yang memiliki tujuan untuk mengembalikan inisiasi optimizer berdasarkan inputan konfigurasi yang ada. Proses berikutnya adalah inisialisasi *learning rate scheduler* yang berfungsi untuk mengubah nilai *learning rate* secara adaptif selama proses pelatihan berlangsung. Proses *learning rate scheduler* memanfaatkan *Cosine Learning Rate Decay* dengan pengurangan.

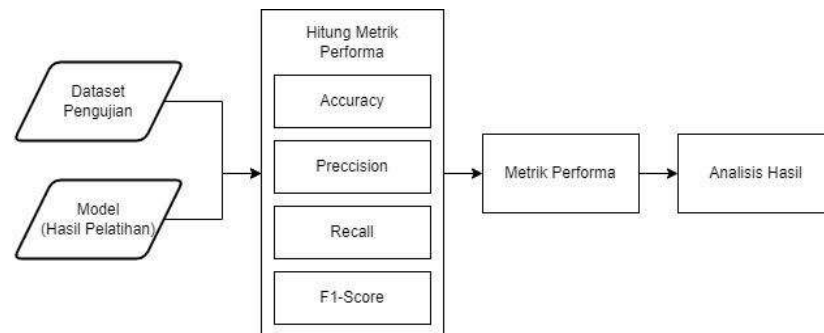
Proses kedua adalah proses pelatihan model ConvNeXt yang meliputi pelatihan, proses *transfer learning* model, dan juga proses penghitungan fungsi loss

dan metrik performa. Proses melatih model akan dilakukan oleh komponen Trainer yang akan memproses pelatihan model ConvNeXt menggunakan Optimizer dan juga *EarlyStopCallback*. Proses pelatihan bagian *adaptation* akan dilakukan sebanyak 2 epoch pertama untuk mendapatkan bobot pada *classification layer*. Proses pelatihan bagian *fine tuning* akan dilakukan sebanyak total *epoch* dikurangi 2, contoh jika total epoch sama dengan 25, maka model akan melakukan proses pelatihan fine tuning sebanyak 23 epoch. Proses validasi performa model merupakan proses dimana hasil pelatihan model tiap epoch dilakukan validasi pada data validasi yang telah disiapkan sebelumnya dengan cara mengukur nilai loss dan juga performa metrik yang meliputi *accuracy*, *recall*, *precision*, dan *f1-score*. Hal ini bertujuan agar model dapat memperbaharui nilai bobot pengetahuan dengan cara melakukan *backpropagation* berdasarkan nilai loss dan akan menyimpan file model terbaik berdasarkan hasil validasi metrik performa pada data validasi.

Proses ketiga adalah log hasil pelatihan model yang meliputi menyimpan hasil output model dan juga log pelatihan menggunakan Comet logger. Comet logger akan menyimpan nilai hasil pelatihan seperti *loss*, *learning rate*, dan *metrik performa* pada platform CometML untuk visualisasi grafik pelatihan model. Proses penyimpanan log ini juga bertujuan agar dapat membandingkan berbagai hasil pelatihan dengan konfigurasi berbeda sehingga mendapatkan model dengan performa terbaik berdasarkan metrik performa pada data validasi.

3.7 Evaluasi Model

Evaluasi Model adalah tahap di mana model yang telah dilatih dievaluasi menggunakan dataset uji. Tujuan dari pengujian ini adalah untuk mengevaluasi kinerja model pada data yang belum pernah dipelajari sebelumnya. Hasil pengujian model akan diukur menggunakan beberapa metrik performa, seperti akurasi, presisi, recall, dan f1-score.



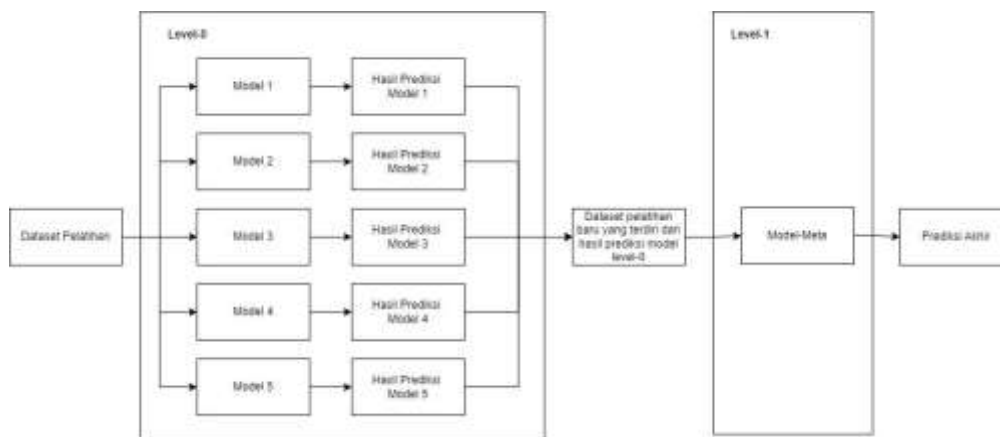
Gambar 3.9. Rancangan Alur Pengujian Model

Gambar 3.9 merupakan alur pengujian model dalam penelitian ini. Pengujian model dimulai dengan input berupa dataset pengujian dan model yang telah dilatih sebelumnya. Semua model yang telah dilatih sebelumnya diuji menggunakan dataset ini untuk membandingkan performa tiap model pada dataset yang sama. Proses berikutnya adalah perhitungan metrik performa yang terdiri dari *accuracy*, *precision*, *recall*, dan *F1-score*.

Penggunaan metrik *accuracy* memiliki tujuan untuk mengetahui tingkat keakuratan prediksi yang dibuat oleh model terhadap data uji. Metrik ini dihitung dengan mengambil jumlah total prediksi yang benar baik *true positives* (kasus positif yang diprediksi dengan benar) dan *true negatives* (kasus negatif yang diprediksi dengan benar) dan membaginya dengan jumlah total sampel dalam dataset. Metrik *precision* mengukur ketepatan sebuah model dalam memprediksi label kelas positif. *Precision* merupakan proporsi dari *true positives* terhadap jumlah keseluruhan prediksi yang dinyatakan sebagai positif oleh model, termasuk *false positives*. Metrik *recall* bertujuan untuk mengukur seberapa akurat model dalam mengidentifikasi semua kasus positif yang ada dalam suatu kelas tertentu. Recall dihitung dengan membandingkan jumlah prediksi yang benar-benar positif yang berhasil diidentifikasi oleh model dengan jumlah total kasus positif sebenarnya dalam kelas tersebut. Penggunaan *F1-score* bertujuan untuk menilai keseimbangan antara *precision* dan *recall* dalam performa model klasifikasi. Metrik ini sangat penting untuk menghindari permasalahan di mana model memiliki *precision* tinggi tapi *recall* rendah, atau sebaliknya.

3.8 Metode Stacking

Stacking atau *Stacked generalization* merupakan teknik *ensemble learning* yang mengintegrasikan prediksi dari beberapa model untuk menghasilkan prediksi yang lebih akurat. *Stacking* berbeda dari metode *ensemble* lain seperti *bagging* dan *boosting*. Fokus utama model *stacking* adalah menggabungkan kekuatan model yang berbeda melalui model meta. Komponen utama metode *stacking* terbagi menjadi 2, yaitu model dasar dan meta-model. Model dasar adalah beberapa model tunggal yang masing masing dilatih menggunakan dataset yang sama. Output dari setiap model dasar, yang merupakan prediksi digunakan sebagai input untuk meta-model. Meta-model adalah model yang dilatih pada prediksi yang dihasilkan oleh model dasar. Model ini berfungsi untuk mempelajari bagaimana prediksi dari model dasar dapat digabungkan untuk menghasilkan prediksi akhir yang lebih akurat.



Gambar 3.10. Arsitektur Metode Stacking

Proses implementasi metode *stacking* dalam penelitian ini terdiri dari 3 tahap. Tahap pertama, hasil prediksi dari beberapa model dasar dikumpulkan. Hasil prediksi yang dikumpulkan dari model-model dasar kemudian digunakan untuk membentuk dataset baru. Setelah dataset baru dibuat, yang terdiri dari prediksi dari model-model dasar sebagai fitur, langkah selanjutnya adalah pelatihan meta-model.

3.9 Evaluasi Model Stacking

Pengujian model stacking dalam penelitian ini dilakukan seperti pengujian pada model tunggal. Pengujian dilakukan dengan menghitung metrik akurasi seperti *accuracy*, *precision*, *recall*, dan *F1-score*.

3.10 Inference dan Deployment

Inference dan *Deployment* adalah tahap di mana model terbaik yang telah melalui proses pengujian digunakan untuk membuat prediksi pada data baru. *Inference* dilakukan melalui sebuah API yang dibuat menggunakan *framework Flask* untuk menjalankan model. API yang dibuat menerima file citra X-ray data sebagai *input*. *Output* dari API ini adalah hasil prediksi yang mencakup nama kelas dan *confidence score* untuk citra tersebut. *confidence score* ini mengindikasikan tingkat keyakinan model terhadap prediksinya. Tahapan *deployment* merupakan tahapan proses mengepak API yang telah dibuat ke dalam satu *environment* yang siap dijalankan. Proses pengepakan ini menggunakan teknologi Docker yang memiliki tujuan mengisolasi *environment* yang digunakan oleh API dengan *environment* yang ada pada mesin utama. Hal ini juga memudahkan proses *deployment* karena tahapan instalasi semua komponen seperti *library*, *framework*, dan *interpreter* yang digunakan telah diinisiasi dalam bentuk docker image.

3.11 Time Table

[illegible]

Daftar Pustaka

- Al-Zyoud, W., Erekat, D., & Saraiji, R. (2023). COVID-19 chest X-ray image analysis by threshold-based segmentation. *Heliyon*, 9(3).
<https://doi.org/10.1016/j.heliyon.2023.e14453>
- Amrizal, A. (2013.). *naskah kecerdasan buatan (1)*.
- Apostolopoulos, I. D., & Mpesiana, T. A. (2020). Covid-19: automatic detection from X-ray images utilizing transfer learning with convolutional neural networks. *Physical and Engineering Sciences in Medicine*, 43(2), 635–640.
<https://doi.org/10.1007/s13246-020-00865-4>
- Basha, S. M., Albuquerque, V. H. C. de, Chelloug, S. A., Elaziz, M. A., Mohisin, S. H., & Pathan, S. P. (2024). Robust Machine Learning Technique to Classify COVID-19 Using Fusion of Texture and Vesselness of X-Ray Images. *Computer Modeling in Engineering & Sciences*, 138(2), 1981–2004.
<https://doi.org/10.32604/cmes.2023.031425>
- Brijesh Soni. (2023, May). *Stacking to Improve Model Performance: A Comprehensive Guide on Ensemble Learning in Python*. Medium.
- Burhan, E., Dwi Susanto, A., Isbaniah, F., Aman Nasution, S., Ginanjar, E., Wicaksono Pitoyo, C., Susilo, A., Firdaus, I., Santoso, A., Arifa Juzar, D., Kamsul Arif, S., Lolong Wulung, N. G., Muchtar, F., Pulungan, A. B., Basarah Yanuarso, P., Ambara Sjakti, H., Prawira, Y., Dwi Putri TIM PENYUSUN Erlina Burhan, N., Adityaningsih, D., ... Dharmawan, I. (n.d.). *PEDOMAN TATALAKSANA COVID-19 Edisi 4 TIM EDITOR Perhimpunan Dokter Paru Indonesia (PDPI) Perhimpunan Dokter Spesialis Kardiovaskular Indonesia (PERKI) Perhimpunan Dokter Spesialis Penyakit Dalam Indonesia (PAPDI) Perhimpunan Dokter Anestesiologi dan Terapi Intensif Indonesia (PERDATIN) Ikatan Dokter Anak Indonesia (IDAI)*.
- Filipović-Grčić, L., & Đerke, F. (2019). Artificial intelligence in radiology. *Rad Hrvatske Akademije Znanosti i Umjetnosti. Medicinske Znanosti*, 537(46–47), 55–59. <https://doi.org/10.21857/y26kec3o79>
- Gong, J., Liu, J.-Y., Sun, X.-W., Zheng, B., & Nie, S.-D. (2018). Computer-aided diagnosis of lung cancer: the effect of training data sets on classification accuracy of lung nodules. *Physics in Medicine & Biology*, 63(3), 035036.
<https://doi.org/10.1088/1361-6560/aaa610>
- Goodfellow, I., Bengio, Y., & Courville, A. (n.d.). *Deep Learning*.

- Goyal, S., & Singh, R. (2023). Detection and classification of lung diseases for pneumonia and Covid-19 using machine and deep learning techniques. *Journal of Ambient Intelligence and Humanized Computing*, 14(4), 3239–3259. <https://doi.org/10.1007/s12652-021-03464-7>
- Gupta, A., Anjum, Gupta, S., & Katarya, R. (2021). InstaCovNet-19: A deep learning classification model for the detection of COVID-19 patients using Chest X-ray. *Applied Soft Computing*, 99. <https://doi.org/10.1016/j.asoc.2020.106859>
- Hasoon, J. N., Fadel, A. H., Hameed, R. S., Mostafa, S. A., Khalaf, B. A., Mohammed, M. A., & Nedoma, J. (2021). COVID-19 anomaly detection and classification method based on supervised machine learning of chest X-ray images. In *Results in Physics* (Vol. 31). Elsevier B.V. <https://doi.org/10.1016/j.rinp.2021.105045>
- Hook, W. F. (n.d.). *X-RAY FILM READING MADE EASY DEDICATION*.
- Huang, C., Wang, Y., Li, X., Ren, L., Zhao, J., Hu, Y., Zhang, L., Fan, G., Xu, J., Gu, X., Cheng, Z., Yu, T., Xia, J., Wei, Y., Wu, W., Xie, X., Yin, W., Li, H., Liu, M., ... Cao, B. (2020). Clinical features of patients infected with 2019 novel coronavirus in Wuhan, China. *The Lancet*, 395(10223), 497–506. [https://doi.org/10.1016/S0140-6736\(20\)30183-5](https://doi.org/10.1016/S0140-6736(20)30183-5)
- Institute of Biomedical Imaging, N. (2022). *X-Rays What are medical x-rays?* www.nibib.nih.gov
- Jin, D., Harrison, A. P., Zhang, L., Yan, K., Wang, Y., Cai, J., Miao, S., & Lu, L. (2020). Artificial intelligence in radiology. In *Artificial Intelligence in Medicine: Technical Basis and Clinical Applications* (pp. 265–289). Elsevier Applied Science. <https://doi.org/10.1016/B978-0-12-821259-2.00014-4>
- Kesehatan Manarang, J., Suswanti Agustina, A., & Fajrunni, R. (n.d.). *Volume 6, Nomor Khusus, Oktober 2020 Perbandingan Metode RT-PCR dan Tes Rapid ...* 47. <http://jurnal.poltekkesmamuju.ac.id/index.php/m>
- Khafaji, M. A., Safhi, M. A., Albadawi, R. H., Al-Amoudi, S. O., Shehata, S. S., & Toonsi, F. (2022). Artificial intelligence in radiology Are Saudi residents ready, prepared, and knowledgeable? *Saudi Medical Journal*, 43(1), 53–60. <https://doi.org/10.15537/SMJ.2022.43.1.20210337>
- Kumar Verma, M., & Verma, M. (2018). Artificial intelligence and its scope in different areas with special reference to the field of education. In *International Journal of Advanced Educational Research 5 International Journal of Advanced Educational Research* (Vol. 3). <https://www.researchgate.net/publication/340886150>

- Lai, C. C., Shih, T. P., Ko, W. C., Tang, H. J., & Hsueh, P. R. (2020). Severe acute respiratory syndrome coronavirus 2 (SARS-CoV-2) and coronavirus disease-2019 (COVID-19): The epidemic and the challenges. In *International Journal of Antimicrobial Agents* (Vol. 55, Issue 3). Elsevier B.V.
<https://doi.org/10.1016/j.ijantimicag.2020.105924>
- Lampignano, Jhon P, Kendrick, & Leslie E. (2018). *Bontrager's Textbook of Radiographic Positioning and Related Anatomy*.
- Liu, P. ran, Lu, L., Zhang, J. yao, Huo, T. tong, Liu, S. xiang, & Ye, Z. wei. (2021). Application of Artificial Intelligence in Medicine: An Overview. *Current Medical Science*, 41(6), 1105–1115. <https://doi.org/10.1007/s11596-021-2474-3>
- Lucci, K. (2016). *Artificial intelligence in the 21 st century second edition*.
- Madenda, S. (2015). *Pengolahan Cita dan Video Digital*.
- Mahaboob Basha, S., Lira Neto, A. V., Alshathri, S., Elaziz, M. A., Hashmitha Mohisin, S., & De Albuquerque, V. H. C. (2022). Multithreshold Segmentation and Machine Learning Based Approach to Differentiate COVID-19 from Viral Pneumonia. *Computational Intelligence and Neuroscience*, 2022.
<https://doi.org/10.1155/2022/2728866>
- Munne, K., Bhanothu, V., Bhor, V., Patel, V., Mahale, S. D., & Pande, S. (2021). Detection of SARS-CoV-2 infection by RT-PCR test: factors influencing interpretation of results. In *VirusDisease* (Vol. 32, Issue 2, pp. 187–189). Springer. <https://doi.org/10.1007/s13337-021-00692-5>
- Nour, M., Cömert, Z., & Polat, K. (2020). A Novel Medical Diagnosis model for COVID-19 infection detection based on Deep Features and Bayesian Optimization. *Applied Soft Computing*, 97.
<https://doi.org/10.1016/j.asoc.2020.106580>
- Ozturk, T., Talo, M., Yildirim, E. A., Baloglu, U. B., Yildirim, O., & Rajendra Acharya, U. (2020). Automated detection of COVID-19 cases using deep neural networks with X-ray images. *Computers in Biology and Medicine*, 121.
<https://doi.org/10.1016/j.combiomed.2020.103792>
- Protopapas, P., & Rader, K. (n.d.). *CS109A Introduction to Data Science*.
- Purwono, Ma'arif, A., Rahmaniar, W., Fathurrahman, H. I. K., Frisky, A. Z. K., & Haq, Q. M. U. (2022). Understanding of Convolutional Neural Network (CNN): A Review. *International Journal of Robotics and Control Systems*, 2(4), 739–748.
<https://doi.org/10.31763/ijrcs.v2i4.888>

- Rakhmina, D., Elyn Herlina, T., Studi Teknologi Laboratorium Medis, P., Analisis Kesehatan, J., & Kemenkes Banjarmasin, P. (2022). Literature Review : Perbandingan Hasil Diagnosis Laboratorium pada COVID-19 menggunakan Metode Real Time-Polymerase Chain Reaction (RT-PCR) dan Metode Rapid Test Antigen. In *41 JURNAL KESEHATAN* (Vol. 15, Issue 1). <https://doi.org/10.3276>
- Rehman, M. F. ur, Fariha, C., Anwar, A., Shahzad, N., Ahmad, M., Mukhtar, S., & Farhan Ul Haque, M. (2021). Novel coronavirus disease (COVID-19) pandemic: A recent mini review. In *Computational and Structural Biotechnology Journal* (Vol. 19, pp. 612–623). Elsevier B.V. <https://doi.org/10.1016/j.csbj.2020.12.033>
- Sorrentino, F. S., Jurman, G., De Nadai, K., Campa, C., Furlanello, C., & Parmeggiani, F. (2020). Application of Artificial Intelligence in Targeting Retinal Diseases. *Current Drug Targets*, *21*(12), 1208–1215. <https://doi.org/10.2174/1389450121666200708120646>
- Soundrapandiyan, R., Naidu, H., Karuppiah, M., Maheswari, M., & Poonia, R. C. (2023). AI-based wavelet and stacked deep learning architecture for detecting coronavirus (COVID-19) from chest X-ray images. *Computers and Electrical Engineering*, *108*. <https://doi.org/10.1016/j.compeleceng.2023.108711>
- Stuart Russell and Peter Norvig. (2010). *Artificial Intelligence A Modern Approach Third Edition*.
- Tajdini, F., Piri, M., & Tajidini, F. (2022). *Artificial intelligence in Healthcare: A Review*. <https://www.researchgate.net/publication/365635704>
- Tecuci, G. (2012). Artificial intelligence. *Wiley Interdisciplinary Reviews: Computational Statistics*, *4*(2), 168–180. <https://doi.org/10.1002/wics.200>
- Teixeira, L. O., Pereira, R. M., Bertolini, D., Oliveira, L. S., Nanni, L., Cavalcanti, G. D. C., & Costa, Y. M. G. (2021). Impact of lung segmentation on the diagnosis and explanation of covid-19 in chest x-ray images. *Sensors*, *21*(21). <https://doi.org/10.3390/s21217116>
- Tenali, N., & Babu, G. R. M. (2023). HQDCNet: Hybrid Quantum Dilated Convolution Neural Network for detecting covid-19 in the context of Big Data Analytics. *Multimedia Tools and Applications*. <https://doi.org/10.1007/s11042-023-15515-6>
- Teuwen, J., & Moriakov, N. (2019). Convolutional neural networks. In *Handbook of Medical Image Computing and Computer Assisted Intervention* (pp. 481–501). Elsevier. <https://doi.org/10.1016/B978-0-12-816176-0.00025-9>
- Vancheri, S. G., Savietto, G., Ballati, F., Maggi, A., Canino, C., Bortolotto, C., Valentini, A., Dore, R., Giulia, & Stella, M., Angelo, & Corsico, G., Iotti, G. A.,

- Mojoli, F., Perlini, S., Bruno, R., & Preda, L. (2020). *Radiographic findings in 240 patients with COVID-19 pneumonia: time-dependence after the onset of symptoms*. <https://doi.org/10.1007/s00330-020-06967-7>/Published
- Verma, M. (2018). Artificial intelligence and its scope in different areas with special reference to the field of education. In *International Journal of Advanced Educational Research 5 International Journal of Advanced Educational Research* (Vol. 3). www.educationjournal.org
- Wong, H. Y. F., Lam, H. Y. S., Fong, A. H. T., Leung, S. T., Chin, T. W. Y., Lo, C. S. Y., Lui, M. M. S., Lee, J. C. Y., Chiu, K. W. H., Chung, T. W. H., Lee, E. Y. P., Wan, E. Y. F., Hung, I. F. N., Lam, T. P. W., Kuo, M. D., & Ng, M. Y. (2020). Frequency and Distribution of Chest Radiographic Findings in Patients Positive for COVID-19. *Radiology*, 296(2), E72–E78. <https://doi.org/10.1148/radiol.2020201160>
- Wong, W. Y., Hasikin, K., Khairuddin, A. S. M., Razak, S. A., Hizaddin, H. F., Mokhtar, M. I., & Azizan, M. M. (2023). A Stacked Ensemble Deep Learning Approach for Imbalanced Multi-Class Water Quality Index Prediction. *Computers, Materials and Continua*, 76(2), 1361–1384. <https://doi.org/10.32604/cmc.2023.038045>
- Wu, F., Zhao, S., Yu, B., Chen, Y. M., Wang, W., Song, Z. G., Hu, Y., Tao, Z. W., Tian, J. H., Pei, Y. Y., Yuan, M. L., Zhang, Y. L., Dai, F. H., Liu, Y., Wang, Q. M., Zheng, J. J., Xu, L., Holmes, E. C., & Zhang, Y. Z. (2020). A new coronavirus associated with human respiratory disease in China. *Nature*, 579(7798), 265–269. <https://doi.org/10.1038/s41586-020-2008-3>
- Yamashita, R., Nishio, M., Do, R. K. G., & Togashi, K. (2018). Convolutional neural networks: an overview and application in radiology. In *Insights into Imaging* (Vol. 9, Issue 4, pp. 611–629). Springer Verlag. <https://doi.org/10.1007/s13244-018-0639-9>
- Yulia, N. (2020). *Anatomi Fisiologi*.
- Zhang, J., Xie, Y., Pang, G., Liao, Z., Verjans, J., Li, W., Sun, Z., He, J., Li, Y., Shen, C., & Xia, Y. (2021). Viral Pneumonia Screening on Chest X-Rays Using Confidence-Aware Anomaly Detection. *IEEE Transactions on Medical Imaging*, 40(3), 879–890. <https://doi.org/10.1109/TMI.2020.3040950>